

机器学习笔记

F.Z.

2026 年 8 月 18 日

目录

第一部分 统计学基础	23
第一章 概率论回顾	25
1.1 随机变量与分布	25
1.1.1 离散随机变量	25
1.1.2 连续随机变量	25
1.1.3 常见分布	25
1.2 条件概率与独立性	26
1.3 矩与特征	26
1.3.1 Pearson 与 Spearman 相关系数	26
第二章 样本及抽样分布	29
2.1 随机样本	29
2.1.1 总体与样本	29
2.1.2 常用统计量	32
2.2 直方图和箱线图	34
2.2.1 直方图	34
2.2.2 箱线图	35
2.2.3 经验分布函数	36
2.3 抽样分布	36
2.3.1 χ^2 分布 (卡方分布)	36
2.3.2 t 分布 (学生氏分布)	43
2.3.3 F 分布	51
2.3.4 正态总体的抽样分布定理 (核心定理)	56
第三章 参数估计	59
3.1 点估计	59
3.1.1 矩估计法	59
3.1.2 极大似然估计 (MLE)	59
3.1.3 最大后验估计 (MAP)	67

3.2	基于截尾样本的最大似然估计	68
3.2.1	定时截尾	68
3.2.2	定数截尾	68
3.2.3	指数分布截尾样本的 MLE	68
3.3	估计量的评选标准	68
3.3.1	无偏性	68
3.3.2	有效性	69
3.3.3	相合性（一致性）	69
3.3.4	均方误差（综合评价）	69
3.4	区间估计	69
3.4.1	基本概念	69
3.4.2	枢轴量法（构造置信区间的通用方法）	70
3.5	正态总体均值与方差的区间估计	70
3.5.1	单个正态总体均值的置信区间	70
3.5.2	单个正态总体方差的置信区间	70
3.5.3	两个正态总体均值差的置信区间	71
3.5.4	两个正态总体方差比的置信区间	71
3.6	(0-1) 分布参数的区间估计	71
3.7	单侧置信区间	72
第四章	假设检验	73
4.1	假设检验的基本概念	73
4.1.1	假设检验问题	73
4.1.2	两类错误	73
4.1.3	拒绝域与检验统计量	74
4.2	正态总体均值的假设检验	74
4.2.1	单个正态总体均值的检验	74
4.2.2	两个正态总体均值差的检验	75
4.2.3	配对数据的 t 检验	75
4.3	正态总体方差的假设检验	76
4.3.1	单个正态总体方差的检验— χ^2 检验	76
4.3.2	两个正态总体方差比的检验— F 检验	76
4.4	置信区间与假设检验之间的关系	76
4.5	样本容量的选取	77
4.5.1	Z 检验的样本容量	77
4.5.2	t 检验的样本容量	77
4.5.3	影响样本容量的因素	78
4.6	分布拟合检验	78

4.6.1	χ^2 拟合优度检验	78
4.6.2	正态性检验概述	79
4.7	秩和检验	79
4.7.1	Wilcoxon 秩和检验（两独立样本）	79
4.7.2	Wilcoxon 符号秩检验（配对样本）	81
4.8	假设检验问题的 p 值检验法	84
4.8.1	p 值的定义	84
4.8.2	p 值的解释	84
4.8.3	p 值与置信区间的关系	85
第五章	方差分析及回归分析	89
5.1	单因素试验的方差分析	89
5.1.1	问题的提出	89
5.1.2	平方和分解	90
5.1.3	F 检验	90
5.1.4	多重比较	91
5.2	双因素试验的方差分析	92
5.2.1	无交互作用的双因素 ANOVA	92
5.2.2	有交互作用的双因素 ANOVA	94
5.3	一元线性回归	97
5.3.1	模型与假设	97
5.3.2	最小二乘估计 (OLS)	97
5.3.3	拟合优度: R^2	97
5.3.4	回归系数的假设检验	98
5.3.5	置信区间与预测区间	98
5.4	多元线性回归	99
5.4.1	模型与矩阵形式	99
5.4.2	最小二乘估计	99
5.4.3	显著性检验	100
5.4.4	多重共线性	100
5.4.5	回归诊断: 假设验证	101
5.4.6	混合效应模型简介	102
5.4.7	分位数回归 (Quantile Regression)	103
5.4.8	模型选择	104
第六章	Bootstrap 方法	107
6.1	非参数 Bootstrap 方法	107
6.1.1	基本思想	107

6.1.2	Bootstrap 标准误	107
6.1.3	Bootstrap 置信区间	108
6.1.4	为什么有放回抽样?	108
6.2	参数 Bootstrap 方法	109
6.2.1	与非参数 Bootstrap 的区别	109
6.2.2	算法	109
6.2.3	何时用哪种 Bootstrap?	110
6.2.4	Cluster Bootstrap (聚类自助法)	111
第七章	统计实践：从建模到报告	113
7.1	R^2 与 p 值的区别与联系	113
7.1.1	框架对比	113
7.1.2	为什么 R^2 很低但 p 值可以显著?	114
7.1.3	用“射击靶子”理解二者	114
7.1.4	四种组合判断表	114
7.1.5	常见误区纠正	115
7.2	因素分析的标准流程	115
7.2.1	第 1 步：相关性扫描——看方向和显著性	115
7.2.2	第 2 步：建立回归模型——量化效应大小	115
7.2.3	第 3 步：模型诊断——验证假设	116
7.2.4	第 4 步：模型改进——从简单到复杂	116
7.2.5	第 5 步：报告与解释——讲好故事	116
7.2.6	完整流程图	117
7.3	APA 学术报告规范	117
7.3.1	核心原则	117
7.3.2	常见统计量的 APA 报告格式	118
7.3.3	p 值的写法	118
7.3.4	完整报告示例	118
7.3.5	建模竞赛论文的 APA 使用要点	119
7.4	方法选择速查表	119
第八章	信息论基础	121
8.1	基本概念	121
第二部分	机器学习	123
第九章	矩阵运算与张量记号	125
9.1	迹运算	125

9.2	正定与半正定矩阵	125
9.3	矩阵求导	126
9.3.1	标量对向量的导数	126
9.3.2	标量对矩阵的导数	127
9.3.3	向量对向量的导数（雅可比矩阵）	127
9.4	张量分析的指标记号	127
9.4.1	Einstein 求和约定	127
9.4.2	Kronecker δ 符号	128
9.4.3	偏导数的指标写法	128
9.4.4	矩阵对标量的导数	129
9.4.5	何时用矩阵记号，何时用指标记号	129
9.5	谱分解与奇异值分解 (SVD)	130
9.5.1	对称矩阵的谱分解	130
9.5.2	奇异值分解 (SVD)	130
9.6	矩阵范数	131
9.7	关键恒等式	131
9.7.1	Woodbury 矩阵求逆公式	131
9.7.2	矩阵求逆引理（Woodbury 的特例）	131
9.7.3	期望的二次型	132
第十章	统计学习导论	133
10.1	监督学习的数学框架	133
10.1.1	基本设定	133
10.1.2	损失函数	133
10.1.3	期望风险与经验风险	134
10.1.4	EPE 与 ERM：理想与现实的桥梁	134
10.1.5	最优预测器：回归函数	136
10.1.6	两种建模策略	139
10.1.7	完整示例：从数据到预测	139
10.1.8	理论回看：从最优预测器到实际估计器	144
10.1.9	统计学习 vs 经典统计：两种推理框架	146
10.2	无监督学习的数学框架	147
10.2.1	基本设定	147
10.2.2	聚类	148
10.2.3	密度估计	148
10.2.4	降维	148
10.3	监督学习与无监督学习的对比	149
10.4	维数灾难与高维空间中的局部方法	149

10.4.1	单位超立方体中的邻域	149
10.4.2	期望邻域边长	150
10.4.3	1-NN 的偏差-方差分解（高维示例）	150
10.4.4	线性模型 vs 1-NN：高维下的 EPE 对比	151
10.4.5	维数灾难的形式化定义与启示	152
10.5	统计学习的基本框架：从模型到估计	152
10.5.1	加性误差模型与条件期望	152
10.5.2	条件方差：为什么可以不是常数	154
10.5.3	期望预测误差与最优预测器	154
10.5.4	监督学习的数学表述	155
10.5.5	函数逼近视角	155
10.5.6	参数估计 I：最小二乘法	156
10.5.7	参数估计 II：极大似然估计	157
10.5.8	参数估计 III：从 EPE 到 ERM	158
10.5.9	无约束最小化的根本困境	159
10.5.10	受限制的估计量：几类经典方法	160
10.5.11	模型选择与偏差-方差权衡	165
10.5.12	总结：从模型到估计的统一框架	170
第十一章	线性回归模型与最小二乘法	173
11.1	引言：为什么从线性模型开始	173
11.2	线性回归模型	173
11.2.1	模型形式	173
11.2.2	输入的来源	174
11.2.3	矩阵记号	174
11.3	最小二乘估计	175
11.3.1	残差平方和	175
11.3.2	矩阵形式的解	175
11.3.3	拟合值与 Hat Matrix	178
11.3.4	几何解释	179
11.4	估计量的抽样性质	179
11.4.1	一阶矩与二阶矩的假设	179
11.4.2	三层限制：从模型选择到无偏性的逻辑链	182
11.4.3	深入理解：固定设计与随机设计	184
11.4.4	条件推断：实践中你真正在做的事	187
11.4.5	σ^2 的无偏估计	191
11.4.6	单个系数的方差	191
11.5	正态假设下的推断	191

11.5.1 正态误差假设	192
11.5.2 $\hat{\beta}$ 的抽样分布	192
11.5.3 单个系数的检验: t 检验到底在检验什么?	192
11.5.4 置信区间与显著性检验	196
11.5.5 进一步可检验的假设	197
11.5.6 F 检验与嵌套模型比较	197
11.5.7 联合置信域	198
11.6 高斯-马尔可夫定理	198
11.6.1 定理陈述与意义	198
11.6.2 MSE 分解: 偏差-方差视角	199
11.7 预测误差的分解	199
11.7.1 新观测的预测	200
11.7.2 期望预测误差 (Expected Prediction Error)	200
11.7.3 训练误差 vs 预测误差	200
11.8 多元回归作为单变量回归的叠加	201
11.8.1 单变量回归的最小二乘	201
11.8.2 有截距时的处理	201
11.8.3 推广到多元: 正交化 (Gram-Schmidt)	201
11.8.4 直观理解	202
11.8.5 QR 分解: 从 Gram-Schmidt 到数值计算	202
11.9 多输出回归 (Multiple Outputs)	204
11.9.1 模型形式	204
11.9.2 矩阵形式	205
11.9.3 最小二乘估计	205
11.9.4 当误差跨输出相关时	205
11.10 实例: 前列腺癌数据	206
11.10.1 变量说明	206
11.10.2 预测变量的相关矩阵	207
11.10.3 全模型回归结果	207
11.10.4 F 检验: 小模型 vs 大模型	208
11.11 完整示例: 手算一个线性回归	208
11.11.1 数据与模型	208
11.11.2 Step 1: 估计 $\hat{\beta}$	209
11.11.3 Step 2: 拟合值与残差	209
11.11.4 Step 3: σ^2 的无偏估计	210
11.11.5 Step 4: 系数的标准误与 t 检验	210
11.11.6 Step 5: F 检验——小模型 vs 大模型	210

11.11.7 Step 6: R^2 与模型解释力	211
11.11.8 Step 7: 95% 置信区间	211
11.11.9 Step 8: 预测新观测	212
11.11.10 总结: 从这个例子学到了什么	212
11.12 子集选择与系数收缩	212
11.12.1 为什么要超越最小二乘?	213
11.12.2 最优子集选择 (Best-Subset Selection)	213
11.12.3 逐步选择 (Stepwise Selection)	214
11.12.4 前向分段回归 (Forward-Stagewise Regression)	216
11.12.5 小结: 子集选择的统一视角	217
11.13 收缩方法 (Shrinkage Methods)	218
11.13.1 前列腺癌实例回顾	218
11.13.2 岭回归 (Ridge Regression)	219
11.13.3 岭回归的 SVD 视角	220
11.13.4 主成分与方差方向	222
11.13.5 有效自由度	222
11.13.6 Lasso	222
11.13.7 正交输入情形下的统一视角	223
11.13.8 几何直观: $p = 2$ 时的图形比较	225
11.13.9 一般 L_q 惩罚与贝叶斯统一视角	226
11.13.10 弹性网 (Elastic Net)	228
11.13.11 最小角回归 (LAR)——Lasso 的高效算法	229
11.13.12 小结: 收缩方法谱系	230
11.14 使用导出输入方向的方法 (Derived Input Directions)	230
11.14.1 主成分回归 (PCR)	230
11.14.2 偏最小二乘 (PLS)	231
11.14.3 PCR 与 PLS 的优化问题	231
11.14.4 深入理解 PLS: 正交投影、实例与动机	232
11.15 选择与收缩方法的比较 (Discussion)	237
11.16 多输出收缩与选择	238
11.16.1 典型相关分析 (CCA)	239
11.16.2 降秩回归 (Reduced-Rank Regression)	245
11.16.3 Curds & Whey 收缩	246
11.17 Lasso 深入与路径算法	248
11.17.1 增量前向分段回归 (Incremental Forward Stagewise, FS)	248
11.17.2 分段线性路径算法	249
11.17.3 Dantzig 选择器	249

11.17.4 分组 Lasso (Grouped Lasso)	249
11.17.5 Lasso 的进一步性质	251
11.17.6 路径坐标优化 (Pathwise Coordinate Descent)	252
11.18 计算考量	252
11.19 小结	253
第十二章 分类的线性方法	259
12.1 引言	259
12.1.1 判别函数方法	261
12.1.2 Logit 变换与 Logistic 模型	261
12.1.3 实操流程：从线性函数到分类决策	264
12.1.4 基展开：从线性到非线性	265
12.1.5 本章对 f 的核心限制	265
12.2 指示矩阵的线性回归	266
12.2.1 模型设定	266
12.2.2 理论依据	267
12.2.3 最近目标分类视角	267
12.2.4 完整数值示例 ($N = 5, K = 3, p = 1$)	267
12.2.5 Masking 问题	269
12.2.6 Masking 数值演示 ($N = 5, K = 3, p = 1$)	269
12.3 线性判别分析 (LDA)	273
12.3.1 Bayes 分类框架	273
12.3.2 Gaussian 假设下的 LDA	278
12.3.3 线性判别函数	278
12.3.4 参数估计	278
12.3.5 二分类 LDA 与最小二乘的对应	278
12.4 二次判别分析 (QDA)	279
12.4.1 参数数量	279
12.4.2 LDA 与 QDA 的性能讨论	279
12.5 正则化判别分析 (RDA)	279
12.5.1 模型形式	280
12.6 LDA 的计算	280
12.6.1 对角化方法	280
12.6.2 LDA 的球形化实现	280
12.7 降秩线性判别分析	282
12.7.1 动机：质心在低维仿射子空间中	282
12.7.2 Fisher 的判别准则	282
12.7.3 LDA 子空间的计算步骤	284

12.7.4 用于分类与降维	284
12.7.5 Fisher 方法与 Gaussian LDA 的等价性	284
12.7.6 总结	285
12.8 几何视角: W^{-1} -内积空间中的 LDA 与 Fisher	285
12.8.1 W^{-1} -内积空间	285
12.8.2 标准内积 vs W^{-1} -内积	286
12.8.3 在此框架下重新理解 LDA	286
12.8.4 在此框架下重新理解 Fisher	286
12.8.5 球形化的几何意义	287
12.8.6 统一视角总结	287
12.9 Logistic 回归	287
12.9.1 回到判别函数与 EPE 框架	287
12.9.2 模型设定	288
12.9.3 拟合: 最大似然与 IRLS	289
12.9.4 示例: 南非心脏病数据	290
12.9.5 二次近似与推断	290
12.9.6 L_1 正则化 Logistic 回归	293
12.9.7 Logistic 回归还是 LDA?	294
12.9.8 LDA 和 Logistic 回归总结	295
12.10 分离超平面	295
12.10.1 超平面的线性代数	295
12.10.2 Rosenblatt 感知机学习算法	295
12.10.3 最优分离超平面	297
12.11 本章小结	299
第十三章 基展开与正则化	301
13.1 引言	301
13.1.1 两种突破线性的思路: 参数化 vs 非参数化	301
13.1.2 核心思想: 变换输入空间	302
13.1.3 常见基函数示例	302
13.1.4 复杂度的控制	302
13.2 分段多项式与样条	303
13.2.1 分段常数与分段线性	303
13.2.2 截断幂基	303
13.2.3 三次样条 (Cubic Spline)	305
13.2.4 一般阶样条	305
13.2.5 节点选择	307
13.2.6 自然三次样条	309

13.2.7 样条方法概览	310
13.2.8 示例：南非心脏病数据（续）	311
13.2.9 示例：音素识别	316
13.3 滤波与特征提取	317
13.4 光滑样条	317
13.4.1 惩罚残差平方和	318
13.4.2 有限维解	318
13.4.3 完整示例：光滑样条的符号化流程	319
13.4.4 自由度与光滑矩阵	321
13.5 光滑参数的自动选择	322
13.5.1 用有效自由度参数化	322
13.5.2 偏差-方差权衡	322
13.5.3 交叉验证 (CV)	325
13.6 非参数 Logistic 回归	325
13.7 多维样条	326
13.7.1 张量积基	326
13.7.2 薄板样条 (Thin-Plate Splines)	329
13.7.3 加性样条与 ANOVA 分解	329
13.7.4 小结：从一维到多维的选择路线	330
13.8 正则化与再生核 Hilbert 空间 (RKHS)	330
13.8.1 一般形式	330
13.8.2 RKHS 与核方法	331
13.8.3 实例	334
13.8.4 实践指南：何时使用核方法	334
13.9 小波光滑	336
13.9.1 核心思想：时间-频率定位	336
13.9.2 多分辨率分析	336
13.9.3 小波变换的数学定义	337
13.9.4 自适应小波阈值 (Wavelet Shrinkage)	338
13.9.5 小波 vs 光滑样条（图 5.19）	338
13.10 本章小结	341
第十四章 核光滑方法	343
14.1 一维核光滑器	343
14.1.1 从 k -最近邻平均到核加权平均	343
14.1.2 核函数的形式	345
14.1.3 三种常用核	345
14.1.4 实践中的注意事项	345

14.2 局部线性回归	346
14.2.1 边界偏差问题	346
14.2.2 局部加权最小二乘	346
14.2.3 矩阵形式与等价核	346
14.2.4 自动核木工 (Automatic Kernel Carpentry)	347
14.3 局部多项式回归	348
14.3.1 d 阶局部多项式拟合	348
14.3.2 削峰填谷效应	349
14.3.3 偏差-方差权衡	349
14.3.4 奇数阶 vs 偶数阶: 实践建议	349
14.4 核宽度的选择	350
14.4.1 λ 在不同核中的含义	350
14.4.2 偏差-方差权衡与窗宽	350
14.4.3 线性估计量与光滑矩阵	350
14.4.4 有效自由度	351
14.5 $\mathbb{R}^p$ 中的局部回归	351
14.5.1 多项式向量与径向核	352
14.5.2 高维中的边界问题与维数灾难	352
14.6 $\mathbb{R}^p$ 中的结构化局部回归模型	353
14.6.1 结构化核	353
14.6.2 结构化回归函数	353
14.6.3 变系数模型	354
14.7 局部似然与其他模型	354
14.7.1 局部似然	354
14.7.2 局部自回归时间序列	354
14.7.3 局部多类 Logistic 回归	355
14.8 核密度估计与分类	355
14.8.1 核密度估计	355
14.8.2 核密度分类	356
14.8.3 朴素 Bayes 分类器	356
14.9 径向基函数与核	357
14.10 混合模型用于密度估计与分类	358
14.11 计算考量	358
第十五章 模型评估与选择	361
15.1 引言	361
15.2 偏差、方差与模型复杂度	361
15.2.1 定量响应情形	361

15.2.2 定性响应情形	364
15.2.3 模型选择 vs 模型评估	364
15.3 偏差-方差分解	365
15.3.1 k -最近邻回归的偏差-方差分解	365
15.3.2 线性回归的偏差-方差分解	366
15.3.3 岭回归的偏差分解	366
15.3.4 示例：偏差-方差权衡	366
15.4 训练误差的乐观性	369
15.4.1 泛化误差、期望误差与样本内误差	369
15.4.2 乐观性及其性质	370
15.4.3 线性拟合的特殊情形	371
15.5 样本内预测误差的估计	372
15.5.1 C_p 统计量	372
15.5.2 AIC 准则	372
15.5.3 AIC 的实践使用	373
15.6 有效参数个数	373
15.6.1 线性拟合方法的有效自由度	373
15.6.2 神经网络的有效参数个数	374
15.7 贝叶斯方法与 BIC	374
15.7.1 BIC 的定义	374
15.7.2 BIC 的贝叶斯推导	374
15.7.3 AIC 与 BIC 的比较	375
15.8 最小描述长度	376
15.8.1 编码与熵	376
15.8.2 MDL 用于模型选择	376
15.9 Vapnik–Chervonenkis 维	376
15.9.1 打散与 VC 维定义	376
15.9.2 VC 界与结构风险最小化	377
15.9.3 示例：AIC、BIC、SRM 的比较	377
15.10 交叉验证	377
15.10.1 K 折交叉验证	379
15.10.2 K 的选择：偏差-方差权衡	380
15.10.3 广义交叉验证 (GCV)	380
15.10.4 交叉验证的正确与错误做法	381
15.10.5 交叉验证真的有效吗？——高维示例	384
15.11 自助法 (Bootstrap)	384
15.11.1 基本思想	384

15.11.2 Bootstrap 估计预测误差	386
15.11.3 示例：CV 与 Bootstrap 比较	387
15.12 条件误差还是期望误差？	388
15.13 本章小结	389
15.13.1 核心框架	389
15.13.2 方法选用指南	390
15.13.3 关键结论	390
第十六章 模型推断与平均	393
16.1 引言	393
16.2 Bootstrap 与最大似然方法	393
16.2.1 一个光滑示例	393
16.2.2 非参数 Bootstrap 与参数 Bootstrap	394
16.2.3 最大似然推断	396
16.2.4 Bootstrap 与最大似然的比较	401
16.3 贝叶斯方法	402
16.3.1 基本框架	402
16.3.2 光滑示例的贝叶斯分析	404
16.3.3 Bootstrap 与贝叶斯推断的正式关系	404
16.3.4 Bootstrap 用法总览	405
16.4 EM 算法	406
16.4.1 两分量高斯混合模型	406
16.4.2 EM 算法的一般形式	407
16.5 MCMC：从后验抽样	408
16.5.1 背景与动机：为什么需要从后验分布抽样？	408
16.5.2 先验如何作用：后验是「先验 $\times$ 似然」的目标分布	409
16.5.3 马尔可夫性质：如何体现？	410
16.5.4 为什么联合分布最终稳定？	411
16.5.5 一个具体的 Gibbs 采样例子	411
16.5.6 Gibbs 采样	412
16.5.7 MCMC 的实践：有限步收敛与诊断	414
16.6 Bagging	415
16.6.1 分类情形：投票 vs 平均概率	415
16.6.2 例：树与模拟数据	415
16.6.3 Bagging 为什么有效	416
16.7 模型平均与 Stacking	418
16.7.1 频率学派视角	419
16.7.2 Stacking	420

16.7.3 小结：模型组合方法的谱系	420
16.8 随机搜索：Bumping	422
16.9 本章小结	423
16.9.1 核心框架：两条主线	423
16.9.2 方法选用指南	424
16.9.3 关键结论	424
第十七章 加性模型、树及相关方法	427
17.1 广义加性模型	427
17.1.1 模型定义	427
17.1.2 拟合加性模型：Backfitting	428
17.1.3 例：加性 logistic 回归（spam 数据）	432
17.1.4 小结	433
17.2 基于树的方法	434
17.2.1 背景	434
17.2.2 回归树	436
17.2.3 分类树	438
17.2.4 其他问题	439
17.2.5 分类性能评估统计量	440
17.3 PRIM：Bump Hunting	442
17.4 MARS：多元自适应回归样条	445
17.5 专家分层混合（HME）	448
17.6 缺失数据	452
17.7 计算考虑	454
17.8 本章总结：加性模型、树及相关方法	454
17.8.1 核心主题	454
17.8.2 五种方法的对比	455
17.8.3 关键结论	455
第十八章 提升与加性树（Boosting and Additive Trees）	457
18.1 Boosting 方法	457
18.1.1 本章概览	459
18.2 Boosting 拟合加性模型	460
18.3 前向分阶段加性建模	461
18.4 指数损失与 AdaBoost	462
18.5 为什么用指数损失	464
18.6 损失函数与稳健性	464
18.6.1 平方误差损失不适合分类	466

18.6.2 K 类分类的损失	466
18.6.3 回归的稳健损失	467
18.7 数据挖掘的「现成」程序	469
18.8 Boosting 树	471
18.9 通过梯度提升的数值优化	473
18.9.1 最速下降	474
18.9.2 梯度提升	476
18.9.3 梯度提升的实现	477
18.10 提升树的合适大小	478
18.11 正则化	479
18.11.1 收缩	479
18.11.2 子采样	479
18.12 解释	480
18.12.1 预测变量的相对重要性	480
18.12.2 部分依赖图	481
18.12.3 解释工具的谱系：树特有 vs 模型无关	482
18.13 示例	483
18.13.1 California Housing	483
18.13.2 New Zealand Fish	484
18.13.3 Demographics Data	484
18.14 本章总结	485
18.14.1 核心结论	485
第十九章 Neural Networks（神经网络）	487
19.1 引言	487
19.2 投影寻踪回归 (Projection Pursuit Regression, PPR)	487
19.2.1 PPR 的拟合算法	489
19.3 神经网络	491
19.4 拟合神经网络	492
19.4.1 误差函数	492
19.4.2 反向传播 (Back-Propagation)	494
19.4.3 Batch 学习与在线学习	497
19.5 训练神经网络的若干问题	497
19.5.1 起始值 (Starting Values)	497
19.5.2 过拟合 (Overfitting)	497
19.5.3 输入的缩放 (Scaling of the Inputs)	498
19.5.4 隐藏单元数与层数 (Number of Hidden Units and Layers)	498
19.5.5 多重极小 (Multiple Minima)	498

19.6 模拟数据例子 (Example: Simulated Data)	498
19.7 ZIP 码数据例子 (Example: ZIP Code Data)	500
19.8 讨论 (Discussion)	502
19.9 贝叶斯神经网络与 NIPS 2003 挑战	502
19.9.1 Bayes、Boosting 与 Bagging	503
19.9.2 性能比较	508
19.10 计算考虑 (Computational Considerations)	508
19.11 本章小结	509
19.11.1 核心框架	509
19.11.2 要点回顾	509

第二十章 Support Vector Machines and Flexible Discriminants (支持向量机与灵活判别)	511
20.1 引言	511
20.2 支持向量分类器	511
20.2.1 计算支持向量分类器	513
20.2.2 混合示例 (续)	514
20.3 支持向量机与核	515
20.3.1 计算用于分类的 SVM	515
20.3.2 SVM 作为惩罚方法	517
20.3.3 函数估计与再生核 (Function Estimation and Reproducing Kernels)	518
20.3.4 SVM 与维数灾难	519
20.3.5 SVM 分类器的路径算法	522
20.3.6 支持向量机用于回归	523
20.3.7 回归与核	524
20.3.8 讨论	525
20.4 推广线性判别分析 (Generalizing Linear Discriminant Analysis)	526
20.5 灵活判别分析 (Flexible Discriminant Analysis, FDA)	527
20.5.1 计算 FDA 估计	530
20.6 惩罚判别分析 (Penalized Discriminant Analysis, PDA)	532
20.7 混合判别分析 (Mixture Discriminant Analysis, MDA)	534
20.7.1 示例: 波形数据 (Waveform Data)	537
20.8 计算考虑	538
20.9 本章总结	538

第二十一章 Prototype Methods and Nearest-Neighbors (原型方法与最近邻)	541
21.1 引言	541

21.2 原型方法	541
21.2.1 K-means 聚类	543
21.2.2 学习向量量化 (LVQ)	544
21.2.3 高斯混合	544
21.3 k-最近邻分类器	546
21.3.1 示例：比较研究	547
21.3.2 示例：k-最近邻与图像场景分类	548
21.3.3 不变度量与切向距离	548
21.4 自适应最近邻方法	550
21.4.1 示例	551
21.4.2 最近邻的全局降维	551
21.5 计算考虑	552
21.6 本章总结	553
第二十二章 Unsupervised Learning (非监督学习)	555
22.1 引言	555
22.2 关联规则	556
22.2.1 市场篮子分析	557
22.2.2 Apriori 算法	559
22.2.3 示例：市场篮子分析	562
22.2.4 非监督转化为监督学习	563
22.2.5 广义关联规则	566
22.2.6 监督学习方法的选择	567
22.2.7 示例：市场篮子分析 (续)	567
22.3 聚类分析	568
22.3.1 邻近矩阵	569
22.3.2 基于属性的不相似性	570
22.3.3 对象不相似性	571
22.3.4 聚类算法	572
22.3.5 组合算法	572
22.3.6 K-means	573
22.3.7 高斯混合作为软 K-means	574
22.3.8 示例：人类肿瘤微阵列数据	575
22.3.9 向量量化	575
22.3.10 K-medoids	576
22.3.11 实际问题	577
22.3.12 层次聚类	579
22.4 自组织映射	582

22.5 主成分、主曲线与主曲面	583
22.5.1 主成分	583
22.5.2 主曲线与主曲面	586
22.5.3 谱聚类	587
22.5.4 核主成分	588
22.5.5 稀疏主成分	589

第一部分

统计学基础

第一章 概率论回顾

1.1 随机变量与分布

1.1.1 离散随机变量

定义 1.1 (概率质量函数). 对于离散随机变量 X , 其概率质量函数 (PMF) $p(x)$ 满足:

$$p(x) = P(X = x), \quad \sum_x p(x) = 1. \quad (1.1)$$

定义 1.2 (期望). 离散随机变量 X 的期望定义为:

$$\mathbb{E}[X] = \sum_x x p(x). \quad (1.2)$$

定义 1.3 (方差). 随机变量 X 的方差定义为:

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2. \quad (1.3)$$

1.1.2 连续随机变量

定义 1.4 (概率密度函数). 对于连续随机变量 X , 其概率密度函数 (PDF) $f(x)$ 满足:

$$P(a \leq X \leq b) = \int_a^b f(x) dx, \quad \int_{-\infty}^{\infty} f(x) dx = 1. \quad (1.4)$$

定义 1.5 (期望与方差). 连续随机变量 X 的期望与方差:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f(x) dx, \quad (1.5)$$

$$\text{Var}(X) = \int_{-\infty}^{\infty} (x - \mathbb{E}[X])^2 f(x) dx. \quad (1.6)$$

1.1.3 常见分布

(1) 二项分布 $X \sim \text{Binomial}(n, p)$:

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad \mathbb{E}[X] = np, \quad \text{Var}(X) = np(1-p). \quad (1.7)$$

(2) 泊松分布 $X \sim \text{Poisson}(\lambda)$:

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad \mathbb{E}[X] = \lambda, \quad \text{Var}(X) = \lambda. \quad (1.8)$$

(3) 正态分布 $X \sim \mathcal{N}(\mu, \sigma^2)$:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right). \quad (1.9)$$

(4) 多元正态分布 $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$:

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right). \quad (1.10)$$

1.2 条件概率与独立性

定义 1.6 (条件概率). 事件 A 在事件 B 发生条件下的概率:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0. \quad (1.11)$$

定理 1.1 (贝叶斯公式).

$$P(B_k | A) = \frac{P(A | B_k)P(B_k)}{\sum_i P(A | B_i)P(B_i)}. \quad (1.12)$$

定义 1.7 (独立性). 若 $P(A \cap B) = P(A)P(B)$, 则事件 A 与 B 独立。

1.3 矩与特征

定义 1.8 (协方差). 随机变量 X 与 Y 的协方差:

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]. \quad (1.13)$$

定义 1.9 (相关系数).

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}} \in [-1, 1]. \quad (1.14)$$

1.3.1 Pearson 与 Spearman 相关系数

上面定义的是理论上的 (总体) 相关系数 ρ 。实际中, 我们需要用样本数据估计它, 常用的有两种: Pearson 和 Spearman。

定义 1.10 (Pearson 相关系数 r). 样本 Pearson 相关系数度量的是线性相关程度:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}. \quad (1.15)$$

定义 1.11 (Spearman 秩相关系数 ρ_s). 将原始数据 x_i, y_i 分别替换为它们在各自序列中的排名（秩），然后对排名计算 Pearson 相关系数，即得 Spearman 相关系数。

等价公式（无结时）：

$$\rho_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}, \quad (1.16)$$

其中 d_i 为第 i 对数据的 x 排名与 y 排名之差。

定义 1.12 (Kendall 秩相关系数 τ). Kendall's τ 同样基于排名，但计算逻辑不同——它统计的是一致对与不一致对的数量。

对任意两对观测 (x_i, y_i) 和 (x_j, y_j) ($i < j$):

- 若 $(x_i - x_j)(y_i - y_j) > 0$: **一致对**（两变量同方向变化）
- 若 $(x_i - x_j)(y_i - y_j) < 0$: **不一致对**（两变量反方向变化）

令 n_c 为一致对数， n_d 为不一致对数，则：

$$\tau = \frac{n_c - n_d}{\frac{1}{2}n(n-1)}. \quad (1.17)$$

$\tau = 1$: 所有对都一致（完美正相关）； $\tau = -1$: 所有对都不一致（完美负相关）。

三者对比：

	Pearson r	Spearman ρ_s	Kendall τ
度量什么	线性相关程度	单调相关程度	排序一致程度
计算方式	原始值	原始值的 排名	一致对 vs 不一致对
对异常值	敏感	稳健	最稳健
对结（ties）	无影响	需要修正公式	天然处理结
样本效率	最高	中等	较低（需更多样本）
适用场景	近似正态、线性	非正态、单调	小样本、多结、定序数据

使用规则：

- 先画散点图。如果散点大致沿一条直线分布 → 用 Pearson；
- 如果散点呈曲线但有单调趋势 → 用 Spearman；
- 数据有严重离群值或明显不正态 → Spearman 或 Kendall；
- 样本量小（ $n < 30$ ）、有很多重复值（结）→ 优先 Kendall；

- **最佳实践：**三者都算。若结论一致（如都显著且方向相同），说明相关性结论**稳健**，可放心报告 Pearson。

r 与 r^2 的区别：

	r （相关系数）	r^2 （决定系数）
范围	$[-1, 1]$ （有方向）	$[0, 1]$ （无方向）
含义	方向和强度	变异解释比例
例子	$r = -0.5$ 表示中等负相关	$r^2 = 0.25$ 表示 X 解释了 Y 25% 的变异
关系	$r^2 = r \times r$ （仅在一元回归中等价于 R^2 ）	

注意：

- r^2 只在**一元线性回归**中等价于第 9 章定义的 R^2 ；
- 多元回归的 R^2 是所有自变量共同解释的比例，不是某个 r 的平方。

第二章 样本及抽样分布

2.1 随机样本

2.1.1 总体与样本

定义 2.1 (总体与个体). 总体（母体）是研究对象的全体，通常用一个随机变量 X 表示，其分布函数为 $F(x)$ 。个体是组成总体的每个元素。

定义 2.2 (简单随机样本). 设 X 是具有分布函数 F 的随机变量，若 $X_1, X_2, \dots, X_n$ 满足：

(i) **代表性**：每个 X_i 与 X 有相同的分布函数 F ；

(ii) **独立性**： $X_1, X_2, \dots, X_n$ 相互独立，

则称为来自总体 X 的容量为 n 的简单随机样本，简称样本。记作：

$$X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F(x). \quad (2.1)$$

当获得一组具体观测值 $x_1, x_2, \dots, x_n$ 时，称其为样本值。

注记 2.1 (总体、个体、样本：用三组例子建立直觉). ”总体”不是物理对象的集合，而是你关心的那个量在所有个体上的取值及其概率规律。

实际问题	总体（随机变量 X ）	个体	样本（ n 个个体的观测值）
评估灯泡寿命	这批灯泡的寿命值及其分布	每只灯泡	随机抽 n 只灯泡，测出其寿命 $x_1, \dots, x_n$
了解居民收入	某市所有居民的年收入分布	每位居民	随机调查 n 位居民的年收入 $x_1, \dots, x_n$
监控螺栓直径	某产线所有螺栓的直径分布	每个螺栓	随机抽取 n 个螺栓，测出直径 $x_1, \dots, x_n$

注意”样本”一词的双重含义：

语境	含义	记号
抽样前（理论上）	n 个随机变量，各与总体同分布且相互独立 做实验得到的 n 个具体数字	大写 $X_1, \dots, X_n$
抽样后（实际上）		小写 $x_1, \dots, x_n$

例如 $\bar{X} = \frac{1}{n} \sum X_i$ 是随机变量（统计量），而 $\bar{x} = \frac{1}{n} \sum x_i$ 是一个具体数值。整个统计推断的逻辑链是：用已知的 $\bar{x}$ 去反推未知的 μ ，中间桥梁是 $\bar{X}$ 的抽样分布。

注记 2.2（“简单随机样本”中“简单”与“随机”的含义）。**随机** = 抽样时每个个体被选入样本的概率均等，结果由概率决定而非人为挑选。

简单 = 满足两个条件：

- (i) **代表性（同分布）**：每个 X_i 与总体 X 的波动规律完全相同。
反例——第 1 个灯泡来自 A 厂、第 2 个来自不相关的 B 厂，两者分布不同，不满足同分布。
- (ii) **独立性**：知道 X_1 的取值不能提供任何关于 X_2 的信息。
反例——不放回抽样在有限总体中严格不独立，但当总体容量 $\gg n$ 时可近似视为独立。

两者本质上等价于 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F(x)$ （独立同分布样本）。

一句话区分：

术语	回答的问题
随机	谁被选入样本？——由概率决定，非人为挑选
简单	入选个体的数据有何规律？——彼此独立、同分布

从总体到统计量：四步概念梳理

以下用四步串联“总体 → 样本 → 统计量”的逻辑链条，并指出常见误区。

第 1 步 从总体中抽取一个容量为 n 的样本。

常见误区：“抽样 n 次”听起来像做了 n 轮独立实验，容易和重复抽样混淆。正确说法是：从总体 X 中一次性抽取 n 个独立同分布的个体，记作 $X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F(x)$ 。

第 2 步 每个 X_i 是独立同分布随机变量，但分布参数 μ, σ^2 未知。

在参数统计中，通常假设已知分布的形式（如正态），仅参数未知：

已知	未知
$X_i \sim \mathcal{N}(\mu, \sigma^2)$ （分布族）	μ 和 σ^2 的具体值
$X_i \sim \text{Bernoulli}(p)$	p 的具体值

如果连分布形式都不知道，那属于非参数统计的范畴。后续所有内容（MLE、 t 检验、置信区间）均建立在“已知分布族，未知参数”的前提下。

关键区分： μ 和 σ^2 是总体的均值和方差（固定但未知的常数）； $\bar{X}$ 和 S^2 是样本的均值和方差（随机变量，用来估计它们）。

第 3 步 定义样本均值 $\bar{X}$ ——第一个核心统计量。

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad (2.2)$$

注意：不是 $\hat{X}$ ！标准写法是 $\bar{X}$ ($\bar{\{X\}}$)，读作“X bar”。

$\bar{X}$ 有两个身份：

- **统计量：**抽样前是随机变量，有自己的分布 $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$
- **估计量：**用来估计总体均值 μ ，且是无偏的 ($\mathbb{E}[\bar{X}] = \mu$)


这里没有“组”的概念——“组内均值”是 ANOVA 里的术语（多组比较时组内 vs. 组间）。在单样本场景下，它就是样本均值。

第 4 步 定义样本方差 S^2 ——第二个核心统计量。

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (2.3)$$

用于刻画样本内部的离散程度（而非“组内差异”），同时也是总体方差 σ^2 的无偏估计量。分母 $n-1$ 的来源已在上一节完整推导。

四步总览：



整个数理统计的核心任务就是：用已知的 $\bar{x}$ 和 s^2 （观测值）反推未知的 μ 和 σ^2 （总体参数），而反推的依据就是 $\bar{X}$ 和 S^2 的抽样分布。

定义 2.3 (统计量). 设 $X_1, \dots, X_n$ 是来自总体 X 的样本， $g(x_1, \dots, x_n)$ 是不含任何未知参数的函数，则称

$$T = g(X_1, X_2, \dots, X_n) \quad (2.4)$$

为一个**统计量**。统计量是随机变量的函数，因此它本身也是一个随机变量。

2.1.2 常用统计量

定义 2.4 (样本均值).

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i. \quad (2.5)$$

定义 2.5 (样本方差与样本标准差).

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad (2.6)$$

$$S = \sqrt{S^2}. \quad (2.7)$$

为什么分母是 $n-1$? ——完整推导

推导目标

证明: 若用 $n-1$ 作分母, 则 $\mathbb{E}[S^2] = \sigma^2$ (无偏); 若用 n 作分母, 则估计有偏。

前提假设

设总体 X 的均值 $\mathbb{E}[X] = \mu$, 方差 $\text{Var}(X) = \sigma^2$ 。 $X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} X$, 样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 。

关键恒等式

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2. \quad (2.8)$$

验证:

$$\begin{aligned} \sum_{i=1}^n (X_i - \bar{X})^2 &= \sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2) = \sum_{i=1}^n X_i^2 - 2\bar{X} \underbrace{\sum_{i=1}^n X_i}_{=n\bar{X}} + n\bar{X}^2 \\ &= \sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2. \end{aligned}$$

逐项求期望

第一项: $\mathbb{E}[\sum X_i^2]$

对每个 X_i , 由 $\text{Var}(X_i) = \mathbb{E}[X_i^2] - (\mathbb{E}[X_i])^2$, 得:

$$\mathbb{E}[X_i^2] = \text{Var}(X_i) + (\mathbb{E}[X_i])^2 = \sigma^2 + \mu^2. \quad (2.9)$$

由于 n 个变量同分布:

$$\mathbb{E}\left[\sum_{i=1}^n X_i^2\right] = \sum_{i=1}^n \mathbb{E}[X_i^2] = n(\sigma^2 + \mu^2). \quad (2.10)$$

第二项: $\mathbb{E}[n\bar{X}^2]$

先求 $\bar{X}$ 的期望与方差:

$$\mathbb{E}[\bar{X}] = \mathbb{E}\left[\frac{1}{n} \sum X_i\right] = \frac{1}{n} \sum \mathbb{E}[X_i] = \mu, \quad (2.11)$$

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n} \sum X_i\right) = \frac{1}{n^2} \sum \text{Var}(X_i) \quad (\text{独立性}) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}. \quad (2.12)$$

于是:

$$\mathbb{E}[\bar{X}^2] = \text{Var}(\bar{X}) + (\mathbb{E}[\bar{X}])^2 = \frac{\sigma^2}{n} + \mu^2. \quad (2.13)$$

因此:

$$\mathbb{E}[n\bar{X}^2] = n \cdot \mathbb{E}[\bar{X}^2] = n \left(\frac{\sigma^2}{n} + \mu^2 \right) = \sigma^2 + n\mu^2. \quad (2.14)$$

合并得到最终结果

将式 (2.10) 与 (2.14) 代入恒等式 (2.8) 的期望:

$$\begin{aligned} \mathbb{E}\left[\sum_{i=1}^n (X_i - \bar{X})^2\right] &= \mathbb{E}\left[\sum_{i=1}^n X_i^2\right] - \mathbb{E}[n\bar{X}^2] \\ &= n(\sigma^2 + \mu^2) - (\sigma^2 + n\mu^2) \\ &= (n-1)\sigma^2. \end{aligned} \quad (2.15)$$

结论

定义 2.6 (无偏样本方差). 由式 (2.15), 定义:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad (2.16)$$

则有:

$$\mathbb{E}[S^2] = \frac{1}{n-1} \cdot (n-1)\sigma^2 = \sigma^2. \quad (2.17)$$

即 S^2 是总体方差 σ^2 的无偏估计量。

注记 2.3 (若用 n 作分母). 定义有偏版本 $\tilde{S}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = B_2$ (二阶中心矩), 则:

$$\mathbb{E}[\tilde{S}^2] = \frac{n-1}{n} \sigma^2 < \sigma^2 \quad (n \geq 2). \quad (2.18)$$

它系统性地低估总体方差。当 $n \rightarrow \infty$ 时 $\frac{n-1}{n} \rightarrow 1$, 故 $\tilde{S}^2$ 是渐近无偏的。

直观解释：自由度的损失

为什么“丢失”了 1？因为我们在计算 $\bar{X}$ 时用掉了数据的一个线性关系：

$$\sum_{i=1}^n (X_i - \bar{X}) = 0. \quad (2.19)$$

这个约束意味着 n 个偏差 $(X_i - \bar{X})$ 中只有 $n - 1$ 个是可以自由变化的。因此自由度为 $n - 1$ ，除以 $n - 1$ 才能得到无偏估计。

可以这样记忆：

- $\bar{X}$ 是 μ 的无偏估计，分母用 n （自由度 = n ）
- S^2 是 σ^2 的无偏估计，分母用 $n - 1$ （自由度 = $n - 1$ ，因为用 $\bar{X}$ 替代了 μ ）

定义 2.7 (样本 k 阶原点矩与中心矩).

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \quad (k \text{ 阶原点矩}), \quad (2.20)$$

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k \quad (k \text{ 阶中心矩}). \quad (2.21)$$

定义 2.8 (次序统计量). 将样本观测值从小到大排序： $x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)}$ ，对应的随机变量 $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ 称为次序统计量。

- $X_{(1)} = \min\{X_1, \dots, X_n\}$ — 最小次序统计量
- $X_{(n)} = \max\{X_1, \dots, X_n\}$ — 最大次序统计量
- 样本中位数 M_e ，样本极差 $R = X_{(n)} - X_{(1)}$

2.2 直方图和箱线图

2.2.1 直方图

绘制步骤：

1. 将数据范围分成若干等宽区间（组距）；
2. 统计落入每个区间的数据个数（频数）或比例（频率）；
3. 以区间为底、频数/频率为高画矩形。

作用：观察数据分布的形态——对称性、偏态、峰度、是否多峰、是否有离群值。

2.2.2 箱线图

五数概括:

- 最小值 $x_{\min}$ (或下须线端点)
- 第一四分位数 Q_1 (第 25 百分位数)
- 中位数 M_e (第 50 百分位数)
- 第三四分位数 Q_3 (第 75 百分位数)
- 最大值 $x_{\max}$ (或上须线端点)

四分位距:

$$\text{IQR} = Q_3 - Q_1. \quad (2.22)$$

异常值检测: 小于 $Q_1 - 1.5 \times \text{IQR}$ 或大于 $Q_3 + 1.5 \times \text{IQR}$ 的值视为异常值。

箱线图结构示意图




图 2.1: 箱线图结构示意。箱体范围从 Q_1 到 Q_3 , 箱内红线为中位数 M_e 。须线延伸至非异常值的最远端。虚线的内限 (fence, $Q_1 \pm 1.5 \times \text{IQR}$) 之外的点为异常值/离群点 (红色圆点)。

异常值判定规则

条件	判定	标记方式
$Q_1 - 3 \times \text{IQR} \leq x_i < Q_1 - 1.5 \times \text{IQR}$	温和异常值	●
$x_i < Q_1 - 3 \times \text{IQR}$	极端异常值	● (或 ★)
$Q_3 + 1.5 \times \text{IQR} < x_i \leq Q_3 + 3 \times \text{IQR}$	温和异常值	●
$x_i > Q_3 + 3 \times \text{IQR}$	极端异常值	●

2.2.3 经验分布函数

定义 2.9 (经验分布函数). 设样本观测值为 $x_1, \dots, x_n$, 经验分布函数定义为:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{x_i \leq x\}} = \frac{\#\{i : x_i \leq x\}}{n}. \quad (2.23)$$

由格里汶科定理, $n \rightarrow \infty$ 时 $F_n(x)$ 一致收敛于总体分布 $F(x)$ 。

2.3 抽样分布

统计量的分布称为**抽样分布**。下面介绍三大重要抽样分布。

2.3.1 χ^2 分布 (卡方分布)

历史背景

1900 年, 英国统计学家 **Karl Pearson** (卡尔·皮尔逊) 在研究分类数据的拟合优度时, 发现了一个核心问题: 掷骰子 60 次, 各面分别出现 10, 8, 12, 9, 11, 10 次——这是正常的随机波动, 还是骰子有问题? 他把观测频数与期望频数的偏差平方除期望频数后求和, 发现这个统计量在大样本下服从一个特定分布, 他将其称为 χ^2 分布。这篇论文标志着现代假设检验的诞生。

为什么叫”卡方”? χ 是希腊字母 chi (读作”卡”), χ^2 就是”chi 的平方”。它本质上是 n 个独立标准正态随机变量的平方和。

直观理解

想象你从 $\mathcal{N}(0, 1)$ 中独立抽取 n 个值 $Z_1, \dots, Z_n$:

- 每个 Z_i^2 都是非负的, 大多数在 0 到 1 之间 (因为 $P(|Z| < 1) \approx 68\%$)
- 把 n 个这样的非负数加起来, 总和大概在 n 附近——这就是 $\mathbb{E}[\chi^2] = n$ 的直觉
- n 越大, 求和的结果波动越大—— $\text{Var}(\chi^2) = 2n$ 反映了这一点

自由度 n = 独立信息的个数。每用掉一个估计量 (如用 $\bar{X}$ 替代 μ), 自由度减 1。

核心问题: 总体不是 $\mathcal{N}(0, 1)$ 时怎么用卡方?

这是初学者最困惑的地方。 χ^2 分布的定义要求 $X_i \sim \mathcal{N}(0, 1)$, 但在实际中你只知道 $X_i \sim \mathcal{N}(\mu, \sigma^2)$, μ 和 σ^2 都未知。怎么把一般的正态样本转化为卡方变量?

完整推导流程 (三步桥接):

第 1 步 先假设 μ 已知——标准化。

若 μ 已知，对每个 X_i 做标准化：

$$Z_i = \frac{X_i - \mu}{\sigma} \sim \mathcal{N}(0, 1). \quad (2.24)$$

那么 n 个 Z_i 的平方和就是卡方：

$$\sum_{i=1}^n Z_i^2 = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 \sim \chi^2(n). \quad (2.25)$$

自由度是 n ，因为 n 个 X_i 提供了 n 个独立信息，没有被消耗的。

第 2 步 现实中 μ 未知——用 $\bar{X}$ 替代 μ ，自由度减 1。

实际中 μ 未知，你只能用 $\bar{X}$ 来替代它：

$$\sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma} \right)^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2. \quad (2.26)$$

这个量还是卡方吗？是的，但自由度减少了 1：

$$\boxed{\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \sim \chi^2(n-1)}. \quad (2.27)$$

为什么自由度从 n 变成 $n-1$ ？

因为 $\bar{X}$ 是从数据本身估计出来的，这引入了一个约束： $\sum_{i=1}^n (X_i - \bar{X}) = 0$ 。 n 个偏差中只有 $n-1$ 个可以自由变化，最后一个被前 $n-1$ 个决定。每消耗一个估计量（用 $\bar{X}$ 替代 μ ），自由度就减 1。这就和之前推导 S^2 时 $\mathbb{E}[S^2] = \sigma^2$ （分母 $n-1$ ）是同一个逻辑。

第 3 步 等价形式——用样本方差 S^2 表达。

由 $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ ，式 (2.27) 等价于：

$$\boxed{\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)}. \quad (2.28)$$

这是最常用的形式，因为 S^2 可以直接从样本算出来。

完整数值示例：

假设某工厂螺栓直径服从 $\mathcal{N}(\mu, \sigma^2)$ ， μ 和 σ^2 均未知。抽取 $n = 10$ 个螺栓，测得样本方差 $s^2 = 0.04$ 。

- 若想知道 σ^2 是否等于某标称值 $\sigma_0^2 = 0.02$ ：

- 计算检验统计量: $\frac{(n-1)s^2}{\sigma_0^2} = \frac{9 \times 0.04}{0.02} = 18$
- 在原假设 $H_0: \sigma^2 = 0.02$ 下, 该统计量 $\sim \chi^2(9)$
- 查表: $\chi_{0.05}^2(9) \approx 16.92$, $18 > 16.92$, 拒绝 H_0 , 认为实际方差偏大

一句话总结:

χ^2 定义要求的标准正态 $\xrightarrow{\text{标准化 } Z_i = \frac{X_i - \mu}{\sigma}}$ 一般正态样本 $\xrightarrow{\mu \text{ 未知, 用 } \bar{X} \text{ 替代}}$ $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$

典型应用场景

- (1) 方差估计与检验: $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$, 用于构造 σ^2 的置信区间和检验 $H_0: \sigma^2 = \sigma_0^2$ (已在上节详述)
- (2) 拟合优度检验 (Pearson χ^2 检验): 检验观测数据是否符合某个理论分布
- (3) 独立性检验 (列联表): 检验两个分类变量是否独立
- (4) 机器学习中的特征选择: χ^2 检验用于评估分类特征与标签之间的相关性

拟合优度检验——完整流程与实例

问题: 骰子是否均匀? 掷 60 次, 观测到各面出现的次数为:

骰子面	1	2	3	4	5	6	合计
观测频数 O_i	7	12	9	13	8	11	60

第 1 步: 建立假设。

- H_0 : 骰子是均匀的 (每一面出现的概率 $p_i = \frac{1}{6}$)
- H_1 : 骰子不均匀 (至少有一面概率 $\neq \frac{1}{6}$)

第 2 步: 计算期望频数 E_i 。

在 H_0 成立的前提下, 每一面的期望频数 $= n \times p_i = 60 \times \frac{1}{6} = 10$ 。

骰子面	1	2	3	4	5	6
期望频数 E_i	10	10	10	10	10	10

第 3 步：计算 Pearson χ^2 统计量。

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}. \quad (2.29)$$

核心直觉：分子 $(O_i - E_i)^2$ 度量“观测与期望偏离了多少”；分母 E_i 做归一化（ E_i 大的类别允许更大的绝对偏差）。

逐项计算：

$$\begin{aligned} \frac{(7-10)^2}{10} + \frac{(12-10)^2}{10} + \frac{(9-10)^2}{10} + \frac{(13-10)^2}{10} + \frac{(8-10)^2}{10} + \frac{(11-10)^2}{10} &= \frac{9+4+1+9+4+1}{10} \\ &= 2.8. \end{aligned} \quad (2.30)$$

(2.31)

第 4 步：确定自由度，查临界值。

- $k = 6$ 个类别
- 没有从数据中估计任何参数（ $m = 0$ ，概率 p_i 完全由 H_0 指定，而非从样本估计）
- 约束： $\sum O_i = n$ （每个观测值贡献独立信息，但总和固定），消耗 1 个自由度
- 自由度： $df = k - 1 - m = 6 - 1 - 0 = 5$

在大样本下， $\chi^2 = 2.8 \sim \chi^2(5)$ 。取 $\alpha = 0.05$ ，查表得 $\chi_{0.05}^2(5) \approx 11.07$ 。

第 5 步：做结论。

$2.8 < 11.07$ ，统计量不在拒绝域内，不能拒绝 H_0 ——现有数据不足以认为骰子不均匀。

自由度公式解释： $df = k - 1 - m$

- k ：类别数
- -1 ：因为 $\sum O_i = n$ 是一个固定约束（给定总数后， k 个类别中只有 $k - 1$ 个可自由变化）
- $-m$ ：如果 H_0 中的分布参数不是预先指定的，而是先用样本估计的，每估计一个参数再减 1 个自由度。

例：若检验“数据是否服从正态分布”但 μ, σ^2 都需从样本估计，则 $m = 2$ ， $df = k - 1 - 2$

概念澄清：常见用词误区

以下用上述“掷骰子”例子对照，纠正初学者在描述流程时常犯的用词错误。

易错表述	问题	正确表述
“从认为的概率推出统计量”	期望频数 E_i 不是统计量！统计量是从样本算出的随机变量	$E_i = n \times p_i^{(0)}$ 是 H_0 的推演结果（确定值）； $\chi^2 = \sum (O_i - E_i)^2 / E_i$ 才是检验统计量
“对两组统计结果进行处理”	不是“两组数据”！是同一批样本的两套频数	观测频数 O_i vs. H_0 下的期望频数 E_i
“用卡方进行检验”	不是直接用卡方分布去“测”	构造 Pearson χ^2 统计量，利用其在 H_0 下的渐近分布做决策

修正后的五步标准流程：

第 1 步 提出 H_0 ：数据来自某个已知分布（如每面概率 $p_i = 1/6$ ）。

第 2 步 计算期望频数 $E_i = n \times p_i^{(0)}$ ——这是确定性的数值，不是统计量。

第 3 步 构造检验统计量 $\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$ ——这才是从样本算出的统计量。

第 4 步 确定自由度 $df = k - 1 - m$ ，查 χ^2 临界值。

第 5 步 比较并做结论：若 $\chi^2 > \chi_\alpha^2(df)$ ，拒绝 H_0 。

核心原理：为什么 $\sum (O_i - E_i)^2 / E_i$ 服从 χ^2 分布？

这是 Pearson 在 1900 年做出的最深洞察。以下分三步推导。

第 1 步：每个格子的 O_i 本质上是什么？

O_i 是 n 个独立个体中落入第 i 类的个数。在 H_0 下，每个个体以概率 p_i 落入第 i 类。因此：

$$O_i \sim \text{Binomial}(n, p_i), \quad \mathbb{E}[O_i] = np_i = E_i, \quad \text{Var}(O_i) = np_i(1 - p_i). \quad (2.32)$$

第 2 步：标准化——从二项到近似标准正态。

由中心极限定理（ n 大时二项分布近似正态）：

$$\frac{O_i - E_i}{\sqrt{np_i(1 - p_i)}} \xrightarrow{d} \mathcal{N}(0, 1). \quad (2.33)$$

在实际应用中，大多数 p_i 不大， $1 - p_i \approx 1$ ，分母可近似为 $\sqrt{np_i} = \sqrt{E_i}$ ：

$$\boxed{\frac{O_i - E_i}{\sqrt{E_i}} \approx \mathcal{N}(0, 1)} \quad (2.34)$$

这一项就是第 i 类的**标准化偏差**——“观测值偏离了期望值几个标准差”。

第 3 步：平方求和——从正态到卡方。

χ^2 分布的定义就是 k 个独立标准正态的平方和。因此：

$$\boxed{\chi^2 = \sum_{i=1}^k \left(\frac{O_i - E_i}{\sqrt{E_i}} \right)^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \sim \chi^2(k-1)} \quad (2.35)$$

为什么自由度是 $k-1$ 而非 k ？

因为 $\sum_{i=1}^k O_i = n$ 是一个固定约束—— k 个偏差中只有 $k-1$ 个可以独立变化，最后一个被前 $k-1$ 个自动决定。（若 H_0 中有 m 个参数是用样本估计的，则再减 m 。）

一句话直觉：

$$\frac{O_i - E_i}{\sqrt{E_i}} \xrightarrow[\text{平方}]{} \frac{(O_i - E_i)^2}{E_i} \xrightarrow[\text{对所有 } k \text{ 类求和}]{} \chi^2 \xrightarrow[\text{查表}]{} \text{判断是否显著偏离 } H_0$$

- 若 H_0 为真，每个 $\frac{O_i - E_i}{\sqrt{E_i}}$ 大约在 ± 1 范围内，平方后 ≈ 1 ，总和 $\approx k-1$ （即期望值 = 自由度）
- 若 H_0 为假，某些类别的偏差远大于 1 个标准差，平方后急剧放大，总和 $\gg k-1$ ，落入拒绝域

这就是为什么这个看似简单的公式能区分“随机波动”和“真正的分布差异”——它在数学上等价于把每个类别的标准化偏差平方后累加，然后用卡方分布精确量化“这么大的总和由纯随机产生的概率有多大”。

问题：性别与是否吸烟是否独立？调查 200 人，得到以下 2×2 列联表：

	吸烟	不吸烟	合计
男	60	40	100
女	30	70	100
合计	90	110	200

第 1 步：建立假设。

- H_0 ：性别与吸烟相互独立
- H_1 ：性别与吸烟不独立（存在关联）

第 2 步：在独立假设下计算期望频数。

若两个变量独立，则 $P(\text{男} \cap \text{吸烟}) = P(\text{男}) \times P(\text{吸烟})$ 。

推广到频数：

$$E_{ij} = \frac{(\text{第 } i \text{ 行合计}) \times (\text{第 } j \text{ 列合计})}{\text{总合计}}. \quad (2.36)$$

- E_{11} (男 × 吸烟): $\frac{100 \times 90}{200} = 45$
- E_{12} (男 × 不吸烟): $\frac{100 \times 110}{200} = 55$
- E_{21} (女 × 吸烟): $\frac{100 \times 90}{200} = 45$
- E_{22} (女 × 不吸烟): $\frac{100 \times 110}{200} = 55$

期望频数表：

	吸烟	不吸烟
男	45	55
女	45	55

第 3 步：计算 χ^2 统计量。

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}. \quad (2.37)$$

$$\chi^2 = \frac{(60 - 45)^2}{45} + \frac{(40 - 55)^2}{55} + \frac{(30 - 45)^2}{45} + \frac{(70 - 55)^2}{55} \quad (2.38)$$

$$= \frac{225}{45} + \frac{225}{55} + \frac{225}{45} + \frac{225}{55} \quad (2.39)$$

$$= 5 + 4.09 + 5 + 4.09 = 18.18. \quad (2.40)$$

第 4 步：确定自由度。

对于 $r \times c$ 列联表：

$$df = (r - 1) \times (c - 1). \quad (2.41)$$

直觉：在行和与列和固定的约束下，一旦你填了 $(r - 1) \times (c - 1)$ 个格子，其余格子被这些约束自动决定。本例中 $df = (2 - 1) \times (2 - 1) = 1$ 。

取 $\alpha = 0.05$ ，查表得 $\chi_{0.05}^2(1) \approx 3.84$ 。

第 5 步：做结论。

$18.18 \gg 3.84$ ，强烈拒绝 H_0 ——性别与吸烟之间存在显著关联（男性吸烟比例明显更高）。

拟合优度 vs. 独立性检验的对比：

	拟合优度检验	独立性检验
问题	观测数据符合某理论分布吗?	两个变量独立吗?
H_0	$p_i = p_i^{(0)}$ (给定概率)	$P(A \cap B) = P(A)P(B)$
E_i 来源	$n \times p_i^{(0)}$ (由 H_0 指定)	行合计 $\times$ 列合计 $\div$ 总合计 (由边际推算)
自由度	$k - 1 - m$	$(r - 1)(c - 1)$
数据结构	单行频数向量	$r \times c$ 二维列联表

共同假设：两者都要求期望频数 $E_i \geq 5$ (大样本条件)，否则需用 Fisher 精确检验替代。

定义与性质

定义 2.10 (χ^2 分布). 设 $X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$, 则

$$\chi^2 = \sum_{i=1}^n X_i^2 \sim \chi^2(n), \quad (2.42)$$

称 χ^2 服从自由度为 n 的卡方分布。

性质：

- $\mathbb{E}[\chi^2] = n, \quad \text{Var}(\chi^2) = 2n$
- 可加性：若 $\chi_1^2 \sim \chi^2(n_1), \chi_2^2 \sim \chi^2(n_2)$ 且独立，则 $\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2)$
- $n \rightarrow \infty$ 时 $(\chi^2(n) - n)/\sqrt{2n} \xrightarrow{d} \mathcal{N}(0, 1)$

定义 2.11 (χ^2 分布的上 α 分位点). 点 $\chi_\alpha^2(n)$ 满足：

$$P(\chi^2 > \chi_\alpha^2(n)) = \int_{\chi_\alpha^2(n)}^{\infty} f_{\chi^2}(y) dy = \alpha. \quad (2.43)$$

2.3.2 t 分布 (学生氏分布)

历史背景——“Student” 的真实身份

1908 年，都柏林 Guinness (健力士) 啤酒厂的一位化学师发表了一篇题为 “The Probable Error of a Mean” 的论文，署名 “Student”。他的真名叫 **William Sealy Gosset** (戈塞特)。

为什么化名？ Guinness 公司禁止员工发表论文 (担心泄露商业机密)，Gosset 只能用笔名发表。

他解决了什么问题？在啤酒酿造中，他需要用少量样本（如 $n = 3$ 或 4 ）来估计麦芽质量的平均值。当用 S 替代 σ 时， $\frac{\bar{X} - \mu}{S/\sqrt{n}}$ 不再服从正态分布——因为在分母中用随机量 S 代替了常数 σ ，引入了额外的不确定性。它实际上服从一种“尾部更厚”的分布——这就是 t 分布。

核心洞察： t 分布是专门为“做实验只有 5 个数据点，但还要做统计推断”这种情况设计的。这就是为什么 t 分布也被称为小样本分布。

直观理解


对比两个看起来很相似的量：

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1) \quad \text{——分母是常数 } \sigma, \text{ 精确} \quad (2.44)$$

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1) \quad \text{——分母是随机量 } S, \text{ 有波动} \quad (2.45)$$

S 有时比 σ 小，有时比 σ 大。当 S 偏小时， $|T|$ 就被放大了。这导致 t 分布比正态分布**尾部更厚**（极端值更可能出现）。

当 $n \rightarrow \infty$ ， $S \xrightarrow{P} \sigma$ ， t 分布退化为标准正态分布。 $n \geq 30$ 时两者差异已不大。



核心桥梁： S 怎样与 χ^2 挂钩——从 t 定义到 t 检验

这是理解 t 检验最关键的一步。 t 分布的定义是 $T = \frac{X}{\sqrt{Y/n}}$ ，其中 $X \sim \mathcal{N}(0, 1)$ ， $Y \sim \chi^2(n)$ 。但 t 检验的统计量是 $T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$ ——这里 S 是样本标准差，**不是** χ^2 变量。那么 T 为什么服从 t 分布？

关键在于分子分母同做代数变形，把 S 转化为 χ^2 的形式。

完整推导：

第 1 步 分离 σ ——分子分母同除 σ 。

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} = \frac{(\bar{X} - \mu_0)/(\sigma/\sqrt{n})}{\sqrt{S^2/\sigma^2}} = \frac{Z}{\sqrt{\frac{(n-1)S^2/\sigma^2}{n-1}}} \quad (2.46)$$

令：

- $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$ ——分子是标准正态
- $Y = \frac{(n-1)S^2}{\sigma^2}$ ——分母根号里的分子

第 2 步 识别两个分量的分布。

- $Z \sim \mathcal{N}(0, 1)$: 这是正态总体下样本均值的标准化形式。
- $Y = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$: 这是正态总体抽样分布的定理——已在 χ^2 节“核心问题”中完整推导。本质是 n 个标准正态平方和，用 $\bar{X}$ 替代 μ 后自由度减 1。
- $\bar{X}$ 与 S^2 相互独立（仅对正态总体成立!） $\implies Z$ 与 Y 独立。

第 3 步 套入 t 分布的定义。

$$T = \frac{Z}{\sqrt{Y/(n-1)}} \sim t(n-1). \quad (2.47)$$

这正是 t 分布的标准形式：分子 $\mathcal{N}(0, 1)$ ，分母 $\sqrt{\chi_{n-1}^2/(n-1)}$ ，两者独立。

一句话总结：

$$\underbrace{\frac{\bar{X} - \mu_0}{S/\sqrt{n}}}_{\text{你计算的东西}} = \frac{\overbrace{\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}}^{\sim \mathcal{N}(0,1)}}{\sqrt{\underbrace{\frac{(n-1)S^2}{\sigma^2}}_{\sim \chi^2(n-1)}}/(n-1)} \sim t(n-1).$$

没有这两个事实， t 检验就不存在：

- (1) $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ ——把 S 桥接到 χ^2
- (2) $\bar{X}$ 与 S^2 独立——保证分子分母独立（仅正态总体有此性质）

这就是为什么 t 检验假设数据来自正态总体——如果总体不正态， $\bar{X}$ 和 S^2 不一定独立， $(n-1)S^2/\sigma^2$ 也不精确服从 χ^2 ，整个推导链条就断了。

典型应用场景

- (1) 小样本均值的置信区间与检验（ σ 未知）：最核心的应用。如 10 个病人的血压变化是否显著？用 t 检验
- (2) 两样本均值比较（ t 检验）：A/B 测试中判断实验组与对照组均值差异是否显著
- (3) 回归系数的显著性检验： $\frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)} \sim t(n-p-1)$ ，判断某个特征对目标变量是否有显著影响（线性回归输出中的 p 值来自 t 分布）
- (4) 配对 t 检验：同一样本处理前后比较，如服药前 vs. 服药后
- (5) 机器学习中的特征筛选：对每个特征做两样本 t 检验，筛选出有区分力的特征

单样本 t 检验——完整流程与实例

问题：某新药声称能降低收缩压。给 $n = 10$ 位患者服药，测量服药前后收缩压的差值 X_i ($X_i =$ 服药后 $-$ 服药前，负值表示血压下降)：

患者	1	2	3	4	5	6	7	8	9	10
血压变化 x_i (mmHg)	-5	-2	-8	-3	-1	-6	-4	-7	-2	-3

- 样本量 $n = 10$
- 样本均值 $\bar{x} = \frac{1}{10} \sum x_i = -4.1$ (平均降低 4.1 mmHg)
- 样本标准差 $s = \sqrt{\frac{1}{9} \sum (x_i - \bar{x})^2} \approx 2.38$
- 总体标准差 σ 未知！

第 1 步：建立假设。

- $H_0: \mu = 0$ (药物无效，血压没有变化)
- $H_1: \mu < 0$ (药物有效，血压下降) ——单侧 (左尾) 检验

第 2 步：构造检验统计量。

若 σ 已知，自然用 $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$ 。但 σ 未知，只能用 S 替代 σ ，统计量变为：

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1). \quad (2.48)$$

代入数值：

$$t = \frac{-4.1 - 0}{2.38/\sqrt{10}} = \frac{-4.1}{0.753} \approx -5.45. \quad (2.49)$$

为什么不能直接用正态分布？分母 S 是随机变量 (不是常数 σ)，引入了额外的不确定性。 t 分布的尾部比正态更厚，正是为了补偿“用 S 替代 σ ”带来的额外风险。当 $n = 10$ ($df = 9$) 时， $t_{0.05}(9) \approx 1.833$ 而 $z_{0.05} = 1.645$ —— t 检验更保守，需要更大的 $|T|$ 才能拒绝 H_0 。

第 3 步：确定自由度，查临界值。

自由度为 $n - 1 = 9$ 。取 $\alpha = 0.05$ 。

因为是单侧左尾检验：拒绝域为 $T < -t_{\alpha}(n-1)$ 。查表得 $t_{0.05}(9) \approx 1.833$ ，故拒绝域为 $T < -1.833$ 。

第 4 步：做决策。

$t = -5.45 < -1.833$ ，检验统计量落入拒绝域。拒绝 H_0 ，认为药物能显著降低血压。等价地，可计算 p 值： $p = P(T < -5.45 \mid df = 9) \ll 0.001$ ，远小于 $\alpha = 0.05$ 。

第 5 步：报告同时给出置信区间 (良好实践)。

不仅说“有无效果”，还应给出效果大小的范围估计。 μ 的 95% 置信区间（双侧）：

$$\bar{x} \pm t_{\alpha/2}(n-1) \cdot \frac{s}{\sqrt{n}} = -4.1 \pm t_{0.025}(9) \times 0.753. \quad (2.50)$$

查表 $t_{0.025}(9) \approx 2.262$ ：

$$-4.1 \pm 2.262 \times 0.753 = (-5.80, -2.40). \quad (2.51)$$

解读：有 95% 的把握认为，该药平均降低收缩压 2.40 到 5.80 mmHg（整个区间在 0 以下，与拒绝 H_0 的结论一致）。

双侧 vs. 单侧：什么时候用哪个？

	双侧检验	单侧检验
H_1	$\mu \neq \mu_0$ （有差异，不管方向）	$\mu < \mu_0$ 或 $\mu > \mu_0$ （有方向的差异）
拒绝域	$ T > t_{\alpha/2}(n-1)$	$T < -t_{\alpha}(n-1)$ 或 $T > t_{\alpha}(n-1)$
适用场景	新药是否改变了血压（不确定方向）	新药是否降低了血压（有先验方向）

单样本 t 检验与 z 检验的对比总结：

	z 检验 (σ 已知)	t 检验 (σ 未知)
检验统计量	$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$	$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$
分布	$\mathcal{N}(0, 1)$ （精确）	$t(n-1)$ （ σ 未知时的精确分布）
适用条件	σ 已知，或 n 很大 (≥ 30)	σ 未知，尤其 $n < 30$
实际中多用谁	几乎只存在于教科书	现实中的默认选择—— σ 几乎永远是未知的
关系	$n \rightarrow \infty$ 时 $t \rightarrow z$	n 大时 $t \approx z$ ， $n \geq 30$ 时差异可忽略

关键前提：为什么假定 X_i 服从正态分布？违背了怎么办？

t 检验的全部推导基于一个核心前提：**数据来自正态总体**。在血压例子中，这意味着假定 10 位患者的血压变化值 $X_1, \dots, X_{10} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$ 。

这并不是一个“已被证明的事实”，而是一个建模假设。

为什么这个假设在血压例子中合理？

血压是大量微小生理因素叠加的结果——心率、血管阻力、激素水平、测量误差……根据中心极限定理，大量独立微小效应的叠加趋向正态分布。同类医学研究中，血压变化确实通常近似正态。

但并非所有场景都适用：

数据类型	为什么不正态	合适的方法
治愈天数	右偏（有下界 0，不能为负）	Wilcoxon 符号秩检验，或对数变换后做 t 检验
消费金额	长尾，少数人消费极高	同上
点击/计数	泊松型（方差 = 均值）	泊松回归，或平方根变换
比例/百分比	有界 $[0, 1]$ ，两端堆积	Beta 回归，或 logit 变换

正态假定违背了会怎样？

t 检验对正态性偏离有一定稳健性，但并非无限制：

偏离程度	后果	n 的影响
轻度偏态（略有不对称）	t 检验近似有效，影响不大	n 越大越安全（CLT 保证 $\bar{X}$ 渐近
重尾或有离群值	第一类错误率膨胀，可能误拒 H_0	n 再大也救不了（离群值不因 n 增大
严重偏态	检验功效下降，可能漏掉真实效应	需要换非参数方法

实际诊断流程（在跑 t 检验之前）：

- (1) 画 Q-Q 图（详见下方详解）
- (2) 做 Shapiro-Wilk 检验： H_0 为”数据来自正态分布”。若 $p > 0.05$ ，不拒绝正态性假定。
- (3) 若正态性不满足且 n 小：改用 Wilcoxon 符号秩检验——不要求正态，只要求分布对称。
这是 t 检验最常用的非参数替代方案。
- (4) 若 n 较大 (≥ 30)：由 CLT， $\bar{X}$ 近似正态， t 检验仍可近似使用（但仍需留意离群值）。

Q-Q 图详解：为什么能检查正态性？

什么是 Q-Q 图？

Q-Q 图（Quantile-Quantile Plot，分位数-分位数图）将样本的分位数与某个理论分布（如正态）的分位数画在同一张散点图上：

- **横轴：**理论分位数——例如 $\mathcal{N}(0, 1)$ 的第 $1/(n+1), 2/(n+1), \dots, n/(n+1)$ 分位数
- **纵轴：**样本分位数——将 n 个数据从小到大排序后对应的值

为什么正态数据落在一条直线上？

这是 Q-Q 图最核心的数学原理。

假设数据真的来自正态总体 $X \sim \mathcal{N}(\mu, \sigma^2)$ 。将 X 标准化： $Z = (X - \mu)/\sigma \sim \mathcal{N}(0, 1)$ 。

反过来写： $X = \mu + \sigma Z$ 。这意味着样本的第 p 分位数 $Q_X(p)$ 与标准正态的第 p 分位数 $Q_Z(p)$ 之间有**线性关系**：

$$Q_X(p) = \mu + \sigma \cdot Q_Z(p).$$

(2.52)

因此，若以 $Q_Z(p)$ 为横轴、 $Q_X(p)$ 为纵轴画散点图，正态数据应沿一条直线分布：

- **截距** $\approx \mu$ （数据均值）
- **斜率** $\approx \sigma$ （数据标准差）

数据是否在一条直线上就是 Q-Q 图判断正态性的全部依据——**形状比位置更重要**。截距和斜率不同只说明 $\mu \neq 0$ 或 $\sigma \neq 1$ ，这并不违背正态性。

常见偏离模式及其含义：

Q-Q 图形状	说明	暗示的分布特征
点沿一条直线	正态性良好	数据符合正态
两端向上翘（S 形上凸）	右尾偏长	右偏（正偏）， 如收入数据
两端向下弯（S 形下凹）	左尾偏长	左偏（负偏）， 如考试高分数据
左端下弯、右端上翘（反 S 形）	两端都长	重尾分布 （比正态更易出极端值）
左端上翘、右端下弯	两端都短	轻尾分布 （如均匀分布）

Q-Q 图 vs. 直方图：为什么 Q-Q 图更灵敏？

- 直方图：依赖分组宽度选择，小样本时很难判断尾部形态
- Q-Q 图：直接比较分位数，对尾部偏离特别敏感（因为两端点稀疏，偏离一目了然），且不依赖任何参数选择

实操规则：如果 Q-Q 图上的点大致沿一条直线，不必追求完美贴合（特别是两端几个点略有波动是正常的）。真正需要警惕的是**系统性弯曲**——所有点整体呈弧形或 S 形。

与 Shapiro-Wilk 检验的互补关系：




图 2.2: Q-Q 图的三种典型模式。左：正态数据，点沿直线分布。中：右偏数据，右端向上翘（S 形上凸）。右：重尾数据，左端下弯、右端上翘（反 S 形）。灰色对角线为参考线 $y = x$ 。

	Q-Q 图	Shapiro-Wilk 检验
本质	可视化工具	统计假设检验
优势	直观，一眼看出偏离类型（偏态/重尾）	给出 p 值，客观判断
劣势	依赖人眼判断，主观	n 大时过于敏感（轻微偏离也拒绝 H_0 ）
最佳实践	两者结合：先看 Q-Q 图判断偏离类型和程度，必要时用 SW 检验佐证	

注记 2.4 (关于 CLT 的一个重要但常被忽视的细节). CLT 保证了 $\bar{X}$ 的渐近正态性，但 t 检验还需要 S^2 的行为。若总体非正态， $(n-1)S^2/\sigma^2$ 不再精确服从 $\chi^2(n-1)$ ，且 $\bar{X}$ 与 S^2 也不一定独立。因此 $n = 30$ 的“经验法则”只能视为一个便利的近似，并非严格的数学保证。最安全的做法始终是用 Q-Q 图检查正态性，有疑虑时换非参数方法。

定义与性质

定义 2.12 (t 分布). 设 $X \sim \mathcal{N}(0, 1)$, $Y \sim \chi^2(n)$, 且 X 与 Y 相互独立, 则

$$T = \frac{X}{\sqrt{Y/n}} \sim t(n), \quad (2.53)$$

称 T 服从自由度为 n 的 t 分布。

性质:

- PDF 关于 $x = 0$ 对称, $\mathbb{E}[T] = 0$ ($n > 1$ 时)
- $\text{Var}(T) = \frac{n}{n-2}$ ($n > 2$)

- $n \rightarrow \infty$ 时 $t(n) \rightarrow \mathcal{N}(0, 1)$
- $n = 1$ 时即为柯西分布（期望不存在，尾部极厚）

定义 2.13 (t 分布的上 α 分位点). 点 $t_\alpha(n)$ 满足 $P(T > t_\alpha(n)) = \alpha$ 。由对称性: $t_{1-\alpha}(n) = -t_\alpha(n)$ 。

2.3.3 F 分布

历史背景

F 分布由英国统计学家 **Ronald A. Fisher**（费希尔）在 1920 年代提出，并以他姓氏的首字母命名。Fisher 是现代统计学的奠基人之一——他提出了极大似然估计、实验设计、ANOVA 等核心方法论。 F 分布最初正是为方差分析（ANOVA）设计的。

直观理解

F 分布本质上是两个独立的 χ^2 变量（各自除以自由度）的比值：

$$F = \frac{\chi_1^2/n_1}{\chi_2^2/n_2}. \quad (2.54)$$

这意味着什么？ F 统计量比较两个方差（或两种变异性来源）的大小：

- 分子 = “组间方差”，反映不同组之间均值的差异
- 分母 = “组内方差”，反映组内个体的随机波动
- 如果 $F \approx 1$ ，组间差异和组内波动差不多 $\rightarrow$ 各组可能来自同一总体
- 如果 $F \gg 1$ ，组间差异远大于随机波动 $\rightarrow$ 至少有一组明显不同

与 t 分布的关系: $T \sim t(n) \iff T^2 \sim F(1, n)$ 。 t 检验（比较两组均值）是 ANOVA（比较多组均值）在 $k = 2$ 时的特例。

典型应用场景

- (1) **方差分析 (ANOVA)**: 判断三组或以上样本的均值是否有显著差异。
例：三种教学方法的效果是否不同？A/B/C 三个版本的点击率是否不同？
- (2) **两正态总体方差比的检验与置信区间**: 检验 $H_0: \sigma_1^2 = \sigma_2^2$ 。
例：新工艺是否比旧工艺的波动更小（更稳定）？
- (3) **回归模型的整体显著性检验 (F 检验)**: 判断所有回归系数是否同时为 0。
$$F = \frac{R^2/p}{(1-R^2)/(n-p-1)} \sim F(p, n-p-1),$$
 检验“模型是否比纯截距模型好”

- (4) **机器学习中的特征选择**: ANOVA F 检验用于评估每个数值特征与分类标签的关联强度, scikit-learn 中的 `f_classif` 和 `SelectKBest` 即基于此
- (5) **模型比较**: 比较两个嵌套模型的拟合优度是否有显著差异 (Partial F 检验)

单因素 ANOVA——完整流程与实例

问题: 三种教学方法 (A: 传统讲授, B: 视频自学, C: 互动讨论) 是否对考试成绩有不同影响? 每种方法随机分配 6 名学生, 期末考试成绩如下:

方法	学生成绩						组均值
A (传统)	78	82	85	90	76	88	$\bar{x}_A = 83.17$
B (视频)	65	70	72	68	74	69	$\bar{x}_B = 69.67$
C (互动)	82	85	88	79	91	84	$\bar{x}_C = 84.83$
总均值 $\bar{x} = 79.22$, 总样本量 $N = 18$							

为什么不能用三次 t 检验代替一次 ANOVA?

如果做三次两两 t 检验 (A vs. B, B vs. C, A vs. C), 每次 $\alpha = 0.05$, 累积犯第一类错误的概率为 $1 - (1 - 0.05)^3 \approx 0.143$, 远超预设的 0.05。ANOVA 通过一次检验同时比较所有组, 控制整体错误率。

核心直觉: 比较两种”波动来源”

把 18 个学生的成绩波动拆成两部分:

$$\underbrace{\text{总变异 } SS_T}_{18 \text{ 个分数各不相同}} = \underbrace{\text{组间变异 } SS_B}_{\text{三组的均值不同}} + \underbrace{\text{组内变异 } SS_W}_{\text{同组内学生仍有差异}}$$

- 若 H_0 为真 (三种方法效果相同), 组间差异 $\approx$ 随机波动 $\rightarrow SS_B/SS_W \approx 1$
- 若 H_0 为假 (至少一种方法不同), 组间差异 $\gg$ 随机波动 $\rightarrow SS_B/SS_W \gg 1$

F 统计量正是这两种变异的比值 (经自由度调整后)。

第 1 步: 建立假设。

- H_0 : $\mu_A = \mu_B = \mu_C$ (三种方法的总体均值相等)
- H_1 : 至少有一个 μ_i 不同

第 2 步: 计算各项平方和。

总平方和 SS_T (Total): 每个数据点偏离总均值的平方和。

$$SS_T = \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x})^2. \quad (2.55)$$

组间平方和 SS_B (Between): 每组均值偏离总均值的平方和 (按样本量加权)。

$$SS_B = \sum_{i=1}^k n_i (\bar{x}_i - \bar{x})^2. \quad (2.56)$$

组内平方和 SS_W (Within): 每个数据点偏离其组均值的平方和。

$$SS_W = \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_i)^2. \quad (2.57)$$

且恒有 $SS_T = SS_B + SS_W$ (可验证)。

代入本例数值:

$$\begin{aligned} SS_B &= 6 \times (83.17 - 79.22)^2 + 6 \times (69.67 - 79.22)^2 + 6 \times (84.83 - 79.22)^2 \\ &= 6 \times (3.95^2 + (-9.56)^2 + 5.61^2) \\ &= 6 \times (15.60 + 91.31 + 31.47) = 830.28. \end{aligned} \quad (2.58)$$

$$\begin{aligned} SS_W &= \sum_A (x - 83.17)^2 + \sum_B (x - 69.67)^2 + \sum_C (x - 84.83)^2 \\ &= 154.83 + 61.33 + 85.83 = 302.00. \end{aligned} \quad (2.59)$$

$$SS_T = 830.28 + 302.00 = 1132.28. \quad (2.60)$$

第 3 步: 计算均方 (方差估计) 和 F 统计量。

将平方和除以各自的自由度, 得到”均方”(Mean Square)——本质上就是方差的两种估计:

$$MS_B = \frac{SS_B}{k-1} = \frac{830.28}{2} = 415.14, \quad MS_W = \frac{SS_W}{N-k} = \frac{302.00}{15} = 20.13. \quad (2.61)$$

$$F = \frac{MS_B}{MS_W} = \frac{415.14}{20.13} = 20.62.$$

自由度解释:

- SS_B 的 $df = k - 1 = 2$: k 个组均值, 受总均值一个约束
- SS_W 的 $df = N - k = 15$: 每组 n_i 个数据, 受各组均值 k 个约束
- SS_T 的 $df = N - 1 = 17$: 且 $(k - 1) + (N - k) = N - 1$, 自由度可加

为什么 F 统计量服从 F 分布?

在 H_0 和正态假定下:

- $SS_B/\sigma^2 \sim \chi^2(k-1)$ (组间变异, 由各组均值的正态性导出)

- $SS_W/\sigma^2 \sim \chi^2(N-k)$ (组内变异, 由各组内部的正态性导出)
- 两者相互独立

因此:

$$F = \frac{(SS_B/\sigma^2)/(k-1)}{(SS_W/\sigma^2)/(N-k)} = \frac{MS_B}{MS_W} \sim F(k-1, N-k). \quad (2.62)$$

第 4 步: 查表, 做决策。

$df = (2, 15)$, 取 $\alpha = 0.05$, 查表 $F_{0.05}(2, 15) \approx 3.68$ 。

$F = 20.62 \gg 3.68$, 拒绝 H_0 ——三种教学方法的效果存在显著差异。

第 5 步: 事后两两比较 (Post-hoc)。

ANOVA 只告诉你”至少有一组不同”, 但没说是哪两组。需要做事后检验来找出具体差异。

常用方法: **Tukey HSD 检验**——在所有两两比较中控制整体错误率。

结论 (示意): A vs. B 显著 ($p < 0.01$), C vs. B 显著 ($p < 0.01$), A vs. C 不显著 ($p > 0.05$)。即: 传统讲授和互动讨论效果相近, 均显著优于视频自学。

ANOVA 结果的标准报告格式 (APA 风格):

$F(2, 15) = 20.62, p < 0.001$ 。

三种教学方法的效果存在显著差异。Tukey HSD 事后检验表明, 传统讲授 ($M = 83.17$) 和互动讨论 ($M = 84.83$) 的考试成绩均显著高于视频自学 ($M = 69.67$), 前两者之间无显著差异。

ANOVA 的前提条件 (与 t 检验一致):

- (1) **正态性:** 每组数据来自正态总体 (用 Q-Q 图或 Shapiro-Wilk 检验各组)
- (2) **方差齐性:** 各组方差相等 $\sigma_A^2 = \sigma_B^2 = \sigma_C^2$ (用 Levene 检验或 Bartlett 检验)
- (3) **独立性:** 观测值之间相互独立 (由实验设计保证)

方差齐性不满足时怎么办? 改用 Welch ANOVA (不要求等方差), 原理类似 Welch t 检验的推广。

t 检验 vs. ANOVA 的关系:

	t 检验	单因素 ANOVA
比较组数	2 组	$k \geq 2$ 组
统计量	$T = \frac{\bar{x}_1 - \bar{x}_2}{SE}$	$F = \frac{MS_B}{MS_W}$
$k = 2$ 时的关系	$T \sim t(N-2)$	$F \sim F(1, N-2)$, 且 $T^2 = F$

定义与性质

定义 2.14 (F 分布). 设 $U \sim \chi^2(n_1)$, $V \sim \chi^2(n_2)$, 且 U, V 相互独立, 则

$$F = \frac{U/n_1}{V/n_2} \sim F(n_1, n_2), \quad (2.63)$$

称 F 服从自由度为 (n_1, n_2) 的 F 分布。 n_1 为分子（第一）自由度， n_2 为分母（第二）自由度。

性质：

$$F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}. \quad (2.64)$$

若 $T \sim t(n)$, 则 $T^2 \sim F(1, n)$ 。

三大抽样分布对比总结

分布	构造方式	核心用途	ML 中的身影
$\chi^2(n)$	n 个独立 $\mathcal{N}(0, 1)$ 的平方和	方差估计、拟合优度、独立性检验	χ^2 特征选择、决策树
$t(n)$	$\frac{\mathcal{N}(0, 1)}{\sqrt{\chi^2(n)/n}}$	小样本均值推断、回归系数显著性	t 检验特征筛选、A/B 测试
$F(n_1, n_2)$	$\frac{\chi^2(n_1)/n_1}{\chi^2(n_2)/n_2}$	方差比较、ANOVA、模型显著性	ANOVA 特征选择、模型比较

常见理解误区：各分布的适用范围被窄化了

初学者常把三个分布和理解场景做一一映射，但实际它们的适用范围远比直觉广。

误区一：“ χ^2 只能看观测频数和期望频数的差异”

χ^2 分布的本质是标准正态随机变量的平方和——频数比较只是其应用之一。因为任何被标准化后的偏差平方累加都可能涉及 χ^2 ，它在完全不同类型的场景中都会出现：

应用	数学形式	是“频数比较”吗？
拟合优度 / 独立性检验	$\sum \frac{(O_i - E_i)^2}{E_i} \sim \chi^2$	✓ 是
连续数据的方差估计	$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$	× 否——这是连续量，与频数无关
t 分布的底层构件	$t = \frac{\mathcal{N}(0,1)}{\sqrt{\chi^2/df}}$	× 否—— χ^2 在此承载方差信息
F 分布的底层构件	$F = \frac{\chi_1^2/df_1}{\chi_2^2/df_2}$	× 否
似然比检验（模型比较）	$2(\ln L_1 - \ln L_0) \xrightarrow{d} \chi^2$	× 否——比较两个模型的拟合优度

误区二：“ t 分布只能检验 μ 是否差异显著”

t 分布的数学形式是 $T = \frac{\text{估计量} - \text{假设值}}{\text{该估计量的标准误}}$ 。只要你的统计量长成“估计值除以它的标准误”，大概率就服从 t 分布——被估计的对象不一定是 μ 。

应用	检验对象	是“检验 μ ”吗？
单样本 t 检验	总体均值 μ	✓ 是
两样本 t 检验	两个总体均值差 $\mu_1 - \mu_2$	✓ 是
配对 t 检验	配对差值的均值	✓ 是
回归系数显著性	$\beta_j = 0?$	× 否——这是斜率，不是均值！
相关系数检验	$\rho = 0?$	× 否
两个回归系数比较	$\beta_1 = \beta_2?$	× 否
A/B 测试转化率	比例差异	✓ 实质是两样本均值的变体

回归系数检验是 t 分布在实际工作中最高频的应用——‘statsmodels’ / R 的 ‘summary()’ 输出里每一行的 ‘t value’ 和 ‘Pr(>|t|)’，全部是 t 检验。

三个分布的正确理解——层次关系：

$$\chi^2 \text{ 是砖块} \rightarrow t = \frac{\mathcal{N}(0,1)}{\sqrt{\chi^2/df}}, F = \frac{\chi_1^2/df_1}{\chi_2^2/df_2} \text{ 是它垒出的两种建筑}$$

分布	数学本质	不要窄化为
χ^2	标准正态平方和的分布	” 只能比较频数”
t	$\mathcal{N}(0,1)/\sqrt{\chi^2/df}$	” 只能检验 μ ”
F	$(\chi_1^2/df_1)/(\chi_2^2/df_2)$	” 只能做 ANOVA”

理解了这个层次关系，每个分布的适用范围自然就打开了——凡是你某个量做了标准化再平方求和， χ^2 就会出现；凡是某个估计量除以它的标准误， t 就会出现。

2.3.4 正态总体的抽样分布定理（核心定理）

定理 2.1 (单个正态总体). 设 $X_1, X_2, \dots, X_n$ 是来自正态总体 $\mathcal{N}(\mu, \sigma^2)$ 的样本， $\bar{X}$ 与 S^2 分别为样本均值与样本方差，则：

$$(1) \bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right), \text{ 即 } \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1);$$

$$(2) \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1);$$

(3) $\bar{X}$ 与 S^2 相互独立;

$$(4) \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

定理 2.2 (两个正态总体). 设 $X_1, \dots, X_{n_1} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu_1, \sigma_1^2)$, $Y_1, \dots, Y_{n_2} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu_2, \sigma_2^2)$, 两样本独立, 则:

$$(1) \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0, 1);$$

$$(2) \text{ 当 } \sigma_1^2 = \sigma_2^2 = \sigma^2 \text{ 时, } \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2), \text{ 其中 } S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2};$$

$$(3) \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1).$$

第三章 参数估计

3.1 点估计

点估计：用统计量的一个具体数值 $\hat{\theta}$ 来估计未知参数 θ 。

常用的构造估计量的方法有矩估计法和极大似然估计法。

3.1.1 矩估计法

核心思想：用样本矩代替（估计）总体矩。

设总体 X 的分布含 k 个未知参数 $\theta_1, \dots, \theta_k$ ：

$$\mu_\ell = \mathbb{E}[X^\ell] = g_\ell(\theta_1, \dots, \theta_k), \quad \ell = 1, \dots, k. \quad (3.1)$$

步骤：

1. 计算总体矩 $\mu_\ell = \mathbb{E}[X^\ell]$ （用参数表示）；
2. 令样本矩等于总体矩： $A_\ell = \mu_\ell$ ；
3. 解方程组得到 $\hat{\theta}_1, \dots, \hat{\theta}_k$ 。

例 3.1 (正态分布的矩估计). 设 $X \sim \mathcal{N}(\mu, \sigma^2)$ ：

$$\mathbb{E}[X] = \mu, \quad (3.2)$$

$$\mathbb{E}[X^2] = \text{Var}(X) + (\mathbb{E}[X])^2 = \sigma^2 + \mu^2. \quad (3.3)$$

令 $A_1 = \mu$, $A_2 = \sigma^2 + \mu^2$, 解得：

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2. \quad (3.4)$$

3.1.2 极大似然估计 (MLE)

定义 3.1 (似然函数). 设 $x_1, \dots, x_n$ 为来自总体 X 的样本观测值，总体的分布为 $f(x; \theta)$ (离散时为概率质量函数，连续时为概率密度函数)，则似然函数为：

$$L(\theta) = L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta). \quad (3.5)$$

注记 3.1 (符号 $L(\theta; x_1, \dots, x_n)$ 中分号的含义). $L(\theta; x_1, \dots, x_n)$ 中的分号 **不是** 条件概率的竖线 $|$, 它只是一个分隔符, 用于区分两类量:

- **分号前** (θ): 当前关注的**变量**——MLE 中我们要对它求导、最大化
- **分号后** ($x_1, \dots, x_n$): 已观测到的**固定数据**——拿到手后就不再改变

写成 $L(\theta | x_1, \dots, x_n)$ 也不少见, 但分号写法在统计学中更规范, 因为:

记号	含义	例子
$f(x; \theta)$ 或 $p(x \theta)$	θ 固定时, x 的概率密度/质量函数	正态 PDF
$L(\theta; x)$ 或 $L(\theta x)$	x 固定时, θ 的似然函数	MLE 的目标函数
$P(\theta x)$	观测到 x 后, θ 的 后验概率 (贝叶斯)	不是 MLE! 需要先验

关键区分: $L(\theta; x)$ 和 $P(\theta | x)$ 是完全不同的量。前者是频率学派的核心工具 (MLE), 后者是贝叶斯学派的核心工具 (MAP / 后验推断)。两者通过贝叶斯公式关联: $P(\theta | x) \propto L(\theta; x) \cdot P(\theta)$ 。

核心思想: 选择使观测数据出现概率最大的参数值。

极大似然估计值 $\hat{\theta}$ 满足:

$$L(\hat{\theta}) = \max_{\theta \in \Theta} L(\theta). \quad (3.6)$$

由于 $\ln$ 单调递增, 通常最大化**对数似然函数**:

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta). \quad (3.7)$$

求 $\frac{\partial \ell}{\partial \theta} = 0$ 解得 $\hat{\theta}_{\text{MLE}}$ 。

注记 3.2 (为什么 MLE 常写成 $\arg \max_{\theta} P(\mathcal{D} | \theta)$? 这不是贝叶斯). MLE 的两种等价写法常引起混淆:

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} L(\theta; \mathcal{D}) = \arg \max_{\theta} P(\mathcal{D} | \theta).$$

$P(\mathcal{D} | \theta)$ 不是贝叶斯, 因为它读作”给定参数, 数据的概率”。

竖线 $|$ 在概率论中是**条件概率**的标准符号: $P(A | B) = P(A \cap B)/P(B)$ 。 $P(\mathcal{D} | \theta)$ 的含义是: ”当参数取值为 θ 时, 数据 $\mathcal{D}$ 的分布”——这正是采样分布/似然。频率学派和贝叶斯学派都使用 $P(\mathcal{D} | \theta)$, 分歧在于用它做什么:

	频率学派 (MLE)	贝叶斯学派
用的量	$P(\mathcal{D} \theta)$	$P(\mathcal{D} \theta) \cdot P(\theta)$
对 θ 的立场	固定未知常数，放在竖线右边作为“条件”	随机变量，有先验分布 $P(\theta)$
目标	找使 $P(\mathcal{D} \theta)$ 最大的 θ	求 $P(\theta \mathcal{D}) \propto P(\mathcal{D} \theta)P(\theta)$

分号；和竖线 | 在这里可以互换吗？

- $L(\theta; x)$ 用分号强调“视角翻转”：数据固定， θ 是变量
- $P(x | \theta)$ 用竖线因为它确实满足条件概率的数学定义（ θ 固定时 x 的分布）
- 两者数学上完全相等： $L(\theta; x) = P(x | \theta) = \prod f(x_i; \theta)$
- 分号更“安全”（不会误以为是贝叶斯），竖线更“标准”（符合概率论规范）。两种写法都正确

MLE 从未把 θ 当作随机变量。 $P(\mathcal{D} | \theta = 0.5)$ 的意思是“假设硬币正面概率恰好是 0.5，那么掷出 8 正 2 反的概率是多少”——“ $\theta = 0.5$ ”只是一个假定的场景，不是随机事件。这就像“假如明天下雨，你带伞的概率是多少”——“下雨”在条件位置，不意味着你把天气当作随机变量来建模。

只有当竖线左右颠倒—— $P(\theta | \mathcal{D})$ ——才是贝叶斯，因为此时参数被当作随机变量。

完整示例：正态分布 $N(\mu, \sigma^2)$ 的 MLE

设 $X \sim \mathcal{N}(\mu, \sigma^2)$ ， μ, σ^2 均未知。 $x_1, x_2, \dots, x_n$ 为样本观测值。求 μ, σ^2 的 MLE。

第 1 步：写出 PDF，构造似然函数。

正态分布的 PDF：

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right). \quad (3.8)$$

将 PDF 中的参数固定位置换成变量视角，似然函数为 n 个独立观测的联合密度：

$$L(\mu, \sigma^2) = \prod_{i=1}^n f(x_i; \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right). \quad (3.9)$$

第 2 步：取对数，化积为和。

$$\ell(\mu, \sigma^2) = \ln L(\mu, \sigma^2) = \sum_{i=1}^n \left[-\frac{1}{2} \ln(2\pi) - \frac{1}{2} \ln(\sigma^2) - \frac{(x_i - \mu)^2}{2\sigma^2} \right] \quad (3.10)$$

$$= -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2. \quad (3.11)$$

第 3 步：分别对 μ 和 σ^2 求偏导，令其为零。

对 μ 求偏导：

$$\frac{\partial \ell}{\partial \mu} = -\frac{1}{2\sigma^2} \sum_{i=1}^n 2(x_i - \mu)(-1) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0. \quad (3.12)$$

解得：

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}. \quad (3.13)$$

对 σ^2 求偏导（注意是对 σ^2 整体，而非 σ ）：

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2} \cdot \frac{1}{\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0. \quad (3.14)$$

代入 $\hat{\mu} = \bar{x}$ ，解得：

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2. \quad (3.15)$$

第 4 步：验证极值点。

可以验证二阶导数矩阵（Hessian）为负定， $\hat{\mu}, \hat{\sigma}^2$ 确为极大值点（略）。

注意：MLE 的 $\hat{\sigma}^2$ 分母是 n ，不是 $n-1$ ！

$$\mathbb{E}[\hat{\sigma}_{\text{MLE}}^2] = \frac{n-1}{n} \sigma^2 \neq \sigma^2. \quad (3.16)$$

MLE 给出的方差估计是有偏的（虽然渐近无偏）。这就是为什么样本方差 S^2 用 $n-1$ 做分母——修正了这个偏差。MLE 追求最大化似然，不追求无偏性。

概念纠正：似然函数 $L(\theta)$ 究竟是谁的“概率”？

以下对照你的理解逐条纠正。

你的第 2 点： $f(x_i)$ 能知道每个观测值被取到的概率。

这正是最常见的误区。对连续分布， $f(x_i)$ 是**概率密度**，不是**概率**！对于连续随机变量，单点概率恒为零： $P(X = x_i) = 0$ 。

但“密度”可以理解为“单位长度上的概率浓度”： $P(x_i < X < x_i + dx) \approx f(x_i) \cdot dx$ 。虽然 $f(x_i)$ 本身不是概率（可以大于 1），但 $f(x_i)$ 越大意味着数据集中在 x_i 附近的概率越高。

正因为单点概率为零，MLE 对连续分布用的是 PDF 的乘积而非概率的乘积——这是合理的，因为要比较“哪组参数让观测数据更可能”，只需比较密度的相对大小。

你的第 3 点： $L(\theta; x_i)$ 是在观测到 $\{x_i\}$ 的情况下参数为 θ 的概率。

这是错误的，而且是最关键的概念混淆。

$L(\theta)$ 不等于 $P(\theta | \text{数据})$ 。两者的方向完全不同：

	似然函数 $L(\theta)$	后验概率 $P(\theta \mid \text{数据})$
含义	参数为 θ 时，数据出现的可能性	观测到数据后，参数为 θ 的概率
方向	$\theta \rightarrow$ 数据的分布	数据 $\rightarrow \theta$ 的分布
是否概率	否—— $L(\theta)$ 不是 θ 上的概率分布	是—— $\int P(\theta \mid \mathcal{D}) d\theta = 1$
所属框架	频率学派	贝叶斯学派

$L(\theta)$ 和 PDF 是同一个公式，只是视角不同——前者把数据固定、参数当变量，后者反之。它不满足概率的归一化条件： $\int L(\theta) d\theta$ 一般不等于 1。

> 似然函数不是”参数的后验概率”，它是”固定数据后，参数与数据兼容程度的度量”。

你的第 4 点：为什么 L 能和 PDF 挂钩？

答案：它们本质上是同一个数学表达式，只是”谁当变量”的视角切换。

写出联合 PDF (θ 固定， x 是变量)：

$$f(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta).$$

(3.17)

现在做一次**视角翻转**——数据已经拿到了 ($x_1, \dots, x_n$ 是固定常数)，问题是”哪组 θ 让这些数据最可能？”直接把上面的表达式看作 θ 的函数：

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta).$$

(3.18)

形式上二者一模一样，但数学身份不同： $f(x_1, \dots, x_n; \theta)$ 是 x 上的概率密度（积分为 1）； $L(\theta)$ 是 θ 上的函数（积分一般不为 1，不是密度）。

$f(x_1, \dots, x_n; \theta)$

PDF: θ 固定, x 变量

$\xrightarrow{\text{数据拿到手, } \theta \text{ 变参数}}$

$\xrightarrow{\text{同一个公式, 视角翻转}}$

$L(\theta; x_1, \dots, x_n)$

似然: x 固定, θ 变量

因此你的第 1 点方向正确，只需补充：我们有一组已观测到的数据 $x_1, \dots, x_n$ 。总体分布的形式已知（如正态），参数未知。目标是用观测数据反过来推断最合理的参数值——MLE 就是”哪组 θ 让手上这组数据出现的联合密度最大”。

频率学派 vs. 贝叶斯学派：根本分歧

MLE 和 MAP 分别代表统计推断的两大范式。理解它们的底层分歧，比记住公式更重要。

核心分歧：参数 θ 是什么？

	频率学派 (Frequentist)	贝叶斯学派 (Bayesian)
θ 的本质	θ 是一个固定但未知的常数。没有“ θ 的分布”这个概念。	θ 是一个随机变量，有自己的分布。在观测数据前，你对 θ 已有先验信念 $P(\theta)$ 。
概率的含义	概率是长期频率——无限次重复实验中事件发生的比例。”下次掷硬币正面的概率是 0.5” = 长期来看一半是正面。	概率是信念程度——你对一个命题的相信程度。”明天有 60% 概率下雨” = 你对“明天下雨”有 60% 的把握。
推断的目标	给出 θ 的一个点估计 (MLE) 或一个置信区间。	给出 θ 的整个后验分布 $P(\theta \mathcal{D})$ 。
数据的角色	数据是唯一的随机来源。参数固定，数据随机。	参数和数据都是随机变量。数据更新信念。
核心工具	MLE、假设检验、置信区间	贝叶斯公式、后验分布、可信区间
区间含义	置信区间 : 重复抽样 100 次, 约 95 个区间包含 θ 。不能说“这个区间有 95% 概率包含 θ ”。	可信区间 : 给定数据, θ 落在此区间的概率是 95%。可以直接说“我们有 95% 把握 θ 在区间内”。

用一个具体例子体会差异：

你掷硬币 10 次，8 次正面。想知道硬币正面的概率 p 。

频率学派 (MLE)：

- p 是一个固定的数，只是你不知道。
- $\hat{p} = 8/10 = 0.8$ ，这是 p 的最佳点估计。
- “ p 的 95% 置信区间是 $[0.49, 0.96]$ ”——如果重复这个实验无数次，95% 的置信区间会包含真实的 p 。
- 你不能说“ p 落在这个区间里的概率是 95%”—— p 不是随机的。

贝叶斯学派 (MAP / 后验)：

- p 本身是不确定的——你相信 p 可能接近 0.5（硬币通常公平），但也可能不是。
- 用 Beta(2,2) 作为先验（弱偏向公平），后验为 Beta(10,4)。
- 后验均值 $\frac{10}{14} \approx 0.714$ （比 0.8 更保守，因为先验往回拉了一点）。
- “ p 的 95% 可信区间是 [0.46, 0.90]”——可以直接说“有 95% 的概率 p 在这个区间里”。

MLE 和 MAP 在公式上的区别只有一项：

$$\underbrace{\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \log P(\mathcal{D} | \theta)}_{\text{只看数据}} \quad \underbrace{\hat{\theta}_{\text{MAP}} = \arg \max_{\theta} [\log P(\mathcal{D} | \theta) + \log P(\theta)]}_{\text{数据 + 先验信念}} \quad (3.19)$$

MAP 比 MLE 多了一项 $\log P(\theta)$ ——这就是“你对参数已有的信念”。当 $P(\theta)$ 是均匀分布时，MAP = MLE。

现代 ML 中两类方法的分布：

- **频率派占主导的：**大多数监督学习（线性回归、SVM、GBDT、深度学习训练）——目标就是找一个最好的 θ ，不关心它的分布。
- **贝叶斯派占主导的：**不确定性量化（什么时候模型该说“我不知道”）、小样本学习、超参数调优（贝叶斯优化）、主题模型、变分推断。
- **融合趋势：**现代 DL 中的 Dropout、BatchNorm 的推理可以看作变分推断；Ensemble 本质上是后验分布的蒙特卡洛近似。

深层追问：把 θ 当常数 vs. 当变量，实际差别在哪？

表面上，MLE 和 MAP 都是求一个最优的 θ ，公式只差一项 $\log P(\theta)$ 。但底层的世界观分歧远比公式大：

差别一：能否谈论“ θ 的不确定性”。

频率学派：你只能得到 $\hat{\theta}_{\text{MLE}} = 0.8$ ，这是一个数。你可以构造置信区间，但不能说 θ 落在这个区间的概率是 95%—— θ 不是随机的，它要么在里面，要么不在。95% 是方法的长期成功率，不是本次推断的可信度。

贝叶斯学派：你得到整个后验分布 $P(\theta | \mathcal{D})$ 。你可以直接说“ θ 有 95% 的概率在 [0.46, 0.90] 之间”，也可以量化“ $\theta > 0.5$ 的概率是 97%”。这在需要决策的场景中至关重要——如果有 10% 的概率 θ 落在危险区域，你可能会采取完全不同的行动。

差别二：先验知识能不能进入推断。

频率学派拒绝先验，坚持“让数据自己说话”。这在样本量大时没问题，但在小样本场景下会出荒谬结果：

- 掷硬币 1 次，正面。MLE: $\hat{p} = 1.0$ ，认为硬币永远出正面。
- 掷硬币 3 次，3 次正面。MLE: $\hat{p} = 1.0$ 。但你的常识告诉你”硬币通常接近公平”。

贝叶斯学派用一个温和的先验（如 $\text{Beta}(2,2)$ ，相当于假设已经见过 2 正 2 反）把估计往回拉：1 次正面 $\rightarrow$ 后验均值 $\frac{3}{5} = 0.6$ （比 1.0 合理得多）。

这不是”主观偏见”，而是用先验编码常识，防止小样本过拟合。这在现代 ML 中对应正则化——Ridge 回归的 L_2 惩罚等价于高斯先验，Lasso 的 L_1 惩罚等价于拉普拉斯先验。

差别三：频率论的保证是”长期校准”而非”单次可信”。

这是频率学派最强也最微妙的优势。

一个 95% 置信区间的含义是：如果你把这个实验重复 100 次，每次算一个区间，大约 95 个会包含真实的 θ 。这是一种**过程保证**——方法本身在长期使用中是可靠的。

但贝叶斯 95% 可信区间可能没有这个性质：在重复抽样中，贝叶斯区间可能只有 80% 的次数覆盖真值（如果先验选得不好）。频率学派正是用这一点批评贝叶斯：你的区间说”95% 概率包含 θ ”，但在客观世界中这个覆盖频率可能远低于 95%。

为什么频率学派历史上排斥贝叶斯？三个核心原因：

(1) 先验的主观性（最根本的批评）：

”你的先验 $P(\theta)$ 从哪来？如果两个人用不同的先验，同一个数据得出不同的结论，科学还叫科学吗？”——频率学派追求”客观”推断，只依赖数据，不依赖分析者的主观信念。

(2) θ 经常确实不是随机的：

硬币的正面概率 p 是一个物理常数（虽然你不知道具体值），把它当作随机变量建模在哲学上就是错的。频率学派的回答：我们不需要给 p 一个分布——我们只需要一个估计方法和它的误差特性。

(3) 频率方法有客观的频率保证：

95% 置信区间在长期中确实有 95% 的覆盖率——这是数学定理，不依赖任何先验假设。贝叶斯可信区间没有这种频率主义校准——如果先验错了，区间也错了。

现代视角：分歧在收敛，不在对立。

今天的共识是：两种方法各有适用的场景，不是非此即彼的关系。

场景	推荐方法	原因
n 很大，只需点估计	MLE（频率）	简单、客观、有效。先验被数据淹没，两派结论一致
n 很小，需要利用常识	MAP / 后验（贝叶斯）	纯靠数据会过拟合，先验起正则化作用
需要量化不确定性	后验分布（贝叶斯）	频率区间不能说“概率”，决策需要真正的概率
需要长期频率保证	频率方法	置信区间有客观的覆盖率保证
$p \gg n$ （高维稀疏）	MAP（等价于正则化）	频率派称为“加惩罚项”，贝叶斯派称为“加先验”
A/B 测试、临床试验	频率为主	监管机构要求频率主义的 p 值和错误率控制

一句话总结分歧的本质：

频率派： θ 是客观的常数，推断 = 用随机数据去逼近固定真相。

贝叶斯派： θ 是主观的不确定性，推断 = 用数据更新你对真相的信念。

3.1.3 最大后验估计 (MAP)

引入先验分布 $P(\theta)$ ，最大化后验概率：

$$\hat{\theta}_{\text{MAP}} = \arg \max_{\theta} P(\theta \mid \mathcal{D}) = \arg \max_{\theta} P(\mathcal{D} \mid \theta) P(\theta).$$

(3.20)

注记 3.3 (第二个等号为什么成立？——贝叶斯公式 + 分母与 θ 无关). 贝叶斯公式为：

$$P(\theta \mid \mathcal{D}) = \frac{P(\mathcal{D} \mid \theta) P(\theta)}{P(\mathcal{D})}.$$

(3.21)

其中 $P(\mathcal{D}) = \int P(\mathcal{D} \mid \theta) P(\theta) d\theta$ 是数据的边缘概率。**关键：** $P(\mathcal{D})$ 与 θ 无关——它是对所有可能的 θ 做了积分，积分完成后 θ 已消失。在关于 θ 最大化时， $P(\mathcal{D})$ 是常数，可以直接扔掉：

$$\arg \max_{\theta} P(\theta \mid \mathcal{D}) = \arg \max_{\theta} \frac{P(\mathcal{D} \mid \theta) P(\theta)}{P(\mathcal{D})} = \arg \max_{\theta} P(\mathcal{D} \mid \theta) P(\theta).$$

(3.22)

三步可视化：

$$\underbrace{P(\theta \mid \mathcal{D})}_{\text{后验}} = \frac{\overbrace{P(\mathcal{D} \mid \theta)}^{\text{似然}} \times \overbrace{P(\theta)}^{\text{先验}}}{\underbrace{P(\mathcal{D})}_{\text{与 } \theta \text{ 无关, argmax 时可忽略}}} \xrightarrow{\arg \max_{\theta}} P(\mathcal{D} \mid \theta) P(\theta).$$

直觉：后验 $\propto$ 似然 $\times$ 先验。最大化后验 = 最大化（数据支持度 $\times$ 先验信念）。先验 $P(\theta)$ 把 MLE 的纯数据驱动估计往你认为合理的区域”拉”了一把。

当先验为均匀分布时， $P(\theta)$ 是常数，MAP 退化为 MLE。

3.2 基于截尾样本的最大似然估计

在可靠性试验和寿命试验中，由于时间和成本限制，试验往往在全部样品失效前终止，产生的数据称为**截尾样本**。

3.2.1 定时截尾

试验进行到规定时间 t_0 时停止。假设 n 个样品中有 r 个在 t_0 前失效，失效时间分别为 $t_1 \leq t_2 \leq \dots \leq t_r \leq t_0$ 。

似然函数：

$$L(\theta) = \left[\prod_{i=1}^r f(t_i; \theta) \right] \cdot [1 - F(t_0; \theta)]^{n-r}, \quad (3.23)$$

其中 f 为失效时间分布的 PDF， F 为 CDF， $1 - F(t_0)$ 表示一个样品在 t_0 时仍未失效的概率（生存概率）。

3.2.2 定数截尾

试验进行到有 r 个样品失效时停止，第 r 个失效时间为 t_r 。

似然函数：

$$L(\theta) = \left[\prod_{i=1}^r f(t_i; \theta) \right] \cdot [1 - F(t_r; \theta)]^{n-r}. \quad (3.24)$$

3.2.3 指数分布截尾样本的 MLE

设寿命 $T \sim \text{Exp}(\lambda)$ ，即 $f(t) = \lambda e^{-\lambda t}$ ($t \geq 0$)， $F(t) = 1 - e^{-\lambda t}$ 。

定时截尾下的 MLE：

$$\hat{\lambda} = \frac{r}{\sum_{i=1}^r t_i + (n-r)t_0}. \quad (3.25)$$

3.3 估计量的评选标准

3.3.1 无偏性

定义 3.2 (无偏估计量). 若估计量 $\hat{\theta}$ 满足 $\mathbb{E}[\hat{\theta}] = \theta$ ，则称 $\hat{\theta}$ 为 θ 的无偏估计量。若 $\mathbb{E}[\hat{\theta}] \neq \theta$ ，其差 $\text{Bias}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta$ 称为**偏差**。

例 3.2. $\bar{X}$ 是 μ 的无偏估计量; $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ 是 σ^2 的无偏估计量, 而 $\frac{1}{n} \sum (X_i - \bar{X})^2$ 是有偏的 (渐近无偏)。

3.3.2 有效性

定义 3.3 (有效性). 设 $\hat{\theta}_1$ 与 $\hat{\theta}_2$ 都是 θ 的无偏估计量, 若

$$\text{Var}(\hat{\theta}_1) \leq \text{Var}(\hat{\theta}_2), \quad (3.26)$$

则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效。

在所有无偏估计量中方差达到下界的称为最小方差无偏估计量 (MVUE)。

3.3.3 相合性 (一致性)

定义 3.4 (相合估计量). 若对任意 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \varepsilon) = 1, \quad (3.27)$$

即 $\hat{\theta}_n \xrightarrow{P} \theta$, 则称 $\hat{\theta}_n$ 为 θ 的相合估计量 (一致估计量)。

3.3.4 均方误差 (综合评价)

定义 3.5 (均方误差).

$$\text{MSE}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + (\text{Bias}(\hat{\theta}))^2. \quad (3.28)$$

MSE 同时考虑了方差和偏差, 常用于有偏估计量的比较。

3.4 区间估计

3.4.1 基本概念

点估计给出了参数的一个具体值, 但无法反映估计的精度。区间估计用一个随机区间来估计参数, 并给出该区间包含参数真值的可信程度。

定义 3.6 (置信区间). 设 θ 为总体分布中的未知参数。对于给定的 α ($0 < \alpha < 1$), 若存在统计量 $\hat{\theta}_L = \hat{\theta}_L(X_1, \dots, X_n)$ 和 $\hat{\theta}_U = \hat{\theta}_U(X_1, \dots, X_n)$, 使得

$$P(\hat{\theta}_L < \theta < \hat{\theta}_U) = 1 - \alpha, \quad (3.29)$$

则称随机区间 $(\hat{\theta}_L, \hat{\theta}_U)$ 为 θ 的置信水平为 $1 - \alpha$ 的置信区间。

- $1 - \alpha$: 置信水平 (置信度), 常用 0.90, 0.95, 0.99

- $\hat{\theta}_L$: 置信下限
- $\hat{\theta}_U$: 置信上限

精确解释: 重复抽样 100 次, 大约有 $100 \times (1 - \alpha)$ 个区间包含 θ 。

3.4.2 枢轴量法 (构造置信区间的通用方法)

1. 找一个枢轴量 $G = G(X_1, \dots, X_n; \theta)$, 其分布完全已知且与 θ 无关;
2. 对给定 α , 确定 a, b 使 $P(a < G < b) = 1 - \alpha$;
3. 解不等式 $a < G < b$ 得到 $\hat{\theta}_L < \theta < \hat{\theta}_U$ 。

3.5 正态总体均值与方差的区间估计

3.5.1 单个正态总体均值的置信区间

σ^2 已知时

枢轴量: $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$ 。

μ 的 $1 - \alpha$ 置信区间:

$$\left(\bar{X} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \right). \quad (3.30)$$

常用分位点: $z_{0.025} = 1.96$ ($\alpha = 0.05$), $z_{0.005} = 2.576$ ($\alpha = 0.01$)。

σ^2 未知时

枢轴量: $\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$ 。

μ 的 $1 - \alpha$ 置信区间:

$$\left(\bar{X} - t_{\alpha/2}(n-1) \cdot \frac{S}{\sqrt{n}}, \bar{X} + t_{\alpha/2}(n-1) \cdot \frac{S}{\sqrt{n}} \right). \quad (3.31)$$

3.5.2 单个正态总体方差的置信区间

枢轴量: $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ 。

σ^2 的 $1 - \alpha$ 置信区间:

$$\left(\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)} \right). \quad (3.32)$$

注意: χ^2 分布不对称, 需双侧分位点。

3.5.3 两个正态总体均值差的置信区间

σ_1^2, σ_2^2 已知

$$\left((\bar{X} - \bar{Y}) - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, (\bar{X} - \bar{Y}) + z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right). \quad (3.33)$$

$\sigma_1^2 = \sigma_2^2 = \sigma^2$ 但 σ^2 未知

枢轴量涉及 S_w (合并方差) 和 $t(n_1 + n_2 - 2)$:

$$\left((\bar{X} - \bar{Y}) \pm t_{\alpha/2}(n_1 + n_2 - 2) \cdot S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right). \quad (3.34)$$

3.5.4 两个正态总体方差比的置信区间

枢轴量: $\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$ 。

$\frac{\sigma_1^2}{\sigma_2^2}$ 的 $1 - \alpha$ 置信区间:

$$\left(\frac{S_1^2}{S_2^2} \cdot \frac{1}{F_{\alpha/2}(n_1 - 1, n_2 - 1)}, \frac{S_1^2}{S_2^2} \cdot \frac{1}{F_{1-\alpha/2}(n_1 - 1, n_2 - 1)} \right). \quad (3.35)$$

3.6 (0-1) 分布参数的区间估计

设总体 $X \sim B(1, p)$, 即 $P(X = 1) = p$, $P(X = 0) = 1 - p$ 。

由中心极限定理, 当 n 充分大时:

$$\frac{\bar{X} - p}{\sqrt{p(1-p)/n}} \xrightarrow{d} \mathcal{N}(0, 1). \quad (3.36)$$

p 的近似 $1 - \alpha$ 置信区间 (解二次不等式):

$$\frac{1}{1 + \frac{z_{\alpha/2}^2}{n}} \left(\hat{p} + \frac{z_{\alpha/2}^2}{2n} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n} + \frac{z_{\alpha/2}^2}{4n^2}} \right), \quad (3.37)$$

其中 $\hat{p} = \bar{X} = \frac{1}{n} \sum X_i$ 。

当 n 很大且 $\hat{p}$ 不接近 0 或 1 时, 可用简化公式:

$$\left(\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}, \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right). \quad (3.38)$$

3.7 单侧置信区间

在某些实际问题中, 我们只关心参数的上限 (不超过多少) 或下限 (不低于多少), 此时使用单侧置信区间。

定义 3.7 (单侧置信区间). • **单侧置信上限:** 若 $P(\theta < \hat{\theta}_U) = 1 - \alpha$, 则 $(-\infty, \hat{\theta}_U)$ 为单侧置信区间, $\hat{\theta}_U$ 为单侧置信上限;

• **单侧置信下限:** 若 $P(\theta > \hat{\theta}_L) = 1 - \alpha$, 则 $(\hat{\theta}_L, +\infty)$ 为单侧置信区间, $\hat{\theta}_L$ 为单侧置信下限。

构造方法: 与双侧类似, 但将 $\alpha/2$ 换为 α :

例 3.3 (正态总体均值的单侧置信区间 (σ^2 未知)). • **单侧上限:** $\mu < \bar{X} + t_\alpha(n-1) \cdot \frac{S}{\sqrt{n}}$

• **单侧下限:** $\mu > \bar{X} - t_\alpha(n-1) \cdot \frac{S}{\sqrt{n}}$

例 3.4 (正态总体方差的单侧置信区间). σ^2 的单侧上限:

$$\sigma^2 < \frac{(n-1)S^2}{\chi_{1-\alpha}^2(n-1)}. \quad (3.39)$$

如材料的强度只需关注下限, 寿命的方差只需关注上限。

第四章 假设检验

4.1 假设检验的基本概念

4.1.1 假设检验问题

在许多实际问题中，我们不仅需要对未知参数作出估计，还需要对总体的某些特性作出判断。例如：

- 新药是否比旧药更有效？
- 某批产品的次品率是否超过 3%？
- 两种测量方法的精度是否相同？

这类问题可以归结为**假设检验** (hypothesis testing)：先对总体提出一个假设，然后利用样本信息来判断这个假设是否成立。

定义 4.1 (原假设与备择假设). 将需要检验的假设称为**原假设** (零假设, null hypothesis), 记为 H_0 ; 与原假设对立的假设称为**备择假设** (alternative hypothesis), 记为 H_1 。

例如，检验总体均值 μ 是否等于某给定值 μ_0 ：

- 双侧检验： $H_0 : \mu = \mu_0$ vs. $H_1 : \mu \neq \mu_0$
- 右侧检验： $H_0 : \mu \leq \mu_0$ vs. $H_1 : \mu > \mu_0$
- 左侧检验： $H_0 : \mu \geq \mu_0$ vs. $H_1 : \mu < \mu_0$

4.1.2 两类错误

由于决策基于样本，我们可能犯两类错误：

定义 4.2 (第一类错误与第二类错误). • **第一类错误 (弃真)**： H_0 为真时拒绝 H_0 ,

$$\alpha = P(\text{拒绝 } H_0 \mid H_0 \text{ 为真}). \quad (4.1)$$

α 称为**显著性水平** (significance level), 通常取 0.01, 0.05, 0.10。

- 第二类错误（取伪）： H_0 为假时接受 H_0 ,

$$\beta = P(\text{接受 } H_0 \mid H_0 \text{ 为假}). \quad (4.2)$$

	H_0 为真	H_0 为假
接受 H_0	正确决策	第二类错误 (β)
拒绝 H_0	第一类错误 (α)	正确决策

Neyman–Pearson 原则：在控制第一类错误概率 α 的前提下，使第二类错误概率 β 尽可能小。

定义 4.3 (检验的功效). 当 H_1 为真时拒绝 H_0 的概率称为检验的**功效** (power):

$$\text{power} = 1 - \beta = P(\text{拒绝 } H_0 \mid H_0 \text{ 为假}). \quad (4.3)$$

4.1.3 拒绝域与检验统计量

定义 4.4 (拒绝域). 当检验统计量落入某区域 W 时拒绝 H_0 , 则 W 称为**拒绝域** (rejection region) 或临界域。

假设检验的基本步骤:

1. 提出原假设 H_0 和备择假设 H_1 ;
2. 选取适当的检验统计量, 并在 H_0 为真下确定其分布;
3. 给定显著性水平 α , 确定拒绝域 W ;
4. 由样本计算检验统计量的观测值, 若落入 W 则拒绝 H_0 , 否则不拒绝 H_0 。

4.2 正态总体均值的假设检验

4.2.1 单个正态总体均值的检验

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$, 检验 $H_0: \mu = \mu_0$ 。

情形 1: σ^2 已知— Z 检验

检验统计量:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1) \quad (\text{在 } H_0 \text{ 下}). \quad (4.4)$$

备择假设	拒绝域
$H_1: \mu \neq \mu_0$	$ Z \geq z_{\alpha/2}$
$H_1: \mu > \mu_0$	$Z \geq z_\alpha$
$H_1: \mu < \mu_0$	$Z \leq -z_\alpha$

情形 2: σ^2 未知— t 检验

用样本标准差 S 代替 σ :

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1) \quad (\text{在 } H_0 \text{ 下}). \quad (4.5)$$

备择假设	拒绝域
$H_1: \mu \neq \mu_0$	$ T \geq t_{\alpha/2}(n-1)$
$H_1: \mu > \mu_0$	$T \geq t_{\alpha}(n-1)$
$H_1: \mu < \mu_0$	$T \leq -t_{\alpha}(n-1)$

4.2.2 两个正态总体均值差的检验

设 $X_1, \dots, X_{n_1} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu_1, \sigma_1^2)$, $Y_1, \dots, Y_{n_2} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu_2, \sigma_2^2)$, 两样本独立。检验 $H_0: \mu_1 - \mu_2 = \delta$ (常取 $\delta = 0$)。

情形 1: σ_1^2, σ_2^2 已知

$$Z = \frac{(\bar{X} - \bar{Y}) - \delta}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0, 1). \quad (4.6)$$

情形 2: $\sigma_1^2 = \sigma_2^2 = \sigma^2$ 但未知

合并方差 $S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$, 检验统计量:

$$T = \frac{(\bar{X} - \bar{Y}) - \delta}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2). \quad (4.7)$$

情形 3: $\sigma_1^2 \neq \sigma_2^2$ 且未知 (Welch t 检验)

$$T = \frac{(\bar{X} - \bar{Y}) - \delta}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}, \quad (4.8)$$

其自由度由 Welch-Satterthwaite 公式近似:

$$\nu = \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}. \quad (4.9)$$

4.2.3 配对数据的 t 检验

当两个样本不独立而是配对出现时 (如同一组受试者在处理前后的测量值), 令

$$D_i = X_i - Y_i, \quad i = 1, \dots, n. \quad (4.10)$$

假设 $D_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu_D, \sigma_D^2)$, 检验 $H_0: \mu_D = 0$, 使用单样本 t 检验:

$$T = \frac{\bar{D}}{S_D/\sqrt{n}} \sim t(n-1). \quad (4.11)$$

4.3 正态总体方差的假设检验

4.3.1 单个正态总体方差的检验— χ^2 检验

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$, 检验 $H_0: \sigma^2 = \sigma_0^2$.

检验统计量:

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1) \quad (\text{在 } H_0 \text{ 下}). \quad (4.12)$$

备择假设	拒绝域
$H_1: \sigma^2 \neq \sigma_0^2$	$\chi^2 \leq \chi_{1-\alpha/2}^2(n-1)$ 或 $\chi^2 \geq \chi_{\alpha/2}^2(n-1)$
$H_1: \sigma^2 > \sigma_0^2$	$\chi^2 \geq \chi_{\alpha}^2(n-1)$
$H_1: \sigma^2 < \sigma_0^2$	$\chi^2 \leq \chi_{1-\alpha}^2(n-1)$

4.3.2 两个正态总体方差比的检验— F 检验

设两样本独立, 检验 $H_0: \sigma_1^2 = \sigma_2^2$ (即 $\sigma_1^2/\sigma_2^2 = 1$).

检验统计量:

$$F = \frac{S_1^2}{S_2^2} \sim F(n_1-1, n_2-1) \quad (\text{在 } H_0 \text{ 下}). \quad (4.13)$$

备择假设	拒绝域
$H_1: \sigma_1^2 \neq \sigma_2^2$	$F \leq F_{1-\alpha/2}(n_1-1, n_2-1)$ 或 $F \geq F_{\alpha/2}(n_1-1, n_2-1)$
$H_1: \sigma_1^2 > \sigma_2^2$	$F \geq F_{\alpha}(n_1-1, n_2-1)$
$H_1: \sigma_1^2 < \sigma_2^2$	$F \leq F_{1-\alpha}(n_1-1, n_2-1)$

注记 4.1. 实际计算时常用 $F = \max(S_1^2, S_2^2)/\min(S_1^2, S_2^2)$ 简化为上侧检验。

4.4 置信区间与假设检验之间的关系

置信区间与假设检验之间存在深刻的对偶关系 (duality)。

定理 4.1 (置信区间与假设检验的对偶性). 参数 θ 的 $1-\alpha$ 置信区间恰好由所有使得双侧检验 $H_0: \theta = \theta_0$ 在显著性水平 α 下不被拒绝的 θ_0 组成。

换句话说:

- 若 θ_0 落在 $1 - \alpha$ 置信区间内 $\iff$ 不拒绝 $H_0 : \theta = \theta_0$ (显著性水平 α);
- 若 θ_0 不在 $1 - \alpha$ 置信区间内 $\iff$ 拒绝 $H_0 : \theta = \theta_0$ 。

例 4.1 (均值检验与置信区间的对应). 已知方差时, μ 的 95% 置信区间为 $\bar{X} \pm z_{0.025} \cdot \sigma / \sqrt{n}$ 。双侧 Z 检验在 $|Z| \geq z_{0.025}$ 时拒绝 $H_0 : \mu = \mu_0$, 这等价于 μ_0 不在上述置信区间内。

实际意义:

- 置信区间提供了**更多信息**: 不仅告诉我们是否拒绝 H_0 , 还给出了参数的可能取值范围;
- 假设检验给出明确的**二值决策**: 在需要做出是否采取行动的场合更有用。

4.5 样本容量的选取

在实际问题中, 我们需要在抽样前确定所需的样本容量 n , 以保证检验达到指定的功效。

4.5.1 Z 检验的样本容量

考虑 $H_0 : \mu = \mu_0$ vs. $H_1 : \mu = \mu_1$ (σ^2 已知)。

对于显著性水平 α 和功效 $1 - \beta$, 所需样本容量为:

双侧检验:

$$n \approx \frac{(z_{\alpha/2} + z_{\beta})^2 \sigma^2}{(\mu_1 - \mu_0)^2}. \quad (4.14)$$

单侧检验:

$$n \approx \frac{(z_{\alpha} + z_{\beta})^2 \sigma^2}{(\mu_1 - \mu_0)^2}. \quad (4.15)$$

其中 $\Delta = |\mu_1 - \mu_0|$ 是我们希望检测出的**最小差异** (effect size)。

例 4.2. 某工厂想检验产品重量的均值是否为 500 g。已知 $\sigma = 5$ g, 若真实的均值为 502 g, 希望在 $\alpha = 0.05$, power = 0.90 下能检测出来, 求所需样本容量。

由 $z_{0.025} = 1.96$, $z_{0.10} = 1.28$:

$$n \approx \frac{(1.96 + 1.28)^2 \times 5^2}{(502 - 500)^2} = \frac{(3.24)^2 \times 25}{4} \approx 65.6, \quad (4.16)$$

故取 $n = 66$ 。

4.5.2 t 检验的样本容量

当 σ^2 未知时, 使用迭代方法或查 OC 曲线 (operating characteristic curve) 来确定样本容量。OC 曲线给出了不同样本量下第二类错误概率 β 与参数真值的关系。

4.5.3 影响样本容量的因素

- 效应量 Δ : 希望检测的差异越小, 需要的 n 越大;
- 显著性水平 α : α 越小, 需要的 n 越大;
- 功效 $1 - \beta$: 功效要求越高, 需要的 n 越大;
- 总体方差 σ^2 : 方差越大, 需要的 n 越大。

4.6 分布拟合检验

在许多实际问题中, 总体的分布类型是未知的。我们需要根据样本检验总体是否服从某个指定的分布。

4.6.1 χ^2 拟合优度检验

思想: 将样本分组, 比较各组的观测频数与在 H_0 下的期望频数。

定义 4.5 (Pearson χ^2 统计量). 设将总体取值范围分为 k 个互不相交的区间, 第 i 个区间的观测频数为 f_i , 在 H_0 (总体服从某特定分布) 下的期望频数为 $\hat{e}_i = n \cdot \hat{p}_i$, 其中 $\hat{p}_i$ 为 H_0 下落入第 i 区间的概率。

Pearson χ^2 统计量:

$$\chi^2 = \sum_{i=1}^k \frac{(f_i - \hat{e}_i)^2}{\hat{e}_i}. \quad (4.17)$$

当 $n \rightarrow \infty$ 时, 若 H_0 为真,

$$\chi^2 \xrightarrow{d} \chi^2(k - r - 1), \quad (4.18)$$

其中 r 为 H_0 分布中待估参数的个数。

拒绝域: $\chi^2 \geq \chi_{\alpha}^2(k - r - 1)$ 。

注意事项:

- 每个区间的期望频数应 ≥ 5 , 否则需合并区间;
- 适用于大样本 ($n \geq 50$) 且既可用于离散分布也可用于连续分布。

例 4.3 (检验骰子是否均匀). 掷一枚骰子 120 次, 记录各面出现次数。检验 H_0 : 骰子是均匀的 ($p_i = 1/6$)。期望频数均为 $120/6 = 20$ 。

若观测频数为 $f = (18, 22, 17, 21, 19, 23)$:

$$\chi^2 = \frac{(18 - 20)^2}{20} + \frac{(22 - 20)^2}{20} + \cdots + \frac{(23 - 20)^2}{20} = 1.7 < \chi_{0.05}^2(5) = 11.07, \quad (4.19)$$

故不拒绝 H_0 , 认为骰子是均匀的。

4.6.2 正态性检验概述

判断数据是否来自正态总体是许多统计方法的前提。

常用方法：

- **Q-Q 图 (Quantile-Quantile Plot)**: 将样本分位数与正态理论分位数作图, 若近似为直线则支持正态性假设;
- **Shapiro-Wilk 检验**: 适用于小样本 ($n \leq 50$), 功效较高;
- **Kolmogorov-Smirnov 检验**: 基于经验分布函数与理论分布函数的最大差异;
- **Jarque-Bera 检验**: 基于样本偏度和峰度, 适用于大样本。

4.7 秩和检验

前面讨论的 t 检验等均假设总体服从正态分布。当正态性假设不成立或数据为定序数据时, 需使用非参数方法。秩和检验是最常用的非参数检验之一。

4.7.1 Wilcoxon 秩和检验 (两独立样本)

目的: 比较两个独立总体的位置参数是否相同, 是两样本 t 检验的非参数替代。

注记 4.2 (与 t 检验的对应关系). 注意区分两种不同的一一对应:

参数方法	非参数替代
单样本 t 检验 ($H_0: \mu = \mu_0$)	Wilcoxon 符号秩检验
两样本 t 检验 ($H_0: \mu_1 = \mu_2$)	Wilcoxon 秩和检验

两样本 t 检验是一次性直接比较两个组的均值差, 用 $T = \frac{\bar{X}_1 - \bar{X}_2}{S_w \sqrt{1/n_1 + 1/n_2}}$ 作为统计量, 而不是分别对每组各做一次单样本 t 检验。秩和检验也是如此——它将两组数据合并排序后统一比较。

步骤:

1. 将两组数据 (样本量 n_1, n_2) 合并, 从小到大排序并赋予秩 (rank), 相同值赋予平均秩;
2. 计算第一组样本的秩和 R_1 ;
3. 检验统计量:

$$U = n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - R_1. \quad (4.20)$$

或等价地使用 R_1 本身。

当 n_1, n_2 较大时, R_1 近似服从正态分布:

$$\mathbb{E}[R_1] = \frac{n_1(n_1 + n_2 + 1)}{2}, \quad \text{Var}(R_1) = \frac{n_1 n_2 (n_1 + n_2 + 1)}{12}. \quad (4.21)$$

例 4.4 (Wilcoxon 秩和检验完整演示). 某研究比较两种教学法对学生成绩的影响。随机抽取 A 班 6 名学生、B 班 7 名学生, 期末考试成绩如下 (满分 100):

A 班	72	68	85	91	55	77	
B 班	60	75	82	63	70	58	79

检验 H_0 : 两种教学法的成绩分布相同 vs. H_1 : 两种教学法成绩分布不同 ($\alpha = 0.05$, 双侧)。

步骤 1: 合并排序并赋予秩

将两班共 $n_1 + n_2 = 13$ 个数据从小到大排列, 同分取平均秩:

原始值	所属班	排序位次	秩
55	A	1	1
58	B	2	2
60	B	3	3
63	B	4	4
68	A	5	5
70	B	6	6
72	A	7	7
75	B	8	8
77	A	9	9
79	B	10	10
82	B	11	11
85	A	12	12
91	A	13	13

步骤 2: 计算 A 班的秩和 R_1

$$R_1 = 1 + 5 + 7 + 9 + 12 + 13 = 47. \quad (4.22)$$

步骤 3: 计算检验统计量

取 $n_1 = 6$ (A 班), $n_2 = 7$ (B 班)。

Mann-Whitney U 统计量:

$$U = n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - R_1 = 6 \times 7 + \frac{6 \times 7}{2} - 47 = 42 + 21 - 47 = 16. \quad (4.23)$$

R_1 在 H_0 下的期望与方差:

$$\mathbb{E}[R_1] = \frac{n_1(n_1 + n_2 + 1)}{2} = \frac{6 \times 14}{2} = 42, \quad (4.24)$$

$$\text{Var}(R_1) = \frac{n_1 n_2 (n_1 + n_2 + 1)}{12} = \frac{6 \times 7 \times 14}{12} = 49. \quad (4.25)$$

标准化 (大样本近似):

$$Z = \frac{R_1 - \mathbb{E}[R_1]}{\sqrt{\text{Var}(R_1)}} = \frac{47 - 42}{\sqrt{49}} = \frac{5}{7} \approx 0.714. \quad (4.26)$$

步骤 4: 做出决策

双侧检验, $\alpha = 0.05$, $z_{0.025} = 1.96$ 。

$|Z| = 0.714 < 1.96$, 不拒绝 H_0 。

也可用精确检验: 查 Wilcoxon 秩和检验临界值表, 对于 $n_1 = 6, n_2 = 7$ (双侧 $\alpha = 0.05$), 临界下界 $R_L = 30$, 临界上界 $R_U = 54$ 。 $R_1 = 47$ 落在 $[30, 54]$ 内, 同样不拒绝 H_0 。

结论: 在 $\alpha = 0.05$ 水平下, 没有足够证据认为两种教学法的成绩分布存在显著差异。

补充—— p 值计算:

$$p = 2 \times P(Z \geq 0.714 | H_0) = 2 \times (1 - \Phi(0.714)) \approx 2 \times 0.2375 = 0.475. \quad (4.27)$$

$p = 0.475 > 0.05$, 与上述结论一致。

特点: 不依赖总体分布的具体形式, 对异常值稳健 (robust), 但功效略低于 t 检验 (当正态假设成立时)。

4.7.2 Wilcoxon 符号秩检验 (配对样本)

目的: 配对样本 t 检验的非参数替代。与秩和检验不同, 符号秩检验对应的是**配对设计** (同一受试者前后测量), 等价于对差值 D_i 做单样本检验, 即 H_0 : 差值的分布关于 0 对称。

步骤:

1. 计算每对数据的差值 $D_i = X_i - Y_i$, 去掉 $D_i = 0$ 的对;
2. 对 $|D_i|$ 从小到大赋予秩;
3. 分别计算正差值对应的秩和 R^+ 与负差值对应的秩和 R^- ;
4. 检验统计量可取 R^+ (或 R^-), 其分布在 H_0 下可查 Wilcoxon 符号秩检验表。

当有效对数 n 较大时 (通常 $n \geq 20$), R^+ 近似服从正态分布:

$$\mathbb{E}[R^+] = \frac{n(n+1)}{4}, \quad \text{Var}(R^+) = \frac{n(n+1)(2n+1)}{24}. \quad (4.28)$$

例 4.5 (Wilcoxon 符号秩检验完整演示). 某研究想测试服用某种补充剂是否能改善睡眠时长。招募 10 名受试者，记录服用前与服用一个月后的睡眠时长（小时），数据如下：

受试者编号	1	2	3	4	5	6	7	8	9	10
服用前 (Y_i)	6.2	7.0	5.8	6.5	7.5	5.5	6.0	7.2	6.8	5.9
服用后 (X_i)	6.8	7.3	6.1	7.0	7.6	5.4	6.5	7.5	7.1	6.4

检验 H_0 : 服用前后睡眠时长无差异 vs. H_1 : 服用后睡眠时长增加 ($\alpha = 0.05$, 右侧检验)。

步骤 1: 计算差值 $D_i = X_i - Y_i$ 并取绝对值

受试者	X_i (后)	Y_i (前)	$D_i = X_i - Y_i$
1	6.8	6.2	+0.6
2	7.3	7.0	+0.3
3	6.1	5.8	+0.3
4	7.0	6.5	+0.5
5	7.6	7.5	+0.1
6	5.4	5.5	-0.1
7	6.5	6.0	+0.5
8	7.5	7.2	+0.3
9	7.1	6.8	+0.3
10	6.4	5.9	+0.5

没有 $D_i = 0$ 的对，有效对数 $n = 10$ 。

步骤 2: 对 $|D_i|$ 从小到大赋予秩

受试者	D_i	$ D_i $	$ D_i $ 排序	秩
5	+0.1	0.1	1	1
6	-0.1	0.1	2	2
2	+0.3	0.3	3	4
3	+0.3	0.3	4	4
8	+0.3	0.3	5	4
9	+0.3	0.3	6	4
4	+0.5	0.5	7	8
7	+0.5	0.5	8	8
10	+0.5	0.5	9	8
1	+0.6	0.6	10	10

注意结的处理：

- $|D_i| = 0.1$ 出现 2 次（位次 1, 2），秩各为 $\frac{1+2}{2} = 1.5$ ；
- $|D_i| = 0.3$ 出现 4 次（位次 3–6），秩各为 $\frac{3+4+5+6}{4} = 4.5$ ；
- $|D_i| = 0.5$ 出现 3 次（位次 7–9），秩各为 $\frac{7+8+9}{3} = 8$ ；
- $|D_i| = 0.6$ 出现 1 次，秩为 10。

带符号的秩：

受试者	D_i	符号	带符号秩
1	+0.6	+	+10
2	+0.3	+	+4.5
3	+0.3	+	+4.5
4	+0.5	+	+8
5	+0.1	+	+1.5
6	-0.1	-	-1.5
7	+0.5	+	+8
8	+0.3	+	+4.5
9	+0.3	+	+4.5
10	+0.5	+	+8

步骤 3：计算正秩和 R^+ 与负秩和 R^-

$$R^+ = 10 + 4.5 + 4.5 + 8 + 1.5 + 8 + 4.5 + 4.5 + 8 = 53.5, \quad (4.29)$$

$$R^- = 1.5. \quad (4.30)$$

验证： $R^+ + R^- = 53.5 + 1.5 = 55 = \frac{10 \times 11}{2} = \frac{n(n+1)}{2}$ 。✓

步骤 4：使用正态近似计算 Z 统计量

$$\mathbb{E}[R^+] = \frac{n(n+1)}{4} = \frac{10 \times 11}{4} = 27.5, \quad (4.31)$$

$$\text{Var}(R^+) = \frac{n(n+1)(2n+1)}{24} = \frac{10 \times 11 \times 21}{24} = \frac{2310}{24} = 96.25. \quad (4.32)$$

$$Z = \frac{R^+ - \mathbb{E}[R^+]}{\sqrt{\text{Var}(R^+)}} = \frac{53.5 - 27.5}{\sqrt{96.25}} = \frac{26}{9.811} \approx 2.650. \quad (4.33)$$

步骤 5：做出决策

右侧检验, $\alpha = 0.05$, $z_{0.05} = 1.645$ 。

$Z = 2.650 > 1.645$, 拒绝 H_0 。

也可查 Wilcoxon 符号秩检验临界值表: $n = 10$, 右侧 $\alpha = 0.05$ 时临界值为 $T_{0.05} = 44$ 。 $R^+ = 53.5 > 44$, 同样拒绝 H_0 。

结论: 在 $\alpha = 0.05$ 水平下, 有显著证据表明服用该补充剂后睡眠时长有所增加。

补充—— p 值计算 (正态近似):

$$p = P(Z \geq 2.650 \mid H_0) = 1 - \Phi(2.650) \approx 1 - 0.9960 = 0.004. \quad (4.34)$$

$p = 0.004 < 0.01$, 属于强证据拒绝 H_0 。

注记 4.3. 非参数方法的优势在于无需分布假设, 适用于小样本、有异常值或定序数据的情形。但其代价是当分布假设实际成立时, 功效略低于对应的参数方法。

4.8 假设检验问题的 p 值检验法

4.8.1 p 值的定义

传统检验方法需预先指定显著性水平 α , 然后给出“拒绝”或“不拒绝”的二值结论。但在实际应用中 (尤其是在科学研究和机器学习中), 更常用的是 p 值。

定义 4.6 (p 值). 在原假设 H_0 为真的条件下, 观察到比当前样本更极端结果的概率。

设检验统计量的观测值为 t_{obs} , 则:

- 双侧检验: $p = 2 \cdot P(T \geq |t_{\text{obs}}| \mid H_0)$;
- 右侧检验: $p = P(T \geq t_{\text{obs}} \mid H_0)$;
- 左侧检验: $p = P(T \leq t_{\text{obs}} \mid H_0)$ 。

4.8.2 p 值的解释

p 值范围	解释
$p \leq 0.01$	强证据拒绝 H_0
$0.01 < p \leq 0.05$	中等证据拒绝 H_0
$0.05 < p \leq 0.10$	弱证据拒绝 H_0
$p > 0.10$	不足以拒绝 H_0

p 值的优势:

- 提供了比“拒绝/不拒绝”更丰富的信息——反映了证据的强度;

- 读者可根据自己的 α 标准自行判断;
- 是现代科学研究 (尤其是生命科学、社会科学) 中报告检验结果的标准方式。

注记 4.4 (关于 p 值的常见误解). • p 值不是 H_0 为真的概率;

- p 值不是效应的大小 (effect size 需单独报告);
- 大样本下微小的效应也可能得到很小的 p 值, ”显著” 不等于 ”重要”。

4.8.3 p 值与置信区间的关系

$p < \alpha$ 等价于 $1 - \alpha$ 置信区间不包含 H_0 下的参数值。因此 p 值检验法与置信区间法在数学上等价。

例 4.6 (p 值检验法完整演示). 某灌装生产线标称每瓶装 500 ml。质检员随机抽取 $n = 25$ 瓶, 测得 $\bar{X} = 503.2$ ml。已知灌装量服从正态分布, 且长期记录表明 $\sigma = 8$ ml。问: 是否有证据表明灌装量偏离了 500 ml? (取 $\alpha = 0.05$)

步骤 1: 建立假设

$$H_0: \mu = 500 \quad \text{vs.} \quad H_1: \mu \neq 500 \quad (\text{双侧检验}). \quad (4.35)$$

步骤 2: 计算检验统计量

方差已知, 使用 Z 检验:

$$Z_{\text{obs}} = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} = \frac{503.2 - 500}{8/\sqrt{25}} = \frac{3.2}{1.6} = 2.00. \quad (4.36)$$


步骤 3: 计算 p 值

因为是双侧检验, p 值为观察到 $|Z| \geq 2.00$ 的概率:

$$p = 2 \times P(Z \geq 2.00 | H_0) = 2 \times (1 - \Phi(2.00)). \quad (4.37)$$

查标准正态分布表, $\Phi(2.00) = 0.9772$:

$$p = 2 \times (1 - 0.9772) = 2 \times 0.0228 = 0.0456. \quad (4.38)$$



步骤 4：做出决策

- $p = 0.0456 < \alpha = 0.05$ ，拒绝 H_0 。
- 按 p 值解释标准， $0.01 < p \leq 0.05$ ，属于**中等证据**。

结论：在 $\alpha = 0.05$ 水平下，有显著证据表明灌装量偏离了 500 ml。样本均值 503.2 ml 比标称值高出 3.2 ml，但 $p = 0.0456$ 接近 0.05，证据不算极强，建议增加样本量再次检验。

对比——传统拒绝域法：

若用拒绝域法， $z_{0.025} = 1.96$ ， $|Z_{\text{obs}}| = 2.00 > 1.96$ ，落入拒绝域，同样拒绝 H_0 。两种方法结论一致。

但 p 值法额外告诉我们：若 α 设为 0.01 ($z_{0.005} = 2.576$)，则 $|Z_{\text{obs}}| = 2.00 < 2.576$ ， $p = 0.0456 > 0.01$ ，不拒绝 H_0 。这说明结论**依赖于所选的 α** 。 p 值让读者可以自行判断，而不必受制于作者事先选择的 α 。

延伸——若为单侧检验：

如果质检员只关心灌装量是否**偏多**（右侧检验 $H_1: \mu > 500$ ）：

$$p_{\text{右侧}} = P(Z \geq 2.00) = 1 - \Phi(2.00) = 0.0228. \quad (4.39)$$

$p = 0.0228 < 0.05$ ，同样拒绝 H_0 （证据更强，因为 p 比双侧小一半）。

如果只关心是否**偏少**（左侧检验 $H_1: \mu < 500$ ）：

$$p_{\text{左侧}} = P(Z \leq 2.00) = \Phi(2.00) = 0.9772. \quad (4.40)$$

$p = 0.9772 \gg 0.05$ ，毫无证据拒绝 H_0 。这与样本均值 $503.2 > 500$ 的方向一致。

本章小结

本章系统介绍了统计推断的另一核心内容——假设检验：

1. **基本框架：**原假设/备择假设的设定、两类错误及其概率 α, β 、拒绝域的构造；
2. **正态总体均值检验：** Z 检验（方差已知）、 t 检验（方差未知）、两样本与配对检验；
3. **正态总体方差检验：** χ^2 检验（单总体）、 F 检验（两总体方差比）；
4. **置信区间与检验的对偶性：**置信区间可视为所有不被拒绝的参数值集合；
5. **样本容量选取：**根据效应量、 α 、功效等在抽样前确定所需 n ；
6. **分布拟合检验：**Pearson χ^2 检验判断总体是否服从指定分布；

7. **秩和检验**：不依赖正态假设的非参数方法（Wilcoxon 秩和检验、符号秩检验）；
8. **p 值检验法**：提供证据强度的连续度量，是现代统计实践的标准。

假设检验与参数估计共同构成了**统计推断**的两大基石。在机器学习中，假设检验广泛应用于 A/B 测试、特征选择、模型比较与分布漂移检测等场景。

第五章 方差分析及回归分析

方差分析（ANOVA）和回归分析是统计建模中两类核心方法：

- 方差分析：比较多个总体的均值是否有显著差异（ t 检验的推广）；
- 回归分析：建模自变量与因变量之间的数量关系。

两者在数学上同源——都可以纳入一般线性模型的框架。

5.1 单因素试验的方差分析

5.1.1 问题的提出

前面学过的两样本 t 检验只能比较两个总体的均值。当需要比较三个或更多总体时（如比较 A、B、C 三种教学法的效果），若逐对做 t 检验会累积第一类错误。方差分析（Analysis of Variance, ANOVA）为此提供了一次性检验多个均值是否全相等的框架。

定义 5.1 (单因素方差分析模型). 设因素 A 有 r 个水平，第 i 个水平下有 n_i 个观测值：

$$X_{ij} = \mu_i + \varepsilon_{ij}, \quad i = 1, \dots, r, \quad j = 1, \dots, n_i, \quad (5.1)$$

其中 $\varepsilon_{ij} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2)$ 。

检验假设：

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_r \quad \text{vs.} \quad H_1 : \text{至少有两个 } \mu_i \text{ 不等.} \quad (5.2)$$

ANOVA 的三个前提条件（单因素、双因素均适用）：

1. **独立性**：各观测值相互独立——由随机抽样或随机分配保证；
2. **正态性**：各组数据来自正态总体——用 Q-Q 图或 Shapiro-Wilk 检验诊断；
3. **方差齐性**：各组总体方差相等 $\sigma_1^2 = \dots = \sigma_r^2$ ——用 Levene 检验或 Bartlett 检验诊断。

ANOVA 对正态性偏离有一定鲁棒性，但对方差严重不等较为敏感。

注记 5.1 (模型的另一种参数化). 单因素模型也可等价地写成与双因素统一的形式:

$$X_{ij} = \mu + \alpha_i + \varepsilon_{ij}, \quad \sum_{i=1}^r \alpha_i = 0, \quad (5.3)$$

其中 μ 为总均值 (grand mean), $\alpha_i = \mu_i - \mu$ 为第 i 组偏离总均值的效应量。

这揭示了一种统一的视角: **每个观测值 = 总均值 + 该组效应 + 随机误差**。单因素用 μ_i 更简洁, 双因素因格子均值同时受两个因素影响, 拆成 $\mu + \alpha_i + \beta_j$ 更自然——但两者本质相同。

5.1.2 平方和分解

核心思想: 将总变异分解为**组间变异** (因素引起) 和**组内变异** (随机误差引起), 比较两者的相对大小。

记总均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^r \sum_{j=1}^{n_i} X_{ij}$, 第 i 组均值为 $\bar{X}_{i\cdot} = \frac{1}{n_i} \sum_{j=1}^{n_i} X_{ij}$ 。

分解的核心恒等式 (对每个观测值):

$$X_{ij} - \bar{X} = (\bar{X}_{i\cdot} - \bar{X}) + (X_{ij} - \bar{X}_{i\cdot}). \quad (5.4)$$

即: **总离差 = 组间离差 + 组内离差**。两边平方再对所有 i, j 求和, 交叉项恰好为零:

$$\underbrace{\sum_{i,j} (X_{ij} - \bar{X})^2}_{SS_T} = \underbrace{\sum_i n_i (\bar{X}_{i\cdot} - \bar{X})^2}_{SS_A} + \underbrace{\sum_{i,j} (X_{ij} - \bar{X}_{i\cdot})^2}_{SS_E}. \quad (5.5)$$

符号	名称	含义
SS_T	总平方和	所有数据围绕总均值的总变异
SS_A	组间平方和	各组均值之间的差异 (因素效应)
SS_E	组内平方和 (误差)	组内个体差异 (随机误差)

对应自由度分解: $n - 1 = (r - 1) + (n - r)$ 。

5.1.3 F 检验

均方 (Mean Square):

$$MS_A = \frac{SS_A}{r - 1}, \quad MS_E = \frac{SS_E}{n - r}. \quad (5.6)$$

定理 5.1 (ANOVA F 检验). 在 H_0 为真且正态假设下:

$$F = \frac{MS_A}{MS_E} \sim F(r - 1, n - r). \quad (5.7)$$

若 $F \geq F_\alpha(r - 1, n - r)$, 则拒绝 H_0 。

直观理解：若 H_0 成立，组间差异仅由随机误差造成， MS_A 与 MS_E 应大小接近， $F \approx 1$ ；若因素效应存在， MS_A 会显著偏大， $F \gg 1$ 。

单因素 ANOVA 表

来源	平方和	自由度	均方	F 值
组间 (A)	SS_A	$r - 1$	$MS_A = SS_A / (r - 1)$	$F = MS_A / MS_E$
组内 (E)	SS_E	$n - r$	$MS_E = SS_E / (n - r)$	
总和	SS_T	$n - 1$		

例 5.1 (三种教学法的比较). 比较三种教学法 (A、B、C) 对学生成绩的影响。每种方法随机分配 5 名学生，成绩如下：

教学法	成绩					均值
A	78	82	75	80	85	$\bar{X}_{1.} = 80$
B	88	85	90	86	91	$\bar{X}_{2.} = 88$
C	72	76	70	74	73	$\bar{X}_{3.} = 73$
总均值 $\bar{X} = 80.33$						

计算：

$$SS_A = 5 \times (80 - 80.33)^2 + 5 \times (88 - 80.33)^2 + 5 \times (73 - 80.33)^2 \quad (5.8)$$

$$= 5 \times 0.11 + 5 \times 58.78 + 5 \times 53.78 = 563.33, \quad (5.9)$$

$$SS_E = \text{各组内部离差平方和} = 58 + 26 + 20 = 104, \quad (5.10)$$

$$MS_A = \frac{563.33}{2} = 281.67, \quad MS_E = \frac{104}{12} = 8.67, \quad (5.11)$$

$$F = \frac{281.67}{8.67} = 32.50. \quad (5.12)$$

$F_{0.05}(2, 12) = 3.89$ 。 $F = 32.50 > 3.89$ ，拒绝 H_0 ，三种教学法效果有显著差异。

5.1.4 多重比较

ANOVA 只告诉我们“至少有两个均值不等”，但不告诉我们哪些不等。若 ANOVA 显著，还需做**多重比较** (multiple comparisons) 来找出差异来源。

- **Tukey HSD (Honestly Significant Difference)**: 控制全部配对比较的总体错误率 (family-wise error rate);
- **Bonferroni 校正**: 将显著性水平调整为 α/m (m 为比较次数)，最简单但保守。

5.2 双因素试验的方差分析

实际问题中, 响应变量常受多个因素同时影响。双因素 ANOVA 同时考察两个因素的主效应及其交互作用。

5.2.1 无交互作用的双因素 ANOVA

模型:

$$X_{ij} = \mu + \alpha_i + \beta_j + \varepsilon_{ij}, \quad (5.13)$$

其中 α_i 为因素 A 的第 i 水平效应, β_j 为因素 B 的第 j 水平效应, 且满足约束 $\sum_i \alpha_i = 0$, $\sum_j \beta_j = 0$ (否则模型不可识别)。

平方和分解 (与单因素同理):

对每个观测值, 离差可拆为三部分:

$$X_{ij} - \bar{X} = (\bar{X}_{i\cdot} - \bar{X}) + (\bar{X}_{\cdot j} - \bar{X}) + (X_{ij} - \bar{X}_{i\cdot} - \bar{X}_{\cdot j} + \bar{X}). \quad (5.14)$$

平方求和后交叉项为零:

$$SS_T = SS_A + SS_B + SS_E. \quad (5.15)$$

无交互作用的双因素 ANOVA 表

来源	平方和	自由度	均方	F 值
因素 A	SS_A	$r - 1$	MS_A	$F_A = MS_A / MS_E$
因素 B	SS_B	$s - 1$	MS_B	$F_B = MS_B / MS_E$
误差	SS_E	$(r - 1)(s - 1)$	MS_E	
总和	SS_T	$rs - 1$		

例 5.2 (无交互作用的双因素 ANOVA 完整演示). 某教育研究比较三种教学法 (因素 A: A_1 讲授式、 A_2 讨论式、 A_3 翻转课堂) 在不同学校 (因素 B: B_1, B_2, B_3, B_4 四所学校) 的效果。在每个学校各随机抽取一个班, 共 $3 \times 4 = 12$ 个班, 期末平均成绩如下 (满分 100):

教学法	B_1	B_2	B_3	B_4	行均值 $\bar{X}_{i\cdot}$
A_1 (讲授)	72	75	70	78	73.75
A_2 (讨论)	80	83	78	85	81.50
A_3 (翻转)	88	90	85	92	88.75
列均值 $\bar{X}_{\cdot j}$	80.0	82.67	77.67	85.0	总均值 $\bar{X} = 81.33$

注：每种组合只有一个观测值（无重复），无法估计交互作用，因此假定教学法与学校之间无交互效应。

步骤 1：计算各平方和

$$SS_T = \sum_{i=1}^3 \sum_{j=1}^4 (X_{ij} - 81.33)^2 \quad (5.16)$$

$$= (72 - 81.33)^2 + (75 - 81.33)^2 + \cdots + (92 - 81.33)^2 \quad (5.17)$$

$$= 87.11 + 40.11 + 128.44 + 11.11 \quad (5.18)$$

$$+ 1.78 + 2.78 + 11.11 + 13.44 \quad (5.19)$$

$$+ 44.44 + 75.11 + 13.44 + 113.78 = 542.67, \quad (5.20)$$

$$SS_A = 4 \times [(73.75 - 81.33)^2 + (81.50 - 81.33)^2 + (88.75 - 81.33)^2] \quad (5.21)$$

$$= 4 \times [57.40 + 0.03 + 55.05] = 4 \times 112.48 = 449.92, \quad (5.22)$$

$$SS_B = 3 \times [(80.00 - 81.33)^2 + (82.67 - 81.33)^2 + (77.67 - 81.33)^2 + (85.00 - 81.33)^2] \quad (5.23)$$

$$= 3 \times [1.78 + 1.78 + 13.44 + 13.44] = 3 \times 30.44 = 91.33, \quad (5.24)$$

$$SS_E = SS_T - SS_A - SS_B = 542.67 - 449.92 - 91.33 = 1.42. \quad (5.25)$$

步骤 2：填写 ANOVA 表

来源	SS	df	MS	F	$F_{0.05}$
教学法 (A)	449.92	2	224.96	$F_A = 952.8$	$F_{0.05}(2, 6) = 5.14$
学校 (B)	91.33	3	30.44	$F_B = 128.9$	$F_{0.05}(3, 6) = 4.76$
误差	1.42	6	0.236		
总和	542.67	11			

步骤 3：做出结论

- 教学法： $F_A = 952.8 > 5.14$ ，拒绝 H_0 ，三种教学法效果有极显著差异；
- 学校： $F_B = 128.9 > 4.76$ ，拒绝 H_0 ，不同学校间成绩存在显著差异。

方差分析的解释：

- $SS_A = 449.92$ 占总变异的 82.9%，教学法是成绩差异的主要来源；
- $SS_B = 91.33$ 占 16.8%，学校间差异次之；
- $SS_E = 1.42$ 仅占 0.26%，随机误差极小，模型拟合非常好。

5.2.2 有交互作用的双因素 ANOVA

当两个因素可能相互影响时（如肥料 A 和灌溉量 B 对产量的联合效果），需引入交互效应项 $(\alpha\beta)_{ij}$ ：

模型：

$$X_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk}, \tag{5.26}$$

其中 $k = 1, \dots, c$ （每种处理组合至少有 $c \geq 2$ 次重复）。

有交互作用的双因素 ANOVA 表				
来源	平方和	自由度	均方	F 值
因素 A	SS_A	$r - 1$	MS_A	$F_A = MS_A/MS_E$
因素 B	SS_B	$s - 1$	MS_B	$F_B = MS_B/MS_E$
交互 $A \times B$	SS_{AB}	$(r - 1)(s - 1)$	MS_{AB}	$F_{AB} = MS_{AB}/MS_E$
误差	SS_E	$rs(c - 1)$	MS_E	
总和	SS_T	$rsc - 1$		

分析策略：先检验交互作用。若交互显著，主效应的分析需谨慎——因素 A 的效果可能依赖于因素 B 的水平，应做简单效应分析或分水平讨论。

例 5.3 (有交互作用的双因素 ANOVA 完整演示). 某农业试验研究两种肥料（因素 A: A_1 有机肥、 A_2 化肥）和三种灌溉量（因素 B: B_1 低、 B_2 中、 B_3 高）对作物产量的影响。每种处理组合设置 3 个重复小区，共 $2 \times 3 \times 3 = 18$ 个小区。产量数据（kg/小区）如下：

肥料	灌溉	重复观测值			单元格均值
A_1	B_1	42	45	39	42.0
A_1	B_2	55	58	52	55.0
A_1	B_3	50	53	47	50.0
A_2	B_1	48	51	45	48.0
A_2	B_2	70	73	67	70.0
A_2	B_3	80	84	76	80.0

步骤 1：计算各水平均值

	B_1 （低）	B_2 （中）	B_3 （高）	行均值
A_1 （有机）	42.0	55.0	50.0	49.0
A_2 （化肥）	48.0	70.0	80.0	66.0
列均值	45.0	62.5	65.0	总均值 $\bar{X} = 57.5$

步骤 2：计算各平方和（使用单元格均值 $\bar{X}_{ij}$ 。）

$$SS_A = 3 \times 3 \times [(49.0 - 57.5)^2 + (66.0 - 57.5)^2] \tag{5.27}$$

$$= 9 \times [72.25 + 72.25] = 9 \times 144.5 = 1300.5, \tag{5.28}$$

$$SS_B = 2 \times 3 \times [(45.0 - 57.5)^2 + (62.5 - 57.5)^2 + (65.0 - 57.5)^2] \tag{5.29}$$

$$= 6 \times [156.25 + 25.0 + 56.25] = 6 \times 237.5 = 1425.0, \tag{5.30}$$

$$SS_{AB} = 3 \times [(42.0 - 49.0 - 45.0 + 57.5)^2 + (55.0 - 49.0 - 62.5 + 57.5)^2 \tag{5.31}$$

$$+ (50.0 - 49.0 - 65.0 + 57.5)^2 + (48.0 - 66.0 - 45.0 + 57.5)^2 \tag{5.32}$$

$$+ (70.0 - 66.0 - 62.5 + 57.5)^2 + (80.0 - 66.0 - 65.0 + 57.5)^2] \tag{5.33}$$

$$= 3 \times [30.25 + 1.0 + 42.25 + 30.25 + 1.0 + 42.25] \tag{5.34}$$

$$= 3 \times 147.0 = 441.0, \tag{5.35}$$

$$SS_E = \text{原始 18 个观测值对各自单元格均值的离差平方和} \tag{5.36}$$

$$= [(42 - 42)^2 + (45 - 42)^2 + (39 - 42)^2] + \cdots + [(80 - 80)^2 + (84 - 80)^2 + (76 - 80)^2] \tag{5.37}$$

$$= 18 + 18 + 18 + 18 + 18 + 32 = 122, \tag{5.38}$$

$$SS_T = 1300.5 + 1425.0 + 441.0 + 122 = 3288.5. \tag{5.39}$$

验证（直接从原始数据算 SS_T ）： $SS_T = \sum_{k=1}^{18} (X_k - 57.5)^2 = 3288.5$ 。✓

步骤 3：填写 ANOVA 表

来源	SS	df	MS	F	$F_{0.05}$
肥料 (A)	1300.5	1	1300.5	$F_A = 128.0$	$F_{0.05}(1, 12) = 4.75$
灌溉 (B)	1425.0	2	712.5	$F_B = 70.1$	$F_{0.05}(2, 12) = 3.89$
交互 $A \times B$	441.0	2	220.5	$F_{AB} = 21.7$	$F_{0.05}(2, 12) = 3.89$
误差	122.0	12	10.17		
总和	3288.5	17			

步骤 4：做出结论

- 交互作用： $F_{AB} = 21.7 > 3.89$ ，交互作用极显著。肥料的效果依赖于灌溉水平——不能简单地讨论”哪种肥料更好”。
- 简单效应分析（分灌溉水平看肥料差异）：
 - 低灌溉 (B_1)：有机 42.0 vs 化肥 48.0，化肥略好；
 - 中灌溉 (B_2)：有机 55.0 vs 化肥 70.0，化肥明显更好；

- 高灌溉 (B_3): 有机 50.0 vs 化肥 80.0, 化肥优势最大。

结论: 化肥在高灌溉条件下增产效果最突出, 有机肥产量随灌溉量变化不大。

3. **交互效应图 (概念描述):** 若将两条折线画在同一坐标系中 (横轴为灌溉量, 纵轴为产量), 化肥的线随灌溉量急剧上升 ($48 \rightarrow 70 \rightarrow 80$), 有机肥的线相对平坦 ($42 \rightarrow 55 \rightarrow 50$, 中灌溉后反而略降)。两条线**不平行**, 这正是交互作用存在的直观证据。

与无交互情形的对比: 若忽略交互项而强行拟合无交互模型, 交互的变异 ($SS_{AB} = 441.0$) 会被错误地归入误差, 导致 MS_E 膨胀、 F 检验不敏感、结论可能完全错误。这就是为什么**有重复时必须检验交互**。

注记 5.2 (本例如何满足 ANOVA 的三个前提条件). 以肥料 $\times$ 灌溉的试验为例, 逐一检查:

1. **独立性:** 试验设计层面保证——18 个小区随机分配 6 种处理组合, 各小区的产量互不影响。独立性主要靠**随机化** (randomization) 来确保, 而非事后检验。
2. **正态性:** ANOVA 要求的是**残差** ($X_{ijk} - \bar{X}_{ij\cdot}$, 即每个观测值减去其所在处理组合的均值) 服从正态分布, 而非原始数据本身。本例共 18 个残差 (6 个处理组合 $\times$ 3 个重复), 可做 Q-Q 图检验。实践中 ANOVA 对中等程度的正态偏离是鲁棒的 (中心极限定理的作用)。
3. **方差齐性:** 要求 6 个处理组合的总体方差相等。从样本方差看:

处理组合	单元格数据	样本方差
A_1B_1	42, 45, 39	$s^2 = 9.0$
A_1B_2	55, 58, 52	$s^2 = 9.0$
A_1B_3	50, 53, 47	$s^2 = 9.0$
A_2B_1	48, 51, 45	$s^2 = 9.0$
A_2B_2	70, 73, 67	$s^2 = 9.0$
A_2B_3	80, 84, 76	$s^2 = 16.0$

前五组方差均为 9.0, 仅 A_2B_3 略高 (16.0)。最大方差比 $16/9 \approx 1.78$, 在每组仅 3 个观测的情况下属于可接受范围。若方差差异悬殊 (如最大/最小 > 4), 则需考虑数据变换 (如 $\log$ 变换) 或改用 Welch 型校正。

实用口诀: 独立性靠设计、正态性看残差、方差齐性比组内。三者中独立性最重要且不可补救, **违反独立性 = 结论无效**。

5.3 一元线性回归

回归分析研究变量之间的数量关系，是机器学习中监督学习的基础。

5.3.1 模型与假设

定义 5.2 (一元线性回归模型).

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, n, \quad (5.40)$$

其中:

- x_i 为自变量 (解释变量), 视为非随机;
- $\varepsilon_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2)$.

5.3.2 最小二乘估计 (OLS)

目标: 找 $\hat{\beta}_0, \hat{\beta}_1$ 使残差平方和最小:

$$Q(\beta_0, \beta_1) = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2. \quad (5.41)$$

令偏导为零, 得正规方程:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}, \quad (5.42)$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}. \quad (5.43)$$

5.3.3 拟合优度: R^2

定义 5.3 (决定系数).

$$R^2 = \frac{SS_R}{SS_T} = 1 - \frac{SS_E}{SS_T} = 1 - \frac{\sum (Y_i - \hat{Y}_i)^2}{\sum (Y_i - \bar{Y})^2}. \quad (5.44)$$

$R^2 \in [0, 1]$ 度量了 x 对 Y 变异性的解释比例。 R^2 越接近 1, 拟合越好。

平方和分解 (与 ANOVA 同源):

$$\underbrace{\sum (Y_i - \bar{Y})^2}_{SS_T} = \underbrace{\sum (\hat{Y}_i - \bar{Y})^2}_{SS_R} + \underbrace{\sum (Y_i - \hat{Y}_i)^2}_{SS_E}. \quad (5.45)$$

5.3.4 回归系数的假设检验

- t 检验：检验 $H_0: \beta_1 = 0$ （即 x 对 Y 无线性影响）。

$$T = \frac{\hat{\beta}_1}{SE(\hat{\beta}_1)} \sim t(n-2), \quad SE(\hat{\beta}_1) = \sqrt{\frac{MS_E}{S_{xx}}}. \quad (5.46)$$

- F 检验：等价于 ANOVA 框架下的整体显著性检验。

$$F = \frac{MS_R}{MS_E} = \frac{SS_R/1}{SS_E/(n-2)} \sim F(1, n-2). \quad (5.47)$$

对于一元回归， $F = T^2$ ，两种检验等价。

5.3.5 置信区间与预测区间

- 均值 $E[Y | x_0]$ 的置信区间：

$$\hat{Y}_0 \pm t_{\alpha/2}(n-2) \cdot s \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}. \quad (5.48)$$

- 新观测值 Y_{new} 的预测区间：

$$\hat{Y}_0 \pm t_{\alpha/2}(n-2) \cdot s \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}. \quad (5.49)$$

其中 $s = \sqrt{MS_E}$ 。

预测区间比置信区间宽（多了根号内的 1），因为新观测值含有额外的随机误差。

例 5.4（一元线性回归完整演示）. 研究学习时间（ x ，小时）与考试成绩（ Y ，分）的关系，数据如下：

学习时间 x_i	1	2	3	4	5	6
考试成绩 Y_i	52	58	65	70	78	85

步骤 1：计算基本统计量

$$\bar{x} = 3.5, \quad \bar{Y} = 68, \quad (5.50)$$

$$S_{xx} = \sum (x_i - 3.5)^2 = 17.5, \quad (5.51)$$

$$S_{xy} = \sum (x_i - 3.5)(Y_i - 68) = 115. \quad (5.52)$$

步骤 2：估计回归系数

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{115}{17.5} = 6.571, \quad \hat{\beta}_0 = 68 - 6.571 \times 3.5 = 45.0. \quad (5.53)$$

回归方程: $\hat{Y} = 45.0 + 6.571x$ 。即每多学 1 小时, 成绩预期提高约 6.6 分。

步骤 3: 检验 $\beta_1 = 0$

先计算 $SS_E = \sum(Y_i - \hat{Y}_i)^2 = 18.86$, $MS_E = 18.86/4 = 4.714$ 。

$$SE(\hat{\beta}_1) = \sqrt{\frac{4.714}{17.5}} = 0.519, \quad T = \frac{6.571}{0.519} = 12.66. \quad (5.54)$$

$t_{0.025}(4) = 2.776$ 。 $|T| = 12.66 > 2.776$, 拒绝 H_0 , 学习时间对成绩有显著线性影响。

$R^2 = 1 - 18.86/698 = 0.973$, 学习时间解释了 97.3% 的成绩变异。

5.4 多元线性回归

当影响因素不止一个时, 需要引入多个自变量。

5.4.1 模型与矩阵形式

定义 5.4 (多元线性回归模型)。

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i, \quad \varepsilon_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2). \quad (5.55)$$

矩阵形式:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad (5.56)$$

其中 $\mathbf{Y}$ 为 $n \times 1$ 响应向量, $\mathbf{X}$ 为 $n \times (p+1)$ 设计矩阵 (第一列全为 1), $\boldsymbol{\beta}$ 为 $(p+1) \times 1$ 系数向量, $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$ 。

5.4.2 最小二乘估计

正规方程: $\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{Y}$ 。

当 $\mathbf{X}^\top \mathbf{X}$ 可逆时:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}. \quad (5.57)$$

$\hat{\boldsymbol{\beta}}$ 的协方差矩阵: $\text{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$ 。

注记 5.3 (OLS 与极大似然估计 (MLE) 的关系). OLS 是 MLE 在正态误差假设下的特例。由模型 $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$, 似然函数为:

$$L(\boldsymbol{\beta}, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|^2}{2\sigma^2}\right). \quad (5.58)$$

取对数似然:

$$\ell(\boldsymbol{\beta}, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{\|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|^2}{2\sigma^2}. \quad (5.59)$$

对 β 求最大——前两项不含 β ，第三项分子是残差平方和，负号意味着：

$$\boxed{\arg \max_{\beta} \ell(\beta, \sigma^2) = \arg \min_{\beta} \|\mathbf{Y} - \mathbf{X}\beta\|^2}. \quad (5.60)$$

最大化似然 $\iff$ 最小化残差平方和，因此：

$$\boxed{\hat{\beta}_{\text{OLS}} = \hat{\beta}_{\text{MLE}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}}. \quad (5.61)$$

注意：若误差分布不是正态（如 Laplace），MLE 的解将不再是 OLS——例如 Laplace 误差下 MLE 等价于最小化绝对偏差（LAD / 分位数回归）。OLS 本身是几何/优化方法，无需概率假设即可使用；概率假设赋予其 MLE 的优良渐近性质。

5.4.3 显著性检验

整体显著性检验（ F 检验）：

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0. \quad (5.62)$$

$$F = \frac{SS_R/p}{SS_E/(n-p-1)} \sim F(p, n-p-1). \quad (5.63)$$

单个系数的检验（ t 检验）：

$$H_0 : \beta_j = 0, \quad T_j = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)} \sim t(n-p-1), \quad (5.64)$$

其中 $SE(\hat{\beta}_j) = s\sqrt{(\mathbf{X}^\top \mathbf{X})_{jj}^{-1}}$, $s = \sqrt{MS_E}$ 。

调整 R^2 ：普通 R^2 随变量增加而单调不减（即使加入噪声变量），调整 R^2 引入自由度惩罚：

$$R_{\text{adj}}^2 = 1 - \frac{SS_E/(n-p-1)}{SS_T/(n-1)} = 1 - (1 - R^2) \frac{n-1}{n-p-1}. \quad (5.65)$$

5.4.4 多重共线性

当自变量间高度相关时， $\mathbf{X}^\top \mathbf{X}$ 接近奇异，导致：

- $\hat{\beta}_j$ 的方差极大，估计不稳定；
- 系数符号可能与直觉相反；
- t 检验不显著但 F 检验显著（矛盾现象）。

诊断方法：方差膨胀因子（VIF）， $VIF_j = \frac{1}{1-R_j^2}$ ，其中 R_j^2 为 x_j 对其余 $p-1$ 个自变量回归的决定系数。通常 $VIF > 10$ 表明严重共线性， $VIF > 5$ 需要关注。

5.4.5 回归诊断：假设验证

OLS 回归的 t 检验和 F 检验依赖于三个核心假设。建模后必须逐条诊断——不能跳过这一步直接报告 p 值。

正态性检验：Shapiro-Wilk 检验与 Q-Q 图

回归要求的是残差 $\varepsilon_i = Y_i - \hat{Y}_i$ 服从正态分布（不是 X 或 Y 本身）。

定义 5.5 (Shapiro-Wilk 检验). H_0 : 数据来自正态分布。检验统计量 $W \in [0, 1]$, 越接近 1 越像正态。

- 若 $p > 0.05$: 不拒绝 H_0 , 可以认为残差满足正态性;
- 若 $p \leq 0.05$: 拒绝 H_0 , 残差显著不正态, t 检验和 p 值不可靠。

Shapiro-Wilk 的局限: 样本量很大时 ($n > 5000$), 微小的偏离也会导致 $p < 0.05$ 。此时应以 **Q-Q 图** 为主——只要散点大致沿对角线, 轻微的系统偏离可以接受。

正态性不满足时的补救:

- Box-Cox 变换: $Y^{(\lambda)} = \begin{cases} (Y^\lambda - 1)/\lambda, & \lambda \neq 0 \\ \ln Y, & \lambda = 0 \end{cases}$
- 改用第 4 章的秩和检验等非参数方法
- 大样本下 ($n \geq 30$), 由 CLT, t 检验对正态偏离有一定鲁棒性

方差齐性 (Homoscedasticity)

含义: 不同 X 取值下, Y 的波动幅度应该大致相同。即 $\text{Var}(\varepsilon_i) = \sigma^2$ (常数), 不随 $\hat{Y}_i$ 变化。

诊断方法: 画残差 vs 拟合值散点图:

- 正常: 残差随机散布在零线上下, 无明显的宽窄变化
- 违反正: 残差随拟合值增大而发散 (漏斗形) → **异方差 (Heteroscedasticity)**

异方差的后果: $SE(\hat{\beta}_j)$ 的估计不准确 → t 检验和置信区间无效, 即使系数估计本身仍然无偏。

补救:

- 对 Y 做对数变换 (最常用): $Y' = \ln Y$
- 使用加权最小二乘 (WLS), 给波动大的点更小的权重
- 使用异方差稳健标准误 (Huber-White / sandwich estimator)

异常值与影响力点

- **Cook’s distance:** 度量删除某个观测后回归系数变化的大小。经验阈值: $D_i > 4/n$
- 高 Cook’s distance 的点需要检查——可能是录入错误, 也可能是真正有信息量的极端案例

5.4.6 混合效应模型简介

前述回归模型假设所有观测独立同分布。但在实际数据中, 经常出现**重复测量**或**嵌套结构**:

- NIPT 数据: 同一孕妇在不同孕周检测多次 → 同一个人数据天然相似
- 教育数据: 同一学校的学生成绩相关 → 数据嵌套在学校内
- 医学试验: 同一患者多次随访 → 数据嵌套在患者内

如果用普通回归处理这类数据, 相当于把 n 个不完全独立的数据当成 n 个完全独立的数据, **标准误会被严重低估**, p 值虚低。

模型形式:

$$Y_{ij} = \underbrace{\alpha + \beta X_{ij}}_{\text{固定效应}} + \underbrace{u_i}_{\text{随机效应}} + \varepsilon_{ij},$$

(5.66)

其中 i 表示第 i 个组 (如第 i 个孕妇), j 表示组内第 j 次测量。

	固定效应	随机效应
含义	对所有组都一样的规律	各组独有的偏移
变量	α, β (待估参数)	$u_i \sim \mathcal{N}(0, \tau^2)$ (方差待估)
例子	BMI 每增加 1, Y 浓度降低 0.008	张三天生 Y 浓度偏高 0.01

两种 R^2 (这正是 NIPT 官方解法的核心洞察):

- **Marginal R^2 :** 仅固定效应解释的变异比例——通常很低 (如 3%), 因为个体差异被排除在外
- **Conditional R^2 :** 固定效应 + 随机效应共同解释的变异比例——通常很高 (如 83%), 因为”谁是这个孕妇”本身就携带大量信息

二者的巨大差距揭示了一个重要事实: **Y 染色体浓度的变异主要来自个体差异**, 而非 BMI 或孕周。这正是需要按 BMI 分组、制定个性化检测时点的统计依据。

5.4.7 分位数回归 (Quantile Regression)

普通最小二乘 (OLS) 估计的是**条件均值** $\mathbb{E}[Y | X]$ ——回答“在 X 这个水平下, Y 平均是多少”。但在许多实际问题中, 我们关心的不是均值, 而是**分布的不同位置**。

动机: NIPT 问题 2 要求“最早达标时间”——即 Y 染色体浓度达到 4% 时的孕周。用 OLS 估计“平均何时达标”意味着约一半人会早于、一半人会晚于这个时间——这太乐观了。临床需要的是“确保大多数人都已达标”的保守时点。

基本概念

分位数回归估计的是**条件分位数** $Q_\tau(Y | X)$, 其中 $\tau \in (0, 1)$ 是分位水平:

τ	含义	对应的统计量
0.50	条件中位数	一半人高于、一半人低于此值
0.25	条件下四分位数	25% 的人低于此值
0.75	条件上四分位数	75% 的人低于此值

与 OLS 的对比:

	OLS (均值回归)	分位数回归
估计目标	$\mathbb{E}[Y X]$	$Q_\tau(Y X)$
损失函数	$\sum (y_i - \hat{y}_i)^2$	$\sum \rho_\tau(y_i - \hat{y}_i)$
异常值影响	敏感 (平方放大偏差)	稳健 ($\tau = 0.5$ 即为中位数回归)
假设	残差正态、方差齐性	无需分布假设
输出	一条线 (均值)	可画多条线 (不同分位)

损失函数: 检查函数 (Check Function)

分位数回归最小化的是**非对称绝对损失**:

$$\rho_\tau(u) = u \cdot (\tau - \mathbf{1}_{\{u < 0\}}) = \begin{cases} \tau \cdot u, & u \geq 0 \text{ (高估的惩罚)} \\ (\tau - 1) \cdot u, & u < 0 \text{ (低估的惩罚)} \end{cases} \quad (5.67)$$

- $\tau = 0.50$: $\rho_{0.5}(u) = 0.5|u|$, 高估和低估惩罚对称 $\rightarrow$ 退化为中位数回归

- $\tau = 0.30$: 低估的惩罚 ($0.70|u|$) $\gg$ 高估的惩罚 ($0.30|u|$) $\rightarrow$ 回归线被往下拉, 给出保守估计

目标函数:

$$\hat{\beta}_\tau = \arg \min_{\beta} \sum_{i=1}^n \rho_\tau(y_i - \mathbf{x}_i^\top \beta). \quad (5.68)$$

模型形式

与 OLS 形式完全相同, 但系数依赖于 τ :

$$Q_\tau(Y | X) = \beta_0(\tau) + \beta_1(\tau)X_1 + \cdots + \beta_p(\tau)X_p. \quad (5.69)$$

不同 τ 给出不同的 $\hat{\beta}_j(\tau)$ ——例如 BMI 对 Y 浓度的影响可能在低分位 (体重轻的人) 和高分位 (体重大的人) 不同。

NIPT 中的应用

对每组 BMI, 用分位数回归估计 $Q_{0.30}(Y | \text{GA})$, 然后解:

$$\hat{\alpha}_{g,0.30} + \hat{\gamma}_{g,0.30} \cdot \widehat{\text{GA}}_{g,0.30} = 0.04 \implies \widehat{\text{GA}}_{g,0.30} = \frac{0.04 - \hat{\alpha}_{g,0.30}}{\hat{\gamma}_{g,0.30}}. \quad (5.70)$$

取 $\tau = 0.30$ 的含义: 估计的是”至少 30% 的该 BMI 组孕妇在此孕周已达 Y 浓度 4%”——比均值回归更保守、更符合临床对”安全时点”的要求。

5.4.8 模型选择

选择最优子集自变量的常用准则:

- **AIC (赤池信息准则)**: $AIC = n \ln(SS_E/n) + 2p$, 越小越好;
- **BIC (贝叶斯信息准则)**: $BIC = n \ln(SS_E/n) + p \ln n$, 对变量数惩罚更重;
- **逐步回归**: 前向选择、后向剔除、逐步回归——实用但需谨慎解释。

本章小结

本章涵盖了两个紧密关联的统计建模主题:

1. **单因素 ANOVA**: 将总变异分解为组间 + 组内, 通过 F 检验判断多个均值是否全等;

2. **双因素 ANOVA**: 同时考察两个因素及其交互作用, 平方和分解更复杂但思想相同;
3. **一元线性回归**: 最小二乘估计 $\hat{\beta}_0, \hat{\beta}_1$, R^2 评价拟合, t/F 检验显著性;
4. **多元线性回归**: 矩阵形式 $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$, 多重共线性诊断与模型选择。

ANOVA 与回归的统一视角: 两者都是一般线性模型的特例——ANOVA 的自变量是分类变量 (通过虚拟变量编码), 回归的自变量是连续变量。在机器学习中, 线性回归是最简单的监督学习模型, 而 ANOVA 的思想体现在特征重要性和模型比较的 F 检验中。

回归诊断与混合效应: 建立回归模型后, 必须进行诊断——残差正态性 (Shapiro-Wilk 检验、Q-Q 图)、方差齐性 (残差 vs 拟合值图)、多重共线性 (VIF)。当数据存在重复测量或嵌套结构时, 需引入混合效应模型, 用随机效应 (u_i) 区分个体差异与系统性效应, 避免标准误低估。

第六章 Bootstrap 方法

Bootstrap（自助法）由 Bradley Efron 于 1979 年提出，是统计推断中的一项革命性技术。其核心思想极为简洁：**用重抽样模拟抽样分布**。

传统的参数推断依赖正态近似（如 $\bar{X} \pm z_{\alpha/2} \cdot SE$ ），但当统计量形式复杂、分布未知、或样本量不足以依赖大样本理论时，Bootstrap 提供了一种 **完全基于数据本身的计算机密集型替代方案**。

Bootstrap 在机器学习中应用广泛：模型评估（如 Bagging 中的 Bootstrap 采样）、特征选择稳定性评估、集成学习中的随机森林等。

6.1 非参数 Bootstrap 方法

6.1.1 基本思想

设有样本 $\mathbf{x} = (x_1, x_2, \dots, x_n)$ 来自未知总体分布 F 。我们关心某个统计量 $\hat{\theta} = T(\mathbf{x})$ 的抽样分布（标准误、置信区间等）。

经典方法的问题：需要知道 T 的渐近分布，或假设总体服从某种特定分布。

Bootstrap 的解决思路：用经验分布 $\hat{F}_n$ （每个 x_i 赋予概率 $1/n$ ）替代未知的 F ，然后从 $\hat{F}_n$ 中反复重抽样。

定义 6.1 (非参数 Bootstrap 算法). 1. 从原始样本 $\mathbf{x} = (x_1, \dots, x_n)$ 中有放回地抽取 n 个观测，得到一个 Bootstrap 样本 $\mathbf{x}^{*b} = (x_1^*, \dots, x_n^*)$;

2. 计算该 Bootstrap 样本的统计量 $\hat{\theta}^{*b} = T(\mathbf{x}^{*b})$;

3. 重复步骤 1-2 共 B 次（通常 $B = 1000$ 或更多），得到 Bootstrap 分布 $\{\hat{\theta}^{*1}, \hat{\theta}^{*2}, \dots, \hat{\theta}^{*B}\}$ 。

6.1.2 Bootstrap 标准误

Bootstrap 分布的标准差即为统计量的 Bootstrap 标准误估计：

$$\widehat{SE}_{\text{boot}}(\hat{\theta}) = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}^{*b} - \bar{\theta}^*)^2}, \quad (6.1)$$

其中 $\bar{\theta}^* = \frac{1}{B} \sum_{b=1}^B \hat{\theta}^{*b}$ 。

6.1.3 Bootstrap 置信区间

方法一：正态近似区间

$$\hat{\theta} \pm z_{\alpha/2} \cdot \widehat{SE}_{\text{boot}}. \quad (6.2)$$

简单但不处理偏态。

方法二：百分位数区间 (Percentile Interval) 取 Bootstrap 分布的 $\alpha/2$ 和 $1 - \alpha/2$ 分位数：

$$\left[\hat{\theta}_{(\alpha/2)}^*, \hat{\theta}_{(1-\alpha/2)}^* \right], \quad (6.3)$$

其中 $\hat{\theta}_{(q)}^*$ 为 Bootstrap 分布的 q 分位数。

方法三：BCa 区间 (Bias-Corrected and Accelerated) 对百分位数法做偏度校正和加速校正，处理偏态效果更好，但需要额外计算 jackknife 统计量。

6.1.4 为什么有放回抽样？

有放回地抽取 n 次，一个 Bootstrap 样本中约 63.2% 的原始观测至少出现一次：

$$P(\text{某特定 } x_i \text{ 被抽中}) = 1 - \left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} 1 - e^{-1} \approx 0.632. \quad (6.4)$$

剩余的约 36.8% 的观测未出现，称为**袋外样本** (out-of-bag, OOB)，可用于无偏评估模型——这正是随机森林中 OOB 误差估计的原理。

例 6.1 (Bootstrap 估计中位数的标准误—完整演示). 某研究记录了 8 名患者术后恢复时长 (天)：

$$\mathbf{x} = (12, 15, 18, 22, 25, 30, 35, 48). \quad (6.5)$$

我们关心的是**中位数** $\hat{\theta} = \text{median}(\mathbf{x})$ ，但中位数的标准误没有像 $\bar{X}$ 那样简单的公式。Bootstrap 恰好擅长处理这类问题。

原始样本中位数： $\hat{\theta} = \frac{22+25}{2} = 23.5$ 天。

Bootstrap 过程 ($B = 5$ 次示意，实际应用取 $B \geq 1000$)：

b	Bootstrap 样本 $\mathbf{x}^{*b}$ (有放回)	$\hat{\theta}^{*b}$
1	15, 25, 12, 35, 25, 18, 30, 22	23.5
2	48, 18, 18, 22, 12, 35, 25, 15	20.0
3	30, 30, 22, 15, 48, 25, 12, 35	27.5
4	25, 12, 35, 18, 48, 30, 22, 22	23.5
5	15, 15, 18, 25, 35, 48, 30, 12	21.5

实际运行 $B = 2000$ 次的结果（用计算机模拟）：

Bootstrap 中位数分布：

- 均值 $\bar{\theta}^* = 23.84$
- Bootstrap 标准误： $\widehat{SE}_{\text{boot}} = 4.31$
- Bootstrap 偏度估计： $\widehat{\text{Bias}} = \bar{\theta}^* - \hat{\theta} = 23.84 - 23.5 = 0.34$

95% 百分位数置信区间：取 Bootstrap 分布的 2.5% 和 97.5% 分位数：

$$[\hat{\theta}_{(0.025)}^*, \hat{\theta}_{(0.975)}^*] = [16.50, 34.25]. \quad (6.6)$$

结论：术后恢复时长中位数的 95% Bootstrap 置信区间为 $[16.5, 34.25]$ 天。注意区间不对称（23.5 不居中），说明中位数分布是偏态的——百分位数法自动捕捉了这一点，这是正态近似法做不到的。

6.2 参数 Bootstrap 方法

6.2.1 与非参数 Bootstrap 的区别

非参数 Bootstrap 直接从原始数据重抽样，不对总体分布形式做任何假设。但当我们知道总体分布的函数形式（只是参数未知）时，可以利用这一额外信息获得更精确的推断——这就是参数 Bootstrap。

	非参数 Bootstrap	参数 Bootstrap
从何处抽样	原始样本（经验分布 $\hat{F}_n$ ）	参数模型 $F_{\hat{\eta}}$
需要假设分布形式	否	是
适用场景	探索性分析、复杂统计量	已知分布族、小样本
信息利用效率	较低	较高（模型正确时）

6.2.2 算法

1. 从原始样本 $\mathbf{x}$ 得到参数 $\boldsymbol{\eta}$ 的估计 $\hat{\boldsymbol{\eta}}$ （如 MLE）；
2. 从拟合分布 $F_{\hat{\boldsymbol{\eta}}}$ 中生成 Bootstrap 样本 $\mathbf{x}^{*b}$ （样本量 n ）；
3. 计算 $\hat{\theta}^{*b}$ ，重复 B 次。

例 6.2 (参数 Bootstrap 估计正态总体方差的置信区间). 设 $n = 10$ 个观测来自 $\mathcal{N}(\mu, \sigma^2)$ ：

$$\mathbf{x} = (4.2, 5.1, 3.8, 6.0, 4.5, 5.5, 3.9, 4.8, 5.2, 4.0). \quad (6.7)$$

步骤 1：参数估计

$$\hat{\mu} = \bar{x} = 4.70, \quad (6.8)$$

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2 = 0.542. \quad (6.9)$$

步骤 2：参数 Bootstrap ($B = 2000$)

每次从 $\mathcal{N}(4.70, 0.542)$ 中生成 $n = 10$ 个新观测，计算样本方差 $\hat{\sigma}^{2*}$ 。

步骤 3：结果

Bootstrap 方差分布：

- 均值 $\bar{\sigma}^{2*} = 0.488$ （略低于 $\hat{\sigma}^2 = 0.542$ ，体现方差的负偏）
- 标准误： $\widehat{SE}_{\text{boot}} = 0.225$

95% 百分位数置信区间：

$$\sigma^2 \in [0.183, 1.085]. \quad (6.10)$$

对比理论解：正态总体下 $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(9)$ ，精确的 95% CI 为：

$$\sigma^2 \in \left[\frac{9 \times 0.542}{19.02}, \frac{9 \times 0.542}{2.70} \right] = [0.256, 1.807]. \quad (6.11)$$

参数 Bootstrap 的区间更窄，这是因为 Bootstrap 额外利用了 $\hat{\sigma}^2$ 点估计的信息（而精确 χ^2 区间只用到 S^2 的抽样分布，未假设 σ^2 的可能范围）。一般而言，在小样本下精确理论解更可靠；参数 Bootstrap 在大样本下与之渐近等价。

6.2.3 何时用哪种 Bootstrap?

- **非参数 Bootstrap：**当你不确定总体分布形式，或统计量很复杂（如中位数、分位数、相关系数、AUC）时——这是最通用、最安全的选择。
- **参数 Bootstrap：**当你有充分理由相信数据来自某个已知分布族（如寿命数据常用 Weibull、失效次数用 Poisson），且希望利用这一结构获得更精确的推断时。

Bootstrap 的局限性：

- 当样本量极小（ $n < 8$ ）时，Bootstrap 分布只能取有限个值，效果差；
- 对极值统计量（如最大值）Bootstrap 不一致；
- 对重尾分布，Bootstrap 可能低估尾部变异性；
- 计算量大（但现代硬件下 $B = 2000$ 通常几秒内完成）。

6.2.4 Cluster Bootstrap（聚类自助法）

前述 Bootstrap 方法假设所有观测相互独立。但在实际数据中，经常存在组内相关：

- NIPT 数据：同一孕妇在不同孕周测了多次——这几次检测天然相似（第 9 章混合效应）
- 教育数据：同一学校的学生成绩相关
- 面板数据：同一个体在不同时间点的重复测量

如果无视组结构做普通 Bootstrap——每次以单次检测为单位有放回抽样——同一个孕妇的 3 次检测可能被拆散到不同的 Bootstrap 样本中，组内相关性被破坏，导致标准误被严重低估。

Cluster Bootstrap 的做法：

以“组”（cluster）为单位重抽样，而非以单个观测为单位。

- (1) 将数据按组 ID 分组（如按孕妇 ID）；
- (2) 从所有组中有放回地抽取 K 个组（ K 为原始组数）；
- (3) 被抽中的组的所有观测全部进入 Bootstrap 样本；
- (4) 对 Bootstrap 样本计算统计量，重复 B 次。

与普通 Bootstrap 的对比：

	普通 Bootstrap	Cluster Bootstrap
抽样单位	单个观测	整组（cluster）
保持的内部结构	无	组内相关性
适用数据	独立观测	重复测量 / 嵌套数据
标准误	若忽略组结构则低估	正确反映组间变异

NIPT 问题 2 中的应用：

问题要求“分析检测误差对最佳 NIPT 时点的影响”。由于同一孕妇多次检测，必须用 Cluster Bootstrap（按孕妇 ID 分组重抽样）：

- (1) 保持 BMI 分组和分位数回归模型不变

- (2) 按孕妇 ID 做 Cluster Bootstrap ($B = 1000$)
- (3) 每次重抽样后重新计算每组的最优时点 $\widehat{GA}_{gr}$
- (4) 从 1000 次结果中提取 2.5% 和 97.5% 分位数作为 95% CI

结论：检测误差会使最佳时点推后，BMI 越高推后越明显——这与“高 BMI 组 Y 浓度达标慢、不确定性大”的生物学直觉一致。

本章小结

Bootstrap 是现代统计计算中最强大的工具之一：

1. **核心思想**：用重抽样模拟抽样分布——从经验分布（非参数）或拟合参数模型（参数）中反复抽样；
2. **非参数 Bootstrap**：有放回重抽样，每个样本约 63% 的原始观测被抽中，36.8% 为 OOB 样本；
3. **参数 Bootstrap**：适用于已知分布族的情形，信息利用更充分但依赖模型正确性；
4. **输出**：标准误估计、百分位数置信区间（自动处理偏态）、Bias 估计等；
5. **在 ML 中的角色**：Bagging 的根基、随机森林的 OOB 误差、模型稳定性和变量重要性评估。

关键在于：**Bootstrap 将“分析推导抽样分布”的难题转化为“计算机模拟”的工程问题**，使得我们几乎可以为任何统计量获得标准误和置信区间。

第七章 统计实践：从建模到报告

前面各章分别介绍了假设检验、方差分析、回归分析和 Bootstrap 等统计方法。本章将把这些方法串联起来，形成从数据探索到结果报告的完整实践流程，并介绍学术写作中的 APA 报告规范。

7.1 R^2 与 p 值的区别与联系

R^2 和 p 值是回归输出中最常见的两个数字，但初学者常混淆它们的含义。二者来自完全不同的统计框架，回答完全不同的问题。

7.1.1 框架对比

	R^2 （决定系数）	p 值
所属章节	第 9 章：方差分析与回归分析	第 4 章：假设检验
所属框架	方差分析（ANOVA）	假设检验
回答的问题	模型解释了多少变异？	效应是真实存在的还是巧合？
数学定义	$R^2 = \frac{SS_R}{SS_T} = 1 - \frac{SS_E}{SS_T}$	$p = P(T \geq t_{\text{obs}} \mid H_0)$
关注的是	效应大小（effect size）	效应是否为零（显著性）
取值范围	$[0, 1]$ （调整 R^2 可为负）	$(0, 1)$
受样本量影响	不敏感—— n 增大, R^2 趋于稳定	极敏感—— n 越大, 越容易显著

7.1.2 为什么 R^2 很低但 p 值可以显著？

这是初学者最困惑的地方，答案藏在样本量里。

考虑回归模型 $Y = \beta_0 + \beta_1 X + \varepsilon$ ，检验 $H_0: \beta_1 = 0$ 。


检验统计量 $T = \frac{\hat{\beta}_1}{SE(\hat{\beta}_1)}$ ， $SE(\hat{\beta}_1) = \frac{s}{\sqrt{S_{xx}}}$ 随着 n 增大而减小。而 $s^2 = \frac{SS_E}{n-2}$ 度量的是不能被 X 解释的那部分变异——即使 R^2 很低， SS_E 也不会随着 n 增大而消失，只是我们对 $\hat{\beta}_1$ 的估计越来越精确（ SE 越来越小）。

R^2 与 F 检验的精确关系（已在第 9 章推导）：

$$F = \frac{SS_R/1}{SS_E/(n-2)} = \frac{R^2/1}{(1-R^2)/(n-2)}. \quad (7.1)$$

- 即使 $R^2 = 0.03$ ，只要 n 足够大， $F = \frac{0.03}{(0.97)/(n-2)}$ 仍可超越临界值；
- 例如 $n = 10000$ ： $F = \frac{0.03}{0.97/9998} \approx 309$ ， $p \ll 0.001$ ；
- 结论： p 值显著只说明效应不为零，不说明效应很大。

7.1.3 用“射击靶子”理解二者



7.1.4 四种组合判断表

R^2	p 值	判断	说明
高	显著	理想情况	解释力强，效应确凿
高	不显著	罕见，需检查	可能多重共线性（ F 显著但各 t 不显著，见第 9 章 VIF）
低	显著	最常见于大样本	效应存在但效应量小（如 NIPT 数据）
低	不显著	模型无效	变量可能没有解释力

7.1.5 常见误区纠正

- (1) “ $p < 0.05$ 说明效应很大” → 错。 p 值只拒绝 “效应为零”。大样本下微小效应也能 $p < 0.001$ 。
- (2) “ R^2 低说明模型没用” → 错。生物/社会科学中 $R^2 = 0.05 \sim 0.30$ 是常态。关键是 p 值。
- (3) “ $p > 0.05$ 说明 H_0 为真” → 错。只能说 “证据不足”（第 4 章第二类错误 β ）。
- (4) “ p 值是 H_0 为真的概率” → 错。 p 值是 $P(\text{数据} \mid H_0)$ ，不是 $P(H_0 \mid \text{数据})$ 。

7.2 因素分析的标准流程

以下结合 NIPT 数据（Y 染色体浓度 ~ 孕周 + BMI）为例，给出因素建模的五步标准流程。每一步都在 R^2 （方差分解，第 9 章）和 p 值（假设检验，第 4 章）之间交替使用。

7.2.1 第 1 步：相关性扫描——看方向和显著性

- 计算 Pearson / Spearman 相关系数矩阵（第 1 章），同时报告 r 和 p 值
- 画散点图矩阵（pairplot），观察非线性关系
- 目的：初步判断哪些变量有关联（ p 值）、关联多强（ r 或 r^2 ）

7.2.2 第 2 步：建立回归模型——量化效应大小

- 从简单模型开始： $Y \sim X_1$ ，逐步加入变量（第 9 章多元回归）
- 对每个系数报告： $\hat{\beta}_j$ 、 $SE(\hat{\beta}_j)$ 、 t 值、 p 值
- 报告整体 R^2 、调整 R^2_{adj} 、 F 统计量及其 p 值

- 目的：量化效应大小 ($\hat{\beta}$)，判断显著性 (p)，评估解释力 (R^2)

7.2.3 第 3 步：模型诊断——验证假设

- 正态性：残差的 Q-Q 图（第 4 章），或 Shapiro-Wilk 检验
- 方差齐性：残差 vs 拟合值散点图（不应有漏斗形）
- 多重共线性：计算 VIF（第 9 章）， $VIF > 10$ 表明严重共线性
- 异常值：Cook's distance 识别高影响力点
- 假设不满足时：Box-Cox 变换、加权最小二乘、或改用第 4 章的秩和检验等非参数方法

7.2.4 第 4 步：模型改进——从简单到复杂

当简单线性模型表现不佳 (R^2 低但 p 值显著，或残差有结构)，考虑：


- (1) 加入交互项： $Y \sim X_1 + X_2 + X_1:X_2$ ，检验交互是否显著
- (2) 加入非线性项： $Y \sim X + X^2$ ，或用 GAM（广义可加模型）
- (3) 分段/分层建模：按关键变量分组，每组独立拟合，比较各组 R^2 和系数
- (4) 引入随机效应（混合效应模型）：当数据有重复测量时（如同一孕妇多次检测），用 $Y_{ij} = \alpha + u_i + \beta X_{ij} + \varepsilon_{ij}$ 区分个体差异（随机效应 u_i ）和系统性效应（固定效应 β ）

7.2.5 第 5 步：报告与解释——讲好故事

不能只报数字，要给出实际含义。结合第 4 章的 p 值检验法和本章的 APA 规范：

- 效应报告示例：
“孕周每增加 1 周，Y 染色体浓度平均增加 0.0035 个单位 ($SE = 0.0004$, $t(9998) = 8.75$, $p < 0.001$)”
- R^2 低的解释示例：
“BMI 和孕周仅解释 Y 浓度变异的 3% ($R^2 = 0.030$)，但效应方向明确且统计显著 ($F(2, 9997) = 154.6$, $p < 0.001$)。剩余变异主要来自个体间差异（条件 $R^2 = 83\%$ ），这正是需要按 BMI 分组制定个性化检测时点的依据。”

7.2.6 完整流程图



7.3 APA 学术报告规范

APA 风格 (American Psychological Association) 是心理学、教育学、社会科学及生物医学领域最广泛使用的学术写作规范。建模竞赛论文虽非正式期刊论文，但遵循 APA 报告统计结果能显著提升论文的专业性和可信度。

7.3.1 核心原则

不能只报 p 值，必须同时报告效应大小。 p 值只回答“效应是否存在”，效应量 ($\hat{\beta}$ 、Cohen's d 、 R^2 等) 回答“效应有多大”。两者缺一不可——这是 APA 规范最核心的要求。

7.3.2 常见统计量的 APA 报告格式

检验类型	APA 格式	示例
t 检验（第 4 章）	$t(df) = x.xx, p = .xxx$	$t(24) = 2.14, p = .043$
F 检验（第 9 章 ANOVA）	$F(df_1, df_2) = x.xx, p = .xxx$	$F(2, 97) = 5.43, p = .006$
χ^2 检验（第 4 章）	$\chi^2(df, N = n) = x.xx, p = .xxx$	$\chi^2(1, N = 200) = 12.5, p < .001$
相关系数（第 1 章）	$r(df) = .xx, p = .xxx$	$r(98) = .34, p < .001$
回归系数（第 9 章）	$b = x.xx, SE = .xxx, t(df) = x.xx, p = .xxx$	$b = -0.008, SE = 0.001, t(98) = -7.0, p < .001$
Bootstrap CI（第 10 章）	95% CI [L, U]	95% CI [16.50, 34.25]

7.3.3 p 值的写法

- 小数前不加 0: $p = .032$ （而非 $p = 0.032$ ），因为 p 值永远不超过 1
- 极小时不写具体值: $p < .001$ （而非 $p = .0003$ ）
- 报告精确值优先于笼统表述: $p = .032$ 好于 $p < .05$

7.3.4 完整报告示例

以下是一个符合 APA 规范的回归分析报告，综合运用了第 1 章（相关系数）、第 4 章（ t 检验与 p 值）、第 9 章（回归与 F 检验）的方法：

结果

首先进行了相关性分析（Pearson 相关系数，第 1 章）。孕周与 Y 染色体浓度呈显著正相关（ $r(9998) = .12, p < .001$ ），BMI 与 Y 染色体浓度呈显著负相关（ $r(9998) = -.08, p < .001$ ）。

随后建立了多元线性回归模型，以 Y 染色体浓度为因变量，孕周和 BMI 为自变量。模型整体显著， $F(2, 9997) = 154.6, p < .001$ ，解释了 Y 浓度变异的 3.0%（ $R^2 = .030$ ，调整 $R^2 = .030$ ）。

BMI 对 Y 浓度具有显著的负效应 ($\hat{\beta} = -0.0084$, $SE = 0.0012$, $t(9997) = -7.00$, $p < .001$), 孕周对 Y 浓度具有显著的正效应 ($\hat{\beta} = 0.0035$, $SE = 0.0004$, $t(9997) = 8.75$, $p < .001$)。

残差的 Q-Q 图表明正态性假设基本满足, VIF 均为 1.02, 表明不存在多重共线性问题。

讨论

虽然 $R^2 = .030$ 看似较低, 但在生物医学数据中属于常见水平。所有系数的 p 值均远小于 .001, 表明效应方向明确且统计可靠。剩余未解释的变异主要来自个体间差异, 这支持了按 BMI 分组制定个性化检测时点的必要性。

7.3.5 建模竞赛论文的 APA 使用要点

- (1) 摘要中必须报告关键数值: 不能只写“模型显著”, 要写“ $F(2, 97) = 5.43$, $p = .006$, $R^2 = .101$ ”
- (2) 每个系数都报告 $\hat{\beta}$ 、 SE 、 t 、 p : 最好用表格呈现
- (3) 效应量和显著性缺一不可: “ $p < .001$ 但不报告 $\hat{\beta}$ ” 是常见扣分点
- (4) 诊断结果要写出: “残差正态 (Shapiro-Wilk $p = .32$), VIF 均 < 2 ” 一句话就够了
- (5) p 值小时写 APA 格式: $p = .032$ (而非 $p = 0.032$)、 $p < .001$ (而非 $p = 0.0003$)

7.4 方法选择速查表

将前面各章的方法按其适用场景整理为速查表, 方便建模时快速定位。

你想做什么	数据类型	参数方法	非参数替代	对应章节
比较两组均值	连续, 正态	两样本 t 检验	Wilcoxon 秩和	第 4 章
比较两组均值	配对数据	配对 t 检验	Wilcoxon 符号秩	第 4 章
比较三组以上	连续, 正态	单因素 ANOVA (F)	Kruskal-Wallis	第 9 章
两个因素的比较	连续, 正态	双因素 ANOVA	—	第 9 章
检验方差齐性	连续	F 检验 / Bartlett	Levene	第 4/9 章
一个 $X \rightarrow Y$	连续	一元线性回归	—	第 9 章
多个 $X \rightarrow Y$	连续	多元线性回归	—	第 9 章
分类 Y	二分类	逻辑回归	—	机器学习部分
分布拟合	频数	Pearson χ^2	—	第 4 章
正态性检验	连续	Shapiro-Wilk	Q-Q 图	第 4 章
标准误/CI (任意统计量)	任意	参数 Bootstrap	非参数 Bootstrap	第 10 章

本章小结

本章作为统计方法部分的收尾，完成了三件事：

- 1. **区分 R^2 与 p 值：** R^2 来自第 9 章的方差分解，度量效应大小； p 值来自第 4 章的假设检验，度量统计显著性。二者互补，必须同时报告。
- 2. **标准化因素分析流程：**相关性扫描 $\rightarrow$ 回归建模 $\rightarrow$ 模型诊断 $\rightarrow$ 模型改进 $\rightarrow$ 报告解释，五步将第 2、4、9、10 章的方法串联为可操作的工作流。
- 3. **规范化学术报告：**介绍了 APA 风格的核心规则——报告效应量 + 显著性、 p 值的正确写法、各检验的规范格式，并给出了完整的报告示例。

掌握这些内容后，面对建模竞赛的数据分析题（如 CUMCM C 题），你就有了从数据探索到论文写作的完整方法论工具箱。

第八章 信息论基础

8.1 基本概念

定义 8.1 (信息量 / 自信息).

$$I(x) = -\log p(x). \quad (8.1)$$

定义 8.2 (熵). 随机变量 X 的熵度量其不确定性:

$$H(X) = -\sum_x p(x) \log p(x). \quad (8.2)$$

定义 8.3 (KL 散度). 分布 P 与 Q 之间的 KL 散度:

$$D_{\text{KL}}(P\|Q) = \sum_x p(x) \log \frac{p(x)}{q(x)}. \quad (8.3)$$

非负、非对称, $D_{\text{KL}}(P\|Q) = 0 \iff P = Q$.

定义 8.4 (交叉熵).

$$H(P, Q) = -\sum_x p(x) \log q(x) = H(P) + D_{\text{KL}}(P\|Q). \quad (8.4)$$

定义 8.5 (互信息).

$$I(X; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}. \quad (8.5)$$

第二部分

机器学习

第九章 矩阵运算与张量记号

本章为进入机器学习核心内容做数学准备。假设读者已学过线性代数（向量空间、矩阵乘法、行列式、特征值），但未系统学过矩阵微积分。本章聚焦**推导中高频使用的矩阵操作**，并引入张量分析的指标记号（Einstein 求和约定），便于在后续章节中简洁地表达梯度和优化问题。

9.1 迹运算

迹运算是矩阵求导的核心工具——几乎所有标量对矩阵的求导都可以通过迹来统一处理。

定义 9.1 (迹). $n \times n$ 方阵 A 的迹是其主对角线元素之和：

$$\text{tr}(A) = \sum_{i=1}^n a_{ii}. \quad (9.1)$$

命题 9.1 (迹的基本性质). (1) **线性性**: $\text{tr}(\alpha A + \beta B) = \alpha \text{tr}(A) + \beta \text{tr}(B)$;

(2) **转置不变**: $\text{tr}(A^\top) = \text{tr}(A)$;

(3) **循环性 (核心)**: $\text{tr}(AB) = \text{tr}(BA)$, 推广为

$$\text{tr}(ABC) = \text{tr}(BCA) = \text{tr}(CAB); \quad (9.2)$$

(4) **标量即迹**: 若 $x^\top Ax$ 是标量, 则 $x^\top Ax = \text{tr}(x^\top Ax) = \text{tr}(Axx^\top)$ 。

迹技巧的本质: 把标量表达式塞进 $\text{tr}(\cdot)$, 利用循环性质把要求导的变量移到最右侧, 然后利用 $\frac{\partial}{\partial X} \text{tr}(AX) = A^\top$ 一步得出结果。这是推导 OLS、Ridge、MLE 中矩阵梯度的标准方法。

9.2 正定与半正定矩阵

定义 9.2 (正定与半正定). 设 A 为 $n \times n$ 实对称矩阵:

- A **正定** ($A \succ 0$): 对所有 $x \neq 0$, $x^\top Ax > 0$;

- A 半正定 ($A \succeq 0$): 对所有 x , $x^\top A x \geq 0$ 。

命题 9.2 (等价条件). (1) $A \succ 0 \iff$ 所有特征值 $\lambda_i > 0$;

(2) $A \succeq 0 \iff$ 所有特征值 $\lambda_i \geq 0$;

(3) $A \succeq 0 \iff$ 存在 B 使得 $A = B^\top B$ (如 Cholesky 分解 $A = LL^\top$)。

在 ML 中的意义:

- 协方差矩阵 Σ 总是半正定——这是它能做 Cholesky 分解的原因;
- 设计矩阵乘积 $X^\top X$ 是半正定的。当 $p > N$ 时, $X^\top X$ 奇异 (不可逆)——Ridge 回归通过加 λI 使其变为正定, 从而可逆;
- Hessian 矩阵正定 $\implies$ 目标函数是凸函数 $\implies$ 驻点即全局最优。

9.3 矩阵求导

矩阵求导是梯度下降、正规方程推导、MLE 的必要工具。本节以分子布局 (numerator layout) 为约定, 即标量对列向量求导得到行向量。

9.3.1 标量对向量的导数

表达式 $f(x)$	梯度 $\nabla_x f$	出现场景
$a^\top x$	$a^\top$	线性函数求导
$x^\top A x$	$x^\top (A + A^\top)$	二次型的一般形式
$x^\top A x$ (A 对称)	$2x^\top A$	RSS、马氏距离
$\ Ax - b\ ^2$	$2(Ax - b)^\top A$	最小二乘损失
$\ x\ ^2 = x^\top x$	$2x^\top$	L_2 正则化

例 9.1 (OLS 正规方程的推导). 最小二乘的损失函数 $J(\beta) = \|X\beta - y\|^2$:

$$\begin{aligned}
 J(\beta) &= (X\beta - y)^\top (X\beta - y) \\
 \nabla_\beta J &= 2(X\beta - y)^\top X = 0 \\
 \implies X^\top X\beta &= X^\top y \quad (\text{正规方程}).
 \end{aligned} \tag{9.3}$$

9.3.2 标量对矩阵的导数

表达式 $f(X)$	导数 $\frac{\partial f}{\partial X}$	出现场景
$\log \det X$	$X^{-\top}$ (或 X^{-1})	多元正态 MLE 中 Σ 估计
$\text{tr}(AX)$	$A^\top$	迹求导基础公式
$a^\top X b$	$ab^\top$	双线性形式
$\text{tr}(X^\top A X)$	$(A + A^\top)X$	加权最小二乘

9.3.3 向量对向量的导数（雅可比矩阵）

$$\frac{\partial y}{\partial x} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_m}{\partial x_1} & \cdots & \frac{\partial y_m}{\partial x_n} \end{bmatrix}, \quad \frac{\partial Ax}{\partial x} = A. \quad (9.4)$$

9.4 张量分析的指标记号

矩阵语言在处理二阶及以上的求导时会变得非常臃肿。张量分析的指标记号（index notation）提供了一套并行使用的简洁语言，特别适用于表达元素的偏导数关系和 Hessian 结构。

9.4.1 Einstein 求和约定

核心规则：在同一项中，若一个指标出现两次（一上一下，或两下标），则默认对该指标的所有可能取值求和。求和号 $\sum$ 被省略。

矩阵记号	Einstein 记号	含义
$y = Ax$	$y_i = A_{ij}x_j$	$y_i = \sum_j A_{ij}x_j$
$c = a^\top b$	$c = a_i b_i$	$\sum_i a_i b_i$ (内积)
$C = AB$	$C_{ik} = A_{ij}B_{jk}$	$C_{ik} = \sum_j A_{ij}B_{jk}$
$\text{tr}(A)$	A_{ii}	$\sum_i A_{ii}$
$x^\top Ax$	$x_i A_{ij} x_j$	$\sum_{i,j} x_i A_{ij} x_j$

关键约定：

- **哑指标 (dummy index)**：出现两次、被求和的指标（如 j 在 $A_{ij}B_{jk}$ 中），字母可任意更换—— $A_{ij}B_{jk} = A_{ik}B_{kl}$ 并不成立，但 $A_{ij}B_{jk} = A_{im}B_{mk}$ ；
- **自由指标 (free index)**：只出现一次、不被求和的指标（如 i 和 k ）——这些指标在等式两边必须一致出现。

9.4.2 Kronecker δ 符号

$$\delta_{ij} = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases} \quad (9.5)$$

在指标记号中， δ_{ij} 就是单位矩阵 I 的 (i, j) 元素。其核心功能是指标的替换：

$$\delta_{ij}a_j = a_i, \quad \delta_{ij}A_{jk} = A_{ik}. \quad (9.6)$$

例 9.2 (迹的循环性在指标记号下是显然的).

$$\text{tr}(AB) = (AB)_{ii} = A_{ij}B_{ji} = B_{ji}A_{ij} = (BA)_{jj} = \text{tr}(BA). \quad (9.7)$$

不需要任何技巧——指标记号的交换直接揭示了循环性。

9.4.3 偏导数的指标写法

将向量偏导写成指标形式，能大幅简化 Hessian 的分析：

对象	矩阵写法	指标写法
标量对向量的梯度	$\nabla_x f$	$\frac{\partial f}{\partial x_i}$
向量对向量的雅可比	$\frac{\partial y}{\partial x}$	$\frac{\partial y_i}{\partial x_j}$
标量的 Hessian	$\nabla_x^2 f$	$\frac{\partial^2 f}{\partial x_i \partial x_j}$

例 9.3 (二次型的梯度与 Hessian). 设 $f(x) = \frac{1}{2}x^\top Ax$ (A 对称):

$$\text{指标形式: } f = \frac{1}{2}x_i A_{ij} x_j, \quad (9.8)$$

$$\frac{\partial f}{\partial x_k} = \frac{1}{2}(\delta_{ik} A_{ij} x_j + x_i A_{ij} \delta_{jk}) = \frac{1}{2}(A_{kj} x_j + A_{ik} x_i) = A_{ki} x_i \quad (\text{即 } Ax). \quad (9.9)$$

$$\frac{\partial^2 f}{\partial x_k \partial x_\ell} = A_{k\ell} \quad (\text{Hessian 就是 } A). \quad (9.10)$$

9.4.4 矩阵对标量的导数

当损失函数包含参数矩阵时, 需要矩阵对标量求导:

$$\frac{\partial L}{\partial W_{ij}} \quad \text{—— 损失 } L \text{ 对权重矩阵 } W \text{ 每个元素的偏导。} \quad (9.11)$$

这正是反向传播中的 $\nabla_W L$ ——梯度矩阵与 W 同形状。

9.4.5 何时用矩阵记号, 何时用指标记号

场景	推荐记号	原因
OLS 正规方程推导	矩阵	整体运算紧凑, 一步到位
迹技巧 & 矩阵求导	矩阵	查表法最直接
二次型/线性型梯度	矩阵 + 指标	矩阵给结果, 指标验证细节
Hessian 的稀疏结构分析	指标	元素级偏导一目了然
反向传播推导	指标	逐元素的链式法则无法用矩阵简洁表达
$X^\top X$ 不可逆时的分析	矩阵 (谱分解)	SVD 视角揭示本质

实用策略: 用矩阵记号写算法框架, 用指标记号填写推导细节——两者互补而非替代。

9.5 谱分解与奇异值分解 (SVD)

9.5.1 对称矩阵的谱分解

若 A 是 $n \times n$ 实对称矩阵, 则存在正交矩阵 Q ($Q^\top Q = I$) 和对角矩阵 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$, 使得:

$$A = Q\Lambda Q^\top = \sum_{i=1}^n \lambda_i q_i q_i^\top. \quad (9.12)$$

指标形式: $A_{ij} = \sum_k \lambda_k Q_{ik} Q_{jk}$ 。

在 ML 中的意义:

- 若 A 是协方差矩阵, λ_i 是第 i 主成分的方差, q_i 是方向;
- $A^{-1} = Q\Lambda^{-1}Q^\top = \sum \lambda_i^{-1} q_i q_i^\top$ ——特征值越小, 求逆时贡献越大, 这也是 $X^\top X$ 接近奇异时 OLS 方差爆炸的根源。

9.5.2 奇异值分解 (SVD)

对任意 $N \times p$ 矩阵 X , 存在正交矩阵 $U_{N \times N}$ 、 $V_{p \times p}$ 和对角矩阵 $D_{N \times p}$ (对角元 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$), 使得:

$$X = UDV^\top. \quad (9.13)$$

- σ_i : X 的奇异值 (非负);
- U 的列: 左奇异向量 = $XX^\top$ 的特征向量;
- V 的列: 右奇异向量 = $X^\top X$ 的特征向量;
- 关系: $X^\top X = VD^\top DV^\top$, $XX^\top = UDD^\top U^\top$ 。

在 ML 中的关键应用:

- (1) **PCA**: 对去均值后的 X 做 SVD, V 的列就是主成分方向;
- (2) **伪逆 (Moore-Penrose)**: $X^+ = VD^+U^\top$, 其中 D^+ 将非零奇异值取倒数。当 $p > N$ 时 OLS 无唯一解, 伪逆给出最小范数解;
- (3) **Ridge 回归的谱形式**:

$$\hat{\beta}_{\text{ridge}} = (X^\top X + \lambda I)^{-1} X^\top y = V \frac{D}{D^2 + \lambda I} U^\top y = \sum_{j=1}^r \frac{\sigma_j}{\sigma_j^2 + \lambda} (u_j^\top y) v_j. \quad (9.14)$$

λ 将所有方向上的 σ_j^2 上移——小奇异值方向不再爆炸。

9.6 矩阵范数

定义 9.3 (常用矩阵范数). • **Frobenius 范数**: $\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2} = \sqrt{\text{tr}(A^\top A)} = \sqrt{\sum \sigma_i^2}$;

• **谱范数** (L_2 范数): $\|A\|_2 = \sigma_{\max}(A)$, 即最大的奇异值;

• **核范数**: $\|A\|_* = \sum \sigma_i(A)$ (奇异值之和)。

在 ML 中的角色:

- L_2 权重衰减 $\lambda\|w\|^2$ 本质是惩罚向量的 Frobenius 范数平方;
- 谱范数控制 Lipschitz 常数——在 GAN 和对抗训练中用于稳定训练;
- 核范数是秩函数的凸松弛: $\min \text{rank}(A)$ 是 NP-hard, $\min \|A\|_*$ 可凸优化求解——用于矩阵补全 (推荐系统)、低秩表示。

9.7 关键恒等式

9.7.1 Woodbury 矩阵求逆公式

$$(A + UCV)^{-1} = A^{-1} - A^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1}. \quad (9.15)$$

用途: 将一个大矩阵的求逆转化为一个小矩阵的求逆。在留一法交叉验证中, 每次移除一个观测后不需重算整个 $(X^\top X)^{-1}$, 而是用 Woodbury 公式做 $O(p^2)$ 的更新。

9.7.2 矩阵求逆引理 (Woodbury 的特例)

$$(I + AB)^{-1}A = A(I + BA)^{-1}. \quad (9.16)$$

用途: Ridge 回归的等价变形。当 $p \gg N$ 时:

$$\hat{\beta} = (X^\top X + \lambda I_p)^{-1}X^\top y = X^\top (XX^\top + \lambda I_N)^{-1}y. \quad (9.17)$$

左边求逆的是 $p \times p$ 矩阵, 右边是 $N \times N$ ——当 $p \gg N$ 时右边计算量小得多。

9.7.3 期望的二次型

设 $\mathbb{E}[x] = \mu$, $\text{Var}(x) = \Sigma$:

$$\mathbb{E}[x^\top Ax] = \text{tr}(A\Sigma) + \mu^\top A\mu. \quad (9.18)$$

推导:

$$\begin{aligned} \mathbb{E}[x^\top Ax] &= \mathbb{E}[\text{tr}(x^\top Ax)] = \mathbb{E}[\text{tr}(Axx^\top)] = \text{tr}(A\mathbb{E}[xx^\top]) \\ &= \text{tr}(A(\Sigma + \mu\mu^\top)) = \text{tr}(A\Sigma) + \mu^\top A\mu. \end{aligned} \quad (9.19)$$

用途: 推导 RSS 的期望 ($\mathbb{E}[\|y - X\hat{\beta}\|^2]$), 计算预测误差的偏差-方差分解的矩阵形式。

第十章 统计学习导论

统计学习的核心问题是：从数据中学习一个函数，使得它能对未见过的输入做出准确的预测。

10.1 监督学习的数学框架

10.1.1 基本设定

定义 10.1 (监督学习的构成要素). 监督学习由以下要素构成：

- (i) 输入空间 $\mathcal{X} \subseteq \mathbb{R}^p$: p 维特征（自变量）的取值空间；
- (ii) 输出空间 $\mathcal{Y}$:
 - 回归问题: $\mathcal{Y} = \mathbb{R}$ （定量输出）；
 - 分类问题: $\mathcal{Y} = \{1, 2, \dots, K\}$ （定性输出, K 类）；
- (iii) 训练数据 $\mathcal{D} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$, 其中 $(\mathbf{x}_i, y_i) \stackrel{\text{i.i.d.}}{\sim} P(X, Y)$;
- (iv) 预测函数（模型）: $f: \mathcal{X} \rightarrow \mathcal{Y}$;
- (v) 损失函数 $L: \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_{\geq 0}$, 衡量预测 $f(\mathbf{x})$ 与真实 y 之间的代价。

10.1.2 损失函数

定义 10.2 (常见损失函数). • 平方损失（回归）:

$$L(y, f(\mathbf{x})) = (y - f(\mathbf{x}))^2. \quad (10.1)$$

- 绝对损失（回归）:

$$L(y, f(\mathbf{x})) = |y - f(\mathbf{x})|. \quad (10.2)$$

- 0-1 损失（分类）:

$$L(y, f(\mathbf{x})) = \mathbb{I}\{y \neq f(\mathbf{x})\}. \quad (10.3)$$

- 交叉熵损失 / 负对数似然 (分类):

$$L(y, \hat{\mathbf{p}}) = - \sum_{k=1}^K \mathbb{I}\{y = k\} \log \hat{p}_k, \quad (10.4)$$

其中 $\hat{\mathbf{p}} = (\hat{p}_1, \dots, \hat{p}_K)$ 为预测的类别概率向量。

- Hinge 损失 (SVM):

$$L(y, f(\mathbf{x})) = \max(0, 1 - yf(\mathbf{x})), \quad y \in \{-1, +1\}. \quad (10.5)$$

10.1.3 期望风险与经验风险

定义 10.3 (期望风险 (Expected Risk)). 给定损失函数 L , 预测函数 f 的期望风险 (泛化误差) 为:

$$R(f) = \mathbb{E}_{(X,Y) \sim P} [L(Y, f(X))] = \int_{\mathcal{X} \times \mathcal{Y}} L(y, f(\mathbf{x})) dP(\mathbf{x}, y). \quad (10.6)$$

学习的目标是找到 f^* 使得 $R(f)$ 最小化:

$$f^* = \arg \min_{f \in \mathcal{F}} R(f), \quad (10.7)$$

其中 $\mathcal{F}$ 为假设空间 (模型族)。

由于真实分布 $P(X, Y)$ 未知, 无法直接计算 $R(f)$ 。在实践中, 我们最小化经验风险:

定义 10.4 (经验风险 (Empirical Risk)).

$$\hat{R}(f) = \frac{1}{N} \sum_{i=1}^N L(y_i, f(\mathbf{x}_i)). \quad (10.8)$$

定义 10.5 (经验风险最小化 (ERM)).

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \frac{1}{N} \sum_{i=1}^N L(y_i, f(\mathbf{x}_i)). \quad (10.9)$$

核心挑战: ERM 得到的 $\hat{f}$ 在训练数据上表现好, 但我们需要它在未见数据上也表现好。这引出了统计学习理论的核心概念——泛化误差界与偏差-方差权衡。

10.1.4 EPE 与 ERM: 理想与现实的桥梁

前两小节的内容可以总结为一个简洁的逻辑链条:

$$\underbrace{\min_f \mathbb{E}[L(Y, f(X))]}_{\text{EPE 最小化: 理想目标, 不可计算}} \xrightarrow{\text{大数定律: 用样本均值替代期望}} \underbrace{\min_f \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i))}_{\text{ERM: 实际做法, 可计算}}$$

EPE 是真正的目标

无论回归还是分类，EPE 统一了所有监督学习问题的优化目标：

$$\text{EPE}(f) = \mathbb{E}_{(X,Y)\sim P}[L(Y, f(X))].$$

只取决于损失函数 L ，不挑问题类型：

- 平方损失 $\rightarrow$ 回归 $\rightarrow$ 最优解 $f^* = \mathbb{E}[Y \mid X]$;
- 0-1 损失 $\rightarrow$ 分类 $\rightarrow$ 最优解 $f^* = \arg \max_k \Pr(G = k \mid X)$;
- 一般损失矩阵 $\rightarrow$ 非对称代价分类 $\rightarrow$ 最优解 $\arg \min_g \sum_k L(G_k, g) \Pr(G_k \mid X)$ 。

ERM 是唯一能做的

EPE 的期望 $\mathbb{E}[\cdot]$ 是对真实联合分布 $P(X, Y)$ 取的，而 P 未知。我们手中只有从 P 中独立抽取的 N 个样本 $\{(x_i, y_i)\}_{i=1}^N$ 。

大数定律保证：独立同分布样本的均值收敛到期望：

$$\frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i)) \xrightarrow{N \rightarrow \infty} \mathbb{E}[L(Y, f(X))].$$

因此， $\frac{1}{N} \sum L(y_i, f(x_i))$ 是 $\mathbb{E}[L(Y, f(X))]$ 最自然、最直接的**样本替代品**——不需要任何分布假设、不需要参数化，仅靠大数定律就完成了从 EPE 到 ERM 的转换。这正是 ERM 框架如此通用的根本原因。

EPE 与 ERM 的对比

	EPE（期望预测误差）	ERM（经验风险最小化）
公式	$\mathbb{E}_{(X,Y)\sim P}[L(Y, f(X))]$	$\min_f \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i))$
能否计算	需要知道 $P(X, Y)$	只需要训练样本
角色	理想目标（你真正想最小化的）	实际手段（你唯一能做的）
关系	大数定律： $\frac{1}{N} \sum L(y_i, f(x_i)) \rightarrow \mathbb{E}[L(Y, f(X))]$	

核心张力：泛化差距

ERM 最小化得到的是 $\hat{f}$ ，EPE 最小的才是 f^* 。两者一般不相等：

- 训练误差（ERM 的值）可以压到任意低，甚至为零（如 k -NN 取 $k = 1$ ）；

- 测试误差 (EPE 的估计) 才是真正在乎的。

当 ERM 很低而 EPE 很高时 $\rightarrow$ 过拟合。这正是为什么后续章节需要正则化、交叉验证、模型选择——全是为了填平 ERM 和 EPE 之间的这道沟（泛化差距）。

10.1.5 最优预测器：回归函数

下面用 ESL 的符号体系，严格推导平方损失和 0-1 损失下的最优预测器。记 $X \in \mathbb{R}^p$ 为实值随机输入向量， $Y \in \mathbb{R}$ 为实值随机输出，二者的联合分布为 $\Pr(X, Y)$ 。

平方损失下的推导（回归）

定义 10.6 (期望预测误差 (Expected Prediction Error, EPE)). 在平方损失下，函数 f 的期望预测误差为：

$$\text{EPE}(f) = \mathbb{E}[(Y - f(X))^2] = \int_{\mathbb{R}^p \times \mathbb{R}} [y - f(\mathbf{x})]^2 \Pr(d\mathbf{x}, dy). \quad (10.10)$$

这里 $\Pr(d\mathbf{x}, dy)$ 是 X 与 Y 的联合概率测度。

下面推导使 $\text{EPE}(f)$ 最小的 f 。

Step 1 — 条件期望展开. 对 X 取条件，将联合期望分解为：

$$\begin{aligned} \text{EPE}(f) &= \mathbb{E}_X \mathbb{E}_{Y|X} \left([Y - f(X)]^2 \mid X \right) \\ &= \int_{\mathbb{R}^p} \left[\int_{\mathbb{R}} [y - f(\mathbf{x})]^2 \Pr(dy \mid \mathbf{x}) \right] \Pr(d\mathbf{x}). \end{aligned} \quad (10.11)$$

Step 2 — 逐点最小化. 由于 (10.11) 中被积函数非负，最小化 $\text{EPE}(f)$ 等价于对每个固定的 $\mathbf{x}$ ，选择 $f(\mathbf{x})$ 来最小化条件期望：

$$f(\mathbf{x}) = \arg \min_{c \in \mathbb{R}} \mathbb{E}_{Y|X} \left([Y - c]^2 \mid X = \mathbf{x} \right). \quad (10.12)$$

Step 3 — 求解 c^* . 记 $\mu(\mathbf{x}) = \mathbb{E}[Y \mid X = \mathbf{x}]$ ，将平方展开：

$$\begin{aligned} \mathbb{E}_{Y|X} [(Y - c)^2 \mid X = \mathbf{x}] &= \mathbb{E}[(Y - \mu(\mathbf{x}) + \mu(\mathbf{x}) - c)^2 \mid X = \mathbf{x}] \\ &= \mathbb{E}[(Y - \mu(\mathbf{x}))^2 \mid X = \mathbf{x}] + \underbrace{2 \mathbb{E}[(Y - \mu(\mathbf{x}))(\mu(\mathbf{x}) - c) \mid X = \mathbf{x}]}_{=0} \\ &\quad + \mathbb{E}[(\mu(\mathbf{x}) - c)^2 \mid X = \mathbf{x}] \\ &= \underbrace{\text{Var}(Y \mid X = \mathbf{x})}_{\text{与 } c \text{ 无关}} + \underbrace{(\mu(\mathbf{x}) - c)^2}_{\geq 0}. \end{aligned} \quad (10.13)$$

交叉项为零的原因如下。在条件期望 $\mathbb{E}[\cdot \mid X = \mathbf{x}]$ 中， $\mu(\mathbf{x}) = \mathbb{E}[Y \mid X = \mathbf{x}]$ 和 c 都是常数（因为已经条件在 $\mathbf{x}$ 上），可以提到期望外：

$$\mathbb{E}[(Y - \mu(\mathbf{x}))(\mu(\mathbf{x}) - c) \mid X = \mathbf{x}] = (\mu(\mathbf{x}) - c) \cdot \mathbb{E}[Y - \mu(\mathbf{x}) \mid X = \mathbf{x}].$$

而 $\mathbb{E}[Y - \mu(\mathbf{x}) \mid X = \mathbf{x}] = \mathbb{E}[Y \mid \mathbf{x}] - \mathbb{E}[\mu(\mathbf{x}) \mid \mathbf{x}] = \mu(\mathbf{x}) - \mu(\mathbf{x}) = 0$ 。 $\mathbb{E}[\mu(\mathbf{x}) \mid \mathbf{x}] = \mu(\mathbf{x})$ 是因为已经条件在 $\mathbf{x}$ 上， $\mu(\mathbf{x})$ 是确定的数——这和 $\mathbb{E}[5 \mid X] = 5$ 是同一个道理。

直观理解：回归函数 $\mu(\mathbf{x})$ 的定义性特征就是把 Y 分解为 $Y = \mu(\mathbf{x}) + \varepsilon$ ，其中残差 ε 的条件均值为零。若 $\mathbb{E}[\varepsilon \mid \mathbf{x}] \neq 0$ ，则 $\mu(\mathbf{x})$ 就不是真正的条件期望。

Step 4 — 结论. (10.13) 中仅第二项依赖于 c ，当 $c = \mu(\mathbf{x})$ 时取到最小值 0。因此：

定理 10.1 (平方损失下的最优预测器). 在平方损失 $L(y, f(\mathbf{x})) = (y - f(\mathbf{x}))^2$ 下，使 $\text{EPE}(f)$ 最小的唯一函数是**回归函数 (regression function)**：

$$f^*(\mathbf{x}) = \mathbb{E}[Y \mid X = \mathbf{x}] = \int_{\mathbb{R}} y \cdot \Pr(dy \mid \mathbf{x}). \quad (10.14)$$

EPE 的一般形式：损失矩阵

前面的 0-1 损失把所有分类错误一视同仁——把猫判为狗和判为老虎代价一样。但在实际问题中，不同错误的代价往往不同（例如：把恶性肿瘤判为良性的代价远大于反过来）。因此需要更一般的框架。

定义 10.7 (损失矩阵与 EPE 的一般形式). 设输出 $G \in \mathcal{G} = \{G_1, \dots, G_K\}$ 有 K 个类别。定义 $K \times K$ 的损失矩阵 $\mathbf{L}$ ，其元素：

$$L_{k\ell} = L(G_k, G_\ell) = \text{将真实类 } G_k \text{ 错判为 } G_\ell \text{ 的代价}, \quad L_{kk} = 0, \quad L_{k\ell} \geq 0.$$

分类器 $\hat{G}(X)$ 的期望预测误差为：

$$\text{EPE} = \mathbb{E}[L(G, \hat{G}(X))] = \mathbb{E}_X \sum_{k=1}^K L(G_k, \hat{G}(X)) \Pr(G_k \mid X). \quad (10.15)$$

Step 1 — 条件期望展开. 与平方损失一样，对 X 取条件：

$$\text{EPE} = \mathbb{E}_X \left[\sum_{k=1}^K L(G_k, \hat{G}(X)) \Pr(G_k \mid X) \right]. \quad (10.16)$$

Step 2 — 逐点最小化. 由于被积函数非负，只需对每个 $\mathbf{x}$ 独立地选择 $\hat{G}(\mathbf{x}) \in \mathcal{G}$ 最小化括号内的条件风险：

$$\hat{G}(\mathbf{x}) = \arg \min_{g \in \mathcal{G}} \sum_{k=1}^K L(G_k, g) \Pr(G_k \mid X = \mathbf{x}). \quad (10.17)$$

这就是**贝叶斯决策规则**的一般形式：在每个点上，选那个使**期望代价**最小的类。

Step 3 — 退化到 0-1 损失. 当 $L(G_k, G_\ell) = \mathbb{I}\{k \neq \ell\}$ （所有错误代价相同）时：

$$\sum_{k=1}^K \mathbb{I}\{k \neq g\} \Pr(G_k \mid \mathbf{x}) = \sum_{k \neq g} \Pr(G_k \mid \mathbf{x}) = 1 - \Pr(G = g \mid \mathbf{x}).$$

最小化 $1 - \Pr(G = g \mid \mathbf{x})$ 等价于最大化 $\Pr(G = g \mid \mathbf{x})$ ，退化为之前得到的贝叶斯分类器（定理 10.2）。

0-1 损失下的详细推导 (0-1 作为特例验证)

现在考虑 K 类分类问题, 输出 $G \in \mathcal{G} = \{1, 2, \dots, K\}$ 。

0-1 损失是损失矩阵 $L(G_k, G_\ell) = \mathbb{I}\{k \neq \ell\}$ 的特例。下面用 EPE 框架从头推导。

定义 10.8 (0-1 损失下的 EPE).

$$\text{EPE}(f) = \mathbb{E}[\mathbb{I}\{G \neq f(X)\}] = \int_{\mathbb{R}^p \times \mathcal{G}} \mathbb{I}\{g \neq f(\mathbf{x})\} \Pr(d\mathbf{x}, dg). \quad (10.18)$$

Step 1 — 条件期望展开.

$$\begin{aligned} \text{EPE}(f) &= \mathbb{E}_X \mathbb{E}_{G|X}(\mathbb{I}\{G \neq f(X)\} \mid X) \\ &= \int_{\mathbb{R}^p} \left[\sum_{g=1}^K \mathbb{I}\{g \neq f(\mathbf{x})\} \Pr(G = g \mid X = \mathbf{x}) \right] \Pr(d\mathbf{x}). \end{aligned} \quad (10.19)$$

Step 2 — 逐点最小化. 对每个固定的 $\mathbf{x}$, 需选择 $f(\mathbf{x}) \in \mathcal{G}$ 使括号内部最小。注意到:

$$\sum_{g=1}^K \mathbb{I}\{g \neq k\} \Pr(G = g \mid \mathbf{x}) = \sum_{g \neq k} \Pr(G = g \mid \mathbf{x}) = 1 - \Pr(G = k \mid \mathbf{x}).$$

因此最小化该式等价于最大化 $\Pr(G = k \mid \mathbf{x})$ 。

定理 10.2 (贝叶斯分类器). 在 0-1 损失下, 使 $\text{EPE}(f)$ 最小的最优分类器为:

$$f^*(\mathbf{x}) = \arg \max_{k \in \{1, \dots, K\}} \Pr(G = k \mid X = \mathbf{x}). \quad (10.20)$$

该分类器称为贝叶斯分类器 (Bayes classifier), 其错误率:

$$\text{EPE}(f^*) = \int_{\mathbb{R}^p} \left[1 - \max_k \Pr(G = k \mid X = \mathbf{x}) \right] \Pr(d\mathbf{x}) \quad (10.21)$$

称为贝叶斯错误率 (Bayes error rate)——任何分类器都无法超越的下界。

三种损失形式的统一视角

	平方损失 (回归)	0-1 损失 (分类)	一般损失矩阵
EPE	$\mathbb{E}[(Y - f(X))^2]$	$\mathbb{E}[\mathbb{I}\{G \neq f(X)\}]$	$\mathbb{E}[L(G, \hat{G}(X))]$
逐点目标	$\min_c \mathbb{E}[(Y - c)^2 \mid X = \mathbf{x}]$	$\min_k [1 - \Pr(G = k \mid \mathbf{x})]$	$\min_g \sum_k L(G_k, g) \Pr(G_k \mid \mathbf{x})$
最优解	$f^*(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{x}]$	$\arg \max_k \Pr(G = k \mid \mathbf{x})$	$\arg \min_g \sum_k L(G_k, g) \Pr(G_k \mid \mathbf{x})$
不可达下界	$\mathbb{E}[\text{Var}(Y \mid X)]$	$1 - \mathbb{E}[\max_k \Pr(G = k \mid X)]$	$\mathbb{E}[\min_g \sum_k L(G_k, g) \Pr(G_k \mid X)]$

所有情况下, 最优预测器都依赖于真实的条件分布 $P(Y \mid X)$ 。在实际问题中这个条件分布是未知的, 因此学习问题的本质是: 用有限样本 $\mathcal{D}$ 去逼近 $P(Y \mid X)$ 或直接逼近 f^* 。

10.1.6 两种建模策略

统计学习提供了两种基本策略来逼近 $f^*(\mathbf{x}) = \mathbb{E}[Y | X = \mathbf{x}]$:

(1) **参数方法 (Parametric)**: 假设 f 具有某种参数化形式。

- 例: 线性模型 $f(\mathbf{x}) = \boldsymbol{\beta}^\top \mathbf{x} + \beta_0$.
- 将估计无穷维函数的问题简化为估计有限个参数。
- 优点: 高效、可解释; 缺点: 模型假设可能错误 (欠拟合)。

(2) **非参数方法 (Nonparametric)**: 不假设 f 的具体形式, 直接从数据中学习。

- 例: k -近邻、核平滑、决策树、神经网络。

10.1.7 完整示例: 从数据到预测

下面通过两个完整的数值例子, 把上文的概念串成一条线: 数据 $\rightarrow$ 模型假设 $\rightarrow$ 参数估计 $\rightarrow$ 预测 $\rightarrow$ 评估。

例 1: 一元线性回归 (参数方法)

Step 1 — 数据. 设有 $N = 5$ 个观测:

$$\mathcal{D} = \{(1, 2.1), (2, 3.8), (3, 6.2), (4, 7.9), (5, 10.1)\}.$$

Step 2 — 模型假设. 假设 Y 与 X 呈线性关系:

$$f(x) = \beta_0 + \beta_1 x. \quad (10.22)$$

此时假设空间 $\mathcal{F} = \{f(x) = \beta_0 + \beta_1 x \mid \beta_0, \beta_1 \in \mathbb{R}\}$, 仅含两个参数。

Step 3 — 损失函数与优化. 采用平方损失, 经验风险为:

$$\hat{R}(\beta_0, \beta_1) = \frac{1}{5} \sum_{i=1}^5 (y_i - (\beta_0 + \beta_1 x_i))^2.$$

令梯度为零 $\frac{\partial \hat{R}}{\partial \beta_0} = \frac{\partial \hat{R}}{\partial \beta_1} = 0$, 解得:

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{10.0}{10.0} = 1.00, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 6.02 - 1.00 \times 3 = 3.02.$$

用矩阵形式 (正规方程) 得到相同结果。令设计矩阵 $\mathbf{X} = \begin{bmatrix} \mathbf{1} & \mathbf{x} \end{bmatrix}$:

$$\mathbf{X} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 2.1 \\ 3.8 \\ 6.2 \\ 7.9 \\ 10.1 \end{bmatrix}, \quad \hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \begin{bmatrix} 3.02 \\ 1.00 \end{bmatrix}.$$

Step 4 — 预测. 对新输入 $x_0 = 6$, 预测值为:

$$\hat{f}(6) = 3.02 + 1.00 \times 6 = 9.02.$$

Step 5 — 评估. 训练集上的均方误差:

$$\hat{R}(\hat{\beta}) = \frac{1}{5} \sum_{i=1}^5 (y_i - \hat{y}_i)^2 = \frac{0.0064 + 0.0144 + 0.0064 + 0.0144 + 0.0064}{5} \approx 0.0096.$$

训练误差很小, 说明模型对训练数据拟合良好。但真正的泛化能力需要用**独立测试集**来评估——这是第 7 章的核心议题。

例 2: 二分类——线性回归用作分类器 (ESL §2.4 经典示例)

Step 1 — 数据生成. 从两个二元正态分布中各抽取 100 个点, 总计 $N = 200$:

$$\text{Class BLUE: } \mathbf{x} \sim \mathcal{N}\left(\begin{bmatrix} 1 \\ 0 \end{bmatrix}, \mathbf{I}_2\right), \quad Y = 0, \quad (10.23)$$

$$\text{Class ORANGE: } \mathbf{x} \sim \mathcal{N}\left(\begin{bmatrix} 0 \\ 1 \end{bmatrix}, \mathbf{I}_2\right), \quad Y = 1. \quad (10.24)$$

Step 2 — 模型假设: 线性回归用于分类. 虽然是分类问题, 我们先用线性回归来拟合一个连续输出, 然后通过阈值转化为类别:

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2, \quad (10.25)$$

分类规则:

$$\hat{G} = \begin{cases} \text{ORANGE,} & \text{if } \hat{Y} > 0.5, \\ \text{BLUE,} & \text{if } \hat{Y} \leq 0.5. \end{cases} \quad (10.26)$$

Step 3 — 参数估计. 将 BLUE 编码为 $y = 0$, ORANGE 编码为 $y = 1$, 用最小二乘拟合:

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

得到的决策边界 $\hat{Y} = 0.5$ 在输入空间中是一条直线。

Step 4 — 预测与决策边界. 将 $\hat{Y} = 0.5$ 代入 (10.25):

$$\hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2 = 0.5.$$

这是一条将平面划分为两部分的直线——**线性决策边界**。

Step 5 — 评估: 训练误差 vs 测试误差.

(a) **训练误差.** 在训练集 (200 个点) 上计算 0-1 损失:

$$\hat{R}_{\text{train}}(\hat{f}) = \frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} \mathbb{I}\{\hat{G}_i \neq G_i\}. \quad (10.27)$$




图 10.1: 线性回归用于二分类: 决策边界将特征空间划分为两个区域。蓝色点为 Class BLUE, 橙色点为 Class ORANGE。

(b) 生成测试集. 从与训练集相同的分布中独立生成一个大规模测试集 (例如 $N_{\text{test}} = 10,000$ 个点), 以精确估计泛化误差:

$$\mathcal{D}_{\text{test}} = \{(\mathbf{x}_j, y_j)\}_{j=1}^{N_{\text{test}}}, \quad \mathbf{x}_j \sim \begin{cases} \mathcal{N}\left(\begin{bmatrix} 1 \\ 0 \end{bmatrix}, \mathbf{I}_2\right), & y_j = 0 \text{ (BLUE)}, \\ \mathcal{N}\left(\begin{bmatrix} 0 \\ 1 \end{bmatrix}, \mathbf{I}_2\right), & y_j = 1 \text{ (ORANGE)}. \end{cases}$$

注意: 测试集中的点绝不参与模型训练—— $\hat{f}$ 仅由训练集 $\mathcal{D}_{\text{train}}$ 得到。这是评估中最重要的纪律。

(c) 测试误差. 在测试集上计算 0-1 损失, 得到泛化误差的无偏估计:

$$\hat{R}_{\text{test}}(\hat{f}) = \frac{1}{N_{\text{test}}} \sum_{j=1}^{N_{\text{test}}} \mathbb{I}\{\hat{G}_j \neq G_j\}. \quad (10.28)$$

(d) 对比.

	公式	含义
训练误差	$\frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} \mathbb{I}\{\hat{G}_i \neq G_i\}$	模型对见过的数据错多少
测试误差	$\frac{1}{N_{\text{test}}} \sum_{j=1}^{N_{\text{test}}} \mathbb{I}\{\hat{G}_j \neq G_j\}$	模型对未见过的数据错多少

通常训练误差 < 测试误差（因为参数是针对训练数据优化的）。若两者的差距很大，说明模型过拟合；若两者都很大，说明模型欠拟合。这一诊断框架将在第 7 章（模型评估与选择）中系统展开。

Step 6 — 反思：线性回归做分类的问题。

- 编码方式 (0/1) 是任意的——若改为 $-1/+1$ ，结果不同；
- $\hat{Y}$ 可能超出 $[0, 1]$ ，无法解释为概率；
- 当 $K \geq 3$ 时，类别之间的顺序假设不合理。

这些缺陷正是第 4 章引入 Logistic 回归与线性判别分析 (LDA) 的动机。

例 3: k-近邻 (k-NN) 分类——非参数方法的代表

与例 2 使用完全相同的数据（两类二元高斯，各 100 个训练点），改用 k -近邻分类器。

算法. 对于输入 $\mathbf{x}$ ，k-NN 分类器的决策规则为：

- 在训练集中找出离 $\mathbf{x}$ 最近的 k 个点，记其索引为 $\mathcal{N}_k(\mathbf{x})$ ；
- 对这些点的类别进行多数投票：

$$\hat{G}(\mathbf{x}) = \arg \max_{g \in \{\text{BLUE}, \text{ORANGE}\}} \sum_{i \in \mathcal{N}_k(\mathbf{x})} \mathbb{I}\{G_i = g\}. \quad (10.29)$$

距离通常取欧氏距离： $\|\mathbf{x} - \mathbf{x}_i\|$ 。

有效参数个数. k-NN 没有显式的 β 参数，但其复杂度由 k 控制。ESL 定义其有效自由度为：

$$\text{df}(k) \approx \frac{N}{k}. \quad (10.30)$$

直观含义：

- $k = 1$: $\text{df} \approx 200$ ——每个训练点就是一个“参数”，纯记忆，决策边界极度蜿蜒；
- $k = 200$: $\text{df} \approx 1$ ——所有人一起投票退化为多数类预测，模型僵硬；
- $k \approx N/p$ 时，k-NN 与 p 个参数的线性模型复杂度大致相当——这是模型选择的粗略基准。

训练误差. 训练误差随 k 单调递增（ k 越小越能完美记住训练集）：

$$k = 1 \Rightarrow \text{训练误差} = 0 \quad (\text{每个点都是自己的最近邻}).$$

因此不能用训练误差来选择 k ——它永远偏向 $k = 1$ 。

测试误差与 k 的选择. 在独立测试集（10,000 个点）上评估不同 k 的表现，得到 U 形曲线（参见 ESL Figure 2.4）：

$$\text{测试误差}(k) = \frac{1}{N_{\text{test}}} \sum_{j=1}^{N_{\text{test}}} \mathbb{I}\{\hat{G}_j^{(k)} \neq G_j\}.$$

选择使测试误差最小的 k 。在 Scenario 1（两类各一个高斯，线性最优边界）下，最优 k 约在 30–40 左右。

两个极端：偏差-方差视角.

线性回归与 k -NN 代表了统计学习的两种**极端哲学**：

	线性模型（参数方法）	k -近邻（非参数方法）
核心假设	假设 f 是线性的（全局刚性）	不做假设，纯靠局部记忆
偏差	高（模型错 $\rightarrow$ 预测系统偏）	低（足够灵活，能拟合任意形状）
方差	低（估计量稳定，不易受扰动）	高（局部依赖，对训练样本敏感）
决策边界	光滑、稳定	蜿蜒、不稳定
典型问题	欠拟合（模型太简单）	过拟合（ k 太小则死记硬背）

几乎所有现代 ML 方法都是这两种简单过程的变体：

线性模型谱系	最近邻谱系
Ridge / Lasso（第 3 章）	核平滑（第 6 章）
Logistic 回归 / LDA（第 4 章）	局部回归
SVM（线性核）（第 12 章）	决策树 / 随机森林（第 9, 15 章）
GAM / 样条（第 5, 9 章）	神经网络（第 11 章）

所有现代方法的本质都是在**偏差与方差之间找平衡**——这构成了全书的方法论主线。

三个例子串联总结：

步骤	数据	模型	损失	优化	预测/评估
例 1	$(x_i, y_i) \in \mathbb{R} \times \mathbb{R}$	$f(x) = \beta_0 + \beta_1 x$	平方损失	正规方程	MSE
例 2	$(\mathbf{x}_i, y_i) \in \mathbb{R}^2 \times \{0, 1\}$	$f(\mathbf{x}) = \boldsymbol{\beta}^\top \mathbf{x} + \beta_0$	平方损失	正规方程	0-1 损失
例 3	同例 2	k -NN 多数投票	0-1 损失	调 k	测试误差 U 形曲线

10.1.8 理论回看：从最优预测器到实际估计器

在前面的推导中，定理 10.1 告诉我们：在平方损失下，最优预测器是回归函数 $f^*(\mathbf{x}) = \mathbb{E}[Y | X = \mathbf{x}]$ 。但在实践中我们不知道真实的联合分布 $\Pr(X, Y)$ ，只能用训练数据 $\mathcal{D}$ 去估计它。例 1–3 恰恰展示了两种截然不同的估计策略。

线性回归的估计器（例 1 & 例 2）

线性回归将条件期望限定为**线性函数**：

$$f(\mathbf{x}) \approx \mathbb{E}[Y | X = \mathbf{x}] \implies \hat{f}(\mathbf{x}) = \hat{\beta}_0 + \sum_{j=1}^p \hat{\beta}_j X_j = \mathbf{x}^\top \hat{\boldsymbol{\beta}}. \quad (10.31)$$

其中 $\hat{\boldsymbol{\beta}}$ 通过**经验风险最小化**（平方损失）得到：

$$\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta} \in \mathbb{R}^{p+1}} \frac{1}{N} \sum_{i=1}^N (y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}. \quad (10.32)$$

关键点：线性模型用一个**全局参数化假设**来逼近 f^* ——对所有 $\mathbf{x}$ 用同一组 $\hat{\boldsymbol{\beta}}$ 做预测。这等价于假设真实的 $\mathbb{E}[Y | X = \mathbf{x}]$ 恰好是 $\mathbf{x}$ 的线性函数。如果这个假设成立（Scenario 1），则偏差很小；如果不成立（Scenario 2），则偏差很大。

k-NN 的估计器（例 3）

k-NN 不做全局假设，而是用**局部样本平均**直接估计条件期望：

$$f^*(\mathbf{x}) = \mathbb{E}[Y | X = \mathbf{x}] \approx \hat{f}(\mathbf{x}) = \frac{1}{k} \sum_{i \in \mathcal{N}_k(\mathbf{x})} y_i, \quad (10.33)$$

其中 $\mathcal{N}_k(\mathbf{x})$ 是 $\mathbf{x}$ 的 k 个最近邻的指标集。

关键点：这是条件期望的一个非常直接的非参数估计——用「离 $\mathbf{x}$ 最近的 k 个点的 y 的均值」作为 $\mathbb{E}[Y | X = \mathbf{x}]$ 的估计。不需要假设 f 的形式，但也因此需要足够多的数据来保证局部平均的精度（维数灾难）。

两种估计器的渐近行为：谁逼近了 f^* ？

一个关键问题是：当 $N \rightarrow \infty$ 时， $\hat{f}$ 是否收敛到 $f^*(\mathbf{x}) = \mathbb{E}[Y | X = \mathbf{x}]$ ？

k-NN：在适当条件下（ $N \rightarrow \infty, k \rightarrow \infty, k/N \rightarrow 0$ ），局部平均收敛到条件期望：

$$\hat{f}_{\text{kNN}}(\mathbf{x}) \xrightarrow{N \rightarrow \infty} \mathbb{E}[Y | X = \mathbf{x}] = f^*(\mathbf{x}).$$

k-NN 是渐近无偏的——只要数据够多、 k 增长恰当，它最终能逼近真实的 f^* 。

线性回归：即使 $N \rightarrow \infty$ ， $\hat{f}$ 的极限不一定是 f^* 。线性回归的极限是 f^* 在全体线性函数中的**最佳 L_2 投影**：

$$\hat{f}_{\text{linear}}(\mathbf{x}) \xrightarrow{N \rightarrow \infty} \mathbf{x}^\top \boldsymbol{\beta}^*, \quad \boldsymbol{\beta}^* = \arg \min_{\boldsymbol{\beta} \in \mathbb{R}^{p+1}} \mathbb{E}[(Y - \mathbf{X}^\top \boldsymbol{\beta})^2].$$

只有当真实的 $f^*(\mathbf{x})$ 恰好是线性函数时，投影才等于 f^* 本身；否则 $\mathbf{x}^\top \boldsymbol{\beta}^*$ 只是 f^* 在线性子空间中的**最佳逼近**，而非 f^* 本身。

投影的几何含义. 考虑全体平方可积函数的空间 $\mathcal{L}^2(P_X) = \{g \mid \mathbb{E}[g(X)^2] < \infty\}$ ，其上定义内积 $\langle g, h \rangle = \mathbb{E}[g(X)h(X)]$ 。

线性函数构成一个子空间：

$$\mathcal{L} = \{g(\mathbf{x}) = \mathbf{x}^\top \boldsymbol{\beta} \mid \boldsymbol{\beta} \in \mathbb{R}^{p+1}\} \subset \mathcal{L}^2(P_X).$$

最佳线性近似 $\mathbf{x}^\top \boldsymbol{\beta}^*$ 就是 f^* 向 $\mathcal{L}$ 的**正交投影**：残差 $f^* - \mathbf{x}^\top \boldsymbol{\beta}^*$ 与 $\mathcal{L}$ 中每个函数正交，即 $\mathbb{E}[X_j \cdot (f^*(X) - X^\top \boldsymbol{\beta}^*)] = 0$ 对所有 j 成立。

换句话说： $\mathbf{x}^\top \boldsymbol{\beta}^*$ 是 $\mathcal{L}$ 中离 f^* “最近”的函数（在 $\|g\|^2 = \mathbb{E}[g(X)^2]$ 的距离意义下）。投影与真值之间的差距 $\|f^* - \mathbf{x}^\top \boldsymbol{\beta}^*\|^2$ 就是线性模型的**平方偏差**。

用欧氏空间的类比：三维空间中，点 f^* 向二维平面 $\mathcal{L}$ 作垂线，垂足 $\mathbf{x}^\top \boldsymbol{\beta}^*$ 就是最佳逼近，垂线长度就是偏差。这和线性代数中 $\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 是 $\mathbf{y}$ 向列空间的投影是同一个道理——只不过这里的“空间”是无穷维的函数空间，内积是 $\mathbb{E}[\cdot]$ 而非 $\mathbf{a}^\top \mathbf{b}$ 。

为什么线性函数不完备？ 线性子空间 $\mathcal{L}$ 的维度仅为 $p + 1$ ，而 $\mathcal{L}^2(P_X)$ 是无穷维的。因此 $\mathcal{L}$ 中的有限个基函数 $\{1, X_1, \dots, X_p\}$ 无法张成整个函数空间——它们构成的是一个**不完备的基**。这意味着：除非 f^* 恰好落在 $\mathcal{L}$ 内（即真实关系恰为线性），否则投影永远有非零残差，这正是偏差的来源。

反过来看，这正是全书后续章节的推进逻辑——**逐步扩充基函数集合，让不完备逼近完备**：

方法	扩充方式	子空间维度
线性回归	$\{1, X_1, \dots, X_p\}$	$p + 1$ （有限）
多项式回归	加 $X_1^2, X_1 X_2, X_2^2, \dots$	有限，可增大
样条（第 5 章）	加截断幂基 $h_j(X)$	有限，可控
核方法（第 6 章）	每个训练点一个基 $\rightarrow$ RKHS	无穷维（完备!）
神经网络（第 11 章）	万能逼近定理：宽网络可稠密	渐近完备

其中核方法使用的 RKHS（再生核希尔伯特空间）是完备的——其基函数族的闭包就是整个 $\mathcal{L}^2$ ，因此理论上可以逼近任意光滑的 f^* 。偏差-方差权衡中的“偏差”一侧，本质上就是不完备基无法表示 f^* 所带来的**结构误差**。

两种策略对比

	线性回归	k -近邻
对 f^* 的逼近方式	全局线性参数化	局部样本平均
预测函数	$\hat{f}(\mathbf{x}) = \mathbf{x}^\top \hat{\boldsymbol{\beta}}$	$\hat{f}(\mathbf{x}) = \frac{1}{k} \sum_{i \in \mathcal{N}_k(\mathbf{x})} y_i$
假设强度	强（线性）	弱（仅光滑性）
来源	参数方法传统	非参数 / 局部方法传统

两种方法的共同目标都是逼近同一个 $f^*(\mathbf{x}) = \mathbb{E}[Y | X = \mathbf{x}]$ 。差异在于**用什么结构来约束这个逼近**：线性回归用全局线性结构（偏差换方差）， k -NN 用局部常数结构（方差换偏差）。后续章节的所有方法——Ridge、Lasso、样条、核方法、树、神经网络——都可以理解为在这两种极端之间寻找更优的偏差-方差折中。

10.1.9 统计学习 vs 经典统计：两种推理框架

本章建立的数学框架与之前在“统计学基础”部分使用的框架有本质区别。两者并不矛盾，但出发点和核心关切截然不同。

经典统计框架（推断范式）

经典统计的核心目标是**推断 (inference)**——理解数据背后的生成机制：

数据 $\rightarrow$ 假设分布族（正态、二项等） $\rightarrow$ 估计参数 θ $\rightarrow$ 检验假设、构建置信区间。

典型问题：

- “ β_1 显著不为零吗？它的 95% 置信区间是什么？”
- “这批药的效果是否显著优于安慰剂？”
- “哪个自变量对因变量有显著影响？”

好坏的度量： p 值、置信区间、无偏性、有效性、功效。

统计学习框架（预测范式）

统计学习的核心目标是**预测 (prediction)**——对未见过的输入做出准确判断：

数据 $\rightarrow$ 选定损失函数 L $\rightarrow$ 学一个函数 f $\rightarrow$ 在新数据上评估误差。

典型问题：

- “给定这个用户的行为，他明天会不会流失？准确率多少？”

- “这张图片里是什么物体？”
- “这个病人五年内存活的概率是多少？”

好坏的度量：测试误差、交叉验证误差、AUC。

核心对比

	经典统计（推断）	统计学习（预测）
核心问题	数据是怎么生成的？	对新数据能预测多准？
核心对象	参数 θ (β, μ, σ^2)	函数 $f: \mathcal{X} \rightarrow \mathcal{Y}$
必需假设	分布族（正态、二项…）	仅需损失函数（不一定要分布）
模型角色	用于 解释 （哪个变量重要？）	用于 预测 （准确率够不够上线？）
好坏标准	p 值、置信区间、无偏性	测试误差、交叉验证误差

两者并非对立

统计学习中大量使用经典统计的工具，但**目的变了**：

统计工具	在经典统计中的角色	在统计学习中的角色
MLE	参数推断（估计 β 的标准误）	Logistic 回归的参数估计 (§4.4)
正态假设	推导 t 检验、 F 检验	线性回归的噪声模型 (§3.2)
偏差-方差分解	—（经典统计少有此视角）	模型选择的核心工具 (§2.5, §7.3)
Bootstrap	估计标准误	模型评估与 Bagging (§8.2, §8.7)

本质区别：在统计学习中，即使模型参数在统计意义上不显著、无法给出置信区间，只要它能让预测误差降低，它就是有用的——这在经典统计中是不可接受的。一切以预测性能为最终裁判，而非以统计显著性为裁判。

10.2 无监督学习的数学框架

10.2.1 基本设定

定义 10.9 (无监督学习的构成要素). 无监督学习仅有输入而没有输出标签：

- (i) 输入空间 $\mathcal{X} \subseteq \mathbb{R}^p$;
- (ii) 数据 $\mathcal{D} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$, 其中 $\mathbf{x}_i \stackrel{\text{i.i.d.}}{\sim} P(X)$;
- (iii) 目标: 从无标签数据中发现结构——聚类、降维、密度估计、生成建模等。

10.2.2 聚类

定义 10.10 (聚类问题). 给定 N 个数据点 $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ 和聚类数 K , 将数据划分为 K 个互不相交的子集 (簇) $C_1, \dots, C_K$, 使得簇内相似度高、簇间相似度低。

形式化地, K -means 的目标是最小化簇内平方和:

$$W(C) = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2, \quad (10.34)$$

其中 $\boldsymbol{\mu}_k = \frac{1}{|C_k|} \sum_{i \in C_k} \mathbf{x}_i$ 为第 k 簇的质心。

10.2.3 密度估计

定义 10.11 (密度估计). 给定 $\mathbf{x}_1, \dots, \mathbf{x}_N \stackrel{\text{i.i.d.}}{\sim} P$ (密度为 $p(\mathbf{x})$), 密度估计的目标是构造 $\hat{p}(\mathbf{x})$ 来逼近未知的真实密度 $p(\mathbf{x})$ 。

核密度估计 (KDE):

$$\hat{p}(\mathbf{x}) = \frac{1}{Nh^p} \sum_{i=1}^N K\left(\frac{\|\mathbf{x} - \mathbf{x}_i\|}{h}\right), \quad (10.35)$$

其中 $K(\cdot)$ 为核函数, $h > 0$ 为带宽参数。

10.2.4 降维

定义 10.12 (降维问题). 给定 $\mathbf{X} \in \mathbb{R}^{N \times p}$, 降维的目标是找到低维表示 $\mathbf{Z} \in \mathbb{R}^{N \times q}$ ($q < p$), 使得 $\mathbf{Z}$ 尽可能保留原始数据的结构信息。

定义 10.13 (主成分分析 (PCA)). PCA 寻找数据方差最大的方向。形式化地, 第 j 个主成分方向 $\mathbf{v}_j$ 满足:

$$\mathbf{v}_j = \arg \max_{\|\mathbf{v}\|=1, \mathbf{v} \perp \mathbf{v}_1, \dots, \mathbf{v}_{j-1}} \text{Var}(\mathbf{X}\mathbf{v}). \quad (10.36)$$

等价地, $\mathbf{v}_1, \dots, \mathbf{v}_q$ 是样本协方差矩阵 $\hat{\Sigma} = \frac{1}{N} \mathbf{X}^\top \mathbf{X}$ (中心化后) 的前 q 个特征向量。

10.3 监督学习与无监督学习的对比

	监督学习	无监督学习
数据	$\{(\mathbf{x}_i, y_i)\}_{i=1}^N$	$\{\mathbf{x}_i\}_{i=1}^N$
目标	学习映射 $f: \mathcal{X} \rightarrow \mathcal{Y}$	发现 $\mathcal{X}$ 的内在结构
数学核心	条件分布 $P(Y X)$	边缘分布 $P(X)$
优化对象	$\min_f \mathbb{E}[L(Y, f(X))]$	取决于任务（聚类、降维等）
典型任务	回归、分类	聚类、降维、密度估计、关联规则
评估难度	有标签，可计算准确率/MSE	无标签，评估更主观

补充：半监督学习 (Semi-supervised Learning)

- 数据：少量有标签 $\{(\mathbf{x}_i, y_i)\}_{i=1}^{\ell}$ + 大量无标签 $\{\mathbf{x}_j\}_{j=\ell+1}^N$.
- 核心思想：利用 $P(X)$ 的信息来改善对 $P(Y | X)$ 的估计.
- 常见方法：自训练 (self-training)、一致性正则化 (consistency regularization)、生成模型.

10.4 维数灾难与高维空间中的局部方法

维数灾难 (Curse of Dimensionality) 是 Bellman (1961) 提出的概念，在统计学习中特指：随着输入维度 p 增大，基于局部邻域的方法（如 k -NN、核平滑）会遭遇样本稀疏性的指数级恶化。本节用 ESL §2.5 的经典分析来量化这一现象。

10.4.1 单位超立方体中的邻域

考虑 p 维单位超立方体 $[0, 1]^p$ 中均匀分布的数据。对任意点 x_0 ，我们希望捕获其周围占总数据比例 r 的邻域。

问题：要覆盖 r 比例的数据，邻域在每个维度上的边长 $e_p(r)$ 是多少？

$$e_p(r) = r^{1/p}. \quad (10.37)$$

r	$p = 1$	$p = 3$	$p = 10$
1%	0.01	0.22	0.63
10%	0.10	0.46	0.80

在 $p = 10$ 维空间中, 要覆盖仅 1% 的数据就需要在每个维度上扩展 63% 的边长——几乎覆盖了整个范围。这意味着在十维空间中, 不存在真正意义上的”局部”邻域: 要么邻域几乎是全局的, 要么里面几乎没有点。

10.4.2 期望邻域边长

N 个点均匀分布在 $[0, 1]^p$ 中, 为在 x_0 处捕获 k 个最近邻, 所需超立方体邻域的期望边长为:

$$d(p, N) = \left(1 - 2^{-1/N}\right)^{1/p}. \quad (10.38)$$

典型数值 (ESL Exercise 2.3):

$$N = 500, p = 10 \implies d(p, N) \approx 0.52.$$

即需要覆盖每个维度上 52% 的范围来形成邻域——这已是全局尺度, 不再”局部”。

10.4.3 1-NN 的偏差-方差分解 (高维示例)

ESL §2.5 用一个具体例子展示维数灾难如何影响预测性能。

设定.

- $N = 1000$ 个训练点 x_i 均匀分布在 $[-1, 1]^p$ 中;
- 真实函数: $Y = f(X) = e^{-8\|X\|^2}$ ($x_0 = \mathbf{0}$ 处 $f(0) = 1$);
- 在 $x_0 = \mathbf{0}$ 处用 1-NN 预测 $\hat{y}_0$ 。

1-NN 的预测 $\hat{y}_0$ 就是离原点最近的训练点的 y 值。在 $x_0 = \mathbf{0}$ 处, MSE 分解为:

$$\text{MSE}(x_0) = \mathbb{E}_{\mathcal{T}}[(\hat{y}_0 - f(x_0))^2] = \text{Var}_{\mathcal{T}}(\hat{y}_0) + \text{Bias}^2(\hat{y}_0), \quad (10.39)$$

其中 $\mathcal{T}$ 表示对训练集的随机性取期望。

偏差-方差分解 (Bias-Variance Decomposition). 这是频率学派框架下分析模型性能的核心工具 (ESL 第 7 章将系统展开)。设真实函数为 $f(x_0)$, $\hat{f}(x_0)$ 为基于训练集 $\mathcal{T}$ 的估计, ε 为不可约噪声 ($\mathbb{E}[\varepsilon] = 0$, $\text{Var}(\varepsilon) = \sigma^2$), 则:

$$\mathbb{E}_{\mathcal{T}}[(y_0 - \hat{f}(x_0))^2] = \underbrace{(\mathbb{E}_{\mathcal{T}}[\hat{f}(x_0)] - f(x_0))^2}_{\text{偏差}^2} + \underbrace{\mathbb{E}_{\mathcal{T}}[(\hat{f}(x_0) - \mathbb{E}_{\mathcal{T}}[\hat{f}(x_0)])^2]}_{\text{方差}} + \underbrace{\sigma^2}_{\text{不可约噪声}}.$$

- **偏差 (Bias):** 即使有无限多训练集, 模型的平均预测离真实值有多远——衡量模型族本身的表达能力是否足够;
- **方差 (Variance):** 换一组训练集, 预测值波动多大——衡量模型对训练数据的敏感度;
- **不可约噪声:** 数据本身固有的随机性, 与模型无关。

偏差和方差通常不可兼得: 简单模型低方差高偏差 (欠拟合), 复杂模型低偏差高方差 (过拟合)。这里的 $\mathbb{E}_{\mathcal{T}}[\cdot]$ 是对不同训练集的重复抽样取期望——典型的频率学派视角。

本例中的表现. 随着 p 增大:

- **偏差增大:** 最近邻离原点越来越远 (因为高维中数据稀疏), 其 y 值随 $\|x\|$ 增大而衰减 ($f(x) = e^{-8\|x\|^2}$), 导致 $\hat{y}_0$ 系统性低于 $f(0) = 1$;
- **方差增大:** 最近邻位置的高度可变性导致 $\hat{y}_0$ 波动剧烈。

10.4.4 线性模型 vs 1-NN: 高维下的 EPE 对比

ESL 进一步对比了线性回归 (最小二乘) 和 1-NN 在 p 增大时的表现。

线性模型的设定. 假设真实模型为 $Y = X^\top \beta + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma^2)$, 用最小二乘拟合 $\hat{\beta}$ 。对 x_0 的预测:

$$\hat{y}_0 = x_0^\top \hat{\beta} = x_0^\top \beta + \sum_{i=1}^N \ell_i(x_0) \varepsilon_i,$$

其中 $\ell_i(x_0)$ 为 x_0 在帽子矩阵 $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ 中的对应元素。

在模型正确设定下, 对 x_0 取期望后:

$$\mathbb{E}_{x_0} \text{EPE}(x_0) \approx \sigma^2 \frac{p}{N} + \sigma^2. \quad (10.40)$$

第一项 $\sigma^2 p/N$ 来自估计 β 的方差, 随 p 线性增长; 第二项 σ^2 是不可约噪声。

1-NN 的 EPE 行为. 在高维空间中, 1-NN 最近邻的距离随 p 急剧增大, 导致偏差和方差均随 p 爆炸, EPE 远高于线性模型 (在真实模型为线性的条件下)。

核心教训.

方法	EPE 在高维下的行为	根本原因
线性回归	$\approx \sigma^2(p/N) + \sigma^2$, 随 p 线性增长	需要估计 p 个参数, 方差 $\propto p$
1-NN	随 p 指数恶化	邻域在高维中不再“局部”

在高维设置中, 即使真实函数是非线性的, 参数方法 (如线性回归) 往往优于非参数局部方法——因为非参数方法的方差代价在高维中变得不可接受。这一反直觉的结论是理解现代高维统计学习的基石, 也是为什么 Ridge、Lasso、正则化等方法如此重要的原因。

10.4.5 维数灾难的形式化定义与启示

定义 10.14 (维数灾难 (Curse of Dimensionality)). 设 p 为输入维度, ε 为邻域半径的相对大小。为在 p 维空间中保持相同的局部数据密度 (以覆盖固定比例的数据), 所需样本量 N 随 p 指数增长:

$$N \propto \varepsilon^{-p} \quad \text{或等价地} \quad \varepsilon \propto N^{-1/p}. \quad (10.41)$$

启示.

- (1) 基于局部邻域的方法 (k -NN、核平滑、局部回归) 仅在**低维** ($p \leq 4-5$) 中有效;
- (2) 在高维问题中, 必须引入**结构性假设** (线性、稀疏性、光滑性、低秩等) 来规避维数灾难;
- (3) 维数灾难并非诅咒一切方法——它主要打击的是**非参数局部方法**, 而参数方法和正则化方法可以通过假设结构来绕开它。

10.5 统计学习的基本框架：从模型到估计

本节系统梳理统计学习的核心概念链条——从加性误差模型出发, 经过损失函数与期望预测误差, 到达监督学习的参数估计方法 (最小二乘与极大似然), 最终揭示这些方法在函数逼近视角下的统一性。

10.5.1 加性误差模型与条件期望

统计学习最基本的出发点是假设输入 $X \in \mathbb{R}^p$ 与输出 $Y \in \mathbb{R}$ 之间存在如下关系:

$$Y = f(X) + \varepsilon, \quad (10.42)$$

其中:

- $f(X)$ 是 X 对 Y 的系统性影响——一个未知但确定性的函数;
- ε 是随机误差项, 满足

$$\mathbb{E}[\varepsilon] = 0, \quad \varepsilon \perp X; \quad (10.43)$$

- 独立性假设 $\varepsilon \perp X$ 意味着误差的分布不依赖于 X 的取值。

在式 (10.42) 两边对 $X = x$ 取条件期望:

$$\mathbb{E}[Y \mid X = x] = f(x) + \mathbb{E}[\varepsilon \mid X = x] = f(x). \quad (10.44)$$

因此 $f(x)$ 的统计含义就是条件期望（回归函数）：

$$f(x) = \mathbb{E}[Y | X = x]. \quad (10.45)$$

这正是回归分析的核心目标——在任意输入点 x 处，用条件均值作为 Y 的最佳预测。

注记 10.1 (回归函数 $\equiv$ 条件均值：是定义还是推导？). 初学者常有的困惑是：书中似乎”跳过”了损失函数的选择，直接宣称 $f(x) = \mathbb{E}[Y | X = x]$ 是回归函数。这背后的逻辑需要澄清。

两条汇合的推理路径.

路径一（定义先行，*ESL* 的叙述方式）：

”回归函数”在统计学中有历史定义 $\rightarrow f(x) = \mathbb{E}[Y | X = x] \rightarrow$ 后来发现平方损失恰好以它为目标

路径二（从损失出发，你的推理方式）：

选择损失函数 $L \rightarrow$ 最小化 $\text{EPE}(f) = \mathbb{E}[L(f(X), Y)] \rightarrow$ 解出最优 $f^* \rightarrow$ 若 L 是平方损失， f^* 恰好是条件均值

两条路径最终汇合，但因果关系不同。*ESL* 选择路径一，是因为”回归”(regression) 一词的历史起源就是条件均值——Galton (1886) 研究父子身高时发现了”向均值回归”(regression toward the mean) 现象，此后统计学便以 regression function 指代 $\mathbb{E}[Y | X]$ 。并非”因为选了平方损失所以最优是条件均值”，而是”回归函数的定义本就是条件均值，平方损失恰好以它为目标”。

不同损失函数导出不同的最优 f^* . 你关于损失函数决定最优预测器的理解完全正确。以下是常见对应：

损失 $L(y, f)$	最优 $f^*(x)$	名称
$(y - f)^2$	$\mathbb{E}[Y X = x]$	条件均值（回归函数）
$ y - f $	$\text{median}(Y X = x)$	条件中位数
$\mathbf{1}_{\{g \neq f\}}$ (0-1 分类损失)	$\arg \max_g P(G = g X = x)$	贝叶斯分类器
$\rho_\tau(y - f)$ (分位数损失)	$Q_\tau(Y X = x)$	条件 τ 分位数
Huber 损失	介于均值和截断均值之间（对异常值稳健）	

”回归”总是指均值吗？

在经典统计学中——是。”回归函数”严格定义为条件期望 $\mathbb{E}[Y | X]$ 。这一术语自 Galton 起已沿用百余年。教科书（包括 *ESL*）中未加修饰的”回归”默认指对条件均值的建模。

但在现代机器学习中——不完全如此。”回归”常被宽松地用来指任何输出为连续量的预测任务，不一定以均值为目标：

- 用 MAE 训练的网络仍被称为”回归模型”，尽管它估计的是条件中位数而非均值；
- 分位数回归 (quantile regression) 估计条件分位数，名称中仍带”回归”二字；
- 实践中大多默认使用平方损失/MSE，因此多数”回归”确实在估计条件均值——但这更多是惯例而非必然。

区分方式：严格写作时用”均值回归”(mean regression) 或”条件期望估计”；宽松语境下，”回归”≈”预测连续量”，具体目标取决于所用的损失函数。本书此后提及”回归函数”，除非特别说明，均指 $\mathbb{E}[Y | X]$ 。

10.5.2 条件方差：为什么可以不是常数

定义条件方差：

$$\text{Var}(Y | X = x) = \mathbb{E}[(Y - f(x))^2 | X = x] = \mathbb{E}[\varepsilon^2 | X = x] =: \sigma^2(x). \quad (10.46)$$

关键点：模型仅假设了 $\mathbb{E}[\varepsilon | X] = 0$ （一阶矩为零），对二阶矩 $\sigma^2(x)$ 没有任何约束。因此 $\sigma^2(x)$ 完全可以依赖于 x ，不需要是常数——这称为异方差性 (heteroscedasticity)。

例 10.1 (二分类问题的条件方差). 当 $Y \in \{0, 1\}$ 为二分类变量时，设 $p(x) = P(Y = 1 | X = x)$ ，则 $Y | X = x \sim \text{Bernoulli}(p(x))$ ：

$$\text{Var}(Y | X = x) = p(x)[1 - p(x)]. \quad (10.47)$$

方差在 $p = 0.5$ 处最大，在 $p \rightarrow 0$ 或 $p \rightarrow 1$ 时趋于零——明显依赖于 x 。

例 10.2 (泊松计数数据). 若 $Y | X \sim \text{Poisson}(\lambda(x))$ ，则 $\text{Var}(Y | X = x) = \lambda(x) = \mathbb{E}[Y | X = x]$ ——方差等于均值，随 x 变化。

10.5.3 期望预测误差与最优预测器

为了评价一个预测函数的好坏，引入期望预测误差 (Expected Prediction Error, EPE)：

$$\text{EPE}(f) = \mathbb{E}[(Y - f(X))^2]. \quad (10.48)$$

在平方损失下，可以证明**条件期望是最优预测器**：

定理 10.3 (最优预测器). 在加性误差模型 (10.42) 和平方损失下，条件期望 $f(x) = \mathbb{E}[Y | X = x]$ 最小化期望预测误差：

$$\arg \min_g \mathbb{E}[(Y - g(X))^2] = \mathbb{E}[Y | X]. \quad (10.49)$$

推导. 对任意函数 g , 在 $X = x$ 处展开:

$$\begin{aligned}\mathbb{E}[(Y - g(X))^2 | X = x] &= \mathbb{E}[(Y - f(x) + f(x) - g(x))^2 | X = x] \\ &= \underbrace{\mathbb{E}[(Y - f(x))^2 | X = x]}_{\sigma^2(x)} + (f(x) - g(x))^2 \\ &\geq \sigma^2(x),\end{aligned}\tag{10.50}$$

等号成立当且仅当 $g(x) = f(x)$ 。对所有 x 取期望即得结论。 $\square$

平方误差的分解:

$$\mathbb{E}[(Y - \hat{f}(X))^2] = \underbrace{\mathbb{E}[(f(X) - \hat{f}(X))^2]}_{\text{可约误差}} + \underbrace{\mathbb{E}[\sigma^2(X)]}_{\text{不可约噪声}}.\tag{10.51}$$

第一项取决于模型 $\hat{f}$ 的好坏 (可通过改进模型减小), 第二项 $\sigma^2(x) = \text{Var}(Y | X = x)$ 是数据固有的随机性 (≥ 0 , 无法消除)。

当 Y 是定性变量 (类别 G) 时, 平方损失替换为 0-1 损失或其他分类损失, 最优分类器为 $\arg \max_g P(G = g | X = x)$ 。

10.5.4 监督学习的数学表述

定义 10.15 (监督学习). 给定训练集 $\mathcal{T} = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, 其中 (x_i, y_i) 来自某个未知的联合分布 $P(X, Y)$ 的独立抽样。学习算法是一个映射 $\mathcal{A}: \mathcal{T} \mapsto \hat{f}$, 输出一个函数 $\hat{f}: \mathbb{R}^p \rightarrow \mathbb{R}$ (或 $\mathbb{R}^p \rightarrow \mathcal{G}$ 用于分类), 使得 $\hat{f}(x)$ 在未见过的 x 上也能较好地预测 y 。

核心挑战是泛化 (generalization) —— 在训练集上表现好是容易的, 在未知数据上也表现好才是学习的目标。这引出了偏差-方差权衡、正则化、模型选择等核心议题。

10.5.5 函数逼近视角

将 (X, Y) 看作 $\mathbb{R}^{p+1}$ 空间中的点, 学习 f 就是在这个空间中拟合一个曲面。参数化方法将 f 限制在某个函数族 $\{f_\theta: \theta \in \Theta\}$ 中。

线性模型

最简单的参数化是线性模型:

$$f(x) = x^\top \beta = \sum_{j=1}^p x_j \beta_j.\tag{10.52}$$

模型关于参数 β 是线性的, 但 x 本身可以是原始输入变量的任意变换。

线性基展开

更一般地，可以用 K 个基函数 $\{h_k(x)\}_{k=1}^K$ 的线性组合来表示 f ：

$$f_{\theta}(x) = \sum_{k=1}^K h_k(x) \theta_k. \quad (10.53)$$

模型关于参数 $\theta = (\theta_1, \dots, \theta_K)^\top$ 仍然是线性的，但基函数 $h_k(x)$ 可以是非线性的。常见选择：

基函数类型	$h_k(x)$ 的形式	示例
多项式	$h_k(x) = x_1^2, x_1 x_2, x_2^2, \dots$	二次回归
三角函数	$h_k(x) = \cos(\omega_k^\top x), \sin(\omega_k^\top x)$	傅里叶基
样条基	$h_k(x)$ 为分段多项式	光滑样条
Sigmoid	$h_k(x) = \frac{1}{1 + \exp(-x^\top \beta_k)}$	神经网络隐层
径向基	$h_k(x) = \exp(-\gamma \ x - c_k\ ^2)$	RBF 网络

关键洞察：线性基展开 (10.53) 在数学形式上与线性模型 (10.52) 完全一致——只需将 x 替换为 $h(x) = (h_1(x), \dots, h_K(x))^\top$ 。这意味着所有针对线性模型开发的估计理论和算法（最小二乘、正则化等）都可以直接应用于基展开模型——只需先做一次特征变换。

当 $h_k(x) = 1/(1 + \exp(-x^\top \beta_k))$ 且 β_k 本身也参与学习时，式 (10.53) 就是单隐层前馈神经网络——这是深度学习的基础构件。

10.5.6 参数估计 I：最小二乘法

对于参数化模型 $f_{\theta}(x)$ ，最自然的估计方法是最小化训练集上的残差平方和（Residual Sum of Squares, RSS）：

$$\text{RSS}(\theta) = \sum_{i=1}^N (y_i - f_{\theta}(x_i))^2, \quad (10.54)$$

其中 $r_i = y_i - f_{\theta}(x_i)$ 称为第 i 个观测的残差（residual）——模型预测值与真实值之间的差距。RSS 将所有残差的平方累加，度量模型在训练集上的总拟合误差。

最小二乘估计量为：

$$\hat{\theta}_{\text{LS}} = \arg \min_{\theta} \text{RSS}(\theta). \quad (10.55)$$

在加性误差模型和线性基展开 $f_{\theta}(x) = h(x)^\top \theta$ 下， $\text{RSS}(\theta)$ 是关于 θ 的二次函数，有显式解（假设 $\mathbf{H}^\top \mathbf{H}$ 可逆）：

$$\hat{\theta}_{\text{LS}} = (\mathbf{H}^\top \mathbf{H})^{-1} \mathbf{H}^\top \mathbf{y}, \quad (10.56)$$

其中 $\mathbf{H}$ 是 $N \times K$ 的设计矩阵，第 i 行为 $h(x_i)^\top$ 。

几何解释：最小二乘将 $\mathbf{y}$ 正交投影到 $\mathbf{H}$ 的列空间上， $\hat{\mathbf{y}} = \mathbf{H}\hat{\boldsymbol{\theta}}$ 是该空间中最接近 $\mathbf{y}$ 的点。

10.5.7 参数估计 II：极大似然估计

最小二乘只关心 f_θ 本身。更一般的框架是极大似然估计 (MLE)，它对整个条件分布 $\Pr(Y | X)$ 建模。

条件似然

设条件分布 $\Pr(Y | X)$ 的参数为 θ ，则对数似然为：

$$\ell(\theta) = \sum_{i=1}^N \log \Pr_\theta(y_i | x_i). \quad (10.57)$$

极大似然估计量：

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \ell(\theta). \quad (10.58)$$

正态误差下的 MLE $\Leftrightarrow$ 最小二乘

这是连接两种方法的关键桥梁。假设 $Y | X \sim \mathcal{N}(f_\theta(X), \sigma^2)$ ，即正态分布的位置参数由 f_θ 决定，尺度参数 σ^2 为常数。

对数条件密度：

$$\log \Pr(y_i | x_i, \theta) = -\frac{1}{2} \log(2\pi\sigma^2) - \frac{(y_i - f_\theta(x_i))^2}{2\sigma^2}. \quad (10.59)$$

忽略与 θ 无关的项（仅 σ^2 已知时成立；若 σ^2 也未知则需联合估计），最大化对数似然等价于最小化 $\sum (y_i - f_\theta(x_i))^2$ ：

$$\boxed{\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \ell(\theta) = \arg \min_{\theta} \sum_{i=1}^N (y_i - f_\theta(x_i))^2 = \hat{\theta}_{\text{LS}}.} \quad (10.60)$$

结论：正态误差假设下，MLE 与最小二乘完全等价。

若放宽到 $\text{Var}(Y | X = x) = \sigma^2(x)$ （异方差），最小二乘仍然给出 θ 的一致估计（在温和条件下），但不再是有效的 MLE。此时需用加权最小二乘 (WLS) ——对方差小的点赋予更大权重。

分类问题：多项似然 $\Leftrightarrow$ 交叉熵

当 $Y = G$ 是 K 类定性变量时，用多项分布 (multinomial) 建模条件概率 $p_{g,\theta}(x) = P_\theta(G = g | X = x)$ 。

对数似然为：

$$\ell(\theta) = \sum_{i=1}^N \log p_{g_i, \theta}(x_i), \quad (10.61)$$

其中 g_i 是第 i 个样本的真实类别。

最大化 (10.61) 等价于最小化交叉熵损失 (cross-entropy loss)：

$$\text{CE}(\theta) = - \sum_{i=1}^N \sum_{g=1}^K \mathbf{1}_{\{g_i=g\}} \log p_{g, \theta}(x_i). \quad (10.62)$$

结论：交叉熵损失 = 分类问题中 MLE 的等价形式。

10.5.8 参数估计 III：从 EPE 到 ERM

前面讨论了 LS 和 MLE 两种参数估计方法。在将它们与统计学习理论衔接时，有一个关键区别需要澄清。

EPE vs. ERM

平方损失下的期望预测误差 (EPE) 是对真实分布的期望：

$$\text{EPE}(f) = \mathbb{E}_{(X,Y)}[(Y - f(X))^2]. \quad (10.63)$$

但真实的联合分布 $P(X, Y)$ 未知，EPE 无法直接计算。实际中，我们用训练集上的经验平均来近似它，得到经验风险最小化 (Empirical Risk Minimization, ERM)：

$$\widehat{\text{EPE}}(f) = \frac{1}{N} \sum_{i=1}^N (y_i - f(x_i))^2. \quad (10.64)$$

最小二乘就是 ERM 在平方损失下的具体形式：

$$\hat{f}_{\text{LS}} = \arg \min_f \frac{1}{N} \sum_{i=1}^N (y_i - f(x_i))^2. \quad (10.65)$$

由大数定律，当 $N \rightarrow \infty$ 时 $\widehat{\text{EPE}}(f) \xrightarrow{P} \text{EPE}(f)$ ，因此 ERM 的解在样本量足够大时会逼近 EPE 的最优解。

但问题来了：大数定律的收敛需要 f 被固定（或至少来自一个不太复杂的函数族）。如果允许 f 是任意函数，ERM 会直接崩溃——这就是下一节的主题。

LS、ERM、EPE、MLE 四者关系总结：

概念	目标函数	对什么取平均	能否直接计算
EPE	$\mathbb{E}_{(X,Y)}[L(Y, f(X))]$	真实分布 $P(X, Y)$	× 未知
ERM	$\frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i))$	训练样本	✓ 可计算
LS	$\sum_{i=1}^N (y_i - f(x_i))^2$	训练样本（平方损失）	✓ ERM 的特例
MLE	$\sum_{i=1}^N \log P(y_i x_i, \theta)$	训练样本（对数似然）	✓ 等价于 ERM + KL 散度

MLE 与 ERM 的联系：在条件分布建模下，最大化对数似然等价于最小化模型分布与经验分布之间的 KL 散度，因此 MLE 本质上是 ERM 在概率建模框架下的对应物。

10.5.9 无约束最小化的根本困境

到目前为止，我们假设 f_θ 属于某个参数化的函数族（如线性模型 $f_\theta(x) = x^\top \beta$ 或基展开 $f_\theta(x) = \sum_k h_k(x) \theta_k$ ），参数个数 K 远小于样本量 N 。但如果我们不对 f 施加任何限制，直接最小化 $\text{RSS}(f) = \sum_{i=1}^N (y_i - f(x_i))^2$ ，会发生什么？

无穷多完美解

任何经过所有 N 个训练点 (x_i, y_i) 的函数 f 都满足 $\text{RSS}(f) = 0$ ——完美拟合训练数据。但这样的函数有无穷多个：

- 用折线依次连接所有数据点（按 x 排序）；
- 用一个 $N - 1$ 次多项式恰好穿过所有 N 个点（Lagrange 插值）；
- 在训练点之外任取任意值，只要在 x_i 处取值 y_i 即可。

这无穷多个解中，绝大多数在训练集之外的泛化性能极差——它们没有从数据中学到任何“规律”，只是在“背诵”训练点。

核心困境：

无限制的灵活性 + 有限的数据 = $\text{RSS} = 0$ 有无穷多解，全都没有泛化能力

从函数逼近的角度看，问题不在于“找不到函数穿过数据点”，而在于在无穷多穿过数据点的函数中，哪一个在未知点上表现好。

出路：对解空间施加限制

要获得有意义的解，必须缩小候选函数的范围。限制的强弱决定了模型的复杂度：

- **限制太强**（如只允许线性函数）：偏差大，可能漏掉数据的真实结构——欠拟合；
- **限制太弱**（如允许任意光滑函数）：方差大，模型被噪声牵着走——过拟合；
- **合适的限制**：在偏差和方差之间找到平衡。

限制可以通过多种方式实现，下面介绍两类最经典的方法：粗糙惩罚（正则化）和核方法（局部平均）。

10.5.10 受限制的估计量：几类经典方法

粗糙惩罚与平滑样条

核心思想：在 RSS 上添加一个惩罚项，惩罚 f 的“粗糙程度”——越粗糙（波动越剧烈）的函数被罚得越重。

带惩罚的残差平方和（Penalized RSS）：

$$\text{PRSS}(f; \lambda) = \underbrace{\sum_{i=1}^N (y_i - f(x_i))^2}_{\text{对数据的拟合度}} + \lambda \cdot \underbrace{J(f)}_{\text{对粗糙度的惩罚}}. \quad (10.66)$$

其中：

- $J(f)$ 是衡量 f 粗糙度的泛函—— $J(f)$ 越大， f 越“不光滑”；
- $\lambda \geq 0$ 是平滑参数，控制拟合度与光滑度之间的权衡：
 - $\lambda = 0$ ：无惩罚，退化为无约束 RSS 最小化（过拟合）；
 - $\lambda \rightarrow \infty$ ：无限惩罚，强制 $J(f) = 0$ ，即 f 必须是线性函数（欠拟合）；
 - λ 取中间值：在数据拟合和函数光滑之间找到平衡。

例 10.3 (三次平滑样条 (Cubic Smoothing Spline)). 在一维输入 $x \in \mathbb{R}$ 的情形下，一个经典选择是惩罚 f 的二阶导数的平方积分：

$$J(f) = \int [f''(x)]^2 dx. \quad (10.67)$$

带惩罚的目标函数为：

$$\text{PRSS}(f; \lambda) = \sum_{i=1}^N (y_i - f(x_i))^2 + \lambda \int [f''(x)]^2 dx. \quad (10.68)$$

这个问题的解是一个自然三次样条 (natural cubic spline) —— 在所有具有绝对连续一阶导数和平方可积二阶导数的函数中, 式 (10.68) 的极小值点是一个节点恰好在所有训练点 x_i 处的三次样条。

直觉:

- $f''(x)$ 度量 f 的曲率——函数“拐弯”的剧烈程度;
- $\int [f'']^2$ 累积了整条曲线的总弯曲量;
- 惩罚此项意味着: 倾向于选择“尽可能直”但仍能拟合数据的曲线。

贝叶斯解释. 粗糙惩罚有一个优雅的贝叶斯对应:

$$\underbrace{\text{PRSS}(f; \lambda)}_{\text{频率学派: 惩罚最小二乘}} \longleftrightarrow \underbrace{-\log P(f \mid \text{数据})}_{\text{贝叶斯: 负对数后验}}$$

具体地, $\lambda J(f)$ 对应负对数先验 $-\log P(f)$:

- 惩罚 $\int [f'']^2$ 对应高斯过程先验: 假定 f 是一个具有特定协方差结构的高斯过程;
- λ 控制先验的强度——等价于贝叶斯框架中“你对 f 光滑的信念有多强”。

这正是正则化与贝叶斯方法的深层联系:**Ridge** 回归的 L_2 惩罚 $\leftrightarrow$ 高斯先验, **Lasso** 的 L_1 惩罚 $\leftrightarrow$ 拉普拉斯先验, 平滑样条的 $\int [f'']^2 \leftrightarrow$ 高斯过程先验。

核方法与局部回归

核思想: 在预测 x_0 处的 $f(x_0)$ 时, 只使用 x_0 附近的训练点, 而且离 x_0 越近的点权重越大。这通过一个核函数 $K_\lambda(x_0, x)$ 来实现。

核函数. $K_\lambda(x_0, x)$ 衡量输入点 x 对目标点 x_0 的“相关性”或“影响力”:

- 当 x 离 x_0 很近时, $K_\lambda(x_0, x)$ 取较大值;
- 当 x 离 x_0 很远时, $K_\lambda(x_0, x)$ 衰减到零;
- λ 是带宽参数, 控制“附近”的范围: λ 越小 $\rightarrow$ 邻域越窄 $\rightarrow$ 模型越灵活 (更局部); λ 越大 $\rightarrow$ 邻域越宽 $\rightarrow$ 模型越光滑 (更全局)。

例 10.4 (高斯核 (Gaussian Kernel)). 最常用的核函数之一:

$$K_\lambda(x_0, x) = \frac{1}{\lambda} \exp\left(-\frac{\|x - x_0\|^2}{2\lambda}\right). \quad (10.69)$$

带宽 λ 控制高斯函数的宽度, 决定了有效邻域的范围。

Nadaraya–Watson 估计量. 最简单的核回归估计量是加权平均:

$$\hat{f}(x_0) = \frac{\sum_{i=1}^N K_\lambda(x_0, x_i) y_i}{\sum_{i=1}^N K_\lambda(x_0, x_i)}. \quad (10.70)$$

这就是 **Nadaraya–Watson 核加权平均**—— $\hat{f}(x_0)$ 是周围训练点 y 值的加权平均, 权重由核函数决定。分母确保所有权重之和为 1, 使估计量成为真正的加权平均。

直觉:

- 预测 x_0 处的值 = 看看周围的数据点标签是什么, 取加权平均;
- 离得近的多参考, 离得远的少参考;
- λ 控制”周围”的范围——这是偏差-方差权衡的旋钮。

局部多项式回归. Nadaraya–Watson 等价于在每个 x_0 处拟合一个局部常数模型。更一般地, 可以在 x_0 的邻域内拟合局部多项式:

$$\min_{\beta_0, \dots, \beta_d} \sum_{i=1}^N K_\lambda(x_0, x_i) (y_i - \beta_0 - \beta_1(x_i - x_0) - \dots - \beta_d(x_i - x_0)^d)^2. \quad (10.71)$$

当 $d = 0$ 时退化为 Nadaraya–Watson (局部常数); $d = 1$ 为局部线性回归 (能更好地处理边界效应); 更高阶的 d 能捕捉更复杂的局部结构。

k -最近邻 (k -NN). 核方法的另一种变体是 k -NN:

$$\hat{f}(x_0) = \frac{1}{k} \sum_{x_i \in \mathcal{N}_k(x_0)} y_i, \quad (10.72)$$

其中 $\mathcal{N}_k(x_0)$ 是 x_0 的 k 个最近邻构成的集合。

k -NN 与核方法的区别:

- 核方法: 固定带宽 λ (固定距离范围), 邻域内的点数随位置变化;
- k -NN: 固定邻域点数 k , 邻域半径随位置和数据密度自适应调整。

在数据密度不均匀的区域, k -NN 的适应性更好 (密集区域邻域小, 稀疏区域邻域大)。

局部方法的共同局限: 维数灾难. 所有基于邻域的方法 (核平滑、局部回归、 k -NN) 在高维空间中都会遭遇维数灾难——为保持相同的局部数据密度, 所需样本量随维度指数增长。这正是为什么在高维问题中, 必须借助结构性假设 (线性、稀疏性、可加性等) 来规避这一问题。

方法	限制方式	复杂度旋钮	数学形式
粗糙惩罚/样条	惩罚 f 的曲率	λ (平滑参数)	$\text{RSS} + \lambda J(f)$
核平滑	局部加权平均	λ (带宽)	$\sum K_\lambda(x_0, x_i) y_i / \sum K_\lambda$
k -NN	固定邻域点数	k (邻居数)	$\frac{1}{k} \sum_{x_i \in \mathcal{N}_k(x_0)} y_i$
局部多项式	局部多项式拟合	λ (带宽) + d (阶数)	加权最小二乘

基函数与字典方法

第三类限制估计量的策略是：将 f 表示为一组基函数的线性组合，从而把无限维的函数空间限制在有限维的线性空间中。

线性基展开（回顾）。如 §5 所述，参数化模型的最一般形式是：

$$f_\theta(x) = \sum_{m=1}^M \theta_m h_m(x), \quad (10.73)$$

其中 $\{h_m(x)\}_{m=1}^M$ 是预先选定的一组基函数（或称为字典）。模型关于参数 θ 是线性的，因此可以用最小二乘直接求解。复杂度由基函数的个数 M 控制： M 太小 $\rightarrow$ 欠拟合（高偏差）， M 太大 $\rightarrow$ 过拟合（高方差）。

多项式样条（Polynomial Splines）。一维输入时，一种经典的基函数选择是截断幂基（truncated power basis）。将输入域用 $M-2$ 个节点（knots） $t_1, \dots, t_{M-2}$ 划分，构造如下基函数：

$$\begin{aligned} h_1(x) &= 1, \\ h_2(x) &= x, \\ h_{m+2}(x) &= (x - t_m)_+, \quad m = 1, \dots, M-2, \end{aligned} \quad (10.74)$$

其中 $(x - t)_+ = \max(0, x - t)$ 是截断幂函数——在节点 t 之前为零，在节点 t 之后线性增长。每个节点处的“弯折”由对应的基函数贡献。

这类基函数产生的 f_θ 是一个分段多项式：在相邻节点之间是低阶多项式，在节点处具有某种连续阶数。例如，上述构造产生的是线性样条（一阶，节点处连续但导数不连续）。若加入二次项 x^2 和截断二次项 $(x - t_m)_+^2$ ，则得到二次样条（一阶导数也连续）；更常用的是三次样条（基函数包含 $1, x, x^2, x^3$ 及 $(x - t_m)_+^3$ ，在节点处直到二阶导数都连续）。

样条与粗糙惩罚的关系。三次平滑样条（§10 粗糙惩罚部分）可以证明等价于将所有 N 个训练点都作为节点的三次样条，加上对系数的特定 L_2 型惩罚——两种视角殊途同归。

径向基函数 (Radial Basis Functions, RBF) . 对于多维输入, 一个自然的选择是径向基函数——它们的值只依赖于输入点到某个中心 μ_m 的距离:

$$f_{\theta}(x) = \sum_{m=1}^M K_{\lambda_m}(\mu_m, x) \theta_m,$$

(10.75)

其中 $K_{\lambda_m}(\mu_m, x)$ 是关于 $\|x - \mu_m\|$ 对称的核函数 (如高斯核 $K_{\lambda}(\mu, x) = \exp(-\|x - \mu\|^2/2\lambda)$).

中心 μ_m 和尺度 λ_m 需要预先选定 (如通过聚类确定中心位置), 然后 θ_m 用最小二乘估计. RBF 网络在低维插值和函数逼近中非常有效, 但在高维中同样受制于维数灾难.

自适应基函数: 单隐层前馈神经网络. 前述所有方法的基函数 $\{h_m\}$ 都是在见到数据之前预先选定的. 神经网络的突破性思想是: 让基函数本身也由数据决定——即基函数含可学习的参数.

单隐层前馈神经网络的形式为:

$$f_{\theta}(x) = \sum_{m=1}^M \beta_m \sigma(\alpha_m^{\top} x + b_m),$$

(10.76)

其中:

- $\sigma(\cdot)$ 是激活函数, 经典选择是 **sigmoid**:

$$\sigma(v) = \frac{1}{1 + e^{-v}};$$

(10.77)

- $\alpha_m \in \mathbb{R}^p$ 和 $b_m \in \mathbb{R}$ 控制第 m 个基函数的形状和位置——它们是从数据中学习的, 而非预先固定;
- β_m 是输出层的权重, 与基展开中的 θ_m 角色相同.

将式 (10.76) 与线性基展开 (10.73) 对比:

	固定基展开	神经网络
基函数	$h_m(x)$ 预先选定	$\sigma(\alpha_m^{\top} x + b_m)$, α_m, b_m 可学习
参数	仅 θ_m (线性)	α_m, b_m, β_m (非线性)
优化	最小二乘有显式解	需迭代优化 (反向传播)
复杂度控制	基函数个数 M	M + 正则化 (权重衰减、早停等)

神经网络的代价是：由于基函数本身含可学习参数，目标函数不再是 θ 的二次函数，无法显式求解，需要迭代数值优化（梯度下降及其变体）。但收益是巨大的——只需适量的 M ，神经网络就能逼近非常复杂的函数，因为每个基函数可以根据数据自适应地调整形状和位置。

限制方法的总览：

方法	限制方式	复杂度旋钮	数学形式
粗糙惩罚/样条	惩罚 f 的曲率	λ （平滑参数）	$\text{RSS} + \lambda J(f)$
核平滑	局部加权平均	λ （带宽）	$\sum K_\lambda(x_0, x_i) y_i / \sum K_\lambda$
k -NN	固定邻域点数	k （邻居数）	$\frac{1}{k} \sum_{x_i \in \mathcal{N}_k(x_0)} y_i$
基展开	限定在 $\{h_m\}$ 张成的空间	M （基函数个数）	$\sum_{m=1}^M \theta_m h_m(x)$
神经网络	自适应基函数	M + 权重衰减	$\sum \beta_m \sigma(\alpha_m^\top x + b_m)$

10.5.11 模型选择与偏差-方差权衡

所有限制估计量方法都有一个复杂度参数（ λ, k, M 等），它控制着模型的灵活度。如何选择这个参数的最优值，是模型选择的核心问题。

偏差-方差分解

在进入 ML 语境下的偏差-方差分解之前，先看一个更基础的概率恒等式——全方差公式（Law of Total Variance）。它不仅本身重要，更是理解“预测误差为什么能拆成偏差和方差”的钥匙。

定理 10.4 (全方差公式 (Law of Total Variance)). 对任意随机变量 X 和 Y ：

$$\text{Var}(X) = \mathbb{E}[\text{Var}(X | Y)] + \text{Var}(\mathbb{E}[X | Y]). \quad (10.78)$$

三项的含义（与 ML 的对照将在后面展开）：

项	公式	直觉
总方差	$\text{Var}(X)$	X 本身的全部不确定性
组内方差（期望）	$\mathbb{E}[\text{Var}(X Y)]$	知道了 Y 之后， X 还剩多少波动？
组间方差	$\text{Var}(\mathbb{E}[X Y])$	不同 Y 取值下， X 的均值差异有多大？

直觉：全方差公式说的是—— X 的不确定性来自两个来源：（1）即使你知道 Y ， X 仍然有随机波动（组内方差，不可消除）；（2）不同 Y 下 X 的均值不同（组间方差，这是“规律”部分的差异）。

例 10.5 (一个具体例子). 设 X 是某学生的考试成绩。 Y 是他所属的班级（A 班或 B 班）。

- $\mathbb{E}[\text{Var}(X | Y)]$: 班级确定后，学生在班内的成绩波动——如 A 班内部有人考 70 有人考 90；
- $\text{Var}(\mathbb{E}[X | Y])$: 两个班平均分之间的差异——如 A 班平均 80，B 班平均 72。

全班学生成绩的总方差 = 班内波动的平均 + 班间均值的方差。

全方差公式 → 偏差-方差分解的桥梁.

现在做一步类比替换，全方差公式立刻变成 ML 中的偏差-方差分解：

全方差公式中的量	替换为 ML 中的量	得到
X （被研究的随机变量）	$Y - \hat{f}(x_0)$ （预测误差）	总预测误差的方差
Y （条件变量）	$\mathcal{T}$ （训练集）	以训练集为条件
$\mathbb{E}[X Y]$	$\mathbb{E}_{\mathcal{T}}[Y - \hat{f}(x_0)]$	平均预测误差

代入全方差公式：

$$\text{Var}(Y - \hat{f}(x_0)) = \underbrace{\mathbb{E}_{\mathcal{T}}[\text{Var}(Y - \hat{f}(x_0) | \mathcal{T})]}_{\text{给定训练集后, 预测误差的波动}} + \underbrace{\text{Var}_{\mathcal{T}}(\mathbb{E}[Y - \hat{f}(x_0) | \mathcal{T}])}_{\text{不同训练集下, 平均预测误差的差异}}. \quad (10.79)$$

给定训练集 $\mathcal{T}$ 后， $\hat{f}(x_0)$ 是固定的（模型已经训练好了），而 $Y = f(x_0) + \varepsilon$ ， ε 与 $\mathcal{T}$ 独立。于是第一项展开就是 σ^2 ，第二项展开后分解为 $\text{Bias}^2 + \text{Var}$ 。

下面给出 ML 语境下的标准形式。**推导分两步：先走全方差路径得到 $\text{Var}(Y - \hat{f})$ ，再补上均值平方得到 $\mathbb{E}[(Y - \hat{f})^2]$ 。**

第一步：全方差公式分解 $\text{Var}(Y - \hat{f}(x_0))$ 。

回忆全方差公式 (10.78)，令 $X = Y - \hat{f}(x_0)$ ，条件变量为 $\mathcal{T}$ ：

$$\text{Var}(Y - \hat{f}(x_0)) = \underbrace{\mathbb{E}_{\mathcal{T}}[\text{Var}(Y - \hat{f}(x_0) | \mathcal{T})]}_{\text{①}} + \underbrace{\text{Var}_{\mathcal{T}}(\mathbb{E}[Y - \hat{f}(x_0) | \mathcal{T}])}_{\text{②}}. \quad (10.80)$$

分别化简两项：

化简 ① ——给定 $\mathcal{T}$ 后的条件方差. 给定训练集 $\mathcal{T}$, $\hat{f}(x_0)$ 是一个固定的数 (模型已训练好). 而 $Y = f(x_0) + \varepsilon$, 其中 ε 与 $\mathcal{T}$ 独立, $\text{Var}(\varepsilon) = \sigma^2$:

$$\text{Var}(Y - \hat{f}(x_0) \mid \mathcal{T}) = \text{Var}(f(x_0) + \varepsilon - \hat{f}(x_0) \mid \mathcal{T}) = \text{Var}(\varepsilon \mid \mathcal{T}) = \sigma^2. \quad (10.81)$$

因此 ① = $\mathbb{E}_{\mathcal{T}}[\sigma^2] = \boxed{\sigma^2}$ ——这就是不可约噪声。

化简 ② ——不同训练集下的均值波动. 先求内层期望. $f(x_0)$ 是常数, $\mathbb{E}[\varepsilon] = 0$:

$$\mathbb{E}[Y - \hat{f}(x_0) \mid \mathcal{T}] = f(x_0) + \mathbb{E}[\varepsilon] - \hat{f}(x_0) = f(x_0) - \hat{f}(x_0). \quad (10.82)$$

于是 ② 化为 $\hat{f}(x_0)$ 的方差 ($f(x_0)$ 是常数, 不影响方差):

$$\textcircled{2} = \text{Var}_{\mathcal{T}}(f(x_0) - \hat{f}(x_0)) = \text{Var}_{\mathcal{T}}(\hat{f}(x_0)). \quad (10.83)$$

综上, 全方差公式给出:

$$\boxed{\text{Var}(Y - \hat{f}(x_0)) = \sigma^2 + \text{Var}_{\mathcal{T}}(\hat{f}(x_0))}. \quad (10.84)$$

第二步: 从方差到期望平方误差.

方差和期望平方误差之间差了一个“均值平方”:

$$\mathbb{E}[(Y - \hat{f})^2] = \underbrace{(\mathbb{E}[Y - \hat{f}])^2}_{\text{均值}^2} + \text{Var}(Y - \hat{f}). \quad (10.85)$$

先算均值 (对训练集的期望 + 对 Y 的期望):

$$\mathbb{E}[Y - \hat{f}(x_0)] = \mathbb{E}_{\mathcal{T}}[\mathbb{E}[Y - \hat{f}(x_0) \mid \mathcal{T}]] = \mathbb{E}_{\mathcal{T}}[f(x_0) - \hat{f}(x_0)] = f(x_0) - \mathbb{E}_{\mathcal{T}}[\hat{f}(x_0)]. \quad (10.86)$$

均值平方项恰好是偏差²:

$$(\mathbb{E}[Y - \hat{f}])^2 = (f(x_0) - \mathbb{E}_{\mathcal{T}}[\hat{f}(x_0)])^2 = \text{偏差}^2. \quad (10.87)$$

合并两步:

$$\begin{aligned} \mathbb{E}_{\mathcal{T}}[(Y - \hat{f}(x_0))^2 \mid X = x_0] &= (f(x_0) - \mathbb{E}_{\mathcal{T}}[\hat{f}(x_0)])^2 + \text{Var}(Y - \hat{f}(x_0)) \\ &= (f(x_0) - \mathbb{E}_{\mathcal{T}}[\hat{f}(x_0)])^2 + \sigma^2 + \text{Var}_{\mathcal{T}}(\hat{f}(x_0)) \\ &= \text{偏差}^2 + \sigma^2 + \text{方差}. \end{aligned} \quad (10.88)$$

推导的核心链条:

$$\underbrace{\text{Var}(Y - \hat{f})}_{\text{全方差分解}} = \underbrace{\mathbb{E}[\text{Var}(\cdot \mid \mathcal{T})]}_{=\sigma^2} + \underbrace{\text{Var}(\mathbb{E}[\cdot \mid \mathcal{T}])}_{=\text{Var}(\hat{f})} \xrightarrow{+ (\mathbb{E}[Y - \hat{f}])^2} \underbrace{\mathbb{E}[(Y - \hat{f})^2]}_{\text{EPE}} = \underbrace{(f - \mathbb{E}[\hat{f}])^2}_{\text{偏差}^2} + \underbrace{\text{Var}(\hat{f})}_{\text{方差}} + \underbrace{\sigma^2}_{\text{噪声}}$$

定理 10.5 (偏差-方差分解). 设 $Y = f(X) + \varepsilon$, $\mathbb{E}[\varepsilon] = 0$, $\text{Var}(\varepsilon) = \sigma^2$. 对于在训练集 $\mathcal{T}$ 上拟合的模型 $\hat{f}(x_0)$, 在测试点 x_0 处的期望预测误差为:

$$\mathbb{E}_{\mathcal{T}}[(Y - \hat{f}(x_0))^2 | X = x_0] = \underbrace{(f(x_0) - \mathbb{E}_{\mathcal{T}}[\hat{f}(x_0)])^2}_{\text{偏差}^2} + \underbrace{\mathbb{E}_{\mathcal{T}}[(\hat{f}(x_0) - \mathbb{E}_{\mathcal{T}}[\hat{f}(x_0)])^2]}_{\text{方差}} + \underbrace{\sigma^2}_{\text{不可约噪声}}. \quad (10.89)$$

其中 $\mathbb{E}_{\mathcal{T}}[\cdot]$ 是对不同训练集（从同一分布重复抽样）取期望——典型的频率学派视角。三项的含义:

- **偏差 (Bias²)**: 即使有无穷多训练集, 模型平均预测与真实值差多远。衡量模型族本身的表达能力是否足够;
- **方差 (Variance)**: 换一组训练集, 预测值波动多大。衡量模型对训练数据的敏感度;
- **不可约噪声 (σ^2)**: 数据本身固有的随机性, 与模型无关, 是任何预测器的误差下界。

偏差与方差不可兼得:

- **简单模型 (高偏差, 低方差)**: 模型族不够灵活, 系统地偏离真实函数, 但对训练数据的扰动不敏感——欠拟合;
- **复杂模型 (低偏差, 高方差)**: 模型族足够灵活, 可以逼近任意函数, 但不同训练集会给出差异很大的估计——过拟合。

k -NN 的偏差-方差分析

k -最近邻回归为偏差-方差分解提供了一个清晰的实例。在 x_0 处, $\hat{f}_k(x_0) = \frac{1}{k} \sum_{\ell=1}^k y_{(\ell)}$, 其中 $y_{(\ell)}$ 是 x_0 的第 ℓ 近邻的标签。假设 $y_i = f(x_i) + \varepsilon_i$, ε_i 独立且 $\text{Var}(\varepsilon_i) = \sigma^2$:

$$\begin{aligned} \text{EPE}_k(x_0) &= \mathbb{E}[(Y - \hat{f}_k(x_0))^2 | X = x_0] \\ &= \sigma^2 + \underbrace{\left(f(x_0) - \frac{1}{k} \sum_{\ell=1}^k f(x_{(\ell)})\right)^2}_{\text{偏差}^2} + \underbrace{\frac{\sigma^2}{k}}_{\text{方差}}. \end{aligned} \quad (10.90)$$

这个分解非常直观:

- **偏差**: $\hat{f}_k(x_0)$ 的期望是 k 个近邻真实函数值的平均。若 f 在该邻域内不是常数, 这个平均值偏离 $f(x_0)$ —— k 越大, 邻域越大, f 在邻域内变化越大, 偏差越大;
- **方差**: k 个独立噪声的平均, 方差为 σ^2/k —— k 越大, 平均越多, 方差越小。

k 的角色:

- k 小 (如 $k = 1$): 偏差小 (只用最近邻, 其 f 值最接近 $f(x_0)$), 但方差大 ($\sigma^2/1 = \sigma^2$, 没有任何平均) —— 过拟合;
- k 大 (如 $k = N$): 方差小 ($\sigma^2/N \approx 0$), 但偏差大 (所有点的平均 $\approx \mathbb{E}[Y]$, 与 $f(x_0)$ 无关) —— 欠拟合;
- 最优的 k 在两者之间取得平衡。

对照全方差公式解读 k -NN 的分解. 将式 (10.90) 与全方差公式 (10.78) 逐项对照:

$$\text{Var}(Y - \hat{f}_k(x_0)) = \underbrace{\mathbb{E}_{\mathcal{T}}[\text{Var}(Y - \hat{f}_k(x_0) | \mathcal{T})]}_{=\sigma^2} + \underbrace{\text{Var}_{\mathcal{T}}(\mathbb{E}[Y - \hat{f}_k(x_0) | \mathcal{T}])}_{=\text{Bias}^2 + \frac{\sigma^2}{k}}.$$

- 组内方差 $\mathbb{E}[\text{Var}(\cdot | \mathcal{T})] = \sigma^2$: 给定训练集 (即固定了 k 个近邻的位置) 后, 预测误差的唯一随机来源是 $Y = f(x_0) + \varepsilon$ 中的 ε ——其方差为 σ^2 。这就是”不可约噪声”——与 k 无关、与模型无关;
- 组间方差 $\text{Var}(\mathbb{E}[\cdot | \mathcal{T}]) = \text{Bias}^2 + \frac{\sigma^2}{k}$: 不同训练集会选出不同的 k 个近邻, 导致 $\hat{f}_k(x_0)$ 的平均值发生变化。这个变化来自两个来源:
 - 偏差部分: 不同训练集的 k 个近邻位置不同, 其 f 值的平均也不同——离 $f(x_0)$ 的平均距离就是偏差;
 - 方差部分: 不同训练集的 ε_i 不同, 导致 $\frac{1}{k} \sum \varepsilon_i$ 波动——这就是 $\frac{\sigma^2}{k}$ 。

k 控制组间方差的结构:

- k 很小: $\frac{\sigma^2}{k}$ 很大 (噪声平均不够), 组间方差主要由噪声主导 $\rightarrow$ 过拟合;
- k 很大: $\frac{\sigma^2}{k} \rightarrow 0$ (噪声被充分平均), 但偏差部分增大 (邻域太大, 邻近的 f 值不再与 $f(x_0)$ 接近) $\rightarrow$ 欠拟合。

全方差公式在这里的作用是: 把”为什么 k 太大或太小都不好”这个直觉, 精确地分解为两个可量化部分——组内 (不可消除的噪声) 和组间 (偏差 + 方差)。

训练误差 vs. 测试误差

关键观察:

- 训练误差随模型复杂度增加而单调递减——不能单独用训练误差选择模型 (否则永远选最复杂的);
- 测试误差呈 U 形——这是模型选择的核心依据;
- 测试误差的最低点对应最优模型复杂度——在偏差和方差之间取得最佳平衡。




图 10.2: 训练误差与测试误差随模型复杂度的典型变化。训练误差（蓝色）随复杂度增加单调递减——越复杂的模型越能拟合训练数据。测试误差（红色）呈 U 形曲线：模型太简单时高偏差主导（欠拟合），模型太复杂时高方差主导（过拟合），最优复杂度在两者之间。虚线 σ^2 是不可约噪声的下界。

模型选择的实践方法

直接使用测试集来选模型会导致对测试误差的乐观估计（因为你本质上是用测试集来“训练”超参数）。实践中常用以下方法：

- (1) **留出法 (Hold-out)**：将数据划分为训练集和验证集，用验证集选择复杂度参数，最后在测试集上报告性能；
- (2) **K 折交叉验证 (K -fold CV)**：将数据分为 K 份，每次用 $K-1$ 份训练、1 份验证，轮换 K 次后取平均；
- (3) **信息准则**：AIC、BIC 等在训练误差上加一项对复杂度的惩罚，避免需要单独的验证集（但这些准则通常依赖特定的概率模型假设）。

核心教训：

训练集上的表现 $\neq$ 泛化能力

泛化能力——在未见过的数据上的表现——才是统计学习的终极目标。偏差-方差分解为理解和诊断泛化问题提供了数学框架，而复杂度参数的选择（ λ , k , M 等）正是控制偏差-方差权衡的旋钮。

10.5.12 总结：从模型到估计的统一框架

下图总结了统计学习从建模、估计到模型选择的完整逻辑链条：

$$\underbrace{Y = f(X) + \varepsilon}_{\text{加性误差模型}} \xrightarrow{\mathbb{E}[\cdot|X]} \underbrace{f(x) = \mathbb{E}[Y | X = x]}_{\text{条件期望是最优预测}} \xrightarrow{\text{参数化}} \underbrace{f_{\theta}(x) = \sum_{k=1}^K h_k(x) \theta_k}_{\text{基展开 / 函数逼近}}$$

↓ 如何估计 θ ?

$$\left\{ \begin{array}{l} \text{LS (ERM): } \min_{\theta} \underbrace{\frac{1}{N} \sum_{i=1}^N (y_i - f_{\theta}(x_i))^2}_{\text{经验风险} \approx \text{EPE}} \\ \text{MLE: } \max_{\theta} \underbrace{\sum_{i=1}^N \log \Pr_{\theta}(y_i | x_i)}_{\text{条件对数似然}} \end{array} \right.$$

↓ LS 与 MLE 的关系

正态误差	MLE $\Leftrightarrow$ 最小二乘
多项分布 (分类)	MLE $\Leftrightarrow$ 交叉熵

↓ 无约束 RSS 最小化的困境

RSS = 0 有无穷多解，全都没有泛化能力 $\xrightarrow{\text{必须限制}}$ 对 f 施加约束

↓ 三类限制方法

$$\left\{ \begin{array}{l} \text{粗糙惩罚: } \min_f \text{RSS}(f) + \lambda J(f) \quad (\lambda \text{ 控制光滑度}) \\ \text{核/局部方法: } \hat{f}(x_0) = \frac{\sum K_{\lambda}(x_0, x_i) y_i}{\sum K_{\lambda}(x_0, x_i)} \quad (\lambda \text{ 控制邻域大小}) \\ \text{基展开/字典: } f_{\theta}(x) = \sum_{m=1}^M \theta_m h_m(x) \quad (M \text{ 控制模型容量}) \end{array} \right.$$

↓ 如何选择复杂度参数?

$$\text{EPE} = \underbrace{\text{Bias}^2}_{\text{模型太简单} \uparrow} + \underbrace{\text{Var}}_{\text{模型太复杂} \uparrow} + \underbrace{\sigma^2}_{\text{不可约}} \xrightarrow{\text{权衡}} \text{交叉验证 / 信息准则选择 } \lambda, k, M$$

核心要点:

- (1) **加性误差模型** $Y = f(X) + \varepsilon$ ($\mathbb{E}[\varepsilon] = 0, \varepsilon \perp X$) 是统计学习最基本的建模假设, $f(x) = \mathbb{E}[Y | X = x]$ 是平方损失下的最优预测器;
- (2) **条件方差** $\text{Var}(Y | X = x) = \sigma^2(x)$ 可以依赖于 x , 模型只约束了一阶矩, 对二阶矩没有限制;
- (3) **监督学习的本质**是从训练集 $\mathcal{T} = \{(x_i, y_i)\}$ 中学出一个函数 $\hat{f}$, 使其在未知数据上也能良好泛化;
- (4) **函数逼近**将学习问题视为在 $\mathbb{R}^{p+1}$ 空间中拟合曲面。线性基展开 $f_{\theta}(x) = \sum_k h_k(x) \theta_k$ 是连接线性模型与神经网络等复杂模型的桥梁;

- (5) **LS 是 ERM，不是直接最小化 EPE。** $RSS(\theta) = \sum (y_i - f_\theta(x_i))^2$ 是训练集上的经验平均， $N \rightarrow \infty$ 时收敛到真实的 EPE。MLE 在正态误差下与 LS 等价，在分类问题中与交叉熵等价——**MLE 是比 LS 更统一的参数估计框架**；
- (6) **无约束最小化 RSS 必然失败。**任何穿过所有训练点的函数都满足 $RSS = 0$ ，但这样的函数有无穷多个且全无泛化能力。**必须限制候选函数的范围**——这是所有正则化方法的根本动机；
- (7) **三类经典的限制方法：**
- **粗糙惩罚** ($RSS + \lambda J(f)$)：惩罚函数的曲率， λ 控制光滑度，等价于贝叶斯框架中的先验分布；
 - **核方法与局部回归**：用邻域内的加权平均做预测，带宽/邻居数控制局部范围；
 - **基展开与字典方法**：将 f 限制在一组基函数张成的空间中，神经网络将固定基推广为自适应基（基函数本身也由数据学习）。
- (8) **偏差-方差权衡是模型选择的核心。** $EPE = \text{Bias}^2 + \text{Var} + \sigma^2$ 。简单模型高偏差低方差（欠拟合），复杂模型低偏差高方差（过拟合）。复杂度参数 (λ, k, M) 正是控制这一权衡的旋钮，最优值通过交叉验证等方法选取；
- (9) **泛化能力是终极目标。**训练误差随模型复杂度单调递减，不能用于模型选择。测试误差呈 U 形曲线——统计学习的核心挑战是在偏差和方差之间找到最优平衡点。

第十一章 线性回归模型与最小二乘法

11.1 引言：为什么从线性模型开始

线性回归是统计学习中最基础、最经典的监督学习方法。尽管看起来简单，但它具备几个重要优势：

- **简单性与可解释性：**模型参数直接对应每个特征对输出的线性贡献，易于理解和沟通；
- **低信噪比与小样本场景：**当数据量小或信噪比低时，简单线性模型往往比复杂模型表现更好（偏差-方差权衡）；
- **稀疏数据：**在高维稀疏设定下，带正则化的线性模型（如 Lasso）仍是 SOTA 方法之一；
- **基展开的基石：**通过基函数变换，线性模型可以扩展到非线性关系——样条、核方法、神经网络（最后一层）本质上都是线性模型的推广。

线性回归模型的核心假设是：回归函数 $\mathbb{E}[Y \mid X]$ 是输入 $X_1, \dots, X_p$ 的线性函数。尽管这个假设几乎从来不是精确成立的，但由于上述原因，它仍然是一个非常实用的出发点。

11.2 线性回归模型

11.2.1 模型形式

定义 11.1 (线性回归模型). 给定输入向量 $X = (X_1, X_2, \dots, X_p)^\top \in \mathbb{R}^p$ ，线性回归模型将输出 $Y \in \mathbb{R}$ 建模为输入的线性组合：

$$f(X) = \beta_0 + \sum_{j=1}^p X_j \beta_j. \quad (11.1)$$

其中 β_0 为截距项 (intercept), β_j ($j = 1, \dots, p$) 为系数 (coefficients) 或权重 (weights)。

11.2.2 输入的来源

线性模型中的 X_j 可以有多种来源，不限于原始测量值：

- (1) **定量输入 (Quantitative inputs)**: 原始连续变量，如温度、年龄、收入；
- (2) **定量输入的变换 (Transformations)**: 如 $\log X$ 、 $\sqrt{X}$ 、 X^2 等，用于捕捉非线性效应；
- (3) **基展开 (Basis expansions)**: 如 $X_2 = X_1^2$ 、 $X_3 = X_1^3$ ，将输入映射到一组基函数上，产生多项式回归；
- (4) **哑变量编码 (Dummy coding)**: 将定性（类别）变量转化为 0/1 指示变量。例如，有 K 个水平的类别变量需要 $K - 1$ 个哑变量（或 K 个哑变量但去掉截距）；
- (5) **交互项 (Interactions)**: 如 $X_3 = X_1 \cdot X_2$ ，用于捕捉变量之间的交互效应。

核心思想: 无论 X_j 是如何构造的，模型关于参数 β_j 始终是线性的。这意味着 $f(X)$ 是 β 的线性函数，尽管它可以是 X 的非线性函数。例如， $f(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_1^2 + \beta_3 X_1 X_2$ 对 X 是非线性的，但对 β 仍是线性的。

11.2.3 矩阵记号

为简洁起见，通常用矩阵记号表示。设训练数据为 $\{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ ，其中 $x_i = (x_{i1}, x_{i2}, \dots, x_{ip})^\top$ 为第 i 个样本的特征向量。

将截距项纳入设计矩阵：

$$\mathbf{X}_{N \times (p+1)} = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{N1} & x_{N2} & \cdots & x_{Np} \end{pmatrix}, \quad \boldsymbol{\beta}_{(p+1) \times 1} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}, \quad \mathbf{y}_{N \times 1} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix}. \quad (11.2)$$

则线性模型写为：

$$\hat{\mathbf{y}} = \mathbf{X}\boldsymbol{\beta}. \quad (11.3)$$

其中 $\hat{y}_i = f(x_i) = \beta_0 + \sum_{j=1}^p x_{ij}\beta_j$ 为第 i 个样本的预测值。

11.3 最小二乘估计

11.3.1 残差平方和

定义 11.2 (残差平方和 (Residual Sum of Squares, RSS)). 给定训练数据, 参数 β 的残差平方和定义为:

$$\text{RSS}(\beta) = \sum_{i=1}^N (y_i - f(x_i))^2 = \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2. \quad (11.4)$$

定义 11.3 (最小二乘估计 (Least Squares Estimator)). 最小二乘法选择使 RSS 最小的参数:

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^{p+1}} \text{RSS}(\beta). \quad (11.5)$$

从 ERM 角度看: 平方损失 $L(y, f(x)) = (y - f(x))^2$ 下的 ERM 正是最小二乘法。因此, LS 是平方损失下的经验风险最小化器。

11.3.2 矩阵形式的解

用矩阵记号, RSS 可写为:

$$\text{RSS}(\beta) = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta) = \|\mathbf{y} - \mathbf{X}\beta\|^2. \quad (11.6)$$

对 β 求导并令其为零, 即可得到最小化 RSS 的 $\hat{\beta}$ 。下面给出两种完整的求导方式——矩阵微积分形式和 Einstein 求和形式——并逐行标注每一步的依据。

方式一: 矩阵微积分求导

Step 1 — 展开 RSS.

$$\begin{aligned} \text{RSS}(\beta) &= (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta) \\ &= \mathbf{y}^\top \mathbf{y} - \mathbf{y}^\top \mathbf{X}\beta - \beta^\top \mathbf{X}^\top \mathbf{y} + \beta^\top \mathbf{X}^\top \mathbf{X}\beta. \end{aligned} \quad (11.7)$$

注: $(\mathbf{X}\beta)^\top \mathbf{y} = \beta^\top \mathbf{X}^\top \mathbf{y}$ 是一个标量, 标量的转置等于自身, 故 $\mathbf{y}^\top \mathbf{X}\beta = \beta^\top \mathbf{X}^\top \mathbf{y}$, 两项合并为 $2\beta^\top \mathbf{X}^\top \mathbf{y}$:

$$\text{RSS}(\beta) = \mathbf{y}^\top \mathbf{y} - 2\beta^\top \mathbf{X}^\top \mathbf{y} + \beta^\top \mathbf{X}^\top \mathbf{X}\beta. \quad (11.8)$$

Step 2 — 逐项对 β 求导.

需要对向量 $\beta \in \mathbb{R}^{p+1}$ 对标量函数 $f(\beta)$ 求梯度:

$$\frac{\partial f}{\partial \beta} = \left(\frac{\partial f}{\partial \beta_0}, \frac{\partial f}{\partial \beta_1}, \dots, \frac{\partial f}{\partial \beta_p} \right)^\top \in \mathbb{R}^{p+1}.$$

结果是一个列向量 (分母布局 / denominator layout)。

第一项: $\mathbf{y}^\top \mathbf{y}$

$\mathbf{y}^\top \mathbf{y} = \sum_{i=1}^N y_i^2$ 是常数, 不含 β :

$$\frac{\partial}{\partial \beta} (\mathbf{y}^\top \mathbf{y}) = \mathbf{0}.$$

依据: 常数的导数为零。

第二项: $-2\beta^\top \mathbf{X}^\top \mathbf{y}$

令 $\mathbf{a} = \mathbf{X}^\top \mathbf{y} \in \mathbb{R}^{p+1}$ (常向量), 则 $-2\beta^\top \mathbf{a} = -2 \sum_{j=0}^p \beta_j a_j$ 。

对每个分量 β_j :

$$\frac{\partial}{\partial \beta_j} (-2 \sum_k \beta_k a_k) = -2a_j.$$

因此:

$$\frac{\partial}{\partial \beta} (-2\beta^\top \mathbf{X}^\top \mathbf{y}) = -2\mathbf{X}^\top \mathbf{y}.$$

依据: $\frac{\partial}{\partial \mathbf{x}} (\mathbf{x}^\top \mathbf{a}) = \frac{\partial}{\partial \mathbf{x}} (\mathbf{a}^\top \mathbf{x}) = \mathbf{a}$ (分母布局)。

第三项: $\beta^\top \mathbf{X}^\top \mathbf{X} \beta$

令 $\mathbf{A} = \mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{(p+1) \times (p+1)}$, 则此项为二次型 $\beta^\top \mathbf{A} \beta$ 。

展开:

$$\beta^\top \mathbf{A} \beta = \sum_{j=0}^p \sum_{k=0}^p \beta_j A_{jk} \beta_k.$$

对分量 β_m 求偏导:

$$\begin{aligned} \frac{\partial}{\partial \beta_m} (\beta^\top \mathbf{A} \beta) &= \frac{\partial}{\partial \beta_m} \sum_j \sum_k \beta_j A_{jk} \beta_k \\ &= \sum_j \sum_k \frac{\partial}{\partial \beta_m} (\beta_j A_{jk} \beta_k) \\ &= \sum_j \sum_k (\delta_{jm} A_{jk} \beta_k + \beta_j A_{jk} \delta_{km}) \\ &= \sum_k A_{mk} \beta_k + \sum_j \beta_j A_{jm} \\ &= (\mathbf{A} \beta)_m + (\mathbf{A}^\top \beta)_m. \end{aligned} \tag{11.9}$$

由于 $\mathbf{A} = \mathbf{X}^\top \mathbf{X}$ 是对称矩阵 ($\mathbf{A}^\top = \mathbf{A}$), 故:

$$\frac{\partial}{\partial \beta} (\beta^\top \mathbf{X}^\top \mathbf{X} \beta) = 2\mathbf{X}^\top \mathbf{X} \beta.$$

依据: $\frac{\partial}{\partial \mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$ (分母布局), 若 $\mathbf{A}$ 对称则为 $2\mathbf{A} \mathbf{x}$ 。

Step 3 — 合并并令其为零。

将三项导数相加：

$$\begin{aligned}\frac{\partial \text{RSS}}{\partial \boldsymbol{\beta}} &= \mathbf{0} - 2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X} \boldsymbol{\beta} \\ &= -2\mathbf{X}^\top (\mathbf{y} - \mathbf{X} \boldsymbol{\beta}) = \mathbf{0}.\end{aligned}\quad (11.10)$$

Step 4 — 正规方程及其解.

令导数为零，得到正规方程 (normal equations)：

$$\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}.\quad (11.11)$$

若 $\mathbf{X}^\top \mathbf{X}$ 可逆，则：

$$\boxed{\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}}.\quad (11.12)$$

方式二：Einstein 求和约定 (Einstein Summation)

Einstein 求和约定：当一个指标在同一项中出现两次时，默认对该指标求和，省略 $\sum$ 符号。例如 $a_i b_i \equiv \sum_i a_i b_i$ ， $X_{ij} \beta_j \equiv \sum_j X_{ij} \beta_j$ 。

用 Einstein 记号重写 RSS：

$$\text{RSS}(\boldsymbol{\beta}) = (y_i - X_{ij} \beta_j)(y_i - X_{ik} \beta_k).\quad (11.13)$$

展开（注意指标命名需区分，两个括号用不同的哑指标 j 和 k ）：

$$\begin{aligned}\text{RSS} &= (y_i - X_{ij} \beta_j)(y_i - X_{ik} \beta_k) \\ &= y_i y_i - y_i X_{ik} \beta_k - X_{ij} \beta_j y_i + X_{ij} \beta_j X_{ik} \beta_k \\ &= y_i y_i - 2X_{ij} \beta_j y_i + X_{ij} \beta_j X_{ik} \beta_k.\end{aligned}\quad (11.14)$$

这里约定： i 遍历 $1, \dots, N$ （样本）， j, k 遍历 $0, \dots, p$ （参数，含截距），其中 $X_{i0} \equiv 1$ （截距列）。

对 β_m 求偏导：

$$\begin{aligned}\frac{\partial}{\partial \beta_m}(y_i y_i) &= 0 \quad (\text{常数项}) \\ \frac{\partial}{\partial \beta_m}(-2X_{ij} \beta_j y_i) &= -2X_{ij} \delta_{jm} y_i = -2X_{im} y_i \quad \left(\frac{\partial \beta_j}{\partial \beta_m} = \delta_{jm}\right) \\ \frac{\partial}{\partial \beta_m}(X_{ij} \beta_j X_{ik} \beta_k) &\text{。用乘积法则：}\end{aligned}$$

$$\begin{aligned}\frac{\partial}{\partial \beta_m}(X_{ij} \beta_j X_{ik} \beta_k) &= X_{ij} \delta_{jm} X_{ik} \beta_k + X_{ij} \beta_j X_{ik} \delta_{km} \\ &= X_{im} X_{ik} \beta_k + X_{ij} \beta_j X_{im} \\ &= 2X_{im} X_{ik} \beta_k.\end{aligned}\quad (11.15)$$

（最后一步利用了 j, k 都是哑指标，两项相等。）

合并：

$$\frac{\partial \text{RSS}}{\partial \beta_m} = 0 - 2X_{im}y_i + 2X_{im}X_{ik}\beta_k = 0. \quad (11.16)$$

两边除以 2 并移项：

$$X_{im}X_{ik}\beta_k = X_{im}y_i. \quad (11.17)$$

回到矩阵形式： $X_{im}X_{ik}$ 就是 $(\mathbf{X}^\top \mathbf{X})_{mk}$ ， $X_{im}y_i$ 就是 $(\mathbf{X}^\top \mathbf{y})_m$ 。对每个 m ：

$$(\mathbf{X}^\top \mathbf{X})_{mk} \hat{\beta}_k = (\mathbf{X}^\top \mathbf{y})_m \iff \mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}.$$

这正是正规方程。若 $\mathbf{X}^\top \mathbf{X}$ 可逆，则 $\hat{\beta}_k = (\mathbf{X}^\top \mathbf{X})_{km}^{-1} (\mathbf{X}^\top \mathbf{y})_m$ 。

两种方式的对比

	矩阵微积分	Einstein 求和
表达形式	$\mathbf{X}, \boldsymbol{\beta}, \mathbf{y}$ 整体运算	X_{ij}, β_j, y_i 分量运算
RSS	$(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$	$(y_i - X_{ij}\beta_j)(y_i - X_{ik}\beta_k)$
求导法则	$\frac{\partial}{\partial \mathbf{x}}(\mathbf{x}^\top \mathbf{a}) = \mathbf{a}, \quad \frac{\partial}{\partial \mathbf{x}}(\mathbf{x}^\top \mathbf{A}\mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top)\mathbf{x}$	$\frac{\partial \beta_j}{\partial \beta_m} = \delta_{jm}$ (Kronecker delta), 乘法法则逐分量计算
优势	简洁紧凑, 适合公式推导和编程实现	每个分量显式可见, 适合手算和初学者理解
正规方程	$\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}$	$X_{im}X_{ik}\hat{\beta}_k = X_{im}y_i$
解的矩阵形式	$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$	$\hat{\beta}_k = (\mathbf{X}^\top \mathbf{X})_{km}^{-1} X_{im}y_i$

一句话总结：矩阵微积分是“整体算”，Einstein 是“分量算”——两者指向同一个正规方程。用哪种取决于场景：编程/论文用矩阵形式，手算/验证用 Einstein 形式。

11.3.3 拟合值与 Hat Matrix

定义 11.4 (拟合值). 将 $\hat{\boldsymbol{\beta}}$ 代入模型，得到训练集上的拟合值：

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}. \quad (11.18)$$

定义 11.5 (Hat Matrix (帽子矩阵)). 定义:

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top, \quad (11.19)$$

则 $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ 。矩阵 $\mathbf{H}$ 将观测向量 $\mathbf{y}$ “投射”为拟合值向量 $\hat{\mathbf{y}}$ ，因此也称为投影矩阵 (projection matrix)。

11.3.4 几何解释

最小二乘拟合有清晰的几何意义:

- $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ 是 $\mathbf{y}$ 在 $\mathbf{X}$ 的列空间 (column space) 上的正交投影;
- 残差向量 $\hat{\boldsymbol{\varepsilon}} = \mathbf{y} - \hat{\mathbf{y}} = (\mathbf{I} - \mathbf{H})\mathbf{y}$ 与 $\mathbf{X}$ 的列空间正交:

$$\mathbf{X}^\top (\mathbf{y} - \hat{\mathbf{y}}) = \mathbf{X}^\top (\mathbf{I} - \mathbf{H})\mathbf{y} = \mathbf{0}. \quad (11.20)$$

- $\mathbf{H}$ 是幂等矩阵 (idempotent): $\mathbf{H}^2 = \mathbf{H}$, 且对称: $\mathbf{H}^\top = \mathbf{H}$;
- $\mathbf{H}$ 的迹等于其秩: $\text{tr}(\mathbf{H}) = p + 1$ (参数个数)。

注记 11.1 ($\mathbf{X}^\top \mathbf{X}$ 不可逆时). 当 $\mathbf{X}$ 的列线性相关 (如 $p > N$ 或存在完全共线性) 时, $\mathbf{X}^\top \mathbf{X}$ 奇异, 正规方程有无穷多解。此时需要通过正则化 (如岭回归) 或伪逆来获得唯一解。

11.4 估计量的抽样性质

为了讨论 $\hat{\boldsymbol{\beta}}$ 的统计性质, 需要对数据的生成机制做出假设。

11.4.1 一阶矩与二阶矩的假设

定义 11.6 (一阶与二阶矩假设). 假设观测值 y_i 满足:

$$\mathbb{E}[Y | X = x_i] = \beta_0 + \sum_{j=1}^p x_{ij}\beta_j, \quad (11.21)$$

$$\text{Var}(Y | X = x_i) = \sigma^2, \quad (11.22)$$

$$\text{Cov}(y_i, y_j) = 0 \quad (i \neq j). \quad (11.23)$$

即: 线性模型正确设定, 误差有常数方差 (同方差性), 且不同观测的误差不相关。

用 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ 理解三个假设

上面三条假设直接写在 y_i 上，但更直观的方式是引入误差项 ε ，把数据生成过程显式写出来，然后看每条假设到底在约束谁。

数据生成模型：

$$\underset{N \times 1}{\mathbf{y}} = \underset{N \times (p+1)}{\mathbf{X}} \underset{(p+1) \times 1}{\boldsymbol{\beta}} + \underset{N \times 1}{\boldsymbol{\varepsilon}}. \quad (11.24)$$

即对每个观测 $i = 1, \dots, N$ ：

$$y_i = \underbrace{\beta_0 + \sum_{j=1}^p x_{ij}\beta_j}_{\text{信号 (系统部分)}} + \underbrace{\varepsilon_i}_{\text{噪声 (随机部分)}}.$$

涉及四个量，各自的性质：

量	符号	维度	是随机的吗？
设计矩阵	$\mathbf{X}$	$N \times (p+1)$	$\times$ 固定（固定设计下， x_{ij} 是已知常数）
真实参数	$\boldsymbol{\beta}$	$(p+1) \times 1$	$\times$ 固定（未知但不变的常数，是我们要估计的目标）
误差项	$\boldsymbol{\varepsilon}$	$N \times 1$	$\checkmark$ 随机（不可观测的噪声，所有随机性的 唯一来源 ）
响应变量	$\mathbf{y}$	$N \times 1$	$\checkmark$ 随机（ $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ ，随 $\boldsymbol{\varepsilon}$ 而变）

核心认知：在固定设计下， $\mathbf{X}$ 和 $\boldsymbol{\beta}$ 都不是随机变量——数据中唯一在变的东西是噪声 $\boldsymbol{\varepsilon}$ 。 $\mathbf{y}$ 之所以是随机的，完全因为 $\boldsymbol{\varepsilon}$ 是随机的。因此，对 $\mathbf{y}$ 的三条假设本质上就是对 $\boldsymbol{\varepsilon}$ 的三条约束。

逐条翻译：

假设 1：线性均值假设 $\mathbb{E}[Y | X = x_i] = \beta_0 + \sum_{j=1}^p x_{ij}\beta_j$

- 代入 $y_i = x_i^\top \boldsymbol{\beta} + \varepsilon_i$ ：

$$\mathbb{E}[x_i^\top \boldsymbol{\beta} + \varepsilon_i | X = x_i] = x_i^\top \boldsymbol{\beta} + \mathbb{E}[\varepsilon_i | X = x_i] = x_i^\top \boldsymbol{\beta}.$$

- 因此等价于：

$$\boxed{\mathbb{E}[\varepsilon_i | X = x_i] = 0}.$$

- 含义：**噪声 ε_i 的条件期望为零。给定 x_i 后，误差没有系统性偏差——信号 $x_i^\top \boldsymbol{\beta}$ 已经捕获了 y_i 的全部系统变化，剩下的只是均值为零的随机扰动。

- **如果违反：** $\mathbb{E}[\varepsilon_i | X] \neq 0$ 意味着模型遗漏了与 X 相关的系统成分（如漏掉了重要的 X_{p+1} ，或真实关系是非线性的），此时 $\hat{\beta}$ 不再收敛到任何有意义的量。

假设 2：同方差假设 $\text{Var}(Y | X = x_i) = \sigma^2$

- 代入 $y_i = x_i^\top \beta + \varepsilon_i$ ：

$$\text{Var}(y_i | X = x_i) = \text{Var}(x_i^\top \beta + \varepsilon_i | X = x_i) = \text{Var}(\varepsilon_i | X = x_i).$$

($x_i^\top \beta$ 是常数，不影响方差。)

- 因此等价于：

$$\boxed{\text{Var}(\varepsilon_i | X = x_i) = \sigma^2, \quad \text{对所有 } i}.$$

- **含义：** 噪声的波动幅度是常数 σ^2 ，不随 x_i 变化。无论 x_i 取什么值， y_i 在回归线周围的散布程度都一样。
- **如果违反（异方差）：** 比如 x_i 大时 y_i 波动也大（金融数据中常见），LS 仍然无偏，但不再是最优的——加权最小二乘（WLS）会更好。异方差下 $\hat{\beta}$ 的标准误公式也会失效。

假设 3：不相关假设 $\text{Cov}(y_i, y_j) = 0 \ (i \neq j)$

- 代入 $y_i = x_i^\top \beta + \varepsilon_i$ ：

$$\text{Cov}(y_i, y_j | \mathbf{X}) = \text{Cov}(x_i^\top \beta + \varepsilon_i, x_j^\top \beta + \varepsilon_j | \mathbf{X}) = \text{Cov}(\varepsilon_i, \varepsilon_j | \mathbf{X}).$$

- 因此等价于：

$$\boxed{\text{Cov}(\varepsilon_i, \varepsilon_j | \mathbf{X}) = 0, \quad i \neq j}.$$

- **含义：** 不同观测的噪声互不相关。知道 ε_1 不能提供任何关于 ε_2 的信息。
- **如果违反（自相关）：** 常见于时间序列数据（今天的误差与昨天的相关）、空间数据（邻近点的误差相关）、重复测量数据（同一个体的多次测量）。此时 LS 仍然无偏，但方差公式 $(\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2$ 不再正确，需要用稳健标准误（sandwich estimator）或广义最小二乘（GLS）。

三条约束的矩阵统一形式：

三条合在一起，可以简洁地写成 ε 的一阶矩和二阶矩条件：

$$\boxed{\mathbb{E}[\varepsilon | \mathbf{X}] = \mathbf{0}, \quad \text{Var}(\varepsilon | \mathbf{X}) = \sigma^2 \mathbf{I}_N}. \quad (11.25)$$

等价地：

$$\mathbb{E}[\mathbf{y} | \mathbf{X}] = \mathbf{X}\beta, \quad \text{Var}(\mathbf{y} | \mathbf{X}) = \sigma^2 \mathbf{I}_N.$$

为什么只假设一阶矩和二阶矩？（不要求正态性）

注意：上述三条约束只涉及期望和方差，没有要求 ε_i 服从正态分布。这意味着：

- $\hat{\beta}$ 的无偏性 ($\mathbb{E}[\hat{\beta}] = \beta$) 和方差公式 ($\text{Var}(\hat{\beta}) = (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2$) 只依赖一阶和二阶矩, 不依赖正态性;
- 高斯-马尔可夫定理同样只要求一阶 + 二阶矩假设, 就能保证 LS 是 BLUE;
- 正态假设是额外加上去的——只有当你需要做精确的 t 检验、 F 检验、置信区间时, 才需要假设 $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ 。

这就是为什么 ESL 将“一阶/二阶矩假设”和“正态假设”分成两节来写——前者保证估计量的质量, 后者保证推断的有效性, 约束强度递增。

定理 11.1 ($\hat{\beta}$ 的均值和方差). 在假设 (11.21)–(11.23) 下:

$$\mathbb{E}[\hat{\beta} | \mathbf{X}] = \beta, \quad (11.26)$$

$$\text{Var}(\hat{\beta} | \mathbf{X}) = (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2. \quad (11.27)$$

简要推导. 由 $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 及 $\mathbb{E}[\mathbf{y} | \mathbf{X}] = \mathbf{X}\beta$:

$$\mathbb{E}[\hat{\beta} | \mathbf{X}] = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbb{E}[\mathbf{y} | \mathbf{X}] = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X} \beta = \beta.$$

由 $\text{Var}(\mathbf{y} | \mathbf{X}) = \sigma^2 \mathbf{I}$:

$$\text{Var}(\hat{\beta} | \mathbf{X}) = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \text{Var}(\mathbf{y} | \mathbf{X}) \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\sigma^2 \mathbf{I}) \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} = (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2.$$

□

11.4.2 三层限制：从模型选择到无偏性的逻辑链

初学者往往会困惑: $\mathbb{E}[\hat{\beta} | \mathbf{X}] = \beta$ 到底是什么意思? $\mathbf{X}$ 不就是手上这份数据吗, 哪来的“期望”? 下面用三层递进来回答这个问题。

第一层：我们对 f 施加了什么限制?

从统计学习的一般框架出发, 我们希望找到 $f(X) \approx \mathbb{E}[Y | X]$ 。但 $\mathbb{E}[Y | X]$ 可以是任意函数, 直接从数据中搜索“所有可能函数”是不可能的。因此, 我们主动施加了**两重限制**:

限制	选择	后果
函数族 $\mathcal{F}$	$f(X) = \beta_0 + \sum_{j=1}^p X_j \beta_j$ (线性)	将搜索空间从“所有函数”压缩到 $\mathbb{R}^{p+1}$ ERM 退化为 $\min_{\beta} \text{RSS}(\beta)$
损失函数 L	$L(y, f(x)) = (y - f(x))^2$ (平方损失)	

两者叠加就唯一确定了估计方法：

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^N (y_i - \mathbf{x}_i^{\top} \beta)^2 = (\mathbf{X}^{\top} \mathbf{X})^{-1} \mathbf{X}^{\top} \mathbf{y}.$$

关键认知： $\hat{\beta}$ 不是一个“发现”——它是在选定线性模型 + 平方损失之后的必然结果。换一种损失（如绝对损失）或换一种函数族（如加样条），得到的就是另一种估计量。

第二层：在这个限制下， $\hat{\beta}$ 是不是“好”的？

选定了估计方法之后，我们需要评估它的质量。评估需要一个标尺：如果数据真的是从线性模型生成的，我们的 $\hat{\beta}$ 能恢复到真实的 β 吗？

这就是 $\mathbb{E}[\hat{\beta} | \mathbf{X}] = \beta$ 的含义：在模型正确设定的前提下，LS 估计量是无偏的。

更进一步，高斯-马尔可夫定理告诉我们：在所有线性无偏估计量中，LS 的方差最小（BLUE）。所以在“线性 + 无偏”这个约束类里，LS 确实是最好的。

但注意前提条件：

- 线性模型必须正确设定： $\mathbb{E}[Y | X] = X\beta$ ；
- 误差必须同方差且不相干： $\text{Var}(\mathbf{y} | \mathbf{X}) = \sigma^2 \mathbf{I}$ 。

如果真实回归函数不是线性的， $\mathbb{E}[\hat{\beta} | \mathbf{X}]$ 根本不等於任何有意义的量—— $\hat{\beta}$ 只是“最优线性近似”的系数，不是“真实参数”的估计。

第三层： $\mathbf{X}$ 固定时，期望到底是对什么取的？

这是最容易混淆的核心问题。手上只有一份数据集 $\{\mathbf{X}, \mathbf{y}\}$ ， $\mathbf{X}$ 是 concrete 的数字矩阵， $\mathbf{y}$ 是 concrete 的数字向量。哪里来的“随机性”？哪里来的“期望”？

答案：随机性来自 $\mathbf{y}$ ，而 $\mathbf{y}$ 的随机性来自误差 ϵ 。

在固定设计 (fixed design) 设定下， $\mathbf{X}$ 被视为已知常数矩阵（非随机）。数据的生成过程是：

$$\underbrace{\mathbf{y}}_{N \times 1} = \underbrace{\mathbf{X}}_{N \times (p+1), \text{ 固定}} \underbrace{\beta}_{(p+1) \times 1, \text{ 未知常数}} + \underbrace{\epsilon}_{N \times 1, \text{ 随机}}.$$

$\mathbf{X}$ 和 β 都是固定的——变的是 ϵ ，从而变的是 $\mathbf{y}$ 。

用重复抽样来理解 $\mathbb{E}[\hat{\beta} | \mathbf{X}]$ ：

想象我们能让时间倒流，重复以下实验 M 次 ($M \rightarrow \infty$):

第 1 次 保持 $\mathbf{X}$ 完全不变 (同样的 N 个样本点, 同样的特征值);

第 2 次 从 $\mathcal{N}(0, \sigma^2)$ 中重新抽取 N 个独立的误差 $\varepsilon_1^{(m)}, \dots, \varepsilon_N^{(m)}$;

第 3 次 生成新的响应 $\mathbf{y}^{(m)} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}^{(m)}$;

第 4 次 在 $(\mathbf{X}, \mathbf{y}^{(m)})$ 上做 LS, 得到 $\hat{\boldsymbol{\beta}}^{(m)} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}^{(m)}$ 。

那么:

$$\mathbb{E}[\hat{\boldsymbol{\beta}} | \mathbf{X}] = \lim_{M \rightarrow \infty} \frac{1}{M} \sum_{m=1}^M \hat{\boldsymbol{\beta}}^{(m)} = \boldsymbol{\beta}.$$

直观总结:

量	是随机的吗?	说明
$\mathbf{X}$	× 固定	设计矩阵, 已知常数
$\boldsymbol{\beta}$	× 固定	真实参数, 未知但不变
$\boldsymbol{\varepsilon}$	✓ 随机	不可观测的噪声
$\mathbf{y}$	✓ 随机	$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$, 随 $\boldsymbol{\varepsilon}$ 而变
$\hat{\boldsymbol{\beta}}$	✓ 随机	$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$, 是 $\mathbf{y}$ 的函数

一句话: $\mathbb{E}[\hat{\boldsymbol{\beta}} | \mathbf{X}]$ 的期望不是“对不同数据集取平均”, 而是对同一个 $\mathbf{X}$ 下的不同噪声实现取平均。 $\mathbf{X}$ 固定, $\boldsymbol{\varepsilon}$ 在变。

注记 11.2 (固定设计 vs 随机设计). 本书 (ESL) 主要采用固定设计视角, 因为:

- 它让分析更简洁 (不需要对 X 的分布建模);
- 条件推断 (给定观测到的 X 做推断) 在实际中最常用;
- 大多数结果在随机设计下也成立 (只需对 X 取额外期望)。

随机设计视角下, X 也是随机的 (从某个分布 $P(X)$ 中抽取), 此时 $\mathbb{E}[\hat{\boldsymbol{\beta}}] = \mathbb{E}_X [\mathbb{E}[\hat{\boldsymbol{\beta}} | \mathbf{X}]] = \boldsymbol{\beta}$, 无偏性仍然成立, 但方差需要额外考虑 X 的随机性。

11.4.3 深入理解: 固定设计与随机设计

上一节的 remark 提到了两种设计视角, 下面展开讨论。这是理解回归分析中“随机性从哪来”的关键。

固定设计 (Fixed Design)

定义： $\mathbf{X}$ 被视为非随机的已知常数。数据对 (x_i, y_i) 中，只有 y_i 是随机变量（因为 $y_i = f(x_i) + \varepsilon_i$ ， ε_i 是随机的）。

典型场景：控制实验 (controlled experiment)

- 你想研究不同施肥量对作物产量的影响 → 你主动设定 $x_1 = 10, x_2 = 20, x_3 = 30$ (kg/亩)；
- 你想研究温度对化学反应速率的影响 → 你把恒温箱分别设为 $20^\circ, 30^\circ, 40^\circ$ ；
- 药厂做剂量试验 → 医生给患者分配固定剂量：0, 50, 100, 200 mg。

共同特征：实验者控制了 X 的取值。 X 不是从自然界随机观测来的，而是被设计出来的。此时把 X 当常数处理完全合理。

数学上：

- 所有期望和方差都是条件于 $\mathbf{X}$ 的： $\mathbb{E}[\cdot | \mathbf{X}]$, $\text{Var}(\cdot | \mathbf{X})$ ；
- $\mathbf{X}^\top \mathbf{X}$ 是常数矩阵（不是随机矩阵的期望）；
- $\hat{\beta}$ 的随机性完全来自 ε （从而来自 $\mathbf{y}$ ）。

随机设计 (Random Design)

定义： X 和 Y 都是从某个联合分布 $P(X, Y)$ 中随机抽取的。每个数据对 (x_i, y_i) 都是 i.i.d. 的联合观测。

典型场景：观测研究 (observational study) 和机器学习

- 你想预测房价 → 从市场上随机收集 N 套房的面积、地段、房龄和成交价；
- 你想做信用评分 → 从银行数据库中随机抽取客户的收入、负债、历史违约记录；
- 任何“你无法控制 X ，只能被动观测”的场景。

共同特征：你没有控制 X —— X 本身就是随机的。下次再抽一组数据， X 的值也会改变。

数学上：

- $\mathbf{X}$ 本身也是随机矩阵；
- 无条件的期望需要通过迭代期望来求： $\mathbb{E}[\hat{\beta}] = \mathbb{E}_X[\mathbb{E}[\hat{\beta} | \mathbf{X}]]$ ；
- $\mathbf{X}^\top \mathbf{X}$ 是随机的——不同数据集会给出不同的 $(\mathbf{X}^\top \mathbf{X})^{-1}$ ；
- 方差需要额外考虑 $\mathbf{X}$ 的随机性带来的波动。

两者关系：条件推断作为桥梁

实践中，无论数据是怎么来的，统计推断几乎总是条件于观测到的 $\mathbf{X}$ 进行的。原因很简单：你的报告写的是“给定这些数据， β_1 的 95% 置信区间是 $[0.3, 0.8]$ ”，而不是“如果我们从 $P(X)$ 中反复抽样，平均而言置信区间覆盖真值的概率是 95%”。

关键事实：随机设计下的绝大多数结论，只需先对 $\mathbf{X}$ 取条件，就可直接套用固定设计的结论。因为：

$$\begin{cases} \mathbb{E}[\hat{\beta} | \mathbf{X}] = \beta & (\text{固定设计无偏}) \\ \mathbb{E}[\hat{\beta}] = \mathbb{E}_X[\mathbb{E}[\hat{\beta} | \mathbf{X}]] = \mathbb{E}_X[\beta] = \beta & (\text{随机设计无偏}) \end{cases}$$

只要模型在条件意义下正确 ($\mathbb{E}[Y | X] = X\beta$)，无偏性对两种设计都成立。

三种视角的对比

	固定设计 (Fixed)	随机设计 (Random)	条件推断 (Conditional)
X 的性质	已知常数，由实验者设定	随机变量，从 $P(X)$ 中抽取	不管来源，条件于观测值
典型场景	控制实验、A/B 测试	观测研究、ML 预测建模	写统计报告、做置信区间
随机性来源	仅 ε (从而仅 $\mathbf{y}$)	ε 和 $\mathbf{X}$	仅 ε ($\mathbf{X}$ 已观测到)
期望记号	$\mathbb{E}[\cdot \mathbf{X}]$	$\mathbb{E}[\cdot]$	$\mathbb{E}[\cdot \mathbf{X}]$
$X^\top X$	常数矩阵	随机矩阵	常数矩阵 (已观测)
推断性质	精确 (t/F 检验在正态下精确)	渐近 (大样本近似)	精确 (条件于 $\mathbf{X}$)
预测	内插 (interpolation) 较安全	外推 (extrapolation) 有风险	取决于 X 的覆盖范围

ESL 的选择：为什么偏好固定设计视角？

全书 (Elements of Statistical Learning) 几乎都在固定设计 (条件于 $\mathbf{X}$) 框架下讨论，原因有三：

- (1) **数学更简洁。**不需要对 $P(X)$ 建模，不需要 X 的分布假设，避免了“ X 也是随机的所以 $\mathbf{X}^\top \mathbf{X}$ 的逆也有分布”这类复杂问题；
- (2) **更贴近实际推断。**在实际问题中，你拿到的是一份具体的数据集，你要基于这份数据给出结论——这正是条件推断做的事；
- (3) **结论可迁移。**固定设计下的结论（如 $\hat{\beta}_j$ 的标准误公式、 t 检验、 F 检验）在随机设计下也渐近成立，只是需要大样本和适当的正则条件。

一句话总结：固定设计说“ X 不变，我们看噪声怎么影响估计”——这是**分析的工具**；随机设计说“ X 也在变，下次采的数据不一样”——这是**真实的场景**；条件推断说“不管 X 怎么来的，我就基于手上这份 X 做推断”——这是**实践的方法**。三者不矛盾，是同一问题的三个层次。

11.4.4 条件推断：实践中你真正在做的事

前面提到条件推断是“实践的方法”。这一节专门展开：条件推断到底是什么？为什么它如此重要？以及你需要知道什么才能正确理解和报告你的结果。

什么是条件推断？

定义 11.7 (条件推断 (Conditional Inference)). 条件推断是指：所有统计推断（置信区间、 p 值、假设检验）都**条件于观测到的 $\mathbf{X}$** 进行。也就是说，你把 $\mathbf{X}$ 当作已知常数，仅考虑给定这份 $\mathbf{X}$ 下， $\mathbf{y}$ （通过 ϵ ）的随机性带来的不确定性。

用数学记号表达：

类型	记号	含义
无条件推断	$\Pr(\text{CI 覆盖 } \beta_j)$	同时考虑 $\mathbf{X}$ 和 $\mathbf{y}$ 的随机性
条件推断	$\Pr(\text{CI 覆盖 } \beta_j \mid \mathbf{X})$	$\mathbf{X}$ 固定，仅考虑 $\mathbf{y}$ 的随机性

实践中，你用的永远是条件推断。当你写下“ β_1 的 95% 置信区间是 $[0.32, 0.78]$ ”时，你没有说“如果重新采样 $\mathbf{X}$ 和 $\mathbf{y}$ ，95% 的区间会覆盖真值”。你说的是：**给定手上这份数据，基于 $\mathbf{y}$ 的随机性，这个区间以 95% 的概率覆盖 β_1 。**

为什么条件推断是默认选择？

有四个根本原因：

- (1) **你只有一份 $\mathbf{X}$ 。**在实际问题中，你不会重复采样新的 $\mathbf{X}$ 。你拿到的就是这一份设计矩阵。对一份永远不会变的 $\mathbf{X}$ 做“平均而言”的推断没有实操意义——你需要的是**给定这份 $\mathbf{X}$ 的结论**。

- (2) **条件推断更精确。**无条件推断把 $\mathbf{X}$ 的变异性也混进了方差估计里，导致置信区间更宽、检验更保守。条件推断把 $\mathbf{X}$ 的变异性剥离出去，只保留 ε 的不确定性，因此给出的区间更紧、检验更灵敏。
- (3) **条件推断与固定设计的公式完全一致。**在固定设计下推导的 $\text{Var}(\hat{\beta} | \mathbf{X}) = (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2$ 和 $t_j \sim t_{N-p-1}$ 直接就是条件推断的结果。你不需要额外学一套新公式。
- (4) **即使 $\mathbf{X}$ 是随机的，条件推断的性质也是逐点成立的。**对于每份具体的 $\mathbf{X}$ ， $\Pr(t_j \in \text{拒绝域} | \mathbf{X}, H_0) = \alpha$ （精确或在渐近意义下）。无条件性质只需对 $\mathbf{X}$ 取期望即可恢复：

$$\Pr(t_j \in \text{拒绝域} | H_0) = \mathbb{E}_{\mathbf{X}}[\Pr(t_j \in \text{拒绝域} | \mathbf{X}, H_0)] = \alpha.$$

条件推断下，置信区间的正确解读

这是最容易出错的地方。考虑 β_1 的 $100(1 - \alpha)\%$ 置信区间：

$$\hat{\beta}_1 \pm t_{N-p-1}^{(1-\alpha/2)} \cdot \text{se}(\hat{\beta}_1).$$

✓ **正确解读（条件推断）：**“给定我们观测到的 $\mathbf{X}$ ，如果我们能无限次地重新抽取 $\mathbf{y}$ （每次用新的 ε ，保持 $\mathbf{X}$ 不变），那么构造出的区间中有 $100(1 - \alpha)\%$ 会覆盖真实的 β_1 。因此，我们手上这个具体的区间有 $100(1 - \alpha)\%$ 的置信度覆盖 β_1 。”

× **错误解读：**“ β_1 有 95% 的概率落在这个具体区间里。”（ β_1 是固定常数，不是随机变量——要么在里面，要么不在。“概率”描述的是区间的构造方法，不是参数的位置。）

× **也错误：**“如果我们重新采样 $\mathbf{X}$ 和 $\mathbf{y}$ ，95% 的区间会覆盖 β_1 。”（这描述的是无条件性质，混合了 $\mathbf{X}$ 的随机性。）

条件推断 vs 无条件推断：什么时候有区别？

大多数情况下，条件推断和无条件推断给出的数值结果是一样的（比如 t 统计量、 p 值的计算），但它们在哲学层面和某些特殊场景下有本质区别。

- (1) **大多数场景——无区别。**在线性回归中， $\text{Var}(\hat{\beta}_j | \mathbf{X}) = v_j \sigma^2$ 仅通过 $v_j = [(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}$ 依赖于 $\mathbf{X}$ 。条件和无条件标准误公式在数值上是一样的（因为 $\mathbf{X}$ 已观测）。
- (2) **预测区间——条件推断更合理。**对新点 x_0 的预测区间，条件于训练集的 $\mathbf{X}$ 和新的 x_0 给出：

$$\hat{y}_0 \pm t_{N-p-1}^{(1-\alpha/2)} \cdot \hat{\sigma} \sqrt{1 + x_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} x_0}.$$

如果做无条件推断，你需要知道未来 x_0 的分布，而这在实际中几乎不可能准确获得。

- (3) **模型选择后的推断——条件推断是必需的。**如果你先用数据做了变量选择（如 Lasso、逐步回归），再对选出的变量做检验，那么 $\mathbf{X}$ 中哪些列被保留本身是随机的（依赖于 $\mathbf{y}$ ）。此时条件推断必须考虑选择过程带来的不确定性——这是**选择性推断 (selective inference)** 的研究范畴，也是近年来统计学的前沿热点。
- (4) **辅助统计量 (Ancillary Statistics)。**如果一个统计量的分布不依赖于未知参数，它被称为辅助统计量。条件推断原则 (Conditionality Principle) 要求：如果存在辅助统计量，应该条件于它做推断。例如， $\mathbf{X}$ 本身（在随机设计下）就是辅助的——它的分布不含 β 。

你需要记住的三个要点

1. **你总是在做条件推断。**无论你是否意识到，当你基于一份具体数据报告置信区间或 p 值时，你已经在条件于 $\mathbf{X}$ 了。这是实践中的唯一合理做法。
2. **条件推断的公式 = 固定设计的公式。**教材中所有在“固定设计”下推导的标准误、 t 分布、 F 分布结论，都可以直接用作条件推断的工具。你无需区分“这份 $\mathbf{X}$ 是固定的还是随机的”——只要条件于它，结论就一样。
3. **不要混淆条件性质和无条件性质。**一个检验可能在条件意义下是水平的 ($\Pr(\text{拒绝} | \mathbf{X}, H_0) = \alpha$)，也在无条件意义下是水平的 ($\Pr(\text{拒绝} | H_0) = \alpha$)。但**条件性质更强**——它保证了你的推断在每一份具体数据上都是可靠的，而不仅仅是“平均而言”可靠。

一句话总结：条件推断就是把 $\mathbf{X}$ 锁死，只在噪声 ϵ 的维度上讨论不确定性。这是统计实践中唯一合理的做法，也是全书所有公式的默认前提。

总结图：从数据生成到推断的完整逻辑链

下图总结了本节从建模假设、估计量性质、设计视角到条件推断的完整逻辑链条：

$$\boxed{\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}} \xrightarrow{\text{三个量}} \begin{cases} \mathbf{X}: \text{已知常数 (固定设计)} \\ \boldsymbol{\beta}: \text{未知常数 (估计目标)} \\ \boldsymbol{\varepsilon}: \text{随机噪声 (唯一随机源)} \end{cases}$$

↓ 对 $\boldsymbol{\varepsilon}$ 的三条约束 (一阶 + 二阶矩)

$$\begin{cases} \mathbb{E}[\boldsymbol{\varepsilon} | \mathbf{X}] = \mathbf{0} & \implies \mathbb{E}[\mathbf{y} | \mathbf{X}] = \mathbf{X}\boldsymbol{\beta} \quad (\text{线性均值}) \\ \text{Var}(\varepsilon_i) = \sigma^2 & \implies \text{同方差 (常数波动幅度)} \\ \text{Cov}(\varepsilon_i, \varepsilon_j) = 0 & \implies \text{观测间不相关} \end{cases}$$

↓ 约束下的最优估计

$$\boxed{\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}} \xrightarrow{\text{性质}} \begin{cases} \mathbb{E}[\hat{\boldsymbol{\beta}} | \mathbf{X}] = \boldsymbol{\beta} & (\text{无偏性}) \\ \text{Var}(\hat{\boldsymbol{\beta}} | \mathbf{X}) = (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2 & (\text{方差公式}) \\ \text{高斯-马尔可夫: LS 是 BLUE} & (\text{不依赖正态性}) \end{cases}$$

↓ 三种设计视角

固定设计	随机设计	条件推断
$\mathbf{X}$ 不变	$\mathbf{X}$ 也是随机的	不管 $\mathbf{X}$ 怎么来的
控制实验	观测研究 / ML	手上这份数据
分析的工具	真实的场景	实践的方法

↓ 实践中: 永远是条件推断

$$\boxed{\text{给定 } \mathbf{X}, \text{ 仅 } \boldsymbol{\varepsilon} \text{ 是随机的}} \xrightarrow{\text{所有公式}} \begin{cases} \text{Var}(\hat{\beta}_j) = v_j \sigma^2 & (\text{标准误}) \\ t_j = \frac{\hat{\beta}_j}{\hat{\sigma} \sqrt{v_j}} \sim t_{N-p-1} & (t \text{ 检验}) \\ \text{CI: } \hat{\beta}_j \pm t \cdot \hat{\sigma} \sqrt{v_j} & (\text{置信区间}) \end{cases}$$

↓ 加上正态假设: $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$

$$\boxed{\hat{\boldsymbol{\beta}} \sim \mathcal{N}(\boldsymbol{\beta}, (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2)} \xrightarrow{\text{推断}} t \text{ 检验} / F \text{ 检验} / \text{精确置信区间}$$

核心教训:

- 一阶 + 二阶矩假设 $\Rightarrow$ 无偏性 + 方差公式 + 高斯-马尔可夫 (不需正态);
- 正态假设 $\Rightarrow t$ 分布 / F 分布 / 精确推断 (额外条件);
- 条件推断 = 锁死 $\mathbf{X}$, 仅对 ε 的随机性做推断——这是实践中的唯一做法;
- $\mathbb{E}[\hat{\beta} | \mathbf{X}]$ 的期望不是对不同的 $\mathbf{X}$ 取平均, 而是对同一个 $\mathbf{X}$ 下的不同噪声实现取平均。

11.4.5 σ^2 的无偏估计

实践中 σ^2 未知, 需要从数据估计。

定义 11.8 (σ^2 的无偏估计量)。

$$\hat{\sigma}^2 = \frac{1}{N-p-1} \sum_{i=1}^N (y_i - \hat{y}_i)^2 = \frac{\text{RSS}(\hat{\beta})}{N-p-1}. \quad (11.28)$$

分母 $N-p-1$ (而非 N) 保证了无偏性: $\mathbb{E}[\hat{\sigma}^2] = \sigma^2$ 。其中 $p+1$ 是被估计的参数个数 (含截距), 因此自由度为 $N-(p+1)$ 。

注记 11.3 (与第 2 章 S^2 的联系). 单样本情形 ($p=0$, 仅截距) 下, $\hat{\beta}_0 = \bar{y}$, 则:

$$\hat{\sigma}^2 = \frac{1}{N-1} \sum_{i=1}^N (y_i - \bar{y})^2 = S^2.$$

这是第 2 章样本方差 S^2 的自然推广。

11.4.6 单个系数的方差

记 v_j 为 $(\mathbf{X}^\top \mathbf{X})^{-1}$ 的第 $(j+1)$ 个对角元 ($j=0, 1, \dots, p$), 则:

$$\text{Var}(\hat{\beta}_j) = v_j \sigma^2. \quad (11.29)$$

用 $\hat{\sigma}^2$ 替代 σ^2 , 得到 $\hat{\beta}_j$ 的估计标准误:

$$\text{se}(\hat{\beta}_j) = \hat{\sigma} \sqrt{v_j}. \quad (11.30)$$

11.5 正态假设下的推断

如需进行置信区间和假设检验, 则需要更强的分布假设。

11.5.1 正态误差假设

定义 11.9 (带正态误差的线性模型). 假设:

$$Y = \beta_0 + \sum_{j=1}^p X_j \beta_j + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2), \quad (11.31)$$

且不同观测的 ε_i 相互独立。

等价地:

$$\mathbf{y} \mid \mathbf{X} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}). \quad (11.32)$$

11.5.2 $\hat{\boldsymbol{\beta}}$ 的抽样分布

定理 11.2 ($\hat{\boldsymbol{\beta}}$ 的正态性). 在正态误差假设下:

$$\boxed{\hat{\boldsymbol{\beta}} \sim \mathcal{N}(\boldsymbol{\beta}, (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2)}. \quad (11.33)$$

证明. $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 是 $\mathbf{y}$ 的线性变换. $\mathbf{y}$ 服从多元正态分布, 其任意线性变换也服从多元正态分布. 均值和方差已在式 (11.26) 和 (11.27) 中给出. $\square$

11.5.3 单个系数的检验: t 检验到底在检验什么?

核心问题: 你拟合了一个线性模型, 得到了 $\hat{\beta}_j$. 但 $\hat{\beta}_j$ 永远不精确为零——即使 X_j 和 Y 完全无关, 抽样噪声也会让 $\hat{\beta}_j$ 偏离零. t 检验要回答的是: 观测到的 $\hat{\beta}_j$ 离零有多远, 这个距离是否大到不能用“随机噪声”来解释?

原假设与备择假设

定义 11.10 (t 检验的假设). 对于单个系数 β_j ($j = 0, 1, \dots, p$):

$$\boxed{H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0}.$$

用大白话说:

- H_0 (原假设 / 零假设): $\beta_j = 0$, 即 X_j 对 Y 没有线性贡献. 在模型中, X_j 这个变量是“多余”的——去掉它, 模型预测能力不会系统性地变差;
- H_1 (备择假设): $\beta_j \neq 0$, 即 X_j 对 Y 有线性贡献. X_j 提供了关于 Y 的信息, 保留它能改善预测。

注记 11.4 (为什么总是检验 $\beta_j = 0$?). 你可能想问: 为什么标准检验的目标是 $\beta_j = 0$, 而不是 $\beta_j = 0.5$ 或其他值?

答案： $\beta_j = 0$ 对应一个自然的基准问题——“这个变量有没有用？”这是模型选择的第一步：先筛掉显然没用的变量，再考虑更精细的问题。

当然，你也可以检验 $H_0 : \beta_j = c$ (c 为任意常数)，只需将 t 统计量改为 $t_j = (\hat{\beta}_j - c)/\text{se}(\hat{\beta}_j)$ 。例如，检验“ X_j 每增加 1 单位， Y 是否恰好增加 2”： $H_0 : \beta_j = 2$ 。但 $\beta_j = 0$ 是最常见、最基础的检验。

检验的逻辑结构

整个 t 检验遵循假设检验的经典四步逻辑：

第 1 步：假定 H_0 为真。

我们暂时假设 X_j 真的没用 ($\beta_j = 0$)。在这个假设下， $\hat{\beta}_j$ 应该怎样分布？

在 H_0 和正态误差下：

$$\hat{\beta}_j \sim \mathcal{N}(0, v_j \sigma^2).$$

即 $\hat{\beta}_j$ 以 0 为中心、方差为 $v_j \sigma^2$ 的正态分布。这意味着：即使 β_j 真的是 0，由于抽样噪声， $\hat{\beta}_j$ 也不会恰好为 0——它会围绕 0 随机波动。

第 2 步：构造检验统计量，衡量观测值与 H_0 的偏离程度。

定义 11.11 (t 统计量).

$$t_j = \frac{\hat{\beta}_j}{\text{se}(\hat{\beta}_j)} = \frac{\hat{\beta}_j}{\hat{\sigma} \sqrt{v_j}} \sim t_{N-p-1}. \quad (11.34)$$

t_j 衡量的是： $\hat{\beta}_j$ 离零有多少个标准误。

- $|t_j|$ 很大 $\rightarrow \hat{\beta}_j$ 离零很远（相对于噪声水平） $\rightarrow$ 不太可能是噪声造成的；
- $|t_j|$ 很小 $\rightarrow \hat{\beta}_j$ 离零很近 $\rightarrow$ 很可能只是随机波动。

第 3 步：计算 p 值：在 H_0 为真的前提下，看到这么极端的结果有多不寻常？

定义 11.12 (p 值).

$$p\text{-value} = \Pr(|T| \geq |t_j^{\text{obs}}| \mid H_0 \text{ 为真}), \quad (11.35)$$

其中 $T \sim t_{N-p-1}$ ， t_j^{obs} 是从数据中算出的实际 t 值。

p 值大小	含义	通俗解释
$p < 0.001$	极端罕见	“如果 X_j 真的没用，这种结果几乎不可能出现”
$p \approx 0.01$	很罕见	“只有 1% 的概率是噪声搞出来的”
$p \approx 0.05$	边缘显著	“勉强强强，可能是真信号也可能是噪声”
$p \approx 0.3$	很常见	“即使 X_j 没用，这种结果也经常出现——不稀奇”

第 4 步：做出决策。

设定显著性水平 α (通常 $\alpha = 0.05$):

- 若 $p < \alpha$: 拒绝 H_0 。有足够的证据认为 $\beta_j \neq 0$, X_j 对 Y 有显著贡献;
- 若 $p \geq \alpha$: 不拒绝 H_0 。数据没有提供足够证据说明 X_j 有用——但这不等于证明了 X_j 没用!

等价形式：用 t 值与临界值比较

除了看 p 值, 也可以直接将 $|t_j|$ 与 t 分布的临界值比较:

$$|t_j| > t_{N-p-1}^{(1-\alpha/2)} \iff p < \alpha.$$

两种方式是等价的——只是表达习惯不同。软件输出通常同时给出 t 值和 p 值。

 t 检验与置信区间的关系

拒绝 $H_0: \beta_j = 0$ (在水平 α 下) 等价于: 0 不在 β_j 的 $100(1 - \alpha)\%$ 置信区间内。
置信区间为:

$$\hat{\beta}_j \pm t_{N-p-1}^{(1-\alpha/2)} \cdot \text{se}(\hat{\beta}_j). \quad (11.36)$$

所以 t 检验和置信区间是同一件事的两种说法:

- t 检验问: “ β_j 可能是 0 吗?” → 用 p 值回答;
- 置信区间问: “ β_j 可能在什么范围?” → 如果区间包含 0, 则不能拒绝 H_0 。

常见误区

- (1) “ $p > 0.05$ 说明 X_j 没用” → $\times$ 错误。

正确的说法是: “没有足够证据证明 X_j 有用”。可能是样本量太小 (标准误太大)、噪声太强、或 X_j 与别的变量高度相关导致效应被分散。不显著 $\neq$ 不存在。

- (2) “ $p < 0.05$ 说明效应很大” → $\times$ 错误。

p 值小只说明 $\hat{\beta}_j$ 稳定地不为零, 不说明它很大。大样本下, 即使 $\hat{\beta}_j = 0.001$ (几乎可以忽略的实际效应) 也能得到 $p < 0.001$ 。统计显著 $\neq$ 实际重要。判断实际重要性应看 $\hat{\beta}_j$ 的大小及其实际含义。

- (3) “ p 值是 H_0 为真的概率” → $\times$ 错误。

p 值是 $\Pr(\text{数据} | H_0)$, 不是 $\Pr(H_0 | \text{数据})$ 。这是频率学派最常被误解的一点: H_0 ($\beta_j = 0$) 不是随机事件——它要么对要么错。 p 值告诉你的是: 假设 H_0 对, 你看到这种数据的概率, 而不是给定数据, H_0 对的概率。

(4) “ $\alpha = 0.05$ 是绝对的阈值” $\rightarrow \times$ 过于僵化。

$p = 0.049$ 和 $p = 0.051$ 几乎没有区别，不应得出截然相反的结论。建议报告实际的 p 值而非仅报告“显著/不显著”。

(5) “ t 分布 vs 正态” 不必纠结。

t 分布比正态分布有更厚的尾部（尤其是在小自由度时），反映了用 $\hat{\sigma}$ 代替 σ 带来的额外不确定性。当自由度 $N - p - 1 \rightarrow \infty$ 时， t 分布收敛于 $\mathcal{N}(0, 1)$ 。实践中， $N - p - 1 \geq 30$ 时 t 分布与标准正态的差异已不大——可以直接用 ± 1.96 （正态 95% 分位数）近似 $\pm t_{30}^{(0.975)} \approx 2.04$ 。

追问： t 检验不显著，可以直接去掉这个变量吗？

这是实践中非常自然的想法，答案是：要小心，不能机械地做。

✓ 什么时候去掉是合理的：

- 变量确实无关。从领域知识判断， X_j 与 Y 之间没有合理的因果或关联机制；
- 样本量足够大。 N 大意味着检验功效 (power) 充足——如果真有微小的效应，应该能检测到。在 N 很大时仍不显著，说明效应确实太小，不值得保留；
- 你不关心预测之外的推断。如果目标是纯预测（而非因果推断或解释），去掉噪声变量可以降低方差，提升泛化性能。

× 什么时候要谨慎——甚至不该去掉：

(1) 样本量太小。

小样本下标准误 $se(\hat{\beta}_j)$ 很大，即使 $\hat{\beta}_j$ 本身很大也可能不显著。这不是变量没用，是数据不够——你区分不了“效应为零”和“有效应但估计不准”。

例子：医学研究中，某种新药只试了 20 个人， $\hat{\beta} = 2.0$ （效果不小）但 $se = 1.2$ ， $p = 0.11$ 。如果因此扔掉这个变量，你可能错过了一个真正有效的治疗方法。

(2) 变量是控制变量 (control variable)。

有些变量你不关心它的系数，但必须放在模型里。典型场景：

- 因果推断中， X_j 是混杂因子 (confounder)——去掉它会使得其他变量的系数产生偏倚；
- 实验设计中，实验组别、分层变量等即使不显著也应保留。

核心原则：变量的去留不应仅由 p 值决定。控制变量的存在是为了保护其他系数的估计不受混杂偏倚，而不是因为它们自己显著。

(3) 多重共线性 (multicollinearity)。

如果 X_j 与模型中其他变量高度相关，它的效应会被“分散”到相关变量上，导致每个变量单独都不显著——但它们联合起来可能是显著的。

这正是 F 检验的用武之地：单个 t 检验不显著的一组变量，联合 F 检验可能是显著的。如果你只根据 t 检验逐个删除，可能会误删一组实际上有用的变量。

(4) 变量是理论要求的。

如果你的模型基于某个理论（如经济学模型、物理定律），某些变量必须出现——即使数据中它们不显著，也应该保留并报告。科学推断不只是“让数据说话”。

(5) 逐步删除会扭曲推断。

如果你先做了 t 检验，删掉不显著的变量，再用同样的数据重新拟合，那么剩余变量的 p 值和置信区间就不再有效——它们已经被选择过程污染了。这就是**选择性推断 (selective inference)** 要解决的问题。

正确的做法是：如果要删变量，应该在独立的验证集上评估，或使用专门的选择后推断方法。

实用的经验法则：

场景	建议	理由
纯预测、大样本、 $p \gg 0.05$	可以去掉	减少噪声、降低方差
纯预测、小样本	谨慎，考虑正则化 (Lasso)	正则化自动选择变量，比手动删更好
因果推断 / 控制变量	不能仅看 p 值	保留是为了消除混杂
多重共线性明显	先看 F 检验，考虑合并或正则化	单独 t 检验不可靠
理论驱动的研究	保留并报告	科学推断优先于统计显著

一句话总结： t 检验不显著给了你一个怀疑的理由，但不是删除的充分条件。删不删，要结合样本量、变量的领域角色、共线性状况和你的分析目标来综合判断。

11.5.4 置信区间与显著性检验

对于单个系数 β_j ， $100(1 - \alpha)\%$ 置信区间已在上一节给出 (11.36)。这里补充两点扩展：

任意值的检验：要检验 $H_0: \beta_j = c$ (不一定是 0)，只需将 t 统计量改为：

$$t_j = \frac{\hat{\beta}_j - c}{\text{se}(\hat{\beta}_j)} \sim t_{N-p-1}.$$

置信区间同样适用：若 c 不在 $100(1-\alpha)\%$ 置信区间内，则在水平 α 下拒绝 $H_0: \beta_j = c$ 。

11.5.5 进一步可检验的假设

除单个系数外，还可以检验：

- 一组系数的联合显著性： $H_0: \beta_{j_1} = \beta_{j_2} = \cdots = \beta_{j_k} = 0$ ，使用 F 检验；
- 系数的线性组合： $H_0: \mathbf{a}^\top \boldsymbol{\beta} = c$ ；
- 多个线性约束： $H_0: \mathbf{C}\boldsymbol{\beta} = \mathbf{d}$ ，其中 $\mathbf{C}$ 是约束矩阵。

11.5.6 F 检验与嵌套模型比较

单个系数的显著性用 t 检验。当需要同时检验多个系数是否为零（或更一般地，比较两个嵌套模型），则使用 F 检验。

嵌套模型与 F 统计量

定义 11.13 (嵌套模型 (Nested Models)). 模型 $M_0 (\subset M_1)$ 称为嵌套于 M_1 ，若 M_0 的参数是 M_1 参数的子集。典型的 M_0 是令 M_1 中某几个 $\beta_j = 0$ 。

设有两个模型：

- 大模型 M_1 ：含 $p_1 + 1$ 个参数（含截距），残差平方和 RSS_1 ；
- 小模型 M_0 ：含 $p_0 + 1$ 个参数（ $p_0 < p_1$ ），残差平方和 RSS_0 。

M_0 是 M_1 的限制版本（令 $p_1 - p_0$ 个系数为 0）。由于 M_1 有更多自由度来拟合数据，总有 $\text{RSS}_1 \leq \text{RSS}_0$ 。问题是：RSS 的减少是否足够大，值得增加这些额外参数？

定义 11.14 (F 统计量).

$$F = \frac{(\text{RSS}_0 - \text{RSS}_1)/(p_1 - p_0)}{\text{RSS}_1/(N - p_1 - 1)}. \quad (11.37)$$

定理 11.3 (F 统计量的分布). 在正态误差假设下，若 M_0 为真（即被约束的系数确实为 0），则：

$$F \sim F_{p_1 - p_0, N - p_1 - 1}. \quad (11.38)$$

直觉解释：

- 分子： M_1 相比 M_0 的 RSS 改善量 / 额外参数的个数 = “每个额外参数贡献的 RSS 减少”；
- 分母： M_1 的单位自由度 RSS $= \hat{\sigma}^2$ = 噪声方差的估计；
- 比值 F ：信号（改善量）与噪声（ $\hat{\sigma}^2$ ）的对比。 $F \gg 1$ 意味着改善量远超噪声水平 $\rightarrow$ 拒绝 M_0 。

特例：检验所有非截距系数

最常见的 F 检验是检验“除截距外所有系数均为零”：

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0.$$

此时 M_0 仅含截距 ($p_0 = 0$)， $\text{RSS}_0 = \sum (y_i - \bar{y})^2 = \text{TSS}$ （总平方和）。 F 统计量退化为：

$$F = \frac{(\text{TSS} - \text{RSS})/p}{\text{RSS}/(N - p - 1)}. \quad (11.39)$$

11.5.7 联合置信域

单个系数的置信区间每次只考虑一个 β_j 。如果同时对所有参数做推断，需要**联合置信域 (joint confidence region)**——校正多重比较带来的覆盖概率膨胀。

定义 11.15 (β 的联合置信域). 在正态误差假设下， β 的一个 $100(1 - \alpha)\%$ 联合置信域为：

$$C_\beta = \left\{ \beta \in \mathbb{R}^{p+1} \mid (\hat{\beta} - \beta)^\top \mathbf{X}^\top \mathbf{X} (\hat{\beta} - \beta) \leq \hat{\sigma}^2 \cdot (p + 1) \cdot F_{p+1, N-p-1}^{(1-\alpha)} \right\}. \quad (11.40)$$

这是一个以 $\hat{\beta}$ 为中心的**椭球**。

单个区间 vs 联合域：单个 $100(1 - \alpha)\%$ 置信区间意味着该区间有 $1 - \alpha$ 的概率覆盖对应的 β_j （条件于 $\mathbf{X}$ ）。但如果对 $\beta_0, \beta_1, \dots, \beta_p$ 同时使用 $p + 1$ 个单独的区间，**所有区间同时覆盖各自真值的概率小于 $1 - \alpha$** （多重比较问题）。联合置信域校正了这一点。

用大样本近似时，椭球可用 χ^2 分位数替代 F 分位数：

$$C_\beta \approx \left\{ \beta \mid (\hat{\beta} - \beta)^\top \mathbf{X}^\top \mathbf{X} (\hat{\beta} - \beta) \leq \hat{\sigma}^2 \cdot \chi_{p+1, (1-\alpha)}^2 \right\}.$$

11.6 高斯-马尔可夫定理

11.6.1 定理陈述与意义

定理 11.4 (高斯-马尔可夫定理 (Gauss–Markov Theorem)). 在假设 (11.21)–(11.23) 下（仅一阶、二阶矩假设，不要求正态性），对任意线性组合 $\theta = \mathbf{a}^\top \beta$ ($\mathbf{a} \in \mathbb{R}^{p+1}$)：

(i) $\hat{\theta} = \mathbf{a}^\top \hat{\boldsymbol{\beta}}$ 是 θ 的线性无偏估计: $\mathbb{E}[\hat{\theta} | \mathbf{X}] = \mathbf{a}^\top \boldsymbol{\beta} = \theta$;

(ii) 对任意其他线性无偏估计 $\tilde{\theta} = \mathbf{c}^\top \mathbf{y}$ (满足 $\mathbb{E}[\tilde{\theta} | \mathbf{X}] = \theta$): $\text{Var}(\hat{\theta} | \mathbf{X}) \leq \text{Var}(\tilde{\theta} | \mathbf{X})$ 。

即: LS 估计量是 $\theta = \mathbf{a}^\top \boldsymbol{\beta}$ 的最佳线性无偏估计 (BLUE)。

定理的意义:

- 在所有线性无偏估计量中, LS 的方差最小——没有人能用线性方法做得更好 (在不引入偏差的前提下);
- 定理不依赖正态性——只要求一阶矩 (线性均值) 和二阶矩 (同方差 + 不相关);
- 但如果误差不是正态的, 可能存在非线性估计量 (如稳健回归中的 M-估计量) 在某些标准下优于 LS。

11.6.2 MSE 分解: 偏差-方差视角

高斯-马尔可夫定理讨论的是无偏估计量类中的最优性。但如果我们放开“无偏”约束呢? 这就引出了 MSE 的分解:

定义 11.16 (均方误差 (Mean Squared Error, MSE)). 对于 θ 的任意估计量 $\tilde{\theta}$:

$$\text{MSE}(\tilde{\theta}) = \mathbb{E}[(\tilde{\theta} - \theta)^2] = \underbrace{\text{Var}(\tilde{\theta})}_{\text{方差}} + \underbrace{(\mathbb{E}[\tilde{\theta}] - \theta)^2}_{\text{偏差}^2}. \quad (11.41)$$

关键洞察:

- LS 估计量 $\hat{\theta}$ 偏差为零, 在所有无偏估计量中方差最小——BLUE;
- 但如果引入一点偏差, 可能大幅降低方差, 从而在 MSE 上优于 LS;
- 这恰恰是岭回归、Lasso 等正则化方法的动机——用有偏换方差, 从而降低 MSE。

高斯-马尔可夫定理告诉我们: 在无偏的线性世界里, LS 已经是最好的了。但现代统计学习恰恰选择了走出这个“无偏”世界——这就是第 3.4 节 (收缩方法) 要讨论的内容。

11.7 预测误差的分解

除了估计 $\boldsymbol{\beta}$ 本身, 我们更关心模型在新数据上的预测表现。

11.7.1 新观测的预测

设新观测点为 x_0 ($p+1$ 维, 含截距列), 其真实响应为:

$$Y_0 = x_0^\top \beta + \varepsilon_0, \quad \varepsilon_0 \sim (0, \sigma^2), \quad \varepsilon_0 \perp \{\varepsilon_1, \dots, \varepsilon_N\}.$$

我们用 $\hat{f}(x_0) = x_0^\top \hat{\beta}$ 来预测 Y_0 。

11.7.2 期望预测误差 (Expected Prediction Error)

定理 11.5 (新点上的预测误差分解).

$$\mathbb{E}[(Y_0 - \hat{f}(x_0))^2] = \sigma^2 + \mathbb{E}[(\hat{f}(x_0) - f(x_0))^2]. \quad (11.42)$$

其中 σ^2 是不可约误差 (即使知道真实 f 也无法消除), 第二项是 $\hat{f}(x_0)$ 作为 $f(x_0)$ 估计量的 MSE。

证明.

$$\begin{aligned} \mathbb{E}[(Y_0 - \hat{f}(x_0))^2] &= \mathbb{E}[(f(x_0) + \varepsilon_0 - \hat{f}(x_0))^2] \\ &= \mathbb{E}[(\varepsilon_0 + (f(x_0) - \hat{f}(x_0)))^2] \\ &= \mathbb{E}[\varepsilon_0^2] + 2\mathbb{E}[\varepsilon_0 \cdot (f(x_0) - \hat{f}(x_0))] + \mathbb{E}[(f(x_0) - \hat{f}(x_0))^2] \\ &= \sigma^2 + 0 + \text{MSE}(\hat{f}(x_0)). \end{aligned} \quad (11.43)$$

交叉项为零因为 ε_0 与训练数据 (从而 $\hat{f}$) 独立。 $\square$

进一步将 $\text{MSE}(\hat{f}(x_0))$ 按偏差-方差分解:

$$\text{MSE}(\hat{f}(x_0)) = \text{Var}(\hat{f}(x_0)) + (\mathbb{E}[\hat{f}(x_0)] - f(x_0))^2.$$

在线性模型正确设定的前提下 ($\mathbb{E}[\hat{f}(x_0)] = f(x_0)$), 偏差为零, 只剩下方差:

$$\mathbb{E}[(Y_0 - \hat{f}(x_0))^2] = \sigma^2 + \underbrace{\text{Var}(x_0^\top \hat{\beta})}_{\text{估计方差}} = \sigma^2 + x_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} x_0 \cdot \sigma^2.$$

11.7.3 训练误差 vs 预测误差

- **训练误差:** $\frac{1}{N} \sum (y_i - \hat{y}_i)^2$ 随模型复杂度增加而单调递减;
- **预测误差 (EPE):** 呈 U 形曲线——模型太简单则欠拟合 (高偏差), 太复杂则过拟合 (高方差)。

这就是第 2 章统计学习导论中讨论的核心张力: 偏差-方差权衡。

11.8 多元回归作为单变量回归的叠加

本节讨论一个深刻而优雅的几何事实：多元线性回归的系数可以逐个通过一系列单变量回归来获得。这不仅是计算上的洞察（Gram-Schmidt 正交化），也揭示了“多元回归 = 逐步剥离已解释信息”的本质。

11.8.1 单变量回归的最小二乘

先回顾最简单的情形——只有一个预测变量（无截距）：

$$\mathbf{y} = \mathbf{x}\beta + \varepsilon.$$

此时 $\mathbf{X}^\top \mathbf{X} = \mathbf{x}^\top \mathbf{x} = \langle \mathbf{x}, \mathbf{x} \rangle$ （内积）， $\mathbf{X}^\top \mathbf{y} = \langle \mathbf{x}, \mathbf{y} \rangle$ 。LS 估计为：

$$\boxed{\hat{\beta} = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\langle \mathbf{x}, \mathbf{x} \rangle}}. \quad (11.44)$$

残差为 $\mathbf{r} = \mathbf{y} - \mathbf{x}\hat{\beta}$ ，满足 $\langle \mathbf{x}, \mathbf{r} \rangle = 0$ （正交）。

11.8.2 有截距时的处理

若模型含截距 $\mathbf{y} = \beta_0 \mathbf{1} + \mathbf{x}\beta_1 + \varepsilon$ ，可以先从 $\mathbf{x}$ 中回归掉 $\mathbf{1}$ （即中心化），再对残差做无截距回归：

第 1 步：将 $\mathbf{x}$ 对 $\mathbf{1}$ 回归，得残差 $\mathbf{z} = \mathbf{x} - \bar{x}\mathbf{1}$ （中心化后的 $\mathbf{x}$ ）；

第 2 步：将 $\mathbf{y}$ 对 $\mathbf{z}$ 做无截距回归：

$$\hat{\beta}_1 = \frac{\langle \mathbf{z}, \mathbf{y} \rangle}{\langle \mathbf{z}, \mathbf{z} \rangle} = \frac{\sum (x_i - \bar{x})y_i}{\sum (x_i - \bar{x})^2}.$$

$\hat{\beta}_0$ 则从 $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ 得到。

11.8.3 推广到多元：正交化 (Gram-Schmidt)

上述思路可以逐列推广到多元回归。设有 p 个预测变量 $\mathbf{x}_1, \dots, \mathbf{x}_p$ ，算法：

第 1 步：初始化 $\mathbf{z}_0 = \mathbf{1}$ （截距列）；

第 2 步：对 $j = 1, \dots, p$ ：

- 将 $\mathbf{x}_j$ 对 $\mathbf{z}_0, \mathbf{z}_1, \dots, \mathbf{z}_{j-1}$ 做多元回归，得残差 $\mathbf{z}_j$ ；
- $\mathbf{z}_j$ 是 $\mathbf{x}_j$ 中与前面所有变量正交的部分——即 $\mathbf{x}_j$ 中不能被 $\mathbf{x}_1, \dots, \mathbf{x}_{j-1}$ 线性表出的“新信息”；

第 3 步：将 $\mathbf{y}$ 对 $\mathbf{z}_p$ 做单变量回归，得 $\hat{\beta}_p$ ；

第 4 步：以此类推，得到所有系数。

关键公式：多元回归中 $\mathbf{x}_j$ 的系数 $\hat{\beta}_j$ 可以通过单变量回归获得：

$$\hat{\beta}_j = \frac{\langle \mathbf{z}_j, \mathbf{y} \rangle}{\langle \mathbf{z}_j, \mathbf{z}_j \rangle}, \quad (11.45)$$

其中 $\mathbf{z}_j$ 是 $\mathbf{x}_j$ 在 $\mathbf{x}_1, \dots, \mathbf{x}_{j-1}$ （及截距）的正交补上的投影残差。

11.8.4 直观理解

- $\hat{\beta}_j$ 测量的是：去掉前面 $j-1$ 个变量已经解释的部分后， $\mathbf{x}_j$ 独有的贡献；
- 如果 $\mathbf{x}_j$ 与前面的变量高度相关，则 $\mathbf{z}_j$ 很小 $\rightarrow \hat{\beta}_j$ 的方差很大（多重共线性问题）；
- 如果预测变量彼此正交（ $\langle \mathbf{x}_j, \mathbf{x}_k \rangle = 0, j \neq k$ ），则每个系数的估计独立于其他变量，添加/删除变量不影响已有系数。

一句话：多元回归中的 $\hat{\beta}_j$ = “ $\mathbf{x}_j$ 独有部分的单变量回归系数”。这就是为什么 $\hat{\beta}_j$ 的符号和大小不能简单解释为 $\mathbf{x}_j$ 的“重要性”——它的估计依赖于模型中还有哪些其他变量。

11.8.5 QR 分解：从 Gram-Schmidt 到数值计算

上一节的 Gram-Schmidt 过程不仅是概念工具，它直接引出了线性回归最重要的数值方法——QR 分解。

从 Gram-Schmidt 到矩阵分解

Gram-Schmidt 过程产生了一组正交向量 $\mathbf{z}_0, \mathbf{z}_1, \dots, \mathbf{z}_p$ 。将它们写成矩阵形式，可以得到 $\mathbf{X}$ 的一个分解。

定义矩阵 $\mathbf{Z} = [\mathbf{z}_0 \ \mathbf{z}_1 \ \cdots \ \mathbf{z}_p]$ （各列正交）。Gram-Schmidt 的构造方式意味着原始设计矩阵 $\mathbf{X}$ 可以表示为 $\mathbf{Z}$ 的列的一个上三角线性组合：

$$\mathbf{X} = \mathbf{Z}\mathbf{\Gamma}, \quad (11.46)$$

其中 $\mathbf{\Gamma}$ 是 $(p+1) \times (p+1)$ 的上三角矩阵，对角线元素全为 1。

为什么是上三角？因为 $\mathbf{z}_j$ 仅依赖 $\mathbf{x}_1, \dots, \mathbf{x}_j$ ， $\mathbf{x}_j$ 表示为 $\mathbf{z}_0, \dots, \mathbf{z}_j$ 的线性组合——系数矩阵自然是上三角的。

标准化得到 QR 分解

将 $\mathbf{Z}$ 的各列标准化为单位长度。令 $\mathbf{D}$ 为对角矩阵, $D_{jj} = \|\mathbf{z}_j\|$ (第 j 列的长度), 定义:

$$\mathbf{Q} = \mathbf{Z}\mathbf{D}^{-1},$$

即 $\mathbf{Q}$ 的每一列 $\mathbf{q}_j = \mathbf{z}_j / \|\mathbf{z}_j\|$ 。则 $\mathbf{Q}$ 是列正交矩阵: $\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}$ 。

定义 11.17 (QR 分解). 将 $\mathbf{X} = \mathbf{Z}\mathbf{\Gamma}$ 改写为:

$$\boxed{\mathbf{X} = \mathbf{Z}\mathbf{D}^{-1}\mathbf{D}\mathbf{\Gamma} = \mathbf{Q}\mathbf{R}}, \quad (11.47)$$

其中:

- $\mathbf{Q}$ 是 $N \times (p+1)$ 列正交矩阵 ($\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}$);
- $\mathbf{R} = \mathbf{D}\mathbf{\Gamma}$ 是 $(p+1) \times (p+1)$ 上三角矩阵, 且对角元 $R_{jj} = \|\mathbf{z}_j\| > 0$ 。

用 QR 分解求解最小二乘

QR 分解让 LS 估计变得极其简洁。代入 $\hat{\beta}$ 的公式:

$$\begin{aligned} \hat{\beta} &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \\ &= ((\mathbf{Q}\mathbf{R})^\top \mathbf{Q}\mathbf{R})^{-1} (\mathbf{Q}\mathbf{R})^\top \mathbf{y} \\ &= (\mathbf{R}^\top \mathbf{Q}^\top \mathbf{Q}\mathbf{R})^{-1} \mathbf{R}^\top \mathbf{Q}^\top \mathbf{y} \\ &= (\mathbf{R}^\top \mathbf{R})^{-1} \mathbf{R}^\top \mathbf{Q}^\top \mathbf{y} \quad (\text{因为 } \mathbf{Q}^\top \mathbf{Q} = \mathbf{I}) \\ &= \mathbf{R}^{-1} \mathbf{Q}^\top \mathbf{y}. \end{aligned} \quad (11.48)$$

即:

$$\boxed{\hat{\beta} = \mathbf{R}^{-1} \mathbf{Q}^\top \mathbf{y}} \iff \boxed{\mathbf{R} \hat{\beta} = \mathbf{Q}^\top \mathbf{y}}.$$

由于 $\mathbf{R}$ 是上三角矩阵, $\mathbf{R} \hat{\beta} = \mathbf{Q}^\top \mathbf{y}$ 可以通过 回代 (back-substitution) 高效求解——从 $\hat{\beta}_p$ 开始向上逐一算出。

拟合值也有了简洁形式:

$$\hat{\mathbf{y}} = \mathbf{X} \hat{\beta} = \mathbf{Q}\mathbf{R} \cdot \mathbf{R}^{-1} \mathbf{Q}^\top \mathbf{y} = \mathbf{Q}\mathbf{Q}^\top \mathbf{y}.$$

单个系数的方差

在 QR 分解下, $\hat{\beta}_j$ 的方差有特别简洁的表达式:

$$\boxed{\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{\|\mathbf{z}_j\|^2}}. \quad (11.49)$$

推导：由 $\text{Var}(\hat{\beta}) = (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2 = (\mathbf{R}^\top \mathbf{R})^{-1} \sigma^2$ ，而 $\mathbf{R}$ 的对角元 $R_{jj} = \|\mathbf{z}_j\|$ 。由于 $\mathbf{R}$ 上三角， $(\mathbf{R}^{-1})_{jj} = 1/R_{jj}$ ，因此：

$$\text{Var}(\hat{\beta}_j) = \sigma^2 \sum_k (\mathbf{R}^{-1})_{jk}^2 \geq \sigma^2 (\mathbf{R}^{-1})_{jj}^2 = \frac{\sigma^2}{\|\mathbf{z}_j\|^2}.$$

当 $\mathbf{X}$ 的列正交时等号成立（ $\mathbf{R}$ 为对角矩阵）。

直观含义： $\|\mathbf{z}_j\|$ 是 $\mathbf{x}_j$ 中“独有信息”的强度。 $\|\mathbf{z}_j\|$ 越小（ $\mathbf{x}_j$ 与其他变量高度相关）， $\hat{\beta}_j$ 的方差越大——这精确量化了多重共线性的危害。

QR vs 正规方程：数值稳定性

实践中，直接计算 $(\mathbf{X}^\top \mathbf{X})^{-1}$ （正规方程法）在数值上不稳定——如果 $\mathbf{X}$ 接近秩亏， $\mathbf{X}^\top \mathbf{X}$ 的条件数是 $\mathbf{X}$ 条件数的平方，求逆会放大舍入误差。QR 分解绕过了 $\mathbf{X}^\top \mathbf{X}$ 的构造，直接处理 $\mathbf{X}$ ，数值稳定性好得多。因此实际统计软件（R 的 `lm`、Python 的 `statsmodels`）都使用 QR 分解，而不是正规方程。

11.9 多输出回归 (Multiple Outputs)

此前我们一直假设 Y 是标量（单输出）。实际中常常需要同时预测多个响应变量。例如：

- 根据天气数据同时预测温度、湿度和风速；
- 根据医学影像同时预测多种疾病的概率；
- 根据学生背景同时预测多门课程的成绩。

11.9.1 模型形式

设有 K 个输出变量 $Y_1, Y_2, \dots, Y_K$ ，每个都使用相同的 p 个预测变量：

定义 11.18 (多输出线性模型). 对第 k 个输出：

$$Y_k = \beta_{0k} + \sum_{j=1}^p X_j \beta_{jk} + \varepsilon_k, \quad k = 1, \dots, K.$$

注意：每个输出有自己的一组系数 $\beta_{0k}, \beta_{1k}, \dots, \beta_{pk}$ ，但所有输出共享同一组输入 $X_1, \dots, X_p$ 。

11.9.2 矩阵形式

将 K 个输出堆叠为矩阵，得到紧凑的矩阵形式：

$$\mathbf{Y}_{N \times K} = \mathbf{X}_{N \times (p+1)} \mathbf{B}_{(p+1) \times K} + \mathbf{E}_{N \times K}. \quad (11.50)$$

其中：

$$\mathbf{Y} = \begin{pmatrix} y_{11} & \cdots & y_{1K} \\ \vdots & \ddots & \vdots \\ y_{N1} & \cdots & y_{NK} \end{pmatrix}, \quad \mathbf{B} = \begin{pmatrix} \beta_{01} & \cdots & \beta_{0K} \\ \beta_{11} & \cdots & \beta_{1K} \\ \vdots & \ddots & \vdots \\ \beta_{p1} & \cdots & \beta_{pK} \end{pmatrix}, \quad \mathbf{E} = \begin{pmatrix} \varepsilon_{11} & \cdots & \varepsilon_{1K} \\ \vdots & \ddots & \vdots \\ \varepsilon_{N1} & \cdots & \varepsilon_{NK} \end{pmatrix}.$$

$\mathbf{X}$ 与单输出情形完全相同 ($N \times (p+1)$ ，含截距列)。 $\mathbf{B}$ 的第 k 列就是第 k 个输出的系数向量。

11.9.3 最小二乘估计

多输出 RSS 定义为所有输出、所有观测的平方误差之和：

$$\text{RSS}(\mathbf{B}) = \sum_{k=1}^K \sum_{i=1}^N (y_{ik} - f_k(\mathbf{x}_i))^2 = \text{tr}((\mathbf{Y} - \mathbf{XB})^\top (\mathbf{Y} - \mathbf{XB})). \quad (11.51)$$

对 $\mathbf{B}$ 求导并令其为零，得到与单输出完全相同的正规方程：

$$\mathbf{X}^\top \mathbf{XB} = \mathbf{X}^\top \mathbf{Y}. \quad (11.52)$$

因此：

$$\hat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}. \quad (11.53)$$

注记 11.5 (核心洞察：为什么可以逐列求解). 注意 $\hat{\mathbf{B}}$ 的公式和单输出的 $\hat{\beta}$ 完全一样，只是把 $\mathbf{y}$ (向量) 换成了 $\mathbf{Y}$ (矩阵)。

这意味着：如果误差在不同输出间不相关，多输出回归等价于对每个输出 Y_k 单独做一次单输出回归。 $\hat{\mathbf{B}}$ 的第 k 列 = $(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}_k$ 。

11.9.4 当误差跨输出相关时

如果不同输出的误差相关 ($\text{Cov}(\varepsilon_{ik}, \varepsilon_{i\ell}) \neq 0$)，逐列 LS 仍然是无偏的，但不再是最优的。此时可以引入多变量加权最小二乘。

定义 11.19 (误差协方差矩阵). 设第 i 个观测的 K 维误差向量 $\boldsymbol{\varepsilon}_i = (\varepsilon_{i1}, \dots, \varepsilon_{iK})^\top$ ，其协方差矩阵为 $\text{Cov}(\boldsymbol{\varepsilon}_i) = \boldsymbol{\Sigma}$ ($K \times K$ ，对所有 i 相同，且不同 i 间独立)。

多变量加权准则：

$$\text{RSS}_{\Sigma}(\mathbf{B}) = \sum_{i=1}^N (\mathbf{y}_i - \mathbf{B}^{\top} \mathbf{x}_i)^{\top} \Sigma^{-1} (\mathbf{y}_i - \mathbf{B}^{\top} \mathbf{x}_i). \quad (11.54)$$

但 Σ 在实践中通常未知。幸运的是：如果所有输出使用相同的输入矩阵 $\mathbf{X}$ ，即使 $\Sigma \neq \mathbf{I}$ ，逐列 LS 仍然是逐列最优的——因为 $\hat{\mathbf{B}}$ 就是最大化多变量似然的解（在正态假设下），且 $\hat{\mathbf{B}}$ 不依赖 Σ 。

一句话总结：如果所有输出用同一组 $\mathbf{X}$ ，多输出回归直接退化为 K 个独立的单输出回归——对每个 Y_k 跑一次 `lm(y_k ~ X)` 即可。这正是 R 中 `lm(Y ~ X)`（ Y 为矩阵时）的行为。

11.10 实例：前列腺癌数据

本节用 ESL 中的前列腺癌数据集来展示线性回归的完整流程。数据来自 Stamey et al. (1989)，研究前列腺特异性抗原 (PSA) 水平与多个临床指标的关系。

11.10.1 变量说明

变量	含义	类型
lcavol	log(癌体积)	连续
lweight	log(前列腺重量)	连续
age	年龄	连续
lbph	log(良性增生量)	连续
svi	精囊侵犯	二值 (0/1)
lcp	log(包膜穿透)	连续
gleason	Gleason 评分	有序类别
pgg45	Gleason 评分 4/5 的百分比	连续
响应变量		
lpsa	log(PSA)	连续

共 $N = 97$ 个观测（划分为训练集 67 + 测试集 30）。

11.10.2 预测变量的相关矩阵

表 ?? 给出了 8 个预测变量两两之间的 Pearson 相关系数。注意到：lcavol 与 lcp 高度相关 ($r \approx 0.68$)，gleason 与 pgg45 也高度相关 ($r \approx 0.75$)，这提示可能存在多重共线性问题。

	lcavol	lweight	age	lbph	svi	lcp	gleason	pgg45
lcavol	1.00	0.30	0.29	0.06	0.59	0.68	0.43	0.43
lweight		1.00	0.35	0.44	0.16	0.16	0.06	0.11
age			1.00	0.35	0.13	0.18	0.27	0.28
lbph				1.00	-0.09	-0.01	0.08	0.08
svi					1.00	0.67	0.32	0.25
lcp						1.00	0.51	0.63
gleason							1.00	0.75
pgg45								1.00

11.10.3 全模型回归结果

将 lpsa 对所有 8 个预测变量做线性回归，结果见表 ??。

项	系数 $\hat{\beta}_j$	标准误	z 值	p 值 (近似)
Intercept	0.429	1.036	0.41	0.68
lcavol	0.576	0.107	5.37	< 0.001
lweight	0.614	0.201	3.06	0.002
age	-0.019	0.011	-1.73	0.084
lbph	0.145	0.058	2.50	0.012
svi	0.737	0.237	3.11	0.002
lcp	-0.106	0.090	-1.18	0.239
gleason	-0.036	0.136	-0.26	0.792
pgg45	0.00446	0.00436	1.02	0.307

解读：

- 显著的变量：lcavol、lweight、svi、lbph ($p < 0.05$)；
- 不显著的变量：age (边缘显著)、lcp、gleason、pgg45；

- 这是典型的多重共线性表现——`lcp` 与 `lcavol` 高度相关，单独的贡献被 `lcavol` “抢走”了；
- `gleason` 和 `pgg45` 高度相关，两者都不显著，但它们联合可能显著。

11.10.4 F 检验：小模型 vs 大模型

考虑比较两个嵌套模型：

- M_1 (全模型)：8 个预测变量 + 截距， $p_1 = 8$ ， $RSS_1 = 29.43$ ；
- M_0 (小模型)：仅 `lcavol`、`lweight`、`svi`、`lbph` 4 个变量 + 截距， $p_0 = 4$ ， $RSS_0 = 32.81$ 。

检验 H_0 ：被去掉的 4 个变量 (`age`, `lcp`, `gleason`, `pgg45`) 的系数全为零。

$$F = \frac{(32.81 - 29.43)/(8 - 4)}{29.43/(67 - 8 - 1)} = \frac{3.38/4}{29.43/58} = \frac{0.845}{0.507} \approx 1.67.$$

$F \sim F_{4,58}$ ， $p\text{-value} \approx 0.17 > 0.05$ 。结论：不能拒绝 H_0 ——这 4 个变量联合来看也不显著，可以从小模型中移除。

这体现了 F 检验的价值：单个变量不显著不代表它们联合也不显著（反之亦然）。 F 检验提供了一种整体评估一组变量贡献的方法。

11.11 完整示例：手算一个线性回归

下面用一个极小的数据集 ($N = 6$, $p = 2$)，从原始数据开始，逐步走完本章讲过的全部流程。所有数值都可以手算验证。

11.11.1 数据与模型

i	y_i	x_{i1}	x_{i2}
1	4	1	3
2	5	2	1
3	7	3	4
4	8	4	2
5	10	5	5
6	12	6	3

模型： $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$ 。

设计矩阵与响应向量：

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 3 \\ 1 & 2 & 1 \\ 1 & 3 & 4 \\ 1 & 4 & 2 \\ 1 & 5 & 5 \\ 1 & 6 & 3 \end{pmatrix}_{6 \times 3}, \quad \mathbf{y} = \begin{pmatrix} 4 \\ 5 \\ 7 \\ 8 \\ 10 \\ 12 \end{pmatrix}_{6 \times 1}.$$

11.11.2 Step 1: 估计 $\hat{\beta}$

计算 $\mathbf{X}^\top \mathbf{X}$ 和 $\mathbf{X}^\top \mathbf{y}$ ：

$$\mathbf{X}^\top \mathbf{X} = \begin{pmatrix} 6 & 21 & 18 \\ 21 & 91 & 71 \\ 18 & 71 & 64 \end{pmatrix}, \quad \mathbf{X}^\top \mathbf{y} = \begin{pmatrix} 46 \\ 189 \\ 153 \end{pmatrix}.$$

求逆（可用软件，此处给出结果）：

$$(\mathbf{X}^\top \mathbf{X})^{-1} \approx \begin{pmatrix} 1.557 & -0.214 & -0.200 \\ -0.214 & 0.071 & -0.019 \\ -0.200 & -0.019 & 0.092 \end{pmatrix}.$$

最小二乘估计：

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} \approx \begin{pmatrix} 1.17 \\ 1.45 \\ 0.28 \end{pmatrix}.$$

拟合模型： $\hat{y} = 1.17 + 1.45x_1 + 0.28x_2$ 。

11.11.3 Step 2: 拟合值与残差

i	y_i	$\hat{y}_i = 1.17 + 1.45x_{i1} + 0.28x_{i2}$	$\hat{\varepsilon}_i = y_i - \hat{y}_i$	$\hat{\varepsilon}_i^2$
1	4	$1.17 + 1.45(1) + 0.28(3) = 3.46$	+0.54	0.29
2	5	$1.17 + 1.45(2) + 0.28(1) = 4.35$	+0.65	0.42
3	7	$1.17 + 1.45(3) + 0.28(4) = 6.64$	+0.36	0.13
4	8	$1.17 + 1.45(4) + 0.28(2) = 7.53$	+0.47	0.22
5	10	$1.17 + 1.45(5) + 0.28(5) = 9.82$	+0.18	0.03
6	12	$1.17 + 1.45(6) + 0.28(3) = 10.71$	+1.29	1.66

$$\text{RSS} = \sum_{i=1}^6 \hat{\varepsilon}_i^2 = 0.29 + 0.42 + 0.13 + 0.22 + 0.03 + 1.66 = 2.75.$$

11.11.4 Step 3: σ^2 的无偏估计

$$\hat{\sigma}^2 = \frac{\text{RSS}}{N - p - 1} = \frac{2.75}{6 - 2 - 1} = \frac{2.75}{3} \approx 0.917。$$

$\hat{\sigma} = \sqrt{0.917} \approx 0.957$ ——这是模型误差的标准差估计。

11.11.5 Step 4: 系数的标准误与 t 检验

$v_j = [(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}$ (对角元):

$$v_0 \approx 1.557, \quad v_1 \approx 0.071, \quad v_2 \approx 0.092。$$

$$\text{se}(\hat{\beta}_j) = \hat{\sigma} \sqrt{v_j}。$$

系数	估计 $\hat{\beta}_j$	$\text{se}(\hat{\beta}_j)$	t_j	p 值	结论 ($\alpha = 0.05$)
β_0 (截距)	1.17	$0.957 \times \sqrt{1.557} \approx 1.19$	0.98	0.399	不显著
β_1 (x_1)	1.45	$0.957 \times \sqrt{0.071} \approx 0.255$	5.69	0.011	显著
β_2 (x_2)	0.28	$0.957 \times \sqrt{0.092} \approx 0.290$	0.97	0.405	不显著

$t_j = \hat{\beta}_j / \text{se}(\hat{\beta}_j)$, 自由度 = $N - p - 1 = 3$ 。

解读:

- β_1 : $p = 0.011 < 0.05$, 拒绝 $H_0: \beta_1 = 0$ 。 x_1 对 y 有显著的线性贡献。每增加 1 单位 x_1 , y 平均增加约 1.45;
- β_2 : $p = 0.405$, 不能拒绝 $H_0: \beta_2 = 0$ 。单独看, 没有足够证据说明 x_2 有用。但这不自动意味着应该删除 x_2 (见下一节讨论)。

11.11.6 Step 5: F 检验——小模型 vs 大模型

现在考虑是否可以把 x_2 从模型中删掉。比较两个嵌套模型:

- 大模型 M_1 : $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2$, $\text{RSS}_1 = 2.75$, $p_1 = 2$;
- 小模型 M_0 : $y = \beta_0 + \beta_1 x_1$ (去掉 x_2), 重新拟合……

先单独拟合 $y \sim x_1$ (仅截距 + x_1):

$$\mathbf{X}_0 = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \\ 1 & 6 \end{pmatrix}, \quad \hat{\beta}_0 = (\mathbf{X}_0^\top \mathbf{X}_0)^{-1} \mathbf{X}_0^\top \mathbf{y} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} \approx \begin{pmatrix} 2.33 \\ 1.54 \end{pmatrix}.$$

拟合值: $\hat{y}_i^{(0)} = 2.33 + 1.54x_{i1}$: 3.87, 5.41, 6.95, 8.49, 10.03, 11.57。

残差平方和:

$$\text{RSS}_0 \approx (4 - 3.87)^2 + \cdots + (12 - 11.57)^2 \approx 3.62.$$

现在计算 F 统计量 (检验 $H_0: \beta_2 = 0$):

$$F = \frac{(\text{RSS}_0 - \text{RSS}_1)/(p_1 - p_0)}{\text{RSS}_1/(N - p_1 - 1)} = \frac{(3.62 - 2.75)/(2 - 1)}{2.75/3} = \frac{0.87}{0.917} \approx 0.95.$$

$F \sim F_{1,3}$, $p\text{-value} \approx 0.40$ 。

注意: 这里 $p_1 - p_0 = 1$ (只检验一个系数), $F = t_2^2$ ($0.95 \approx 0.97^2$), F 检验的 p 值与 β_2 的 t 检验的 p 值一致——因为检验的是同一个假设 $H_0: \beta_2 = 0$ 。

结论: 不能拒绝 $H_0: \beta_2 = 0$ 。但鉴于样本量极小 ($N = 6$), 我们只能说“没有足够证据支持保留 x_2 ”, 不能说“ x_2 一定没用”。

11.11.7 Step 6: R^2 与模型解释力

总平方和: $\text{TSS} = \sum(y_i - \bar{y})^2$, $\bar{y} = 46/6 \approx 7.67$ 。

$$\text{TSS} = (4 - 7.67)^2 + \cdots + (12 - 7.67)^2 \approx 46.33.$$

$$R^2 = 1 - \frac{\text{RSS}}{\text{TSS}} = 1 - \frac{2.75}{46.33} \approx 0.941.$$

模型解释了 y 约 94% 的变异。但注意 $N = 6$ 时 R^2 会被高估——调整 R^2 (adjusted R^2) 对此做了校正:

$$R_{\text{adj}}^2 = 1 - \frac{\text{RSS}/(N - p - 1)}{\text{TSS}/(N - 1)} = 1 - \frac{2.75/3}{46.33/5} \approx 0.901.$$

11.11.8 Step 7: 95% 置信区间

β_1 的 95% 置信区间 ($t_3^{(0.975)} \approx 3.182$, 自由度小所以临界值大):

$$1.45 \pm 3.182 \times 0.255 \approx 1.45 \pm 0.81 = [0.64, 2.26].$$

解读：我们以 95% 的置信度认为， x_1 每增加 1 单位， y 的增加量在 0.64 到 2.26 之间。区间不包含 0，这与 t 检验拒绝 $H_0: \beta_1 = 0$ 一致。

β_2 的 95% 置信区间：

$$0.28 \pm 3.182 \times 0.290 \approx 0.28 \pm 0.92 = [-0.64, 1.20].$$

区间包含 0，与 t 检验不拒绝 $H_0: \beta_2 = 0$ 一致。但区间非常宽（跨度 1.84），反映了 $N = 6$ 时估计的不确定性很大——这就是为什么“不显著”不等于“效应为零”。

11.11.9 Step 8: 预测新观测

假设新样本 $x_1^* = 3.5$, $x_2^* = 3$ ，点预测为：

$$\hat{y}^* = 1.17 + 1.45 \times 3.5 + 0.28 \times 3 = 7.09.$$

预测的标准误需考虑两个不确定性来源：

$$\text{se}(\hat{y}^*) = \hat{\sigma} \sqrt{1 + x^{*\top}(\mathbf{X}^\top \mathbf{X})^{-1}x^*} \approx 0.957 \times \sqrt{1 + 0.19} \approx 1.04.$$

（根号里的“1”来自 σ^2 ——不可约噪声——“0.19”来自系数估计的不确定性。）

95% 预测区间：

$$7.09 \pm 3.182 \times 1.04 \approx 7.09 \pm 3.31 = [3.78, 10.40].$$

11.11.10 总结：从这个例子学到了什么

- (1) **完整流程：**数据 $\rightarrow \hat{\beta} \rightarrow$ 残差 $\rightarrow \hat{\sigma}^2 \rightarrow$ SE $\rightarrow t$ 检验 $\rightarrow F$ 检验 $\rightarrow R^2 \rightarrow$ CI $\rightarrow$ 预测——每一步都环环相扣；
- (2) **小样本的代价：** $N = 6$, $df = 3$ 时 t 的临界值高达 3.182（相比大样本的 1.96），CI 很宽——同样的 $\hat{\beta}_j$ 在大样本中可能显著，在小样本中却未必；
- (3) **t 检验与 F 检验的等价性：**单变量时 $F = t^2$ ，两者给出相同的 p 值；多变量时 F 检验才有独特价值（联合检验一组系数）；
- (4) **“不显著”不等于“可删除”：** β_2 的 $p = 0.40$ ，但 CI 跨度从 -0.64 到 1.20——真值可能是 0，也可能是 1.0（一个不小的效应）——只是 $N = 6$ 让我们区分不了。

11.12 子集选择与系数收缩

前几节回答了“如何拟合线性模型”和“如何检验系数”。本节回答一个更根本的问题：**哪些变量应该留在模型里？**

11.12.1 为什么要超越最小二乘?

LS 估计 $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 有两个 实践中的不足:

- (1) **预测精度 (Prediction Accuracy)**: LS 估计无偏, 但方差可能很大——尤其当 p 较大或变量高度相关时。如果愿意牺牲一点无偏性 (引入偏差), 换取方差的大幅下降, 整体预测误差 (MSE) 可能更低:

$$\text{MSE} = \underbrace{\text{Bias}^2}_{\text{有偏} \Rightarrow \uparrow} + \underbrace{\text{Var}}_{\text{收缩} \Rightarrow \downarrow} + \sigma^2.$$

策略: 将某些系数向零收缩, 甚至直接置零。

- (2) **可解释性 (Interpretation)**: 预测变量太多时, 我们希望找出一个较小的子集, 展现“最强效应”。牺牲一些细节, 换来对大局的清晰理解。

解决方案三条路径:

- **子集选择 (Subset Selection)**: 只保留一部分变量, 其余丢弃 (本节);
- **收缩方法 (Shrinkage)**: 保留所有变量, 但把系数向零压缩 (§3.4, 岭回归/Lasso);
- **降维方法 (Dimension Reduction)**: 将原始变量投影到低维空间 (§3.5, PCR/PLS)。

11.12.2 最优子集选择 (Best-Subset Selection)

定义 11.20 (最优子集选择). 对每个 $k \in \{0, 1, 2, \dots, p\}$, 在所有 $\binom{p}{k}$ 个可能的 k 变量子集中, 找到使 RSS 最小的那个:

$$\mathcal{M}_k = \arg \min_{\text{含 } k \text{ 个变量的模型}} \text{RSS}.$$

算法: leaps and bounds 过程 (Furnival & Wilson, 1974) 使得 $p \leq 30 \sim 40$ 时计算可行。它高效地搜索所有子集而不必穷举。

关键性质:

- RSS 随 k 增大必然单调递减——变量越多, 拟合越好 (至少不更差);
- 因此 RSS 本身不能用来选 k (总是倾向于选全模型);
- 需要其他准则来平衡拟合优度与模型复杂度——交叉验证、AIC、BIC 等 (详见第 7 章);
- 通常选择使期望预测误差估计最小的最小模型。

11.12.3 逐步选择 (Stepwise Selection)

当 p 较大时, $\binom{p}{k}$ 的组合爆炸使得最优子集搜索不可行。逐步选择提供了一条计算上可行的“路径”。

前向逐步选择 (Forward-Stepwise)

第 1 步: 从仅含截距的模型开始;

第 2 步: 在所有不在模型中的变量中, 选择加入后 RSS 下降最多的那个, 将其加入;

第 3 步: 重复步骤 2, 直到模型包含 p 个变量 (或达到预设的 $k_{\max}$)。

特点:

- 贪心算法: 每一步只看眼前最优, 不保证全局最优;
- 嵌套序列: $\mathcal{M}_1 \subset \mathcal{M}_2 \subset \cdots \subset \mathcal{M}_p$;
- 计算高效: 利用 QR 分解的更新公式, 每一步只需很少的额外计算;
- 即使 $p \gg N$ 也能用 (而最优子集和向后选择在 $p > N$ 时不可用)。

后向逐步选择 (Backward-Stepwise)

第 1 步: 从全模型 (含所有 p 个变量) 开始;

第 2 步: 在模型当前的变量中, 选择删除后 RSS 增加最少的那个 (即 $|z|$ 值最小的变量), 将其删除;

第 3 步: 重复步骤 2, 直到模型只剩截距 (或达到预设的 $k_{\min}$)。

限制: 仅当 $N > p$ 时可用 (全模型需要 $\mathbf{X}^T \mathbf{X}$ 可逆)。

三种方法的比较

	最优子集	前向逐步	后向逐步
搜索方式	遍历所有 $\binom{p}{k}$	贪心前向添加	贪心后向删除
是否全局最优	✓	×	×
计算可行性	$p \leq 40$	任意 p (包括 $p \gg N$)	$N > p$
嵌套性	不一定	✓ 必然嵌套	✓ 必然嵌套
方差 vs 偏差	低偏差、高方差 (选择空间大)	较低方差、可能稍高偏差 (搜索受限)	介于两者之间

ESL 的模拟研究 (图 3.6, $N = 300$, $p = 31$, 变量间强相关) 表明: 三种方法的 MSE 曲线非常接近, 前向/后向逐步在实际中通常不输给最优子集太多。

关于基于 F 检验的逐步选择

传统软件包常用 F 检验来决定添加/删除变量 (“添加显著的, 删除不显著的”)。这种做法现在已不受推荐, 原因如下。

多重检验问题 (Multiple Testing) 假设有 $p = 20$ 个候选变量, 全都与 Y 无关。用 $\alpha = 0.05$ 逐个做 t 检验, 每个检验有 5% 的概率 “错误显著” (第一类错误)。20 次独立检验中, 至少一次假显著的概率为:

$$1 - (1 - 0.05)^{20} \approx 0.64.$$

64% 的概率会至少 “发现” 一个虚假的显著变量。而逐步回归在每一步都做检验, 整个过程相当于做了几十甚至几百次检验, 却完全不做任何多重性校正——整体的第一类错误率完全不可控。你 “显著” 的变量中可能有相当一部分纯属运气。

选择后偏倚 (Post-Selection Bias) 更隐蔽的问题是选择后偏倚。逐步选择用数据挑出了 “最好的” 变量子集, 然后用同一份数据报告这些变量的系数、标准误和 p 值。但这些数字已经被选择过程污染了:

- 你选出的正是那些 “看起来显著” 的变量 $\rightarrow$ 它们的 $\hat{\beta}_j$ 被系统性高估 (赢家诅咒);
- 标准误被系统性低估, 因为没有考虑 “我们是从一堆候选变量中挑出来的” 这个事实;
- p 值过于乐观——报告 $p = 0.01$ 的真实意义可能更接近 $p = 0.1$ 。

打个比方：你让 100 个人掷硬币，选出掷出 10 次正面的人，然后宣称“这个人的硬币不是公平的”——你没有考虑他是从 100 个人中**选出来的**。数据的同一个随机波动既被用于“选择他”，又被用于“检验他”——选择过程和推断过程用了同一份数据。

替代方案：

- 使用交叉验证或 AIC/BIC 选择模型大小（而非基于 p 值的阈值）；
- 使用 Lasso 或弹性网等收缩方法——连续收缩，无离散选择，自动避免选择后偏倚；
- 若必须在选择后做推断，可以用**数据分割**（只在训练集上选模型，只在验证集上做推断），或使用专门的**选择性推断 (selective inference)** 方法（如 `selectiveInference` R 包）；
- Bootstrap（第 8.2 节）可以部分校正选择带来的不确定性。

现代实践：收缩方法优于逐步选择 正因为上述问题，现代统计实践中：

- 做变量选择时，首选 **Lasso/弹性网 + 交叉验证**（R: `glmnet::cv.glmnet()`, Python: `sklearn.linear_model.LassoCV`），让 L_1 惩罚自动收缩/置零，看交叉验证误差曲线选 λ （推荐用 1-SE rule 取 `lambda.1se`）；
- 逐步选择（基于 AIC 的 `step()`）在探索性分析中仍有使用，但应被视为**模型建议**而非**统计推断**——不能信任其 p 值和标准误；
- 基于 p 值阈值的 add/drop 逐步选择（如 SPSS 的默认行为）应**避免使用**。

其他实践注意事项

- **分组变量：**哑变量编码的多水平分类变量应作为一个整体同时添加或删除，‘R’ 的 ‘`step()`’ 函数默认如此（按自由度整体处理）；
- **混合策略：**‘R’ 的 ‘`step()`’ 在每一步同时考虑前向和后向移动，选择使 AIC 最小的那一步——比纯前向/纯后向更灵活。

11.12.4 前向分段回归 (Forward-Stagewise Regression)

前向分段回归是比前向逐步**更加保守**的方法：

第 1 步： 所有系数初始化为 0，中心化所有预测变量；

第 2 步： 计算当前残差 $\mathbf{r} = \mathbf{y} - \hat{\mathbf{y}}$ ；

第 3 步： 找到与残差**相关性最大**的变量 $\mathbf{x}_j$ ；

第 4 步：将残差对 $\mathbf{x}_j$ 做单变量回归，得增量 $\delta_j = \langle \mathbf{x}_j, \mathbf{r} \rangle / \langle \mathbf{x}_j, \mathbf{x}_j \rangle$ ；

第 5 步：只更新 $\hat{\beta}_j \leftarrow \hat{\beta}_j + \delta_j$ ，其他系数不变；

第 6 步：重复步骤 2-5，直到所有变量与残差的相关性都低于阈值。

与前向逐步的关键区别：

- 前向逐步每次添加变量后，会重新调整所有已选变量的系数（做完整 LS）；
- 前向分段不调整其他变量——只对被选中的那个变量做一次单变量更新；
- 因此前向分段可能需要远超 p 步才能逼近 LS 解（ESL 的例子中超过 1000 步）。

为什么需要这么慢的方法？

- 在高维问题（ $p \gg N$ ）中，LS 甚至不存在唯一解；
- “慢拟合”相当于一种隐式的正则化——每步只走一点点，类似于梯度下降的小步长，避免过拟合；
- 与后续的 Lasso 和 LAR (§3.8) 有深刻联系。

11.12.5 小结：子集选择的统一视角

三种子集选择方法构成了一个约束强度递增的谱系：

方法	搜索空间	约束强度	适用场景
最优子集	所有 $\binom{p}{k}$ 子集	最弱	$p \leq 40$ ，追求最优
前向/后向逐步	序列化嵌套路径	中等	p 较大，计算均衡
前向分段	比逐步更慢、更受限	最强	高维（ $p \gg N$ ），隐式正则化

核心教训：

- 搜索空间越大 $\rightarrow$ 偏差越低、方差越高。限制搜索（前向逐步、前向分段）是一种用偏差换方差的策略——与收缩方法（岭回归/Lasso）殊途同归；
- 模型选择 $\neq$ 推断：选择后的标准误和 p 值不可信——模型选择是预测导向的工具，不是推断工具；
- 下一节 (§3.4) 将引入收缩方法——保留所有变量但压缩系数，用连续的惩罚代替离散的“选/不选”决策。

11.13 收缩方法 (Shrinkage Methods)

子集选择是离散的——变量要么在模型里，要么不在。这种“硬”决策导致高方差：数据稍有扰动，选出的子集可能完全不同。**收缩方法**用连续的方式替代离散选择：保留所有变量，但把系数向零压缩。

11.13.1 前列腺癌实例回顾

在进入方法细节之前，先看表 11.13.1 中所有方法的对比结果。表中展示了 LS、最优子集、岭回归、Lasso、主成分回归 (PCR) 和偏最小二乘 (PLS) 的估计系数和测试误差。

项	LS	最优子集	岭回归	Lasso	PCR	PLS
Intercept	2.465	2.477	2.452	2.468	2.497	2.452
lcavol	0.680	0.740	0.420	0.533	0.543	0.419
lweight	0.263	0.316	0.238	0.169	0.289	0.344
age	-0.141		-0.046		-0.152	-0.026
lbph	0.210		0.162	0.002	0.214	0.220
svi	0.305		0.227	0.094	0.315	0.243
lcp	-0.288		0.000		-0.051	0.079
gleason	-0.021		0.040		0.232	0.011
pgg45	0.267		0.133	-0.056	0.084	
测试误差	0.521	0.492	0.492	0.479	0.449	0.528
标准误	0.179	0.143	0.165	0.164	0.105	0.152

复杂度参数的选择：每种方法都有一个复杂度参数（子集大小 k 、惩罚 λ 、主成分个数等），通过**十折交叉验证 (10-fold CV)** 选择：将训练集随机分成 10 份，每次用 9 份训练、1 份验证，轮换 10 次取平均预测误差。选择一个**标准误规则 (one-standard-error rule)**：取在最小 CV 误差一个标准误以内的最简约模型。

关键观察：

- LS 的测试误差为 0.521；所有收缩方法都降低了测试误差；
- 最优子集只选了 lcavol 和 lweight 两个变量；
- 注意 LS 中 lcavol 系数最大 (0.680)，岭回归将其收缩到 0.420，Lasso 进一步收缩到 0.533——但都保留了它。

11.13.2 岭回归 (Ridge Regression)

定义与两种等价形式

岭回归在线性回归的 RSS 上增加一个系数的平方和惩罚：

定义 11.21 (岭回归——惩罚形式 (Lagrangian)).

$$\hat{\beta}^{\text{ridge}} = \arg \min_{\beta} \left\{ \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}. \quad (11.55)$$

其中 $\lambda \geq 0$ 是复杂度参数： λ 越大，收缩越强。

定义 11.22 (岭回归——约束形式). 等价地：

$$\hat{\beta}^{\text{ridge}} = \arg \min_{\beta} \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 \quad \text{s.t.} \quad \sum_{j=1}^p \beta_j^2 \leq t. \quad (11.56)$$

λ 与 t 一一对应： $\lambda = 0 \Leftrightarrow t = \infty$ (LS), $\lambda \rightarrow \infty \Leftrightarrow t \rightarrow 0$ (仅截距)。

注意：

- 截距 β_0 不参与惩罚。惩罚截距会使得模型依赖于 Y 的原点选择——给所有 y_i 加常数 c ，预测不应只平移 c ；
- 输入需标准化。惩罚 $\sum \beta_j^2$ 不是尺度不变的—— β_j 的大小依赖于 x_j 的单位。标准做法是将每个 x_j 中心化并缩放到单位方差后，用 $\bar{y}$ 估计 β_0 ，对中心化后的 $\mathbf{X}$ 做无截距岭回归。

矩阵形式与闭式解

中心化后，设 $\mathbf{X}$ 为 $N \times p$ (不含截距列， p 个变量均中心化)，岭回归准则为：

$$\text{RSS}(\lambda) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) + \lambda \boldsymbol{\beta}^\top \boldsymbol{\beta}. \quad (11.57)$$

求导并令其为零：

$$\boxed{\hat{\beta}^{\text{ridge}} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}}. \quad (11.58)$$

与 LS 的唯一区别：对角线上加了 λ 。这使得：

- 即使 $\mathbf{X}^\top \mathbf{X}$ 奇异 ($p > N$ 或完全共线性)， $(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})$ 总是可逆；
- 当 $\lambda = 0$ 时退化为 LS；
- $\hat{\beta}^{\text{ridge}}$ 仍然是 $\mathbf{y}$ 的线性函数。

贝叶斯解释

岭回归有自然的贝叶斯解读。假设：

$$y_i | \mathbf{x}_i, \boldsymbol{\beta}, \sigma^2 \sim \mathcal{N}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2), \quad \beta_j \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \tau^2).$$

则 $\boldsymbol{\beta}$ 的（负对数）后验密度正比于：

$$\frac{1}{\sigma^2} \sum_{i=1}^N (y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 + \frac{1}{\tau^2} \sum_{j=1}^p \beta_j^2.$$

这恰好是岭回归准则 (11.55)，其中 $\lambda = \sigma^2/\tau^2$ 。因此：**岭估计 = 高斯先验 $\mathcal{N}(0, \tau^2)$ 下的后验众数（也是后验均值）**。 τ^2 越大（先验越扩散） $\rightarrow \lambda$ 越小 $\rightarrow$ 越接近 LS。

11.13.3 岭回归的 SVD 视角

对中心化后的 $\mathbf{X}$ 做奇异值分解 (SVD)，可以最深刻地理解岭回归在做什么。

定义 11.23 (SVD of $\mathbf{X}$).

$$\underset{N \times p}{\mathbf{X}} = \underset{N \times p}{\mathbf{U}} \underset{p \times p}{\mathbf{D}} \underset{p \times p}{\mathbf{V}}^\top, \quad (11.59)$$

其中：

- $\mathbf{U}$ ($N \times p$): 列正交 ($\mathbf{U}^\top \mathbf{U} = \mathbf{I}$)，列空间 = $\mathbf{X}$ 的列空间；
- $\mathbf{V}$ ($p \times p$): 正交 ($\mathbf{V}^\top \mathbf{V} = \mathbf{V} \mathbf{V}^\top = \mathbf{I}$)；
- $\mathbf{D}$ ($p \times p$): 对角阵， $d_1 \geq d_2 \geq \dots \geq d_p \geq 0$ 为**奇异值**。

LS 的 SVD 表示

利用 SVD，LS 的拟合值可写为：

$$\mathbf{X} \hat{\boldsymbol{\beta}}^{\text{ls}} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \mathbf{U} \mathbf{U}^\top \mathbf{y} = \sum_{j=1}^p \mathbf{u}_j (\mathbf{u}_j^\top \mathbf{y}). \quad (11.60)$$

$\mathbf{u}_j^\top \mathbf{y}$ 是 $\mathbf{y}$ 在正交基 $\mathbf{u}_j$ 上的坐标；LS 不做任何收缩——直接将 $\mathbf{y}$ 投影到 $\mathbf{U}$ 的列空间。

岭回归的 SVD 表示

代入岭回归解：

$$\begin{aligned} \mathbf{X} \hat{\boldsymbol{\beta}}^{\text{ridge}} &= \mathbf{X}(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y} \\ &= \mathbf{U} \mathbf{D} (\mathbf{D}^2 + \lambda \mathbf{I})^{-1} \mathbf{D} \mathbf{U}^\top \mathbf{y} \\ &= \sum_{j=1}^p \mathbf{u}_j \underbrace{\frac{d_j^2}{d_j^2 + \lambda}}_{\text{收缩因子}} (\mathbf{u}_j^\top \mathbf{y}). \end{aligned} \quad (11.61)$$

核心洞察：

- 岭回归和 LS 使用同一个正交基 $\mathbf{U}$;
- 区别在于每个方向上乘以了收缩因子 $\frac{d_j^2}{d_j^2 + \lambda} \leq 1$;
- d_j^2 大 (高方差方向) $\rightarrow$ 收缩因子接近 1 $\rightarrow$ 几乎不收缩;
- d_j^2 小 (低方差方向) $\rightarrow$ 收缩因子接近 0 $\rightarrow$ 大量收缩。

追问：为什么 d_j^2 大就是“高方差方向”？

这要从 SVD 与 PCA 的联系来理解。 $\mathbf{X}$ 是中心化后的设计矩阵，其 (缩放) 协方差矩阵为 $\frac{1}{N}\mathbf{X}^\top\mathbf{X}$ 。对 $\mathbf{X}^\top\mathbf{X}$ 做特征分解：

$$\mathbf{X}^\top\mathbf{X} = \mathbf{V}\mathbf{D}^2\mathbf{V}^\top.$$

$\mathbf{V}$ 的列 $\mathbf{v}_j$ 是特征向量 (主成分方向)，对角阵 $\mathbf{D}^2$ 的对角元 d_j^2 是特征值。

现在看投影 $\mathbf{z}_j = \mathbf{X}\mathbf{v}_j$ (第 j 个主成分得分)。由 SVD $\mathbf{X} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$ 得：

$$\mathbf{z}_j = \mathbf{X}\mathbf{v}_j = \mathbf{U}\mathbf{D}\mathbf{V}^\top\mathbf{v}_j = \mathbf{U}\mathbf{D}\mathbf{e}_j = \mathbf{u}_jd_j.$$

这个投影的样本方差为：

$$\text{Var}(\mathbf{z}_j) = \frac{1}{N}\mathbf{z}_j^\top\mathbf{z}_j = \frac{1}{N}(\mathbf{u}_jd_j)^\top(\mathbf{u}_jd_j) = \frac{d_j^2}{N}.$$

追问：为什么 $\text{Var}(\mathbf{z}_j) = \frac{1}{N}\mathbf{z}_j^\top\mathbf{z}_j$ ？向量方差的定义是什么？

$\mathbf{z}_j = (z_{1j}, z_{2j}, \dots, z_{Nj})^\top$ 是一个 N 维向量，每个分量 z_{ij} 是第 i 个观测在第 j 个主成分上的得分。

N 个标量 $\{z_{1j}, \dots, z_{Nj}\}$ 的样本方差定义为：

$$\text{Var}(\mathbf{z}_j) = \frac{1}{N} \sum_{i=1}^N (z_{ij} - \bar{z}_j)^2.$$

关键： $\mathbf{X}$ 已经中心化 (每列均值为 0)，而 $\mathbf{z}_j = \mathbf{X}\mathbf{v}_j$ 是中心化列的一个线性组合，因此 $\bar{z}_j = 0$ 。于是：

$$\text{Var}(\mathbf{z}_j) = \frac{1}{N} \sum_{i=1}^N z_{ij}^2 = \frac{1}{N} \mathbf{z}_j^\top\mathbf{z}_j.$$

(严格来说，无偏样本方差用 $N-1$ 。这里用 $1/N$ 是 ESL 的约定——将 $\frac{1}{N}\mathbf{X}^\top\mathbf{X}$ 视作协方差矩阵的估计， d_j^2/N 视作该方向的方差估计。用 N 还是 $N-1$ 只差一个常数因子，不影响 PCA 方向的排序。)

所以： d_j^2 直接正比于第 j 个主成分方向的投影方差。 $d_1^2 \geq d_2^2 \geq \dots \geq d_p^2$ 意味着第一主成分捕获了最多的数据变异，最后一主成分变异最小。

回到岭回归：收缩因子 $\frac{d_j^2}{d_j^2 + \lambda}$ 的意思是——数据在某个方向上散布得越开 (d_j^2 越大)，我们越信任该方向的 LS 估计，收缩越少；散布得越窄 (d_j^2 越小)，该方向的估计越不可靠 (方差大)，收缩越多。这就是岭回归保护我们不被低方差方向上不可靠的梯度估计所伤害的机制。

11.13.4 主成分与方差方向

SVD 中的 $\mathbf{V}$ 和 $\mathbf{D}$ 与 $\mathbf{X}$ 的主成分分析 (PCA) 密切相关。样本协方差矩阵的特征分解为:

$$\mathbf{X}^\top \mathbf{X} = \mathbf{V} \mathbf{D}^2 \mathbf{V}^\top. \quad (11.62)$$

$\mathbf{v}_j$ ($\mathbf{V}$ 的第 j 列) 是第 j 个主成分方向。投影 $\mathbf{z}_j = \mathbf{X} \mathbf{v}_j = \mathbf{u}_j d_j$ 是第 j 个主成分, 其方差为 $\text{Var}(\mathbf{z}_j) = d_j^2/N$ 。

- **第一主成分:** 投影方差最大 (d_1^2/N) 的方向;
- **最后一主成分:** 投影方差最小的方向。

岭回归的隐含假设: 响应 Y 倾向于在输入的高方差方向上变化最多。这在实践中常常成立 (预测变量之所以被选中, 正是因为它们与响应有关), 但不是必然。

11.13.5 有效自由度

岭回归虽然估计了 p 个系数, 但由于 λ 的约束, **有效自由度** 小于 p :

$$\text{df}(\lambda) = \text{tr}(\mathbf{H}_\lambda) = \text{tr}(\mathbf{X}(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top) = \sum_{j=1}^p \frac{d_j^2}{d_j^2 + \lambda}. \quad (11.63)$$

- $\lambda = 0$: $\text{df} = p$ (无正则化, 每个变量贡献 1 个自由度);
- $\lambda \rightarrow \infty$: $\text{df} \rightarrow 0$ (所有系数被压缩到零, 只剩截距);
- $\text{df}(\lambda)$ 是 λ 的单调递减函数。

在交叉验证中, 通常将误差曲线画成 $\text{df}(\lambda)$ 的函数 (而非 λ 本身), 因为这在不同方法间具有可比性。

11.13.6 Lasso

定义

Lasso (Least Absolute Shrinkage and Selection Operator) 将岭回归的 L_2 惩罚替换为 L_1 惩罚:

定义 11.24 (Lasso——约束形式).

$$\hat{\boldsymbol{\beta}}^{\text{lasso}} = \arg \min_{\boldsymbol{\beta}} \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 \quad \text{s.t.} \quad \sum_{j=1}^p |\beta_j| \leq t. \quad (11.64)$$

定义 11.25 (Lasso——Lagrangian 形式).

$$\hat{\boldsymbol{\beta}}^{\text{lasso}} = \arg \min_{\boldsymbol{\beta}} \left\{ \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}. \quad (11.65)$$

Lasso 与岭回归的本质区别

	岭回归 (L_2)	Lasso (L_1)
惩罚	$\sum \beta_j^2$	$\sum \beta_j $
解的闭式	✓ $\hat{\beta} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}$	× 需迭代算法
对 $\mathbf{y}$ 的线性性	✓ 线性	× 非线性
稀疏性	× 系数都非零	✓ 可将系数精确压缩到 0
变量选择	×	✓ 自带变量选择功能
几何形状	球形约束域	菱形约束域（有尖角）

Lasso 为何能得到零系数？关键在于 L_1 约束域的尖角。RSS 的等高线（椭圆）与菱形约束域的接触点最容易落在坐标轴上（即某些 $\beta_j = 0$ ）。而球形约束域（ L_2 ）与椭圆的切点几乎总在内部，所有系数非零。

一句话：岭回归把大系数压小，Lasso 把小系数压到零。因此 Lasso 同时做了收缩 + 变量选择，而岭回归只做收缩。

11.13.7 正交输入情形下的统一视角

当输入矩阵 $\mathbf{X}$ 的列彼此正交时（ $\mathbf{X}^\top \mathbf{X} = \mathbf{I}$ ），三种方法都有显式解。设 $\hat{\beta}_j^{\text{LS}}$ 为 LS 估计，则：

方法	公式	操作
最优子集 (size M)	$\hat{\beta}_j \cdot I(\hat{\beta}_j \geq \hat{\beta}_{(M)})$	硬阈值：保留最大的 M 个，其余置零
岭回归	$\hat{\beta}_j / (1 + \lambda)$	比例收缩：所有系数等比缩放
Lasso	$\text{sign}(\hat{\beta}_j)(\hat{\beta}_j - \lambda)_+$	软阈值：向零平移 λ ，过零则截断

其中 $x_+ = \max(x, 0)$ 表示“正部”。这揭示了三个方法的本质：

- **岭回归：**均匀收缩，无一为零——“大家都少一点”；
- **Lasso：**软阈值——“不够强的直接清零，够强的减去一个常数”；
- **最优子集：**硬阈值——“只留前 M 名，其余全砍”。

在非正交情形下，没有如此简洁的显式解，但几何直觉仍然成立。




图 11.1: 三种收缩方法的可视化比较。灰色 45° 线为 OLS 基准（无收缩）；红色虚线分别为最优子集（硬阈值）、岭回归（比例收缩）和 Lasso（软阈值）。横轴为 OLS 估计 $\hat{\beta}_j^{\text{ls}}$ ，纵轴为各方法的估计值。

11.13.8 几何直观： $p = 2$ 时的图形比较

图 3.11 是理解 Lasso 与岭回归差异的最经典图示。考虑 $p = 2$ （两个预测变量）：

- **RSS 等高线**：以 LS 估计 $\hat{\beta}^{\text{ls}}$ 为中心的椭圆；
- **岭回归约束域**：圆盘 $\beta_1^2 + \beta_2^2 \leq t$ （光滑边界）；
- **Lasso 约束域**：菱形 $|\beta_1| + |\beta_2| \leq t$ （有四个尖角）。

两种方法都在寻找 RSS 等高线首次触及约束域边界的那一点。

关键差异：

- 圆盘没有角落 $\rightarrow$ 切点几乎总在弧上 $\rightarrow \beta_1 \neq 0$ 且 $\beta_2 \neq 0$ ；
- 菱形有尖角 $\rightarrow$ 如果切点落在角上（如 β_1 轴上），则 $\beta_2 = 0$ 。

当 $p > 2$ 时，约束域变为菱形体 (rhomboid)，有大量的角、棱和面——因此 Lasso 有很多机会将某些系数精确置零。

图中三种元素的含义（逐层解读）

为彻底理解这张图，把图中的元素拆成三层来看：

1. 红色同心椭圆——RSS 等高线

$$\text{RSS}(\beta) = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta)$$

- 椭圆中心 $\hat{\beta}^{\text{ls}}$ 是无约束最小二乘解——RSS 的全局最小值点。
- 每一条椭圆线代表 RSS 取某一固定值；越靠近中心 RSS 越小，越远离 RSS 越大。
- 如果没有约束，最优解就是椭圆中心本身。

2. 蓝色区域——约束范围（可行域）

	Lasso（左图）	Ridge（右图）
约束形式	$ \beta_1 + \beta_2 \leq t$	$\beta_1^2 + \beta_2^2 \leq t^2$
几何形状	菱形（ L_1 球）	圆形（ L_2 球）
边界特征	有四个尖角（在坐标轴上）	处处光滑，没有尖角

参数必须在蓝色区域内部（或边界上）取值——这是正则化施加的硬约束。

3. 最优解：椭圆首次碰到蓝色区域的那个点

约束优化问题等价于从椭圆中心出发，逐步扩大 RSS 椭圆的半径。椭圆扩大的过程中，第一次触碰到蓝色区域边界的那个点，就是约束下的最优解 $\hat{\beta}^{\text{constrained}}$ 。

为什么 Lasso 产生零系数而 Ridge 不能？

关键全在尖角上：

- **Lasso (菱形)：**菱形在坐标轴上有四个尖角，例如 $(\beta_1, 0)$ 或 $(0, \beta_2)$ 。当 RSS 椭圆向外扩展时，**极易先碰到尖角**——此时交点恰好落在坐标轴上，意味着其中一个参数被精确压到 0。
- **Ridge (圆形)：**圆形处处光滑。RSS 椭圆与圆的切点几乎总在弧的内部——两坐标均非零。系数被压缩，但**从不精确为零**。

一句话总结：

Lasso 的 L_1 约束域有尖角，

RSS 椭圆碰到尖角时就自动做了变量选择——不重要的系数精确置零。

当 $p \gg 2$ 时， L_1 约束域变为高维菱形体，拥有大量的角、棱和面，Lasso 有更多机会将不重要的系数精确置零——这就是它的高维问题中表现优异的原因。

11.13.9 一般 L_q 惩罚与贝叶斯统一视角

三种方法可以纳入一个统一的 L_q 惩罚框架：

$$\tilde{\beta} = \arg \min_{\beta} \left\{ \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \sum_{j=1}^p |\beta_j|^q \right\}, \quad q \geq 0. \quad (11.66)$$

不同 q 值对应不同方法：

q	方法	先验分布	约束域形状
0	最优子集	尖峰-平板 (spike-and-slab)	计数惩罚 (非凸)
1	Lasso	拉普拉斯 (双指数)	菱形 (凸)
2	岭回归	高斯	球 (凸)

贝叶斯解读：将 $\sum |\beta_j|^q$ 视为 β_j 的负对数先验密度，则：

- $q = 2$ ：高斯先验 $\beta_j \sim \mathcal{N}(0, \tau^2)$ ， $\lambda = \sigma^2/\tau^2$ ；
- $q = 1$ ：拉普拉斯先验 $p(\beta_j) = \frac{1}{2\tau} \exp(-|\beta_j|/\tau)$ ， $\tau = 1/\lambda$ ；
- $q < 1$ ：先验在坐标轴方向上集中更多质量——更容易产生零系数。

推导：从最大后验 (MAP) 到正则化

考虑线性模型 $y_i = \beta_0 + \sum_j x_{ij}\beta_j + \varepsilon_i$, $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ 。似然函数为：

$$p(\mathbf{y} | \boldsymbol{\beta}) \propto \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij}\beta_j\right)^2\right).$$

为 β_j 引入独立先验 $p(\beta_j) \propto \exp(-|\beta_j|^q/\tau)$ 。由贝叶斯定理，后验：

$$p(\boldsymbol{\beta} | \mathbf{y}) \propto p(\mathbf{y} | \boldsymbol{\beta}) \cdot \prod_{j=1}^p p(\beta_j).$$

取负对数，最大化后验 (MAP) 等价于最小化：

$$-\log p(\boldsymbol{\beta} | \mathbf{y}) = \underbrace{\frac{1}{2\sigma^2} \sum_{i=1}^N \left(y_i - \beta_0 - \sum_j x_{ij}\beta_j\right)^2}_{\text{RSS} / 2\sigma^2} + \underbrace{\frac{1}{\tau} \sum_{j=1}^p |\beta_j|^q}_{\text{负对数先验}} + \text{const.}$$

乘以 $2\sigma^2$ ，令 $\lambda = 2\sigma^2/\tau$ ，即得：

$$\hat{\boldsymbol{\beta}}^{\text{MAP}} = \arg \min_{\boldsymbol{\beta}} \left\{ \text{RSS} + \lambda \sum_{j=1}^p |\beta_j|^q \right\}$$

这就是正则化框架：惩罚系数 λ 本质上编码了先验强度 (τ 小 $\Rightarrow \lambda$ 大 $\Rightarrow$ 先验强 $\Rightarrow$ 强收缩)。

为什么 $q = 2$ 对应高斯， $q = 1$ 对应拉普拉斯？

核心对应关系： L_q 惩罚 $\leftrightarrow$ 指数幂分布族

$$p(\beta) \propto \exp(-|\beta|^q/\tau)$$

具体展开：

q	先验密度形式	分布名称	在 0 处的形状
2	$p(\beta) \propto \exp\left(-\frac{\beta^2}{2\tau^2}\right)$	$\mathcal{N}(0, \tau^2)$ (高斯)	光滑抛物线，可微
1	$p(\beta) \propto \exp\left(-\frac{ \beta }{\tau}\right)$	Laplace(0, τ) (拉普拉斯/双指数)	尖峰，在 0 处不可微
0	$p(\beta)$ 为 0 处点质量 + 平坦尾部的混合	尖峰-平板 (spike-and-slab)	极端集中

几何直觉：为什么拉普拉斯先验导致稀疏？

- **高斯先验** ($q = 2$)：在 $\beta_j = 0$ 附近光滑、平缓——先验并不特别偏爱零值，后验众数几乎不会精确落在 0 上。
- **拉普拉斯先验** ($q = 1$)：在 $\beta_j = 0$ 处有一个**尖峰**——先验强烈倾向于零。只要数据没有压倒性证据，MAP 估计就会精确落在 0。

换个角度：拉普拉斯分布的尾部比高斯更重——如果 β_j 真的非零，它允许系数取到较大值而不被过度惩罚。这正是 Lasso 的优势：**对小系数”赶尽杀绝”（压到 0），对大系数”网开一面”（只减去常数 λ ）。**

注意：以上都是后验众数（mode）。岭回归同时也是后验均值（因为高斯后验对称），但 Lasso 和最优子集的后验均值不等于后验众数。

为什么 $q = 1$ 是”神奇”的值？

- $q = 1$ 是使得约束域**凸**的最小 q ($q < 1$ 时为非凸，优化困难)；
- $q = 1$ 是使得约束域在坐标轴上有**尖角**的最大 q ($q > 1$ 时在零点可微，无尖角 $\rightarrow$ 无稀疏性)。

因此 $q = 1$ 是唯一同时满足**凸性**（易于优化）+ **稀疏性**（可产生零系数）的值。

11.13.10 弹性网 (Elastic Net)

$q \in (1, 2)$ 的 L_q 惩罚是岭回归和 Lasso 的折中，但在零点处可微（无尖角），因此不能产生稀疏解。Zou & Hastie (2005) 提出了弹性网惩罚：

$$\lambda \sum_{j=1}^p \left(\alpha \beta_j^2 + (1 - \alpha) |\beta_j| \right). \quad (11.67)$$

弹性网 = 岭回归 (L_2) + Lasso (L_1) 的**凸组合**，通过 $\alpha \in [0, 1]$ 调节两者权重：

- $\alpha = 0$ ：退化为 Lasso；
- $\alpha = 1$ ：退化为岭回归；
- 中间值：同时具备两者的优点。

弹性网的优势：

- **变量选择**： L_1 部分保留尖角 $\rightarrow$ 可产生稀疏解，像 Lasso；
- **处理相关变量**： L_2 部分使高度相关的变量系数被一起收缩，像岭回归；
- **计算优势**：比一般的 L_q ($1 < q < 2$) 更容易优化；
- **高维适用**：当 $p \gg N$ 时，Lasso 最多选 N 个变量，弹性网可以选更多。

11.13.11 最小角回归 (LAR)——Lasso 的高效算法

Lasso 没有闭式解，如何高效计算整个解路径（随 λ 变化的所有 $\hat{\beta}^{\text{lasso}}$ ）？答案是最小角回归 (Least Angle Regression, LAR) (Efron et al., 2004)。

与前向逐步的对比

- **前向逐步**：每次选出与残差最相关的变量，然后完全拟合该变量（调整到 LS 值），再找下一个变量。偏好过于激进——一旦加入就“吃饱”；
- **LAR**：每次选出与残差最相关的变量，但只让它的系数沿 LS 方向移动，直到另一个变量与残差的相关性追上来。然后两者一起移动，保持相关性相等。这是一种“民主”的前向逐步——每个变量只得到它“应得”的那份。

算法直觉

第 1 步：所有系数初始化为 0，残差 $\mathbf{r} = \mathbf{y} - \bar{y}$ ；

第 2 步：找到与 $\mathbf{r}$ 最相关的变量 $\mathbf{x}_{j_1}$ ；

第 3 步：将 $\hat{\beta}_{j_1}$ 从 0 向 LS 方向移动。随 $\hat{\beta}_{j_1}$ 增大， $\mathbf{x}_{j_1}$ 与残差的相关性逐渐下降；

第 4 步：当某个其他变量 $\mathbf{x}_{j_2}$ 与残差的相关性追上来（等于 $\mathbf{x}_{j_1}$ 的），将其加入活跃集；

第 5 步：现在同时移动 $\hat{\beta}_{j_1}$ 和 $\hat{\beta}_{j_2}$ ，保持两者与残差的相关性相等且逐步减小；

第 6 步：重复，直到所有变量都进入模型（或残差为 0）。

与 Lasso 的深刻联系：LAR 稍加修改（当一个系数穿过零时从活跃集中移除该变量），就精确等价于 Lasso 的解路径。因此 LAR 提供了一种计算整个 Lasso 路径的高效方法——计算量与单次 LS 拟合相当。

11.13.12 小结：收缩方法谱系

	子集选择	岭回归	Lasso
操作方式	/		+
解的线性性	×	✓	×
稀疏性	✓	×	✓
变量选择	✓	×	✓
方差			
偏差			
高维适用	p	✓	✓
贝叶斯解释	(<i>spike</i>)		

核心教训：

- 子集选择的离散性导致高方差——数据微小扰动可能选出完全不同的子集；
- 岭回归通过 L_2 惩罚连续收缩，方差低但无稀疏性；
- Lasso 通过 L_1 惩罚同时实现收缩和变量选择——是现代高维统计的基准方法；
- 正交情形下三者有统一显式解：硬阈值 / 比例收缩 / 软阈值；
- LAR 为 Lasso 提供了高效的计算路径——增量式地、“民主”地添加变量；
- 弹性网结合 $L_1 + L_2$ ，在有相关变量和高维场景下优于纯 Lasso。

11.14 使用导出输入方向的方法 (Derived Input Directions)

前两节（子集选择和收缩方法）通过控制系数来正则化。另一种思路是：先把原始变量降维，在低维空间做回归。这是一种“先压缩、再回归”的策略。

11.14.1 主成分回归 (PCR)

定义 11.26 (主成分回归). PCR 的执行步骤：

第 1 步：对 $\mathbf{X}$ （中心化后）做 PCA，取前 M 个主成分 $\mathbf{z}_1, \dots, \mathbf{z}_M$ ；

第 2 步：将 $\mathbf{y}$ 对 $\mathbf{z}_1, \dots, \mathbf{z}_M$ 做普通最小二乘。

关键特征：

- 主成分 $\mathbf{z}_m = \mathbf{X}\mathbf{v}_m$ 的选择只依赖 $\mathbf{X}$ ，不依赖 $\mathbf{y}$ ；
- PCR 丢弃了低方差方向——这些方向上信噪比通常最差；
- 但与 PLS 不同，PCR 不考虑 $\mathbf{y}$ ——高方差方向不一定预测力强。

11.14.2 偏最小二乘 (PLS)

PLS 的思想是：在构造降维方向时同时考虑 $\mathbf{x}$ 的方差和与 $\mathbf{y}$ 的相关性。

定义 11.27 (PLS 算法 (Algorithm 3.3)). 第 1 步： 标准化所有 $\mathbf{x}_j$ (均值 0, 方差 1), 设 $\hat{\mathbf{y}}^{(0)} = \bar{y}\mathbf{1}$;

第 2 步： 对 $m = 1, 2, \dots, p$:

- (a) $\mathbf{z}_m = \sum_{j=1}^p \hat{\phi}_{mj} \mathbf{x}_j^{(m-1)}$, 其中 $\hat{\phi}_{mj} = \langle \mathbf{x}_j^{(m-1)}, \mathbf{y} \rangle$;
- (b) $\hat{\theta}_m = \langle \mathbf{z}_m, \mathbf{y} \rangle / \langle \mathbf{z}_m, \mathbf{z}_m \rangle$;
- (c) $\hat{\mathbf{y}}^{(m)} = \hat{\mathbf{y}}^{(m-1)} + \hat{\theta}_m \mathbf{z}_m$;
- (d) 将每个 $\mathbf{x}_j^{(m-1)}$ 关于 $\mathbf{z}_m$ 正交化: $\mathbf{x}_j^{(m)} = \mathbf{x}_j^{(m-1)} - [\langle \mathbf{z}_m, \mathbf{x}_j^{(m-1)} \rangle / \langle \mathbf{z}_m, \mathbf{z}_m \rangle] \mathbf{z}_m$.

第 3 步： 输出拟合序列 $\{\hat{\mathbf{y}}^{(m)}\}_{m=1}^p$.

PLS 与 PCR 的核心区别：

- **PCR**: 选择方向只最大化 $\text{Var}(\mathbf{X}\boldsymbol{\alpha})$ (不管 $\mathbf{y}$);
- **PLS**: 选择方向最大化 $\text{Corr}^2(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha}) \cdot \text{Var}(\mathbf{X}\boldsymbol{\alpha})$ (同时考虑方差和相关性)。

实证研究表明: PLS 中方差项倾向于占主导地位, 因此 PLS 的表现与岭回归和 PCR 非常相似。Frank & Friedman (1993) 结论: 就最小化预测误差而言, 岭回归通常优于变量子集选择、PCR 和 PLS, 但优势仅略微。

有趣的事实: 如果 $\mathbf{X}$ 的列正交, PLS 在 $m = 1$ 步后就得到 LS 解——后续步骤没有效果 (因为 $\hat{\phi}_{mj} = 0, m > 1$)。PLS 系数序列 $m = 1, 2, \dots, p$ 恰好是计算 LS 解的共轭梯度序列。

11.14.3 PCR 与 PLS 的优化问题

第 m 个 PCR 方向 $\mathbf{v}_m$ 求解:

$$\max_{\boldsymbol{\alpha}} \text{Var}(\mathbf{X}\boldsymbol{\alpha}) \quad \text{s.t.} \quad \|\boldsymbol{\alpha}\| = 1, \quad \boldsymbol{\alpha}^\top \mathbf{S}\mathbf{v}_\ell = 0, \quad \ell = 1, \dots, m-1. \quad (11.68)$$

第 m 个 PLS 方向 $\hat{\phi}_m$ 求解:

$$\max_{\boldsymbol{\alpha}} \text{Corr}^2(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha}) \cdot \text{Var}(\mathbf{X}\boldsymbol{\alpha}) \quad \text{s.t.} \quad \|\boldsymbol{\alpha}\| = 1, \quad \boldsymbol{\alpha}^\top \mathbf{S}\hat{\phi}_\ell = 0, \quad \ell = 1, \dots, m-1. \quad (11.69)$$

11.14.4 深入理解 PLS：正交投影、实例与动机

从正交投影看 PLS

PLS 的每一步本质上在做两件事：**投影** + **剔除**。理解它的关键是把它和 Gram-Schmidt 正交化做类比。

回顾 Gram-Schmidt（纯 $\mathbf{X}$ 视角）：

给定向量 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_p$ ，Gram-Schmidt 依次构造正交基：

$$\mathbf{z}_1 = \mathbf{x}_1, \quad \mathbf{z}_2 = \mathbf{x}_2 - \frac{\langle \mathbf{z}_1, \mathbf{x}_2 \rangle}{\langle \mathbf{z}_1, \mathbf{z}_1 \rangle} \mathbf{z}_1, \quad \mathbf{z}_3 = \mathbf{x}_3 - \frac{\langle \mathbf{z}_1, \mathbf{x}_3 \rangle}{\langle \mathbf{z}_1, \mathbf{z}_1 \rangle} \mathbf{z}_1 - \frac{\langle \mathbf{z}_2, \mathbf{x}_3 \rangle}{\langle \mathbf{z}_2, \mathbf{z}_2 \rangle} \mathbf{z}_2, \quad \dots$$

每一步把新向量投影到前面所有 $\mathbf{z}$ 的正交补上——提取“前面还没用过的信息”。

PLS 的投影逻辑（ $\mathbf{X} + \mathbf{y}$ 联合视角）：

PLS 把同样的正交化思想用在 $\mathbf{X}$ 上，但顺序由 $\mathbf{y}$ 来定：

第 m 步的核心操作：

- (1) **选方向权重**：计算每个 $\mathbf{x}_j^{(m-1)}$ （经前面 $m-1$ 步正交化后的残差变量）与 $\mathbf{y}$ 的内积： $\hat{\phi}_{mj} = \langle \mathbf{x}_j^{(m-1)}, \mathbf{y} \rangle$ 。这是 $\mathbf{x}_j^{(m-1)}$ 与 $\mathbf{y}$ 的协方差（在零均值下）。
- (2) **构造方向**： $\mathbf{z}_m = \sum_j \hat{\phi}_{mj} \mathbf{x}_j^{(m-1)}$ ，相当于把当前所有“剩余变量”按它们与 $\mathbf{y}$ 的协方差加权组合成新方向。
- (3) **$\mathbf{y}$ 对 $\mathbf{z}_m$ 投影**： $\hat{\theta}_m = \langle \mathbf{z}_m, \mathbf{y} \rangle / \langle \mathbf{z}_m, \mathbf{z}_m \rangle$ ，这就是 $\mathbf{y}$ 在 $\mathbf{z}_m$ 上的最小二乘回归系数（无截距）。更新拟合： $\hat{\mathbf{y}}^{(m)} = \hat{\mathbf{y}}^{(m-1)} + \hat{\theta}_m \mathbf{z}_m$ 。
- (4) **剔除已用信息**：将每个 $\mathbf{x}_j^{(m-1)}$ 对 $\mathbf{z}_m$ 做正交投影，去掉 $\mathbf{z}_m$ 分量：

$$\mathbf{x}_j^{(m)} = \mathbf{x}_j^{(m-1)} - \frac{\langle \mathbf{z}_m, \mathbf{x}_j^{(m-1)} \rangle}{\langle \mathbf{z}_m, \mathbf{z}_m \rangle} \mathbf{z}_m.$$

这一步保证 $\mathbf{z}_{m+1}$ （下一轮构造的方向）与 $\mathbf{z}_m$ 正交。

一句话理解：PLS = Gram-Schmidt 正交化，但每次选哪个变量先做，由“谁和 $\mathbf{y}$ 协方差大”来决定，而非由“谁方差大”来决定。

投影矩阵视角：

由于 $\mathbf{z}_m$ 是 $\mathbf{x}_j^{(m-1)}$ 的线性组合，而 $\mathbf{x}_j^{(m-1)}$ 本身是原始 $\mathbf{X}$ 的线性组合（经过 $m-1$ 次正交化），所以 $\mathbf{z}_m$ 最终是 $\mathbf{X}$ 的线性组合：

$$\mathbf{z}_m = \mathbf{X} \mathbf{w}_m,$$

其中 $\mathbf{w}_m$ 可由 PLS 权重反向推导。所有 $\mathbf{z}_1, \dots, \mathbf{z}_M$ 张成的子空间是 $\mathbf{X}$ 列空间的子空间。最终的拟合 $\hat{\mathbf{y}}^{(M)}$ 是 $\mathbf{y}$ 在这个子空间上的投影。

完整数值例子

下面用一个极简数据集 ($N = 4, p = 2$) 手动走一遍 PLS。

i	y_i	x_{i1}	x_{i2}
1	3	1	2
2	5	2	2
3	7	3	5
4	9	4	3

第 0 步：标准化。

中心化：

$$\bar{y} = 6, \quad \bar{x}_1 = 2.5, \quad \bar{x}_2 = 3.0.$$

$$\mathbf{y}^{(0)} = \begin{pmatrix} -3 \\ -1 \\ 1 \\ 3 \end{pmatrix}, \quad \mathbf{x}_1^{(0)} = \begin{pmatrix} -1.5 \\ -0.5 \\ 0.5 \\ 1.5 \end{pmatrix}, \quad \mathbf{x}_2^{(0)} = \begin{pmatrix} -1 \\ -1 \\ 2 \\ 0 \end{pmatrix}.$$

缩放到单位范数 ($\|\mathbf{x}_j\| = 1$):

$$\|\mathbf{x}_1^{(0)}\| = \sqrt{1.5^2 + 0.5^2 + 0.5^2 + 1.5^2} = \sqrt{5} \approx 2.236, \quad \|\mathbf{x}_2^{(0)}\| = \sqrt{1^2 + 1^2 + 2^2 + 0^2} = \sqrt{6} \approx 2.449.$$

$$\mathbf{x}_1^{(0)} \leftarrow \frac{1}{\sqrt{5}} \begin{pmatrix} -1.5 \\ -0.5 \\ 0.5 \\ 1.5 \end{pmatrix}, \quad \mathbf{x}_2^{(0)} \leftarrow \frac{1}{\sqrt{6}} \begin{pmatrix} -1 \\ -1 \\ 2 \\ 0 \end{pmatrix}.$$

$$\hat{\mathbf{y}}^{(0)} = \bar{y} \mathbf{1} = (6, 6, 6, 6)^\top.$$

第 1 步 ($m = 1$):

(a) 计算权重：

$$\hat{\phi}_{11} = \langle \mathbf{x}_1^{(0)}, \mathbf{y}^{(0)} \rangle = \frac{(-1.5)(-3) + (-0.5)(-1) + 0.5 \cdot 1 + 1.5 \cdot 3}{\sqrt{5}} = \frac{4.5 + 0.5 + 0.5 + 4.5}{\sqrt{5}} = \frac{10}{\sqrt{5}} \approx 4.472.$$

$$\hat{\phi}_{12} = \langle \mathbf{x}_2^{(0)}, \mathbf{y}^{(0)} \rangle = \frac{(-1)(-3) + (-1)(-1) + 2 \cdot 1 + 0 \cdot 3}{\sqrt{6}} = \frac{3 + 1 + 2 + 0}{\sqrt{6}} = \frac{6}{\sqrt{6}} \approx 2.45.$$

(b) 构造 $\mathbf{z}_1$ ：

$$\mathbf{z}_1 = \hat{\phi}_{11} \mathbf{x}_1^{(0)} + \hat{\phi}_{12} \mathbf{x}_2^{(0)} = \frac{10}{\sqrt{5}} \mathbf{x}_1^{(0)} + \frac{6}{\sqrt{6}} \mathbf{x}_2^{(0)}.$$

直接写出 $\mathbf{z}_1$ 的坐标（代入标准化前的中心化值更方便）——等价于用原始中心化变量： $\mathbf{z}_1 \propto 10 \cdot \tilde{\mathbf{x}}_1 + 6 \cdot \tilde{\mathbf{x}}_2$ ，其中 $\tilde{\mathbf{x}}_j$ 为中心化后的原始值。

$$\mathbf{z}_1 \propto 10 \begin{pmatrix} -1.5 \\ -0.5 \\ 0.5 \\ 1.5 \end{pmatrix} + 6 \begin{pmatrix} -1 \\ -1 \\ 2 \\ 0 \end{pmatrix} = \begin{pmatrix} -21 \\ -11 \\ 17 \\ 15 \end{pmatrix}.$$

归一化： $\|\mathbf{z}_1\| = \sqrt{21^2 + 11^2 + 17^2 + 15^2} = \sqrt{1076}$ 。实际 PLS 中不必须单位化，关键是计算 $\hat{\theta}_1$ ：

(c) 计算回归系数：

$$\hat{\theta}_1 = \frac{\langle \mathbf{z}_1, \mathbf{y}^{(0)} \rangle}{\langle \mathbf{z}_1, \mathbf{z}_1 \rangle} = \frac{(-21)(-3) + (-11)(-1) + 17 \cdot 1 + 15 \cdot 3}{1076} = \frac{63 + 11 + 17 + 45}{1076} = \frac{136}{1076} \approx 0.1264.$$

(d) 更新拟合 ($\mathbf{y}$ 的投影)：

$$\hat{\mathbf{y}}^{(1)} = \hat{\mathbf{y}}^{(0)} + \hat{\theta}_1 \mathbf{z}_1 = \begin{pmatrix} 6 \\ 6 \\ 6 \\ 6 \end{pmatrix} + 0.1264 \begin{pmatrix} -21 \\ -11 \\ 17 \\ 15 \end{pmatrix} \approx \begin{pmatrix} 3.35 \\ 4.61 \\ 8.15 \\ 7.90 \end{pmatrix}.$$

残差 $\mathbf{y}^{(1)} = \mathbf{y} - \hat{\mathbf{y}}^{(1)} \approx (-0.35, 0.39, -1.15, 1.10)^\top$ 。

(e) 正交化 $\mathbf{x}_j$ (剔除 $\mathbf{z}_1$ 分量)：

$$\mathbf{x}_1^{(1)} = \mathbf{x}_1^{(0)} - \frac{\langle \mathbf{z}_1, \mathbf{x}_1^{(0)} \rangle}{\langle \mathbf{z}_1, \mathbf{z}_1 \rangle} \mathbf{z}_1, \quad \mathbf{x}_2^{(1)} = \mathbf{x}_2^{(0)} - \frac{\langle \mathbf{z}_1, \mathbf{x}_2^{(0)} \rangle}{\langle \mathbf{z}_1, \mathbf{z}_1 \rangle} \mathbf{z}_1.$$

第 2 步 ($m = 2$)：

用 $\mathbf{x}_1^{(1)}, \mathbf{x}_2^{(1)}$ 和残差 $\mathbf{y}^{(1)}$ ($\mathbf{y}$ 中尚未被 $\mathbf{z}_1$ 解释的部分) 重复上述过程。构造 $\mathbf{z}_2$ (与 $\mathbf{z}_1$ 正交)，将 $\mathbf{y}^{(1)}$ 投影到 $\mathbf{z}_2$ 上，更新拟合。此时 $\hat{\mathbf{y}}^{(2)}$ 接近 $\mathbf{y}$ 在 $\mathbf{X}$ 列空间上的完整投影。

观察：

- $\mathbf{z}_1$ 里， x_1 的权重 (10) 大于 x_2 (6) ——因为 x_1 与 y 的协方差更大；
- 经过第 1 步正交化， $\mathbf{x}_j^{(1)} \perp \mathbf{z}_1$ ——第 2 步只会用到“ $\mathbf{z}_1$ 没吸收的信息”；
- 这和 Gram-Schmidt 一模一样，只是顺序由协方差驱动。

为什么同时考虑方差和相关性？

PLS 的优化准则可以化简：

$$\text{Corr}^2(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha}) \cdot \text{Var}(\mathbf{X}\boldsymbol{\alpha}) = \frac{\text{Cov}^2(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha})}{\text{Var}(\mathbf{y})\text{Var}(\mathbf{X}\boldsymbol{\alpha})} \cdot \text{Var}(\mathbf{X}\boldsymbol{\alpha}) = \frac{\text{Cov}^2(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha})}{\text{Var}(\mathbf{y})}.$$

由于 $\text{Var}(\mathbf{y})$ 是常数，这等价于最大化 $|\text{Cov}(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha})|$ 。也就是说，PLS 的准则在数学上退化为简单的协方差最大化。那为什么 ESL 要写成“相关性 × 方差”这种貌似复杂的形式？

答案：两个极端失败案例能说明一切。

	只最大化相关性 (CCA 方向)	只最大化方差 (PCA 方向)
准则	$\max \text{Corr}^2(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha})$	$\max \text{Var}(\mathbf{X}\boldsymbol{\alpha})$
会怎样	可能选到一个与 $\mathbf{y}$ 高度相关、但 $\mathbf{X}\boldsymbol{\alpha}$ 波动极小的方向 → $\hat{\theta}$ 估计极不稳定（方差巨大）	可能选到一个 $\mathbf{X}\boldsymbol{\alpha}$ 方差大、但与 $\mathbf{y}$ 完全不相干的方向 → 白做，预测力为零
极端例子	$\mathbf{x}_1$ 与 $\mathbf{y}$ 相关 0.9，但 $\text{Var}(\mathbf{x}_1) = 0.001$ ； $\hat{\theta}$ 的方差 $\propto 1/\ \mathbf{z}\ ^2 \rightarrow \infty$	$\mathbf{x}_2$ 方差极大但 $\text{Corr}(\mathbf{x}_2, \mathbf{y}) \approx 0$ ；这个方向对预测毫无用处
PLS 的做法	同时要求两者： $\text{Corr}^2 \cdot \text{Var} = \text{Cov}^2 / \text{Var}(\mathbf{y})$ —— 既不接受方差太小的方向（不稳定），也不接受相关性太弱的方向（无预测力）	

更深入的理解——为什么恰好是协方差？

协方差 $\text{Cov}(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha}) = \rho \cdot \sigma_y \cdot \sigma_{\mathbf{X}\boldsymbol{\alpha}}$ 本身就是“相关性 × 标准差”：

$$\text{Cov} = \underbrace{\text{Corr}}_{\text{关系强度}} \times \underbrace{\sigma_y}_{\text{固定常数}} \times \underbrace{\sigma_{\mathbf{X}\boldsymbol{\alpha}}}_{\text{信号强度}}.$$

所以 PLS 选的方向是在相关性和信号强度之间取得平衡：

- 信号太弱 ($\sigma_{\mathbf{X}\boldsymbol{\alpha}}$ 小) → 即使相关性高也不可靠；
- 相关性太弱 ($\rho \approx 0$) → 即使信号强也与 $\mathbf{y}$ 无关。

这就是为什么 PLS 的准则写成 $\text{Corr}^2 \cdot \text{Var}$ ——它清楚地表达了这两个成分的权衡，尽管数学上退化为协方差最大化。

与 PCR 的对比更加清楚：

- PCR: $\max \text{Var}(\mathbf{X}\boldsymbol{\alpha}) \rightarrow$ 只关心 $\mathbf{X}$ 自己的变异结构，完全忽略 $\mathbf{y}$ 。如果 $\mathbf{y}$ 主要依赖低方差成分（如光谱学中痕量成分），PCR 会直接扔掉它。
- PLS: $\max \text{Cov}(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha}) \rightarrow$ 取 $\mathbf{X}$ 的变异和 $\mathbf{y}$ 的交集。不浪费自由度在“方差大但与 $\mathbf{y}$ 无关”的方向上。

一句话总结：PLS 的准则看似是两个量的乘积，实际就是协方差最大化——它要的是“ $\mathbf{X}$ 中与 $\mathbf{y}$ 有关系的那部分变异”，PCR 要的是“ $\mathbf{X}$ 中变异最大的那部分”，而不管变异是否与 $\mathbf{y}$ 有关。

追问：按协方差大小选方向，会不会让与 $\mathbf{y}$ 几乎无关的变量永远被忽略？

这恰恰是 PLS 设计中最精妙的地方——正交化步骤让变量有“第二次机会”。

关键不在于单个变量在第 1 步权重有多大，而在于第 m 步用的是什么变量。第 m 步使用的 $\mathbf{x}_j^{(m-1)}$ 不是原始 $\mathbf{x}_j$ ，而是经过前 $m-1$ 轮正交化后的残差：

$$\mathbf{x}_j^{(m-1)} = \mathbf{x}_j - \sum_{\ell=1}^{m-1} \frac{\langle \mathbf{z}_\ell, \mathbf{x}_j \rangle}{\langle \mathbf{z}_\ell, \mathbf{z}_\ell \rangle} \mathbf{z}_\ell.$$

这意味着：

三种典型情况：

情况 1: $\mathbf{x}_j$ 与 $\mathbf{y}$ 边缘协方差很大 $\rightarrow$ 第 1 步权重高，直接被大量纳入 $\mathbf{z}_1$ 。好的——这正是我们想要的。

情况 2: $\mathbf{x}_j$ 与 $\mathbf{y}$ 边缘协方差很小，但与某个已被纳入的 $\mathbf{x}_k$ 高度相关 $\rightarrow$ 第 1 步权重小，但正交化后 $\mathbf{x}_j^{(1)}$ 很小（因为大部分已被 $\mathbf{z}_1$ 剥离）。后续步骤中它与残差 $\mathbf{y}^{(m)}$ 的协方差仍然很小 $\rightarrow$ 最终被忽略。这是对的：它的信息已经被 $\mathbf{x}_k$ 代表了。

情况 3: $\mathbf{x}_j$ 与 $\mathbf{y}$ 边缘协方差很小，但与已纳入变量不相关 $\rightarrow$ 第 1 步权重小。但正交化几乎不影响它 ($\mathbf{x}_j^{(1)} \approx \mathbf{x}_j$)。第 1 步后， $\mathbf{y}^{(1)} = \mathbf{y} - \hat{\theta}_1 \mathbf{z}_1$ 中与 $\mathbf{x}_j$ 有关的分量 仍然在残差里——因此第 2 步时 $\langle \mathbf{x}_j^{(1)}, \mathbf{y}^{(1)} \rangle$ 和 $\langle \mathbf{x}_j, \mathbf{y} \rangle$ 几乎一样大。如果其他变量的协方差在第 1 步已被大量消耗， $\mathbf{x}_j$ 在第 2 步就会脱颖而出。这就是“第二次机会”。

用一个具体例子说明：

假设 $p=3$ ，真实模型为 $y = 2x_1 + 1.5x_3 + \varepsilon$ ，且 x_1 与 x_2 高度相关 ($r \approx 0.9$)， x_3 与 x_1, x_2 均独立。

第 1 步的边际协方差大小排序可能是：

$$|\text{Cov}(\mathbf{x}_1, \mathbf{y})| > |\text{Cov}(\mathbf{x}_2, \mathbf{y})| > |\text{Cov}(\mathbf{x}_3, \mathbf{y})|.$$

$\mathbf{x}_2$ 的协方差较大，不是因为 $\mathbf{x}_2$ 本身对 y 有因果效应，而是因为它与 $\mathbf{x}_1$ 高度相关—— $\mathbf{x}_2$ “搭了 $\mathbf{x}_1$ 的便车”。 $\mathbf{x}_3$ 虽然真实系数是 1.5，但因为方差可能较小，边际协方差排在最后。

第 1 步后：

- $\mathbf{z}_1$ 主要捕获了 $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 的共同变异；
- $\mathbf{x}_1^{(1)}$ 和 $\mathbf{x}_2^{(1)}$ 都变得很小（大部分已被剥离）；
- $\mathbf{x}_3^{(1)} \approx \mathbf{x}_3$ （几乎未被触及，因为它与 $\mathbf{z}_1$ 正交）。

第 2 步：

- $\mathbf{y}^{(1)}$ 中 $\mathbf{x}_3$ 的贡献纹丝未动；
- 此时 $\langle \mathbf{x}_3^{(1)}, \mathbf{y}^{(1)} \rangle \approx \langle \mathbf{x}_3, \mathbf{y} \rangle$ ；
- 而 $\mathbf{x}_1^{(1)}, \mathbf{x}_2^{(1)}$ 与 $\mathbf{y}^{(1)}$ 的协方差已大幅下降；
- 因此 $\mathbf{x}_3$ 在第 2 步以最高权重进入 $\mathbf{z}_2$ 。

核心结论： PLS 不会因为一个变量第 1 步协方差不够大就永远丢弃它。正交化步骤在每一轮“消耗”已纳入变量的信息，给尚未被代表的变量腾出空间。这与逐步回归的“竞争”逻辑完全不同——逐步回归是淘汰制，PLS 是排队制。只要变量与 y 有任何独特的线性关系（不以其他变量为中介），它总会在某一轮被选中。

一句话： PLS 不会丢失与 y 有关的变量——它只是让协方差大的先走，协方差小的耐心排队。正交化保证每一轮过后，前排选手已经被消化，后排选手的“相对重要性”自动上升。

11.15 选择与收缩方法的比较 (Discussion)

考虑两个相关输入 X_1, X_2 （相关系数 ρ ），真实系数 $\beta_1 = 4, \beta_2 = 2$ 。图 3.18 展示了不同方法的系数路径（随着调节参数变化）：

- **岭回归：** 将所有系数一起向原点收缩，最终收敛到 LS 解；
- **PCR 和 PLS：** 行为与岭回归相似，但是离散的且更极端；
- **最优子集：** 先“冲过头”再折回 LS 解（overshoot）；
- **Lasso：** 介于岭回归和最优子集之间。

关于收缩行为的核心发现：

- 岭回归对所有方向做收缩，但低方差方向收缩更多；
- PCR 保留 M 个高方差方向，丢弃其余方向；
- PLS 也倾向于收缩低方差方向，但可能膨胀某些高方差方向——导致 PLS 比岭回归略不稳定、预测误差略高。

总结：PLS、PCR 和岭回归的行为往往相似。岭回归可能更受青睐，因为它连续收缩而非离散步骤。Lasso 介于岭回归和最优子集之间，兼具两者的特性。

11.16 多输出收缩与选择

当有 K 个输出时，可以独立处理每个输出（使用不同的 λ_k ），也可以共享同一个 λ 。但更精细的策略可以利用输出之间的相关性。

两个前提性问题

前文方法（子集选择、岭回归、Lasso）在多输出场景下有什么局限？

前文所有方法都是单输出的——每次只建模一个 y 。当有 K 个输出时，最直接的做法是对每个输出独立跑一遍。但这有四个问题：

- (1) 忽略输出间的共享结构。如果 y_1 和 y_2 高度相关且背后是同一个 $f(X)$ （如 $y_1 = f(X) + \varepsilon_1$, $y_2 = f(X) + \varepsilon_2$ ），独立建模等于把本该合并在一起估计 $f(X)$ 的 $2N$ 个观测，拆成两份各 N 个去分别估计——浪费了一半数据。
- (2) 调参成本高。独立做意味着 K 个 λ （岭回归/Lasso）或 K 个子集大小（子集选择）需要分别调。如果共享同一个 λ ，则隐含假设所有输出需要相同强度的正则化——这在实践中几乎从不成立。
- (3) 变量选择不一致。用 Lasso 对每个输出独立选变量，可能 y_1 选了 $\{x_1, x_3\}$ ， y_2 选了 $\{x_2, x_4\}$ 。即使两个输出高度相关，选出的变量集合也可能完全不同——这对科学解释是灾难性的。
- (4) 不能利用输出间的相关性来降噪。多输出场景的核心优势是借力（borrow strength）：如果一个输出在某些观测上噪声大，其他与之相关的输出可以提供额外信息来稳定估计。单输出方法完全放弃了这种可能性。

一句话：单输出方法把 K 个输出当成 K 个互不相关的独立问题，而多输出方法把它们当成一个整体的 K 维问题来建模。

CCA / 降秩回归 / C+W 的前提条件是什么？

这三种方法都建立在线性框架之上，核心前提如下：

前提	具体要求	违反时的后果
多输出	$K \geq 2$ ，否则退化为单输出问题	无意义
线性关联	$\mathbf{X}$ 和 $\mathbf{Y}$ 之间主要是线性关系	CCA 只捕捉线性相关，非线性关联（U 形、交互）会被遗漏
中心化	$\mathbf{X}$ 、 $\mathbf{Y}$ 需列中心化（均值为 0）。标准化（单位方差）非必须但强烈建议	不中心化会导致截距污染交叉协方差；不标准化会导致尺度大的变量主导方向
样本量	至少 $N > p + K$ 才能稳定估计协方差矩阵。建议 $N \gg pK$ （高维小样本下 CCA 极不稳定）	N 不够时典型相关系数被严重高估（回忆前面例子中 $c_1 > 1$ ）
误差结构 (RRR/C+W)	假设 $\text{Cov}(\epsilon_i) = \Sigma$ 对所有 i 相同（同方差），不同 i 间独立	异方差或自相关时最优性不保证，但只要 $\mathbf{X}$ 和 Σ 无关，解仍然不依赖 Σ
无多重共线性极端值	Σ_{XX} 和 Σ_{YY} 需可逆（用于白化）	完全共线时需先做 PCA 或正则化预处理

实践中最重要的两个检查：

- **N 够不够？** 如果 $N < p$ 或 $N < K$ ， Σ_{XX} 或 Σ_{YY} 不可逆——白化步骤无法进行。此时可以先用 PCA 降维，或在 Σ_{XX} 上加 ridge ($\Sigma_{XX} + \gamma \mathbf{I}$) 做正则化 CCA。
- **是线性关系吗？** 画散点图矩阵检查 $\mathbf{X}$ 和 $\mathbf{Y}$ 的边际关系。如果明显非线性，CCA 找到的方向可能没有意义。可以先用基展开（样条、多项式）将 $\mathbf{X}$ 变换后再做 CCA。

11.16.1 典型相关分析 (CCA)

CCA 找到 $\mathbf{x}_j$ 的线性组合 $\mathbf{X}\mathbf{v}_m$ 和响应的线性组合 $\mathbf{Y}\mathbf{u}_m$ ，使得两者的相关性依次最大化：

$$\text{Corr}^2(\mathbf{Y}\mathbf{u}_m, \mathbf{X}\mathbf{v}_m) \rightarrow \max.$$

最多可找到 $M = \min(K, p)$ 对方向。

核心直觉：前面的典型响应变元被 $\mathbf{x}$ 预测得最好；后面的典型变元预测力弱，可以考虑丢弃。

完整例子：手动走一遍 CCA。

下面用一个 $N = 4$ 、 $p = 2$ 、 $K = 2$ 的小数据集，逐步展示 CCA 的计算流程。

第 0 步：原始数据。

i	x_{i1}	x_{i2}	y_{i1}	y_{i2}
1	0	0	1	1
2	0	1	1	4
3	1	0	3	3
4	1	1	3	6

实质关系（从数据生成看）：

$$y_1 = 1 + 2x_1, \quad y_2 = 1 + 3x_1 + 2x_2.$$

这意味着 y_1 只和 x_1 有关， y_2 同时依赖 x_1 和 x_2 。CCA 能否自动发现这个结构？

第 1 步：中心化 + 标准化。

中心化（每列减均值）：

$$\bar{x}_1 = 0.5, \bar{x}_2 = 0.5, \bar{y}_1 = 2, \bar{y}_2 = 3.5.$$

$$\mathbf{X}_c = \begin{pmatrix} -0.5 & -0.5 \\ -0.5 & 0.5 \\ 0.5 & -0.5 \\ 0.5 & 0.5 \end{pmatrix}, \quad \mathbf{Y}_c = \begin{pmatrix} -1.0 & -2.5 \\ -1.0 & 0.5 \\ 1.0 & -0.5 \\ 1.0 & 2.5 \end{pmatrix}.$$

缩放到单位方差（每列除以标准差）。 $\mathbf{X}_c$ 的每列方差 = 0.25，标准差 = 0.5； $\mathbf{Y}_c$ 的 y_1 方差 = 1（标准差 = 1）， y_2 方差 = 3.25（标准差 ≈ 1.803 ）：

$$\mathbf{X} = \begin{pmatrix} -1 & -1 \\ -1 & 1 \\ 1 & -1 \\ 1 & 1 \end{pmatrix}, \quad \mathbf{Y} = \begin{pmatrix} -1 & -1.387 \\ -1 & 0.277 \\ 1 & -0.277 \\ 1 & 1.387 \end{pmatrix}.$$

验证： $\mathbf{X}^\top \mathbf{X} / 4 = \mathbf{I}_2$ ， $\mathbf{Y}^\top \mathbf{Y} / 4 = \mathbf{I}_2$ 。✓

第 2 步：计算交叉协方差矩阵。

$$\Sigma_{XY} = \frac{\mathbf{X}^\top \mathbf{Y}}{N} = \frac{1}{4} \begin{pmatrix} (-1)(-1) + (-1)(-1) + (1)(1) + (1)(1) & (-1)(-1.387) + (-1)(0.277) + (1)(-0.277) \\ (-1)(-1) + (1)(-1) + (-1)(1) + (1)(1) & (-1)(-1.387) + (1)(0.277) + (-1)(-0.277) \end{pmatrix}$$

观察：第一行 (1.000, 0.832) 说明 $\mathbf{x}_1$ 与两个 y 都有很强协方差；第二行 (0, 0.555) 说明 $\mathbf{x}_2$ 与 y_1 正交、与 y_2 有中等协方差——与真实生成关系一致。

第 3 步：计算核心矩阵并做 SVD。

由于 $\mathbf{X}$ 和 $\mathbf{Y}$ 都已标准化 ($\Sigma_{XX} = \Sigma_{YY} = \mathbf{I}$)，CCA 的核心矩阵简化为交叉协方差本身：

$$\mathbf{K} = \Sigma_{XX}^{-1/2} \Sigma_{XY} \Sigma_{YY}^{-1/2} = \Sigma_{XY} = \begin{pmatrix} 1.000 & 0.832 \\ 0 & 0.555 \end{pmatrix}.$$

对 $\mathbf{K}$ 做 SVD: $\mathbf{K} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$ 。

先计算 $\mathbf{K}^\top \mathbf{K}$ ：

$$\mathbf{K}^\top \mathbf{K} = \begin{pmatrix} 1.000 & 0.832 \\ 0.832 & 1.000 \end{pmatrix}.$$

特征值： $\det(\mathbf{K}^\top \mathbf{K} - \lambda \mathbf{I}) = (1 - \lambda)^2 - 0.832^2 = 0$ ，得 $\lambda_1 = 1.832$, $\lambda_2 = 0.168$ 。

典型相关系数（奇异值）：

$$c_1 = \sqrt{\lambda_1} \approx 1.353, \quad c_2 = \sqrt{\lambda_2} \approx 0.410.$$

但相关系数不能超过 1——说明我们的计算中 $c_1 > 1$ 是因为 $N = 4$ 的小样本偏高。在总体中 $0 \leq c_m \leq 1$ 。这里我们把 c_1 理解为接近 1（完美相关）， $c_2 \approx 0.41$ 。

c_1 很大 $\rightarrow$ 存在一个 $\mathbf{X}$ 的线性组合与某个 $\mathbf{Y}$ 的线性组合高度相关。 c_2 较小 $\rightarrow$ 第二个方向的相关性弱得多。

第 4 步：提取典型方向。

对 $\mathbf{K}^\top \mathbf{K}$ 的特征向量（即 $\mathbf{V}$ 的列， $\mathbf{X}$ 端方向）：

$\lambda_1 = 1.832$ 的特征向量： $(1 - \lambda_1)v_1 + 0.832v_2 = 0$ ，即 $-0.832v_1 + 0.832v_2 = 0$, $v_1 = v_2$ ：

$$\mathbf{v}_1 \propto (1, 1)^\top \xrightarrow{\text{归一化}} \mathbf{v}_1 \approx (0.707, 0.707)^\top.$$

$\lambda_2 = 0.168$ 的特征向量： $v_1 = -v_2$ ：

$$\mathbf{v}_2 \propto (1, -1)^\top \xrightarrow{\text{归一化}} \mathbf{v}_2 \approx (0.707, -0.707)^\top.$$

$\mathbf{Y}$ 端方向 $\mathbf{u}_m$ 由 $\mathbf{u}_m \propto \mathbf{K}\mathbf{v}_m$ （归一化后）：

$$\mathbf{u}_1 \propto \mathbf{K}\mathbf{v}_1 = \begin{pmatrix} 1.000 & 0.832 \\ 0 & 0.555 \end{pmatrix} \begin{pmatrix} 0.707 \\ 0.707 \end{pmatrix} \approx \begin{pmatrix} 1.295 \\ 0.392 \end{pmatrix} \xrightarrow{\text{归一化}} \mathbf{u}_1 \approx (0.957, 0.290)^\top.$$

$$\mathbf{u}_2 \propto \mathbf{K}\mathbf{v}_2 \approx \begin{pmatrix} 0.119 \\ -0.392 \end{pmatrix} \xrightarrow{\text{归一化}} \mathbf{u}_2 \approx (0.290, -0.957)^\top.$$

第 5 步：解读。

方向	典型相关系数	$\mathbf{X}$ 端组合	$\mathbf{Y}$ 端组合
第 1	$c_1 \approx 1.0$	$0.71 x_1 + 0.71 x_2$	$0.96 y_1 + 0.29 y_2$
第 2	$c_2 \approx 0.41$	$0.71 x_1 - 0.71 x_2$	$0.29 y_1 - 0.96 y_2$

发现了什么？

- **第一典型方向：** $\mathbf{X}$ 端几乎等权重地组合 x_1 和 x_2 ， $\mathbf{Y}$ 端主要由 y_1 主导（权重 0.96）。这说明 y_1 和 $x_1 + x_2$ 高度相关。但回忆真实模型： y_1 只和 x_1 有关！这里 x_2 也获得了权重，是因为在 $N = 4$ 的小样本中， $x_1 + x_2$ 碰巧与 y_1 的相关性比单独的 x_1 更高（过拟合的雏形）。
- **第二典型方向：** y_2 权重最大（ -0.96 ），对应 $x_1 - x_2$ 。这和真实模型一致—— y_2 同时依赖 x_1 和 x_2 ，两者方向相反说明它们对 y_2 的贡献在 CCA 视角下有某种互补关系。
- CCA 成功发现了两个正交的关联维度，但第一维度将 x_2 也纳入，反映出小样本下估计的不稳定性。在大样本（ $N \rightarrow \infty$ ）极限下，CCA 会正确恢复： $y_1 \leftrightarrow x_1$ （ $c_1 \rightarrow 1$ ）和 $y_2 \leftrightarrow x_1, x_2$ 的某种组合。

CCA 算法总结（五步）：

第 1 步： 标准化 $\mathbf{X}$ 和 $\mathbf{Y}$ （每列均值 0，方差 1）；

第 2 步： 计算交叉协方差 $\Sigma_{XY} = \mathbf{X}^\top \mathbf{Y} / N$ ；

第 3 步： 构造核心矩阵 $\mathbf{K} = \Sigma_{XX}^{-1/2} \Sigma_{XY} \Sigma_{YY}^{-1/2}$ （若已标准化则 $\mathbf{K} = \Sigma_{XY}$ ）；

第 4 步： 对 $\mathbf{K}$ 做 SVD： $\mathbf{K} = \mathbf{U} \mathbf{D} \mathbf{V}^\top$ ，奇异值 d_m 就是典型相关系数 c_m ；

第 5 步： 提取方向： $\mathbf{X}$ 端 $\mathbf{v}_m$ （ $\mathbf{V}$ 的列）， $\mathbf{Y}$ 端 $\mathbf{u}_m$ （ $\mathbf{U}$ 的列）。

为什么 SVD 能给出 $\mathbf{X}$ 端和 $\mathbf{Y}$ 端的组合？

这是 CCA 最核心的数学洞察。下面从优化问题出发，完整推导出 SVD 的来龙去脉。

第一步：CCA 的优化问题

CCA 要找到 $\mathbf{v} \in \mathbb{R}^p$ （ $\mathbf{X}$ 端权重）和 $\mathbf{u} \in \mathbb{R}^K$ （ $\mathbf{Y}$ 端权重），最大化：

$$\text{Corr}(\mathbf{Y}\mathbf{u}, \mathbf{X}\mathbf{v}) = \frac{\text{Cov}(\mathbf{Y}\mathbf{u}, \mathbf{X}\mathbf{v})}{\sqrt{\text{Var}(\mathbf{Y}\mathbf{u}) \cdot \text{Var}(\mathbf{X}\mathbf{v})}}.$$

代入协方差矩阵：

$$\begin{aligned}\text{Cov}(\mathbf{Y}\mathbf{u}, \mathbf{X}\mathbf{v}) &= \frac{1}{N}(\mathbf{Y}\mathbf{u})^\top(\mathbf{X}\mathbf{v}) = \mathbf{u}^\top \frac{\mathbf{Y}^\top \mathbf{X}}{N} \mathbf{v} = \mathbf{u}^\top \Sigma_{YX} \mathbf{v}. \\ \text{Var}(\mathbf{X}\mathbf{v}) &= \mathbf{v}^\top \Sigma_{XX} \mathbf{v}, \quad \text{Var}(\mathbf{Y}\mathbf{u}) = \mathbf{u}^\top \Sigma_{YY} \mathbf{u}.\end{aligned}$$

所以 CCA 求解：

$$\max_{\mathbf{u}, \mathbf{v}} \frac{\mathbf{u}^\top \Sigma_{YX} \mathbf{v}}{\sqrt{\mathbf{u}^\top \Sigma_{YY} \mathbf{u} \cdot \mathbf{v}^\top \Sigma_{XX} \mathbf{v}}}.$$

第二步：白化——消去分母

分子和分母都依赖 $\mathbf{u}$ 和 $\mathbf{v}$ ，不好直接优化。关键在于先做变量替换，把分母消掉。
令：

$$\tilde{\mathbf{v}} = \Sigma_{XX}^{1/2} \mathbf{v}, \quad \tilde{\mathbf{u}} = \Sigma_{YY}^{1/2} \mathbf{u}.$$

这里 $\Sigma^{1/2}$ 是协方差矩阵的对称平方根 ($\Sigma^{1/2} \Sigma^{1/2} = \Sigma$)。

则有 $\mathbf{v} = \Sigma_{XX}^{-1/2} \tilde{\mathbf{v}}$, $\mathbf{u} = \Sigma_{YY}^{-1/2} \tilde{\mathbf{u}}$ 。代入：

- 分子： $\mathbf{u}^\top \Sigma_{YX} \mathbf{v} = \tilde{\mathbf{u}}^\top \Sigma_{YY}^{-1/2} \Sigma_{YX} \Sigma_{XX}^{-1/2} \tilde{\mathbf{v}} = \tilde{\mathbf{u}}^\top \mathbf{K} \tilde{\mathbf{v}}$,

其中 $\mathbf{K} = \Sigma_{YY}^{-1/2} \Sigma_{YX} \Sigma_{XX}^{-1/2}$ 。

- 分母： $\mathbf{v}^\top \Sigma_{XX} \mathbf{v} = \tilde{\mathbf{v}}^\top \Sigma_{XX}^{-1/2} \Sigma_{XX} \Sigma_{XX}^{-1/2} \tilde{\mathbf{v}} = \|\tilde{\mathbf{v}}\|^2$ 。

同理 $\mathbf{u}^\top \Sigma_{YY} \mathbf{u} = \|\tilde{\mathbf{u}}\|^2$ 。

因此，CCA 的优化问题变为：

$$\max_{\tilde{\mathbf{u}}, \tilde{\mathbf{v}}} \frac{\tilde{\mathbf{u}}^\top \mathbf{K} \tilde{\mathbf{v}}}{\|\tilde{\mathbf{u}}\| \cdot \|\tilde{\mathbf{v}}\|}.$$

分母被消掉了——这就是白化的几何意义：把 $\mathbf{X}$ 和 $\mathbf{Y}$ 内部的协方差结构“拉平”，让不同方向和变量不再有尺度差异，剩下的 $\mathbf{K}$ 就是纯净的跨集合关联矩阵。

注意：笔记中前面例子用的是 $\mathbf{K} = \Sigma_{XX}^{-1/2} \Sigma_{XY} \Sigma_{YY}^{-1/2}$ ，与这里 $\Sigma_{YY}^{-1/2} \Sigma_{YX} \Sigma_{XX}^{-1/2}$ 的区别只是转置——两者做 SVD 后的奇异值相同， $\mathbf{U}$ 和 $\mathbf{V}$ 交换。哪个顺手用哪个。

第三步：Rayleigh 商与 SVD

现在问题变成：

$$\max_{\tilde{\mathbf{u}}, \tilde{\mathbf{v}}} \tilde{\mathbf{u}}^\top \mathbf{K} \tilde{\mathbf{v}}, \quad \|\tilde{\mathbf{u}}\| = 1, \|\tilde{\mathbf{v}}\| = 1.$$

这是一个双线性型在有约束下的最大化。SVD 恰好是它的最优解。

定理 11.6 (SVD 与双线性型的极值). 对任意矩阵 $\mathbf{K}$ ，其 SVD 为 $\mathbf{K} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$ ，其中 $\mathbf{D}$ 的对角元 $d_1 \geq d_2 \geq \dots \geq 0$ 。则：

$$\max_{\|\tilde{\mathbf{u}}\|=1, \|\tilde{\mathbf{v}}\|=1} \tilde{\mathbf{u}}^\top \mathbf{K} \tilde{\mathbf{v}} = d_1,$$

最优解为 $\tilde{\mathbf{u}} = \mathbf{u}_1$ ($\mathbf{U}$ 的第 1 列)， $\tilde{\mathbf{v}} = \mathbf{v}_1$ ($\mathbf{V}$ 的第 1 列)。

直观验证. 取 $\tilde{\mathbf{u}} = \mathbf{u}_1$, $\tilde{\mathbf{v}} = \mathbf{v}_1$:

$$\tilde{\mathbf{u}}^\top \mathbf{K} \tilde{\mathbf{v}} = \mathbf{u}_1^\top (\mathbf{U} \mathbf{D} \mathbf{V}^\top) \mathbf{v}_1 = (\mathbf{U}^\top \mathbf{u}_1)^\top \mathbf{D} (\mathbf{V}^\top \mathbf{v}_1) = \mathbf{e}_1^\top \mathbf{D} \mathbf{e}_1 = d_1.$$

这就是最大的可能值, 因为任何单位向量 $\tilde{\mathbf{u}}$ 都是 $\mathbf{U}$ 列的线性组合 $\tilde{\mathbf{u}} = \mathbf{U} \mathbf{a}$ ($\|\mathbf{a}\| = 1$), $\tilde{\mathbf{v}} = \mathbf{V} \mathbf{b}$ ($\|\mathbf{b}\| = 1$), 则:

$$\tilde{\mathbf{u}}^\top \mathbf{K} \tilde{\mathbf{v}} = \mathbf{a}^\top \mathbf{D} \mathbf{b} \leq \sum_i d_i |a_i b_i| \leq d_1 \sum_i |a_i b_i| \leq d_1 \|\mathbf{a}\| \|\mathbf{b}\| = d_1.$$

□

第四步: 回到原始坐标

SVD 给出的是白化空间中的方向。回到原始变量:

$$\mathbf{v}_1^{\text{orig}} = \Sigma_{XX}^{-1/2} \mathbf{v}_1, \quad \mathbf{u}_1^{\text{orig}} = \Sigma_{YY}^{-1/2} \mathbf{u}_1.$$

这就是 $\mathbf{X}$ 端和 $\mathbf{Y}$ 端的典型方向。对于第二个方向, 在约束与第一个方向正交的条件下重复。

用一句话记住

$$\mathbf{K} = \Sigma_{YY}^{-1/2} \Sigma_{YX} \Sigma_{XX}^{-1/2} \xrightarrow{\text{SVD}} \mathbf{U} \mathbf{D} \mathbf{V}^\top$$

SVD 输出	CCA 中的含义	来源
$\mathbf{D}$ 的对角元 d_m	典型相关系数 c_m	奇异值 = 最大可达的交叉协方差
$\mathbf{V}$ 的第 m 列 $\mathbf{v}_m$	$\mathbf{X}$ 端典型方向 (白化空间)	右奇异向量
$\mathbf{U}$ 的第 m 列 $\mathbf{u}_m$	$\mathbf{Y}$ 端典型方向 (白化空间)	左奇异向量
$\Sigma_{XX}^{-1/2} \mathbf{v}_m$	$\mathbf{X}$ 端典型方向 (原始坐标)	从白化空间拉回
$\Sigma_{YY}^{-1/2} \mathbf{u}_m$	$\mathbf{Y}$ 端典型方向 (原始坐标)	从白化空间拉回

几何直觉: SVD 把 $\mathbf{K}$ 分解为“旋转 $\rightarrow$ 缩放 $\rightarrow$ 再旋转”。

- $\mathbf{V}^\top$: 把 $\mathbf{X}$ 空间旋转到最优方向 ($\mathbf{v}_m$ 彼此正交);
- $\mathbf{D}$: 在每个方向上缩放, 缩放因子就是典型相关系数 c_m ;
- $\mathbf{U}$: 把缩放后的结果旋转到 $\mathbf{Y}$ 空间 ($\mathbf{u}_m$ 彼此正交)。

所以 $\mathbf{X}$ 端的组合是 $\mathbf{V}$ 的列 (经过白化逆变换), $\mathbf{Y}$ 端的组合是 $\mathbf{U}$ 的列 (经过白化逆变换) ——两者分别从 SVD 的左右两侧“对偶”地产生, 通过奇异值 c_m 连接。

11.16.2 降秩回归 (Reduced-Rank Regression)

定义 11.28 (降秩回归). 在约束 $\text{rank}(\mathbf{B}) \leq m$ 下最小化多变量回归的加权 RSS:

$$\hat{\mathbf{B}}(m) = \arg \min_{\text{rank}(\mathbf{B})=m} \sum_{i=1}^N (\mathbf{y}_i - \mathbf{B}^\top \mathbf{x}_i)^\top \boldsymbol{\Sigma}^{-1} (\mathbf{y}_i - \mathbf{B}^\top \mathbf{x}_i). \quad (11.70)$$

其解由 CCA 给出:

$$\hat{\mathbf{B}}(m) = \hat{\mathbf{B}} \mathbf{U}_m \mathbf{U}_m^{-},$$

其中 $\mathbf{U}_m$ 是前 m 个左典型向量, $\mathbf{U}_m^{-}$ 是其广义逆。

解读: 降秩回归先在“合并后的响应矩阵” $\mathbf{Y}\mathbf{U}_m$ 上做普通回归, 再将系数映射回原始响应空间。拟合值为:

$$\hat{\mathbf{Y}}(m) = \mathbf{H}\mathbf{Y}\mathbf{P}_m,$$

其中 $\mathbf{H}$ 是普通 LS 投影矩阵, $\mathbf{P}_m$ 是秩- m CCA 响应投影矩阵。

$\boldsymbol{\Sigma}^{-1}$ 是什么?

$\boldsymbol{\Sigma}$ 是多输出误差的协方差矩阵, 维度 $K \times K$ 。

在多输出线性模型 $\mathbf{Y} = \mathbf{X}\mathbf{B} + \mathbf{E}$ 中, 每个观测 i 的 K 个误差构成一个向量:

$$\boldsymbol{\varepsilon}_i = (\varepsilon_{i1}, \dots, \varepsilon_{iK})^\top \in \mathbb{R}^K,$$

其协方差矩阵为 $\text{Cov}(\boldsymbol{\varepsilon}_i) = \boldsymbol{\Sigma}$ (假设对所有 i 相同, 且不同 i 间独立)。

$\boldsymbol{\Sigma}$ 的对角元 Σ_{kk} 是第 k 个输出的误差方差; 非对角元 $\Sigma_{k\ell}$ 是第 k 和第 ℓ 个输出误差之间的协方差。

为什么目标函数里要乘 $\boldsymbol{\Sigma}^{-1}$? 这和 GLS (广义最小二乘) 的逻辑一致。如果不同输出的误差尺度不同 (如温度误差 $\approx 1^\circ\text{C}$, 湿度误差 $\approx 5\%$), 直接加和 RSS 会让尺度大的输出主导优化。 $\boldsymbol{\Sigma}^{-1}$ 将其「标准化」——每个输出的残差按其精度加权, 同时消除输出间相关性对拟合方向的扭曲。

实践中 $\boldsymbol{\Sigma}$ 未知, 通常用 $\mathbf{Y}^\top \mathbf{Y} / N$ 估计。好消息是: 在正态假设下, 降秩回归的解不依赖 $\boldsymbol{\Sigma}$ 的具体值 (见 ESL 习题 3.22), 所以实际操作中可以直接用 CCA 求解, 无需显式估计 $\boldsymbol{\Sigma}$ 。

「降秩」是让输入变量变少吗?

不是。降秩回归不减少输入变量, 它约束的是系数矩阵 $\mathbf{B}$ 的秩。

$\mathbf{B}$ 是 $(p+1) \times K$ 的矩阵——每一列是某个输出对应的 $p+1$ 个系数。如果不加约束, $\mathbf{B}$ 的秩最多为 $\min(p+1, K)$, 意味着 K 个输出的系数向量可以是「各自独立的」。

$\text{rank}(\mathbf{B}) \leq m$ 强制 $\mathbf{B}$ 的列最多张成一个 m 维子空间。等价地说: 所有 K 个输出共享 m 个「潜在因子」, 每个输出的回归系数是这 m 个因子的线性组合:

$$\mathbf{B} = \underset{(p+1) \times m}{\mathbf{A}} \underset{m \times K}{\mathbf{C}}.$$

m 个因子 $\times K$ 个输出 = 参数从 $(p+1)K$ 降到 $m(p+1+K)$ 。

	普通多输出回归	降秩回归 (rank = m)
B 的样子	K 列彼此独立	K 列共享 m 个因子
参数个数	$(p+1)K$	$m(p+1+K)$ (实际更少)
对输出的假设	各输出独立建模	输出间有共享结构
极端 $m=1$	—	所有输出共用一个回归方向 (缩放不同)

输入变量一个没少—— p 个 x_j 全部参与。变的是它们到 K 个输出的映射方式：不是 K 条独立的路，而是 m 条共享的路再分配到 K 个出口。

打个比方：普通回归是给每个学生（输出）单独请家教（系数），降秩回归是开 m 门大课（因子），每个学生去听然后按自己的权重组合。老师（输入变量）数量不变，但授课方式被约束了。

11.16.3 Curds & Whey 收缩

Breiman & Friedman (1997) 提出对典型变元做连续收缩（而非离散截断），形式为：

$$\hat{\mathbf{B}}^{\text{c+w}} = \hat{\mathbf{B}} \mathbf{U} \mathbf{\Lambda} \mathbf{U}^{-1},$$

其中 $\mathbf{\Lambda}$ 为对角收缩矩阵，对角元：

$$\lambda_m = \frac{c_m^2}{c_m^2 + \frac{p}{N}(1 - c_m^2)},$$

c_m 是第 m 个典型相关系数。当 p/N 很小时，收缩因子接近 1。

他们还建议同时在 $\mathbf{Y}$ 空间和 $\mathbf{X}$ 空间做收缩，得到混合收缩模型 $\hat{\mathbf{Y}} = \mathbf{A}_\lambda \mathbf{Y} \mathbf{S}^{\text{c+w}}$ 。

这三样东西各自什么时候用？

三个方法共享同一个数学核心——对 $\mathbf{X}$ 和 $\mathbf{Y}$ 的交叉协方差矩阵做 SVD 找典型方向——但目的不同，场景不同。

	CCA	降秩回归 (RRR)	Curds & Whey
本质	探索性工具：发现 $\mathbf{X}$ 与 $\mathbf{Y}$ 之间的关联结构	建模工具：强制系数矩阵低秩来约束模型	预测工具：连续收缩典型方向来改善预测
对典型方向的处理	保留/丢弃（看相关性大小）	取前 m 个，后面截断	全部保留，但按 λ_m 软收缩
输出	典型变量对 $(\mathbf{Y}\mathbf{u}_m, \mathbf{X}\mathbf{v}_m)$ ，典型相关系数 c_m	低秩系数矩阵 $\hat{\mathbf{B}}(m)$ ，拟合值	收缩后的系数矩阵和预测值
调参	选 m （保留几对典型变量）	选秩 m	λ_m 由 c_m 和 p/N 自动确定
典型场景	心理学/社会科学：人格特质与学业成绩的关系；基因组学：基因表达与药物响应的关联	经济学：多国 GDP、通胀、失业率联合建模；信号处理：多通道信号的联合滤波	任何多输出预测问题：同时预测温度/湿度/风速；化学计量学：从光谱同时预测多种成分浓度

用一个具体行业例子串起来。

假设你是气象局的数据科学家， $p = 10$ 个大气指标预测 $K = 3$ 个目标（温度、湿度、风速）。

- **CCA 阶段（探索）**：你发现第一对典型变量的 $c_1 = 0.92$ ——存在一个大气指标的线性组合，与一个温度/湿度/风速的特定加权组合高度相关。这个组合告诉你什么物理过程在主导——可能是“海洋气团输送效应”。第二对 $c_2 = 0.45$ ，第三对 $c_3 = 0.12$ 。探索完成：你知道大概有 1–2 个有意义的关联方向。
- **降秩回归（建模）**：基于 CCA 结果，你决定用秩 $m = 2$ 的降秩回归。这相当于说：三个目标之间的变化主要由两个潜在因子驱动，第三个“因子”基本是噪声。秩约束强制模型只从数据中学习这两个因子， $\hat{\mathbf{B}}$ 有 $10 \times 3 = 30$ 个参数但只有 $10 \times 2 + 2 \times 3 = 26$ 个自由度（实际更低）。**相比对每个目标独立跑回归（30 个参数），降秩回归参数更少、方差更低。**
- **C+W 收缩（预测）**：你不想硬截断（ $c_3 = 0.12$ 可能还有点信息），也不想要秩约束的离散决策。C+W 对三个方向分别收缩：

$$\lambda_1 \approx \frac{0.92^2}{0.92^2 + \frac{10}{N} \cdot 0.15} \approx 0.98, \quad \lambda_2 \approx 0.82, \quad \lambda_3 \approx 0.12 \text{(几乎被压到零)}.$$

第一个方向几乎原样保留，第三个基本丢弃，第二个部分收缩——用连续权重替代了硬截断。预测时你甚至可以在 $\mathbf{X}$ 端也做岭回归收缩（混合模型），进一步降低方差。

选择指南：

你的目标	用哪个
我只是想理解 $\mathbf{X}$ 和 $\mathbf{Y}$ 之间的关联结构	CCA
我要做预测，且输出之间肯定有共享结构	降秩回归
我要做预测，但不确定截断几个方向最好	Curds & Whey（或交叉验证选 m 的 RRR）
N 很小、 K 很大，我需要大幅降维	降秩回归（用力截断）
p/N 很大（高维），输出高度相关	C+W（自动根据 p/N 调整收缩力度）

一句话：CCA 是显微镜（看结构），降秩回归是剪刀（硬截断），C+W 是调光器（软收缩）。同一个数学底座，三种使用姿势。

11.17 Lasso 深入与路径算法

11.17.1 增量前向分段回归 (Incremental Forward Stagewise, FS)

第 3.3.3 节的前向分段回归每次走一整步 ($\delta_j = \langle \mathbf{x}_j, \mathbf{r} \rangle$)。增量版本只走一小步 $\epsilon > 0$ ：

第 1 步：残差 $\mathbf{r} = \mathbf{y}$ ，所有 $\beta_j = 0$ ($\mathbf{x}_j$ 标准化)；

第 2 步：找到与 $\mathbf{r}$ 最相关的 $\mathbf{x}_j$ ；

第 3 步： $\beta_j \leftarrow \beta_j + \delta_j$ ，其中 $\delta_j = \epsilon \cdot \text{sign}(\langle \mathbf{x}_j, \mathbf{r} \rangle)$ ；

第 4 步： $\mathbf{r} \leftarrow \mathbf{r} - \delta_j \mathbf{x}_j$ ；

第 5 步：重复，直到所有变量与残差不相关。

关键极限： $\epsilon \rightarrow 0$ 的极限过程称为 FS_0 （无穷小前向分段回归）。图 3.19 展示了前列腺癌数据上 $\epsilon = 0.01$ 和 $\epsilon \rightarrow 0$ 的系数路径。在此例中 FS_0 路径是单调的，因此与 Lasso/LAR 完全相同。

FS_0 与 LAR 的关系：Efron 最初以为 LAR 算法就是 FS_0 的实现，但发现 LAR 在活跃变量间的最小二乘拟合可能导致某个系数的方向与其相关性符号相反——这在 FS 中不可能发生。修正方案是 LAR 的修改版 (Algorithm 3.2b)：在活跃集中求解带符号约束的最小二乘问题。

定义 11.29 (FS_0 与 Lasso 的区别).

- Lasso 每次在 RSS 下降每单位 L_1 范数增加上做最优推进;
- FS_0 在 RSS 下降每单位 L_1 弧长上做最优推进。

因此 FS_0 的系数路径被“抑制频繁改变方向”，可以被视为 Lasso 的单调版本。在 $p \gg N$ 场景下， FS_0 的路径更平滑、方差更低。

11.17.2 分段线性路径算法

LAR 利用了 Lasso 解路径的分段线性特性。Rosset & Zhu (2007) 给出了解路径分段线性的充分条件：

$$\hat{\beta}(\lambda) = \arg \min_{\beta} [R(\beta) + \lambda J(\beta)]$$

1. R 是 β 的二次或分段二次函数；
2. J 是 β 的分段线性函数。

满足此条件的例子包括：平方/绝对误差损失 + L_1/L_∞ 惩罚、Hinge Loss (SVM) + 二次惩罚（在对偶空间中分段线性）。

11.17.3 Dantzig 选择器

Candes & Tao (2007) 提出了 Dantzig 选择器 (DS)：

$$\min_{\beta} \|\beta\|_1 \quad \text{s.t.} \quad \|\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\beta)\|_\infty \leq s. \quad (11.71)$$

等价于：

$$\min_{\beta} \|\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\beta)\|_\infty \quad \text{s.t.} \quad \|\beta\|_1 \leq t.$$

与 Lasso 的区别：Lasso 最小化 RSS（梯度分量的平方和）；DS 最小化梯度的最大绝对值。两者在 t 大时都收敛到 LS 解（ $N < p$ 时取最小 L_1 范数解）。

但 DS 的运行性质不太令人满意：DS 试图让残差与所有预测变量的最大内积最小化，但它选入模型的变量不一定与当前残差相关性最大——可能出现模型中某变量的相关性反而低于某些被排除变量的情况。这可能导致预测精度较差和极不稳定的系数路径。

11.17.4 分组 Lasso (Grouped Lasso)

当预测变量有自然分组时（如同一条生物通路中的基因、一个分类变量的哑变量组），可能希望整组同时被选入或剔除。

定义 11.30 (分组 Lasso). 设 p 个预测变量分为 L 组 (第 ℓ 组有 p_ℓ 个), $\mathbf{X}_\ell$ 和 β_ℓ 对应第 ℓ 组。最小化:

$$\min_{\beta} \left\{ \left\| \mathbf{y} - \beta_0 \mathbf{1} - \sum_{\ell=1}^L \mathbf{X}_\ell \beta_\ell \right\|^2 + \lambda \sum_{\ell=1}^L \sqrt{p_\ell} \|\beta_\ell\|_2 \right\}. \quad (11.72)$$

关键: 惩罚项使用欧几里得范数 $\|\beta_\ell\|_2$ (不是平方)。因为 $\|\beta_\ell\|_2 = 0$ 当且仅当该组所有系数为零——这鼓励**组级稀疏性**。 $\sqrt{p_\ell}$ 项用于调整不同组的大小。

推广包括更一般的 L_2 范数 $\|\eta\|_K = (\eta^\top \mathbf{K} \eta)^{1/2}$ 和允许重叠分组。

完整例子：房价预测中的分组 Lasso

设你要预测房价 y , 候选预测变量来自三个来源:

组	变量	含义
组 1: 地段	$x_1 =$ 距市中心距离, $x_2 =$ 周边学校评分, $x_3 =$ 犯罪率	
组 2: 户型	$x_4 =$ 面积, $x_5 =$ 卧室数, $x_6 =$ 建造年份	
组 3: 经济	$x_7 =$ 当地失业率, $x_8 =$ 家庭收入中位数	

$L = 3$ 组, $p_1 = 3, p_2 = 3, p_3 = 2$, 共 $p = 8$ 。每组有内在关联——「地段」的三个指标来自同一个社区的描述,「户型」的三个来自同一套房的特征,「经济」的两个来自同一个宏观经济背景。

为什么不用普通 Lasso? 普通 Lasso 可能选出 (x_1, x_5, x_8) 这样横跨三组的组合, 报告会很难解释:「房价由距市中心距离、卧室数和家庭收入决定, 但地段中的学校评分和犯罪率反而没影响」——这在领域逻辑上说不通 (同一地段的数据不应该被割裂)。分组 Lasso 强制每组要么全进、要么全出。

过程 (概念层面):

第 1 步: 数据准备: 中心化所有 x_j , 标准化到单位范数 ($\|\mathbf{x}_j\| = 1$)。截距 $\beta_0 = \bar{y}$ 。

第 2 步: 选 λ : 用 10 折交叉验证。从小到大试 λ 的网格, 记录 CV 误差。

第 3 步: 路径追踪: 从 $\lambda_{\max}$ (所有组系数全为零) 开始, 逐步减小 λ 。

不同 λ 下各组的表现:

λ	组 1（地段）	组 2（户型）	组 3（经济）	CV 误差
大 λ	全为零	全为零	全为零	高（欠拟合）
中等 λ	被激活（三个系数都非零）	全为零	全为零	中等
较小 λ		被激活	全为零	最低
极小 λ	非零	非零	被激活	略回升（过拟合）

用 1-SE rule：选 CV 误差在一个标准误以内的最简模型 → 保留组 1 + 组 2，剔除组 3。

第 4 步： 最终模型：

$$\hat{y} = \hat{\beta}_0 + \underbrace{(\hat{\beta}_1x_1 + \hat{\beta}_2x_2 + \hat{\beta}_3x_3)}_{\text{地段：全部保留}} + \underbrace{(\hat{\beta}_4x_4 + \hat{\beta}_5x_5 + \hat{\beta}_6x_6)}_{\text{户型：全部保留}} + \underbrace{(0 \cdot x_7 + 0 \cdot x_8)}_{\text{经济：整组剔除}}.$$

读出的结论：「地段和户型对房价有联合影响，经济指标在控制了地段和户型后没有额外解释力。」这句话比分变量 Lasso 的三变量散装结论干净得多，也更容易被领域专家接受。

为什么 L2 范数（不是平方）使整组可以恰好为零？

单变量 Lasso 用 $|\beta_j|$ 而非 β_j^2 来实现稀疏——绝对值在零点不可微，导数不连续。分组 Lasso 同理： $\|\beta_\ell\|_2$ （欧几里得范数）在 $\beta_\ell = \mathbf{0}$ 处不可微（梯度不存在），而 $\|\beta_\ell\|_2^2$ 在零点光滑可微。当一个组对当前残差的贡献不够大时，不可微性使最优点精确落在 $\beta_\ell = \mathbf{0}$ ——全组一并清零。换成平方范数就退化为组级岭回归，系数只收缩、不归零。

11.17.5 Lasso 的进一步性质

大量文献研究了 Lasso 在 $N, p \rightarrow \infty$ 时恢复正确模型的能力（Knight & Fu, 2000; Greenshtein & Ritov, 2004; Donoho, 2006b; Meinshausen & Bühlmann, 2006; Zhao & Yu, 2006; Wainwright, 2006 等）。

模型选择一致性条件：很多结果假设设计矩阵满足：

$$\max_{j \in S^c} \|\mathbf{x}_j^\top \mathbf{X}_S (\mathbf{X}_S^\top \mathbf{X}_S)^{-1}\|_1 \leq 1 - \epsilon, \quad \epsilon \in (0, 1].$$

即“好”变量 S 不应该与“噪声”变量 S^c 高度相关。

系数一致性问题：Lasso 将非零系数向零收缩，因此估计量不是一致的（即使 $N \rightarrow \infty$ ， $\hat{\beta}_j$ 也不收敛到 β_j ）。缓解方案：

- **Relaxed Lasso (Meinshausen, 2007)**：先用 Lasso 选变量，再对被选变量用更小的 λ 做第二次 Lasso；因为被选变量不再与噪声变量“竞争”，交叉验证会选到更小的 λ ；

- **SCAD 惩罚 (Fan & Li, 2005)**: 用非凸惩罚代替 $\lambda|\beta|$, 对大系数减少惩罚力度:

$$\frac{dJ_a(\beta, \lambda)}{d\beta} = \lambda \cdot \text{sign}(\beta) \left[I(|\beta| \leq \lambda) + \frac{(a\lambda - |\beta|)_+}{(a-1)\lambda} I(|\beta| > \lambda) \right], \quad a \geq 2. \quad (11.73)$$

当 $a \rightarrow \infty$ 时退化为不收缩——但非凸性使计算困难;

- **Adaptive Lasso (Zou, 2006)**: 使用加权惩罚 $\sum w_j |\beta_j|$, 其中 $w_j = 1/|\hat{\beta}_j|^\nu$ ($\hat{\beta}_j$ 为 OLS 估计, $\nu > 0$)。这是 $|\beta_j|^q$ ($q = 1 - \nu$) 惩罚的实用近似——保留了凸性而获得一致估计。

11.17.6 路径坐标优化 (Pathwise Coordinate Descent)

这是计算 Lasso 解的另一种重要算法 (与 LAR 互补):

第 1 步: 固定 λ , 对每个参数逐一优化 (其他参数固定在当前值);

第 2 步: β_j 的更新有显式解:

$$\tilde{\beta}_j(\lambda) \leftarrow S\left(\sum_{i=1}^N x_{ij}(y_i - \tilde{y}_i^{(j)}), \lambda\right), \quad (11.74)$$

其中 $\tilde{y}_i^{(j)} = \sum_{k \neq j} x_{ik} \tilde{\beta}_k(\lambda)$ 是排除变量 j 的当前拟合值, $S(t, \lambda) = \text{sign}(t)(|t| - \lambda)_+$ 是软阈值算子。

第 3 步: 循环所有变量直到收敛; 从 $\lambda_{\max}$ (所有系数为零的最大 λ) 开始, 逐步减小 λ , 用前一个解作为“热启动”。

优势:

- 在大问题上可以比 LAR 更快;
- 关键加速技巧: $\sum x_{ij}(y_i - \tilde{y}_i^{(j)})$ 可以快速更新, 且经常是保持 $\tilde{\beta}_j = 0$ 不变 (无需更新);
- 输出的是 λ 网格上的解 (而非整个解路径);
- 可应用于弹性网、分组 Lasso、融合 Lasso 等。

11.18 计算考量

最小二乘拟合的两种主要数值方法:

	Cholesky 分解	QR 分解
操作	对 $\mathbf{X}^\top \mathbf{X}$ 做 Cholesky	对 $\mathbf{X}$ 做 QR
运算量	$p^3 + Np^2/2$	Np^2
速度	$N \gg p$ 时可能更快	N 和 p 相当时更快
稳定性	较差（条件数平方放大）	更稳定

实践建议：大多数现代统计软件（R 的 `lm`、Python 的 `statsmodels`）使用 QR 分解，因为数值稳定性更重要。LAR 算法计算 Lasso 路径的运算量与单次 LS 拟合同阶。

11.19 小结

I. 模型、估计与几何

$$\underbrace{\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}}_{\text{线性模型}} \quad \begin{array}{l} \mathbf{X} : N \times (p+1), \text{ 固定设计} \\ \boldsymbol{\beta} : (p+1) \times 1, \text{ 未知常数} \\ \boldsymbol{\varepsilon} : \mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{X}] = \mathbf{0}, \text{ Var}(\boldsymbol{\varepsilon} \mid \mathbf{X}) = \sigma^2 \mathbf{I} \end{array}$$

↓ 平方损失下 ERM

$$\boxed{\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}} \xrightarrow{\text{几何}} \boxed{\hat{\mathbf{y}} = \mathbf{H} \mathbf{y}} \quad \begin{array}{l} \mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \\ \mathbf{H}^2 = \mathbf{H}, \text{ tr}(\mathbf{H}) = p+1 \end{array}$$

Gram-Schmidt: $\hat{\beta}_j = \frac{\langle \mathbf{z}_j, \mathbf{y} \rangle}{\langle \mathbf{z}_j, \mathbf{z}_j \rangle}$, $\mathbf{z}_j = \mathbf{x}_j$ 对 $\{\mathbf{z}_0, \dots, \mathbf{z}_{j-1}\}$ 的正交补

$$\downarrow \xrightarrow{\text{数值}} \mathbf{X} = \mathbf{Q}\mathbf{R}, \mathbf{R}\hat{\boldsymbol{\beta}} = \mathbf{Q}^\top \mathbf{y}, \text{ Var}(\hat{\beta}_j) = \frac{\sigma^2}{\|\mathbf{z}_j\|^2}$$

II. 推断层次（固定设计，条件于 $\mathbf{X}$ ）

	一阶 + 二阶矩	正态假设
条件	$\mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{X}] = \mathbf{0}$ $\text{Var}(\boldsymbol{\varepsilon} \mid \mathbf{X}) = \sigma^2 \mathbf{I}$	$\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$
$\hat{\boldsymbol{\beta}}$	$\mathbb{E}[\hat{\boldsymbol{\beta}}] = \boldsymbol{\beta}$ $\text{Var}(\hat{\boldsymbol{\beta}}) = (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2$	$\hat{\boldsymbol{\beta}} \sim \mathcal{N}(\boldsymbol{\beta}, (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2)$
单系数	Gauss-Markov: BLUE	$t_j = \frac{\hat{\beta}_j}{\hat{\sigma} \sqrt{v_j}} \sim t_{N-p-1}$ CI: $\hat{\beta}_j \pm t^{(1-\alpha/2)} \text{se}(\hat{\beta}_j)$
多系数	—	$F = \frac{(\text{RSS}_0 - \text{RSS}_1)/(p_1 - p_0)}{\text{RSS}_1/(N - p_1 - 1)} \sim F_{p_1 - p_0, N - p_1 - 1}$
联合	—	联合置信椭球（ F 分布）
$\downarrow \hat{\sigma}^2 = \frac{\text{RSS}}{N - p - 1} \xrightarrow{\text{预测}} \mathbb{E}[(Y_0 - \hat{f})^2] = \underbrace{\sigma^2}_{\text{不可约}} + \underbrace{\text{Var}(\hat{f}) + \text{Bias}^2(\hat{f})}_{\text{MSE}}$		

III. 正则化：偏差-方差与收缩方法

$$\underbrace{\text{MSE} = \text{Bias}^2 + \text{Var}}_{\text{偏差-方差权衡}} \xrightarrow{\text{用偏差换方差}} \begin{cases} \text{子集选择 (离散, 硬阈值)} \\ \text{Lasso } L_1 (\text{连续, 软阈值, 稀疏}) \\ \text{弹性网 } L_1 + L_2 \\ \text{岭回归 } L_2 (\text{连续, 比例收缩}) \end{cases}$$

↓ 正交设计下的解对比

	子集	Lasso	岭回归
正交解	硬阈值	$\text{sign}(\hat{\beta}_j)(\hat{\beta}_j - \lambda)_+$	$\hat{\beta}_j/(1 + \lambda)$
稀疏	✓	✓	×
凸优化	×	✓	✓
先验	spike-slab	拉普拉斯	高斯

↓ SVD 视角下的岭回归

$$\hat{\mathbf{y}}^{\text{ridge}} = \sum \mathbf{u}_j \frac{d_j^2}{d_j^2 + \lambda} (\mathbf{u}_j^\top \mathbf{y}) \quad \text{低方差方向收缩更多}$$

↓ Lasso 的计算路径

$$\text{LAR} \xrightarrow{\text{活跃变量等速推进}} \text{保持与残差等相关} \xrightarrow{\text{稍加修改}} \boxed{\text{Lasso 路径}}$$

$$\text{FS}_0 \xrightarrow{\epsilon \rightarrow 0} \text{增量前向分段} \xrightarrow{p \gg N \text{ 更平滑}} \text{Lasso 单调版}$$

$$\tilde{\beta}_j \leftarrow S\left(\sum x_{ij}(y_i - \tilde{y}_i^{(j)}), \lambda\right) \xrightarrow{\text{热启动} + \text{循环}} \boxed{\text{坐标下降: 大问题比 LAR 快}}$$

↓ 扩展：分组稀疏与去偏

$$\lambda \sum_{\ell} \sqrt{p_{\ell}} \|\beta_{\ell}\|_2 \xrightarrow{\text{零点不可微}} \text{分组 Lasso: 整组归零}$$

$$\text{SCAD} / \text{Adaptive} \xrightarrow{\text{非凸惩罚}} \text{减偏倚, 一致估计}$$

IV. 降维与多输出

$$\underbrace{\text{PCR}}_{\max \text{Var}(\mathbf{X}\boldsymbol{\alpha})} \longrightarrow \underbrace{\text{PLS}}_{\max \text{Cov}^2} \longrightarrow \underbrace{\text{CCA/SVD}}_{\max \text{Corr}(\mathbf{Y}\mathbf{u}, \mathbf{X}\mathbf{v})}$$

	PCR	PLS
准则	$\max \text{Var}(\mathbf{X}\boldsymbol{\alpha})$	$\max \text{Cov}^2(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha})$
用 $\mathbf{y}$	$\times$	$\checkmark (\hat{\phi}_{mj} \propto \langle \mathbf{x}_j^{(m-1)}, \mathbf{y} \rangle)$
正交化	—	每步后剔除 $\mathbf{z}_m$ 分量

↓ 多输出：从 SVD 到收缩

$$\mathbf{K} = \mathbf{U}\mathbf{D}\mathbf{V}^\top \rightarrow \text{降秩回归 (RRR): } \text{rank}(\mathbf{B}) \leq m, \text{ 硬截断}$$

↓ Curds&Whey: 用软收缩替代硬截断

$$\lambda_m = \frac{c_m^2}{c_m^2 + \frac{p}{N}(1 - c_m^2)}$$

	CCA	RRR	C+W
角色	看结构	硬截断建模	软收缩预测
输出	典型对 + c_m	低秩 $\hat{\mathbf{B}}(m)$	收缩预测值

$$\underbrace{\max \text{Corr}(\mathbf{Y}\mathbf{u}, \mathbf{X}\mathbf{v})}_{\text{CCA 优化}} \xrightarrow{\text{白化}} \underbrace{\max_{\|\tilde{\mathbf{u}}\|=\|\tilde{\mathbf{v}}\|=1} \tilde{\mathbf{u}}^\top \mathbf{K} \tilde{\mathbf{v}}}_{\|\tilde{\mathbf{u}}\|=\|\tilde{\mathbf{v}}\|=1} \xrightarrow{\text{SVD}} \boxed{\mathbf{K} = \mathbf{U}\mathbf{D}\mathbf{V}^\top}$$

$\mathbf{V} \rightarrow \mathbf{X}$ 端方向, $\mathbf{U} \rightarrow \mathbf{Y}$ 端方向, $\mathbf{D} \rightarrow c_m$ (典型相关系数)

核心要点:

1. 模型形式: $f(X) = \beta_0 + \sum_{j=1}^p X_j \beta_j$, 关于参数线性, X_j 可来自任意变换;
2. LS 估计: $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$, 几何上是 $\mathbf{y}$ 在 $\mathbf{X}$ 列空间的正交投影 (Hat matrix);
3. 推断层次: 一阶 + 二阶矩 $\Rightarrow$ 无偏 + BLUE (Gauss-Markov); 正态假设 $\Rightarrow t/F$ 检验 + 精确置信区间/椭圆;
4. 偏差-方差: $\text{MSE} = \text{Bias}^2 + \text{Var}$ ——正则化用偏差换方差, 在 MSE 上优于 LS;
5. 正则化谱系: 子集选择 (离散) $\rightarrow$ Lasso (L_1 , 稀疏 + 凸) $\rightarrow$ 弹性网 $\rightarrow$ 岭回归 (L_2 , 仅收缩);

6. 降维三兄弟: PCR(方差) $\rightarrow$ PLS(协方差 = 相关性 $\times$ 信号) $\rightarrow$ CCA/SVD(双向关联);
7. 多输出: CCA(探索结构) $\rightarrow$ 降秩回归 (硬截断建模) $\rightarrow$ C+W(软收缩预测)。

第十二章 分类的线性方法

本章聚焦于**决策边界为线性**的分类方法。虽然限制在线性边界，但通过基展开可以推广到二次或更一般的非线性边界。

12.1 引言

分类问题中，预测函数 $G(x)$ 取值于离散集合 $\mathcal{G}$ ，因此可将输入空间划分为对应各类的区域。若这些区域的边界是线性的，就称为**分类的线性方法**。

基本设定

设输入空间 $\mathcal{X} \subseteq \mathbb{R}^p$ ，类别标签集 $\mathcal{G} = \{1, 2, \dots, K\}$ 。 (X, Y) 服从联合分布 P_{XY} ，其中 $X \in \mathcal{X}$ ， $Y \in \mathcal{G}$ 。

判别函数与分类规则

一族判别函数 $\{\delta_k\}_{k \in \mathcal{G}}$ ， $\delta_k : \mathcal{X} \rightarrow \mathbb{R}$ 。分类器 $\hat{G} : \mathcal{X} \rightarrow \mathcal{G}$ 定义为取最大判别值：

$$\hat{G}(x) = \arg \max_{k \in \mathcal{G}} \delta_k(x). \quad (12.1)$$

用一阶逻辑精确表述（假设最大值唯一，否则约定取最小的 k ）：

$$\forall x \in \mathcal{X}, \quad \hat{G}(x) = k \iff \left(\forall j \in \mathcal{G} \setminus \{k\}, \delta_k(x) > \delta_j(x) \right).$$

决策边界

类别 k 与 ℓ ($k \neq \ell$) 之间的决策边界 $\mathcal{B}_{k\ell}$ 定义为使 δ_k 与 δ_ℓ 并列最大（且不小于其他任何类）的全体 x ：

$$\mathcal{B}_{k\ell} = \left\{ x \in \mathcal{X} \mid \delta_k(x) = \delta_\ell(x) \wedge \forall j \in \mathcal{G} \setminus \{k, \ell\}, \delta_k(x) \geq \delta_j(x) \right\}. \quad (12.2)$$

线性判别函数的充要条件

称 δ_k 是线性的，当且仅当：

$$\forall k \in \mathcal{G}, \exists \beta_k \in \mathbb{R}^p, \exists \beta_{k0} \in \mathbb{R}, \forall x \in \mathcal{X} : \quad \delta_k(x) = \beta_k^\top x + \beta_{k0}.$$

此时对任意 $k \neq \ell$, 由式 (12.2):

$$\mathcal{B}_{k\ell} = \left\{ x \in \mathcal{X} \mid (\beta_k - \beta_\ell)^\top x + (\beta_{k0} - \beta_{\ell0}) = 0 \right\},$$

即 $\mathbb{R}^p$ 中的一个超平面 (线性决策边界)。

若存在严格单调递增函数 $g: \mathbb{R} \rightarrow \mathbb{R}$ 使得 $g \circ \delta_k$ 是线性的, 则决策边界仍是线性的, 因为:

$$\forall k \neq \ell, \forall x \in \mathcal{X}: g(\delta_k(x)) = g(\delta_\ell(x)) \iff \delta_k(x) = \delta_\ell(x).$$

关键: 只要求 δ_k 的某个单调变换是线性的, δ_k 本身不必是线性的。

损失函数

损失函数是一个映射 $L: \mathcal{G} \times \mathcal{G} \rightarrow \mathbb{R}_{\geq 0}$, 其中 $L(g, \hat{g})$ 表示真类别为 g 、预测为 $\hat{g}$ 时的代价。最常用的 0-1 损失:

$$L(g, \hat{g}) = \mathbf{1}\{g \neq \hat{g}\} = \begin{cases} 0, & g = \hat{g}, \\ 1, & g \neq \hat{g}. \end{cases}$$

更一般地可用损失矩阵 $\mathbf{L} = (L_{k\ell})_{K \times K}$, 其中 $L_{k\ell} = L(k, \ell)$ 。

期望预测误差 (EPE)

分类器 $\hat{G}$ 的期望预测误差为损失在联合分布下的期望:

$$\text{EPE}(\hat{G}) = \mathbb{E}_{(X,Y) \sim P_{XY}} [L(Y, \hat{G}(X))]. \quad (12.3)$$

展开为积分形式 (记 f_X 为 X 的边缘密度, $P(Y = k \mid X = x)$ 为后验概率):

$$\text{EPE}(\hat{G}) = \int_{\mathcal{X}} \left[\sum_{k=1}^K L(k, \hat{G}(x)) \cdot P(Y = k \mid X = x) \right] f_X(x) dx. \quad (12.4)$$

逐点最小化: 要最小化 EPE, 等价于对每个 $x \in \mathcal{X}$ 独立地最小化括号内的条件期望——

$$\forall x \in \mathcal{X}, \quad \hat{G}_{\text{opt}}(x) = \arg \min_{g \in \mathcal{G}} \sum_{k=1}^K L(k, g) \cdot P(Y = k \mid X = x).$$

Bayes 分类器: EPE 的最优解

在 0-1 损失下, 逐点最小化简化为:

$$\hat{G}_{\text{Bayes}}(x) = \arg \min_{g \in \mathcal{G}} (1 - P(Y = g \mid X = x)) = \arg \max_{g \in \mathcal{G}} P(Y = g \mid X = x).$$

即: 选择后验概率最大的类别。

框架统一

将上述诸概念串成一条链：

$$\begin{array}{l}
 \text{判别函数族 } \{\delta_k\}_{k \in \mathcal{G}} \\
 \downarrow \quad \hat{G}(x) = \arg \max_k \delta_k(x) \\
 \text{EPE} = \mathbb{E}_{(X,Y)}[L(Y, \hat{G}(X))] \\
 \downarrow \quad \text{逐点最小化} \\
 \hat{G}_{\text{Bayes}}(x) = \arg \max_k P(Y = k \mid X = x)
 \end{array}$$

若取 $\delta_k(x) = P(Y = k \mid X = x)$ （或其单调变换如 $\log P(Y = k \mid X = x)$ ），则判别函数分类器 $\hat{G}$ 等价于 Bayes 分类器。实际算法（LDA、Logistic 回归等）通过不同方式估计这些后验概率或其单调变换，从而逼近 Bayes 最优解。

12.1.1 判别函数方法

一类通用方法是：对每个类别 k 建模一个判别函数 $\delta_k(x)$ ，然后分类到最大值：

$$\hat{G}(x) = \arg \max_{k \in \mathcal{G}} \delta_k(x). \quad (12.5)$$

如果 $\delta_k(x)$ （或其某个单调变换）是 x 的线性函数，则决策边界是线性的。

12.1.2 Logit 变换与 Logistic 模型

对于二分类，一个流行的后验概率模型是：

$$\Pr(G = 1 \mid X = x) = \frac{\exp(\beta_0 + \beta^\top x)}{1 + \exp(\beta_0 + \beta^\top x)}, \quad \Pr(G = 2 \mid X = x) = \frac{1}{1 + \exp(\beta_0 + \beta^\top x)}. \quad (12.6)$$

取 logit 变换 $\log[p/(1-p)]$ 后得到线性形式：

$$\log \frac{\Pr(G = 1 \mid X = x)}{\Pr(G = 2 \mid X = x)} = \beta_0 + \beta^\top x. \quad (12.7)$$

决策边界是 $\{x \mid \beta_0 + \beta^\top x = 0\}$ ，即一个超平面。

下面将 Logistic 回归套入前面建立的判别函数 / EPE 框架，逐一说明各符号的具体含义。

Logistic 回归中的 δ_k 是什么？

在 Logistic 回归中，自然地取后验概率作为判别函数：

$$\delta_1(x) = \Pr(G = 1 \mid X = x), \quad \delta_2(x) = \Pr(G = 2 \mid X = x) = 1 - \delta_1(x).$$

分类规则 $\hat{G}(x) = \arg \max_k \delta_k(x)$ 即选择后验概率较大的类别，等价于 Bayes 分类器（在 0-1 损失下最优）。

δ_k 本身并非线性，但单调变换后是线性的

这里的 $\delta_1(x)$ 是 sigmoid 函数，显然不是 x 的线性函数。但取 logit 变换

$$g(p) = \log \frac{p}{1 - p}$$

(g 在 $(0, 1)$ 上严格单调递增)，则有：

$$g(\delta_1(x)) = \log \frac{\Pr(G = 1 \mid X = x)}{\Pr(G = 2 \mid X = x)} = \beta_0 + \beta^\top x,$$

即 $g \circ \delta_1$ 是 x 的线性函数。

由于 g 严格单调递增，对任意 x ：

$$\delta_1(x) > \delta_2(x) \iff g(\delta_1(x)) > g(\delta_2(x)) \iff \beta_0 + \beta^\top x > 0.$$

因此决策边界 $\{x \mid \delta_1(x) = \delta_2(x)\}$ 等价于 $\{x \mid \beta_0 + \beta^\top x = 0\}$ ，是一个线性超平面。这正好印证了引言中的结论：只要存在某个单调变换使 δ_k 变为线性，决策边界就是线性的， δ_k 本身不必是线性的。

δ_k 的一般取法

除后验概率外，不同方法中 δ_k 还有多种自然取法，本质都是对「 x 属于第 k 类的证据强度」的某种度量：

$\delta_k(x)$ 的取法	来源方法	单调变换后线性？
$P(G = k \mid X = x)$	Bayes 最优	不一定
$\log P(G = k \mid X = x)$	等价 Bayes (log 单调)	不一定
$x^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k$	LDA	δ_k 本身就是线性的
$\beta_{k0} + \beta_k^\top x$ (直接建模)	指示矩阵回归	δ_k 本身就是线性的
$\beta_{k0} + \beta_k^\top x$ (log-odds 形式)	多类 Logistic 回归	其 logit 变换是线性的
$f_k(x) \pi_k$ (似然 $\times$ 先验)	Bayes 定理展开	取决于 f_k 假设

关键：只要各类使用同一个度量尺度（同一单调变换）， $\arg \max_k \delta_k(x)$ 的结果不变。

「后验概率」的理解

「后验」即后于数据、后于经验——看到证据 x 之后更新了的信念。由 Bayes 定理展开：

$$\underbrace{P(G = k | X = x)}_{\text{后验}} = \frac{\overbrace{f_k(x)}^{\text{似然}} \cdot \overbrace{\pi_k}^{\text{先验}}}{\underbrace{\sum_{j=1}^K f_j(x) \pi_j}_{\text{归一化常数}}},$$

其中:

- **先验** $\pi_k = P(G = k)$: 在看到任何特征之前, 样本属于第 k 类的初始信念;
- **似然** $f_k(x) = P(X = x | G = k)$: 已知属于第 k 类的前提下, 观察到 x 的可能性 (类条件密度);
- **后验** $P(G = k | X = x)$: 给定已观察到的 x , 属于第 k 类的更新后概率。

整条逻辑链为: 先验 $\xrightarrow{\text{数据 } x}$ 后验。这正是统计推断的核心思想, 也是 LDA (§4.3) 通过假设 f_k 为 Gaussian 来估计后验概率的理论基础。

训练的本质: 用数据估计 δ_k

前面把后验概率当作 δ_k , 自然会引出一个困惑: 训练时只有 $\{(x_i, y_i)\}_{i=1}^N$, 既不知道真实的 δ_k , 也不知道真实的 $P(G = k | X = x)$ ——为什么还能用它?

关键在于区分**理论目标**和**实践操作**:

理论: Bayes 分类器 $\arg \max_k P(G = k | X = x)$ 是 EPE 最小的最优解 (不可达上界)

实践: 用数据拟合参数化模型来**估计**后验, 而非直接使用真实后验

训练流程可以拆成三步:

- (1) **选定模型族:** 假设 δ_k 具有某种参数化形式 $\delta_k(x; \theta)$, 例如 Logistic 回归假设 $\log \frac{P(G=k)}{P(G=K)} = \beta_{k0} + \beta_k^\top x$;
- (2) **用数据估计参数:** 通过训练数据 $\{(x_i, y_i)\}$ 估计参数 $\hat{\theta}$ (MLE、最小二乘等), 得到 $\hat{\delta}_k(x) = \delta_k(x; \hat{\theta})$;
- (3) **预测:** 对新输入 x , 计算 $\hat{G}(x) = \arg \max_k \hat{\delta}_k(x)$ 。

不同方法估计后验的方式不同:

方法	如何估计后验
Logistic 回归	假设 log-odds 线性, 用 MLE 估计 β , 代入公式算 $\hat{P}(G = k X = x)$
LDA	假设 f_k 为 Gaussian 且等协方差, 用样本均值/协方差估计 $\hat{\mu}_k, \hat{\Sigma}$, 代入 Bayes 公式
KNN	用邻居类别比例直接估计 $\hat{P}(G = k X = x) = \frac{\#\{i \in \mathcal{N}(x): y_i = k\}}{ \mathcal{N}(x) }$

一句话: 真实后验是靶子, $\hat{\delta}_k$ 是射出的箭, 训练就是用 (X, Y) 校准瞄准的过程。

12.1.3 实操流程：从线性函数到分类决策


看完公式 (12.6) 和 (12.7)，自然会产生三个疑问：

- (1) 目标还是最小化 $\mathbb{E}[L(f(X), Y)]$ 吗？
- (2) 「单调变换」到底加在哪一步？
- (3) $\Pr(G = 1 \mid X = x)$ 在整个流程中起什么作用？

下面把完整流水线串起来。

预测阶段（前向传播）：三段式流水线

给定一个已训练好的系数 β_0, β ，对新输入 x 做分类经过三步：



关键洞察：Step 1 中的 $\eta(x)$ 就是那个「线性函数」；Step 2 中的 sigmoid（即 logit^{-1} ）就是那个「单调变换」。正向走是 $\eta \xrightarrow{\text{sigmoid}} p$ ，反向看就是 $\log \frac{p}{1-p} = \eta$ ，即 logit 变换。

由于 sigmoid 是单调的， $\eta(x) > 0 \iff p(x) > 0.5$ ，所以决策边界可以等价地写为 $\{x \mid \eta(x) = 0\}$ ，即 $\{x \mid \beta_0 + \beta^\top x = 0\}$ 。根本不需要显式计算 $p(x)$ 就能做分类。

训练阶段：用什么损失函数？

你的第一个直觉是对的——总体框架仍是最小化期望损失 $\mathbb{E}[L(f(X), Y)]$ 。但损失函数不是平方误差！

对于分类，我们有两层损失：

- 最终评估用 0-1 损失： $L(G, \hat{G}) = \mathbb{I}\{G \neq \hat{G}\}$ 。这是真正关心的指标，但它不可导，不能直接优化。
- 训练用负对数似然（交叉熵）：对二分类 Logistic 回归，第 i 个样本的损失为

$$\ell_i(\beta) = -\left[\mathbb{I}\{y_i = 1\} \log p(x_i) + \mathbb{I}\{y_i = 2\} \log(1 - p(x_i))\right], \quad (12.8)$$

其中 $p(x_i) = 1/(1 + e^{-(\beta_0 + \beta^\top x_i)})$ 。最小化 $\sum_i \ell_i(\beta)$ 等价于最大化似然。

注记 12.1. 为什么不用平方误差？如果强行对 0/1 标签做线性最小二乘（即 §4.2 的指示矩阵回归），拟合值 $\hat{f}(x)$ 可能 < 0 或 > 1 ，且会出现 masking。Logistic 回归通过 sigmoid 变换把输出压缩到 $[0, 1]$ ，解决了这个问题。

$\Pr(G = 1 \mid X = x)$ 的作用

后验概率 $p(x) = \Pr(G = 1 \mid X = x)$ 在整个流程中扮演三个角色：

- (1) **建模目标：**我们不是直接建模 $G(x)$ ，而是建模 $\Pr(G \mid X = x)$ ——一个 $[0, 1]$ 内的实数。这比直接输出离散标签信息更丰富。
- (2) **sigmoid 的输出：** $p(x)$ 是线性得分 $\eta(x)$ 经过 sigmoid 后的结果，是连接线性函数与分类决策的桥梁。
- (3) **置信度量：** $p(x)$ 不仅告诉我们分到哪一类，还告诉我们有多确信。例如 $p(x) = 0.51$ 和 $p(x) = 0.99$ 都预测类别 1，但后者置信度更高。

一句话总结

Logistic 回归 = 线性函数 $\xrightarrow{\text{sigmoid}}$ 概率 $\xrightarrow{>0.5}$ 分类 用交叉熵（而非 MSE）拟合

本章将讨论两种产生线性 log-odds 的方法：

- 线性判别分析 (LDA)；
- 线性 Logistic 回归。

二者本质区别在于线性函数拟合到训练数据的方式不同。

此外还介绍直接建模分离超平面的方法：感知机 (Rosenblatt, 1958) 和最优分离超平面 (Vapnik, 1996, 不可分情况见第 12 章)。

12.1.4 基展开：从线性到非线性

通过变量集的基展开，可以将线性边界推广为非线性边界。例如添加平方项和交互项：

$$X_1, X_2 \longrightarrow X_1, X_2, X_1^2, X_2^2, X_1 X_2,$$

增广为 $p(p+1)/2$ 个额外变量。增广空间中的线性函数映射到原始空间即为二次函数，从而实现二次决策边界（见图 4.1）。

任何基变换 $h: \mathbb{R}^p \rightarrow \mathbb{R}^q$ ($q > p$) 都可以类似使用，后续章节将进一步探讨。

12.1.5 本章对 f 的核心限制

本章名为「分类的线性方法」，对判别函数 f （或 δ_k ）的根本限制是：

决策边界必须是线性的（即 $\mathbb{R}^p$ 中的超平面）

但这并不意味着 $\delta_k(x)$ 或 $\Pr(G = k | X = x)$ 本身必须是 x 的线性函数。原书原文明确指出：

“Actually, all we require is that some monotone transformation of δ_k or $\Pr(G = k | X = x)$ be linear for the decision boundaries to be linear.”

也就是说：只要存在某个单调变换 g ，使得 $g(\delta_k(x))$ 是 x 的线性函数，那么决策边界 $\{x | \delta_k(x) = \delta_\ell(x)\}$ 就是线性的。

各方法以不同方式落实这一限制：

- (1) **指示矩阵回归 (§4.2)**：直接限制 $\hat{f}_k(x) = \beta_{k0} + \beta_k^\top x$ 为线性。这是最「刚性」的——不仅边界线性，拟合值本身也是线性的，导致 masking 问题。
- (2) **LDA (§4.3)**：通过分布假设间接实现。假设每类 $f_k(x)$ 为多元 Gaussian 且协方差矩阵相同 ($\Sigma_k = \Sigma$)，则 log-ratio 中的二次项抵消，自然导出线性判别函数 $\delta_k(x) = x^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k$ 。
- (3) **Logistic 回归 (§4.4)**：直接假设 log-odds 为线性： $\log \frac{\Pr(G=k)}{\Pr(G=K)} = \beta_{k0} + \beta_k^\top x$ 。这里限制的是后验概率的 logit 变换，而非判别函数本身。
- (4) **分离超平面方法**：显式地寻找一个超平面来分离类别。

为什么限制为线性？不是因为我们相信真实边界是线性的，而是出于**偏差-方差权衡**：线性边界的偏差可以接受，但其估计方差远低于复杂模型。数据往往只能支持简单边界，线性模型提供了稳定且可解释的解。此外，通过基展开 $h(X)$ 可以将线性限制推广为非线性边界（如二次判别边界），在对 β 保持线性的同时获得灵活性。

注记 12.2. QDA (§4.3) 放松了等协方差假设，边界变为二次的——这已超出「线性方法」的范畴，但仍属于参数化 Gaussian 框架内的自然推广。

12.2 指示矩阵的线性回归

12.2.1 模型设定

将 K 个类别用指示变量编码： $Y_k = 1$ 若 $G = k$ ，否则 0。 N 个训练样本构成 $N \times K$ 的指示响应矩阵 $\mathbf{Y}$ ，每行恰好有一个 1。

对 $\mathbf{Y}$ 的每一列同时拟合线性回归：

$$\hat{\mathbf{Y}} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}, \quad (12.9)$$

得到 $(p+1) \times K$ 的系数矩阵 $\hat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$ 。

对新观测 x 的分类规则：

$$\hat{G}(x) = \arg \max_{k \in \mathcal{G}} \hat{f}_k(x), \quad \text{其中 } \hat{f}(x) = (1, x^\top) \hat{\mathbf{B}}. \quad (12.10)$$

12.2.2 理论依据

一种形式化的理由是：将回归视为条件期望的估计。由于 $\mathbb{E}(Y_k | X = x) = \Pr(G = k | X = x)$ ，每个 Y_k 的条件期望是合理的估计目标。

关键在于：刚性线性回归对条件期望的近似有多好？

注记 12.3. 可以验证：只要模型有截距项， $\sum_k \hat{f}_k(x) = 1$ 对任意 x 成立。但 $\hat{f}_k(x)$ 可能为负或大于 1——这是线性回归刚性本质的后果，尤其是对训练数据凸包之外的预测。

通过基展开 $h(X)$ 上的线性回归，当 $N \rightarrow \infty$ 时自适应地增加基函数数量，可以一致地估计概率（第 5 章讨论）。

12.2.3 最近目标分类视角

令 t_k 为 $K \times K$ 单位矩阵的第 k 列（第 k 类的目标向量）。最小二乘准则可写为：

$$\min_{\mathbf{B}} \sum_{i=1}^N \|y_i - [(1, x_i^\top) \mathbf{B}]^\top\|^2. \quad (12.11)$$

分类时选择与拟合向量最近的目标：

$$\hat{G}(x) = \arg \min_k \|\hat{f}(x) - t_k\|^2. \quad (12.12)$$

这与最大化 $\hat{f}_k(x)$ 完全等价，因为平方范数是分量可分离的。

12.2.4 完整数值示例（ $N = 5$, $K = 3$, $p = 1$ ）

下面用一个具体的数据集走通全流程。

Step 1: 构造数据

5 个样本，1 个特征 X ，3 个类别：

i	X	类别 G
1	1	1
2	2	1
3	3	2
4	4	2
5	5	3

Step 2: 构建设计矩阵 $\mathbf{X}$ 和指示矩阵 $\mathbf{Y}$

$$\mathbf{X}_{5 \times 2} = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}, \quad \mathbf{Y}_{5 \times 3} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}.$$

$\mathbf{X}$ 第一列全是 1 (截距), 第二列是特征 X 。 $\mathbf{Y}$ 每行有且仅有一个 1。

Step 3: 计算 $\mathbf{X}^\top \mathbf{X}$ 和 $\mathbf{X}^\top \mathbf{Y}$

$$\mathbf{X}^\top \mathbf{X} = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}, \quad \mathbf{X}^\top \mathbf{Y} = \begin{pmatrix} 2 & 2 & 1 \\ 3 & 7 & 5 \end{pmatrix}.$$

Step 4: 求逆并计算系数矩阵 $\hat{\mathbf{B}}$

$$\det(\mathbf{X}^\top \mathbf{X}) = 5 \times 55 - 15^2 = 50, \quad (\mathbf{X}^\top \mathbf{X})^{-1} = \frac{1}{50} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} = \begin{pmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{pmatrix}.$$

$$\hat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} = \begin{pmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{pmatrix} \begin{pmatrix} 2 & 2 & 1 \\ 3 & 7 & 5 \end{pmatrix} = \begin{pmatrix} 1.3 & 0.1 & -0.4 \\ -0.3 & 0.1 & 0.2 \end{pmatrix}.$$

因此三个类的拟合函数为:

$$\hat{f}_1(x) = 1.3 - 0.3x, \quad \hat{f}_2(x) = 0.1 + 0.1x, \quad \hat{f}_3(x) = -0.4 + 0.2x.$$

验证: $\hat{f}_1(x) + \hat{f}_2(x) + \hat{f}_3(x) = (1.3 + 0.1 - 0.4) + (-0.3 + 0.1 + 0.2)x = 1$ 。

Step 5: 用 $\hat{\mathbf{B}}$ 对新点分类

新点 x	$\hat{f}_1(x)$	$\hat{f}_2(x)$	$\hat{f}_3(x)$	预测类别
2.5	$1.3 - 0.75 = 0.55$	$0.1 + 0.25 = 0.35$	$-0.4 + 0.50 = 0.10$	1
3.5	$1.3 - 1.05 = 0.25$	$0.1 + 0.35 = 0.45$	$-0.4 + 0.70 = 0.30$	2
5.5	$1.3 - 1.65 = -0.35$	$0.1 + 0.55 = 0.65$	$-0.4 + 1.10 = 0.70$	3


Step 6: 确定决策边界

令 $\hat{f}_k(x) = \hat{f}_\ell(x)$:

$$\text{类 1-2: } 1.3 - 0.3x = 0.1 + 0.1x \implies x = 3,$$

$$\text{类 2-3: } 0.1 + 0.1x = -0.4 + 0.2x \implies x = 5,$$

$$\text{类 1-3: } 1.3 - 0.3x = -0.4 + 0.2x \implies x = 3.4.$$



最终分类规则: $x < 3 \rightarrow$ 类别 1, $3 < x < 5 \rightarrow$ 类别 2, $x > 5 \rightarrow$ 类别 3。在本例中三类有序排列且分离良好, 没有发生 masking。

注记 12.4. 注意 $\hat{f}_2(5.5) = 0.65$ 和 $\hat{f}_3(5.5) = 0.70$ 都很正常 (在 $[0, 1]$ 内), 但 $\hat{f}_1(5.5) = -0.35$ 是负数——这就是线性回归刚性本质的体现: 在外推区域, 拟合值可能超出 $[0, 1]$ 。Logistic 回归通过 sigmoid 变换解决了这个问题。

12.2.5 Masking 问题

当 $K \geq 3$ 时, 线性回归存在严重的掩蔽 (masking) 问题: 某些类别可能被其他类别完全掩盖。

例 12.1 (三类完美分离的 masking). 图 4.2 展示了一个极端情况: 三类数据被线性决策边界完美分离, 但线性回归完全错过了中间类。将数据投影到连接三个类质心的直线上, 中间类的回归线是水平的, 其拟合值永远不会最大。

注记 12.5. 一个宽松的通用规则是: 如果 $K \geq 3$ 个类别排成一线, 可能需要高达 $K - 1$ 次的多项式才能区分它们。在 p 维输入空间中, 最坏情况下需要总次数 $K - 1$ 的通用多项式和交互项, 共 $O(p^{K-1})$ 个项。


12.2.6 Masking 数值演示 ($N = 5, K = 3, p = 1$)

下面构造一个会发生 masking 的数据集, 与上一节的正常示例对比。

数据构造: 让中间类「被夹击」

关键思路: 让类别 1 和类别 3 分别位于两端, 类别 2 孤零零在中间。

i	X	类别 G
1	0	1
2	1	1
3	4	2
4	7	3
5	8	3



Step 1-2: 构造 $\mathbf{X}$ 和 $\mathbf{Y}$

$$\mathbf{X}_{5 \times 2} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 4 \\ 1 & 7 \\ 1 & 8 \end{pmatrix}, \quad \mathbf{Y}_{5 \times 3} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{pmatrix}.$$

Step 3: 计算 $\mathbf{X}^\top \mathbf{X}$ 和 $\mathbf{X}^\top \mathbf{Y}$

$$\mathbf{X}^\top \mathbf{X} = \begin{pmatrix} 5 & 20 \\ 20 & 130 \end{pmatrix}, \quad \mathbf{X}^\top \mathbf{Y} = \begin{pmatrix} 2 & 1 & 2 \\ 1 & 4 & 15 \end{pmatrix}.$$

Step 4: 系数矩阵 $\hat{\mathbf{B}}$

$$\det = 5 \times 130 - 20^2 = 250, \quad (\mathbf{X}^\top \mathbf{X})^{-1} = \frac{1}{250} \begin{pmatrix} 130 & -20 \\ -20 & 5 \end{pmatrix} = \begin{pmatrix} 0.52 & -0.08 \\ -0.08 & 0.02 \end{pmatrix}.$$

$$\hat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} = \begin{pmatrix} 0.52 & -0.08 \\ -0.08 & 0.02 \end{pmatrix} \begin{pmatrix} 2 & 1 & 2 \\ 1 & 4 & 15 \end{pmatrix} = \begin{pmatrix} 0.96 & 0.20 & -0.16 \\ -0.14 & 0.00 & 0.14 \end{pmatrix}.$$

因此:

$$\boxed{\hat{f}_1(x) = 0.96 - 0.14x}, \quad \boxed{\hat{f}_2(x) = 0.20}, \quad \boxed{\hat{f}_3(x) = -0.16 + 0.14x}.$$

关键发现: $\hat{f}_2(x)$ 是常数 0.20, 斜率为零! 这意味着一根水平线——这正是 masking 的数学表现。

验证: $\sum_k \hat{f}_k(x) = (0.96 + 0.20 - 0.16) + (-0.14 + 0 + 0.14)x = 1$ 。

Step 5: 检验各类拟合值——谁在主导？

x	$\hat{f}_1(x)$	$\hat{f}_2(x)$	$\hat{f}_3(x)$	最大值
0	0.96	0.20	-0.16	类 1 (0.96)
2	0.68	0.20	0.12	类 1 (0.68)
4	0.40	0.20	0.40	类 1/3 平局 (0.40)
6	0.12	0.20	0.68	类 3 (0.68)
8	-0.16	0.20	0.96	类 3 (0.96)

在任意 x 处, $\hat{f}_2(x) = 0.20$ 永远不会是最大值!

Step 6: 从数学上看为什么会这样

求两两决策边界:

$$\text{类 1-2: } 0.96 - 0.14x = 0.20 \implies x \approx 5.43,$$


$$\text{类 2-3: } 0.20 = -0.16 + 0.14x \implies x \approx 2.57,$$

$$\text{类 1-3: } 0.96 - 0.14x = -0.16 + 0.14x \implies x = 4.$$

注意: 类 2「理论上应该统治」的区间是 $(2.57, 5.43)$ ——在这个区间内, $\hat{f}_2$ 同时大于 $\hat{f}_1$ 和 $\hat{f}_3$ 的 等等, 真的是这样吗?

$$x \in (2.57, 5.43) \implies \begin{cases} \hat{f}_1(x) < 0.20 & (\text{只在 } x > 5.43 \text{ 时}) \\ \hat{f}_3(x) < 0.20 & (\text{只在 } x < 2.57 \text{ 时}) \end{cases}$$

在 $(2.57, 5.43)$ 内, $\hat{f}_1(x) > 0.20$ 且 $\hat{f}_3(x) > 0.20$, 两者都不给 $\hat{f}_2$ 机会!



橙色阴影是类 2 本应统治的区间, 但被 $\hat{f}_1$ 和 $\hat{f}_3$ 的斜线从上方盖过。即使 $x = 4$ (类 2 唯一的训练点), $\hat{f}_1 = \hat{f}_3 = 0.40$ 也远超 $\hat{f}_2 = 0.20$ 。

与正常示例的对比

	正常示例 (前节)	Masking 示例 (本节)	原因
数据排列	1,1,2,2,3 (各类均匀)	1,1,2,3,3 (中间稀疏)	类 2 样本太少、太孤立
$\hat{f}_2$ 斜率	+0.10 (正斜率)	0 (水平线)	线性回归无法为上翘分配系数
类 2 是否出现	是, $3 < x < 5$	否, 永不最大	水平线被两条斜线全程压制

本质原因

线性回归对每个类的指示变量独立拟合一条直线。当中间类样本稀疏且被两端类「夹击」时，最小二乘倾向于给中间类分配**近零斜率**——因为任何非零斜率都会增大对两端类标签的残差，而最小二乘被两端类的多数样本主导。中间类于是变成水平线，被全程压制。

这也解释了为什么 **LDA 能解决 masking**：LDA 不是对每类独立拟合，而是通过共同的协方差矩阵 Σ 把所有类的几何关系耦合在一起。

为什么只有 1 个点时 $\hat{f}_2$ 恰好是常数？——最小二乘的视角

回到 $\hat{f}_2(x) = 0.20$ （斜率为零）这个结果。你的直觉很对： $\hat{f}_2$ 和 $\hat{f}_1, \hat{f}_3$ 是独立拟合的，给 $\hat{f}_2$ 加斜率不会直接影响另外两条线。那为什么最小二乘偏偏选择了斜率为零？

原因：简单线性回归的斜率公式。

$\hat{f}_2$ 只拟合类 2 的指示变量列： $\mathbf{y}_2 = (0, 0, 1, 0, 0)^\top$ 。这是 $N = 5$ 个点上的简单线性回归（带截距）。斜率的 OLS 公式为：

$$\hat{\beta}_{12} = \frac{\text{Cov}(x, y_2)}{\text{Var}(x)} = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_{2i} - \bar{y}_2)}{\sum_{i=1}^N (x_i - \bar{x})^2}.$$

代入数值： $\bar{x} = \frac{0+1+4+7+8}{5} = 4$ ， $\bar{y}_2 = \frac{1}{5} = 0.2$ 。

$$\begin{aligned} \text{Cov}(x, y_2) &= (0-4)(0-0.2) + (1-4)(0-0.2) + \underbrace{(4-4)(1-0.2)}_{=0} + (7-4)(0-0.2) + (8-4)(0-0.2) \\ &= (-4)(-0.2) + (-3)(-0.2) + 0 + (3)(-0.2) + (4)(-0.2) \\ &= 0.8 + 0.6 + 0 - 0.6 - 0.8 = 0. \end{aligned}$$

$$\hat{\beta}_{12} = \frac{0}{\text{Var}(x)} = 0.$$

协方差恰好为零！这不是巧合——因为类 2 唯一的训练点 $x = 4$ 恰好等于所有样本的均值 $\bar{x} = 4$ 。在最小二乘的几何中，回归直线必然经过 $(\bar{x}, \bar{y}_2) = (4, 0.2)$ 。此时类 2 的正样本就在「重心」上，**没有任何杠杆来撬动斜率**——无论向左还是向右倾斜，都会增大其余 4 个零标签点的残差，而不会改善 $x = 4$ 处的拟合（它已经被截距覆盖了）。

如果类 2 的点不在均值呢？

假设把类 2 的点从 $x = 4$ 移到 $x = 5$ （即数据变为 0, 1, 5, 7, 8），则：

$$\begin{aligned} \bar{x} = 4.2, \quad \text{Cov}(x, y_2) &= (-4.2)(-0.2) + (-3.2)(-0.2) + (0.8)(0.8) + (2.8)(-0.2) + (3.8)(-0.2) \\ &= 0.84 + 0.64 + 0.64 - 0.56 - 0.76 = 0.80, \end{aligned}$$

$$\hat{\beta}_{12} = \frac{0.80}{50.8} \approx 0.016, \quad \hat{f}_2(x) \approx 0.134 + 0.016x.$$

斜率不再是零，但非常接近零（几乎水平）。Masking 依然发生，只是不如斜率为零时那么「干净」。

结论：

$\hat{f}_2$ 为常数是**最小二乘 + 正样本位于重心**的共同结果，不是独立拟合的必然。

独立拟合意味着各 $\hat{f}_k$ 互不干扰，但每条 $\hat{f}_k$ 自身的斜率完全由最小二乘决定。当 $K \geq 3$ 且中间类样本稀疏时，最小二乘自然倾向于给中间类分配近零斜率，从而产生 masking。这正是 ESL 指出「指示矩阵回归本质上是刚性线性回归」的含义——刚性不在于各条线之间的耦合，而在于**每条线自身的线性约束 + 最小二乘准则**共同导致的脆弱性。

注记 12.6. 即使在 $x = 4$ （类 2 唯一训练点所在位置）， $\hat{f}_2(4) = 0.20$ 也小于 $\hat{f}_1(4) = \hat{f}_3(4) = 0.40$ ——连自己的训练样本都分不对。这是 masking 最直观的体现。

12.3 线性判别分析 (LDA)

12.3.1 Bayes 分类框架

分类的决策论 (§2.4) 指出，最优分类需要知道后验概率 $\Pr(G | X)$ 。设 $f_k(x)$ 为类别 k 下 X 的条件密度， π_k 为类别 k 的先验概率。由 Bayes 定理：

$$\Pr(G = k | X = x) = \frac{f_k(x)\pi_k}{\sum_{\ell=1}^K f_{\ell}(x)\pi_{\ell}}. \quad (12.13)$$

为什么最优分类需要 $\Pr(G | X)$ ？——从损失函数到后验概率

前面 §4.1–§4.2 讨论了各种分类方法，但始终没有显式写出 $\Pr(G | X)$ 和损失函数 $L(G, \hat{G})$ 之间的关系。这里补全。

给定 x ，预测类别 k 的期望损失：

设损失函数为 $L(g, \hat{g})$ ，其中 g 为真实类别， $\hat{g}$ 为预测类别。对于一个新的输入点 x ，若我们预测其类别为 k ，则该决策的**条件期望损失**为：

$$R(k | x) = \mathbb{E}_{G|X} [L(G, k) | X = x] = \sum_{\ell=1}^K L(\ell, k) \cdot \Pr(G = \ell | X = x). \quad (12.14)$$

即：遍历所有可能的真实类别 ℓ ，用后验概率加权对应的损失。

$\mathbb{E}[L(G, \hat{G})]$ 与 $R(k | x)$ 的关系：

上述 $R(k | x)$ 是**给定 x 之后**，选择类别 k 的条件风险。而我们在 §4.1 讨论的 $\mathbb{E}[L(G, \hat{G})]$ 是**无条件期望损失**。二者通过全期望公式（tower property）连接：

$$\mathbb{E}[L(G, \hat{G}(X))] = \mathbb{E}_X [\mathbb{E}_{G|X} [L(G, \hat{G}(X)) | X]] = \mathbb{E}_X [R(\hat{G}(X) | X)]. \quad (12.15)$$

展开为积分形式：

$$\mathbb{E}[L(G, \hat{G})] = \int_{\mathcal{X}} R(\hat{G}(x) | x) dP_X(x).$$

含义：整体期望损失 = 在每个 x 处查询分类器 $\hat{G}(x)$ 所选类别的条件风险 $R(\hat{G}(x) | x)$ ，再对 x 的分布取平均。

由此，Bayes 最优分类器的构造逻辑是**逐点最小化**——对每个 x 独立地选择使 $R(k | x)$ 最小的 k ：

$$\hat{G}^*(x) = \arg \min_{k \in \mathcal{G}} R(k | x), \quad (12.16)$$

其对应的 **Bayes 风险**（不可再降低的最小期望损失）为：

$$R^* = \mathbb{E}_X \left[\min_k R(k | X) \right]. \quad (12.17)$$

对任意分类器 $\hat{G}$ ，恒有 $\mathbb{E}[L(G, \hat{G})] \geq R^*$ 。

代入 0-1 损失：

对于分类问题最自然的损失——0-1 损失 $L(\ell, k) = \mathbb{I}\{\ell \neq k\}$ ：

$$\begin{aligned} R(k | x) &= \sum_{\ell=1}^K \mathbb{I}\{\ell \neq k\} \cdot \Pr(G = \ell | X = x) \\ &= \sum_{\ell \neq k} \Pr(G = \ell | X = x) \\ &= 1 - \Pr(G = k | X = x). \end{aligned} \quad (12.18)$$

预测为类别 k 的期望 0-1 损失 = $1 - \Pr(G = k | X = x)$

Bayes 最优分类器：

要最小化期望 0-1 损失，只需最大化后验概率。因此最优分类规则为：

$$\hat{G}^*(x) = \arg \max_{k \in \mathcal{G}} \Pr(G = k | X = x). \quad (12.19)$$

这就是「最优分类需要知道后验概率」的完整数学链条：

最小化 $\mathbb{E}[L(G, \hat{G})] \iff$ 逐点最小化 $R(k | x) \iff$ 最大化 $\Pr(G = k | X = x)$

推广到一般损失函数：

若损失不是 0-1（例如非对称损失：把「类 1 错判为类 2」的代价远大于反向），则 (12.14) 依然适用——只需将 $L(\ell, k)$ 替换为实际损失矩阵。此时最优分类不再是简单地取最大后验，而是取最小期望代价。

回到本章的方法：

本章所有方法本质上都是在**用不同方式估计** $\Pr(G = k | X = x)$ （或其单调变换）：

- LDA/QDA：假设 $f_k(x)$ 为 Gaussian $\rightarrow$ Bayes 定理 $\rightarrow$ 后验；
- Logistic 回归：直接参数化 log-odds $\rightarrow$ sigmoid $\rightarrow$ 后验；
- 指示矩阵回归：用 $\hat{f}_k(x)$ 近似 $\Pr(G = k | X = x)$ （但可能越界）。

LDA/QDA 如何逼近 Bayes 上界

Bayes 分类器 $\arg \max_k P(G = k \mid X = x)$ 给出了 EPE 的理论下界——但真实后验未知。LDA/QDA 的策略不是直接估计后验，而是通过 Bayes 定理把它拆成可估计的零件：

$$P(G = k \mid X = x) = \frac{f_k(x) \pi_k}{\sum_j f_j(x) \pi_j},$$

然后对类条件密度 $f_k(x)$ 做分布假设，用训练数据估计其参数。

二者的差异仅在于协方差假设：

	LDA	QDA
假设	$f_k \sim N(\mu_k, \Sigma)$, Σ 所有类共用	$f_k \sim N(\mu_k, \Sigma_k)$, Σ_k 各类不同
决策边界	线性超平面	二次曲面

逼近上界的逻辑：如果 Gaussian 假设恰好成立，代入估计参数后 $\hat{\delta}_k$ 在大样本下收敛到真实 Bayes 上界 ($\hat{\mu}_k \rightarrow \mu_k$ 等)。若假设不成立，则是有偏近似——偏差来自分布假设的错误，方差来自参数估计的不确定性。

LDA/QDA 的训练：估计什么参数？

LDA/QDA 的训练不涉及迭代优化或梯度下降——直接从 (X, Y) 计算样本统计量，然后组装成 δ_k ：

参数	含义	估计公式
$\hat{\mu}_k \in \mathbb{R}^p$	第 k 类均值	$\frac{1}{N_k} \sum_{i:y_i=k} x_i$ (类内样本均值)
$\hat{\Sigma} \in \mathbb{R}^{p \times p}$	LDA 公共协方差	$\frac{1}{N - K} \sum_{k=1}^K \sum_{i:y_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^\top$ (池化)
$\hat{\Sigma}_k \in \mathbb{R}^{p \times p}$	QDA 各类协方差	$\frac{1}{N_k - 1} \sum_{i:y_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^\top$ (各自估计)
$\hat{\pi}_k \in [0, 1]$	先验概率	N_k / N (类频率)，或由领域知识给定

最后将估计参数代入 LDA 的线性判别函数：

$$\delta_k(x) = x^\top \hat{\Sigma}^{-1} \hat{\mu}_k - \frac{1}{2} \hat{\mu}_k^\top \hat{\Sigma}^{-1} \hat{\mu}_k + \log \hat{\pi}_k,$$

或 QDA 的二次判别函数：

$$\delta_k(x) = -\frac{1}{2} \log |\hat{\Sigma}_k| - \frac{1}{2} (x - \hat{\mu}_k)^\top \hat{\Sigma}_k^{-1} (x - \hat{\mu}_k) + \log \hat{\pi}_k.$$

训练完成后，对新输入 x 只需计算这些 $\delta_k(x)$ 并取 $\arg \max$ 即可分类。

这与 Logistic 回归的本质区别在于：LDA 是**生成式**（建模 $P(X \mid G)$ ，再通过 Bayes 定理得后验），Logistic 回归是**判别式**（直接建模 $P(G \mid X)$ ，跳过了对 X 分布的假设）。

完整数值示例：从密度到后验到决策

下面用一个二分类一维 Gaussian 例子走完整个 Bayes 分类流水线。

设定：

- 类别 1: $X | G = 1 \sim \mathcal{N}(\mu_1 = 2, \sigma^2 = 1)$, 先验 $\pi_1 = 0.4$;
- 类别 2: $X | G = 2 \sim \mathcal{N}(\mu_2 = 5, \sigma^2 = 1)$, 先验 $\pi_2 = 0.6$ 。

两类的方差相同（这是 LDA 的前提），但先验不同。

Step 1: 对新点 $x = 3$, 计算类条件密度 $f_k(x)$ 。

$$f_k(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu_k)^2}{2\sigma^2}\right), \quad \frac{1}{\sqrt{2\pi}} \approx 0.3989.$$

$$f_1(3) = 0.3989 \cdot \exp\left(-\frac{(3-2)^2}{2}\right) = 0.3989 \cdot e^{-0.5} \approx 0.3989 \cdot 0.6065 = 0.2420,$$

$$f_2(3) = 0.3989 \cdot \exp\left(-\frac{(3-5)^2}{2}\right) = 0.3989 \cdot e^{-2} \approx 0.3989 \cdot 0.1353 = 0.0540.$$

Step 2: Bayes 定理 $\rightarrow$ 后验概率 $\Pr(G = k | X = 3)$ 。

$$\begin{aligned} \Pr(G = 1 | X = 3) &= \frac{f_1(3) \pi_1}{f_1(3) \pi_1 + f_2(3) \pi_2} \\ &= \frac{0.2420 \times 0.4}{0.2420 \times 0.4 + 0.0540 \times 0.6} = \frac{0.0968}{0.0968 + 0.0324} = \frac{0.0968}{0.1292} \approx \mathbf{0.749}, \end{aligned}$$

$$\Pr(G = 2 | X = 3) = 1 - 0.749 = \mathbf{0.251}.$$

Step 3: 计算条件风险 $R(k | x)$ (0-1 损失)。

$$R(1 | 3) = 1 - \Pr(G = 1 | X = 3) = 1 - 0.749 = \mathbf{0.251},$$

$$R(2 | 3) = 1 - \Pr(G = 2 | X = 3) = 1 - 0.251 = \mathbf{0.749}.$$

Step 4: 最优决策。

$$\hat{G}^*(3) = \arg \min_k R(k | 3) = \arg \max_k \Pr(G = k | X = 3) = \mathbf{1}.$$

在 $x = 3$ 处, 预测为类别 1 的期望 0-1 损失 (0.251) 远小于预测为类别 2 (0.749), 因此判为类别 1。

Step 5 (附加): 求决策边界。

决策边界是 $\Pr(G = 1 | X = x) = \Pr(G = 2 | X = x)$ 的位置, 即 $f_1(x) \pi_1 = f_2(x) \pi_2$:

$$0.4 \cdot \exp\left(-\frac{(x-2)^2}{2}\right) = 0.6 \cdot \exp\left(-\frac{(x-5)^2}{2}\right).$$

取对数:

$$\ln 0.4 - \frac{(x-2)^2}{2} = \ln 0.6 - \frac{(x-5)^2}{2}.$$

$$-0.9163 - \frac{x^2 - 4x + 4}{2} = -0.5108 - \frac{x^2 - 10x + 25}{2}.$$

两边乘以 2:


$$-1.8326 - (x^2 - 4x + 4) = -1.0216 - (x^2 - 10x + 25).$$

展开并消去 $-x^2$:

$$-1.8326 - x^2 + 4x - 4 = -1.0216 - x^2 + 10x - 25 \implies -6x = -20.189 \implies x \approx 3.365.$$

更简洁地用判别函数: 由于方差相等, 边界也可由 (12.21) 的特例得出:

$$x = \frac{\mu_1 + \mu_2}{2} - \frac{\sigma^2}{\mu_2 - \mu_1} \ln \frac{\pi_2}{\pi_1} = \frac{7}{2} - \frac{1}{3} \ln \frac{0.6}{0.4} = 3.5 - \frac{\ln 1.5}{3} \approx 3.5 - 0.135 = 3.365.$$



总结流水线:

$$\begin{aligned} & \text{类条件密度 } f_k(x) \\ & \downarrow \text{Bayes 定理} \\ & \text{后验概率 } \Pr(G = k \mid X = x) \\ & \downarrow \text{0-1 损失} \\ & \text{条件风险 } R(k \mid x) = 1 - \Pr(G = k \mid X = x) \\ & \downarrow \arg \min_k \\ & \text{最优分类 } \hat{G}^*(x) \end{aligned}$$

在本例中, 当 $x < 3.365$ 时判为类 1, 否则判为类 2。注意由于 $\pi_2 > \pi_1$, 边界从 $\frac{\mu_1 + \mu_2}{2} = 3.5$ 向左偏移到了 3.365——先验的差异会移动决策边界。

基于类条件密度的常见方法有:

- 线性/二次判别分析: 使用 Gaussian 密度;
- 混合 Gaussian: 允许非线性边界 (§6.8);
- 非参数密度估计: 最大灵活性 (§6.6.2);
- Naive Bayes: 假设各输入在类内条件独立 (§6.6.3)。

12.3.2 Gaussian 假设下的 LDA

假设每类密度为多元 Gaussian:

$$f_k(x) = \frac{1}{(2\pi)^{p/2} |\Sigma_k|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu_k)^\top \Sigma_k^{-1} (x - \mu_k)\right). \quad (12.20)$$

LDA 的特例: 假设各类协方差相同 $\Sigma_k = \Sigma$ (对所有 k)。比较两类 k 和 ℓ 时, 考虑 log-ratio:

$$\log \frac{\Pr(G = k | X = x)}{\Pr(G = \ell | X = x)} = \log \frac{\pi_k}{\pi_\ell} - \frac{1}{2}(\mu_k + \mu_\ell)^\top \Sigma^{-1} (\mu_k - \mu_\ell) + x^\top \Sigma^{-1} (\mu_k - \mu_\ell). \quad (12.21)$$

注记 12.7. 等协方差矩阵使得归一化因子和指数中的二次项相互抵消, log-ratio 成为 x 的线性函数。因此决策边界是超平面。

12.3.3 线性判别函数

从 (12.21) 可提取出等价的判别函数:

$$\delta_k(x) = x^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k. \quad (12.22)$$

分类规则为 $\hat{G}(x) = \arg \max_k \delta_k(x)$ 。

注记 12.8. 决策边界不是类质心连线的垂直平分线, 除非 $\Sigma = \sigma^2 \mathbf{I}$ 且各类先验相等。

12.3.4 参数估计

实践中参数由训练数据估计:

- $\hat{\pi}_k = N_k/N$, 其中 N_k 为第 k 类的样本数;
- $\hat{\mu}_k = \sum_{g_i=k} x_i / N_k$;
- $\hat{\Sigma} = \sum_{k=1}^K \sum_{g_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^\top / (N - K)$ (pooled 协方差)。

12.3.5 二分类 LDA 与最小二乘的对应

对于二分类, LDA 分类为类别 2 的条件是:

$$x^\top \hat{\Sigma}^{-1} (\hat{\mu}_2 - \hat{\mu}_1) > \frac{1}{2} (\hat{\mu}_1 + \hat{\mu}_2)^\top \hat{\Sigma}^{-1} (\hat{\mu}_2 - \hat{\mu}_1) - \log(N_2/N_1). \quad (12.23)$$

若将两类分别编码为 +1 和 -1, 最小二乘得到的系数向量与 LDA 方向成比例 (习题 4.2)。但除非 $N_1 = N_2$, 截距不同, 从而决策规则不同。

注记 12.9. LDA 方向通过最小二乘的推导不依赖于 Gaussian 假设, 因此适用范围超出 Gaussian 数据。但截距/切点的推导确实需要 Gaussian 假设。实践中, 可以选择经验上最小化训练误差的切点, 效果通常很好。

当 $K > 2$ 时, LDA 与指示矩阵的线性回归不再等价, 且 LDA 能避免 masking 问题。回归与 LDA 的对应可通过最优得分 (§12.5) 建立。

12.4 二次判别分析 (QDA)

若不假设各类协方差相等 (Σ_k 不同), 则 (12.21) 中的抵消不再发生, x 的二次项保留。得到二次判别函数:

$$\delta_k(x) = -\frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (x - \mu_k)^\top \Sigma_k^{-1} (x - \mu_k) + \log \pi_k. \quad (12.24)$$

每对类别之间的决策边界由二次方程 $\{x \mid \delta_k(x) = \delta_\ell(x)\}$ 描述。

12.4.1 参数数量

- LDA: $(K-1) \times (p+1)$ 个参数 (因为只需知道 $\delta_k(x) - \delta_K(x)$ 的差分);
- QDA: $(K-1) \times \{p(p+3)/2 + 1\}$ 个参数。

当 p 较大时, QDA 的参数数量急剧增加。

12.4.2 LDA 与 QDA 的性能讨论

LDA 和 QDA 在很多分类任务中表现优异。例如 STATLOG 项目 (Michie et al., 1994) 中:

- LDA 在 22 个数据集中的 7 个上进入前三;
- QDA 在 4 个数据集上进入前三;
- 二者之一在 10 个数据集上进入前三。

注记 12.10. LDA/QDA 表现好的原因不太可能是数据近似 Gaussian 且协方差近似相等。更可能的原因是: 数据只能支持简单的线性或二次决策边界, 而 Gaussian 模型提供的估计是稳定的。这是偏差-方差权衡——线性边界的偏差可以接受, 因为其方差远低于更复杂的替代方法。

12.5 正则化判别分析 (RDA)

Friedman (1989) 提出了 LDA 与 QDA 之间的折中方案: 将 QDA 的各类协方差向公共协方差收缩, 类似于岭回归的思想。

12.5.1 模型形式

正则化协方差矩阵:

$$\hat{\Sigma}_k(\alpha) = \alpha \hat{\Sigma}_k + (1 - \alpha) \hat{\Sigma}, \quad (12.25)$$

其中 $\hat{\Sigma}$ 是 LDA 的池化协方差矩阵。 $\alpha \in [0, 1]$ 控制从 LDA ($\alpha = 0$) 到 QDA ($\alpha = 1$) 的连续过渡, 通常通过交叉验证选择。

进一步可将 $\hat{\Sigma}$ 自身向标量协方差收缩:

$$\hat{\Sigma}(\gamma) = \gamma \hat{\Sigma} + (1 - \gamma) \hat{\sigma}^2 \mathbf{I}, \quad (12.26)$$

$\gamma \in [0, 1]$ 。将 $\hat{\Sigma}(\gamma)$ 替代 (12.25) 中的 $\hat{\Sigma}$, 得到由 (α, γ) 参数化的更一般的协方差族 $\hat{\Sigma}_k(\alpha, \gamma)$ 。

12.6 LDA 的计算

LDA 和 QDA 的计算可通过对角化协方差矩阵来简化。

12.6.1 对角化方法

对每个 $\hat{\Sigma}_k$ 做特征分解 $\hat{\Sigma}_k = U_k D_k U_k^\top$, 其中 U_k 为 $p \times p$ 正交矩阵, D_k 为对角正特征值矩阵。则判别函数 $\delta_k(x)$ 的两个成分简化为:

- 马氏距离: $(x - \hat{\mu}_k)^\top \hat{\Sigma}_k^{-1} (x - \hat{\mu}_k) = [U_k^\top (x - \hat{\mu}_k)]^\top D_k^{-1} [U_k^\top (x - \hat{\mu}_k)]$;
- 对数行列式: $\log |\hat{\Sigma}_k| = \sum_\ell \log d_{k\ell}$ 。

12.6.2 LDA 的球形化实现

为什么要球形化?

LDA 的判别函数 (12.22) 中, 核心项是马氏距离:

$$(x - \mu_k)^\top \Sigma^{-1} (x - \mu_k).$$

若直接使用欧氏距离 $\|x - \mu_k\|^2$, 则隐含假设协方差 $\Sigma = \sigma^2 \mathbf{I}$ (各向同性球状分布)。但实际数据常呈椭球状——不同方向上的方差不同, 且特征之间可能相关 (Σ 非对角)。

马氏距离通过 Σ^{-1} 对空间做了「扭曲」, 正确度量了在数据分布下的距离。但每分类一个新点都要算一次 $(\cdot)^\top \Sigma^{-1} (\cdot)$, 不够经济。球形化的思路是: 一次性把整个空间变换好, 此后距离计算退化为欧氏距离。

球形化变换

对公共协方差估计做特征分解：

$$\hat{\Sigma} = UDU^{\top}, \quad (12.27)$$

其中 U 为 $p \times p$ 正交矩阵（列是 $\hat{\Sigma}$ 的特征向量）， $D = \text{diag}(d_1, \dots, d_p)$ 为特征值对角矩阵（ $d_j > 0$ ）。

定义球形化变换：

$$X^* = D^{-\frac{1}{2}}U^{\top}X, \quad (12.28)$$

其中 $D^{-\frac{1}{2}} = \text{diag}(d_1^{-1/2}, \dots, d_p^{-1/2})$ 。

变换后的协方差

验证：变换后 X^* 的公共协方差成为单位矩阵：

$$\begin{aligned} \text{Cov}(X^*) &= D^{-\frac{1}{2}}U^{\top} \hat{\Sigma} U D^{-\frac{1}{2}} \\ &= D^{-\frac{1}{2}}U^{\top} (UDU^{\top}) U D^{-\frac{1}{2}} \\ &= D^{-\frac{1}{2}} D D^{-\frac{1}{2}} \\ &= \mathbf{I}. \end{aligned}$$

Sphering 的几何含义

$D^{-\frac{1}{2}}U^{\top}$ 这个操作分两步理解：

- (1) $U^{\top}X$ （旋转）：将坐标轴旋转到 $\hat{\Sigma}$ 的特征向量方向，消除特征间的相关性（使协方差矩阵对角化）；
- (2) $D^{-\frac{1}{2}}(\cdot)$ （缩放）：沿每个新坐标轴除以对应的标准差 $\sqrt{d_j}$ ，使各方向方差均变为 1。

几何上，原始空间中「1 单位马氏距离」的椭球 $\{x \mid x^{\top} \hat{\Sigma}^{-1} x = 1\}$ ，经变换后成为单位球面 $\{x^* \mid \|x^*\|^2 = 1\}$ 。

球形化后的分类规则

设 $\mu_k^* = D^{-\frac{1}{2}}U^{\top} \hat{\mu}_k$ 为球形化空间中的类质心。则在球形化空间中，马氏距离退化为欧氏距离：

$$(x - \hat{\mu}_k)^{\top} \hat{\Sigma}^{-1} (x - \hat{\mu}_k) = \|x^* - \mu_k^*\|^2.$$

因此 LDA 分类规则等价于：

$$\hat{G}(x) = \arg \max_k \delta_k(x) = \arg \max_k \left(x^{*\top} \mu_k^* - \frac{1}{2} \|\mu_k^*\|^2 + \log \hat{\pi}_k \right).$$

在球形化空间中， $-\frac{1}{2} \|\mu_k^*\|^2 + \log \hat{\pi}_k$ 是仅依赖类别的常数修正项。

简化情形：若各类先验相等（ $\pi_k \equiv 1/K$ ），修正项退化为仅依赖 $\|\mu_k^*\|^2$ ，分类简化为——在球形化空间中，到哪个质心最近就分到哪类。

两步实现总结

- (1) **球形化**: 对原始数据施加 (12.28), 一次性变换为「各向同性」空间;
- (2) **分类到最近质心**: 在球形化空间中计算到各类质心的欧氏距离, 取最近者 (必要时加 $\log \pi_k$ 修正)。

注记 12.11. 实际使用 `sklearn` 等库时无需手动实现这些步骤——库内部自动完成特征分解和球形化。但理解球形化有助于: 诊断 $\hat{\Sigma}$ 奇异 (特征值为零时 $D^{-\frac{1}{2}}$ 无定义 $\rightarrow$ 无法球形化 $\rightarrow$ 高维小样本下 LDA 失效), 以及理解后续降秩 LDA 的原理。

12.7 降秩线性判别分析

12.7.1 动机: 质心在低维仿射子空间中

K 个类质心 (p 维空间中的点) 必然落在至多 $K-1$ 维的仿射子空间中。若 $p \gg K$, 维度大幅降低。在定位最近质心时, 可忽略与该子空间正交方向上的距离——因为这些距离对各质心贡献相同, 不影响比较结果。

当 $K=3$ 时, 可将数据投影到二维平面上查看 (如图 4.4), 且不丢失 LDA 分类所需的任何信息。

12.7.2 Fisher 的判别准则

Fisher 不从 Gaussian 假设出发, 而是直接提出优化问题。




FIGURE 4.9. Although the line joining the centroids defines the direction of greatest centroid spread, the projected data overlap because of the covariance (left panel). The discriminant direction minimizes this overlap for Gaussian data (right panel).

图 12.1: 左图: 质心连线方向投影——虽然该方向质心分离最大, 但由于协方差结构, 投影后两类严重重叠。右图: Fisher 判别方向——同时考虑类内协方差, 投影后方差最小化、类间分离最大化 (Gaussian 数据下)。来源: ESL Figure 4.9。

如图 12.1 所示，仅沿质心连线方向投影是不够的——该方向虽然最大化质心间距，却忽略了数据本身的散布（协方差）。Fisher 的关键洞察是：**好的投影方向应同时最大化类间分离和最小化类内散布**。形式化地：

寻找线性组合 $Z = a^\top X$ ，使类间方差相对于类内方差最大化

这等价于最大化 Rayleigh 商：

$$\max_a \frac{a^\top B a}{a^\top W a}, \quad (12.29)$$

或等价地：

$$\max_a a^\top B a \quad \text{s.t.} \quad a^\top W a = 1,$$

其中 B 为类间散布矩阵， W 为类内散布矩阵。

各符号的精确含义

- $a \in \mathbb{R}^p \setminus \{0\}$ ：投影方向向量。投影操作 $z = a^\top x$ 将 p 维向量 x 压缩为标量 z （沿 a 方向的坐标）。任何非零 p 维向量都是候选方向，优化目标是从 $\mathbb{R}^p$ 中选出最好的那个。
- B （类间散布，**Between-class scatter**）：度量各类质心相对于总质心的散布程度，

$$B = \sum_{k=1}^K N_k (\mu_k - \mu)(\mu_k - \mu)^\top,$$

其中 μ_k 为第 k 类均值（质心）， μ 为全体总均值。对二分类退化为 $B \propto (\mu_1 - \mu_2)(\mu_1 - \mu_2)^\top$ （秩-1 矩阵，方向沿质心连线）。

- W （类内散布，**Within-class scatter**）：池化（pooled）的公共类内离差和，

$$W = \sum_{k=1}^K \sum_{i: y_i=k} (x_i - \mu_k)(x_i - \mu_k)^\top = \sum_{k=1}^K (N_k - 1) \hat{\Sigma}_k,$$

其中 $\hat{\Sigma}_k$ 为各类各自的协方差估计。注意 W 不分类别——它假设各类协方差相同（ $\Sigma_1 = \dots = \Sigma_K = \Sigma$ ），用一个公共 W 估计。这就是 LDA 的核心假设：等协方差。若各类协方差不同，则需用 QDA。

为什么是比值形式？

若只最大化 $a^\top B a$ （组间方差），问题病态——将 a 放大 10 倍， $a^\top B a$ 放大 100 倍，无上界。因此必须归一化。分母 $a^\top W a$ 是投影后的类内方差，比值 $a^\top B a / a^\top W a$ 就是**信噪比**（组间分离是「信号」，类内散布是「噪声」）。方向缩放时分子分母同比例变化，比值不变——优化良定。

比值形式和约束形式等价：

$$\max_a \frac{a^\top B a}{a^\top W a} \iff \max_a a^\top B a \quad \text{s.t.} \quad a^\top W a = 1.$$

后者将类内方差固定为 1，在此约束下最大化组间方差。

这是一个广义特征值问题，解 a_1 是 $W^{-1}B$ 的最大特征值对应的特征向量。后续方向 $a_2, a_3, \dots$ 在 W -正交约束下依次最大化 Rayleigh 商，对应 $W^{-1}B$ 的次大特征值对应的特征向量。

这些 a_ℓ 称为判别坐标 (discriminant coordinates) 或典型变量 (canonical variates)。

12.7.3 LDA 子空间的计算步骤

- (1) 计算 $K \times p$ 的类质心矩阵 M 和公共类内协方差矩阵 W ；
- (2) 计算 $M^* = MW^{-\frac{1}{2}}$ （利用 W 的特征分解）；
- (3) 计算 M^* 的协方差矩阵 B^* （类间协方差），做特征分解 $B^* = V^* D_B V^{*\top}$ ；
- (4) V^* 的列按特征值从大到小排列，定义了最优子空间的坐标。

结合以上步骤，第 ℓ 个判别变量为：

$$Z_\ell = v_\ell^\top X, \quad v_\ell = W^{-\frac{1}{2}} v_\ell^*.$$

12.7.4 用于分类与降维

降秩子空间不仅可用于数据可视化，还可直接用于分类——只需将距离计算限制在所选子空间内即可。可以证明这等价于附加约束（Gaussian 质心位于 $\mathbb{R}^p$ 的 L 维子空间中）的高斯分类规则。

12.7.5 Fisher 方法与 Gaussian LDA 的等价性

Fisher 的判别坐标 a_ℓ 与 Gaussian LDA 导出的 v_ℓ 完全相同（习题 4.1）。这意味着：

Fisher 判别 $\iff$ Gaussian LDA 的最优子空间

但 Fisher 的推导不依赖 Gaussian 假设，因此其适用范围更广。这里「更广」需精确理解：Fisher 和 Gaussian LDA 给出同一套判别方向，但二者提供的保证层次不同。

	Gaussian LDA	Fisher 判别
给出什么	方向 a_ℓ + 截距/切点（完整分类器）	仅给出方向 a_ℓ
依赖假设	$f_k \sim N(\mu_k, \Sigma)$	无分布假设（仅需均值、协方差存在）
方向最优性	Gaussian 下全体线性分类器中 EPE 最优	对任意分布，在方差比意义下是最优线性判别
切点最优性	Gaussian 下切点最优	不提供切点，需另行确定

关键区别：Fisher 只回答「往哪个方向投影使类间分离相对类内散布最大」——这仅涉及一阶矩和二阶矩，不依赖分布形状（偏态、厚尾、多峰均无妨）。而 Gaussian LDA 额外用 Gaussian 假设确定决策边界的具体位置（切点）。

因此：

- 若数据确实为 Gaussian 且等协方差：LDA 的完整分类器（方向 + 切点）是最优的；
- 若数据非 Gaussian：Fisher 方向仍然有效，但 Gaussian 导出的切点可能次优。此时可保留 Fisher 方向，通过训练集上扫描切点最小化分类误差来另行确定决策边界。

一句话：Fisher 保证方向对（任意分布成立）；Gaussian LDA 额外承诺截距也对（仅 Gaussian 下成立）。

12.7.6 总结

- Gaussian 分类（等协方差）→ 线性决策边界。通过球形化后分类到最近质心（加 $\log \pi_k$ 修正）。
- 只需相对距离 → 数据可限制在球形化空间中质心张成的子空间内。
- 该子空间可进一步分解为 centroid separation 意义上的递进最优子空间，等价于 Fisher 分解。

12.8 几何视角： W^{-1} -内积空间中的 LDA 与 Fisher

前面各节的推导可以统一到一个更深刻的几何框架下：一切操作本质上都是在由 W^{-1} （或 Σ^{-1} ）定义的内积空间中进行的。

12.8.1 W^{-1} -内积空间

以类内散布矩阵 W （对称正定）的逆作为度量矩阵，定义新内积：

$$\langle x, y \rangle_W = x^\top W^{-1} y.$$

(12.30)

W^{-1} 对称正定, 满足内积的三条公理 (对称、双线性、正定性), 因此 $(\mathbb{R}^p, \langle \cdot, \cdot \rangle_W)$ 是合法的内积空间。

导出:

$$\|x\|_W = \sqrt{\langle x, x \rangle_W} = \sqrt{x^\top W^{-1}x}, \quad d_W(x, y) = \|x - y\|_W = \sqrt{(x - y)^\top W^{-1}(x - y)}.$$

d_W 正是马氏距离 (Mahalanobis distance)。

12.8.2 标准内积 vs W^{-1} -内积

同一向量空间 $\mathbb{R}^p$ 上可定义不同内积, 度量不同的「形状」:

	标准欧氏内积 $x^\top y$	W^{-1} -内积 $x^\top W^{-1}y$
单位球形状	球面	椭球面 (贴合数据散布)
正交的含义	直角	马氏意义下的「不相关」
距离	欧氏距离	马氏距离

关键思想: Fisher/LDA 使用 W^{-1} -内积而非标准欧氏内积, 是因为它尊重数据本身的协方差结构——在数据散布大的方向上「距离单位」被压缩, 散布小的方向上被拉伸。这比强加外部标准欧氏几何更合理。

12.8.3 在此框架下重新理解 LDA

LDA 判别函数 (12.22) 用 W -内积改写:

$$\delta_k(x) = \langle x, \mu_k \rangle_W - \frac{1}{2} \|\mu_k\|_W^2 + \log \pi_k.$$

展开 $\|x - \mu_k\|_W^2 = \|x\|_W^2 - 2\langle x, \mu_k \rangle_W + \|\mu_k\|_W^2$, 消去与 k 无关的 $\frac{1}{2}\|x\|_W^2$, 得:

$$\hat{G}(x) = \arg \max_k \delta_k(x) = \arg \min_k \left(\frac{1}{2} \|x - \mu_k\|_W^2 - \log \pi_k \right).$$

LDA = 在 W^{-1} -内积空间中, 用马氏距离分类到最近质心, 以 $\log \pi_k$ 修正。

12.8.4 在此框架下重新理解 Fisher

Fisher 的 Rayleigh 商可写为:

$$R(a) = \frac{a^\top B a}{a^\top W a} = \frac{\text{标准内积下的组间方差}}{\|a\|_W^2}.$$

分子用标准内积度量组间分离, 分母用 W -范数归一化方向长度。做变量替换 $b = W^{1/2}a$, 问题退化为标准特征值问题。

Fisher = 在 W^{-1} -内积几何中寻找使信噪比最大的投影方向, 即 $W^{-1}B$ 的最大特征向量。

12.8.5 球形化的几何意义

球形化变换 $X^* = D^{-1/2}U^\top X$ (其中 $W = UDU^\top$) 等价于将 W^{-1} -内积空间等距映射到标准欧氏空间:

$$\langle x, y \rangle_W = x^\top W^{-1}y = (D^{-1/2}U^\top x)^\top (D^{-1/2}U^\top y) = \langle x^*, y^* \rangle_{\text{std}}.$$

即: 球形化是一次性地将弯曲的 W^{-1} -几何「拉直」为欧氏几何。此后所有操作退化为标准欧氏空间中的最近质心分类。

12.8.6 统一视角总结

概念	标准欧氏空间	W^{-1} -内积空间
内积	$x^\top y$	$x^\top W^{-1}y$
范数	$\ x\ $	$\ x\ _W$ (马氏范数)
距离	欧氏距离	马氏距离
单位球	球面	数据分布形状的椭球面
LDA 分类	—	马氏最近质心 + $\log \pi_k$
Fisher 方向	—	$W^{-1}B$ 的最大特征向量
球形化	—	将 W^{-1} -几何等距拉直为欧氏几何

一句话: LDA 和 Fisher 本质上都是在马氏距离定义的弯曲几何中做线性代数——Fisher 找该几何的「主轴」, LDA 用马氏距离做最近质心分类, 球形化是一次性将该几何拉直。

12.9 Logistic 回归

12.9.1 回到判别函数与 EPE 框架

在 §4.1 引言中建立了分类问题的严格框架: 判别函数 $\delta_k(x) \rightarrow \arg \max \rightarrow \hat{G}(x) \rightarrow$ EPE 最小化 $\rightarrow$ Bayes 分类器 $\arg \max_k P(G = k | X = x)$ 。Logistic 回归是该框架的直接实例化:

框架概念	Logistic 回归中的对应
$\delta_k(x)$	$p_k(x; \theta) = \Pr(G = k X = x; \theta)$, 即参数化后验概率
分类规则	$\hat{G}(x) = \arg \max_k p_k(x; \theta)$ (等价于 Bayes 分类器)
线性条件	不要求 δ_k 线性, 只要求 $\log \frac{p_k}{p_K}$ 是 x 的线性函数 (单调变换后线性)
损失函数	训练用交叉熵 (负对数似然); 最终评估用 0-1 损失
训练方式	最大似然估计 (MLE), 等价于最小化 EPE 的经验近似

与 LDA (§4.3) 的生成式路线不同, Logistic 回归走判别式路线: 直接参数化 $P(G | X)$ 的 log-odds, 跳过对 X 分布的建模。核心假设只有一条——log-odds 是 x 的线性函数。

12.9.2 模型设定

出发点: 我们有什么, 不知道什么

训练时手头只有数据 $\{(x_i, y_i)\}_{i=1}^N$ ($x_i \in \mathbb{R}^p$, $y_i \in \{1, \dots, K\}$), 并不知道真实的 $P(G = k | X = x)$ 。但引言中已证明 Bayes 分类器 $\arg \max_k P(G = k | X = x)$ 是 EPE 的最优解——因此目标不是使用真实后验, 而是用一个参数化模型去逼近它。这与回归中不知道真实 $f(x)$ 却用 $\hat{f}(x) = \hat{\beta}^\top x$ 去逼近的逻辑完全一致。

核心假设: log-odds 是线性的

Logistic 回归不假设 $P(G | X)$ 本身是线性的, 而是假设其 log-odds (logit 变换) 是 x 的线性函数。对 K 类问题:

$$\log \frac{\Pr(G = k | X = x)}{\Pr(G = K | X = x)} = \beta_{k0} + \beta_k^\top x, \quad k = 1, \dots, K-1. \quad (12.31)$$

注意:

- 这是假设, 不是从数据推导出的事实——是我们选择相信这个结构, 然后用数据去验证和拟合;
- 因为只对 $P(G | X)$ 做假设、不对 X 的分布做任何假设, Logistic 回归是判别式方法; 而 LDA 假设了 $X | G$ 的 Gaussian 分布, 是生成式方法。

从 log-odds 到后验概率

以最后一类 K 为参考类 (选择任意, 估计是等变的)。由 (12.31) 解出后验概率:

$$\Pr(G = k | X = x) = \frac{\exp(\beta_{k0} + \beta_k^\top x)}{1 + \sum_{\ell=1}^{K-1} \exp(\beta_{\ell 0} + \beta_\ell^\top x)}, \quad k = 1, \dots, K-1, \quad (12.32)$$

且 $\Pr(G = K | X = x) = 1 / (1 + \sum_{\ell=1}^{K-1} \exp(\beta_{\ell 0} + \beta_\ell^\top x))$ 。记全部参数为 $\theta = \{\beta_{10}, \beta_1, \dots, \beta_{(K-1)0}, \beta_{K-1}\}$, 概率简记为 $p_k(x; \theta) = \Pr(G = k | X = x; \theta)$ 。

当 $K = 2$ 时退化为一对 log-odds, 即 §4.1 中讨论的二分类形式。

训练的本质: 找参数 β

模型结构 (log-odds 线性) 已经定了, 剩下的工作是用数据 $\{(x_i, y_i)\}$ 来估计参数 β :

$$\text{训练} = \arg \min_{\beta} \left(\text{负对数似然} \ell(\beta) \right) = \arg \max_{\beta} \left(\text{观测数据的似然} \right).$$

训练结束后得到 $\hat{\beta}$ ，代入 (12.32) 即可算出任何新 x 的后验概率估计 $\hat{P}(G = k | X = x)$ ，从而分类。具体求解算法 (IRLS) 在下一节详述。

一句话：Logistic 回归 = 假设 log-odds 线性 + 用 MLE 拟合 β ，与线性回归「假设 f 线性 + 用最小二乘拟合 β 」逻辑完全相同。

12.9.3 拟合：最大似然与 IRLS

Logistic 回归通常通过最大化条件似然 $\Pr(G | X)$ 来拟合。由于 $\Pr(G | X)$ 完全指定了条件分布，适用多项分布。 N 个观测的对数似然为：

$$\ell(\theta) = \sum_{i=1}^N \log p_{g_i}(x_i; \theta). \quad (12.33)$$

二分类情形

用 0/1 编码： $y_i = 1$ 当 $g_i = 1$ ， $y_i = 0$ 当 $g_i = 2$ 。记 $p(x; \beta) = p_1(x; \beta)$ ，对数似然写为：

$$\ell(\beta) = \sum_{i=1}^N \left\{ y_i \log p(x_i; \beta) + (1 - y_i) \log(1 - p(x_i; \beta)) \right\} = \sum_{i=1}^N \left\{ y_i \beta^\top x_i - \log(1 + e^{\beta^\top x_i}) \right\}. \quad (12.34)$$

这里 $\beta = (\beta_{10}, \beta_1)$ ， x_i 包含常数项 1。

令导数为零得得分方程：

$$\frac{\partial \ell(\beta)}{\partial \beta} = \sum_{i=1}^N x_i (y_i - p(x_i; \beta)) = 0, \quad (12.35)$$

这是 $p + 1$ 个关于 β 的非线性方程。注意第一分量 ($x_{i1} = 1$) 给出 $\sum_i y_i = \sum_i p(x_i; \beta)$ ——观测类别 1 的数量等于期望类别 1 的数量。

Newton-Raphson 算法

需要 Hessian 矩阵：

$$\frac{\partial^2 \ell(\beta)}{\partial \beta \partial \beta^\top} = - \sum_{i=1}^N x_i x_i^\top p(x_i; \beta) (1 - p(x_i; \beta)). \quad (12.36)$$

Newton 更新为 $\beta^{\text{new}} = \beta^{\text{old}} - (\partial^2 \ell / \partial \beta \partial \beta^\top)^{-1} (\partial \ell / \partial \beta)$ 。

矩阵形式与 IRLS

记 $\mathbf{y}$ 为 y_i 向量， $\mathbf{X}$ 为 $N \times (p + 1)$ 矩阵， $\mathbf{p}$ 为拟合概率向量， $\mathbf{W}$ 为 $N \times N$ 对角权重矩阵（第 i 个对角元为 $p(x_i; \beta^{\text{old}})(1 - p(x_i; \beta^{\text{old}}))$ ）。则：

$$\frac{\partial \ell}{\partial \beta} = \mathbf{X}^\top (\mathbf{y} - \mathbf{p}), \quad \frac{\partial^2 \ell}{\partial \beta \partial \beta^\top} = -\mathbf{X}^\top \mathbf{W} \mathbf{X}.$$

Newton 步可改写为加权最小二乘形式：

$$\beta^{\text{new}} = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{z}, \quad \mathbf{z} = \mathbf{X} \beta^{\text{old}} + \mathbf{W}^{-1}(\mathbf{y} - \mathbf{p}), \quad (12.37)$$

其中 $\mathbf{z}$ 称为调整响应 (adjusted response)。

每次迭代求解加权最小二乘问题 $\beta^{\text{new}} \leftarrow \arg \min_{\beta} (\mathbf{z} - \mathbf{X}\beta)^\top \mathbf{W}(\mathbf{z} - \mathbf{X}\beta)$ 。该算法称为迭代重加权最小二乘 (IRLS)。

注记 12.12. 对数似然是凹函数，算法通常收敛。若罕见情况下似然下降，步长减半可保证收敛。对于多分类 ($K \geq 3$)，Newton 算法也可写为 IRLS 形式，但每观测有一个 $K - 1$ 维响应向量和对角块权重矩阵。实际中可用坐标下降方法（如 R 包 `glmnet`）高效拟合。

12.9.4 示例：南非心脏病数据

表 4.2 展示了对南非心脏病数据的 Logistic 回归拟合结果。该数据来自 CORIS 基线调查，响应变量为心肌梗死 (MI) 的有无（总体患病率 5.1%），包含 160 个病例和 302 个对照。

输出包括每个系数的 Z 得分（系数除以其标准误）。Z 得分不显著（绝对值 < 2 ）的变量可考虑从模型中剔除，对应于 Wald 检验（零假设为该系数为零而其他系数不变）。显著性水平 5% 对应 $|Z| \approx 2$ 。

该例揭示了几个意外：**sbp**（收缩压）不显著，而 **obesity**（肥胖）的系数甚至为负——这并不意味着肥胖对心脏病有保护作用，而是可能被其他变量（如年龄、ldl）所解释（多重共线性效应）。典型分析中需要拟合多个模型来寻找简约且包含交互项的子集。

注记 12.13. Logistic 回归与 LDA 的关键区别：

- LDA 是生成式：假设 $X | G$ 的分布 $\rightarrow$ Bayes 定理 $\rightarrow$ 后验，log-odds 自然为线性（若等协方差）；
- Logistic 回归是判别式：直接假设 log-odds 为线性，不对 X 的分布做任何假设。

这使得 Logistic 回归比 LDA 更一般、更鲁棒（不依赖 Gaussian 假设），但在数据确实近似 Gaussian 且等协方差时效率略低于 LDA。

12.9.5 二次近似与推断

与加权最小二乘的联系

在 IRLS 的收敛点 $\hat{\beta}$ 处，调整响应与拟合值满足精确的加权最小二乘关系：

$$\hat{\beta} = \arg \min_{\beta} (\mathbf{z} - \mathbf{X}\beta)^\top \mathbf{W}(\mathbf{z} - \mathbf{X}\beta), \quad (12.38)$$

其中权重 $w_i = \hat{p}_i(1 - \hat{p}_i)$ 依赖于 $\hat{\beta}$ 本身。这一联系不仅提供了计算上的便利，还有更多统计推断上的价值。

Pearson 卡方与离差

加权残差平方和正是熟悉的 Pearson 卡方统计量：

$$\sum_{i=1}^N \frac{(y_i - \hat{p}_i)^2}{\hat{p}_i(1 - \hat{p}_i)}, \quad (12.39)$$

它是离差 (deviance) 的二次近似。离差定义为模型拟合的对数似然的两倍差值（类比线性回归中的残差平方和）。

渐近理论

若模型设定正确，最大似然估计具有优良的大样本性质：

- **一致性：** $\hat{\beta} \xrightarrow{P} \beta$ （样本量增大时收敛到真值）；
- **渐近正态性：** $\hat{\beta} \sim N(\beta, (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1})$ 。该结果可直接从加权最小二乘的类比导出。

模型选择的快捷方法

Logistic 回归中每个子模型都需迭代拟合，计算开销较大。常用的不需要重新完整迭代的方法：

- **Rao 得分检验 (score test)：** 检验是否可以添加某个变量（基于当前模型的得分函数，无需拟合更大模型）；
- **Wald 检验：** 检验是否可以剔除某个变量（利用当前模型的 $\hat{\beta}$ 和标准误）。

两者均等价于在加权最小二乘中添加/剔除一项（使用相同权重），计算高效。

GLM 框架

R 中广义线性模型 (GLM) 软件将上述联系充分工具化：Logistic 回归作为二项分布族模型处理，GLM 对象可视为线性模型对象，所有线性模型的诊断工具（残差图、杠杆值等）均可自动应用。

几何解释：W-加权内积空间

上述所有操作可以在统一的几何框架下理解。

定义 W-内积： 对 $\mathbf{u}, \mathbf{v} \in \mathbb{R}^N$ ，定义

$$\langle \mathbf{u}, \mathbf{v} \rangle_W = \mathbf{u}^\top \mathbf{W} \mathbf{v} = \sum_{i=1}^N w_i u_i v_i,$$

对应范数 $\|\mathbf{u}\|_W = \sqrt{\langle \mathbf{u}, \mathbf{u} \rangle_W}$ 。这是 $\mathbb{R}^N$ 上的**加权欧氏内积**——每观测按其权重 w_i 被赋予不同重要性。

注意与 LDA 中 W^{-1} -内积的区别：

	LDA/Fisher	IRLS/Logistic
空间	$\mathbb{R}^p$ (特征空间)	$\mathbb{R}^N$ (观测空间)
度量矩阵	Σ^{-1} (固定)	$W = \text{diag}(p_i(1-p_i))$ (逐轮变化)
含义	马氏距离几何	加权残差几何

IRLS 的几何意义：每次 Newton 迭代等价于求 $\mathbf{z}$ 在 $\mathbf{X}$ 列空间中的 W -正交投影：

$$\mathbf{X}\hat{\beta} = P_W^{\mathbf{X}}\mathbf{z}, \quad \mathbf{X}^\top W(\mathbf{z} - \mathbf{X}\hat{\beta}) = 0.$$

即残差与 $\mathbf{X}$ 的每一列在 W -内积意义下正交。对比普通最小二乘，仅将正交性从「等权重」推广为「 w_i 加权」。

Pearson 卡方的几何意义：残差向量在 W^{-1} -范数下的平方长度，

$$\text{Pearson } \chi^2 = \sum_{i=1}^N \frac{(y_i - \hat{p}_i)^2}{\hat{p}_i(1 - \hat{p}_i)} = (\mathbf{y} - \hat{\mathbf{p}})^\top W^{-1}(\mathbf{y} - \hat{\mathbf{p}}) = \|\mathbf{y} - \hat{\mathbf{p}}\|_{W^{-1}}^2.$$

同一个 W ：正向用于拟合（ W -范数加权 LS），逆向用于检验（ W^{-1} -范数标准化残差）。

这里关键厘清两条线的方向：

- **IRLS 的 W ：** $W = \text{diag}(p_i(1-p_i)) = \text{diag}(\text{Var}(\hat{Y}_i))$ 。权重就是方差本身——方差大的点（ $\hat{p}_i \approx 0.5$ ，模型不确定）被赋予更高权重，IRLS 重点关注。
- **Pearson 的 W^{-1} ：** $W^{-1} = \text{diag}(1/\text{Var}(\hat{Y}_i))$ 。方差大的点除以大方差 → 容忍更大残差；方差小的点除以小方差 → 微小残差也被放大惩罚。拟合阶段多关注模糊点，检验阶段多挑剔确信点。

W^{-1} -范数与 Pearson 型统计量在其他 GLM 中的推广：上述「残差除以方差」的结构是 GLM 的通用模式。对 $Y_i \sim$ 指数族分布， $\text{Var}(Y_i) = \phi V(\mu_i)$ （ V 为方差函数）。IRLS 的权重 W_{ii} 来自 Hessian，等于 $V(\mu_i)$ （对典型链接）；Pearson 统计量除以 $V(\mu_i)$ ，即使用 W^{-1} 。不同分布下的对应：

分布	$V(\mu)$ (方差函数)	IRLS 权重 W_{ii}	Pearson 分母 = W_{ii}^{-1}
Bernoulli	$\mu(1-\mu)$	$\mu_i(1-\mu_i)$	$\mu_i(1-\mu_i)$ (除以它)
Poisson	μ	μ_i	μ_i
Gaussian	1	1	1 (即普通 RSS)
Gamma	μ^2	μ_i^2	μ_i^2

注意：IRLS 的 W_{ii} 和 Pearson 的分母数值相同（都是 $V(\mu_i)$ ），但作用方向相反——IRLS 乘它（ W -范数），Pearson 除它（ W^{-1} -范数）。

统一形式：

$$\text{Pearson } \chi^2 = \sum_i \frac{(y_i - \hat{\mu}_i)^2}{\text{Var}(\hat{Y}_i)} = \|\mathbf{y} - \hat{\boldsymbol{\mu}}\|_{W^{-1}}^2, \quad W = \text{diag}(\text{Var}(\hat{Y}_i)).$$

核心不变： $W_{ii} = \text{Var}(\hat{Y}_i)$ ——方差大的点 IRLS 重点关注（乘），Pearson 宽容对待（除）。

权重 w_i 的来源： $w_i = p_i(1 - p_i)$ 并非人为设定，而是 Logistic 回归 Hessian 的必然结果。对数似然的 Hessian 为 $\partial^2 \ell / \partial \beta \partial \beta^\top = -\mathbf{X}^\top \mathbf{W} \mathbf{X}$ ，Newton 步重排后自然导出加权 LS 形式。 $p(1 - p)$ 是 Bernoulli 分布的方差——当 $\hat{p}_i \approx 0.5$ （模型不确定）， w_i 最大；当 $\hat{p}_i \approx 0$ 或 1（模型确信）， $w_i \rightarrow 0$ 。IRLS 因此自适应地关注分类边界附近最模糊的样本。

W-加权内积的起源与推广：加权欧氏内积并非 Logistic 回归的专属发明，其思想可追溯至 Gauss (1821) 和 Aitken (1934) 的广义最小二乘 (GLS)——当误差具有异方差性时，按方差的倒数加权修正。Logistic 回归的 IRLS 借用了这一既有数学结构。该方法在统计中广泛应用：

应用场景	w_i 的来源	含义
异方差线性回归	$w_i = 1/\sigma_i^2$	噪声小的观测更可信
加权最小二乘 (WLS)	用户指定	对特定数据点赋予优先拟合
GLM (IRLS)	$w_i = 1/\text{Var}(Y_i) \cdot (\partial \mu_i / \partial \eta_i)^2$	Fisher 信息权重
鲁棒回归	$w_i = \psi(r_i)/r_i$	自动降权离群点
核平滑/局部回归	$w_i = K_h(x - x_i)$	靠近目标点的观测权重大
逆概率加权 (IPW)	$w_i = 1/\text{Pr}(\text{observed})$	因果推断中校正选择偏差

这些方法的共同结构： $\hat{\beta} = \arg \min_{\beta} \|\mathbf{y}_{\text{adj}} - \mathbf{X}\beta\|_W^2$ ，其中 W 可为已知常数、依赖参数的变量、或依赖目标位置的函数。 W -加权内积本质上是「给不同观测赋不同重要性」的数学表达。

12.9.6 L_1 正则化 Logistic 回归

Lasso (§3.4.2) 的 L_1 惩罚可应用于 Logistic 回归，实现变量选择与系数收缩。最大化带惩罚的对数似然：

$$\max_{\beta_0, \beta} \left\{ \sum_{i=1}^N [y_i(\beta_0 + \beta^\top x_i) - \log(1 + e^{\beta_0 + \beta^\top x_i})] - \lambda \sum_{j=1}^p |\beta_j| \right\}. \quad (12.40)$$

求解方法：利用与 Newton 算法相同的二次近似，可通过反复应用加权 Lasso 算法求解。非零系数的得分方程形式为：

$$\mathbf{x}_j^\top (\mathbf{y} - \mathbf{p}) = \lambda \cdot \text{sign}(\beta_j), \quad (12.41)$$

这推广了 §3.4.4 中线性回归 Lasso 的类似方程——活跃变量在「与残差的广义相关性」上被绑定。

系数路径：由于目标函数的非线性，系数路径是分段光滑而非分段线性的。但使用二次近似仍可追踪。R 包 `glmnet` (Friedman et al., 2010) 可高效拟合大规模 (N 大或 p 大) Logistic 回归问题，并支持稀疏矩阵 $\mathbf{X}$ 。详见 §18.4 对 L_1 正则化多项模型的讨论。

12.9.7 Logistic 回归还是 LDA?

形式上的等价

在 Gaussian 且等协方差假设下, LDA 的对数后验比也是 x 的线性函数 (见 (12.21)):

$$\log \frac{\Pr(G = k \mid X = x)}{\Pr(G = K \mid X = x)} = \alpha_{k0} + \alpha_k^\top x.$$

Logistic 回归直接假设 log-odds 为线性:

$$\log \frac{\Pr(G = k \mid X = x)}{\Pr(G = K \mid X = x)} = \beta_{k0} + \beta_k^\top x.$$

形式上完全一样——但线性系数的估计方式不同。

似然分解视角

将 X 和 G 的联合密度分解为:

$$\Pr(X, G = k) = \underbrace{\Pr(X)}_{\text{边缘密度}} \cdot \underbrace{\Pr(G = k \mid X)}_{\text{logit-线性}}. \quad (12.42)$$

- **Logistic 回归:** $\Pr(X)$ 完全放任自流——用经验分布 (每观测赋质量 $1/N$) 非参数估计; 只对 $\Pr(G \mid X)$ 的参数做条件似然最大化。
- **LDA:** 对 $\Pr(X)$ 施加 Gaussian 混合结构:

$$\Pr(X) = \sum_{k=1}^K \pi_k \phi(X; \mu_k, \Sigma),$$

并通过最大化全似然 (包括 $\Pr(X)$ 部分) 来估计参数。

效率与鲁棒性的权衡

LDA 的额外假设 ($\Pr(X)$ 为 Gaussian 混合) 既是优势也是代价:

- **优势——更高效率:** 若真实 $f_k(x)$ 确实是 Gaussian, LDA 利用了更多信息, 参数估计方差更低。Efron (1975) 指出忽略边缘部分最多损失约 30% 的渐近效率——即 Logistic 回归需要多约 30% 数据才能达到相同的误分类率。
- **代价——缺乏鲁棒性:** 远离决策边界的观测点仍然对协方差估计有贡献 $\rightarrow$ LDA 对离群点敏感。此外, 即使没有标签的观测在混合模型中也提供参数信息 (虽然标签昂贵、无标签数据便宜时可利用)。
- **完全分离问题:** 若两类可被超平面完美分离, Logistic 回归的 MLE 无定义 (系数趋于无穷, 习题 4.5); 而 LDA 由于 Gaussian 假设的正则化效应, 系数仍有限。

12.9.8 LDA 和 Logistic 回归总结

	LDA	Logistic 回归
建模方式	生成式： $X G$ 的分布 + Bayes 定理	判别式：直接建模 $P(G X)$
对 X 的假设	$f_k \sim N(\mu_k, \Sigma)$	无任何假设
参数估计	最大化全似然（含 $\Pr(X)$ 部分）	最大化条件似然
效率（Gaussian 成立时）	更高（30% 渐近优势）	略低
鲁棒性	对离群点敏感	更鲁棒
完美分离时	系数有限	MLE 无定义（ $\rightarrow \infty$ ）
参数个数	$(K - 1) \times (p + 1)$	$(K - 1) \times (p + 1)$ （相同）

12.10 分离超平面

LDA 和 Logistic 回归都通过不同方式估计线性决策边界。分离超平面分类器走另一条路：**显式地构造一个尽可能好地分离各类数据的线性边界**。它们是第 12 章支持向量机的基础。

12.10.1 超平面的线性代数

超平面（仿射集）定义为 $\{x \mid f(x) = \beta_0 + \beta^\top x = 0\}$ 。其基本性质：

- (1) 对 L 上任意两点 x_1, x_2 , $\beta^\top (x_1 - x_2) = 0$, 故 $\beta^* = \beta / \|\beta\|$ 是 L 的单位法向量；
- (2) 对 L 上任一点 x_0 , $\beta^\top x_0 = -\beta_0$;
- (3) 任意点 x 到 L 的带符号距离为：

$$\beta^{*\top}(x - x_0) = \frac{1}{\|\beta\|}(\beta^\top x + \beta_0) = \frac{1}{\|f'(x)\|}f(x).$$

(12.43)

即 $f(x)$ 与 x 到超平面的带符号距离成正比。

12.10.2 Rosenblatt 感知机学习算法

感知机（Rosenblatt, 1958）试图通过最小化误分类点到决策边界的距离来寻找分离超平面，奠定了 1980–90 年代神经网络的基础。

动机：一条不断修正的线

感知机的核心思想极其朴素：找一条直线把两堆点分开，分错了就往正确方向挪一挪。用几何直觉来理解：在 $\mathbb{R}^2$ 中有一面墙（超平面），红点在左、蓝点在右。目标是调整墙的角度和位置，使所有点都在正确的一侧。算法流程为：

- (1) 随机初始化一面墙（任意 β, β_0 ）；
- (2) 逐个检查每个点——若发现一个红点跑到了蓝侧（分错），把墙往红点方向推一下；
- (3) 若发现蓝点在红侧，反方向推一下；
- (4) 反复修正，直到没有点被分错。

这与线性回归、LDA、Logistic 回归的哲学截然不同：

方法	动机
线性回归	最小化残差平方和（关心所有点，包括分对的）
LDA	Bayes 最优分类（Gaussian 假设下）
Logistic 回归	最大化似然（概率框架，关注边界附近）
感知机	只关心分错的点——错了就推一把，对了就不动

感知机不问「离边界多远」「概率是多少」——只回答一个二值问题：分对还是分错？这种简单粗暴的风格正是神经网络最早的雏形。

目标函数

设 $y_i \in \{-1, +1\}$ 。若 $y_i = +1$ 被误分类，则 $\beta^\top x_i + \beta_0 < 0$ （反之亦然）。令 $\mathcal{M}$ 为误分类点集，目标为：

$$D(\beta, \beta_0) = - \sum_{i \in \mathcal{M}} y_i (\beta^\top x_i + \beta_0). \quad (12.44)$$

该值非负，与误分类点到决策边界的距离成正比。

随机梯度下降更新

感知机使用**随机梯度下降**——逐个访问误分类点，每次更新（学习率 ρ 可取 1）：

$$\begin{pmatrix} \beta \\ \beta_0 \end{pmatrix} \leftarrow \begin{pmatrix} \beta \\ \beta_0 \end{pmatrix} + \rho \begin{pmatrix} y_i x_i \\ y_i \end{pmatrix}. \quad (12.45)$$

收敛性与问题

若类别线性可分，算法在有限步内收敛到某个分离超平面（习题 4.6）。但存在若干问题（Ripley, 1996）：

- **解不唯一**：分离超平面有无穷多个，哪个被找到取决于初值；
- **收敛可能极慢**：间隔（margin）越小，收敛越慢；
- **数据不可分时发散**：算法不收敛且产生周期振荡，可能难以检测。

图 4.14 展示了两类的玩具数据：最小二乘线（等价于 LDA）误分一个点，而两条蓝色感知机线（不同随机初值）均完美分离。

12.10.3 最优分离超平面

感知机有多解的问题可通过对分离超平面施加额外约束来解决。最优分离超平面 (Vapnik, 1996) 分离两类且最大化到最近点的距离——不仅给出唯一解, 通过最大化训练数据上的间隔 (margin) 还能改善泛化性能。

优化问题的建立

设 $y_i \in \{-1, +1\}$ 。最大化间隔的优化问题:

$$\max_{\beta, \beta_0, \|\beta\|=1} M \quad \text{s.t.} \quad y_i(\beta^\top x_i + \beta_0) \geq M, \quad i = 1, \dots, N.$$

消去 $\|\beta\| = 1$ 约束 (用 $\frac{1}{\|\beta\|}y_i(\beta^\top x_i + \beta_0) \geq M$ 替换), 并注意到对任意满足不等式的 (β, β_0) , 正缩放倍数仍满足, 可设 $\|\beta\| = 1/M$, 得到等价凸优化问题:

$$\min_{\beta, \beta_0} \frac{1}{2} \|\beta\|^2 \quad \text{s.t.} \quad y_i(\beta^\top x_i + \beta_0) \geq 1, \quad i = 1, \dots, N. \quad (12.46)$$

几何解释

约束定义了一个围绕决策边界的空「平板」(slab), 厚度为 $1/\|\beta\|$ 。最小化 $\|\beta\|^2$ 即最大化该厚度——在线性可分约束下尽可能扩大 margin。

Lagrange 对偶推导

引入 Lagrange 乘子 $\alpha_i \geq 0$, Lagrange 原始函数为:

$$L_P = \frac{1}{2} \|\beta\|^2 - \sum_{i=1}^N \alpha_i [y_i(\beta^\top x_i + \beta_0) - 1]. \quad (12.47)$$

令导数为零:

$$\beta = \sum_{i=1}^N \alpha_i y_i x_i, \quad 0 = \sum_{i=1}^N \alpha_i y_i. \quad (12.48)$$

代入 L_P 消去 β 和 β_0 , 得 Wolfe 对偶:

$$L_D = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{k=1}^N \alpha_i \alpha_k y_i y_k x_i^\top x_k \quad \text{s.t.} \quad \alpha_i \geq 0, \quad \sum_{i=1}^N \alpha_i y_i = 0. \quad (12.49)$$

这是在正象限中的更简单的凸优化问题, 可用标准软件求解。

KKT 条件与支持向量

Karush-Kuhn-Tucker 条件要求:

$$\alpha_i [y_i(\beta^\top x_i + \beta_0) - 1] = 0, \quad \forall i. \quad (12.50)$$

由此得到关键性质:

- 若 $\alpha_i > 0$, 则 $y_i(\beta^\top x_i + \beta_0) = 1$ ——该点恰好落在 margin 边界上, 称为**支持向量 (support point)**;
- 若 $y_i(\beta^\top x_i + \beta_0) > 1$, 则该点在 margin 外部, $\alpha_i = 0$ 。

由 (12.48), 解向量 β 是支持向量的线性组合:

$$\beta = \sum_{i:\alpha_i>0} \alpha_i y_i x_i.$$

即只有支持向量对决定超平面有贡献——移动非支持向量不改变解。 β_0 可由任一支持向量的 (12.50) 解出。

分类函数

最优分离超平面产生的分类函数为:

$$\hat{f}(x) = x^\top \hat{\beta} + \hat{\beta}_0, \quad \hat{G}(x) = \text{sign } \hat{f}(x). \quad (12.51)$$

训练数据全部落在 margin 之外 (由构造保证), 但测试数据则不一定。

与 LDA 和 Logistic 回归的对比

图 4.16 展示了同一玩具数据上三种方法的决策边界:

- **最优分离超平面** (蓝色线): 三个支持向量 (落在 margin 边界上的点) 完全决定了它。直觉上, 它更关注「关键点」, 对模型误设更鲁棒。
- **Logistic 回归** (红色线): 与最优分离超平面非常接近 (参见 §12.3.3 的详细讨论)。当分离超平面存在时, Logistic 回归总能找到它 (似然可驱动至 0, 习题 4.5)。其系数由加权 LS 确定, 靠近决策边界的点权重较大。
- **LDA**: 依赖所有数据, 包括远离决策边界的点。若各类确为 Gaussian, LDA 最优; 而分离超平面因聚焦于边界附近 (噪声更大的) 数据, 会付出一定代价。

支持向量的识别需使用全部数据——这不是无成本的稀疏性。

不可分情况的推广


当数据线性不可分时, (12.46) 无可行解。此时可:

- 通过基展开将数据映射到高维空间 (但可能导致过拟合下的伪分离);
- 允许重叠并最小化重叠程度——即第 12 章的**支持向量机 (SVM)**, 引入松弛变量实现软间隔。

注记 12.14. 本章参考文献包括 Duda et al. (2000)、Ripley (1996)、Vapnik (1996) 等。习题 4.1 证明 Fisher 特征值问题与标准特征值问题的等价性; 习题 4.2 证明二分类下 LDA 方向与最小二乘系数成比例 ($\hat{\beta} \propto \hat{\Sigma}^{-1}(\hat{\mu}_2 - \hat{\mu}_1)$)。

12.11 本章小结

下图总结了本章各类线性分类方法的逻辑关系与统一框架：



第十三章 基展开与正则化

13.1 引言

到目前为止，我们使用的模型——线性回归、LDA、Logistic 回归、分离超平面——全部依赖**线性模型**。但真实的 $f(X) = \mathbb{E}[Y | X]$ 几乎不可能恰好是 X 的线性函数。线性模型只是一种便利的、有时是必须的近似：便利是因为易于解释且是 $f(X)$ 的一阶 Taylor 近似；必须是因为当 N 小或 p 大时，线性模型可能是我们唯一能拟合而不至于过拟合的模型。

本章讨论突破线性局限的核心方法。

13.1.1 两种突破线性的思路：参数化 vs 非参数化

面对「 $f(X)$ 不是线性的」这个问题，存在两条建模路线：

参数化路线（变换—验证）：用领域知识或探索性分析猜测一个具体的变换形式—— $h(X) = \log X, \sqrt{X}, X^2, \dots$ ——然后在新变量上做线性拟合。例如，若猜测血压与剂量的对数成正比，则拟合 $BP = \beta_0 + \beta_1 \log(\text{dose})$ 。这种做法的优势在于解释性强、参数量少（低方差），但风险是：一旦猜错了 h 的形式，模型就是错的（高偏差）。

非参数化路线（基展开—让数据说话）：不对 f 的形状做具体假设，而是用一组足够丰富的基函数 $\{h_m(X)\}$ 的线性组合去自适应逼近。样条、核方法、小波、神经网络均属此类。优势在于灵活——几乎任何光滑函数都能被逼近；代价是使用了更多参数（高方差风险），需要复杂度控制（本章核心主题）。

实践中二者并非互斥。在低维问题中，现代做法（如广义可加模型 GAM）倾向于对每个变量单独使用非参数光滑（如样条），同时保持可加结构 $\sum_j f_j(X_j)$ ——相当于「结构参数化、形状非参数化」的折中方案。本章重点介绍非参数化路线中的基展开与正则化方法。

13.1.2 核心思想：变换输入空间

用 X 的变换 $h_m(X) : \mathbb{R}^p \rightarrow \mathbb{R}$ ($m = 1, \dots, M$) 替代或增广原始输入，然后在这些派生特征的新空间中继续使用线性模型：

$$f(X) = \sum_{m=1}^M \beta_m h_m(X). \quad (13.1)$$

关键在于：一旦基函数 h_m 确定，模型对新变量仍是线性的，所有之前的拟合方法（最小二乘、MLE 等）照常使用。

13.1.3 常见基函数示例

- 恒等变换： $h_m(X) = X_m$ ($m = 1, \dots, p$)，还原为原始线性模型。
- 多项式： $h_m(X) = X_j^2$ 或 $X_j X_k$ ，实现高阶 Taylor 展开。注意：变量数随阶数指数增长—— p 个变量的 d 次多项式需要 $O(p^d)$ 个项。
- 非线性变换： $h_m(X) = \log(X_j), \sqrt{X_j}, \dots$ ，也可使用涉及多个输入的变换如 $\|X\|$ 。
- 指示函数（分箱）： $h_m(X) = I(L_m \leq X_k < U_m)$ ，将 X_k 划分为区间，得到分段常数模型。

13.1.4 复杂度的控制

基展开产生一个字典 $\mathcal{D}$ ，通常包含大量基函数——远超我们负担得起的数量。控制模型复杂度的方法分为三类：

- 限制法：限定每个分量函数使用的基函数数量 M_j ；
- 选择法：自适应扫描字典，仅包含对拟合有显著贡献的基函数（CART、MARS、boosting 走这条路）；
- 正则化法：使用整个字典但限制系数（Ridge、Lasso 属于此类）。

Q：基展开到底是一种什么方法？是给出很多基函数的通用方法吗？

基展开不是一种具体的“生成基”的方法，而是一种建模框架/范式：把原始输入 X 通过基函数 $h_m(X)$ 变换到派生特征空间，然后在这个新空间里用线性模型 $\sum \beta_m h_m(X)$ 去拟合。之所以叫“展开”（expansion），是因为把原本只有 p 维的输入空间“撑开”成一个更大的 M 维空间——在这个高维空间里，原本非线性的关系变得（近似）线性了。

类比线性代数：一组基向量通过线性组合可以张成向量空间；这里一组基函数通过线性组合可以逼近很宽泛的一类函数。基展开本身只是一个容器——它统一了

后面几乎所有非参数方法的视角：样条是手工设计基函数 + 限制数量，平滑样条是每个点放一个基 + 正则化，CART/MARS 是自适应选择基，boosting 是自适应学习基。

Q：为什么说字典 $\mathcal{D}$ 通常包含大量基函数——远超负担得起的数量？

这是刻意为之的：字典必须足够大才能灵活逼近任意的 $f(X)$ ，否则能表示的函数类太窄。例如多项式基中 p 个变量 d 次就有 $O(p^d)$ 个项，样条网格上有 K^p 个项，核基可以在每个训练点放一个。但数据量 N 是有限的—— $M \gg N$ 时全用上必然过拟合，这就是“远超负担得起”的含义（“负担”指在有限数据下稳定拟合的能力）。所以整章的逻辑链是：要灵活 $\rightarrow$ 字典必须大 $\rightarrow$ 但数据有限 $\rightarrow$ 需要复杂度控制（限制/选择/正则化）。字典大不是失误，而是这个框架要解决的核心张力。

13.2 分段多项式与样条

本节假设 X 为一维（至 §5.7 放宽）。分段多项式通过将 X 的定义域划分为连续区间、在每个区间内用单独的多项式表示 f 来构造。

13.2.1 分段常数与分段线性

分段常数：三个基函数

$$h_1(X) = I(X < \xi_1), \quad h_2(X) = I(\xi_1 \leq X < \xi_2), \quad h_3(X) = I(\xi_2 \leq X),$$

最小二乘估计 $\hat{\beta}_m = \bar{Y}_m$ （第 m 区间的 Y 均值）。

分段线性：需要额外三个基函数 $h_{m+3} = h_m(X)X$ ($m = 1, 2, 3$)，共 6 个参数。但通常我们希望函数在节点 ξ_1, ξ_2 处连续——连续性约束 $f(\xi_1^-) = f(\xi_1^+)$ 和 $f(\xi_2^-) = f(\xi_2^+)$ 各消耗一个自由度，剩下 4 个自由参数。

13.2.2 截断幂基

更直接的方式是使用内建了连续性约束的基函数：

$$h_1(X) = 1, \quad h_2(X) = X, \quad h_3(X) = (X - \xi_1)_+, \quad h_4(X) = (X - \xi_2)_+,$$

其中 $(X - \xi)_+ = \max(0, X - \xi)$ 为截断幂函数。

截断幂函数的直观： $(X - \xi)_+$ 在 ξ 之前恒为 0（「关着」），在 ξ 之后是一条斜率为 1 的直线（「打开」）。在 ξ 处值为 0，故连续但导数不连续（有个「折角」）。用截断幂函数构造分段线性模型的逻辑为：

$$f(X) = \beta_0 + \beta_1 X + \beta_2 (X - \xi_1)_+ + \beta_3 (X - \xi_2)_+.$$




FIGURE 5.1. The top left panel shows a piecewise constant function fit to some artificial data. The broken vertical lines indicate the positions of the two knots ξ_1 and ξ_2 . The blue curve represents the true function, from which the data were generated with Gaussian noise. The remaining two panels show piecewise linear functions fit to the same data—the top right unrestricted, and the lower left restricted to be continuous at the knots. The lower right panel shows a piecewise-linear basis function, $h_3(X) = (X - \xi_1)_+$, continuous at ξ_1 . The black points indicate the sample evaluations $h_3(x_i)$, $i = 1, \dots, N$.

图 13.1: 分段多项式拟合人造数据。左上: 分段常数 (三个区间各自的均值); 右上: 无约束分段线性; 左下: 节点处连续的分段线性; 右下: 截断幂基函数 $h_3(X) = (X - \xi_1)_+$ (在 ξ_1 之前为 0, 之后线性增长)。来源: ESL Figure 5.1。

- $X < \xi_1$: 只有 $\beta_0 + \beta_1 X$ (一条直线);
- $\xi_1 \leq X < \xi_2$: $(X - \xi_1)_+$ 打开 $\rightarrow$ 斜率从 β_1 变为 $\beta_1 + \beta_2$ (拐弯了);
- $X \geq \xi_2$: $(X - \xi_2)_+$ 也打开 $\rightarrow$ 斜率再变一次。

每个截断幂函数在对应节点处添加一个「拐弯」, 不影响节点左侧, 只改变右侧行为。这比显式施加连续性约束更加自然。

更高次幂的推广: $(X - \xi)_+^2$ 在节点处有一阶连续导数 (光滑拐弯), $(X - \xi)_+^3$ 在节点处有二阶连续导数 (人眼无法察觉拐弯)。

注记 13.1. 有人可能会问: 为什么 $(X - \xi_1)_+$ 在第二、第三区间都开着, 而不设计成只在 $[\xi_1, \xi_2)$ 上非零? 答案是为了**保证连续性**——如果在 ξ_2 处强行把它关掉 (变为 0), 函数值会突然跳变, 破坏连续性。截断幂基的「全局影响」是换取系数可解释性的代价 (β_j 直接对应「第 j 个节点处的斜率变化量」)。若需要只在局部非零的基函数, 可用 **B-样条 (B-splines)**——每个 B-样条基函数只在有限几个区间上非零 (局部支撑), 数值更稳定, 但系数不再有截断幂基那样的直观解释。

13.2.3 三次样条 (Cubic Spline)

分段三次多项式, 在节点处具有连续的一阶和二阶导数 ($M = 4$ 阶样条)。可视作:

阶数	连续性	名称
$M = 1$	无连续要求	分段常数
$M = 2$	连续, 导数不连续	线性样条 (连续分段线性)
$M = 4$	二阶导数连续	三次样条

对于节点 ξ_1, ξ_2 , 三次样条的一个基础表示 (截断幂基):

$$\begin{aligned} h_1(X) &= 1, & h_2(X) &= X, & h_3(X) &= X^2, \\ h_4(X) &= X^3, & h_5(X) &= (X - \xi_1)_+^3, & h_6(X) &= (X - \xi_2)_+^3. \end{aligned} \quad (13.2)$$

共 6 个基函数对应 6 维线性函数空间。参数计数验证: 3 个区域 $\times$ 每区域 4 参数 $-$ 2 个节点 $\times$ 每节点 3 个约束 $= 6$ 。

13.2.4 一般阶样条

M (阶数) 的含义: $M = \text{次数} + 1$, 即每个区间内多项式的参数个数。

M	次数	名称	连续性
1	0 次 (常数)	分段常数	无
2	1 次 (线性)	线性样条	f 连续
3	2 次 (二次)	二次样条	f, f' 连续
4	3 次 (三次)	三次样条	f, f', f'' 连续




FIGURE 5.2. A series of piecewise-cubic polynomials, with increasing orders of continuity.

图 13.2: 分段三次多项式, 节点处连续性递增。左上: 不连续; 右上: 连续但导数不连续; 左下: 一阶导数连续; 右下: 一阶和二阶导数均连续 (三次样条)。再额外施加一阶连续性将退化为全局三次多项式。来源: ESL Figure 5.2。

M 阶样条是 M 阶分段多项式，且在节点处有直到 $M - 2$ 阶的连续导数。带 K 个节点 ξ_j 的截断幂基一般形式为：

$$\begin{aligned} h_j(X) &= X^{j-1}, \quad j = 1, \dots, M, \\ h_{M+\ell}(X) &= (X - \xi_\ell)_+^{M-1}, \quad \ell = 1, \dots, K. \end{aligned}$$

(13.3)

即 M 个全局多项式基函数 + K 个节点处的截断幂基函数，共 $M + K$ 个。

自由度的计算：

$$\text{df} = M + K.$$

推导：($K + 1$) 个区间 $\times$ 每区间 M 个系数 $- K$ 个节点 $\times$ 每节点 $M - 1$ 个连续性约束
 $= M(K + 1) - K(M - 1) = M + K$ 。

具体示例：

样条类型	M	节点数 K	df
分段常数	1	2	3
线性样条	2	2	4
三次样条	4	2	6
自然三次样条	4	K	K ($4 + K$ 减去边界 4 个约束)

在 R 中，`bs(x, df=7)` 的内部逻辑：三次样条 $M = 4$ ，故内节点数 $= 7 - 4 = 3$ （加 3 个边界节点共 6 个节点），放于适当的分位数处。

实践中最常用的阶数： $M = 1, 2, 4$ 。三次样条是最低阶的「人眼看不见节点处不连续」的样条——极少有理由使用更高阶。

注记 13.2. 截断幂基在概念上简单，但数值上不稳健——大数的幂会导致严重舍入误差。实际计算中普遍使用 **B-样条基**（见本章附录），它具有更好的数值稳定性且计算高效。

13.2.5 节点选择

R 中的实现

ESL 全书使用统计编程语言 R 做代码示例。`bs(x, df=7)` 是 R 的 `splines` 包中的函数：输入向量 x ，输出 $N \times 7$ 的 B-样条基矩阵。Python 中类似功能由 `scipy.interpolate.BSpline` 或 `patsy.dmatrix` 提供。

内部逻辑：三次样条 $M = 4$ ，故 $\text{df}=7 \rightarrow$ 内节点数 $= 7 - 4 = 3$ ，自动放置在 x 的 25%, 50%, 75% 分位数处（加上边界节点构成完整节点集）。

实践中节点位置怎么选？

标准做法——不看节点位置，只选 df。实践中几乎不手动指定节点位置，而是通过交叉验证选择 df（自由度 复杂度），让函数自动放置节点：

df	模型含义
1	常数（仅截距）
2	直线（截距 + 斜率）
4	很光滑的非线性
7	中等弯曲
12	相当灵活

df 越大 → 节点越多 → 模型越灵活 → 偏差 ↓、方差 ↑。通过 K 折交叉验证选择使测试误差最小的 df。

默认分位数放置的启发式原理：R 将节点放在 x 的均匀分位数处（而不是等间距）。直觉是——数据密集的地方需要更多灵活性来捕捉信号，数据稀疏的地方不宜浪费自由度拟合噪声。这并非数学最优（本节末尾讨论），但在绝大多数实际问题中足够好用。

特定场景的调整：

- 有领域知识时：在已知的物理拐点（如材料相变温度、药物半衰期）处手动放置节点；
- 自然样条：边界外线性约束 → 边界节点靠近数据极值，内部节点均匀分位数；
- 周期性数据：改用周期样条基（Fourier 基或周期 B-样条）。

分位数放置是最优的吗？

不是。最优节点选择是组合优化问题——从 N 个数据点中选 K 个节点有 $\binom{N}{K}$ 种可能，NP-hard。

分位数放置只是一个统计上稳健的启发式，原理是「在数据多的地方多放节点」。真正试图优化节点位置的方法：

- **MARS (§9.4)：**贪心添加 + 剪枝，自适应搜索节点位置；
- **穷举/贪心搜索：**计算量过大， $K > 3$ 时不可行。

实践结论：没人手动调节点位置。标准做法是用 $\text{bs}(x, \text{df}=k)$ ， k 由 CV 决定，分位数自动放置节点。这套组合虽非数学最优，但在偏差-方差权衡下统计上稳健。真正花精力搜索最优节点的方法反而不如大量节点 + 惩罚（光滑样条，§5.4）实用。

13.2.6 自然三次样条

标准三次样条在边界区域方差爆增（图 5.3）。**自然三次样条**添加额外约束：函数在边界节点之外是**线性的**。这释放了 4 个自由度（两个边界区域各两个约束），可重新分配到内部区域增加节点。

带 K 个节点的自然三次样条由 K 个基函数表示。从截断幂基出发施加边界约束，可得基函数（习题 5.4）：

$$N_1(X) = 1, \quad N_2(X) = X, \quad N_{k+2}(X) = d_k(X) - d_{K-1}(X), \quad (13.4)$$

其中

$$d_k(X) = \frac{(X - \xi_k)_+^3 - (X - \xi_K)_+^3}{\xi_K - \xi_k}.$$

每个基函数在 $X \geq \xi_K$ 处二阶和三阶导数均为零。

权衡：边界附近偏差略有增加（假设函数在边界处近似线性通常是合理的），但方差大幅降低。

为什么边界外是线性的？

这里的「边界」指最外层节点 ξ_1 和 ξ_K ，而非数据的最值点。自然样条的线性约束作用于两个区域： $X < \xi_1$ （最左节点以左）和 $X > \xi_K$ （最右节点以右）。

左侧边界外（ $X < \xi_1$ ）。此时对所有 $j = 1, \dots, K$ ， $(X - \xi_j)_+ = 0$ （截断幂函数尚未「打开」），故 $d_k(X) = 0$ 。于是 $N_{k+2}(X) = 0 - 0 = 0$ ，只剩下 $N_1(X) = 1$ 和 $N_2(X) = X$ ：

$$f(X) = \beta_1 \cdot 1 + \beta_2 \cdot X = \beta_1 + \beta_2 X,$$

是严格的线性函数。

右侧边界外（ $X > \xi_K$ ）。此时所有截断都开着， $(X - \xi_j)_+ = X - \xi_j$ 。代入 $d_k(X)$ ：

$$\begin{aligned} d_k(X) &= \frac{(X - \xi_k)^3 - (X - \xi_K)^3}{\xi_K - \xi_k} = \frac{1}{\xi_K - \xi_k} \left[(X^3 - 3X^2\xi_k + 3X\xi_k^2 - \xi_k^3) \right. \\ &\quad \left. - (X^3 - 3X^2\xi_K + 3X\xi_K^2 - \xi_K^3) \right] \\ &= \frac{1}{\xi_K - \xi_k} \left[3X^2(\xi_K - \xi_k) - 3X(\xi_K^2 - \xi_k^2) + (\xi_K^3 - \xi_k^3) \right] \\ &= 3X^2 - 3X(\xi_K + \xi_k) + (\xi_K^2 + \xi_K\xi_k + \xi_k^2). \end{aligned}$$

可见 $d_k(X)$ 在 $X > \xi_K$ 时是 X 的**二次函数**，且 X^2 的系数始终为 3，与 k 无关。

现在考虑 $N_{k+2}(X) = d_k(X) - d_{K-1}(X)$ 。因为 d_k 和 d_{K-1} 的 X^2 系数都是 3，相减时恰好消掉：

$$\begin{aligned} N_{k+2}(X) &= [3X^2 - 3X(\xi_K + \xi_k) + \dots] - [3X^2 - 3X(\xi_K + \xi_{K-1}) + \dots] \\ &= 3X(\xi_{K-1} - \xi_k) + \text{常数}, \end{aligned}$$

剩下的是 X 的一次函数（线性）。加上 $N_1 = 1$ （常数）和 $N_2 = X$ （线性），所有基函数在 $X > \xi_K$ 时都是线性的，因此 $f(X) = \sum \beta_m N_m(X)$ 也是线性的，且二阶、三阶导数均为零。

一句话总结：线性外推不是拟合后施加的额外约束，而是基函数本身内建性质—— $d_k - d_{K-1}$ 的设计故意消掉了 X^3 和 X^2 项。

基函数构造示例（ $K = 5$ ）

以 $\xi = [0, 1, 2, 3, 4]$ （ $K = 5$ ）为例，逐步构造 $N_1, \dots, N_5$ 。

Step 1——前两个基函数始终不变：

$$N_1(X) = 1, \quad N_2(X) = X.$$

Step 2——计算 $d_k(X)$ ， $k = 1, 2, 3, 4$ （分母用 $\xi_K = \xi_5 = 4$ ）：

$$\begin{aligned} d_1(X) &= \frac{(X-0)_+^3 - (X-4)_+^3}{4-0} = \frac{(X)_+^3 - (X-4)_+^3}{4}, \\ d_2(X) &= \frac{(X-1)_+^3 - (X-4)_+^3}{4-1} = \frac{(X-1)_+^3 - (X-4)_+^3}{3}, \\ d_3(X) &= \frac{(X-2)_+^3 - (X-4)_+^3}{4-2} = \frac{(X-2)_+^3 - (X-4)_+^3}{2}, \\ d_4(X) &= \frac{(X-3)_+^3 - (X-4)_+^3}{4-3} = (X-3)_+^3 - (X-4)_+^3. \end{aligned}$$

Step 3——以 $d_{K-1} = d_4$ 为基准，构造 N_3, N_4, N_5 ：

$$N_3(X) = d_1(X) - d_4(X), \quad N_4(X) = d_2(X) - d_4(X), \quad N_5(X) = d_3(X) - d_4(X).$$

直观理解： d_4 充当「基准函数」，每个 N_{k+2} 是「第 k 个节点的贡献减去基准贡献」。这个减法有两个目的：(i) 保证边界外的线性性（消去高阶项）；(ii) 使得基函数之间在节点密度和位置变化时保持数值稳定性。在实践中， d_{K-1} 的选择并非唯一——任何 d_j 都可以充当基准，但 ESL 选择 d_{K-1} 是约定俗成。

验证：取 $X = 5, 6, 7$ （均在 $\xi_5 = 4$ 右侧），计算 N_3 的一阶差分——若为常数则 N_3 是线性的：

$$\begin{aligned} N_3(5) &= d_1(5) - d_4(5), \quad N_3(6) = d_1(6) - d_4(6), \quad N_3(7) = d_1(7) - d_4(7), \\ \implies N_3(6) - N_3(5) &= N_3(7) - N_3(6). \quad (\text{一阶差分为常数} \rightarrow \text{线性无误}) \end{aligned}$$

13.2.7 样条方法概览

在进入具体实例之前，对目前以及后续出现的样条方法做一个系统总结：

类型	节点	复杂度控制	特点
回归样条 (§5.2)	手动选 K 个内节点	$df = M + K$	最基础
自然样条 (§5.2.1)	同上 + 边界线性约束	$df = K$	降边界方差, 最常用
B-样条 (附录)	同回归样条	同回归样条	局部支撑, 数值稳定
周期样条	同上 + 循环边界	同上	周期性数据
光滑样条 (§5.4)	每个 x_i 都是节点	λ 惩罚 $\int (f'')^2$	免选节点, λ 由 CV 定
惩罚样条 (P-splines)	均匀密节点 + 差分惩罚	λ 惩罚系数差	更高效, 现代 GAM 主流
薄板样条 (§5.7)	多维推广	λ 惩罚曲率	多维光滑样条
张量积样条	多维交互	基数 = 各维基数的乘积	建模联合非线性
MARS (§9.4)	自适应选择	贪心 + 剪枝	自动找交互和节点

本章重点介绍回归样条 (§5.2)、自然样条 (§5.2.1) 和光滑样条 (§5.4), 后续各章将逐步展开其余方法。读者可随时回查此表以保持方向感。

13.2.8 示例：南非心脏病数据（续）

问题设定

将 §4.4.2 的南非心脏病回顾性调查重新考察。数据概要：

- **响应 Y ：**二分类——是否患有心肌梗死 (MI/chd), $Y = 1$ (患病/病例), $Y = 0$ (未患病/对照);
- **特征 X ：**7 个风险因子——sbp (收缩压)、tobacco (累计烟龄, kg)、ldl (坏胆固醇)、famhist (家族史: 有/无)、obesity (肥胖指数)、alcohol (饮酒量)、age (年龄);
- **样本量：** $N = 462$ (160 病例 + 302 对照)。

第一步：线性 Logistic 回归 → 确定谁不显著

先用线性 Logistic 回归 (§4.4.2, 表 4.2) 拟合并做 Wald 检验。Z 得分 = $\hat{\beta}_j / SE(\hat{\beta}_j)$ (系数除以其标准误), $|Z| > 2 \approx p < 0.05$ 表示显著。结果：

变量	$\hat{\beta}$	SE	Z
sbp	0.006	0.006	1.02 不显著
tobacco	0.080	0.026	3.03 显著
ldl	0.185	0.057	3.22 显著
famhist	0.939	0.225	4.18 显著
obesity	-0.035	0.029	-1.19 不显著
age	0.043	0.010	4.18 显著

在线性模型中, **sbp** 和 **obesity** 被判为「没有用」——会被剔除。但直觉上血压和肥胖应该与心脏病相关——可能线性假设太强了。

第二步：改用自然样条 → 允许非线性效应

对每个连续变量 X_j , 用 4 个自然样条基函数（对应 3 个内节点放在 X_j 的均匀分位数处）替代原始 X_j :

$$\text{logit}[\text{Pr}(\text{chd} \mid X)] = \theta_0 + h_1(X_1)^\top \theta_1 + \cdots + h_p(X_p)^\top \theta_p, \quad (13.5)$$

其中每个 $h_j(X_j)$ 是 X_j 处 4 个自然样条基函数的取值向量, θ_j 是 4 维系数向量。二值因子 **famhist** 仍用哑变量编码（1 个参数）。

关键区别：线性模型中 **sbp** 的效应是 $\beta_{\text{sbp}} \times \text{sbp}$ （一条直线，一个系数）；样条模型中 **sbp** 的效应是 $f_{\text{sbp}}(\text{sbp}) = h(\text{sbp})^\top \theta_{\text{sbp}}$ （一条曲线，4 个系数共同决定形状）。图 5.4 中每个面板画的正是 $\hat{f}_j(X_j)$ ——第 j 个变量对 log-odds 的（非线性的）估计贡献函数。

$f_j(X_j)$ 的计算方式：将所有 p 组基函数（加常数项）合并为大向量 $h(X)$, 总参数 $\text{df} = 1 + \sum_j \text{df}_j$ 。评在 N 个样本上得 $N \times \text{df}$ 基矩阵 **H**, 用 §4.4.1 的 IRLS 算法拟合 Logistic 回归得 $\hat{\theta}$, 然后 f_j 在任意 X_j 处的值由 $h_j(X_j)^\top \hat{\theta}_j$ 计算。

第三步：模型选择与最终结果

执行向后逐步删除，保留项的组结构（一次删除整组基函数而非单个系数），用 AIC 统计量（§7.5）决定。最终模型见 Figure 5.4 和 Table 5.1。

Figure 5.4 读法：六个面板，每个对应一个变量。

- **实线** = $\hat{f}_j(X_j)$ ——该变量对 log-odds 的非线性估计效应。弯曲 = 非线性，平直 = 线性够用；
- **虚线带** = ± 2 标准误的逐点置信带——带越宽，估计越不确定（数据稀疏处自然宽）；
- **底部 rug plot** = 每个刻度是一个样本在该变量上的取值——刻度密 → 数据多 → 曲线可信；
- **famhist 面板：**二值变量，显示为两个点 + 误差棒（有/无家族史 增加约 0.5 个 log-odds 单位的风险）。

Table 5.1 读法（以 sbp 行为例）：

Terms	Df	Deviance	AIC	LRT	P-value
none（全模型）	—	458.09	502.09	—	—
sbp（删除后）	4	467.16	503.16	9.076	0.059




FIGURE 5.4. Fitted natural-spline functions for each of the terms in the final model selected by the stepwise procedure. Included are pointwise standard-error bands. The rug plot at the base of each figure indicates the location of each of the sample values for that variable (jittered to break ties).

图 13.3: 最终模型中各变量的拟合自然样条函数。实线: $\hat{f}_j(X_j)$; 虚线带: ± 2 标准误差的逐点置信带; 底部 rug plot: 每个刻度对应一个样本在该变量上的取值 (抖动防重叠)。famhist 为二值变量, 显示为两个点 + 误差棒。来源: ESL Figure 5.4。

TABLE 5.1. Final logistic regression model, after stepwise deletion of natural splines terms. The column labeled “LRT” is the likelihood-ratio test statistic when that term is deleted from the model, and is the change in deviance from the full model (labeled “none”).

Terms	Df	Deviance	AIC	LRT	P-value
none		458.09	502.09		
sbp	4	467.16	503.16	9.076	0.059
tobacco	4	470.48	506.48	12.387	0.015
ldl	4	472.39	508.39	14.307	0.006
famhist	1	479.44	521.44	21.356	0.000
obesity	4	466.24	502.24	8.147	0.086
age	4	481.86	517.86	23.768	0.000

图 13.4: 逐步删除自然样条项后的最终 Logistic 回归模型。Terms: 变量名 (none= 全模型); Df: 该变量占用自由度; Deviance: 离差; AIC: 赤池信息准则; LRT: 似然比检验统计量 (该变量删除后 deviance 的增加量); P-value: LRT 的 p 值。来源: ESL Table 5.1。

- **Df:** 该变量占用的自由度 (连续变量 = 4 个样条基函数; famhist = 1 个哑变量);
- **Deviance:** 删除该变量后模型的离差 ($= -2 \times$ 对数似然, 类比 RSS);
- **AIC:** Deviance + $2 \times df$ 的惩罚 (越小越好);
- **LRT (似然比检验)** = Deviance_{删除后} - Deviance_{全模型}: 衡量删除该变量造成的拟合损失。越大 变量越重要;
- **P-value:** LRT 的 p 值, < 0.05 显著 (不能删)。sbp 的 $p=0.059$, 接近显著但刚好过线——作者选择保留。

按重要性排名(LRT 从大到小): age(23.8) > famhist(21.4) > ldl(14.3) > tobacco(12.4) > sbp(9.1) > obesity(8.1)。

关键发现与解释

sbp (收缩压) 和 obesity (肥胖) 在线性模型中不显著 (Z 得分 ≈ 1), 但在样条模型中被保留下来——因为它们的贡献本质上是非线性的 (图 5.4 显示 U 形效应: 低值和高值均增加风险)。这正是基展开超越线性的实际价值: 「直线工具太钝, 切不出曲线」——换样条这把更灵活的工具, 真实的非线性效应才得以显现。

低值区域出现风险上升看似反常 (血压低/体重轻反而风险高?), 但这是回顾性数据的体现: 患者心梗发作后已受益于健康饮食和生活方式改变 (血压降低了、体重减轻了), 导致低 sbp/obesity 区域的表面风险升高——因果方向被数据收集方式反转。

数学推导： $\hat{f}_{\text{sbp}}(x)$ 如何计算

以 sbp 为例，用严格的符号语言揭示图 5.4 的完整计算链。

Step 1——构造基函数：对 sbp 选取 $K = 5$ 个节点（2 个边界 = min 和 max，3 个内节点放在样本分位数处），4 个自然三次样条基函数为 ((13.4))：

$$h_1(x) = 1, \quad h_2(x) = x, \quad h_3(x) = d_1(x) - d_{K-1}(x), \quad h_4(x) = d_2(x) - d_{K-1}(x),$$

其中 $d_k(x) = \frac{(x-\xi_k)_+^3 - (x-\xi_K)_+^3}{\xi_K - \xi_k}$ （每 d_k 保证在 $x \geq \xi_K$ 处三阶导数为零）。

Step 2——构造 sbp 的设计矩阵：对 $i = 1, \dots, N$ ，第 i 个样本的 sbp 值为 $x_{i,\text{sbp}}$ ，其对应的 1×4 基向量为：

$$h_{\text{sbp}}(x_{i,\text{sbp}}) = [h_1(x_{i,\text{sbp}}), h_2(x_{i,\text{sbp}}), h_3(x_{i,\text{sbp}}), h_4(x_{i,\text{sbp}})].$$

所有 7 个变量的基函数 + 常数项合并为 $\mathbf{H}_{N \times \text{df}}$ ，其中 sbp 对应的 4 列为第 $k_{\text{sbp}} + 1$ 到 $k_{\text{sbp}} + 4$ 列。

Step 3——拟合 Logistic 回归：用 IRLS (§4.4.1) 最大化对数似然，得参数估计 $\hat{\theta} \in \mathbb{R}^{\text{df}}$ 。sbp 对应的 4 个系数为子向量 $\hat{\theta}_{\text{sbp}} = (\hat{\theta}_{\text{sbp},1}, \dots, \hat{\theta}_{\text{sbp},4})^\top$ 。

Step 4——在任意值 x 处计算 $\hat{f}_{\text{sbp}}(x)$ ：

$$\hat{f}_{\text{sbp}}(x) = \sum_{m=1}^4 \hat{\theta}_{\text{sbp},m} h_m(x) = h_{\text{sbp}}(x)^\top \hat{\theta}_{\text{sbp}}.$$

在 sbp 的值域上取均匀网格 $\{x_1, \dots, x_{100}\}$ ，逐点计算即得图 5.4 中的实线。

Step 5——置信带的计算： $\hat{\theta}$ 的渐近协方差矩阵为 $\widehat{\text{Cov}}(\hat{\theta}) = (\mathbf{H}^\top \mathbf{W} \mathbf{H})^{-1}$ （从 IRLS 最后一轮获得）。取 sbp 对应的 4×4 子块 $\widehat{\text{Cov}}(\hat{\theta}_{\text{sbp}})$ ，则在 x 处 $\hat{f}_{\text{sbp}}(x)$ 的标准误为：

$$\text{SE}[\hat{f}_{\text{sbp}}(x)] = \sqrt{h_{\text{sbp}}(x)^\top \widehat{\text{Cov}}(\hat{\theta}_{\text{sbp}}) h_{\text{sbp}}(x)}.$$

图中虚线带即为 $\hat{f}_{\text{sbp}}(x) \pm 2 \cdot \text{SE}[\hat{f}_{\text{sbp}}(x)]$ 。

标准误 (Standard Error) 的定义

给定参数估计量 $\hat{\psi}$ （例如一个回归系数 $\hat{\beta}_j$ ，或某点处的拟合值 $\hat{f}(x_0)$ ），其**标准误**是估计量抽样分布的标准差的估计：

$$\text{SE}(\hat{\psi}) = \sqrt{\widehat{\text{Var}}(\hat{\psi})} = \text{「如果我们反复从同一总体中抽取新样本并重拟合，}\hat{\psi}\text{ 会如何波动」的估计标准}$$

以线性回归为例： $\text{Cov}(\hat{\beta}) = \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}$ ，故 $\text{SE}(\hat{\beta}_j) = \hat{\sigma} \sqrt{[(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}}$ 。Logistic 回归中相应量为 $(\mathbf{H}^\top \mathbf{W} \mathbf{H})^{-1}$ （Fisher 信息矩阵的逆）。标准误不是数据的标准差，而是**估计精度的度量**——SE 越小，估计越精确，Z 得分 ($\hat{\beta}_j/\text{SE}$) 越大，越可能统计显著。

训练与画图的时序

一个容易混淆的点： $\hat{f}(\text{sbp})$ 看起来是「对 sbp 单独拟合的曲线」，但实际上 $\hat{\theta}$ 在画图之前就已经训练完毕。完整时序如下：

- (1) 构造完整设计矩阵 $\mathbf{H}$ ($N \times \text{df}$, 包含所有 7 个变量的样条基函数列 + 常数项);
- (2) 一次性拟合 Logistic 回归 $\min \ell(\theta) \xrightarrow{\text{IRLS}} \hat{\theta}$ ——此时模型已训练完成;
- (3) 用 $\hat{\theta}$ 做各种事后操作:
 - 画 $\hat{f}(\text{sbp})$: 在 sbp 值域网格上计算 $h_{\text{sbp}}(x)^\top \hat{\theta}_{\text{sbp}}$;
 - 预测新患者: 输入 7 个变量值 $\rightarrow \text{logit} = \hat{\theta}_0 + \sum_j \hat{f}_j(x_j) \rightarrow \text{分类}$;
 - 模型选择: 删变量 $\rightarrow$ 看 AIC 变化 (可在原 $\hat{\theta}$ 上近似计算, 无需重拟合);
 - 推断: 对每组系数做 LRT、计算 p 值。

$\hat{f}(\text{sbp})$ 不是单独训练的——它是完整大模型的一个「切片」, 与 $\hat{f}(\text{obesity}), \hat{f}(\text{age})$ 等同时通过同一个最大似然过程得到。画图只是在已训练好的模型上, 把 sbp 维度拎出来观察其形状。训练 (找 $\hat{\theta}$) 只做一次, 之后的画图、预测、检验都是对同一个 $\hat{\theta}$ 的不同使用方式。

13.2.9 示例：音素识别

另一个应用方向：用样条增加约束而非灵活性——即函数型建模。与前一例构成样条的两个极端用法：

	南非心脏病	音素识别
特征数 p	7 (很少)	256 (很多)
每系数有效数据	充足	≈ 4 个观测/系数
原始模型的问题	太刚性——直线切不出曲线	太灵活——256 个系数严重过拟合
样条的作用	增加灵活性: 每变量 $1 \rightarrow 4$ 个参数	减少灵活性: $256 \rightarrow 12$ 个参数
$\mathbf{H}$ 维度变化	$N \times 7 \rightarrow N \times 28$ (变大)	$N \times 256 \rightarrow N \times 12$ (变小)
方向	展开 (expand)	压缩 (compress)

数学操作完全相同——自然三次样条 $\beta = \mathbf{H}\theta$ ——但统计目的恰好相反。合在一起完整展示了样条作为「复杂度双向调节器」的威力。

数据: 两个音素「aa」和「ao」的 log-periodogram, 在 256 个均匀频率点上测量 (图 5.5 上)。目标是用这些数据分类口语音素。

原始 Logistic 回归: 将 256 个 log-periodogram 值作为输入直接拟合（相当于离散化 $\int X(f)\beta(f)df \approx \sum_j x_j\beta_j$ ）。系数曲线（图 5.5 下的灰色锯齿线）极其粗糙——输入信号有强正自相关，导致系数负自相关，且有效样本量仅每系数约 4 个观测。

正则化方案: 用自然三次样条强制系数作为频率的光滑函数： $\beta(f) = \sum_{m=1}^M h_m(f)\theta_m$ ，即 $\beta = \mathbf{H}\theta$ ，其中 $\mathbf{H}$ 是 $p \times M$ 自然样条基矩阵（ $M = 12$ ，节点在 $1, \dots, 256$ 上均匀放置）。

由于 $\mathbf{x}^\top \beta = \mathbf{x}^\top \mathbf{H}\theta$ ，只需将输入特征替换为滤波后版本 $\mathbf{x}^* = \mathbf{H}^\top \mathbf{x}$ ，然后对 $\mathbf{x}^*$ 拟合线性 Logistic 回归。红色光滑曲线 $\hat{\beta}(f) = h(f)^\top \hat{\theta}$ （图 5.5 下）清晰揭示：低频区域提供最大判别力。

	训练误差	测试误差
原始（无约束）	0.080	0.255
光滑样条正则化	0.185	0.158

光滑化不仅使对比模式更易解释，还产生了更准确的分类器——偏差-方差权衡的又一个例证：接受少量偏差增加换取了大幅方差降低。

13.3 滤波与特征提取

音素识别示例体现了一个更一般的模式：构造 $p \times M$ 基矩阵 $\mathbf{H}$ ，然后将特征变换为 $\mathbf{x}^* = \mathbf{H}^\top \mathbf{x}$ ，最后将滤波后的特征作为学习过程的输入。这种高维特征的预处理在信号和图像处理中尤为常见。

- 可通过基 $\mathbf{H}$ 的选择来施加先验知识——如要求系数光滑或稀疏；
- 滤波后的特征 $\mathbf{x}^*$ 维度 $M \ll p$ ，实现降维的同时保留对预测有用的结构。

更一般地，派生特征 $\mathbf{x}^* = g(\mathbf{x})$ 可作为任何学习过程（线性或非线性）的输入。例如信号/图像识别中常用小波变换 $\mathbf{x}^* = \mathbf{H}^\top \mathbf{x}$ （§5.9）提取特征后送入神经网络（第 11 章）：小波擅长捕获离散跳跃和边缘，神经网络擅长构造这些特征的非线性组合。

13.4 光滑样条

前面讨论的回归样条需要手动选择节点位置和数量。光滑样条通过采取最大节点集 + 正则化控制复杂度的策略，彻底规避了节点选择问题。

13.4.1 惩罚残差平方和

在具有二阶连续导数的所有函数 $f(x)$ 中, 寻找最小化以下目标的 f :

$$\text{RSS}(f, \lambda) = \sum_{i=1}^N \{y_i - f(x_i)\}^2 + \lambda \int \{f''(t)\}^2 dt, \quad (13.6)$$

其中 $\lambda \geq 0$ 是固定的光滑参数。

两项的含义:

- 第一项: 与数据的拟合紧密度 (残差平方和);
- 第二项: 对曲率的惩罚—— f'' 越大 (曲线越弯), 惩罚越重;
- λ : 在拟合度与光滑度之间建立权衡。

两种极端:

$\lambda = 0 \implies f$ 可以是任何插值数据的函数 (极度粗糙),

$\lambda = \infty \implies$ 最小二乘直线 (无曲率可容忍)。

希望 $\lambda \in (0, \infty)$ 索引一类有意义的折中函数。

13.4.2 有限维解

准则 (13.6) 定义在无穷维函数空间 (Sobolev 空间) 上。但可以证明 (习题 5.7): 其唯一最小化解是节点位于所有唯一 x_i 值处的自然三次样条。表面上参数数量惊人 (多达 N 个节点), 但正则化项 $\lambda \int (f'')^2$ 自动控制了有效复杂度。

为什么恰好是自然三次样条? 两个互补的直觉:

物理直觉——弹性梁: 将 f 想象成一根弹性木条, $\int (f'')^2$ 即弯曲能 (弯得越厉害弹性势能越大)。 N 个数据点好比套在木条上的环, 木条倾向于笔直 (减小弯曲能), 但环拉着它靠近数据 (减小残差)。在环之间的自由段, 弯曲能的 Euler-Lagrange 方程 $f'''' = 0$ 表明最优形状是分段三次多项式。环处 f, f', f'' 连续 (外力平衡), 端点外无力作用 $\implies f'' = 0$ (直线) ——即自然边界。

变分直觉——任何非样条函数都可改善: 若 f 不是节点在 x_i 的自然三次样条, 可构造 g 为插值 $f(x_i)$ 的自然三次样条。由分部积分可得 $\int f'' g'' = \int (g'')^2$, 于是

$$\int (f'')^2 = \int (g'')^2 + \int (f'' - g'')^2 \geq \int (g'')^2,$$

即 g 与 f 拟合完全一致但曲率惩罚更小。因此最优解必须在自然三次样条族中。

推论: 无穷维优化 $\implies$ 有限维广义岭回归。这个定理是光滑样条能够实际计算的数学基础——没有它, 光滑样条只是一个不可计算的抽象概念。

设 $\{N_j(x)\}_{j=1}^N$ 为此族自然样条的 N 维基函数，则 $f(x) = \sum_{j=1}^N N_j(x) \theta_j$ 。准则化为：

$$\text{RSS}(\theta, \lambda) = (\mathbf{y} - \mathbf{N}\theta)^\top (\mathbf{y} - \mathbf{N}\theta) + \lambda \theta^\top \mathbf{\Omega} \theta, \quad (13.7)$$

其中 $\mathbf{N}_{ij} = N_j(x_i)$ ， $\mathbf{\Omega}_{jk} = \int N_j''(t) N_k''(t) dt$ 。解为：

$$\hat{\theta} = (\mathbf{N}^\top \mathbf{N} + \lambda \mathbf{\Omega})^{-1} \mathbf{N}^\top \mathbf{y}, \quad (13.8)$$

广义岭回归的形式。拟合的光滑样条为：

$$\hat{f}(x) = \sum_{j=1}^N N_j(x) \hat{\theta}_j.$$

图 5.6 展示了青少年骨密度（BMD）数据上男性和女性各一条光滑样条（ $\lambda \approx 0.00022$ ，对应约 12 个自由度），清晰揭示女性的生长陡增比男性早约两年。

13.4.3 完整示例：光滑样条的符号化流程

下面不涉及具体数值，用标准符号语言展示光滑样条从数据到预测的完整六步流水线。

给定

训练数据 $\{(x_i, y_i)\}_{i=1}^N$ ， $x_i \in \mathbb{R}$ （一维输入）， $y_i \in \mathbb{R}$ （连续响应）。真实 $f(x) = \mathbb{E}[Y | X = x]$ 未知，不假设任何参数形式。目标：估计一个光滑的 $\hat{f}(x)$ 。

Step 1——选择光滑参数 λ （或等价地 df_λ ）

λ 控制拟合度与光滑度的权衡，通常通过交叉验证确定。等价地可指定有效自由度 $\text{df}_\lambda \in [2, N]$ ——实践中最常用的参数化方式（如 ‘smooth.spline(x, y, df=12)’）。

Step 2——构造自然三次样条基矩阵

将全体 $\{x_i\}$ 的 M 个唯一值排序： $x_{(1)} < x_{(2)} < \cdots < x_{(M)}$ 。以这些点为节点构造 M 个自然三次样条基函数 $\{N_j(x)\}_{j=1}^M$ （ $N_1(x) = 1, N_2(x) = x$ ，其余由 (13.4) 定义）。在 N 个训练点上求值，构造 $N \times M$ 基矩阵：

$$\mathbf{N}_{ij} = N_j(x_i), \quad i = 1, \dots, N, j = 1, \dots, M.$$

Step 3——构造惩罚矩阵

计算基函数二阶导数的内积：

$$\mathbf{\Omega}_{jk} = \int N_j''(t) N_k''(t) dt, \quad j, k = 1, \dots, M,$$

得 $M \times M$ 惩罚矩阵 $\mathbf{\Omega}$ （对称半正定）。注意： $\mathbf{\Omega}$ 仅依赖于 $\{x_i\}$ 的位置，与 y 无关。

Step 4——求解广义岭回归

模型为 $f(x) = \sum_{j=1}^M N_j(x) \theta_j$ 。将 $\{N_j\}$ 代入 (13.6)，目标函数化为：

$$\min_{\boldsymbol{\theta} \in \mathbb{R}^M} \{(\mathbf{y} - \mathbf{N}\boldsymbol{\theta})^\top (\mathbf{y} - \mathbf{N}\boldsymbol{\theta}) + \lambda \boldsymbol{\theta}^\top \boldsymbol{\Omega} \boldsymbol{\theta}\}.$$

解析解：

$$\hat{\boldsymbol{\theta}} = (\mathbf{N}^\top \mathbf{N} + \lambda \boldsymbol{\Omega})^{-1} \mathbf{N}^\top \mathbf{y}.$$

此时 $\hat{\boldsymbol{\theta}}$ 已确定，模型训练完毕。拟合值向量 $\hat{\mathbf{f}} = \mathbf{N}\hat{\boldsymbol{\theta}} = \mathbf{S}_\lambda \mathbf{y}$ ，其中 $\mathbf{S}_\lambda = \mathbf{N}(\mathbf{N}^\top \mathbf{N} + \lambda \boldsymbol{\Omega})^{-1} \mathbf{N}^\top$ 为光滑矩阵。

Step 5——在新点 x_0 处预测

计算 x_0 处的基函数值 $\mathbf{n}_0 = [N_1(x_0), \dots, N_M(x_0)]^\top \in \mathbb{R}^M$ 。预测为：

$$\hat{f}(x_0) = \sum_{j=1}^M \hat{\theta}_j N_j(x_0) = \mathbf{n}_0^\top \hat{\boldsymbol{\theta}}.$$

Step 6——复杂度与 λ 的选择

光滑矩阵的迹给出有效自由度：

$$\text{df}_\lambda = \text{trace}(\mathbf{S}_\lambda) = \sum_{k=1}^M \frac{1}{1 + \lambda d_k} \in [2, M],$$

其中 d_k 为惩罚矩阵 $\boldsymbol{\Omega}$ 相对于 $\mathbf{N}^\top \mathbf{N}$ 的广义特征值 ($d_1 = d_2 = 0$ ，线性函数永不惩罚)。实践中：

- 用 K 折 CV 对 df_λ (或 λ) 的候选网格做搜索，选 CV 误差最小的；
- 或直接用 R 的 `smooth.spline(x, y, df=12)` / Python 的 `UnivariateSpline(x, y, s=...)`，库内部完成所有矩阵操作。

与回归样条的操作对比

	回归样条 (§5.2)	光滑样条 (§5.4)
节点数	手动选 K (少)	每个 x_i 一个 (多)
防止过拟合	基函数本身就少	$\lambda \int (f'')^2$ 惩罚
目标函数	$\min \ \mathbf{y} - \mathbf{B}\boldsymbol{\beta}\ ^2$	$\min \ \mathbf{y} - \mathbf{N}\boldsymbol{\theta}\ ^2 + \lambda \boldsymbol{\theta}^\top \boldsymbol{\Omega} \boldsymbol{\theta}$
复杂度旋钮	K (节点数)	λ 或 df_λ (连续值)
解的形式	$\hat{\boldsymbol{\beta}} = (\mathbf{B}^\top \mathbf{B})^{-1} \mathbf{B}^\top \mathbf{y}$	$\hat{\boldsymbol{\theta}} = (\mathbf{N}^\top \mathbf{N} + \lambda \boldsymbol{\Omega})^{-1} \mathbf{N}^\top \mathbf{y}$

一句话：光滑样条将节点的离散选择替换为 λ (光滑度) 的连续调节——你拧旋钮，它自动决定曲线弯多少。

13.4.4 自由度与光滑矩阵

光滑矩阵 $\mathbf{S}_\lambda$

光滑样条是**线性光滑器**——拟合值 $\hat{\mathbf{f}}$ 是 $\mathbf{y}$ 的线性函数。记 $\hat{f}_i = \hat{f}(x_i)$, 则:

$$\hat{\mathbf{f}} = \mathbf{N}(\mathbf{N}^\top \mathbf{N} + \lambda \mathbf{\Omega})^{-1} \mathbf{N}^\top \mathbf{y} = \mathbf{S}_\lambda \mathbf{y}, \quad (13.9)$$

其中 $\mathbf{S}_\lambda$ ($N \times N$) 称为**光滑矩阵**。 $\hat{\mathbf{f}}$ 的构造过程不依赖于 $\mathbf{y}$ 本身—— $\mathbf{S}_\lambda$ 仅由 x_i 和 λ 决定。

投影光滑器 vs 收缩光滑器

对比回归样条的帽子矩阵 $\mathbf{H}_\xi$ 与光滑样条的 $\mathbf{S}_\lambda$:

性质	$\mathbf{H}_\xi$ (回归样条)	$\mathbf{S}_\lambda$ (光滑样条)
对称半正定		
幂等性	$\mathbf{H}_\xi \mathbf{H}_\xi = \mathbf{H}_\xi$	$\mathbf{S}_\lambda \mathbf{S}_\lambda \preceq \mathbf{S}_\lambda$ (收缩性)
秩	M (基函数个数)	N
类型	投影光滑器	收缩光滑器

$\mathbf{H}_\xi$ 将 $\mathbf{y}$ 投影到 M 维子空间 (M 个特征值为 1, 其余为 0), 而 $\mathbf{S}_\lambda$ 对所有方向做不同程度的收缩 (所有特征值 $\in [0, 1]$)。

光滑样条的自由度

有效自由度定义为光滑矩阵的迹:

$$\boxed{\text{df}_\lambda = \text{trace}(\mathbf{S}_\lambda)}. \quad (13.10)$$

这一极有用的定义提供了参数化光滑样条的一致方式——不说「 $\lambda = 0.00022$ 」, 而说「 $\text{df} = 12$ 」。图 5.6 中正是通过数值求解 $\text{trace}(\mathbf{S}_\lambda) = 12$ 来反推 $\lambda \approx 0.00022$ 。

df_λ 的两个极端:

$$\lambda \rightarrow 0 \implies \text{df}_\lambda \rightarrow N \quad (\text{插值}), \quad \lambda \rightarrow \infty \implies \text{df}_\lambda \rightarrow 2 \quad (\text{线性回归}).$$

特征分解

$\mathbf{S}_\lambda$ 可写为 Reinsch 形式 $\mathbf{S}_\lambda = (\mathbf{I} + \lambda \mathbf{K})^{-1}$ ($\mathbf{K}$ 为惩罚矩阵, 不依赖 λ , 习题 5.9)。 $\hat{\mathbf{f}} = \mathbf{S}_\lambda \mathbf{y}$ 等价于求解 $\min_f (\mathbf{y} - \mathbf{f})^\top (\mathbf{y} - \mathbf{f}) + \lambda \mathbf{f}^\top \mathbf{K} \mathbf{f}$ 。

$\mathbf{S}_\lambda$ 的特征分解:

$$\mathbf{S}_\lambda = \sum_{k=1}^N \rho_k(\lambda) \mathbf{u}_k \mathbf{u}_k^\top, \quad \rho_k(\lambda) = \frac{1}{1 + \lambda d_k},$$

其中 d_k 是 $\mathbf{K}$ 的特征值 ($d_1 = d_2 = 0$, 对应线性函数空间, 永不收缩)。

关键性质 (图 5.7):

- 特征向量 $\mathbf{u}_k$ **不依赖** λ ——整个光滑样条族共享同一组特征基 (Demmler-Reinsch 基);
- $\mathbf{S}_\lambda \mathbf{y} = \sum_k \mathbf{u}_k \rho_k(\lambda) \langle \mathbf{u}_k, \mathbf{y} \rangle$, 即沿各特征方向对 $\mathbf{y}$ 的分量进行**差异收缩**;
- 特征向量按 $\rho_k(\lambda)$ 递减排序, 复杂度递增 (类似递增阶数的多项式); 复杂度越高的方向被收缩得越厉害;
- 前两个特征值恒为 1 (对应 $\{u: u \text{ 是 } x \text{ 的线性函数}\}$, 永不惩罚);
- $\text{df}_\lambda = \text{trace}(\mathbf{S}_\lambda) = \sum_{k=1}^N \rho_k(\lambda)$ 。对投影光滑器, 所有特征值为 1, 每个对应投影子空间的一个维度。

等价核——光滑样条的局部性

图 5.8 展示了光滑矩阵 $\mathbf{S}_\lambda$ 的带状结构 (行按 x 排序)——表明光滑样条本质上是一个**局部拟合方法**, 类似于第 6 章的局部加权回归。 $\mathbf{S}_\lambda$ 的每一行即为**等价核**—— $\hat{f}(x_i)$ 实质上是 y_i 附近点的加权平均, 权重在 x_i 处最大并向两侧衰减。

$$\lambda \rightarrow 0 \implies \text{df} \rightarrow N, \mathbf{S}_\lambda \rightarrow \mathbf{I}, \quad \lambda \rightarrow \infty \implies \text{df} \rightarrow 2, \mathbf{S}_\lambda \rightarrow \mathbf{H}_{\text{线性}}.$$

13.5 光滑参数的自动选择

13.5.1 用有效自由度参数化

光滑样条的 $\text{df}_\lambda = \text{trace}(\mathbf{S}_\lambda)$ 关于 λ 单调递减 (λ 越大 $\rightarrow$ df 越小 $\rightarrow$ 越光滑), 可以反解——**固定 df 来确定 λ** 。实践中通过简单数值方法实现 (如 R 的 `smooth.spline(x, y, df=6)`)。

这种方法鼓励更传统的模型选择模式: 尝试几个不同的 df 值, 基于近似 F 检验、残差图等主观准则选择。 **df 的统一度量使不同的光滑方法可以公平比较**——在广义加性模型 (第 9 章) 中尤其有用, 多个光滑方法可同时用于一个模型。

13.5.2 偏差-方差权衡

图 5.9 用模拟数据 $Y = \frac{\sin(12(X+0.2))}{X+0.2} + \varepsilon$ ($X \sim U[0, 1], \varepsilon \sim N(0, 1), N = 100$) 展示了 df 的三个取值:




FIGURE 5.8. The smoother matrix for a smoothing spline is nearly banded, indicating an equivalent kernel with local support. The left panel represents the elements of S as an image. The right panel shows the equivalent kernel or weighting function in detail for the indicated rows.

图 13.5: 光滑样条的光滑矩阵 S_λ 。左: 矩阵元素图 (行按 x 排序), 带状结构表明局部支撑。右: 选定行的等价核 (加权函数), 每行在对应 x_i 处取峰值并向两侧衰减。来源: ESL Figure 5.8。




FIGURE 5.9. The top left panel shows the $EPE(\lambda)$ and $CV(\lambda)$ curves for a realization from a nonlinear additive error model (5.22). The remaining panels show the data, the true functions (in purple), and the fitted curves (in green) with yellow shaded $\pm 2 \times$ standard error bands, for three different values of df_λ .

图 13.6: 左上: $EPE(\lambda)$ 和 $CV(\lambda)$ 曲线。其余三面板: 真实函数 (紫色)、拟合曲线 (绿色) 及 ± 2 标准误差带 (黄色), 分别对应 $df = 5, 9, 15$ 。 $df = 5$ 欠拟合, $df = 15$ 略显过拟合, $df = 9$ 接近最优。来源: ESL Figure 5.9。

df_λ	表现	诊断
5	欠拟合: 削峰填谷, 高曲率区偏差大	标准误差带极窄——有偏但确信
9	接近最优, 轻微偏差	方差尚未明显增加
15	略显波动, 接近真实函数	标准误差带增宽——追随个别点

定量表达: $\hat{\mathbf{f}} = \mathbf{S}_\lambda \mathbf{y}$ 的方差-偏差分解为

$$\text{Cov}(\hat{\mathbf{f}}) = \mathbf{S}_\lambda \mathbf{S}_\lambda^\top, \quad \text{Bias}(\hat{\mathbf{f}}) = \mathbf{f} - \mathbf{S}_\lambda \mathbf{f},$$

其中 $\mathbf{f}$ 是未知真实值向量。**EPE** (期望预测误差) 综合了偏差和方差:

$$\text{EPE}(\hat{f}_\lambda) = \mathbb{E}(Y - \hat{f}_\lambda(X))^2 = \sigma^2 + \underbrace{\mathbb{E}[\text{Bias}^2(\hat{f}_\lambda(X))] + \mathbb{E}[\text{Var}(\hat{f}_\lambda(X))]}_{\text{MSE}(\hat{f}_\lambda)}.$$

13.5.3 交叉验证 (CV)

λ 的实际选择通过最小化 CV 得分:

$$\text{CV}(\hat{f}_\lambda) = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{f}_\lambda^{(-i)}(x_i))^2,$$

其中 $\hat{f}_\lambda^{(-i)}$ 是删除第 i 个观测后拟合的模型。对光滑样条这一线性光滑器, 有**免重拟合公式** (习题 5.13):

$$\text{CV}(\hat{f}_\lambda) = \frac{1}{N} \sum_{i=1}^N \left(\frac{y_i - \hat{f}_\lambda(x_i)}{1 - S_\lambda(i, i)} \right)^2,$$

即只需完整拟合一次, 使用对角线元素 $S_\lambda(i, i)$ 校正。CV 曲线是 EPE 曲线的近似无偏估计量 (图 5.9 左上)。**对回归样条**还需额外选择节点位置和数量——这是个组合爆炸问题, 除非使用 MARS (§9.4) 等贪心策略。

13.6 非参数 Logistic 回归

将光滑样条从回归推广到分类是直接了当的。对单个连续输入 X 的 Logistic 回归:

$$\log \frac{\Pr(Y = 1 | X = x)}{\Pr(Y = 0 | X = x)} = f(x), \quad \Pr(Y = 1 | X = x) = \frac{e^{f(x)}}{1 + e^{f(x)}}.$$

在光滑样条框架下拟合 f 得到条件概率 $\Pr(Y = 1 | x)$ 的光滑估计。

惩罚对数似然准则:

$$\ell(f; \lambda) = \sum_{i=1}^N [y_i f(x_i) - \log(1 + e^{f(x_i)})] - \frac{\lambda}{2} \int \{f''(t)\}^2 dt, \quad (13.11)$$

第一项是二项分布的对数似然（第 4 章），第二项是曲率惩罚。与回归情况一样，最优 f 是节点在唯一 x_i 处的有限维自然样条： $f(x) = \sum_{j=1}^N N_j(x) \theta_j$ 。

Newton-Raphson 迭代：梯度和 Hessian 为

$$\frac{\partial \ell}{\partial \boldsymbol{\theta}} = \mathbf{N}^\top (\mathbf{y} - \mathbf{p}) - \lambda \boldsymbol{\Omega} \boldsymbol{\theta}, \quad \frac{\partial^2 \ell}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}^\top} = -\mathbf{N}^\top \mathbf{W} \mathbf{N} - \lambda \boldsymbol{\Omega},$$

其中 $\mathbf{W} = \text{diag}(p_i(1 - p_i))$ 。Newton 更新为：

$$\boldsymbol{\theta}^{\text{new}} = (\mathbf{N}^\top \mathbf{W} \mathbf{N} + \lambda \boldsymbol{\Omega})^{-1} \mathbf{N}^\top \mathbf{W} \mathbf{z}, \quad (13.12)$$

或以拟合值表示：

$$\mathbf{f}^{\text{new}} = \underbrace{\mathbf{N}(\mathbf{N}^\top \mathbf{W} \mathbf{N} + \lambda \boldsymbol{\Omega})^{-1} \mathbf{N}^\top \mathbf{W}}_{\mathbf{S}_{\lambda, w}} \mathbf{z} = \mathbf{S}_{\lambda, w} \mathbf{z}.$$

这恰好是加权光滑样条对工作响应 $\mathbf{z}$ 的拟合——与 §4.4.1 的 IRLS 完全一致，只是将线性回归换成了光滑样条。

推广： $\mathbf{S}_{\lambda, w}$ 可替换为任何非参数（加权）回归算子，得到一般的非参数 Logistic 回归族。该思想自然推广到高维——这正是广义加性模型（GAM，第 9 章）的基石。

13.7 多维样条

至此所有样条均为一维。本节讨论多维推广。

13.7.1 张量积基

设有一维基函数族 $\{h_{1j}(X_1)\}_{j=1}^{M_1}$ 和 $\{h_{2k}(X_2)\}_{k=1}^{M_2}$ ，则 $M_1 \times M_2$ 维张量积基定义为：

$$g_{jk}(X) = h_{1j}(X_1) h_{2k}(X_2), \quad j = 1, \dots, M_1, \quad k = 1, \dots, M_2, \quad (13.13)$$

二维函数表示为：

$$g(X) = \sum_{j=1}^{M_1} \sum_{k=1}^{M_2} \theta_{jk} g_{jk}(X).$$

系数由最小二乘拟合。

可推广到 d 维，但基的维度指数增长——维数灾难的又一个表现。MARS (§9.4) 使用贪心前向算法仅包含最小二乘认为必要的张量积项。

加性 vs 张量积：图 5.11 比较了二维分类问题上两者的决策边界。加性模型（各自样条相加）捕捉主效应，张量积可拟合更灵活的交互，但可能引入虚假结构。




FIGURE 5.10. A tensor product basis of B-splines, showing some selected pairs. Each two-dimensional function is the tensor product of the corresponding one dimensional marginals.

图 13.7: B-样条的张量积基。选取了部分代表性函数对，每个二维函数是对应一维边缘基函数的张量积。来源：ESL Figure 5.10。




FIGURE 5.11. The simulation example of Figure 2.1. The upper panel shows the decision boundary of an additive logistic regression model, using natural splines in each of the two coordinates (total $df = 1 + (4 - 1) + (4 - 1) = 7$). The lower panel shows the results of using a tensor product of natural spline bases in each coordinate (total $df = 4 \times 4 = 16$). The broken purple boundary is the Bayes decision boundary for this problem.

图 13.8: 图 2.1 模拟例子的二维分类。上图: 可加 Logistic 回归模型, 每维用自然样条 (总 $df = 1 + (4 - 1) + (4 - 1) = 7$)。下图: 每维自然样条基的张量积 (总 $df = 4 \times 4 = 16$)。紫色虚线为 Bayes 决策边界。来源: ESL Figure 5.11。

13.7.2 薄板样条 (Thin-Plate Splines)

一维光滑样条的正则化思想可推广到 $\mathbb{R}^d$:

$$\min_f \sum_{i=1}^N \{y_i - f(x_i)\}^2 + \lambda J[f], \quad (13.14)$$

其中 $J[f]$ 是 d 维粗糙度惩罚。对 $d = 2$:

$$J[f] = \iint_{\mathbb{R}^2} \left[\left(\frac{\partial^2 f}{\partial x_1^2} \right)^2 + 2 \left(\frac{\partial^2 f}{\partial x_1 \partial x_2} \right)^2 + \left(\frac{\partial^2 f}{\partial x_2^2} \right)^2 \right] dx_1 dx_2.$$

解的形式 (与一维自然三次样条共享性质):

$$f(x) = \beta_0 + \beta^\top x + \sum_{j=1}^N \alpha_j h_j(x), \quad h_j(x) = \|x - x_j\|^2 \log \|x - x_j\|,$$

其中 h_j 为径向基函数 (§5.9 详述)。系数由带线性约束的惩罚最小二乘确定 (习题 5.14)。

$$\lambda \rightarrow 0 \Rightarrow \text{插值表面}, \quad \lambda \rightarrow \infty \Rightarrow \text{最小二乘平面}.$$

计算复杂度: 薄板样条为 $O(N^3)$ (一般无稀疏结构可资利用), 实践中用放置在一组格点上的节点约简: 用 K 个节点将计算量降至 $O(NK^2 + K^3)$ 。图 5.12 展示了心脏病数据上年龄 $\times$ 肥胖的薄板样条拟合 ($df = 15$)。

13.7.3 加性样条与 ANOVA 分解

多维样条的一类重要限制是**加性模型**:

$$f(X) = \alpha + f_1(X_1) + f_2(X_2) + \cdots + f_d(X_d),$$

每 f_j 是一维样条。惩罚自然施加于各分量:

$$J[f] = \sum_{j=1}^d \int f_j''(t_j)^2 dt_j.$$

这自然推广到 ANOVA 分解:

$$f(X) = \alpha + \sum_j f_j(X_j) + \sum_{j < k} f_{jk}(X_j, X_k) + \cdots,$$

每项为相应维数的样条。需做的选择包括: 最大交互阶数、包含哪些项、每项使用回归样条还是光滑样条。MARS (§9.4) 和 MART (第 10 章) 提供了自动化方案。

13.7.4 小结：从一维到多维的选择路线

面对 d 维输入，样条建模有三条路线，对应递增的复杂度与表达力：

策略	模型形式	基函数数	能建模的效应
加性模型	$\alpha + \sum_{j=1}^d f_j(X_j)$	$O(dM)$	仅主效应
ANOVA 分解	$\alpha + \sum_j f_j + \sum_{j < k} f_{jk} + \cdots$	递增	主效应 + 指定交互
全张量积	$\sum_{j,k,\dots} \theta_{jk\dots} h_{1j} h_{2k} \cdots$	$O(M^d)$	所有效应（维数灾难）

实践中何时考虑交互效应？一个务实的四步流程：

1. **领域知识优先**：若物理/生物学机制暗示交互存在（如「药效取决于年龄」），直接加入；
2. **加性拟合后检查残差**：拟合纯加性模型，画残差 vs (X_j, X_k) 的二维散点图或热力图——若出现系统模式（而非随机噪声），提示遗漏了交互；
3. **定量诊断**：使用 Friedman's H -statistic 测两个变量间的交互强度——该统计量衡量预测函数偏离纯加性的程度，值越大交互越强（ $H_{jk}^2 \in [0, 1]$ ，0 表示纯加性）；
4. **交叉验证做最终裁决**：加入候选交互项后，用 CV 检验预测误差是否显著下降——下降则保留，否则剔除（除非解释性有强需求）。

EDA 的局限性：对于两连续变量的交互，肉眼从散点图中几乎无法察觉——因为交互本质是「 X_1 对 Y 的效应如何随 X_2 变化」，这需要条件化思维，通常超出纯 EDA 的能力。MARS 和 boosting 等自适应方法（后续章节）能自动检测并纳入交互，是实践中更可靠的方案。

一般原则：大多数问题中，主效应解释了绝大部分可预测变异——交互是锦上添花，常带来过拟合风险而非实质提升。从加性出发，有证据再加交互。

13.8 正则化与再生核 Hilbert 空间 (RKHS)

本节将样条纳入正则化方法的更广阔框架。

13.8.1 一般形式

一类正则化问题可统一写为：

$$\min_{f \in \mathcal{H}} \left[\sum_{i=1}^N L(y_i, f(x_i)) + \lambda J(f) \right], \quad (13.15)$$

其中 L 为损失函数， $J(f)$ 为惩罚泛函， $\mathcal{H}$ 为 $J(f)$ 有定义的函数空间。

若惩罚在 Fourier 域中取形式 $J(f) = \int |\tilde{f}(s)|^2 / \tilde{G}(s) ds$ ($\tilde{G}$ 在高频处衰减), 则解具有有限维表示:

$$f(X) = \sum_{k=1}^K \alpha_k \phi_k(X) + \sum_{i=1}^N \theta_i G(X - x_i),$$

其中 ϕ_k 张成惩罚的零空间 (不惩罚的方向), G 是 $\tilde{G}$ 的 Fourier 逆变换。光滑样条和薄板样条均属此框架。

13.8.2 RKHS 与核方法

正定核

一个二元函数 $K(\cdot, \cdot) : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ 称为**正定核**, 当且仅当: 对任意 n 个点 $\{x_1, \dots, x_n\} \subset \mathcal{X}$ 和任意实数 $\{c_1, \dots, c_n\}$,

$$\sum_{i=1}^n \sum_{j=1}^n c_i c_j K(x_i, x_j) \geq 0. \quad (13.16)$$

等价地, $n \times n$ 的 Gram 矩阵 $\mathbf{K}_{ij} = K(x_i, x_j)$ 对任意 n 和任意点集都是**半正定**的。

这个条件的几何含义是: K 可以作为某个函数空间的内积。直观上, $K(x, y)$ 度量了 x 和 y 的「相似度」; 半正定性保证了这个相似度定义在几何上是自洽的——你无法通过加权组合相似度得到负值。

常见正定核示例:

- **线性核**: $K(x, y) = x^\top y$, 对应有限维内积空间, 生成的函数类为线性函数;
- **多项式核**: $K(x, y) = (x^\top y + 1)^d$, 对应 $\binom{p+d}{d}$ 维特征空间, 生成的函数类为 d 次多项式;
- **高斯核 (RBF)**: $K(x, y) = e^{-\nu \|x-y\|^2}$, 对应无限维特征空间, 生成的函数类为任意光滑函数 (ν 越大 $\rightarrow$ 越局部 $\rightarrow$ 有效维数越高)。

再生核 Hilbert 空间 (RKHS)

给定正定核 K , 其对应的函数空间 $\mathcal{H}_K$ 按如下方式构造:

Step 1——构造稠密子集。把核固定在每个训练点 x_i 上, 得到单变量函数 $K(\cdot, x_i)$ 。这些函数的有限线性组合:

$$f(x) = \sum_{i=1}^n \alpha_i K(x, x_i)$$

构成了 $\mathcal{H}_K$ 的一个稠密子集——即任何属于 $\mathcal{H}_K$ 的函数都可以用这种形式的函数序列去逼近。

Step 2——定义内积。在该稠密子集上定义内积：

$$\left\langle \sum_i \alpha_i K(\cdot, x_i), \sum_j \beta_j K(\cdot, y_j) \right\rangle_{\mathcal{H}_K} = \sum_i \sum_j \alpha_i \beta_j K(x_i, y_j).$$

注意两个核函数的内积恰好是核本身的价值——这是 RKHS 构造的精妙之处。

Step 3——完备化。取该内积空间在 Cauchy 列意义下的完备化, 得到真正的 Hilbert 空间 $\mathcal{H}_K$ ——其范数由内积自然诱导: $\|f\|_{\mathcal{H}_K}^2 = \langle f, f \rangle_{\mathcal{H}_K}$ 。

再生性 (Reproducing Property)——RKHS 得名的关键性质:

$$f(x) = \langle f, K(\cdot, x) \rangle_{\mathcal{H}_K}, \quad \forall x \in \mathcal{X}, \forall f \in \mathcal{H}_K. \quad (13.17)$$

函数 f 在任意点 x 处的求值操作等价于 f 与「以 x 为中心的核」做内积。换言之, 求值泛函在 RKHS 中是连续的——这是普通 Hilbert 空间 (如 L^2) 不具备的性质, 也是 RKHS 能支撑「无穷维优化 $\Rightarrow$ 有限维问题」这一魔法的基础。

范数的含义。回头再看特征展开视角——设核有特征分解 $K(x, y) = \sum_{m=1}^{\infty} \gamma_m \phi_m(x) \phi_m(y)$ (Mercer 定理), 则任意 $f \in \mathcal{H}_K$ 可展开为 $f = \sum_m c_m \phi_m$, 且

$$\|f\|_{\mathcal{H}_K}^2 = \sum_{m=1}^{\infty} \frac{c_m^2}{\gamma_m}.$$

这意味着: 若 γ_m 随 m 增大而快速衰减 (如高斯核), 则函数在高频方向的分量 c_m 被赋予极大的范数惩罚——RKHS 范数天然偏好「低频」(光滑) 函数。这正是 $\lambda \|f\|_{\mathcal{H}_K}^2$ 作为正则化项的内在机理。

表示定理 (Representer Theorem): 问题

$$\min_{f \in \mathcal{H}_K} \sum_{i=1}^N L(y_i, f(x_i)) + \lambda \|f\|_{\mathcal{H}_K}^2$$

的有限维解为:

$$f(x) = \sum_{i=1}^N \alpha_i K(x, x_i).$$

且 $J(f) = \alpha^\top \mathbf{K} \alpha$ ($\mathbf{K}_{ij} = K(x_i, x_j)$)。无穷维优化 $\Rightarrow N$ 维问题 $\min_{\alpha} L(\mathbf{y}, \mathbf{K} \alpha) + \lambda \alpha^\top \mathbf{K} \alpha$ 。

表示定理如何导出 α 的解

以最重要的特例——平方损失 $L(y_i, f(x_i)) = (y_i - f(x_i))^2$ ——演示从无穷维泛函到有限维解析解的完整推导。

Step 1——代入表示定理。将 $f(x) = \sum_{j=1}^N \alpha_j K(x, x_j)$ 代入目标函数的两项。

Step 2——化简损失项。在训练点 x_i 处:

$$f(x_i) = \sum_{j=1}^N \alpha_j K(x_i, x_j) = (\mathbf{K} \alpha)_i,$$

其中 $\mathbf{K}$ 是 $N \times N$ 的 Gram 矩阵。因此：

$$\sum_{i=1}^N (y_i - f(x_i))^2 = \|\mathbf{y} - \mathbf{K}\boldsymbol{\alpha}\|_2^2 = (\mathbf{y} - \mathbf{K}\boldsymbol{\alpha})^\top (\mathbf{y} - \mathbf{K}\boldsymbol{\alpha}).$$

Step 3——化简惩罚项。由 RKHS 内积的定义：

$$\langle K(\cdot, x_i), K(\cdot, x_j) \rangle_{\mathcal{H}_K} = K(x_i, x_j),$$

可得：

$$\|f\|_{\mathcal{H}_K}^2 = \left\langle \sum_i \alpha_i K(\cdot, x_i), \sum_j \alpha_j K(\cdot, x_j) \right\rangle_{\mathcal{H}_K} = \sum_i \sum_j \alpha_i \alpha_j K(x_i, x_j) = \boldsymbol{\alpha}^\top \mathbf{K} \boldsymbol{\alpha}.$$

Step 4——化为有限维二次型。无穷维泛函转化为对 $\boldsymbol{\alpha} \in \mathbb{R}^N$ 的普通无约束二次优化：

$$\min_{\boldsymbol{\alpha} \in \mathbb{R}^N} \{(\mathbf{y} - \mathbf{K}\boldsymbol{\alpha})^\top (\mathbf{y} - \mathbf{K}\boldsymbol{\alpha}) + \lambda \boldsymbol{\alpha}^\top \mathbf{K} \boldsymbol{\alpha}\}. \quad (13.18)$$

Step 5——求导得解析解。对 $\boldsymbol{\alpha}$ 求梯度（利用 $\mathbf{K}$ 对称）：

$$\frac{\partial}{\partial \boldsymbol{\alpha}} = -2\mathbf{K}(\mathbf{y} - \mathbf{K}\boldsymbol{\alpha}) + 2\lambda \mathbf{K}\boldsymbol{\alpha} = 0 \implies \mathbf{K}\mathbf{K}\boldsymbol{\alpha} + \lambda \mathbf{K}\boldsymbol{\alpha} = \mathbf{K}\mathbf{y}.$$

对严格正定核（如高斯核、多项式核）， $\mathbf{K}$ 可逆，两边左乘 $\mathbf{K}^{-1}$ 即得：

$$\boxed{\hat{\boldsymbol{\alpha}} = (\mathbf{K} + \lambda \mathbf{I})^{-1} \mathbf{y}.} \quad (13.19)$$

Step 6——预测新点。对于任意新输入 x_{new} ，预测直接在核空间中完成：

$$\hat{f}(x_{\text{new}}) = \sum_{i=1}^N \hat{\alpha}_i K(x_{\text{new}}, x_i) = \mathbf{k}_{\text{new}}^\top \hat{\boldsymbol{\alpha}},$$

其中 $\mathbf{k}_{\text{new}} = [K(x_{\text{new}}, x_1), \dots, K(x_{\text{new}}, x_N)]^\top$ 只需 N 次核函数求值。

与线性岭回归的平行结构。核岭回归与线性岭回归在代数上完全对应——唯一的区别是把 $p \times p$ 的 $\mathbf{X}^\top \mathbf{X}$ 换成了 $N \times N$ 的 $\mathbf{K}$ ：

	线性岭回归	核岭回归
参数空间	$\boldsymbol{\beta} \in \mathbb{R}^p$	$\boldsymbol{\alpha} \in \mathbb{R}^N$
目标	$\ \mathbf{y} - \mathbf{X}\boldsymbol{\beta}\ ^2 + \lambda \ \boldsymbol{\beta}\ ^2$	$\ \mathbf{y} - \mathbf{K}\boldsymbol{\alpha}\ ^2 + \lambda \boldsymbol{\alpha}^\top \mathbf{K} \boldsymbol{\alpha}$
解析解	$(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}$	$(\mathbf{K} + \lambda \mathbf{I})^{-1} \mathbf{y}$
预测	$x_{\text{new}}^\top \hat{\boldsymbol{\beta}}$	$\mathbf{k}_{\text{new}}^\top \hat{\boldsymbol{\alpha}}$
计算量	$O(p^3 + p^2 N)$	$O(N^3)$

核形式的关键优势：计算复杂度与特征维度 p 完全无关——即使核隐式映射到无限维空间，实际求解始终是 $N \times N$ 的线性系统。代价是 $O(N^3)$ 对大规模数据不友好，后续章节（如 SVM 的 SMO 算法、高斯过程的稀疏近似）将讨论应对策略。

一般损失函数的推广。若 L 不是平方损失（如分类问题的 hinge loss 或交叉熵），则优化问题

$$\min_{\alpha} L(\mathbf{y}, \mathbf{K}\alpha) + \lambda \alpha^{\top} \mathbf{K} \alpha$$

通常无闭式解，但可用梯度下降或 Newton 法迭代求解。支持向量机（第 12 章）和核 Logistic 回归（第 4 章）恰是这一框架在不同损失函数下的特例。

更一般的分解 $\mathcal{H} = \mathcal{H}_0 \oplus \mathcal{H}_1$ ： $\mathcal{H}_0$ （多项式零空间，不惩罚）+ $\mathcal{H}_1$ （惩罚空间）。解为 $f(x) = \sum_j \beta_j h_j(x) + \sum_i \alpha_i K(x, x_i)$ 。

13.8.3 实例

平方误差损失： $\hat{\alpha} = (\mathbf{K} + \lambda \mathbf{I})^{-1} \mathbf{y}$, $\hat{\mathbf{f}} = \mathbf{K}(\mathbf{K} + \lambda \mathbf{I})^{-1} \mathbf{y} = (\mathbf{I} + \lambda \mathbf{K}^{-1})^{-1} \mathbf{y}$ （对比光滑样条的 $(\mathbf{I} + \lambda \mathbf{K})^{-1} \mathbf{y}$ ）。在空间统计中称为 Kriging 估计。

多项式核： $K(x, y) = (\langle x, y \rangle + 1)^d$ 。 $M = \binom{p+d}{d}$ 个基函数（可能 $\gg N$ ），但核表示只需 $O(N^3)$ ——这是**核技巧**的本质：隐式使用高维特征空间而不显式构造它。

高斯径向基核： $K(x, y) = e^{-\nu \|x - y\|^2}$ 。每个基函数 $k_m(x) = K(x, x_m)$ 是以训练点 x_m 为中心的 Gaussian。核尺度 ν 控制局部性： ν 越大 $\rightarrow$ 越局部 $\rightarrow$ 有效维数越高（图 5.14–5.15）。

薄板样条核： $K(x, y) = \|x - y\|^2 \log(\|x - y\|)$ （径向基函数形式的薄板样条）。

支持向量机（第 12 章）：二分类下使用 hinge loss：

$$\min_{\alpha_0, \alpha} \sum_{i=1}^N [1 - y_i f(x_i)]_+ + \frac{\lambda}{2} \alpha^{\top} \mathbf{K} \alpha,$$

非零 $\hat{\alpha}_i$ 对应的 x_i 即为**支持向量**。

13.8.4 实践指南：何时使用核方法

核方法并非万能工具。以下从数据规模、特征维度、任务需求三个维度给出实用判断标准。

核方法的理想适用场景

以下三个条件**同时成立**时，核方法通常是最优选择：

条件	原因
N 适中 ($10^2 \sim 10^4$)	$O(N^3)$ 的计算量是主要瓶颈。 $N > 10^4$ 时需用 Nyström 近似或随机 Fourier 特征，但实践中常被 XGBoost 取代
p 中等 ($5 \sim 100$)	p 太大时高斯核的距离在高维中坍塌（维数灾难）； p 很小时 (< 5) 样条或 GAM 更简单且可解释
非线性复杂且未知	确定存在非线性，但无法用简单参数形式（二次、对数等）捕捉——如生物标记物预测、信用评分、图像像素级分类

典型成功案例： $N = 500$ ， $p = 30$ ，分类问题中决策边界高度非线性——SVM with RBF 核是标准基线。

何时不应使用核方法

- **大样本** ($N > 10^5$): $O(N^3)$ 直接不可行。即使采用近似方法, XGBoost / LightGBM / 神经网络通常更快、精度相当或更好。
- **高维稀疏数据** ($p > 10^3$, 多数特征为零): 高维中欧氏距离失去区分力, 高斯核退化为近似常数矩阵。此时带 L_1 惩罚的线性模型或稀疏加性模型更实用。
- **需要强解释性**: $\hat{f}(x) = \sum \alpha_i K(x, x_i)$ 本质是「与训练点的加权相似度」, 医生、风控人员等非技术受众通常无法理解。若解释性必需, 优先考虑 GAM 或决策树。
- **特征有明确的物理含义和尺度**: 如果已知 $y \approx \log(x_1) + x_2^2$ 这类显式关系, 直接做参数化建模比核方法更高效（更少参数、更低方差）。

EDA 中值得注意的信号

做探索性分析时，以下模式提示核方法可能优于线性或简单参数模型：

1. **线性回归残差图有系统结构**：残差 vs 拟合值图呈现 U 形、波浪形或局部团簇，而非均匀随机散布——说明线性模型遗漏了非线性信号；
2. **变量间存在复杂互补性**： X_1 大且 X_2 中等时 Y 才高——这类交互难以用有限阶多项式捕捉，但 RBF 核能自然建模；
3. **样本量和维度落入「甜区」**： N 在数百至数千、 p 在数十量级——刚好是参数模型可能欠拟合、深度学习数据不足的交界地带。

快速决策表

数据画像	推荐方法
$N < 10^3$, $p < 20$, 需不确定性量化	高斯过程 (GP) / 核岭回归
$N < 10^4$, $p < 100$, 分类任务	SVM (RBF 核)
$N < 10^4$, $p < 100$, 回归任务	核岭回归 / Nyström 近似 GP
$N > 10^4$, 任意 p	XGBoost / LightGBM / 神经网络
$p > 500$, N 任意	带 L_1 的线性模型 + 特征工程
$p < 10$, 需可解释性	GAM (样条) / 加性核模型

一般原则：核方法是中等规模非线性问题的首选工具之一，但在大规模数据和强解释性需求面前有明确边界。实践中常作为基线模型——先跑一个 SVM/GP，若性能不够再考虑更复杂的集成方法或深度学习。

13.9 小波光滑

小波提供了一种与样条互补的基函数字典：样条通过光滑性实现压缩，小波通过稀疏性实现压缩。

13.9.1 核心思想：时间-频率定位

样条擅长表示光滑函数（用少量基函数）；小波擅长表示「大部分平坦 + 少数突起」的信号（用少量 bumpy 基函数）。小波基能同时定位**时间**（突起在哪里）和**频率**（突起有多尖锐）——传统 Fourier 基只能定位频率。

13.9.2 多分辨率分析

小波基通过单个**尺度函数** $\phi(x)$ （父小波）和**母小波** $\psi(x)$ 的平移和缩放生成。以 Haar 小波为例：

$$\phi(x) = I(0 \leq x < 1), \quad \psi(x) = \phi(2x) - \phi(2x - 1) \quad (\text{在}[0, \frac{1}{2})\text{为} +1, [\frac{1}{2}, 1)\text{为} -1).$$

空间分解： $V_{j+1} = V_j \oplus W_j$ (V_j = 分辨率 2^{-j} 的逼近空间, W_j = 细节空间)。迭代得多分辨率分解：

$$V_J = V_0 \oplus W_0 \oplus W_1 \oplus \cdots \oplus W_{J-1}.$$

V_0 是最粗逼近 (Haar 下为常数), $W_0, W_1, \dots$ 是递增分辨率的细节层。

Haar 基简单但不光滑，实践中更常用 **symmlet-p** 族：

- 支撑： $2p - 1$ 个连续区间 (Haar 为 1)；

- 消失矩: p 个 ($\int \psi(x)x^j dx = 0, j = 0, \dots, p-1$), 使 V_0 可精确复现 p 阶多项式——类比光滑样条惩罚的零空间。




FIGURE 5.16. Some selected wavelets at different translations and dilations for the Haar and symmlet families. The functions have been scaled to suit the display.

图 13.9: Haar 和 symmlet 族在不同平移和尺度下的小波函数。函数已缩放以适配显示。
来源: ESL Figure 5.16。

13.9.3 小波变换的数学定义

设母小波 $\psi(x)$ 满足容许条件 $\int \psi(x)dx = 0$ 。通过平移和缩放生成一族基函数:

$$\psi_{j,k}(x) = 2^{j/2} \psi(2^j x - k), \quad j, k \in \mathbb{Z}, \quad (13.20)$$

其中 j 为尺度参数 (控制频率: j 越大 $\rightarrow$ 基函数越窄 $\rightarrow$ 频率越高), k 为平移参数 (控制时间位置)。因子 $2^{j/2}$ 保证所有基函数具有相同的 L^2 范数。

连续小波变换。函数 $f(x)$ 在尺度 j 和位置 k 处的小波系数为:

$$d_{jk} = \int_{-\infty}^{\infty} f(x) \psi_{j,k}(x) dx = \langle f, \psi_{j,k} \rangle.$$

离散小波变换 (DWT)。给定 $N = 2^J$ 个等间距观测 $y_i = f(x_i)$ ($i = 1, \dots, N$)，存在正交小波基矩阵 $\mathbf{W}$ ($N \times N$) 使得系数向量 $\mathbf{y}^*$ 和原始信号彼此由线性变换关联：

$$\mathbf{y}^* = \mathbf{W}^\top \mathbf{y} \quad (\text{正变换}), \quad \mathbf{y} = \mathbf{W} \mathbf{y}^* \quad (\text{逆变换}). \quad (13.21)$$

$\mathbf{y}^*$ 的前半部分对应粗尺度（低频），后半部分对应细尺度（高频）。正交性 $\mathbf{W}^\top \mathbf{W} = \mathbf{I}$ 保证变换可逆且保范数（Parseval 恒等式： $\|\mathbf{y}^*\| = \|\mathbf{y}\|$ ）。

多分辨率结构。小波系数 $\mathbf{y}^*$ 可按分辨率层级组织：

$$\mathbf{y}^* = (\underbrace{v_0}_{\text{最粗}}, \underbrace{w_0, w_1, \dots, w_{J-1}}_{\text{递增分辨率}}),$$

对应空间分解 $V_J = V_0 \oplus W_0 \oplus W_1 \oplus \dots \oplus W_{J-1}$ 。 v_0 是最粗尺度的逼近， w_j 包含尺度 2^{-j} 的细节信息。

13.9.4 自适应小波阈值 (Wavelet Shrinkage)

对一维离散信号 $\mathbf{y}$ ($N = 2^J$ 均匀样本)，设 $\mathbf{W}$ 为 $N \times N$ 正交小波基矩阵，小波变换 $\mathbf{y}^* = \mathbf{W}^\top \mathbf{y}$ 给出每个基上的系数。

SURE 收缩 (Donoho & Johnstone, 1994) 求解 Lasso 型问题：

$$\min_{\boldsymbol{\theta}} \|\mathbf{y} - \mathbf{W}\boldsymbol{\theta}\|^2 + 2\lambda \|\boldsymbol{\theta}\|_1.$$

由于 $\mathbf{W}$ 正交，解有显式软阈值规则：

$$\hat{\theta}_j = \text{sign}(y_j^*) (|y_j^*| - \lambda)_+. \quad (13.22)$$

即将系数向零平移 λ ，不足 λ 的置为零。常用阈值 $\lambda = \hat{\sigma} \sqrt{2 \log N}$ ——理由： N 个白噪声变量的最大绝对值约为 $\sigma \sqrt{2 \log N}$ ，低于此的系数大概率是噪声。

逆小波变换 $\hat{\mathbf{f}} = \mathbf{W}\hat{\boldsymbol{\theta}}$ 得光滑后信号。

13.9.5 小波 vs 光滑样条 (图 5.19)

	光滑样条	小波收缩
适应对象	整体光滑的信号	平坦 + 局部尖峰的信号
压缩方式	曲率惩罚 $\rightarrow$ 光滑	ℓ_1 阈值 $\rightarrow$ 稀疏
计算	$O(N)$	$O(N)$ (金字塔算法, 比 FFT 更快)

图 5.17 的 NMR 信号演示了完整流程：原始信号 $\rightarrow$ 小波变换（系数按尺度排列） $\rightarrow$ 软阈值去噪 $\rightarrow$ 逆变换重建。

图 5.19 对比了两类信号的拟合：NMR 尖峰信号中小波优于样条（精确定位尖峰，样条为迁就尖峰在整个域引入多余波动）；光滑信号中样条优于小波（小波为获得自适应性付出了额外方差的代价）。两者的选择取决于信号的光滑 vs 稀疏性质。




FIGURE 5.17. The top panel shows an NMR signal, with the wavelet-shrunk version superimposed in green. The lower left panel represents the wavelet transform of the original signal, down to V_4 , using the symmlet-8 basis. Each coefficient is represented by the height (positive or negative) of the vertical bar. The lower right panel represents the wavelet coefficients after being shrunk using the `waveshrink` function in *S-PLUS*, which implements the SureShrink method of wavelet adaptation of Donoho and Johnstone.

图 13.10: 上图: NMR 信号 (黑) 与小波收缩后信号 (绿) 叠绘。左下: 使用 symmlet-8 基的原始信号小波变换系数 (V_0 至 V_4), 竖条高度 = 系数值 (正/负)。右下: 经 S-PLUS 的 SureShrink 方法收缩后的小波系数——大部分噪声尺度的系数被阈值化为零, 仅保留显著突起。来源: ESL Figure 5.17。





FIGURE 5.19. Wavelet smoothing compared with smoothing splines on two examples. Each panel compares the SURE-shrunk wavelet fit to the cross-validated smoothing spline fit.

图 13.11: 小波光滑与光滑样条的对比 (两例)。每面板对比 SURE-shrunk 小波拟合 (实线) 与交叉验证光滑样条拟合 (虚线)。左: NMR 尖峰信号——小波精确定位尖峰, 样条为捕捉尖峰产生额外波动。右: 光滑信号——样条以更少有效参数获得相近拟合, 小波因自适应性付出方差代价。来源: ESL Figure 5.19。

注记 13.3. 二维小波是现代图像压缩（如 JPEG2000）的核心技术。本章参考文献见 de Boor (1978)、Wahba (1990)、Daubechies (1992)、Donoho & Johnstone (1994) 等。

13.10 本章小结

下图总结了本章从线性模型到核方法的完整方法论脉络：



本章核心要点：

- (1) **基展开**是将非线性建模统一纳入线性框架的核心范式： $f(X) = \sum_m \beta_m h_m(X)$ 。基函数一经选定，所有线性方法（最小二乘、MLE、IRLS）照常使用。
- (2) **样条**是最经典的基展开实例。一维样条从分段多项式出发，通过截断幂基 $h_{M+\ell}(X) = (X - \xi_\ell)_+^{M-1}$ 实现节点的平滑过渡。三次样条（ $M = 4$ ）是实践标准——人眼无法察觉节点处的三阶不连续性。
- (3) **自然三次样条**通过边界线性约束 $f''(\xi_1) = f''(\xi_K) = 0$ 释放 4 个自由度，将基函数数从 $K + 4$ 压缩为 K ，显著降低边界方差——是本章最重要的实用改进。
- (4) **光滑样条**将节点选择从离散决策转化为连续调节：每个 x_i 放一个节点 $+\lambda \int (f'')^2$ 惩罚。解为节点在所有唯一 x_i 处的自然三次样条，有效自由度 $\text{df}_\lambda = \text{trace}(\mathbf{S}_\lambda) \in [2, N]$ 。CV/GCV 自动选择 λ ，免去人工调参。
- (5) **RKHS 与核方法**将样条纳入更广阔的正则化框架。正定核 $K(x, y)$ 定义一个再生核 Hilbert 空间 $\mathcal{H}_K$ ，其范数天然偏好低频函数。**表示定理**将无穷维优化 $\min_{f \in \mathcal{H}_K} \sum L(y_i, f(x_i)) + \lambda \|f\|_{\mathcal{H}_K}^2$ 化为 N 维问题 $\min_{\boldsymbol{\alpha}} L(\mathbf{y}, \mathbf{K}\boldsymbol{\alpha}) + \lambda \boldsymbol{\alpha}^\top \mathbf{K}\boldsymbol{\alpha}$ 。高斯核 $K(x, y) = e^{-\nu \|x-y\|^2}$ 隐式映射到无限维空间，是实践中最重要的核函数。
- (6) **小波**通过 ℓ_1 阈值化（软阈值）实现稀疏压缩，与样条的 ℓ_2 光滑惩罚形成互补。小波适合平坦 + 局部尖峰的信号（如 NMR、图像边缘），计算复杂度 $O(N)$ （金字塔算法，比 FFT 更快）。两者选择的根本判据：信号是整体光滑（用样条）还是局部稀疏（用小波）。
- (7) **多维推广**面临维数灾难： d 维张量积样条需 $O(M^d)$ 个基函数。加性模型 $f(X) = \alpha + \sum_j f_j(X_j)$ 降至 $O(dM)$ ，但损失交互效应。ANOVA 分解提供中间地带：按需添加指定交互项。实践中从加性出发，以残差诊断和交叉验证为指导逐步增加交互。
- (8) **复杂度控制的统一视角**：所有方法——限制基函数数（样条）、连续惩罚参数（光滑样条、核岭回归）、 ℓ_1 稀疏化（Lasso、小波阈值）——本质上都是在偏差-方差曲线上寻找最优工作点。本章建立了理解后续章节（MARS、boosting、GAM、SVM、神经网络）所需的核心概念框架。

第十四章 核光滑方法

本章介绍一类基于记忆（memory-based）的回归与分类技术：在每个查询点 x_0 处，仅使用 x_0 附近的观测来拟合一个局部简单模型，并使得整体估计 $\hat{f}(X)$ 在 $\mathbb{R}^p$ 上光滑。这种局部化通过核函数（kernel） $K_\lambda(x_0, x)$ 实现——给 x_i 分配一个随其到 x_0 距离递减的权重，参数 λ 控制邻域宽度。

注意区分：本章的「核」主要用于局部化（localization），与第 5.8、12、14.5.4、18.5 节中计算高维内积的「核方法」（kernel methods）不同，尽管在 §6.7 末尾会建立一些联系。

这类方法几乎不需要训练——所有工作都在评估时完成，唯一需要从训练数据确定的参数是 λ 。

14.1 一维核光滑器

14.1.1 从 k -最近邻平均到核加权平均

在第 2 章中， k -最近邻平均

$$\hat{f}(x_0) = \text{Ave}(y_i \mid x_i \in N_k(x_0)) \quad (14.1)$$

被用作回归函数 $\mathbb{E}[Y \mid X = x_0]$ 的估计，其中 $N_k(x_0)$ 是距离 x_0 最近的 k 个点的集合。其思想是将条件期望的定义「松弛」——在目标点的邻域内做平均。

然而 k -NN 平均存在一个明显缺陷： $\hat{f}(x_0)$ 对 x_0 是不连续的。当 x_0 从左向右移动时， k -最近邻集合保持不变，直至某个右侧点比邻域中最远的左侧点更近——此时邻域成员发生替换，导致平均值跳跃。图 6.1 左面板展示了这种「颠簸」的绿色曲线。

Nadaraya–Watson 核加权平均通过给邻域内各点分配平滑递减的权重来解决此问题：

$$\hat{f}(x_0) = \frac{\sum_{i=1}^N K_\lambda(x_0, x_i) y_i}{\sum_{i=1}^N K_\lambda(x_0, x_i)} \quad (14.2)$$

其中 $K_\lambda(x_0, x_i)$ 是核函数。使用 Epanechnikov 二次核时，拟合函数变为连续的且相当光滑（图 6.1 右面板）。




FIGURE 6.1. In each panel 100 pairs x_i, y_i are generated at random from the blue curve with Gaussian errors: $Y = \sin(4X) + \varepsilon$, $X \sim U[0, 1]$, $\varepsilon \sim N(0, 1/3)$. In the left panel the green curve is the result of a 30-nearest-neighbor running-mean smoother. The red point is the fitted constant $\hat{f}(x_0)$, and the red circles indicate those observations contributing to the fit at x_0 . The solid yellow region indicates the weights assigned to observations. In the right panel, the green curve is the kernel-weighted average, using an Epanechnikov kernel with (half) window width $\lambda = 0.2$.

图 14.1: 每面板中 100 对 (x_i, y_i) 由蓝色曲线加高斯误差随机生成: $Y = \sin(4X) + \varepsilon$, $X \sim U[0, 1]$, $\varepsilon \sim N(0, 1/3)$ 。左面板: 绿色曲线是 30-最近邻滑动平均光滑器的结果。红点是拟合的常数 $\hat{f}(x_0)$, 红色圆圈标示了参与 x_0 处拟合的观测。黄色实心区域表示分配给各观测的权重。右面板: 绿色曲线是核加权平均, 使用 Epanechnikov 核, 半窗宽 $\lambda = 0.2$ 。

14.1.2 核函数的形式

一般地，核函数可写为

$$K_\lambda(x_0, x) = D\left(\frac{|x - x_0|}{h_\lambda(x_0)}\right) \quad (14.3)$$

其中 $D(\cdot)$ 是核函数的具体形状， $h_\lambda(x_0)$ 是宽度函数（width function）。

- **固定宽度（metric window）**: $h_\lambda(x_0) = \lambda$ 为常数，邻域宽度不随 x_0 变化。
- **最近邻宽度**: $h_k(x_0) = |x_0 - x_{[k]}|$ ，其中 $x_{[k]}$ 是距离 x_0 第 k 近的点，邻域大小 k 取代 λ 作为参数。

14.1.3 三种常用核

在介绍具体核之前，先明确**紧支撑（compact support）**的数学含义：函数 f 的支撑集定义为 $\text{supp}(f) = \overline{\{x \mid f(x) \neq 0\}}$ （即非零值集合的闭包）。若 $\text{supp}(f)$ 是紧集（在 $\mathbb{R}^d$ 中等价于有界闭集），则称 f 具有**紧支撑**。直观地说，紧支撑函数仅在有限范围内非零，范围之外恒为零——这对于结合最近邻窗宽使用的核是必要的。

- **Epanechnikov 核**（紧支撑，边界处不可导）：

$$D(t) = \begin{cases} \frac{3}{4}(1 - t^2), & |t| \leq 1 \\ 0, & \text{否则} \end{cases} \quad (14.4)$$

- **Tri-cube 核**（紧支撑，边界处有二阶连续导数，顶部更平坦）：

$$D(t) = \begin{cases} (1 - |t|^3)^3, & |t| \leq 1 \\ 0, & \text{否则} \end{cases} \quad (14.5)$$

- **Gaussian 核**（非紧支撑，无穷可微）：

$$D(t) = \phi(t) = \frac{1}{\sqrt{2\pi}} e^{-t^2/2} \quad (14.6)$$

标准差充当窗口宽度的角色。

14.1.4 实践中的注意事项

1. **光滑参数 λ 的选择**: λ 大 $\rightarrow$ 方差低（平均更多观测）但偏差高（假设窗内函数为常数）。
2. **固定宽度 vs 最近邻宽度的行为差异**:

- 固定宽度：偏差保持恒定，但方差与局部密度成反比；
 - 最近邻宽度：方差保持恒定，绝对偏差与局部密度成反比。
3. **结 (ties) 的处理**：当 x_i 存在重复值时，可以先对相同 x 值处的 y_i 做平均，并对合并后的观测赋予额外的权重 w_i 。
 4. **观测权重 w_i** ：将 w_i 乘以核权重后计算加权平均；在最近邻邻域中，使用权重总量 k （而非点数 k ）来定义邻域。
 5. **边界问题**：固定宽度窗在边界处包含的点更少，而最近邻窗在边界处会变宽。

14.2 局部线性回归

14.2.1 边界偏差问题

尽管核加权平均已经比原始滑动平均光滑得多，但在**定义域边界附近**仍存在严重的偏差问题（图 6.3 左面板）。原因在于：边界处核是非对称的——邻域内大多数观测的均值高于目标点，因此即使加权后均值仍向上偏。

实际上，如果 X 值不是等间距的，在定义域内部也可能存在类似偏差（通常程度较轻）。通过在局部拟合**直线**而非常数，可以精确到一阶地消除这种偏差。

14.2.2 局部加权最小二乘

在每个目标点 x_0 处求解一个独立的加权最小二乘问题：

$$\min_{\alpha(x_0), \beta(x_0)} \sum_{i=1}^N K_\lambda(x_0, x_i) [y_i - \alpha(x_0) - \beta(x_0)x_i]^2 \quad (14.7)$$

估计值为 $\hat{f}(x_0) = \hat{\alpha}(x_0) + \hat{\beta}(x_0)x_0$ 。注意：虽然拟合了整个线性模型，但只在单点 x_0 处使用。

14.2.3 矩阵形式与等价核

定义 $\mathbf{b}(x)^T = (1, x)$ 。设 $\mathbf{B}$ 为 $N \times 2$ 回归矩阵（第 i 行为 $\mathbf{b}(x_i)^T$ ）， $\mathbf{W}(x_0)$ 为 $N \times N$ 对角矩阵，第 i 个对角元为 $K_\lambda(x_0, x_i)$ 。则

$$\hat{f}(x_0) = \mathbf{b}(x_0)^T (\mathbf{B}^T \mathbf{W}(x_0) \mathbf{B})^{-1} \mathbf{B}^T \mathbf{W}(x_0) \mathbf{y} = \sum_{i=1}^N l_i(x_0) y_i \quad (14.8)$$

权重 $l_i(x_0)$ 结合了核权重 $K_\lambda(x_0, \cdot)$ 和最小二乘操作，称为**等价核 (equivalent kernel)**。 $\hat{f}(x_0)$ 对 y_i 是线性的（ $l_i(x_0)$ 不依赖于 y_i ）。




FIGURE 6.3. The locally weighted average has bias problems at or near the boundaries of the domain. The true function is approximately linear here, but most of the observations in the neighborhood have a higher mean than the target point, so despite weighting, their mean will be biased upwards. By fitting a locally weighted linear regression (right panel), this bias is removed to first order.

图 14.2: 局部加权平均在定义域边界处或附近存在偏差问题。此处的真实函数近似线性, 但邻域内大多数观测的均值高于目标点, 因此即使加权后, 其均值仍向上偏。通过在局部拟合加权线性回归 (右面板), 这一偏差被精确到一阶地消除。

14.2.4 自动核木工 (Automatic Kernel Carpentry)

历史上, Nadaraya-Watson 等局部平均核方法的偏差通过直接修改核函数来修正——这些修正基于渐近 MSE 理论, 不仅实现繁琐, 而且在有限样本下仅是近似的。局部线性回归能自动修改核以精确到一阶地校正偏差, 这一现象被称为「自动核木工」。

考虑 $\mathbb{E}[\hat{f}(x_0)]$ 的展开 (利用局部回归的线性和 f 在 x_0 处的 Taylor 展开):

$$\begin{aligned} \mathbb{E}[\hat{f}(x_0)] &= \sum_{i=1}^N l_i(x_0) f(x_i) \\ &= f(x_0) \underbrace{\sum_{i=1}^N l_i(x_0)}_{=1} + f'(x_0) \underbrace{\sum_{i=1}^N (x_i - x_0) l_i(x_0)}_{=0} + \frac{f''(x_0)}{2} \sum_{i=1}^N (x_i - x_0)^2 l_i(x_0) + R \end{aligned} \quad (14.9)$$

其中余项 R 涉及 f 的三阶及以上导数, 在适当光滑性假设下通常很小。对于局部线性回归, 可证 $\sum l_i(x_0) = 1$ 且 $\sum (x_i - x_0) l_i(x_0) = 0$ (习题 6.2), 因此偏差 $\mathbb{E}[\hat{f}(x_0)] - f(x_0)$ 仅依赖于 f 展开中的二阶及更高阶项——一阶偏差被完全消除。

Q: 自动核木工 (Automatic Kernel Carpentry) 到底在说什么?

可以从「等价核」的角度来理解。Nadaraya-Watson 核加权平均本质上等价于用一

个给定的核 $D(\cdot)$ 做局部常数拟合。这个固定形状的核在边界处不对称，导致一阶偏差。历史上人们试图通过手工设计「高阶核」(higher-order kernels) 来修正——让核函数满足特定的矩条件（如 $\int tK(t)dt = 0$ ），从而消除低阶偏差。但这需要针对不同情况手工调整核的形状和参数，实现繁琐，且只在渐近意义下精确。

局部线性回归的巧妙之处在于：它不直接修改 K_λ ，而是通过最小二乘的代数结构自动生成了正确的等价核 $l_i(x_0)$ 。从式 (14.9) 可以看到，只要等价权重满足 $\sum l_i = 1$ 和 $\sum (x_i - x_0)l_i = 0$ ，一阶偏差就自动消失——而局部线性回归的最小二乘解恰好保证这两个条件成立，无需任何手工调整。换句话说，与其自己费劲「雕琢」核函数的形状来消偏差，不如让最小二乘帮你自动「打磨」出正确的权重——这就是「自动核木工」(automatic kernel carpentry) 这个比喻的含义。

Q：在实践中是怎么利用这个方法的？

实践者几乎不需要关心核木工的细节——它对你完全透明。你只需要在使用局部回归软件时选择**局部线性** ($d = 1$) 而非**局部常数** ($d = 0$)，偏差校正就自动生效。具体来说：

- 在 R 的 `loess()` 或 `locfit` 中，设置 `degree=1`（通常这就是默认值）；
- 在 Python 的 `statsmodels.nonparametric.KernelReg` 中，选择 `reg_type='ll'` (local linear)。

你实际要做的决策只有两个：(1) 选什么核（tri-cube 是常用默认，紧支撑且边界光滑）；(2) 选多大窗宽 λ （通过交叉验证确定）。选好之后直接拟合，边界处的偏差自动被一阶校正——不需要你手工设计高阶核，也不需要区分边界和内部做不同处理。这就是自动核木工给实践者带来的便利：用局部线性替代局部常数几乎只有收益（以微小的方差增加换取大幅的边界偏差降低），所以局部线性已经成为了局部多项式回归的事实标准。

14.3 局部多项式回归

14.3.1 d 阶局部多项式拟合

将局部拟合从线性推广到任意 d 次多项式：

$$\min_{\alpha(x_0), \beta_j(x_0)} \sum_{i=1}^N K_\lambda(x_0, x_i) \left[y_i - \alpha(x_0) - \sum_{j=1}^d \beta_j(x_0) x_i^j \right]^2 \quad (14.10)$$

估计值为 $\hat{f}(x_0) = \hat{\alpha}(x_0) + \sum_{j=1}^d \hat{\beta}_j(x_0) x_0^j$ 。类似式 (14.9) 的展开表明，偏差仅包含 $d+1$ 阶及以上的分量（习题 6.2）。

14.3.2 削峰填谷效应

局部线性拟合在真实函数有曲率的区域存在偏差——这一现象称为「削峰填谷 (trimming the hills and filling the valleys)」：线性拟合倾向于低估峰值、高估谷底。局部二次回归通常能够校正这种曲率偏差（图 6.5）。




FIGURE 6.5. Local linear fits exhibit bias in regions of curvature of the true function. Local quadratic fits tend to eliminate this bias.

图 14.3: 局部线性拟合在真实函数曲率区域表现出偏差。局部二次拟合倾向于消除此偏差。左面板中红色曲线（局部线性）在曲率处偏离绿色真实曲线，右面板中局部二次拟合更好地追踪了曲率。

14.3.3 偏差-方差权衡

偏差降低的代价是方差增大。假设模型 $y_i = f(x_i) + \varepsilon_i$, $\varepsilon_i \sim \text{i.i.d.}(0, \sigma^2)$, 则

$$\text{Var}(\hat{f}(x_0)) = \sigma^2 \|\mathbf{l}(x_0)\|^2 \quad (14.11)$$

其中 $\mathbf{l}(x_0)$ 是等价核权重向量。可证 $\|\mathbf{l}(x_0)\|^2$ 随 d 增加而增大（习题 6.3），因此存在偏差-方差权衡。

图 6.6 展示了局部常数、线性、二次回归的方差函数曲线。

14.3.4 奇数阶 vs 偶数阶：实践建议

- 局部线性拟合 ($d = 1$) 能以适度的方差代价在边界处大幅降低偏差；局部二次拟合 ($d = 2$) 在边界处对偏差改善不大，但方差增加很多。
- 局部二次拟合最有助于减少定义域内部的曲率偏差。

- 渐近分析表明，奇数阶局部多项式优于偶数阶——这主要是因为渐近 MSE 由边界效应主导。

通常由应用场景决定拟合阶数：若关注外推，则边界更重要，局部线性拟合更可靠。不推荐在不同区域使用不同阶数的策略。

14.4 核宽度的选择

14.4.1 λ 在不同核中的含义

- Epanechnikov 或 tri-cube 核（固定宽度）： λ 是支撑区域的半径。
- Gaussian 核： λ 是标准差。
- k -最近邻： λ 是近邻数 k ，通常表示为总训练样本的比例（span） k/N 。

14.4.2 偏差-方差权衡与窗宽

改变平均窗宽时存在自然的偏差-方差权衡，以局部平均为例最为直观：

- **窄窗：** $\hat{f}(x_0)$ 仅对 x_0 附近少数 y_i 做平均，方差较大（接近单个 y_i 的方差）；偏差较小——因为每个 $\mathbb{E}(y_i) = f(x_i)$ 都接近 $f(x_0)$ 。
- **宽窗：** $\hat{f}(x_0)$ 的方差因平均效应而较小；偏差较大——使用了远离 x_0 的 x_i ，无法保证 $f(x_i)$ 接近 $f(x_0)$ 。

对局部回归估计（如局部线性）类似：窗宽趋于零时，估计趋近于插值训练数据的分段线性函数；窗宽趋于无穷时，拟合趋近于全局线性最小二乘拟合。

14.4.3 线性估计量与光滑矩阵

局部回归光滑器是线性估计量： $\hat{\mathbf{f}} = \mathbf{S}_\lambda \mathbf{y}$ 。光滑矩阵 $\mathbf{S}_\lambda$ 由等价核构建，其第 ij 个元素为 $\{\mathbf{S}_\lambda\}_{ij} = l_i(x_j)$ 。

为什么称 $\mathbf{S}_\lambda$ 为「光滑」算子？核 K_λ 去哪了？

核 K_λ 并没有消失——它被「吸收」进了 $\mathbf{S}_\lambda$ 。从局部线性回归的矩阵形式

$$\hat{f}(x_0) = \mathbf{b}(x_0)^T (\mathbf{B}^T \mathbf{W}(x_0) \mathbf{B})^{-1} \mathbf{B}^T \mathbf{W}(x_0) \mathbf{y}$$

可以看到，核权重通过 $\mathbf{W}(x_0)$ （对角元为 $K_\lambda(x_0, x_i)$ ）进入计算，再经过最小二乘的代数运算，最终凝练为等价核权重 $l_i(x_0)$ 。 $\mathbf{S}_\lambda$ 的第 j 列正是对所有 x_j 的等价核在这些训练点上的取值排列。

称 $\mathbf{S}_\lambda$ 为「光滑矩阵」(smoother matrix) 是因为: (1) 从效果上看, $\hat{\mathbf{f}} = \mathbf{S}_\lambda \mathbf{y}$ 确实在光滑原始响应 y_i ——把带噪声的点云变成一条平滑曲线; (2) 这一写法是统一的框架——不仅核光滑器, 光滑样条、回归样条等所有线性光滑方法都可以写成 $\hat{\mathbf{f}} = \mathbf{S}_\lambda \mathbf{y}$ 的形式, 便于用统一语言讨论自由度、交叉验证等概念。核的作用在构造 $\mathbf{S}_\lambda$ 的阶段已经完成, 后续分析直接使用 $\mathbf{S}_\lambda$ 即可。

交叉验证 (CV) 在局部回归中的具体做法

因为 $\hat{\mathbf{f}} = \mathbf{S}_\lambda \mathbf{y}$ 是线性估计量, 交叉验证有非常简洁的计算公式, 无需反复重新拟合。

留一交叉验证 (LOOCV)。记 $\hat{f}^{(-i)}(x_i)$ 为去掉第 i 个观测后模型在 x_i 处的预测。LOOCV 准则为

$$\text{CV}(\lambda) = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{f}^{(-i)}(x_i))^2$$

由于 $\hat{f}^{(-i)}(x_i)$ 可写为 $\hat{f}^{(-i)}(x_i) = \sum_{j \neq i} \frac{S_{ij}}{1 - S_{ii}} y_j$ (习题 6.7), 经过代数推导得到捷径公式:

$$\text{CV}(\lambda) = \frac{1}{N} \sum_{i=1}^N \left[\frac{y_i - \hat{f}(x_i)}{1 - S_{ii}} \right]^2 \quad (14.12)$$

这意味着只需拟合一次全模型得到 $\hat{\mathbf{f}}$ 和 S_{ii} ($\mathbf{S}_\lambda$ 的对角元), 即可计算 LOOCV——极大地节省了计算量。

广义交叉验证 (GCV)。GCV 将 S_{ii} 替换为其平均值 $\frac{1}{N} \sum_i S_{ii} = \frac{\text{tr}(\mathbf{S}_\lambda)}{N} = \frac{\text{df}_\lambda}{N}$:

$$\text{GCV}(\lambda) = \frac{1}{N} \sum_{i=1}^N \left[\frac{y_i - \hat{f}(x_i)}{1 - \text{tr}(\mathbf{S}_\lambda)/N} \right]^2 = \frac{\text{RSS}/N}{(1 - \text{df}_\lambda/N)^2} \quad (14.13)$$

GCV 的优势在于: (1) 不需要逐个计算 S_{ii} , 只需 $\text{tr}(\mathbf{S}_\lambda)$; (2) 具有某些不变性 (如在正交变换下不变); (3) 在许多情况下与 LOOCV 表现接近。

k -折交叉验证。将数据随机分为 k 个大小相近的折, 每次留一折作为验证集, 其余 $k-1$ 折训练。计算量比 LOOCV 小 (只需 k 次拟合), 但无法使用上述捷径公式。实践中 $k=5$ 或 $k=10$ 较为常用。

选择 λ 时, 在 λ 的候选网格上计算 CV/GCV 得分, 选择使得分最小的 λ 。这一过程对局部平均和局部回归均适用。

14.4.4 有效自由度

有效自由度定义为 $\text{df}_\lambda = \text{tr}(\mathbf{S}_\lambda)$, 可用于校准光滑量。

14.5 $\mathbb{R}^p$ 中的局部回归

核光滑和局部回归可以非常自然地推广到二维及以上。Nadaraya-Watson 核光滑器使用 p 维核提供的权重在局部拟合常数; 局部线性回归则通过加权最小二乘在 X 空间中局部拟合超平面, 实现简单且边界性能优于局部常数拟合。




FIGURE 6.7. *Equivalent kernels for a local linear regression smoother (tri-cube kernel; orange) and a smoothing spline (blue), with matching degrees of freedom. The vertical spikes indicates the target points.*

图 14.4: 局部线性回归光滑器 (tri-cube 核, 橙色) 与光滑样条 (蓝色) 的等价核, 两者具有匹配的自由度。竖直尖刺标示目标点。局部回归光滑器的 span 为 40%, 对应 $df = \text{tr}(\mathbf{S}_\lambda) = 5.86$; 光滑样条被校准到相同 df, 两者的等价核定性上高度相似。

14.5.1 多项式向量与径向核

设 $\mathbf{b}(X)$ 为 X 中最大次数为 d 的多项式项向量。例如:

- $d = 1, p = 2$: $\mathbf{b}(X) = (1, X_1, X_2)$;
- $d = 2, p = 2$: $\mathbf{b}(X) = (1, X_1, X_2, X_1^2, X_2^2, X_1X_2)$;
- $d = 0$: $\mathbf{b}(X) = 1$ (退化为局部常数)。

在每个 $x_0 \in \mathbb{R}^p$ 处求解

$$\min_{\beta(x_0)} \sum_{i=1}^N K_\lambda(x_0, x_i) (y_i - \mathbf{b}(x_i)^T \beta(x_0))^2 \quad (14.14)$$

得到拟合 $\hat{f}(x_0) = \mathbf{b}(x_0)^T \hat{\beta}(x_0)$ 。

核通常采用径向函数, 如径向 Epanechnikov 或 tri-cube 核:

$$K_\lambda(x_0, x) = D \left(\frac{\|x - x_0\|}{\lambda} \right) \quad (14.15)$$

其中 $\|\cdot\|$ 为欧氏距离。由于欧氏距离依赖于各坐标的单位, 最合理的做法是先在平滑前将每个预测变量标准化 (如标准化到单位标准差)。

14.5.2 高维中的边界问题与维数灾难

边界效应在一维平滑中是一个问题, 但在二维或更高维中更为严重——边界上点的比例更大。事实上, 维数灾难的一个表现就是: 随着维数增长, 靠近边界的点的比例趋

近于 1。直接修改核以适应二维边界非常繁琐（尤其对于不规则边界），而局部多项式回归能在任意维度下无缝地完成所需阶数的边界校正。

然而，局部回归在维数远高于 2 或 3 时变得不太有用。第 2 章已详细讨论过维数问题：随着维数增加，不可能同时保持局部性（低偏差）和邻域内有足够的样本量（低方差），除非总样本量随 p 指数增长。此外， $\hat{f}(X)$ 的可视化在高维也变得困难——而这往往是平滑的主要目标之一。从数据分析的角度看，条件图（conditional plots）远比散点云和线框图更有用（图 6.9 的 trellis 展示）。

14.6 $\mathbb{R}^p$ 中的结构化局部回归模型

当维数与样本量之比不利时，局部回归的帮助有限——除非我们愿意对模型施加一些结构性假设。

14.6.1 结构化核

一种思路是修改核函数。默认的球形核（式 14.15）对各坐标赋予等权重，因此自然的默认策略是将每个变量标准化到单位标准差。更一般的方法是用一个半正定矩阵 $\mathbf{A}$ 对不同坐标加权：

$$K_{\lambda, \mathbf{A}}(x_0, x) = D \left(\frac{(x - x_0)^T \mathbf{A} (x - x_0)}{\lambda} \right) \quad (14.16)$$

通过对 $\mathbf{A}$ 施加适当的限制，可以降权或忽略某些坐标或方向。例如，若 $\mathbf{A}$ 为对角阵，则可以增大或减小单个预测变量 X_j 的影响。当预测变量多且高度相关时（如来自数字化模拟信号或图像），可利用预测变量的协方差函数来定制度量 $\mathbf{A}$ ，使对高频对比的关注减少。也有方法尝试学习多维核的参数（如第 11 章中的投影寻踪回归）。

14.6.2 结构化回归函数

我们试图在 $\mathbb{R}^p$ 中拟合 $f(X_1, X_2, \dots, X_p)$ ，其中可能存在各种交互。自然的思路是考虑方差分析（ANOVA）分解：

$$f(X_1, \dots, X_p) = \alpha + \sum_j g_j(X_j) + \sum_{k < \ell} g_{k\ell}(X_k, X_\ell) + \dots \quad (14.17)$$

然后通过去掉某些高阶项来引入结构。

可加模型仅保留主效应项： $f(X) = \alpha + \sum_{j=1}^p g_j(X_j)$ 。二阶模型最多包含二阶交互项，以此类推。第 9 章描述了用于拟合此类低阶交互模型的**迭代 backfitting 算法**。以可加模型为例：若假设除第 k 项外所有项已知，则可通过 $Y - \sum_{j \neq k} g_j(X_j)$ 对 X_k 的局部回归来估计 g_k ；轮流对每个函数重复此操作直至收敛。关键细节是：在任何阶段都只需一维局部回归。

14.6.3 变系数模型

结构化模型的一个重要特例是变系数模型 (varying coefficient models)。将 p 个预测变量划分为集合 $(X_1, \dots, X_q)$ ($q < p$) 和 Z , 假设条件线性模型:

$$f(X) = \alpha(Z) + \beta_1(Z)X_1 + \dots + \beta_q(Z)X_q \quad (14.18)$$

对给定的 Z , 这是线性模型, 但每个系数可随 Z 变化。自然地通过局部加权最小二乘拟合:

$$\min_{\alpha(z_0), \beta(z_0)} \sum_{i=1}^N K_\lambda(z_0, z_i) (y_i - \alpha(z_0) - x_{1i}\beta_1(z_0) - \dots - x_{qi}\beta_q(z_0))^2 \quad (14.19)$$

图 6.10–6.11 以人体主动脉数据为例: 将主动脉直径建模为年龄的线性函数, 但允许系数随性别和沿主动脉的深度变化。

14.7 局部似然与其他模型

局部回归和变系数模型的概念非常广泛: 只要拟合方法支持观测权重, 任何参数模型都可以「局部化」。

14.7.1 局部似然

设每个观测 y_i 关联一个参数 $\theta_i = \theta(x_i) = x_i^T \beta$, 基于对数似然 $l(\beta) = \sum_i l(y_i, x_i^T \beta)$ 对 β 做推断。通过使用 x_0 处的局部似然, 可以对 $\theta(x_0) = x_0^T \beta(x_0)$ 做更灵活的推断:

$$l(\beta(x_0)) = \sum_{i=1}^N K_\lambda(x_0, x_i) l(y_i, x_i^T \beta(x_0)) \quad (14.20)$$

许多似然模型——特别是广义线性模型家族 (包括 logistic 和对数线性模型) ——以线性方式引入协变量。局部似然允许从全局线性模型松弛到局部线性模型。

进一步, 定义 θ 的变量和用于定义局部似然的变量可以不同:

$$l(\theta(z_0)) = \sum_{i=1}^N K_\lambda(z_0, z_i) l(y_i, \eta(x_i, \theta(z_0))) \quad (14.21)$$

例如 $\eta(x, \theta) = x^T \theta$ 是 x 中的线性模型——这将通过最大化局部似然来拟合变系数模型 $\theta(z)$ 。

14.7.2 局部自回归时间序列

k 阶自回归模型 $y_t = \beta_0 + \beta_1 y_{t-1} + \dots + \beta_k y_{t-k} + \varepsilon_t$ 。记滞后集 $z_t = (y_{t-1}, \dots, y_{t-k})$, 模型形如标准线性模型 $y_t = z_t^T \beta + \varepsilon_t$ 。使用核 $K(z_0, z_t)$ 做局部最小二乘拟合, 使模型可随序列的短期历史变化——这有别于按时间加窗的传统动态线性模型。

14.7.3 局部多类 Logistic 回归

以第 4 章的多类线性 logistic 回归模型为例。数据包含特征 x_i 和类别响应 $g_i \in \{1, \dots, J\}$, 线性模型为

$$\Pr(G = j \mid X = x) = \frac{e^{\beta_{j0} + \beta_j^T x}}{1 + \sum_{k=1}^{J-1} e^{\beta_{k0} + \beta_k^T x}} \quad (14.22)$$

其局部对数似然可写为 ($\beta_{j0} = 0, \beta_J = 0$, 且局部回归在 x_0 处做了中心化):

$$\sum_{i=1}^N K_\lambda(x_0, x_i) \left\{ \beta_{g_i 0}(x_0) + \beta_{g_i}(x_0)^T (x_i - x_0) - \log \left[1 + \sum_{k=1}^{J-1} \exp(\beta_{k0}(x_0) + \beta_k(x_0)^T (x_i - x_0)) \right] \right\} \quad (14.23)$$

中心化后, x_0 处的拟合后验概率简化为

$$\widehat{\Pr}(G = j \mid X = x_0) = \frac{e^{\hat{\beta}_{j0}(x_0)}}{1 + \sum_{k=1}^{J-1} e^{\hat{\beta}_{k0}(x_0)}} \quad (14.24)$$

图 6.12 展示了用局部线性 logistic 模型对心脏病数据的两个风险因子分别拟合的结果——这是一种检测非线性的有用筛查工具。由于 CHD 是二值指标, 也可以直接对二值响应做平滑来估计条件概率 (相当于局部常数 logistic 回归, 习题 6.5); 但为了享受局部线性平滑的偏差校正, 在无约束的 logit 尺度上操作更为自然。此外, 局部 logistic 回归同样可以计算参数估计及其标准误, 从而得到逐点标准误带。

14.8 核密度估计与分类

核密度估计是一种无监督学习过程, 历史早于核回归。它也自然地引出一类简单的非参数分类方法。

14.8.1 核密度估计

假设有来自概率密度 $f_X(x)$ 的随机样本 $x_1, \dots, x_N$, 欲在点 x_0 处估计 f_X 。类似之前的论证, 自然的局部估计为

$$\hat{f}_X(x_0) = \frac{\#\{x_i \in N(x_0)\}}{N\lambda} \quad (14.25)$$

其中 $N(x_0)$ 是 x_0 周围宽度为 λ 的小邻域。此估计是颠簸的, 更光滑的 **Parzen** 估计被优先采用:

$$\hat{f}_X(x_0) = \frac{1}{N\lambda} \sum_{i=1}^N K_\lambda(x_0, x_i) \quad (14.26)$$

即每个点 x_0 处的密度估计是各核在该点的平均贡献。

若取 K_λ 为 Gaussian 核 ϕ_λ (均值为零、标准差为 λ)，则 Parzen 估计可写为卷积形式：

$$\hat{f}_X(x) = \frac{1}{N} \sum_{i=1}^N \phi_\lambda(x - x_i) = (\hat{F} \star \phi_\lambda)(x) \quad (14.27)$$

其中 $\hat{F}$ 是经验分布 (在每个观测 x_i 处放置质量 $1/N$)。这意味着核密度估计本质上是对颠簸的经验分布 $\hat{F}$ 用 ϕ_λ 做了光滑——等价于给每个 x_i 加上独立 Gaussian 噪声。

在 $\mathbb{R}^p$ 中，Gaussian 密度估计的自然推广是使用 Gaussian 乘积核：

$$\hat{f}_X(x_0) = \frac{1}{N(2\lambda^2\pi)^{p/2}} \sum_{i=1}^N e^{-\frac{1}{2}(\|x_i - x_0\|/\lambda)^2} \quad (14.28)$$

14.8.2 核密度分类

利用 Bayes 定理，可以直接用各类别的非参数密度估计来做分类。对 J 类问题，分别在每个类中拟合密度估计 $\hat{f}_j(X)$ ，并估计类先验 $\hat{\pi}_j$ (通常取样本比例)，则

$$\widehat{\Pr}(G = j \mid X = x_0) = \frac{\hat{\pi}_j \hat{f}_j(x_0)}{\sum_{k=1}^J \hat{\pi}_k \hat{f}_k(x_0)} \quad (14.29)$$

图 6.14 用此方法估计了心脏病的 CHD 概率，与局部 logistic 回归 (图 6.12) 相比，主要差异出现在高 SBP 区域——那里数据稀疏，Gaussian 核密度估计 (使用固定宽度核) 质量差、方差大。而局部 logistic 回归使用的 tri-cube 核配合 k -NN 窗宽在稀疏区域自动展宽了核，并利用局部线性假设 (在 logit 尺度上) 平滑了估计。

一个重要的洞察 (图 6.15)：如果最终目标是分类，则没有必要把各类密度本身估计得很好——事实上这样做可能具有误导性。图 6.15 展示了两类密度都是多峰的，但后验比值相当光滑。学习各类密度时，为了捕捉这些多峰结构可能采用较粗糙的高方差拟合，而这些特征对估计后验概率而言是**无关的**。实际上，若目标仅为分类，只需在**决策边界附近**把后验估计好即可 (对于二分类，即集合 $\{x \mid \Pr(G = 1 \mid X = x) = \frac{1}{2}\}$)。

14.8.3 朴素 Bayes 分类器

朴素 Bayes 分类器尽管名字朴素，却历久不衰。当特征空间维数 p 很高、密度估计不可行时尤其适用。其核心假设是：**给定类别 $G = j$ ，各特征 X_k 相互独立**：

$$f_j(X) = \prod_{k=1}^p f_{jk}(X_k) \quad (14.30)$$

虽然这个假设一般不成立，但它极大地简化了估计：

- 每个类条件边缘密度 f_{jk} 可以分别用**一维核密度估计**来拟合——这实际上是对原始朴素 Bayes (使用单变量 Gaussian 表示边缘密度) 的推广。

- 若某分量 X_j 是离散的，可使用直方图估计——这提供了一种在特征向量中无缝混合不同变量类型的方法。

尽管假设如此「天真」，朴素 Bayes 分类器的表现往往优于远更复杂的方法。原因与图 6.15 相关：虽然各类密度估计可能有偏，但偏差未必损害后验概率——尤其在决策区域附近。问题可能能够承受可观的偏差，以换取「朴素」假设带来的方差节省。

从式 (14.30) 可以推导 logit 变换（以第 J 类为基准）：

$$\begin{aligned} \log \frac{\Pr(G = \ell | X)}{\Pr(G = J | X)} &= \log \frac{\pi_\ell \prod_{k=1}^p f_{\ell k}(X_k)}{\pi_J \prod_{k=1}^p f_{Jk}(X_k)} \\ &= \log \frac{\pi_\ell}{\pi_J} + \sum_{k=1}^p \log \frac{f_{\ell k}(X_k)}{f_{Jk}(X_k)} = \alpha_\ell + \sum_{k=1}^p g_{\ell k}(X_k) \end{aligned} \quad (14.31)$$

这恰好具有广义可加模型（GAM）的形式（第 9 章详述），尽管拟合方式截然不同。朴素 Bayes 与 GAM 的关系，类似于线性判别分析与 logistic 回归的关系。

14.9 径向基函数与核

第 5 章将函数表示为基展开 $f(x) = \sum_j \beta_j h_j(x)$ 。基展开的灵活性取决于选择合适的基函数族并控制复杂度。有些基函数族是局部定义的（如 B-样条在 $\mathbb{R}$ 中局部）；张量积将其推广到 $\mathbb{R}^p$ 中的局部基。但并非所有基函数都是局部的——例如样条的截断幂基，或神经网络中的 sigmoid 基函数 $\sigma(\alpha_0 + \alpha^T x)$ 。

核方法通过在目标点 x_0 附近拟合简单模型来获得灵活性，局部化通过加权核 K_λ 实现。径向基函数（RBF）将这两种思想融合——将核函数 $K_\lambda(\xi, x)$ 本身作为基函数：

$$f(x) = \sum_{j=1}^M K_{\lambda_j}(\xi_j, x) \beta_j = \sum_{j=1}^M D\left(\frac{\|x - \xi_j\|}{\lambda_j}\right) \beta_j \quad (14.32)$$

每个基元素由位置（原型）参数 ξ_j 和尺度参数 λ_j 索引。常用 D 为标准 Gaussian 密度。

参数学习方法（以 Gaussian 核最小二乘回归为例）：

1. 联合优化所有参数（RBF 网络）：

$$\min_{\{\lambda_j, \xi_j, \beta_j\}_1^M} \sum_{i=1}^N \left[y_i - \beta_0 - \sum_{j=1}^M \beta_j \exp\left(-\frac{(x_i - \xi_j)^T(x_i - \xi_j)}{\lambda_j^2}\right) \right]^2 \quad (14.33)$$

该准则非凸、有多个局部极小值，优化算法类似神经网络训练。 ξ_j 和 λ_j 扮演类似神经网络中权重的角色。

2. 分离估计 $\{\lambda_j, \xi_j\}$ 与 β_j ：先确定核参数，再用最小二乘求 β_j 。核参数通常以无监督方式仅基于 X 分布确定——常用方法是对训练 x_i 拟合 Gaussian 混合密度模型来获得中心 ξ_j 和尺度 λ_j ；更简单的方法是用聚类定位原型 ξ_j ，取 $\lambda_j = \lambda$ 为超参数。这种方法显然忽略了条件分布 $\Pr(Y | X)$ 的信息，但实现简单得多。

空洞问题与重归一化 RBF。若所有 $\lambda_j = \lambda$ 取常数值，可能导致空洞—— $\mathbb{R}^p$ 中某些区域没有任何核具有显著支撑（图 6.16 上）。重归一化径向基函数可以避免此问题：

$$h_j(x) = \frac{D(\|x - \xi_j\|/\lambda)}{\sum_{k=1}^M D(\|x - \xi_k\|/\lambda)} \quad (14.34)$$

Nadaraya–Watson 作为 RBF 展开。 $\mathbb{R}^p$ 中的 NW 核回归估计量可以视为重归一化 RBF 展开：

$$\hat{f}(x_0) = \sum_{i=1}^N y_i \frac{K_\lambda(x_0, x_i)}{\sum_{i=1}^N K_\lambda(x_0, x_i)} = \sum_{i=1}^N y_i h_i(x_0) \quad (14.35)$$

每个观测点 x_i 处放置一个基函数 h_i ，系数为 y_i ：即 $\xi_i = x_i$, $\hat{\beta}_i = y_i$, $i = 1, \dots, N$ 。

注意式 (14.35) 与第 5 章由核 K 诱导的正则化问题的解（式 5.50）之间的相似性。径向基函数构成了现代「核方法」与局部拟合技术之间的桥梁。

14.10 混合模型用于密度估计与分类

混合模型是密度估计的有用工具，可视为一种核方法。Gaussian 混合模型的形式为

$$f(x) = \sum_{m=1}^M \alpha_m \phi(x; \mu_m, \Sigma_m) \quad (14.36)$$

其中 $\sum \alpha_m = 1$ 。参数通常通过 EM 算法（第 8 章）做最大似然估计。

一些特例：

- 若协方差阵约束为标量阵 $\Sigma_m = \sigma_m I$ ，则式 (14.36) 具有径向基展开的形式。
- 若进一步 $\sigma_m = \sigma > 0$ 固定，且 $M \uparrow N$ ，则最大似然估计趋近于核密度估计 (14.26)，其中 $\hat{\alpha}_m = 1/N$, $\hat{\mu}_m = x_m$ 。

利用 Bayes 定理，各类别分别拟合混合密度可得到灵活的 $\Pr(G | X)$ 模型（第 12 章详述）。图 6.17 以心脏病风险研究中的年龄变量为例：在不使用 CHD 标签的情况下，用双分量 Gaussian 混合模型拟合年龄数据，结果自动发现的两个分量与 CHD / 非 CHD 两组有较好的对应（分类误差率 32%，与线性 logistic 回归相当）。

14.11 计算考量

核方法与局部回归是**基于记忆**的方法：模型就是整个训练数据集，拟合在评估或预测时进行。对许多实时应用来说，这可能使此类方法不可行。

- 在单个 x_0 处拟合的计算代价为 $O(N)$ ，除非是过度简化的情况（如方形核）。
- 相比之下， M 个基函数的展开每次评估仅需 $O(M)$ ，且通常 $M \sim O(\log N)$ 。基函数方法的初始代价至少为 $O(NM^2 + M^3)$ 。

- 核方法的光滑参数 λ 通常离线确定（如交叉验证），代价 $O(N^2)$ 。

主流局部回归实现（如 S-PLUS/R 的 `loess` 和 `locfit`）使用三角剖分方案来减少计算量：在 M 个精心选择的位置精确计算拟合（ $O(NM)$ ），然后用混合技术在其他位置插值（每次评估 $O(M)$ ）。

第十五章 模型评估与选择

15.1 引言

学习方法的泛化性能 (generalization performance) 涉及其在独立测试数据上的预测能力。在实践中, 评估这一性能极为重要——它指导学习方法或模型的选择, 并给出最终所选模型质量的度量。

本章描述并展示性能评估的关键方法, 以及如何利用它们进行模型选择。我们从偏差、方差和模型复杂度之间的交互关系开始讨论。

15.2 偏差、方差与模型复杂度

15.2.1 定量响应情形

对定量 (区间尺度) 响应 Y , 给定输入向量 X 和由训练集 $\mathcal{T}$ 估计的预测模型 $\hat{f}(X)$ 。损失函数 $L(Y, \hat{f}(X))$ 衡量预测误差, 常见选择为:

- 平方误差: $L(Y, \hat{f}(X)) = (Y - \hat{f}(X))^2$
- 绝对误差: $L(Y, \hat{f}(X)) = |Y - \hat{f}(X)|$

测试误差 (test error), 也称泛化误差, 是在独立测试样本上的预测误差:

$$\text{Err}_{\mathcal{T}} = \mathbb{E}_{X^0, Y^0} [L(Y^0, \hat{f}(X^0)) \mid \mathcal{T}] \quad (15.1)$$

其中 (X^0, Y^0) 是从联合分布 (总体) 中随机抽取的。训练集 $\mathcal{T}$ 固定, 测试误差指该特定训练集的误差。

$\text{Err}_{\mathcal{T}}$ 中的 (X^0, Y^0) 是从测试集中抽的吗?

不是。 (X^0, Y^0) 并非从某个实际的「测试集」中抽取, 而是从数据的联合分布 (总体) F 中随机抽取的。 $\mathbb{E}_{X^0, Y^0}$ 是对总体的积分, 而非对有限测试样本的平均。

区别在于: 理论上 $\text{Err}_{\mathcal{T}}$ 对所有可能的未来数据点取期望, 衡量模型在整个分布上的表现; 实践中我们只有一个有限的测试集, 用其上的平均损失 $\frac{1}{M} \sum_{j=1}^M L(y_j^0, \hat{f}(x_j^0))$ 来




FIGURE 7.1. Behavior of test sample and training sample error as the model complexity is varied. The light blue curves show the training error $\overline{\text{err}}$, while the light red curves show the conditional test error $\text{Err}_{\mathcal{T}}$ for 100 training sets of size 50 each, as the model complexity is increased. The solid curves show the expected test error Err and the expected training error $\mathbb{E}[\overline{\text{err}}]$.

图 15.1: 测试误差和训练误差随模型复杂度变化的行为。浅蓝色曲线为训练误差 $\overline{\text{err}}$, 浅红色曲线为 100 个大小为 50 的训练集各自的条件测试误差 $\text{Err}_{\mathcal{T}}$, 随模型复杂度增加而变化。实线为期望测试误差 Err 和期望训练误差 $\mathbb{E}[\overline{\text{err}}]$ 。

估计 $\text{Err}_{\mathcal{T}}$ 。这就是 $\text{Err}_{\mathcal{T}}$ 被称为「额外样本误差 (extra-sample error)」的原因——测试输入向量不需要与训练输入向量重合。

与此相关的量是**期望预测误差 (expected prediction error)**：

$$\text{Err} = \mathbb{E}[L(Y^0, \hat{f}(X^0))] = \mathbb{E}[\text{Err}_{\mathcal{T}}] \quad (15.2)$$

该期望对一切随机因素取平均，包括产生 $\hat{f}$ 的训练集的随机性。

图 7.1 展示了 100 个大小为 50 的模拟训练集的预测误差曲线（浅红色），以及其平均（实红色，估计 Err ）。Lasso（第 3.4.2 节）用于产生拟合序列。

如何区分不同训练集训练出的模型？

$\hat{f}$ 依赖于训练集 $\mathcal{T}$ ，不同的 $\mathcal{T}$ 会拟合出不同的 $\hat{f}$ 。 $\text{Err}_{\mathcal{T}}$ 的下标 $\mathcal{T}$ 明确表示在**该特定训练集**上训练出的模型的测试误差。在图 7.1 中，100 条浅红色曲线各对应一个不同的 $\mathcal{T}$ ，框架本身不需要额外的区分机制—— $\mathcal{T}$ 的随机性已经刻画了这种差异。简言之： $\text{Err}_{\mathcal{T}}$ 把 $\mathcal{T}$ 视为条件（固定）， Err 把 $\mathcal{T}$ 视为随机变量（对其积分）。

期望预测误差和测试误差的区别

两个概念的区别在于**对什么取平均**：两者都对 (X^0, Y^0) 在总体上积分，但 $\text{Err}_{\mathcal{T}}$ 固定训练集 $\mathcal{T}$ （是随机变量，取决于抽到哪份数据），而 $\text{Err} = \mathbb{E}_{\mathcal{T}}[\text{Err}_{\mathcal{T}}]$ 进一步对训练集取平均（是固定数，属于学习方法本身的属性）。

类比： $\text{Err}_{\mathcal{T}}$ 像某个人的身高（取决于挑中谁）， Err 像人群平均身高（固定参数）。ESL 更关注 Err ，因为它具有更好的统计可操作性——大多数方法（ C_p 、AIC、交叉验证等）实际估计的都是 Err 而非 $\text{Err}_{\mathcal{T}}$ 。

训练误差 (training error) 是训练样本上的平均损失：

$$\overline{\text{err}} = \frac{1}{N} \sum_{i=1}^N L(y_i, \hat{f}(x_i)) \quad (15.3)$$

$\overline{\text{err}}$ 、 $\text{Err}_{\mathcal{T}}$ 、 Err 三者的关系

三个量构成一条从「可算」到「不可算」的链条：

$$\overline{\text{err}} \leq \text{Err}_{\mathcal{T}} \approx \text{Err} \quad (15.4)$$

- Err 是最终目标——它回答「这个学习方法从总体中反复抽样训练，平均表现如何」，是方法本身的属性，不依赖于某一份运气好坏的训练集。
- $\text{Err}_{\mathcal{T}}$ 是「用手里这份 $\mathcal{T}$ 训练出的那个模型」在全体未来数据上的期望误差。它仍是对总体积分，但训练集固定，故 $\text{Err} = \mathbb{E}_{\mathcal{T}}[\text{Err}_{\mathcal{T}}]$ 。实践中我们只有一份 $\mathcal{T}$ ，只能接触到 $\text{Err}_{\mathcal{T}}$ ，但**算不出来**（需要对总体积分）。

- $\overline{\text{err}}$ 是唯一能直接算的量，但它是 $\text{Err}_{\mathcal{T}}$ 的系统性偏低估计——同一批数据既拟合又评估，模型会「记忆」训练数据。

本章所有方法（ C_p 、AIC、交叉验证、Bootstrap）本质上都是在 $\overline{\text{err}}$ 上加一个乐观性修正项 $\hat{\omega}$ ，使其逼近 Err （或 $\text{Err}_{\mathcal{T}}$ ）：

$$\widehat{\text{Err}} = \overline{\text{err}} + \hat{\omega} \quad (15.5)$$

随着模型越来越复杂，它更好地利用训练数据并适应更复杂的底层结构，因此偏差减小但方差增大。存在某个中间模型复杂度使期望测试误差达到最小。

注记 15.1. 训练误差不是测试误差的良好估计（如图 7.1 所示）。训练误差随模型复杂度单调递减，若模型足够复杂甚至可以降至零。然而，训练误差为零的模型是对训练数据过拟合的，通常泛化能力很差。

15.2.2 定性响应情形

对于取 $\mathcal{G}$ 中 K 个值之一的定性（分类）响应 G ，通常对概率 $p_k(X) = \Pr(G = k | X)$ 建模，然后 $\hat{G}(X) = \arg \max_k \hat{p}_k(X)$ 。常见损失函数为：

- 0-1 损失： $L(G, \hat{G}(X)) = I(G \neq \hat{G}(X))$
- 偏差（deviance）：

$$L(G, \hat{p}(X)) = -2 \sum_{k=1}^K I(G = k) \log \hat{p}_k(X) = -2 \log \hat{p}_G(X) \quad (15.6)$$

量 $-2 \times$ 对数似然也称为偏差。

测试误差 $\text{Err}_{\mathcal{T}}$ 是分类器在总体上的误分类误差， Err 是期望误分类误差。训练误差为样本类似量，例如：

$$\overline{\text{err}} = -\frac{2}{N} \sum_{i=1}^N \log \hat{p}_{g_i}(x_i) \quad (15.7)$$

即模型的样本对数似然。

注记 15.2. 「 -2 」使得高斯分布下的对数似然损失与平方误差损失一致。为叙述方便，本章后续以定量响应（平方误差损失）为主，其他情形的适当变换是显然的。

15.2.3 模型选择 vs 模型评估

本章的方法通常涉及调节参数 α ，预测记为 $\hat{f}_{\alpha}(x)$ 。调节参数改变模型复杂度，我们希望找到使误差最小的 α 。

需要区分两个目标：

- **模型选择 (Model selection)**: 估计不同模型的性能以选择最佳模型。
- **模型评估 (Model assessment)**: 选定最终模型后, 估计其在新数据上的预测误差 (泛化误差)。

在数据充足的情况下, 最佳做法是随机将数据分为三部分:

- **训练集 (training set)**: 用于拟合模型;
- **验证集 (validation set)**: 用于估计预测误差以进行模型选择;
- **测试集 (test set)**: 用于评估最终所选模型的泛化误差。

注记 15.3. 理想情况下, 测试集应被「锁在保险柜里」, 仅在数据分析的最后阶段取出。若反复使用测试集——选择测试集误差最小的模型——则最终所选模型的测试集误差将低估真实测试误差, 有时低得相当严重。

本章的方法通过**解析近似** (AIC、BIC、MDL、SRM) 或**高效的样本重复利用** (交叉验证和自助法) 来近似验证步骤。

15.3 偏差-方差分解

与第 2 章一样, 假设 $Y = f(X) + \varepsilon$, 其中 $\mathbb{E}(\varepsilon) = 0$, $\text{Var}(\varepsilon) = \sigma_\varepsilon^2$ 。对回归拟合 $\hat{f}(X)$ 在输入点 $X = x_0$ 处的期望预测误差 (使用平方误差损失), 有如下分解:

$$\begin{aligned} \text{Err}(x_0) &= \mathbb{E}[(Y - \hat{f}(x_0))^2 \mid X = x_0] \\ &= \sigma_\varepsilon^2 + [\mathbb{E}\hat{f}(x_0) - f(x_0)]^2 + \mathbb{E}[\hat{f}(x_0) - \mathbb{E}\hat{f}(x_0)]^2 \\ &= \sigma_\varepsilon^2 + \text{Bias}^2(\hat{f}(x_0)) + \text{Var}(\hat{f}(x_0)) \\ &= \text{不可约误差} + \text{偏差}^2 + \text{方差}. \end{aligned} \quad (15.8)$$

第一项是目标值围绕其真实均值 $f(x_0)$ 的方差, 无论 $\hat{f}$ 多好都无法避免 (除非 $\sigma_\varepsilon^2 = 0$)。第二项是**平方偏差**——估计的均值与真实均值之差; 第三项是**方差**——估计围绕其均值的期望平方偏差。

注记 15.4. 通常模型越复杂, 平方偏差越低但方差越高。

15.3.1 k -最近邻回归的偏差-方差分解

对 k -最近邻回归拟合, 假设训练输入 x_i 固定, 随机性仅来自 y_i :

$$\text{Err}(x_0) = \mathbb{E}[(Y - \hat{f}_k(x_0))^2 \mid X = x_0] = \sigma_\varepsilon^2 + \left[f(x_0) - \frac{1}{k} \sum_{\ell=1}^k f(x_{(\ell)}) \right]^2 + \frac{\sigma_\varepsilon^2}{k} \quad (15.9)$$

邻居数 k 与模型复杂度成反比。 k 小 $\rightarrow$ 能更好地适应 $f(x_0)$; k 增大 $\rightarrow$ 偏差通常增大而方差减小。

15.3.2 线性回归的偏差-方差分解

对线性模型 $\hat{f}_p(x_0) = x_0^T \hat{\beta}$ 使用最小二乘拟合：

$$\text{Err}(x_0) = \sigma_\varepsilon^2 + [f(x_0) - \mathbb{E}\hat{f}_p(x_0)]^2 + \|h(x_0)\|^2 \sigma_\varepsilon^2 \quad (15.10)$$

其中 $h(x_0) = X(X^T X)^{-1}x_0$ ，是产生拟合的 N 维线性权重向量。该方差虽随 x_0 变化，但其平均值（以样本值 x_i 为 x_0 ）为 $(p/N)\sigma_\varepsilon^2$ ，从而得到样本内误差：

$$\frac{1}{N} \sum_{i=1}^N \text{Err}(x_i) = \sigma_\varepsilon^2 + \frac{1}{N} \sum_{i=1}^N [f(x_i) - \mathbb{E}\hat{f}_p(x_i)]^2 + \frac{p}{N} \sigma_\varepsilon^2 \quad (15.11)$$

复杂度直接与参数个数 p 相关。

15.3.3 岭回归的偏差分解

对岭回归拟合 $\hat{f}_\alpha(x_0)$ ，检验误差形式与 (15.10) 相同，但方差项中的线性权重不同： $h(x_0) = X(X^T X + \alpha I)^{-1}x_0$ 。偏差项也不同。

对线性模型族（如岭回归），偏差可进一步精细分解。设 β_* 为 f 的最佳线性逼近参数：

$$\beta_* = \arg \min_{\beta} \mathbb{E}[f(X) - X^T \beta]^2 \quad (15.12)$$

期望关于输入变量 X 的分布。则平均平方偏差可写为：

$$\begin{aligned} \mathbb{E}_{x_0} [f(x_0) - \mathbb{E}\hat{f}_\alpha(x_0)]^2 &= \mathbb{E}_{x_0} [f(x_0) - x_0^T \beta_*]^2 + \mathbb{E}_{x_0} [x_0^T \beta_* - \mathbb{E}(x_0^T \hat{\beta}_\alpha)]^2 \\ &= \text{Ave}[\text{模型偏差}] + \text{Ave}[\text{估计偏差}] \end{aligned} \quad (15.13)$$

- **模型偏差 (Model Bias)：** 最佳线性逼近与真实函数之间的误差——只能通过将线性模型族扩大为更丰富的模型集合（如引入交互项和变量变换）来减小。
- **估计偏差 (Estimation Bias)：** 平均估计与最佳线性逼近之间的误差。OLS 的估计偏差为零；受限拟合（如岭回归）的估计偏差为正，我们用它换取方差的降低。

若用更少的预测变量或对系数向零收缩来拟合模型，则得到「收缩拟合」。该拟合离模型空间中的最佳拟合更远（增加了估计偏差），但方差更小。若方差减少超过（平方）偏差的增加，则这种收缩是值得的。

15.3.4 示例：偏差-方差权衡

共有 80 个观测和 20 个预测变量，均匀分布在超立方体 $[0, 1]^{20}$ 中：

- **左侧面板：** Y 当 $X_1 \leq 1/2$ 时为 0，否则为 1，使用 k -最近邻。




FIGURE 7.2. Schematic of the behavior of bias and variance. The model space is the set of all possible predictions from the model, with the “closest fit” labeled with a black dot. The model bias from the truth is shown, along with the variance, indicated by the large yellow circle centered at the black dot labeled “closest fit in population.” A shrunken or regularized fit is also shown, having additional estimation bias, but smaller prediction error due to its decreased variance.

图 15.2: 偏差与方差行为的示意图。模型空间是模型所有可能预测的集合,「最近拟合」以黑点标出。真值与最近拟合之间的距离为模型偏差。方差由以「总体中的最近拟合」为中心的大黄色圆表示。收缩/正则化拟合具有额外的估计偏差,但由于方差减小,预测误差反而更小。




FIGURE 7.3. Expected prediction error (orange), squared bias (green) and variance (blue) for a simulated example. The top row is regression with squared error loss; the bottom row is classification with 0–1 loss. The models are k -nearest neighbors (left) and best subset regression of size p (right). The variance and bias curves are the same in regression and classification, but the prediction error curve is different.

图 15.3: 模拟示例的期望预测误差（橙色）、平方偏差（绿色）和方差（蓝色）。上行：平方误差损失的回归；下行：0-1 损失的分类。左列： k -最近邻；右列：大小为 p 的最佳子集线性回归。偏差和方差曲线在回归与分类中相同，但预测误差曲线不同。

- **右侧面板：** Y 当 $\sum_{j=1}^{10} X_j > 5$ 时为 1，否则为 0，使用大小为 p 的最佳子集线性回归。

上行是平方误差损失的回归；下行是 0-1 损失的分​​类。图中展示了预测误差（红色）、平方偏差（绿色）和方差（蓝色），均在大型测试样本上计算。

回归情形：偏差和方差相加产生预测误差曲线，最小值出现在 $k \approx 5$ (k -NN) 和 $p \geq 10$ (线性模型)。

分类情形（下行）：出现了一些有趣现象：

- 偏差和方差曲线与上行相同，但预测误差现在指误分类率。
- 预测误差不再是平方偏差与方差之和。
- 对 k -NN 分类器，当邻居数从 1 增加到 20 时，预测误差下降或保持不变，尽管平方偏差在上升。
- 对线性模型分类器，最小值和回归一样在 $p \geq 10$ 处，但相比 $p = 1$ 的改进更为显著。
- 偏差和方差似乎在决定预测误差时存在交互作用。

15.4 训练误差的乐观性

关于误差率估计的讨论可能令人困惑，因为需要明确哪些量是固定的、哪些是随机的。

15.4.1 泛化误差、期望误差与样本内误差

给定训练集 $\mathcal{T} = \{(x_1, y_1), \dots, (x_N, y_N)\}$ ，模型 $\hat{f}$ 的泛化误差为：

$$\text{Err}_{\mathcal{T}} = \mathbb{E}_{X^0, Y^0} [L(Y^0, \hat{f}(X^0)) \mid \mathcal{T}] \quad (15.14)$$

训练集 $\mathcal{T}$ 固定， (X^0, Y^0) 是从数据的联合分布 F 中抽取的新测试点。

对训练集 $\mathcal{T}$ 取平均得到期望误差：

$$\text{Err} = \mathbb{E}_{\mathcal{T}} \mathbb{E}_{X^0, Y^0} [L(Y^0, \hat{f}(X^0)) \mid \mathcal{T}] \quad (15.15)$$

大多数方法实际估计的是期望误差而非 $\text{Err}_{\mathcal{T}}$ （见第 7.12 节）。

训练误差为：

$$\overline{\text{err}} = \frac{1}{N} \sum_{i=1}^N L(y_i, \hat{f}(x_i)) \quad (15.16)$$

由于同一批数据既用于拟合方法又用于评估误差，训练误差 $\overline{\text{err}}$ 通常是泛化误差 $\text{Err}_{\mathcal{T}}$ 的过度乐观的估计。

为了更清晰地理解乐观性的本质，引入**样本内误差**（in-sample error）：

$$\text{Err}_{\text{in}} = \frac{1}{N} \sum_{i=1}^N \mathbb{E}_{Y_i^0} [L(Y_i^0, \hat{f}(x_i)) \mid \mathcal{T}] \quad (15.17)$$

其中 Y_i^0 表示在每个训练点 x_i 处观察 N 个新的响应值。

Err_{in} 与 Err_T 的关系

两者评估的是不同位置的数据：

- Err_T：(X^0, Y^0) 从总体 F 中任意抽取， X^0 是全新的——称为「额外样本误差」。
- Err_{in}： X 固定在训练集的 x_i 上，仅 Y_i^0 重新生成——称为「样本内误差」。

引入 Err_{in} 的原因在于数学上的便利： X 不动，只有 Y 重抽样，这使得乐观性公式 $\omega = \frac{2}{N} \sum \text{Cov}(\hat{y}_i, y_i)$ 得以推导。 C_p 、AIC 等解析准则估计的正是 Err_{in}（或其对训练集的期望）。

Err_{in} 与最终目标 Err 的关系

Err_{in} 与 Err 之间没有简单的等号或近似关系——它们服务于不同目的：

- **模型比较**：Err_{in} 足以胜任。在训练 x_i 上表现好的模型，在新 X 上也通常表现好，排序一致。
- **绝对评估**：Err_{in} 的绝对值没有实际意义——未来数据的 X 几乎不可能恰好等于某个训练 x_i 。需用交叉验证或 Bootstrap 直接估计 Err。

简言之： C_p 、AIC 估计 Err_{in} → 用于选模型（比大小）；交叉验证、Bootstrap 估计 Err → 用于评估最终模型（要绝对值）。

15.4.2 乐观性及其性质

定义**乐观性**（optimism）为样本内误差与训练误差之差：

$$\text{op} \equiv \text{Err}_{\text{in}} - \overline{\text{err}} \quad (15.18)$$

这通常是正的，因为 $\overline{\text{err}}$ 作为预测误差的估计通常偏低。

平均乐观性是乐观性对训练集的期望：

$$\omega \equiv \mathbb{E}_y(\text{op}) \quad (15.19)$$

这里预测变量固定，期望针对训练集的响应值。




图 15.4: $\overline{\text{err}}$ 、 Err_{in} 、 $\text{Err}_{\mathcal{T}}$ 、 Err 四者关系与各自用途。上行为样本内视角， C_p 、AIC 修正乐观性后用于模型比较；下行为泛化视角，交叉验证与 Bootstrap 直接估计 Err 用于最终评估。

对于平方误差、0-1 损失及其他损失函数，可以一般地证明：

$$\omega = \frac{2}{N} \sum_{i=1}^N \text{Cov}(\hat{y}_i, y_i) \quad (15.20)$$

其中 Cov 表示协方差。

注记 15.5. $\overline{\text{err}}$ 低估真实误差的程度取决于 y_i 对其自身预测的影响有多强。我们对数据拟合越用力， $\text{Cov}(\hat{y}_i, y_i)$ 就越大，乐观性也随之增加。对于回归的平方误差损失， $\hat{y}_i$ 是拟合值；对 0-1 分类， $\hat{y}_i \in \{0, 1\}$ 是分类结果；对熵损失， $\hat{y}_i \in [0, 1]$ 是类别 1 的拟合概率。

综上，有重要关系：

$$\mathbb{E}_y(\text{Err}_{\text{in}}) = \mathbb{E}_y(\overline{\text{err}}) + \frac{2}{N} \sum_{i=1}^N \text{Cov}(\hat{y}_i, y_i) \quad (15.21)$$

15.4.3 线性拟合的特殊情形

若 $\hat{y}_i$ 由具有 d 个输入或基函数的线性拟合得到，且假设可加误差模型 $Y = f(X) + \varepsilon$ ，则：

$$\sum_{i=1}^N \text{Cov}(\hat{y}_i, y_i) = d \sigma_{\varepsilon}^2 \quad (15.22)$$

从而：

$$\mathbb{E}_y(\text{Err}_{\text{in}}) = \mathbb{E}_y(\overline{\text{err}}) + 2 \cdot \frac{d}{N} \sigma_{\varepsilon}^2 \quad (15.23)$$

这是第 7.6 节定义的有效参数个数概念的基础。乐观性随使用的输入/基函数个数 d 线性增长，但随训练样本量增大而减小。

注记 15.6. 一个自然的估计预测误差的思路是：先估计乐观性，然后将它加到训练误差上。下一节描述的 C_p 、AIC、BIC 等方法即是按此思路运作的——对参数为线性的特殊估计类。

注记 15.7. 交叉验证和自助法（本章后续介绍）则是直接估计额外样本误差（extra-sample error） $\text{Err}_{\mathcal{T}}$ 。这些通用工具可用于任意损失函数以及非线性、自适应的拟合技术。

样本内误差虽然在实践中不直接关注（因为未来特征值不太可能与训练集特征值重合），但对于模型间的比较，样本内误差是方便的，且通常能有效地进行模型选择——因为重要的是误差的相对（而非绝对）大小。

15.5 样本内预测误差的估计

样本内估计的一般形式为：

$$\widehat{\text{Err}}_{\text{in}} = \overline{\text{err}} + \hat{\omega} \quad (15.24)$$

其中 $\hat{\omega}$ 是平均乐观性的估计。

15.5.1 C_p 统计量

利用 (15.23)（ d 个参数在平方误差损失下拟合），得到 C_p 统计量的一种形式：

$$C_p = \overline{\text{err}} + 2 \cdot \frac{d}{N} \hat{\sigma}_\varepsilon^2 \quad (15.25)$$

其中 $\hat{\sigma}_\varepsilon^2$ 是噪声方差的估计，由低偏差模型的均方误差获得。该准则按使用的基函数数量成比例地调整训练误差。

15.5.2 AIC 准则

Akaike 信息准则（AIC）是使用对数似然损失函数时更一般适用的 Err_{in} 估计。它依赖于当 $N \rightarrow \infty$ 时渐近成立的类似关系：

$$-2 \cdot \mathbb{E}[\log \Pr_{\hat{\theta}}(Y)] \approx -\frac{2}{N} \cdot \mathbb{E}[\log \text{lik}] + 2 \cdot \frac{d}{N} \quad (15.26)$$

其中 $\Pr_{\theta}(Y)$ 是 Y 的密度族（包含「真实」密度）， $\hat{\theta}$ 是 θ 的极大似然估计， $\log \text{lik} = \sum_{i=1}^N \log \Pr_{\hat{\theta}}(y_i)$ 是最大化对数似然。

AIC 定义为：

$$\text{AIC} = -\frac{2}{N} \cdot \log \text{lik} + 2 \cdot \frac{d}{N} \quad (15.27)$$

选择使 AIC 最小的模型。注意到 $-\frac{2}{N} \cdot \log \text{lik}$ 是训练误差（对数似然损失），而 $2d/N$ 是乐观性的估计。

注记 15.8. C_p 和 AIC 虽然形式相似，但动机不同： C_p 来自精确的无偏估计（线性模型 + 平方误差），而 AIC 来自渐近论证（一般似然框架）。

15.5.3 AIC 的实践使用

对 logistic 回归，使用二项对数似然：

$$\text{AIC} = -\frac{2}{N} \cdot \text{loglik} + 2 \cdot \frac{d}{N} \quad (15.28)$$

对高斯模型（方差 $\sigma_\varepsilon^2 = \hat{\sigma}_\varepsilon^2$ 已知），AIC 与 C_p 等价，因此常统称为 AIC。

给定由调节参数 α 索引的模型族 $f_\alpha(x)$ ，记 $\overline{\text{err}}(\alpha)$ 和 $d(\alpha)$ 为每个模型的训练误差和参数个数，则：

$$\text{AIC}(\alpha) = \overline{\text{err}}(\alpha) + 2 \cdot \frac{d(\alpha)}{N} \hat{\sigma}_\varepsilon^2 \quad (15.29)$$

$\text{AIC}(\alpha)$ 给出测试误差曲线的估计，选择使 AIC 最小的 $\hat{\alpha}$ 。

注记 15.9. 若基函数是自适应选择的（如从 p 个输入中选最佳 $d < p$ 个），则乐观性将超过 $2d\sigma_\varepsilon^2/N$ ——选择最佳 d 输入模型时，实际拟合的有效参数个数大于 d 。

图 7.4 展示了 AIC 在音素识别示例中的应用：logistic 回归系数 $\beta(f) = \sum_{m=1}^M h_m(f)\theta_m$ 展开为 M 个样条基函数，AIC 选择的基函数个数近似最小化了 $\text{Err}(M)$ （对对数似然和 0-1 损失均表现良好）。

15.6 有效参数个数

「参数个数」的概念可以推广，尤其适用于使用正则化的模型。

15.6.1 线性拟合方法的有效自由度

将输出 $y_1, \dots, y_N$ 和预测 $\hat{y}_1, \dots, \hat{y}_N$ 分别堆叠为向量 $\mathbf{y}$ 和 $\hat{\mathbf{y}}$ 。线性拟合方法满足：

$$\hat{\mathbf{y}} = \mathbf{S}\mathbf{y} \quad (15.30)$$

其中 $\mathbf{S}$ 是 $N \times N$ 矩阵，仅依赖于输入 $\mathbf{x}_i$ 而不依赖于 y_i 。此类方法包括：原始特征或导出基上的线性回归、岭回归、三次光滑样条等。

有效参数个数定义为：

$$\text{df}(\mathbf{S}) = \text{tr}(\mathbf{S}) \quad (15.31)$$

即 $\mathbf{S}$ 对角元之和（也称有效自由度）。若 $\mathbf{S}$ 是向 M 个特征张成的基集的正交投影矩阵，则 $\text{tr}(\mathbf{S}) = M$ 。

可以证明， $\text{tr}(\mathbf{S})$ 恰好是 C_p 统计量中替代 d 的正确量。在可加误差模型下：

$$\sum_{i=1}^N \text{Cov}(\hat{y}_i, y_i) = \text{tr}(\mathbf{S}) \sigma_\varepsilon^2 \quad (15.32)$$

这引出了更一般的定义：

$$\text{df}(\hat{\mathbf{y}}) = \frac{\sum_{i=1}^N \text{Cov}(\hat{y}_i, y_i)}{\sigma_\varepsilon^2} \quad (15.33)$$

15.6.2 神经网络的有效参数个数

对带权重衰减惩罚（正则化） $\alpha \sum_m w_m^2$ 的神经网络，有效参数个数为：

$$\text{df}(\alpha) = \sum_{m=1}^M \frac{\theta_m}{\theta_m + \alpha} \quad (15.34)$$

其中 θ_m 是 Hessian 矩阵 $\partial^2 R(\mathbf{w})/\partial \mathbf{w} \partial \mathbf{w}^T$ 在解处的特征值。该式可在误差函数的二次逼近下由 (15.31) 导出。

15.7 贝叶斯方法与 BIC

15.7.1 BIC 的定义

贝叶斯信息准则（BIC）适用于通过最大化对数似然进行拟合的情形，其一般形式为：

$$\text{BIC} = -2 \cdot \log \text{lik} + (\log N) \cdot d \quad (15.35)$$

BIC（乘 1/2 后）也称 Schwarz 准则。

在高斯模型（方差 σ_ε^2 已知）下：

$$\text{BIC} = \frac{N}{\sigma_\varepsilon^2} \left[\overline{\text{err}} + (\log N) \cdot \frac{d}{N} \sigma_\varepsilon^2 \right] \quad (15.36)$$

因此 BIC 与 AIC (C_p) 成比例，只是因子 2 被替换为 $\log N$ 。由于 $N > e^2 \approx 7.4$ 时 $\log N > 2$ ，BIC 对复杂模型的惩罚更重，倾向于选择更简单的模型。

注记 15.10. 误分类误差度量不出现于 BIC 框架中，因为它不对应于任何概率模型下数据的对数似然。

15.7.2 BIC 的贝叶斯推导

设候选模型为 $\mathcal{M}_m$ ($m = 1, \dots, M$)，对应参数 θ_m ，先验为 $\Pr(\theta_m | \mathcal{M}_m)$ 。模型的后验概率为：

$$\Pr(\mathcal{M}_m | \mathbf{Z}) \propto \Pr(\mathcal{M}_m) \cdot \Pr(\mathbf{Z} | \mathcal{M}_m) \quad (15.37)$$

其中 $\mathbf{Z}$ 表示训练数据。比较两个模型的后验几率（posterior odds）：

$$\frac{\Pr(\mathcal{M}_m | \mathbf{Z})}{\Pr(\mathcal{M}_\ell | \mathbf{Z})} = \frac{\Pr(\mathcal{M}_m)}{\Pr(\mathcal{M}_\ell)} \cdot \frac{\Pr(\mathbf{Z} | \mathcal{M}_m)}{\Pr(\mathbf{Z} | \mathcal{M}_\ell)} \quad (15.38)$$

右端第二个因子称为贝叶斯因子（Bayes factor）。

假设模型先验均匀，对积分 $\Pr(\mathbf{Z} | \mathcal{M}_m)$ 使用 Laplace 近似：

$$\log \Pr(\mathbf{Z} | \mathcal{M}_m) = \log \Pr(\mathbf{Z} | \hat{\theta}_m, \mathcal{M}_m) - \frac{d_m}{2} \cdot \log N + O(1) \quad (15.39)$$

其中 $\hat{\theta}_m$ 是极大似然估计, d_m 是模型 $\mathcal{M}_m$ 的自由参数个数。因此选择最小 BIC 等价于选择最大 (近似) 后验概率的模型。

此外, 可估计每个模型的后验概率:

$$\Pr(\mathcal{M}_m | \mathbf{Z}) \approx \frac{e^{-\frac{1}{2}\text{BIC}_m}}{\sum_{\ell=1}^M e^{-\frac{1}{2}\text{BIC}_\ell}} \quad (15.40)$$

15.7.3 AIC 与 BIC 的比较

- **BIC 是渐近一致的:** 若真实模型在候选族中, 当 $N \rightarrow \infty$ 时 BIC 选出正确模型的概率趋近于 1。AIC 不具有此性质——随 $N \rightarrow \infty$ 倾向于选择过于复杂的模型。
- **有限样本下:** BIC 因其对复杂度的重惩罚, 常选择过于简单的模型。
- 模型选择中 AIC 与 BIC 没有绝对的优劣, 取决于具体场景。

如何直观理解 C_p 、AIC、df、BIC?

这四个量都围绕同一个核心公式: $\widehat{\text{Err}} = \overline{\text{err}} + \text{复杂度惩罚}$ 。区别在于惩罚项用什么、怎么来:

- C_p (Mallows' C_p): 最直白—— $\overline{\text{err}} + 2 \cdot \frac{d}{N} \hat{\sigma}_\epsilon^2$ 。思想是「用了 d 个参数, 每个参数贡献 $2\sigma_\epsilon^2/N$ 的乐观性」。仅在平方误差 + 线性模型下精确成立。
- **AIC (Akaike 信息准则):** C_p 的泛化版——把 $\overline{\text{err}}$ 换成对数似然损失, 惩罚项仍是 $2d/N$ 。来自渐近理论 ($N \rightarrow \infty$), 适用于任何用极大似然拟合的模型。记法: **AIC = 「2 × 参数个数」的惩罚**。
- **df (有效自由度):** 回答「 d 到底该用多少」的问题。对线性模型 d 就是参数个数; 对正则化模型 (岭回归、样条), 系数被收缩了, 实际「有效」参数少于名义 d 。公式 $\text{df} = \text{tr}(\mathbf{S})$ 给出精确答案: $\hat{\mathbf{y}} = \mathbf{S}\mathbf{y}$, $\mathbf{S}$ 的对角元之和就是有效参数个数。记法: **df 就是 $\mathbf{S}$ 的迹**。
- **BIC (贝叶斯信息准则):** AIC 的「更严厉」版本——惩罚项从 2 换成 $\log N$ 。由于 $\log N > 2$ ($N \geq 8$), BIC 对复杂模型惩罚更重。来自贝叶斯推导 (选择最大后验概率模型), 具有渐近一致性。记法: **BIC = 「 $\log N \times$ 参数个数」的惩罚**。

一句话区分:

准则	惩罚因子	适用场景
C_p	2	线性模型 + 平方误差
AIC	2	一般似然模型, $N \rightarrow \infty$ 渐近
df	—	回答「有效参数个数是多少」
BIC	$\log N$	贝叶斯框架, $N \rightarrow \infty$ 一致性

15.8 最小描述长度

最小描述长度（MDL）方法给出的选择准则在形式上与 BIC 相同，但其动机来自最优编码视角。

15.8.1 编码与熵

将数据 $\mathbf{z}$ 视为需要编码传输的消息，模型视为编码方式，选择最精简的模型（最短编码）。

对具有概率 $\Pr(z_i)$ 的消息，Shannon 定理指出应使用码长 $l_i = -\log_2 \Pr(z_i)$ ，且平均消息长度满足：

$$\mathbb{E}(\text{length}) \geq -\sum_i \Pr(z_i) \log_2 \Pr(z_i) \quad (15.41)$$

右端称为分布的熵。结论：传输概率密度为 $\Pr(z)$ 的随机变量约需 $-\log_2 \Pr(z)$ 比特。

15.8.2 MDL 用于模型选择

对于模型 $\mathcal{M}$ （参数 θ ）和数据 $\mathbf{Z} = (\mathbf{X}, \mathbf{y})$ ，假设接收方已知输入 $\mathbf{X}$ ，需传输输出 $\mathbf{y}$ 。总消息长度为：

$$\text{length} = -\log \Pr(\mathbf{y} \mid \theta, \mathcal{M}, \mathbf{X}) - \log \Pr(\theta \mid \mathcal{M}) \quad (15.42)$$

第一项传输模型与真实目标的偏差，第二项传输模型参数。二者之和的最小化即最小描述长度原则。

MDL 的模型选择观点是选择后验概率最高的模型——这与 BIC 一致。然而许多贝叶斯学者更倾向于从后验分布中抽样做推断，而非仅选一个模型。

15.9 Vapnik–Chervonenkis 维

使用样本内误差估计的一个困难在于需要指定拟合中使用的参数个数（复杂度） d 。第 7.6 节的有效参数个数对某些非线性模型有用，但并不完全通用。VC 理论提供了复杂度的一般度量，并给出相应的乐观性界。

15.9.1 打散与 VC 维定义

设 $\{f(x, \alpha)\}$ 为一类函数。暂时假设 f 是指示函数（取值 0 或 1）。例如：

- $f(x, \alpha) = I(\alpha_0 + \alpha_1 x > 0)$ ——线性指示函数
- $f(x, \alpha) = I(\sin(\alpha \cdot x) > 0)$ ——正弦指示函数（图 7.5）

VC 维定义为该类函数能打散 (shatter) 的点的最大个数 (在某种配置下)。

一组点被函数类「打散」是指：无论怎样为每个点分配二值标签，该类中总存在一个成员能完全分离它们。

图 7.6 表明平面中线性指示函数的 VC 维为 3 (3 个点可被打散, 4 个点不可)。一般地, p 维线性指示函数的 VC 维为 $p + 1$ ——等于自由参数个数。而 $\sin(\alpha x)$ 族的 VC 维为无穷 (通过选择适当频率 α 可打散任意多个点)。

对实值函数类 $\{g(x, \alpha)\}$, 其 VC 维定义为指示函数类 $\{I(g(x, \alpha) - \beta > 0)\}$ 的 VC 维, 其中 β 取 g 的值域。

15.9.2 VC 界与结构风险最小化

利用 VC 维可构造预测误差的估计。对二分类:

$$\text{Err}_{\mathcal{T}} \leq \overline{\text{err}} + \frac{\epsilon}{2} \left(1 + \sqrt{1 + \frac{4 \cdot \overline{\text{err}}}{\epsilon}} \right) \quad (15.43)$$

对回归:

$$\text{Err}_{\mathcal{T}} \leq \frac{\overline{\text{err}}}{(1 - c\sqrt{\epsilon})_+} \quad (15.44)$$

其中 $\epsilon = a_1 \frac{h[\log(a_2 N/h) + 1] - \log(\eta/4)}{N}$, h 为 VC 维。这些界对所有 $f(x, \alpha)$ 同时成立, 从而允许在函数类中搜索。

结构风险最小化 (SRM): 拟合一个 VC 维递增的嵌套模型序列 $h_1 < h_2 < \dots$, 选择使上界最小的模型。

注记 15.11. VC 界通常非常宽松, 但这不妨碍其作为模型选择准则——重要的是相对而非绝对大小。主要缺点是 VC 维计算困难, 通常只能获得粗略上界。支持向量机 (第 12.2 节) 是 SRM 的成功应用案例。

15.9.3 示例: AIC、BIC、SRM 的比较

AIC 在所有四个场景中表现良好 (即使 0-1 损失缺乏理论支持), BIC 表现接近, SRM 表现参差不齐。

15.10 交叉验证

交叉验证可能是估计预测误差最简单且最广泛使用的方法。该方法直接估计期望额外样本误差 $\text{Err} = \mathbb{E}[L(Y, \hat{f}(X))]$ ——即将方法 $\hat{f}(X)$ 应用于来自 X 和 Y 联合分布的独立测试样本时的平均泛化误差。第 7.12 节将说明, 交叉验证通常只能较好地估计期望预测误差, 而非条件误差 $\text{Err}_{\mathcal{T}}$ 。




FIGURE 7.7. Boxplots show the distribution of the relative error $100 \times [\text{Err}_{\mathcal{T}}(\hat{\alpha}) - \min_{\alpha} \text{Err}_{\mathcal{T}}(\alpha)] / [\max_{\alpha} \text{Err}_{\mathcal{T}}(\alpha) - \min_{\alpha} \text{Err}_{\mathcal{T}}(\alpha)]$ over the four scenarios of Figure 7.3. This is the error in using the chosen model relative to the best model. There are 100 training sets each of size 80 represented in each boxplot, with the errors computed on test sets of size 10,000.

图 15.5: 箱线图展示图 7.3 四个场景下相对误差 $100 \times [\text{Err}_{\mathcal{T}}(\hat{\alpha}) - \min_{\alpha} \text{Err}_{\mathcal{T}}(\alpha)] / [\max_{\alpha} \text{Err}_{\mathcal{T}}(\alpha) - \min_{\alpha} \text{Err}_{\mathcal{T}}(\alpha)]$ 的分布——即使用所选模型相对于最佳模型的误差。每个箱线图代表 100 个大小为 80 的训练集，误差在大小为 10,000 的测试集上计算。

15.10.1 K 折交叉验证

将数据随机分为 K 个大小大致相等的折。对第 k 折，用其余 $K - 1$ 折数据拟合模型，计算在第 k 折上的预测误差。 K 折 CV 估计为：

$$\text{CV}(\alpha) = \frac{1}{K} \sum_{k=1}^K \frac{1}{|F_k|} \sum_{i \in F_k} L(y_i, \hat{f}_\alpha^{-k}(x_i)) \quad (15.45)$$

其中 $\hat{f}_\alpha^{-k}$ 是剔除第 k 折后拟合的模型， F_k 为第 k 折的索引集。

典型选择： $K = 5$ 或 $K = 10$ 。 $K = N$ 的特例称为**留一交叉验证 (LOOCV)**。

更精确地，设 $\kappa: \{1, \dots, N\} \rightarrow \{1, \dots, K\}$ 为指示观测 i 分配到哪一折的索引函数， $\hat{f}^{-k}(x)$ 为剔除第 k 折后拟合的函数。则 CV 预测误差估计为：

$$\text{CV}(\hat{f}) = \frac{1}{N} \sum_{i=1}^N L(y_i, \hat{f}^{-\kappa(i)}(x_i)) \quad (15.46)$$

对含调节参数 α 的模型族：

$$\text{CV}(\hat{f}, \alpha) = \frac{1}{N} \sum_{i=1}^N L(y_i, \hat{f}^{-\kappa(i)}(x_i, \alpha)) \quad (15.47)$$

选择使 $\text{CV}(\hat{f}, \alpha)$ 最小的 $\hat{\alpha}$ ，再用全部数据拟合最终模型 $f(x, \hat{\alpha})$ 。

这里容易混淆：LOOCV ($K = N$) 并非一种不同的做法——它仍是 K 折 CV，只是每折恰好包含 1 个观测。以 $N = 100$ 为例，5 折 CV 每次用 80 个训练、20 个验证，共做 5 次；LOOCV 每次用 99 个训练、1 个验证，共做 100 次。LOOCV 的每个训练集几乎等于全量数据（只差一个点），因此偏差极低；但 100 个训练集高度相似，导致方差大。

最终模型用什么训练？ CV 全程只用原始训练集——从未见过独立的测试集。CV 的作用仅仅是选 $\hat{\alpha}$ 。选定后，用**全部 N 个观测**重新训练一次，得到最终模型 $\hat{f}(\cdot, \hat{\alpha})$ 。测试集（如果保留了一份）只在最后评估这个最终模型时使用一次。

一个具体流程示例。 假设有 $N = 150$ 条数据，要做岭回归，调节参数 α 候选为 $\{0.01, 0.1, 1, 10, 100\}$ 。

1. 随机打乱数据，分成 5 折（每折 30 条）。
2. 对每个候选 α ：
 - 第 1 折做验证，第 2-5 折（120 条）训练 $\rightarrow$ 算验证误差 $e_1(\alpha)$
 - 第 2 折做验证，其余训练 $\rightarrow e_2(\alpha)$
 - ... 共 5 次，取平均 $\text{CV}(\alpha) = \frac{1}{5} \sum_{k=1}^5 e_k(\alpha)$
3. 选 $\hat{\alpha} = \arg \min_{\alpha} \text{CV}(\alpha)$ ，假设结果为 $\hat{\alpha} = 1$ 。

4. 用全部 150 条数据，以 $\alpha = 1$ 做岭回归 $\rightarrow$ 得到最终模型 $\hat{\beta}_{\alpha=1}^{\text{ridge}}$ 。

5. (可选) 在保留的独立测试集上评估该模型的泛化误差。

整个过程没有用到测试集来选 α ——这正是 CV 的核心价值：在训练数据内部模拟「训-验」分离。

15.10.2 K 的选择：偏差-方差权衡

CV 实际估计的是什么呢？ $K = 5$ 或 10 时，每折的训练集与原训练集差别较大，估计的应是 Err （期望误差）。 $K = N$ （LOOCV）时，训练集几乎与原集相同，可能更接近 $\text{Err}_{\mathcal{T}}$ 。但第 7.12 节将说明，CV 通常只能有效估计 Err 。

- $K = N$ （LOOCV）：近似无偏（对 Err ），但方差高—— N 个训练集高度相似。
- $K = 5$ 或 10 ：方差低，但若学习曲线在给定训练集大小处有显著斜率，则会有偏差。




FIGURE 7.8. Hypothetical learning curve for a classifier on a given task: a plot of $1 - \text{Err}$ versus the size of the training set N . With a dataset of 200 observations, 5-fold cross-validation would use training sets of size 160, which would behave much like the full set. However, with a dataset of 50 observations fivefold cross-validation would use training sets of size 40, and this would result in a considerable overestimate of prediction error.

图 15.6: 某个分类任务假设的学习曲线： $1 - \text{Err}$ 随训练集大小 N 的变化。若数据集有 200 个观测，5 折 CV 使用大小为 160 的训练集，其表现与全量集几乎相同。但若仅有 50 个观测，5 折 CV 使用大小为 40 的训练集，将导致显著高估预测误差。

总体建议：5 折或 10 折 CV 作为折中方案。

15.10.3 广义交叉验证（GCV）

GCV 为线性拟合方法在平方误差损失下的 LOOCV 提供方便的近似。对线性拟合 $\hat{\mathbf{y}} = \mathbf{S}\mathbf{y}$ ：

$$\text{GCV}(\hat{f}) = \frac{1}{N} \sum_{i=1}^N \left[\frac{y_i - \hat{f}(x_i)}{1 - \text{tr}(\mathbf{S})/N} \right]^2 \quad (15.48)$$

其中 $\text{tr}(\mathbf{S})$ 是有效参数个数。当 $\text{tr}(\mathbf{S})$ 比单个 S_{ii} 更易计算时, GCV 有计算优势。在光滑问题中, GCV 还可缓解 CV 的欠光滑倾向。

GCV 与 AIC 的联系: 利用近似 $1/(1-x)^2 \approx 1+2x$ 可见其相似性。

15.10.4 交叉验证的正确与错误做法

常见错误: 先在全量数据上做变量筛选 (如选与标签最相关的 100 个预测变量), 再对筛选后的数据做 CV。这相当于筛选出的变量「已经见过」被留出的样本——CV 误差会严重偏低。

仿真示例: $N = 50$, $p = 5000$ 个与标签独立的预测变量, 真实误差率 50%。先用全量数据选 100 个最相关变量, 再对 1-NN 做 CV $\rightarrow$ 平均 CV 误差仅 3% (严重错误)。




图 15.7: 交叉验证的错误做法与正确做法对比。上图: 先在全量数据上做变量筛选再划分折——筛选时已「偷看」了所有样本的标签, 导致 CV 误差严重偏低。下图: 先划分折, 在每折的训练部分独立筛选变量和训练——CV 误差无偏。

这里「变量筛选」指的是从众多预测变量中挑选出一个子集——选列, 而非选值。




FIGURE 7.10. Cross-validation the wrong and right way: histograms shows the correlation of class labels, in 10 randomly chosen samples, with the 100 predictors chosen using the incorrect (upper red) and correct (lower green) versions of cross-validation.

图 15.8: 交叉验证的错误与正确方式: 直方图展示了在 10 个随机选择的样本中, 使用错误 (上, 红色) 和正确 (下, 绿色) CV 方式所选 100 个预测变量与类别标签的相关性。错误方式下相关性被人为夸大。

例如从 5000 个基因中挑出与标签 Y 最相关的前 100 个，扔掉其余 4900 个：

$$X_1, X_2, \dots, X_{5000} \xrightarrow{\text{按相关性排序截断}} X_{(1)}, X_{(2)}, \dots, X_{(100)}$$

筛选方法：对每个变量 j 单独计算 $|r_j| = |\text{Cor}(X_j, Y)|$ ，排序取最大的若干个。每折独立做——用该折的 40 个训练样本算相关性、独立排序、独立截断，各折选出的变量通常不同，不取平均。

完整流程演示 ($N = 50$, $p = 5000$, 5 折 CV, 1-NN 分类器)：

1. 随机将 50 人分成 5 折，每折 10 人。
2. **第 1 折做验证**：用折 2-5 的 40 人，对 5000 个基因逐一算 $|r_j|$ ，取前 100 个。用这 100 个基因和 40 人训练 1-NN，在折 1 的 10 人上算误差 e_1 。
3. **第 2 折做验证**：用折 1,3,4,5 的 40 人，重新算 $|r_j|$ 、重新选前 100（可能与折 1 不同！），训练并算 e_2 。
4. 第 3-5 折同理，分别得 e_3, e_4, e_5 。
5. $CV = \frac{1}{5}(e_1 + \dots + e_5)$ 。CV 的作用至此完成——它给出了用 100 个基因时 1-NN 的期望误差估计。
6. **训练最终模型**：回到全量 50 人，重新算 $|r_j|$ （这次用全部 50 人），取前 100 个基因。用这 100 个基因和全部 50 人训练最终 1-NN 分类器。这 100 个基因可能与任一折选出的都不同——这是正常的，因为现在是用全量数据筛选。
7. **最终评估**：在独立的测试集（从未参与上述任何步骤）上评估最终模型的泛化误差。

错误做法的区别仅在于第 1 步之前：先用全部 50 人算 $|r_j|$ 、一次性选出 100 个基因，此后各折不再重新筛选——这 100 个基因在筛选时已「见过」全部 50 人的标签，导致 CV 误差虚低。

这里有一个容易困惑的点：既然 CV 时每折独立筛选、最终训练又回到全量数据重新筛选，那 CV 到底做了什么决策？CV 的目的不是训练最终模型，而是**评估和选择方案**。比如你同时考虑三种方案——用 50 个基因、100 个基因、200 个基因——CV 分别给出它们的泛化误差估计，你据此选择最合适的方案（如 100 个基因）。决策完成后 CV 使命结束。最后一步用全量数据重新筛选 100 个基因并训练，是**充分利用所有数据产出最佳模型**——此时不再需要验证，用全量数据筛选不违反任何原则。两个阶段的分工：CV 负责选超参数，最终训练负责出模型。

正确做法：CV 必须应用于**整个建模流程**——样本必须在任何筛选步骤之前被留出。对 K 折 CV 的第 k 折：

1. 用除第 k 折外的样本筛选「好」变量

2. 用除第 k 折外的样本构建分类器
3. 在第 k 折上评估

唯一的例外是**无监督**的初始筛选（如按方差选变量）可在留出样本前进行——因为它不涉及标签，不会给变量不公平的优势。

15.10.5 交叉验证真的有效吗？——高维示例

考虑 $N = 20$ （两类各半）， $p = 500$ 个与标签独立的标准高斯预测变量，真实误差率 50%。使用单变量树桩（stump）分类器。简单论证认为 CV 会失败：因为全量数据上总能找到一个分裂得很好的预测变量，它在任何 $4/5$ 和 $1/5$ 子集上也应分裂得好。

图 7.11 的仿真表明这个论证是**错误**的——关键在于**分割点必须在 CV 的每折中重新估计**。对 50 个模拟数据集的 5 折 CV，平均误差率约为 50%，正是真实的期望预测误差。不过 CV 估计的变异性很大，报告 CV 估计的标准误差很重要。

15.11 自助法（Bootstrap）

自助法是一种评估统计准确性的通用工具。与交叉验证类似，Bootstrap 试图估计条件误差 Err_T ，但通常只能较好地估计期望预测误差 Err 。

15.11.1 基本思想

设训练集为 $\mathbf{Z} = (z_1, z_2, \dots, z_N)$ ，其中 $z_i = (x_i, y_i)$ 。基本做法是从 $\mathbf{Z}$ 中有放回地随机抽取 N 个样本，形成一个 Bootstrap 样本 $\mathbf{Z}^{*b}$ 。重复 B 次（如 $B = 100$ ），对每个 $\mathbf{Z}^{*b}$ 拟合模型 $\hat{f}^{*b}(x)$ 。

一个具体例子。设 $N = 5$ 的数据为 $\mathbf{Z} = \{z_1, z_2, z_3, z_4, z_5\}$ ，欲估计 $\bar{z}$ 的标准误差。

1. 从 $\mathbf{Z}$ 中有放回地抽 5 个样本，得 $\mathbf{Z}^{*1}$ 。例如抽到 $\{z_3, z_1, z_1, z_5, z_2\}$ （ z_1 出现两次， z_4 未出现）。计算 $\bar{z}^{*1}$ 。
2. 重复 $B = 1000$ 次： $\mathbf{Z}^{*1}, \mathbf{Z}^{*2}, \dots, \mathbf{Z}^{*1000}$ ，每次计算 $\bar{z}^{*b}$ 。
3. $\{\bar{z}^{*1}, \dots, \bar{z}^{*1000}\}$ 的样本标准差即为 $\bar{z}$ 标准误差的 Bootstrap 估计。

对于预测误差估计， $S(\mathbf{Z})$ 就是模型在原始训练集上的某种误差度量。Bootstrap 的核心优势是**无需假设数据分布**——仅通过重抽样模拟「从总体中反复抽样」的过程。直观理解：总体 F 不可知，样本 $\mathbf{Z}$ 是你对于 F 的全部认知，Bootstrap 把 $\mathbf{Z}$ 当作「迷你总体」，从中反复抽样来模拟从真总体反复抽样会发生什么——数据长什么样，Bootstrap 就照猫画虎，不需要假设正态或任何参数分布。




FIGURE 7.12. Schematic of the bootstrap process. We wish to assess the statistical accuracy of a quantity $S(\mathbf{Z})$ computed from our dataset. B training sets $\mathbf{Z}^{*b}$, $b = 1, \dots, B$ each of size N are drawn with replacement from the original dataset. The quantity of interest $S(\mathbf{Z})$ is computed from each bootstrap training set, and the values $S(\mathbf{Z}^{*1}), \dots, S(\mathbf{Z}^{*B})$ are used to assess the statistical accuracy of $S(\mathbf{Z})$.

图 15.9: Bootstrap 过程示意图。目标是从数据集计算出的量 $S(\mathbf{Z})$ 的统计准确性。 B 个训练集 $\mathbf{Z}^{*b}$ ($b = 1, \dots, B$) 各含 N 个观测，均从原始数据集中有放回抽取。在每个 Bootstrap 训练集上计算 $S(\mathbf{Z}^{*b})$ ，用 $S(\mathbf{Z}^{*1}), \dots, S(\mathbf{Z}^{*B})$ 来评估 $S(\mathbf{Z})$ 的统计准确性。

何时使用 Bootstrap? 当公式推导困难或不可行时。典型场景：估计中位数或自定义复杂统计量的标准误差、小样本下正态假设不成立、对非线性自适应模型估计预测误差（解析准则如 C_p 、AIC 失效）、以及任何需要评估统计量稳定性的场合。原则是「能用公式算就用公式，推不出就用 Bootstrap」，代价是计算量——需重复拟合 B 次模型（通常 $B = 200$ 或更多）。

每次 Bootstrap 样本平均含有约 $0.632N$ 个不同的原始观测（其余为重复），这一点在后面.632 估计的推导中起关键作用。

15.11.2 Bootstrap 估计预测误差

一种自然的做法是用 Bootstrap 样本拟合模型后，在原始训练集上评估：

$$\widehat{\text{Err}}_{\text{boot}} = \frac{1}{B} \frac{1}{N} \sum_{b=1}^B \sum_{i=1}^N L(y_i, \hat{f}^{*b}(x_i)) \quad (15.49)$$

但此估计通常很差——Bootstrap 样本与原始训练集有重叠，过拟合会导致估计过于乐观。例如对 1-NN 分类器，当预测变量与标签独立时（真实误差 50%）， $\widehat{\text{Err}}_{\text{boot}}$ 的期望仅为约 $0.5 \times 0.368 = 0.184$ 。这是因为一个观测不在某次 Bootstrap 样本中的概率约为：

$$\Pr\{\text{观测 } i \in \text{Bootstrap 样本 } b\} = 1 - \left(1 - \frac{1}{N}\right)^N \approx 1 - e^{-1} = 0.632 \quad (15.50)$$

留一 Bootstrap (leave-one-out bootstrap)：对每个观测 i ，仅使用不含 i 的 Bootstrap 样本来预测 i ：

$$\widehat{\text{Err}}^{(1)} = \frac{1}{N} \sum_{i=1}^N \frac{1}{|C^{-i}|} \sum_{b \in C^{-i}} L(y_i, \hat{f}^{*b}(x_i)) \quad (15.51)$$

其中 C^{-i} 是不含观测 i 的 Bootstrap 样本的索引集。留一 Bootstrap 解决了过拟合问题，但产生训练集大小偏差——每次 Bootstrap 样本平均仅含 $0.632N$ 个不同观测，其偏差大致类似于 2 折 CV。若学习曲线在 $N/2$ 处有显著斜率，留一 Bootstrap 会高估真实误差。

.632 估计：为缓解此偏差，将留一 Bootstrap 估计向训练误差方向拉回：

$$\widehat{\text{Err}}^{(.632)} = .368 \cdot \overline{\text{err}} + .632 \cdot \widehat{\text{Err}}^{(1)} \quad (15.52)$$

常数.632 来自 (15.50)。但.632 估计对过拟合严重的情况（如 1-NN 与独立标签）会低估误差——此时 $\widehat{\text{Err}}^{(1)} = 0.5$ ， $\overline{\text{err}} = 0$ ， $\widehat{\text{Err}}^{(.632)} = 0.316$ ，而真实误差为 0.5。

.632+ 估计：通过考虑过拟合程度来改进。定义无信息误差率 γ 为预测变量与标签独立时的误差率，其估计为：

$$\hat{\gamma} = \frac{1}{N^2} \sum_{i=1}^N \sum_{i'=1}^N L(y_i, \hat{f}(x_{i'})) \quad (15.53)$$

相对过拟合率:

$$\hat{R} = \frac{\widehat{\text{Err}}^{(1)} - \overline{\text{err}}}{\hat{\gamma} - \overline{\text{err}}} \quad (15.54)$$

$\hat{R}$ 从 0 (无过拟合) 到 1 (过拟合最严重)。 $.632+$ 估计为:

$$\widehat{\text{Err}}^{(.632+)} = (1 - \hat{w}) \cdot \overline{\text{err}} + \hat{w} \cdot \widehat{\text{Err}}^{(1)}, \quad \hat{w} = \frac{.632}{1 - .368\hat{R}} \quad (15.55)$$

权重 $\hat{w}$ 从 .632 (无过拟合) 到 1 (严重过拟合), 使 .632+ 在 .632 估计和留一 Bootstrap 之间自适应插值。

15.11.3 示例: CV 与 Bootstrap 比较




FIGURE 7.13. Boxplots show the distribution of the relative error $100 \cdot [\text{Err}_{\hat{\alpha}} - \min_{\alpha} \text{Err}(\alpha)] / [\max_{\alpha} \text{Err}(\alpha) - \min_{\alpha} \text{Err}(\alpha)]$ over the four scenarios of Figure 7.3. This is the error in using the chosen model relative to the best model. There are 100 training sets represented in each boxplot.

图 15.10: 箱线图展示四个场景 (图 7.3) 下相对误差 $100 \cdot [\text{Err}_{\hat{\alpha}} - \min_{\alpha} \text{Err}(\alpha)] / [\max_{\alpha} \text{Err}(\alpha) - \min_{\alpha} \text{Err}(\alpha)]$ 的分布——即所选模型相对于最佳模型的误差百分比。每个箱线图代表 100 个训练集。上部为 10 折 CV, 下部为 .632+ Bootstrap。

箱线图读法：每个箱子代表一种场景（如「reg/KNN」即回归 + KNN）下 100 个训练集的相对误差分布。箱子中间的粗线为中位数，箱体上下沿为第 25 和 75 百分位（即中间 50% 数据的范围），延伸出的须线（whisker）达到约 $\pm 1.5 \times$ 四分位距内的最远点，须线外的空心点为离群值。纵轴「% Increase Over Best」表示：若最佳模型误差为 0.20，所选模型误差为 0.22，则相对误差为 $100 \times (0.22 - 0.20) / (\max - \min)$ 。数字越小说明选出的模型越接近最优。

从图中可见，CV 和 Bootstrap 在所有四个场景中整体良好，与 AIC（图 7.7）相比略优或持平。对模型选择目的，任一度量的偏差不影响相对排序。

然而作为**绝对误差估计**，AIC 平均高估 30%–51%，而 CV 仅高估 0%–4%，Bootstrap 与之相当。因此若需要准确的测试误差估计值，CV 或 Bootstrap 的额外计算代价是值得的。

注意对树等自适应方法，CV 和 Bootstrap 可低估真实误差约 10%（因为最优树的搜索受验证集影响强烈），此时只有独立测试集能提供无偏估计。

15.12 条件误差还是期望误差？

CV 到底估计的是 Err_T （条件误差）还是 Err （期望误差）？图 7.14 和图 7.15 给出了答案。

图 7.14 的仿真表明：10 折 CV 对 Err 的估计优于对 Err_T 的估计——10 折 CV 的黑曲线与 Err （红色）几乎重合，而与各 Err_T 的偏差更大。N 折（LOO）CV 的表现类似。

图 7.15 更揭示了惊人事实：CV 误差与条件误差 Err_T 之间的相关性往往是**负的**——CV 低的训练集反而可能泛化差。

结论：仅凭一份训练集自身的数据，通常难以估计该特定训练集的条件测试误差。CV 和相关方法能合理估计的是**期望误差** Err 。这一现象对 Bootstrap 误差估计同样成立。

简言之：CV 告诉我们「这个方法平均有多好」，而非「这一份数据训练的模型有多好」。从实践角度看这通常已足够——我们更关心方法的整体表现，而非某一次抽样的运气。

15.13 本章小结

15.13.1 核心框架




图 15.13: 第 7 章核心框架：四种误差量、两大目标、各类方法的对应关系。 C_p /AIC/BIC 估计样本内误差 Err_{in} ，常用于模型选择（只需相对比较）；CV/Bootstrap 直接估计期望误差 Err ，既可用于模型选择（计算代价更高但更通用），也可用于模型评估（需绝对值）。

15.13.2 方法选用指南




图 15.14: 模型评估与选择方法的选用决策树。选模型：线性 + 平方误差用 C_p ，否则 AIC/BIC（CV 也可但更慢）；评估：首选 CV，小样本或需精校用 .632+ Bootstrap。核心： C_p /AIC/BIC 估计 Err_{in} 用于比大小；CV/Bootstrap 直接估计 Err 可得绝对值，但所有方法估计的都是期望误差 Err 而非条件误差 $\text{Err}_{\mathcal{T}}$ 。

记忆要点： $C_p = \overline{\text{err}} + 2 \cdot \frac{d}{N} \hat{\sigma}_\epsilon^2$ （线性 + 平方误差） $\text{AIC} = -2\log\text{lik}/N + 2d/N$ （一般似然，渐近） $\text{BIC} = -2\log\text{lik} + d\log N$ （重罚，渐近一致）。CV 直接估计 Err，最通用，误差估计最准（高估 0–4% vs AIC 高估 30–50%）。**关键局限：**所有方法估计的都是期望误差 Err，无法仅凭一份训练集估计该特定训练集的条件误差 $\text{Err}_{\mathcal{T}}$ 。

15.13.3 关键结论

1. **偏差-方差权衡**是模型选择的根基：复杂模型偏差低但方差高，最优复杂度在两者之间。
2. $\overline{\text{err}}$ 是唯一可算的，但它系统性偏低——所有方法本质上都是 $\widehat{\text{Err}} = \overline{\text{err}} + \hat{\omega}$ 。
3. **解析准则** (C_p , AIC, BIC) 估计 Err_{in} ，适合模型选择，计算快但只适用于参数可数的模型。AIC 渐近选复杂模型，BIC 渐近一致。
4. **重抽样方法** (CV, Bootstrap) 直接估计 Err，适用任何模型和损失函数，但计算量大。CV 的正确做法是包裹整个建模流程。
5. **关键局限：**所有方法估计的都是 Err（期望误差），而非 $\text{Err}_{\mathcal{T}}$ （你手头这份训练集的条件误差）。独立的测试集是获得无偏 $\text{Err}_{\mathcal{T}}$ 估计的唯一途径。




FIGURE 7.14. Conditional prediction-error $\text{Err}_{\mathcal{T}}$, 10-fold cross-validation, and leave-one-out cross-validation curves for a 100 simulations from the top-right panel in Figure 7.3. The thick red curve is the expected prediction error Err , while the thick black curves are the expected CV curves $\mathbb{E}_{\mathcal{T}}\text{CV}_{10}$ and $\mathbb{E}_{\mathcal{T}}\text{CV}_N$. The lower-right panel shows the mean absolute deviation of the CV curves from the conditional error, $\mathbb{E}_{\mathcal{T}}|\text{CV}_K - \text{Err}_{\mathcal{T}}|$ for $K = 10$ (blue) and $K = N$ (green), as well as from the expected error $\mathbb{E}_{\mathcal{T}}|\text{CV}_{10} - \text{Err}|$ (orange).

图 15.11: 在图 7.3 右上场景的 100 次模拟中, 条件预测误差 $\text{Err}_{\mathcal{T}}$ 、10 折 CV 和留一 CV 曲线。粗红线为期望预测误差 Err , 粗黑线为期望 CV 曲线 $\mathbb{E}_{\mathcal{T}}\text{CV}_{10}$ 和 $\mathbb{E}_{\mathcal{T}}\text{CV}_N$ 。右下面板展示 CV 曲线与条件误差的平均绝对偏差 $\mathbb{E}_{\mathcal{T}}|\text{CV}_K - \text{Err}_{\mathcal{T}}|$ ($K = 10$ 蓝色, $K = N$ 绿色), 以及与期望误差的偏差 $\mathbb{E}_{\mathcal{T}}|\text{CV}_{10} - \text{Err}|$ (橙色)。




FIGURE 7.15. Plots of the CV estimates of error versus the true conditional error for each of the 100 training sets, for the simulation setup in the top right panel Figure 7.3. Both 10-fold and leave-one-out CV are depicted in different colors. The first three panels correspond to different subset sizes p , and vertical and horizontal lines are drawn at $\text{Err}(p)$. Although there appears to be little correlation in these plots, we see in the lower right panel that for the most part the correlation is negative.

图 15.12: CV 误差估计值与真实条件误差的散点图 (100 个训练集, 图 7.3 右上场景)。10 折 CV (蓝色) 和留一 CV (绿色) 分别展示。前三面板对应不同子集大小 p , 水平和垂直线标于 $\text{Err}(p)$ 处。图中散点几乎无相关性; 右下面板显示大部分情形下相关性为负。

第十六章 模型推断与平均

16.1 引言

此前章节中，模型拟合（学习）通过最小化平方和（回归）或交叉熵（分类）来实现。这些最小化本质上都是最大似然估计的特例。

本章将系统介绍最大似然方法和贝叶斯推断方法，并讨论 Bootstrap 在这两种框架下的角色。最后介绍模型平均与改进的相关技术，包括委员会方法、Bagging、Stacking 和 Bumping。

16.2 Bootstrap 与最大似然方法

16.2.1 一个光滑示例

Bootstrap 提供了一种直接的计算方式，通过从训练数据中抽样来评估不确定性。这里以一个一维光滑问题为例，展示其与最大似然的联系。

数据与模型：训练数据 $\mathbf{Z} = \{z_1, \dots, z_N\}$, $z_i = (x_i, y_i)$, x_i 为一维输入， y_i 为响应。考虑 $N = 50$ 的数据点（图 8.1 左面板）。用三次样条拟合，在 X 的四分位处放置三个结点，构成 7 维 B-样条基函数空间（图 8.1 右面板）：

$$\mu(x) = \sum_{j=1}^7 \beta_j h_j(x) \quad (16.1)$$

令 $\mathbf{H}$ 为 $N \times 7$ 矩阵， $h_{ij} = h_j(x_i)$ 。最小二乘估计为：

$$\hat{\boldsymbol{\beta}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y} \quad (16.2)$$

$\hat{\boldsymbol{\beta}}$ 的估计协方差矩阵为：

$$\widehat{\text{Var}}(\hat{\boldsymbol{\beta}}) = (\mathbf{H}^T \mathbf{H})^{-1} \hat{\sigma}^2 \quad (16.3)$$

其中 $\hat{\sigma}^2 = \sum_{i=1}^N (y_i - \hat{\mu}(x_i))^2 / N$ 。预测 $\hat{\mu}(x) = \mathbf{h}(x)^T \hat{\boldsymbol{\beta}}$ 的标准误差为：

$$\widehat{\text{se}}[\hat{\mu}(x)] = [\mathbf{h}(x)^T (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{h}(x)]^{1/2} \hat{\sigma} \quad (16.4)$$

右上展示了 $\hat{\mu}(x) \pm 1.96 \cdot \widehat{\text{se}}$ 的逐点 95% 置信带。




FIGURE 8.1. (Left panel): Data for smoothing example. (Right panel:) Set of seven B-spline basis functions. The broken vertical lines indicate the placement of the three knots.

图 16.1: (左) 光滑示例的数据。(右) 七个 B-样条基函数。竖直虚线指示三个结点的位置。

Bootstrap 做法: 从训练数据中有放回地抽取 B 个大小为 $N = 50$ 的数据集, 抽样单位为 (x_i, y_i) 对。对每个 Bootstrap 数据集拟合三次样条 $\hat{\mu}^*(x)$ 。图 8.2 左下展示了 10 次 Bootstrap 光滑, 右下为由 $B = 200$ 次 Bootstrap 的分位数构造的 95% 置信带——与最小二乘置信带相似, 在端点处略宽。

16.2.2 非参数 Bootstrap 与参数 Bootstrap

上述直接从数据中有放回重抽样的做法称为**非参数 Bootstrap** (nonparametric bootstrap), 它是「无模型」的——只用原始数据本身生成新数据集, 不依赖特定的参数模型。

若假设模型误差为高斯:

$$Y = \mu(X) + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2), \quad \mu(x) = \sum_{j=1}^7 \beta_j h_j(x) \quad (16.5)$$

则可使用**参数 Bootstrap** (parametric bootstrap): 向拟合值添加高斯噪声模拟新响应

$$y_i^* = \hat{\mu}(x_i) + \varepsilon_i^*, \quad \varepsilon_i^* \sim N(0, \hat{\sigma}^2), \quad i = 1, \dots, N \quad (16.6)$$

重复 B 次, 重新拟合 B-样条光滑。参数 Bootstrap 给出的置信带与最小二乘置信带**精确一致**——因为高斯误差的可加性。




FIGURE 8.2. (Top left:) B-spline smooth of data. (Top right:) B-spline smooth plus and minus $1.96 \times$ standard error bands. (Bottom left:) Ten bootstrap replicates of the B-spline smooth. (Bottom right:) B-spline smooth with 95% standard error bands computed from the bootstrap distribution.

图 16.2: (左上) 数据的 B-样条光滑。(右上) B-样条光滑 $\pm 1.96 \times$ 标准误差带。(左下) B-样条光滑的 10 次 Bootstrap 重复。(右下) 由 Bootstrap 分布构造的 95% 标准误差带。

16.2.3 最大似然推断

基本定义

设观测的密度函数（或概率质量函数）为 $z_i \sim g_\theta(z)$ ，其中 θ 为未知参数。似然函数定义为：

$$L(\theta; \mathbf{Z}) = \prod_{i=1}^N g_\theta(z_i) \quad (16.7)$$

对数似然（log-likelihood）为：

$$\ell(\theta; \mathbf{Z}) = \sum_{i=1}^N \log g_\theta(z_i) = \sum_{i=1}^N \ell(\theta; z_i) \quad (16.8)$$

最大似然估计（MLE） $\hat{\theta}$ 使 $\ell(\theta; \mathbf{Z})$ 最大化。

得分函数（score function）：

$$\dot{\ell}(\theta; \mathbf{Z}) = \sum_{i=1}^N \dot{\ell}(\theta; z_i), \quad \dot{\ell}(\theta; z_i) = \frac{\partial \ell(\theta; z_i)}{\partial \theta} \quad (16.9)$$

信息矩阵（information matrix）：

$$\mathbf{I}(\theta) = - \sum_{i=1}^N \frac{\partial^2 \ell(\theta; z_i)}{\partial \theta \partial \theta^T} \quad (16.10)$$

在 $\hat{\theta}$ 处取值时称为观测信息（observed information）。Fisher 信息（期望信息）为 $\mathbf{i}(\theta) = \mathbb{E}_\theta[\mathbf{I}(\theta)]$ 。

MLE 属于频率学派框架：参数 θ 是固定但未知的常数，数据是随机的；推断依赖「重复抽样下估计量的行为」。与之对照，贝叶斯学派将 θ 视为随机变量，用先验 $\Pr(\theta)$ 表达初始不确定性，数据固定后通过贝叶斯公式更新为后验 $\Pr(\theta | \mathbf{Z})$ 。频率学派给出置信区间（「若重复实验，95% 的区间会覆盖 θ 」），贝叶斯给出可信区间（「 θ 有 95% 概率在此区间」）。

实践中真的知道分布族吗？常不知道确切形式，但有合理理由假设：计数数据 $\rightarrow$ Poisson，二元结果 $\rightarrow$ Bernoulli，大样本独立和 $\rightarrow$ 近似正态（CLT）。有时为了数学可行性而假设（如回归中的高斯误差）。当不愿假设分布时，非参数 Bootstrap 是替代方案——直接从数据重抽样，不指定 g_θ 。这也是 §8.2 将 Bootstrap 和 MLE 放在同一章的原因。

MLE 框架的完整定义体系

除已给出的基本定义外，MLE 框架还包括以下核心概念：

- 一致性（Consistency）： $\hat{\theta} \xrightarrow{P} \theta_0$ ($N \rightarrow \infty$)，样本越大估计越准。

- **渐近有效性 (Asymptotic efficiency)**: $N \rightarrow \infty$ 时 MLE 达到 Cramér-Rao 下界 (见下文详述), 在所有渐近无偏估计中方差最小。
- **不变性 (Invariance)**: 若 $\hat{\theta}$ 是 θ 的 MLE, 则 $g(\hat{\theta})$ 是 $g(\theta)$ 的 MLE。
- **Delta 方法**: 用于求 $g(\hat{\theta})$ 的渐近分布: $\sqrt{N}(g(\hat{\theta}) - g(\theta_0)) \xrightarrow{d} N(0, g'(\theta_0)^2 / \mathbf{i}(\theta_0))$ 。
- **似然比检验 (LRT)**: $2[\ell(\hat{\theta}) - \ell(\theta_0)] \xrightarrow{d} \chi_p^2$, 即式 (16.19)。
- **Wald 检验**: 直接用 $\hat{\theta}$ 的渐近正态性检验 $H_0: \theta = \theta_0$ 。
- **得分检验 (Rao)**: 仅需在原假设下拟合模型, 计算量最小。
- **剖面似然 (Profile likelihood)**: 处理多余参数——对不感兴趣的参数取最大化后留轮廓。
- **指数族**: GLM 的基础, 似然标准形式为 $\exp\{[y\theta - b(\theta)]/a(\phi) + c(y, \phi)\}$ 。

LRT、Wald、得分检验合称 MLE 框架的「三大检验」。




图 16.3: MLE 框架的完整定义体系。自上而下: 数据 + 模型 $\rightarrow$ 似然 $\rightarrow$ 对数似然 $\rightarrow$ 得分 $\rightarrow$ MLE; 左下: 大样本性质 (一致性、有效性、渐近正态、不变性); 右下: 三大检验 (LRT、Wald、得分); 底部: 扩展工具 (Delta 方法、剖面似然、指数族)。

Cramér-Rao 下界

Cramér-Rao 下界 (CRLB) 给出了所有无偏估计量方差的下限, 是 Fisher 信息最核心的应用。设 $T(\mathbf{Z})$ 是 θ 的任意无偏估计量 ($\mathbb{E}_\theta[T] = \theta$), 在正则条件下:

$$\text{Var}_\theta(T) \geq \frac{1}{\mathbf{i}(\theta)} \quad (16.11)$$

其中 $\mathbf{i}(\theta) = \mathbb{E}_\theta[(\frac{\partial}{\partial \theta} \log g_\theta(Z))^2]$ 是 Fisher 信息 (单参数情形)。

多参数推广: 对 $\theta \in \mathbb{R}^p$, 无偏估计量 $\mathbf{T}$ 的协方差矩阵满足 $\text{Cov}_\theta(\mathbf{T}) \succeq \mathbf{i}(\theta)^{-1}$ (矩阵差为半正定), 各分量方差 $\text{Var}_\theta(T_j) \geq [\mathbf{i}(\theta)^{-1}]_{jj}$ 。

三种理解角度:

1. **参数估计精度的理论上限**— $\mathbf{i}(\theta)$ 越大, CRLB 越低, 参数能被估计得越精确。MLE 渐近达到此下界 (渐近有效性), 这就是为什么 MLE 在理论上是最优的。
2. **得分函数的方差 (基础定义)**— $\mathbf{i}(\theta) = \text{Var}_\theta[\dot{\ell}(\theta; Z)]$ 。得分函数衡量「数据对参数的敏感度」: 数据轻微变化, 得分剧烈波动 $\rightarrow$ 方差大 $\rightarrow$ 信息多 $\rightarrow$ 下界低。若不管数据怎么变得分几乎不动 $\rightarrow$ 信息少 $\rightarrow$ 参数难以估计。
3. **区分邻近参数的能力 (KL 散度视角)**—两个邻近参数 θ 和 $\theta + d\theta$ 对应分布的 KL 散度展开为 $\text{KL}(g_\theta \parallel g_{\theta+d\theta}) \approx \frac{1}{2}\mathbf{i}(\theta)(d\theta)^2$ 。Fisher 信息大 $\rightarrow$ 邻近参数对应分布差异大 $\rightarrow$ 容易区分 $\rightarrow$ 可精确估计。Fisher 信息小 $\rightarrow$ 参数变化几乎不影响分布 $\rightarrow$ 不可识别。

与观测信息的区别: 观测信息 $\mathbf{I}(\hat{\theta})$ 和 Fisher 信息 $\mathbf{i}(\hat{\theta})$ 在大样本下等价, 均可用于构造标准误差。实践中 $\mathbf{I}(\hat{\theta})$ 更常用——它只需在 MLE 处计算二阶导数, 无需对 g_θ 积分。

正则条件与推导

CRLB 的成立需要以下正则条件 (regularity conditions):

1. **支撑集与 θ 无关:** $\{z : g_\theta(z) > 0\}$ 不依赖于 θ 。这排除了均匀分布 $U(0, \theta)$ 等边界随参数移动的情形。
2. **可微性:** $g_\theta(z)$ 对 θ 可微, 且积分和求导可交换次序:

$$\frac{\partial}{\partial \theta} \int g_\theta(z) dz = \int \frac{\partial}{\partial \theta} g_\theta(z) dz = 0 \quad (16.12)$$

3. **得分函数零均值:** 由条件 2 立即得到 $\mathbb{E}_\theta[\dot{\ell}(\theta; Z)] = 0$ 。
4. **Fisher 信息有限且正定:** $0 < \mathbf{i}(\theta) < \infty$ 。

推导 (单参数情形): 设 $T = T(\mathbf{Z})$ 为 θ 的任意无偏估计量, $\mathbb{E}_\theta[T] = \theta$ 。

由无偏性 $\int T(\mathbf{z}) g_\theta(\mathbf{z}) d\mathbf{z} = \theta$, 两边对 θ 求导:

$$\int T(\mathbf{z}) \frac{\partial g_\theta(\mathbf{z})}{\partial \theta} d\mathbf{z} = 1 \quad (16.13)$$

利用 $\frac{\partial g_\theta}{\partial \theta} = g_\theta \cdot \frac{\partial \log g_\theta}{\partial \theta} = g_\theta \cdot \dot{\ell}(\theta)$, 代入得:

$$\int T(\mathbf{z}) \dot{\ell}(\theta; \mathbf{z}) g_\theta(\mathbf{z}) d\mathbf{z} = \mathbb{E}_\theta[T \cdot \dot{\ell}] = 1 \quad (16.14)$$

又 $\mathbb{E}_\theta[\dot{\ell}] = 0$, 故 $\text{Cov}_\theta(T, \dot{\ell}) = \mathbb{E}_\theta[T \cdot \dot{\ell}] - \mathbb{E}_\theta[T] \cdot \mathbb{E}_\theta[\dot{\ell}] = 1$ 。

由 Cauchy-Schwarz 不等式:

$$1 = \text{Cov}_\theta(T, \dot{\ell})^2 \leq \text{Var}_\theta(T) \cdot \text{Var}_\theta(\dot{\ell}) = \text{Var}_\theta(T) \cdot \mathbf{i}(\theta) \quad (16.15)$$

移项即得:

$$\boxed{\text{Var}_\theta(T) \geq \frac{1}{\mathbf{i}(\theta)}} \quad (16.16)$$

取等条件: 当且仅当 T 和 $\dot{\ell}$ 线性相关, 即 $\dot{\ell}(\theta) = a(\theta)(T - \theta)$ 时等号成立。这意味着分布族必须是指数族且 T 是充分统计量——这正是 MLE 渐近达到下界的深层原因。

直观小结: CRLB 的推导核心只有三步: 无偏性 $\rightarrow$ 协方差为 1 $\rightarrow$ Cauchy-Schwarz 放缩。Fisher 信息出现在分母是因为它恰好是得分函数的方差。

三个完整示例

例 1: Bernoulli 试验 (p 未知)。 N 次独立抛硬币, 观测 $y_i \in \{0, 1\}, Y_i \sim \text{Bernoulli}(p)$ 。

- **模型:** $g_p(y) = p^y(1-p)^{1-y}$
- **对数似然:** $\ell(p) = \sum y_i \log p + \sum (1-y_i) \log(1-p) = N\bar{y} \log p + N(1-\bar{y}) \log(1-p)$
- **得分 (找 MLE):** $\dot{\ell}(p) = \frac{N\bar{y}}{p} - \frac{N(1-\bar{y})}{1-p} = 0 \Rightarrow \hat{p} = \bar{y}$ (样本均值)
- **信息 (算 SE):** $\mathbf{I}(\hat{p}) = -\ddot{\ell}(\hat{p}) = \frac{N}{\hat{p}(1-\hat{p})}$, 故 $\widehat{\text{se}}(\hat{p}) = \sqrt{\hat{p}(1-\hat{p})/N}$
- **CI (表达不确定性):** $\hat{p} \pm 1.96 \sqrt{\frac{\hat{p}(1-\hat{p})}{N}}$

数值演示: $N = 100$ 次抛硬币, 58 次正面。

- **MLE:** $\hat{p} = 58/100 = 0.58$
- **SE:** $\widehat{\text{se}} = \sqrt{0.58 \times 0.42/100} = 0.049$
- **95% CI:** $0.58 \pm 1.96 \times 0.049 = [0.484, 0.676]$

结论：硬币正面概率的 MLE 为 0.58，标准误差 0.049（基于 100 次观测的信息量）。95% 置信区间 $[0.484, 0.676]$ 包含 0.5——因此 58 次正面并不构成硬币不公平的充分证据（在 95% 置信水平下不能拒绝 $p = 0.5$ ）。这里得分求出了点估计，信息量化了精度（ $SE=0.049$ 意味着要检测出 0.08 的偏差，大约需要 $1.96 \times 0.049 < 0.08 \rightarrow N$ 不足），CI 把精度翻译为可读的区间。

例 2：高斯分布（ μ 未知， σ^2 已知）。 $Y_i \stackrel{\text{iid}}{\sim} N(\mu, \sigma_0^2)$ ， σ_0^2 已知。

- 对数似然： $\ell(\mu) = -\frac{N}{2} \log(2\pi\sigma_0^2) - \frac{1}{2\sigma_0^2} \sum (y_i - \mu)^2$
- 得分（找 MLE）： $\dot{\ell}(\mu) = \frac{1}{\sigma_0^2} \sum (y_i - \mu) = 0 \Rightarrow \hat{\mu} = \bar{y}$
- Fisher 信息（算 SE）： $\mathbf{i}(\mu) = -\mathbb{E}[\ddot{\ell}(\mu)] = N/\sigma_0^2$ ， $\widehat{\text{se}}(\hat{\mu}) = \sigma_0/\sqrt{N}$
- CI（表达不确定性）： $\bar{y} \pm 1.96 \sigma_0/\sqrt{N}$

数值演示：测量某零件长度 25 次，已知仪器精度 $\sigma_0 = 0.2$ mm， $\bar{y} = 10.3$ mm。

- MLE： $\hat{\mu} = 10.3$
- SE： $\widehat{\text{se}} = 0.2/\sqrt{25} = 0.04$
- 95% CI： $10.3 \pm 1.96 \times 0.04 = [10.22, 10.38]$

结论：零件平均长度为 10.3 mm，标准误差 0.04 mm（25 次测量 + 已知精度提供了足够信息）。95% CI $[10.22, 10.38]$ 很窄，说明估计相当精确。如果规格要求为 10.0 mm，则 CI 不包含 10.0——有明显偏差。这里 σ_0 已知使得信息可以直接写为 N/σ_0^2 ，不需要从数据估计。

例 3：高斯分布（ μ 和 σ^2 均未知）。 $Y_i \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$ ， $\theta = (\mu, \sigma^2)$ 。

- 对数似然： $\ell(\mu, \sigma^2) = -\frac{N}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum (y_i - \mu)^2$ （略去常数项）
- 得分方程组（联合求解）： $\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum (y_i - \mu) = 0$ ， $\frac{\partial \ell}{\partial \sigma^2} = -\frac{N}{2\sigma^2} + \frac{1}{2\sigma^4} \sum (y_i - \mu)^2 = 0$
- MLE： $\hat{\mu} = \bar{y}$ ， $\hat{\sigma}^2 = \frac{1}{N} \sum (y_i - \bar{y})^2$ （分母为 N ，非 $N-1$ ——MLE 不校正自由度）
- 观测信息矩阵：块对角（ μ 和 σ^2 在 MLE 处信息正交）， $\mathbf{I}_{11} = N/\hat{\sigma}^2$ ， $\mathbf{I}_{22} = N/(2\hat{\sigma}^4)$
- SE： $\widehat{\text{se}}(\hat{\mu}) = \hat{\sigma}/\sqrt{N}$ ， $\widehat{\text{se}}(\hat{\sigma}^2) = \hat{\sigma}^2\sqrt{2/N}$
- CI for μ ：由于 σ^2 未知，实际用 t 分布： $\bar{y} \pm t_{N-1, 0.975} \cdot s/\sqrt{N}$ （ s 为样本标准差 $s^2 = \sum (y_i - \bar{y})^2/(N-1)$ ）；大样本下近似于 $\bar{y} \pm 1.96 \cdot \hat{\sigma}/\sqrt{N}$

数值演示：测量 16 次， $\bar{y} = 10.3$ ， $s = 0.5$ ， $\hat{\sigma} = 0.484$ 。

- MLE： $\hat{\mu} = 10.3$ ， $\hat{\sigma}^2 = 0.234$

- **SE:** $\widehat{\text{se}}(\hat{\mu}) = 0.484/\sqrt{16} = 0.121$, $\widehat{\text{se}}(\hat{\sigma}^2) = 0.234 \times \sqrt{2/16} = 0.083$
- **95% CI for μ :** $10.3 \pm 2.131 \times 0.125 = [10.03, 10.57]$ (用 $t_{15,0.975} = 2.131$ 和 $s/\sqrt{16} = 0.125$); 大样本近似: $10.3 \pm 1.96 \times 0.121 = [10.06, 10.54]$
- **95% CI for σ^2 :** 基于卡方近似 $[\hat{\sigma}^2 \cdot \chi_{15,0.025}^2/15, \hat{\sigma}^2 \cdot \chi_{15,0.975}^2/15] = [0.128, 0.519]$

结论: 当 σ^2 未知时, μ 的 SE 变大了 (0.121 vs 例 2 的 0.04) ——多估计一个参数消耗了信息。信息矩阵的块对角性意味着 μ 和 σ^2 的 MLE 渐近不相关, 可以分别推断。 $\hat{\sigma}^2$ 的 MLE 有有限样本偏差 ($\mathbb{E}[\hat{\sigma}^2] = \frac{15}{16}\sigma^2$), 但 $N = 16$ 时偏差已很小, 且渐近性质优良——这是 MLE 的典型特征。

渐近正态性

经典结果: 当 $N \rightarrow \infty$ 时, MLE 的抽样分布趋于正态:

$$\hat{\theta} \rightarrow N(\theta_0, \mathbf{i}(\theta_0)^{-1}) \quad (16.17)$$

其中 θ_0 为真实参数值。实践中用以下近似:

$$\hat{\theta} \sim N(\hat{\theta}, \mathbf{i}(\hat{\theta})^{-1}) \text{ 或 } N(\hat{\theta}, \mathbf{I}(\hat{\theta})^{-1}) \quad (16.18)$$

标准误差的估计为 $\sqrt{\mathbf{i}(\hat{\theta})_{jj}^{-1}}$ 或 $\sqrt{\mathbf{I}(\hat{\theta})_{jj}^{-1}}$ 。置信区间形如 $\hat{\theta}_j \pm z^{(1-\alpha)} \cdot \widehat{\text{se}}$ 。也可直接利用似然函数构造更精确的置信区域——利用卡方近似:

$$2[\ell(\hat{\theta}) - \ell(\theta_0)] \sim \chi_p^2 \quad (16.19)$$

光滑示例的最大似然解

在光滑示例中, $\theta = (\beta, \sigma^2)$, 对数似然为:

$$\ell(\theta) = -\frac{N}{2} \log \sigma^2 2\pi - \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \mathbf{h}(x_i)^T \beta)^2 \quad (16.20)$$

MLE 解与最小二乘一致, β 的信息矩阵块为 $\mathbf{I}(\beta) = \mathbf{H}^T \mathbf{H} / \sigma^2$, 方差估计 $\widehat{\text{Var}}(\hat{\beta}) = (\mathbf{H}^T \mathbf{H})^{-1} \hat{\sigma}^2$ 与 (8.3) 一致。

16.2.4 Bootstrap 与最大似然的比较

Bootstrap 本质上是非参数或参数最大似然的计算机实现。其优势在于: 当解析公式不可得时, Bootstrap 仍能计算标准误差和其他量。

例如, 若结点数量和位置 λ 通过交叉验证自适应选择, 则标准误差和置信带应反映 λ 的变异性——解析上无法处理, 但 Bootstrap 可以在每轮重抽样中自适应选择 λ , 从而捕捉这种额外的不确定性。在多数使用更多自适应的实际问题中, 这一效应非常重要。

16.3 贝叶斯方法

16.3.1 基本框架

贝叶斯推断包含三个要素：

1. 抽样模型 $\Pr(\mathbf{Z} \mid \theta)$ ：给定参数下数据的分布
2. 先验分布 $\Pr(\theta)$ ：见到数据前对 θ 的了解
3. 后验分布：见到数据后对 θ 的更新认知

$$\Pr(\theta \mid \mathbf{Z}) = \frac{\Pr(\mathbf{Z} \mid \theta) \cdot \Pr(\theta)}{\int \Pr(\mathbf{Z} \mid \theta) \cdot \Pr(\theta) d\theta} \quad (16.21)$$


不确定性更新视角：公式中三个角色分工明确——**先验是起点**（数据前的信念），**似是更新器**（数据如何修改信念），**后验是终点**（更新后的信念）。后验通常比先验更集中（数据提供了信息），但除非数据无穷，否则不确定性不会归零。

与频率学派的分歧在“谁随机”：频率学派认为参数 θ 固定未知、**数据随机**（依赖重复抽样视角）；贝叶斯认为数据已实现、固定不变，**参数随机**（有分布）。同样“给定数据做推断”，两派眼中的随机性归属完全相反。

预测分布给出未来观测 z^{new} 的预测：

$$\Pr(z^{\text{new}} \mid \mathbf{Z}) = \int \Pr(z^{\text{new}} \mid \theta) \cdot \Pr(\theta \mid \mathbf{Z}) d\theta \quad (16.22)$$

这比最大似然插值式预测 $\Pr(z^{\text{new}} \mid \hat{\theta})$ 更合理——后者未考虑 θ 估计的不确定性。



先验知识错了会怎样？需区分“错在哪”：

- 先验的支撑不含真值（如真实 $\theta = 5$ ，先验只在 $[0, 1]$ 上有质量）：后验永远无法接近真值——真实 θ 处 $\Pr(\mathbf{Z} | \theta) \Pr(\theta) = 0$ ，数据再多也救不回来，先验“不可反驳”地错。
- 先验形状偏了但支撑包含真值（如真实 $\theta = 5$ ，先验集中在 3 附近）：数据足够多时，似然项越来越尖锐地压在真值附近，逐渐“淹没”先验（Bernstein–von Mises 定理），后验收敛到真值；但小样本下错误先验会显著带偏结论。

因此实践中倾向选无信息/扩散先验作为保守默认，并做敏感性分析（换几个先验看结论是否稳健）。频率学派“无先验”看似回避了此问题，代价是数据前无法融入知识、不确定性无法表达为概率——它只是把模型假设藏了起来，并非没有假设。

我们控制什么？目的是什么？贝叶斯中真正可控的是先验（最自由的建模选择）与模型/似然（分布族假设）；数据 $\mathbf{Z}$ 已实现、真实 θ 未知，均不可控。一旦选定先验与似然，后验就被贝叶斯公式唯一确定——贝叶斯里没有“最大化”（与 MLE 的优化不同），只有“乘起来、归一化”。目的分三层：推断（由后验回答 θ 的合理取值与不确定性）、预测（用后验做 $\Pr(z^{\text{new}} | \mathbf{Z})$ ）、决策（在期望损失意义下做最优决策、模型平均/选择，见 §8.8）。一句话：贝叶斯是概率论的“推理引擎”——输入先验、似然与数据，引擎内部按贝叶斯公式唯一运转，输出后验、预测与决策。

16.3.2 光滑示例的贝叶斯分析

在光滑示例中，假设模型 (8.5) 且 σ^2 已知。对 β 取高斯先验：

$$\beta \sim N(\mathbf{0}, \tau) \quad (16.23)$$

τ 控制先验的强度， τ 控制相关性结构。

后验分布也为高斯，均值和协方差为：

$$\begin{aligned} \mathbb{E}(\beta | \mathbf{Z}) &= \left(\mathbf{H}^T \mathbf{H} + \frac{\sigma^2}{\tau} \mathbf{I} \right)^{-1} \mathbf{H}^T \mathbf{y} \\ \text{Cov}(\beta | \mathbf{Z}) &= \left(\mathbf{H}^T \mathbf{H} + \frac{\sigma^2}{\tau} \mathbf{I} \right)^{-1} \sigma^2 \end{aligned} \quad (16.24)$$

$\mu(x)$ 的后验均值和协方差为：

$$\begin{aligned} \mathbb{E}(\mu(x) | \mathbf{Z}) &= \mathbf{h}(x)^T \left(\mathbf{H}^T \mathbf{H} + \frac{\sigma^2}{\tau} \mathbf{I} \right)^{-1} \mathbf{H}^T \mathbf{y} \\ \text{Cov}[\mu(x), \mu(x') | \mathbf{Z}] &= \mathbf{h}(x)^T \left(\mathbf{H}^T \mathbf{H} + \frac{\sigma^2}{\tau} \mathbf{I} \right)^{-1} \mathbf{h}(x') \sigma^2 \end{aligned} \quad (16.25)$$

取 $\tau = \mathbf{I}$ (B-样条基已保证光滑性)。图 8.3 展示了先验分布中 $\mu(x)$ 的 10 次抽样；图 8.4 展示了后验分布的 10 次抽样，取 $\tau = 1$ 和 $\tau = 1000$ 。

关键观察：当 $\tau \rightarrow \infty$ (无信息先验) 时，后验分布 (8.27) 与 Bootstrap 分布 (8.7) 完全一致。 $\tau = 1000$ 的右面板几乎等同于图 8.2 左下的 Bootstrap 分布。而 $\tau = 1$ 时后验曲线更光滑——更强的先验平滑约束。

Bootstrap 与贝叶斯的对应：在高斯模型中使用无信息先验时，最大似然和参数 Bootstrap 与贝叶斯分析趋于一致——因为常数先验下，后验正比于似然。这一对应关系也推广到非参数情形：非参数 Bootstrap 近似于无信息贝叶斯分析。

16.3.3 Bootstrap 与贝叶斯推断的正式关系

考虑一个极简例子：单个观测 $z \sim N(\theta, 1)$ 。取先验 $\theta \sim N(0, \tau)$ ，后验为：

$$\theta | z \sim N\left(\frac{z}{1 + 1/\tau}, \frac{1}{1 + 1/\tau}\right) \quad (16.26)$$

当 $\tau \rightarrow \infty$ (无信息先验) 时， $\theta | z \sim N(z, 1)$ ——这与参数 Bootstrap 分布一致 (重抽样 $z^* \sim N(\hat{\theta} = z, 1)$ 然后估计 $\hat{\theta}^* = z^*$)。

这种对应的三个条件：

1. 选择无信息先验
2. 对数似然对数据的依赖仅通过 $\hat{\theta}$: $\ell(\theta; \mathbf{Z}) = \ell(\theta; \hat{\theta})$

3. ℓ 在 θ 和 $\hat{\theta}$ 间的对称性: $\ell(\theta; \hat{\theta}) = \ell(\hat{\theta}; \theta) + \text{const}$


条件 2 和 3 严格仅在高斯分布下成立, 但多项分布下近似成立。

多项分布下的对应: 设样本空间有 L 个类别, w_j 为真实概率, $\hat{w}_j$ 为观测比例。取对称 Dirichlet 先验 $\mathbf{w} \sim \text{Di}_L(a\mathbf{1})$, 令 $a \rightarrow 0$ 得无信息先验, 后验为 $\mathbf{w} \sim \text{Di}_L(N\hat{\mathbf{w}})$ 。Bootstrap 抽样等价于 $\mathbf{w}^* \sim \frac{1}{N}\text{Mult}(N, \hat{\mathbf{w}})$ ——与后验有相同支撑集、相同均值、几乎相同的协方差。因此 Bootstrap 分布紧密近似后验分布。

一句话: Bootstrap 是「穷人的贝叶斯后验」——通过扰动数据来近似扰动参数的贝叶斯效果, 无需显式指定先验, 也无需从后验抽样。

四种方法的统一视角

参数 Bootstrap、非参数 Bootstrap、MLE、贝叶斯四者围绕同一个核心关系:



核心链条: MLE → 需要 SE/CI → 参数 Bootstrap (假设分布) → 不愿假设分布 → 非参数 Bootstrap (直接重抽样) → 无信息先验 → 贝叶斯后验。四种方法在渐近意义下等价——都是利用数据中的信息来刻画参数的不确定性, 区别仅在于对「数据生成机制」的假设强度。

简言之: MLE 给出点估计; 需要精度时, 若知道分布族用参数 Bootstrap, 不知道用非参数 Bootstrap; 若愿意引入先验知识, 用贝叶斯。扰动数据 (Bootstrap) 和扰动参数 (贝叶斯) 在渐近意义下殊途同归。

16.3.4 Bootstrap 用法总览

Bootstrap 的三方面应用与参数/非参数分类是两个独立维度——前者回答「抽完干什么」, 后者回答「怎么抽」:

应用方面	做什么	典型例子
统计推断	估计任意统计量 $S(\mathbf{Z})$ 的 SE / CI	中位数的标准误差、AUC 差的置信区间
预测误差估计	通过重抽样估计泛化误差（第 7 章）	$\widehat{\text{Err}}^{(1)}$ 、.632、.632+
模型改进	生成多个模型后组合以降低方差	Bagging、Bumping、随机森林

参数 Bootstrap（假设 g_θ ，从 $g_{\hat{\theta}}$ 抽） $\left\{ \begin{array}{ll} \text{统计推断} & \text{如光滑示例的标准误差带} \\ \text{预测误差估计} & \text{如 BIC 框架下的误差评估} \\ \text{模型改进} & \text{Bagging 通常在参数模型下} \end{array} \right.$

非参数 Bootstrap（不假设分布，从数据直接抽） $\left\{ \begin{array}{ll} \text{统计推断} & \text{分布未知时最通用} \\ \text{预测误差估计} & \text{CV 的竞争方法} \\ \text{模型改进} & \text{随机森林的本质} \end{array} \right.$

原则：知道分布族用参数 Bootstrap（更精确），不知道用非参数 Bootstrap（更通用）。第 7 章用 Bootstrap 估计误差，第 8 章用 Bootstrap 做推断和改进——同一工具，不同目的。

16.4 EM 算法

EM 算法是简化困难最大似然问题的流行工具。基本思想：引入**隐变量**（latent variables）使似然最大化变简单，然后迭代地估计隐变量、更新参数。

16.4.1 两分量高斯混合模型

图 8.5 显示了一个双峰数据集的直方图，单一高斯无法拟合。模型设为两个高斯分布的混合：

$$Y_1 \sim N(\mu_1, \sigma_1^2), \quad Y_2 \sim N(\mu_2, \sigma_2^2)$$
$$Y = (1 - \Delta) \cdot Y_1 + \Delta \cdot Y_2, \quad \Delta \in \{0, 1\}, \Pr(\Delta = 1) = \pi$$

(16.27)

混合密度为：

$$g_Y(y) = (1 - \pi)\phi_{\theta_1}(y) + \pi\phi_{\theta_2}(y)$$

(16.28)

参数 $\theta = (\pi, \mu_1, \sigma_1^2, \mu_2, \sigma_2^2)$ 。对数似然为 $\ell(\theta; \mathbf{Z}) = \sum_{i=1}^N \log[(1 - \pi)\phi_{\theta_1}(y_i) + \pi\phi_{\theta_2}(y_i)]$ ——直接最大化困难，因为对数内有求和。

引入隐变量 Δ_i ：若知道每个 y_i 来自哪个分量，对数似然分裂为：

$$\ell_0(\theta; \mathbf{Z}, \Delta) = \sum_{i=1}^N \left[(1 - \Delta_i) \log \phi_{\theta_1}(y_i) + \Delta_i \log \phi_{\theta_2}(y_i) \right] + \sum_{i=1}^N \left[(1 - \Delta_i) \log(1 - \pi) + \Delta_i \log \pi \right] \quad (16.29)$$

此时 MLE 就是简单的分组均值和方差。但 Δ_i 未知——所以取其期望（在当前参数估计下）：

$$\hat{\gamma}_i = \mathbb{E}[\Delta_i | \theta, \mathbf{Z}] = \Pr(\Delta_i = 1 | \theta, \mathbf{Z}) = \frac{\hat{\pi} \phi_{\hat{\theta}_2}(y_i)}{(1 - \hat{\pi}) \phi_{\hat{\theta}_1}(y_i) + \hat{\pi} \phi_{\hat{\theta}_2}(y_i)} \quad (16.30)$$

$\hat{\gamma}_i$ 称为观测 i 对分量 2 的责任（responsibility）。

EM 算法（两分量高斯混合）：

1. **初始化：** $\hat{\mu}_1, \hat{\mu}_2$ 取两个随机数据点； $\hat{\sigma}_1^2 = \hat{\sigma}_2^2$ 取总体方差； $\hat{\pi} = 0.5$ 。
2. **E 步（Expectation）：** 用当前参数计算责任 $\hat{\gamma}_i$ （式 8.42）。
3. **M 步（Maximization）：** 用 $\hat{\gamma}_i$ 作为权重计算加权均值和方差，更新 $\hat{\pi} = \frac{1}{N} \sum \hat{\gamma}_i$ 。
4. 迭代至收敛。

表 8.2 展示了实际数据（20 个点）的 EM 迭代过程，约 20 次后收敛： $\hat{\mu}_1 = 4.62$ ， $\hat{\mu}_2 = 1.06$ ， $\hat{\pi} = 0.546$ 。

16.4.2 EM 算法的一般形式

一般 EM（Algorithm 8.2）：观测数据 $\mathbf{Z}$ ，隐变量 $\mathbf{Z}^m$ ，完全数据 $\mathbf{T} = (\mathbf{Z}, \mathbf{Z}^m)$ ，完全数据对数似然 $\ell_0(\theta; \mathbf{T})$ 。

1. **E 步：** 计算 $Q(\theta', \hat{\theta}^{(j)}) = \mathbb{E}[\ell_0(\theta'; \mathbf{T}) | \mathbf{Z}, \hat{\theta}^{(j)}]$
2. **M 步：** $\hat{\theta}^{(j+1)} = \arg \max_{\theta'} Q(\theta', \hat{\theta}^{(j)})$

为什么 EM 有效？设 $\ell(\theta; \mathbf{Z})$ 为观测对数似然。令 $\theta^* = \hat{\theta}^{(j)}$ 。由于：

$$\ell(\theta'; \mathbf{Z}) = Q(\theta', \theta^*) - R(\theta', \theta^*) \quad (16.31)$$

其中 R 是条件对数似然的期望。由 Jensen 不等式， $R(\theta', \theta^*) \leq R(\theta^*, \theta^*)$ ，故 θ' 使 Q 增加必使 ℓ 增加。EM 永不降低似然。

E-M 作为联合最大化： EM 也可看作交替最大化函数 $F(\theta', \tilde{P}) = \mathbb{E}_{\tilde{P}}[\ell_0(\theta'; \mathbf{T})] - \mathbb{E}_{\tilde{P}}[\log \tilde{P}(\mathbf{Z}^m)]$ 。E 步在固定 θ' 下对 $\tilde{P}$ 最大化；M 步在固定 $\tilde{P}$ 下对 θ' 最大化。图 8.7 展示了此交替过程。

注记 16.1. M 步不需要完全最大化——只需增加 Q 即可（广义 EM，GEM）。EM 也可看作 minorization 过程（见练习 8.7）。

16.5 MCMC：从后验抽样

定义贝叶斯模型后，需要从后验分布抽样以做推断。除简单模型外，这通常很困难。本节讨论马尔可夫链蒙特卡洛（MCMC）方法。

16.5.1 背景与动机：为什么需要从后验分布抽样？

「定义贝叶斯模型后，需要从后验分布抽样以做推断」这句话的完整含义，需要拆开来谈：

1. 贝叶斯建模先给出后验分布。由贝叶斯公式

$$\Pr(\theta | \mathbf{Z}) = \frac{\Pr(\mathbf{Z} | \theta) \Pr(\theta)}{\int \Pr(\mathbf{Z} | \theta) \Pr(\theta) d\theta}$$

后验综合了先验知识 $\Pr(\theta)$ 与数据信息 $\Pr(\mathbf{Z} | \theta)$ 。

2. 所有推断都归结为对后验求期望。后验均值 $\mathbb{E}[\theta | \mathbf{Z}]$ 、后验方差、预测分布 $\Pr(z^{\text{new}} | \mathbf{Z})$ 等，都可以写成某个函数 $g(\theta)$ 在后验分布下的积分 $\int g(\theta) \Pr(\theta | \mathbf{Z}) d\theta$ 。
3. 但这个积分常常算不出来。复杂模型（高维、非共轭、多模态）下，后验没有解析形式，分母（归一化常数）也无法计算。
4. 抽样替代积分（蒙特卡洛）。若能「从后验分布抽出大量样本」 $\theta^{(1)}, \dots, \theta^{(M)}$ ，则由大数定律

$$\mathbb{E}[g(\theta) | \mathbf{Z}] \approx \frac{1}{M} \sum_{t=1}^M g(\theta^{(t)})$$

完全绕开了解析积分。这就是「需要从后验分布抽样以做推断」。

5. 最后的问题：后验很难直接抽样。后验分布不标准、归一化常数未知，逆变换法等直接抽样手段不可行。MCMC 的解决办法是：构造一条马尔可夫链，使它的平稳分布恰好是目标后验，让链跑足够久，链上的状态就近似是来自后验的样本。

注记 16.2. 整个动机链条：贝叶斯模型 → 需要后验期望 → 解析积分不可行 → 蒙特卡洛（抽样求期望）→ 无法直接抽样 → 构造以目标分布为平稳分布的马尔可夫链。EM 求点估计，MCMC 求分布，二者是同一类「隐变量迭代」思想的两面。

问：这里的「推断」是什么意思？

答：「推断」（inference）就是从数据对未知量做结论，并量化这种结论的不确定性。贝叶斯框架下，数据 $\mathbf{Z}$ 与先验只给出一张「关于 θ 的分布图」——后验 $\Pr(\theta | \mathbf{Z})$ 。它本身不是答案，而是所有知识的载体；「做推断」就是从这张图里读出我们关心的具体问题的答案：

- θ 大概是多少? $\rightarrow$ 后验均值 $\mathbb{E}[\theta | \mathbf{Z}]$ (类比频率学派的点估计)
- 有多大把握? $\rightarrow$ 后验可信区间 (θ 落在区间内的概率为 95%, 类比置信区间)
- 新观测会怎样? $\rightarrow$ 预测分布 $\Pr(z^{\text{new}} | \mathbf{Z})$
- 哪个模型更合理? $\rightarrow$ 模型后验概率 $\Pr(M_m | \mathbf{Z})$

换言之: 后验是「答案库」, 推断是「查询」。MCMC 抽样的意义在于——答案库里的量都是对后验的积分, 算不出来; 抽出大量样本后, 用样本平均近似这些积分, 就能完成查询。

16.5.2 先验如何作用: 后验是「先验 $\times$ 似然」的目标分布

「后验推不出来」的准确含义: 后验的公式永远存在——它是贝叶斯公式的定义; 推不出来的不是公式, 而是数值。能否解析读出后验, 取决于共轭性:

- 共轭情形 (先验与似然是「好搭档」, 如高斯先验 $\times$ 高斯似然): 分母积分能解析算出, 后验有闭合形式 (见 §8.3 光滑示例) ——**不需要 MCMC**。
- 非共轭情形: 分母 $\int \Pr(\mathbf{Z} | \theta) \Pr(\theta) d\theta$ 算不出来, 后验的归一化常数、均值、方差、分位数全都没有解析数值。此时后验「存在但读不出来」, 才需要 MCMC 数值读出。

一个没有解析数值的简单例子: 单个观测 $Y \sim N(\theta, 1)$ (高斯似然), 但先验取 Laplace (双指数) 分布 $\theta \sim \text{Laplace}(0, b)$, 密度正比于 $e^{-|\theta|/b}$ 。共轭性被破坏, 未归一化后验为

$$\Pr(\theta | y) \propto \underbrace{\exp\left(-\frac{(y-\theta)^2}{2}\right)}_{\text{似然}} \cdot \underbrace{\exp\left(-\frac{|\theta|}{b}\right)}_{\text{先验}}$$

归一化常数 $\int \exp\left(-\frac{(y-\theta)^2}{2} - \frac{|\theta|}{b}\right) d\theta$ 没有闭合形式——即使似然是最「友善」的高斯, 一旦先验换成 Laplace, 后验便失去解析解, 只能用抽样读出。

先验如何作用 (核心): 后验正比于

$$\pi(\theta) \propto \Pr(\mathbf{Z} | \theta) \Pr(\theta) \quad (16.32)$$

MCMC 的目标分布就是这个乘积 (未归一化)。于是先验作为乘法权重直接塑造了被抽样的分布: 先验密度高的区域乘积大、被访问得多; 先验密度为 0 的区域乘积恒为 0、抽样永远不会到达 (即使似然很大)。先验从未消失, 它内建在目标分布里。

MCMC 随机游走的形式化 (Metropolis-Hastings 视角): 设 $\pi(\theta)$ 如 (16.32)。每一步 t :

1. 从提议分布 $q(\theta' | \theta^{(t)})$ 提议候选 θ'
2. 以接受概率接受:

$$\alpha(\theta^{(t)} \rightarrow \theta') = \min \left\{ 1, \frac{\pi(\theta') q(\theta^{(t)} | \theta')}{\pi(\theta^{(t)}) q(\theta' | \theta^{(t)})} \right\}$$

3. 若接受则 $\theta^{(t+1)} = \theta'$, 否则 $\theta^{(t+1)} = \theta^{(t)}$

两个关键观察:

1. 只需要未归一化的后验。接受概率中只出现密度比值 $\pi(\theta')/\pi(\theta)$, 归一化常数 $Z = \int \Pr(\theta) \Pr(\mathbf{Z} | \theta) d\theta$ 在比值中被消掉——这正是 MCMC 能工作的原因: 只需知道 $\pi \propto \text{先验} \times \text{似然}$, 而无需算出那个算不出的积分。
2. 访问频率正比于 $\pi(\theta)$ 。链达到平稳后, 在 θ 处停留的时间比例收敛到 $\pi(\theta)$, 即按正比于 $\Pr(\theta) \Pr(\mathbf{Z} | \theta)$ 的密度访问 θ 。先验的乘法权重就这样进入每一步抽样: 多访问先验支持的区域, 永不去先验否决的区域。

注记 16.3. Gibbs 采样是 Metropolis–Hastings 的一个特例: 其转移核即条件分布抽样, 接受概率恒为 1。两种方法都只依赖「先验 $\times$ 似然」这个未归一化目标, 区别仅在如何游走。

16.5.3 马尔可夫性质: 如何体现?

马尔可夫性质指: 给定「现在」, 过去与未来条件独立, 即

$$\Pr(U^{(t+1)} | U^{(t)}, U^{(t-1)}, \dots, U^{(0)}) = \Pr(U^{(t+1)} | U^{(t)})$$

一步转移只依赖当前状态, 与更早的历史无关。

在 Gibbs 采样 (Algorithm 8.3) 中, 这一性质直接体现: 生成 $U_k^{(t)}$ 时只用

$$U_1^{(t)}, \dots, U_{k-1}^{(t)}, \quad U_{k+1}^{(t-1)}, \dots, U_K^{(t-1)}$$

即只依赖「现在」的状态向量 $U^{(t-1)}$ (以及本轮已更新的分量), 不依赖 $U^{(t-2)}, U^{(t-3)}, \dots$ 。整条样本序列 $\{U^{(0)}, U^{(1)}, U^{(2)}, \dots\}$ 构成一条一阶马尔可夫链, 其行为完全由转移核 $\Pr(U' | U)$ 描述。

注记 16.4. 强调: 马尔可夫链的相邻样本不独立 (它们强烈相关), 不能直接当作独立同分布样本。但链收敛后, 从长远看访问各状态的比例收敛到目标分布——我们只需对长期的样本求平均。相关性只影响估计的效率 (需要更多样本), 不影响正确性。

16.5.4 为什么联合分布最终稳定？

分两层理解：

(1) 目标联合分布是平稳分布 (stationary / invariant distribution)。若从分布 π 出发做一次转移后分布仍为 π ，即满足细致平衡 (detailed balance)

$$\pi(U) \Pr(U' | U) = \pi(U') \Pr(U | U')$$

则 π 是平稳分布。Gibbs 采样满足这一条件，直观理由是：若当前状态 U 已服从目标联合分布 π ，那么只把其中一个分量 U_k 按其条件分布 $\Pr(U_k | U_{-k})$ 重新抽样，新向量 $(U_1, \dots, U'_k, \dots, U_K)$ 仍然服从 π ——因为「从条件分布重新抽样」保持联合分布不变。逐分量依次操作，每一步都保持 π 不变，故 π 是平稳分布。

(2) 从任意初始分布收敛到平稳分布。在正则条件 (不可约、非周期、正递归) 下，马尔可夫链理论保证：无论从哪个初始状态 $U^{(0)}$ 出发，当 $t \rightarrow \infty$ 时 $U^{(t)}$ 的分布都收敛到唯一的平稳分布。直观上，每次转移都在状态分布空间上施加一次「混合」操作，反复施加会把任何初始分布「拉」向不动点——即平稳分布。因此需要一段 burn-in (烧入) 期，丢弃开头未收敛的样本，只用收敛后的部分 (式 (16.33) 中从 m 开始平均)。

16.5.5 一个具体的 Gibbs 采样例子

用一个离散二维例子直观展示整个过程。设目标联合分布 $\pi(x, y)$ ($x, y \in \{0, 1\}$) 为：

$$\pi(0, 0) = 0.1, \quad \pi(0, 1) = 0.2, \quad \pi(1, 0) = 0.3, \quad \pi(1, 1) = 0.4$$

边际为 $\pi(x=0) = 0.3$, $\pi(x=1) = 0.7$; $\pi(y=0) = 0.4$, $\pi(y=1) = 0.6$ 。由这些可算出所有条件分布，例如：

$$\pi(y | x) : \quad \pi(0 | 0) = \frac{1}{3}, \quad \pi(1 | 0) = \frac{2}{3}; \quad \pi(0 | 1) = \frac{3}{7}, \quad \pi(1 | 1) = \frac{4}{7}$$

$$\pi(x | y) : \quad \pi(0 | 0) = \frac{1}{4}, \quad \pi(1 | 0) = \frac{3}{4}; \quad \pi(0 | 1) = \frac{1}{3}, \quad \pi(1 | 1) = \frac{2}{3}$$

假设从任意起点 $(x, y) = (0, 0)$ 出发 (它可能远离高概率区域，对应未收敛的 burn-in 期)，开始交替抽样：

- 固定 $x = 0$ ，按 $\pi(y | x = 0)$ 抽 y ：以概率 $2/3$ 抽到 $y = 1$ ，状态变为 $(0, 1)$ 。
- 固定 $y = 1$ ，按 $\pi(x | y = 1)$ 抽 x ：以概率 $2/3$ 抽到 $x = 1$ ，状态变为 $(1, 1)$ 。
- 固定 $x = 1$ ，按 $\pi(y | x = 1)$ 抽 y ：以概率 $4/7$ 抽到 $y = 1$ ，状态仍为 $(1, 1)$ 。
- 继续迭代……

每一步都只依赖当前状态（马尔可夫性质），且每次条件抽样都让链在保持联合分布的意义下移动。长时间运行后，各状态被访问的频率收敛到目标联合分布：

$$\hat{\pi}(0,0) \rightarrow 0.1, \quad \hat{\pi}(0,1) \rightarrow 0.2, \quad \hat{\pi}(1,0) \rightarrow 0.3, \quad \hat{\pi}(1,1) \rightarrow 0.4$$

于是 $\mathbb{E}[g(X,Y)] \approx \frac{1}{M} \sum_t g(x^{(t)}, y^{(t)})$ 。教材中的高斯混合例子（Algorithm 8.4）原理与此完全相同，只是把离散状态换成连续参数：从 $\Pr(\Delta_i | \theta, \mathbf{Z})$ 和 $\Pr(\mu_1, \mu_2 | \Delta, \mathbf{Z})$ 交替抽样，最终收敛到参数的后验分布。

16.5.6 Gibbs 采样

设有随机变量 $U_1, U_2, \dots, U_K$ ，从联合分布直接抽样困难，但从每个条件分布 $\Pr(U_j | U_1, \dots, U_{j-1}, U_{j+1}, \dots, U_K)$ 抽样容易。Gibbs 采样（Algorithm 8.3）交替从每个条件分布模拟，过程稳定后即从目标联合分布抽样。

1. 初始化 $U_k^{(0)}$, $k = 1, \dots, K$
2. 对 $t = 1, 2, \dots$ ：依次从 $\Pr(U_k | U_1^{(t)}, \dots, U_{k-1}^{(t)}, U_{k+1}^{(t-1)}, \dots, U_K^{(t-1)})$ 抽样 $U_k^{(t)}$
3. 直到联合分布稳定

注记 16.5. Gibbs 采样与 EM 算法紧密相关：主要区别在于 Gibbs 从条件分布抽样，而 EM 在条件分布上取最大值。两者都是处理隐变量问题的迭代算法，只是目的不同——EM 求点估计（MAP），Gibbs 求分布。

收敛性与边际密度估计

Gibbs 采样之所以有效，是因为它产生一条马尔可夫链，其平稳分布（stationary distribution）恰为 $U_1, \dots, U_K$ 的真实联合分布——这正是「马尔可夫链蒙特卡洛」名称的由来。虽然不同 t 的样本 $(U_1^{(t)}, \dots, U_K^{(t)})$ 明显不独立，但在正则条件下该过程最终稳定，得到的随机变量确实是联合分布的一个样本。因为每一步都保持各个 U_k 的边际分布不变，所以真实联合分布是此过程的平稳分布。

达到平稳后，任何变量子集的边际密度都可以把密度估计方法应用于样本值来近似。若条件密度 $\Pr(U_k | U_\ell, \ell \neq k)$ 的显式形式已知，则 U_k 边际密度的更好估计为（练习 8.3）：

$$\widehat{\Pr}_{U_k}(u) = \frac{1}{M - m + 1} \sum_{t=m}^M \Pr(u | U_\ell^{(t)}, \ell \neq k) \quad (16.33)$$

其中对序列的最后 $M - m + 1$ 个成员求平均，以允许在达到平稳前有一段初始「烧入（burn-in）」期。

注记 16.6. 我们不需要知道条件密度的显式形式，只需能够从条件分布抽样。这就是 Gibbs 采样的实用门槛：对贝叶斯推断而言，只要给定其他参数和数据 $\mathbf{Z}$ 时每个参数的条件后验易于抽样，即可应用。

高斯混合模型的 Gibbs 采样

在指数族模型中，从后验的 Gibbs 采样与 EM 算法有密切联系。关键是把 EM 中的隐数据 $\mathbf{Z}^m$ 视为 Gibbs 采样器的另一个参数。对高斯混合问题，取参数为 (θ, Δ) ；为简洁固定 σ_1^2, σ_2^2 和 π 于其最大似然值，仅 μ_1, μ_2 未知。Gibbs 采样器 (Algorithm 8.4) 为：

1. 取初始值 $\theta^{(0)} = (\mu_1^{(0)}, \mu_2^{(0)})$

2. 对 $t = 1, 2, \dots$ ：

(a) 对 $i = 1, \dots, N$ 生成 $\Delta_i^{(t)} \in \{0, 1\}$ ，其中 $\Pr(\Delta_i^{(t)} = 1) = \hat{\gamma}_i(\theta^{(t)})$ (由式 (16.30) 的责任)

(b) 令

$$\hat{\mu}_1 = \frac{\sum_i (1 - \Delta_i^{(t)}) y_i}{\sum_i (1 - \Delta_i^{(t)})}, \quad \hat{\mu}_2 = \frac{\sum_i \Delta_i^{(t)} y_i}{\sum_i \Delta_i^{(t)}}$$

并生成 $\mu_1^{(t)} \sim N(\hat{\mu}_1, \hat{\sigma}_1^2)$ 、 $\mu_2^{(t)} \sim N(\hat{\mu}_2, \hat{\sigma}_2^2)$

3. 直到联合分布 $(\Delta^{(t)}, \mu_1^{(t)}, \mu_2^{(t)})$ 稳定

步骤 2(a) 和 2(b) 与 EM 的 E 步、M 步相同，区别仅在于**抽样而非最大化**：2(a) 不是计算最大似然责任 $\gamma_i = \mathbb{E}(\Delta_i | \theta, \mathbf{Z})$ ，而是从 $\Pr(\Delta_i | \theta, \mathbf{Z})$ 模拟隐数据 Δ_i ；2(b) 不是计算后验 $\Pr(\mu_1, \mu_2 | \Delta, \mathbf{Z})$ 的最大化者，而是从条件分布 $\Pr(\mu_1, \mu_2 | \Delta, \mathbf{Z})$ 模拟。

图 8.8 展示了 200 次 Gibbs 迭代：均值参数 μ_1 (下)、 μ_2 (上) 稳定后围绕最大似然估计 $\hat{\mu}_1, \hat{\mu}_2$ 均匀分布。更现实的做法是对 σ_1^2, σ_2^2 和 π 也放置先验，并加入单独的抽样步骤。注意均值参数的先验不能是**非正常先验** (improper prior)，否则会导致退化后验——所有权重落到一个分量上。

注记 16.7. Gibbs 采样会围绕 MLE 波动 (后验均值的中心是 $\hat{\mu}$)，而不是停在 MLE 上——因为后验是分布而非点。这是贝叶斯「推断分布而非点估计」思想的直接体现。

其他 MCMC 方法

Gibbs 采样只是从后验抽样的一类方法。它利用「给定其余参数时的条件抽样」，当问题结构使这种抽样容易时很有用。其他方法不要求这种结构，例如 **Metropolis–Hastings 算法**。这些计算贝叶斯方法已应用于高斯过程模型和神经网络等复杂学习算法。

16.5.7 MCMC 的实践：有限步收敛与诊断

平稳分布是 $t \rightarrow \infty$ 的极限性质，而所有 MCMC 使用都只有有限步。关键在于理解：我们并不需要「到达」平稳，只需要任意精确的近似，且这个近似由两部分误差控制：

$$\hat{\mathbb{E}}[g(\theta) | \mathbf{Z}] = \frac{1}{M} \sum_{t=1}^M g(\theta^{(t)}) \approx \mathbb{E}[g(\theta) | \mathbf{Z}]$$

误差的两个来源：

- **burn-in 误差**：链从初始状态出发，需要一段时间「忘记起点」，分布才接近平稳。实践中丢弃开头 m 个样本（烧入期，见式 (16.33)）。
- **蒙特卡洛误差**：即使已收敛， M 个样本的估计仍有方差，随 $1/\sqrt{M_{\text{eff}}}$ 衰减，其中 M_{eff} 是有效样本量（effective sample size, ESS）。因为链内样本相关， $M_{\text{eff}} \leq M$ ，相关性越强越小。

MCMC 与模拟退火的区别：模拟退火解决优化（把温度压到 $T \rightarrow 0$ ，使分布 $\pi(\theta)^{1/T}$ 收敛到众数，输出一个点）；MCMC 解决采样（还原整个分布，输出一串样本）。因此 MCMC 没有「模拟退火式的有限步保证」。但确有退火式改进技巧：**并行回火**（parallel tempering）同时跑几条不同温度的链，高温链分布平坦、易全局探索，低温链聚焦真实后验的模式，定期交换状态——用于帮助多模态、高相关的链更快混合，本质是增大谱隙、加速收敛，而非保证到达平稳。

数学视角：收敛其实是指数的。在正则条件下，有限步分布以几何速率逼近平稳：

$$\|\pi^{(t)} - \pi\|_{\text{TV}} \leq C \lambda_2^t$$

其中 λ_2 是转移核的第二大特征值，谱隙 $1 - \lambda_2$ 控制混合时间（mixing time）。收敛本身是指数的；问题是谱隙可能很小（高相关、多模态的链混合慢），此时需要的步数才多。

实践中的收敛诊断（有限步「是否够好」靠诊断而非保证）：

1. **轨迹图（trace plot）**：看链是否稳定振荡、无漂移趋势。
2. **Gelman–Rubin 诊断 $\hat{R}$** ：跑多条不同起点的链， $\hat{R}$ 接近 1（通常 < 1.1 ）表示各链分布一致、起点影响已消失。
3. **自相关时间与有效样本量 ESS**：判断需要多少样本才足够（ESS 越大越好）。

对一般目标分布，「是否已收敛」在理论上不可判定（无免费午餐），故实践中靠诊断 + 多条链交叉验证 + 领域常识来确认。

注记 16.8. 所有改善技巧（好的提议分布、参数化、并行回火）本质上都是在增大谱隙、加速混合，从而减小有限步近似的误差。

16.6 Bagging

此前我们用 Bootstrap 评估参数估计或预测的精度。本节展示如何用 Bootstrap 改进估计或预测本身。§8.4 中发现 Bootstrap 均值近似于后验平均，**Bagging** (bootstrap aggregation, Bootstrap 聚合) 进一步利用这一联系。

考虑回归问题：对训练数据 $\mathbf{Z} = \{(x_1, y_1), \dots, (x_N, y_N)\}$ 拟合模型，得到输入 x 处的预测 $\hat{f}(x)$ 。Bagging 在一组 Bootstrap 样本上平均这个预测，从而降低其方差。对每个 Bootstrap 样本 $\mathbf{Z}^{*b}$ ($b = 1, \dots, B$) 拟合模型，得预测 $\hat{f}^{*b}(x)$ ，Bagging 估计定义为：

$$\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x) \quad (16.34)$$

记 $\hat{P}$ 为对每个数据点 (x_i, y_i) 赋予等概率 $1/N$ 的经验分布。「真正的」Bagging 估计定义为 $\mathbb{E}_{\hat{P}} \hat{f}^*(x)$ ，其中 $\mathbf{Z}^* = \{(x_1^*, y_1^*), \dots, (x_N^*, y_N^*)\}$ 且每个 $(x_i^*, y_i^*) \sim \hat{P}$ 。式 (16.34) 是真实 Bagging 估计的蒙特卡洛估计， $B \rightarrow \infty$ 时逼近之。

注记 16.9. Bagging 只对数据的非线性或自适应函数有效果。例如 B-样条光滑对数据是线性的，故使用参数 Bootstrap 时 $\hat{f}_{\text{bag}}(x) \rightarrow \hat{f}(x)$ (练习 8.4) ——Bagging 只是复现原始光滑，没有改进。更典型的例子是回归树：每个 Bootstrap 树通常使用不同特征、可能有不同终结点数，Bagged 估计是这 B 棵树预测的平均。

16.6.1 分类情形：投票 vs 平均概率

若树产生 K 类分类器 $\hat{G}(x)$ ，可考虑底层指示向量函数 $\hat{f}(x)$ (一个 1、其余 $K-1$ 个 0)，使得 $\hat{G}(x) = \arg \max_k \hat{f}_k(x)$ 。此时 Bagged 估计 $\hat{f}_{\text{bag}}(x)$ 是 K 维向量 $[p_1(x), \dots, p_K(x)]$ ，其中 $p_k(x)$ 是预测第 k 类的树的**比例**。Bagged 分类器选择「得票」最多的类：

$$\hat{G}_{\text{bag}}(x) = \arg \max_k \hat{f}_{\text{bag},k}(x) \quad (16.35)$$

注记 16.10. 投票比例 $p_k(x)$ 未必是好的类概率估计。反例：若 x 处类 1 的真实概率为 0.75，且每个 Bagged 分类器都准确预测类 1，则 $p_1(x) = 1$ ，这是错误的。许多分类器 (如树的终结点类比例) 已有估计类概率的底层函数 $\hat{f}(x)$ ——更好的策略是**平均这些概率**而非投票指示向量。这既改进了类概率估计，又往往降低 Bagged 分类器的方差 (尤其小 B 时，见图 8.10)。

16.6.2 例：树与模拟数据

生成 $N = 30$ 的样本，两类、 $p = 5$ 个特征 (标准高斯、两两相关 0.95)。响应按 $\Pr(Y = 1 \mid x_1 \leq 0.5) = 0.2$ 、 $\Pr(Y = 1 \mid x_1 > 0.5) = 0.8$ 生成，贝叶斯误差为 0.2。对训练样本及 200 个 Bootstrap 样本拟合分类树 (不剪枝)。图 8.9 显示原始树和 11 棵 Bootstrap 树——它们完全不同 (不同的分裂特征和切点)。图 8.10 显示测试误差：由于预测变量相关，树的方差很高，Bagging 成功平滑了方差并降低测试误差。

16.6.3 Bagging 为什么有效

平方误差损失下, Bagging 能戏剧性地降低不稳定过程(如树)的方差。设训练观测独立同分布地来自分布 P , 考虑理想聚合估计 $f_{\text{ag}}(x) = \mathbb{E}_P \hat{f}^*(x)$ (x 固定, Bootstrap 数据集从真实总体 P 而非数据抽样)。它是不可用于实践的分析工具。可以写:

$$\begin{aligned} \mathbb{E}_P[Y - \hat{f}^*(x)]^2 &= \mathbb{E}_P[Y - f_{\text{ag}}(x) + f_{\text{ag}}(x) - \hat{f}^*(x)]^2 \\ &= \mathbb{E}_P[Y - f_{\text{ag}}(x)]^2 + \mathbb{E}_P[\hat{f}^*(x) - f_{\text{ag}}(x)]^2 \\ &\geq \mathbb{E}_P[Y - f_{\text{ag}}(x)]^2 \end{aligned} \quad (16.36)$$

右边多出的误差来自 $\hat{f}^*(x)$ 围绕其均值 $f_{\text{ag}}(x)$ 的方差。因此真实总体聚合从不增加均方误差。这提示 Bagging (从训练数据抽样) 通常会降低均方误差。

三层概念对照: 上述推导容易混淆, 这里明确区分三个对象:

名称	定义	从哪抽样	能否实现
理想聚合 $f_{\text{ag}}(x)$	$\mathbb{E}_P \hat{f}^*(x)$	真实总体 P	否 (P 未知)
真 Bagging	$\mathbb{E}_{\hat{P}} \hat{f}^*(x)$	经验分布 $\hat{P}$	仍是期望
实际 Bagging	$\frac{1}{B} \sum_b \hat{f}^{*b}(x)$	训练数据重抽样	是

实际 Bagging 是「真 Bagging」的蒙特卡洛估计 ($B \rightarrow \infty$ 时逼近之); 「真 Bagging」是「理想聚合」用经验分布 $\hat{P}$ 替换 P 的插件版本。平时所说的 Bagging 即第三行——从训练集抽样。

推导 (16.36) 的要点: 交叉项之所以消失, 是因为 $\mathbb{E}_P[\hat{f}^*(x)] = f_{\text{ag}}(x)$ (f_{ag} 正是 $\hat{f}^*$ 的期望), 故

$$\mathbb{E}_P[(Y - f_{\text{ag}}(x))(f_{\text{ag}}(x) - \hat{f}^*(x))] = 0$$

于是分解为「偏差 + 方差」, 而方差项 ≥ 0 , 去掉它只会更小——这正是「平均消除方差、不影响偏差」的数学来源。

两个常见误区:

- 「正常不就应该从训练集抽样吗?」对——实际 Bagging 就是从训练集 (经验分布 $\hat{P}$) 抽样。理想聚合从真实总体 P 抽样, 只是为推导而构造的思想实验, 不是实践算法。
- 「理想聚合不可用是因为抽到了测试集数据?」错——不可用的原因是真实总体 P 未知、无法从它抽样, 与测试集无关。实际做法是**插件原则**: 用经验分布 $\hat{P}$ (训练数据) 代替未知的 P 。

「真实总体聚合从不增加均方误差」的理解: 不等式 (16.36) 的比较对象是任意单个 Bootstrap 模型 $\hat{f}^*$:

$$\underbrace{\mathbb{E}_P[Y - \hat{f}^*(x)]^2}_{\text{随机抽一个 Bootstrap 模型的期望误差}} \geq \underbrace{\mathbb{E}_P[Y - f_{\text{ag}}(x)]^2}_{\text{聚合模型 } f_{\text{ag}} \text{ 的误差}}$$

左侧是「从 P 抽一个 Bootstrap 数据集、训练一个模型 $\hat{f}^*$ 」的期望误差；右侧是所有这些模型平均值 f_{ag} 的误差。结论：聚合模型的 MSE 不超过随机单个 Bootstrap 模型的期望 MSE。

机理：方差项正是单个模型的方差。 分解式中第二项 $\mathbb{E}_P[\hat{f}^*(x) - f_{\text{ag}}(x)]^2$ 就是单个模型围绕其均值（聚合值）波动的方差，它 ≥ 0 ，故「单个模型误差 = 聚合误差 + 单模型方差」。平均把这种抖动（方差）消掉，而 f_{ag} 本身是均值、没有围绕均值的波动——所以 MSE 不增。直觉：某 x 处 10 棵 Bootstrap 树的预测在 0.1, 0.3, ..., 0.9 间大幅抖动、真值为 0.5，随机挑一棵可能误差很大，平均后约 0.5、几乎无偏差。

两点边界（教材用词是「提示」而非严格保证）：

- **比较对象不是原始模型 $\hat{f}$ ：**不等式比较的是 f_{ag} 与随机单模型 $\hat{f}^*$ ；而实际 Bagging 想改进的是用全部数据训练的原模型 $\hat{f}$ （比单个重抽样模型更稳定）。故「提示」Bagging 通常会降低 MSE，是理想情形下的推断。
- **仅在平方损失下成立：**0-1 损失下偏差与方差不可加，见下节。

0-1 损失下不成立

上述论证在 0-1 损失分类下不成立，因为偏差和方差不可加。此时 Bagging 一个好分类器可以更好，但 Bagging 一个差分类器可能更差。简单反例（随机化规则）：设对所有 x 有 $Y = 1$ ，分类器 $\hat{G}(x)$ 以概率 0.4 预测 1、以概率 0.6 预测 0。则 $\hat{G}$ 的误分类率为 0.6，而 Bagged 分类器的误分类率为 1.0。

分类情形可用「独立弱学习者的共识」理解 (Dietterich, 2000a)。设二分类中贝叶斯最优决策为 $G(x) = 1$ ，每个弱学习者 G_b^* 有错误率 $e_b = e < 0.5$ ， $S_1(x) = \sum_{b=1}^B I(G_b^*(x) = 1)$ 为类 1 的共识票。弱学习者独立时 $S_1(x) \sim \text{Bin}(B, 1 - e)$ ，故 $\Pr(S_1 > B/2) \rightarrow 1$ (B 增大)。这被普及为「**众智 (Wisdom of Crowds)**」——多样化且独立的人群的集体知识通常超过任何个人，且可通过投票利用。

注记 16.11. 关键前提是「独立」——而 Bagged 树并不独立。第 15 章的**随机森林**正是通过降低抽样树之间的相关性来改进 Bagging。

Bagging 不生效的情形

Bagging 一个模型会**丢失模型的简单结构**——Bagged 树不再是树，解释性丧失。更稳定的过程（如最近邻）受 Bagging 影响很小；而最受益于 Bagging 的不稳定模型恰恰因强调可解释性而不稳定，这种可解释性在 Bagging 中丢失了。

图 8.12 展示 Bagging 无帮助的例子：100 个数据点、两个特征两类，被线性边界 $x_1 + x_2 = 1$ 分开，选择单个轴对齐分裂分类器。将 0-1 决策规则在 $B = 50$ 个 Bootstrap 样本上 Bagging 得到的边界（蓝线）未能捕捉真实边界。Bagging 估计的是单分裂规则的平均类概率，无法在单个复现中实现——如同「一个女人不可能有 2.4 个孩子」。Bagging

一定程度上扩大了基础分类器的模型空间，但在此类需要更大模型类扩展的例子中无济于事。「Boosting」正是扩展模型类的方法，见第 10 章。

16.7 模型平均与 Stacking

在 §8.4 中我们将估计量的 Bootstrap 值视为对应参数的后验值（一种非参数贝叶斯分析）。如此看来，Bagged 估计 (16.34) 是近似的后验贝叶斯均值，而训练样本估计 $\hat{f}(x)$ 对应后验的众数。由于后验均值（而非众数）最小化平方误差损失，Bagging 常能降低均方误差就不足为奇了。

更一般地讨论贝叶斯模型平均（Bayesian model averaging）。对训练集 $\mathbf{Z}$ 有一组候选模型 M_m ($m = 1, \dots, M$)，它们可以是同类型不同参数值（如线性回归的子集），或不同模型（如神经网络和回归树）。

设 ζ 是感兴趣的某个量（如固定特征值 x 处的预测 $f(x)$ ）。 ζ 的后验分布为：

$$\Pr(\zeta | \mathbf{Z}) = \sum_{m=1}^M \Pr(\zeta | M_m, \mathbf{Z}) \Pr(M_m | \mathbf{Z}) \quad (16.37)$$

后验均值为：

$$\mathbb{E}(\zeta | \mathbf{Z}) = \sum_{m=1}^M \mathbb{E}(\zeta | M_m, \mathbf{Z}) \Pr(M_m | \mathbf{Z}) \quad (16.38)$$

即各模型预测以模型后验概率为权重的加权平均。

此框架引出一系列模型平均策略：

- **委员会方法（committee methods）**：对每个模型的预测取简单无加权平均，本质上是给每个模型相等的概率。
- **BIC 加权**：§7.7 表明 BIC 准则可用于估计后验模型概率，适用于同一参数模型、不同参数值的情形。BIC 依据拟合好坏和参数数量给各模型权重。
- **完整贝叶斯**：若每个模型 M_m 有参数 θ_m ，

$$\Pr(M_m | \mathbf{Z}) \propto \Pr(M_m) \Pr(\mathbf{Z} | M_m) \propto \Pr(M_m) \int \Pr(\mathbf{Z} | \theta_m, M_m) \Pr(\theta_m | M_m) d\theta_m \quad (16.39)$$

原则上可指定先验 $\Pr(\theta_m | M_m)$ 并数值计算后验概率作为权重，但没有实际证据表明这比简单得多的 BIC 近似更值得。

BIC 的定义式与渐进：最常用的权重来自 **BIC 准则** (§7.7)。BIC 定义为

$$\text{BIC}_m = -2\ell(\hat{\theta}_m) + d_m \log N \quad (16.40)$$

其中 $\hat{\theta}_m$ 是模型 m 的最大似然估计， $\ell(\hat{\theta}_m)$ 是最大对数似然， d_m 是模型 m 的参数个数， N 是样本量。第一项 -2ℓ 衡量拟合好坏（越小越好），第二项 $d_m \log N$ 是复杂度惩罚（参数越多惩罚越大）——BIC 在「拟合」与「复杂度」之间取平衡。

BIC 的渐近合理性 (Laplace 近似)：在正则条件下，BIC 是「对数边际似然 $\log \Pr(\mathbf{Z} | M_m)$ 」的近似：

$$\log \Pr(\mathbf{Z} | M_m) = \ell(\hat{\theta}_m) - \frac{d_m}{2} \log N + O_P(1)$$

即 $\text{BIC}_m = -2 \log \Pr(\mathbf{Z} | M_m) + \text{const}$ 。于是模型后验概率可近似为（先验均匀时）

$$\Pr(M_m | \mathbf{Z}) \propto e^{-\text{BIC}_m/2}$$

这就是 BIC 作为 BMA 权重的基础：与 §7.7 模型选择一致——BIC 最小的模型后验概率最大。

注记 16.12. BMA 的深层动机不只是「让预测更有效」，而是把「选哪个模型」的不确定性也纳入预测——不把模型选择当作确定的一步，而是对候选模型平均。这与本章「量化不确定性」的主线一脉相承。

16.7.1 频率学派视角

给定预测 $\hat{f}_1(x), \dots, \hat{f}_M(x)$ ，在平方误差损失下求权重 $w = (w_1, \dots, w_M)$ 使得：

$$\hat{w} = \arg \min_w \mathbb{E}_P \left[Y - \sum_{m=1}^M w_m \hat{f}_m(x) \right]^2 \quad (16.41)$$

解是 Y 对 $\hat{F}(x)^T \equiv [\hat{f}_1(x), \dots, \hat{f}_M(x)]$ 的总体线性回归：

$$\hat{w} = \mathbb{E}_P[\hat{F}(x)\hat{F}(x)^T]^{-1} \mathbb{E}_P[\hat{F}(x)Y] \quad (16.42)$$

且完整回归的误差不超过任何单个模型：

$$\mathbb{E}_P \left[Y - \sum_{m=1}^M \hat{w}_m \hat{f}_m(x) \right]^2 \leq \mathbb{E}_P[Y - \hat{f}_m(x)]^2, \quad \forall m \quad (16.43)$$

即在总体层面，组合模型从不使事情变差。

但总体回归 (16.42) 不可得，自然地用训练集上的线性回归替代——但有简单反例说明这不奏效。若 $\hat{f}_m(x)$ 表示在 M 个总输入中大小为 m 的最佳输入子集的预测，则线性回归会把所有权重放在最大的模型上（ $\hat{w}_M = 1$ ，其余为 0）。问题在于没有通过考虑各模型的复杂度（本例中输入数量 m ）把它们放在同等的地位。

为什么训练集回归会偏爱复杂模型？ 直接原因有两点：

1. **嵌套结构**：大模型（ m 大的子集）通常嵌套小模型，在训练集上拟合更好，其预测与 y 的相关性更强；
2. **共线性**：各模型预测高度共线，最小二乘回归把权重几乎全部推给「训练集上最能解释 y 」的那个模型。

但训练集拟合好 $\neq$ 泛化好——复杂模型过拟合训练集，测试集上未必最优。因此直接在训练集上回归得到的权重反映的是训练拟合能力而非泛化能力，这正是 Stacking 需要改用「样本外」预测的原因。

16.7.2 Stacking

堆叠泛化 (stacked generalization)，或 **stacking** 是解决上述问题的方法。设 $\hat{f}_m^{-i}(x)$ 为使用模型 m 、去掉第 i 个训练观测后对 x 的预测。Stacking 的权重估计来自 y_i 对 $\hat{f}_m^{-i}(x_i)$ ($m = 1, \dots, M$) 的最小二乘回归：

$$\hat{w}^{\text{st}} = \arg \min_w \sum_{i=1}^N \left[y_i - \sum_{m=1}^M w_m \hat{f}_m^{-i}(x_i) \right]^2 \quad (16.44)$$

最终预测为 $\sum_m \hat{w}_m^{\text{st}} \hat{f}_m(x)$ 。通过使用交叉验证预测 $\hat{f}_m^{-i}(x)$ ，Stacking 避免了对复杂度更高的模型给予不公平的高权重。

为什么必须用「样本外」预测（而非训练集预测）赋权？若直接用训练集预测 $\hat{f}_m(x_i)$ 做回归，就掉进上文的陷阱——复杂模型在训练集上表现好而被过度偏爱。 $\hat{f}_m^{-i}(x_i)$ 是模型 m 在「没见过」的点 x_i 上的预测（留一交叉验证预测），公平反映其真实预测能力，不受过拟合偏袒。

Bootstrap 版本是否可行？——可行，是同一思想。除了留一，也可以用 Bootstrap 样本训练模型、在袋外样本 (out-of-bag, OOB) 上预测，再对 y 做最小二乘回归赋权 (**Bootstrap stacking**)。留一、K 折交叉验证、Bootstrap OOB 都是「用样本外预测公平赋权」这一思想的不同实现。教材选留一，是因为它简单，且与 §7.10 的留一交叉验证模型选择联系最直接（把权重限制为 one-hot 即退化为 LOOCV 选模型）。


注记 16.13. 将权重限制为非负且和为 1 可得到更好结果——若把权重解释为 (16.38) 的后验模型概率，这似乎合理，且导致可解的二次规划问题。

Stacking 与留一交叉验证的模型选择 (§7.10) 联系紧密：若把 (16.44) 的最小化限制在「一个单位权重、其余为零」的权重向量上，就得到留一交叉验证误差最小的模型选择 $\hat{m}$ 。Stacking 不是选择单个模型，而是以估计的最优权重组合它们——通常预测更好，但可解释性不如只选 M 个模型之一。

Stacking 的思想比上述更一般：组合模型时可用任何学习方法而不只是线性回归，权重也可依赖输入位置 x 。这样，学习方法被「堆叠」在彼此之上以改进预测性能。

16.7.3 小结：模型组合方法的谱系


§8.8 讨论了几种「组合多个模型」的策略。它们共享同一目标——用多个模型提升预测——但在「权重从哪来」「是否使用样本外信息」上各不相同，形成一条谱系：




三者的关系与取舍：

- **贝叶斯模型平均**：权重 = 模型后验概率（委员会 / BIC / 完整贝叶斯），把「选模型」的不确定性平均掉；权重的统计意义最清晰，但需指定先验或做近似。
- **频率学派最优权重**：理论上最优权重来自总体回归 (16.42)，但 P 未知；直接训练集回归偏爱复杂模型，不可用。
- **Stacking**：用样本外预测（留一 / K 折 / OOB）回归赋权，避开「偏爱复杂模型」问题，是频率学派想法的可用实现，也最灵活（可用任意学习器组合、权重可依赖 x ）。

频率学派赋权思路的演进：



Stacking 的机制：



注记 16.14. 若把 Stacking 的权重限制为 one-hot, 就退化为留一交叉验证模型选择; 若限制为等权, 就退化为委员会方法。因此 Stacking 是「委员会 (等权)」与「选最优模型 (one-hot)」之间的连续统一体——用数据学出最优权重。

16.8 随机搜索: Bumping

本章最后一个方法不涉及平均或组合模型, 而是寻找更好的单个模型的技术。Bumping 使用 Bootstrap 抽样在模型空间中随机移动。

与 Bagging 类似, 抽取 Bootstrap 样本并各拟合一个模型, 但不平均预测, 而是选择在训练数据上拟合最好的 Bootstrap 模型。具体地, 抽取 Bootstrap 样本 $\mathbf{Z}^{*1}, \dots, \mathbf{Z}^{*B}$ 并各拟合模型, 得到输入点 x 处的预测 $\hat{f}^{*b}(x)$ ($b = 1, \dots, B$), 然后选择在原始训练集上平均预测误差最小的模型。平方误差下, 选择来自 Bootstrap 样本 $\hat{b}$ 的模型:

$$\hat{b} = \arg \min_b \sum_{i=1}^N [y_i - \hat{f}^{*b}(x_i)]^2 \quad (16.45)$$

对应预测为 $\hat{f}^{*\hat{b}}(x)$ 。按惯例把原始训练样本也包含在 Bootstrap 样本集合中, 使方法在原始模型训练误差最低时自由选择之。

注记 16.15. 通过扰动数据, Bumping 试图把拟合过程移到模型空间的良好区域。若少数数据点导致过程找到差解, 任何省略这些点的 Bootstrap 样本都应产生更好的解。

例: XOR 问题 (图 8.13)。 两类、两个输入特征, 特征表现出纯交互作用。在 $x_1 = 0$ 处分裂、再在每个分块内于 $x_2 = 0$ 处分裂 (或反之), 树分类器即可完美判别。然而贪心短视的 CART 算法 (§9.2) 尝试在任一特征上找最佳分裂再分裂所得分块。由于数


据平衡, x_1 或 x_2 上的所有初始分裂看起来都没用, 过程在顶层本质上产生随机分裂。Bumping 通过 Bootstrap 抽样打破类别平衡, 在合理数量的 Bootstrap 样本 (此处 20) 下, 碰巧至少产生一棵初始分裂接近 $x_1 = 0$ 或 $x_2 = 0$ 的树。仅用 20 个 Bootstrap 样本, Bumping 就找到了接近最优的分裂 (图 8.13 右面板)。若加入若干与类别标签无关的噪声特征, 贪心树生长算法的这一缺陷会加剧——它无法区分 x_1, x_2 与其他特征, 会严重迷失。

注记 16.16. 由于 Bumping 在训练数据上比较不同模型, 必须确保模型复杂度大致相同 (树的情形即每个 Bootstrap 样本生长相同终结点数量的树)。Bumping 也有助于难以优化拟合准则的问题 (如缺乏光滑性) ——技巧是在 Bootstrap 样本上优化一个更方便的不同准则, 再选择在训练样本上对目标准则产生最佳结果的模型。


16.9 本章小结

16.9.1 核心框架：两条主线

第 8 章围绕「从数据量化不确定性」与「用数据改进预测」两条主线展开：频率学派与贝叶斯学派提供两种推断视角，Bootstrap 是连接二者的计算工具，EM 与 MCMC 处理隐变量问题，而 Bagging、模型平均与 Bumping 属于模型利用层面的改进。



16.9.2 方法选用指南



16.9.3 关键结论

1. 两种学派的根本分歧是「谁随机」：频率学派参数固定、数据随机（重复抽样视角），输出点估计 + 置信区间；贝叶斯学派数据固定、参数随机，输出整个后验分布 + 可信区间。贝叶斯的核心动机是量化不确定性。
2. **Bootstrap 是「穷人的贝叶斯后验」**：无信息先验下，后验 $\approx$ 似然 $\approx$ Bootstrap 分布。Bootstrap 既是评估工具（标准误、置信区间），也是改进工具（Bagging）——同一工具，两种用途。
3. **EM 与 MCMC 是同一隐变量结构的两面**：EM 用「期望 + 最大化」求 MLE 点估计（频率）；Gibbs 把「最大化」换成「抽样」，从后验分布抽样（贝叶斯）。区别是「点」与「分布」。
4. **MCMC 的实践本质**：平稳分布是极限，有限步只能给任意精度的近似；误差来自 burn-in 与蒙特卡洛（ESS）；靠 trace、 $\hat{R}$ 、自相关诊断；谱隙 $1 - \lambda_2$ 决定混合速度。
5. **Bagging 降方差、不扩模型类**：平方损失下理想聚合不增 MSE（消掉单模型方差）；但 Bagging 平均救不了表达能力不足的基础模型——这正是第 10 章 Boosting 的动机。

6. **模型组合的三条路线：** BMA（权重 = 模型后验概率，BIC 近似）、频率最优权重（总体回归，因 P 未知不可用）、Stacking（样本外预测公平赋权）。Stacking 是「等权委员会」与「选最优模型」之间的连续统一体。
7. **Bumping 帮助贪心算法跳出局部最优：** 通过 Bootstrap 扰动在模型空间随机移动，选择训练误差最小的模型（XOR 例），本质是随机化的模型搜索。

第十七章 加性模型、树及相关方法

第 9 章开始讨论监督学习的若干具体方法。这些方法都对未知回归函数假设某种（不同的）结构化形式，从而缓解维数灾难；代价是可能误设模型，因此每处都需要权衡。本章介绍五种相关技术：广义加性模型（GAM）、树（trees）、多元自适应回归样条（MARS）、患者规则归纳法（PRIM）与专家分层混合（HME）。本节先介绍其中的广义加性模型。

17.1 广义加性模型

传统线性模型虽然简洁，但现实效应往往非线性。此前章节用预定义基函数实现非线性；本节介绍更自动、灵活的统计方法——广义加性模型（Generalized Additive Models, GAM），用于识别和刻画非线性回归效应。

17.1.1 模型定义

回归设置下，广义加性模型形式为

$$\mathbb{E}(Y \mid X_1, X_2, \dots, X_p) = \alpha + f_1(X_1) + f_2(X_2) + \dots + f_p(X_p) \quad (17.1)$$

其中 f_j 是未指定的光滑（非参数）函数。与第 5 章「每个函数用基函数展开」不同，这里用散点图平滑器（如三次平滑样条或核平滑器）拟合每个函数，并提供同时估计全部 p 个函数的算法（§9.1.1）。

二分类情形（logistic）：回忆 §4.4 的二元数据 logistic 回归，把响应均值 $\mu(X) = \Pr(Y = 1 \mid X)$ 通过 logit 链接与预测变量线性相连。加性 logistic 回归把每个线性项换成更一般的函数形式：

$$\log \frac{\mu(X)}{1 - \mu(X)} = \alpha + f_1(X_1) + \dots + f_p(X_p) \quad (17.2)$$

非参数形式使模型更灵活，但保留可加性，因此解释方式与线性模型类似。加性 logistic 回归是 GAM 的一个例子。

一般地，响应 Y 的条件均值 $\mu(X)$ 通过链接函数 g 与预测变量的加性函数相连：

$$g[\mu(X)] = \alpha + f_1(X_1) + \dots + f_p(X_p) \quad (17.3)$$

常见链接函数：

- $g(\mu) = \mu$: 恒等链接, 用于高斯响应数据的线性/加性模型
- $g(\mu) = \text{logit}(\mu)$ 或 $g(\mu) = \text{probit}(\mu) = \Phi^{-1}(\mu)$: 二项概率
- $g(\mu) = \log(\mu)$: Poisson 计数数据的对数线性/对数加性模型

这三类都来自指数族抽样模型 (还包括 gamma、负二项分布), 构成著名的**广义线性模型 (GLM)**, 并同样推广为**广义加性模型**。

GAM 的灵活性:

- 可混合线性与非线性项——当某些输入是定性变量 (因子) 时需要参数形式
- 非线性项不限于主效应: 可以是两个以上变量的非线性分量, 或对因子 X_k 每个水平给出独立曲线
- 例: $g(\mu) = X^T\beta + \alpha_k + f(Z)$ (半参数模型, X 线性建模、 Z 非参数、 α_k 是定性输入 V 第 k 水平效应); $g(\mu) = f(X) + g_k(Z)$ (产生交互项 $g(V, Z) = g_k(Z)$); $g(\mu) = f(X) + g(Z, W)$ (g 是双特征非参数函数)

加性模型可在广泛场景替代线性模型, 例如时间序列的加性分解

$$Y_t = S_t + T_t + \varepsilon_t \quad (17.4)$$

其中 S_t 是季节分量、 T_t 是趋势、 ε 是误差项。

17.1.2 拟合加性模型: Backfitting

加性模型形式为

$$Y = \alpha + \sum_{j=1}^p f_j(X_j) + \varepsilon \quad (17.5)$$

其中误差项 ε 均值为零。给定观测 (x_i, y_i) , 可用类似 (5.9) 的惩罚平方和准则:

$$\text{PRSS}(\alpha, f_1, \dots, f_p) = \sum_{i=1}^N \left(y_i - \alpha - \sum_{j=1}^p f_j(x_{ij}) \right)^2 + \sum_{j=1}^p \lambda_j \int f_j''(t_j)^2 dt_j \quad (17.6)$$

其中 $\lambda_j \geq 0$ 是调节参数。可以证明 (9.7) 的极小化者是加性三次样条模型: 每个 f_j 是关于 X_j 的三次样条, 结点在 x_{ij} ($i = 1, \dots, N$) 的每个唯一值处。

为什么用惩罚项 (而不是显式基展开)? 这里与第 5 章形成两条路线的对比:

- **显式基展开 (第 5 章):** 预先选定基函数 (如 B 样条/自然样条) 并手动选择节点的位置与数量, 再最小二乘求系数——节点选择是复杂度控制的关键, 也是麻烦所在。

- **惩罚样条 (本节的 PRSS): 不需要选节点**——每个唯一观测值都作为节点, 靠曲率惩罚 $\lambda_j \int f_j''(t_j)^2 dt_j$ 控制光滑度。节点不再是复杂度控制: $\lambda_j \rightarrow \infty$ 时解退化为全局线性 ($df_j \rightarrow 2$), $\lambda_j \rightarrow 0$ 时解趋向插值 (过拟合)。

所以惩罚项的作用是**正则化**: 非参数 f_j 有无限自由度, 必须有惩罚约束; 同时它把「选节点」换成连续参数 λ_j (或等价地 df_j) 来控制复杂度。「解是自然三次样条、结点在所有观测处、边界线性」是优化问题的自动产物, 而非预先指定的基性质。

可识别性: 常数 α 不可识别——可以给每个 f_j 加/减任意常数, 再相应调整 α 。标准约定是 $\sum_i f_j(x_{ij}) = 0$ (各函数在数据上均值为零), 此时 $\hat{\alpha} = \text{ave}(y_i)$ 。若输入矩阵满列秩, 则 (9.7) 严格凸、极小值唯一; 若奇异, 则各分量的**线性部分**无法唯一确定 (非线性部分仍可, Buja et al., 1989)。

Backfitting 算法 (Algorithm 9.1):

1. 初始化: $\hat{\alpha} = \frac{1}{N} \sum_{i=1}^N y_i$, $\hat{f}_j \equiv 0$ ($\forall j$)
2. 循环 $j = 1, 2, \dots, p, 1, 2, \dots, p, \dots$:

$$\hat{f}_j \leftarrow S_j \left[\left\{ y_i - \hat{\alpha} - \sum_{k \neq j} \hat{f}_k(x_{ik}) \right\}_{i=1}^N \right], \quad \hat{f}_j \leftarrow \hat{f}_j - \frac{1}{N} \sum_{i=1}^N \hat{f}_j(x_{ij})$$

3. 直到 $\hat{f}_j$ 的变化小于预设阈值

其中 S_j 是对目标 $\{y_i - \hat{\alpha} - \sum_{k \neq j} \hat{f}_k(x_{ik})\}$ 关于 x_{ij} 的**三次平滑样条算子**。对每个预测变量依次操作, 计算 $y_i - \hat{\alpha} - \sum_{k \neq j} \hat{f}_k(x_{ik})$ 时使用其他函数的最新估计 $\hat{f}_k$ 。结果类似于线性模型的多重回归。

第二步 (重中心化) 在做什么? $\hat{f}_j \leftarrow \hat{f}_j - \frac{1}{N} \sum_i \hat{f}_j(x_{ij})$ 是把刚更新的 $\hat{f}_j$ 减去它在数据上的均值, 强制满足可识别性约束 $\sum_i f_j(x_{ij}) = 0$ 。原因: α 已锁死为 $\text{ave}(y_i)$, 若某次迭代后 $\hat{f}_j$ 均值不为零, 常数会在各函数间「漂移」、破坏「常数归 α 、函数归 f_j 」的分配。这一步**不是更新变化量** (更新在 $S_j[\dots]$ 那一行已完成), 而是把更新结果拉回均值零的约束流形——类似坐标下降中的投影。理论上它可省略 (对均值零响应的样条拟合均值也为零, 练习 9.1), 但实践中机器舍入会造成偏移 (slippage), 故建议保留。

平滑算子 S_j 做了什么? S_j 是「把散点 (x_j, r) 光滑成自然三次样条曲线」的**线性平滑算子**:

1. **输入**: 目标值向量 $r = \{r_i\}_{i=1}^N$ (在 Backfitting 中即部分残差), 对应输入点 $x_{1j}, \dots, x_{Nj}$
2. **操作**: 求最小化 $\sum_i (r_i - f(x_{ij}))^2 + \lambda_j \int f''(t)^2 dt$ 的函数 f ——在所有唯一 x_{ij} 处放节点, 第一项贴近数据、第二项惩罚弯曲, 解是自然三次样条 (分段三次多项式、拼接处连续到二阶导数、边界段线性)
3. **输出**: 光滑曲线 $\hat{f}_j$ 在数据点处的拟合值

作为线性算子，输出是输入的线性函数： $\hat{\mathbf{f}}_j = \mathbf{S}_j \mathbf{r}$ ，其中 $\mathbf{S}_j$ 是 $N \times N$ 算子矩阵（对称、半正定、行和为 1，类似「软投影」但非幂等）。Backfitting 正是用 S_j 把「 y 去掉其他所有变量贡献后」的部分残差，磨平成 x_j 的光滑效应——这就是「交替一元光滑」的原子操作。

算法的模块化：指定合适的平滑算子 S_j 即可容纳其他拟合方法：

- 一元回归平滑器：局部多项式回归、核方法
- 线性回归算子：多项式拟合、分段常数、参数样条、级数和 Fourier 拟合
- 更复杂算子：二阶及以上交互的表面平滑器、季节效应的周期平滑器

自由度：若只在训练点考察平滑算子 S_j ，可表示为 $N \times N$ 算子矩阵 $\mathbf{S}_j$ （见 §5.4.1）。第 j 项的自由度近似为

$$\text{df}_j = \text{trace}[\mathbf{S}_j] - 1 \quad (17.7)$$

对一大类线性平滑器，backfitting 等价于求解某个线性方程组的 **Gauss–Seidel 算法**（练习 9.2）。

对 logistic 回归等广义加性模型，合适的准则是**惩罚对数似然**；最大化时 backfitting 与似然最大化器结合使用。GLM 中常用的 Newton–Raphson 最大化对数似然可重写为 **IRLS（迭代加权最小二乘）** 算法：反复对工作响应变量关于协变量做加权线性回归，每次回归得到新的参数估计，再得到新的工作响应与权重，迭代进行。在 GAM 中，加权线性回归被替换为**加权 backfitting**。

GLM 与 GAM 是什么、关系如何？

- **GLM（广义线性模型）：**三个组成部分——**随机分量：**响应 Y 服从**指数族**分布（正态、二项、Poisson、gamma、负二项等）；**系统分量：**线性预测子 $\eta = \alpha + \beta_1 X_1 + \cdots + \beta_p X_p$ ；**链接函数：** $g(\mu) = \eta$ ，其中 $\mu = \mathbb{E}(Y | X)$ 。经典 GLM 中每个预测变量的贡献是**线性的**： $g(\mu) = \alpha + \sum_j \beta_j X_j$ 。例：线性回归（正态 + 恒等链接）、logistic 回归（二项 + logit 链接）、Poisson 回归（Poisson + log 链接）。
- **GAM（广义加性模型）：**把 GLM 的线性预测子换成**加性非参数形式** $g(\mu) = \alpha + \sum_j f_j(X_j)$ （式 (17.3)），每个 f_j 是未指定的光滑函数（§9.1.1 用平滑样条估计）。
- **关系：**GAM 是 GLM 的**非参数推广**——保留 GLM 的「随机分布（指数族）+ 链接函数 g 」框架不变，只把「线性项 $\beta_j X_j$ 」换成「光滑函数 $f_j(X_j)$ 」。当所有 f_j 都是线性函数时，GAM 退化为 GLM。这也解释了「广义」一词：链接与分布族共享，变的只是线性预测子被加性化。


拟合的对应关系：GLM 用 IRLS（每次迭代做**加权线性回归**）；GAM 只需把其中的加权线性回归替换为**加权 backfitting**（每次迭代做**加权平滑**）——这正是「加权线性回

归被替换为加权 backfitting」的含义：两者共享分布/链接框架，区别仅在「线性回归器」换成「平滑器」。

Newton–Raphson：求根思想与严格表述。它用于求方程 $f(x) = 0$ 的根（在优化中即解 $\nabla \ell(\theta) = 0$ ）。思想：在 x_k 处作一阶泰勒展开（切线近似），令其为零解出下一个近似：

$$f(x) \approx f(x_k) + f'(x_k)(x - x_k) = 0 \implies x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

即沿当前点切线的方向走到零点附近：



图：Newton 法一步：在 x_0 处作切线，切线与 x 轴的交点 x_1 比 x_0 更接近根 r 。

定理（Newton 法局部二阶收敛）：设 $f \in C^2$ 于含根 r 的开区间 I ，且 $f(r) = 0$ 、 $f'(r) \neq 0$ 。则存在邻域 $U \subset I$ 含 r ，使得对任意初值 $x_0 \in U$ ：

1. 迭代 $x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$ 明确定义且收敛到 r ；
2. 收敛为二阶：存在 $C > 0$ 使 $|x_{k+1} - r| \leq C|x_k - r|^2$ （有效位数每步翻倍）。

若 $f'(r) = 0$ （重根），收敛阶降为线性。该定理是**局部**的——初值必须落在收敛域内，否则可能发散。

推广到优化与多维：求最大化 $\ell(\theta)$ 即解 $\nabla \ell(\theta) = 0$ 。多维更新为

$$\theta_{k+1} = \theta_k - \mathbf{H}(\theta_k)^{-1} \nabla \ell(\theta_k)$$

其中 $\nabla \ell$ 为梯度（得分函数）， $\mathbf{H}$ 为 Hessian。对 GLM，指数族结构使该步等价于**加权最小二乘**（IRLS）；对 GAM，再把加权线性回归换成**加权 backfitting**（Local Scoring）。

注记 17.1. Newton 法二阶收敛（快），但需一阶/二阶导数、只局部收敛、Hessian 可能奇异；优点是初值好时极快，是 GLM/IRLS 等统计优化的骨架。

IRLS 算法步骤（拟合 GLM）：拟合 GLM 即最大化对数似然，等价于 Newton–Raphson；IRLS 把它重写为反复的加权最小二乘。给定当前参数 β ：

1. 计算线性预测子 $\hat{\eta}_i = x_i^T \beta$
2. 计算拟合均值 $\hat{\mu}_i = g^{-1}(\hat{\eta}_i)$ (g 为链接函数)
3. 构造工作响应 $z_i = \hat{\eta}_i + \frac{y_i - \hat{\mu}_i}{g'(\hat{\mu}_i)}$
4. 构造权重 $w_i = \frac{1}{V(\hat{\mu}_i) g'(\hat{\mu}_i)^2}$ ($V(\mu)$ 为指数族的方差函数)
5. 用权重 w_i 对工作响应 z_i 关于 x_i 做加权最小二乘, 得新 β

迭代 1–5 至收敛。对 logistic 回归: $g(\mu) = \text{logit}(\mu)$ 、 $V(\mu) = \mu(1-\mu)$, 于是 $w_i = \hat{\mu}_i(1-\hat{\mu}_i)$ 、 $z_i = \hat{\eta}_i + \frac{y_i - \hat{\mu}_i}{\hat{\mu}_i(1-\hat{\mu}_i)}$ ——正是 Algorithm 9.2 中的工作目标与权重。

例子 1: GLM (logistic 回归) 流程。 设 $X_1, X_2 \in \mathbb{R}$, $Y \in \{0, 1\}$, 模型 $\Pr(Y = 1 | X) = \sigma(\beta_0 + \beta_1 X_1 + \beta_2 X_2)$ (σ 为 sigmoid)。IRLS 流程: 初始化 $\beta = (0, 0, 0) \rightarrow$ 迭代「计算 $\hat{\eta}_i$ 、 $\hat{p}_i = \sigma(\hat{\eta}_i) \rightarrow$ 构造 z_i 、 $w_i = \hat{p}_i(1-\hat{p}_i) \rightarrow$ 加权最小二乘更新 β 」 $\rightarrow$ 收敛得 $\hat{\beta}$, 据此预测任意 x 处的 $\Pr(Y = 1)$ 。输出的是三个常数系数。

例子 2: GAM (加性 logistic) 流程。 同样的二分类, 但模型 $\Pr(Y = 1 | X) = \sigma(\alpha + f_1(X_1) + f_2(X_2))$ 。用 Algorithm 9.2 (Local Scoring): 外层仍是 Newton–Raphson / IRLS 的迭代, 但其中「加权线性回归」一步换成「加权 backfitting」——固定其他函数、对部分残差做加权平滑样条更新 f_j , 直到收敛。输出的是两条光滑曲线 f_1, f_2 (而非常数系数)。

对比与联系:

	GLM	GAM
预测子	$\eta = \alpha + \sum_j \beta_j X_j$ (线性)	$\eta = \alpha + \sum_j f_j(X_j)$ (加性非参数)
参数	有限维 β	无限维 (惩罚约束)
拟合	IRLS (加权最小二乘)	Local Scoring (IRLS + 加权 backfitting)
可解释	系数 β_j = 常数效应	曲线 f_j = 随 X_j 变化的效应
关系	GAM 的特例 (f_j 取线性)	保留 GLM 的分布 + 链接

联系: GAM 与 GLM 共享「指数族分布 + 链接函数 g 」框架; 区别只在预测子的函数形式 (线性 vs 加性光滑)。拟合层面, GAM 的 Local Scoring 就是在 IRLS 中把「加权线性回归」替换为「加权 backfitting」——结构完全对应、层层嵌套。

17.1.3 例: 加性 logistic 回归 (spam 数据)

医学研究中最常用的模型是二元数据的 logistic 模型: 结果 Y 编码为 0/1 (1 表示事件发生, 如死亡或疾病复发), 目标是建模 $\Pr(Y = 1 | X)$ (给定预后因子时事件的概率)。加性 logistic 模型为

$$\log \frac{\Pr(Y = 1 | X)}{\Pr(Y = 0 | X)} = \alpha + f_1(X_1) + \cdots + f_p(X_p) \quad (17.8)$$

Local Scoring 算法 (Algorithm 9.2) ——backfitting 嵌套在 Newton-Raphson 过程内:

1. 初始值: $\hat{\alpha} = \log[\bar{y}/(1 - \bar{y})]$ ($\bar{y} = \text{ave}(y_i)$ 为样本中 1 的比例), $\hat{f}_j \equiv 0$
2. 令 $\hat{\eta}_i = \hat{\alpha} + \sum_j \hat{f}_j(x_{ij})$, $\hat{p}_i = 1/[1 + \exp(-\hat{\eta}_i)]$, 迭代:
 - (a) 构造工作目标 $z_i = \hat{\eta}_i + \frac{y_i - \hat{p}_i}{\hat{p}_i(1 - \hat{p}_i)}$
 - (b) 构造权重 $w_i = \hat{p}_i(1 - \hat{p}_i)$
 - (c) 用权重 w_i 对目标 z_i 拟合加性模型 (加权 backfitting), 得新估计 $\hat{\alpha}, \hat{f}_j$
3. 直到函数变化低于预设阈值

spam 例子: 4601 封电子邮件 (检测垃圾邮件 spam), 57 个预测变量: 48 个定量词频 (business、address、internet、free、george 等)、6 个字符频 (ch;, ch(, ch[, ch!, ch\$, ch#)、以及 3 个大写字母统计 (CAPAVE 平均连续大写长度、CAPMAX 最长连续大写、CAPTOT 连续大写长度总和)。编码 spam = 1、email = 0。随机选 1536 为测试集、3065 为训练集。GAM 对每个预测变量用名义 4 自由度的三次平滑样条——即对每个 X_j 选择 λ_j 使 $\text{trace}[\mathbf{S}_j(\lambda_j)] - 1 = 4$ 。多数预测变量长尾分布, 拟合前做 $\log(x + 0.1)$ 变换。

测试误差 5.3% (线性 logistic 回归为 7.6%, 表 9.1 混淆矩阵)。表 9.2 将显著预测变量的贡献分解为**线性部分 + 非线性部分** (线性部分用加权最小二乘线性拟合, 非线性部分为残差)。图 9.1 显示许多非线性效应在 0 处有**强间断**: 例如 george 频率从 0 增加时 spam 概率显著下降, 之后几乎不变——提示可用「零计数」的指示变量代替频率, 再加线性项, 测试误差降至 6.6%。

非对称损失: 把真实 email 误判为 spam 更严重 (好邮件被过滤掉)。可通过改变损失 (§2.4) 调节两类错误率: 设 L_{01} 为把真 0 判 1 的损失、 L_{10} 为把真 1 判 0 的损失, 贝叶斯规则在概率大于 $L_{01}/(L_{01} + L_{10})$ 时判 1。取 $L_{01} = 10, L_{10} = 1$ 时两类错误率变为 0.8% 与 8.7%; 若再对类 0 观测加权 L_{01} 、类 1 观测加权 L_{10} , 错误率为 1.2% 与 8.0%。

17.1.4 小结

优点: 加性模型是线性模型的灵活扩展, 在更灵活的同时保留大部分可解释性。线性模型中熟悉的建模与推断工具同样可用于加性模型 (如表 9.2)。Backfitting 简单、模块化, 可对每个输入变量选择适当的拟合方法, 因此在统计界被广泛使用。

局限: 大数据挖掘应用中, backfitting 拟合所有预测变量不可行或不可取。**BRUTO** 过程 (Hastie and Tibshirani, 1990) 把 backfitting 与输入选择结合, 但并非为大规模问题设计。近年有使用 lasso 型惩罚估计稀疏加性模型的工作 (如 **COSMO** 的 Lin and Zhang, 2006、**SpAM** 的 Ravikumar et al., 2008)。对大规模问题, **前向分段 (forward stagewise)** 方法如 **boosting** (第 10 章) 更有效, 且可包含交互项。

注记 17.2. GAM 的「可加性」是它与完整非参数回归的关键区别：每个变量贡献独立相加，代价是不能自动捕捉变量间交互；好处是维数灾难被缓解、且每个 f_j 可单独可视化和解释（图 9.1）。这正好呼应本章开篇「结构化假设换取可解释性」的权衡。

17.2 基于树的方法

17.2.1 背景

基于树的方法把特征空间划分为一组**矩形区域**，并在每个区域内拟合简单模型（如常数）。它概念简单而强大。本节介绍 CART（分类与回归树），并与主要竞争对手 C4.5 对比。

特征空间的形式化定义：设有 p 个预测变量，每个观测的输入为 $x = (x_1, x_2, \dots, x_p)$ 。**特征空间（feature space）**是所有输入向量可能取值的集合：

$$\mathcal{X} = \mathcal{X}_1 \times \mathcal{X}_2 \times \dots \times \mathcal{X}_p \quad (17.9)$$

其中 $\mathcal{X}_j$ 是第 j 个变量的取值空间：连续变量 $\mathcal{X}_j \subseteq \mathbb{R}$ （ p 个变量全连续时 $\mathcal{X} \subseteq \mathbb{R}^p$ ）；分类变量 $\mathcal{X}_j$ 为有限集合。训练数据是其中的 N 个带响应点： $\mathbf{Z} = \{(x_i, y_i)\}_{i=1}^N$ ， $x_i \in \mathcal{X}$ ， $y_i \in \mathcal{Y}$ ；监督学习的目标是估计映射 $f: \mathcal{X} \rightarrow \mathcal{Y}$ 。

树的矩形划分：树方法把特征空间划分成互不相交的矩形区域（轴对齐盒）：

$$\mathcal{X} = \bigcup_{m=1}^M R_m, \quad R_m \cap R_{m'} = \emptyset \ (m \neq m') \quad (17.10)$$

每块 R_m 由一系列轴对齐条件（每个形如 $x_j \leq s$ 或 $x_j > s$ ）的交定义：

$$R_m = \{x \in \mathcal{X} : x_{j_1} \leq s_1, x_{j_2} > s_2, \dots\} \quad (17.11)$$

即坐标方向上的「切刀」反复切分特征空间。模型在每块内拟合常数 c_m ：

$$f(x) = \sum_{m=1}^M c_m I(x \in R_m) \quad (17.12)$$

几个相关形式化量（回归树）：记 $N_m = \#\{x_i \in R_m\}$ 为落入区域 R_m 的观测数，区域内拟合常数取均值

$$\hat{c}_m = \text{ave}(y_i \mid x_i \in R_m)$$

维数 p 即特征空间的维数； p 大时空间体积随维度**指数增长**（**维数灾难**），树通过「分块常数」这种强结构化假设来缓解。

考虑连续响应 Y 和输入 X_1, X_2 （都在单位区间）。图 9.2 左上展示用平行于坐标轴的直线划分特征空间，每个划分元素用不同常数建模 Y 。问题：虽然每条划分线有简单描述（如 $X_1 = c$ ），但有些区域难以描述。




FIGURE 9.2. Partitions and CART. Top right panel shows a partition of a two-dimensional feature space by recursive binary splitting, as used in CART, applied to some fake data. Top left panel shows a general partition that cannot be obtained from recursive binary splitting. Bottom left panel shows the tree corresponding to the partition in the top right panel, and a perspective plot of the prediction surface appears in the bottom right panel.

图 17.1: 划分与 CART (图 9.2)。右上: 对二维特征空间用递归二元划分 (CART 采用) 得到的分割; 左上: 无法由递归二元划分得到的一般分割; 左下: 与右上分割对应的树; 右下: 预测面的透视图。

递归二元划分: 为简化, 限制为递归二元划分 (图 9.2 右上)。先把空间分成两个区域, 用每个区域的 Y 均值建模响应; 选择变量和切点使拟合最优。然后其中一个或两个区域再分成两个区域, 如此继续直到某个停止规则。例如图 9.2: 先在 $X_1 = t_1$ 处分裂, $X_1 \leq t_1$ 的区域在 $X_2 = t_2$ 处分裂、 $X_1 > t_1$ 的区域在 $X_1 = t_3$ 处分裂, 最后 $X_1 > t_3$ 在 $X_2 = t_4$ 处分裂, 得到五个区域 $R_1, \dots, R_5$ 。对应的回归模型用区域 R_m 中的常数 c_m 预

测 Y :

$$\hat{f}(X) = \sum_{m=1}^5 c_m I\{(X_1, X_2) \in R_m\} \quad (17.13)$$

同一模型可用二元树表示 (图 9.2 左下): 数据集在树顶, 满足每个节点条件的观测走左支、否则走右支; 终结点 (叶) 对应区域 $R_1, \dots, R_5$ 。右下是预测面的透视图。

关键优势: 可解释性。特征空间划分由单棵树完整描述; 两个以上输入时划分难画, 但树表示同样工作。这在医学中很流行, 因为它模仿医生思考方式——树根据病人特征把总体分层为高/低结果。

17.2.2 回归树

如何生长回归树? 数据为 N 个观测 (x_i, y_i) , $x_i = (x_{i1}, \dots, x_{ip})$ 。算法需自动决定分裂变量、切点、以及树形 (topology)。先假设已有 M 个区域 $R_1, \dots, R_M$, 用每个区域的常数 c_m 建模:

$$f(x) = \sum_{m=1}^M c_m I(x \in R_m) \quad (17.14)$$

以最小化平方和 $\sum_i (y_i - f(x_i))^2$ 为准则, 最优 $\hat{c}_m$ 是区域 R_m 中 y_i 的平均:

$$\hat{c}_m = \text{ave}(y_i \mid x_i \in R_m) \quad (17.15)$$

贪心算法: 求最小化平方和的全局最优二元划分通常计算上不可行, 因此用贪心算法。从全部数据出发, 考虑分裂变量 j 和切点 s , 定义两个半平面:

$$R_1(j, s) = \{X \mid X_j \leq s\}, \quad R_2(j, s) = \{X \mid X_j > s\} \quad (17.16)$$

求使下式最小的 (j, s) :

$$\min_{j, s} \left[\min_{c_1} \sum_{x_i \in R_1(j, s)} (y_i - c_1)^2 + \min_{c_2} \sum_{x_i \in R_2(j, s)} (y_i - c_2)^2 \right] \quad (17.17)$$

对任意 (j, s) , 内层最小化由 $\hat{c}_1 = \text{ave}(y_i \mid x_i \in R_1(j, s))$ 、 $\hat{c}_2 = \text{ave}(y_i \mid x_i \in R_2(j, s))$ 解出。对每个分裂变量, 切点 s 的确定可很快完成, 扫描全部输入即可求最佳 (j, s) 。找到最佳分裂后, 把数据分成两个区域, 在每个区域重复分裂过程。

树该长多大? 大树可能过拟合, 小树可能漏掉重要结构。树大小是控制复杂度的调节参数, 应自适应选择。一种做法是只在分裂使平方和下降超过阈值时才分裂——但这太短视 (看似无用的分裂可能带来其下很好的分裂)。**首选策略: 先长一棵大树 T_0** , 只在达到最小节点大小 (如 5) 时停止; 然后用**代价复杂度剪枝 (cost-complexity pruning)**。

两阶段框架: 回归树 = **贪心生长** (自顶向下切分, 解决「怎么切」) + **代价复杂度剪枝** (自底向上折叠, 解决「切多大」)。关键点: 生长时不用「分裂增益阈值」决定停止——因为看似无用的分裂可能为下方创造出好的分裂 (如两个变量交互时需先切一刀、两侧再各自切); 所以先长满、再用剪枝统一权衡复杂度与误差。

定义子树 $T \subset T_0$ 为对 T_0 剪枝得到的任意树（折叠任意内部节点）。设 $|T|$ 为 T 的终结点数，定义

$$N_m = \#\{x_i \in R_m\}, \quad \hat{c}_m = \frac{1}{N_m} \sum_{x_i \in R_m} y_i, \quad Q_m(T) = \frac{1}{N_m} \sum_{x_i \in R_m} (y_i - \hat{c}_m)^2 \quad (17.18)$$

代价复杂度准则：

$$C_\alpha(T) = \sum_{m=1}^{|T|} N_m Q_m(T) + \alpha |T| \quad (17.19)$$

对每个 α ，求使 $C_\alpha(T)$ 最小的子树 $T_\alpha \subseteq T_0$ 。调节参数 $\alpha \geq 0$ 控制树大小与拟合的权衡： α 大 $\rightarrow$ 树小， α 小 $\rightarrow$ 树大， $\alpha = 0$ 时解为全树 T_0 。

对每个 α 存在唯一的最小化 $C_\alpha(T)$ 的最小子树 T_α 。直接枚举所有子树不可行，**最弱链接剪枝 (weakest link pruning)** 给出高效解法。

每叶代价： 设 t 是内部节点， T_t 是以 t 为根的子树（分支）， $|T_t|$ 为其叶数。若把 T_t 整个折叠成一个叶：误差增加 $\Delta(t)$ （折叠后单叶平方和 - 折叠前分支平方和），叶数减少 $|T_t| - 1$ 。定义「每减少一片叶子的误差代价」

$$g(t) = \frac{\Delta(t)}{|T_t| - 1}$$

剪枝决策： 对固定 α ，剪掉 T_t 使 C_α 的变化为

$$\Delta(t) - \alpha(|T_t| - 1) = (|T_t| - 1)(g(t) - \alpha)$$

故 $g(t) < \alpha$ 时剪掉划算（ C_α 降低）， $g(t) > \alpha$ 时留着划算。对给定 α ，最优树即剪掉所有 $g(t) < \alpha$ 的分支。

算法（自底向上，折叠最弱链接）： 从全树 T_0 出发，对每个内部节点计算 $g(t)$ ；找 $g(t)$ 最小的内部节点（每叶代价最小者，即「最弱链接」）并折叠之；更新受影响的 g ，重复直到单节点（根）树。产生**嵌套序列** $T_0 \supset T_1 \supset \cdots \supset \{\text{根}\}$ 。

关键性质（为何可行）：

1. **嵌套性：** 每棵候选树是前一棵的子树；
2. **完备性（定理）：** 对任意 $\alpha \geq 0$ ，最优子树 T_α 必在此序列中——因为 α 从 0 增大时，满足 $g(t) < \alpha$ 的节点按 $g(t)$ 从小到大**逐个被激活**，折叠最弱链接的顺序恰与激活顺序一致，故任意 α 的最优树都是序列的某个前缀。每棵树对应 α 的一个区间 $[\alpha_k, \alpha_{k+1})$ 。

选 α ： 用五折或十折**交叉验证**在序列上选使交叉验证平方和最小的树（即 $\hat{\alpha}$ ），最终树为 $T_{\hat{\alpha}}$ 。

注记 17.3. 直观：树上有若干分支，有的分支叶子「没什么用」（折叠它误差只增一点， g 小），有的分支叶子「很关键」（折叠误差剧增， g 大）。随 α 增大，先剪「最弱」的分支、最后才剪关键分支。算法复杂度近线性，远比枚举指数级子树高效。

17.2.3 分类树

若目标是取值 $1, \dots, K$ 的分类结果，树算法的变化只在节点分裂和剪枝准则。回归用平方误差节点不纯度 $Q_m(T)$ （式 (17.18)），不适合分类。在节点 m （区域 R_m ， N_m 个观测）中，设

$$\hat{p}_{mk} = \frac{1}{N_m} \sum_{x_i \in R_m} I(y_i = k)$$

为节点 m 中类 k 的比例。把节点 m 中的观测分类到多数类 $k(m) = \arg \max_k \hat{p}_{mk}$ 。节点不纯度 $Q_m(T)$ 的度量包括：

误分类误差： $1 - \hat{p}_{mk(m)}$

$$\text{Gini 指数: } \sum_{k \neq k'} \hat{p}_{mk} \hat{p}_{mk'} = \sum_{k=1}^K \hat{p}_{mk} (1 - \hat{p}_{mk}) \quad (17.20)$$

$$\text{交叉熵 (偏差): } - \sum_{k=1}^K \hat{p}_{mk} \log \hat{p}_{mk}$$

节点不纯度的形式化定义：节点不纯度 $Q_m(T)$ 是衡量节点 m 内观测「混杂程度」的量，是类比例向量 $\hat{\mathbf{p}}_m = (\hat{p}_{m1}, \dots, \hat{p}_{mK})$ 的函数 $Q(\hat{\mathbf{p}}_m)$ ，满足：

- **纯时最小：**某类占满（ $\hat{p}_{mk} = 1$ 对某个 k ）时 Q 取最小值 0（节点完全同质）；
- **杂时最大：**各类均匀（ $\hat{p}_{mk} = 1/K$ 对所有 k ）时 Q 取最大值（节点完全混杂）；
- **对称性：** Q 对类的排列不变；
- **分裂方向：**分裂的目标是使子节点**加权不纯度**下降（子节点比父节点更纯）。

三种度量（误分类率、Gini、交叉熵）都满足这些性质，区别在于对概率变化的敏感性与可微性。

两类情形（ p 为第二类比例）下三者分别为 $1 - \max(p, 1 - p)$ 、 $2p(1 - p)$ 、 $-p \log p - (1 - p) \log(1 - p)$ （图 9.3）。三者相似，但交叉熵和 Gini 指数可微，更适合数值优化。分裂节点时需用两个子节点的观测数 N_{mL}, N_{mR} 加权不纯度。

分类树过程的完整形式化：

1. **节点状态：**节点 m 对应区域 R_m ， $N_m = \#\{x_i \in R_m\}$ ，类 k 的经验比例 $\hat{p}_{mk} = \frac{1}{N_m} \sum_{x_i \in R_m} I(y_i = k)$ ；
2. **叶子决策：**叶 m 输出多数类 $k(m) = \arg \max_k \hat{p}_{mk}$ ，或类概率向量 $\hat{\mathbf{p}}_m = (\hat{p}_{m1}, \dots, \hat{p}_{mK})$ ；
3. **分裂准则（加权不纯度）：**候选分裂 (j, s) 把节点 m 分成子节点 m_L, m_R （区域 $R_{m_L} = R_m \cap \{x_j \leq s\}$ 、 $R_{m_R} = R_m \cap \{x_j > s\}$ ），选使子节点**加权不纯度**最小的分裂：

$$\min_{j,s} \left[\frac{N_{m_L}}{N_m} Q_{m_L}(T) + \frac{N_{m_R}}{N_m} Q_{m_R}(T) \right]$$

其中 Q_m 取式 (17.20) 的度量, 加权因子 N_{mL}/N_m 使大子节点更有发言权; 生长时用 Gini 或交叉熵;

4. **剪枝**: 与回归树相同——代价复杂度 $C_\alpha(T) = \sum_m N_m Q_m(T) + \alpha|T|$ (Q_m 取分类不纯度)、最弱链接剪枝、交叉验证选 α ; 剪枝环节通常用**误分类率**作 Q_m ;
5. **预测**: 输入 x 沿树走到叶 m , 输出多数类 $k(m)$; 需要概率则输出 $\hat{p}_m$ 。

$\hat{p}_m$ 的作用路径: 同一套类比例 $\hat{p}_{mk}$ 驱动三个不同环节, 但各自「消费」方式不同:

1. **分裂**: $\hat{p}$ 经分裂用的 Q_m (Gini 或交叉熵) 决定「怎么切」(加权不纯度最小);
2. **剪枝**: $\hat{p}$ 经剪枝用的 Q_m (通常误分类率) 进入 C_α , 决定「切多大」;
3. **叶子标签**: $k(m) = \arg \max_k \hat{p}_{mk}$ 由 $\hat{p}$ 直接决定, 不经任何 Q_m 。

注记 17.4. 分裂何时停止? 生长阶段不是由「给定层数」决定, 而是由**最小节点大小** (数据量阈值, 教材用 5) 决定——节点样本数降到阈值 (或无法找到有效分裂) 就停止。且生长停止 $\neq$ 最终树: 长满的 T_0 通常过大, 真正决定树大小的是**剪枝 + 交叉验证选 α** ——最终复杂度由数据自适应决定, 而非人工设定层数 (层数限制是工程实现的便利, 不是 CART 经典流程)。

此外, 交叉熵和 Gini 对节点概率变化比误分类率更敏感。例: 两类各 400 观测 (400, 400), 一个分裂产生 (300, 100) 和 (100, 300), 另一个产生 (200, 400) 和 (200, 0)——两者误分类率都是 0.25, 但后者产生**纯节点**、更可取; Gini 和交叉熵对后者更低。因此生长树时用 Gini 或交叉熵; 剪枝时三种都可用, 但通常用误分类率。

Gini 的两种解释: 不把观测分到多数类, 而以概率 $\hat{p}_{mk}$ 分到类 k , 则该规则在节点内的期望训练误差率正是 Gini 指数 $\sum_{k \neq k'} \hat{p}_{mk} \hat{p}_{mk'}$; 把每个观测编码为类 k 则 1、否则 0, 节点内 0-1 响应的方差为 $\hat{p}_{mk}(1 - \hat{p}_{mk})$, 对所有类求和即 Gini 指数。

17.2.4 其他问题

分类预测变量: 有 q 个无序取值的预测变量分裂时, 有 $2^q - 1$ 种把 q 个值分成两组的可能划分, q 大时计算不可行。但 0-1 结果时计算可简化: 按结果类 1 中的比例排序预测变量类别, 然后当作有序预测变量分裂——可证明这在交叉熵或 Gini 意义上给出所有 $2^q - 1$ 种分裂中的最优分裂 (定量结果 + 平方损失也成立, 按结果均值递增排序; Fisher, 1958)。多类别结果无此简化。**注意**: 划分算法倾向偏爱水平数 q 多的分类预测变量 (选择越多越容易对当前数据找到好的), q 大时会导致严重过拟合, 应避免。

损失矩阵: 分类中某些类误分类的后果更严重 (如把有心脏病的人预测为没有)。定义 $K \times K$ 损失矩阵 L , $L_{kk'}$ 是把类 k 观测分成类 k' 的损失, 通常 $L_{kk} = 0$ 。可把 Gini 指数修改为 $\sum_{k \neq k'} L_{kk'} \hat{p}_{mk} \hat{p}_{mk'}$ (随机规则的期望损失)——多类有效, 但二类时因系数为 $L_{kk'} + L_{k'k}$ 而无效果。二类更好的方法是对类 k 的观测加权 $L_{kk'}$ (仅当作为 k 的函

数 $L_{kk'}$ 不依赖 k' 时可用于多类)。观测加权可配合偏差使用，效果是改变类的先验概率。终节点中经验贝叶斯规则分类到 $k(m) = \arg \min_k \sum_{\ell} L_{\ell k} \hat{p}_{m\ell}$ 。

缺失预测值：丢弃含缺失值的观测可能严重削减训练集；填充（如均值）也可行。树模型有更好的两种方法：**分类预测变量：**为「缺失」建一个新类别；**更一般：替代变量 (surrogate variables)**。分裂时只用该预测变量不缺失的观测；选定最佳（主）预测变量和切点后，形成替代预测变量和切点列表——第一替代是最能模仿主分裂的预测变量，第二替代次之，依次类推。训练或预测中，若主分裂变量缺失，就依次使用替代分裂。替代分裂利用预测变量间的相关性缓解缺失的影响。缺失数据的一般问题见 §9.6。

为什么二元分裂？多元分裂（一次分多组）会过快碎片化数据，使下一层数据不足。多元分裂可用一系列二元分裂实现，因此后者更可取。

其他树构建方法：讨论聚焦 CART。另一流行方法是 ID3 及其后续 C4.5、C5.0 (Quinlan, 1993)。早期版本限于分类预测变量、自顶向下且不剪枝；C5.0 与 CART 已很相似。C5.0 独有的最重要特性是**推导规则集**：树长好后，定义终节点的分裂规则有时可简化（去掉一个或多个条件不改变落入节点的观测子集），得到简化的规则集——不再是树结构，但更简单、对用户更有吸引力。

线性组合分裂：可允许沿 $\sum_j a_j X_j \leq s$ 形式的线性组合分裂，权重 a_j 和切点 s 优化以最小化相关准则（如 Gini）。可提高预测力但损害可解释性；切点搜索的离散性使权重无法用光滑优化。更好的方式是在 **HME（专家分层混合）** 模型中引入 (§9.5)。

树的不稳定性：主要问题是高方差。数据的微小变化常导致完全不同的分裂序列，使解释不稳。主因是过程的层次性：顶层分裂的错误会传播到其下所有分裂。可用更稳定的分裂准则缓解，但固有不确定性无法消除——这是从数据估计简单树结构的代价。**Bagging (§8.7)** 平均许多树来降低此方差。

缺乏光滑性：预测面不光滑（图 9.2 右下）。0/1 损失分类下影响不大（类概率估计的偏差影响有限），但回归设置中会降低性能（通常期望底层函数光滑）。**MARS (§9.4)** 可看作缓解此缺点的 CART 修正。

难以捕捉加性结构：树难以建模加性结构。例： $Y = c_1 I(X_1 < t_1) + c_2 I(X_2 < t_2) + \varepsilon$ 。二元树第一层在 X_1 上近 t_1 分裂；下一层需在 X_2 的 t_2 处分裂两个节点才能捕捉加性结构——数据充足时可能发生，但模型没有被特别鼓励去找这种结构。若有十个加性效应，需很多凑巧的分裂才能重建结构。MARS 放弃树结构以捕捉加性结构。

17.2.5 分类性能评估统计量

对二分类问题，把类 1 视为「正类」、类 0 视为「负类」。混淆矩阵记录真正例 TP 、假正例 FP 、真负例 TN 、假负例 FN ：

	预测正类	预测负类
真实正类	TP	FN
真实负类	FP	TN

核心统计量的数学定义：

$$\text{灵敏度 (sensitivity) / 召回率 / TPR} = \frac{TP}{TP + FN} \quad (17.21)$$

$$\text{特异度 (specificity) / TNR} = \frac{TN}{TN + FP} \quad (17.22)$$

$$\text{假正率 FPR} = \frac{FP}{FP + TN} = 1 - \text{特异度} \quad (17.23)$$

$$\text{精度 (precision)} = \frac{TP}{TP + FP} \quad (17.24)$$

$$\text{F1 分数} = \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} = \frac{2TP}{2TP + FP + FN} \quad (17.25)$$

$$\text{准确率 (accuracy)} = \frac{TP + TN}{TP + FP + TN + FN} \quad (17.26)$$

- **灵敏度** (= 召回率 = TPR)：真实正类中被预测为正类的比例——「别漏掉正类」；
- **特异度** (TNR)：真实负类中被预测为负类的比例——「别误报负类」；
- **FPR**：负类被误报为正类的比例，= 1 - 特异度；
- **精度**：预测为正类的样本中真正为正类的比例；
- **F1 分数**：精度与召回率的调和平均，同时惩罚漏报与误报（类别不平衡时比准确率更稳健）；
- **准确率**：总正确比例。

数值示例：若某测试集混淆矩阵为 $TP = 33.4$ 、 $FN = 5.3$ 、 $TN = 57.3$ 、 $FP = 4.0$ （百分比），则

$$\text{灵敏度} = \frac{TP}{TP + FN} = \frac{33.4}{38.7} = 86.3\%, \quad \text{特异度} = \frac{TN}{TN + FP} = \frac{57.3}{61.3} = 93.4\%$$

ROC 曲线：接收者操作特征曲线 (Receiver Operating Characteristic, ROC) 刻画分类器在所有可能阈值下的性能。对每个阈值 τ ，把预测分数 $\hat{s}(x) \geq \tau$ 判为正类，计算一对 (FPR, TPR)；把所有阈值对应的点连成曲线——横轴为假正率 FPR（式 (17.23)）、纵轴为真正率 TPR（式 (17.21)）。两个参考基准：

- **完美分类器**经过 (0, 1) 点 ($FPR = 0$ 、 $TPR = 1$)；
- **随机猜测**为对角线 $TPR = FPR$ 。

曲线越靠近左上角（面积越大）分类器越好。ROC 不依赖具体阈值、对类别不平衡稳健，故常用于比较不同分类器。

曲线下面积 (AUC) 与 c 统计量： AUC 是 ROC 曲线下的面积 (0.5 为随机、1 为完美)，常称为 **c 统计量**。它等价于「随机抽取一个正例与一个负例，正例预测分数高于负例的概率」：

$$\text{AUC} = c = \Pr(\hat{s}_+ > \hat{s}_-)$$

其中 $\hat{s}$ 为分类器的预测分数。可证 AUC 等价于 **Mann–Whitney U 统计量** (或 Wilcoxon 秩和检验) 关于两组预测分数的秩 (Hanley and McNeil, 1982)。注意：评估「给模型新增一个预测变量的贡献」时 c 统计量可能不敏感 (新变量可显著改变模型偏差却只微增 AUC)，应结合单个样本层面的分类变化来考察 (Cook, 2007)。

17.3 PRIM: Bump Hunting

基于树的方法 (回归) 把特征空间划分为盒状区域，使每个盒内响应均值尽可能不同；定义盒子的分裂规则通过二元树关联，便于解释。**患者规则归纳法 (Patient Rule Induction Method, PRIM)** 也在特征空间中找盒子，但寻找响应均值很高的盒子——即寻找目标函数的极大值，称为「bump hunting (隆起搜寻)」 (要找极小值只需对响应取负)。

PRIM 与树方法的区别：盒子定义不由二元树描述——这让规则集合的解释更难，但去掉二元树约束后，单条规则往往更简单。

形式化定义： 设数据 (x_i, y_i) , $x_i \in \mathcal{X} \subseteq \mathbb{R}^p$, y_i 为定量响应。PRIM 的目标是找响应均值高的轴对齐矩形 (盒子)：

$$B = \{x \in \mathcal{X} : a_j \leq x_j \leq b_j, j \in S\}, \quad S \subseteq \{1, \dots, p\}$$

盒子 B 的支持 (样本数) 与均值：

$$N_B = \#\{x_i \in B\}, \quad \bar{y}_B = \frac{1}{N_B} \sum_{x_i \in B} y_i$$

理想情形求 $\max_B \bar{y}_B$ (受盒子最小支持约束)；贪心实现为「剥离 + 粘贴」。记 I_B 为盒子 B 中观测的索引集。**剥离一步：** 对每个变量 j 与上/下端，剥掉比例 α 的观测 (该变量最高或最低值那端)，得候选盒子集合 $\mathcal{P}(B)$ ，选

$$B' = \arg \max_{C \in \mathcal{P}(B)} \bar{y}_C$$

重复直至 $N_B \leq n_{\min}$ (如 10)。**粘贴：** 沿任意边扩张盒子使 $\bar{y}_B$ 增加。得到盒子序列后，用交叉验证选最优大小，得 B_1 ；移除 B_1 中观测，对剩余数据重复，得 $B_1, \dots, B_k$ 。

盒子构建： 自上而下剥离 (top-down peeling) (图 9.7)：

1. 从包含全部数据的盒子出发；
2. 沿一个面小幅压缩盒子，把落入盒子的观测「剥离」；选择使压缩后盒子均值最大的那个面；

3. 重复，直到盒子只剩最少数据点数。




FIGURE 9.7. Illustration of PRIM algorithm. There are two classes, indicated by the blue (class 0) and red (class 1) points. The procedure starts with a rectangle (broken black lines) surrounding all of the data, and then peels away points along one edge by a prespecified amount in order to maximize the mean of the points remaining in the box. Starting at the top left panel, the sequence of peelings is shown, until a pure red region is isolated in the bottom right panel. The iteration number is indicated at the top of each panel.

图 17.2: PRIM 算法示意 (图 9.7)。两个类: 蓝点 (类 0) 与红点 (类 1)。过程从包围全部数据的矩形 (黑色虚线) 出发, 沿一条边按预设量剥离点, 以最大化盒内剩余点的均值。从左上面板开始显示剥离序列, 直到右下面板隔离出纯红区域; 每面板顶部标出迭代号。

自下而上粘贴 (bottom-up pasting): 自上而下序列算完后, PRIM 反向操作——沿任意边扩张盒子, 只要扩张能提高盒子均值就进行。因为自上而下是贪心的, 这种扩张常常可行。

结果是一列盒子 (各有不同观测数), 用交叉验证 + 分析者判断选择最优盒子大小。记 B_1 为第一步找到的盒子的观测索引, PRIM 把 B_1 中的观测从训练集移除, 在剩余数据上重复「自上而下剥离 + 自下而上粘贴」, 得到一系列盒子 $B_1, B_2, \dots, B_k$ 。每个盒子由涉及部分预测变量的规则定义, 如 $(a_1 \leq X_1 \leq b_1)$ 且 $(b_1 \leq X_3 \leq b_2)$ 。




FIGURE 9.8. Box mean as a function of number of observations in the box.

图 17.3: 盒子均值随盒子内观测数的变化 (图 9.8)。随着剥离不断压缩盒子、观测数减少, 盒子均值逐渐上升——用于帮助在「盒子大小」与「盒子纯度」之间权衡、结合交叉验证选择最优盒子。

Algorithm 9.3 (患者规则归纳法):

1. 从全部训练数据出发, 取包含全部数据的最大盒子;
2. 考虑压缩一个面来收缩盒子, 剥离比例 α 的观测 (某预测变量 X_j 最高值或最低值那端); 选择使剩余盒子响应均值最高的剥离 (通常 $\alpha = 0.05$ 或 0.10);
3. 重复步骤 2 直到盒子只剩最小观测数 (如 10);
4. 沿任意面扩张盒子, 只要盒子均值增加;
5. 步骤 1–4 给出盒子序列, 用交叉验证选一个, 记为 B_1 ;
6. 移除 B_1 中的数据, 重复步骤 2–5 得第二个盒子, 继续得任意多个。

PRIM 的「耐心」优势: PRIM 处理分类预测变量、缺失值的方式类似 CART。PRIM 为回归 (定量响应) 设计; 二类结果可编码为 0/1; $k > 2$ 类无简单方法 (可对每类 vs 基线类分别跑)。PRIM 相对 CART 的优势是**耐心**: CART 的二元分裂快速碎片化数据——若等大小分裂, N 个观测只能做 $\log_2(N) - 1$ 次分裂; PRIM 每步剥离比例 α , 可做约 $-\log(N)/\log(1 - \alpha)$ 次剥离。例: $N = 128$ 、 $\alpha = 0.10$ 时 $\log_2(128) - 1 = 6$, 而 $-\log(128)/\log(0.9) \approx 46$ (考虑整数观测实际可剥离 29 次)。PRIM 更耐心, 有助于自上而下贪心算法找到更好的解。

9.3.1 spam 例 (续): 对 spam 数据应用 PRIM (spam = 1、email = 0)。前两个盒子: 第一个盒子几乎纯 spam, 约含测试集 15%; 第二个盒子含 10.6% 测试观测、其中 92.6% 为 spam。两盒合计含 26% 数据、约 97% 为 spam。有趣的是 CART 树 (图 9.5) 的顶层分裂变量没有出现在 PRIM 的第一个盒子里。

17.4 MARS: 多元自适应回归样条

MARS (Multivariate Adaptive Regression Splines) 是自适应回归过程, 适合高维问题 (输入多)。可视为逐步线性回归的推广或 CART 的修正 (改进其在回归设置中的表现)。我们从逐步回归视角引入, 再联系 CART。

MARS 使用指南:

- **适用:** 高维输入 (p 大); 响应与输入非线性、可能含交互项、但又有加性成分 (MARS 两者都能抓——树抓不了加性、GAM 需手动加交互); 预测面需要光滑 (缓解树的阶梯状不光滑); 需要一定可解释性 (最终模型由少量基函数组成)。
- **回归与分类:** 本质是回归工具。定量响应直接做; 二分类可编码 0/1 当回归做 (spam 例); 多分类需指示响应 (§4.2) 多响应 MARS (有 masking 问题) 或更优的最优打分 (§12.5)、PolyMARS (多项 logistic 变体, 见 §9.4.3)。
- **不适合:** 多类分类 (需额外处理); 模型项多而样本小 (计算 $NM^3 + pM^2N$ 昂贵, 见 §9.7)。
- **谱系定位:** 线性回归 $\rightarrow$ GAM (加性、光滑、需手动交互) $\rightarrow$ MARS (加性 + 自动交互、光滑、高维) $\rightarrow$ 树 (分块常数、可解释、方差大)。MARS 处在「光滑 + 自动交互 + 高维」的交点。

为什么需要这些特性 (三条深挖):

1. **为什么树抓不了加性?** 树的模型是 $f(x) = \sum_m c_m I(x \in R_m)$, 区域 R_m 是递归嵌套的矩形 (每个叶子 = 沿树路径的多重条件交集)。对加性结构 $Y = f_1(X_1) + f_2(X_2)$, X_1 的效应在 X_2 的任何取值下都存在——但树要表达 f_2 必须在每一个 X_1 分支里都切 X_2 , 贪心树不会主动这样做。例: $Y = c_1 I(X_1 < t_1) + c_2 I(X_2 < t_2) + \varepsilon$, 第一层在 $X_1 \approx t_1$ 分裂后, 下一层必须同时在 $X_2 = t_2$ 分裂两个子节点。更本质: 加性函数的等值线是「对角/直的」, 而树的矩形是轴对齐的——用分块常数近似加性面需指数级多的叶子 (图 8.12 的 $x_1 + x_2 = 1$ 对角线例子)。而 GAM/MARS 的结构 $f = \sum_j f_j(x_j)$ 天然含加性。
2. **GAM 怎么手动加交互?** GAM 纯加性, 本身不含交互; 教材建议拟合后检查加入交互是否显著改进——「手动」插入显著输入的乘积, 或自动用 MARS。手动方法: 构造乘积项 (把 $X_j X_k$ 作为新变量加入); 加双变量光滑项 $g(X_1, X_2)$ (张量积基 / 表面平滑器), 即 $g(\mu) = \alpha + \sum_j f_j(X_j) + g(X_1, X_2)$; 因子交互 (对定性变量每个水平拟合不同曲线 $g_k(Z)$); 变系数 $X_2 f_1^*(X_1)$ 。GAM 需手动决定加哪些交互并做模型比较; MARS 用乘积基函数自动搜索交互。
3. **什么情况下预测面需要光滑?** 光滑 = 输入微小变化 $\Rightarrow$ 预测微小变化。需要的情形: 回归任务且底层过程连续 (教材: 「回归设置中通常期望底层函数光滑」);

需要连续预测值（响应连续时阶梯跳跃不真实）；需要可解释的效应曲线（GAM 的 f_j 光滑分量）；插值 / 外推。不光滑可接受的情形：0/1 分类（教材：「类概率估计偏差影响有限」）、需要可解释规则（树的 if-then 规则本质离散）。

分段线性基函数： MARS 用形如 $(x - t)_+$ 和 $(t - x)_+$ 的分段线性基函数（图 9.9），其中「+」表示正部：

$$(x - t)_+ = \begin{cases} x - t, & x > t \\ 0, & \text{否则} \end{cases}, \quad (t - x)_+ = \begin{cases} t - x, & x < t \\ 0, & \text{否则} \end{cases}$$

每个函数分段线性、在 t 处有结点（按第 5 章术语即**线性样条**）。把这两个函数称为一个**反射对**（reflected pair）。对每个输入 X_j 、结点取该输入每个观测值 x_{ij} ，形成基函数集合

$$\mathcal{C} = \{(X_j - t)_+, (t - X_j)_+\}_{t \in \{x_{1j}, \dots, x_{Nj}\}, j=1, \dots, p} \quad (17.27)$$

输入值全不同时共有 $2Np$ 个基函数。每个基函数虽只依赖单个 X_j ，但视为整个输入空间 $\mathbb{R}^p$ 上的函数。

模型形式： 建模策略类似前向逐步线性回归，但用 $\mathcal{C}$ 中的函数及其乘积：

$$f(X) = \beta_0 + \sum_{m=1}^M \beta_m h_m(X) \quad (17.28)$$

其中每个 h_m 是 $\mathcal{C}$ 中一个函数，或两个及以上此类函数的乘积。给定 h_m 后，系数 β_m 由最小二乘（残差平方和最小）估计——真正的艺术在于构造 h_m 。

前向构建： 从只有常数 $h_0(X) = 1$ 开始， $\mathcal{C}$ 中所有函数都是候选。每步考虑「模型中一个函数 h_ℓ 与 $\mathcal{C}$ 中一个反射对的乘积」作为新基函数对，加入使训练误差下降最多的项

$$\hat{\beta}_{M+1} h_\ell(X) \cdot (X_j - t)_+ + \hat{\beta}_{M+2} h_\ell(X) \cdot (t - X_j)_+$$

直到模型含预设最大项数。例如第一轮： $h_0(X) = 1$ 、 $h_1(X) = (X_2 - x_{72})_+$ 或 $h_2(X) = (x_{72} - X_2)_+$ ；第三次可产生 $(X_1 - x_{51})_+ \cdot (x_{72} - X_2)_+$ （图 9.11）。

两个构建约束：

- **层次性：** 高阶乘积只能由已在模型中的低阶项生成（如四阶乘积需其一三阶分量已在模型中）——合理假设「高阶交互只在其低阶足迹存在时才可能存在」，避免指数级搜索；
- **每个输入在每个乘积中最多出现一次：** 防止生成高阶幂（在特征空间边界处增减过陡），高阶幂可被分段线性函数更稳定地近似。

可设交互阶数上限（如 2 允许两两乘积；上限 1 即加性模型），有助于解释最终模型。

后向删除与 GCV: 前向得到的模型通常过拟合, 用后向删除——每步删除「移除后残差平方和增加最小」的项, 得到每个大小 (项数) λ 的最佳模型 $\hat{f}_\lambda$ 。为计算节省, MARS 用广义交叉验证 (GCV):

$$\text{GCV}(\lambda) = \frac{\sum_{i=1}^N (y_i - \hat{f}_\lambda(x_i))^2}{(1 - M(\lambda)/N)^2} \quad (17.29)$$

其中 $M(\lambda)$ 是模型的有效参数数——既含项数, 也含选择最优结点位置用的参数数。数学与模拟结果表明, 分段线性回归中选择一个结点应付 3 个参数的代价: 若模型有 r 个线性无关基函数、前向过程选了 K 个结点, 则 $M(\lambda) = r + cK$, $c = 3$ (加性限制时 $c = 2$)。沿后向序列选 GCV 最小的模型。

为什么分段线性基函数?

1. **局部性:** 这些函数在一部分取值范围内为零 (图 9.9); 相乘后 (图 9.11) 只在两个分量函数均非零的小区域非零——回归面得以简约地由局部非零分量搭成, 「只需要处花参数」, 对高维很重要 (多项式等基函数处处非零, 效果不好)。
2. **计算效率:** 试探一个输入的全部 N 个反射对看似需 $O(N^2)$ 操作; 但利用分段线性函数形式, 结点每次左移一个位置时基函数只在左部相差、右部相差常数, 可 $O(1)$ 更新拟合, 最终试探每个结点仅 $O(N)$ 。

9.4.1 spam 例 (续): 对 spam 数据应用 MARS, 限制二阶交互。虽然目标是二类变量, 仍用平方误差损失 (见 §9.4.3)。测试误差约 5.5% (略高于 GAM 的 5.3%)。GCV 选模型大小 60 (约最小的最优模型)。主要交互涉及 (ch\$, remove)、(ch\$, free)、(hp, CAPTOT), 但对性能无提升。

9.4.2 模拟例子: $N = 100$, 预测变量与误差独立标准正态, 三个场景:

$$\text{场景 1: } Y = (X_1 - 1)_+ + (X_1 - 1)_+ \cdot (X_2 - 0.8)_+ + 0.12\varepsilon \quad (17.30)$$

(张量积场景, 乘积项给出图 9.11 那样的面); 场景 2 同场景 1 但 $p = 20$ (18 个与响应无关的输入); 场景 3 为神经网络结构:

$$\ell_1 = X_1 + X_2 + X_3 + X_4 + X_5, \quad \ell_2 = X_6 - X_7 + X_8 - X_9 + X_{10}, \quad Y = \sigma(\ell_1) + \sigma(\ell_2) + 0.12\varepsilon \quad (17.31)$$

场景 1、2 非常适合 MARS, 场景 3 含加性非线性结构。

9.4.3 其他问题:

- **MARS 用于分类:** 二类编码 0/1 当回归做 (spam 例); 多类用指示响应 (§4.2) 做多响应 MARS——所有响应变量共用一组基函数, 分类到预测响应最大的类 (可能有 masking 问题); 更优的是 §12.5 的「最优打分」。PolyMARS (Stone et al., 1997) 用多项 logistic 框架, 每步用多项对数似然的二次近似搜索下一个基函数对。

- **MARS 与 CART 的关系：**把 MARS 做两处修改——分段线性基函数换成阶梯函数 $I(x - t > 0)$ 、 $I(x - t \leq 0)$ ；模型项参与候选相乘后即被交互项替换、不再参与进一步交互——则 MARS 前向过程与 CART 树生长相同。阶梯函数与反射阶梯对相乘等价于在台阶处分裂节点；第二个限制意味着节点最多分裂一次，产生 CART 的二元树表示——也因此 CART 难以建模加性结构，而 MARS 放弃树结构、获得捕捉加性效应的能力。
- **混合输入：**MARS 自然处理定量 + 定性混合输入：对定性预测变量考虑类别的一切二元划分，每划分产生一对分段常数基函数（两个类别集合的指示函数），像其他基函数一样参与张量积。

17.5 专家分层混合（HME）

专家分层混合（Hierarchical Mixtures of Experts, HME）可视为树方法的变体。主要区别：树的分裂不是硬决策而是软概率决策——每个节点处观测按依赖其输入值的概率走左或右。这有计算优势：参数优化问题光滑（不像树方法那样离散切点搜索）。软分裂也可能提高预测精度、提供有用的数据替代描述。

HME 与 CART 的其他区别：HME 在每个终节点拟合线性（或 logistic 回归）模型而非常数；分裂可以多元（非仅二元）；分裂是输入的线性组合的概率函数，而非单个输入。这些选择的相对优劣不明确。

术语：二层 HME（图 9.13）——终节点称**专家（experts）**，非终节点称**门控网络（gating networks）**。每个专家给出对响应的意见（预测），门控网络把它们组合起来。模型形式上是一个混合模型，可扩展到多层，故名「分层混合」。




FIGURE 9.13. A two-level hierarchical mixture of experts (HME) model.

图 17.4: 两层专家分层混合 (HME) 模型 (图 9.13)。上层门控网络 g_1, g_2 把输入按概率分到两支; 每支内第二层门控 $g_{1|1}, g_{2|1}, g_{1|2}, g_{2|2}$ 再软分配到专家; 每个专家给出条件分布 $\Pr(y | x, \theta_{\ell j})$ 。

设数据 (x_i, y_i) , y_i 连续或二元, x_i 向量输入 (第一元素为 1 以计入截距)。顶层门控网络输出

$$g_j(x, \gamma_j) = \frac{e^{\gamma_j^T x}}{\sum_{k=1}^K e^{\gamma_k^T x}}, \quad j = 1, \dots, K \quad (17.32)$$

其中每个 γ_j 是未知参数向量。这个式子叫 **softmax**: 分子 $\exp(\gamma_j^T x)$ 是「输入 x 对第 j 支的偏好得分」, 分母 (对所有 k 求和) 起归一化作用, 使 $0 \leq g_j \leq 1$ 且 $\sum_j g_j = 1$ ——于是一组 g_j 构成概率。这是软的 K 路分裂 (图 9.13 中 $K = 2$), g_j 是把特征 x 的观测分到第 j 支的概率。 $K = 2$ 时若 x 某元素系数取 $+\infty$, 得到无限斜率的 logistic 曲线、门控概率为 0 或 1——对应硬分裂。

第二层门控形式类似:

$$g_{\ell j}(x, \gamma_{j\ell}) = \frac{e^{\gamma_{j\ell}^T x}}{\sum_{k=1}^K e^{\gamma_{jk}^T x}}, \quad \ell = 1, \dots, K \quad (17.33)$$

即给定分配到上层第 j 支后, 分配到第 ℓ 支的概率。注意分母 $\sum_k e^{\gamma_{jk}^T x}$ 只在分支 j 内

归一化 (j 固定), 故 $\sum_{\ell} g_{\ell|j} = 1$ ——对每个上层分支, 第二层各自形成一组概率。

每个专家 (终节点) 对响应建模 $Y \sim \text{Pr}(y | x, \theta_{j\ell})$:

$$\text{回归: } Y = \beta_{j\ell}^T x + \varepsilon, \varepsilon \sim N(0, \sigma_{j\ell}^2) \quad (17.34)$$

$$\text{分类: } \text{Pr}(Y = 1 | x, \theta_{j\ell}) = \frac{1}{1 + e^{-\theta_{j\ell}^T x}} \quad (17.35)$$

每个专家在自己的「负责区域」内用简单模型预测响应: 回归给出条件均值 $\beta_{j\ell}^T x$ (加高斯噪声); 分类给出正类概率 (sigmoid/logistic)。专家是「分工」的执行者——它只学习分配给它的数据, 而不管区域边界 (边界由门控网络决定)。

记全部参数为 $\Psi = \{\gamma_j, \gamma_{j\ell}, \theta_{j\ell}\}$, $Y = y$ 的总概率为

$$\text{Pr}(y | x, \Psi) = \sum_{j=1}^K g_j(x, \gamma_j) \sum_{\ell=1}^K g_{\ell|j}(x, \gamma_{j\ell}) \text{Pr}(y | x, \theta_{j\ell}) \quad (17.36)$$

这是**全概率公式** (对隐变量「哪个专家负责」边缘化): $g_j(x) g_{\ell|j}(x)$ 是走路径 $j\ell$ 的门控概率 (权重), $\text{Pr}(y | x, \theta_{j\ell})$ 是单个专家模型; 把所有专家的贡献按门控概率**加权相加**, 得到响应 y 的**混合分布**。混合权重由门控网络决定——这正是「**分层混合**」的含义。

估计: 最大化数据对数似然 $\sum_i \log \text{Pr}(y_i | x_i, \Psi)$ 。最方便的是 **EM 算法** (§8.5): 定义隐变量 Δ_j (全零仅一个为 1, 解释为顶层门控的分支决策) 与第二层 $\Delta_{\ell|j}$ 。E 步计算 Δ_j 、 $\Delta_{\ell|j}$ 的期望 (概率轮廓), 作为 M 步中的观测权重来估计专家网络参数; 内部节点参数用多重 logistic 回归估计 (期望概率轮廓作为响应向量)。

与 CART 的比较: HME 是 CART 的有力竞争者——软分裂而非硬决策, 可捕捉低到高响应渐变的情形; 对数似然是未知权重的光滑函数, 便于数值优化; 与 CART 的线性组合分裂类似但后者更难优化。另一方面, HME 没有像 CART 那样的树拓扑选择方法 (通常用固定深度树, 可能取 CART 的输出)。HME 研究强调预测而非解释。近亲是**潜类模型** (通常单层, 节点/潜类解释为行为相似的对象组)。

训练: 回归还是分类, 以及如何估计参数

回归还是分类? HME 两者都能处理, 取决于**专家模型** (门控结构不变):

- **回归:** 专家用高斯线性回归 (式 (17.34)) $Y = \beta_{j\ell}^T x + \varepsilon$;
- **分类:** 专家用 logistic 回归 (式 (17.35)) $\text{Pr}(Y = 1 | x, \theta_{j\ell}) = 1/(1 + e^{-\theta_{j\ell}^T x})$ 。

这与「回归树 vs 分类树」类似: 结构一样, 只有叶子 (专家) 的模型按任务选择。

如何估计参数? ——不是「先训练专家 / 分开训练」, 而是 **EM 联合估计**。所有参数 $\Psi = \{\gamma_j, \gamma_{j\ell}, \theta_{j\ell}\}$ 一起最大化数据对数似然:

$$\max_{\Psi} \sum_i \log \text{Pr}(y_i | x_i, \Psi)$$

若知道每个观测实际走哪条路径 (归哪个专家), 可分开拟合——但**路径未知** (正是隐变量), 故用 **EM 算法** (§8.5 混合模型版):

1. **隐变量**： Δ_j （顶层门控分支决策，one-hot）、 $\Delta_{\ell j}$ （第二层门控决策）——表示「该观测走了哪条路径」；
2. **E 步**：给定当前参数，计算隐变量期望 = 每个观测分到各分支/专家的后验概率（「概率轮廓」）——**软分配**（每个观测「部分属于」每个专家）；
3. **M 步**：用这些概率作观测权重更新参数——**专家参数**加权拟合（回归 = 加权最小二乘；分类 = 加权 logistic），**门控参数**用多重 logistic 回归（概率轮廓作响应向量）；
4. 迭代 E/M 至收敛。

直觉：先猜软分配（E），据此优化各专家与门控（M），再看更合理的分配（E），再优化（M）……——一个「软聚类 + 各专家拟合」的交替过程。

「后验」的澄清：参数估计用 MLE（频率学派），而 E 步的「后验」是**隐变量（潜分配）**的后验，不是贝叶斯的参数后验：

- **贝叶斯后验**：参数 θ 的后验 $\Pr(\theta \mid \text{数据})$ ——贝叶斯推断；
- **这里的后验**： $\Pr(\Delta \mid \text{数据}, \Psi)$ ——隐变量（哪个专家负责）的条件概率，是 EM 的计算工具（软分配），服务于频率学派的 MLE。

这与 GMM 的「责任（responsibility）」、§8.5 的 E 步 $\hat{\gamma}_i = \mathbb{E}(\Delta_i \mid \theta, \mathbf{Z})$ 是同一件事。

形式化：

参数定义 ($\Psi = \{\gamma_j, \gamma_{j\ell}, \theta_{jl}\}$)：设输入 $x \in \mathbb{R}^d$ ($d = p + 1$ ，含截距项)。

- $\gamma_j \in \mathbb{R}^d$ ($j = 1, \dots, K$)：**顶层门控参数**——决定把观测分到第 j 支的概率 $g_j(x, \gamma_j)$ （式 (17.32)）；
- $\gamma_{j\ell} \in \mathbb{R}^d$ ($j, \ell = 1, \dots, K$)：**第二层门控参数**——给定上层第 j 支后，决定分到第 ℓ 支的概率 $g_{\ell|j}(x, \gamma_{j\ell})$ （式 (17.33)）；
- θ_{jl} ：**专家参数**——回归时 $\theta_{jl} = (\beta_{jl}, \sigma_{jl}^2)$ ，其中 $\beta_{jl} \in \mathbb{R}^d$ 是回归系数、 $\sigma_{jl}^2 > 0$ 是误差方差（式 (17.34)）；分类时 $\theta_{jl} \in \mathbb{R}^d$ 是 logistic 回归系数（式 (17.35)）。

门控的 softmax 存在尺度冗余（对 γ 加常数不改变概率），实践中常固定一个参考向量（如 $\gamma_K = 0$ ）或对二分支直接用 sigmoid。

1. **模型（前向）**：隐变量 $\Delta_{jl} \in \{0, 1\}$ 、 $\sum_{jl} \Delta_{jl} = 1$ （指示观测属于专家 (j, l) ）；路径概率

$$p_{jl}(x) = g_j(x, \gamma_j) g_{\ell|j}(x, \gamma_{j\ell})$$

专家条件模型 $y \mid \Delta_{jl} = 1, x \sim \text{Pr}(y \mid x, \theta_{jl})$ (若观测由专家 jl 负责, y 按该专家模型生成); 观测密度为混合模型

$$\text{Pr}(y \mid x, \Psi) = \sum_{j,l} p_{jl}(x) \text{Pr}(y \mid x, \theta_{jl}), \quad \Psi = \{\gamma_j, \gamma_{jl}, \theta_{jl}\}$$

其中 $p_{jl}(x)$ 是「走路径 jl 」的总门控概率 (两层软分配的乘积), 混合密度对所有专家加权求和 (隐变量 Δ 被边缘化)。

2. **目标:** 观测对数似然 $\ell(\Psi) = \sum_i \log \text{Pr}(y_i \mid x_i, \Psi)$ (对数内求和, 直接最大化困难); 完全数据对数似然

$$\ell_c(\Psi) = \sum_i \sum_{j,l} \Delta_{i,jl} [\log p_{jl}(x_i) + \log \text{Pr}(y_i \mid x_i, \theta_{jl})]$$

若知道每个观测的 Δ (归属), 完全数据似然对每个专家**独立分解** (对数内无求和), M 步简单; 但 Δ 未知, 故用其期望 (E 步) 填补。

3. **E 步 (隐变量后验 / 软分配):**

$$r_{i,jl} = \text{Pr}(\Delta_{i,jl} = 1 \mid x_i, y_i, \Psi) = \frac{p_{jl}(x_i) \text{Pr}(y_i \mid x_i, \theta_{jl})}{\sum_{j',l'} p_{j'l'}(x_i) \text{Pr}(y_i \mid x_i, \theta_{j'l'})}$$

这是**贝叶斯公式**: 后验 $r = (\text{路径先验 } p_{jl} \times \text{专家似然}) \div \text{归一化常数}$ (y_i 归所有专家的总概率)。它回答「观测 i 归专家 jl 负责的概率」, 即软分配权重。

4. **M 步: 最大化**

$$Q(\Psi) = \sum_i \sum_{j,l} r_{i,jl} [\log p_{jl}(x_i) + \log \text{Pr}(y_i \mid x_i, \theta_{jl})]$$

用软分配 r 作权重, 把「完全数据似然的期望」最大化: 专家 θ_{jl} 用 $r_{i,jl}$ 为权重的加权 MLE (回归 = 加权最小二乘; 分类 = 加权 logistic); 门控 γ 以 r 为响应做 softmax / 多项 logistic 回归。

5. 迭代 E/M 至收敛; EM 保证观测对数似然**单调不减** $\ell(\Psi^{(t+1)}) \geq \ell(\Psi^{(t)})$ 。

树拓扑固定: HME 没有 CART 那样的拓扑选择方法——通常用**固定深度**的树结构 (可能取 CART 输出作初始拓扑)。即「学」的是参数 (门控 + 专家权重), 「结构」(深度、分路数) 预设。

17.6 缺失数据

输入特征常存在缺失值。常用做法是某种方式**填补 (impute)** 缺失值。但首要问题是判断缺失机制是否扭曲了观测数据。

随机缺失的定义：粗略说，若导致缺失的机制独立于其（未观测）值，则数据随机缺失。设 y 为响应向量、 X 为 $N \times p$ 输入矩阵（部分缺失）， X_{obs} 为观测到的条目， $\mathbf{Z} = (y, X)$ 、 $\mathbf{Z}_{\text{obs}} = (y, X_{\text{obs}})$ 。若 R 是指示矩阵（ x_{ij} 缺失则第 (i, j) 项为 1、否则 0），则称数据**随机缺失（MAR）**若 R 的分布只通过 $\mathbf{Z}_{\text{obs}}$ 依赖数据：

$$\Pr(R | \mathbf{Z}, \theta) = \Pr(R | \mathbf{Z}_{\text{obs}}, \theta) \quad (17.37)$$

θ 是 R 分布中的参数。若 R 的分布既不依赖观测也不依赖缺失数据：

$$\Pr(R | \mathbf{Z}, \theta) = \Pr(R | \theta) \quad (17.38)$$

则称**完全随机缺失（MCAR）**。MCAR 比 MAR 强；多数填补方法依赖 MCAR 才有效。

例：若医生因病人「太重病」而未测量某指标，则该观测不满足 MAR/MCAR——缺失机制使训练数据扭曲真实总体，此时填补危险。常需从数据收集过程判断特征是否 MCAR；对分类特征，可把「缺失」编码为额外类，拟合模型看「缺失」类是否预测响应。

三种缺失机制（通俗对照）：

- **MCAR (Missing Completely At Random, 完全随机缺失)：**缺失与任何变量（观测的或未观测的）都无关。例：问卷被风吹走了几页，某几题的缺失纯属偶然。
- **MAR (Missing At Random, 随机缺失)：**缺失与已观测到的变量有关，但与缺失值本身无关。例：男性更不愿填收入——「性别」是已观测变量，可以解释缺失。
- **MNAR (Missing Not At Random, 非随机缺失)：**缺失与缺失值本身有关——即使已知其他所有变量也无法解释。例：高收入者更不愿填收入——缺失本身就指向高收入。

直觉判断：问「能否用已观测到的信息解释这个缺失？」

- 能解释、且与缺失值本身无关 → **MAR**（可用观测变量校正，如按性别分层填补）；
- 完全无法解释（纯偶然）→ **MCAR**（MAR 的特例，最安全）；
- 必须依赖缺失值本身才能解释 → **MNAR**（最棘手——简单填补会系统性扭曲估计）。

MCAR 下的处理方式：

1. 丢弃含缺失值的观测；
2. 依靠学习算法在训练阶段处理缺失值；
3. 训练前填补所有缺失值。

方式 1 仅当缺失比例小时可用。方式 2: CART 用替代分裂有效处理缺失 (§9.2.4), MARS、PRIM 类似; GAM 中, 某输入缺失的观测在该特征的光滑步骤中被省略、拟合值置零 (因曲线均值为零, 等价于赋平均拟合值)。多数学习方法需要方式 3 填补: 最简单用该特征非缺失值的均值/中位数填补 (GAM 的做法与之类似)。

若特征有一定相互依赖, 可对每个特征建立「用其他特征预测该特征」的模型, 用预测填补缺失值。注意: 用于填补的学习方法与预测 y 的方法**独立选择**——即便最终目的是 y 对 X 的线性回归, 也常优选灵活自适应的填补方法。若训练集缺失值多, 填补方法本身需能处理缺失——**CART 是理想的填补「引擎」**。填补后通常把缺失值当作已观测, 这忽略了填补带来的不确定性 (会引入额外不确定性); 可通过**多重填补** (多次填补生成多个训练集、拟合 y 模型、评估跨训练集的变化) 度量; 若用 CART 填补, 可从对应终节点的值中抽样做多重填补。

17.7 计算考虑


N 个观测、 p 个预测变量:

- **加性模型**: 需要 mp 次一元平滑/回归应用 (m 为 backfitting 循环数, 通常 < 20 、常 < 10 , 取决于输入相关性)。三次平滑样条需 $N \log N$ 排序 + N 次样条拟合, 总操作约 $pN \log N + mpN$ 。
- **树**: 每个预测变量初始排序 $pN \log N$, 分裂计算通常再 $pN \log N$; 若分裂靠近预测变量范围边缘, 可能增至 $N^2 p$ 。
- **MARS**: 向含 m 项的模型 (p 个预测变量池) 加一个基函数需 $Nm^2 + pmN$; 建 M 项模型需 $NM^3 + pM^2N$, M 是 N 的相当比例时可能非常昂贵。
- **HME**: 每个 M 步各组件通常便宜: 回归 Np^2 、 K 类 logistic 回归 Np^2K^2 ; 但 EM 收敛可能很慢, 较大的 HME 模型被认为拟合代价高。

17.8 本章总结: 加性模型、树及相关方法

17.8.1 核心主题


第 9 章的五种技术 (GAM、树、PRIM、MARS、HME) 共享同一个出发点: 对未知回归函数假设某种结构化形式, 从而缓解维数灾难——代价是可能误设模型, 因此每次都需要权衡。它们从第 3–6 章出发, 各自以不同方式在「可解释性」与「灵活性」之间取平衡:



17.8.2 五种方法的对比

方法	模型形式	机制	优点	局限
GAM	$g(\mu) = \alpha + \sum_j f_j(X_j)$	加性光滑	可解释、模块化	需手动加交互
树 CART	$\sum_m c_m I(x \in R_m)$	递归二元划分 + 剪枝	可解释、处理混合/缺失	高方差、不光滑、难加性
PRIM	高响应盒子	剥离 + 粘贴	耐心、找隆起	无树结构、多类需逐个
MARS	$\sum_m \beta_m h_m(X)$	自适应基 + GCV	高维、自动交互、光滑	计算贵、分类需处理
HME	专家混合	软划分 + EM	软边界、光滑优化	拓扑固定、EM 慢、解释差

在「可解释性-灵活性」平面上的大致定位：



图：五种方法在「可解释性-灵活性」平面上的大致定位。GAM 与树偏可解释；HME 最灵活但最不可解释；MARS 居中偏灵活；PRIM 居中。

17.8.3 关键结论

- 1. 统一主题：五种技术都以「结构化假设」换取对维数灾难的缓解——灵活性越大，解释越难（HME 最灵活也最不可解释）。
- 2. 加性 vs 交互：GAM 是加性模型（需手动加交互）；MARS 自动搜索交互；树难以捕捉加性结构（需指数级叶子）。
- 3. 硬 vs 软：树的划分是硬决策；HME 是软概率划分（门控）；软划分优化更光滑，但解释性更差。

4. **光滑 vs 分块**：回归任务通常期望光滑预测面（GAM/MARS）；0/1 分类可接受分块（树）。
5. **缺失数据**：区分 MCAR / MAR / MNAR——MCAR 最安全、MNAR 最棘手；CART 是理想的填补引擎（替代分裂）。
6. **计算**：GAM 与树约 $pN \log N$ 量级；MARS 为 $NM^3 + pM^2N$ （ M 大时昂贵）；HME 组件便宜但 EM 收敛慢。

注记 17.5. 这些方法并非互斥——第 8 章的 Bagging、第 10 章的 Boosting 正是把「不稳定的树」作为基学习器来改进；第 15 章的随机森林通过降低树间相关性进一步改进。第 9 章的「单模型」方法为这些「集成」方法提供了基构件。

第十八章 提升与加性树 (Boosting and Additive Trees)

Boosting 是过去二十年最强大的学习思想之一，最初为分类问题设计，也可扩展至回归。其动机是组合多个「弱」分类器的输出，形成一个强大的「委员会」。从这一角度看，boosting 与 **Bagging** (§8.8) 及其他基于委员会的方法相似；但本质不同——Bagging 是降方差、不扩模型类，而 boosting 是通过前向分阶段方式拟合加性模型，从而扩展模型类。

18.1 Boosting 方法

考虑二分类问题，输出编码为 $Y \in \{-1, 1\}$ 。给定预测变量向量 X ，分类器 $G(X)$ 输出 $\{-1, 1\}$ 之一。训练样本上的误差率为


$$\overline{\text{err}} = \frac{1}{N} \sum_{i=1}^N I(y_i \neq G(x_i)), \quad (18.1)$$

未来预测的期望误差率为 $\mathbb{E}_{XY} I(Y \neq G(X))$ 。

弱分类器 (weak classifier): 误差率仅略好于随机猜测的分类器。Boosting 的目标是顺序地把弱分类算法应用到数据的反复修改版本上，产生弱分类器序列 $G_m(x)$, $m = 1, 2, \dots, M$ ，再通过加权多数投票组合所有预测：

$$G(x) = \text{sgn} \left(\sum_{m=1}^M \alpha_m G_m(x) \right), \quad (18.2)$$

其中 $\alpha_1, \dots, \alpha_M$ 由 boosting 算法计算，衡量各 $G_m(x)$ 的贡献；其作用是给序列中更准确的分类器更高影响力。整个流程可示意如下：



图：AdaBoost 示意：对训练数据的加权版本顺序训练弱分类器序列 $G_1(x), \dots, G_M(x)$ ，每步把被 G_m 误分类的观测权重放大，再以权重 α_m 进行加权多数投票，组合成最终分类器

$$G(x) = \text{sgn}\left(\sum_{m=1}^M \alpha_m G_m(x)\right)。$$

sgn 怎么理解？ $\text{sgn}(\cdot)$ 是符号函数：

$$\text{sgn}(z) = \begin{cases} 1, & z > 0, \\ -1, & z < 0, \\ 0, & z = 0. \end{cases}$$

在式 (18.2) 中，每个弱分类器 $G_m(x) \in \{-1, 1\}$ 相当于对类标签**投一票**（+1 投给类 1、-1 投给类 -1）， $\alpha_m > 0$ 是这一票的权重；于是 $\sum_{m=1}^M \alpha_m G_m(x)$ 就是**加权投票的净得分**——所有投 +1 的权重之和减去所有投 -1 的权重之和。**sgn** 的作用是把这个实值净得分翻译成最终类标签：净得分为正判为类 1、为负判为类 -1，即

$$G(x) = +1 \iff \sum_{m: G_m(x)=+1} \alpha_m > \sum_{m: G_m(x)=-1} \alpha_m。$$

所以 $G(x) = \text{sgn}(\sum_{m=1}^M \alpha_m G_m(x))$ 的直观就是**加权多数投票**（weighted majority vote）。注意 sgn 只保留正负号、丢掉幅度信息——训练阶段 AdaBoost 实际拟合的是**连续值** $f(x) = \sum_{m=1}^M \beta_m G_m(x)$ (§10.4)，指数损失 $\exp(-yf(x))$ 依赖连续的 f 而非其符号； sgn 只是最后一步的决策读出。

数据修改方式：在每一步 boosting 中，对每个训练观测 (x_i, y_i) 施加重数 $w_1, w_2, \dots, w_N$ 。初始设 $w_i = 1/N$ （第一步即在原始数据上照常训练）。对后续迭代 $m = 2, 3, \dots, M$ ，被前一步分类器 $G_{m-1}(x)$ 误分类的观测权重**增加**，正确分类的观测权重**减少**。于是随着迭代进行，难以正确分类的观测获得越来越大的影响力，迫使每个后续分类器专注于先前分类器遗漏的样本。

Algorithm 10.1 (AdaBoost.M1, 离散 AdaBoost)：

1. 初始化观测权重 $w_i = 1/N$, $i = 1, 2, \dots, N$ 。

2. 对 $m = 1$ 到 M :

(a) 用权重 w_i 在训练数据上拟合分类器 $G_m(x)$ 。

(b) 计算加权误差率

$$\text{err}_m = \frac{\sum_{i=1}^N w_i I(y_i \neq G_m(x_i))}{\sum_{i=1}^N w_i}. \quad (18.3)$$

(c) 计算 $\alpha_m = \log((1 - \text{err}_m)/\text{err}_m)$ 。

(d) 更新权重 $w_i \leftarrow w_i \cdot \exp[\alpha_m \cdot I(y_i \neq G_m(x_i))]$, $i = 1, 2, \dots, N$ 。

3. 输出 $G(x) = \text{sgn}[\sum_{m=1}^M \alpha_m G_m(x)]$ 。

第 2(c) 行计算的 α_m 是最终分类器中给 G_m 的权重：误分类观测的权重被放大 $\exp(\alpha_m)$ 倍，增强其对下一步分类器 G_{m+1} 的影响力。

离散 AdaBoost: 因基分类器 $G_m(x)$ 返回离散类标签而得名 (Friedman et al., 2000)。若基分类器改为返回实值预测 (例如映射到 $[-1, 1]$ 区间的概率)，可相应修改得到「Real AdaBoost」。

例 18.1 (模拟数据: stump 的威力). 特征 $X_1, \dots, X_{10}$ 为标准独立高斯，确定性目标

$$Y = \begin{cases} 1, & \text{若 } \sum_{j=1}^{10} X_j^2 > \chi_{10}^2(0.5), \\ -1, & \text{否则,} \end{cases} \quad (18.4)$$

其中 $\chi_{10}^2(0.5) = 9.34$ 是 10 自由度卡方随机变量的中位数 (10 个标准高斯的平方和)。2000 个训练样本 (每类约 1000 个)，10000 个测试观测。弱分类器是「stump」——仅含两个终端节点的分类树。

- 单独应用 stump: 测试误差 45.8% (随机猜测为 50%)，几乎无效。
- 400 次 boosting 迭代后: 误差降至 5.8%，约为原误差率的 $\frac{1}{4}$ 。
- 单个 244 节点的大分类树: 误差率 24.7%——boosting 完胜。

Breiman (NIPS Workshop, 1996) 称「带树的 AdaBoost 是世界上最好的现成分类器」(见 Breiman, 1998)，对数据挖掘应用尤其如此 (§10.7 详述)。

18.1.1 本章概览

本章的要点可概述如下:

- AdaBoost 在基学习器上拟合**加性模型**，优化一种新颖的**指数损失**，该损失与 (负) 二项对数似然非常相似 (§10.2–§10.4)。

- 指数损失的总体极小化被证明是类概率的对数优势 (§10.5)。
- 给出比平方误差或指数损失更稳健的回归与分类损失函数 (§10.6)。
- 论证决策树是数据挖掘应用中 boosting 的理想基学习器 (§10.7、§10.9)。
- 发展一类**梯度提升模型 (GBM)**，用于任意损失下对树进行 boosting (§10.10)。
- 强调「慢学习」的重要性，通过每个新进入模型的项的**收缩 (shrinkage)** (§10.12) 及随机化 (§10.12.2) 实现。
- 描述拟合模型的解释工具 (§10.13)。

18.2 Boosting 拟合加性模型

Boosting 的成功并不神秘，关键在式 (18.2)：Boosting 是在一组初等「基」函数上**拟合加性展开**的方法。此处基函数即单个分类器 $G_m(x) \in \{-1, 1\}$ 。更一般地，基函数展开形如

$$f(x) = \sum_{m=1}^M \beta_m b(x; \gamma_m), \quad (18.5)$$

其中 β_m 是展开系数， $b(x; \gamma) \in \mathbb{R}$ 通常是多元自变量 x 的简单函数，由参数集 γ 刻画 (基展开详见第 5 章)。

这类加性展开是书中许多学习技术的核心：

- **单隐层神经网络** (第 11 章)： $b(x; \gamma) = \sigma(\gamma_0 + \gamma_1^T x)$ ，其中 $\sigma(t) = 1/(1 + e^{-t})$ 是 sigmoid 函数， γ 参数化输入变量的线性组合。
- **小波** (§5.9.1)： γ 参数化「母小波」的位置与尺度平移。
- **MARS** (§9.4)：截断幂样条基， γ 参数化结点变量与结点值。
- **树**： γ 参数化内部结点的分裂变量与分裂点、以及终端结点的预测。

这类模型通常通过最小化训练数据上的平均损失 (如平方误差或基于似然的损失) 来拟合：

$$\min_{\{\beta_m, \gamma_m\}_1^M} \frac{1}{N} \sum_{i=1}^N L\left(y_i, \sum_{m=1}^M \beta_m b(x_i; \gamma_m)\right). \quad (18.6)$$

对许多损失 $L(y, f(x))$ 与基函数 $b(x; \gamma)$ ，这需要计算密集の数値优化技术。但若可以快速求解仅拟合单个基函数的子问题，则存在简单替代方案：

$$\min_{\beta, \gamma} \sum_{i=1}^N L(y_i, \beta b(x_i; \gamma)). \quad (18.7)$$

Boosting 拟合的「加性模型」是基于 GAM 吗？不是。两者虽然都叫「加性」，但「加性」的含义不同：

- **GAM (第 9 章)**：加性是按特征加性—— $f(x) = \alpha + \sum_{j=1}^p f_j(X_j)$ ，每个预测变量 X_j 贡献一个光滑函数 f_j ，各项是单个变量的函数（主效应），交互需显式加入（如 $f_{jk}(X_j, X_k)$ ）。
- **Boosting**：加性是按基学习器加性—— $f(x) = \sum_{m=1}^M \beta_m b(x; \gamma_m)$ ，每个基函数 $b(x; \gamma_m)$ 都是整个输入向量 x 的函数（如完整树、完整 stump），可同时依赖任意特征组合，因而天然包含交互。

更准确的定位：两者都是「基函数加性展开」这一更一般框架 (§10.2 开头视角，与第 5 章基展开同构) 的特例，只是基函数的选择与拟合方式不同：

- GAM 的基 = 预定义/数据驱动的单变量光滑函数，用 **backfitting**（交替更新，§9.1.1）同时拟合所有项；
- Boosting 的基 = 自适应地从数据中学到的弱学习器（每步贪心地选最好的基加入），用前向分阶段（Algorithm 10.2）顺序拟合——每次只加一项、不回改已添加的项。

所以不能把 boosting 理解成「基于 GAM」；更准确的说法是：boosting 用前向分阶段方式拟合「弱学习器基函数」上的加性展开，而 GAM 用 backfitting 拟合「特征光滑函数」上的加性展开。二者仅共享「把若干项加起来」的展开形式；分道扬镳之处在于项长什么样（单变量光滑函数 vs 全特征弱学习器）以及怎么拟合（同时交替更新 vs 顺序贪心添加）。这也解释了为什么 boosting 能自动捕捉交互而纯 GAM 不能——每项（如树）本身就可以是特征的非线性 + 交互函数。

18.3 前向分阶段加性建模

前向分阶段建模（forward stagewise modeling）通过顺序添加新基函数来逼近式 (18.6) 的解，不调整已添加项的参数与系数（Algorithm 10.2）。每步迭代 m ，求解要加入当前展开 $f_{m-1}(x)$ 的最优基函数 $b(x; \gamma_m)$ 及其系数 β_m ，得到 $f_m(x)$ 后重复；之前添加的项不再修改。

Algorithm 10.2（前向分阶段加性建模，Forward Stagewise Additive Modeling）：

1. 初始化 $f_0(x) = 0$ 。
2. 对 $m = 1$ 到 M ：

(a) 计算 $(\beta_m, \gamma_m) = \arg \min_{\beta, \gamma} \sum_{i=1}^N L(y_i, f_{m-1}(x_i) + \beta b(x_i; \gamma))$ 。

(b) 令 $f_m(x) = f_{m-1}(x) + \beta_m b(x; \gamma_m)$ 。

对平方误差损失

$$L(y, f(x)) = (y - f(x))^2, \quad (18.8)$$

有

$$L(y_i, f_{m-1}(x_i) + \beta b(x_i; \gamma)) = (y_i - f_{m-1}(x_i) - \beta b(x_i; \gamma))^2 = (r_{im} - \beta b(x_i; \gamma))^2, \quad (18.9)$$

其中 $r_{im} = y_i - f_{m-1}(x_i)$ 恰是当前模型对第 i 个观测的残差。因此，平方误差损失下，每步加入的项 $\beta_m b(x; \gamma_m)$ 就是对当前残差拟合最好的项。这一思想是 §10.10.2「最小二乘回归提升」的基础。但如后文所示，平方误差损失一般不是分类的好选择，因此需要考虑其他损失准则。

18.4 指数损失与 AdaBoost

下面证明 AdaBoost.M1 (Algorithm 10.1) 等价于使用损失

$$L(y, f(x)) = \exp(-yf(x)) \quad (18.10)$$

的前向分阶段加性建模 (Algorithm 10.2)。对 AdaBoost，基函数即单个分类器 $G_m(x) \in \{-1, 1\}$ 。使用指数损失，每步需求解分类器 G_m 与相应系数 β_m ：

$$(\beta_m, G_m) = \arg \min_{\beta, G} \sum_{i=1}^N w_i^{(m)} \exp(-\beta y_i G(x_i)), \quad w_i^{(m)} = \exp(-y_i f_{m-1}(x_i)). \quad (18.11)$$

由于每个 $w_i^{(m)}$ 既不依赖 β 也不依赖 $G(x)$ ，可视为施加到每个观测上的权重；该权重依赖 $f_{m-1}(x_i)$ ，故随迭代 m 变化。

式 (18.11) 的解分两步获得。

第一步：对任意 $\beta > 0$ ，关于 G_m 的最优解为

$$G_m = \arg \min_G \sum_{i=1}^N w_i^{(m)} I(y_i \neq G(x_i)), \quad (18.12)$$

即最小化加权误差率的分类器。这是因为式 (18.11) 的准则可写成

$$(e^\beta - e^{-\beta}) \cdot \sum_{i=1}^N w_i^{(m)} I(y_i \neq G(x_i)) + e^{-\beta} \cdot \sum_{i=1}^N w_i^{(m)}. \quad (18.13)$$

第二步：把第一步得到的 G_m 固定，代回式 (18.11)，把 β 解出来。此时 $G(x_i)$ 已知，只需关于 β 极小化。先把求和按「分类是否正确」拆成两部分——注意对 $y_i \in \{\pm 1\}$ 、 $G_m(x_i) \in \{\pm 1\}$ ，恒有 $y_i G_m(x_i) = 1$ （正确分类）或 -1 （误分类）：

- 若 $y_i = G_m(x_i)$ （正确），则 $y_i G_m(x_i) = 1$ ，该项贡献 $w_i^{(m)} e^{-\beta}$ ；

- 若 $y_i \neq G_m(x_i)$ (误分类), 则 $y_i G_m(x_i) = -1$, 该项贡献 $w_i^{(m)} e^\beta$ 。

于是准则 (18.11) 化为

$$Q(\beta) = e^{-\beta} \underbrace{\sum_{y_i=G_m(x_i)} w_i^{(m)}}_{W^+} + e^\beta \underbrace{\sum_{y_i \neq G_m(x_i)} w_i^{(m)}}_{W^-},$$

其中 W^+ 、 W^- 分别为正确分类、误分类观测的权重和, 且 $W^+ + W^- = \sum_{i=1}^N w_i^{(m)}$ 。注意 W^+ 、 W^- 均与 β 无关 ($w_i^{(m)}$ 只依赖 f_{m-1}), 故可按普通常数对 β 求导。

对 β 求导并令其为零:

$$\frac{dQ}{d\beta} = -W^+ e^{-\beta} + W^- e^\beta \stackrel{!}{=} 0 \implies W^- e^\beta = W^+ e^{-\beta} \implies e^{2\beta} = \frac{W^+}{W^-},$$

两边取对数得

$$\beta = \frac{1}{2} \log \frac{W^+}{W^-}.$$

再把加权误差率 (18.15) 用进来: $\text{err}_m = \frac{W^-}{W^+ + W^-}$, 故 $W^+ = (1 - \text{err}_m)(W^+ + W^-)$ 、 $W^- = \text{err}_m(W^+ + W^-)$, 代入即得

$$\beta_m = \frac{1}{2} \log \frac{1 - \text{err}_m}{\text{err}_m}. \quad (18.14)$$

其中 err_m 为最小化后的加权误差率

$$\text{err}_m = \frac{\sum_{i=1}^N w_i^{(m)} I(y_i \neq G_m(x_i))}{\sum_{i=1}^N w_i^{(m)}}. \quad (18.15)$$

这是极小点吗? 二阶导数 $Q''(\beta) = W^+ e^{-\beta} + W^- e^\beta > 0$ 恒正, 故 $Q(\beta)$ 是 β 的凸函数, 上述驻点是唯一全局极小点。此外, $\beta_m > 0$ 当且仅当 $\text{err}_m < \frac{1}{2}$ ——这正是「弱分类器 (略优于随机猜测)」假设所保证的: 若基分类器误差率超过 $\frac{1}{2}$, 则 $\beta_m \leq 0$, 权重更新方向反转, boosting 失效。这也解释了为何 $w_i^{(m)}$ 与 β 无关是推导的关键——它把式 (18.11) 的联合极小化化成了「先找使加权误差率最小的 G_m , 再闭式求 β_m 」的两步。直觉: β_m 是「对 G_m 有多信任」的度量—— G_m 越准 ($\text{err}_m \rightarrow 0$), β_m 越大, 最终投票 (18.2) 中其权重越高; 纯随机 ($\text{err}_m = \frac{1}{2}$) 时 $\beta_m = 0$, 该分类器不参与投票。

随后更新逼近 $f_m(x) = f_{m-1}(x) + \beta_m G_m(x)$, 使下一步权重变为

$$w_i^{(m+1)} = w_i^{(m)} \cdot e^{-\beta_m y_i G_m(x_i)}. \quad (18.16)$$

利用恒等式 $-y_i G_m(x_i) = 2 \cdot I(y_i \neq G_m(x_i)) - 1$, 式 (18.16) 化为

$$w_i^{(m+1)} = w_i^{(m)} \cdot e^{\alpha_m I(y_i \neq G_m(x_i))} \cdot e^{-\beta_m}, \quad (18.17)$$

其中 $\alpha_m = 2\beta_m$ 正是 AdaBoost.M1 第 2(c) 行定义的量。因子 $e^{-\beta_m}$ 对所有权重乘以同一常数, 无影响。因此式 (18.17) 等价于 Algorithm 10.1 的第 2(d) 行。

注记 18.1. Algorithm 10.1 的第 2(a) 行可视为对式 (18.13) (从而 (18.12)) 极小化的近似求解方法。故结论：**AdaBoost.M1 通过前向分阶段加性建模最小化指数损失准则 (18.10)。**

注记 18.2 (AdaBoost 不优化训练集误分类误差). 对式 (18.4) 的模拟数据, 训练集误分类误差约在 250 次迭代后降到零 (并保持为零), 但平均指数损失 $\frac{1}{N} \sum_i \exp(-y_i f(x_i))$ 仍在持续下降; 同时测试集误分类误差在 250 次迭代后仍继续改善。这说明 AdaBoost 优化的并非训练集误分类误差——指数损失对估计类概率的变化更敏感。

18.5 为什么用指数损失

AdaBoost.M1 最初并非从上一节的角度提出, 其与基于指数损失的前向分阶段加性建模的等价性是提出五年后才被发现的。研究指数损失准则的性质, 可以深入理解该过程并发现改进方向。

指数损失在加性建模语境中的**主要吸引力是计算上的**: 它导致简单、模块化的重新加权 AdaBoost 算法。但值得追问其统计性质: 它估计什么? 估计得好不好? 第一个问题由求其**总体极小化**回答。可以证明 (Friedman et al., 2000):

$$f^*(x) = \arg \min_{f(x)} \mathbb{E}_{Y|x} (e^{-Yf(x)}) = \frac{1}{2} \log \frac{\Pr(Y = 1 | x)}{\Pr(Y = -1 | x)}, \quad (18.18)$$

即指数损失的总体极小化正是**类概率的对数优势 (log-odds) 的一半**。等价地

$$\Pr(Y = 1 | x) = \frac{1}{1 + e^{-2f^*(x)}}. \quad (18.19)$$

因此 AdaBoost 估计的是 (对数优势意义下的) 类概率, 而非简单的分类边界。

注记 18.3 (边际与损失函数). 记**边际** $yf(x)$ 。分类算法的目标是尽可能产生正边际。任何分类损失都应对负边际惩罚更重、对正边际奖励更轻。误分类损失 $I(yf(x) < 0)$ 对负边际罚 1、对正边际不罚; 指数损失与二项偏差 (deviance) 都是它的单调连续逼近, 且对越来越负的边际惩罚比奖励更重——区别只在程度上: 二项偏差对大负边际的惩罚**线性**增长, 而指数损失对这类观测的影响力**指数**增长, 因此在训练过程中把更多影响力集中在负边际大的观测上。

18.6 损失函数与稳健性

本节系统比较二分类的各种损失函数, 并给出更稳健的替代准则。记响应 $y \in \{\pm 1\}$ 、预测为 $f(x)$ 、类预测为 $\text{sgn}(f(x))$, **边际**为 $yf(x)$ 。分类算法的目标是尽可能产生正边际; 任何分类损失都应对**负边际惩罚更重** (负边际观测已被误分类)、对正边际奖励更轻。

误分类损失 $L(y, f(x)) = I(yf(x) < 0)$: 对负边际罚 1、对正边际不罚。指数损失与二项偏差 (deviance) 都可看作它的**单调连续逼近**, 区别只在程度:

- **指数损失** $L(y, f) = e^{-yf}$ (式 (18.10))：对越来越负的边际惩罚呈**指数**增长，把更多影响力集中在负边际大的观测上——在含噪（贝叶斯误差不为零）或训练标签被错误标注的情形下，性能会显著下降。
- **二项偏差** $L(y, f) = \log(1 + e^{-2yf})$ （负二项对数似然）：对大负边际的惩罚近似**线性**增长，影响力更均匀地分布于全部数据，因而**稳健**得多。

二项偏差 $\log(1 + e^{-2yf})$ 真的是「负二项对数似然」吗？是。它正是把类概率写成 logistic 形式后的负对数似然。设 $p = \Pr(Y = 1 | x)$ ，取 logistic 形式

$$p = \frac{1}{1 + e^{-2f}}, \quad \Pr(Y = -1 | x) = 1 - p = \frac{1}{1 + e^{2f}},$$

（这里用 $2f$ 是因为 f 定义为 log-odds 的一半，见式 (18.18)–(18.19)）。对单个观测的负对数似然为


$$-\log \Pr(Y = y | x) = \begin{cases} \log(1 + e^{-2f}), & y = 1, \\ \log(1 + e^{2f}), & y = -1, \end{cases}$$

由于 $y \in \{\pm 1\}$ 时 $-2yf$ 分别等于 $-2f$ 与 $+2f$ ，两种情形可统一写成

$$L(y, f) = -\log \Pr(Y = y | x) = \log(1 + e^{-2yf}),$$

即**负二项对数似然**（二项偏差）。它也叫「logistic 损失」。它与指数损失 e^{-yf} 的关系：对 $\log(1 + e^{-2yf})$ 做大负边际近似得 $2 \cdot (-yf) = 2|yf|$ （线性），而指数损失近似得 $e^{|yf|}$ （指数）——这正是 §10.6 所说「二项偏差对大负边际惩罚线性、指数损失指数增长」的由来。

三个损失函数随边际 $yf(x)$ 的变化如图：



图：二分类的三种损失函数（缩放后均过 $(0, 1)$ 点，对应原书图 10.4）。误分类损失是「对负边际罚 1、正边际不罚」的阶梯；指数损失与二项偏差都是它的**单调连续逼近**，且都随边际变负而增大——指数损失上升**指数级**（对误分类、尤其是标签噪声的观测施加极大影响力），二项偏差上升近似**线性**（影响力更均匀、更稳健）。

18.6.1 平方误差损失不适合分类

平方误差损失 $L(y, f) = (y - f)^2$ 的总体风险极小化者为

$$f^*(x) = \arg \min_{f(x)} \mathbb{E}_{Y|x}(Y - f(x))^2 = \mathbb{E}(Y | x) = 2 \cdot \Pr(Y = 1 | x) - 1, \quad (18.20)$$

分类规则仍取 $G(x) = \text{sgn}[f(x)]$ 。

$\mathbb{E}(Y | x) = 2 \Pr(Y = 1 | x) - 1$ 这个等号怎么成立的？这完全来自二分类的编码约定 $Y \in \{-1, 1\}$ 。设 $p = \Pr(Y = 1 | x)$ ，则 $\Pr(Y = -1 | x) = 1 - p$ 。按（离散）期望的定义把 Y 的两个取值 1 与 -1 及其条件概率代入：

$$\mathbb{E}(Y | x) = \sum_y y \cdot \Pr(Y = y | x) = 1 \cdot p + (-1) \cdot (1 - p) = p - 1 + p = 2p - 1 = 2 \Pr(Y = 1 | x) - 1.$$

直觉： Y 的两个取值 +1、-1 关于 0 对称，因此条件期望就是「两类概率之差的加权平衡点」——当 $\Pr(Y = 1 | x) = \frac{1}{2}$ （两类等可能）时 $\mathbb{E}(Y | x) = 0$ （在 0 处平衡）；当类 1 概率趋向 1 时，期望趋向 +1；趋向 0 时趋向 -1。它把区间 $[0, 1]$ 上的概率线性映射到 $[-1, 1]$ 上的期望，故 $\text{sgn}[\mathbb{E}(Y | x)] = \text{sgn}[2p - 1]$ 恰好实现贝叶斯分类规则（ $p > \frac{1}{2}$ 判类 1）。

但平方误差不是误分类误差的好替代：它不是边际 $yf(x)$ 的单调递减函数——当 $y_i f(x_i) > 1$ 时它反而二次增大，把越来越多误差加在「越来越确定被正确分类」的观测上，从而相对削弱了真正误分类（ $y_i f(x_i) < 0$ ）观测的影响力。若目标是类别判定，应采用单调递减的替代损失。第 12 章图 12.4 给出二次损失的修改——「Huber 化的平方 hinge 损失」（Rosset et al., 2004b），兼具二项偏差、二次损失与 SVM hinge 损失的良好性质：与二次损失 (18.20) 有相同的总体极小化、 $yf(x) > 1$ 时取零、 $yf(x) < -1$ 时变为线性。

18.6.2 K 类分类的损失

响应 Y 取值于无序集合 $\mathcal{G} = \{\mathcal{G}_1, \dots, \mathcal{G}_K\}$ (§2.4、§4.4)。只需类条件概率 $p_k(x) = \Pr(Y = \mathcal{G}_k | x)$ 即可构造贝叶斯分类器

$$G(x) = \mathcal{G}_k, \quad \text{其中 } k = \arg \max_{\ell} p_{\ell}(x). \quad (18.21)$$

数据挖掘应用中常更关心类概率本身。如 §4.4，logistic 模型自然推广到 K 类：

$$p_k(x) = \frac{e^{f_k(x)}}{\sum_{\ell=1}^K e^{f_{\ell}(x)}}, \quad (18.22)$$

保证 $0 \leq p_k(x) \leq 1$ 且求和为 1。这里每类一个函数 f_k ；因给所有 f_k 加上同一 $h(x)$ 不改变模型，存在冗余。传统上令其中一个为零（如 $f_K(x) = 0$ ，见 (4.17)）；本书偏好保

留对称性，施加约束 $\sum_{k=1}^K f_k(x) = 0$ 。二项偏差自然推广为 **K** 类多项式偏差：

$$L(y, p(x)) = - \sum_{k=1}^K I(y = \mathcal{G}_k) \log p_k(x) = - \sum_{k=1}^K I(y = \mathcal{G}_k) f_k(x) + \log \left(\sum_{\ell=1}^K e^{f_{\ell}(x)} \right). \quad (18.23)$$

与二分类情形一致，准则 (18.23) 对错误预测的惩罚只随其错误程度**线性**增长。(Zhu et al., 2005 将指数损失推广到 K 类，见练习 10.5。)

18.6.3 回归的稳健损失

回归中与「指数损失二项对数似然」类比的是「平方误差绝对损失」：

- 平方误差 $L(y, f) = (y - f)^2$ 的总体解是 $f(x) = \mathbb{E}(Y | x)$ ；
- 绝对损失 $L(y, f) = |y - f|$ 的总体解是 $f(x) = \text{median}(Y | x)$ ；对称误差分布下两者相同。


但有限样本下，平方误差在拟合过程中对绝对残差 $|y_i - f(x_i)|$ 大的观测施加**过重**的权重，因而不**稳健**：对长尾误差分布、尤其对严重误测的 y （离群点），性能严重退化；绝对损失等更稳健准则在这些情形表现好得多。稳健统计文献提出了各种对严重离群点强抵抗、对高斯误差又几乎与最小二乘同样有效的回归损失。

Huber 损失

其中最具代表性的是 M-回归的 **Huber 损失** (Huber, 1964)：

$$L(y, f(x)) = \begin{cases} [y - f(x)]^2, & |y - f(x)| \leq \delta, \\ 2\delta |y - f(x)| - \delta^2, & \text{否则}. \end{cases} \quad (18.24)$$

它在零附近是二次的（像平方误差）、大残差处是线性的（像绝对损失），兼具二者优点。三种回归损失随残差 $y - f(x)$ 的变化对比如下（ $\delta = 1$ ）：



图：三种回归损失函数（对应原书图 10.5）。Huber 损失在 $|y - f| \leq \delta$ 内为二次（与平方误差重合）、在 $|y - f| > \delta$ 处变为线性（与绝对损失平行），并在 $\pm\delta$ 处光滑衔接。

Huber 的两段在 $\pm\delta$ 处光滑衔接：当 $|y - f(x)| = \delta$ 时两段取值都为 δ^2 ，且内段导数 2δ 恰等于外段斜率 2δ ，故函数与导数都连续。其导数为

$$\frac{\partial L}{\partial f} = \begin{cases} -2[y - f(x)], & |y - f(x)| \leq \delta, \\ -2\delta \cdot \text{sgn}[y - f(x)], & \text{否则}, \end{cases}$$

即残差的影响力在 $|y - f| \leq \delta$ 内随残差线性增长（像最小二乘）、一旦超过 δ 便饱和为常数 2δ （像绝对损失）——这正是其稳健性的来源：大离群点的梯度贡献被「封顶」，不再随残差二次放大。 δ 是「多少残差视为正常」的阈值，常取 1.345（使高斯误差下相对渐近效率约 95%）。

注记 18.4 (稳健性与算法优雅性的权衡). 当稳健性是关切点（数据挖掘尤甚，见 §10.7），回归的平方误差、分类的指数损失从统计角度看不是最优准则。但它们在**前向分阶段加性建模**中导致优雅的模式化 boosting 算法：平方误差下每步只需把基学习器拟合到当前残差 $y_i - f_{m-1}(x_i)$ ；指数损失下对输出 y_i 做加权拟合、权重 $w_i = \exp(-y_i f_{m-1}(x_i))$ 。直接换用其他稳健准则得不到这样简单的可行 boosting 算法；但 §10.10.2 将展示如何基于任意可微损失导出简单优雅的 boosting 算法，从而为数据挖掘构造高度稳健的 boosting 程序。

既然 AdaBoost 是指数损失，那我能设计一个基于 Huber 的 boost 吗？能，而且这正是从「AdaBoost = 指数损失」到「梯度提升 GBM (§10.10)」的演进动因之一。

框架层面：任意损失都可以 boost。 Boosting 的本质不是「指数损失」，而是**前向分阶段加性建模** (Algorithm 10.2)——对任意损失 L 都可定义。指数损失的特殊之处只在：二分类 + 离散弱分类器时该子问题有**闭式解** (加权误差率 $\rightarrow \beta_m = \frac{1}{2} \log \frac{1-\text{err}_m}{\text{err}_m}$)。这是指数损失的「运气」，不是 boosting 的必要条件。

经典前向分阶段 + Huber 的困难：如上文所述，用 Huber 替换平方误差确实能稳健化提升树，但子问题不再好解——平方误差化简为「把树拟合到残差」；Huber 化简不出残差拟合：给区域 R_{jm} 后，式 (18.30) 的解是 **Huber location 估计** (M-估计)，需迭代 (IRLS)；树诱导 (找区域) 需用近似准则 (18.27)。

现代解法：梯度提升 (§10.10)。对任意可微损失，梯度提升用**负梯度**作「伪残差」，绕过子问题不可解：

$$r_{im} = - \left[\frac{\partial L(y_i, f(x_i))}{\partial f(x_i)} \right]_{f=f_{m-1}}.$$

对 Huber 损失，伪残差为

$$r_{im} = \begin{cases} 2(y_i - f_{m-1}(x_i)), & |\text{残差}| \leq \delta, \\ 2\delta \operatorname{sgn}(y_i - f_{m-1}(x_i)), & |\text{残差}| > \delta, \end{cases}$$

即小残差按普通残差处理、大残差被「封顶」缩水到 $\pm 2\delta$ (winsorized)——这正是 Huber 提升的稳健机制。每步把树拟合到该伪残差，再在各叶节点线性搜索最优 γ 。现代实现早已内置：LightGBM 的 'objective='huber'、XGBoost 的 pseudo-Huber 都直接支持。

若想做「分类的 Huber boost」：Huber 原生是**回归损失** (定义在 $y \in \mathbb{R}$)。用于二分类需写成**边际损失** $\rho(yf(x))$ ——即「Huber 化的平方 hinge」： $yf > 1$ 时为零、 $yf < -1$ 时线性、中间二次 (§10.6 提到的图 12.4, Rosset et al., 2004b)。它与平方损失有相同的总体极小化，但兼具二项偏差、二次损失与 SVM hinge 的优点，同样可用梯度提升实现。

一句话总结：可以设计，而且已经存在。指数损失让 AdaBoost 闭式、优雅但不稳健；Huber (或二项偏差、绝对损失) 让 boosting 稳健，代价是每步子问题变难——连接「损失 $\rightarrow$ 算法」的桥就是梯度提升的伪残差技巧。

18.7 数据挖掘的「现成」程序

预测学习是数据挖掘的重要方面。各种方法各有擅长的情形，但实践中**事先很难知道**哪个程序对给定问题表现最好。表 10.1 汇总了若干学习方法的特性。

表 18.1: 不同学习方法的若干特性 (表 10.1)。记号: 好 = 表现好, 一般 = 表现一般, 差 = 表现差。

特性	神经网络	SVM 核	树	MARS	k-NN
自然处理「混合」类型数据	差	差	好	好	差
处理缺失值	差	差	好	好	好
对输入空间离群点稳健	差	差	好	差	好
对输入单调变换不敏感	差	差	好	差	差
计算可扩展性 (大 N)	差	差	好	好	差
处理无关输入的能力	差	差	好	好	差
提取特征线性组合	好	好	差	差	一般
可解释性	差	差	一般	好	差
预测能力	好	好	差	一般	好

工业与商业数据挖掘应用对学习程序的要求尤其苛刻: 数据集通常**非常大** (观测数与变量数都多), 计算考量重要; 数据通常**杂乱**——输入是定量、二值、分类变量的混合 (后者常有多水平)、缺失值普遍、数值变量的分布常长尾且高度偏斜、常含大量严重误测 (离群点)、各预测变量尺度差异巨大。此外, 通常只有少量预测变量真正与预测相关, 且缺乏可靠领域知识来构造相关特征或过滤无关特征——无关特征的加入会严重损害许多方法的性能。最后, 数据挖掘一般需要**可解释模型**: 不仅要给出预测, 还要提供对输入联合取值与预测响应之间关系的定性理解。因此, 神经网络这类「黑箱」方法在纯粹预测场景 (如模式识别) 很有用, 但对数据挖掘用处小得多。

「**现成 (off-the-shelf)**」方法: 可直接应用于数据、无需大量耗时的数据预处理或对学习程序的仔细调参。在所有著名学习方法中, **决策树最接近**满足数据挖掘「现成」程序的要求: 构建相对快、产生可解释模型 (若树小); 天然容纳数值与分类预测变量的混合及缺失值; 对单个预测变量的 (严格单调) 变换不变, 因而尺度化/变换不成问题、对预测变量离群点免疫; 把**内部特征选择**作为过程的一部分, 从而对大量无关预测变量的加入有抵抗力 (甚至免疫)。这些性质使决策树成为数据挖掘最流行的方法。

但树有一缺陷妨碍它成为理想工具: **不准确**——其预测精度很少能与数据能达到的最佳水平相比。如 §10.1 所见, boosting 树能显著 (常是戏剧性地) 提升其精度, 同时保留其大部分数据挖掘所需性质; 被牺牲的优点是**速度、可解释性**, 以及 (对 AdaBoost 而言) 对重叠类分布、尤其对训练数据**错误标注**的稳健性。**梯度提升模型 (GBM)** 是树提升的推广, 试图缓解这些问题, 成为数据挖掘中准确有效的现成程序。

18.8 Boosting 树

回归与分类树详见 §9.2。树把所有预测变量联合取值空间划分为不相交区域 R_j , $j = 1, 2, \dots, J$ (树的终端节点), 每个区域赋予常数 γ_j , 预测规则为 $\lceil x \in R_j \Rightarrow f(x) = \gamma_j \rceil$ 。树可形式化表示为

$$T(x; \Theta) = \sum_{j=1}^J \gamma_j I(x \in R_j), \quad (18.25)$$

参数 $\Theta = \{R_j, \gamma_j\}_1^J$, J 通常视为元参数。参数通过最小化经验风险求得:

$$\hat{\Theta} = \arg \min_{\Theta} \sum_{j=1}^J \sum_{x_i \in R_j} L(y_i, \gamma_j). \quad (18.26)$$

这是困难的组合优化问题, 通常满足于近似次优解。把优化拆成两部分有用:

- 给定 R_j 求 γ_j : 通常平凡, 常取 $\hat{\gamma}_j = \bar{y}_j$ (落入 R_j 的 y_i 均值); 对误分类损失, $\hat{\gamma}_j$ 取落入 R_j 观测的众数类。
- 求 R_j : 困难部分, 用近似解; 且求 R_j 也暗含估计 γ_j 。典型策略是贪心、自上而下的递归划分算法。有时需用更光滑、更方便的准则 (18.26) 的近似来优化 R_j :

$$\tilde{\Theta} = \arg \min_{\Theta} \sum_{i=1}^N \tilde{L}(y_i, T(x_i, \Theta)), \quad (18.27)$$

得到 $\hat{R}_j = \tilde{R}_j$ 后, 再用原始准则更精确地估计 γ_j 。

误分类损失下 $\hat{\gamma}_j$ 取「众数类」是什么? 众数类 (modal class) 就是区域内出现次数最多的类别 (统计中的众数 mode)。原因是误分类损失 $L(y, \gamma) = I(y \neq \gamma)$ (0-1 损失) 在区域 R_j 内的经验风险为

$$\sum_{x_i \in R_j} I(y_i \neq \gamma) = \underbrace{N_j}_{\text{落入 } R_j \text{ 的观测数}} - \underbrace{\#\{y_i = \gamma\}}_{\text{类别恰为 } \gamma \text{ 的观测数}},$$

其中 N_j 与 γ 无关。因此最小化该风险 $\iff$ 最大化「类别等于 γ 」的计数 $\iff$ 取出出现频率最高的类。

直觉: 误分类损失每错一个样本罚 1。把一个区域 R_j 的预测定成某个类 γ 时, 付出的代价 = 区域内「不是 γ 」的样本数。显然应把 γ 定成区域内样本最多的那个类, 使「被罚错」的样本数最少。若区域内各类计数相同 (如各 50%), 则任取其一即可。

与各损失的最优「位置估计」对应: 给定区域求最优常数, 本质是一个「位置」估计问题, 损失函数决定了答案:

损失	最优 $\hat{\gamma}_j$	统计量
平方误差 $[y - \gamma]^2$	$\bar{y}_j$ (均值)	期望
绝对损失 $ y - \gamma $	median (中位数)	中位数
误分类损失 $I(y \neq \gamma)$	众数类 (modal class)	众数

三类损失分别对应「均值 / 中位数 / 众数」这三种中心趋势统计量。

§9.2 对分类树描述了这样的策略：生长树（确定 R_j ）时用 **Gini 指数** 替代误分类损失。

提升树模型是这种树的和：

$$f_M(x) = \sum_{m=1}^M T(x; \Theta_m), \quad (18.28)$$

以前向分阶段方式（Algorithm 10.2）诱导。前向分阶段每步需对下一棵树求解

$$\hat{\Theta}_m = \arg \min_{\Theta_m} \sum_{i=1}^N L(y_i, f_{m-1}(x_i) + T(x_i; \Theta_m)), \quad (18.29)$$

给定当前模型 $f_{m-1}(x)$ 求区域集与常数 $\Theta_m = \{R_{jm}, \gamma_{jm}\}_1^{J_m}$ 。

为什么式 (18.28) 的提升树模型没有显式权重 β_m ？权重并没有消失——它被吸收进树的叶节点常数 γ_{jm} 里了。回忆 §10.2 的一般加性展开

$$f(x) = \sum_{m=1}^M \beta_m b(x; \gamma_m),$$

其中 β_m 是展开系数（权重）。对树 $T(x; \Theta_m) = \sum_{j=1}^{J_m} \gamma_{jm} I(x \in R_{jm})$ ，若写成 $\beta_m T(x; \Theta_m)$ ，则每叶项变为 $\beta_m \gamma_{jm}$ ——两个自由标量的乘积仍是自由标量，可重新标度 $\tilde{\gamma}_{jm} := \beta_m \gamma_{jm}$ 吸收掉 β_m 。只要叶节点值 γ_{jm} 不受约束（可取任意实数），显式 β_m 就是冗余的，式 (18.28) 直接令 $\beta_m = 1$ 不失一般性。

权重「藏」在哪：每棵树的整体幅度体现在其叶节点值 γ_{jm} 上——例如平方误差损失下， $\hat{\gamma}_{jm}$ 是第 j 区域残差的均值（式 (18.30)），它同时扮演了「拟合残差」与「最优步长」两个角色。前向分阶段每步加的 $T(x; \Theta_m)$ ，其幅度已由 (10.30) 的最优位置估计确定，无需额外系数。

何时必须显式 β_m ：只有当下文的缩放分类树（AdaBoost 情形， $\gamma_{jm} \in \{-1, 1\}$ ）才需要显式 β_m ——因为叶子被限制在 ± 1 ，幅度无法由 γ_{jm} 携带，只能靠外挂的 β_m 。这正是 §10.9 中「二分类 + 指数损失」一项里写 $\beta_m T(x; \Theta_m)$ 的原因；而一般的（不限幅）提升树则无需此系数。

给定区域 R_{jm} ，求每区域最优常数通常直截了当：

$$\hat{\gamma}_{jm} = \arg \min_{\gamma_{jm}} \sum_{x_i \in R_{jm}} L(y_i, f_{m-1}(x_i) + \gamma_{jm}). \quad (18.30)$$

求区域是困难的（比单棵树更难）。少数特殊情形下问题简化：

- **平方误差损失：**式 (18.29) 的解不比单棵树难——只需当前残差 $y_i - f_{m-1}(x_i)$ 预测得最好的回归树， $\hat{\gamma}_{jm}$ 是各区域残差均值。

- **二分类 + 指数损失**: 分阶段方式产生 AdaBoost 提升分类树 (Algorithm 10.1)。若树 $T(x; \Theta_m)$ 限制为**缩放分类树** ($\beta_m T(x; \Theta_m)$, $\gamma_{jm} \in \{-1, 1\}$)，则 §10.4 已证式 (18.29) 的解是使加权误差率 $\sum_{i=1}^N w_i^{(m)} I(y_i \neq T(x_i; \Theta_m))$ 最小的树，权重 $w_i^{(m)} = e^{-y_i f_{m-1}(x_i)}$ 。不加该限制时，指数损失下 (18.29) 仍简化为新树的加权指数准则：

$$\hat{\Theta}_m = \arg \min_{\Theta_m} \sum_{i=1}^N w_i^{(m)} \exp[-y_i T(x_i; \Theta_m)]. \quad (18.31)$$

可用加权指数损失作分裂准则实现贪心递归划分。给定 R_{jm} ，可证 (练习 10.7) 式 (18.30) 的解是各区域的**加权对数优势**：

$$\hat{\gamma}_{jm} = \frac{1}{2} \log \frac{\sum_{x_i \in R_{jm}} w_i^{(m)} I(y_i = 1)}{\sum_{x_i \in R_{jm}} w_i^{(m)} I(y_i = -1)}. \quad (18.32)$$

这需要专门的树生长算法；实践中更偏好下面用加权最小二乘回归树的近似。

用绝对误差或 Huber 损失 (18.24) 替代平方误差 (回归)、用偏差 (18.23) 替代指数损失 (分类)，可使提升树**稳健化**。但不同于其不稳健的对应物，这些稳健准则不产生简单快速的 boosting 算法。对更一般的损失，给定 R_{jm} 后式 (18.30) 的解通常是直截了当的 (一个简单「位置」估计)：绝对损失下是各区域残差的中位数；其他准则有快速迭代算法，通常其更快「单步」近似已足够。问题在**树诱导**：对这些更一般损失不存在求解 (18.29) 的简单快速算法，像 (18.27) 这样的近似变得必不可少。

18.9 通过梯度提升的数值优化

对任意可微损失准则求解式 (18.29) 的快速近似算法，可借助与数值优化的类比导出。用 $f(x)$ 预测训练数据上的 y 的总损失为

$$L(f) = \sum_{i=1}^N L(y_i, f(x_i)). \quad (18.33)$$

目标是关于 f 最小化 $L(f)$ ，此处 $f(x)$ 约束为树的和 (18.28)。忽略此约束，最小化 (18.33) 可视为数值优化

$$\hat{f} = \arg \min_f L(f), \quad (18.34)$$

其中「参数」 $f \in \mathbb{R}^N$ 是逼近函数在 N 个数据点处的取值：

$$f = \{f(x_1), f(x_2), \dots, f(x_N)\}^T.$$

数值优化过程把 (18.34) 的解表示为分量向量之和

$$f_M = \sum_{m=0}^M h_m, \quad h_m \in \mathbb{R}^N,$$

其中 $f_0 = h_0$ 是初始猜测，每个后继 f_m 基于当前参数向量 f_{m-1} (已诱导更新的和) 诱导。不同数值优化方法在如何计算每个增量向量 h_m (「步长」) 上有所不同。

18.9.1 最速下降

最速下降 (steepest descent) 取 $h_m = -\rho_m g_m$, 其中 ρ_m 是标量、 $g_m \in \mathbb{R}^N$ 是 $L(f)$ 在 $f = f_{m-1}$ 处求值的梯度。梯度 g_m 的分量为

$$g_{im} = \left[\frac{\partial L(y_i, f(x_i))}{\partial f(x_i)} \right]_{f(x_i)=f_{m-1}(x_i)}. \quad (18.35)$$

步长 ρ_m 是如下问题的解:

$$\rho_m = \arg \min_{\rho} L(f_{m-1} - \rho g_m), \quad (18.36)$$

随后更新 $f_m = f_{m-1} - \rho_m g_m$ 并进入下一次迭代。最速下降可视为**非常贪心**的策略—— $-g_m$ 是 $\mathbb{R}^N$ 中 $L(f)$ 在 $f = f_{m-1}$ 处下降最快的局部方向。

为什么要取「使损失最小」的步长 ρ_m ? 方向已定为负梯度 $-g_m$ (损失下降最快的局部方向), 剩下只需决定**走多远**。沿这条直线把 L 看成 ρ 的一元函数 $L(f_{m-1} - \rho g_m)$: 对 (局部) 凸的 L , 它随 ρ 增大**先降后升**, 谷底就是该方向上的最优步长——此时新点 $f_m = f_{m-1} - \rho_m g_m$ 的损失最小, 也就是沿这个方向损失下降得最多 (与 f_{m-1} 相比的损失下降量最大):




图 (等高线视角): 最速下降的一步。从 f_{m-1} 沿负梯度方向 $-g_m$ (与等高线垂直) 做一维线搜索, f_m 取该直线上损失最小的点 (直线与等高线相切处)。梯度只给方向, ρ_m 决定走多远。




图 (剖面视角): 沿 $-g_m$ 方向的损失 $L(f_{m-1} - \rho g_m)$ 随 ρ 变化: 先降后升, 谷底 ρ_m 处损失最小——即相对旧点 f_{m-1} 的损失下降量在该方向上最大。

18.9.2 梯度提升

前向分阶段提升 (Algorithm 10.2) 同样是贪心策略：给定当前模型 f_{m-1} 及其拟合 $f_{m-1}(x_i)$ ，每步选出的树是使 (18.29) 减少最多的解树。因此树预测 $T(x_i; \Theta_m)$ 与负梯度 (18.35) 的分量类似。主要区别是树的各分量 $t_m = \{T(x_1; \Theta_m), \dots, T(x_N; \Theta_m)\}^T$ 不独立——它们被约束为某棵 J_m 终端节点决策树的预测，而负梯度是无约束的最大下降方向。分阶段方法中 (18.30) 的解类似于最速下降中的线搜索 (18.36)；区别是 (18.30) 对 t_m 中对应每个独立终端区域的分量分别做线搜索。

若唯一目标是极小化训练损失 (18.33)，最速下降是首选：梯度 (18.35) 对任何可微损失都易于计算，而 (18.29) 对 §10.6 讨论的稳健准则很难求解。遗憾的是梯度 (18.35) 只在训练点 x_i 处有定义，而最终目标是让 $f_M(x)$ 泛化到训练集未出现的新数据。

解决这一困境的办法是：在第 m 次迭代诱导一棵预测 t_m 尽量接近负梯度的树 $T(x; \Theta_m)$ 。用平方误差度量接近程度：

$$\tilde{\Theta}_m = \arg \min_{\Theta} \sum_{i=1}^N (-g_{im} - T(x_i; \Theta))^2, \quad (18.37)$$

即用最小二乘把树 T 拟合到负梯度值 (18.35)。§10.9 已述最小二乘决策树诱导有快速算法。(18.37) 解出的区域 $\tilde{R}_{jm}$ 虽与 (18.29) 的真正解 R_{jm} 不完全相同，但通常足够相似以达同样目的（前向分阶段与自上而下树诱导本身都是近似过程）。构造树 (18.37) 后，各区域常数由 (18.30) 给出。

式 (18.37) 中「谁和谁」在比较？是负梯度 $-g_{im}$ （理想目标）与树的预测 $T(x_i; \Theta)$ （受限近似）在比较，用平方误差度量二者的差距：

- $-g_{im}$ （负梯度）：对每个训练点 x_i ，它给出「 $f(x_i)$ 该往哪个方向、降多少，损失 L 才下降最快」——这是自由、理想的逐点目标，但只定义在 N 个训练点上，无法外推到新数据。
- $T(x_i; \Theta)$ （树的预测）：候选树在 x_i 处的输出——它是定义在整个输入空间上的分段常数函数，可以泛化到任意新点。

于是式 (18.37) 做的事是：把 $-g_{im}$ 当作「回归目标 y 」、把树当作「回归器」，用最小二乘拟合一棵使二者尽量接近的树——即「让树去模仿/逼近负梯度这个理想方向」。

为什么这能解决困境？最速下降的更新 $f_m = f_{m-1} - \rho_m g_m$ 依赖负梯度，但 g_m 只定义在训练点；把树拟合成负梯度的近似 $T(x; \Theta_m) \approx -g_m$ 后，树作为可泛化函数可以评估任意 x ，于是「在函数空间沿负梯度方向下降一步」变成了「把树拟合到负梯度再累加进 f_M 」。

为什么用最小二乘（而非原损失 L ）度量接近程度？真正想解的是 (18.29)（找使 L 减少最多的树），但对稳健损失很难求解；而最小二乘树诱导有快速算法 (§9.2)，且对

梯度做平方拟合在数值上等价于沿负梯度方向逼近极小点。因此 (18.37) 是 (18.29) 的一个实用近似——解出的 $\tilde{R}_{jm}$ 与真正最优区域 R_{jm} 不完全相同，但通常足够好。

常用损失函数的梯度 (表 10.2):

设定	损失函数	$-\partial L(y_i, f(x_i))/\partial f(x_i)$
回归	$\frac{1}{2}[y_i - f(x_i)]^2$	$y_i - f(x_i)$
回归	$ y_i - f(x_i) $	$\text{sgn}[y_i - f(x_i)]$
回归	Huber	$y_i - f(x_i) \quad (y_i - f(x_i) \leq \delta_m)$ $\delta_m \text{sgn}[y_i - f(x_i)] \quad (y_i - f(x_i) > \delta_m)$ 其中 δ_m 是 $ y_i - f(x_i) $ 的 α 分位数
分类	Deviance	第 k 分量: $I(y_i = \mathcal{G}_k) - p_k(x_i)$

平方误差损失下，负梯度即普通残差 $-g_{im} = y_i - f_{m-1}(x_i)$ ，故 (18.37) 本身等价于标准最小二乘提升。绝对误差损失下负梯度是残差的符号，每步把树最小二乘拟合到当前残差的符号。Huber M-回归的负梯度是二者的折中（见表）。分类时损失取多项式偏差 (18.23)，每步构造 K 棵最小二乘树，每棵 T_{km} 拟合各自负梯度向量 g_{km} :

$$-g_{ikm} = \left[\frac{\partial L(y_i, f_1(x_i), \dots, f_K(x_i))}{\partial f_k(x_i)} \right]_{f(x_i)=f_{m-1}(x_i)} = I(y_i = \mathcal{G}_k) - p_k(x_i), \quad (18.38)$$

其中 $p_k(x)$ 由 (18.22) 给出。每步虽建 K 棵树，但它们通过 (18.22) 相互关联；二分类 ($K=2$) 只需一棵树（练习 10.10）。

18.9.3 梯度提升的实现

Algorithm 10.3 给出回归的通用梯度树提升算法；插入不同损失 $L(y, f(x))$ 得到具体算法。第 1 行初始化到最优常数模型（单终端节点树）；第 2(a) 行计算的负梯度分量称为广义/伪残差 r 。

Algorithm 10.3 (梯度树提升算法):

1. 初始化 $f_0(x) = \arg \min_{\gamma} \sum_{i=1}^N L(y_i, \gamma)$ 。
2. 对 $m = 1$ 到 M :
 - (a) 对 $i = 1, 2, \dots, N$ 计算 $r_{im} = -\left[\frac{\partial L(y_i, f(x_i))}{\partial f(x_i)} \right]_{f=f_{m-1}}$ 。
 - (b) 拟合回归树到目标 r_{im} ，得到终端区域 R_{jm} , $j = 1, 2, \dots, J_m$ 。
 - (c) 对 $j = 1, 2, \dots, J_m$ 计算 $\gamma_{jm} = \arg \min_{\gamma} \sum_{x_i \in R_{jm}} L(y_i, f_{m-1}(x_i) + \gamma)$ 。
 - (d) 更新 $f_m(x) = f_{m-1}(x) + \sum_{j=1}^{J_m} \gamma_{jm} I(x \in R_{jm})$ 。
3. 输出 $\hat{f}(x) = f_M(x)$ 。

分类算法类似：每次迭代 m 对每类用 (18.38) 重复第 2(a)–(d) 行 K 次，最后得到 K 个（耦合的）树展开 $f_{kM}(x)$, $k = 1, \dots, K$ ，通过 (18.22) 产生概率或按 (18.21) 分类（练习 10.9）。两个基本调节参数是迭代次数 M 与各组成树的大小 J_m 。

原始实现称为 **MART** (multiple additive regression trees, 多元加性回归树)，本书第一版如此称呼，本章许多图由 MART 产生。梯度提升在 R 的 `gbm` 包 (Ridgeway, 1999) 中实现并免费可用；另一 R 实现是 `mboost` (Hothorn and Bühlmann, 2006)；商业实现 TreeNet 来自 Salford Systems。

18.10 提升树的合适大小

历史上 boosting 被视为组合模型（这里是树）的技术，树构建算法被当作产生待组合模型的「原始构件」，每棵树的最优大小在构建时按常规方式 (§9.2) 单独估计：先诱导一棵很大的（过大）树，再用自底向上过程剪枝到估计的最优终端节点数。这一方法隐含假设每棵树都是展开 (18.28) 中的最后一棵——除最后一棵树外这显然是很差的假设，结果是树通常过大，尤其在早期迭代，显著损害性能并增加计算。

避免此问题的最简单策略是限制所有树同大小： $J_m = J \forall m$ ，每步诱导一棵 J 终端节点回归树。于是 J 成为整个提升过程的元参数，针对手头数据调整以最大化估计性能。

有用 J 值可通过考虑「目标」函数的性质获得：

$$\eta = \arg \min_f \mathbb{E}_{XY} L(Y, f(X)), \quad (18.39)$$

期望取遍 (X, Y) 的总体联合分布； $\eta(x)$ 是对未来数据预测风险最小的函数，即我们要逼近的对象。 $\eta(X)$ 的一个相关性质是坐标变量 $X^T = (X_1, \dots, X_p)$ 之间的交互程度，由它的 ANOVA 展开刻画：

$$\eta(X) = \sum_j \eta_j(X_j) + \sum_{jk} \eta_{jk}(X_j, X_k) + \sum_{jkl} \eta_{jkl}(X_j, X_k, X_l) + \dots \quad (18.40)$$

(18.40) 第一项是对单个预测变量 X_j 的函数，这些 $\eta_j(X_j)$ 是在所用损失下联合最佳逼近 $\eta(X)$ 的函数，每个称为 X_j 的「主效应」；第二项是加入主效应后对 $\eta(X)$ 拟合最好的两变量函数，称为变量对 (X_j, X_k) 的二阶交互；第三项代表三阶交互，依此类推。实践中遇到的许多问题低阶交互占主导；此时产生强高阶交互的模型（如大树）精度受损。

树的大小限制交互阶数：基于树的近似的交互水平受 J 限制——不可能出现高于 $J-1$ 阶的交互。由于提升模型对树是加性的 (18.28)，此限制同样适用于它们。取 $J=2$ （单分裂「decision stump」）产生只有主效应的提升模型，不允许交互； $J=3$ 还允许两变量交互，依此类推。因此 J 的选择应反映 $\eta(x)$ 主导交互的阶数——这通常未知，但多数情况下偏低。图 10.9 用模拟例 (18.4) 展示交互阶数（ J 的选择）的影响：生成函数是加性的（二次单项式之和），故 $J>2$ 的提升模型招致不必要方差、测试误差更高。图 10.10 比较提升 stump 找到的坐标函数与真函数。

虽然很多应用中 $J = 2$ 不够, 但需要 $J > 10$ 的可能性不大。经验表明 boosting 中 $4 \leq J \leq 8$ 效果好, 且对该范围内具体选择相当不敏感。可在验证集上试几个值取风险最低者微调 J , 但这很少比直接用 $J \simeq 6$ 有显著改进。

18.11 正则化

除组成树大小 J 外, 梯度提升的另一个元参数是提升迭代次数 M 。每次迭代通常降低训练风险 $L(f_M)$, 故 M 足够大时该风险可任意小; 但拟合训练数据过好会导致**过拟合**、损害未来预测风险。故存在极小化未来风险的最优 M^* , 与应用相关。方便的估计 M^* 的方法是: 在验证样本上监控预测风险作为 M 的函数, 取使风险最小的 M 作为 M^* 的估计——这与神经网络常用的**早停策略**类似 (§11.4)。

18.11.1 收缩

控制 M 不是唯一的正则化策略; 与岭回归和神经网络类似, 也可用**收缩** (shrinkage, §3.4.1、§11.5)。boosting 中最简单的收缩实现: 把每棵树的贡献缩放因子 $0 < \nu < 1$ 再加到当前逼近上, 即把 Algorithm 10.3 第 2(d) 行替换为

$$f_m(x) = f_{m-1}(x) + \nu \cdot \sum_{j=1}^J \gamma_{jm} I(x \in R_{jm}). \quad (18.41)$$

参数 ν 可看作控制 boosting 过程的**学习率**。更小的 ν (更多收缩) 在相同迭代数 M 下导致更大训练风险, 故 ν 与 M 都控制训练数据上的预测风险; 但它们**不独立**——更小 ν 对应相同训练风险需要更大 M , 二者存在**权衡**。

经验上 (Friedman, 2001) 更小的 ν 偏好更好的测试误差、需要相应更大的 M 。事实上最佳策略似乎是设 ν 很小 ($\nu < 0.1$) 再用早停选 M : 对回归与概率估计较无收缩 ($\nu = 1$) 有显著改进; 对 (18.21) 的误分类风险改进较小但依然可观。代价是计算: 更小 ν 需要更大 M , 计算量正比于后者; 但因每步诱导的树小且不剪枝, 即便非常大的数据集上许多迭代通常也可行。图 10.11 用模拟例 (18.4) 展示测试误差曲线 (MART + 二项偏差, stump 或 6 终端节点树, 有/无收缩): 收缩的益处明显, 尤其跟踪二项偏差时——有收缩时每条测试误差曲线达到更低值且保持多个迭代。§16.2.1 将建立 boosting 前向分阶段收缩与正则化模型参数的 ℓ_1 惩罚 (lasso) 的联系, 并论证 ℓ_1 惩罚可能优于 SVM 等使用的 ℓ_2 惩罚。

18.11.2 子采样

§8.7 已见 bootstrap 平均 (bagging) 通过平均改进噪声分类器性能; 第 15 章详述这种「采样后平均」的降方差机制。梯度提升中可用同一装置**同时改进性能与计算效率**。**随机梯度提升** (Friedman, 1999): 每次迭代从训练观测中**不放回**采样比例 η , 用该子样

本生长下一棵树，其余算法相同。 η 的典型值可为 $\frac{1}{2}$ ， N 大时 η 可远小于 $\frac{1}{2}$ 。采样不仅把计算时间减少同比例 η ，许多情况下还实际产生更准确的模型。图 10.12 用模拟例 (18.4) 展示子采样效果（分类与回归两例）：两例中「采样 + 收缩」略优于其余；此处「子采样而无收缩」表现不佳。代价是现在要设四个参数： J 、 M 、 ν 、 η 。通常一些初步探索确定 J 、 ν 、 η 的合适值，留下 M 作主要参数。

18.12 解释

单棵决策树高度可解释——整个模型可用简单的二维图形（二叉树）完全表示、易于可视化。树的线性组合 (18.28) 丧失了这一重要特性，须以不同方式解释。

18.12.1 预测变量的相对重要性

数据挖掘应用中输入预测变量很少同等相关：往往只有少数对响应有实质影响，绝大多数无关、删掉也无妨。了解每个输入变量在预测响应中的**相对重要性或贡献**通常很有用。

对单棵决策树 T ，Breiman et al. (1984) 提出每个预测变量 X_ℓ 的相关性度量：

$$\mathcal{I}_\ell^2(T) = \sum_{t=1}^{J-1} \hat{i}_t^2 I(v(t) = \ell), \quad (18.42)$$

对树的 $J-1$ 个内部节点求和。在每个内部节点 t ，用一个输入变量 $X_{v(t)}$ 把该节点区域划分为两个子区域，每个子区域内用常数拟合响应；被选中的变量是在整个区域用常数拟合之上给出**最大平方误差风险改进** $\hat{i}_t^2$ 的那个。变量 X_ℓ 的平方相对重要性就是「以它作分裂变量的所有内部节点的平方改进之和」。

该度量容易推广到加性树展开 (18.28)——只需对树求平均：

$$\mathcal{I}_\ell^2 = \frac{1}{M} \sum_{m=1}^M \mathcal{I}_\ell^2(T_m). \quad (18.43)$$

由于平均的稳定化作用，此度量比单棵树的 (18.42) 更可靠；且因收缩 (§10.12.1)，重要变量被与之高度相关的其他变量**掩盖**的问题大大减轻。注意 (18.42)、(18.43) 指**平方**相关性，实际相关性是各自的平方根。由于这些度量是相对的，习惯上把最大者赋为 100、其余按比例缩放。

对 K 类分类，诱导 K 个独立模型 $f_k(x)$ ， $k = 1, 2, \dots, K$ ，每个是树之和

$$f_k(x) = \sum_{m=1}^M T_{km}(x). \quad (18.44)$$

此时 (18.43) 推广为

$$\mathcal{I}_{\ell k}^2 = \frac{1}{M} \sum_{m=1}^M \mathcal{I}_\ell^2(T_{km}), \quad (18.45)$$

其中 $\mathcal{I}_{\ell k}$ 是 X_ℓ 在「把第 k 类观测与其他类分开」中的相关性。 X_ℓ 的总体相关性通过对所有类平均得到:

$$\mathcal{I}_\ell^2 = \frac{1}{K} \sum_{k=1}^K \mathcal{I}_{\ell k}^2. \quad (18.46)$$

18.12.2 部分依赖图

识别出最相关变量后, 下一步是理解逼近 $f(X)$ 对它们联合取值的依赖性质。把 $f(X)$ 作为其自变量的函数图形化, 可对输入变量联合取值上的依赖给出全面概括。但可视化限于低维视图——一元或二元函数(连续、离散或混合)易展示; 稍高维可通过固定除一两个自变量外的其余值、生成 trellis 图(Becker et al., 1996, R 中 lattice)展示; 超过两三个变量则更难。

一个有用的替代: 查看一组图, 每张显示逼近 $f(X)$ 对选定的小变量子集的部分依赖。虽然这类图通常无法全面刻画逼近, 但常能提供有价值的线索, 尤其当 $f(x)$ 由低阶交互(18.40)主导时。

考虑输入预测变量 $X^T = (X_1, \dots, X_p)$ 的子向量 X_S ($|S| = \ell < p$, 索引集 $S \subset \{1, \dots, p\}$)。设 C 为补集, $S \cup C = \{1, \dots, p\}$ 。一般函数 $f(X)$ 原则上依赖所有输入: $f(X) = f(X_S, X_C)$ 。 $f(X)$ 对 X_S 的平均或部分依赖定义为

$$f_S(X_S) = \mathbb{E}_{X_C} f(X_S, X_C), \quad (18.47)$$

即 f 的边际平均, 当 X_S 与 X_C 无强交互时可作为选定子集对 $f(X)$ 影响的有用描述。部分依赖函数可用于解释任何「黑箱」学习方法的输出, 可由下式估计:

$$\bar{f}_S(X_S) = \frac{1}{N} \sum_{i=1}^N f(X_S, x_{iC}), \quad (18.48)$$

其中 $\{x_{1C}, \dots, x_{NC}\}$ 是训练数据中出现的 X_C 值。这需要对每个待求 $\bar{f}_S(X_S)$ 的联合取值遍历一次数据, 即使中等规模数据也可能计算密集。幸运的是对决策树, $\bar{f}_S(X_S)$ (18.48) 可直接从树本身快速计算、无需引用数据(练习 10.11)。

注记 18.5 (部分依赖 vs 条件期望). 部分依赖 (18.47) 表示在考虑(平均掉)其他变量 X_C 对 f 的影响之后, X_S 对 f 的效应; 它不是忽略 X_C 效应的条件期望

$$\tilde{f}_S(X_S) = \mathbb{E}(f(X_S, X_C) | X_S), \quad (18.49)$$

后者是仅用 X_S 函数对 $f(X)$ 的最佳最小二乘逼近。 $\tilde{f}_S(X_S)$ 与 $\bar{f}_S(X_S)$ 仅当 X_S 与 X_C 独立(罕见)时相同。例如若选定子集的效应纯加性

$$f(X) = h_1(X_S) + h_2(X_C), \quad (18.50)$$

则 (18.47) 给出 $h_1(X_S)$ (差一个可加常数); 若效应纯乘性

$$f(X) = h_1(X_S) \cdot h_2(X_C), \quad (18.51)$$

则 (18.47) 给出 $h_1(X_S)$ (差一个乘法常数)。反之 (18.49) 两种情形都给不出 $h_1(X_S)$ ——事实上 (18.49) 甚至可能对 $f(X)$ 完全无关的变量子集产生强效应。

对提升树逼近 (18.28) 的选定变量子集查看部分依赖图, 有助于对其性质给出定性描述。受计算机图形与人眼感知所限, 子集 X_S 的大小必须小 ($\ell \approx 1, 2, 3$)。这样的子集数量众多, 但只有从通常小得多的「高相关预测变量」集合中选出的那些才可能提供信息; 且对 f 效应近似加性 (18.50) 或乘性 (18.51) 的子集最具揭示性。


对 K 类分类, 有 K 个独立模型 (18.44) (每类一个), 每个通过下式与各自概率 (18.22) 联系:

$$f_k(X) = \log p_k(X) - \frac{1}{K} \sum_{l=1}^K \log p_l(X). \quad (18.52)$$

故每个 $f_k(X)$ 是其相应概率在**对数尺度**上的单调增函数。对每个 $f_k(X)$ (18.44) 在其最相关预测变量 (18.45) 上做部分依赖图, 有助于揭示实现该类别的对数优势如何依赖相应输入变量。

18.12.3 解释工具的谱系: 树特有 vs 模型无关

部分依赖图 ((18.47)/(18.48)) 本身是**模型无关**的——它对任何「能对新点预测」的黑箱都适用 (神经网络、SVM、随机森林、自定义模型皆可)。但它通常和**重要性度量**配套使用 (先定位关键变量、再看其形状), 而重要性度量则有树特有与通用之分:



定位关键变量 (重要性) + 刻画效应形状 (部分依赖)

二者配套, 但重要性度量有树特有与通用之分

图: 解释工具的谱系。重要性度量负责「哪些变量重要」——树方法用分裂改进 ((18.42)/(18.43), 树特有), 其他模型用置换重要性、SHAP 等模型无关方法; 部分依赖图负责「效应长什么样」, 模型无关、任何黑箱都适用。

- **树特有 (分裂改进):** 单棵树 $I_\ell^2(T)$ ((18.42)) 按「以 X_ℓ 作分裂变量的内部节点平方误差改进」累加, 多树平均得 (18.43)——它**依赖树的分裂结构**, 只适用于决策树/随机森林/提升树。
- **模型无关 (置换/SHAP):** 置换重要性通过打乱某变量后预测误差上升多少衡量其作用; **SHAP** 从博弈论 Shapley 值出发分配每个变量的贡献——二者只依赖模型预测, 任意模型适用。

- **配套使用：**对树模型，用 (18.43) 选关键变量 + 部分依赖图看形状；对其他黑箱，用置换重要性/SHAP 选变量 + 部分依赖图看形状——**部分依赖图始终通用。**

18.13 示例

本节在几个较大数据集上、按需要选用不同损失函数来展示梯度提升。

18.13.1 California Housing

该数据集 (Pace and Barry, 1997, 来自 Carnegie-Mellon StatLib 仓库) 由加州 20,460 个社区 (1990 年人口普查街区组) 的聚合数据组成。响应 Y 是每个社区的中位房价 (单位 10^5 美元)。预测变量包括：中位收入 MedInc、住房密度 (房屋数 House、平均每房居住人数 AveOccup)、位置 (经度 longitude、纬度 latitude)、以及反映房屋属性的若干量 (平均房间数 AveRooms、平均卧室数 AveBedrms)。共 8 个数值预测变量。

用 MART 拟合梯度提升模型： $J = 6$ 终端节点、学习率 (18.41) $\nu = 0.1$ 、Huber 损失。随机分为训练集 (80

$$\text{AAE} = \mathbb{E} \left| y - \hat{f}_M(x) \right| \quad (18.53)$$

作为训练与测试数据上迭代数 M 的函数：测试误差随 M 增大**单调下降**，早期较快、随后趋于几乎恒定。因此只要 M 不太小，其具体取值并不关键 (许多应用如此)；收缩策略 (18.41) 倾向消除过拟合问题，对较大数据集尤其如此。

800 次迭代后 $\text{AAE} = 0.31$ ，可与最优常数预测器 $\text{median}\{y_i\} = 0.89$ 相比。用更熟悉的量：该模型的平方复相关系数 $R^2 = 0.84$ 。Pace and Barry (1997) 用复杂的空间自回归过程 (基于邻近社区中位房价预测，其余预测变量作协变量)，经变换实验预测 $\log Y$ 得 $R^2 = 0.85$ ；以 $\log Y$ 为响应时梯度提升对应值为 $R^2 = 0.86$ 。

图 10.14 展示 8 个预测变量的相对重要性：中位收入最相关；经度、纬度、平均每房居住人数约有其一半相关性；其余影响力较小。图 10.15 展示最相关非位置变量的单变量部分依赖图。注意这些图**不完全光滑**——这是基于树模型的后果：决策树产生不连续的分段常数模型 (18.25)，树之和 (18.28) 继承之 (只是片段更多)。与本书多数方法不同，结果**不施加光滑约束**，可建模任意尖锐的不连续；曲线总体呈光滑趋势只是因为那是估计出对预测最好的形状。图中底部的刻度线是各变量数据分布的分位数；边缘数据密度较低 (尤其较大值处) 使曲线在该区域略欠确定。各图纵轴尺度相同，可视觉比较不同变量的相对重要性。

中位房价对中位收入的部分依赖单调递增、主体近似线性；对平均每房居住人数总体单调递减 (除小于 1 的情形)；对平均房间数**非单调**——约 3 个房间处最小、更小与更大都上升。房价对房龄的部分依赖很弱，与其重要性排名 (18.46) (图 10.14) 不一致，提示该弱主效应可能掩盖与其他变量更强的交互。图 10.16 展示房价对房龄与平均每房居住人数联合值的双变量部分依赖：二者明显交互——平均每房居住人数大于 2 时房价

几乎不依赖房龄，小于 2 时对房龄强依赖。图 10.17 是拟合模型对经度与纬度联合值的双变量部分依赖（着色等高线图）：中位房价对加州位置有很强的依赖；该图不是「忽略其他预测变量效应的房价对位置图」(18.49)，而是与其他社区和房屋属性效应分离后位置的影响 (18.47)，可看作位置溢价——太平洋沿岸（尤其湾区、洛杉矶-圣地亚哥地区）溢价较大，加州北部、中央谷地与东南荒漠地区位置成本低得多。

18.13.2 New Zealand Fish

动植物生态学家用回归模型以环境变量预测物种存在、丰度与丰富度。近年兴趣从简单线性/参数模型转向更复杂模型：GAM (§9.1)、MARS (§9.4) 与提升回归树 (Leathwick et al., 2005, 2006)。此处建模新西兰周边海域鱼种 Black Oreo Dory 的存在与丰度。

图 10.18 展示 17,000 次拖网（深水网捕鱼，最深 2 km）位置，红点为 Black Oreo 出现的 2,353 次拖网（占经常记录的百余种之一）。每次拖网记录各鱼种捕获量 (kg) 及若干环境测量：平均拖网深度 AvgDepth、水温与盐度（二者与深度强相关，故 Leathwick et al. (2006) 改用 TempResid 与 SalResid——二者对深度调整后的残差）、海表温度梯度 SSTGrad、反映生态系统生产力的卫星图像指标 Chla、沿海悬浮颗粒物 SusPartMatter（卫星测得）。

分析目标是估计单次拖网发现 Black Oreo 的概率及期望捕获量（对拖网速度、距离、网目尺寸的变化标准化）。作者用 logistic 回归估计概率。对捕获量，自然做法是假设 Poisson 分布并对均值对数建模，但因零过多常不合适；尽管有零膨胀 Poisson (Lambert, 1992) 等专门方法，他们选了更简单途径：若 Y 为（非负）捕获量，

$$\mathbb{E}(Y | X) = \mathbb{E}(Y | Y > 0, X) \cdot \Pr(Y > 0 | X), \quad (18.54)$$

第二项由 logistic 回归估计，第一项仅用捕获为正的 2,353 次拖网估计。

logistic 回归用梯度提升模型 (GBM)，二项偏差损失、深度 10 树、收缩因子 $\nu = 0.025$ ；正捕获回归对 $\log Y$ 用平方误差损失 GBM（同样深度 10 树、 $\nu = 0.01$ ），再对预测取指数还原。两处都用 10 折交叉验证选择项数与收缩因子。

图 10.19（左）展示 GBM 模型序列的平均二项偏差（10 折 CV 与测试数据），比用每项 8 自由度光滑样条拟合的 GAM 略有改进；右图为两模型的 ROC 曲线 (§9.2.5)：性能看起来很接近，GBM 或稍有优势（AUC 略高）——等灵敏度/特异度点处 GBM 达

91


18.13.3 Demographics Data

本节用 MART 在多类分类问题上展示梯度提升。数据来自旧金山湾区 9,243 份购物中心顾客问卷 (Impact Resources, Inc., Columbus, OH)，含 14 个人口统计学问题。此例目标是用其余 13 个变量预测职业、识别区分不同职业类别的人口统计变量。随机分为训练集 (80

图 10.22 展示 $K = 9$ 个职业类别及其误差率：总体误差率 42.5%，可比的是「预测最多类别 Prof/Man（专业/管理）」的零模型率 69%。预测最好的四类是 Retired、Student、Prof/Man、Homemaker。图 10.23 展示对所有类平均的预测变量相对重要性 (18.46)；图 10.24 展示四个最好预测类别各自的相对重要性分布 (18.45)——最相关预测变量通常随类别而不同，例外是 age（预测 Retired、Student、Prof/Man 时都排前三）。图 10.25 展示这三类 log-odds (18.52) 对 age 的部分依赖：分离其他变量贡献后，老年人退休对数优势更高、学生相反；专业/管理人员对数优势在中年人最高。逐类检查部分依赖可得到合理结果。

18.14 本章总结

Boosting 是本章的主题：它把「弱学习器」（通常是小树）顺序地组合成强模型。本章的叙事可以概括为一条「从算法到理论再到工具」的链条。



图：本章主线——AdaBoost.M1 等价于指数损失下的前向分阶段加性建模；把损失推广到任意可微损失并借助负梯度（伪残差）技巧，得到通用的梯度提升（GBM）；再配以稳健损失、正则化与解释工具，构成数据挖掘的「现成」强学习器。

18.14.1 核心结论

- **Boosting = 前向分阶段拟合加性展开**： $f_M(x) = \sum_m \beta_m b(x; \gamma_m)$ ，顺序添加基学习器（通常是小树）、不回改已添加项。
- **AdaBoost 的等价性**：AdaBoost.M1 恰是指数损失 e^{-yf} 下的前向分阶段加性建模；指数损失的总体极小化是类概率对数优势的一半。
- **损失的选择**：指数损失不稳健（对标签噪声/大负边际极敏感）；二项偏差、Huber 等稳健损失让 boosting 更可靠，但失去闭式解——用**梯度提升**（负梯度作伪残差）处理任意可微损失。

- **梯度提升的实质：**每步把树最小二乘拟合到当前负梯度（伪残差），再做叶节点最优常数；它是「函数空间的最速下降」被约束到树的可泛化近似。
- **正则化三件套：**树的规模 J （限制交互阶数，通常 $4 \leq J \leq 8$ ）、迭代数 M （早停）、学习率 ν （收缩）、子采样 η （随机梯度提升）——四参数协同控制偏差-方差。
- **解释：**相对重要性（(18.43)）定位关键变量，部分依赖图（(18.48)）刻画其形状与交互——树方法独有的快速计算使解释高效可行。
- **定位：**boosting 是数据挖掘的「现成」强学习器，擅长混合类型数据、缺失值、无关变量与离群点，常显著优于单棵树与 GAM 等。

第十九章 Neural Networks (神经网络)

19.1 引言

神经网络是一类在统计与人工智能两个领域分别发展起来的、基于本质上相同模型的强大学习方法。

定义 19.1 (神经网络的核心思想). 从输入中提取线性组合作为派生特征 (derived features), 再把目标 Y 建模为这些特征的非线性函数。

本章首先讨论投影寻踪回归 (PPR) ——它诞生于半参数统计与光滑领域; 其余内容围绕神经网络模型展开。

19.2 投影寻踪回归 (Projection Pursuit Regression, PPR)

定义 19.2 (PPR 模型). 设有输入向量 $X \in \mathbb{R}^p$ 与目标 Y , ω_m ($m = 1, \dots, M$) 为 p 维单位向量。PPR 模型形如

$$f(X) = \sum_{m=1}^M g_m(\omega_m^T X), \quad (19.1)$$

它是一个加性模型, 但加性作用于派生特征 $V_m = \omega_m^T X$ 而非输入本身。函数 g_m 未指定, 需与方向 ω_m 一起用某种灵活光滑方法估计。

注记 19.1 (ridge function). 函数 $g_m(\omega_m^T X)$ 称为 $\mathbb{R}^p$ 上的脊函数 (ridge function), 它只沿向量 ω_m 定义的方向变化; $V_m = \omega_m^T X$ 是 X 在单位向量 ω_m 上的投影。我们寻找拟合良好的 ω_m , 故称「投影寻踪」。

图 11.1 左例 $\omega = \frac{1}{\sqrt{2}}(1, 1)^T$, 函数只沿 $X_1 + X_2$ 方向变化; 右例 $\omega = (1, 0)$, 即 $g(X_1)$ 。

为什么 $g_m(\omega_m^T X)$ 只在 ω_m 定义的方向上变化? $\omega_m^T X$ 是内积吗? 是的, $\omega_m^T X = \sum_{j=1}^p \omega_{mj} X_j = \langle \omega_m, X \rangle$ 就是标准欧氏内积 (点积)。由于 ω_m 是单位向量 ($\|\omega_m\| = 1$), 该内积的几何




FIGURE 11.1. Perspective plots of two ridge functions.

(Left:) $g(V) = 1/[1 + \exp(-5(V - 0.5))]$, where $V = (X_1 + X_2)/\sqrt{2}$.

(Right:) $g(V) = (V + 0.1) \sin(1/(V/3 + 0.1))$, where $V = X_1$.

图 19.1: 两个脊函数 (ridge function) 的透视图。左: $g(V) = 1/[1 + \exp(-5(V - 0.5))]$, 其中 $V = (X_1 + X_2)/\sqrt{2}$, 函数只沿 $X_1 + X_2$ 方向变化。右: $g(V) = (V + 0.1) \sin(1/(V/3 + 0.1))$, 其中 $V = X_1$ 。

意义正是 X 在 ω_m 方向上的带符号投影长度: $\omega_m^T X = \|X\| \cos \theta$, 其中 θ 为 X 与 ω_m 的夹角。

关键在于 g_m 的输入是标量 $V_m = \omega_m^T X$ 。把 X 正交分解为沿 ω_m 的分量与垂直分量 $X_\perp$ (即 $\omega_m^T X_\perp = 0$):

$$X = (X^T \omega_m) \omega_m + X_\perp \implies g_m(\omega_m^T X) = g_m(X^T \omega_m),$$

函数值完全不依赖 $X_\perp$ 。于是在垂直于 ω_m 的 $(p-1)$ 维超平面 $\{X : \omega_m^T X = c\}$ 上 g_m 取常数 $g_m(c)$; 只有沿 ω_m 方向移动、改变 $X^T \omega_m$ 时才变化。这正解释了图 19.1: 左例 $V = (X_1 + X_2)/\sqrt{2}$ 沿对角线起伏、沿 $X_1 - X_2$ 方向为常数——「山脊」只沿一个方向隆起, 故称脊函数。

注记 19.2 (PPR 的普遍性). PPR 模型 (19.1) 非常一般: 对线性组合做非线性变换能生成数量惊人的模型类。例如乘积可表示为

$$X_1 X_2 = \frac{(X_1 + X_2)^2 - (X_1 - X_2)^2}{4},$$

更高阶乘积也可类似表示。事实上, 当 M 任意大、 g_m 选择适当时, PPR 能以任意精度逼近 $\mathbb{R}^p$ 上的任何连续函数——这类模型称为**通用逼近器** (universal approximator)。

$X_1 X_2 = \frac{(X_1 + X_2)^2 - (X_1 - X_2)^2}{4}$ 里投影方向和 g_m 是什么? 这个恒等式展示了 PPR 的普遍性: 一个很小的 $M = 2$ 模型就能精确表示乘积这一典型的「不可加/交互」结构。逐项对应:

- **第一项** (方向沿对角线): $\omega_1 = \frac{1}{\sqrt{2}}(1, 1)^T$, $V_1 = \omega_1^T X = \frac{X_1 + X_2}{\sqrt{2}}$, $g_1(v) = \frac{1}{2}v^2$ 。验证: $g_1(V_1) = \frac{1}{2} \cdot \frac{(X_1 + X_2)^2}{2} = \frac{(X_1 + X_2)^2}{4}$ 。

- **第二项** (方向沿反对角线): $\omega_2 = \frac{1}{\sqrt{2}}(1, -1)^T$, $V_2 = \omega_2^T X = \frac{X_1 - X_2}{\sqrt{2}}$, $g_2(v) = -\frac{1}{2}v^2$ 。
验证: $g_2(V_2) = -\frac{1}{2} \cdot \frac{(X_1 - X_2)^2}{2} = -\frac{(X_1 - X_2)^2}{4}$ 。

于是 $f(X) = g_1(\omega_1^T X) + g_2(\omega_2^T X) = X_1 X_2$, 这是一个 $M = 2$ 的 PPR 模型。

两个要点: g_m 都是二次函数 $g_m(v) = \pm \frac{1}{2}v^2$ ——注意这是「理想化的表示」, 实际拟合中 g_m 是用光滑器估计出来的, 并不预设为二次。更关键的洞察是: 普通 GAM (可加模型, 用原始变量 $\sum_j f_j(X_j)$) **无法表示** $X_1 X_2$ (没有交互项); 而 PPR 通过「先旋转到投影方向、再施加非线性」就能表示交互。这就是它比 GAM 更一般的本质——非线性的作用对象不是单个输入, 而是输入的**线性组合**。

一句话: 投影方向就是两个「旋转坐标轴」(对角线与反对角线), g_m 是各自方向上的平方函数, 两项相减恰好抵消交叉项、保留下乘积项。

注记 19.3 (代价: 可解释性差). 这种普遍性的代价是: 拟合模型的**解释通常很困难**, 因为每个输入都以复杂、多面的方式进入模型。故 PPR 主要用于**预测**, 而非产生可理解的模型。唯一的例外是 $M = 1$ 情形, 即计量经济学中的**单指标模型** (single index model), 它比线性回归略一般, 且解释方式类似。

19.2.1 PPR 的拟合算法

给定训练数据 (x_i, y_i) , $i = 1, \dots, N$, 我们求误差函数的近似极小值:

$$\sum_{i=1}^N \left[y_i - \sum_{m=1}^M g_m(\omega_m^T x_i) \right]^2, \quad (19.2)$$

对函数 g_m 和方向 ω_m 优化。与其它光滑问题一样, 需对 g_m 显式或隐式地施加复杂度约束以避免过拟合。

拟合采用**两阶段交替迭代**:

1. **给定 ω 估计 g** : 先取 $M = 1$ (去掉下标)。由方向 ω 形成派生变量 $v_i = \omega^T x_i$, 得到一维光滑问题, 可用任意散点图光滑器 (如光滑样条) 估计 g 。
2. **给定 g 更新 ω** : 对 ω 极小化 19.2, 用 Gauss-Newton 搜索 (一种拟牛顿法, 丢弃 Hessian 中含 g 二阶导的部分)。设 ω^{old} 为当前估计, 由一阶 Taylor 展开

$$g(\omega^T x_i) \approx g(\omega_{\text{old}}^T x_i) + g'(\omega_{\text{old}}^T x_i) (\omega - \omega_{\text{old}})^T x_i, \quad (19.3)$$

得到

$$\sum_{i=1}^N [y_i - g(\omega^T x_i)]^2 \approx \sum_{i=1}^N g'(\omega_{\text{old}}^T x_i)^2 \left[\left(\omega_{\text{old}}^T x_i + \frac{y_i - g(\omega_{\text{old}}^T x_i)}{g'(\omega_{\text{old}}^T x_i)} \right) - \omega^T x_i \right]^2. \quad (19.4)$$

极小化右边即: 以 $\omega_{\text{old}}^T x_i + \frac{y_i - g(\omega_{\text{old}}^T x_i)}{g'(\omega_{\text{old}}^T x_i)}$ 为目标、 x_i 为输入、权重为 $g'(\omega_{\text{old}}^T x_i)^2$ 且**无截距**的最小二乘回归, 得到更新后的系数 ω^{new} 。

两步迭代直至收敛。多 term 情形以前向分阶段 (forward stage-wise) 方式建立模型，每阶段添加一对 (ω_m, g_m) 。

注记 19.4 (实现细节). • 原则上任何光滑方法皆可，但方便的是能提供**导数**的方法——局部回归与光滑样条很合适。

- 每步之后可用第 9 章的**反向拟合** (backfitting) 重新调整先前各步的 g_m ；虽可能最终减少 term 数，但未必提升预测性能。
- 通常 ω_m 不重新调整（部分为避免过多计算）。
- term 数 M 通常在前向分阶段策略中估计：当下一个 term 不能明显改善拟合时停止；也可用**交叉验证**确定 M 。

注记 19.5 (PPR 的地位). 投影寻踪思想还有很多其它应用，如密度估计，以及与 §14.7 中 ICA 的探索性投影寻踪关系。但 PPR 在统计界并未被广泛使用——也许因为 1981 年提出时其计算需求超出了当时大多数计算机的能力。然而它代表了一次重要的思想进步，并在神经网络的领域中「重生」。

PPR 像 EM 吗？PPR 常用吗？ 结构上像，本质上有别。两者都属「交替优化」(block-coordinate / alternating minimization) 家族——把参数分成两块，轮流固定一块优化另一块：

- **交替的两块**：EM 是隐变量分布 $\leftrightarrow$ 模型参数；PPR 是函数 $g_m \leftrightarrow$ 方向 ω_m 。
- **目标**：EM 极大化似然；PPR 最小化误差函数 19.2。
- **每步闭式解**：EM 通常有；PPR 的 g 用光滑器、 ω 用 Gauss-Newton (数值)。
- **单调性保证**：EM 的对数似然单调不减；PPR 无 EM 式保证 (Gauss-Newton 只是近似)。
- **动机**：EM 基于隐变量 + 极大似然，有统计理论；PPR 只是把模型拟合好的工程策略。

所以更准确地说，PPR 是**坐标下降式交替**，不是 EM——EM 的「E 步求隐变量后验」在 PPR 中没有对应物 (PPR 无隐变量，两块都是直接可观测模型中的参数/函数)。真正用 EM 的对应物是第 9 章的 **HME** (专家混合)。

PPR 并不常用。书中原话是「在统计领域并未被广泛使用」，原因有二：历史原因 (1981 年提出时计算量超出当时机器能力) 与本质局限 (可解释性差，只适合预测)。它的价值在思想上：它是神经网络的「前世」(单隐层网络就是带参数化 g_m ——sigmoid 的 PPR，见 19.7)； $M = 1$ 的退化情形即**单指标模型** (single index model)，计量经济学中至今有人用；投影思想在 **ICA**、密度估计中仍有应用 (§14.7)。

现代视角：如今单独用 PPR（如 R 的 `stats::ppr`）的人很少，表格数据已被 XGBoost/GBM 与深度学习取代；但「非线性作用于线性组合」这个内核是现代 ML 的地基——神经网络本质上就是把 PPR 中「任意 g_m 」换成「固定 sigmoid + 可学习参数」的产物。

19.3 神经网络

定义 19.3 (神经网络模型). 神经网络是两阶段的回归或分类模型，通常以网络图表示。对回归，一般 $K = 1$ ，顶部只有一个输出单元 Y_1 ；但对 K 类分类，顶部有 K 个单元，第 k 个单元建模第 k 类的概率，目标 Y_k 编码为 0-1 变量。

派生特征 Z_m 由输入的线性组合产生，再把目标 Y_k 建模为 Z_m 线性组合的函数：

$$\begin{aligned} Z_m &= \sigma(\alpha_{0m} + \alpha_m^T X), \quad m = 1, \dots, M, \\ T_k &= \beta_{0k} + \beta_k^T Z, \quad k = 1, \dots, K, \\ f_k(X) &= g_k(T), \quad k = 1, \dots, K, \end{aligned} \quad (19.5)$$

其中 $Z = (Z_1, \dots, Z_M)$, $T = (T_1, \dots, T_K)$ 。




图 19.2: 单隐层前馈神经网络示意图（对应 19.5）：输入层 $X_1, \dots, X_p \rightarrow$ 隐藏层 $Z_1, \dots, Z_M \rightarrow$ 输出层 $Y_1, \dots, Y_K$ 。灰色圆为偏置单元（常数「1」），同时连到隐藏层与输出层，捕获截距 α_{0m} 与 β_{0k} 。

注记 19.6 (激活函数与偏置). 激活函数 $\sigma(v)$ 通常取 sigmoid $\sigma(v) = 1/(1 + e^{-v})$ ；有时也用第 6 章的高斯径向基函数作 $\sigma(v)$ ，得到所谓的**径向基函数网络**（RBF network）。

网络图常额外画一个「偏置单元」连到隐藏层与输出层的每个单元：把常数「1」看作额外的输入特征，该偏置单元就捕获了模型 19.5 中的截距 α_{0m} 与 β_{0k} 。

注记 19.7 (输出函数 $g_k(T)$). $g_k(T)$ 对输出向量 T 作最后的变换。回归通常取恒等 $g_k(T) = T_k$ ； K 类分类早期也用恒等，后来改用 **softmax** 函数

$$g_k(T) = \frac{e^{T_k}}{\sum_{\ell=1}^K e^{T_\ell}}, \quad (19.6)$$

这正是 §4.4 多类 logit 模型所用的变换, 产生为正且和为 1 的估计。§4.2 还讨论了线性激活函数的其它问题 (尤其是潜在的严重掩蔽效应)。

注记 19.8 (隐藏单元 = 学习参数的基展开). 网络中间计算派生特征 Z_m 的单元称为**隐藏单元** (hidden units), 因为 Z_m 不可直接观测。一般可有多个隐藏层。可将 Z_m 看作原始输入 X 的**基展开**, 神经网络就是使用这些变换作为输入的线性模型 (或多类 logit 模型)。与第 5 章基展开技术相比有一个重要增强: **这里基函数的参数是从数据学习的**。

注记 19.9 (sigmoid 的激活行为). 图 11.3 展示了 $\sigma(v) = 1/(1 + \exp(-v))$, 以及 $\sigma(sv)$ ($s = \frac{1}{2}$ 与 $s = 10$)。尺度参数 s 控制激活速率: s 很大时约等于在 $v = 0$ 处硬激活; $\sigma(s(v - v_0))$ 把激活阈值从 0 移到 v_0 。

若 σ 为恒等函数, 整个模型坍缩为输入的**线性模型**。故神经网络是线性模型的非线性推广。注意到 sigmoid 的激活速率取决于 $\|\alpha_m\|$: 若 $\|\alpha_m\|$ 很小, 该单元实际工作在其激活函数的线性部分。

注记 19.10 (神经网络与 PPR 的关系). 单隐层神经网络与 PPR 模型形式**完全相同**, 区别在于: PPR 用非参数函数 $g_m(v)$, 而神经网络用基于 $\sigma(v)$ 的简单得多的函数 (其参数仅 3 个)。将神经网络视为 PPR 模型:

$$g_m(\omega_m^T X) = \beta_m \sigma(\alpha_{0m} + \alpha_m^T X) = \beta_m \sigma(\alpha_{0m} + \|\alpha_m\| (\omega_m^T X)), \quad (19.7)$$

其中 $\omega_m = \alpha_m / \|\alpha_m\|$ 是第 m 个单位向量。由于 $\sigma_{\beta, \alpha_0, s}(v) = \beta \sigma(\alpha_0 + sv)$ 比一般的非参数 $g(v)$ 复杂度低, 神经网络常用 20 或 100 个这样的函数, 而 PPR 通常用更少 (如 $M = 5$ 或 10)。

注记 19.11 (名称由来). 「神经网络」源于其最初作为人脑模型而发展: 每个单元代表一个神经元, 连接 (图中的边) 代表突触。早期模型中, 神经元在传入信号超过某阈值时「激发」, 即 σ 与 g_m 用阶跃函数。后来神经网络被认识到是**非线性统计建模**的有用工具, 而阶跃函数对优化不够光滑, 故被更光滑的阈值函数 (即图 11.3 的 sigmoid) 取代。

19.4 拟合神经网络

神经网络模型的未知参数常称为**权重** (weights)。完整权重集记为 θ :

$$\{\alpha_{0m}, \alpha_m; m = 1, \dots, M\} \text{ 共 } M(p+1) \text{ 个权重, } \{\beta_{0k}, \beta_k; k = 1, \dots, K\} \text{ 共 } K(M+1) \text{ 个权重.} \quad (19.8)$$

19.4.1 误差函数

对回归, 用平方误差和作为拟合度量:

$$R(\theta) = \sum_{k=1}^K \sum_{i=1}^N (y_{ik} - f_k(x_i))^2. \quad (19.9)$$




图 19.3: §11.3 神经网络概念流程: 输入经两阶段线性组合与非线性的激活/输出得到 $f_k(X)$ 。右侧列出本小节的若干要点: 偏置单元、隐藏单元作为学习参数的基展开、sigmoid 激活行为, 以及与 PPR 的关系 (19.7)。

对分类, 用平方误差或交叉熵 (偏差):

$$R(\theta) = - \sum_{i=1}^N \sum_{k=1}^K y_{ik} \log f_k(x_i), \quad (19.10)$$

对应的分类器为 $G(x) = \arg \max_k f_k(x)$ 。

注记 19.12 (softmax + 交叉熵 = 极大似然). 使用 softmax 激活函数与交叉熵误差函数时, 神经网络模型恰是隐藏单元上的线性 **logistic 回归**, 所有参数均由极大似然估计得到。

注记 19.13 (正则化的必要性). 我们通常不想要 $R(\theta)$ 的全局极小, 因为它很可能是过拟合解。需要某种正则化: 通过惩罚项直接实现, 或通过早停 (early stopping) 间接实现 (见下一节)。

19.4.2 反向传播 (Back-Propagation)

极小化 $R(\theta)$ 的通用方法是梯度下降, 在此背景下称为**反向传播**。由于模型的复合结构, 梯度可用链式法则轻松导出; 只需对网络做一次前向、一次后向扫描, 并跟踪各单元局部的量。

以平方误差损失为例详细推导。先整理推导所需的几组关系式:

注记 19.14 (推导所需的关系式). (1) **前向传播链** (由 19.5 逐层复合):

$$\begin{aligned} z_{mi} &= \sigma(\alpha_{0m} + \alpha_m^T x_i), \quad m = 1, \dots, M, \\ T_{ki} &= \beta_{0k} + \beta_k^T z_i, \quad k = 1, \dots, K, \\ f_k(x_i) &= g_k(T_{ki}), \end{aligned} \quad (19.11)$$

即输入 x_i 先经「线性组合 → 激活」得到隐藏单元 z_i , 再经「线性组合 → 输出函数」得到 f_k 。

(2) **平方误差** (19.14): $R_i = \sum_k (y_{ik} - f_k(x_i))^2$, 故 $\partial R_i / \partial f_k = -2(y_{ik} - f_k(x_i))$ 。

(3) **链式法则的两个环节** (β_{km} 与 $\alpha_{m\ell}$ 分别影响 f_k 的路径):

$$\frac{\partial R_i}{\partial \beta_{km}} = \underbrace{\frac{\partial R_i}{\partial f_k}}_{-2(y_{ik} - f_k)} \cdot \underbrace{\frac{\partial f_k}{\partial T_{ki}}}_{g'_k(\beta_k^T z_i)} \cdot \underbrace{\frac{\partial T_{ki}}{\partial \beta_{km}}}_{z_{mi}}, \quad (19.12)$$

$$\frac{\partial R_i}{\partial \alpha_{m\ell}} = \sum_k \frac{\partial R_i}{\partial f_k} \frac{\partial f_k}{\partial T_{ki}} \frac{\partial T_{ki}}{\partial z_{mi}} \frac{\partial z_{mi}}{\partial \alpha_{m\ell}}, \quad (19.13)$$

其中 $\partial T_{ki} / \partial z_{mi} = \beta_{km}$, $\partial z_{mi} / \partial \alpha_{m\ell} = \sigma'(\alpha_m^T x_i) x_{i\ell}$ 。注意 $\alpha_{m\ell}$ 通过单个隐藏单元 z_{mi} 影响所有 k 个输出, 故需对 k 求和。

令 $z_{mi} = \sigma(\alpha_{0m} + \alpha_m^T x_i)$ (来自 19.5), $z_i = (z_{1i}, \dots, z_{Mi})$, 则

$$R(\theta) \equiv \sum_{i=1}^N R_i = \sum_{i=1}^N \sum_{k=1}^K (y_{ik} - f_k(x_i))^2, \quad (19.14)$$

导数为

$$\begin{aligned} \frac{\partial R_i}{\partial \beta_{km}} &= -2(y_{ik} - f_k(x_i)) g'_k(\beta_k^T z_i) z_{mi}, \\ \frac{\partial R_i}{\partial \alpha_{m\ell}} &= -\sum_{k=1}^K 2(y_{ik} - f_k(x_i)) g'_k(\beta_k^T z_i) \beta_{km} \sigma'(\alpha_m^T x_i) x_{i\ell}. \end{aligned} \quad (19.15)$$

给定这些导数, 第 $(r+1)$ 次迭代的梯度下降更新为

$$\begin{aligned} \beta_{km}^{(r+1)} &= \beta_{km}^{(r)} - \gamma_r \sum_{i=1}^N \frac{\partial R_i}{\partial \beta_{km}^{(r)}}, \\ \alpha_{m\ell}^{(r+1)} &= \alpha_{m\ell}^{(r)} - \gamma_r \sum_{i=1}^N \frac{\partial R_i}{\partial \alpha_{m\ell}^{(r)}}, \end{aligned} \quad (19.16)$$

其中 γ_r 是学习率。

将 19.15 改写为

$$\frac{\partial R_i}{\partial \beta_{km}} = \delta_{ki} z_{mi}, \quad \frac{\partial R_i}{\partial \alpha_{m\ell}} = s_{mi} x_{i\ell}. \quad (19.17)$$

量 δ_{ki} 与 s_{mi} 分别是当前模型在输出层与隐藏层单元的「误差」。由定义, 它们满足

$$s_{mi} = \sigma'(\alpha_m^T x_i) \sum_{k=1}^K \beta_{km} \delta_{ki}, \quad (19.18)$$

这就是所谓的反向传播方程。

反向传播方程的详细推导 先由 19.15 第一式与 19.17 第一式对比, 读出 δ_{ki} 的定义:

$$\frac{\partial R_i}{\partial \beta_{km}} = \underbrace{-2(y_{ik} - f_k) g'_k(\beta_k^T z_i)}_{\delta_{ki}} \cdot z_{mi}.$$

即

$$\delta_{ki} = -2(y_{ik} - f_k(x_i)) g'_k(\beta_k^T z_i). \quad (19.19)$$

再看 19.15 第二式, 把不含 k 求和的因子提出来:

$$\frac{\partial R_i}{\partial \alpha_{m\ell}} = -\sum_{k=1}^K 2(y_{ik} - f_k) g'_k(\beta_k^T z_i) \beta_{km} \sigma'(\alpha_m^T x_i) x_{i\ell} = \sigma'(\alpha_m^T x_i) \left[\sum_{k=1}^K \beta_{km} \delta_{ki} \right] x_{i\ell}.$$

与 19.17 第二式 $\partial R_i / \partial \alpha_{m\ell} = s_{mi} x_{i\ell}$ 对比, 即得

$$s_{mi} = \sigma'(\alpha_m^T x_i) \sum_{k=1}^K \beta_{km} \delta_{ki},$$

这正是反向传播方程 19.18。 □

公式意义

- δ_{ki} : 输出层第 k 个单元的误差信号。它等于「输出残差 $-2(y_{ik} - f_k)$ 」乘以「输出函数斜率 g'_k 」, 即该单元输出偏离目标越多、输出函数越陡, 误差信号越强。
- s_{mi} : 隐藏层第 m 个单元的误差信号。它等于「激活函数斜率 $\sigma'(\alpha_m^T x_i)$ 」乘以「所有输出层误差 δ_{ki} 经权重 β_{km} 加权求和」。也就是说, 隐藏单元的误差是从输出层沿连接反向传播回来的: 输出层误差经权重加权、再乘本层激活导数。
- 「反向传播」的名字由此而来: 误差 δ_{ki} (输出层) 沿网络反向传递到隐藏层得到 s_{mi} , 二者分别就是 19.17 中两个梯度所需的「误差」。整个计算只用到各单元局部的量 (本单元输入、激活导数、相邻层的误差), 这正是两遍算法与并行实现的依据。




图 19.4: 前向传播 (灰色实线) 与反向传播 (红色虚线) 中各量在网络中的对应位置: 输入层存放输入值 $x_{i\ell}$; 隐藏层由 $z_{mi} = \sigma(\alpha_{0m} + \alpha_m^T x_i)$ 生成派生特征, 并接收反传误差 s_{mi} ; 输出层由 $f_k = g_k(T_{ki})$ 给出预测并计算误差 δ_{ki} 。反向传播把输出层误差 δ_{ki} 沿连接传回隐藏层得到 s_{mi} (19.18)。

注记 19.15 (两遍算法). 利用上述方程, 更新 19.16 可用两遍算法实现:

- **前向传播**: 固定当前权重, 用 19.5 计算预测值 $\hat{f}_k(x_i)$ 。
- **后向传播**: 计算误差 δ_{ki} , 再经 19.18 反传得到隐藏层误差 s_{mi} 。

两组误差再经 19.17 用于计算 19.16 中的梯度。反向传播也称 **delta 规则** (Widrow & Hoff, 1960)。交叉熵的计算组件与平方误差同形 (见习题 11.3)。

注记 19.16 (反向传播的优点). 反向传播的优点在于**简单、局部**: 每个隐藏单元只与共享连接的单元传递信息, 因此可在并行架构计算机上高效实现。

19.4.3 Batch 学习与在线学习

更新 19.16 是一种 **batch 学习**——参数更新是所有训练样本的和。学习也可**在线**进行：逐个处理观测，每处理一个样本就更新梯度，并多遍循环训练样本；此时 19.16 中的求和退化为单一项。一个 **epoch** (回合) 指完整扫过训练集一遍。在线学习让网络能处理非常大的训练集，也能随新观测到来增量更新权重。

注记 19.17 (学习率 γ_r). batch 学习的学习率 γ_r 通常取常数，也可用线搜索每次更新时极小化误差函数来优化。在线学习中 γ_r 应随迭代 $r \rightarrow \infty$ 趋于 0。这是一种**随机近似** (Robbins–Munro, 1951)：若 $\gamma_r \rightarrow 0$ 、 $\sum_r \gamma_r = \infty$ 、 $\sum_r \gamma_r^2 < \infty$ (例如 $\gamma_r = 1/r$) 则保证收敛。

注记 19.18 (反向传播可能很慢). 反向传播可能非常慢，因而通常不是首选方法。牛顿法等二阶方法也不合适，因为 R 的 Hessian 可能非常大。更好的拟合方法包括**共轭梯度**与**变度量** (variable metric) 方法，它们避免显式计算二阶导矩阵，同时收敛更快。

19.5 训练神经网络的若干问题

训练神经网络颇有「艺术」成分：模型通常**过参数化**，优化问题**非凸**且不稳定，除非遵循某些准则。

19.5.1 起始值 (Starting Values)

注记 19.19 (从小权重随机起始). 若权重接近 0，sigmoid 的有效部分近似线性，网络便坍缩为近似线性模型。通常起始权重取接近 0 的随机值，于是模型从近似线性开始，随权重增大而变非线性：各单元在需要处局部化到某些方向并引入非线性。使用**精确的 0 权重**会导致零导数与完全对称，算法永不动；从大权重开始则常得到差解。

19.5.2 过拟合 (Overfitting)

神经网络常有太多权重，会在 R 的全局极小处过拟合。早期 (有意或无意地) 用**早停** (early stopping) 规则避免过拟合：只训练一段时间，远未接近全局极小前停止。由于权重从高正则化 (线性) 解出发，这等价于把最终模型向线性模型**收缩**。用验证集确定停止时刻——预期验证误差开始上升时停止。

更显式的正则化是**权重衰减** (weight decay)，类比线性模型的岭回归 (§3.4.1)：在误差函数上加惩罚 $R(\theta) + \lambda J(\theta)$ ，其中

$$J(\theta) = \sum_{k,m} \beta_{km}^2 + \sum_{m,\ell} \alpha_{m\ell}^2, \quad (19.20)$$

$\lambda \geq 0$ 是调参参数。 λ 越大，权重越被收缩向 0；通常用交叉验证估计 λ 。惩罚的效果是分别给梯度表达式 19.16 加上 $2\beta_{km}$ 与 $2\alpha_{m\ell}$ 项。

还有其它形式的惩罚，例如

$$J(\theta) = \sum_{k,m} \frac{\beta_{km}^2}{1 + \beta_{km}^2} + \sum_{m,\ell} \frac{\alpha_{m\ell}^2}{1 + \alpha_{m\ell}^2}, \quad (19.21)$$

称为**权重消除** (weight elimination) 惩罚，它对较小的权重比 19.20 收缩更多。

注记 19.20 (图 11.4 / 11.5). 图 11.4 展示了对第 2 章 mixture 例训练含 10 个隐藏单元的网络，无权重衰减（上）与有权重衰减（下）的结果——权重衰减明显改善了预测。图 11.5 是估计权重的热图（其灰度版本称为 Hinton 图），可见权重衰减抑制了两层权重，使权重较均匀地分布在 10 个隐藏单元上。

19.5.3 输入的缩放 (Scaling of the Inputs)

输入的缩放决定了底层权重的有效缩放，因而对最终模型质量有很大影响。最好把所有输入**标准化**为均值 0、标准差 1，这确保所有输入在正则化过程中被**平等对待**，也便于为随机起始权重选取有意义的范围。对标准化后的输入，通常取 $[-0.7, +0.7]$ 上的随机均匀权重。

19.5.4 隐藏单元数与层数 (Number of Hidden Units and Layers)

一般来说，隐藏单元**过多好于过少**：过少则模型灵活性不足，无法捕捉数据中的非线性；过多则多余权重可在合适的正则化下被收缩向 0。典型隐藏单元数在 **5 到 100** 之间，随输入数与训练样本数增加。最常见的做法是放置一个相当大的单元数并用正则化训练；有些研究者用交叉验证估计最优单元数，但若已用交叉验证估计正则化参数，这似乎没有必要。

隐藏层数的选择由背景知识与实验指导。每层都提取输入的特征（用于回归或分类）；使用多层可以构建**不同分辨率的层次化特征**。§11.6 给出有效使用多层的例子。

19.5.5 多重极小 (Multiple Minima)

误差函数 $R(\theta)$ 是**非凸**的，有大量局部极小，因此最终解很依赖起始权重的选择。至少应尝试多个随机起始配置，并选（惩罚）误差最低的解。更好的做法是：用这一组网络的**平均预测**作为最终预测 (Ripley, 1996)——它优于**平均权重**，因为模型的非线性意味着平均权重解可能很差。另一种方法是 **bagging**：对训练数据的随机扰动版本训练网络，再平均其预测（见 §8.7）。

19.6 模拟数据例子 (Example: Simulated Data)

从两个加性误差模型 $Y = f(X) + \varepsilon$ 生成数据：

- **sigmoid 和:** $Y = \sigma(a_1^T X) + \sigma(a_2^T X) + \varepsilon_1$, 其中 $a_1 = (3, 3)$ 、 $a_2 = (3, -3)$, $p = 2$;
- **径向函数:** $Y = \prod_{m=1}^{10} \varphi(X_m) + \varepsilon_2$, 其中 $\varphi(t) = (2\pi)^{-1/2} e^{-t^2/2}$, $p = 10$ 。

X_j 为标准高斯变量。两个模型都取高斯误差, 使信噪比

$$\frac{\text{Var}(E(Y|X))}{\text{Var}(Y - E(Y|X))} = \frac{\text{Var}(f(X))}{\text{Var}(\varepsilon)} \quad (19.22)$$

为 4。训练样本 100, 测试样本 10,000。用带权重衰减、不同隐藏单元数的网络拟合, 对 10 个随机起始权重记录平均测试误差 $E_{\text{Test}}(Y - \hat{f}(X))^2$ 。

注记 19.21 (结论). **零隐藏单元**模型即线性最小二乘回归。神经网络完美适合 sigmoid 和模型: 两单元模型表现最好, 接近 Bayes 率 (回归的 Bayes 率即误差方差)。但随着隐藏单元增多过拟合迅速出现, 有些起始权重下甚至比线性模型更差——即使两隐藏单元, 10 个起始配置中也有 2 个不比线性模型好, 印证了**多起始值**的重要性。

径向函数对神经网络是最难的: 它球对称、无偏好方向。图 11.6 右面板显示其测试误差远高于 Bayes 率 (注意纵轴刻度与左面板不同)——事实上常数拟合 (样本均值) 的相对误差为 5 (信噪比 4 时), 可见网络比均值还差。

脊函数和径向函数的定义分别是什么? **脊函数** (ridge function): 设 $g: \mathbb{R} \rightarrow \mathbb{R}$ 是任意标量函数, $\omega \in \mathbb{R}^p$ 为固定 (通常单位) 向量, 称

$$f(X) = g(\omega^T X)$$

为 $\mathbb{R}^p$ 上的脊函数——它把 p 维输入先投影到一维方向 ω , 再施加一维非线性。其等值面是垂直于 ω 的**超平面族**, 即只在 ω 方向上变化。例如神经网络的单个隐藏单元 $\sigma(\alpha_0 + \omega^T X)$ 、图 11.1 右例 $\sin(X_1)$ 都是脊函数。

径向函数 (radial function): 设 $h: \mathbb{R}_{\geq 0} \rightarrow \mathbb{R}$ 是任意标量函数, $c \in \mathbb{R}^p$ 为固定中心, 称

$$f(X) = h(\|X - c\|)$$

为以 c 为中心的径向函数——它只依赖于 X 到中心 c 的欧氏距离, 其等值面是以 c 为球心的**球面族** (各向同性)。例如高斯核 $\exp(-\frac{1}{2\lambda}\|X - c\|^2)$ (RBF 网络的隐藏单元)、第 5 章的薄板样条基 $r^2 \log r$, 以及书中的 $e^{-\|X\|^2/2}$ ($c = 0$) 都是径向函数。

注记 19.22 (两者的对偶关系). • 脊函数的等值面是**超平面族**, 径向函数的等值面是**球面族**; 它们都把 p 维输入压缩成一个一维量再非线性化, 差别在于这个一维量是「某方向上的坐标」还是「到中心的距离」。

- 代表方法互补: 脊函数对应神经网络、PPR; 径向函数对应 RBF 网络、核方法、高斯过程。
- 用 L 个脊函数逼近球对称函数, 所需 L 随维度 p 指数增长; 反之用 L 个径向函数逼近脊函数也低效。两者的擅长领域互补。

为什么球对称径向函数对神经网络不友好？能否通过更换 sigmoid 来提升？结构不匹配是根本原因。径向函数可化简为

$$\prod_{m=1}^{10} \varphi(X_m) = (2\pi)^{-5} \exp\left(-\frac{1}{2} \sum_{m=1}^{10} X_m^2\right) = (2\pi)^{-5} e^{-\frac{1}{2} \|X\|^2},$$

它只依赖 $\|X\|^2$ ——在所有方向上均匀变化、没有偏好方向。而神经网络每个隐藏单元 $Z_m = \sigma(\alpha_{0m} + \alpha_m^T X)$ 是**脊函数**：只在方向 α_m 上变化，在垂直于 α_m 的超平面上是常数，即每个单元只「看」一个方向。目标函数在每个方向都要变化，而每个单元只能贡献一个方向的信息，要在所有方向上逼近球对称函数就需覆盖单位球面 S^{p-1} 上（连续无穷多的）所有方向——离散化后单元数随维度指数增长。对比 sigmoid 和模型 $Y = \sigma(a_1^T X) + \sigma(a_2^T X)$ ，方向 $a_1 = (3, 3)$ 、 $a_2 = (3, -3)$ 恰是网络要学的方向，两个单元就能精确表达——网络「天生」匹配这种有稀疏偏好方向的结构。

能否通过换掉 sigmoid 提升？——取决于换成什么。换成另一个脊函数（tanh、ReLU、swish...）不能：它们仍是「线性组合 + 一维非线性」，每个单元仍只对应一个方向， $p = 10$ 维球对称的核心困难原封不动——改变激活函数的形状无法改变单元只贡献一维方向信息这一**结构事实**。但若换成**径向基函数（RBF）**激活（以距离为输入的高斯核 $Z_m = \exp(-\frac{1}{2\lambda} \|X - c_m\|^2)$ ，即 §11.3 提到的 RBF 网络），则能大幅提升：此时每个单元本身**球对称**，以中心 c_m 为球心向所有方向衰减，天然匹配 $e^{-\|X\|^2/2}$ 的结构，只需少量 c_m 就能很好地表示球对称函数。

注记 19.23 (现代视角). 脊函数族与径向函数族分别擅长对方的「盲区」。这解释了为何深度学习用卷积等**结构先验**（对图像，局部方向结构比全空间对称更重要），以及为何**高斯过程/核方法**在光滑函数回归上仍强大——它们本质上是把「方向结构」先验换成了「光滑性」先验。

注记 19.24 (正则化的作用). 本例固定权重衰减 $\lambda = 0.0005$ （温和正则化）。图 11.7 显示：无权重衰减时隐藏单元越多过拟合越严重；而 $\lambda = 0.1$ 对所有隐藏单元数都得到好结果，无明显过拟合。图 11.8 对 10 隐藏单元网络扫描权重衰减参数， $\lambda = 0.1$ 近似最优。

总结：有两个自由参数需选择——权重衰减 λ 与隐藏单元数 M 。学习策略可以是：把其中一个固定在最不受约束的值（此处为零权重衰减、10 隐藏单元），确保模型足够丰富，再用**交叉验证**选择另一个。对比图 11.7 与图 11.8 可见测试误差对 λ 不如对 M 敏感，故优先交叉验证 λ 。

19.7 ZIP 码数据例子 (Example: ZIP Code Data)

这是手写数字识别的字符分类任务，曾在 ML 与神经网络界多年作为基准问题。图 11.9 展示了从信封自动扫描、经反倾斜与尺寸归一化后的 16×16 灰度数字图像（Le Cun et al., 1990）；这 256 个像素值作为分类器的输入。

纯黑箱神经网络并不理想地适合此任务，部分因为像素表示缺乏某些不变性（如小幅旋转）。早期尝试的误分类率约 4.5

为使效果突出，样本量刻意取得很小：训练集 320 个数字、测试集 160 个（并加随机水平平移生成额外图像）。拟合了五个不同的网络：

Net-1 无隐藏层，等价于**多项 logistic 回归**（256 输入 $\rightarrow$ 10 个输出单元，对应数字 0–9）。

Net-2 单隐藏层、12 个隐藏单元、全连接（前述标准网络）。

Net-3 两个隐藏层、**局部连接**（locally connected）。

Net-4 两个隐藏层、局部连接 + **权重共享**。

Net-5 两个隐藏层、局部连接、**两级权重共享**。

所有网络用 sigmoid 输出单元与平方误差函数拟合。由于参数多于训练观测，所有网络训练误差均为 0

注记 19.25 (局部连接与卷积网络). **局部连接**：每个隐藏单元只连到下一层的一小块 (patch)。Net-3 第一隐藏层为 8×8 阵列，每个单元取输入层 3×3 块的输入；第二隐藏层取 5×5 块。这使每个单元负责从下层提取局部特征，并大幅减少权重总数——Net-3 比 Net-2 隐藏单元更多，但连接/权重更少 (1226 vs. 3214)，性能相近。

权重共享 (Net-4/Net-5)：同一局部特征图 (feature map) 内所有单元在图像不同位置执行同一操作——共享同一组权重。Net-4 第一隐藏层有两个 8×8 阵列，每个单元取 3×3 块，但同一特征图内各单元共享同一组 9 个权重（各保留自己的偏置）。这迫使图像不同部分用**同一线性泛函**提取特征，这类网络即所谓的**卷积网络** (convolutional network)。共享权重关于 R 的梯度等于该权重控制的各条连接梯度之和。

表 19.1: 五个网络在手写数字分类上的测试表现 (Le Cun, 1989)。

网络	架构	连接数	权重数	正确率
Net-1	单层网络	2570	2570	80.0%
Net-2	两层网络	3214	3214	87.0%
Net-3	局部连接	1226	1226	88.5%
Net-4	约束网络 1	2266	1132	94.0%
Net-5	约束网络 2	5194	1060	98.4%

注记 19.26 (结果与启示). Net-4 连接数多于 Net-3 但权重数更少，测试性能更优；Net-5 第二隐藏层有 4 个 4×4 特征图，各连 5×5 局部块且共享权重，误差仅 1.6%——远优

于标准网络 Net-2 的 13%。Net-5 的巧妙设计源于「手写风格的特征应出现在数字的多处」这一先验，是多年实验的产物。它说明**神经网络并非全自动工具**：和所有统计模型一样，领域知识应当被用来改进性能。

该网络后来被**切线距离方法** (Simard et al., 1993, §13.3.3) 超越。至 1998 年，在大数据集 (NIST, 60,000 训练 / 10,000 测试) 上报告的最佳错误率：切线距离 + 1-NN 1.1%、9 次多项式 SVM 0.8%、更复杂的卷积网络 LeNet-5 0.8%、boosted LeNet-4 0.7%。误差估计的标准误约 0.1% ($N = 10,000$ 、 $p \approx 0.01$ 的二项平均)，故误差率相差 0.1–0.2% 内统计等价；实际标准误更高，因为测试数据已被隐式用于调参。

19.8 讨论 (Discussion)

PPR 与神经网络都是对输入的线性组合 (「派生特征」) 取非线性函数。这是回归与分类非常强大而一般的途径，在许多问题上可与最好的学习方法竞争。

注记 19.27 (适用场景与局限). 这些工具在**高信噪比**、以**预测 (而非解释)** 为目标的问题中尤其有效；在需要描述产生数据的物理过程、解释各输入作用的问题中则较弱——每个输入以非线性方式、在多处进入模型。Hinton (1989) 曾把进入每个隐藏单元的估计权重画成图来理解各单元提取的特征，但这受限于参数向量的**不可识别性**：常有 α_m 张成同一线性空间的解给出几乎相同的预测。有人建议对这些权重做主成分分析以寻找可解释解。总体而言，可解释性困难限制了其在医学等重视解释领域的应用。

另一方面，与 CART、MARS 等方法不同，神经网络是**实值参数的平滑函数**，这为贝叶斯推断提供了便利——下一节讨论一个成功的贝叶斯实现。

19.9 贝叶斯神经网络与 NIPS 2003 挑战

2003 年举行了一个分类竞赛：向参赛者提供五个已标注的二分类训练集 (不同规模、来自不同领域，见表 11.2)，并可用验证集特征在网站上提交预测 (12 周反馈期)，最后用联合训练 + 验证集训练后对独立测试集提交最终预测。共 75 组参赛，20/16 组提交验证/测试结果。竞赛强调特征提取，数据中加入人工「探针」——与真实特征分布相似但与类别标签无关的噪声特征 (各数据集探针比例见表 11.2)，算法须自行识别并降权或剔除。

评估指标包括测试集正确率、ROC 曲线下面积、以及两两分类器直接比较的综合分。结果 (Guyon et al., 2006) 中最重要的发现：**Neal & Zhang (2006) 的参赛条目是明显总冠军**——在五个数据集上三个第一，另两个分别第 5、第 7。其胜出条目用一系列预处理特征选择步骤，之后接**贝叶斯神经网络**、Dirichlet 扩散树及其组合。

表 19.2: NIPS 2003 挑战数据集。 p 为特征数 (Dorothea 的特征为二值), $N_{\text{tr}}, N_{\text{val}}, N_{\text{te}}$ 分别为训练/验证/测试样本数。

数据集	领域	特征类型	p	探针比例	N_{tr}	N_{val}	N_{te}
Arcene	质谱	稠密	10,000	30%	100	100	700
Dexter	文本分类	稀疏	20,000	50%	300	300	2,000
Dorothea	药物发现	稀疏	100,000	50%	800	350	800
Gisette	数字识别	稠密	5,000	30%	6,000	1,000	6,500
Madelon	人工	稠密	500	96%	2,000	600	1,800

19.9.1 Bayes、Boosting 与 Bagging

先简要回顾贝叶斯推断及其在神经网络上的应用。给定训练数据 $(X^{\text{tr}}, y^{\text{tr}})$ 与参数 θ 的采样模型, Neal & Zhang (2006) 使用双隐层神经网络, 输出节点为二分类的类概率 $\Pr(Y | X, \theta)$ 。给先验 $\Pr(\theta)$, 参数后验为

$$\Pr(\theta | X^{\text{tr}}, y^{\text{tr}}) = \frac{\Pr(\theta) \Pr(y^{\text{tr}} | X^{\text{tr}}, \theta)}{\int \Pr(\theta) \Pr(y^{\text{tr}} | X^{\text{tr}}, \theta) d\theta}. \quad (19.23)$$

对测试样本 $(X^{\text{new}}, Y^{\text{new}})$, 预测分布为

$$\Pr(Y^{\text{new}} | X^{\text{new}}, X^{\text{tr}}, y^{\text{tr}}) = \int \Pr(Y^{\text{new}} | X^{\text{new}}, \theta) \Pr(\theta | X^{\text{tr}}, y^{\text{tr}}) d\theta. \quad (19.24)$$

由于 19.24 的积分不可处理, 用成熟的 **MCMC** 方法从后验采样: 生成数百个 θ 值, 简单平均即估计积分。Neal & Zhang (2006) 对所有参数用弥散高斯先验, 采用的 MCMC 叫**混合蒙特卡洛** (hybrid Monte Carlo): 引入辅助动量向量、实现以目标密度为势函数的哈密顿动力学, 从而避免随机游走行为——连续候选点以更大步长在样本空间移动、相关性更低、收敛更快。

HMC 的严格数学定理 设目标分布 $\pi(\theta) \propto e^{-U(\theta)}$, 势能 $U(\theta) = -\log \pi(\theta)$ 。HMC 引入辅助动量 $p \in \mathbb{R}^d$ 与动能 $K(p) = \frac{1}{2}p^T M^{-1}p$ (M 为对称正定质量矩阵), 构造相空间联合分布

$$\pi(\theta, p) \propto e^{-H(\theta, p)}, \quad H(\theta, p) = U(\theta) + K(p),$$

其 θ 边际恰为 $\pi(\theta)$ (因为 $\int e^{-K(p)} dp$ 与 θ 无关)。哈密顿动力学

$$\dot{\theta} = \frac{\partial H}{\partial p} = M^{-1}p, \quad \dot{p} = -\frac{\partial H}{\partial \theta} = -\nabla U(\theta) = \nabla \log \pi(\theta)$$

具有三个关键性质:

1. **能量守恒:** $\frac{d}{dt} H(\theta(t), p(t)) = 0$ (沿轨道 H 不变);

2. **体积守恒** (Liouville 定理): 相空间体积在动力学流下不变, 即映射保测;

3. **时间可逆**: $p \rightarrow -p$ 后轨道反向, 动力学可逆。

数值实现用 **leapfrog** (蛙跳) 积分, 步长 ϵ 、共 L 步:

$$\begin{aligned} p_{t+\epsilon/2} &= p_t - \frac{\epsilon}{2} \nabla U(\theta_t), \\ \theta_{t+\epsilon} &= \theta_t + \epsilon M^{-1} p_{t+\epsilon/2}, \\ p_{t+\epsilon} &= p_{t+\epsilon/2} - \frac{\epsilon}{2} \nabla U(\theta_{t+\epsilon}). \end{aligned} \quad (19.25)$$

蛙跳是**辛** (symplectic) 积分器: 保持体积、可逆, 能量误差 $O(\epsilon^2)$ 且有界。

定理 19.1 (HMC 的正确性). 设 ϵ 固定, leapfrog 映射 $\mathcal{T}_\epsilon: (\theta, p) \mapsto (\theta^*, p^*)$ 是双射、可逆且保体积。以

$$\alpha = \min\left(1, e^{-[H(\theta^*, p^*) - H(\theta, p)]}\right)$$

为接受概率的 Metropolis 校正, 使马尔可夫链以 $\pi(\theta, p) \propto e^{-H(\theta, p)}$ 为**唯一不变分布**, 其 θ 边际即目标 $\pi(\theta)$ 。由于 leapfrog 的能量误差有界且 $O(\epsilon^2)$, 接受率可维持在较高水平。

注记 19.28 (为何 HMC 比随机游走 MH 快). 随机游走 MH 的候选点在高维下扩散缓慢、相邻样本自相关高; HMC 沿能量守恒轨道大步滑动、相邻样本相关性低, 有效样本量更大。代价是需计算梯度 $\nabla U(\theta) = \nabla \log \pi(\theta)$ ——故仅适用于光滑可微的目标 (如神经网络后验), 对不光滑模型 (如树) 不适用 (呼应 §11.9 末尾的结论)。

注记 19.29 (HMC 与模拟退火 (SA) 的关系). 两者都借用统计物理的「能量 + 温度」语言: 目标写成玻尔兹曼形式 $\pi(\theta) \propto e^{-E(\theta)/T}$ 。但目的不同——**HMC 固定温度** ($T = 1$) 用于**高效采样** (估计后验期望), **SA 则随时间降低温度** T 用于**优化** (找 $\arg \min E(\theta)$)。SA 本质是「带温度调度的 Metropolis」: 高温时大范围探索、低温时收敛到低能态; HMC 本质是「带动量/动力学的 Metropolis」: 用哈密顿轨道代替随机游走提议。二者可结合 (如并行回火/退火 HMC), 在高维多模态分布上同时利用温度跨越与动力学加速。

贝叶斯神经网络的形式化定义

定义 19.4 (贝叶斯神经网络 (Bayesian Neural Network, BNN)). 贝叶斯神经网络 = **神经网络骨架** + **贝叶斯推断外壳**。设网络输出为 $f_k(X; \theta)$ (如二分类的类概率 $\Pr(Y | X, \theta)$), 权重 θ 不再是单一点估计, 而视为服从后验分布 $\Pr(\theta | X^{\text{tr}}, y^{\text{tr}})$ (19.23) 的随机变量。输入与普通神经网络完全相同 (特征向量 X); 输出是预测分布 $\Pr(Y^{\text{new}} | X^{\text{new}}, X^{\text{tr}}, y^{\text{tr}})$ (19.24), 而非单点预测——因此天然携带不确定性。

BNN 的四步流程

1. **建模**: 设定采样模型 (似然) 与先验:

$$\Pr(y^{\text{tr}} | X^{\text{tr}}, \theta) = \prod_{i=1}^N \Pr(y_i | x_i, \theta) \quad (\text{网络给出类概率}), \quad \Pr(\theta) \quad (\text{弥散高斯先验}).$$

2. **推断**: 由贝叶斯公式求权重的联合后验 (19.23):

$$\Pr(\theta | X^{\text{tr}}, y^{\text{tr}}) = \frac{\Pr(\theta) \Pr(y^{\text{tr}} | X^{\text{tr}}, \theta)}{\int \Pr(\theta) \Pr(y^{\text{tr}} | X^{\text{tr}}, \theta) d\theta} \propto \Pr(\theta) \Pr(y^{\text{tr}} | X^{\text{tr}}, \theta).$$

注意是整个参数向量 $\theta = (\alpha, \beta)$ 共用一个联合后验, 而非每个权重各自独立; 分母为归一化常数。

3. **采样**: 后验积分不可解析, 用 MCMC (此处为 HMC) 从后验分布采样出数百个权重样本 $\theta_1, \dots, \theta_L$, 用经验分布近似后验:

$$\Pr(\theta | X^{\text{tr}}, y^{\text{tr}}) \approx \frac{1}{L} \sum_{\ell=1}^L \delta(\theta - \theta_{\ell}), \quad \theta_{\ell} \sim \Pr(\theta | X^{\text{tr}}, y^{\text{tr}}).$$

每次采样都同时移动所有权重, 但目的不是「收敛到一个最优」, 而是「遍历后验分布」。

4. **预测**: 把后验近似代入预测分布 19.24, 将积分换成对样本平均 (19.28 取 $w_{\ell} = 1/L$):

$$\Pr(Y^{\text{new}} | X^{\text{new}}, X^{\text{tr}}, y^{\text{tr}}) = \int \Pr(Y^{\text{new}} | X^{\text{new}}, \theta) \Pr(\theta | X^{\text{tr}}, y^{\text{tr}}) d\theta \approx \frac{1}{L} \sum_{\ell=1}^L \Pr(Y^{\text{new}} | X^{\text{new}}, \theta_{\ell}).$$

即对每个采样权重计算预测概率, 再简单平均得到最终预测分布——这正是贝叶斯模型平均 (Bayesian Model Averaging)。

弥散高斯先验 (diffuse Gaussian prior)

定义 19.5 (弥散高斯先验). 弥散 (diffuse) = 对参数几乎没有先验信息。弥散高斯先验就是中心在 0、方差取很大的高斯分布, 作为每个权重的先验:

$$\Pr(\theta_j) = \mathcal{N}(\theta_j | 0, \sigma_0^2), \quad \sigma_0^2 \text{ 很大}, \quad \Pr(\theta) = \prod_j \mathcal{N}(\theta_j | 0, \sigma_0^2),$$

其中 σ_0^2 相对参数的合理尺度取很大值, 使得这个钟形曲线极宽极平, 在感兴趣的区间内几乎处处接近均匀分布。

为什么用高斯? 高斯密度光滑、处处可微——后验因此光滑可微, 保证 HMC 所需的梯度 $\nabla_{\theta} \log \pi(\theta)$ 存在。这正是「HMC 只适用光滑模型」这一要求在选择先验时的体现。

为什么弥散 (方差大)? 因为 $e^{-\theta_j^2/2\sigma_0^2}$ 在 σ_0^2 很大时、于参数合理范围内几乎恒等于 1——先验几乎不改变后验形状, 后验基本由似然决定, 让数据说了算。有限但很大的

σ_0^2 等价于一个极弱的 L_2 (岭式) 先验: 若 $\sigma_0^2 \rightarrow \infty$ 则退化为不严格归一化的无信息均匀先验。

与 ARD 的关系: §11.9 后面的 ARD 是弥散高斯先验的精细化——不再让所有权重共用一个大方差 σ_0^2 , 而是给每个特征 j 一个独立的先验方差 σ_j^2 (均值仍 0), 再看后验中 σ_j^2 是否被数据压得很小: 若后验方差集中在很小的值, 说明该特征不重要, 可丢弃。即 ARD = 逐特征的弥散高斯先验 + 用后验方差做特征筛选。

注记 19.30 (普通 NN 与 BNN 的对比).

	普通神经网络	贝叶斯神经网络
权重	一个 $\hat{\theta}$ (点估计)	后验分布 $\text{Pr}(\theta \text{data})$
迭代目的	收敛到最优	遍历后验 (采样)
最终产物	一个训练好的网络	数百个权重样本
输出	点预测 $\hat{f}(X)$	预测分布 (含不确定性)
过拟合处理	正则化 / 早停	后验平均自动处理
代价	快	慢 (需采多个权重)

特征预处理尝试两种形式:

1. 用 t 检验做单变量筛选 (univariate screening);
2. 自动相关判定 (ARD): 第 j 个特征到第一隐藏层各单元的权重共享共同先验方差 σ_j^2 、先验均值 0, 计算各 σ_j^2 的后验, 丢弃后验方差集中在很小值的特征。

ARD 的全称与定义 ARD = Automatic Relevance Determination (自动相关判定)。它给每个特征 j 一个独立的先验方差 σ_j^2 (先验均值 0), 通过贝叶斯推断计算各 σ_j^2 的后验分布, 然后丢弃那些后验方差集中在很小值的特征。

工作原理: 先验设特征 j 到第一隐藏层各单元的权重共享 $\mathcal{N}(0, \sigma_j^2)$ ——「特征 j 的相关性」由它自己的方差 σ_j^2 控制。贝叶斯推断后, 若数据里特征 j 对预测无关紧要, 后验会把 σ_j^2 压得很小 (等价于把该特征权重强烈收缩到 0)。于是看每个 σ_j^2 的后验: 后验方差集中在很小值 $\Rightarrow$ 该特征「自动判定为不相关」, 可丢弃。即 ARD 让数据自己决定每个特征该保留多少。

公式化表达。 设特征 j 到第一隐藏层的权重为 $\theta_{j\cdot} = (\theta_{j1}, \dots, \theta_{jM})$, ARD 的层级模型为

$$\begin{aligned} \theta_{jm} | \sigma_j^2 &\sim \mathcal{N}(0, \sigma_j^2), \quad m = 1, \dots, M \text{ (共享先验方差)}, \\ \sigma_j^2 &\sim \text{Inv-Gamma}(a, b) \text{ (超先验, 或经验贝叶斯点估计)}, \end{aligned} \quad (19.26)$$

于是「特征 j 的相关性」由 σ_j^2 一个超参数统一控制。对特征 j 的权重做边际化后, 其后验为

$$\text{Pr}(\sigma_j^2 | \text{data}) \propto \text{Pr}(\sigma_j^2) \int \text{Pr}(\text{data} | \theta) \prod_{m=1}^M \mathcal{N}(\theta_{jm} | 0, \sigma_j^2) d\theta_{j\cdot}. \quad (19.27)$$

判定准则：若 $\Pr(\sigma_j^2 \mid \text{data})$ 集中在很小的 σ_j^2 处，则特征 j 的权重后验被强烈收缩向 0，判定该特征不相关并丢弃。

与弥散高斯先验的关系：弥散高斯先验是所有特征共用一个大方差 σ_0^2 ；ARD 是逐特征独立方差 σ_j^2 的精细化——ARD = 逐特征的弥散高斯先验 + 用后验方差做特征筛选。

筛选特征集与 ARD 缩减特征集 这是 §11.9.2 性能比较中使用的两种不同的特征预处理结果：

	筛选特征集	ARD 缩减特征集
所用方法	单变量 t 检验	ARD (贝叶斯)
特征是否独立	每个特征独立筛	由模型后验决定
是否需要模型	不需要 (纯统计检验)	需先拟合贝叶斯网络

关键区别：筛选特征集对每个特征单独做 t 检验（看其在两类间是否有显著差异），完全不依赖任何模型，是「自洽」的预处理；ARD 缩减特征集由贝叶斯神经网络的 ARD 后验方差决定，隐含地用了贝叶斯网络的推断结果。

为何重要：因为 ARD 缩减特征集「来自贝叶斯神经网络方法」，故对比时只有用筛选特征集的方法才是自洽、完整的流程——非贝叶斯方法 (boosted trees、random forests 等) 若用 ARD 缩减特征集，等于「借用」了贝叶斯方法的信息，对它们不公平。这也正是作者强调「只有使用筛选特征集的方法才是 legitimate、self-contained procedures」的原因。

注记 19.31 (成功要素与贝叶斯的真正力量). 该方法有三个可能重要的特征：(a) 特征选择与预处理、(b) 神经网络模型、(c) 用 MCMC 的贝叶斯推断。据 Neal & Zhang (2006)，(a) 中的特征筛选纯为计算效率——特征多时 MCMC 很慢；避免过拟合无需特征选择，因为后验平均 19.24 会自动处理。

作者观点：现代贝叶斯方法的力量不在于作为正式推断程序（很少有人真信高维复杂神经网络中的先验是正确的），而在于它给出一种高效采样模型空间相关部分、再对高概率模型的预测做平均的方式。

Bagging 与 boosting 是非贝叶斯方法，但与贝叶斯模型中的 MCMC 有相似性。贝叶斯方法固定数据、按当前后验估计扰动参数；bagging 以 i.i.d. 方式扰动数据再重估模型得到新参数；boosting 类似 bagging，但拟合的是各基学习器模型的加和，且用非 i.i.d. 样本学习。这些都可写为

$$\hat{f}(x^{\text{new}}) = \sum_{\ell=1}^L w_{\ell} \mathbb{E}(Y^{\text{new}} \mid x^{\text{new}}, \hat{\theta}_{\ell}).$$

(19.28)

其中 $\hat{\theta}_{\ell}$ 是大批模型参数。贝叶斯： $w_{\ell} = 1/L$ ，从后验采样 θ_{ℓ} 估计后验均值；bagging： $w_{\ell} = 1/L$ ， $\hat{\theta}_{\ell}$ 是 bootstrap 重采样重拟合的参数；boosting：权重全为 1，但 $\hat{\theta}_{\ell}$ 以非随机、顺序方式选择以持续改进拟合。

19.9.2 性能比较

基于上述相似性，在表 11.2 的五个数据集上比较了贝叶斯神经网络、boosted 树、boosted 神经网络、随机森林与 bagged 神经网络。细节：贝叶斯网络为双隐层 20 与 8 单元 (Neal 的 C 包)；boosted 树用 R 的 gbm (每轮 bag 80% 数据, shrinkage 0.001–0.1, 树深 2–9)；boosted 神经网络用 2 或 4 单元单隐层网络 (nnet)；随机森林用默认参数；bagged 网络与贝叶斯网络同架构。

注记 19.32 (结果). 图 11.12 与表 11.3 显示，使用筛选特征集与 ARD 缩减特征集时，贝叶斯神经网络再次胜出，但对某些数据集差异统计不显著（误差条宽度为一个标准误）。随机森林在筛选特征集上表现最好，boosted 神经网络在缩减特征集上最好、几乎赶上贝叶斯网络。

boosted 神经网络优于 boosted 树，说明神经网络模型更适合这些问题：单个特征可能不是好的预测器，而特征的线性组合效果更好；但随机森林的出色表现与此解释相悖（出乎作者意料）。由于缩减特征集来自贝叶斯方法，只有用筛选特征集的方法才是自洽的完整流程。表 11.3 同时显示非贝叶斯方法在计算时间上有明显优势。

总体而言，贝叶斯神经网络的优势可能来自：(a) 神经网络模型很适合这五个问题，(b) MCMC 高效探索了参数空间的重要部分并按质量平均模型。贝叶斯方法对平滑参数化的模型（如神经网络）有效；对不光滑的模型（如树）是否同样有效尚不清楚。

表 19.3: 不同方法的性能：五个问题上测试误差的平均排名（低为好）及平均计算时间（分钟，括号内为标准误）。

方法	筛选特征		ARD 缩减特征	
	平均排名	平均时间	平均排名	平均时间
贝叶斯神经网络	1.5	384 (138)	1.6	600 (186)
Boosted 树	3.4	3.0 (2.5)	4.0	34.1 (32.4)
Boosted 神经网络	3.8	9.4 (8.6)	2.2	35.6 (33.5)
随机森林	2.7	1.9 (1.7)	3.2	11.2 (9.3)
Bagged 神经网络	3.6	3.5 (1.1)	4.0	6.4 (4.4)

19.10 计算考虑 (Computational Considerations)

对 N 个观测、 p 个预测变量、 M 个隐藏单元、 L 个训练 epoch，一次神经网络拟合通常需要 $O(NpML)$ 次运算。可用于拟合神经网络的软件包非常多（可能远多于主流统计方法的包），但质量参差；由于神经网络的学习问题对输入缩放等问题敏感，应仔细选择并测试这类软件。

19.11 本章小结

19.11.1 核心框架




图 19.5: 第 11 章核心框架: 神经网络是脊函数的叠加 (输入线性组合 + 非线性激活 $\rightarrow$ 派生特征 $\rightarrow$ 输出函数), 用反向传播拟合、正则化防过拟合; 进一步可用贝叶斯方式把权重视为后验分布, 用 HMC 采样并做后验平均预测。

19.11.2 要点回顾

- **模型本质:** 神经网络是「脊函数」的叠加, 与 PPR 形式相同、只是把非参数 g_m 换成参数化的 sigmoid 函数; 它是线性模型的非线性推广, 参数化的基函数从数据学习。
- **拟合:** 最小化误差函数 (回归用平方误差、分类用交叉熵) $\rightarrow$ 反向传播 (两遍算法, 误差从输出层反传到隐藏层) $\rightarrow$ 梯度下降更新权重。
- **训练艺术:** 小随机起始值、输入标准化、权重衰减/早停、隐藏单元数 5–100、多起始值应对多重极小——误差函数非凸, 训练需要这些准则。
- **适用性:** 适合高信噪比、以预测为目标的问题; 可解释性差 (每个输入多处非线性进入), 不擅长描述物理机制。

- **结构先验**: ZIP 码例子展示用局部连接 + 权重共享 (**卷积网络**) 把领域知识编码进架构, 可大幅提升性能 (Net-5 错误率 1.6% vs. 全连接 13%)。
- **贝叶斯扩展**: 把权重当作随机变量, 求后验 $\Pr(\theta \mid \text{data})$, 用 HMC 从后验采样并做后验平均——自动处理过拟合、给出不确定性; ARD 用逐特征先验方差做特征筛选。

注记 19.33 (一章主线). 从 PPR 的「非线性作用于线性组合」出发, 神经网络把这一思想变成可微、可训练的两阶段模型; 反向传播解决「怎么学」, 正则化与训练技巧解决「学过头」, 贝叶斯视角解决「学多少才可信」。

第二十章 Support Vector Machines and Flexible Discriminants（支持向量机与灵活判别）

20.1 引言

本章介绍分类问题中线性决策边界的推广。第 4 章讨论了两类线性可分情形下的最优分离超平面（optimal separating hyperplane）；这里将其推广到类重叠（不可分）的情形。这些技术进一步推广为支持向量机（support vector machine, SVM）：通过在放大后的特征空间中构造线性边界来产生非线性边界。

第二组方法推广 Fisher 线性判别分析（LDA），包括：

- 灵活判别分析（flexible discriminant analysis, FDA）——以与 SVM 非常类似的方式构造非线性边界；
- 惩罚判别分析（penalized discriminant analysis, PDA）——用于特征数众多且高度相关的信号/图像分类问题；
- 混合判别分析（mixture discriminant analysis, MDA）——用于形状不规则的类别。

20.2 支持向量分类器

第 4 章讨论了在两个完全分离的类之间构造最优分离超平面的技术，这里回顾并推广到类可能无法被线性边界分离的情形。

定义 20.1 (数据与超平面). 训练数据为 N 对 $(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)$, 其中 $x_i \in \mathbb{R}^p$, $y_i \in \{-1, 1\}$. 超平面定义为

$$\{x : f(x) = x^T \beta + \beta_0 = 0\}, \quad (20.1)$$

其中 β 是单位向量： $\|\beta\| = 1$ 。由 $f(x)$ 导出的分类规则为

$$G(x) = \text{sign}[x^T \beta + \beta_0]. \quad (20.2)$$

超平面几何在 §4.5 中回顾: $f(x)$ (式 20.1) 给出点 x 到超平面 $f(x) = 0$ 的带符号距离。

注记 20.1 (可分情形的最大间隔). 若两类线性可分, 可找到 $f(x) = x^T \beta + \beta_0$ 使 $y_i f(x_i) > 0, \forall i$, 从而构造在类 1 与类 -1 的训练点之间产生最大间隔 (margin) 的超平面。优化问题

$$\max_{\beta, \beta_0, \|\beta\|=1} M \quad \text{subject to} \quad y_i(x_i^T \beta + \beta_0) \geq M, \quad i = 1, \dots, N, \quad (20.3)$$

即捕捉这一概念。图 20.1 中, 超平面两侧各 M 个单位距离的带状区域宽 $2M$, 称为间隔。




图 20.1: 可分情形的最大间隔 (示意, 对应书图 12.1 左图)。实线为决策边界 $x^T \beta + \beta_0 = 0$, 两侧虚线界定宽 $2M = 2/\|\beta\|$ 的最大间隔带 (阴影); 加圈的观测为支持向量, 恰好落在间隔边缘上。

该问题可更方便地重写为

$$\min_{\beta, \beta_0} \|\beta\| \quad \text{subject to} \quad y_i(x_i^T \beta + \beta_0) \geq 1, \quad i = 1, \dots, N, \quad (20.4)$$

其中去掉了 β 的范数约束, 且 $M = 1/\|\beta\|$ 。式 20.4 是分离数据下支持向量准则的通常写法。这是一个凸优化问题 (二次准则 + 线性不等式约束), 解在 §4.5.2 中刻画。

注记 20.2 (不可分情形: 松弛变量). 现在假设类在特征空间重叠。处理重叠的方式之一是仍然最大化 M , 但允许一些点位于间隔的错误一侧。定义松弛变量 $\xi = (\xi_1, \dots, \xi_N)$ 。修改式 20.3 的约束有两种自然方式:

$$y_i(x_i^T \beta + \beta_0) \geq M - \xi_i, \quad (20.5)$$

或

$$y_i(x_i^T \beta + \beta_0) \geq M(1 - \xi_i), \quad (20.6)$$

对所有 i 成立, $\xi_i \geq 0$, $\sum_{i=1}^N \xi_i \leq \text{常数}$ 。两种选择导致不同解。

为什么选 (12.6) 而不是 (12.5)? 第一种 (式 20.5) 看似更自然, 因为它以距间隔的实际距离度量重叠; 第二种 (式 20.6) 度量的是相对距离, 随间隔宽度 M 变化。但关键区别在凸性: 第一种选择导致非凸优化问题, 而第二种是凸的。因此式 20.6 导出「标准」支持向量分类器, 本书沿用。

注记 20.3 (ξ_i 的含义). 式 20.6 中, ξ_i 表示预测 $f(x_i) = x_i^T \beta + \beta_0$ 落在其间隔错误一侧的比例量。通过约束 $\sum \xi_i$, 我们限制了预测落在间隔错误一侧的总比例量。当 $\xi_i > 1$ 时发生误分类, 因此将 $\sum \xi_i$ 限制在某值 K , 就限定了训练误分类总数不超过 K 。

与 §4.5.2 中式 (4.48) 一样, 可去掉 β 的范数约束、令 $M = 1/\|\beta\|$, 把式 20.4 写成等价形式

$$\min \|\beta\| \quad \text{subject to} \quad \begin{cases} y_i(x_i^T \beta + \beta_0) \geq 1 - \xi_i, \forall i, \\ \xi_i \geq 0, \sum \xi_i \leq \text{常数}. \end{cases} \quad (20.7)$$

这是不可分情形下支持向量分类器的通常定义方式。书中提到式 20.7 中约束里固定的尺度「1」令人困惑, 更愿意从式 20.6 出发推导。

注记 20.4 (与 LDA 的本质区别). 由准则 20.7 的性质可知, 位于类边界内部深处的点对边界的塑造不起重要作用。这是一个吸引人的性质, 也是它与线性判别分析 (§4.3) 的区别所在: 在 LDA 中, 决策边界由类分布的协方差和类质心的位置决定。我们将在 §12.3.3 看到, 逻辑回归在这点上与支持向量分类器更为相似。

20.2.1 计算支持向量分类器

问题 20.7 是带线性不等式约束的二次问题, 因此是凸优化问题。书中用 Lagrange 乘子给出二次规划解。计算上, 把 20.7 重写为等价形式比较方便:

$$\min_{\beta, \beta_0} \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^N \xi_i \quad \text{subject to} \quad \xi_i \geq 0, y_i(x_i^T \beta + \beta_0) \geq 1 - \xi_i, \forall i, \quad (20.8)$$

其中「代价」参数 C 取代 20.7 中的常数; 可分情形对应 $C = \infty$ 。

Lagrange (原始) 函数为

$$L_P = \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i [y_i(x_i^T \beta + \beta_0) - (1 - \xi_i)] - \sum_{i=1}^N \mu_i \xi_i, \quad (20.9)$$

关于 β, β_0, ξ_i 极小化。令各导数分别为零, 得

$$\beta = \sum_{i=1}^N \alpha_i y_i x_i, \quad (20.10)$$

$$0 = \sum_{i=1}^N \alpha_i y_i, \quad (20.11)$$

$$\alpha_i = C - \mu_i, \forall i, \quad (20.12)$$

以及非负性约束 $\alpha_i, \mu_i, \xi_i \geq 0, \forall i$ 。

将式 20.10–20.12 代入式 20.9, 得到 Lagrange (Wolfe) 对偶目标函数

$$L_D = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{i'=1}^N \alpha_i \alpha_{i'} y_i y_{i'} x_i^T x_{i'}, \quad (20.13)$$

它对任意可行点给出目标函数 20.8 的一个下界。我们在约束 $0 \leq \alpha_i \leq C, \sum_{i=1}^N \alpha_i y_i = 0$ 下最大化 L_D 。

除式 20.10–20.12 外, Karush–Kuhn–Tucker (KKT) 条件还包括约束

$$\alpha_i [y_i (x_i^T \beta + \beta_0) - (1 - \xi_i)] = 0, \quad (20.14)$$

$$\mu_i \xi_i = 0, \quad (20.15)$$

$$y_i (x_i^T \beta + \beta_0) - (1 - \xi_i) \geq 0, \quad (20.16)$$

对 $i = 1, \dots, N$ 成立。这些方程 20.10–20.16 共同唯一刻画原始问题与对偶问题的解。

注记 20.5 (支持向量). 由式 20.10 可见, β 的解具有形式

$$\hat{\beta} = \sum_{i=1}^N \hat{\alpha}_i y_i x_i, \quad (20.17)$$

其中只有那些约束 20.16 恰好取等号的观测才有非零系数 $\hat{\alpha}_i$ (由式 20.14)。这些观测称为支持向量, 因为 $\hat{\beta}$ 仅由它们表示。

在这些支持点中: 有些位于间隔边缘上 ($\hat{\xi}_i = 0$), 由式 20.15 与 20.12 知其特征为 $0 < \hat{\alpha}_i < C$; 其余点 ($\hat{\xi}_i > 0$) 有 $\hat{\alpha}_i = C$ 。由式 20.14, 这些间隔点 ($0 < \hat{\alpha}_i, \hat{\xi}_i = 0$) 中任意一个都可用于解出 β_0 , 为数值稳定起见通常取所有解的平均。

最大化对偶 20.13 是比原始问题 20.9 更简单的凸二次规划问题, 可用标准技术求解。给定解 $\hat{\beta}_0$ 与 $\hat{\beta}$, 决策函数为

$$\hat{G}(x) = \text{sign}[\hat{f}(x)] = \text{sign}[x^T \hat{\beta} + \hat{\beta}_0]. \quad (20.18)$$

该过程的调参参数是代价参数 C 。

20.2.2 混合示例 (续)

图 12.2 展示了图 2.5 (第 21 页) 混合示例中两个重叠类在 $C = 0.01$ 与 $C = 10,000$ 两种代价参数下的支持向量边界, 两者的分类性能相当。

注记 20.6 (C 的作用). 位于边界错误一侧的点是支持向量; 此外, 位于边界正确一侧但靠近边界 (在间隔内) 的点也是支持向量。 $C = 0.01$ 的间隔比 $C = 10,000$ 更大。因此:

- 较大的 C 把注意力更多地放在 (正确分类的) 靠近决策边界的点上;

- 较小的 C 则让更远处的数据也参与。

无论哪种情况，误分类点都被赋权，无论它们离得多远。在此例中，由于线性边界的刚性，过程对 C 的选择并不敏感。

注记 20.7 (留一交叉验证误差的界). C 的最优值可用交叉验证 (第 7 章) 估计。有趣的是，留一交叉验证误差可由数据中支持点所占比例给出上界：因为剔除一个非支持向量的观测不会改变解，这些观测被原边界正确分类，因而在交叉验证过程中也会被正确分类。然而这个界往往偏高，不足以用来选 C (在示例中分别达到 62% 和 85%)。

20.3 支持向量机与核

前面描述的支持向量分类器在输入特征空间中寻找线性边界。与其他线性方法一样，可通过**基展开** (如多项式或样条，第 5 章) 放大特征空间来增加灵活性。一般而言，放大空间中线性边界在训练分离上表现更好，并转化为原空间中的**非线性边界**。一旦选定基函数 $h_m(x)$, $m = 1, \dots, M$, 流程与之前相同：用输入特征 $h(x_i) = (h_1(x_i), \dots, h_M(x_i))$ 拟合支持向量分类器，得到 (非线性) 函数 $\hat{f}(x) = h(x)^T \hat{\beta} + \hat{\beta}_0$, 分类器仍为 $\hat{G}(x) = \text{sign}(\hat{f}(x))$ 。

注记 20.8 (SVM 的动机与核心问题). 支持向量机分类器是这一思想的推广，其中放大空间的维数允许非常大，某些情形下是无穷维。表面上计算会变得不可行，且基函数足够多时数据可分、会发生过拟合。SVM 技术首先解决这些问题；随后我们会看到，SVM 分类器实际上是在用**特定的准则和正则化形式**求解函数拟合问题，它属于一个包含第 5 章**光滑样条**在内的更大问题类。读者可参考 §5.8，那里提供了背景材料，与接下来的两小节内容有部分重叠。

20.3.1 计算用于分类的 SVM

优化问题 20.9 及其解可以一种只通过内积涉及输入特征的特殊方式表示。直接对变换后的特征向量 $h(x_i)$ 做：Lagrange 对偶函数 20.13 具有形式

$$L_D = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{i'=1}^N \alpha_i \alpha_{i'} y_i y_{i'} \langle h(x_i), h(x_{i'}) \rangle. \quad (20.19)$$

由式 20.10 可知解函数 $f(x)$ 可写为

$$f(x) = h(x)^T \beta + \beta_0 = \sum_{i=1}^N \alpha_i y_i \langle h(x), h(x_i) \rangle + \beta_0. \quad (20.20)$$

如前，给定 α_i , β_0 可由对任意 (或全部) 满足 $0 < \alpha_i < C$ 的 x_i 在式 20.20 中解 $y_i f(x_i) = 1$ 得到。

注记 20.9 (核技巧). 式 20.19 与 20.20 都只通过内积涉及 $h(x)$ 。先明确各对象所在的空间：

- h 是基展开映射 (feature map), 它把输入空间 (原特征空间) $\mathbb{R}^p$ 中的点 x 映到特征空间 (变换空间) $\mathcal{H}$:

$$h: \mathbb{R}^p \rightarrow \mathcal{H}, \quad x \mapsto h(x) = (h_1(x), \dots, h_M(x))^T.$$

M 可以非常大, 某些情形下为无穷维 (此时 $\mathcal{H}$ 是无穷维 Hilbert 空间, h 的「分量」来自核 K 的本征展开, 见 §12.3.3)。每个分量 $h_m(x)$ 就是一个基函数 (多项式、样条、径向基等, 见式 20.22)。

- K 是特征空间 $\mathcal{H}$ 上的内积: 把 x, x' 先经 h 映到 $\mathcal{H}$, 再取该空间的内积,

$$K(x, x') = \langle h(x), h(x') \rangle_{\mathcal{H}}. \quad (20.21)$$

M 有限时它是普通的欧氏点积 $\sum_{m=1}^M h_m(x)h_m(x')$; M 无穷时是 $\mathcal{H}$ 的 Hilbert 内积。注意 K 的自变量是原输入 $x, x' \in \mathbb{R}^p$, 值却等于特征空间里的内积。

要点: SVM 只需知道 K ——一个定义在 $\mathbb{R}^p \times \mathbb{R}^p$ 上、却等价于 $\mathcal{H}$ 中内积的二变量函数——无需指明变换 h , 也不必显式构造特征空间。 K 应为对称的正 (半) 定函数; 参见 §5.8.1。

SVM 文献中三种常用的核:

$$\begin{aligned} d \text{ 阶多项式: } & K(x, x') = (1 + \langle x, x' \rangle)^d, \\ \text{径向基: } & K(x, x') = \exp(-\gamma \|x - x'\|^2), \\ \text{神经网络: } & K(x, x') = \tanh(\kappa_1 \langle x, x' \rangle + \kappa_2). \end{aligned} \quad (20.22)$$

多项式核到底对应什么样的基展开? 以二次核为例 考虑有两个输入 X_1, X_2 的特征空间与二次多项式核, 则

$$\begin{aligned} K(X, X') &= (1 + \langle X, X' \rangle)^2 \\ &= (1 + X_1 X'_1 + X_2 X'_2)^2 \\ &= 1 + 2X_1 X'_1 + 2X_2 X'_2 + (X_1 X'_1)^2 + (X_2 X'_2)^2 + 2X_1 X'_1 X_2 X'_2. \end{aligned} \quad (20.23)$$

于是 $M = 6$, 若取 $h_1(X) = 1$, $h_2(X) = \sqrt{2}X_1$, $h_3(X) = \sqrt{2}X_2$, $h_4(X) = X_1^2$, $h_5(X) = X_2^2$, $h_6(X) = \sqrt{2}X_1 X_2$, 则 $K(X, X') = \langle h(X), h(X') \rangle$ 。由式 20.20 知解可写为

$$\hat{f}(x) = \sum_{i=1}^N \hat{\alpha}_i y_i K(x, x_i) + \hat{\beta}_0. \quad (20.24)$$

注记 20.10 (放大空间中 C 的作用). 在放大特征空间中, 由于完美分离常常可以实现, 参数 C 的角色更加清晰: 大的 C 会抑制任何正的 ξ_i , 导致原特征空间中过拟合的 **wiggly** (扭曲) 边界; 小的 C 会促使 $\|\beta\|$ 取较小值, 进而使 $f(x)$ 与边界更光滑。图 12.3 将两个非线性支持向量机应用于第 2 章的混合示例: 径向基核产生的边界与 Bayes 最优边界相当接近 (对比图 2.5)。

在支持向量的早期文献中, 有人声称核性质是支持向量机独有的, 并允许规避维数灾难——这两种说法都不成立, 接下来的三个小节将讨论这两个问题。

20.3.2 SVM 作为惩罚方法

令 $f(x) = h(x)^T \beta + \beta_0$, 考虑优化问题

$$\min_{\beta_0, \beta} \sum_{i=1}^N [1 - y_i f(x_i)]_+ + \frac{\lambda}{2} \|\beta\|^2, \quad (20.25)$$

其中下标「+」表示正部。它具有**损失 + 惩罚**的形式, 是函数估计中的常见范式。容易证明 (习题 12.1): 取 $\lambda = 1/C$ 时, 式 20.25 的解与式 20.8 的解相同。

注记 20.11 (铰链损失). 「铰链」(hinge) 损失函数 $L(y, f) = [1 - yf]_+$ 对二分类问题是合理的, 这可通过与其他更传统的损失函数比较看出。图 12.4 将其与逻辑回归的 (负) 对数似然损失、平方误差损失及其变体比较:

- **逻辑回归的二项偏差** (binomial deviance): 与 SVM 损失有**相似的尾部**——对深居间隔内部的点给零惩罚, 对位于错误一侧且远离的点给线性惩罚;
- **平方误差**: 给二次惩罚, 且深居自身间隔内部的点对模型也有很强影响;
- **平方铰链损失** $L(y, f) = [1 - yf]_+^2$: 像二次损失, 但对间隔内的点为零; 它在左尾仍二次上升, 对误分类观测的**稳健性**不如铰链或偏差。

最近 Rosset & Zhu (2007) 提出了「Huber 化」的平方铰链损失版本, 在 $yf = -1$ 处平滑过渡为线性损失。

这些损失函数可在**总体层面**用它们估计什么来刻画: 考虑极小化 $\mathbb{E}L(Y, f(X))$, 结果总结于表 12.1。

表 20.1: 图 12.4 中不同损失函数的总体极小元。逻辑回归用二项对数似然 (偏差); 线性判别分析 (习题 4.2) 用平方误差损失; SVM 铰链损失估计的是后验类概率的**众数**, 而其余损失估计的是这些概率的一个**线性变换**。

损失函数 $L[y, f(x)]$	极小化函数	
二项偏差	$\log[1 + e^{-yf(x)}]$	$f(x) = \log \frac{\Pr(Y = +1 x)}{\Pr(Y = -1 x)}$
SVM 铰链损失	$[1 - yf(x)]_+$	$f(x) = \text{sign}[\Pr(Y = +1 x) - \frac{1}{2}]$
平方误差	$[y - f(x)]^2 = [1 - yf(x)]^2$	$f(x) = 2 \Pr(Y = +1 x) - 1$
Huber 化平方铰链	$\begin{cases} -4yf(x), & yf(x) < -1 \\ [1 - yf(x)]_+^2, & \text{否则} \end{cases}$	$f(x) = 2 \Pr(Y = +1 x) - 1$

注记 20.12 (铰链损失估计的是什么). 铰链损失估计**分类器 $G(x)$ 本身** (后验概率的符号), 而其余所有损失都估计类后验概率的一个**变换** (见表 20.1):

- 二项偏差估计 **对数几率** $\log \frac{\Pr(Y=+1|x)}{\Pr(Y=-1|x)}$;
- 平方误差与 Huber 化平方铰链估计 $2\Pr(Y = +1 | x) - 1$ ($Y = \pm 1$ 编码下 f 的期望);
- 铰链损失估计 $\text{sign}[\Pr(Y = +1 | x) - \frac{1}{2}]$, 即直接给出判别结果。

「Huber 化」平方铰链损失兼具逻辑回归的优点（损失光滑、估计概率）与 SVM 铰链损失的优点（支持点）。

注记 20.13 (正则化函数估计的视角). 式 20.25 将 SVM 刻画为正则化的函数估计问题: 线性展开 $f(x) = \beta_0 + h(x)^T \beta$ 的系数被**向零收缩** (常数项除外)。若 $h(x)$ 表示具有某种有序结构的层次基 (如按粗糙度排序), 则该惩罚可推广为对粗糙度更一般的惩罚——这一视角将 SVM 与第 5 章的光滑样条统一起来, 并引向下一小节对**再生核 Hilbert 空间** (RKHS, §12.3.3) 的讨论。

注记 20.14 (均匀收缩与边缘最大化损失). 上一段关于有序层次基的收缩, 当 h 中较粗糙的元素 h_j 具有较小范数时, **均匀收缩**更有意义。

表 20.1 中除平方误差外的所有损失函数都是所谓的「**边缘最大化损失函数**」(margin maximizing loss functions, Rosset et al., 2004b): 若数据可分, 则式 20.25 中 $\hat{\beta}_\lambda$ 在 $\lambda \rightarrow 0$ 时的极限定义**最优分离超平面**。(对逻辑回归, 可分数据下 $\hat{\beta}_\lambda$ 发散, 但比值 $\hat{\beta}_\lambda / \|\hat{\beta}_\lambda\|$ 收敛到最优分离方向。)

20.3.3 函数估计与再生核 (Function Estimation and Reproducing Kernels)

这里用**再生核 Hilbert 空间** (reproducing kernel Hilbert space, RKHS) 中的函数估计语言描述 SVM, 核性质在其中处处可见。此材料在 §5.8 中有较详细讨论; 它提供了支持向量分类器的另一个视角, 有助于弄清其工作原理。

定义 20.2 (核的本征展开). 设基 h 来自一个正定核 K 的 (可能无穷) 本征展开:

$$K(x, x') = \sum_{m=1}^{\infty} \phi_m(x) \phi_m(x') \delta_m, \quad (20.26)$$

且 $h_m(x) = \sqrt{\delta_m} \phi_m(x)$ 。令 $\theta_m = \sqrt{\delta_m} \beta_m$, 则式 20.25 可写为

$$\min_{\beta_0, \theta} \sum_{i=1}^N \left[1 - y_i \left(\beta_0 + \sum_{m=1}^{\infty} \theta_m \phi_m(x_i) \right) \right]_+ + \frac{\lambda}{2} \sum_{m=1}^{\infty} \frac{\theta_m^2}{\delta_m}. \quad (20.27)$$

注记 20.15 (有限维表示). 式 20.27 与 §5.8 中式 (5.49) 形式相同, 那里的 RKHS 理论保证存在形如

$$f(x) = \beta_0 + \sum_{i=1}^N \alpha_i K(x, x_i) \quad (20.28)$$

的有限维解。特别地，存在与准则 20.19 (§5.8.2 中式 (5.67)，亦见 Wahba et al., 2000) 等价的优化形式

$$\min_{\beta_0, \alpha} \sum_{i=1}^N (1 - y_i f(x_i))_+ + \frac{\lambda}{2} \alpha^T K \alpha, \quad (20.29)$$

其中 K 是训练特征两两核求值的 $N \times N$ 矩阵 (习题 12.2)。

这些模型非常一般，包含例如光滑样条、加性与交互样条模型的整个族 (第 5、9 章; Wahba 1990; Hastie & Tibshirani 1990)。可更一般地写为

$$\min_{f \in \mathcal{H}} \sum_{i=1}^N [1 - y_i f(x_i)]_+ + \lambda J(f), \quad (20.30)$$

其中 $\mathcal{H}$ 是函数的结构化空间， $J(f)$ 是该空间上合适的正则化子。

例 20.1 (加性三次样条). 设 $\mathcal{H}$ 为加性函数空间 $f(x) = \sum_{j=1}^p f_j(x_j)$ ，且 $J(f) = \sum_{j=1}^p \int \{f_j''(x_j)\}^2 dx_j$ 。则式 20.30 的解是加性三次样条，具有核表示 20.28，其中 $K(x, x') = \sum_{j=1}^p K_j(x_j, x'_j)$ ，每个 K_j 是对应 x_j 上单变量光滑样条的核 (Wahba, 1990)。

注记 20.16 (核与损失的通用搭配). 反过来，这个讨论也表明：式 20.22 中任意核都可用于任意凸损失函数，并仍导致形如 20.28 的有限维表示。图 12.5 使用与图 12.3 相同的核，但损失换成二项对数似然，此时拟合函数估计的是对数几率：

$$\hat{f}(x) = \log \frac{\hat{\Pr}(Y = +1 | x)}{\hat{\Pr}(Y = -1 | x)} = \hat{\beta}_0 + \sum_{i=1}^N \hat{\alpha}_i K(x, x_i), \quad (20.31)$$

反过来可得类概率的估计

$$\hat{\Pr}(Y = +1 | x) = \frac{1}{1 + e^{-\hat{\beta}_0 - \sum_{i=1}^N \hat{\alpha}_i K(x, x_i)}}. \quad (20.32)$$

拟合模型在形状与性能上都相当接近。

注记 20.17 (SVM 的稀疏性). 对 SVM 而言， N 个 α_i 中往往有相当一部分为零 (非支持点)：图 12.3 两个例子中分别有 42% 和 45% 为零。这是准则 20.25 第一部分分段线性的后果。训练数据上的类重叠越低，这一比例越高；减小 λ 通常会降低重叠 (允许更灵活的 f)。支持点少意味着 $\hat{f}(x)$ 计算更快，这对查表 (预测) 阶段很重要。当然，把重叠降得太低会导致泛化变差。

20.3.4 SVM 与维数灾难

本节讨论 SVM 是否在维数灾难上有什么优势。

注记 20.18 (核不能自适应地集中于子空间). 注意在式 20.23 中，我们不允许在幂与乘积空间中用完全一般的内积。例如所有形如 $2X_j X'_j$ 的项被赋予相同权重，核无法自适

应地集中于某些子空间。若特征数 p 很大, 但类别分离只发生在由 (比如) X_1, X_2 张成的线性子空间中, 该核就不容易发现这个结构, 并因要在许多维度上搜索而受损。人们必须把关于子空间的知识**构建进核** (即让它忽略除前两个输入外的一切); 如果这种知识先验可得, 很多统计学习问题会简单得多——自适应方法的一大目标正是发现这类结构。

为什么「固定权重」是关键? 核 K 一旦选定, 就在特征空间 $\mathcal{H}$ 中固定了一个度量 (几何): $K(x, x') = \langle h(x), h(x') \rangle$ 意味着特征向量 $h(x)$ 各坐标的相对长度、夹角都已被隐含设定。以 $d = 2$ 多项式核为例, 特征映射是

$$h(x) = (1, \sqrt{2}x_1, \dots, \sqrt{2}x_p, x_1^2, \dots, x_p^2, \sqrt{2}x_1x_2, \dots, \sqrt{2}x_{p-1}x_p)^T,$$

特征空间维数

$$M = 1 + 2p + \binom{p}{2} = 1 + 2p + \frac{p(p-1)}{2},$$

对 $p = 2$ 是 6, 对 $p = 10$ 是 66, 对 $p = 100$ 是 5151。式 20.23 中每个交叉项 $2X_jX_{j'}$ 的系数 2 对所有 (j, j') 都一样——核把注意力平均分配给所有输入的两两组合, 无法自行放大「真正重要」的那几个方向。

一个具体例子: 圆柱形边界 设 $p = 3$, 类别分离完全发生在 X_1 - X_2 平面内的圆上:

$$Y = +1 \iff X_1^2 + X_2^2 \leq 1 \quad (X_3 \text{ 是纯噪声, 与类别无关}).$$

若不知道真相, 用「盲」的完整二次核 $K(x, x') = (1 + x_1x'_1 + x_2x'_2 + x_3x'_3)^2$, 其 $M = 10$ 个特征中除 X_1, X_2 相关项外还含 X_3^2, X_1X_3, X_2X_3 这些**纯噪声项**——它们在训练集上只是随机拟合, 却挤占间隔预算并让边界在 X_3 方向来回扭曲, 测试误差随之增大。若事先知道只需 X_1, X_2 , 改用「知情」核

$$K_{\text{informed}}(x, x') = (1 + x_1x'_1 + x_2x'_2)^2,$$

则 $h(x) = (1, \sqrt{2}x_1, \sqrt{2}x_2, x_1^2, x_2^2, \sqrt{2}x_1x_2)^T$ 只含真正相关的 6 个特征, 可完美捕捉圆柱结构——但这要求把「只有前两个输入重要」的知识**先验地**写进核。 p 越大, 盲核浪费在噪声维度上的特征占比越高: $p = 10$ 时 66 个特征中只有与 X_1, X_2 有关的约 5 个携带信号, $p = 100$ 时更降到 5151 个中的 5 个——信号几乎被淹没。

与表 20.2 的印证 这正是「橙子的皮」示例的现象: 加上 6 个噪声特征后, 多项式核 SVM 的测试误差显著恶化 (SVM/poly 2 从 0.078 升至 0.152, SVM/poly 10 从 0.230 升至 0.434), 而能忽略冗余变量的自适应方法几乎不受影响 (BRUTO 0.084→0.090、MARS 0.156→0.173)。核是预先固定的, 无法从数据中学会「哪些维度重要」; 自适应方法的一大目标正是从数据中发现这类结构。

书中用一个示例支撑上述论断：每类生成 100 个观测。第一类为 4 个标准正态独立特征 $X_1, \dots, X_4$ ；第二类同样是 4 个标准正态独立特征，但条件于 $9 \leq \sum X_j^2 \leq 16$ ——这是一个相对容易的问题。更难的版本再追加 6 个标准高斯噪声特征，于是第二类几乎完全包围第一类，像「橙子外面的皮」(skin of the orange) 一样包裹在四维子空间中。该问题的 Bayes 误差率为 0.029 (与维数无关)。生成 1000 个测试观测比较各方法，50 次模拟的测试误差均值 (有/无噪声特征) 见表 20.2。

表 20.2: 「橙子的皮」示例：50 次模拟的测试误差均值 (标准误)。BRUTO 自适应拟合加性样条模型；MARS 自适应拟合低阶交互模型。

方法	无噪声特征	六个噪声特征
SV 分类器	0.450 (0.003)	0.472 (0.003)
SVM/poly 2	0.078 (0.003)	0.152 (0.004)
SVM/poly 5	0.180 (0.004)	0.370 (0.004)
SVM/poly 10	0.230 (0.003)	0.434 (0.002)
BRUTO	0.084 (0.003)	0.090 (0.003)
MARS	0.156 (0.004)	0.173 (0.005)
Bayes	0.029	0.029

注记 20.19 (结果解读). 在原特征空间中超平面无法分离两类，SV 分类器 (第 1 行) 表现很差。多项式 SVM 大幅改善测试误差，但受六个噪声特征的不利影响；它对核的选择也高度敏感：**二次多项式核 (第 2 行) 最好**，因为真实决策边界正是二次多项式；但更高阶多项式核 (第 3、4 行) 反而差得多。BRUTO 表现良好，因为边界是**加性的**。BRUTO 与 MARS 自适应得好：在噪声存在下性能不显著恶化。

结论：SVM (核技巧) **并不能规避维数灾难**——核是预先固定的，无法发现「只依赖少数特征/子空间」的结构；自适应方法 (BRUTO、MARS、以及后文的 FDA 等) 才能做到这一点。

实际使用 SVM 时怎么筛选核？ 先想清楚：**选核不是调参，而是「编码先验」**。§12.3.4 的核心观点是知识必须被**构建进核**——核一旦选定就固定了特征空间的度量，也就固定了假设类。所以第一步是问自己对问题结构有什么了解：

- **线性核：**边界近似线性、特征高维稀疏 (如文本)、或需要可解释性时。
- **多项式核：**确信边界是低阶多项式/有交互时 (表 20.2 中边界为二次时 poly 2 最好；阶数过高反而变差)。
- **高斯核 (RBF)：**没有先验时的通用默认—— $K(x, x') = \exp(-\gamma \|x - x'\|^2)$ 只有 γ 一个尺度参数， γ 小近似线性、 γ 大接近插值/最近邻行为，能逼近各种形状的边界。

- **神经网络核 (sigmoid):** 历史遗留, 如今很少用。

然后按「核 + C 」一起做交叉验证网格搜索。核决定假设类(空间), C 决定该空间内的正则化强度, 二者必须一起调(分开调没有意义): 例如 RBF 核常用对数网格 $C \in \{2^{-5}, \dots, 2^{15}\}$ 、 $\gamma \in \{2^{-15}, \dots, 2^3\}$, 在训练集上做 k 折交叉验证(第 7 章)选测试误差最小的组合; 也可用 §12.3.5 的路径算法一次性拟合整条 C 序列。常用经验规则: 多数问题先用 RBF 核 + 交叉验证, 就足够好; 多个核性能接近时, 选更简单、更可解释的那个(奥卡姆剃刀)。

两个实操要点:

- **输入先标准化:** RBF 核的 $\|x - x'\|$ 对每个维度的尺度都敏感, 不缩放时大数值变量会主导距离。
- **警惕核选错的代价:** 表 20.2 表明核选错(如过高阶多项式、噪声维度多)损失可能很大, 且交叉验证对核的敏感度高于对 C 的敏感度。

何时该怀疑核这条路? 若交叉验证误差对核的选择非常敏感、而你又没有可靠的先验, 说明「固定核」这个假设本身可能不对——此时应转向能从数据中自适应发现结构的特征工程或方法(BRUTO、MARS、FDA 等), 而不是继续在核的候选集里打转。

20.3.5 SVM 分类器的路径算法

SVM 分类器的正则化参数是代价参数 C , 或其倒数 λ (式 20.25)。常见用法是把 C 设得较高, 往往导致有点过拟合的分类器。图 12.6 展示混合数据上测试误差随 C 的变化, 使用不同的径向核参数 γ : $\gamma = 5$ (窄而尖的核)时需要最重的正则化(小的 C); $\gamma = 1$ (图 12.3 所用)时需要中间值的 C 。显然需要好的方法选 C (例如交叉验证)。

注记 20.20 (路径算法的思想). 书中描述一个路径算法 (path algorithm, 秉承 §3.8 的精神), 用于高效拟合 C 变化得到的整条 SVM 模型序列。方便起见使用损失 + 惩罚形式 20.25 (配合图 12.4)。给定 λ, β 的解为

$$\beta_\lambda = \frac{1}{\lambda} \sum_{i=1}^N \alpha_i y_i x_i, \quad (20.33)$$

其中 α_i 又是 Lagrange 乘子, 但此处全部位于 $[0, 1]$ 。

KKT 最优性条件表明, 标注点 (x_i, y_i) 落入三类不同的群:

- **正确分类且在间隔之外:** $y_i f(x_i) > 1$, Lagrange 乘子 $\alpha_i = 0$ 。例如橙色点 8、9、11 与蓝色点 1、4。
- **恰好位于间隔边缘上:** $y_i f(x_i) = 1$, 乘子 $\alpha_i \in [0, 1]$ 。例如橙色 7 与蓝色 2、6。

- 位于间隔内部: $y_i f(x_i) < 1$, $\alpha_i = 1$ 。例如蓝色 3、5 与橙色 10、12。

注记 20.21 (路径的演化). 路径算法思想如下: 初始 λ 大, 间隔 $1/\|\beta_\lambda\|$ 宽, 所有点都在间隔内部、 $\alpha_i = 1$ 。随着 λ 减小, $1/\|\beta_\lambda\|$ 减小、间隔变窄, 一些点会从间隔内部移出, 其 α_i 从 1 变为 0。由 $\alpha_i(\lambda)$ 的连续性, 这些点在转变期间会逗留在间隔边缘上。由式 20.33, $\alpha_i = 1$ 的点 $\beta(\lambda)$ 贡献固定, $\alpha_i = 0$ 的点无贡献; 所以随 λ 变化而改变的只是那少数间隔边缘点的 $\alpha_i \in [0, 1]$ 。由于这些点都满足 $y_i f(x_i) = 1$, 这导致一组小规模的线性方程描述 $\alpha_i(\lambda)$ (进而 β_λ) 在这些转变期间如何变化, 最终得到每个 $\alpha_i(\lambda)$ 的分段线性路径; 断点发生在点穿过间隔时。图 12.7 右图展示了小例子的 $\alpha_i(\lambda)$ 剖面。

虽然以上对线性 SVM 描述, 同一思想也适用于非线性模型, 此时式 20.33 换成

$$f_\lambda(x) = \frac{1}{\lambda} \sum_{i=1}^N \alpha_i y_i K(x, x_i). \quad (20.34)$$

细节见 Hastie et al. (2004); R 包 `svmpath` (CRAN) 可用于拟合这些模型。

20.3.6 支持向量机用于回归

本节说明如何把 SVM 改造为定量响应的回归问题, 并继承 SVM 分类器的一些性质。先讨论线性回归模型

$$f(x) = x^T \beta + \beta_0, \quad (20.35)$$

再处理非线性推广。为估计 β , 考虑极小化

$$H(\beta, \beta_0) = \sum_{i=1}^N V(y_i - f(x_i)) + \frac{\lambda}{2} \|\beta\|^2, \quad (20.36)$$

其中

$$V_\varepsilon(r) = \begin{cases} 0, & |r| < \varepsilon, \\ |r| - \varepsilon, & \text{否则}. \end{cases} \quad (20.37)$$

这是「 ε -不敏感」误差度量: 忽略小于 ε 的误差 (图 12.8 左图)。

注记 20.22 (与分类情形的类比). 这与支持向量分类有粗略类比: 在分类中, 位于决策边界正确一侧且远离边界的点在优化中被忽略; 在回归中, 这些「低误差」的点正是残差很小的点。

与统计学中稳健回归所用的误差度量对照也很有趣。最流行的是 Huber (1964) 损失:

$$V_H(r) = \begin{cases} r^2/2, & |r| \leq c, \\ c|r| - c^2/2, & |r| > c, \end{cases} \quad (20.38)$$

(图 12.8 右图)。它把绝对残差超过预设常数 c 的观测贡献从二次降为线性, 使拟合对离群点不敏感。支持向量误差度量 20.37 也有线性尾部 (超过 ε), 但额外把残差小的个案贡献压平。

若 $\hat{\beta}, \hat{\beta}_0$ 是 H 的极小元, 可证解函数具有形式

$$\hat{\beta} = \sum_{i=1}^N (\hat{\alpha}_i^* - \hat{\alpha}_i) x_i, \quad (20.39)$$

$$\hat{f}(x) = \sum_{i=1}^N (\hat{\alpha}_i^* - \hat{\alpha}_i) \langle x, x_i \rangle + \beta_0, \quad (20.40)$$

其中 $\hat{\alpha}_i, \hat{\alpha}_i^*$ 为正且求解如下二次规划问题:

$$\min_{\alpha_i, \alpha_i^*} \varepsilon \sum_{i=1}^N (\alpha_i^* + \alpha_i) - \sum_{i=1}^N y_i (\alpha_i^* - \alpha_i) + \frac{1}{2} \sum_{i, i'=1}^N (\alpha_i^* - \alpha_i) (\alpha_{i'}^* - \alpha_{i'}) \langle x_i, x_{i'} \rangle, \quad (20.41)$$

约束为 $0 \leq \alpha_i, \alpha_i^* \leq 1/\lambda$, $\sum_{i=1}^N (\alpha_i^* - \alpha_i) = 0$, $\alpha_i \alpha_i^* = 0$ 。

注记 20.23 (支持向量与内积). 由于这些约束的性质, 通常只有一部分解值 $(\hat{\alpha}_i^* - \hat{\alpha}_i)$ 非零, 对应的数据点称为**支持向量**。与分类情形一样, 解只通过内积 $\langle x_i, x_{i'} \rangle$ 依赖输入值, 因此可用适当的内积 (如式 20.22 中的核) 推广到更丰富的空间。

注意准则 20.36 有两个参数 ε 与 λ , 作用不同: ε 是损失函数 V_ε 的参数, 正如 c 之于 V_H 。 V_ε 与 V_H 都依赖 y (从而 r) 的尺度; 若对响应做缩放 (改用 $V_H(r/\sigma)$ 、 $V_\varepsilon(r/\sigma)$), 则可预设 c 与 ε 的值 ($c = 1.345$ 对高斯达到 95% 效率)。 λ 则是更传统的正则化参数, 可用交叉验证估计。

20.3.7 回归与核

如 §12.3.3 所述, 核性质并非支持向量机独有。设用一组基函数 $\{h_m(x)\}$, $m = 1, \dots, M$ 逼近回归函数:

$$f(x) = \sum_{m=1}^M \beta_m h_m(x) + \beta_0. \quad (20.42)$$

对某个一般误差度量 $V(r)$, 极小化

$$H(\beta, \beta_0) = \sum_{i=1}^N V(y_i - f(x_i)) + \frac{\lambda}{2} \sum_{m=1}^M \beta_m^2, \quad (20.43)$$

对任意 $V(r)$, 解 $\hat{f}(x) = \sum \hat{\beta}_m h_m(x) + \hat{\beta}_0$ 都具有形式

$$\hat{f}(x) = \sum_{i=1}^N \hat{a}_i K(x, x_i), \quad (20.44)$$

其中 $K(x, y) = \sum_{m=1}^M h_m(x) h_m(y)$ 。注意这与径向基函数展开和正则化估计形式相同 (第 5、6 章)。

例 20.2 (平方损失的具体推导). 设 $V(r) = r^2$. 令 H 为 $N \times M$ 基矩阵 (第 im 元为 $h_m(x_i)$), 设 $M > N$ 很大, 并假设 $\beta_0 = 0$ (或常数被吸收进 h)。极小化惩罚最小二乘准则

$$H(\beta) = (y - H\beta)^T(y - H\beta) + \lambda \|\beta\|^2. \quad (20.45)$$

解为

$$\hat{y} = H\hat{\beta}, \quad (20.46)$$

其中 $\hat{\beta}$ 由

$$-H^T(y - H\hat{\beta}) + \lambda\hat{\beta} = 0 \quad (20.47)$$

确定。表面上看需计算变换空间中 $M \times M$ 内积矩阵; 但左乘 H 得

$$H\hat{\beta} = (HH^T + \lambda I)^{-1}HH^Ty. \quad (20.48)$$

$N \times N$ 矩阵 HH^T 由观测两两之间的内积组成, 即内积核的求值 $\{HH^T\}_{i,i'} = K(x_i, x_{i'})$ 。可直接验证此情形下 20.44: 任意 x 处的预测满足

$$\hat{f}(x) = h(x)^T\hat{\beta} = \sum_{i=1}^N \hat{\alpha}_i K(x, x_i), \quad (20.49)$$

其中 $\hat{\alpha} = (HH^T + \lambda I)^{-1}y$ 。

注记 20.24 (核技巧的本质与代价). 与支持向量机一样, 我们无需指定或求值那一大组函数 $h_1(x), \dots, h_M(x)$ ——只需对 N 个训练点两两及预测点求值内积核 $K(x_i, x_{i'})$ 。精心选择 h_m (例如特定易求值核 K 的本征函数) 可使 HH^T 以 $N^2/2$ 次 K 求值计算, 而非直接成本 N^2M 。

但注意: 该性质依赖于惩罚中的平方范数 $\|\beta\|^2$ 。它对 L_1 范数 $|\beta|$ 不成立——而 L_1 惩罚可能得到更优的模型。

20.3.8 讨论

支持向量机可推广到多分类问题, 本质上通过求解许多二分类问题: 为每对类构造分类器, 最终分类器取「获胜最多」者 (Kressel, 1999; Friedman, 1996; Hastie & Tibshirani, 1998)。或者如 §12.3.3 那样, 用多项损失配合合适的核。SVM 在监督与非监督学习的许多其他问题中也有应用; 截至写作时, 经验证据表明它在许多真实学习问题上表现良好。

注记 20.25 (与结构风险最小化的联系). 最后提一下支持向量机与结构风险最小化 (structural risk minimization, SRM, 式 7.9) 的联系。设训练点 (或其基展开) 包含在半径 R 的球内, $G(x) = \text{sign}[f(x)] = \text{sign}[\beta^T x + \beta_0]$ (式 20.2)。可证函数类 $\{G(x), \|\beta\| \leq A\}$ 的 VC 维 h 满足

$$h \leq R^2 A^2. \quad (20.50)$$

若 $f(x)$ 在 $\|\beta\| \leq A$ 下最优地分离训练数据, 则以至少 $1 - \eta$ 的概率 (Vapnik, 1996, p.139):

$$\text{Error}_{\text{Test}} \leq \frac{4h[\log(2N/h) + 1] - \log(\eta/4)}{N}. \quad (20.51)$$

注记 20.26 (对 SRM 界的一点谨慎). 支持向量分类器是首批能得到 VC 维有用界、从而能执行 SRM 程序的实用学习算法之一。但推导中在数据点周围放了球——这一过程依赖于观测到的特征值, 因此严格地说, 该函数类的 VC 复杂度并非在看到特征之前就固定。

正则化参数 C 控制分类器 VC 维的一个上界。按 SRM 范式, 可用 20.51 给出的测试误差上界最小化来选 C ; 但尚不清楚这比用交叉验证选 C 有任何优势。

20.4 推广线性判别分析 (Generalizing Linear Discriminant Analysis)

§4.3 讨论了线性判别分析 (LDA) 这一分类的基本工具。本章剩余部分讨论一类通过直接推广 LDA 而产生比 LDA 更好分类器的技术。

LDA 的一些优点如下:

- 它是简单的**原型分类器** (prototype classifier): 新观测被分到质心最近的类; 稍微特别的是距离用**马氏度量** (Mahalanobis metric) 衡量, 使用**合并协方差估计**。
- 若每类内观测为多元高斯且协方差矩阵公共, 则 LDA 是估计的 **Bayes 分类器**。由于该假设通常不成立, 这看起来不像是多大优点。
- LDA 的决策边界是**线性的**, 规则简单、易于描述与实现。
- LDA 提供自然的**低维视图**: 例如图 12.12 是 256 维、10 类数据的富有信息的二维视图。
- 因其简单与低方差, LDA 常常产生**最好的分类结果**: 在 STATLOG 项目 (Michie et al., 1994) 研究的 22 个数据集中, LDA 在 7 个里进入前三。

注记 20.27 (LDA 的不足). 遗憾的是, LDA 的简单性也导致它在多种情况下失效:

- **线性边界往往不足以分离各类**。 N 大时可估计更复杂的边界; 此时 **QDA** (二次判别分析) 通常有用, 允许二次决策边界。更一般地, 我们希望建模**不规则的决策边界**。
- 上述不足可概括为「**每类一个原型不够**」: LDA 用单个原型 (类质心) 加公共协方差描述每类数据的散布; 许多情形下多个原型更合适。

- 另一个极端：预测变量太多且相关（如数字化模拟信号、图像）。此时 LDA 参数太多、估计方差高、性能受损，需要进一步限制或正则化 LDA。

本章剩余部分通过推广 LDA 模型处理上述所有问题，主要通过三个不同的思路：

1. 把 LDA 重述为线性回归问题。存在大量把线性回归推广到更灵活的非参数回归形式的技术，由此得到更灵活的判别分析，即 FDA。多数感兴趣情形中，回归过程可看作通过基展开识别出一组放大的预测变量；FDA 就是放大空间中的 LDA——与 SVM 相同的范式。
2. 预测变量过多时（如数字化图像的像素）我们不想再放大变量集——它已经太大。第二个思路是拟合 LDA 模型但惩罚其系数在空间域上光滑（即把系数当作图像看待），称为惩罚判别分析（PDA）。FDA 本身展开的基集通常也很大，同样需要正则化（如同 SVM）。二者都可通过在 FDA 模型语境下做合适的正则化回归实现。
3. 把每个类建模为两个或多个高斯的混合：各成分质心不同，但每个成分高斯（类内与类间）共享同一个协方差矩阵。这允许更复杂的决策边界，并允许像 LDA 那样的子空间降维。称为混合判别分析（MDA）。

三者都利用与 LDA 的联系，使用一个公共框架。

20.5 灵活判别分析 (Flexible Discriminant Analysis, FDA)

本节描述一种用派生响应的线性回归实现 LDA 的方法，由此得到 LDA 的非参数、灵活替代。

定义 20.3 (最优评分 (Optimal Scoring)). 与第 4 章一样，设观测有落入 K 类 $\mathcal{G} = \{1, \dots, K\}$ 之一的定量响应 G ，各有特征 X 。设 $\theta: \mathcal{G} \rightarrow \mathbb{R}^1$ 是给各类赋分的函数，使得变换后的类标签能被 X 上的线性回归最优预测：对训练样本 (g_i, x_i) , $i = 1, \dots, N$ ，求解

$$\min_{\beta, \theta} \sum_{i=1}^N (\theta(g_i) - x_i^T \beta)^2, \quad (20.52)$$

并对 θ 施加限制（在训练数据上均值零、方差单位）以避免平凡解。这产生类之间的一维分离。

更一般地，可找出至多 $L \leq K - 1$ 组独立的类标签评分 $\theta_1, \dots, \theta_L$ 及对应的线性映射 $\eta_\ell(X) = X^T \beta_\ell$, $\ell = 1, \dots, L$ ，选作 $\mathbb{R}^p$ 中多元回归的最优。评分 $\theta_\ell(g)$ 与映射 β_ℓ 极小化平均平方残差 (Average Squared Residual, ASR)

$$\text{ASR} = \frac{1}{N} \sum_{\ell=1}^L \left[\sum_{i=1}^N (\theta_\ell(g_i) - x_i^T \beta_\ell)^2 \right]. \quad (20.53)$$

评分集关于适当内积相互正交且归一化，以防止平凡零解。

注记 20.28 (为什么走这条路?). 可证 §4.3.3 导出的判别 (正则) 向量序列 ν_ℓ 与序列 β_ℓ 只差一个常数 (Mardia et al., 1979; Hastie et al., 1995)。而且，测试点 x 到第 k 类质心 $\hat{\mu}_k$ 的马氏距离为

$$\delta_J(x, \hat{\mu}_k) = \sum_{\ell=1}^{K-1} w_\ell (\hat{\eta}_\ell(x) - \bar{\eta}_\ell^k)^2 + D(x), \quad (20.54)$$

其中 $\bar{\eta}_\ell^k$ 是第 k 类中 $\hat{\eta}_\ell(x_i)$ 的均值, $D(x)$ 与 k 无关。权重 w_ℓ 由第 ℓ 个最优评分拟合的均方残差 r_ℓ^2 定义:

$$w_\ell = \frac{1}{r_\ell^2(1 - r_\ell^2)}. \quad (20.55)$$

§4.3.2 已见: 在高斯设置、各类协方差相等时, 这些正则距离正是分类所需的全部。

总结: LDA 可由一串线性回归、随后在拟合值空间中把观测分到最近的类质心来完成。该类比既适用于降秩版本, 也适用于 $L = K - 1$ 的全秩情形。

注记 20.29 (推广的威力). 这个结果的真正威力在于它带来的推广: 可把线性回归拟合 $\eta_\ell(x) = x^T \beta_\ell$ 换成远更灵活的非参数拟合, 从而类比地得到比 LDA 更灵活的分类器——如广义加性拟合、样条函数、MARS 模型等。更一般形式下, 回归问题由准则

$$\text{ASR}(\{\theta_\ell, \eta_\ell\}_{\ell=1}^L) = \frac{1}{N} \sum_{\ell=1}^L \left[\sum_{i=1}^N (\theta_\ell(g_i) - \eta_\ell(x_i))^2 + \lambda J(\eta_\ell) \right], \quad (20.56)$$

定义, 其中 J 是适合某些非参数回归形式的正则化子, 如光滑样条、加性样条与低阶 ANOVA 样条模型; 也包括 §12.3.3 中核生成的函数类与相关惩罚。

完整的 FDA 计算步骤 (最优评分算法) 当回归过程可表示为线性算子 S_λ (固定光滑参数的加性样条、选定基后的 MARS 等) 时, 最优评分等价于典型相关问题, 可由单次本征分解求解。给定类指示响应矩阵 $Y \in \mathbb{R}^{N \times K}$ ($y_{ik} = 1$ 若 $g_i = k$, 否则 0), 步骤如下:

1. **多元非参数回归:** 对指示矩阵 Y 的每一列 $y_k \in \mathbb{R}^N$ 关于 X 做非参数回归, 得拟合值

$$\hat{y}_k = S_\lambda y_k \quad (k = 1, \dots, K) \implies \hat{Y} = S_\lambda Y,$$

以及拟合回归函数向量 $\eta^*(x) = (\eta_1^*(x), \dots, \eta_K^*(x))^T$, 其中 $\eta_k^*(x_i) = \hat{y}_{ik}$ (训练点上的取值即拟合值)。 S_λ 为拟合最终所选模型的线性算子; 当 $S_\lambda = H_X$ (线性回归投影) 时 $\eta^*(x) = \hat{\beta}_0 + \hat{\beta}^T x$ 。

2. **最优评分:** 求 $Y^T \hat{Y} = Y^T S_\lambda Y$ 关于 D_π 的广义本征分解

$$Y^T S_\lambda Y \Theta = D_\pi \Theta \Lambda,$$

其中 Λ 为特征值对角阵, $\Theta \in \mathbb{R}^{K \times K}$ 为评分矩阵, 归一化为

$$\Theta^T D_\pi \Theta = I, \quad D_\pi = \frac{1}{N} Y^T Y = \text{diag}\left(\frac{N_1}{N}, \dots, \frac{N_K}{N}\right),$$

D_π 是估计的类先验概率对角矩阵 (N_k 为第 k 类样本数)。

3. **更新模型**: 用最优评分对原始拟合做线性组合, 得到最终判别函数

$$\eta(x) = \Theta^T \eta^*(x), \quad \eta_\ell(x) = \sum_{k=1}^K \Theta_{k\ell} \eta_k^*(x) \quad (\ell = 1, \dots, K).$$

K 个函数中的第一个是常数函数 (平凡解), 其余 $K - 1$ 个即判别函数; 常数函数连同归一化 $\Theta^T D_\pi \Theta = I$ 使其余函数都居中、正交。

注记 20.30 (η_ℓ 的角色: 判别函数, 但严格说是「拟合的回归函数」). 式 20.56 中的 $\eta_\ell(x)$ 是 FDA 中扮演判别函数角色的回归函数——分类就发生在这些拟合值的空间里: 由式 20.54, 测试点被分到「拟合值 $\hat{\eta}_\ell(x)$ 到各类均值 $\bar{\eta}_\ell^k$ 的加权距离」最小的类。在线性情形 $\eta_\ell(x) = x^T \beta_\ell$ 下, 它们与 §4.3.3 的典型判别向量 ν_ℓ 只差常数, 故正是 LDA 的判别 (正则) 坐标; 换成非参数拟合后, $\hat{\eta}_\ell(x)$ 就成了 FDA 的灵活判别函数。

但严格区分「原始拟合」与「最终判别函数」: 在 §12.5.1 的算法里, 步骤 1 先对指示矩阵做多响应回归得到原始拟合 $\eta^*(x)$ (即式 20.56 中极小化的对象), 步骤 2 求最优评分 Θ , 步骤 3 才得到最终判别函数 $\eta(x) = \Theta^T \eta^*(x)$ ——它是原始拟合的正交线性组合 (居中、消除平凡常数方向)。一句话: η_ℓ 是 FDA 判别坐标的载体 (回归拟合), 最优评分步骤只是对这些拟合做一次正交旋转/重组。

例 20.3 (二次多项式 FDA 的决策边界). 设对每个 η_ℓ 用二次多项式回归。由 20.54, 每个拟合函数都是二次的, 决策边界将是二次曲面 (在 LDA 中比较距离时平方项相互抵消)。更传统的方式也能达到同样的二次边界: 把原始预测变量加上它们的平方与交叉乘积, 再在放大空间做一次 LDA, 放大空间中的线性边界映射回原空间即二次边界。经典例子: 两个以原点为中心的高斯, 协方差分别为 I 与 cI ($c > 1$) (图 12.9)。Bayes 决策边界是球面 $\|x\|^2 = \frac{pc \log c}{c - 1}$, 即放大空间中的线性边界。

许多非参数回归过程都通过生成派生变量的基展开、再在放大空间做线性回归。MARS (第 9 章) 正是这种形式: 光滑样条与加性样条生成极大的基集 (加性样条有 $N \times p$ 个基函数), 但随后在放大空间做惩罚回归; SVM 也是如此 (见 §12.3.7 的基于核的回归例)。此时可证 FDA 在放大空间做的是惩罚线性判别分析 (§12.6 详述)。放大空间中的线性边界映射回低维空间即非线性边界——与支持向量机 (§12.3) 完全相同的范式。

注记 20.31 (语音识别示例). 书用第 4 章语音识别示例说明 FDA: $K = 11$ 类、 $p = 10$ 个预测变量。11 个元音, 各含于 11 个不同单词: i: (heed)、I (hid)、E (head)、A (had)、a: (hard)、Y (hud)、3: (heard)、O (hod)、C: (hoard)、U (hood)、u: (who'd)。

训练集中 8 位说话者每人把每个词说 6 遍, 测试集 7 位说话者; 10 个预测变量以相当复杂的方式由数字化语音导出 (语音识别界的标准)。共 528 个训练观测、462 个测试观测。图 12.10 展示 LDA 与 FDA 的二维投影 (FDA 用自适应加性样条拟合 $\eta_\ell(x)$), 可见灵活建模帮助分离了各类。表 20.3 列出多种分类技术的训练/测试误差。

注记 20.32 (BRUTO 是什么?). **BRUTO** 是拟合加性模型的算法 (S-PLUS 里的例程), 出自 Hastie & Tibshirani (1990) 《Generalized Additive Models》:

- **模型:** $f(x) = \alpha + \sum_{j=1}^p f_j(x_j)$ (加性模型);
- **算法:** 后退拟合 (backfitting), 反复对每个变量做部分残差的光滑、轮流更新 f_j 直到收敛;
- **自动选参:** 对每个 f_j 的光滑量用 **GCV** 自动选择——某变量不相关时, GCV 会把它的 f_j 估成接近常数, 等价于自动忽略该变量。

因此 BRUTO 能自适应地忽略冗余/噪声变量: 表 20.2 中加上 6 个噪声特征后它的性能几乎不变 (0.084→0.090); 表 20.3 中 FDA/BRUTO 测试误差 0.44, 明显优于 LDA 的 0.56。在 FDA 里, BRUTO 被当作步骤 1 的「回归方法」(method=), 即 FDA/BRUTO。

注记 20.33 (表 12.3 的解读). FDA/MARS 指 Friedman 的多元自适应回归样条; degree=2 表示允许两两乘积。注意对 FDA/MARS, 最好结果出现在降秩子空间中。整体看: LDA 测试误差 0.56, FDA/BRUTO 降到 0.44, FDA/MARS (degree=2, 降秩 6) 达 0.39——灵活模型显著优于 LDA。

20.5.1 计算 FDA 估计

许多重要情形下 FDA 坐标的计算可简化, 尤其是当非参数回归过程可表示为线性算子时。记该算子为 S_λ : $\hat{y} = S_\lambda y$, 其中 y 为响应向量、 $\hat{y}$ 为拟合向量。固定光滑参数后, 加性样条有此性质; 选定基函数后的 MARS 也是。下标 λ 表示整组光滑参数。此时最优评分等价于典型相关问题, 解可由单次本征分解算出 (习题 12.6 推导), 算法如下。

由响应 g_i 构造 $N \times K$ 指示响应矩阵 Y : $y_{ik} = 1$ 若 $g_i = k$, 否则 0。例如五类问题:

$$Y = \begin{pmatrix} 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 1 & 0 & 0 \end{pmatrix} \quad \begin{matrix} g_1 = 2 \\ g_2 = 1 \\ g_3 = 1 \\ g_4 = 5 \\ g_5 = 4 \\ \vdots \\ g_N = 3 \end{matrix} \quad (20.57)$$

计算步骤 (FDA 算法):

表 20.3: 元音识别数据性能 (书表 12.3)。神经网络结果是取自神经网络档案的更大集合中最好的; FDA/BRUTO 记号指 FDA 所用的回归方法。

技术	训练误差	测试误差
(1) LDA	0.32	0.56
Softmax	0.48	0.67
(2) QDA	0.01	0.53
(3) CART	0.05	0.56
(4) CART (线性组合分裂)	0.05	0.54
(5) 单层感知机		0.67
(6) 多层感知机 (88 隐藏单元)		0.49
(7) 高斯节点网络 (528 隐藏单元)		0.45
(8) 最近邻		0.44
(9) FDA/BRUTO	0.06	0.44
Softmax	0.11	0.50
(10) FDA/MARS (degree=1)	0.09	0.45
最佳降秩维数 (=2)	0.18	0.42
Softmax	0.14	0.48
(11) FDA/MARS (degree=2)	0.02	0.42
最佳降秩维数 (=6)	0.13	0.39
Softmax	0.10	0.50

1. **多元非参数回归**: 对 Y 关于 X 做多响应、自适应的非参数回归, 得拟合值 $\hat{Y}$ 。设 S_λ 为拟合最终所选模型的线性算子, $\eta^*(x)$ 为拟合回归函数向量。
2. **最优评分**: 计算 $Y^T \hat{Y} = Y^T S_\lambda Y$ 的本征分解, 其中本征向量 Θ 归一化为 $\Theta^T D_\pi \Theta = I$ 。这里 $D_\pi = Y^T Y / N$ 是估计的类先验概率的对角矩阵。
3. **用最优评分更新模型**: $\eta(x) = \Theta^T \eta^*(x)$ 。

$\eta(x)$ 中 K 个函数的第一个是**常数函数** (平凡解); 其余 $K - 1$ 个是判别函数。常数函数连同归一化使其余函数都居中。

注记 20.34 (模块化: 任何回归方法皆可). S_λ 可对应任意回归方法。当 $S_\lambda = H_X$ (线性回归投影算子) 时, FDA 就是线性判别分析。书中引用的软件利用了这一模块性: `fd` 函数有 `method=` 参数, 可传入任意回归函数 (只要遵循一些自然约定)。提供的回归函数支持多项式回归、自适应加性模型与 MARS; 它们都高效处理多响应, 故步骤 (1) 只是对回归例程的一次调用, 步骤 (2) 的本征分解同时算出全部最优评分函数。

§4.2 讨论了用指示响应矩阵做线性回归用于分类的陷阱——尤其是三类及以上时的严重 **masking**。FDA 在步骤 (1) 使用这种回归的拟合值, 但进一步变换产生**没有这些陷阱**的有用判别函数 (习题 12.9 提供另一视角)。

20.6 惩罚判别分析 (Penalized Discriminant Analysis, PDA)

虽然 FDA 的动机是推广最优评分, 它也可直接看作一种**正则化判别分析**。设 FDA 所用的回归过程归结为对基展开 $h(X)$ 的线性回归、并对系数加二次惩罚:

$$\text{ASR}(\{\theta_\ell, \beta_\ell\}_{\ell=1}^L) = \frac{1}{N} \sum_{\ell=1}^L \left[\sum_{i=1}^N (\theta_\ell(g_i) - h^T(x_i) \beta_\ell)^2 + \lambda \beta_\ell^T \Omega \beta_\ell \right]. \quad (20.58)$$

注记 20.35 (Ω 的选择). Ω 的选择取决于问题。若 $\eta_\ell(x) = h(x) \beta_\ell$ 是样条基函数上的展开, Ω 可约束 η_ℓ 在 $\mathbb{R}^p$ 上光滑。加性样条情形下每个坐标有 N 个样条基函数, $h(x)$ 共 Np 个基函数; 此时 Ω 是 $Np \times Np$ 的分块对角矩阵。

于是 FDA 的步骤可看作 LDA 的一种广义形式, 即**惩罚判别分析 (PDA)**:

1. 通过基展开 $h(X)$ **放大预测变量集**。
2. 在放大空间用 (惩罚) LDA, 其中**惩罚马氏距离**为

$$D(x, \mu) = (h(x) - h(\mu))^T (\Sigma_W + \lambda \Omega)^{-1} (h(x) - h(\mu)), \quad (20.59)$$

其中 Σ_W 是派生变量 $h(x_i)$ 的类内协方差矩阵。

3. 用惩罚度量分解分类子空间：

$$\max u^T \Sigma_{\text{Bet}} u \quad \text{subject to} \quad u^T (\Sigma_W + \lambda \Omega) u = 1.$$

注记 20.36 (如何理解「基展开 $h(X)$ 放大预测变量集」?)。「放大」指的是换一个更高维的特征空间：基展开把原始 p 维输入 $x = (x_1, \dots, x_p)$ 通过一组基函数 $h_m(x)$ 映到 M 维派生空间

$$h(x) = (h_1(x), \dots, h_M(x))^T, \quad M \text{ 通常远大于 } p.$$

于是判别分析的「预测变量」从 p 个原始输入变成 M 个派生特征。关键洞察：**放大空间中的线性判别边界，映射回原空间就是非线性边界**——这与 SVM 的核技巧 (§12.3)、FDA 的放大空间范式 (§12.5) 完全相同。

举例：只有两个输入 x_1, x_2 时，取二次多项式展开 $h(x) = (x_1, x_2, x_1^2, x_2^2, x_1 x_2)^T$ ，放大空间中「线性」的 $u^T h(x) = 0$ 在原空间就是 x_1, x_2 的二次曲线（椭圆、双曲线等）。基展开还可取样条（加性样条每个坐标 N 个基、共 Np 个）、MARS 生成的基、或核方法生成的函数类（RKHS）。

两点提醒：

- **PDA 的关键不在放大，而在惩罚。**展开后的基集往往极大（同 SVM 一样需要正则化）， $\lambda \Omega$ 正是那个在放大空间起作用的惩罚。
- **并非总要做这一步：**当预测变量已经太多且相关（如图像、256 频率对数周期图）时，第一步应**跳过**——此时直接在原始空间惩罚系数使其在空间域光滑，这正是下文「何时不需要基展开」注记的内容。

注记 20.37 (惩罚马氏距离的含义). 粗略地说，惩罚马氏距离倾向于给「粗糙」坐标较少的权重、给「光滑」坐标较多权重；由于惩罚非对角，对粗糙或光滑的线性组合同样如此。

注记 20.38 (何时不需要基展开). 对某类问题，第一步（基展开）不需要——我们已经拥有太多（相关的）预测变量。典型例子是待分类对象是**数字化模拟信号**：

- 一段口语语音片段的**对数周期图** (log-periodogram)，在 256 个频率上采样（见图 5.5）；
- 手写数字的数字化图像的**灰度像素值**。

注记 20.39 (为什么需要正则化：以数字图像为例). 直观上很清楚为什么需要正则化。以数字化图像为例：相邻像素值往往相关，常常几乎相同。这意味着这些像素对应的一对 **LDA 系数**可以差异极大且符号相反，从而在作用于相似像素值时相互抵消。正相关的预测变量导致噪声大、负相关的系数估计，这种噪声造成多余的抽样方差。合理的策略是正则化系数使其在**空间域**（即当作图像）上光滑——这正是 PDA 所做的。

PDA 的计算与 FDA 一样，只是改用合适的惩罚回归。这里 $h^T(X)\beta_\ell = X\beta_\ell$ ， Ω 的选择使 $\beta_\ell^T \Omega \beta_\ell$ 把 β_ℓ 当作图像惩罚其粗糙度。图 12.11 展示 LDA 与 PDA 的判别变量：LDA 的像「盐和胡椒」(salt-and-pepper)，PDA 的则光滑。第一幅光滑图像可看作一个线性对比泛函的系数：把「中央有暗竖条」的图像（1、可能 7）与「中间空心」的图像（0、某些 4）分开。图 12.12 支持这一解读。这些例子在 Hastie et al. (1995) 中有更详细讨论；他们还证明，在其尝试的案例中，正则化使 LDA 在独立测试数据上的分类性能提升了约 25%。

20.7 混合判别分析 (Mixture Discriminant Analysis, MDA)

线性判别分析可看作原型分类器：每类用其质心表示，用适当度量把观测分到最近的质心。许多情形下单个原型不足以表示不均质 (inhomogeneous) 的类，此时混合模型更合适。本节回顾高斯混合模型，并说明如何通过前面讨论的 FDA 与 PDA 方法推广它们。

「原型」(prototype) 指什么？「不均质 (inhomogeneous)」怎么定义？原型 = 每类的「代表点」/模板，分类就按「离哪个原型最近」来判：

- 在 LDA 里，原型就是类质心（均值） μ_k ——用「一个点」代表整类；
- 分类规则：新观测 x 被分到「在某种度量下离它最近」的原型所属的类；LDA 用的度量是马氏距离（带合并协方差 Σ ）；
- 因此 LDA 属于原型分类器 (prototype classifier) 家族——这类方法以「与原型（们）的距离/相似度」为判别依据（第 13 章还会见到 LVQ、 k 最近邻等）；
- 每个原型只是类的「中心位置」，整个类被描述成「一个原型 + 一个散布（协方差）」；
- 一个类可以有多个原型：MDA 里每类有 R_k 个子类，就有 R_k 个子质心 μ_{kr} ——这就是「多原型」的体现。

不均质不是严格数学定义，而是描述「类内部不是单一、紧凑、单峰结构」的性质——一个类的数据由几个明显分离的「子群/子簇」组成，即类内密度多峰 (multimodal)。它与 LDA 的均质 (homogeneous) 假设相对：均质 = 类内单峰、紧凑，一个质心 + 协方差就足以描述。

特点：

1. 单峰假设失效：类内数据形成多个分离的簇，整体密度多峰；

2. **单个质心是坏代表**：质心常落在子群之间的「空洞」里，甚至那里一个样本都没有，不能代表任何子群；
3. **分类会出问题**：用单原型分类会把子群之间的空白区也划归该类，边界不自然；
4. **典型来源**：同一类由不同机制/子过程产生——如手写「7」有带/不带横杠两种写法、同一元音由不同说话人发出、图像中同一目标的不同姿态等；
5. **需要多原型才能刻画**：这正是 MDA 的动机——每类用 R_k 个高斯成分（子类，各带自己的质心 μ_{kr} 、共享同一 Σ ）来「多原型」表示一个不均质类。

一句话：均质类 = 一个团、一个中心就够；不均质类 = 内部有几个子团，一个质心代表不了——LDA 在这类问题上失效，MDA 用「每类多个子高斯」来补救。

怎么知道在度量空间中是不是多簇的（类是否不均质）？没有单一公式，可从几个互补角度判断：

1. **可视化 + 降维投影**：对每个类内部做 PCA / LDA 典型变量 / t-SNE / UMAP 投影，看该类是否分成几个明显分离的「团」——注意要按类分开看，否则会把类间分离误判为类内多簇；再画类内成对距离的直方图，双峰提示有子簇。
2. **聚类 / 模型比较**：单独对一个类的数据做 k -means / 层次聚类，用总 SSE 的肘部、gap statistic、silhouette 判断最优簇数是否 > 1 ；或用 GMM 以 BIC/AIC 比较单高斯 vs 多成分，多成分显著胜出即密度多峰——这正对应 MDA「每类 R_k 个子类」的假设；层次聚类树状图中该类在很高处才合并也提示子分支。
3. **统计检验**：Hartigan 的单峰性 **dip** 检验（ p 值小 $\Rightarrow$ 拒绝单峰，即多模态）；辅助用正态性检验（Shapiro-Wilk、JB），但「非正态」 $\neq$ 「多簇」，只能当线索。
4. **从分类性能反推**：在验证集/交叉验证上比较 LDA（单原型）vs MDA（每类多子类），若 MDA 明显更好就是类不均质/多簇的证据；看 LDA 的类内残差，若系统性偏大且集中在某些区域，说明质心代表不了整类。

两个提醒：要在与问题一致的度量里查（LDA 用马氏距离、SVM 用核距离等），否则结论可能失真；区分类内多簇（几个分离的峰）与类间重叠/类内拖尾（单峰但被拉长/偏斜），并注意类内样本量太小会让随机波动伪装成「几簇」。

定义 20.4 (高斯混合模型). 第 k 类的密度为

$$P(X | G = k) = \sum_{r=1}^{R_k} \pi_{kr} \varphi(X; \mu_{kr}, \Sigma), \quad (20.60)$$

其中混合比例 π_{kr} 之和为 1。这为第 k 类给出 R_k 个原型；在我们的设定中，全程用同一个协方差矩阵 Σ 作为度量。

给定每类的模型后，类后验概率为

$$P(G = k \mid X = x) = \frac{\sum_{r=1}^{R_k} \pi_{kr} \varphi(X; \mu_{kr}, \Sigma) \Pi_k}{\sum_{\ell=1}^K \sum_{r=1}^{R_\ell} \pi_{\ell r} \varphi(X; \mu_{\ell r}, \Sigma) \Pi_\ell}, \quad (20.61)$$

其中 Π_k 表示类先验概率。

与 LDA 一样用最大似然估计参数，基于 $P(G, X)$ 的联合对数似然：

$$\sum_{k=1}^K \sum_{g_i=k} \log \left[\sum_{r=1}^{R_k} \pi_{kr} \varphi(x_i; \mu_{kr}, \Sigma) \Pi_k \right]. \quad (20.62)$$

$\log$ 内的求和使直接求解成为相当棘手的优化问题。计算混合分布 MLE 的经典且自然的方法是 **EM 算法** (Dempster et al., 1977)，已知具有良好的收敛性质。EM 在两个步骤间交替：

1. **E 步**：给定当前参数，计算子类 c_{kr} (类 k 内第 r 个子类) 对每个类 k 观测 ($g_i = k$) 的责任 (responsibility)：

$$W(c_{kr} \mid x_i, g_i) = \frac{\pi_{kr} \varphi(x_i; \mu_{kr}, \Sigma)}{\sum_{\ell=1}^{R_k} \pi_{k\ell} \varphi(x_i; \mu_{k\ell}, \Sigma)}. \quad (20.63)$$

2. **M 步**：用 E 步的权重，计算每个类内各成分高斯的**加权 MLE**。

注记 20.40 (EM 的解释与初始化). E 步把类 k 中一个观测的单位权重按比例分配给该类下辖的各子类：若它靠近某子类质心而远离其他，则对该子类得到接近 1 的质量；若恰在两子类之间，则对两者得到近似相等的权重。M 步中，类 k 的一个观测被使用 R_k 次，分别以不同权重估计 R_k 个成分密度的参数。EM 在第 8 章有详细研究。

算法需要初始化，且由于混合似然通常是**多峰的**，初始化会有影响。默认策略：用户提供每类子类数 R_k ；对类 k 内数据用**多次随机起始的 k -means** 聚类，把观测分成 R_k 个不相交组，据此构造由 0 和 1 组成的初始权重矩阵。

注记 20.41 (降秩与加权 LDA). 假设全程等成分协方差 Σ 带来额外的简洁性：可在混合公式中像 LDA 一样加入**秩约束**。为此回顾一个 LDA 的少为人知事实：秩 L 的 LDA 拟合 (§4.3.3) 等价于「各类均值向量被约束在 $\mathbb{R}^p$ 的秩 L 子空间内」的高斯模型的最大似然拟合 (习题 4.8)。混合模型可继承这一性质：在所有 $\sum_k R_k$ 个质心上加秩约束 $\text{rank}\{\mu_{k\ell}\} = L$ 来最大化对数似然 20.62。

此时 EM 仍然可用，且 **M 步变成带权重的 LDA**，有 $R = \sum_{k=1}^K R_k$ 个「类」。此外可用最优评分如前求解加权 LDA 问题，从而在该阶段使用带权重的 FDA 或 PDA。

注记 20.42 (模糊响应矩阵 Z). 可以预期：除了「类」数增加，「观测」数也应相应增加 (第 k 类放大 R_k 倍)。但若最优评分回归用线性算子，则事实并非如此：放大的指示矩

阵 Y 此时坍缩为一个模糊响应矩阵 Z , 这在直观上是令人满意的。例如 $K = 3$ 类、每类 $R_k = 3$ 个子类, Z 可能形如 (行对应 $g_1, \dots, g_N$, 列对应各子类 $c_{11}, \dots, c_{33}$):

$$Z = \begin{pmatrix} 0 & 0 & 0 & 0.3 & 0.5 & 0.2 & 0 & 0 & 0 \\ 0.9 & 0.1 & 0.0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0.1 & 0.8 & 0.1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0.5 & 0.4 & 0.1 \\ 0 & 0 & 0 & 0.7 & 0.1 & 0.2 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & 0 & 0 & 0.1 & 0.1 & 0.8 \end{pmatrix} \begin{matrix} g_1 = 2 \\ g_2 = 1 \\ g_3 = 1 \\ g_4 = 3 \\ g_5 = 2 \\ \vdots \\ g_N = 3 \end{matrix} \quad (20.64)$$

其中类 k 某行的元素正是 $W(c_{kr} | x_i, g_i)$ 。余下的步骤与前面相同, 构成 MDA 的 M 步:

$$\hat{Z} = SZ, \quad Z^T \hat{Z} = \Theta D \Theta^T, \quad \text{更新 } \pi \text{ 与 } \Pi.$$

注记 20.43 (MDA 带来的灵活性). 这些简单修改给混合模型带来相当大的灵活性:

- LDA、FDA 或 PDA 中的降维受类数限制; 特别是 $K = 2$ 类时无法降维。MDA 用子类代替类, 从而允许查看这些子类质心张成的子空间的低维视图——该子空间对判别往往很重要。
- 在 M 步中使用 FDA 或 PDA, 可更适应特定情形: 例如可对数字化模拟信号与图像拟合 MDA, 并内置光滑性约束。

图 12.13 比较了混合示例上的 FDA 与 MDA。

20.7.1 示例: 波形数据 (Waveform Data)

例 20.4 (波形数据生成). 该流行模拟示例取自 Breiman et al. (1984, pp. 49–55), 也用于 Hastie & Tibshirani (1996b) 等处。它是一个三分类、21 个变量的问题, 被认为是困难的模式识别问题。预测变量定义为

$$\begin{aligned} X_j &= U h_1(j) + (1 - U) h_2(j) + \varepsilon_j && \text{类 1,} \\ X_j &= U h_1(j) + (1 - U) h_3(j) + \varepsilon_j && \text{类 2,} \\ X_j &= U h_2(j) + (1 - U) h_3(j) + \varepsilon_j && \text{类 3,} \end{aligned} \quad (20.65)$$

其中 $j = 1, \dots, 21$, U 在 $(0, 1)$ 上均匀分布, ε_j 为标准正态变量, h_ℓ 是平移的三角波形: $h_1(j) = \max(6 - |j - 11|, 0)$, $h_2(j) = h_1(j - 4)$, $h_3(j) = h_1(j + 4)$ 。图 12.14 展示各类的示例波形。

注记 20.44 (波形数据的分析与结果). 表 20.4 展示 MDA 及本章和其他章若干方法在波形数据上的结果。每个训练样本 300 个观测, 用等先验 (每类约 100 个); 测试样本 500 个。

图 12.15 展示惩罚 MDA 模型在测试数据上评估的前两个典型变量：各类看起来位于三角形的边上——因为 $h_j(i)$ 由 21 空间中的三个点表示、构成三角形顶点，而每类是两个顶点的一个凸组合，故位于一条边上。显然所有信息都在前两维：前两个坐标解释的方差百分比为 99.8%，在此截断不会损失任何东西。该问题的 Bayes 风险估计约 0.14 (Breiman et al., 1984)；MDA 接近最优率——这不奇怪，因为 MDA 模型的结构与生成模型相似。

表 20.4: 波形数据结果 (书表 12.4)。数值是十次模拟的平均，括号内为平均的标准误。线上五项取自 Hastie et al. (1994)；线下第一行是每类三个子类的 MDA；第二行相同但判别系数经粗糙度惩罚等效为 4df；第三行是对应的惩罚 LDA (PDA)。

技术	训练误差	测试误差
LDA	0.121 (0.006)	0.191 (0.006)
QDA	0.039 (0.004)	0.205 (0.006)
CART	0.072 (0.003)	0.289 (0.004)
FDA/MARS (degree=1)	0.100 (0.006)	0.191 (0.006)
FDA/MARS (degree=2)	0.068 (0.004)	0.215 (0.002)
MDA (3 子类)	0.087 (0.005)	0.169 (0.006)
MDA (3 子类, 惩罚 4 df)	0.137 (0.006)	0.157 (0.005)
PDA (惩罚 4 df)	0.150 (0.005)	0.171 (0.005)
Bayes		0.140

20.8 计算考虑

- **SVM:** N 个训练样本、 p 个预测变量、 m 个支持向量时需约 $m^3 + mN + mpN$ 次运算 (假设 $m \approx N$)，随 N 扩展性不好，但已有计算捷径 (Platt, 1999)。
- **LDA / PDA:** 需 $Np^2 + p^3$ 次运算。
- **FDA:** 复杂度取决于所用回归方法；许多技术对 N 是线性的 (如加性模型与 MARS)，一般样条与基于核的回归方法通常需 N^3 次运算。

拟合 FDA、PDA、MDA 模型的软件在 R 包 `mda` 中可用 (S-PLUS 也有)。本章书目注记 (Bibliographic Notes) 与习题从略。

20.9 本章总结

本章沿「把线性分类边界推广到非线性」这一主线展开，包含两大块内容。

注记 20.45 (两条主线). **支持向量机 (SVM)**: 从线性最大间隔分类器出发, 用**核技巧**与**正则化**把线性边界推广到非线性, 并扩展到回归 (SVR)。核心要素: 最大间隔 / 松弛变量 / 对偶与 KKT / 支持向量 / 代价 C / 核函数 / 铰链损失。

推广线性判别分析 (LDA): 从原型分类器 (LDA) 出发, 用三个思路分别解决三类问题——FDA (边界不灵活)、PDA (变量太多且相关)、MDA (类不均质)。

注记 20.46 (共同范式: 放大空间). SVM、FDA、PDA 共享同一范式: 在放大空间 (基展开 / 核) 里做线性模型, 映射回原空间即非线性边界。区别在于:

- **SVM**: 核 $K = \langle h(x), h(x') \rangle + \text{铰链损失 } [1 - yf]_+$;
- **FDA**: 最优评分 + 非参数回归 (样条 / MARS / GAM);
- **PDA**: 惩罚马氏距离 $(\Sigma_W + \lambda\Omega)^{-1}$, 使系数在空间域光滑。

注记 20.47 (关键点).

- **支持向量**是决定边界的少数观测; C (或 λ) 控制间隔宽度与正则化强度, 通常用交叉验证选择。
- **核技巧**: 只需知道 $K(x, x')$, 无需显式构造 h ; 但核一旦固定就无法自适应发现子空间结构, 不规避维数灾难。
- **损失函数** (表 20.1): 铰链损失估计后验概率的**众数** (直接给出分类器), 偏差 / 平方误差估计其**线性变换**。
- **FDA**: LDA 可看作「一串回归 + 在拟合值空间按最近质心分类」; 最优评分由单次本征分解完成 ($\Theta^T D_\pi \Theta = I$)。
- **PDA**: 用 Ω 惩罚「粗糙」方向, 使正相关的相邻像素不再产生符号相反、相互抵消的噪声系数。
- **MDA**: 每类用 R_k 个子高斯 + EM 拟合, 子类代替类可实现降维与非线性边界, 适用于不均质类。

一句话总结: SVM 用「核 + 铰链损失」把线性边界推向非线性; FDA / PDA / MDA 分别用「最优评分 + 非参回归」「系数惩罚」「高斯混合多原型」推广 LDA——两条路线殊途同归, 都落在「放大空间中的线性模型」这一共同范式上。




图 20.2: 第 12 章结构总结。两大主线: 支持向量机 (核技巧 + 正则化); 推广 LDA (FDA / PDA / MDA)。底部为贯穿全章的共同范式——放大空间中的线性模型。

第二十一章 Prototype Methods and Nearest-Neighbors (原型方法与最近邻)

21.1 引言

本章讨论一些简单且本质上无模型 (model-free) 的分类与模式识别方法。由于它们高度非结构化，通常不适合用来理解特征与类别结果之间关系的本质；但作为黑箱预测引擎 (black box prediction engine)，它们可以非常有效，常常是真实数据问题中表现最好的方法之一。

最近邻技术也可用于回归 (第 2 章曾提及)，在低维问题中表现合理。然而当特征维数较高时，最近邻回归的偏差-方差权衡不如分类情形有利，因此本章聚焦分类问题。

21.2 原型方法

定义 21.1 (数据与原型). 训练数据为 N 对 $(x_1, g_1), (x_2, g_2), \dots, (x_N, g_N)$ ，其中 g_i 是取值于 $\{1, 2, \dots, K\}$ 的类标签。原型方法 (prototype methods) 用特征空间中的一组点来表示训练数据，这些点称为原型 (prototype)。原型通常不是训练样本本身 (仅 1-最近邻分类除外，见后文)。每个原型带有一个类标签，查询点 x 被分到最近原型所属的类。

「最近」通常由特征空间中的欧氏距离定义，且每个特征先标准化为训练样本上的总体均值 0、方差 1。欧氏距离适用于定量特征；定性及其他类型特征值之间的距离度量在第 14 章讨论。

例 21.1 (原型：一个直观的例子). 设 $x = (x_1, x_2)$ 描述一只动物， x_1 、 x_2 分别代表某两个特征 (如体重与身高，已标准化到示意尺度)，类标签 $g \in \{1, 2\}$ 分别表示「猫」和「狗」。训练集共有 40 个样本 (每类 20 个)。图 21.1 中，左下角蓝色小点是猫类样本、右上角绿色小点是狗类样本。

原型方法不直接保存这 40 个样本，而是先用某种算法 (如 §13.2.1 的 K-means) 为

每个类挑出 $R = 2$ 个「代表性」的点作为原型，例如：

$$\text{猫 (类 1)} : m_1^{(1)} = (1.4, 1.7), \quad m_2^{(1)} = (2.2, 2.3),$$

$$\text{狗 (类 2)} : m_1^{(2)} = (6.0, 4.5), \quad m_2^{(2)} = (7.0, 5.3).$$

每个原型（图中方块）带一个类标签。于是整个训练集被压缩成 $K \times R = 4$ 个原型。

现在来了一个未知动物 $x = (3.4, 3.2)$ （图 21.1 中实心点）。计算它到 4 个原型的欧氏距离：

$$\begin{aligned} d(x, m_1^{(1)}) &= \|(2.0, 1.5)\| \approx 2.50, & d(x, m_2^{(1)}) &= \|(1.2, 0.9)\| \approx 1.50, \\ d(x, m_1^{(2)}) &= \|(-2.6, -1.3)\| \approx 2.91, & d(x, m_2^{(2)}) &= \|(-3.6, -2.1)\| \approx 4.17. \end{aligned}$$

最近的原型是 $m_2^{(1)}$ （属于猫类），因此 x 被分类为「猫」（图中红色箭头指向该原型）。

这个例子说明三个要点：

1. **原型是「代表点」，通常不是训练样本本身**——它们是特征空间中能概括一类数据分布的点；
2. **压缩表示**：分类时只需把 x 与少数原型（这里是 4 个）比较距离，而无需与全部 40 个样本逐一比较，从而大幅降低存储与计算成本；
3. **1-最近邻是极端情形**：若 $R = N$ （每个训练样本都保留为原型），就退化为 1-最近邻分类器——它不压缩，需要保存并比较全部数据。




图 21.1: 原型方法示意：每类用两个原型（方块）代表大量训练样本（小点），查询点 x （实心点）被分到最近原型所属的类。

注记 21.1 (有效性与挑战). 若原型定位得当，能很好地捕捉各类的分布，不规则类边界也可用足够多的原型放在正确位置来表示。主要挑战是：用多少个原型、放在哪里。不同方法按原型的选取数量与方式区分。

21.2.1 K-means 聚类

K-means 聚类是在无标签数据中寻找簇与簇中心的方法：先选定期望的簇中心个数 R ，然后迭代移动中心以最小化总簇内方差。

注记 21.2 (符号约定). K-means 中的「K」指簇中心个数。由于本书已用 K 表示类别数，这里用 R 表示簇的个数。

给定一组初始中心，K-means 算法交替执行两步：

1. 对每个中心，识别出距离它比距其他任何中心都更近的训练点子集（即它的簇）；
2. 计算每个簇中各数据点的各特征均值，该均值向量成为该簇的新中心。

这两步迭代直到收敛。通常初始中心是从训练数据中随机选取的 R 个观测。K-means 的细节、允许不同变量类型与更一般距离度量的推广见第 14 章。

将 K-means 聚类用于有标签数据的分类，步骤如下：

1. 对每个类分别应用 K-means 聚类，每类使用 R 个原型；
2. 给这 $K \times R$ 个原型分配类标签；
3. 将新特征 x 分到最近原型所属的类。

监督分类问题为什么用聚类 (K-means)？ 关键是角色区分：这里的 K-means 不是最终分类器，而是「原型生成 / 数据压缩」的子程序。监督信息（类标签）只决定两件事——每类用 R 个原型、聚类完成后给每个原型贴类标签；而无监督的 K-means 只负责在每一类内部找出数据密集的「代表点」。上面的三个步骤中，第 1 步是对每个类分别单独聚类，第 2 步才用到类标签，第 3 步做分类。因此更准确的说法是：用聚类作为「有监督分类」中生成原型的工具，而不是「用无监督算法做分类」。§13.2.3 的高斯混合也是同样的角色，只是它是「软」的原型生成。

注记 21.3 (图 21.2 (上)：K-means 的缺点). 三类两特征的模拟例子中取 $R = 5$ 个原型/类。可以看到许多原型靠近类边界，导致边界附近的点可能被错分。这源于该方法一个明显的不足：对每个类而言，其他类在定位该类的原型时没有发言权。更好的方法（接下来讨论）用全部数据来定位所有原型。

K-means 初始化原型时没有把类标签考虑进去吗？ 确实没有——这正是上一则注记所述不足的根源。对每类分别聚类时，原型的摆放只取决于本类数据分布，完全忽略类边界与类间重叠。后果如图 21.2 (上)：许多原型落在靠近类边界的位置，边界附近的点易被错分；图 13.2 中 K-means 甚至把（错误的）蓝色原型放在西北角，且因只按距离分类而无法忽略它。

这正是作者紧接着引入 LVQ (§13.2.2) 的原因: LVQ 用全部数据 (含类标签) 定位所有原型, 靠「正确类吸引、错误类排斥」把原型推离决策边界 (图 21.2 下), 弥补 K-means 的缺陷。简言之: K-means 提供初始位置 (但「盲」, 不看标签), LVQ 用标签信息把原型重新摆放到位。

21.2.2 学习向量量化 (LVQ)

该技术源于 Kohonen (1989), 原型相对于决策边界策略性地放置。LVQ 是一种在线算法——观测被逐个处理。

其思想是: 训练点吸引正确类的原型、排斥其他类的原型。迭代稳定后, 原型应接近其所在类中的训练点。学习率 ϵ 随每次迭代递减至零, 遵循随机近似学习率准则 (见 §11.4)。

Algorithm 13.1 (学习向量量化, LVQ)

1. 为每类选择 R 个初始原型 $m_1^{(k)}, m_2^{(k)}, \dots, m_R^{(k)}$, $k = 1, 2, \dots, K$, 例如从每类随机采样 R 个训练点。
2. 随机 (有放回) 抽样一个训练点 x_i , 记 (j, k) 为距离 x_i 最近的原型 $m_j^{(k)}$ 的索引:

(a) 若 $g_i = k$ (同属一类), 将原型向训练点移动:

$$m_j^{(k)} \leftarrow m_j^{(k)} + \epsilon(x_i - m_j^{(k)}), \quad (21.1)$$

其中 ϵ 为学习率;

(b) 若 $g_i \neq k$ (属于不同类), 将原型远离训练点移动:

$$m_j^{(k)} \leftarrow m_j^{(k)} - \epsilon(x_i - m_j^{(k)}). \quad (21.2)$$

3. 重复第 2 步, 学习率 ϵ 随每次迭代递减至零。

注记 21.4 (LVQ 的结果与不足). 图 21.2 (下) 展示了以 K-means 解为初值运行 LVQ 的结果: 原型倾向于远离决策边界、远离竞争类的原型。上述过程实际称为 LVQ1; 已有改进版本 (LVQ2、LVQ3 等) 有时可提升性能。LVQ 类方法的一个缺点是: 它们由算法定义, 而非优化某个固定准则, 因此其性质难以理解。

21.2.3 高斯混合

高斯混合模型也可视为一种原型方法, 与 K-means 和 LVQ 精神类似 (详见 §6.8、§8.5 与 §12.7)。每个簇由一个高斯密度描述: 它既有质心 (如同 K-means), 又有协方差矩阵。若将分量高斯限制为标量协方差矩阵, 与 K-means 的对比会更清晰 (习题 13.1)。




FIGURE 13.1. Simulated example with three classes and five prototypes per class. The data in each class are generated from a mixture of Gaussians. In the upper panel, the prototypes were found by applying the K-means clustering algorithm separately in each class. In the lower panel, the LVQ algorithm (starting from the K-means solution) moves the prototypes away from the decision boundary. The broken purple curve in the background is the Bayes decision boundary.

图 21.2: 三类、每类五个原型的模拟例子(书图 13.1)。每类的数据由高斯混合生成。上方面板: 对每类分别应用 K-means 聚类算法找到原型; 下方面板: LVQ 算法(以 K-means 解为起点)把原型移离决策边界。背景中的紫色虚线是 Bayes 决策边界。

交替 EM 算法的两步与 K-means 的两步非常相似：

- **E 步**：每个观测基于各对应高斯的似然，为每个簇分配一个**责任** (responsibility) 或权重。靠近某簇中心的观测通常对该簇权重接近 1、对其他簇权重接近 0；位于两簇中间的观测则按比例分摊权重。
- **M 步**：每个观测对每个簇的**加权均值** (和协方差) 作出贡献。

因此高斯混合模型常被称为**软聚类** (soft clustering)，而 K-means 是**硬聚类**。

注记 21.5 (软分类的实质). 当高斯混合模型用于表示每个类中的特征密度时，会为分类 x 产生平滑的后验概率 $\hat{p}(x) = \{\hat{p}_1(x), \dots, \hat{p}_K(x)\}$ (见式 (12.60))。这常被解读为软分类，但实际分类规则仍是

$$\hat{G}(x) = \arg \max_k \hat{p}_k(x). \quad (21.3)$$

图 13.2 比较了 K-means 与高斯混合在第 2 章模拟混合问题上的结果：虽然决策边界大致相似，但混合模型的边界**更平滑** (尽管原型位置大致相同)。更重要的是，两种方法都在西北区域放置了一个 (错误的) 蓝色原型，但高斯混合分类器最终可以**忽略**这一区域，而 K-means 不能。高斯混合 (公共协方差) 测试误差约 0.22，K-means 约 0.243，Bayes 误差 0.210。

21.3 k-最近邻分类器

定义 21.2 (k-最近邻分类). k-最近邻分类器是**基于记忆** (memory-based) 的，无需拟合模型。给定查询点 x_0 ，找出距离它最近的 k 个训练点 $x_{(r)}$, $r = 1, \dots, k$ ，然后在这 k 个近邻中按**多数投票**分类；平局随机打破。

为简单起见假设特征为实值，并使用特征空间中的欧氏距离：

$$d_{(i)} = \|x_{(i)} - x_0\|. \quad (21.4)$$

通常先把每个特征标准化为均值 0、方差 1 (不同特征可能量纲不同)。第 14 章讨论定性/序数特征适用的距离度量及混合数据的组合方式；自适应选择的距离度量在本章后面讨论。

注记 21.6 (成功与适用场景). 尽管简单，k-最近邻在手写数字、卫星图像场景、EKG 模式等大量分类问题中非常成功。当每类有多个可能原型、且决策边界很不规则时，它往往表现优异。图 13.3 上方面板是 15-最近邻在三类模拟数据上的决策边界 (相当平滑)，下方面板是 1-最近邻 (边界粗糙)。最近邻与原型方法联系紧密：在 1-最近邻分类中，每个训练点都是一个原型。

注记 21.7 (偏差-方差与邻域大小). 图 13.4 展示了二类混合问题中训练、测试与十折交叉验证误差随邻域大小的变化 (十折 CV 是十个数的平均, 可估计标准误)。由于只用离查询点最近的训练点, 1-最近邻估计的**偏差通常低但方差高**。简单最近邻的偏差/方差特性决定了给定问题的最优近邻数。

定理 21.1 (Cover-Hart 定理). **渐近地**, 1-最近邻分类器的错误率**不超过 Bayes 错误率的两倍** (Cover and Hart, 1967)。

注记 21.8 (证明思路 (平方误差损失)). 假设查询点与某个训练点重合, 则偏差为零 (当特征空间维数固定、训练数据稠密填满空间时渐近成立)。于是 Bayes 规则的误差只是查询点目标 (一个 Bernoulli 随机变量) 的方差; 而 1-最近邻规则的误差是 **两个** Bernoulli 随机变量 (训练目标与查询目标) 方差之和, 即其两倍。

注记 21.9 (误分类损失下的渐近分析). 在 x 处令 k^* 为主导类, $p_k(x)$ 为类 k 的真实条件概率, 则

$$\text{Bayes 误差} = 1 - p_{k^*}(x), \quad (21.5)$$

$$1\text{-最近邻误差} = \sum_{k=1}^K p_k(x)(1 - p_k(x)), \quad (21.6)$$

$$\geq 1 - p_{k^*}(x). \quad (21.7)$$

渐近 1-最近邻错误率是一个**随机规则**的错误率: 以概率 $p_k(x)$, $k = 1, \dots, K$ 随机选择分类与测试点。当 $K = 2$ 时, 1-最近邻错误率为

$$2p_{k^*}(x)(1 - p_{k^*}(x)) \leq 2(1 - p_{k^*}(x)),$$

即 Bayes 错误率的两倍。更一般地可证明 (习题 13.3)

$$\sum_{k=1}^K p_k(x)(1 - p_k(x)) \leq 2(1 - p_{k^*}(x)) - \frac{K}{K-1}(1 - p_{k^*}(x))^2. \quad (21.8)$$

Ripley (1996) 总结了大量此类结果。

注记 21.10 (结果的应用与局限). 该结果可用于粗略估计某个问题可能达到的最佳性能: 例如若 1-最近邻规则有 10% 错误率, 则渐近 Bayes 错误率至少为 5%。关键在于「渐近」部分——它假设最近邻规则的偏差为零; 而**实际问题中偏差可能很大**。本章后面介绍的自适应最近邻规则正是为缓解这种偏差而设计的。

21.3.1 示例: 比较研究

在**两个模拟问题**上测试最近邻、K-means 与 LVQ 分类器。有 10 个独立特征 X_j , 每个在 $[0, 1]$ 上均匀分布; 二类 0-1 目标变量定义为

$$\begin{aligned} \text{问题 1 (“简单”)} : \quad Y &= I(X_1 > \tfrac{1}{2}), \\ \text{问题 2 (“困难”)} : \quad Y &= I\left(\text{sgn}\left\{\prod_{j=1}^3 (X_j - \tfrac{1}{2})\right\} > 0\right). \end{aligned} \quad (21.9)$$

在问题 1 中, 两类被超平面 $X_1 = 1/2$ 分开; 问题 2 中, 两类在前三个特征张成的超立方体内形成**棋盘图案**。两个问题的 Bayes 错误率均为零。训练集 100 个、测试集 1000 个观测。

图 13.5 展示了随调参参数变化的十次实现上最近邻、K-means 与 LVQ 错分误差的均值与标准误:

- K-means 与 LVQ 给出几乎相同的结果; 在调参参数的最佳取值下, 问题 1 中 K-means/LVQ 优于最近邻, 问题 2 中二者表现相近。
- 每个调参参数的最佳值**明显依赖具体情境**: 例如问题 1 中 25-最近邻比 1-最近邻好约 70%; 而问题 2 中 1-最近邻最佳, 比 25-最近邻好约 18%。

这些结果强调了用**客观的、基于数据**的方法(如交叉验证, 见图 13.4 与第 7 章)来估计调参参数最佳值的重要性。

21.3.2 示例: k-最近邻与图像场景分类

STATLOG 项目 (Michie et al., 1994) 用部分 **LANDSAT 卫星图像**作为分类基准 (82×100 像素)。图 13.6 展示了澳大利亚某农区的四个热图波段(两个可见光、两个红外)。每个像素有来自 7 元素集合

$$G = \{\text{红土, 棉花, 植被残茬, 混合, 灰土, 湿灰土, 很湿灰土}\}$$

的类标签(由研究人员实地调查确定)。目标是根据四个光谱带的信息对像素的土地利用进行分类。

5-最近邻的预测地图按如下方式计算: 对每个像素提取一个 **8-邻域特征图**——像素本身及其 8 个直接邻居(图 13.7)。在四个光谱带分别这样做, 得到每个像素 $(1+8) \times 4 = 36$ 个输入特征。然后在这个 36 维特征空间中进行 5-最近邻分类, 测试错误率约 **9.5%**(图 13.8)。

注记 21.11 (STATLOG 结论). 在 STATLOG 项目使用的所有方法(包括 LVQ、CART、神经网络、线性判别分析等)中, k-最近邻在此任务上**表现最好**。由此推断, $\mathbb{R}^{36}$ 中的决策边界很可能相当不规则。

21.3.3 不变度量与切向距离

在某些问题中, 训练特征在某些自然变换下不变。最近邻分类器可以通过把这种不变性**并入距离度量**来加以利用。这里给出一个非常成功的例子 (Simard et al., 1993): **手写数字识别**, 输入是 $16 \times 16 = 256$ 像素的灰度图像(示例见图 13.9)。

图 13.10 顶部展示了一个「3」的原始朝向(中间)及旋转 $\pm 7.5^\circ$ 、 $\pm 15^\circ$ 的版本。手写中常出现这类旋转, 人眼很容易看出小幅旋转后的「3」仍是「3」, 因此希望最近邻分

类器认为这些「3」彼此接近。然而，旋转「3」的 256 个灰度像素值与原始图像差异很大，两个对象在 $\mathbb{R}^{256}$ 的欧氏距离下可能相距很远。

定义 21.3 (不变流形与不变度量). 考虑由原始「3」及其旋转版本组成的像素值集合：这是 $\mathbb{R}^{256}$ 中的一条一维曲线，称为该图像在此变换下的不变流形 (invariance manifold)。两幅图像之间的距离取为第一个图像的任意变换版本与第二个图像的任意变换版本之间的最短欧氏距离，称为不变度量 (invariant metric)。

注记 21.12 (不变度量的两个问题). 原则上可以用该不变度量进行 1-最近邻分类，但它有两个问题：其一，对真实图像很难计算；其二，它允许过大的变换导致性能下降——例如「6」旋转 180° 后会被认为接近「9」。因此需要把注意力限制在小旋转上。

切向距离 (tangent distance) 同时解决这两个问题。如图 13.10 所示，可用原始图像处不变流形的切线来近似该流形。这条切线可通过小旋转图像估计方向向量来计算，也可用更精细的空间平滑方法 (习题 13.4)。对于大旋转，切线图像不再像「3」，从而缓解了大变换带来的问题。

定义 21.4 (切向距离分类). 对每个训练图像计算其不变切线；对要分类的查询图像同样计算其不变切线，然后在训练集的所有切线中找最近的一条切线，该切线对应的类别即预测类别。图 13.11 中我们用的是两条切线之间的最短距离，而非两图像间欧氏距离或两曲线间最短距离。(图中两切线看似相交，只是因为是在二维中示意实际的 256 维情形；在 $\mathbb{R}^{256}$ 中两条直线相交的概率实际上为零。)

注记 21.13 (更简单的替代：hints). 实现这种不变性的更简单做法是把每个训练图像的若干旋转版本加入训练集，再用标准最近邻分类器。这一思想在 Abu-Mostafa (1995) 中称为“hints”，当不变空间较小时效果不错。但除旋转外，还有六种我们希望的变换不变性：平移（两个方向）、缩放（两个方向）、剪切、字符粗细。因此图 13.10/13.11 中的曲线与切线实际上是 7 维流形与超平面。为每个训练图像加入所有这些变换版本不可行，而切线流形优雅地捕获了这些不变性。

表 21.1: 手写 ZIP 码问题的测试错误率 (书表 13.1)。数据为美国邮政服务数据库：7291 个训练图像、2007 个测试数字。

方法	错误率
神经网络	0.049
1-最近邻 / 欧氏距离	0.055
1-最近邻 / 切向距离	0.026

注记 21.14 (结果与实践). 切向距离最近邻分类器效果惊人地好，测试错误率接近人眼水平 (这是公认很难的测试集)。实际应用中最近邻对该在线分类任务而言太慢 (见 §13.5)，因此随后开发了神经网络分类器来模拟它。

21.4 自适应最近邻方法

当最近邻分类在**高维**特征空间中进行时，一个点的最近邻可能**非常远**，从而引入偏差、降低规则性能。

注记 21.15 (维数灾难的量化). 考虑 N 个数据点均匀分布在单位立方体 $[-\frac{1}{2}, \frac{1}{2}]^p$ 中。设 R 为原点处 1-最近邻域的半径，则

$$\text{median}(R) = v_p^{-1/p} \left(1 - \left(\frac{1}{2}\right)^{1/N}\right)^{1/p}, \quad (21.10)$$

其中 $v_p r^p$ 是 p 维空间中半径 r 的球体积。图 13.12 显示中位半径随样本量 N 与维数 p 的变化：中位半径**迅速逼近 0.5**——即到立方体边缘的距离。样本量需随维数指数级增长才能维持小的邻域。

注记 21.16 (如何补救：自适应度量). 考虑图 13.13 的二类情形：两个特征，查询点处的最近邻域为圆形区域。最近邻分类隐含假设类概率在邻域内近似恒定、因而简单平均就能给出好的估计。但该例中类概率**只在水平方向变化**：若知道这一点，就应把邻域在垂直方向拉伸（如图中高矩形），这会在**保持方差不变的同时降低偏差**。

一般而言，这要求在最近邻分类中**自适应地选择度量**，使邻域沿类概率变化不大的方向拉伸。在高维特征空间中，类概率可能只在一个低维子空间变化，因此自适应度量可能带来显著优势。

注记 21.17 (发展脉络). Friedman (1994a) 提出一种方法：通过依次切除包含训练数据的盒子的边，自适应地找到矩形邻域。本节描述 Hastie and Tibshirani (1996a) 的判别**自适应最近邻** (discriminant adaptive nearest-neighbor, **DANN**) 规则；更早的相关建议见 Short and Fukunaga (1981)、Myles and Hand (1990)。

在每个查询点处先形成一个约 50 个点的邻域，用其中的类分布决定如何**变形邻域**（即自适应度量），自适应度量再用于该查询点的最近邻规则。因此**每个查询点可能使用不同的度量**。

在图 13.13 中，邻域显然应沿**连接类质心的直线的正交方向**拉伸。该方向也与线性判别边界重合，是类概率变化最小的方向。一般而言，最大变化方向并不正交于连接类质心的直线（见图 4.9，第 116 页）。假设局部判别模型成立，则局部**类内与类间**协方差矩阵所含信息足以确定邻域的最优形状。

定义 21.5 (DANN 度量). 查询点 x_0 处的判别自适应最近邻 (DANN) 度量定义为

$$D(x, x_0) = (x - x_0)^T \Sigma (x - x_0), \quad (21.11)$$

其中

$$\Sigma = W^{-1/2} [W^{-1/2} B W^{-1/2} + \epsilon I] W^{-1/2} = W^{-1/2} [B^* + \epsilon I] W^{-1/2}. \quad (21.12)$$

这里 $W = \sum_{k=1}^K \pi_k W_k$ 是合并的类内协方差矩阵, $B = \sum_{k=1}^K \pi_k (\bar{x}_k - \bar{x})(\bar{x}_k - \bar{x})^T$ 是类间协方差矩阵, 其中 W 与 B 只用 x_0 周围约 50 个最近邻计算。算出度量后, 再把它用于 x_0 处的最近邻规则。

注记 21.18 (Σ 的操作理解). 这个复杂的公式操作上其实很简单:

1. 先用 W 对数据**球化** (sphering);
2. 再在 B^* (球化后数据的类间矩阵) 的**零特征值方向**上拉伸邻域。

这很合理: 这些方向上局部观测到的各类均值没有差异。参数 ϵ 把邻域从无限条带**圆整为椭球**, 避免使用离查询点太远的点; $\epsilon = 1$ 通常效果不错。

图 13.14 展示了同心圆 (一类包围另一类) 问题中 DANN 找到的邻域: 当邻域内两类同时存在时, 邻域沿与决策边界正交的方向拉伸; 在只有一类的**纯净区域**, 邻域保持圆形——此时类间矩阵 $B = 0$, 式 (13.8) 中的 Σ 为单位阵。

21.4.1 示例

这里生成十维二类数据, 与图 13.14 的二维例子类似: 类 1 的所有十个预测变量为独立标准正态, 且条件于平方半径 $22.4 < \|x\|^2 < 40$; 类 2 的预测变量为无限制的独立标准正态。每类 250 个观测。因此类 1 在完整十维空间中几乎完全包围类 2。

注记 21.19 (本例特点). 本例没有最近邻子集选择规则可以剔除的**纯噪声变量**: 在特征空间的任意给定点, 判别只沿一个方向发生, 但该方向随空间位置变化, **所有变量在空间的某处都是重要的**。

图 13.15 展示十次实现上测试错误率的箱线图, 比较标准 5-最近邻、LVQ 与判别自适应 5-最近邻。LVQ 每类使用 50 个原型 ($250/5 = 50$, 使其与 5-最近邻可比)。自适应度量相对 LVQ 或标准最近邻**显著降低了错误率**。

21.4.2 最近邻的全局降维

判别自适应最近邻方法进行的是**局部降维**——即在每个查询点分别降维。许多问题还可以受益于**全局降维**: 在原始特征空间某个最优选择的**子空间**中应用最近邻规则。

例如, 假设两类在四维特征空间中形成两个**嵌套球**, 另有六个与类无关的噪声特征。那么我们对数据**发现重要的四维子空间**, 并在该降维子空间中进行最近邻分类。

Hastie and Tibshirani (1996a) 为此讨论了判别自适应最近邻方法的一种变体: 在每个训练点 x_i 处计算**类间质心平方和矩阵** B_i , 然后对所有训练点取平均:

$$\bar{B} = \frac{1}{N} \sum_{i=1}^N B_i. \quad (21.13)$$

定义 21.6 (全局最优子空间). 设 $e_1, e_2, \dots, e_p$ 为矩阵 $\bar{B}$ 的特征向量, 按特征值 θ_k 从大到小排列。这些特征向量张成全局子空间约简的最优子空间。其推导基于如下事实: $\bar{B}$ 的最佳秩 L 逼近

$$\bar{B}_{[L]} = \sum_{\ell=1}^L \theta_{\ell} e_{\ell} e_{\ell}^T \quad (21.14)$$

求解如下的最小二乘问题:

$$\min_{\text{rank}(M)=L} \sum_{i=1}^N \text{tr} [(B_i - M)^2]. \quad (21.15)$$

注记 21.20 (理解与联系). 每个 B_i 含有 (a) 局部判别子空间的信息, 以及 (b) 该子空间中判别强度的信息, 因此式 (13.11) 可看作对一系列 N 个子空间按加权最小二乘寻找最优 L 维逼近子空间 (习题 13.5)。

在四维球例子中, $\bar{B}$ 的四个特征值 θ_{ℓ} 很大 (其特征向量几乎张成感兴趣的子空间), 其余六个接近零。操作上, 把数据投影到前四维子空间后做最近邻分类即可。在 §13.3.2 的卫星图像分类例子中, 图 13.8 标注为 DANN 的技术正是使用了全局降维子空间中的 5-最近邻。

该技术与 Duan and Li (1991) 的切片逆回归 (sliced inverse regression) 也有联系: 后者在回归设定中使用类似思想, 但做全局而非局部计算, 并假设特征分布具有球对称性来估计感兴趣的子空间。

21.5 计算考虑

最近邻规则的一个普遍缺点是**计算负载**——既包括找近邻, 也包括存储整个训练集。有 N 个观测、 p 个预测变量时, 每个查询点找近邻需要 Np 次运算。已有更快的找最近邻算法 (Friedman et al., 1975, 1977) 可降低部分负载。Hastie and Simard (1998) 通过在不变量度下开发 K-means 聚类的类似物, 减少了**切向距离**的计算量。

降低存储需求更困难, 已有各种**编辑** (editing) 与**压缩** (condensing) 程序被提出:

- **思想**: 隔离出足以进行最近邻预测的训练集子集, 丢掉其余训练数据。直觉上应保留**靠近决策边界且位于边界正确一侧**的训练点, 而可丢弃远离边界的点。
- **多编辑算法** (Devijver and Kittler, 1982): 把数据循环地分成训练集与测试集, 在训练集上计算最近邻规则, 删除被错分的测试点——目的是保留同质的观测簇。
- **压缩程序** (Hart, 1968): 更进一步, 只保留簇的重要**外部点**。从随机选出的单个观测作为训练集开始, 每个附加数据项逐个处理, 仅当它被当前训练集上的最近邻规则**错分**时才加入训练集。

这些程序综述见 Dasarathy (1991) 与 Ripley (1996), 也可应用于最近邻以外的其他学习程序。本章书目注记 (Bibliographic Notes) 与习题从略。

21.6 本章总结




图 21.3: 本章方法总览: 原型方法 (压缩) 与最近邻方法 (记忆式) 两大分支及其变体。

本章介绍了一族**无模型** (model-free) 的分类方法: 它们不显式估计特征与类别之间的关系, 而是把分类建立在**距离 / 邻近性**之上。方法可按是否**压缩数据**分为两大范式 (图 21.3):

原型方法——压缩 $N \rightarrow R$: 用每类 R 个原型点代表训练数据, 查询点分给最近原型。三种原型生成方式:

- **K-means:** 对每类分别做硬聚类取 R 个中心。定位原型时**未利用类标签** (「盲」), 原型易靠近类边界 (图 21.2 上)。
- **LVQ:** 用**全部数据含标签**在线更新——正确类吸引、错误类排斥, 把原型**推离决策边界** (图 21.2 下)。
- **高斯混合:** 软聚类 (EM 分配责任权重), 得到平滑后验 $\hat{p}(x)$, 分类取 $\arg \max_k \hat{p}_k(x)$ 。

最近邻方法——记忆式、不压缩: 每个训练点即原型 ($R = N$)。

- **k-NN:** 多数投票; **Cover-Hart 定理** 保证渐近 1-NN 误差不超过 $2 \times$ Bayes 率。

- **不变度量 / 切向距离**: 把旋转、平移、缩放、剪切、粗细等不变性并入度量 (以切线近似不变流形), 把手写数字 1-NN 错误率从 5.5% 降到 2.6% (表 21.1)。
- **自适应最近邻 (DANN)**: 高维下最近邻退化 (邻域半径迅速逼近立方体边缘, 式 21.10); DANN 用局部类内 W 与类间 B 协方差自适应度量 (式 21.11–21.12), 全局降维用 $\bar{B}$ 的特征子空间 (式 21.13–21.15)。

贯穿全章的**核心权衡**:

- **偏差–方差**: k 越小偏差越低、方差越高; 最优 k 依赖具体问题, 需交叉验证选择 (§13.3.1)。
- **压缩 vs 记忆**: 原型数 R 决定压缩比与保真度; R 越大保留信息越多, 但存储与计算成本越高。
- **计算**: 每查询点需 Np 次比较; 可用编辑/压缩程序剪枝训练集 (§13.5)。

一句话概括: 方法越结构化越利于**解释**, 越无模型越利于**黑箱预测**——当决策边界极不规则、每类原型众多时, 最近邻及其变体往往是真实数据上表现最好的选择 (如 STATLOG 36 维场景, §13.3.2)。

第二十二章 Unsupervised Learning (非监督学习)

22.1 引言

注记 22.1 (监督学习回顾). 前面各章处理的都是**监督学习**: 给定输入 $X^T = (X_1, \dots, X_p)$, 预测输出 $Y = (Y_1, \dots, Y_m)$ 。训练样本 $(x_1, y_1), \dots, (x_N, y_N)$ 中联合值全部已知, 目标由损失函数 $L(y, \hat{y})$ (例如平方损失 $(y - \hat{y})^2$) 刻画。若视 (X, Y) 服从联合密度 $\Pr(X, Y)$, 则监督学习本质上是在估计**条件密度** $\Pr(Y | X)$ 的性质, 其中最典型的是逐点最小化期望误差的「位置」参数

$$\mu(x) = \arg \min_{\theta} \mathbb{E}_{Y|X} L(Y, \theta). \quad (22.1)$$

由于 Y 通常低维 (一般一维) 且只关心位置 $\mu(x)$, 加上 $\Pr(X)$ (输入的边际密度) 在监督学习中一般不是直接关心的对象, 问题被大大简化。

本章转向**非监督学习** (unsupervised learning, 即「无师学习」)。此时只有 N 个观测 $x_1, x_2, \dots, x_N$, 来自随机 p 维向量 X 的联合密度 $\Pr(X)$; 目标是在**没有监督者**提供正确解答或误差度量的情况下, 直接推断该密度 $\Pr(X)$ 的性质。

与监督学习相比, 非监督学习有两个不利因素:

1. X 的维数常常高得多;
2. 感兴趣的性质往往比简单的位置估计更复杂。

但也有一点缓解: X 涵盖了所有变量, 无需推断 $\Pr(X)$ 的性质如何随另一组变量变化。

在低维情形 ($p \leq 3$), 有各种有效的**非参数方法**可直接在全体 X 值上估计 $\Pr(X)$ 并作图 (Silverman, 1986)。由于**维数灾难**, 这些方法在高维失效, 只能退而估计较粗糙的全局模型, 如**高斯混合**或各种刻画 $\Pr(X)$ 的简单描述性统计。一般地, 这些描述性统计试图刻画 $\Pr(X)$ 相对较大的那些 X 值或值的集合:

主成分、多维缩放 (MDS)、自组织映射 (SOM)、主曲线 : 识别 X 空间中代表高数据密度的一类**低维流形**, 提供变量间关联的信息, 以及各变量能否视为少数「隐变量」的函数;

聚类分析：寻找 X 空间中含 $\Pr(X)$ 众数的多个凸区域，判断 $\Pr(X)$ 是否能表示为若干更简单密度（代表不同类型/类别观测）的混合；

混合建模：目标与聚类类似；

关联规则：在极高维二元值数据的特殊情形下，构造描述高密度区域的简单合取规则。

注记 22.2 (非监督学习没有直接的成功度量). 监督学习有清晰的成败度量（联合分布上的期望损失，可用交叉验证估计）；非监督学习没有这种直接度量，很难判定推断的有效性，只能诉诸启发式论证——不仅用于动机，也用于判断结果质量。这种困境导致方法大量涌现，因为「有效性」是见仁见智、无法直接验证的。本章只介绍实践中用得最多的技术，外加作者偏爱的一些方法。

22.2 关联规则

关联规则分析（association rule analysis）已成为挖掘商业数据库的流行工具，目标是找出变量 $X = (X_1, X_2, \dots, X_p)$ 在数据库中出现最频繁的联合取值。它最常应用于二元数据 $X_j \in \{0, 1\}$ ，此时称为「市场篮子」分析（market basket analysis）：观测是销售交易（如收银台结账记录），变量是商店所有商品—— $x_{ij} = 1$ 表示第 i 笔交易购买了第 j 件商品，否则为 0。经常同时取 1 的变量对应经常被一起购买的商品，可用于货架摆放、交叉营销、目录设计、按购买习惯细分顾客等。

更一般地，关联规则分析的基本目标是找特征向量 X 的一组原型值 $v_1, \dots, v_L$ ，使密度在这些值处相对较大，即 $\Pr(v_l)$ 相对大。该框架可视为「众数寻找」（mode finding）或「凸包搜索」（bump hunting）。然而这个一般问题极其困难： $\Pr(v_l)$ 的自然估计是 $X = v_l$ 的观测比例，但变量一多、取值一多， $X = v_l$ 的观测数几乎总少到无法可靠估计。因此必须对分析目标与数据普遍性做大幅简化。

定义 22.1 (合取规则). 第一个简化修改目标：不再寻找 $\Pr(x)$ 大的点 x ，而是寻找 X 空间中概率含量相对其尺寸或支撑较大的区域。设 S_j 为第 j 个变量的全部可能取值（其支撑）， $s_j \subseteq S_j$ 为其子集。修改后的目标是找变量取值子集 $s_1, \dots, s_p$ ，使各变量同时落入相应子集的概率

$$\Pr \left[\bigcap_{j=1}^p (X_j \in s_j) \right] \quad (22.2)$$

相对较大。交集 $\bigcap_{j=1}^p (X_j \in s_j)$ 称为一个合取规则（conjunctive rule）。定量变量的 s_j 取连续区间，分类变量的 s_j 显式划定。若 $s_j = S_j$ （整个取值集合，常见情形），则称变量 X_j 不出现在该规则中。

注记 22.3 (几何视角：盒子的连续性与分块). 在几何上，合取规则 (22.2) 是一个轴平行、连通的超矩形（box）：对每个定量坐标取一个连续区间，故单个规则是「连续」的、不可分块。若高密度区域是分块/非凸的（如图 22.1 左图的 2×2 块），单条规则无法刻

画, 需用多条规则 (多个盒子) 的并集来覆盖——这正是「众数寻找 / bump hunting」的思路。此外注意目标是「概率含量相对其尺寸较大」的区域, 而非绝对概率 $\Pr(x)$ 最大的点。

22.2.1 市场篮子分析

求解 (22.2) 的一般方法在 §14.2.5 讨论, 对许多应用很有用; 但对市场篮子分析常面对的极大数据库 ($p \approx 10^4$, $N \approx 10^8$) 不可行, 还需进一步简化:

1. 只考虑两种子集: s_j 为单个值 $\{v_j^0\}$, 或为全部取值 S_j 。于是问题化为找整数子集 $J \subset \{1, \dots, p\}$ 及对应值 v_j^0 ($j \in J$), 使

$$\Pr \left[\bigcap_{j \in J} (X_j = v_j^0) \right] \quad (22.3)$$

较大。图 22.1 说明了这一假设。

2. 用哑变量技巧把 (22.3) 转化为纯二元问题。这里 S_j 是 X_j 的支撑 (support), 即其全部可能取值的集合, 假设每个 S_j 有限。严格定义: 对每个变量 X_j 的每个取值 $v_l^j \in S_j$, 构造一个哑变量 Z_k , 它是该取值事件的指示函数

$$Z_k = I(X_j = v_l^j) = \begin{cases} 1, & X_j = v_l^j, \\ 0, & \text{否则,} \end{cases}$$

其中下标 k 遍历所有 (j, l) 对, 故哑变量总数恰为所有变量取值个数之和

$$K = \sum_{j=1}^p |S_j|,$$

即「把全部变量的所有取值摊平成一条 0/1 向量」的长度。于是 (22.3) 化为找下标集 $\mathcal{K} \subset \{1, \dots, K\}$ (花体 $\mathcal{K}$ 区别于哑变量总数 K) 使

$$\Pr \left[\bigcap_{k \in \mathcal{K}} (Z_k = 1) \right] = \Pr \left[\prod_{k \in \mathcal{K}} Z_k = 1 \right] \quad (22.4)$$

较大——这就是市场篮子问题的标准形式。等号成立是因为每个 $Z_k \in \{0, 1\}$: 「所有 Z_k 都等于 1」当且仅当「其乘积等于 1」, 交与乘积只是记号等价。

例 22.1 (市场篮子问题的完整流程演示). 为把 (22.2)–(22.4) 的抽象过程串成一条直观的链条, 这里给出一个不含数值计算的最小例子。

设一家小超市只卖四种商品: 牛奶 (M)、面包 (B)、鸡蛋 (E)、黄油 (U)。某一天收银台记录了 5 笔交易 (市场篮子):




图 22.1: 关联规则的简化假设。两个输入 X_1 、 X_2 分别取 4 个与 6 个相异值，红框表示高密度区域。

图 22.1: 关联规则的简化假设：高密度区域只能取「某输入的单值」或「全部值」两种形式。此假设下可以找到中、右两种模式，但找不到左侧的 2×2 块模式。

交易 i	购买的商品
1	牛奶、面包、鸡蛋
2	牛奶、面包
3	牛奶、鸡蛋、黄油
4	面包、鸡蛋
5	牛奶、面包、黄油

第 1 步：原始目标。对应 (22.2)，目标是在四个商品变量 $X_1, \dots, X_4$ （均取值 $\{0, 1\}$ ，1 表示购买）上找取值子集 $s_1, \dots, s_4$ ，使「各商品同时落入其子集」的概率较大。直觉上，牛奶与面包经常一起出现，就是这类高概率的取值组合。

第 2 步：单值/全集简化。按市场篮子分析的简化，每个 s_j 只允许两种形式：单值 $s_j = \{1\}$ （要求购买该商品）或全集 $s_j = \{0, 1\}$ （不约束该商品）。于是 (22.2) 化为 (22.3)：找商品子集 $J \subset \{1, 2, 3, 4\}$ ，使「 J 中所有商品都被购买」的概率较大。

第 3 步：哑变量编码。严格按 (22.3) 之前的公式，每个原始变量的每个取值对应一个哑变量，故 $K = \sum_{j=1}^4 |S_j| = 4 \times 2 = 8$ ——每个商品对应「买了」「没买」两个哑变量。但市场篮子分析只关心「买了」（ $X_j = 1$ ）这个事件，实践中省略「没买」哑变量，每个商品只保留一个购买指示 Z_k （直接取 X_j 本身），实际纳入分析的有效哑变量数为 $p = 4$ 。每笔交易变成一个 0/1 向量：

交易 i	Z_M	Z_B	Z_E	Z_U	含义
1	1	1	1	0	买了牛奶、面包、鸡蛋
2	1	1	0	0	买了牛奶、面包
3	1	0	1	1	买了牛奶、鸡蛋、黄油
4	0	1	1	0	买了面包、鸡蛋
5	1	1	0	1	买了牛奶、面包、黄油

第 4 步：引出项集与支持度。现在问题化为 (22.4)：找哑变量下标集 $\mathcal{K}$ ，使「 $\mathcal{K}$ 中

所有哑变量同时为 1」(即这些商品同时被购买)的概率较大。例如「牛奶、面包」对应 $\mathcal{K} = \{Z_M, Z_B\}$, 它在 5 笔交易中的出现频率就是该组合的支持度 $T(\mathcal{K})$ ——即下文定义中 (22.5) 所刻画的对象。此处 $N = 5$, 有效哑变量数为 4, 共有 $2^4 = 16$ 个可能的项集 (若按公式口径 $K = 8$ 计入「没买」哑变量则为 $2^8 = 256$, 实践中弃之不用); 实际操作中用支持度阈值 t ((22.6)) 筛掉出现太少的组合。

这样一个完整的市场篮子问题就串通了: 交易数据 $\rightarrow$ 单值/全集简化 $\rightarrow$ 哑变量编码 $\rightarrow$ 项集与支持度。

定义 22.2 (项集、支持度). 设 $\mathcal{K}$ 为哑变量下标集, 称 $\mathcal{K}$ 为一个项集 (item set), 其中哑变量个数称为其大小 (size, 不超过 p)。 (22.4) 的估计取数据库中含该合取的观测比例:

$$\hat{\text{Pr}} \left[\prod_{k \in \mathcal{K}} Z_k = 1 \right] = \frac{1}{N} \sum_{i=1}^N \prod_{k \in \mathcal{K}} z_{ik}, \quad (22.5)$$

其中 z_{ik} 是第 i 个案例的 Z_k 值。上式称为项集 $\mathcal{K}$ 的支持度或流行度 (support / prevalence) $T(\mathcal{K})$ 。满足 $\prod_{k \in \mathcal{K}} z_{ik} = 1$ 的观测 i 称包含 (contain) 项集 $\mathcal{K}$ 。

关联规则挖掘中指定支持度下界 t , 寻找可由 $Z_1, \dots, Z_K$ 构成、且在数据库中支持度超过 t 的所有项集:

$$\{\mathcal{K}_l \mid T(\mathcal{K}_l) > t\}. \quad (22.6)$$

22.2.2 Apriori 算法

只要把阈值 t 调得使 (22.6) 只占全部 2^K 个项集的很小一部分, **Apriori 算法** (Agrawal et al., 1995) 就能以少量数据遍历求解 (22.6)。它利用了「维数灾难」的几个方面: 对给定支持度阈值 t ,

1. 基数 $|\{\mathcal{K} \mid T(\mathcal{K}) > t\}|$ 相对较小;
2. **单调性**: $\mathcal{K}$ 的任意子集项集 L 的支持度不小于 $\mathcal{K}$ 的, 即

$$L \subseteq \mathcal{K} \implies T(L) \geq T(\mathcal{K}).$$

注记 22.4 (单调性为什么成立). 直观上, 项集越大要求「同时成立」的条件越多、越严格, 能同时满足的观测只会更少。严格证明: 记包含项集 $\mathcal{K}$ 的观测集合

$$A(\mathcal{K}) = \left\{ i : \prod_{k \in \mathcal{K}} z_{ik} = 1 \right\},$$

由 (22.5) 有 $T(\mathcal{K}) = |A(\mathcal{K})|/N$ 。若 $L \subseteq \mathcal{K}$, 则任何包含 $\mathcal{K}$ 的观测 i 对所有 $k \in \mathcal{K}$ 满足 $z_{ik} = 1$, 特别地对 L 中所有 k 亦然, 故 i 必包含 L , 从而

$$A(\mathcal{K}) \subseteq A(L) \implies T(\mathcal{K}) \leq T(L).$$

即「满足更多约束」的观测集合是「满足更少约束」观测集合的子集。例如在 §14.2.1 的市场篮子例子中, $T(\{\text{牛奶}\}) = 4/5 \geq T(\{\text{牛奶}, \text{面包}\}) = 3/5$ 。

由此得到**反单调性/向下闭包** (anti-monotone / downward closure): 若 m 项集 $\mathcal{K}$ 不频繁 ($T(\mathcal{K}) \leq t$), 则其一切超集也不可能频繁。这正是 Apriori 剪枝的依据: 第 m 遍只须考虑「所有 $m-1$ 个祖先项集都频繁」的候选, 含非频繁子集的候选可直接丢弃、无需扫描数据。

Algorithm 1 Apriori 算法 (市场篮子)

Require: 事务数据库 D (N 笔交易, 哑变量 $Z_1, \dots, Z_K$); 最小支持度阈值 t

Ensure: 所有频繁项集 $\{\mathcal{K} \mid T(\mathcal{K}) > t\}$

- 1: 扫描 D , 按 (22.5) 统计每个单项集支持度, 得频繁 1-项集 $F_1 = \{\{k\} \mid T(\{k\}) > t\}$, 令 $m \leftarrow 1$
 - 2: **while** $F_m \neq \emptyset$ **do**
 - 3: 生成候选 $(m+1)$ -项集 C_{m+1} : 由 F_m 中的项集两两合并, 且每个候选的所有 m -子集都在 F_m 中
 - 4: 扫描 D , 统计 C_{m+1} 中每个候选的支持度 $T(\cdot)$
 - 5: $F_{m+1} \leftarrow \{\mathcal{K} \in C_{m+1} \mid T(\mathcal{K}) > t\}$
 - 6: $m \leftarrow m + 1$
 - 7: **end while**
 - 8: **return** $\bigcup_{m \geq 1} F_m$
-

算法过程 (文字描述): 第一遍遍历数据计算所有**单项集**的支持度, 低于阈值者丢弃; 第二遍只计算由第一遍幸存单项构成的两项集, 低于阈值者再丢弃; 此后每一遍只考虑「由上一遍幸存项集与第一遍保留项组合而成」的候选。生成大小 m 的频繁项集只需考虑其所有 $m-1$ 个祖先项集都频繁的候选。遍历持续到上一遍的候选规则支持度全部低于阈值为止。

关键的一点是: Apriori 对每个 $|K|$ 值**只需一遍数据**——因为假设数据放不进主存。若数据足够稀疏 (或阈值 t 足够高), 即使数据集巨大也能在合理时间内终止。Apriori 算法代表了数据挖掘技术的一项重大进步。

定义 22.3 (关联规则及其属性). 每个高支持度项集 $\mathcal{K}$ ((22.6)) 被转化为一组**关联规则**: 把 $\mathcal{K}$ 的项划分成两个不相交子集 $A \cup B = \mathcal{K}$, 记为

$$A \Rightarrow B. \quad (22.7)$$

A 称**前件** (antecedent), B 称**后件** (consequent)。关联规则有如下性质:

- **支持度** $T(A \Rightarrow B)$: 前件与后件并集 (即原项集 $\mathcal{K}$) 的支持度, 可视为随机市场篮子中同时出现 A 、 B 的概率 $\Pr(A \text{ and } B)$ 的估计 ((22.5));

- **置信度** (或可预测性) $C(A \Rightarrow B)$: 支持度除以前件的支持度

$$C(A \Rightarrow B) = \frac{T(A \Rightarrow B)}{T(A)}, \quad (22.8)$$

可视为 $\Pr(B | A)$ 的估计 (记号 $\Pr(A)$ 是 $\Pr(\prod_{k \in A} Z_k = 1)$ 的简写);

- **期望置信度** (expected confidence): 后件的支持度 $T(B)$, 即无条件概率 $\Pr(B)$ 的估计;
- **提升度** (lift):

$$L(A \Rightarrow B) = \frac{C(A \Rightarrow B)}{T(B)},$$

即 $\Pr(A \text{ and } B) / [\Pr(A) \Pr(B)]$ 的估计。

小结: 四种属性的公式、估计对象与常用阈值归纳如下 (阈值均为实践常用经验值, 需按数据规模与应用调整; 其中支持度阈值 t 、置信度阈值 c 正是 (22.6)、(22.9) 中的下界):

属性	记号	公式	估计对象	常用阈值
支持度	$T(A \Rightarrow B)$	$T(K)$	$\Pr(A \text{ 且 } B)$	t : 1% ~ 10%
置信度	$C(A \Rightarrow B)$	$T(A \Rightarrow B) / T(A)$	$\Pr(B A)$	c : 50% ~ 90%
期望置信度	$T(B)$	$T(B)$	$\Pr(B)$ (基准)	—
提升度	$L(A \Rightarrow B)$	$C(A \Rightarrow B) / T(B)$	$\Pr(A, B) / [\Pr(A) \Pr(B)]$	> 1 正关联, 常用 > 1.5

例 22.2 (花生酱-果冻-面包). 设项集 $K = \{\text{peanut butter, jelly, bread}\}$, 考虑规则 $\{\text{peanut butter, jelly}\} \Rightarrow \{\text{bread}\}$. 支持度 0.03 表示三种商品同时出现在 3% 的市场篮子中; 置信度 0.82 表示买了花生酱和果冻的篮子里 82% 也买了面包; 若面包出现在 43% 的篮子中, 则该规则提升度为 1.95。

规则生成: 设置信度阈值 c , 报告所有由 (22.6) 的项集构成且置信度超过 c 的规则:

$$\{A \Rightarrow B \mid C(A \Rightarrow B) > c\}. \quad (22.9)$$

对大小为 $|K|$ 的项集, 形如 $A \Rightarrow (K - A)$, $A \subset K$ 的规则共有 $2^{|K|-1} - 1$ 条。Agrawal 等给出 Apriori 的变体, 可快速确定哪些规则通过置信度阈值。

整体输出: 满足约束

$$T(A \Rightarrow B) > t \quad \text{且} \quad C(A \Rightarrow B) > c$$

的关联规则集合, 通常存入可查询的数据库, 例如按置信度、提升度或支持度排序展示, 或以后件中特定商品为条件筛选——这实际上把问题转入了监督学习框架。

注记 22.5 (关联规则的局限). 关联规则成功的关键是**支持度阈值** ((22.6)) 保证计算可行。随着该下界减小, 解项集的个数、大小以及所需数据遍历次数可能**指数增长**。因此, 高置信度/高提升度但**低支持度**的规则不会被发现——例如“vodka $\Rightarrow$ caviar”这类规则, 因后件 caviar 销量低而无法被挖出。

22.2.3 示例：市场篮子分析

我们在中等规模的人口统计数据库上演示 Apriori。数据是旧金山湾区购物中心顾客填写的 $N = 9409$ 份问卷（Impact Resources, Inc., Columbus OH, 1987），此处使用前 14 个与人口统计有关的问题（表 22.1）。数据是序数变量与（无序）分类变量的混合，很多分类变量取值较多，且含大量缺失值。

表 22.1: 人口统计数据中的输入变量。

编号	特征	取值数	类型
1	Sex（性别）	2	分类
2	Marital status（婚姻状况）	5	分类
3	Age（年龄）	7	序数
4	Education（教育）	6	序数
5	Occupation（职业）	9	分类
6	Income（收入）	9	序数
7	Years in Bay Area（居留年数）	5	序数
8	Dual incomes（双收入）	3	分类
9	Number in household（家庭人数）	9	序数
10	Number of children（子女数）	9	序数
11	Householder status（户主身份）	3	分类
12	Type of home（住房类型）	5	分类
13	Ethnic classification（族裔）	8	分类
14	Language in home（家庭语言）	3	分类

使用 Christian Borgelt 提供的免费 Apriori 实现(<http://fuzzy.cs.uni-magdeburg.de/~borgelt/>)剔除含缺失值的观测后，每个序数预测变量按**中位数**切分、编码为两个哑变量；每个有 k 类的分类变量编码为 k 个哑变量，最终得到 6876×50 的矩阵（6876 个观测、50 个哑变量）。

算法共找到 **6288** 条关联规则，涉及 ≤ 5 个预测变量，支持度至少 10%。理解这大批规则本身就是一项富有挑战性的数据分析任务。图 22.2（书中图 14.2）显示了各哑变量在数据中的相对频率（上）与在关联规则中的相对频率（下）：常见类别往往在规则中更频繁出现（如家庭语言的第一类 English），而有些（如 occupation）被低估。

书中给出 Apriori 找到的三条示例规则：

例 22.3 (三条示例规则). **规则 1**：支持度 25%，置信度 99.7%，提升度 1.03。

$$\left[\begin{array}{l} \text{number in household} = 1 \\ \text{number of children} = 0 \end{array} \right] \implies \text{language in home} = \text{English}.$$




图 22.2 (示意): 数据中 (上) 与规则中 (下) 各哑变量相对频率的对比

图 22.2: 市场篮子分析 (书中图 14.2 的示意): Apriori 找到的规则中各哑变量 (编码一个输入类别) 的相对频率。

规则 2: 支持度 13.4%, 置信度 80.8%, 提升度 2.13。

$$\left[\begin{array}{l} \text{language in home} = \text{English} \\ \text{householder status} = \text{own} \\ \text{occupation} = \{\text{professional/managerial}\} \end{array} \right] \Rightarrow \text{income} \geq \$40,000.$$

规则 3: 支持度 26.5%, 置信度 82.8%, 提升度 2.15。

$$\left[\begin{array}{l} \text{language in home} = \text{English} \\ \text{income} < \$40,000 \\ \text{marital status} = \text{not married} \\ \text{number of children} = 0 \end{array} \right] \Rightarrow \text{education} \notin \{\text{college graduate, graduate study}\}.$$

我们根据高支持度选了规则 1 和 3; 规则 2 是「高收入」后件的关联规则, 可用于定向瞄准高收入人群。

注记 22.6 (哑变量的取舍). 如前所述, 每个输入类别都建了哑变量, 例如 $Z_1 = I(\text{income} < \$40,000)$ 与 $Z_2 = I(\text{income} \geq \$40,000)$ 。若只关心与「高收入」类别的关联, 就只把 Z_2 纳入 (而不放 Z_1)。实际市场篮子问题常如此: 我们关心与**相对稀有商品**的出现的关联, 而不关心与其**缺失**的关联。

22.2.4 非监督转化为监督学习

本节讨论把**密度估计问题转化为监督函数逼近**的技巧, 它是下一节广义关联规则的基础。

定义 22.4 (密度估计转分类). 设 $g(x)$ 为待估计的未知数据密度, $g_0(x)$ 为指定的**参考密度** (例如变量范围内的均匀密度)。数据 $x_1, \dots, x_N$ 视为来自 $g(x)$ 的 i.i.d. 样本; 用 Monte Carlo 方法从 $g_0(x)$ 抽取大小为 N_0 的样本。把两组数据合并, 并赋予权重

$$w = \frac{N_0}{N + N_0} \text{ (来自 } g), \quad w_0 = \frac{N}{N + N_0} \text{ (来自 } g_0),$$

得到来自混合密度 $(g(x) + g_0(x))/2$ 的随机样本。若给来自 $g(x)$ 的样本标 $Y = 1$ 、来自 $g_0(x)$ 的标 $Y = 0$ ，则

$$\mu(x) = \mathbb{E}(Y | x) = \frac{g(x)}{g(x) + g_0(x)} = \frac{g(x)/g_0(x)}{1 + g(x)/g_0(x)} \quad (22.10)$$

可用监督学习在合并样本

$$(y_1, x_1), (y_2, x_2), \dots, (y_{N+N_0}, x_{N+N_0}) \quad (22.11)$$

上估计。所得估计 $\hat{\mu}(x)$ 可反演为 $g(x)$ 的估计：

$$\hat{g}(x) = g_0(x) \frac{\hat{\mu}(x)}{1 - \hat{\mu}(x)}. \quad (22.12)$$

例 22.4 (一维密度估计转分类的完整流程). 设数据密度为 $g(x) = 2x$ ($x \in [0, 1]$ ，高密度在右半)，参考密度取均匀 $g_0(x) = 1$ 。取 $N_0 = N$ (两样本等大，使混合严格为等权的 $(g + g_0)/2$ ；一般 $N_0 \neq N$ 时混合密度为加权形式 $[N g(x) + N_0 g_0(x)]/(N + N_0)$ ，此时 (22.10) 应代以带权重的 $\mu(x) = N g(x)/[N g(x) + N_0 g_0(x)]$)。

第 1 步：构造两类样本。 从 $g(x) = 2x$ 抽 N 个数据点 (大多落在 $x > 0.5$ 一侧)，标 $Y = 1$ ；从 $g_0(x) = 1$ 用 Monte Carlo 抽 $N_0 = N$ 个参考点 (均匀散布)，标 $Y = 0$ 。合并后每点来自混合密度

$$\frac{g(x) + g_0(x)}{2} = \frac{2x + 1}{2}.$$

第 2 步：分类目标。 由 (22.10)，

$$\mu(x) = \frac{g(x)}{g(x) + g_0(x)} = \frac{2x}{2x + 1},$$

它是 x 的单调递增曲线：如 $\mu(0.25) = 1/3$ (更像参考点)、 $\mu(0.75) = 3/5$ (更像数据点)。分类器只需学会这条简单曲线。

第 3 步：反演还原。 用 (22.12)：

$$\hat{g}(x) = g_0(x) \frac{\hat{\mu}(x)}{1 - \hat{\mu}(x)} = \frac{2x/(2x + 1)}{1/(2x + 1)} = 2x = g(x),$$

精确还原数据密度。若用对数几率 (22.13) 则 $f(x) = \log[g(x)/g_0(x)] = \log(2x)$ ，(22.14) 同样给出 $\hat{g} = g_0 e^{\hat{f}} = 2x$ 。

可见：把密度估计「伪装」成分类后，只需拟合 μ (或 f) 这个简单对象，再经单调反演即得 $\hat{g}$ 。

广义逻辑回归 (第 4.4 节) 尤其适合此应用，因为它直接估计对数几率 (log-odds)

$$f(x) = \log \frac{g(x)}{g_0(x)}, \quad (22.13)$$

此时

$$\hat{g}(x) = g_0(x) e^{\hat{f}(x)}. \quad (22.14)$$




FIGURE 14.3. *Density estimation via classification. (Left panel:) Training set of 200 data points. (Right panel:) Training set plus 200 reference data points, generated uniformly over the rectangle containing the training data. The training sample was labeled as class 1, and the reference sample class 0, and a semiparametric logistic regression model was fit to the data. Some contours for $\hat{g}(x)$ are shown.*

图 22.3: 通过分类进行密度估计。(左图) 训练集 200 个数据点。(右图) 训练集加上 200 个参考数据点, 参考点在包含训练数据的最小矩形上均匀生成; 训练样本标为类 1、参考样本标为类 0, 用半参数逻辑回归模型拟合数据, 图中显示若干 $\hat{g}(x)$ 的等值线。

例 22.5 (书中图 14.3: 通过分类进行密度估计). 左图: 200 个训练点。右图: 在包含训练数据的最小矩形上均匀生成 200 个参考点 (蓝色), 训练样本标为类 1、参考样本标为类 0, 用自然样条张量积的逻辑回归 (第 5.2.1 节) 拟合。图中显示若干 $\hat{\mu}(x)$ 的等值线; 由于 $\hat{g}(x) = \hat{\mu}(x)/(1 - \hat{\mu}(x))$ 是 $\hat{\mu}$ 的单调函数, 这些等值线也是密度估计 $\hat{g}(x)$ 的等值线, 大致刻画了数据密度。

注记 22.7 (参考密度的选择). 原则上 (22.14) 中 $g_0(x)$ 可取任意参考密度, 但实际中 $\hat{g}(x)$ 的精度可能对 g_0 的选择高度敏感, 且取决于数据密度 $g(x)$ 与估计 (22.10) / (22.13) 所用的方法。若以精度为目标, 应选使 $\mu(x)$ 或 $f(x)$ 易于被所用方法逼近的 g_0 。

但精度并非总是首要目标: $\mu(x)$ 与 $f(x)$ 都是密度比 $g(x)/g_0(x)$ 的单调函数, 可视为「对比统计量」(contrast statistics), 提供数据密度 g 偏离所选参考密度 g_0 的信息。因此在数据分析场景中, g_0 的选择由具体问题中最感兴趣的偏离类型决定:

- 关心偏离均匀: g_0 取变量范围内的均匀密度;
- 关心偏离联合正态: g_0 取与数据同均值、同协方差的高斯分布;
- 研究偏离独立: 取

$$g_0(x) = \prod_{j=1}^p g_j(x_j), \quad (22.15)$$

其中 $g_j(x_j)$ 是 X_j 第 j 个坐标的**边际数据密度**。来自该独立密度 (22.15) 的样本极易由数据本身生成——只需对各变量的数据值施加**不同的随机置换**。

注记 22.8 (此法为何未被重视). 这种把问题转化为监督学习 ((22.10)–(22.14)) 的思路似乎是统计学中的「民间传说」, 但至今影响不大。原因之一: 问题需用 Monte Carlo 模拟数据集扩充, 且该数据集至少不小于原始样本 ($N_0 \geq N$), 计算与内存需求至少翻倍; 生成 Monte Carlo 样本本身也需要大量计算。随着计算资源日益廉价, 这一障碍正变得越来越小。

22.2.5 广义关联规则

更一般的寻找高密度区域问题 (22.2) 可用上述**监督学习途径**解决。虽然它不适用于市场篮子分析那种巨型数据库, 但能从中等规模数据集中获得有用信息。(22.2) 可表述为: 找整数子集 $J \subset \{1, 2, \dots, p\}$ 及对应变量 X_j 的取值子集 s_j ($j \in J$), 使

$$\hat{\text{Pr}} \left[\bigcap_{j \in J} (X_j \in s_j) \right] = \frac{1}{N} \sum_{i=1}^N I \left[\bigcap_{j \in J} (x_{ij} \in s_j) \right] \quad (22.16)$$

较大。沿用关联规则分析的术语, $\{(X_j \in s_j)\}_{j \in J}$ 称为一个「**广义**」项集 (generalized item set), 定量变量对应的子集 s_j 取其取值范围内的**连续区间**, 分类变量的子集可含**多于一个值**。

广义表述野心之大, 使无法像市场篮子分析那样对支持度 ((22.16)) 超过指定下界的所有广义项集穷举搜索, 只能用**启发式搜索**, 最多期望找到一组有用的广义项集。

注记 22.9 (均匀分布的隐含偏好). 市场篮子分析 ((22.5)) 与广义表述 ((22.16)) 都隐含**参照均匀分布**: 寻找「比所有联合取值均匀分布时更频繁」的项集。这偏向发现**边际成分本身频繁**的项集, 即

$$\frac{1}{N} \sum_{i=1}^N I(x_{ij} \in s_j) \quad (22.17)$$

较大。频繁子集 ((22.17)) 的合取会比边际较不频繁子集的合取更常出现在高支持度项集 ((22.16)) 中——这正是 $\text{vodka} \Rightarrow \text{caviar}$ 难被发现的原因: 二者边际支持度都不高, 联合支持度尤其小。参照均匀分布还会使「成分间关联弱但自身高频」的项集主导最高支持度项集的集合。

用边际密度的乘积 ((22.15)) 作参考分布可**消除**对高频单值的偏好: 因为若变量间完全独立, 密度比 $g(x)/g_0(x)$ 恰为常数 (均匀), 与各变量取值的频率分布无关, 于是 $\text{vodka} \Rightarrow \text{caviar}$ 这类规则有机会浮现。但如何把均匀之外的参考分布纳入 Apriori 尚不明确; 不过按 §14.2.4, 从乘积密度 (22.15) 生成样本是容易的。

选定参考分布并按 (22.11) 抽取样本后, 就得到一个输出为二值 $Y \in \{0, 1\}$ 的**监督学习问题**。目标是用这些训练数据寻找目标函数 $\mu(x) = \mathbb{E}(Y | x)$ 相对较大的**区域**

$$R = \bigcap_{j \in J} (X_j \in s_j), \quad (22.18)$$

并且可能还要求这些区域的数据支持

$$T(R) = \int_{x \in R} g(x) dx \quad (22.19)$$

不过小。

22.2.6 监督学习方法的选择

区域 ((22.18)) 由合取规则定义，因此能学习此类规则的监督方法最合适。

CART 决策树：其终结点正由形如 (22.18) 的规则定义。把 CART 应用于合并数据 ((22.11))，将得到一棵在整个数据空间上用一组不相交区域 (终结点) 建模目标 ((22.10)) 的决策树。平均 y 值

$$\bar{y}_t = \text{ave}(y_i \mid x_i \in t)$$

较高的终结点 t 就是高支持度广义项集 ((22.16)) 的候选，其 (数据) 支持度为

$$T(R) = \bar{y}_t \cdot \frac{N_t}{N + N_0},$$

其中 N_t 是该终结点区域内 (合并) 观测的个数。检查所得决策树可发现相对高支持度的有趣广义项集，再把它们划分成前件与后件，搜索高置信度/高提升度的广义关联规则。

PRIM (第 9.3 节) 是另一种自然选择：它也产生形如 (22.18) 的规则，但专门设计用于寻找区域内部平均目标 ((22.10)) 最大的高支持度区域，而非对整个数据空间建模目标函数；它还对「支持度 vs 平均目标值」的权衡提供更多控制。

练习 14.3 讨论这两种方法在从边际分布乘积生成随机数据时的一个问题。

22.2.7 示例：市场篮子分析 (续)

把 PRIM 应用于表 22.1 的人口统计数据，得到三个高支持度广义项集：

例 22.6 (PRIM 得到的三个广义项集). **项集 1** (支持度 24%)：

$$\left[\begin{array}{l} \text{marital status} = \text{married} \\ \text{householder status} = \text{own} \\ \text{type of home} \neq \text{apartment} \end{array} \right]$$

项集 2 (支持度 24%)：

$$\left[\begin{array}{l} \text{age} \leq 24 \\ \text{marital status} \in \{\text{living together-not married, single}\} \\ \text{occupation} \notin \{\text{professional, homemaker, retired}\} \\ \text{householder status} \in \{\text{rent, live with family}\} \end{array} \right]$$

项集 3 (支持度 15%):

$$\left[\begin{array}{l} \text{householder status} = \text{rent} \\ \text{type of home} \neq \text{house} \\ \text{number in household} \leq 2 \\ \text{number of children} = 0 \\ \text{occupation} \notin \{\text{homemaker, student, unemployed}\} \\ \text{income} \in [\$20,000, \$150,000] \end{array} \right]$$

由这些项集派生出置信度 ((22.8)) 大于 95% 的广义关联规则:

例 22.7 (置信度 > 95% 的广义关联规则). **规则 1:** 支持度 25%, 置信度 99.7%, 提升度 1.35。

$\{\text{marital status} = \text{married}, \text{householder status} = \text{own}\} \Rightarrow \text{type of home} \neq \text{apartment}.$

规则 2: 支持度 25%, 置信度 98.7%, 提升度 1.97。

$\{\text{age} \leq 24, \text{occupation} \notin \{\text{professional, homemaker, retired}\}, \text{householder status} \in \{\text{rent, live with fam}\}$

规则 3: 支持度 25%, 置信度 95.9%, 提升度 2.61。

$\{\text{householder status} = \text{own}, \text{type of home} \neq \text{apartment}\} \Rightarrow \text{marital status} = \text{married}.$

规则 4: 支持度 15%, 置信度 95.4%, 提升度 1.50。

$\{\text{householder status} = \text{rent}, \text{type of home} \neq \text{house}, \text{number in household} \leq 2, \text{occupation} \notin \{\text{homemaker, student, unemployed}\}\}$

这些规则没有大的意外, 大多验证了直觉; 但在先验信息较少的其他场景中, 意外结果更可能涌现。它们展示了广义关联规则能提供的信息类型, 以及「监督学习途径 + CART/PRIM 等规则归纳方法」能发现成分间高关联的项集。

注记 22.10 (Apriori 与 PRIM 的对比). Apriori 是**穷举**的——找出所有支持度超过给定值的规则; PRIM 是**贪婪**的, 不保证给出「最优」规则集。另一方面, Apriori 只能处理**哑变量**, 因而找不到上述某些规则: 例如 `type of home` 是分类输入、每个水平一个哑变量, Apriori 无法找到涉及集合 $\{\text{type of home} \neq \text{apartment}\}$ 的规则 (除非预先为「apartment vs 其他」编码哑变量); 而预先编码所有这类潜在有趣的比较通常不可行。

22.3 聚类分析

聚类分析 (cluster analysis), 又称**数据分割** (data segmentation), 有一系列目标, 都与把对象集合划分成子集或「簇」有关: 使同一簇内的对象彼此比不同簇的对象**更相似**。对象可由一组测量描述, 也可由其与其他对象的关系描述。有时目标还包括把簇组织成

自然层次——逐层对簇本身再分组，使层次每一层中同一组的簇比不同组的更相似。聚类分析也用于形成描述性统计，判断数据是否由若干性质显著不同的子群组成（这需要评估分到各簇的对象间的差异程度）。

注记 22.11 (相似度量的核心地位). 聚类分析所有目标的核心是对象间的**相似度/不相似度** (similarity / dissimilarity) 概念。聚类方法基于提供给它的相似度定义来分组，而这种定义只能来自**领域知识**——类似监督学习中损失/代价函数的选择（那里不准确预测的代价取决于数据之外的考量）。

图 22.4 展示了用流行的 K-means 算法把模拟数据聚成三簇（橙色、蓝色、绿色）的例子。其中两簇**分离不好**，用「分割」比「聚类」更贴切。K-means 从三个簇中心的猜测出发，然后交替以下两步直到收敛：

1. 对每个数据点，找出**欧氏距离**最近的簇中心；
2. 把每个簇中心替换为所有离它最近数据点的**坐标平均**。

K-means 是**自上而下** (top-down) 的过程，而后面讨论的其他聚类方法是**自下而上** (bottom-up) 的。所有聚类技术的基础是两对象间**距离/不相似度量**的选择——先讨论距离度量，再描述各类聚类算法。




图 22.4: K-means 聚类 (书中图 14.4 的示意): 模拟数据被聚成三类 (橙、蓝、绿), 其中两类分离得不好, 「分割」比「聚类」更贴切。

22.3.1 邻近矩阵

有时数据直接以对象对的**邻近度** (proximity, 相似或亲和) 表示, 可以是相似度或不相似度。例如社会科学实验中让参与者判断某些对象彼此差异多大, 再对这些判断取平均得到不相似度。这类数据可表示为 $N \times N$ 矩阵 D (N 为对象数), 元素 $d_{ii'}$ 记录第 i 与第 i' 个对象间的邻近度, 直接作为聚类算法的输入。

多数算法假定不相似度矩阵满足**非负、零对角** ($d_{ii} = 0$)。若原始数据是相似度, 可用合适的**单调递减函数**转为不相似度。多数算法还假定矩阵**对称**; 若不满足, 用 $(D + D^T)/2$

代替。主观判断的不相似度通常不是严格意义的距离——三角不等式 $d_{ii'} \leq d_{ik} + d_{i'k}$ 未必成立，因此某些假设距离的算法不能用于这类数据。

22.3.2 基于属性的不相似性

最常见的情形是有 N 个观测、 p 个变量（属性）的测量 x_{ij} 。多数流行聚类算法以不相似度矩阵为输入，故须先构造观测对间的不相似度。通常定义第 j 个属性值间的不相似度 $d_j(x_{ij}, x_{i'j})$ ，再定义对象 i 与 i' 间的

$$D(x_i, x_{i'}) = \sum_{j=1}^p d_j(x_{ij}, x_{i'j}), \quad (22.20)$$

最常见的取平方距离

$$d_j(x_{ij}, x_{i'j}) = (x_{ij} - x_{i'j})^2. \quad (22.21)$$

但其他选择也可能且会带来不同结果；对非定量属性（如分类数据）平方距离未必合适；有时还希望给属性不同权重而非如 (22.20) 的等权。

按属性类型讨论：

定量变量：取值是连续实数，自然的「误差」是绝对差值的单调增函数

$$d(x_i, x_{i'}) = l(|x_i - x_{i'}|).$$

除平方误差 $(x_i - x_{i'})^2$ 外，常用恒等（绝对误差），前者更强调较大差异。也可基于相关

$$\rho(x_i, x_{i'}) = \frac{\sum_j (x_{ij} - \bar{x}_i)(x_{i'j} - \bar{x}_{i'})}{\sqrt{\sum_j (x_{ij} - \bar{x}_i)^2 \sum_j (x_{i'j} - \bar{x}_{i'})^2}}, \quad (22.22)$$

其中 $\bar{x}_i = \sum_j x_{ij}/p$ （注意是对变量平均而非观测）。若先把观测标准化，则 $\sum_j (x_{ij} - x_{i'j})^2 \propto 2(1 - \rho(x_i, x_{i'}))$ ，故基于相关（相似度）的聚类与基于平方距离（不相似度）的聚类等价。

序数变量：取值常表示为连续整数、构成有序集（如成绩 A,B,C,D,F）。其误差度量一般先把 M 个原始值按原顺序替换为

$$\frac{i - \frac{1}{2}}{M}, \quad i = 1, \dots, M \quad (22.23)$$

再按此尺度当定量变量处理。秩数据是序数数据的特例。

分类变量：对无序分类（nominal）变量，值对间的差异程度须显式划定。若变量取 M 个相异值，可排成对称 $M \times M$ 矩阵，元素满足 $L_{rr'} = L_{r'r}$, $L_{rr} = 0$, $L_{rr'} \geq 0$ 。最常见取 $L_{rr'} = 1$ ($r \neq r'$)；也可用不等损失强调某些错误。

22.3.3 对象不相似性

把 p 个属性的不相似度 $d_j(x_{ij}, x_{i'j})$ 合并成两个对象 $x_i, x_{i'}$ 间整体不相似度的过程, 几乎总是用加权平均 (凸组合)

$$D(x_i, x_{i'}) = \sum_{j=1}^p w_j \cdot d_j(x_{ij}, x_{i'j}), \quad \sum_{j=1}^p w_j = 1, \quad (22.24)$$

其中 w_j 是第 j 个属性的权重, 调节它在对象整体不相似度中的相对影响, 应基于领域知识选择。

注记 22.12 (等权重不等于等影响). 把 w_j 设为相同值 (如 $w_j = 1, \forall j$) 并不必然给所有属性相等影响。第 j 个属性对 $D(x_i, x_{i'})$ ((22.24)) 的影响取决于它对该数据集中所有观测对平均对象不相似度

$$\bar{D} = \frac{1}{N^2} \sum_{i=1}^N \sum_{i'=1}^N D(x_i, x_{i'}) = \sum_{j=1}^p w_j \bar{d}_j$$

的相对贡献, 其中

$$\bar{d}_j = \frac{1}{N^2} \sum_{i=1}^N \sum_{i'=1}^N d_j(x_{ij}, x_{i'j}) \quad (22.25)$$

是第 j 个属性上的平均不相似度。故第 j 个变量的相对影响是 $w_j \bar{d}_j$, 取 $w_j \sim 1/\bar{d}_j$ 会给所有属性相等影响。例如 p 个定量变量都用平方误差距离时, (22.24) 成为 (加权) 平方欧氏距离

$$D_I(x_i, x_{i'}) = \sum_{j=1}^p w_j (x_{ij} - x_{i'j})^2, \quad (22.26)$$

此时 (22.25) 成为

$$\bar{d}_j = \frac{1}{N^2} \sum_{i=1}^N \sum_{i'=1}^N (x_{ij} - x_{i'j})^2 = 2 \text{var}_j, \quad (22.27)$$

其中 var_j 是 $\text{Var}(X_j)$ 的样本估计。故每个这类变量的相对重要性与其在数据上的方差成正比。

一般而言取 $w_j = 1/\bar{d}_j$ (不论属性类型) 会使每个属性对对象间整体不相似度有相等影响。这看似合理也常被推荐, 但可能适得其反: 若目标是分割成相似对象的组, 所有属性未必对「不相似度」这一 (问题相关的) 概念贡献相同——某些属性值差异可能反映实际问题域中更大的对象不相似度。若目标是发现数据中的自然分组, 有些属性可能比别的更有分组倾向, 对更相关的分离变量应赋予更高影响。给所有属性相等影响会掩盖分组, 使聚类算法无法发现它们 (图 22.5: 先标准化后, 原本分离良好的两簇被掩盖)。

尽管给出选择单个属性不相似度 d_j 及其权重 w_j 的通用处方令人安心, 但没有替代每个具体问题中的仔细思考。指定合适的相似度度量对聚类成败的重要性远超聚类算法的选择——这一点在聚类文献中受到的重视远不如算法本身, 因为它依赖具体领域知识、不易做一般化研究。

最后, 观测常在部分属性上缺失。在 (22.24) 中纳入缺失值的最常用方法是: 计算两观测间不相似度时, 省略至少一个值缺失的观测对 $x_{ij}, x_{i'j}$ 。当两观测无共同测量值时此法失效, 此时可删去这两个观测, 或用各属性非缺失数据的均值/中位数插补。对分类变量, 若「两对象在同一变量上都缺失」视为相似是合理的, 则把「缺失」当作一个额外分类值。




图 22.5: 模拟数据 (书中图 14.5 的示意): 左图对原始数据做 K-means ($K = 2$), 两簇分离良好; 右图先标准化再聚类 (等价于特征权重 $1/[2 \text{Var}(X_j)]$), 标准化掩盖了分离良好的两簇。

22.3.4 聚类算法

聚类分析的目标是把观测划分成组 (簇), 使分到同簇的观测对间不相似度趋于小于不同簇的。聚类算法分三类:

组合算法 (combinatorial algorithms): 直接处理观测, 不参照任何潜在概率模型;

混合建模 (mixture modeling): 假定数据是某个密度函数描述总体的 i.i.d. 样本, 该密度由参数化模型刻画为若干成分密度的混合, 每个成分描述一个簇, 用极大似然或相应贝叶斯方法拟合;

众数寻找 (mode seekers, 即 bump hunters): 非参数视角, 直接估计密度函数的相异众数, 「最靠近」各众数的观测构成各簇。

混合建模见第 6.8 节; PRIM (第 9.3 节与 §14.2.5) 是众数寻找的例子。下面讨论组合算法。

22.3.5 组合算法

最流行的聚类算法直接把每个观测分到一个组或簇, 不参照描述数据的概率模型。每个观测用整数 $i \in \{1, \dots, N\}$ 唯一标记; 预先给定簇数 $K < N$, 每个簇用整数 $k \in \{1, \dots, K\}$ 标记。每个观测恰好分到一个簇, 这可由多对一映射 (编码器) $k = C(i)$ 刻画。目标是基于观测对不相似度 $d(x_i, x_{i'})$ (由用户按前述方法给定) 寻找达到目标的

特定编码器 $C^*(i)$ 。编码器 $C(i)$ 通常显式给出每个观测的簇指派，故该过程的「参数」就是 N 个观测各自的簇指派，通过最小化刻画聚类目标未达成程度的损失函数来调整。

一种做法是直接指定数学损失函数并做组合优化。由于目标是把相近的点分到同簇，自然的损失（或「能量」）函数是

$$W(C) = \frac{1}{2} \sum_{k=1}^K \sum_{C(i)=k} \sum_{C(i')=k} d(x_i, x_{i'}), \quad (22.28)$$

刻画同簇观测彼此接近的程度，称为「组内点散布」(within-cluster point scatter)。记 $d_{ii'} = d(x_i, x_{i'})$ ，则总点散布

$$T = \frac{1}{2} \sum_{i=1}^N \sum_{i'=1}^N d_{ii'} = \frac{1}{2} \sum_{k=1}^K \sum_{C(i)=k} \left(\sum_{C(i')=k} d_{ii'} + \sum_{C(i') \neq k} d_{ii'} \right) = W(C) + B(C),$$

其中 T 对给定数据是常数、与簇指派无关，而

$$B(C) = \frac{1}{2} \sum_{k=1}^K \sum_{C(i)=k} \sum_{C(i') \neq k} d_{ii'} \quad (22.29)$$

是「组间点散布」——不同簇的观测相距越远越大。于是 $W(C) = T - B(C)$ ，最小化 W 等价于最大化 B 。

组合优化的聚类分析原理上直接：在 N 个点分到 K 簇的所有可能指派上最小化 W （等价最大化 B ）。遗憾的是完全枚举只对极小数据可行——不同指派数（Jain and Dubes, 1988）为

$$S(N, K) = \frac{1}{K!} \sum_{k=1}^K (-1)^{K-k} \binom{K}{k} k^N. \quad (22.30)$$

例如 $S(10, 4) = 34,105$ 尚可行，但 $S(N, K)$ 随参数增长极快， $S(19, 4) \simeq 10^{10}$ ，而多数聚类问题的数据远超 $N = 19$ 。因此实际算法只能考察全部编码器的极小一部分，目标是找到很可能包含最优解的小子集，或至少一个好的次优划分。

可行策略基于**迭代贪婪下降**：先给定初始划分，每步按某种规则修改簇指派使准则值改善；当规则无法再改进时终止，以当前指派为解。这类算法的差异在于每步修改指派的处方不同。由于每步指派都是上一步的扰动，只考察了全部指派（(22.30)）的很小一部分；但这类算法收敛到**局部最优**，相对全局最优可能严重次优。

22.3.6 K-means

K-means 是最流行的迭代下降聚类方法之一，适用于所有变量均为定量且不相似度取平方欧氏距离

$$d(x_i, x_{i'}) = \sum_{j=1}^p (x_{ij} - x_{i'j})^2 = \|x_i - x_{i'}\|^2$$

的情形（加权欧氏距离可通过重新定义 x_{ij} 实现，练习 14.1）。

组内点散布 ((22.28)) 可写为

$$W(C) = \frac{1}{2} \sum_{k=1}^K \sum_{C(i)=k} \sum_{C(i')=k} \|x_i - x_{i'}\|^2 = \sum_{k=1}^K N_k \sum_{C(i)=k} \|x_i - \bar{x}_k\|^2, \quad (22.31)$$

其中 $\bar{x}_k = (\bar{x}_{1k}, \dots, \bar{x}_{pk})$ 是第 k 簇的均值向量, $N_k = \sum_{i=1}^N I(C(i) = k)$ 。于是准则最小化等价于把 N 个观测分到 K 簇, 使每簇内观测与簇均值的平均不相似度最小。

求解 (22.31) 的迭代下降算法基于两个事实。首先, 对任意观测集合 S , 其均值是平方距离和的最小元:

$$\bar{x}_S = \arg \min_m \sum_{i \in S} \|x_i - m\|^2, \quad (22.32)$$

故 $C^* = \min_C \sum_{k=1}^K N_k \sum_{C(i)=k} \|x_i - \bar{x}_k\|^2$ 可通过求解扩大后的优化问题

$$\min_{C, \{m_k\}} \sum_{k=1}^K N_k \sum_{C(i)=k} \|x_i - m_k\|^2 \quad (22.33)$$

得到, 而它可由 Algorithm 14.1 的交替优化过程最小化, 其中分配步为

$$C(i) = \arg \min_{1 \leq k \leq K} \|x_i - m_k\|^2. \quad (22.34)$$

Algorithm 2 K-means 聚类 (Algorithm 14.1)

- 1: 给定簇指派 C , 总簇方差 ((22.33)) 关于 $\{m_1, \dots, m_K\}$ 最小化, 得到当前指派簇的均值 ((22.32))
 - 2: 给定当前均值集 $\{m_1, \dots, m_K\}$, (22.33) 通过把每个观测指派到最近 (当前) 簇均值 ((22.34)) 最小化
 - 3: 重复步骤 1、2 直到指派不再改变
-

步骤 1、2 都降低准则 ((22.33)), 故收敛有保证; 但结果可能是次优的局部极小。Hartigan and Wong (1979) 的算法更进一步, 保证不存在「把某观测从一组换到另一组能使目标下降」的单次切换; 此外应从多个不同随机起始均值出发, 取目标函数最小的解。

图 14.6 (书中) 展示图 14.4 模拟数据的若干 K-means 迭代: 质心用「O」表示, 直线刻画点的分割——每个扇区是离该质心最近的点集, 即 **Voronoi 剖分** (Voronoi tessellation)。约 20 次迭代后收敛。

22.3.7 高斯混合作为软 K-means

K-means 与估计某类高斯混合模型的 EM 算法密切相关 (第 6.8 节与第 8.5.1 节)。EM 的 **E** 步根据每个数据点在每个混合成分下的相对密度赋予「责任」(responsibility),

M 步根据当前责任重新计算成分密度参数。若指定 K 个混合成分、每个都是标量协方差 $\sigma^2 I$ 的高斯密度，则数据点在每个成分下的相对密度是它到混合中心的欧氏距离的单调函数——于是此设定下 EM 是 K-means 的「软」版本：对点进行概率性（而非确定性）的簇中心指派。当方差 $\sigma^2 \rightarrow 0$ 时这些概率趋于 0 或 1，两方法重合（练习 14.2）。

注记 22.13 (责任与硬/软指派). 图 14.7（书中）展示实线上两个高斯密度 $g_0(x)$ 、 $g_1(x)$ （蓝、橙）与单个数据点（ $x = 0.5$ ，绿点）。右图画出相对密度 $g_0/(g_0 + g_1)$ 与 $g_1/(g_0 + g_1)$ ——即各簇对该点的「责任」。上方 $\sigma = 1.0$ 时责任可接近 0.5（实际为 0.36 与 0.64）；当 $\sigma \rightarrow 0$ ，责任趋于 1（对最近簇中心）与 0（对其余）——这就是「硬」指派（右下图）。

22.3.8 示例：人类肿瘤微阵列数据

把 K-means 应用于第 1 章的人类肿瘤微阵列数据——一个高维聚类例子。数据是 6830×64 实数矩阵，每个元素是基因（行）与样本（列）的表达测量。这里对样本聚类，每个样本是长 6830 的向量（对应 6830 个基因的表达值）。每个样本带标签（如 breast 乳腺癌、melanoma 黑色素瘤等）；聚类时不用这些标签，聚类后再检查各簇落入哪些标签。

对 $K = 1, \dots, 10$ 运行 K-means 并计算每次的总组内平方和（图 14.8）。通常从平方和曲线（或其对数）找拐点（kink）定位最优簇数（见 §14.3.11）；此处曲线无明确指示，为便于说明选 $K = 3$ ，得到表 22.2 的三簇。

表 22.2: 人类肿瘤数据：K-means 三簇中各类癌症的病例数（节选）。

簇	Breast	CNS	Colon	K562	Leukemia	MCF7
1	3	5	0	0	0	0
2	2	0	0	2	6	2
3	2	0	7	0	0	0

该过程成功把同种癌症的样本聚在一起；事实上第 2 簇中的两个乳腺癌后来被发现是误诊——是已转移的黑色素瘤。但 K-means 在此应用有不足：其一，不给出簇内对象的线性排序；其二，簇数 K 改变时簇成员关系可能任意变化（如取四簇时未必嵌套在三簇内）。因此层次聚类（后述）可能更适合此应用。

22.3.9 向量量化

K-means 在看似无关的图像与信号压缩领域是核心工具，尤其向量量化（vector quantization, VQ; Gersho and Gray, 1992）。图 14.9（书中）是著名统计学家 Sir Ronald A. Fisher 的照片：左图为 1024×1024 灰度图（每像素 0–255，8 位），整图约 1 MB；中

图为 VQ 压缩版 (约原始 0.239 的存储, 质量略损); 右图压缩更甚 (约 0.0625, 质量损失大)。

此处 VQ 的实现先把图像切成小块 (2×2 像素块), 每个 512×512 的 4 数块视作 $\mathbb{R}^4$ 中的向量, 再在此空间运行 K-means (此语境下也称 **Lloyd 算法**)。中图 $K = 200$ 、右图 $K = 4$ 。每个像素块由其最近的簇质心近似, 质心称**码字** (codeword); 聚类过程称**编码步**, 质心集合称**码本** (codebook)。

重建近似图像需对每块提供码本条目标识: 每块 $\log_2(K)$ 位, 另加码本本身 ($K \times 4$ 个实数, 通常可忽略)。压缩存储为原始的 $\log_2(K)/(4 \cdot 8)$ ($K = 200$ 时 0.239, $K = 4$ 时 0.063), 常表示为每像素位数 $\log_2(K)/4$ (分别为 1.91 与 0.50)。从质心构造近似图像的过程称**解码步**。

注记 22.14 (VQ 为什么有效). 对日常图像, 许多块看起来相同 (大量近纯白块、各种灰度的纯灰块), 每类只需一个块表示, 再用多个指针指向它即可。

这属于**有损压缩**, 失真通常用均方误差度量: $D = 0.89$ ($K = 200$)、 $D = 16.95$ ($K = 4$)。更一般用率/失真曲线评估权衡。也可做基于块聚类的**无损压缩**并利用重复模式——对原图无损压缩最好也只需 4.48 bits/pixel。

用 $\log_2(K)$ 位标识码本是**定长码**; 若某些码字出现远多于其他, 可用**变长码**更高效 (Shannon 编码理论), 率变为 $-\sum_{\ell=1}^K p_\ell \log_2(p_\ell)/4$ (分子是码字分布 p_ℓ 的熵)。用变长码后率降至 1.42 与 0.39。VQ 还有多种推广: 如**树结构化 VQ** 用自上而下的 2-means 式算法 (见 §14.3.12), 实现压缩的逐级细化。

22.3.10 K-medoids

K-means 适用于不相似度为平方欧氏距离 $D(x_i, x_{i'}) = \|x_i - x_{i'}\|^2$ 的情形 (需全部定量变量), 且平方距离给**最大距离最高影响**——这使过程对产生巨大距离的**异常值缺乏稳健性**。这些限制可以 (以计算为代价) 去除。

K-means 中唯一假设平方欧氏距离的部分是极小化步 ((22.32)): (22.33) 中的簇代表 $\{m_1, \dots, m_K\}$ 取当前簇的均值。对任意定义的不相似度 $D(x_i, x_{i'})$, 把该步换成对 $\{m_k\}$ 的显式优化即可推广。最常见的形式是限制每簇中心为该簇的一个观测, 见 Algorithm 14.2。该算法假定属性数据, 但也适用于仅由邻近矩阵 (§14.3.1) 描述的数据——无需显式计算簇中心, 只需记录索引 i_k^* 。

$$i_k^* = \arg \min_{\{i: C(i)=k\}} \sum_{C(i')=k} D(x_i, x_{i'}), \quad (22.35)$$

$$C(i) = \arg \min_{1 \leq k \leq K} D(x_i, m_k), \quad (22.36)$$

Algorithm 3 K-medoids 聚类 (Algorithm 14.2)

- 1: 给定簇指派 C , 找簇内到其他点总距离最小的观测 ((22.35)), 于是 $m_k = x_{i_k^*}$, $k = 1, \dots, K$ 为当前簇中心估计
- 2: 给定当前簇中心 $\{m_1, \dots, m_K\}$, 把每个观测指派到最近的 (当前) 簇中心 ((22.36)) 以最小化总误差
- 3: 重复步骤 1、2 直到指派不再改变

求解 (22.32) 每个临时簇 k 需要正比于簇内观测数的计算, 而求解 (22.35) 计算增至 $O(N_k^2)$ 。给定簇中心集 $\{i_1, \dots, i_K\}$ 后求新指派

$$C(i) = \arg \min_{1 \leq k \leq K} d_{i i_k^*}, \quad (22.37)$$

需要正比于 $K \cdot N$ 的计算。故 K-medoids 远比 K-means 计算密集。

在 (22.35) 与 (22.37) 间交替是对求解

$$\min_{C, \{i_k\}} \frac{1}{K} \sum_{k=1}^K \sum_{C(i)=k} d_{i i_k} \quad (22.38)$$

的一种特定启发式搜索。Kaufman and Rousseeuw (1990) 提出直接求解 (22.38) 的替代策略: 临时把每个中心 i_k 与当前非中心的观测交换, 选使准则 ((22.38)) 下降最大的交换, 重复直到无有利交换。Massart et al. (1983) 导出求 (22.38) 全局最小的分支定界组合方法, 但仅对很小数据集实用。

例 22.8 (国家不相似性 (表 22.3))。例子取自 Kaufman and Rousseeuw (1990): 让政治学学生给 12 个国家两两提供不相似度评分 (比利时、巴西、智利、古巴、埃及、法国、印度、以色列、美国、苏联、南斯拉夫、扎伊尔), 表 22.3 是平均不相似度。对之做 3-medoid 聚类 (注意: 只有距离而无原始观测, K-means 无法应用)。图 14.10 (书中) 左图为按 3-medoid 聚类重排分块的不相似度; 右图为二维多维缩放 (MDS, §14.8) 图、用颜色标出 3-medoid 簇。两图都显示三个分离良好的簇, 但 MDS 显示「Egypt」约落在两簇之间。

22.3.11 实际问题

应用 K-means 或 K-medoids 需选择簇数 K^* 与初始化。初始化可通过指定初始中心集 $\{m_1, \dots, m_K\}$ (或 $\{i_1, \dots, i_K\}$) 或初始编码器 $C(i)$ 定义, 通常指定中心更方便。建议从简单随机选择到基于前向逐步指派的刻意策略: 每一步在给定前 $k-1$ 步所选中心下选使准则 ((22.33) 或 (22.38)) 最小的新中心 i_k , 如此进行 K 步得到 K 个初始中心。

簇数 K 的选择取决于目标:

表 22.3: 政治学调查数据：学生对 12 国两两不相似度的平均评分。

	BEL	BRA	CHI	CUB	EGY	FRA	IND	ISR	USA	USS	YUG
BRA	5.58										
CHI	7.00	6.50									
CUB	7.08	7.00	3.83								
EGY	4.83	5.08	8.17	5.83							
FRA	2.17	5.75	6.67	6.92	4.92						
IND	6.42	5.00	5.58	6.00	4.67	6.42					
ISR	3.42	5.50	6.42	6.42	5.00	3.92	6.17				
USA	2.50	4.92	6.25	7.33	4.50	2.25	6.33	2.75			
USS	6.08	6.67	4.25	2.67	6.00	6.17	6.17	6.92	6.17		
YUG	5.25	6.83	4.50	3.75	5.75	5.42	6.08	5.83	6.67	3.67	
ZAI	4.75	3.00	6.08	6.67	5.00	5.58	4.83	6.17	5.67	6.50	6.92

- **数据分割：** K 通常是问题的一部分（如公司雇 K 名销售、把客户库分成 K 段、每名销售一段，段内客户尽可能相似）；
- **描述统计：**常用来判断数据是否落在自然相异分组中，此时 K^* 未知、需连同分组本身一起从数据估计。

基于数据的 K^* 估计方法通常考察组内不相似度 W_K 随簇数 K 的变化：对 $K \in \{1, \dots, K_{\max}\}$ 分别求解，得 $\{W_1, \dots, W_{K_{\max}}\}$ ，一般随 K 增加而减小——即使在独立测试集上评估也如此（大量簇中心会稠密填满特征空间、靠近所有数据点），故监督学习中常用的交叉验证在此不适用。

直觉：若确实有 K^* 个相异分组，则 $K < K^*$ 时算法返回的簇各含真实底层组的一个子集，准则值会随指定簇数每次增加而大幅下降（ $W_{K+1} \ll W_K$ ，自然组被逐一分到不同簇）； $K > K^*$ 时某个估计簇必把至少一个自然组切成两部分，其准则下降更小（切分内部紧密的自然组不如把两个分离组正确分开）。于是 $K = K^*$ 处准则的连续差分 $W_K - W_{K+1}$ 出现骤降：

$$\{W_K - W_{K+1} \mid K < K^*\} \gg \{W_K - W_{K+1} \mid K \geq K^*\}.$$

由此在 W_K 对 K 的图中找「拐点」(kink) 估计 $\hat{K}^*$ ——与其他聚类环节一样，此法有些启发式。

新近提出的 **Gap 统计量** (Tibshirani et al., 2001b) 把 $\log W_K$ 曲线与覆盖数据的矩形上均匀分布数据的曲线比较，在两条曲线差距最大处估计最优簇数——本质是自动定位上述「拐点」。它在数据落入单簇时也表现良好（此时估计最优簇数为 1），而这正是多数其他方法失效的场景。

注记 22.15 (Gap 统计量的形式规则). 图 14.11 (书中) 是 Gap 统计量应用于图 14.4 模拟数据的结果：左图为 $K = 1, \dots, 8$ 的 $\log W_K$ (绿) 与 20 次均匀数据模拟的期望

$\log W_K$ (蓝); 右图为 Gap 曲线 (期望减观测), 并带半宽 $s'_K = s_K \sqrt{1 + 1/20}$ (s_K 为 20 次模拟的 $\log W_K$ 标准差)。Gap 曲线在 $K = 2$ 处最大。设 $G(K)$ 为 K 簇时的 Gap 值, 估计 K^* 的形式规则是

$$K^* = \arg \min_K \{K \mid G(K) \geq G(K+1) - s'_{K+1}\}, \quad (22.39)$$

本例给出 $K^* = 2$, 从图 14.4 看是合理的。

22.3.12 层次聚类

K-means / K-medoids 的结果依赖所选簇数与起始指派; **层次聚类**则无需这些指定, 而是要求用户指定 (不相交) 观测组间的**不相相似度量** (基于两组中观测的两两不相相似度)。它产生层次表示: 层次每一层的簇由合并下一层的簇得到——最低层每簇含单个观测, 最高层只有一簇含全部数据。

层次聚类策略分两种基本范式:

凝聚 (agglomerative, 自下而上) : 从底部开始, 每层递归地把选中的一对簇合并成一簇 (组间不相相似度最小的两簇), 得到少一个簇的上一层次分组;

分裂 (divisive, 自上而下) : 从顶部开始, 每层递归地把现有簇之一分裂成两个新簇, 选使两组间不相相似度最大的分裂。

两种范式都有 $N - 1$ 层。

层次每一层代表数据的一个特定分组 (不相交簇), 整个层次是有序分组序列; 由用户决定哪一层真正代表「自然」聚类 (可用前述 Gap 统计量判断)。

递归二分/凝聚可用**有根二叉树**表示: 节点代表组, 根节点是全部数据, N 个终结点各代表一个观测 (单例簇); 每个非终结 (父) 节点有两个子节点——分裂聚类中两子节点是父分裂所得的两组, 凝聚聚类中两子节点是被合并成父的两组。

多数凝聚 (及一些自下而上看的分裂) 方法有**单调性**: 被合并簇间的不相似度随合并层次单调递增。于是可画树使每个节点的高度正比于其两子节点间的组间不相相似度, 终结点高度为零——这种图称**树状图** (dendrogram)。树状图以图形化方式给出层次聚类的完整可解释描述, 是层次聚类流行的重要原因。

图 14.12 (书中) 是平均链接凝聚聚类对微阵列数据的树状图。在特定高度**横向切割**树状图, 把数据分成由与切割线相交的竖线代表的若干不相交簇——即当最优组间不相相似度超过该阈值时终止过程的簇。相对其下层子组合并值而言在**高值处合并**的组是自然簇的候选; 注意这可能在多个层次发生, 表明聚类层次 (簇内嵌簇)。树状图常被视为数据本身的图形摘要而非算法结果的描述, 但应谨慎: 不同层次方法或数据的微小变化会得到很不同的树状图, 且摘要只在两两观测不相相似度确实具有算法产生的层次结构时有效——层次方法**无论数据中是否真的存在层次结构都会强加**。

树状图产生的层次结构在多大程度上真正代表数据, 可用**共表型相关系数** (cophenetic correlation coefficient) 判断: 它是输入算法的 $N(N - 1)/2$ 个两两观测不相相似度

$d_{ii'}$ 与由树状图导出的**共表型不相似度** $C_{ii'}$ 的相关系数, 其中 $C_{ii'}$ 是观测 i, i' 首次被合并进同一簇时的组间不相似度。

注记 22.16 (共表型不相似度是非常受限的度量). 第一, $C_{ii'}$ 必含大量重复值—— $N(N-1)/2$ 个值中只有 $N-1$ 个可相异; 第二, 它满足**超度量不等式** (ultrametric inequality)

$$C_{ii'} \leq \max\{C_{ik}, C_{i'k}\} \quad (22.40)$$

对任意三个观测 (i, i', k) 成立。几何上, 若数据是欧氏坐标点, 要使点间距离满足 (22.40), 任意三点组成的三角形必须是**等腰三角形**, 且不等的边长不超过两等边长 (Jain and Dubes, 1988)。因此一般数据的不相似度不太可能接近其树状图共表型不相似度 (尤其当重复值不多时)。故树状图主要应视为特定算法强加于数据的聚类结构的描述。

凝聚聚类

凝聚聚类算法从每个观测代表一个单例簇开始, 在 $N-1$ 步中每步把**最接近** (最不相似) 的两簇合并成一簇, 在上层少一个簇。因此需定义两簇 (观测组) 间的不相似度量。

设 G, H 为两组, 其不相似度 $d(G, H)$ 由一组两两观测不相似度 $d_{ii'} (i \in G, i' \in H)$ 计算。三种最常用的组间不相似度:

$$d_{SL}(G, H) = \min_{\substack{i \in G \\ i' \in H}} d_{ii'}, \quad \text{单链接 (single linkage, 最近邻)} \quad (22.41)$$

$$d_{CL}(G, H) = \max_{\substack{i \in G \\ i' \in H}} d_{ii'}, \quad \text{完全链接 (complete linkage, 最远邻)} \quad (22.42)$$

$$d_{GA}(G, H) = \frac{1}{N_G N_H} \sum_{i \in G} \sum_{i' \in H} d_{ii'}, \quad \text{组平均 (group average)} \quad (22.43)$$

其中 N_G, N_H 是各组的观测数。图 14.13 (书中) 展示三种链接的树状图。

若数据不相似度 $\{d_{ii'}\}$ 呈现强聚类倾向、各簇紧凑且彼此分离, 则三种方法结果相似; 否则结果会不同。

单链接 ((22.41)) 只要有一对 $d_{ii'}$ 小就认为两簇接近, 因此在相对低的阈值处会把由一连串接近的中间观测连接起来的观测合并——这种**链式效应** (chaining) 常被视为缺陷。它产生的簇可违反「紧凑性」(簇内所有观测彼此相似)。若定义观测组直径 D_G 为其成员最大不相似度

$$D_G = \max_{\substack{i \in G \\ i' \in G}} d_{ii'}, \quad (22.44)$$

则单链接可产生直径很大的簇。

完全链接 ((22.42)) 是相反极端: 仅当并集内所有观测都相对相似时两簇才接近, 倾向于产生直径 ((22.44)) 小的紧凑簇; 但可违反「接近性」——簇内观测可能比对自己的某些成员更接近其他簇的成员。

组平均 ((22.43)) 是两极端间的折中, 试图产生相对紧凑且彼此相对远的簇; 但其结果依赖观测不相似度 $d_{ii'}$ 的**数值尺度**——对 $d_{ii'}$ 施加严格单调增变换 $h(\cdot)$ 、 $h_{ii'} = h(d_{ii'})$, 会改变 ((22.43)) 的结果; 而 ((22.41)) 与 ((22.42)) 只依赖 $d_{ii'}$ 的**排序**、对该类单调变换不变。这种不变性常被用作支持单/完全链接而非组平均的论据。

也可论证组平均有单/完全链接缺乏的**统计一致性**: 设属性值数据 $X^T = (X_1, \dots, X_p)$ 、每个簇 k 是某总体联合密度 $p_k(x)$ 的随机样本, 完整数据是 K 个这种密度的混合随机样本。组平均不相似度 $d_{GA}(G, H)$ ((22.43)) 估计

$$\iint d(x, x') p_G(x) p_H(x') dx dx', \quad (22.45)$$

其中 $d(x, x')$ 是属性值空间中点 x, x' 间的不相似度。样本量 $N \rightarrow \infty$ 时 $d_{GA}(G, H)$ ((22.43)) 趋于 ((22.45)) (两密度 p_G, p_H 关系的特征); 而单链接 $d_{SL} \rightarrow 0$ 、完全链接 $d_{CL} \rightarrow \infty$, 都与两密度无关——故 d_{SL}, d_{CL} 究竟在估计总体的什么方面并不清楚。

例 22.9 (人类癌症微阵列 (续)). 图 14.13 (书中) 左图是平均链接对微阵列样本的树状图, 中、右图是完全、单链接。平均与完全链接结果相似; 单链接产生不平衡的细长簇。平均链接聚类与 K-means 一样能把同类癌症聚在一起, 且有两个优点: 不同高度切割树状图得到不同簇数、且簇集合**彼此嵌套**; 还给出样本的部分**排序信息**。图 14.14 把表达矩阵的行 (基因) 与列 (样本) 按层次聚类导出的排序重排。若翻转树状图任一合并处的分支, 仍与层次聚类操作序列一致, 故确定叶序需加约束——S-PLUS 默认规则: 每次合并时较紧的子树放左边 (图 14.14 中旋转树状图里靠下), 单个基因是最紧簇、两基因合并按观测号排序; 也可用其他规则 (如按基因的 MDS 排序, §14.8)。这种**双向重排**比第 1 章图 1.3 的随机行列更有信息量, 树状图本身也有用 (生物学家可据生物学过程解释基因簇)。

分裂聚类

分裂聚类算法从整个数据集作为单簇开始, 每次迭代**自上而下**地递归把现有簇之一分成两个子簇。它在聚类文献中远不如凝聚方法研究充分, 但在工程文献 (Gersho and Gray, 1992) 中作为压缩手段被探索; 在聚类设定中, 当兴趣聚焦于把数据分成**相对少量**簇时, 分裂可能优于凝聚。

分裂范式可通过对组合方法 (如 K-means §14.3.6、K-medoids §14.3.10) 递归应用 $K = 2$ 来执行分裂。但此法依赖每步指定的起始配置, 且未必产生树状图表示所需的**单调性**。

Macnaughton Smith et al. (1965) 提出避免这些问题的分裂算法: 先把所有观测放入单簇 G , 选出**到其余观测平均不相似度最大的观测**作为第二个簇 H 的首个成员; 之后每步把 G 中「到 H 的平均距离减去到 G 剩余观测的平均距离」**最大的观测**转入 H , 直到该平均差为负 (G 中不再有平均上更靠近 H 的观测), 得到 G 分裂成两个子簇——即层次第二层; 每层对上一层某簇应用此分裂过程。Kaufman and Rousseeuw (1990) 建

议每层选直径 ((22.44)) 最大的簇分裂；也可选成员平均不相似度

$$\bar{d}_G = \frac{1}{N_G^2} \sum_{i \in G} \sum_{i' \in G} d_{ii'}$$

最大的簇。递归分裂持续到所有簇成为单例或簇内成员彼此零不相似度。

22.4 自组织映射

自组织映射 (self-organizing maps, SOM) 可视为 **K-means** 的约束版本：原型被鼓励落在特征空间的一个一维或二维流形上。所得流形也称**约束拓扑图** (constrained topological map)，因为原始高维观测可映射到二维坐标系。原版 SOM 是**在线的** (观测逐个处理)，后有**批次**版本。它也与下一节的主曲线/主曲面密切相关。

考虑 K 个原型 $m_j \in \mathbb{R}^p$ 排成二维矩形网格 (也可用六边形等)。每个原型用整数坐标对 $\ell_j \in Q_1 \times Q_2$ 参数化，其中 $Q_1 = \{1, \dots, q_1\}$ 、 $Q_2 = \{1, \dots, q_2\}$ 、 $K = q_1 q_2$ 。 m_j 初始化为位于数据的主成分平面 (下一节) 上——可把原型想成「按钮」规则地「缝」在主成分平面上，SOM 过程试着弯曲平面使按钮尽可能逼近数据点。模型拟合后，观测可映射到二维网格上。

观测 x_i 逐个处理：找在 $\mathbb{R}^p$ 欧氏距离下离 x_i 最近的原型 m_j ，然后对所有 m_j 的「邻居」 m_k ，按

$$m_k \leftarrow m_k + \alpha (x_i - m_k) \quad (22.46)$$

把 m_k 移向 x_i 。 m_j 的「邻居」定义为所有使 ℓ_j 与 ℓ_k 间距离小的 m_k ：最简单用欧氏距离，「小」由阈值 r 决定，邻域总含最近原型 m_j 本身。

注意距离定义在整数**拓扑坐标空间** $Q_1 \times Q_2$ 中，而非特征空间 $\mathbb{R}^p$ 。更新 ((22.46)) 的效果既使原型移向数据，也保持原型间**光滑的二维空间关系**。

SOM 性能取决于学习率 α 与距离阈值 r 。通常 α 在几千次迭代 (每次一个观测) 中从约 1.0 线性降到 0.0， r 从起始值 R 线性降到 1。更精细的版本按距离修改更新步：

$$m_k \leftarrow m_k + \alpha h(\|\ell_j - \ell_k\|) (x_i - m_k), \quad (22.47)$$

其中邻域函数 h 给索引 ℓ_k 更靠近 ℓ_j 的原型更大权重。

注记 22.17 (SOM 与 K-means 的关系). 若把距离 r 取到每个邻域只含一个点，原型间的空间联系丢失——此时可证明 SOM 算法是 K-means 的**在线版本**，最终稳定于 K-means 的某个局部极小。由于 SOM 是 K-means 的约束版本，需检查约束在具体问题中是否合理：可对两种方法计算重建误差 $\|x - m_j\|^2$ (对所有观测求和)，K-means 必然更小，但若 SOM 是合理近似则不应小太多。

例 22.10 (半球的模拟数据). 生成 90 个三维数据点，靠近半径 1 的半球表面，分属三簇 (红、绿、蓝)，中心分别在 (0, 1, 0)、(0, 0, 1)、(1, 0, 0) 附近 (图 14.15；数据生成细

节见练习 14.5)。红色簇刻意比绿、蓝更紧。用 5×5 原型网格，初始网格半径 $R = 2$ (约三分之一原型最初在各自邻域内)，对 90 个观测共做 40 遍， r 与 α 在 3600 次迭代中线性下降。图 14.16 中圆圈表示原型、投影到各原型的点随机画在对应圆内：左图为初始、右图为最终配置。算法成功分离了簇；但红色簇的分离表明流形折叠回自身（图 14.17），且由于二维显示中不使用距离，SOM 投影没有表明红色簇比其他更紧。

图 14.18 显示重建误差（每个数据点绕其原型的总平方和），并对比 25 个质心的 K-means（水平线）。SOM 显著降低误差、几乎达到 K-means 水平——说明二维约束对该数据集是合理的。

批次版本：更新每个 m_j 为

$$m_j = \frac{\sum w_k x_k}{\sum w_k}, \quad (22.48)$$

其中求和覆盖映射到 m_j 的邻居 m_k 的点 x_k ；权重函数可为矩形（对 m_k 的邻居取 1）或随距离 $\|\ell_k - \ell_j\|$ 平滑下降。若邻域大小小到只含 m_k 且矩形权重，则退化为前述 K-means；它也可视为 §14.5 主曲线/主曲面的离散版本。

例 22.11 (文档组织与检索 (WEBSOM)). 文档检索随互联网迅速发展而重要，SOM 对组织与索引大型语料很有用。例子取自 WEBSOM 主页 (Kohonen et al., 2000)：图 14.19 是对 12,088 篇新闻组 comp.ai.neural-nets 文章的 SOM，标签由 WEBSOM 软件自动生成、指示节点的典型内容。此类应用中文档需预处理成特征向量：构造词-文档矩阵，每行是一篇文档，行内是预定词集的相对频率（词集可为约 5 万词的字典条目、甚至更大的二元组集合或其子集）。矩阵通常极稀疏，常预处理降维（列数），有时用 SVD（下一节）降维，Kohonen 等用其随机化变体；降维后的向量作为 SOM 输入。作者还开发「缩放」功能交互查看地图细节，最末层缩放可检索实际新闻文章。

22.5 主成分、主曲线与主曲面

主成分已在第 3.4.1 节讨论（那里揭示了岭回归的收缩机制）。主成分是数据的一列互不相关、按方差排序的投影。下一小节把主成分作为逼近 N 个点 $x_i \in \mathbb{R}^p$ 的线性流形来呈现，§14.5.2 给出一些非线性推广，§14.9 讨论其他非线性逼近流形的新近提案。

22.5.1 主成分

$\mathbb{R}^p$ 中一组数据的主成分给出该数据在所有秩 $q \leq p$ 上的最佳线性逼近序列。记观测为 $x_1, x_2, \dots, x_N$ ，考虑表示它们的秩- q 线性模型

$$f(\lambda) = \mu + V_q \lambda, \quad (22.49)$$

其中 μ 是 $\mathbb{R}^p$ 中的位置向量， V_q 是 $p \times q$ 矩阵（ q 个正交单位向量为列）， λ 是 q 维参数向量——这是秩 q 仿射超平面的参数表示（图 14.20/14.21 分别示意 $q = 1, 2$ ）。用最小

二乘拟合该模型等价于最小化重建误差

$$\min_{\mu, \{\lambda_i\}, V_q} \sum_{i=1}^N \|x_i - \mu - V_q \lambda_i\|^2. \quad (22.50)$$

对 μ 与 λ_i 部分优化 (练习 14.7) 得

$$\hat{\mu} = \bar{x}, \quad \hat{\lambda}_i = V_q^T (x_i - \bar{x}), \quad (22.51)$$

剩下只需找正交矩阵 V_q :

$$\min_{V_q} \sum_{i=1}^N \|(x_i - \bar{x}) - V_q V_q^T (x_i - \bar{x})\|^2. \quad (22.52)$$

为方便设 $\bar{x} = 0$ (否则先中心化 $\tilde{x}_i = x_i - \bar{x}$)。 $p \times p$ 矩阵 $H_q = V_q V_q^T$ 是投影矩阵, 把每个点 x_i 映到其秩- q 重建 $H_q x_i$ (x_i 到 V_q 列张成子空间的正交投影)。

把 (中心化的) 观测排成 $N \times p$ 矩阵 X 的行, 作奇异值分解 (SVD)

$$X = U D V^T. \quad (22.53)$$

其中 U 是 $N \times p$ 正交矩阵 ($U^T U = I_p$), 其列 u_j 称左奇异向量; V 是 $p \times p$ 正交矩阵 ($V^T V = I_p$), 其列 v_j 称右奇异向量; D 是 $p \times p$ 对角矩阵, 对角元 $d_1 \geq d_2 \geq \cdots \geq d_p \geq 0$ 称奇异值。对每个秩 q , (22.52) 的解 V_q 由 V 的前 q 列组成。 UD 的列称为 X 的主成分 (第 3.5.1 节); (22.51) 中的 N 个最优 $\hat{\lambda}_i$ 由前 q 个主成分 ($N \times q$ 矩阵 $U_q D_q$ 的 N 行) 给出。

注记 22.18 (主成分的性质与解释). 图 14.20 中一维主成分线: 每个数据点 x_i 在线上有点最近点 $u_{i1} d_1 v_1$ —— v_1 是线的方向, $\hat{\lambda}_i = u_{i1} d_1$ 度量沿线的距离。图 14.21 是半球数据的二维主成分曲面 (左) 及投影到前两个主成分 (右, 坐标由 $U_2 D_2$ 给出); 此投影正是前面 SOM 初始配置的基础, 能较好分离簇; 但因半球非线性, 非线性投影会更好 (下一节主题)。主成分还有其他好性质: 如线性组合 $X v_1$ 在所有特征线性组合中方差最大, $X v_2$ 在与 v_1 正交的所有线性组合中方差最大, 依此类推。

例 22.12 (手写数字). 主成分是降维与压缩的有用工具。以第 1 章手写数字数据演示: 图 14.22 显示 130 个手写「3」 (共 658 个), 每个是 16×16 灰度图。把每个图看作 $\mathbb{R}^{256}$ 中的点 x_i , 用 SVD ((22.53)) 算主成分。图 14.23 显示前两个主成分: 对 $u_{i1} d_1$ 、 $u_{i2} d_2$ 取 5%/25%/50%/75%/95% 分位数定义网格, 圈出靠近网格顶点的投影图像——可见 v_1 (水平移动) 主要对应「3」下部尾端的拉长, v_2 (垂直移动) 对应字符粗细。按参数化模型 (22.49), 这个双成分模型形如

$$\hat{f}(\lambda) = \bar{x} + \lambda_1 v_1 + \lambda_2 v_2, \quad (22.54)$$

其中 v_1, v_2 可作为图像显示。虽然可能有 256 个主成分, 约 50 个就占「3」变化的 90%、12 个占 63%。图 14.24 把奇异值与等价不相关数据 (随机打乱 X 各列) 的奇异值比较——数字化图像的像素天然相关、且同为同一数字相关性更强, 故前几个奇异值显著更大。相对少的主成分即可作为表示高维数据的优秀低维特征。

例 22.13 (Procrustes 变换与形状平均). 图 14.25 表示两组点 (橙、绿), 是签名者「Suresh」手写 S 的两个数字化版本 (各 96 个对应点, $N \times 2$ 矩阵 X_1, X_2 , 第 i 行对应两 S 上的同一位置——形态测量学中称**地标** landmarks; 寻找对应地标通常困难且因问题而异, 本例用沿签名的速度信号做动态时间规整)。右图对绿色点施加平移旋转以最佳匹配橙色——即所谓 **Procrustes 变换**。考虑问题

$$\min_{\mu, R} \|X_2 - (X_1 R + \mathbf{1}\mu^T)\|_F, \quad (22.55)$$

其中 X_1, X_2 是 $N \times p$ 对应点矩阵, R 是 $p \times p$ 标准正交矩阵, μ 是 p 维位置向量, $\|\cdot\|_F^2 = \text{trace}(X^T X)$ 为 Frobenius 范数平方。设 $\bar{x}_1, \bar{x}_2$ 为列均值, $\tilde{X}_1, \tilde{X}_2$ 为去均值版本, 对 $\tilde{X}_1^T \tilde{X}_2 = U D V^T$ 作 SVD, 则 (22.55) 的解为 (练习 14.8)

$$\hat{R} = UV^T, \quad \hat{\mu} = \bar{x}_2 - \hat{R}\bar{x}_1, \quad (22.56)$$

最小距离称 **Procrustes 距离**。由解的形式, 可先把每矩阵按列质心中心化、完全忽略位置。带缩放的 Procrustes 距离求解更一般问题

$$\min_{\beta, R} \|X_2 - \beta X_1 R\|_F, \quad (22.57)$$

其中 $\beta > 0$; R 解如前, $\hat{\beta} = \text{trace}(D) / \|X_1\|_F^2$ 。

与 Procrustes 距离相关的是一族 L 个形状的 **Procrustes 平均**, 求解

$$\min_{\{R_\ell\}_1^L, M} \sum_{\ell=1}^L \|X_\ell R_\ell - M\|_F^2, \quad (22.58)$$

即找平均平方 Procrustes 距离上离所有形状最近的形状 M 。用简单交替算法求解:

1. 初始化 $M = X_1$ (例如);
2. M 固定, 解 L 个 Procrustes 旋转问题, 得 $X'_\ell \leftarrow X_\ell \hat{R}_\ell$;
3. 令 $M \leftarrow \frac{1}{L} \sum_{\ell=1}^L X'_\ell$ 。

重复步骤 1–2 直到准则 ((22.58)) 收敛。图 14.26 是三个形状的简单例子; 注意只能期望解到旋转为止 (或强加如 M 上三角的约束保证唯一); 缩放可轻易并入 (练习 14.9)。更一般地可定义一族形状的**仿射不变平均**

$$\min_{\{A_\ell\}_1^L, M} \sum_{\ell=1}^L \|X_\ell A_\ell - M\|_F^2, \quad (22.59)$$

其中 A_ℓ 是任意 $p \times p$ 非奇异矩阵; 需标准化 (如 $M^T M = I$) 避免平凡解。其解优美且无需迭代 (练习 14.10): 令 $H_\ell = X_\ell (X_\ell^T X_\ell)^{-1} X_\ell^T$ 为 X_ℓ 定义的秩- p 投影矩阵, 则 M 由 $\bar{H} = \frac{1}{L} \sum_{\ell} H_\ell$ 的 p 个最大特征向量组成。

22.5.2 主曲线与主曲面

主曲线推广主成分线，给出 $\mathbb{R}^p$ 中一组数据点的**光滑一维弯曲逼近**；主曲面更一般，给出二维或更高维的弯曲流形逼近。

先对随机变量 $X \in \mathbb{R}^p$ 定义主曲线，再转到有限数据情形。设 $f(\lambda)$ 是 $\mathbb{R}^p$ 中参数化的光滑曲线（ p 个坐标函数，每个是单一参数 λ 的光滑函数； λ 可取为从某固定原点沿曲线的弧长）。对每个数据值 x ，设 $\lambda_f(x)$ 定义曲线上离 x 最近的点。若

$$f(\lambda) = \mathbb{E}(X \mid \lambda_f(X) = \lambda), \quad (22.60)$$

则 $f(\lambda)$ 称为随机向量 X 分布的**主曲线**。它说 $f(\lambda)$ 是所有投影到它的数据点的平均，即它「负责」的点——也称**自一致性**（self-consistency）性质。实践中连续多元分布有无穷多条主曲线（Duchamp and Stuetzle, 1996），我们主要关心光滑的。图 14.27 展示了主曲线。

主点（principal points）是相关概念：对分布支撑中每个点 x 找最近原型（负责它的原型），诱导特征空间划分为 **Voronoi 区域**。使 X 到其原型的期望距离最小的 k 个点称为分布的**主点**——每个主点自一致（等于其 Voronoi 区域中 X 的均值）。例如圆形正态分布 $k=1$ 的主点是均值向量， $k=2$ 是一对对称放在过均值射线上的点。主点是 K-means 所得质心的分布类比；主曲线可视为 $k=\infty$ 个主点、但约束落在光滑曲线上——类似 SOM 把 K-means 簇中心约束在光滑流形上。

为找分布的主曲线 $f(\lambda)$ ，考虑坐标函数 $f(\lambda) = [f_1(\lambda), \dots, f_p(\lambda)]$, $X^T = (X_1, \dots, X_p)$ ，交替两步：

$$\begin{aligned} \text{(a)} \quad & \hat{f}_j(\lambda) \leftarrow \mathbb{E}(X_j \mid \lambda(X) = \lambda), \quad j = 1, \dots, p, \\ \text{(b)} \quad & \hat{\lambda}_f(x) \leftarrow \arg \min_{\lambda'} \|x - \hat{f}(\lambda')\|^2. \end{aligned} \quad (22.61)$$

第一式固定 λ 并执行自一致性要求（(22.60)）；第二式固定曲线并找每个数据点在曲线上的最近点。有限数据下主曲线算法从**线性主成分**出发，迭代 (22.61) 两式直到收敛：用散点图平滑器把每个 X_j 作为弧长 $\hat{\lambda}(X)$ 的函数来估计 (a) 中的条件期望，(b) 对每个观测数据点做投影。一般收敛证明困难，但可证若散点图平滑用线性最小二乘拟合，则过程收敛到**第一线性主成分**，等价于求矩阵最大特征向量的**幂法**。

主曲面与主曲线形式完全相同、只是维度更高；最常用二维主曲面，坐标函数 $f(\lambda_1, \lambda_2) = [f_1(\lambda_1, \lambda_2), \dots, f_p(\lambda_1, \lambda_2)]$ ，(a) 中的估计用二维曲面平滑器。高于二维的主曲面很少用（可视化吸引力下降、高维平滑也难）。图 14.28 是对半球数据的主曲面拟合结果：按估计的非线性坐标 $\hat{\lambda}_1(x_i), \hat{\lambda}_2(x_i)$ 画数据点，类别分离明显。

注记 22.19 (主曲面与 SOM 的关系). 若用核曲面平滑器估计每个坐标函数 $f_j(\lambda_1, \lambda_2)$ ，则与 SOM 批次版本（(22.48)）形式相同——SOM 的权重 w_k 就是核中的权重。但有区别：主曲面为每个数据点 x_i 估计一个单独的原型 $f(\lambda_1(x_i), \lambda_2(x_i))$ ，而 SOM 对所有数据点共享较少原型；故仅当 SOM 原型数趋于很大时两者一致。概念上也有差异：主曲

面以坐标函数给出整个流形的光滑参数化, SOM 是离散的、只给出近似数据的估计原型; 主曲面的光滑参数化局部保距——图 14.28 中它揭示了红色簇比绿、蓝簇更紧(简单例子中坐标函数本身可提供信息, 练习 14.13)。

22.5.3 谱聚类

K-means 等传统聚类用球形或椭球度量分组, 因此当簇非凸时(如图 14.29 左上角的同心圆)效果不好。谱聚类(spectral clustering)推广标准聚类方法、专为此类情形设计, 与推广 MDS 的局部多维缩放技术 (§14.9) 关系密切。

出发点是一对观测两两相似度组成的 $N \times N$ 矩阵 $s_{ii'} \geq 0$ 。把观测表示成无向相似图 $G = \langle V, E \rangle$: N 个顶点 v_i 代表观测, 两顶点间有边当且仅当相似度为正(或超过某阈值), 边按 $s_{ii'}$ 加权。聚类重述为图划分问题: 不同组的边权重低、组内边权重高。谱聚类的思想是构造表示观测间局部邻域关系的相似图。

具体化: 设 N 个点 $x_i \in \mathbb{R}^p$, $d_{ii'}$ 为欧氏距离, 取径向核 Gram 矩阵作相似矩阵: $s_{ii'} = \exp(-d_{ii'}^2/c)$, $c > 0$ 是尺度参数。定义局部行为的相似图方式很多, 最流行的是互 K -最近邻图: 设 N_K 为对称的邻近点对集合—— (i, i') 在 N_K 中若点 i 是 i' 的 K 近邻之一或反之; 连接所有对称近邻、边权 $w_{ii'} = s_{ii'}$, 否则 0 (等价于把不在 N_K 中的两两相似度置零)。也可用全连接图: 包含所有两两边、权重 $w_{ii'} = s_{ii'}$, 局部行为由尺度 c 控制。

相似图的边权矩阵 $W = \{w_{ii'}\}$ 称邻接矩阵。顶点 i 的度 $g_i = \sum_{i'} w_{ii'}$, G 为对角线为 g_i 的对角矩阵。定义图拉普拉斯

$$L = G - W, \quad (22.62)$$

称未归一化图拉普拉斯; 还有多种归一化版本(如 $\tilde{L} = I - G^{-1}W$, 按节点度标准化)。

谱聚类找 L 的 m 个最小特征值对应的 m 个特征向量 ($N \times m$ 矩阵 Z , 忽略平凡常数特征向量), 再用 K-means 等标准方法对 Z 的行聚类, 得到原始数据点的聚类。

例 22.14 (谱聚类为什么有效). 图 14.29: 左上为 450 个模拟点、分属三个同心圆形簇(各 150 点, 角向均匀、半径 1/2.8/5, 加 $\sigma = 0.25$ 高斯噪声); K-means 显然难以识别外层簇。用 10-近邻相似图做谱聚类, 左下显示图拉普拉斯第 2、3 小特征值对应的特征向量; 右上显示 15 个最小特征值; 右下把特征向量矩阵 Y 的 450 行散点化——三个簇清晰分离, 再用 K-means 极易识别。原因: 对任意向量 f ,

$$f^T L f = \sum_{i=1}^N g_i f_i^2 - \sum_{i=1}^N \sum_{i'=1}^N f_i f_{i'} w_{ii'} = \frac{1}{2} \sum_{i=1}^N \sum_{i'=1}^N w_{ii'} (f_i - f_{i'})^2. \quad (22.63)$$

(22.63) 说明 $f^T L f$ 小意味着邻接大的点对坐标 $f_i, f_{i'}$ 接近。任何图都有 $\mathbf{1}^T L \mathbf{1} = 0$, 故常数向量是零特征值平凡特征向量; 不太显然的是若图连通则它是唯一零特征向量(练习 14.21)。推广: 有 m 个连通分量时, 节点可重排使 L 为分块对角(每连通分量一块),

L 有 m 个零特征值特征向量、零特征空间由连通分量的**指示向量**张成。实践中强弱连接并存，零特征值由小特征值近似。谱聚类是找非凸簇的有趣方法；用归一化拉普拉斯时还有另一视角：令 $P = G^{-1}W$ ，考虑图上的**随机游走**（转移概率矩阵 P ），谱聚类给出的节点组使随机游走很少从一个组转到另一个组。

注记 22.20 (谱聚类的实际问题). 实践中需选择相似图类型（全连接或近邻）及参数（近邻数 k 或核尺度 c ）、从 L 提取的特征向量数、以及（与其他聚类一样）簇数。在图 14.29 的玩具例中 $k \in [5, 200]$ 都得好结果（200 对应全连接图）， $k < 5$ 则退化；且从右上图看最小的三个特征值与其余之间没有明显间隔，故选多少个特征向量并不清楚。

22.5.4 核主成分

谱聚类与**核主成分**（kernel PCA，线性主成分的非线性版本）相关。标准线性 PCA 由协方差矩阵的特征向量给出数据最大方差方向；核 PCA（Schölkopf et al., 1999）扩展 PCA 范围，模拟「先把特征做非线性变换、再在变换后的特征空间中做 PCA」的效果。

第 18.5.2 节将证明数据矩阵 X 的主成分变量 Z 可由内积（Gram）矩阵 $K = XX^T$ 计算：对 Gram 矩阵的双中心化版本作特征分解

$$\tilde{K} = (I - M)K(I - M) = UD^2U^T, \quad (22.64)$$

其中 $M = \mathbf{1}\mathbf{1}^T/N$ ，然后 $Z = UD$ （练习 18.15 说明如何计算新观测在此空间的投影）。

核 PCA 直接模仿此过程：把核矩阵 $K = \{K(x_i, x_{i'})\}$ 解释为隐式特征的内积矩阵 $\langle \varphi(x_i), \varphi(x_{i'}) \rangle$ 并求其特征向量。第 m 个成分 z_m （ Z 的第 m 列）的元素（差一个中心化）可写为

$$z_{im} = \sum_{j=1}^N \alpha_{jm} K(x_i, x_j), \quad \alpha_{jm} = u_{jm}/d_m,$$

（练习 14.16）。更多洞见：把 z_m 视为主成分函数 $g_m \in \mathcal{H}_K$ （ K 生成的再生核希尔伯特空间，第 5.8.1 节）的样本取值。第一主成分函数 g_1 求解

$$\max_{g_1 \in \mathcal{H}_K} \text{Var}_T g_1(X) \quad \text{s.t.} \quad \|g_1\|_{\mathcal{H}_K} = 1, \quad (22.65)$$

其中 Var_T 指训练数据 T 上的样本方差；范数约束控制函数 g_1 的大小与粗糙度（由核 K 决定）。与回归情形一样可证 (22.65) 的解有限维、有表示 $g_1(x) = \sum_{j=1}^N c_j K(x, x_j)$ ，且解由 $\hat{c}_j = \alpha_{j1}$ 给出（练习 14.17）；第二主成分函数类似定义、另加 $\langle g_1, g_2 \rangle_{\mathcal{H}_K} = 0$ 约束，依此类推。Schölkopf 等演示了核主成分作为手写数字分类特征、相对线性主成分能提升分类器性能。

注记 22.21 (核 PCA 与谱聚类的关系). 若用径向核

$$K(x, x') = \exp(-\|x - x'\|^2/c), \quad (22.66)$$

则核矩阵 K 与谱聚类的相似矩阵 S 形式相同；边权矩阵 W 是 K 的局部化版本（把非近邻点对的相似度置零）。核 PCA 找 $\tilde{K}$ 的最大特征值特征向量，等价于找

$$I - \tilde{K} \quad (22.67)$$

的最小特征值特征向量——这与拉普拉斯 ((22.62)) 几乎相同，差别在于 $\tilde{K}$ 的中心化以及 G 对角线为节点度。图 14.30 在玩具例中检验核 PCA：径向核 $c = 2$ 不能分离组、 $c = 10$ 时第一成分分离良好；用谱聚类的近邻径向核 W 或直接用核矩阵构造拉普拉斯都不能分离——可见核 PCA 对核的尺度与性质相当敏感，且近邻截断对谱聚类的成功很重要。

22.5.5 稀疏主成分

我们常通过查看方向向量 v_j （又称**载荷** loadings）来解释主成分、看哪些变量起作用（如 (22.54) 的图像载荷）。若载荷**稀疏**，这种解释往往更容易。本节简述一些推导稀疏载荷主成分的方法，都基于 lasso (L_1) 惩罚。

设 X 为 $N \times p$ 数据矩阵（列已中心化）。所提方法聚焦主成分的最大方差性质或最小重建误差。Jolliffe 等的 SCoTLASS 程序取第一种途径，求解

$$\max_v v^T (X^T X) v \quad \text{s.t.} \quad \sum_{j=1}^p |v_j| \leq t, \quad v^T v = 1. \quad (22.68)$$

绝对值约束鼓励部分载荷为零、故 v 稀疏；进一步稀疏主成分通过强制第 k 个成分与前 $k-1$ 个正交类似求得。可惜此问题**非凸**、计算困难。

Zou et al. (2006) 改从 PCA 的回归/重建性质出发（类似 §14.5.1）。设 x_i 为 X 的第 i 行，对单成分其稀疏主成分技术求解

$$\min_{\theta, v} \sum_{i=1}^N \|x_i - \theta v^T x_i\|_2^2 + \lambda \|v\|_2^2 + \lambda_1 \|v\|_1 \quad \text{s.t.} \quad \|\theta\|_2 = 1. \quad (22.69)$$

分析该形式：

- 若 $\lambda = \lambda_1 = 0$ 且 $N > p$ ，易证 $v = \theta$ 且为最大主成分方向；
- 当 $p \gg N$ 时解未必唯一，除非 $\lambda > 0$ ；对任意 $\lambda > 0$ 且 $\lambda_1 = 0$ ， v 的解正比于最大主成分方向；
- 对 v 的第二个惩罚鼓励载荷稀疏。

对多成分，稀疏主成分程序最小化

$$\sum_{i=1}^N \|x_i - \Theta V^T x_i\|_2^2 + \lambda \sum_{k=1}^K \|v_k\|_2^2 + \sum_{k=1}^K \lambda_{1k} \|v_k\|_1, \quad (22.70)$$

约束 $\Theta^T \Theta = I_K$, V 是 $p \times K$ 矩阵 (列为 v_k)、 Θ 也是 $p \times K$ 。准则 ((22.70)) 对 V, Θ 非联合凸, 但对每个参数 (另一参数固定) 凸; Θ 固定时对 V 最小化等价于 K 个弹性网问题 (§18.4)、可高效求解; V 固定时对 Θ 最小化是 (22.55) 类 Procrustes 问题、用简单 SVD 求解 (练习 14.12); 交替迭代至收敛。

例 22.15 (胼胝体形状研究). 图 14.31 是用 (22.70) 做稀疏主成分分析的例子 (Sjöstrand et al., 2007): 一项涉及 569 名老人的研究中, 胼胝体 (corpus callosum, CC) 矢状切面形状与各种临床参数相关。此处 PCA 应用于形状数据——形态测量学中的流行工具: 沿形状圆周识别若干地标 (图 14.32), 用 Procrustes 分析对齐 (允许旋转、本例还有缩放, 见 §14.5.1), PCA 的特征是各地标坐标对序列展开成的单个向量。分析中同时计算标准与稀疏主成分, 识别出与临床参数显著相关的成分。图 14.31 中显著主成分对应的形状变化 (红曲线) 叠加在平均 CC 形状 (黑曲线) 上: 步行速度低对应连接运动控制与认知中枢区域 CC 变薄 (萎缩); 言语流畅度低对应连接听觉/视觉/认知中枢区域 CC 变薄。稀疏主成分给出更简洁、可能更有信息的差异图景。