

机器学习笔记

F.Z.

2026 年 8 月 5 日

目录

第一部分 统计学基础	19
第一章 概率论回顾	21
1.1 随机变量与分布	21
1.1.1 离散随机变量	21
1.1.2 连续随机变量	21
1.1.3 常见分布	21
1.2 条件概率与独立性	22
1.3 矩与特征	22
1.3.1 Pearson 与 Spearman 相关系数	22
第二章 样本及抽样分布	25
2.1 随机样本	25
2.1.1 总体与样本	25
2.1.2 常用统计量	28
2.2 直方图和箱线图	30
2.2.1 直方图	30
2.2.2 箱线图	31
2.2.3 经验分布函数	32
2.3 抽样分布	32
2.3.1 χ^2 分布 (卡方分布)	32
2.3.2 t 分布 (学生氏分布)	39
2.3.3 F 分布	47
2.3.4 正态总体的抽样分布定理 (核心定理)	52
第三章 参数估计	55
3.1 点估计	55
3.1.1 矩估计法	55
3.1.2 极大似然估计 (MLE)	55
3.1.3 最大后验估计 (MAP)	63

3.2	基于截尾样本的最大似然估计	64
3.2.1	定时截尾	64
3.2.2	定数截尾	64
3.2.3	指数分布截尾样本的 MLE	64
3.3	估计量的评选标准	64
3.3.1	无偏性	64
3.3.2	有效性	65
3.3.3	相合性（一致性）	65
3.3.4	均方误差（综合评价）	65
3.4	区间估计	65
3.4.1	基本概念	65
3.4.2	枢轴量法（构造置信区间的通用方法）	66
3.5	正态总体均值与方差的区间估计	66
3.5.1	单个正态总体均值的置信区间	66
3.5.2	单个正态总体方差的置信区间	66
3.5.3	两个正态总体均值差的置信区间	67
3.5.4	两个正态总体方差比的置信区间	67
3.6	(0-1) 分布参数的区间估计	67
3.7	单侧置信区间	68
第四章	假设检验	69
4.1	假设检验的基本概念	69
4.1.1	假设检验问题	69
4.1.2	两类错误	69
4.1.3	拒绝域与检验统计量	70
4.2	正态总体均值的假设检验	70
4.2.1	单个正态总体均值的检验	70
4.2.2	两个正态总体均值差的检验	71
4.2.3	配对数据的 t 检验	71
4.3	正态总体方差的假设检验	72
4.3.1	单个正态总体方差的检验— χ^2 检验	72
4.3.2	两个正态总体方差比的检验— F 检验	72
4.4	置信区间与假设检验之间的关系	72
4.5	样本容量的选取	73
4.5.1	Z 检验的样本容量	73
4.5.2	t 检验的样本容量	73
4.5.3	影响样本容量的因素	74
4.6	分布拟合检验	74

4.6.1	χ^2 拟合优度检验	74
4.6.2	正态性检验概述	75
4.7	秩和检验	75
4.7.1	Wilcoxon 秩和检验（两独立样本）	75
4.7.2	Wilcoxon 符号秩检验（配对样本）	77
4.8	假设检验问题的 p 值检验法	80
4.8.1	p 值的定义	80
4.8.2	p 值的解释	80
4.8.3	p 值与置信区间的关系	81
第五章	方差分析及回归分析	85
5.1	单因素试验的方差分析	85
5.1.1	问题的提出	85
5.1.2	平方和分解	86
5.1.3	F 检验	86
5.1.4	多重比较	87
5.2	双因素试验的方差分析	88
5.2.1	无交互作用的双因素 ANOVA	88
5.2.2	有交互作用的双因素 ANOVA	90
5.3	一元线性回归	93
5.3.1	模型与假设	93
5.3.2	最小二乘估计 (OLS)	93
5.3.3	拟合优度: R^2	93
5.3.4	回归系数的假设检验	94
5.3.5	置信区间与预测区间	94
5.4	多元线性回归	95
5.4.1	模型与矩阵形式	95
5.4.2	最小二乘估计	95
5.4.3	显著性检验	96
5.4.4	多重共线性	96
5.4.5	回归诊断: 假设验证	97
5.4.6	混合效应模型简介	98
5.4.7	分位数回归 (Quantile Regression)	99
5.4.8	模型选择	100
第六章	Bootstrap 方法	103
6.1	非参数 Bootstrap 方法	103
6.1.1	基本思想	103

6.1.2	Bootstrap 标准误	103
6.1.3	Bootstrap 置信区间	104
6.1.4	为什么有放回抽样?	104
6.2	参数 Bootstrap 方法	105
6.2.1	与非参数 Bootstrap 的区别	105
6.2.2	算法	105
6.2.3	何时用哪种 Bootstrap?	106
6.2.4	Cluster Bootstrap (聚类自助法)	107
第七章	统计实践：从建模到报告	109
7.1	R^2 与 p 值的区别与联系	109
7.1.1	框架对比	109
7.1.2	为什么 R^2 很低但 p 值可以显著?	110
7.1.3	用“射击靶子”理解二者	110
7.1.4	四种组合判断表	110
7.1.5	常见误区纠正	111
7.2	因素分析的标准流程	111
7.2.1	第 1 步：相关性扫描——看方向和显著性	111
7.2.2	第 2 步：建立回归模型——量化效应大小	111
7.2.3	第 3 步：模型诊断——验证假设	112
7.2.4	第 4 步：模型改进——从简单到复杂	112
7.2.5	第 5 步：报告与解释——讲好故事	112
7.2.6	完整流程图	113
7.3	APA 学术报告规范	113
7.3.1	核心原则	113
7.3.2	常见统计量的 APA 报告格式	114
7.3.3	p 值的写法	114
7.3.4	完整报告示例	114
7.3.5	建模竞赛论文的 APA 使用要点	115
7.4	方法选择速查表	115
第八章	信息论基础	117
8.1	基本概念	117
第二部分	机器学习	119
第九章	矩阵运算与张量记号	121
9.1	迹运算	121

9.2	正定与半正定矩阵	121
9.3	矩阵求导	122
9.3.1	标量对向量的导数	122
9.3.2	标量对矩阵的导数	123
9.3.3	向量对向量的导数（雅可比矩阵）	123
9.4	张量分析的指标记号	123
9.4.1	Einstein 求和约定	123
9.4.2	Kronecker δ 符号	124
9.4.3	偏导数的指标写法	124
9.4.4	矩阵对标量的导数	125
9.4.5	何时用矩阵记号，何时用指标记号	125
9.5	谱分解与奇异值分解 (SVD)	126
9.5.1	对称矩阵的谱分解	126
9.5.2	奇异值分解 (SVD)	126
9.6	矩阵范数	127
9.7	关键恒等式	127
9.7.1	Woodbury 矩阵求逆公式	127
9.7.2	矩阵求逆引理（Woodbury 的特例）	127
9.7.3	期望的二次型	128
第十章	统计学习导论	129
10.1	监督学习的数学框架	129
10.1.1	基本设定	129
10.1.2	损失函数	129
10.1.3	期望风险与经验风险	130
10.1.4	EPE 与 ERM：理想与现实的桥梁	130
10.1.5	最优预测器：回归函数	132
10.1.6	两种建模策略	135
10.1.7	完整示例：从数据到预测	135
10.1.8	理论回看：从最优预测器到实际估计器	140
10.1.9	统计学习 vs 经典统计：两种推理框架	142
10.2	无监督学习的数学框架	143
10.2.1	基本设定	143
10.2.2	聚类	144
10.2.3	密度估计	144
10.2.4	降维	144
10.3	监督学习与无监督学习的对比	145
10.4	维数灾难与高维空间中的局部方法	145

10.4.1	单位超立方体中的邻域	145
10.4.2	期望邻域边长	146
10.4.3	1-NN 的偏差-方差分解（高维示例）	146
10.4.4	线性模型 vs 1-NN：高维下的 EPE 对比	147
10.4.5	维数灾难的形式化定义与启示	148
10.5	统计学习的基本框架：从模型到估计	148
10.5.1	加性误差模型与条件期望	148
10.5.2	条件方差：为什么可以不是常数	150
10.5.3	期望预测误差与最优预测器	150
10.5.4	监督学习的数学表述	151
10.5.5	函数逼近视角	151
10.5.6	参数估计 I：最小二乘法	152
10.5.7	参数估计 II：极大似然估计	153
10.5.8	参数估计 III：从 EPE 到 ERM	154
10.5.9	无约束最小化的根本困境	155
10.5.10	受限制的估计量：几类经典方法	156
10.5.11	模型选择与偏差-方差权衡	161
10.5.12	总结：从模型到估计的统一框架	166
第十一章	线性回归模型与最小二乘法	169
11.1	引言：为什么从线性模型开始	169
11.2	线性回归模型	169
11.2.1	模型形式	169
11.2.2	输入的来源	170
11.2.3	矩阵记号	170
11.3	最小二乘估计	171
11.3.1	残差平方和	171
11.3.2	矩阵形式的解	171
11.3.3	拟合值与 Hat Matrix	174
11.3.4	几何解释	175
11.4	估计量的抽样性质	175
11.4.1	一阶矩与二阶矩的假设	175
11.4.2	三层限制：从模型选择到无偏性的逻辑链	178
11.4.3	深入理解：固定设计与随机设计	180
11.4.4	条件推断：实践中你真正在做的事	183
11.4.5	σ^2 的无偏估计	187
11.4.6	单个系数的方差	187
11.5	正态假设下的推断	187

11.5.1 正态误差假设	188
11.5.2 $\hat{\beta}$ 的抽样分布	188
11.5.3 单个系数的检验: t 检验到底在检验什么?	188
11.5.4 置信区间与显著性检验	192
11.5.5 进一步可检验的假设	193
11.5.6 F 检验与嵌套模型比较	193
11.5.7 联合置信域	194
11.6 高斯-马尔可夫定理	194
11.6.1 定理陈述与意义	194
11.6.2 MSE 分解: 偏差-方差视角	195
11.7 预测误差的分解	195
11.7.1 新观测的预测	196
11.7.2 期望预测误差 (Expected Prediction Error)	196
11.7.3 训练误差 vs 预测误差	196
11.8 多元回归作为单变量回归的叠加	197
11.8.1 单变量回归的最小二乘	197
11.8.2 有截距时的处理	197
11.8.3 推广到多元: 正交化 (Gram-Schmidt)	197
11.8.4 直观理解	198
11.8.5 QR 分解: 从 Gram-Schmidt 到数值计算	198
11.9 多输出回归 (Multiple Outputs)	200
11.9.1 模型形式	200
11.9.2 矩阵形式	201
11.9.3 最小二乘估计	201
11.9.4 当误差跨输出相关时	201
11.10 实例: 前列腺癌数据	202
11.10.1 变量说明	202
11.10.2 预测变量的相关矩阵	203
11.10.3 全模型回归结果	203
11.10.4 F 检验: 小模型 vs 大模型	204
11.11 完整示例: 手算一个线性回归	204
11.11.1 数据与模型	204
11.11.2 Step 1: 估计 $\hat{\beta}$	205
11.11.3 Step 2: 拟合值与残差	205
11.11.4 Step 3: σ^2 的无偏估计	206
11.11.5 Step 4: 系数的标准误与 t 检验	206
11.11.6 Step 5: F 检验——小模型 vs 大模型	206

11.11.7 Step 6: R^2 与模型解释力	207
11.11.8 Step 7: 95% 置信区间	207
11.11.9 Step 8: 预测新观测	208
11.11.10 总结: 从这个例子学到了什么	208
11.12 子集选择与系数收缩	208
11.12.1 为什么要超越最小二乘?	209
11.12.2 最优子集选择 (Best-Subset Selection)	209
11.12.3 逐步选择 (Stepwise Selection)	210
11.12.4 前向分段回归 (Forward-Stagewise Regression)	212
11.12.5 小结: 子集选择的统一视角	213
11.13 收缩方法 (Shrinkage Methods)	214
11.13.1 前列腺癌实例回顾	214
11.13.2 岭回归 (Ridge Regression)	215
11.13.3 岭回归的 SVD 视角	216
11.13.4 主成分与方差方向	218
11.13.5 有效自由度	218
11.13.6 Lasso	218
11.13.7 正交输入情形下的统一视角	219
11.13.8 几何直观: $p = 2$ 时的图形比较	221
11.13.9 一般 L_q 惩罚与贝叶斯统一视角	222
11.13.10 弹性网 (Elastic Net)	224
11.13.11 最小角回归 (LAR)——Lasso 的高效算法	225
11.13.12 小结: 收缩方法谱系	226
11.14 使用导出输入方向的方法 (Derived Input Directions)	226
11.14.1 主成分回归 (PCR)	226
11.14.2 偏最小二乘 (PLS)	227
11.14.3 PCR 与 PLS 的优化问题	227
11.14.4 深入理解 PLS: 正交投影、实例与动机	228
11.15 选择与收缩方法的比较 (Discussion)	233
11.16 多输出收缩与选择	234
11.16.1 典型相关分析 (CCA)	235
11.16.2 降秩回归 (Reduced-Rank Regression)	241
11.16.3 Curds & Whey 收缩	242
11.17 Lasso 深入与路径算法	244
11.17.1 增量前向分段回归 (Incremental Forward Stagewise, FS)	244
11.17.2 分段线性路径算法	245
11.17.3 Dantzig 选择器	245

11.17.4 分组 Lasso (Grouped Lasso)	245
11.17.5 Lasso 的进一步性质	247
11.17.6 路径坐标优化 (Pathwise Coordinate Descent)	248
11.18 计算考量	248
11.19 小结	249
第十二章 分类的线性方法	255
12.1 引言	255
12.1.1 判别函数方法	257
12.1.2 Logit 变换与 Logistic 模型	257
12.1.3 实操流程：从线性函数到分类决策	260
12.1.4 基展开：从线性到非线性	261
12.1.5 本章对 f 的核心限制	261
12.2 指示矩阵的线性回归	262
12.2.1 模型设定	262
12.2.2 理论依据	263
12.2.3 最近目标分类视角	263
12.2.4 完整数值示例 ($N = 5, K = 3, p = 1$)	263
12.2.5 Masking 问题	265
12.2.6 Masking 数值演示 ($N = 5, K = 3, p = 1$)	265
12.3 线性判别分析 (LDA)	269
12.3.1 Bayes 分类框架	269
12.3.2 Gaussian 假设下的 LDA	274
12.3.3 线性判别函数	274
12.3.4 参数估计	274
12.3.5 二分类 LDA 与最小二乘的对应	274
12.4 二次判别分析 (QDA)	275
12.4.1 参数数量	275
12.4.2 LDA 与 QDA 的性能讨论	275
12.5 正则化判别分析 (RDA)	275
12.5.1 模型形式	276
12.6 LDA 的计算	276
12.6.1 对角化方法	276
12.6.2 LDA 的球形化实现	276
12.7 降秩线性判别分析	278
12.7.1 动机：质心在低维仿射子空间中	278
12.7.2 Fisher 的判别准则	278
12.7.3 LDA 子空间的计算步骤	280

12.7.4 用于分类与降维	280
12.7.5 Fisher 方法与 Gaussian LDA 的等价性	280
12.7.6 总结	281
12.8 几何视角: W^{-1} -内积空间中的 LDA 与 Fisher	281
12.8.1 W^{-1} -内积空间	281
12.8.2 标准内积 vs W^{-1} -内积	282
12.8.3 在此框架下重新理解 LDA	282
12.8.4 在此框架下重新理解 Fisher	282
12.8.5 球形化的几何意义	283
12.8.6 统一视角总结	283
12.9 Logistic 回归	283
12.9.1 回到判别函数与 EPE 框架	283
12.9.2 模型设定	284
12.9.3 拟合: 最大似然与 IRLS	285
12.9.4 示例: 南非心脏病数据	286
12.9.5 二次近似与推断	286
12.9.6 L_1 正则化 Logistic 回归	289
12.9.7 Logistic 回归还是 LDA?	290
12.9.8 LDA 和 Logistic 回归总结	291
12.10 分离超平面	291
12.10.1 超平面的线性代数	291
12.10.2 Rosenblatt 感知机学习算法	291
12.10.3 最优分离超平面	293
12.11 本章小结	295
第十三章 基展开与正则化	297
13.1 引言	297
13.1.1 两种突破线性的思路: 参数化 vs 非参数化	297
13.1.2 核心思想: 变换输入空间	298
13.1.3 常见基函数示例	298
13.1.4 复杂度的控制	298
13.2 分段多项式与样条	299
13.2.1 分段常数与分段线性	299
13.2.2 截断幂基	299
13.2.3 三次样条 (Cubic Spline)	301
13.2.4 一般阶样条	301
13.2.5 节点选择	303
13.2.6 自然三次样条	305

13.2.7 样条方法概览	306
13.2.8 示例：南非心脏病数据（续）	307
13.2.9 示例：音素识别	312
13.3 滤波与特征提取	313
13.4 光滑样条	313
13.4.1 惩罚残差平方和	314
13.4.2 有限维解	314
13.4.3 完整示例：光滑样条的符号化流程	315
13.4.4 自由度与光滑矩阵	317
13.5 光滑参数的自动选择	318
13.5.1 用有效自由度参数化	318
13.5.2 偏差-方差权衡	318
13.5.3 交叉验证 (CV)	321
13.6 非参数 Logistic 回归	321
13.7 多维样条	322
13.7.1 张量积基	322
13.7.2 薄板样条 (Thin-Plate Splines)	325
13.7.3 加性样条与 ANOVA 分解	325
13.7.4 小结：从一维到多维的选择路线	326
13.8 正则化与再生核 Hilbert 空间 (RKHS)	326
13.8.1 一般形式	326
13.8.2 RKHS 与核方法	327
13.8.3 实例	330
13.8.4 实践指南：何时使用核方法	330
13.9 小波光滑	332
13.9.1 核心思想：时间-频率定位	332
13.9.2 多分辨率分析	332
13.9.3 小波变换的数学定义	333
13.9.4 自适应小波阈值 (Wavelet Shrinkage)	334
13.9.5 小波 vs 光滑样条（图 5.19）	334
13.10 本章小结	337
第十四章 核光滑方法	339
14.1 一维核光滑器	339
14.1.1 从 k -最近邻平均到核加权平均	339
14.1.2 核函数的形式	341
14.1.3 三种常用核	341
14.1.4 实践中的注意事项	341

14.2 局部线性回归	342
14.2.1 边界偏差问题	342
14.2.2 局部加权最小二乘	342
14.2.3 矩阵形式与等价核	342
14.2.4 自动核木工 (Automatic Kernel Carpentry)	343
14.3 局部多项式回归	344
14.3.1 d 阶局部多项式拟合	344
14.3.2 削峰填谷效应	345
14.3.3 偏差-方差权衡	345
14.3.4 奇数阶 vs 偶数阶: 实践建议	345
14.4 核宽度的选择	346
14.4.1 λ 在不同核中的含义	346
14.4.2 偏差-方差权衡与窗宽	346
14.4.3 线性估计量与光滑矩阵	346
14.4.4 有效自由度	347
14.5 $\mathbb{R}^p$ 中的局部回归	347
14.5.1 多项式向量与径向核	348
14.5.2 高维中的边界问题与维数灾难	348
14.6 $\mathbb{R}^p$ 中的结构化局部回归模型	349
14.6.1 结构化核	349
14.6.2 结构化回归函数	349
14.6.3 变系数模型	350
14.7 局部似然与其他模型	350
14.7.1 局部似然	350
14.7.2 局部自回归时间序列	350
14.7.3 局部多类 Logistic 回归	351
14.8 核密度估计与分类	351
14.8.1 核密度估计	351
14.8.2 核密度分类	352
14.8.3 朴素 Bayes 分类器	352
14.9 径向基函数与核	353
14.10 混合模型用于密度估计与分类	354
14.11 计算考量	354
第十五章 模型评估与选择	357
15.1 引言	357
15.2 偏差、方差与模型复杂度	357
15.2.1 定量响应情形	357

15.2.2 定性响应情形	360
15.2.3 模型选择 vs 模型评估	360
15.3 偏差-方差分解	361
15.3.1 k -最近邻回归的偏差-方差分解	361
15.3.2 线性回归的偏差-方差分解	362
15.3.3 岭回归的偏差分解	362
15.3.4 示例：偏差-方差权衡	362
15.4 训练误差的乐观性	365
15.4.1 泛化误差、期望误差与样本内误差	365
15.4.2 乐观性及其性质	366
15.4.3 线性拟合的特殊情形	367
15.5 样本内预测误差的估计	368
15.5.1 C_p 统计量	368
15.5.2 AIC 准则	368
15.5.3 AIC 的实践使用	369
15.6 有效参数个数	369
15.6.1 线性拟合方法的有效自由度	369
15.6.2 神经网络的有效参数个数	370
15.7 贝叶斯方法与 BIC	370
15.7.1 BIC 的定义	370
15.7.2 BIC 的贝叶斯推导	370
15.7.3 AIC 与 BIC 的比较	371
15.8 最小描述长度	372
15.8.1 编码与熵	372
15.8.2 MDL 用于模型选择	372
15.9 Vapnik–Chervonenkis 维	372
15.9.1 打散与 VC 维定义	372
15.9.2 VC 界与结构风险最小化	373
15.9.3 示例：AIC、BIC、SRM 的比较	373
15.10 交叉验证	373
15.10.1 K 折交叉验证	375
15.10.2 K 的选择：偏差-方差权衡	376
15.10.3 广义交叉验证 (GCV)	376
15.10.4 交叉验证的正确与错误做法	377
15.10.5 交叉验证真的有效吗？——高维示例	380
15.11 自助法 (Bootstrap)	380
15.11.1 基本思想	380

15.11.2 Bootstrap 估计预测误差	382
15.11.3 示例：CV 与 Bootstrap 比较	383
15.12 条件误差还是期望误差？	384
15.13 本章小结	385
15.13.1 核心框架	385
15.13.2 方法选用指南	386
15.13.3 关键结论	386
第十六章 模型推断与平均	389
16.1 引言	389
16.2 Bootstrap 与最大似然方法	389
16.2.1 一个光滑示例	389
16.2.2 非参数 Bootstrap 与参数 Bootstrap	390
16.2.3 最大似然推断	392
16.2.4 Bootstrap 与最大似然的比较	397
16.3 贝叶斯方法	398
16.3.1 基本框架	398
16.3.2 光滑示例的贝叶斯分析	400
16.3.3 Bootstrap 与贝叶斯推断的正式关系	400
16.3.4 Bootstrap 用法总览	401
16.4 EM 算法	402
16.4.1 两分量高斯混合模型	402
16.4.2 EM 算法的一般形式	403
16.5 MCMC：从后验抽样	404
16.5.1 背景与动机：为什么需要从后验分布抽样？	404
16.5.2 先验如何作用：后验是「先验 $\times$ 似然」的目标分布	405
16.5.3 马尔可夫性质：如何体现？	406
16.5.4 为什么联合分布最终稳定？	407
16.5.5 一个具体的 Gibbs 采样例子	407
16.5.6 Gibbs 采样	408
16.5.7 MCMC 的实践：有限步收敛与诊断	410
16.6 Bagging	411
16.6.1 分类情形：投票 vs 平均概率	411
16.6.2 例：树与模拟数据	411
16.6.3 Bagging 为什么有效	412
16.7 模型平均与 Stacking	414
16.7.1 频率学派视角	415
16.7.2 Stacking	416

16.7.3 小结：模型组合方法的谱系	416
16.8 随机搜索：Bumping	418
16.9 本章小结	419
16.9.1 核心框架：两条主线	419
16.9.2 方法选用指南	420
16.9.3 关键结论	420
第十七章 加性模型、树及相关方法	423
17.1 广义加性模型	423
17.1.1 模型定义	423
17.1.2 拟合加性模型：Backfitting	424
17.1.3 例：加性 logistic 回归（spam 数据）	428
17.1.4 小结	429
17.2 基于树的方法	430
17.2.1 背景	430
17.2.2 回归树	432
17.2.3 分类树	433
17.2.4 其他问题	434
17.2.5 spam 例子（续）	435
17.3 PRIM：Bump Hunting（引入）	436

第一部分

统计学基础

第一章 概率论回顾

1.1 随机变量与分布

1.1.1 离散随机变量

定义 1.1 (概率质量函数). 对于离散随机变量 X , 其概率质量函数 (PMF) $p(x)$ 满足:

$$p(x) = P(X = x), \quad \sum_x p(x) = 1. \quad (1.1)$$

定义 1.2 (期望). 离散随机变量 X 的期望定义为:

$$\mathbb{E}[X] = \sum_x x p(x). \quad (1.2)$$

定义 1.3 (方差). 随机变量 X 的方差定义为:

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2. \quad (1.3)$$

1.1.2 连续随机变量

定义 1.4 (概率密度函数). 对于连续随机变量 X , 其概率密度函数 (PDF) $f(x)$ 满足:

$$P(a \leq X \leq b) = \int_a^b f(x) dx, \quad \int_{-\infty}^{\infty} f(x) dx = 1. \quad (1.4)$$

定义 1.5 (期望与方差). 连续随机变量 X 的期望与方差:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f(x) dx, \quad (1.5)$$

$$\text{Var}(X) = \int_{-\infty}^{\infty} (x - \mathbb{E}[X])^2 f(x) dx. \quad (1.6)$$

1.1.3 常见分布

(1) 二项分布 $X \sim \text{Binomial}(n, p)$:

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad \mathbb{E}[X] = np, \quad \text{Var}(X) = np(1-p). \quad (1.7)$$

(2) 泊松分布 $X \sim \text{Poisson}(\lambda)$:

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad \mathbb{E}[X] = \lambda, \quad \text{Var}(X) = \lambda. \quad (1.8)$$

(3) 正态分布 $X \sim \mathcal{N}(\mu, \sigma^2)$:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right). \quad (1.9)$$

(4) 多元正态分布 $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$:

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right). \quad (1.10)$$

1.2 条件概率与独立性

定义 1.6 (条件概率). 事件 A 在事件 B 发生条件下的概率:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0. \quad (1.11)$$

定理 1.1 (贝叶斯公式).

$$P(B_k | A) = \frac{P(A | B_k)P(B_k)}{\sum_i P(A | B_i)P(B_i)}. \quad (1.12)$$

定义 1.7 (独立性). 若 $P(A \cap B) = P(A)P(B)$, 则事件 A 与 B 独立。

1.3 矩与特征

定义 1.8 (协方差). 随机变量 X 与 Y 的协方差:

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]. \quad (1.13)$$

定义 1.9 (相关系数).

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}} \in [-1, 1]. \quad (1.14)$$

1.3.1 Pearson 与 Spearman 相关系数

上面定义的是理论上的 (总体) 相关系数 ρ 。实际中, 我们需要用样本数据估计它, 常用的有两种: Pearson 和 Spearman。

定义 1.10 (Pearson 相关系数 r). 样本 Pearson 相关系数度量的是线性相关程度:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}. \quad (1.15)$$

定义 1.11 (Spearman 秩相关系数 ρ_s). 将原始数据 x_i, y_i 分别替换为它们在各自序列中的排名（秩），然后对排名计算 Pearson 相关系数，即得 Spearman 相关系数。

等价公式（无结时）：

$$\rho_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}, \quad (1.16)$$

其中 d_i 为第 i 对数据的 x 排名与 y 排名之差。

定义 1.12 (Kendall 秩相关系数 τ). Kendall's τ 同样基于排名，但计算逻辑不同——它统计的是一致对与不一致对的数量。

对任意两对观测 (x_i, y_i) 和 (x_j, y_j) ($i < j$):

- 若 $(x_i - x_j)(y_i - y_j) > 0$: **一致对**（两变量同方向变化）
- 若 $(x_i - x_j)(y_i - y_j) < 0$: **不一致对**（两变量反方向变化）

令 n_c 为一致对数， n_d 为不一致对数，则：

$$\tau = \frac{n_c - n_d}{\frac{1}{2}n(n-1)}. \quad (1.17)$$

$\tau = 1$: 所有对都一致（完美正相关）； $\tau = -1$: 所有对都不一致（完美负相关）。

三者对比：

	Pearson r	Spearman ρ_s	Kendall τ
度量什么	线性相关程度	单调相关程度	排序一致程度
计算方式	原始值	原始值的 排名	一致对 vs 不一致对
对异常值	敏感	稳健	最稳健
对结（ties）	无影响	需要修正公式	天然处理结
样本效率	最高	中等	较低（需更多样本）
适用场景	近似正态、线性	非正态、单调	小样本、多结、定序数据

使用规则：

- 先画散点图。如果散点大致沿一条直线分布 → 用 Pearson；
- 如果散点呈曲线但有单调趋势 → 用 Spearman；
- 数据有严重离群值或明显不正态 → Spearman 或 Kendall；
- 样本量小（ $n < 30$ ）、有很多重复值（结）→ 优先 Kendall；

- **最佳实践：**三者都算。若结论一致（如都显著且方向相同），说明相关性结论**稳健**，可放心报告 Pearson。

r 与 r^2 的区别：

	r （相关系数）	r^2 （决定系数）
范围	$[-1, 1]$ （有方向）	$[0, 1]$ （无方向）
含义	方向和强度	变异解释比例
例子	$r = -0.5$ 表示中等负相关	$r^2 = 0.25$ 表示 X 解释了 Y 25% 的变异
关系	$r^2 = r \times r$ （仅在一元回归中等价于 R^2 ）	

注意：

- r^2 只在**一元线性回归**中等价于第 9 章定义的 R^2 ；
- 多元回归的 R^2 是所有自变量共同解释的比例，不是某个 r 的平方。

第二章 样本及抽样分布

2.1 随机样本

2.1.1 总体与样本

定义 2.1 (总体与个体). 总体（母体）是研究对象的全体，通常用一个随机变量 X 表示，其分布函数为 $F(x)$ 。个体是组成总体的每个元素。

定义 2.2 (简单随机样本). 设 X 是具有分布函数 F 的随机变量，若 $X_1, X_2, \dots, X_n$ 满足：

(i) **代表性**：每个 X_i 与 X 有相同的分布函数 F ；

(ii) **独立性**： $X_1, X_2, \dots, X_n$ 相互独立，

则称为来自总体 X 的容量为 n 的简单随机样本，简称样本。记作：

$$X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F(x). \quad (2.1)$$

当获得一组具体观测值 $x_1, x_2, \dots, x_n$ 时，称其为样本值。

注记 2.1 (总体、个体、样本：用三组例子建立直觉). ”总体”不是物理对象的集合，而是你关心的那个量在所有个体上的取值及其概率规律。

实际问题	总体（随机变量 X ）	个体	样本（ n 个个体的观测值）
评估灯泡寿命	这批灯泡的寿命值及其分布	每只灯泡	随机抽 n 只灯泡，测出其寿命 $x_1, \dots, x_n$
了解居民收入	某市所有居民的年收入分布	每位居民	随机调查 n 位居民的年收入 $x_1, \dots, x_n$
监控螺栓直径	某产线所有螺栓的直径分布	每个螺栓	随机抽取 n 个螺栓，测出直径 $x_1, \dots, x_n$

注意”样本”一词的双重含义：

语境	含义	记号
抽样前（理论上）	n 个随机变量，各与总体同分布且相互独立	大写 $X_1, \dots, X_n$
抽样后（实际上）	做实验得到的 n 个具体数字	小写 $x_1, \dots, x_n$

例如 $\bar{X} = \frac{1}{n} \sum X_i$ 是随机变量（统计量），而 $\bar{x} = \frac{1}{n} \sum x_i$ 是一个具体数值。整个统计推断的逻辑链是：用已知的 $\bar{x}$ 去反推未知的 μ ，中间桥梁是 $\bar{X}$ 的抽样分布。

注记 2.2（“简单随机样本”中“简单”与“随机”的含义）。**随机** = 抽样时每个个体被选入样本的概率均等，结果由概率决定而非人为挑选。

简单 = 满足两个条件：

(i) **代表性（同分布）**：每个 X_i 与总体 X 的波动规律完全相同。

反例——第 1 个灯泡来自 A 厂、第 2 个来自不相关的 B 厂，两者分布不同，不满足同分布。

(ii) **独立性**：知道 X_1 的取值不能提供任何关于 X_2 的信息。

反例——不放回抽样在有限总体中严格不独立，但当总体容量 $\gg n$ 时可近似视为独立。

两者本质上等价于 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F(x)$ （独立同分布样本）。

一句话区分：

术语	回答的问题
随机	谁被选入样本？——由概率决定，非人为挑选
简单	入选个体的数据有何规律？——彼此独立、同分布

从总体到统计量：四步概念梳理

以下用四步串联“总体 $\rightarrow$ 样本 $\rightarrow$ 统计量”的逻辑链条，并指出常见误区。

第 1 步 从总体中抽取一个容量为 n 的样本。

常见误区：“抽样 n 次”听起来像做了 n 轮独立实验，容易和重复抽样混淆。正确说法是：从总体 X 中一次性抽取 n 个独立同分布的个体，记作 $X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F(x)$ 。

第 2 步 每个 X_i 是独立同分布随机变量，但分布参数 μ, σ^2 未知。

在参数统计中，通常假设已知分布的形式（如正态），仅参数未知：

已知	未知
$X_i \sim \mathcal{N}(\mu, \sigma^2)$ （分布族）	μ 和 σ^2 的具体值
$X_i \sim \text{Bernoulli}(p)$	p 的具体值

如果连分布形式都不知道，那属于非参数统计的范畴。后续所有内容（MLE、 t 检验、置信区间）均建立在“已知分布族，未知参数”的前提下。

关键区分： μ 和 σ^2 是总体的均值和方差（固定但未知的常数）； $\bar{X}$ 和 S^2 是样本的均值和方差（随机变量，用来估计它们）。

第 3 步 定义样本均值 $\bar{X}$ ——第一个核心统计量。

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad (2.2)$$

注意：不是 $\hat{X}$ ！标准写法是 $\bar{X}$ ($\bar{\{X\}}$)，读作“X bar”。

$\bar{X}$ 有两个身份：

- **统计量：**抽样前是随机变量，有自己的分布 $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$
- **估计量：**用来估计总体均值 μ ，且是无偏的 ($\mathbb{E}[\bar{X}] = \mu$)


这里没有“组”的概念——“组内均值”是 ANOVA 里的术语（多组比较时组内 vs. 组间）。在单样本场景下，它就是样本均值。

第 4 步 定义样本方差 S^2 ——第二个核心统计量。

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (2.3)$$

用于刻画样本内部的离散程度（而非“组内差异”），同时也是总体方差 σ^2 的无偏估计量。分母 $n-1$ 的来源已在上一节完整推导。

四步总览：



整个数理统计的核心任务就是：用已知的 $\bar{x}$ 和 s^2 （观测值）反推未知的 μ 和 σ^2 （总体参数），而反推的依据就是 $\bar{X}$ 和 S^2 的抽样分布。

定义 2.3 (统计量). 设 $X_1, \dots, X_n$ 是来自总体 X 的样本， $g(x_1, \dots, x_n)$ 是不含任何未知参数的函数，则称

$$T = g(X_1, X_2, \dots, X_n) \quad (2.4)$$

为一个**统计量**。统计量是随机变量的函数，因此它本身也是一个随机变量。

2.1.2 常用统计量

定义 2.4 (样本均值).

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i. \quad (2.5)$$

定义 2.5 (样本方差与样本标准差).

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad (2.6)$$

$$S = \sqrt{S^2}. \quad (2.7)$$

为什么分母是 $n-1$? ——完整推导

推导目标

证明: 若用 $n-1$ 作分母, 则 $\mathbb{E}[S^2] = \sigma^2$ (无偏); 若用 n 作分母, 则估计有偏。

前提假设

设总体 X 的均值 $\mathbb{E}[X] = \mu$, 方差 $\text{Var}(X) = \sigma^2$ 。 $X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} X$, 样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 。

关键恒等式

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2. \quad (2.8)$$

验证:

$$\begin{aligned} \sum_{i=1}^n (X_i - \bar{X})^2 &= \sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2) = \sum_{i=1}^n X_i^2 - 2\bar{X} \underbrace{\sum_{i=1}^n X_i}_{=n\bar{X}} + n\bar{X}^2 \\ &= \sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2. \end{aligned}$$

逐项求期望

第一项: $\mathbb{E}[\sum X_i^2]$

对每个 X_i , 由 $\text{Var}(X_i) = \mathbb{E}[X_i^2] - (\mathbb{E}[X_i])^2$, 得:

$$\mathbb{E}[X_i^2] = \text{Var}(X_i) + (\mathbb{E}[X_i])^2 = \sigma^2 + \mu^2. \quad (2.9)$$

由于 n 个变量同分布:

$$\mathbb{E}\left[\sum_{i=1}^n X_i^2\right] = \sum_{i=1}^n \mathbb{E}[X_i^2] = n(\sigma^2 + \mu^2). \quad (2.10)$$

第二项: $\mathbb{E}[n\bar{X}^2]$

先求 $\bar{X}$ 的期望与方差:

$$\mathbb{E}[\bar{X}] = \mathbb{E}\left[\frac{1}{n} \sum X_i\right] = \frac{1}{n} \sum \mathbb{E}[X_i] = \mu, \quad (2.11)$$

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n} \sum X_i\right) = \frac{1}{n^2} \sum \text{Var}(X_i) \quad (\text{独立性}) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}. \quad (2.12)$$

于是:

$$\mathbb{E}[\bar{X}^2] = \text{Var}(\bar{X}) + (\mathbb{E}[\bar{X}])^2 = \frac{\sigma^2}{n} + \mu^2. \quad (2.13)$$

因此:

$$\mathbb{E}[n\bar{X}^2] = n \cdot \mathbb{E}[\bar{X}^2] = n \left(\frac{\sigma^2}{n} + \mu^2 \right) = \sigma^2 + n\mu^2. \quad (2.14)$$

合并得到最终结果

将式 (2.10) 与 (2.14) 代入恒等式 (2.8) 的期望:

$$\begin{aligned} \mathbb{E}\left[\sum_{i=1}^n (X_i - \bar{X})^2\right] &= \mathbb{E}\left[\sum_{i=1}^n X_i^2\right] - \mathbb{E}[n\bar{X}^2] \\ &= n(\sigma^2 + \mu^2) - (\sigma^2 + n\mu^2) \\ &= (n-1)\sigma^2. \end{aligned} \quad (2.15)$$

结论

定义 2.6 (无偏样本方差). 由式 (2.15), 定义:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad (2.16)$$

则有:

$$\mathbb{E}[S^2] = \frac{1}{n-1} \cdot (n-1)\sigma^2 = \sigma^2. \quad (2.17)$$

即 S^2 是总体方差 σ^2 的无偏估计量。

注记 2.3 (若用 n 作分母). 定义有偏版本 $\tilde{S}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = B_2$ (二阶中心矩), 则:

$$\mathbb{E}[\tilde{S}^2] = \frac{n-1}{n} \sigma^2 < \sigma^2 \quad (n \geq 2). \quad (2.18)$$

它系统性地低估总体方差。当 $n \rightarrow \infty$ 时 $\frac{n-1}{n} \rightarrow 1$, 故 $\tilde{S}^2$ 是渐近无偏的。

直观解释：自由度的损失

为什么“丢失”了 1？因为我们在计算 $\bar{X}$ 时用掉了数据的一个线性关系：

$$\sum_{i=1}^n (X_i - \bar{X}) = 0. \quad (2.19)$$

这个约束意味着 n 个偏差 $(X_i - \bar{X})$ 中只有 $n - 1$ 个是可以自由变化的。因此自由度为 $n - 1$ ，除以 $n - 1$ 才能得到无偏估计。

可以这样记忆：

- $\bar{X}$ 是 μ 的无偏估计，分母用 n （自由度 = n ）
- S^2 是 σ^2 的无偏估计，分母用 $n - 1$ （自由度 = $n - 1$ ，因为用 $\bar{X}$ 替代了 μ ）

定义 2.7 (样本 k 阶原点矩与中心矩).

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \quad (k \text{ 阶原点矩}), \quad (2.20)$$

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k \quad (k \text{ 阶中心矩}). \quad (2.21)$$

定义 2.8 (次序统计量). 将样本观测值从小到大排序: $x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)}$, 对应的随机变量 $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ 称为次序统计量。

- $X_{(1)} = \min\{X_1, \dots, X_n\}$ —最小次序统计量
- $X_{(n)} = \max\{X_1, \dots, X_n\}$ —最大次序统计量
- 样本中位数 M_e , 样本极差 $R = X_{(n)} - X_{(1)}$

2.2 直方图和箱线图

2.2.1 直方图

绘制步骤：

1. 将数据范围分成若干等宽区间（组距）；
2. 统计落入每个区间的数据个数（频数）或比例（频率）；
3. 以区间为底、频数/频率为高画矩形。

作用：观察数据分布的形态——对称性、偏态、峰度、是否多峰、是否有离群值。

2.2.2 箱线图

五数概括:

- 最小值 $x_{\min}$ (或下须线端点)
- 第一四分位数 Q_1 (第 25 百分位数)
- 中位数 M_e (第 50 百分位数)
- 第三四分位数 Q_3 (第 75 百分位数)
- 最大值 $x_{\max}$ (或上须线端点)

四分位距:

$$\text{IQR} = Q_3 - Q_1. \quad (2.22)$$

异常值检测: 小于 $Q_1 - 1.5 \times \text{IQR}$ 或大于 $Q_3 + 1.5 \times \text{IQR}$ 的值视为异常值。

箱线图结构示意图




图 2.1: 箱线图结构示意。箱体范围从 Q_1 到 Q_3 , 箱内红线为中位数 M_e 。须线延伸至非异常值的最远端。虚线的内限 (fence, $Q_1 \pm 1.5 \times \text{IQR}$) 之外的点为异常值/离群点 (红色圆点)。

异常值判定规则

条件	判定	标记方式
$Q_1 - 3 \times \text{IQR} \leq x_i < Q_1 - 1.5 \times \text{IQR}$	温和异常值	●
$x_i < Q_1 - 3 \times \text{IQR}$	极端异常值	● (或 ★)
$Q_3 + 1.5 \times \text{IQR} < x_i \leq Q_3 + 3 \times \text{IQR}$	温和异常值	●
$x_i > Q_3 + 3 \times \text{IQR}$	极端异常值	●

2.2.3 经验分布函数

定义 2.9 (经验分布函数). 设样本观测值为 $x_1, \dots, x_n$, 经验分布函数定义为:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{x_i \leq x\}} = \frac{\#\{i : x_i \leq x\}}{n}. \quad (2.23)$$

由格里汶科定理, $n \rightarrow \infty$ 时 $F_n(x)$ 一致收敛于总体分布 $F(x)$ 。

2.3 抽样分布

统计量的分布称为**抽样分布**。下面介绍三大重要抽样分布。

2.3.1 χ^2 分布 (卡方分布)

历史背景

1900 年, 英国统计学家 **Karl Pearson** (卡尔·皮尔逊) 在研究分类数据的拟合优度时, 发现了一个核心问题: 掷骰子 60 次, 各面分别出现 10, 8, 12, 9, 11, 10 次——这是正常的随机波动, 还是骰子有问题? 他把观测频数与期望频数的偏差平方除期望频数后求和, 发现这个统计量在大样本下服从一个特定分布, 他将其称为 χ^2 分布。这篇论文标志着现代假设检验的诞生。

为什么叫“卡方”? χ 是希腊字母 chi (读作“卡”), χ^2 就是“chi 的平方”。它本质上是 n 个独立标准正态随机变量的平方和。

直观理解

想象你从 $\mathcal{N}(0, 1)$ 中独立抽取 n 个值 $Z_1, \dots, Z_n$:

- 每个 Z_i^2 都是非负的, 大多数在 0 到 1 之间 (因为 $P(|Z| < 1) \approx 68\%$)
- 把 n 个这样的非负数加起来, 总和大概在 n 附近——这就是 $\mathbb{E}[\chi^2] = n$ 的直觉
- n 越大, 求和的结果波动越大—— $\text{Var}(\chi^2) = 2n$ 反映了这一点

自由度 n = 独立信息的个数。每用掉一个估计量 (如用 $\bar{X}$ 替代 μ), 自由度减 1。

核心问题: 总体不是 $\mathcal{N}(0, 1)$ 时怎么用卡方?

这是初学者最困惑的地方。 χ^2 分布的定义要求 $X_i \sim \mathcal{N}(0, 1)$, 但在实际中你只知道 $X_i \sim \mathcal{N}(\mu, \sigma^2)$, μ 和 σ^2 都未知。怎么把一般的正态样本转化为卡方变量?

完整推导流程 (三步桥接):

第 1 步 先假设 μ 已知——标准化。

若 μ 已知，对每个 X_i 做标准化：

$$Z_i = \frac{X_i - \mu}{\sigma} \sim \mathcal{N}(0, 1). \quad (2.24)$$

那么 n 个 Z_i 的平方和就是卡方：

$$\sum_{i=1}^n Z_i^2 = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 \sim \chi^2(n). \quad (2.25)$$

自由度是 n ，因为 n 个 X_i 提供了 n 个独立信息，没有被消耗的。

第 2 步 现实中 μ 未知——用 $\bar{X}$ 替代 μ ，自由度减 1。

实际中 μ 未知，你只能用 $\bar{X}$ 来替代它：

$$\sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma} \right)^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2. \quad (2.26)$$

这个量还是卡方吗？是的，但自由度减少了 1：

$$\boxed{\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \sim \chi^2(n-1)}. \quad (2.27)$$

为什么自由度从 n 变成 $n-1$ ？

因为 $\bar{X}$ 是从数据本身估计出来的，这引入了一个约束： $\sum_{i=1}^n (X_i - \bar{X}) = 0$ 。 n 个偏差中只有 $n-1$ 个可以自由变化，最后一个被前 $n-1$ 个决定。每消耗一个估计量（用 $\bar{X}$ 替代 μ ），自由度就减 1。这就和之前推导 S^2 时 $\mathbb{E}[S^2] = \sigma^2$ （分母 $n-1$ ）是同一个逻辑。

第 3 步 等价形式——用样本方差 S^2 表达。

由 $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ ，式 (2.27) 等价于：

$$\boxed{\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)}. \quad (2.28)$$

这是最常用的形式，因为 S^2 可以直接从样本算出来。

完整数值示例：

假设某工厂螺栓直径服从 $\mathcal{N}(\mu, \sigma^2)$ ， μ 和 σ^2 均未知。抽取 $n = 10$ 个螺栓，测得样本方差 $s^2 = 0.04$ 。

- 若想知道 σ^2 是否等于某标称值 $\sigma_0^2 = 0.02$ ：

- 计算检验统计量: $\frac{(n-1)s^2}{\sigma_0^2} = \frac{9 \times 0.04}{0.02} = 18$
- 在原假设 $H_0: \sigma^2 = 0.02$ 下, 该统计量 $\sim \chi^2(9)$
- 查表: $\chi_{0.05}^2(9) \approx 16.92$, $18 > 16.92$, 拒绝 H_0 , 认为实际方差偏大

一句话总结:

χ^2 定义要求的标准正态 $\xrightarrow{\text{标准化 } Z_i = \frac{X_i - \mu}{\sigma}}$ 一般正态样本 $\xrightarrow{\mu \text{ 未知, 用 } \bar{X} \text{ 替代}}$ $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$

典型应用场景

- (1) 方差估计与检验: $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$, 用于构造 σ^2 的置信区间和检验 $H_0: \sigma^2 = \sigma_0^2$ (已在上节详述)
- (2) 拟合优度检验 (Pearson χ^2 检验): 检验观测数据是否符合某个理论分布
- (3) 独立性检验 (列联表): 检验两个分类变量是否独立
- (4) 机器学习中的特征选择: χ^2 检验用于评估分类特征与标签之间的相关性

拟合优度检验——完整流程与实例

问题: 骰子是否均匀? 掷 60 次, 观测到各面出现的次数为:

骰子面	1	2	3	4	5	6	合计
观测频数 O_i	7	12	9	13	8	11	60

第 1 步: 建立假设。

- H_0 : 骰子是均匀的 (每一面出现的概率 $p_i = \frac{1}{6}$)
- H_1 : 骰子不均匀 (至少有一面概率 $\neq \frac{1}{6}$)

第 2 步: 计算期望频数 E_i 。

在 H_0 成立的前提下, 每一面的期望频数 $= n \times p_i = 60 \times \frac{1}{6} = 10$ 。

骰子面	1	2	3	4	5	6
期望频数 E_i	10	10	10	10	10	10

第 3 步：计算 Pearson χ^2 统计量。

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}. \quad (2.29)$$

核心直觉：分子 $(O_i - E_i)^2$ 度量“观测与期望偏离了多少”；分母 E_i 做归一化（ E_i 大的类别允许更大的绝对偏差）。

逐项计算：

$$\begin{aligned} \frac{(7-10)^2}{10} + \frac{(12-10)^2}{10} + \frac{(9-10)^2}{10} + \frac{(13-10)^2}{10} + \frac{(8-10)^2}{10} + \frac{(11-10)^2}{10} &= \frac{9+4+1+9+4+1}{10} \\ &= 2.8. \end{aligned} \quad (2.30)$$

(2.31)

第 4 步：确定自由度，查临界值。

- $k = 6$ 个类别
- 没有从数据中估计任何参数（ $m = 0$ ，概率 p_i 完全由 H_0 指定，而非从样本估计）
- 约束： $\sum O_i = n$ （每个观测值贡献独立信息，但总和固定），消耗 1 个自由度
- 自由度： $df = k - 1 - m = 6 - 1 - 0 = 5$

在大样本下， $\chi^2 = 2.8 \sim \chi^2(5)$ 。取 $\alpha = 0.05$ ，查表得 $\chi_{0.05}^2(5) \approx 11.07$ 。

第 5 步：做结论。

$2.8 < 11.07$ ，统计量不在拒绝域内，不能拒绝 H_0 ——现有数据不足以认为骰子不均匀。

自由度公式解释： $df = k - 1 - m$

- k ：类别数
- -1 ：因为 $\sum O_i = n$ 是一个固定约束（给定总数后， k 个类别中只有 $k - 1$ 个可自由变化）
- $-m$ ：如果 H_0 中的分布参数不是预先指定的，而是先用样本估计的，每估计一个参数再减 1 个自由度。

例：若检验“数据是否服从正态分布”但 μ, σ^2 都需从样本估计，则 $m = 2$ ， $df = k - 1 - 2$

概念澄清：常见用词误区

以下用上述“掷骰子”例子对照，纠正初学者在描述流程时常犯的用词错误。

易错表述	问题	正确表述
“从认为的概率推出统计量”	期望频数 E_i 不是统计量！统计量是从样本算出的随机变量	$E_i = n \times p_i^{(0)}$ 是 H_0 的推演结果（确定值）； $\chi^2 = \sum (O_i - E_i)^2 / E_i$ 才是检验统计量
“对两组统计结果进行处理”	不是“两组数据”！是同一批样本的两套频数	观测频数 O_i vs. H_0 下的期望频数 E_i
“用卡方进行检验”	不是直接用卡方分布去“测”	构造 Pearson χ^2 统计量，利用其在 H_0 下的渐近分布做决策

修正后的五步标准流程：

第 1 步 提出 H_0 ：数据来自某个已知分布（如每面概率 $p_i = 1/6$ ）。

第 2 步 计算期望频数 $E_i = n \times p_i^{(0)}$ ——这是确定性的数值，不是统计量。

第 3 步 构造检验统计量 $\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$ ——这才是从样本算出的统计量。

第 4 步 确定自由度 $df = k - 1 - m$ ，查 χ^2 临界值。

第 5 步 比较并做结论：若 $\chi^2 > \chi_\alpha^2(df)$ ，拒绝 H_0 。

核心原理：为什么 $\sum (O_i - E_i)^2 / E_i$ 服从 χ^2 分布？

这是 Pearson 在 1900 年做出的最深洞察。以下分三步推导。

第 1 步：每个格子的 O_i 本质上是什么？

O_i 是 n 个独立个体中落入第 i 类的个数。在 H_0 下，每个个体以概率 p_i 落入第 i 类。因此：

$$O_i \sim \text{Binomial}(n, p_i), \quad \mathbb{E}[O_i] = np_i = E_i, \quad \text{Var}(O_i) = np_i(1 - p_i). \quad (2.32)$$

第 2 步：标准化——从二项到近似标准正态。

由中心极限定理（ n 大时二项分布近似正态）：

$$\frac{O_i - E_i}{\sqrt{np_i(1 - p_i)}} \xrightarrow{d} \mathcal{N}(0, 1). \quad (2.33)$$

在实际应用中，大多数 p_i 不大， $1 - p_i \approx 1$ ，分母可近似为 $\sqrt{np_i} = \sqrt{E_i}$ ：

$$\boxed{\frac{O_i - E_i}{\sqrt{E_i}} \approx \mathcal{N}(0, 1)} \quad (2.34)$$

这一项就是第 i 类的**标准化偏差**——“观测值偏离了期望值几个标准差”。

第 3 步：平方求和——从正态到卡方。

χ^2 分布的定义就是 k 个独立标准正态的平方和。因此：

$$\boxed{\chi^2 = \sum_{i=1}^k \left(\frac{O_i - E_i}{\sqrt{E_i}} \right)^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \sim \chi^2(k-1)} \quad (2.35)$$

为什么自由度是 $k-1$ 而非 k ？

因为 $\sum_{i=1}^k O_i = n$ 是一个固定约束—— k 个偏差中只有 $k-1$ 个可以独立变化，最后一个被前 $k-1$ 个自动决定。（若 H_0 中有 m 个参数是用样本估计的，则再减 m 。）

一句话直觉：

$$\frac{O_i - E_i}{\sqrt{E_i}} \xrightarrow[\text{平方}]{} \frac{(O_i - E_i)^2}{E_i} \xrightarrow[\text{对所有 } k \text{ 类求和}]{} \chi^2 \xrightarrow[\text{查表}]{} \text{判断是否显著偏离 } H_0$$

- 若 H_0 为真，每个 $\frac{O_i - E_i}{\sqrt{E_i}}$ 大约在 ± 1 范围内，平方后 ≈ 1 ，总和 $\approx k-1$ （即期望值 = 自由度）
- 若 H_0 为假，某些类别的偏差远大于 1 个标准差，平方后急剧放大，总和 $\gg k-1$ ，落入拒绝域

这就是为什么这个看似简单的公式能区分“随机波动”和“真正的分布差异”——它在数学上等价于把每个类别的标准化偏差平方后累加，然后用卡方分布精确量化“这么大的总和由纯随机产生的概率有多大”。

问题：性别与是否吸烟是否独立？调查 200 人，得到以下 2×2 列联表：

	吸烟	不吸烟	合计
男	60	40	100
女	30	70	100
合计	90	110	200

第 1 步：建立假设。

- H_0 ：性别与吸烟相互独立
- H_1 ：性别与吸烟不独立（存在关联）

第 2 步：在独立假设下计算期望频数。

若两个变量独立，则 $P(\text{男} \cap \text{吸烟}) = P(\text{男}) \times P(\text{吸烟})$ 。

推广到频数：

$$E_{ij} = \frac{(\text{第 } i \text{ 行合计}) \times (\text{第 } j \text{ 列合计})}{\text{总合计}}. \quad (2.36)$$

- E_{11} (男 $\times$ 吸烟): $\frac{100 \times 90}{200} = 45$
- E_{12} (男 $\times$ 不吸烟): $\frac{100 \times 110}{200} = 55$
- E_{21} (女 $\times$ 吸烟): $\frac{100 \times 90}{200} = 45$
- E_{22} (女 $\times$ 不吸烟): $\frac{100 \times 110}{200} = 55$

期望频数表：

	吸烟	不吸烟
男	45	55
女	45	55

第 3 步：计算 χ^2 统计量。

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}. \quad (2.37)$$

$$\chi^2 = \frac{(60 - 45)^2}{45} + \frac{(40 - 55)^2}{55} + \frac{(30 - 45)^2}{45} + \frac{(70 - 55)^2}{55} \quad (2.38)$$

$$= \frac{225}{45} + \frac{225}{55} + \frac{225}{45} + \frac{225}{55} \quad (2.39)$$

$$= 5 + 4.09 + 5 + 4.09 = 18.18. \quad (2.40)$$

第 4 步：确定自由度。

对于 $r \times c$ 列联表：

$$df = (r - 1) \times (c - 1). \quad (2.41)$$

直觉：在行和与列和固定的约束下，一旦你填了 $(r - 1) \times (c - 1)$ 个格子，其余格子被这些约束自动决定。本例中 $df = (2 - 1) \times (2 - 1) = 1$ 。

取 $\alpha = 0.05$ ，查表得 $\chi_{0.05}^2(1) \approx 3.84$ 。

第 5 步：做结论。

$18.18 \gg 3.84$ ，强烈拒绝 H_0 ——性别与吸烟之间存在显著关联（男性吸烟比例明显更高）。

拟合优度 vs. 独立性检验的对比：

	拟合优度检验	独立性检验
问题	观测数据符合某理论分布吗?	两个变量独立吗?
H_0	$p_i = p_i^{(0)}$ (给定概率)	$P(A \cap B) = P(A)P(B)$
E_i 来源	$n \times p_i^{(0)}$ (由 H_0 指定)	行合计 $\times$ 列合计 $\div$ 总合计 (由边际推算)
自由度	$k - 1 - m$	$(r - 1)(c - 1)$
数据结构	单行频数向量	$r \times c$ 二维列联表

共同假设：两者都要求期望频数 $E_i \geq 5$ (大样本条件)，否则需用 Fisher 精确检验替代。

定义与性质

定义 2.10 (χ^2 分布). 设 $X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$, 则

$$\chi^2 = \sum_{i=1}^n X_i^2 \sim \chi^2(n), \quad (2.42)$$

称 χ^2 服从自由度为 n 的卡方分布。

性质：

- $\mathbb{E}[\chi^2] = n, \quad \text{Var}(\chi^2) = 2n$
- 可加性：若 $\chi_1^2 \sim \chi^2(n_1), \chi_2^2 \sim \chi^2(n_2)$ 且独立，则 $\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2)$
- $n \rightarrow \infty$ 时 $(\chi^2(n) - n)/\sqrt{2n} \xrightarrow{d} \mathcal{N}(0, 1)$

定义 2.11 (χ^2 分布的上 α 分位点). 点 $\chi_\alpha^2(n)$ 满足：

$$P(\chi^2 > \chi_\alpha^2(n)) = \int_{\chi_\alpha^2(n)}^{\infty} f_{\chi^2}(y) dy = \alpha. \quad (2.43)$$

2.3.2 t 分布 (学生氏分布)

历史背景——“Student” 的真实身份

1908 年，都柏林 Guinness (健力士) 啤酒厂的一位化学师发表了一篇题为 “The Probable Error of a Mean” 的论文，署名 “Student”。他的真名叫 **William Sealy Gosset** (戈塞特)。

为什么化名？Guinness 公司禁止员工发表论文 (担心泄露商业机密)，Gosset 只能用笔名发表。

他解决了什么问题？在啤酒酿造中，他需要用少量样本（如 $n = 3$ 或 4 ）来估计麦芽质量的平均值。当用 S 替代 σ 时， $\frac{\bar{X} - \mu}{S/\sqrt{n}}$ 不再服从正态分布——因为在分母中用随机量 S 代替了常数 σ ，引入了额外的不确定性。它实际上服从一种“尾部更厚”的分布——这就是 t 分布。

核心洞察： t 分布是专门为“做实验只有 5 个数据点，但还要做统计推断”这种情况设计的。这就是为什么 t 分布也被称为小样本分布。

直观理解


对比两个看起来很相似的量：

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1) \quad \text{——分母是常数 } \sigma, \text{ 精确} \quad (2.44)$$

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1) \quad \text{——分母是随机量 } S, \text{ 有波动} \quad (2.45)$$

S 有时比 σ 小，有时比 σ 大。当 S 偏小时， $|T|$ 就被放大了。这导致 t 分布比正态分布尾部更厚（极端值更可能出现）。

当 $n \rightarrow \infty$, $S \xrightarrow{P} \sigma$, t 分布退化为标准正态分布。 $n \geq 30$ 时两者差异已不大。



核心桥梁： S 怎样与 χ^2 挂钩——从 t 定义到 t 检验

这是理解 t 检验最关键的一步。 t 分布的定义是 $T = \frac{X}{\sqrt{Y/n}}$ ，其中 $X \sim \mathcal{N}(0, 1)$, $Y \sim \chi^2(n)$ 。但 t 检验的统计量是 $T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$ ——这里 S 是样本标准差，不是 χ^2 变量。那么 T 为什么服从 t 分布？

关键在于分子分母同做代数变形，把 S 转化为 χ^2 的形式。

完整推导：

第 1 步 分离 σ ——分子分母同除 σ 。

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} = \frac{(\bar{X} - \mu_0)/(\sigma/\sqrt{n})}{\sqrt{S^2/\sigma^2}} = \frac{Z}{\sqrt{\frac{(n-1)S^2/\sigma^2}{n-1}}} \quad (2.46)$$

令：

- $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$ ——分子是标准正态
- $Y = \frac{(n-1)S^2}{\sigma^2}$ ——分母根号里的分子

第 2 步 识别两个分量的分布。

- $Z \sim \mathcal{N}(0, 1)$: 这是正态总体下样本均值的标准化形式。
- $Y = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$: 这是正态总体抽样分布的定理——已在 χ^2 节“核心问题”中完整推导。本质是 n 个标准正态平方和，用 $\bar{X}$ 替代 μ 后自由度减 1。
- $\bar{X}$ 与 S^2 相互独立（仅对正态总体成立!） $\implies Z$ 与 Y 独立。

第 3 步 套入 t 分布的定义。

$$T = \frac{Z}{\sqrt{Y/(n-1)}} \sim t(n-1). \quad (2.47)$$

这正是 t 分布的标准形式：分子 $\mathcal{N}(0, 1)$ ，分母 $\sqrt{\chi_{n-1}^2/(n-1)}$ ，两者独立。

一句话总结：

$$\underbrace{\frac{\bar{X} - \mu_0}{S/\sqrt{n}}}_{\text{你计算的东西}} = \frac{\overbrace{\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}}^{\sim \mathcal{N}(0,1)}}{\sqrt{\underbrace{\frac{(n-1)S^2}{\sigma^2}}_{\sim \chi^2(n-1)}}/(n-1)} \sim t(n-1).$$

没有这两个事实， t 检验就不存在：

- (1) $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ ——把 S 桥接到 χ^2
- (2) $\bar{X}$ 与 S^2 独立——保证分子分母独立（仅正态总体有此性质）

这就是为什么 t 检验假设数据来自正态总体——如果总体不正态， $\bar{X}$ 和 S^2 不一定独立， $(n-1)S^2/\sigma^2$ 也不精确服从 χ^2 ，整个推导链条就断了。

典型应用场景

- (1) 小样本均值的置信区间与检验（ σ 未知）：最核心的应用。如 10 个病人的血压变化是否显著？用 t 检验
- (2) 两样本均值比较（ t 检验）：A/B 测试中判断实验组与对照组均值差异是否显著
- (3) 回归系数的显著性检验： $\frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)} \sim t(n-p-1)$ ，判断某个特征对目标变量是否有显著影响（线性回归输出中的 p 值来自 t 分布）
- (4) 配对 t 检验：同一样本处理前后比较，如服药前 vs. 服药后
- (5) 机器学习中的特征筛选：对每个特征做两样本 t 检验，筛选出有区分力的特征

单样本 t 检验——完整流程与实例

问题：某新药声称能降低收缩压。给 $n = 10$ 位患者服药，测量服药前后收缩压的差值 X_i ($X_i =$ 服药后 $-$ 服药前，负值表示血压下降)：

患者	1	2	3	4	5	6	7	8	9	10
血压变化 x_i (mmHg)	-5	-2	-8	-3	-1	-6	-4	-7	-2	-3

- 样本量 $n = 10$
- 样本均值 $\bar{x} = \frac{1}{10} \sum x_i = -4.1$ (平均降低 4.1 mmHg)
- 样本标准差 $s = \sqrt{\frac{1}{9} \sum (x_i - \bar{x})^2} \approx 2.38$
- 总体标准差 σ 未知！

第 1 步：建立假设。

- $H_0: \mu = 0$ (药物无效，血压没有变化)
- $H_1: \mu < 0$ (药物有效，血压下降) ——单侧 (左尾) 检验

第 2 步：构造检验统计量。

若 σ 已知，自然用 $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$ 。但 σ 未知，只能用 S 替代 σ ，统计量变为：

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1). \quad (2.48)$$

代入数值：

$$t = \frac{-4.1 - 0}{2.38/\sqrt{10}} = \frac{-4.1}{0.753} \approx -5.45. \quad (2.49)$$

为什么不能直接用正态分布？分母 S 是随机变量 (不是常数 σ)，引入了额外的不确定性。 t 分布的尾部比正态更厚，正是为了补偿“用 S 替代 σ ”带来的额外风险。当 $n = 10$ ($df = 9$) 时， $t_{0.05}(9) \approx 1.833$ 而 $z_{0.05} = 1.645$ —— t 检验更保守，需要更大的 $|T|$ 才能拒绝 H_0 。

第 3 步：确定自由度，查临界值。

自由度为 $n - 1 = 9$ 。取 $\alpha = 0.05$ 。

因为是单侧左尾检验：拒绝域为 $T < -t_{\alpha}(n-1)$ 。查表得 $t_{0.05}(9) \approx 1.833$ ，故拒绝域为 $T < -1.833$ 。

第 4 步：做决策。

$t = -5.45 < -1.833$ ，检验统计量落入拒绝域。拒绝 H_0 ，认为药物能显著降低血压。等价地，可计算 p 值： $p = P(T < -5.45 \mid df = 9) \ll 0.001$ ，远小于 $\alpha = 0.05$ 。

第 5 步：报告同时给出置信区间 (良好实践)。

不仅说” 有无效果”，还应给出效果大小的范围估计。 μ 的 95% 置信区间（双侧）：

$$\bar{x} \pm t_{\alpha/2}(n-1) \cdot \frac{s}{\sqrt{n}} = -4.1 \pm t_{0.025}(9) \times 0.753.$$

(2.50)

查表 $t_{0.025}(9) \approx 2.262$ ：

$$-4.1 \pm 2.262 \times 0.753 = (-5.80, -2.40).$$

(2.51)

解读：有 95% 的把握认为，该药平均降低收缩压 2.40 到 5.80 mmHg（整个区间在 0 以下，与拒绝 H_0 的结论一致）。

双侧 vs. 单侧：什么时候用哪个？

	双侧检验	单侧检验
H_1	$\mu \neq \mu_0$ （有差异，不管方向）	$\mu < \mu_0$ 或 $\mu > \mu_0$ （有方向的差异）
拒绝域	$ T > t_{\alpha/2}(n-1)$	$T < -t_{\alpha}(n-1)$ 或 $T > t_{\alpha}(n-1)$
适用场景	新药是否改变了血压（不确定方向）	新药是否降低了血压（有先验方向）

单样本 t 检验与 z 检验的对比总结：

	z 检验（ σ 已知）	t 检验（ σ 未知）
检验统计量	$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$	$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$
分布	$\mathcal{N}(0, 1)$ （精确）	$t(n-1)$ （ σ 未知时的精确分布）
适用条件	σ 已知，或 n 很大（ ≥ 30 ）	σ 未知，尤其 $n < 30$
实际中多用谁	几乎只存在于教科书	现实中的默认选择—— σ 几乎永远是未知的
关系	$n \rightarrow \infty$ 时 $t \rightarrow z$	n 大时 $t \approx z$ ， $n \geq 30$ 时差异可忽略

关键前提：为什么假定 X_i 服从正态分布？违背了怎么办？

t 检验的全部推导基于一个核心前提：**数据来自正态总体**。在血压例子中，这意味着假定 10 位患者的血压变化值 $X_1, \dots, X_{10} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$ 。

这并不是一个” 已被证明的事实”，而是一个建模假设。

为什么这个假设在血压例子中合理？

血压是大量微小生理因素叠加的结果——心率、血管阻力、激素水平、测量误差……根据中心极限定理，大量独立微小效应的叠加趋向正态分布。同类医学研究中，血压变化确实通常近似正态。

但并非所有场景都适用：

数据类型	为什么不正态	合适的方法
治愈天数	右偏（有下界 0，不能为负）	Wilcoxon 符号秩检验，或对数变换后做 t 检验
消费金额	长尾，少数人消费极高	同上
点击/计数	泊松型（方差 = 均值）	泊松回归，或平方根变换
比例/百分比	有界 $[0, 1]$ ，两端堆积	Beta 回归，或 logit 变换

正态假定违背了会怎样？

t 检验对正态性偏离有一定稳健性，但并非无限制：

偏离程度	后果	n 的影响
轻度偏态（略有不对称）	t 检验近似有效，影响不大	n 越大越安全（CLT 保证 $\bar{X}$ 渐近
重尾或有离群值	第一类错误率膨胀，可能误拒 H_0	n 再大也救不了（离群值不因 n 增大
严重偏态	检验功效下降，可能漏掉真实效应	需要换非参数方法

实际诊断流程（在跑 t 检验之前）：

- (1) 画 Q-Q 图（详见下方详解）
- (2) 做 Shapiro-Wilk 检验： H_0 为”数据来自正态分布”。若 $p > 0.05$ ，不拒绝正态性假定。
- (3) 若正态性不满足且 n 小：改用 Wilcoxon 符号秩检验——不要求正态，只要求分布对称。
这是 t 检验最常用的非参数替代方案。
- (4) 若 n 较大 (≥ 30)：由 CLT， $\bar{X}$ 近似正态， t 检验仍可近似使用（但仍需留意离群值）。

Q-Q 图详解：为什么能检查正态性？

什么是 Q-Q 图？

Q-Q 图（Quantile-Quantile Plot，分位数-分位数图）将样本的分位数与某个理论分布（如正态）的分位数画在同一张散点图上：

- **横轴：**理论分位数——例如 $\mathcal{N}(0, 1)$ 的第 $1/(n+1), 2/(n+1), \dots, n/(n+1)$ 分位数
- **纵轴：**样本分位数——将 n 个数据从小到大排序后对应的值

为什么正态数据落在一条直线上？

这是 Q-Q 图最核心的数学原理。

假设数据真的来自正态总体 $X \sim \mathcal{N}(\mu, \sigma^2)$ 。将 X 标准化： $Z = (X - \mu)/\sigma \sim \mathcal{N}(0, 1)$ 。

反过来写： $X = \mu + \sigma Z$ 。这意味着样本的第 p 分位数 $Q_X(p)$ 与标准正态的第 p 分位数 $Q_Z(p)$ 之间有线性关系：

$$Q_X(p) = \mu + \sigma \cdot Q_Z(p). \quad (2.52)$$

因此，若以 $Q_Z(p)$ 为横轴、 $Q_X(p)$ 为纵轴画散点图，正态数据应沿一条直线分布：

- **截距** $\approx \mu$ （数据均值）
- **斜率** $\approx \sigma$ （数据标准差）

数据是否在一条直线上就是 Q-Q 图判断正态性的全部依据——**形状比位置更重要**。截距和斜率不同只说明 $\mu \neq 0$ 或 $\sigma \neq 1$ ，这并不违背正态性。

常见偏离模式及其含义：

Q-Q 图形状	说明	暗示的分布特征
点沿一条直线	正态性良好	数据符合正态
两端向上翘（S 形上凸）	右尾偏长	右偏（正偏），如收入数据
两端向下弯（S 形下凹）	左尾偏长	左偏（负偏），如考试高分数据
左端下弯、右端上翘（反 S 形）	两端都长	重尾分布（比正态更易出极端值）
左端上翘、右端下弯	两端都短	轻尾分布（如均匀分布）

Q-Q 图 vs. 直方图：为什么 Q-Q 图更灵敏？

- 直方图：依赖分组宽度选择，小样本时很难判断尾部形态
- Q-Q 图：直接比较分位数，对尾部偏离特别敏感（因为两端点稀疏，偏离一目了然），且不依赖任何参数选择

实操规则：如果 Q-Q 图上的点大致沿一条直线，不必追求完美贴合（特别是两端几个点略有波动是正常的）。真正需要警惕的是系统性弯曲——所有点整体呈弧形或 S 形。

与 Shapiro-Wilk 检验的互补关系：




图 2.2: Q-Q 图的三种典型模式。左：正态数据，点沿直线分布。中：右偏数据，右端向上翘（S 形上凸）。右：重尾数据，左端下弯、右端上翘（反 S 形）。灰色对角线为参考线 $y = x$ 。

	Q-Q 图	Shapiro-Wilk 检验
本质	可视化工具	统计假设检验
优势	直观，一眼看出偏离类型（偏态/重尾）	给出 p 值，客观判断
劣势	依赖人眼判断，主观	n 大时过于敏感（轻微偏离也拒绝 H_0 ）
最佳实践	两者结合：先看 Q-Q 图判断偏离类型和程度，必要时用 SW 检验佐证	

注记 2.4 (关于 CLT 的一个重要但常被忽视的细节). CLT 保证了 $\bar{X}$ 的渐近正态性，但 t 检验还需要 S^2 的行为。若总体非正态， $(n-1)S^2/\sigma^2$ 不再精确服从 $\chi^2(n-1)$ ，且 $\bar{X}$ 与 S^2 也不一定独立。因此 $n = 30$ 的“经验法则”只能视为一个便利的近似，并非严格的数学保证。最安全的做法始终是用 Q-Q 图检查正态性，有疑虑时换非参数方法。

定义与性质

定义 2.12 (t 分布). 设 $X \sim \mathcal{N}(0, 1)$, $Y \sim \chi^2(n)$, 且 X 与 Y 相互独立, 则

$$T = \frac{X}{\sqrt{Y/n}} \sim t(n), \quad (2.53)$$

称 T 服从自由度为 n 的 t 分布。

性质:

- PDF 关于 $x = 0$ 对称, $\mathbb{E}[T] = 0$ ($n > 1$ 时)
- $\text{Var}(T) = \frac{n}{n-2}$ ($n > 2$)

- $n \rightarrow \infty$ 时 $t(n) \rightarrow \mathcal{N}(0, 1)$
- $n = 1$ 时即为柯西分布（期望不存在，尾部极厚）

定义 2.13 (t 分布的上 α 分位点). 点 $t_\alpha(n)$ 满足 $P(T > t_\alpha(n)) = \alpha$ 。由对称性: $t_{1-\alpha}(n) = -t_\alpha(n)$ 。

2.3.3 F 分布

历史背景

F 分布由英国统计学家 **Ronald A. Fisher**（费希尔）在 1920 年代提出，并以他姓氏的首字母命名。Fisher 是现代统计学的奠基人之一——他提出了极大似然估计、实验设计、ANOVA 等核心方法论。 F 分布最初正是为方差分析（ANOVA）设计的。

直观理解

F 分布本质上是两个独立的 χ^2 变量（各自除以自由度）的比值：

$$F = \frac{\chi_1^2/n_1}{\chi_2^2/n_2}. \quad (2.54)$$

这意味着什么？ F 统计量比较两个方差（或两种变异性来源）的大小：

- 分子 = “组间方差”，反映不同组之间均值的差异
- 分母 = “组内方差”，反映组内个体的随机波动
- 如果 $F \approx 1$ ，组间差异和组内波动差不多 $\rightarrow$ 各组可能来自同一总体
- 如果 $F \gg 1$ ，组间差异远大于随机波动 $\rightarrow$ 至少有一组明显不同

与 t 分布的关系: $T \sim t(n) \iff T^2 \sim F(1, n)$ 。 t 检验（比较两组均值）是 ANOVA（比较多组均值）在 $k = 2$ 时的特例。

典型应用场景

- (1) **方差分析 (ANOVA)**: 判断三组或以上样本的均值是否有显著差异。
例：三种教学方法的效果是否不同？A/B/C 三个版本的点击率是否不同？
- (2) **两正态总体方差比的检验与置信区间**: 检验 $H_0: \sigma_1^2 = \sigma_2^2$ 。
例：新工艺是否比旧工艺的波动更小（更稳定）？
- (3) **回归模型的整体显著性检验 (F 检验)**: 判断所有回归系数是否同时为 0。
$$F = \frac{R^2/p}{(1-R^2)/(n-p-1)} \sim F(p, n-p-1),$$
 检验“模型是否比纯截距模型好”

- (4) **机器学习中的特征选择**: ANOVA F 检验用于评估每个数值特征与分类标签的关联强度, scikit-learn 中的 `f_classif` 和 `SelectKBest` 即基于此
- (5) **模型比较**: 比较两个嵌套模型的拟合优度是否有显著差异 (Partial F 检验)

单因素 ANOVA——完整流程与实例

问题: 三种教学方法 (A: 传统讲授, B: 视频自学, C: 互动讨论) 是否对考试成绩有不同影响? 每种方法随机分配 6 名学生, 期末考试成绩如下:

方法	学生成绩						组均值
A (传统)	78	82	85	90	76	88	$\bar{x}_A = 83.17$
B (视频)	65	70	72	68	74	69	$\bar{x}_B = 69.67$
C (互动)	82	85	88	79	91	84	$\bar{x}_C = 84.83$
总均值 $\bar{x} = 79.22$, 总样本量 $N = 18$							

为什么不能用三次 t 检验代替一次 ANOVA?

如果做三次两两 t 检验 (A vs. B, B vs. C, A vs. C), 每次 $\alpha = 0.05$, 累积犯第一类错误的概率为 $1 - (1 - 0.05)^3 \approx 0.143$, 远超预设的 0.05。ANOVA 通过一次检验同时比较所有组, 控制整体错误率。

核心直觉: 比较两种”波动来源”

把 18 个学生的成绩波动拆成两部分:

$$\underbrace{\text{总变异 } SS_T}_{18 \text{ 个分数各不相同}} = \underbrace{\text{组间变异 } SS_B}_{\text{三组的均值不同}} + \underbrace{\text{组内变异 } SS_W}_{\text{同组内学生仍有差异}}$$

- 若 H_0 为真 (三种方法效果相同), 组间差异 $\approx$ 随机波动 $\rightarrow SS_B/SS_W \approx 1$
- 若 H_0 为假 (至少一种方法不同), 组间差异 $\gg$ 随机波动 $\rightarrow SS_B/SS_W \gg 1$

F 统计量正是这两种变异的比值 (经自由度调整后)。

第 1 步: 建立假设。

- $H_0: \mu_A = \mu_B = \mu_C$ (三种方法的总体均值相等)
- H_1 : 至少有一个 μ_i 不同

第 2 步: 计算各项平方和。

总平方和 SS_T (Total): 每个数据点偏离总均值的平方和。

$$SS_T = \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x})^2. \quad (2.55)$$

组间平方和 SS_B (Between): 每组均值偏离总均值的平方和 (按样本量加权)。

$$SS_B = \sum_{i=1}^k n_i (\bar{x}_i - \bar{x})^2. \quad (2.56)$$

组内平方和 SS_W (Within): 每个数据点偏离其组均值的平方和。

$$SS_W = \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_i)^2. \quad (2.57)$$

且恒有 $SS_T = SS_B + SS_W$ (可验证)。

代入本例数值:

$$\begin{aligned} SS_B &= 6 \times (83.17 - 79.22)^2 + 6 \times (69.67 - 79.22)^2 + 6 \times (84.83 - 79.22)^2 \\ &= 6 \times (3.95^2 + (-9.56)^2 + 5.61^2) \\ &= 6 \times (15.60 + 91.31 + 31.47) = 830.28. \end{aligned} \quad (2.58)$$

$$\begin{aligned} SS_W &= \sum_A (x - 83.17)^2 + \sum_B (x - 69.67)^2 + \sum_C (x - 84.83)^2 \\ &= 154.83 + 61.33 + 85.83 = 302.00. \end{aligned} \quad (2.59)$$

$$SS_T = 830.28 + 302.00 = 1132.28. \quad (2.60)$$

第 3 步: 计算均方 (方差估计) 和 F 统计量。

将平方和除以各自的自由度, 得到”均方”(Mean Square)——本质上就是方差的两种估计:

$$MS_B = \frac{SS_B}{k-1} = \frac{830.28}{2} = 415.14, \quad MS_W = \frac{SS_W}{N-k} = \frac{302.00}{15} = 20.13. \quad (2.61)$$

$$F = \frac{MS_B}{MS_W} = \frac{415.14}{20.13} = 20.62.$$

自由度解释:

- SS_B 的 $df = k - 1 = 2$: k 个组均值, 受总均值一个约束
- SS_W 的 $df = N - k = 15$: 每组 n_i 个数据, 受各组均值 k 个约束
- SS_T 的 $df = N - 1 = 17$: 且 $(k - 1) + (N - k) = N - 1$, 自由度可加

为什么 F 统计量服从 F 分布?

在 H_0 和正态假定下:

- $SS_B/\sigma^2 \sim \chi^2(k-1)$ (组间变异, 由各组均值的正态性导出)

- $SS_W/\sigma^2 \sim \chi^2(N-k)$ (组内变异, 由各组内部的正态性导出)
- 两者相互独立

因此:

$$F = \frac{(SS_B/\sigma^2)/(k-1)}{(SS_W/\sigma^2)/(N-k)} = \frac{MS_B}{MS_W} \sim F(k-1, N-k). \quad (2.62)$$

第 4 步: 查表, 做决策。

$df = (2, 15)$, 取 $\alpha = 0.05$, 查表 $F_{0.05}(2, 15) \approx 3.68$ 。

$F = 20.62 \gg 3.68$, 拒绝 H_0 ——三种教学方法的效果存在显著差异。

第 5 步: 事后两两比较 (Post-hoc)。

ANOVA 只告诉你”至少有一组不同”, 但没说是哪两组。需要做事后检验来找出具体差异。

常用方法: **Tukey HSD 检验**——在所有两两比较中控制整体错误率。

结论 (示意): A vs. B 显著 ($p < 0.01$), C vs. B 显著 ($p < 0.01$), A vs. C 不显著 ($p > 0.05$)。即: 传统讲授和互动讨论效果相近, 均显著优于视频自学。

ANOVA 结果的标准报告格式 (APA 风格):

$F(2, 15) = 20.62, p < 0.001$ 。

三种教学方法的效果存在显著差异。Tukey HSD 事后检验表明, 传统讲授 ($M = 83.17$) 和互动讨论 ($M = 84.83$) 的考试成绩均显著高于视频自学 ($M = 69.67$), 前两者之间无显著差异。

ANOVA 的前提条件 (与 t 检验一致):

- (1) **正态性:** 每组数据来自正态总体 (用 Q-Q 图或 Shapiro-Wilk 检验各组)
- (2) **方差齐性:** 各组方差相等 $\sigma_A^2 = \sigma_B^2 = \sigma_C^2$ (用 Levene 检验或 Bartlett 检验)
- (3) **独立性:** 观测值之间相互独立 (由实验设计保证)

方差齐性不满足时怎么办? 改用 Welch ANOVA (不要求等方差), 原理类似 Welch t 检验的推广。

t 检验 vs. ANOVA 的关系:

	t 检验	单因素 ANOVA
比较组数	2 组	$k \geq 2$ 组
统计量	$T = \frac{\bar{x}_1 - \bar{x}_2}{SE}$	$F = \frac{MS_B}{MS_W}$
$k = 2$ 时的关系	$T \sim t(N-2)$	$F \sim F(1, N-2)$, 且 $T^2 = F$

定义与性质

定义 2.14 (F 分布). 设 $U \sim \chi^2(n_1)$, $V \sim \chi^2(n_2)$, 且 U, V 相互独立, 则

$$F = \frac{U/n_1}{V/n_2} \sim F(n_1, n_2), \quad (2.63)$$

称 F 服从自由度为 (n_1, n_2) 的 F 分布。 n_1 为分子（第一）自由度， n_2 为分母（第二）自由度。

性质：

$$F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}. \quad (2.64)$$

若 $T \sim t(n)$, 则 $T^2 \sim F(1, n)$ 。

三大抽样分布对比总结

分布	构造方式	核心用途	ML 中的身影
$\chi^2(n)$	n 个独立 $\mathcal{N}(0, 1)$ 的平方和	方差估计、拟合优度、独立性检验	χ^2 特征选择、决策树
$t(n)$	$\frac{\mathcal{N}(0, 1)}{\sqrt{\chi^2(n)/n}}$	小样本均值推断、回归系数显著性	t 检验特征筛选、A/B 测试
$F(n_1, n_2)$	$\frac{\chi^2(n_1)/n_1}{\chi^2(n_2)/n_2}$	方差比较、ANOVA、模型显著性	ANOVA 特征选择、模型比较

常见理解误区：各分布的适用范围被窄化了

初学者常把三个分布和理解场景做一一映射，但实际它们的适用范围远比直觉广。

误区一：“ χ^2 只能看观测频数和期望频数的差异”

χ^2 分布的本质是标准正态随机变量的平方和——频数比较只是其应用之一。因为任何被标准化后的偏差平方累加都可能涉及 χ^2 ，它在完全不同类型的场景中都会出现：

应用	数学形式	是“频数比较”吗？
拟合优度 / 独立性检验	$\sum \frac{(O_i - E_i)^2}{E_i} \sim \chi^2$	✓ 是
连续数据的方差估计	$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$	× 否——这是连续量，与频数无关
t 分布的底层构件	$t = \frac{\mathcal{N}(0,1)}{\sqrt{\chi^2/df}}$	× 否—— χ^2 在此承载方差信息
F 分布的底层构件	$F = \frac{\chi_1^2/df_1}{\chi_2^2/df_2}$	× 否
似然比检验（模型比较）	$2(\ln L_1 - \ln L_0) \xrightarrow{d} \chi^2$	× 否——比较两个模型的拟合优度

误区二：“t 分布只能检验 μ 是否差异显著”

t 分布的数学形式是 $T = \frac{\text{估计量} - \text{假设值}}{\text{该估计量的标准误}}$ 。只要你的统计量长成“估计值除以它的标准误”，大概率就服从 t 分布——被估计的对象不一定是 μ 。

应用	检验对象	是” 检验 μ ” 吗？
单样本 t 检验	总体均值 μ	✓ 是
两样本 t 检验	两个总体均值差 $\mu_1 - \mu_2$	✓ 是
配对 t 检验	配对差值的均值	✓ 是
回归系数显著性	$\beta_j = 0?$	× 否——这是斜率，不是均值！
相关系数检验	$\rho = 0?$	× 否
两个回归系数比较	$\beta_1 = \beta_2?$	× 否
A/B 测试转化率	比例差异	✓ 实质是两样本均值的变体

回归系数检验是 t 分布在实际工作中最高频的应用——‘statsmodels’ / R 的 ‘summary()’ 输出里每一行的 ‘t value’ 和 ‘Pr(>|t|)’，全部是 t 检验。

三个分布的正确理解——层次关系：

$$\chi^2 \text{ 是砖块} \longrightarrow t = \frac{\mathcal{N}(0,1)}{\sqrt{\chi^2/df}}, F = \frac{\chi_1^2/df_1}{\chi_2^2/df_2} \text{ 是它垒出的两种建筑}$$

分布	数学本质	不要窄化为
χ^2	标准正态平方和的分布	” 只能比较频数”
t	$\mathcal{N}(0,1)/\sqrt{\chi^2/df}$	” 只能检验 μ ”
F	$(\chi_1^2/df_1)/(\chi_2^2/df_2)$	” 只能做 ANOVA”

理解了这个层次关系，每个分布的适用范围自然就打开了——凡是你某个量做了标准化再平方求和， χ^2 就会出现；凡是某个估计量除以它的标准误， t 就会出现。

2.3.4 正态总体的抽样分布定理（核心定理）

定理 2.1 (单个正态总体). 设 $X_1, X_2, \dots, X_n$ 是来自正态总体 $\mathcal{N}(\mu, \sigma^2)$ 的样本， $\bar{X}$ 与 S^2 分别为样本均值与样本方差，则：

(1) $\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$, 即 $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$;

$$(2) \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1);$$

(3) $\bar{X}$ 与 S^2 相互独立;

$$(4) \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

定理 2.2 (两个正态总体). 设 $X_1, \dots, X_{n_1} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu_1, \sigma_1^2)$, $Y_1, \dots, Y_{n_2} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu_2, \sigma_2^2)$, 两样本独立, 则:

$$(1) \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0, 1);$$

$$(2) \text{ 当 } \sigma_1^2 = \sigma_2^2 = \sigma^2 \text{ 时, } \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2), \text{ 其中 } S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2};$$

$$(3) \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1).$$

第三章 参数估计

3.1 点估计

点估计：用统计量的一个具体数值 $\hat{\theta}$ 来估计未知参数 θ 。

常用的构造估计量的方法有矩估计法和极大似然估计法。

3.1.1 矩估计法

核心思想：用样本矩代替（估计）总体矩。

设总体 X 的分布含 k 个未知参数 $\theta_1, \dots, \theta_k$ ：

$$\mu_\ell = \mathbb{E}[X^\ell] = g_\ell(\theta_1, \dots, \theta_k), \quad \ell = 1, \dots, k. \quad (3.1)$$

步骤：

1. 计算总体矩 $\mu_\ell = \mathbb{E}[X^\ell]$ （用参数表示）；
2. 令样本矩等于总体矩： $A_\ell = \mu_\ell$ ；
3. 解方程组得到 $\hat{\theta}_1, \dots, \hat{\theta}_k$ 。

例 3.1 (正态分布的矩估计). 设 $X \sim \mathcal{N}(\mu, \sigma^2)$ ：

$$\mathbb{E}[X] = \mu, \quad (3.2)$$

$$\mathbb{E}[X^2] = \text{Var}(X) + (\mathbb{E}[X])^2 = \sigma^2 + \mu^2. \quad (3.3)$$

令 $A_1 = \mu$, $A_2 = \sigma^2 + \mu^2$, 解得：

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2. \quad (3.4)$$

3.1.2 极大似然估计 (MLE)

定义 3.1 (似然函数). 设 $x_1, \dots, x_n$ 为来自总体 X 的样本观测值，总体的分布为 $f(x; \theta)$ (离散时为概率质量函数，连续时为概率密度函数)，则似然函数为：

$$L(\theta) = L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta). \quad (3.5)$$

注记 3.1 (符号 $L(\theta; x_1, \dots, x_n)$ 中分号的含义). $L(\theta; x_1, \dots, x_n)$ 中的分号 **不是** 条件概率的竖线 $|$, 它只是一个分隔符, 用于区分两类量:

- **分号前 (θ):** 当前关注的**变量**——MLE 中我们要对它求导、最大化
- **分号后 ($x_1, \dots, x_n$):** 已观测到的**固定数据**——拿到手后就不再改变

写成 $L(\theta | x_1, \dots, x_n)$ 也不少见, 但分号写法在统计学中更规范, 因为:

记号	含义	例子
$f(x; \theta)$ 或 $p(x \theta)$	θ 固定时, x 的概率密度/质量函数	正态 PDF
$L(\theta; x)$ 或 $L(\theta x)$	x 固定时, θ 的似然函数	MLE 的目标函数
$P(\theta x)$	观测到 x 后, θ 的 后验概率 (贝叶斯)	不是 MLE! 需要先验

关键区分: $L(\theta; x)$ 和 $P(\theta | x)$ 是完全不同的量。前者是频率学派的核心工具 (MLE), 后者是贝叶斯学派的核心工具 (MAP / 后验推断)。两者通过贝叶斯公式关联: $P(\theta | x) \propto L(\theta; x) \cdot P(\theta)$ 。

核心思想: 选择使观测数据出现概率最大的参数值。

极大似然估计值 $\hat{\theta}$ 满足:

$$L(\hat{\theta}) = \max_{\theta \in \Theta} L(\theta). \quad (3.6)$$

由于 $\ln$ 单调递增, 通常最大化**对数似然函数**:

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta). \quad (3.7)$$

求 $\frac{\partial \ell}{\partial \theta} = 0$ 解得 $\hat{\theta}_{\text{MLE}}$ 。

注记 3.2 (为什么 MLE 常写成 $\arg \max_{\theta} P(\mathcal{D} | \theta)$? 这不是贝叶斯). MLE 的两种等价写法常引起混淆:

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} L(\theta; \mathcal{D}) = \arg \max_{\theta} P(\mathcal{D} | \theta).$$

$P(\mathcal{D} | \theta)$ 不是贝叶斯, 因为它读作”给定参数, 数据的概率”。

竖线 $|$ 在概率论中是**条件概率**的标准符号: $P(A | B) = P(A \cap B)/P(B)$ 。 $P(\mathcal{D} | \theta)$ 的含义是: ”当参数取值为 θ 时, 数据 $\mathcal{D}$ 的分布”——这正是采样分布/似然。频率学派和贝叶斯学派都使用 $P(\mathcal{D} | \theta)$, 分歧在于用它做什么:

	频率学派 (MLE)	贝叶斯学派
用的量	$P(\mathcal{D} \theta)$	$P(\mathcal{D} \theta) \cdot P(\theta)$
对 θ 的立场	固定未知常数，放在竖线右边作为“条件”	随机变量，有先验分布 $P(\theta)$
目标	找使 $P(\mathcal{D} \theta)$ 最大的 θ	求 $P(\theta \mathcal{D}) \propto P(\mathcal{D} \theta)P(\theta)$

分号；和竖线 | 在这里可以互换吗？

- $L(\theta; x)$ 用分号强调“视角翻转”：数据固定， θ 是变量
- $P(x | \theta)$ 用竖线因为它确实满足条件概率的数学定义（ θ 固定时 x 的分布）
- 两者数学上完全相等： $L(\theta; x) = P(x | \theta) = \prod f(x_i; \theta)$
- 分号更“安全”（不会误以为是贝叶斯），竖线更“标准”（符合概率论规范）。两种写法都正确

MLE 从未把 θ 当作随机变量。 $P(\mathcal{D} | \theta = 0.5)$ 的意思是“假设硬币正面概率恰好是 0.5，那么掷出 8 正 2 反的概率是多少”——“ $\theta = 0.5$ ”只是一个假定的场景，不是随机事件。这就像“假如明天下雨，你带伞的概率是多少”——“下雨”在条件位置，不意味着你把天气当作随机变量来建模。

只有当竖线左右颠倒—— $P(\theta | \mathcal{D})$ ——才是贝叶斯，因为此时参数被当作随机变量。

完整示例：正态分布 $N(\mu, \sigma^2)$ 的 MLE

设 $X \sim \mathcal{N}(\mu, \sigma^2)$ ， μ, σ^2 均未知。 $x_1, x_2, \dots, x_n$ 为样本观测值。求 μ, σ^2 的 MLE。

第 1 步：写出 PDF，构造似然函数。

正态分布的 PDF：

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right). \quad (3.8)$$

将 PDF 中的参数固定位置换成变量视角，似然函数为 n 个独立观测的联合密度：

$$L(\mu, \sigma^2) = \prod_{i=1}^n f(x_i; \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right). \quad (3.9)$$

第 2 步：取对数，化积为和。

$$\ell(\mu, \sigma^2) = \ln L(\mu, \sigma^2) = \sum_{i=1}^n \left[-\frac{1}{2} \ln(2\pi) - \frac{1}{2} \ln(\sigma^2) - \frac{(x_i - \mu)^2}{2\sigma^2} \right] \quad (3.10)$$

$$= -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2. \quad (3.11)$$

第 3 步：分别对 μ 和 σ^2 求偏导，令其为零。

对 μ 求偏导：

$$\frac{\partial \ell}{\partial \mu} = -\frac{1}{2\sigma^2} \sum_{i=1}^n 2(x_i - \mu)(-1) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0. \quad (3.12)$$

解得：

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}. \quad (3.13)$$

对 σ^2 求偏导（注意是对 σ^2 整体，而非 σ ）：

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2} \cdot \frac{1}{\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0. \quad (3.14)$$

代入 $\hat{\mu} = \bar{x}$ ，解得：

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2. \quad (3.15)$$

第 4 步：验证极值点。

可以验证二阶导数矩阵（Hessian）为负定， $\hat{\mu}, \hat{\sigma}^2$ 确为极大值点（略）。

注意：MLE 的 $\hat{\sigma}^2$ 分母是 n ，不是 $n-1$ ！

$$\mathbb{E}[\hat{\sigma}_{\text{MLE}}^2] = \frac{n-1}{n} \sigma^2 \neq \sigma^2. \quad (3.16)$$

MLE 给出的方差估计是有偏的（虽然渐近无偏）。这就是为什么样本方差 S^2 用 $n-1$ 做分母——修正了这个偏差。MLE 追求最大化似然，不追求无偏性。

概念纠正：似然函数 $L(\theta)$ 究竟是谁的“概率”？

以下对照你的理解逐条纠正。

你的第 2 点： $f(x_i)$ 能知道每个观测值被取到的概率。

这正是最常见的误区。对连续分布， $f(x_i)$ 是**概率密度**，不是**概率**！对于连续随机变量，单点概率恒为零： $P(X = x_i) = 0$ 。

但“密度”可以理解为“单位长度上的概率浓度”： $P(x_i < X < x_i + dx) \approx f(x_i) \cdot dx$ 。虽然 $f(x_i)$ 本身不是概率（可以大于 1），但 $f(x_i)$ 越大意味着数据集中在 x_i 附近的概率越高。

正因为单点概率为零，MLE 对连续分布用的是 PDF 的乘积而非概率的乘积——这是合理的，因为要比较“哪组参数让观测数据更可能”，只需比较密度的相对大小。

你的第 3 点： $L(\theta; x_i)$ 是在观测到 $\{x_i\}$ 的情况下参数为 θ 的概率。

这是错误的，而且是最关键的概念混淆。

$L(\theta)$ 不等于 $P(\theta | \text{数据})$ 。两者的方向完全不同：

	似然函数 $L(\theta)$	后验概率 $P(\theta \text{数据})$
含义	参数为 θ 时，数据出现的可能性	观测到数据后，参数为 θ 的概率
方向	$\theta \rightarrow$ 数据的分布	数据 $\rightarrow \theta$ 的分布
是否概率	否—— $L(\theta)$ 不是 θ 上的概率分布	是—— $\int P(\theta \mathcal{D}) d\theta = 1$
所属框架	频率学派	贝叶斯学派

$L(\theta)$ 和 PDF 是同一个公式，只是视角不同——前者把数据固定、参数当变量，后者反之。它不满足概率的归一化条件： $\int L(\theta) d\theta$ 一般不等于 1。

> 似然函数不是“参数的后验概率”，它是“固定数据后，参数与数据兼容程度的度量”。

你的第 4 点：为什么 L 能和 PDF 挂钩？

答案：它们本质上是同一个数学表达式，只是“谁当变量”的视角切换。

写出联合 PDF (θ 固定, x 是变量)：

$$f(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta). \quad (3.17)$$

现在做一次视角翻转——数据已经拿到了 ($x_1, \dots, x_n$ 是固定常数)，问题是“哪组 θ 让这些数据最可能？”直接把上面的表达式看作 θ 的函数：

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta). \quad (3.18)$$

形式上二者一模一样，但数学身份不同： $f(x_1, \dots, x_n; \theta)$ 是 x 上的概率密度（积分为 1）； $L(\theta)$ 是 θ 上的函数（积分一般不为 1，不是密度）。

$\underbrace{f(x_1, \dots, x_n; \theta)}_{\text{PDF: } \theta \text{ 固定, } x \text{ 变量}} \xrightarrow[\text{同一个公式, 视角翻转}]{\text{数据拿到手, } \theta \text{ 变参数}} \underbrace{L(\theta; x_1, \dots, x_n)}_{\text{似然: } x \text{ 固定, } \theta \text{ 变量}}$
--

因此你的第 1 点方向正确，只需补充：我们有一组已观测到的数据 $x_1, \dots, x_n$ 。总体分布的形式已知（如正态），参数未知。目标是用观测数据反过来推断最合理的参数值——MLE 就是“哪组 θ 让手上这组数据出现的联合密度最大”。

频率学派 vs. 贝叶斯学派：根本分歧

MLE 和 MAP 分别代表统计推断的两大范式。理解它们的底层分歧，比记住公式更重要。

核心分歧：参数 θ 是什么？

	频率学派 (Frequentist)	贝叶斯学派 (Bayesian)
θ 的本质	θ 是一个固定但未知的常数。没有“ θ 的分布”这个概念。	θ 是一个随机变量，有自己的分布。在观测数据前，你对 θ 已有先验信念 $P(\theta)$ 。
概率的含义	概率是长期频率——无限次重复实验中事件发生的比例。”下次掷硬币正面的概率是 0.5” = 长期来看一半是正面。	概率是信念程度——你对一个命题的相信程度。”明天有 60% 概率下雨” = 你对“明天下雨”有 60% 的把握。
推断的目标	给出 θ 的一个点估计 (MLE) 或一个置信区间。	给出 θ 的整个后验分布 $P(\theta \mathcal{D})$ 。
数据的角色	数据是唯一的随机来源。参数固定，数据随机。	参数和数据都是随机变量。数据更新信念。
核心工具	MLE、假设检验、置信区间	贝叶斯公式、后验分布、可信区间
区间含义	置信区间 : 重复抽样 100 次, 约 95 个区间包含 θ 。不能说“这个区间有 95% 概率包含 θ ”。	可信区间 : 给定数据, θ 落在此区间的概率是 95%。可以直接说“我们有 95% 把握 θ 在区间内”。

用一个具体例子体会差异：

你掷硬币 10 次，8 次正面。想知道硬币正面的概率 p 。

频率学派 (MLE)：

- p 是一个固定的数，只是你不知道。
- $\hat{p} = 8/10 = 0.8$ ，这是 p 的最佳点估计。
- “ p 的 95% 置信区间是 $[0.49, 0.96]$ ”——如果重复这个实验无数次，95% 的置信区间会包含真实的 p 。
- 你不能说“ p 落在这个区间里的概率是 95%”—— p 不是随机的。

贝叶斯学派 (MAP / 后验)：

- p 本身是不确定的——你相信 p 可能接近 0.5（硬币通常公平），但也可能不是。
- 用 $\text{Beta}(2,2)$ 作为先验（弱偏向公平），后验为 $\text{Beta}(10,4)$ 。
- 后验均值 $\frac{10}{14} \approx 0.714$ （比 0.8 更保守，因为先验往回拉了一点）。
- “ p 的 95% 可信区间是 $[0.46, 0.90]$ ”——可以直接说“有 95% 的概率 p 在这个区间里”。

MLE 和 MAP 在公式上的区别只有一项：

$$\underbrace{\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \log P(\mathcal{D} | \theta)}_{\text{只看数据}} \quad \underbrace{\hat{\theta}_{\text{MAP}} = \arg \max_{\theta} [\log P(\mathcal{D} | \theta) + \log P(\theta)]}_{\text{数据 + 先验信念}} \quad (3.19)$$

MAP 比 MLE 多了一项 $\log P(\theta)$ ——这就是“你对参数已有的信念”。当 $P(\theta)$ 是均匀分布时， $\text{MAP} = \text{MLE}$ 。

现代 ML 中两类方法的分布：

- **频率派占主导的：**大多数监督学习（线性回归、SVM、GBDT、深度学习训练）——目标就是找一个最好的 θ ，不关心它的分布。
- **贝叶斯派占主导的：**不确定性量化（什么时候模型该说“我不知道”）、小样本学习、超参数调优（贝叶斯优化）、主题模型、变分推断。
- **融合趋势：**现代 DL 中的 Dropout、BatchNorm 的推理可以看作变分推断；Ensemble 本质上是后验分布的蒙特卡洛近似。

深层追问：把 θ 当常数 vs. 当变量，实际差别在哪？

表面上，MLE 和 MAP 都是求一个最优的 θ ，公式只差一项 $\log P(\theta)$ 。但底层的世界观分歧远比公式大：

差别一：能否谈论“ θ 的不确定性”。

频率学派：你只能得到 $\hat{\theta}_{\text{MLE}} = 0.8$ ，这是一个数。你可以构造置信区间，但不能说 θ 落在这个区间的概率是 95%—— θ 不是随机的，它要么在里面，要么不在。95% 是方法的长期成功率，不是本次推断的可信度。

贝叶斯学派：你得到整个后验分布 $P(\theta | \mathcal{D})$ 。你可以直接说“ θ 有 95% 的概率在 $[0.46, 0.90]$ 之间”，也可以量化“ $\theta > 0.5$ 的概率是 97%”。这在需要决策的场景中至关重要——如果有 10% 的概率 θ 落在危险区域，你可能会采取完全不同的行动。

差别二：先验知识能不能进入推断。

频率学派拒绝先验，坚持“让数据自己说话”。这在样本量大时没问题，但在小样本场景下会出荒谬结果：

- 掷硬币 1 次，正面。MLE: $\hat{p} = 1.0$ ，认为硬币永远出正面。
- 掷硬币 3 次，3 次正面。MLE: $\hat{p} = 1.0$ 。但你的常识告诉你”硬币通常接近公平”。

贝叶斯学派用一个温和的先验（如 $\text{Beta}(2,2)$ ，相当于假设已经见过 2 正 2 反）把估计往回拉：1 次正面 $\rightarrow$ 后验均值 $\frac{3}{5} = 0.6$ （比 1.0 合理得多）。

这不是”主观偏见”，而是用先验编码常识，防止小样本过拟合。这在现代 ML 中对应正则化——Ridge 回归的 L_2 惩罚等价于高斯先验，Lasso 的 L_1 惩罚等价于拉普拉斯先验。

差别三：频率论的保证是”长期校准”而非”单次可信”。

这是频率学派最强也最微妙的优势。

一个 95% 置信区间的含义是：如果你把这个实验重复 100 次，每次算一个区间，大约 95 个会包含真实的 θ 。这是一种**过程保证**——方法本身在长期使用中是可靠的。

但贝叶斯 95% 可信区间可能没有这个性质：在重复抽样中，贝叶斯区间可能只有 80% 的次数覆盖真值（如果先验选得不好）。频率学派正是用这一点批评贝叶斯：你的区间说”95% 概率包含 θ ”，但在客观世界中这个覆盖频率可能远低于 95%。

为什么频率学派历史上排斥贝叶斯？三个核心原因：

(1) 先验的主观性（最根本的批评）：

”你的先验 $P(\theta)$ 从哪来？如果两个人用不同的先验，同一个数据得出不同的结论，科学还叫科学吗？”——频率学派追求”客观”推断，只依赖数据，不依赖分析者的主观信念。

(2) θ 经常确实不是随机的：

硬币的正面概率 p 是一个物理常数（虽然你不知道具体值），把它当作随机变量建模在哲学上就是错的。频率学派的回答：我们不需要给 p 一个分布——我们只需要一个估计方法和它的误差特性。

(3) 频率方法有客观的频率保证：

95% 置信区间在长期中确实有 95% 的覆盖率——这是数学定理，不依赖任何先验假设。贝叶斯可信区间没有这种频率主义校准——如果先验错了，区间也错了。

现代视角：分歧在收敛，不在对立。

今天的共识是：两种方法各有适用的场景，不是非此即彼的关系。

场景	推荐方法	原因
n 很大，只需点估计	MLE（频率）	简单、客观、有效。先验被数据淹没，两派结论一致
n 很小，需要利用常识	MAP / 后验（贝叶斯）	纯靠数据会过拟合，先验起正则化作用
需要量化不确定性	后验分布（贝叶斯）	频率区间不能说“概率”，决策需要真正的概率
需要长期频率保证	频率方法	置信区间有客观的覆盖率保证
$p \gg n$ （高维稀疏）	MAP（等价于正则化）	频率派称为“加惩罚项”，贝叶斯派称为“加先验”
A/B 测试、临床试验	频率为主	监管机构要求频率主义的 p 值和错误率控制

一句话总结分歧的本质：

频率派： θ 是客观的常数，推断 = 用随机数据去逼近固定真相。

贝叶斯派： θ 是主观的不确定性，推断 = 用数据更新你对真相的信念。

3.1.3 最大后验估计 (MAP)

引入先验分布 $P(\theta)$ ，最大化后验概率：

$$\hat{\theta}_{\text{MAP}} = \arg \max_{\theta} P(\theta \mid \mathcal{D}) = \arg \max_{\theta} P(\mathcal{D} \mid \theta) P(\theta).$$

(3.20)

注记 3.3 (第二个等号为什么成立？——贝叶斯公式 + 分母与 θ 无关). 贝叶斯公式为：

$$P(\theta \mid \mathcal{D}) = \frac{P(\mathcal{D} \mid \theta) P(\theta)}{P(\mathcal{D})}.$$

(3.21)

其中 $P(\mathcal{D}) = \int P(\mathcal{D} \mid \theta) P(\theta) d\theta$ 是数据的边缘概率。**关键：** $P(\mathcal{D})$ 与 θ 无关——它是对所有可能的 θ 做了积分，积分完成后 θ 已消失。在关于 θ 最大化时， $P(\mathcal{D})$ 是常数，可以直接扔掉：

$$\arg \max_{\theta} P(\theta \mid \mathcal{D}) = \arg \max_{\theta} \frac{P(\mathcal{D} \mid \theta) P(\theta)}{P(\mathcal{D})} = \arg \max_{\theta} P(\mathcal{D} \mid \theta) P(\theta).$$

(3.22)

三步可视化：

$$\underbrace{P(\theta \mid \mathcal{D})}_{\text{后验}} = \frac{\overbrace{P(\mathcal{D} \mid \theta)}^{\text{似然}} \times \overbrace{P(\theta)}^{\text{先验}}}{\underbrace{P(\mathcal{D})}_{\text{与 } \theta \text{ 无关, argmax 时可忽略}}} \xrightarrow{\arg \max_{\theta}} P(\mathcal{D} \mid \theta) P(\theta).$$

直觉：后验 $\propto$ 似然 $\times$ 先验。最大化后验 = 最大化（数据支持度 $\times$ 先验信念）。先验 $P(\theta)$ 把 MLE 的纯数据驱动估计往你认为合理的区域”拉”了一把。

当先验为均匀分布时， $P(\theta)$ 是常数，MAP 退化为 MLE。

3.2 基于截尾样本的最大似然估计

在可靠性试验和寿命试验中，由于时间和成本限制，试验往往在全部样品失效前终止，产生的数据称为**截尾样本**。

3.2.1 定时截尾

试验进行到规定时间 t_0 时停止。假设 n 个样品中有 r 个在 t_0 前失效，失效时间分别为 $t_1 \leq t_2 \leq \dots \leq t_r \leq t_0$ 。

似然函数：

$$L(\theta) = \left[\prod_{i=1}^r f(t_i; \theta) \right] \cdot [1 - F(t_0; \theta)]^{n-r}, \quad (3.23)$$

其中 f 为失效时间分布的 PDF， F 为 CDF， $1 - F(t_0)$ 表示一个样品在 t_0 时仍未失效的概率（生存概率）。

3.2.2 定数截尾

试验进行到有 r 个样品失效时停止，第 r 个失效时间为 t_r 。

似然函数：

$$L(\theta) = \left[\prod_{i=1}^r f(t_i; \theta) \right] \cdot [1 - F(t_r; \theta)]^{n-r}. \quad (3.24)$$

3.2.3 指数分布截尾样本的 MLE

设寿命 $T \sim \text{Exp}(\lambda)$ ，即 $f(t) = \lambda e^{-\lambda t}$ ($t \geq 0$)， $F(t) = 1 - e^{-\lambda t}$ 。

定时截尾下的 MLE：

$$\hat{\lambda} = \frac{r}{\sum_{i=1}^r t_i + (n-r)t_0}. \quad (3.25)$$

3.3 估计量的评选标准

3.3.1 无偏性

定义 3.2 (无偏估计量). 若估计量 $\hat{\theta}$ 满足 $\mathbb{E}[\hat{\theta}] = \theta$ ，则称 $\hat{\theta}$ 为 θ 的无偏估计量。若 $\mathbb{E}[\hat{\theta}] \neq \theta$ ，其差 $\text{Bias}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta$ 称为**偏差**。

例 3.2. $\bar{X}$ 是 μ 的无偏估计量; $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ 是 σ^2 的无偏估计量, 而 $\frac{1}{n} \sum (X_i - \bar{X})^2$ 是有偏的 (渐近无偏)。

3.3.2 有效性

定义 3.3 (有效性). 设 $\hat{\theta}_1$ 与 $\hat{\theta}_2$ 都是 θ 的无偏估计量, 若

$$\text{Var}(\hat{\theta}_1) \leq \text{Var}(\hat{\theta}_2), \quad (3.26)$$

则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效。

在所有无偏估计量中方差达到下界的称为最小方差无偏估计量 (MVUE)。

3.3.3 相合性 (一致性)

定义 3.4 (相合估计量). 若对任意 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \varepsilon) = 1, \quad (3.27)$$

即 $\hat{\theta}_n \xrightarrow{P} \theta$, 则称 $\hat{\theta}_n$ 为 θ 的相合估计量 (一致估计量)。

3.3.4 均方误差 (综合评价)

定义 3.5 (均方误差).

$$\text{MSE}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + (\text{Bias}(\hat{\theta}))^2. \quad (3.28)$$

MSE 同时考虑了方差和偏差, 常用于有偏估计量的比较。

3.4 区间估计

3.4.1 基本概念

点估计给出了参数的一个具体值, 但无法反映估计的精度。区间估计用一个随机区间来估计参数, 并给出该区间包含参数真值的可信程度。

定义 3.6 (置信区间). 设 θ 为总体分布中的未知参数。对于给定的 α ($0 < \alpha < 1$), 若存在统计量 $\hat{\theta}_L = \hat{\theta}_L(X_1, \dots, X_n)$ 和 $\hat{\theta}_U = \hat{\theta}_U(X_1, \dots, X_n)$, 使得

$$P(\hat{\theta}_L < \theta < \hat{\theta}_U) = 1 - \alpha, \quad (3.29)$$

则称随机区间 $(\hat{\theta}_L, \hat{\theta}_U)$ 为 θ 的置信水平为 $1 - \alpha$ 的置信区间。

- $1 - \alpha$: 置信水平 (置信度), 常用 0.90, 0.95, 0.99

- $\hat{\theta}_L$: 置信下限
- $\hat{\theta}_U$: 置信上限

精确解释: 重复抽样 100 次, 大约有 $100 \times (1 - \alpha)$ 个区间包含 θ 。

3.4.2 枢轴量法 (构造置信区间的通用方法)

1. 找一个枢轴量 $G = G(X_1, \dots, X_n; \theta)$, 其分布完全已知且与 θ 无关;
2. 对给定 α , 确定 a, b 使 $P(a < G < b) = 1 - \alpha$;
3. 解不等式 $a < G < b$ 得到 $\hat{\theta}_L < \theta < \hat{\theta}_U$ 。

3.5 正态总体均值与方差的区间估计

3.5.1 单个正态总体均值的置信区间

σ^2 已知时

枢轴量: $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$ 。

μ 的 $1 - \alpha$ 置信区间:

$$\left(\bar{X} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \right). \quad (3.30)$$

常用分位点: $z_{0.025} = 1.96$ ($\alpha = 0.05$), $z_{0.005} = 2.576$ ($\alpha = 0.01$)。

σ^2 未知时

枢轴量: $\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$ 。

μ 的 $1 - \alpha$ 置信区间:

$$\left(\bar{X} - t_{\alpha/2}(n-1) \cdot \frac{S}{\sqrt{n}}, \bar{X} + t_{\alpha/2}(n-1) \cdot \frac{S}{\sqrt{n}} \right). \quad (3.31)$$

3.5.2 单个正态总体方差的置信区间

枢轴量: $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ 。

σ^2 的 $1 - \alpha$ 置信区间:

$$\left(\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)} \right). \quad (3.32)$$

注意: χ^2 分布不对称, 需双侧分位点。

3.5.3 两个正态总体均值差的置信区间

σ_1^2, σ_2^2 已知

$$\left((\bar{X} - \bar{Y}) - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, (\bar{X} - \bar{Y}) + z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right). \quad (3.33)$$

$\sigma_1^2 = \sigma_2^2 = \sigma^2$ 但 σ^2 未知

枢轴量涉及 S_w (合并方差) 和 $t(n_1 + n_2 - 2)$:

$$\left((\bar{X} - \bar{Y}) \pm t_{\alpha/2}(n_1 + n_2 - 2) \cdot S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right). \quad (3.34)$$

3.5.4 两个正态总体方差比的置信区间

枢轴量: $\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$ 。

$\frac{\sigma_1^2}{\sigma_2^2}$ 的 $1 - \alpha$ 置信区间:

$$\left(\frac{S_1^2}{S_2^2} \cdot \frac{1}{F_{\alpha/2}(n_1 - 1, n_2 - 1)}, \frac{S_1^2}{S_2^2} \cdot \frac{1}{F_{1-\alpha/2}(n_1 - 1, n_2 - 1)} \right). \quad (3.35)$$

3.6 (0-1) 分布参数的区间估计

设总体 $X \sim B(1, p)$, 即 $P(X = 1) = p$, $P(X = 0) = 1 - p$ 。

由中心极限定理, 当 n 充分大时:

$$\frac{\bar{X} - p}{\sqrt{p(1-p)/n}} \xrightarrow{d} \mathcal{N}(0, 1). \quad (3.36)$$

p 的近似 $1 - \alpha$ 置信区间 (解二次不等式):

$$\frac{1}{1 + \frac{z_{\alpha/2}^2}{n}} \left(\hat{p} + \frac{z_{\alpha/2}^2}{2n} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n} + \frac{z_{\alpha/2}^2}{4n^2}} \right), \quad (3.37)$$

其中 $\hat{p} = \bar{X} = \frac{1}{n} \sum X_i$ 。

当 n 很大且 $\hat{p}$ 不接近 0 或 1 时, 可用简化公式:

$$\left(\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}, \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right). \quad (3.38)$$

3.7 单侧置信区间

在某些实际问题中, 我们只关心参数的上限 (不超过多少) 或下限 (不低于多少), 此时使用单侧置信区间。

定义 3.7 (单侧置信区间). • **单侧置信上限:** 若 $P(\theta < \hat{\theta}_U) = 1 - \alpha$, 则 $(-\infty, \hat{\theta}_U)$ 为单侧置信区间, $\hat{\theta}_U$ 为单侧置信上限;

• **单侧置信下限:** 若 $P(\theta > \hat{\theta}_L) = 1 - \alpha$, 则 $(\hat{\theta}_L, +\infty)$ 为单侧置信区间, $\hat{\theta}_L$ 为单侧置信下限。

构造方法: 与双侧类似, 但将 $\alpha/2$ 换为 α :

例 3.3 (正态总体均值的单侧置信区间 (σ^2 未知)). • **单侧上限:** $\mu < \bar{X} + t_\alpha(n-1) \cdot \frac{S}{\sqrt{n}}$

• **单侧下限:** $\mu > \bar{X} - t_\alpha(n-1) \cdot \frac{S}{\sqrt{n}}$

例 3.4 (正态总体方差的单侧置信区间). σ^2 的单侧上限:

$$\sigma^2 < \frac{(n-1)S^2}{\chi_{1-\alpha}^2(n-1)}. \quad (3.39)$$

如材料的强度只需关注下限, 寿命的方差只需关注上限。

第四章 假设检验

4.1 假设检验的基本概念

4.1.1 假设检验问题

在许多实际问题中，我们不仅需要对未知参数作出估计，还需要对总体的某些特性作出判断。例如：

- 新药是否比旧药更有效？
- 某批产品的次品率是否超过 3%？
- 两种测量方法的精度是否相同？

这类问题可以归结为**假设检验** (hypothesis testing)：先对总体提出一个假设，然后利用样本信息来判断这个假设是否成立。

定义 4.1 (原假设与备择假设). 将需要检验的假设称为**原假设** (零假设, null hypothesis), 记为 H_0 ; 与原假设对立的假设称为**备择假设** (alternative hypothesis), 记为 H_1 。

例如，检验总体均值 μ 是否等于某给定值 μ_0 ：

- 双侧检验： $H_0 : \mu = \mu_0$ vs. $H_1 : \mu \neq \mu_0$
- 右侧检验： $H_0 : \mu \leq \mu_0$ vs. $H_1 : \mu > \mu_0$
- 左侧检验： $H_0 : \mu \geq \mu_0$ vs. $H_1 : \mu < \mu_0$

4.1.2 两类错误

由于决策基于样本，我们可能犯两类错误：

定义 4.2 (第一类错误与第二类错误). • **第一类错误 (弃真)**： H_0 为真时拒绝 H_0 ,

$$\alpha = P(\text{拒绝 } H_0 \mid H_0 \text{ 为真}). \quad (4.1)$$

α 称为**显著性水平** (significance level), 通常取 0.01, 0.05, 0.10。

- 第二类错误（取伪）： H_0 为假时接受 H_0 ,

$$\beta = P(\text{接受 } H_0 \mid H_0 \text{ 为假}). \quad (4.2)$$

	H_0 为真	H_0 为假
接受 H_0	正确决策	第二类错误 (β)
拒绝 H_0	第一类错误 (α)	正确决策

Neyman–Pearson 原则：在控制第一类错误概率 α 的前提下，使第二类错误概率 β 尽可能小。

定义 4.3 (检验的功效). 当 H_1 为真时拒绝 H_0 的概率称为检验的**功效** (power):

$$\text{power} = 1 - \beta = P(\text{拒绝 } H_0 \mid H_0 \text{ 为假}). \quad (4.3)$$

4.1.3 拒绝域与检验统计量

定义 4.4 (拒绝域). 当检验统计量落入某区域 W 时拒绝 H_0 , 则 W 称为**拒绝域** (rejection region) 或临界域。

假设检验的基本步骤:

1. 提出原假设 H_0 和备择假设 H_1 ;
2. 选取适当的检验统计量, 并在 H_0 为真下确定其分布;
3. 给定显著性水平 α , 确定拒绝域 W ;
4. 由样本计算检验统计量的观测值, 若落入 W 则拒绝 H_0 , 否则不拒绝 H_0 。

4.2 正态总体均值的假设检验

4.2.1 单个正态总体均值的检验

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$, 检验 $H_0: \mu = \mu_0$ 。

情形 1: σ^2 已知— Z 检验

检验统计量:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1) \quad (\text{在 } H_0 \text{ 下}). \quad (4.4)$$

备择假设	拒绝域
$H_1: \mu \neq \mu_0$	$ Z \geq z_{\alpha/2}$
$H_1: \mu > \mu_0$	$Z \geq z_{\alpha}$
$H_1: \mu < \mu_0$	$Z \leq -z_{\alpha}$

情形 2: σ^2 未知— t 检验

用样本标准差 S 代替 σ :

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1) \quad (\text{在 } H_0 \text{ 下}). \quad (4.5)$$

备择假设	拒绝域
$H_1: \mu \neq \mu_0$	$ T \geq t_{\alpha/2}(n-1)$
$H_1: \mu > \mu_0$	$T \geq t_{\alpha}(n-1)$
$H_1: \mu < \mu_0$	$T \leq -t_{\alpha}(n-1)$

4.2.2 两个正态总体均值差的检验

设 $X_1, \dots, X_{n_1} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu_1, \sigma_1^2)$, $Y_1, \dots, Y_{n_2} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu_2, \sigma_2^2)$, 两样本独立。检验 $H_0: \mu_1 - \mu_2 = \delta$ (常取 $\delta = 0$)。

情形 1: σ_1^2, σ_2^2 已知

$$Z = \frac{(\bar{X} - \bar{Y}) - \delta}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0, 1). \quad (4.6)$$

情形 2: $\sigma_1^2 = \sigma_2^2 = \sigma^2$ 但未知

合并方差 $S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$, 检验统计量:

$$T = \frac{(\bar{X} - \bar{Y}) - \delta}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2). \quad (4.7)$$

情形 3: $\sigma_1^2 \neq \sigma_2^2$ 且未知 (Welch t 检验)

$$T = \frac{(\bar{X} - \bar{Y}) - \delta}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}, \quad (4.8)$$

其自由度由 Welch-Satterthwaite 公式近似:

$$\nu = \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}. \quad (4.9)$$

4.2.3 配对数据的 t 检验

当两个样本不独立而是配对出现时 (如同一组受试者在处理前后的测量值), 令

$$D_i = X_i - Y_i, \quad i = 1, \dots, n. \quad (4.10)$$

假设 $D_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu_D, \sigma_D^2)$, 检验 $H_0: \mu_D = 0$, 使用单样本 t 检验:

$$T = \frac{\bar{D}}{S_D/\sqrt{n}} \sim t(n-1). \quad (4.11)$$

4.3 正态总体方差的假设检验

4.3.1 单个正态总体方差的检验— χ^2 检验

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$, 检验 $H_0: \sigma^2 = \sigma_0^2$.

检验统计量:

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1) \quad (\text{在 } H_0 \text{ 下}). \quad (4.12)$$

备择假设	拒绝域
$H_1: \sigma^2 \neq \sigma_0^2$	$\chi^2 \leq \chi_{1-\alpha/2}^2(n-1)$ 或 $\chi^2 \geq \chi_{\alpha/2}^2(n-1)$
$H_1: \sigma^2 > \sigma_0^2$	$\chi^2 \geq \chi_{\alpha}^2(n-1)$
$H_1: \sigma^2 < \sigma_0^2$	$\chi^2 \leq \chi_{1-\alpha}^2(n-1)$

4.3.2 两个正态总体方差比的检验— F 检验

设两样本独立, 检验 $H_0: \sigma_1^2 = \sigma_2^2$ (即 $\sigma_1^2/\sigma_2^2 = 1$).

检验统计量:

$$F = \frac{S_1^2}{S_2^2} \sim F(n_1-1, n_2-1) \quad (\text{在 } H_0 \text{ 下}). \quad (4.13)$$

备择假设	拒绝域
$H_1: \sigma_1^2 \neq \sigma_2^2$	$F \leq F_{1-\alpha/2}(n_1-1, n_2-1)$ 或 $F \geq F_{\alpha/2}(n_1-1, n_2-1)$
$H_1: \sigma_1^2 > \sigma_2^2$	$F \geq F_{\alpha}(n_1-1, n_2-1)$
$H_1: \sigma_1^2 < \sigma_2^2$	$F \leq F_{1-\alpha}(n_1-1, n_2-1)$

注记 4.1. 实际计算时常常用 $F = \max(S_1^2, S_2^2)/\min(S_1^2, S_2^2)$ 简化为上侧检验。

4.4 置信区间与假设检验之间的关系

置信区间与假设检验之间存在深刻的对偶关系 (duality)。

定理 4.1 (置信区间与假设检验的对偶性). 参数 θ 的 $1-\alpha$ 置信区间恰好由所有使得双侧检验 $H_0: \theta = \theta_0$ 在显著性水平 α 下不被拒绝的 θ_0 组成。

换句话说:

- 若 θ_0 落在 $1 - \alpha$ 置信区间内 $\iff$ 不拒绝 $H_0 : \theta = \theta_0$ (显著性水平 α);
- 若 θ_0 不在 $1 - \alpha$ 置信区间内 $\iff$ 拒绝 $H_0 : \theta = \theta_0$ 。

例 4.1 (均值检验与置信区间的对应). 已知方差时, μ 的 95% 置信区间为 $\bar{X} \pm z_{0.025} \cdot \sigma / \sqrt{n}$ 。双侧 Z 检验在 $|Z| \geq z_{0.025}$ 时拒绝 $H_0 : \mu = \mu_0$, 这等价于 μ_0 不在上述置信区间内。

实际意义:

- 置信区间提供了**更多信息**: 不仅告诉我们是否拒绝 H_0 , 还给出了参数的可能取值范围;
- 假设检验给出明确的**二值决策**: 在需要做出是否采取行动的场合更有用。

4.5 样本容量的选取

在实际问题中, 我们需要在抽样前确定所需的样本容量 n , 以保证检验达到指定的功效。

4.5.1 Z 检验的样本容量

考虑 $H_0 : \mu = \mu_0$ vs. $H_1 : \mu = \mu_1$ (σ^2 已知)。

对于显著性水平 α 和功效 $1 - \beta$, 所需样本容量为:

双侧检验:

$$n \approx \frac{(z_{\alpha/2} + z_{\beta})^2 \sigma^2}{(\mu_1 - \mu_0)^2}. \quad (4.14)$$

单侧检验:

$$n \approx \frac{(z_{\alpha} + z_{\beta})^2 \sigma^2}{(\mu_1 - \mu_0)^2}. \quad (4.15)$$

其中 $\Delta = |\mu_1 - \mu_0|$ 是我们希望检测出的**最小差异** (effect size)。

例 4.2. 某工厂想检验产品重量的均值是否为 500 g。已知 $\sigma = 5$ g, 若真实的均值为 502 g, 希望在 $\alpha = 0.05$, power = 0.90 下能检测出来, 求所需样本容量。

由 $z_{0.025} = 1.96$, $z_{0.10} = 1.28$:

$$n \approx \frac{(1.96 + 1.28)^2 \times 5^2}{(502 - 500)^2} = \frac{(3.24)^2 \times 25}{4} \approx 65.6, \quad (4.16)$$

故取 $n = 66$ 。

4.5.2 t 检验的样本容量

当 σ^2 未知时, 使用迭代方法或查 OC 曲线 (operating characteristic curve) 来确定样本容量。OC 曲线给出了不同样本量下第二类错误概率 β 与参数真值的关系。

4.5.3 影响样本容量的因素

- 效应量 Δ : 希望检测的差异越小, 需要的 n 越大;
- 显著性水平 α : α 越小, 需要的 n 越大;
- 功效 $1 - \beta$: 功效要求越高, 需要的 n 越大;
- 总体方差 σ^2 : 方差越大, 需要的 n 越大。

4.6 分布拟合检验

在许多实际问题中, 总体的分布类型是未知的。我们需要根据样本检验总体是否服从某个指定的分布。

4.6.1 χ^2 拟合优度检验

思想: 将样本分组, 比较各组的观测频数与在 H_0 下的期望频数。

定义 4.5 (Pearson χ^2 统计量). 设将总体取值范围分为 k 个互不相交的区间, 第 i 个区间的观测频数为 f_i , 在 H_0 (总体服从某特定分布) 下的期望频数为 $\hat{e}_i = n \cdot \hat{p}_i$, 其中 $\hat{p}_i$ 为 H_0 下落入第 i 区间的概率。

Pearson χ^2 统计量:

$$\chi^2 = \sum_{i=1}^k \frac{(f_i - \hat{e}_i)^2}{\hat{e}_i}. \quad (4.17)$$

当 $n \rightarrow \infty$ 时, 若 H_0 为真,

$$\chi^2 \xrightarrow{d} \chi^2(k - r - 1), \quad (4.18)$$

其中 r 为 H_0 分布中待估参数的个数。

拒绝域: $\chi^2 \geq \chi_{\alpha}^2(k - r - 1)$ 。

注意事项:

- 每个区间的期望频数应 ≥ 5 , 否则需合并区间;
- 适用于大样本 ($n \geq 50$) 且既可用于离散分布也可用于连续分布。

例 4.3 (检验骰子是否均匀). 掷一枚骰子 120 次, 记录各面出现次数。检验 H_0 : 骰子是均匀的 ($p_i = 1/6$)。期望频数均为 $120/6 = 20$ 。

若观测频数为 $f = (18, 22, 17, 21, 19, 23)$:

$$\chi^2 = \frac{(18 - 20)^2}{20} + \frac{(22 - 20)^2}{20} + \cdots + \frac{(23 - 20)^2}{20} = 1.7 < \chi_{0.05}^2(5) = 11.07, \quad (4.19)$$

故不拒绝 H_0 , 认为骰子是均匀的。

4.6.2 正态性检验概述

判断数据是否来自正态总体是许多统计方法的前提。

常用方法：

- **Q-Q 图 (Quantile-Quantile Plot)**: 将样本分位数与正态理论分位数作图, 若近似为直线则支持正态性假设;
- **Shapiro-Wilk 检验**: 适用于小样本 ($n \leq 50$), 功效较高;
- **Kolmogorov-Smirnov 检验**: 基于经验分布函数与理论分布函数的最大差异;
- **Jarque-Bera 检验**: 基于样本偏度和峰度, 适用于大样本。

4.7 秩和检验

前面讨论的 t 检验等均假设总体服从正态分布。当正态性假设不成立或数据为定序数据时, 需使用非参数方法。秩和检验是最常用的非参数检验之一。

4.7.1 Wilcoxon 秩和检验 (两独立样本)

目的: 比较两个独立总体的位置参数是否相同, 是两样本 t 检验的非参数替代。

注记 4.2 (与 t 检验的对应关系). 注意区分两种不同的一一对应:

参数方法	非参数替代
单样本 t 检验 ($H_0: \mu = \mu_0$)	Wilcoxon 符号秩检验
两样本 t 检验 ($H_0: \mu_1 = \mu_2$)	Wilcoxon 秩和检验

两样本 t 检验是一次性直接比较两个组的均值差, 用 $T = \frac{\bar{X}_1 - \bar{X}_2}{S_w \sqrt{1/n_1 + 1/n_2}}$ 作为统计量, 而不是分别对每组各做一次单样本 t 检验。秩和检验也是如此——它将两组数据合并排序后统一比较。

步骤:

1. 将两组数据 (样本量 n_1, n_2) 合并, 从小到大排序并赋予秩 (rank), 相同值赋予平均秩;
2. 计算第一组样本的秩和 R_1 ;
3. 检验统计量:

$$U = n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - R_1. \quad (4.20)$$

或等价地使用 R_1 本身。

当 n_1, n_2 较大时, R_1 近似服从正态分布:

$$\mathbb{E}[R_1] = \frac{n_1(n_1 + n_2 + 1)}{2}, \quad \text{Var}(R_1) = \frac{n_1 n_2 (n_1 + n_2 + 1)}{12}. \quad (4.21)$$

例 4.4 (Wilcoxon 秩和检验完整演示). 某研究比较两种教学法对学生成绩的影响。随机抽取 A 班 6 名学生、B 班 7 名学生, 期末考试成绩如下 (满分 100):

A 班	72	68	85	91	55	77	
B 班	60	75	82	63	70	58	79

检验 H_0 : 两种教学法的成绩分布相同 vs. H_1 : 两种教学法成绩分布不同 ($\alpha = 0.05$, 双侧)。

步骤 1: 合并排序并赋予秩

将两班共 $n_1 + n_2 = 13$ 个数据从小到大排列, 同分取平均秩:

原始值	所属班	排序位次	秩
55	A	1	1
58	B	2	2
60	B	3	3
63	B	4	4
68	A	5	5
70	B	6	6
72	A	7	7
75	B	8	8
77	A	9	9
79	B	10	10
82	B	11	11
85	A	12	12
91	A	13	13

步骤 2: 计算 A 班的秩和 R_1

$$R_1 = 1 + 5 + 7 + 9 + 12 + 13 = 47. \quad (4.22)$$

步骤 3: 计算检验统计量

取 $n_1 = 6$ (A 班), $n_2 = 7$ (B 班)。

Mann-Whitney U 统计量:

$$U = n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - R_1 = 6 \times 7 + \frac{6 \times 7}{2} - 47 = 42 + 21 - 47 = 16. \quad (4.23)$$

R_1 在 H_0 下的期望与方差:

$$\mathbb{E}[R_1] = \frac{n_1(n_1 + n_2 + 1)}{2} = \frac{6 \times 14}{2} = 42, \quad (4.24)$$

$$\text{Var}(R_1) = \frac{n_1 n_2 (n_1 + n_2 + 1)}{12} = \frac{6 \times 7 \times 14}{12} = 49. \quad (4.25)$$

标准化 (大样本近似):

$$Z = \frac{R_1 - \mathbb{E}[R_1]}{\sqrt{\text{Var}(R_1)}} = \frac{47 - 42}{\sqrt{49}} = \frac{5}{7} \approx 0.714. \quad (4.26)$$

步骤 4: 做出决策

双侧检验, $\alpha = 0.05$, $z_{0.025} = 1.96$ 。

$|Z| = 0.714 < 1.96$, 不拒绝 H_0 。

也可用精确检验: 查 Wilcoxon 秩和检验临界值表, 对于 $n_1 = 6, n_2 = 7$ (双侧 $\alpha = 0.05$), 临界下界 $R_L = 30$, 临界上界 $R_U = 54$ 。 $R_1 = 47$ 落在 $[30, 54]$ 内, 同样不拒绝 H_0 。

结论: 在 $\alpha = 0.05$ 水平下, 没有足够证据认为两种教学法的成绩分布存在显著差异。

补充—— p 值计算:

$$p = 2 \times P(Z \geq 0.714 | H_0) = 2 \times (1 - \Phi(0.714)) \approx 2 \times 0.2375 = 0.475. \quad (4.27)$$

$p = 0.475 > 0.05$, 与上述结论一致。

特点: 不依赖总体分布的具体形式, 对异常值稳健 (robust), 但功效略低于 t 检验 (当正态假设成立时)。

4.7.2 Wilcoxon 符号秩检验 (配对样本)

目的: 配对样本 t 检验的非参数替代。与秩和检验不同, 符号秩检验对应的是**配对设计** (同一受试者前后测量), 等价于对差值 D_i 做单样本检验, 即 H_0 : 差值的分布关于 0 对称。

步骤:

1. 计算每对数据的差值 $D_i = X_i - Y_i$, 去掉 $D_i = 0$ 的对;
2. 对 $|D_i|$ 从小到大赋予秩;
3. 分别计算正差值对应的秩和 R^+ 与负差值对应的秩和 R^- ;
4. 检验统计量可取 R^+ (或 R^-), 其分布在 H_0 下可查 Wilcoxon 符号秩检验表。

当有效对数 n 较大时 (通常 $n \geq 20$), R^+ 近似服从正态分布:

$$\mathbb{E}[R^+] = \frac{n(n+1)}{4}, \quad \text{Var}(R^+) = \frac{n(n+1)(2n+1)}{24}. \quad (4.28)$$

例 4.5 (Wilcoxon 符号秩检验完整演示). 某研究想测试服用某种补充剂是否能改善睡眠时长。招募 10 名受试者，记录服用前与服用一个月后的睡眠时长（小时），数据如下：

受试者编号	1	2	3	4	5	6	7	8	9	10
服用前 (Y_i)	6.2	7.0	5.8	6.5	7.5	5.5	6.0	7.2	6.8	5.9
服用后 (X_i)	6.8	7.3	6.1	7.0	7.6	5.4	6.5	7.5	7.1	6.4

检验 H_0 : 服用前后睡眠时长无差异 vs. H_1 : 服用后睡眠时长增加 ($\alpha = 0.05$, 右侧检验)。

步骤 1: 计算差值 $D_i = X_i - Y_i$ 并取绝对值

受试者	X_i (后)	Y_i (前)	$D_i = X_i - Y_i$
1	6.8	6.2	+0.6
2	7.3	7.0	+0.3
3	6.1	5.8	+0.3
4	7.0	6.5	+0.5
5	7.6	7.5	+0.1
6	5.4	5.5	-0.1
7	6.5	6.0	+0.5
8	7.5	7.2	+0.3
9	7.1	6.8	+0.3
10	6.4	5.9	+0.5

没有 $D_i = 0$ 的对，有效对数 $n = 10$ 。

步骤 2: 对 $|D_i|$ 从小到大赋予秩

受试者	D_i	$ D_i $	$ D_i $ 排序	秩
5	+0.1	0.1	1	1
6	-0.1	0.1	2	2
2	+0.3	0.3	3	4
3	+0.3	0.3	4	4
8	+0.3	0.3	5	4
9	+0.3	0.3	6	4
4	+0.5	0.5	7	8
7	+0.5	0.5	8	8
10	+0.5	0.5	9	8
1	+0.6	0.6	10	10

注意结的处理：

- $|D_i| = 0.1$ 出现 2 次（位次 1, 2），秩各为 $\frac{1+2}{2} = 1.5$ ；
- $|D_i| = 0.3$ 出现 4 次（位次 3–6），秩各为 $\frac{3+4+5+6}{4} = 4.5$ ；
- $|D_i| = 0.5$ 出现 3 次（位次 7–9），秩各为 $\frac{7+8+9}{3} = 8$ ；
- $|D_i| = 0.6$ 出现 1 次，秩为 10。

带符号的秩：

受试者	D_i	符号	带符号秩
1	+0.6	+	+10
2	+0.3	+	+4.5
3	+0.3	+	+4.5
4	+0.5	+	+8
5	+0.1	+	+1.5
6	-0.1	-	-1.5
7	+0.5	+	+8
8	+0.3	+	+4.5
9	+0.3	+	+4.5
10	+0.5	+	+8

步骤 3：计算正秩和 R^+ 与负秩和 R^-

$$R^+ = 10 + 4.5 + 4.5 + 8 + 1.5 + 8 + 4.5 + 4.5 + 8 = 53.5, \quad (4.29)$$

$$R^- = 1.5. \quad (4.30)$$

验证： $R^+ + R^- = 53.5 + 1.5 = 55 = \frac{10 \times 11}{2} = \frac{n(n+1)}{2}$ 。✓

步骤 4：使用正态近似计算 Z 统计量

$$\mathbb{E}[R^+] = \frac{n(n+1)}{4} = \frac{10 \times 11}{4} = 27.5, \quad (4.31)$$

$$\text{Var}(R^+) = \frac{n(n+1)(2n+1)}{24} = \frac{10 \times 11 \times 21}{24} = \frac{2310}{24} = 96.25. \quad (4.32)$$

$$Z = \frac{R^+ - \mathbb{E}[R^+]}{\sqrt{\text{Var}(R^+)}} = \frac{53.5 - 27.5}{\sqrt{96.25}} = \frac{26}{9.811} \approx 2.650. \quad (4.33)$$

步骤 5：做出决策

右侧检验, $\alpha = 0.05$, $z_{0.05} = 1.645$ 。

$Z = 2.650 > 1.645$, 拒绝 H_0 。

也可查 Wilcoxon 符号秩检验临界值表: $n = 10$, 右侧 $\alpha = 0.05$ 时临界值为 $T_{0.05} = 44$ 。 $R^+ = 53.5 > 44$, 同样拒绝 H_0 。

结论: 在 $\alpha = 0.05$ 水平下, 有显著证据表明服用该补充剂后睡眠时长有所增加。

补充—— p 值计算 (正态近似):

$$p = P(Z \geq 2.650 \mid H_0) = 1 - \Phi(2.650) \approx 1 - 0.9960 = 0.004. \quad (4.34)$$

$p = 0.004 < 0.01$, 属于强证据拒绝 H_0 。

注记 4.3. 非参数方法的优势在于无需分布假设, 适用于小样本、有异常值或定序数据的情形。但其代价是当分布假设实际成立时, 功效略低于对应的参数方法。

4.8 假设检验问题的 p 值检验法

4.8.1 p 值的定义

传统检验方法需预先指定显著性水平 α , 然后给出“拒绝”或“不拒绝”的二值结论。但在实际应用中 (尤其是在科学研究和机器学习中), 更常用的是 p 值。

定义 4.6 (p 值). 在原假设 H_0 为真的条件下, 观察到比当前样本更极端结果的概率。

设检验统计量的观测值为 t_{obs} , 则:

- 双侧检验: $p = 2 \cdot P(T \geq |t_{\text{obs}}| \mid H_0)$;
- 右侧检验: $p = P(T \geq t_{\text{obs}} \mid H_0)$;
- 左侧检验: $p = P(T \leq t_{\text{obs}} \mid H_0)$ 。

4.8.2 p 值的解释

p 值范围	解释
$p \leq 0.01$	强证据拒绝 H_0
$0.01 < p \leq 0.05$	中等证据拒绝 H_0
$0.05 < p \leq 0.10$	弱证据拒绝 H_0
$p > 0.10$	不足以拒绝 H_0

p 值的优势:

- 提供了比“拒绝/不拒绝”更丰富的信息——反映了证据的强度;

- 读者可根据自己的 α 标准自行判断;
- 是现代科学研究 (尤其是生命科学、社会科学) 中报告检验结果的标准方式。

注记 4.4 (关于 p 值的常见误解). • p 值不是 H_0 为真的概率;

- p 值不是效应的大小 (effect size 需单独报告);
- 大样本下微小的效应也可能得到很小的 p 值, ”显著” 不等于 ”重要”。

4.8.3 p 值与置信区间的关系

$p < \alpha$ 等价于 $1 - \alpha$ 置信区间不包含 H_0 下的参数值。因此 p 值检验法与置信区间法在数学上等价。

例 4.6 (p 值检验法完整演示). 某灌装生产线标称每瓶装 500 ml。质检员随机抽取 $n = 25$ 瓶, 测得 $\bar{X} = 503.2$ ml。已知灌装量服从正态分布, 且长期记录表明 $\sigma = 8$ ml。问: 是否有证据表明灌装量偏离了 500 ml? (取 $\alpha = 0.05$)

步骤 1: 建立假设

$$H_0: \mu = 500 \quad \text{vs.} \quad H_1: \mu \neq 500 \quad (\text{双侧检验}). \quad (4.35)$$

步骤 2: 计算检验统计量

方差已知, 使用 Z 检验:

$$Z_{\text{obs}} = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} = \frac{503.2 - 500}{8/\sqrt{25}} = \frac{3.2}{1.6} = 2.00. \quad (4.36)$$


步骤 3: 计算 p 值

因为是双侧检验, p 值为观察到 $|Z| \geq 2.00$ 的概率:

$$p = 2 \times P(Z \geq 2.00 \mid H_0) = 2 \times (1 - \Phi(2.00)). \quad (4.37)$$

查标准正态分布表, $\Phi(2.00) = 0.9772$:

$$p = 2 \times (1 - 0.9772) = 2 \times 0.0228 = 0.0456. \quad (4.38)$$



步骤 4：做出决策

- $p = 0.0456 < \alpha = 0.05$ ，拒绝 H_0 。
- 按 p 值解释标准， $0.01 < p \leq 0.05$ ，属于**中等证据**。

结论：在 $\alpha = 0.05$ 水平下，有显著证据表明灌装量偏离了 500 ml。样本均值 503.2 ml 比标称值高出 3.2 ml，但 $p = 0.0456$ 接近 0.05，证据不算极强，建议增加样本量再次检验。

对比——传统拒绝域法：

若用拒绝域法， $z_{0.025} = 1.96$ ， $|Z_{\text{obs}}| = 2.00 > 1.96$ ，落入拒绝域，同样拒绝 H_0 。两种方法结论一致。

但 p 值法额外告诉我们：若 α 设为 0.01 ($z_{0.005} = 2.576$)，则 $|Z_{\text{obs}}| = 2.00 < 2.576$ ， $p = 0.0456 > 0.01$ ，不拒绝 H_0 。这说明结论**依赖于所选的 α** 。 p 值让读者可以自行判断，而不必受制于作者事先选择的 α 。

延伸——若为单侧检验：

如果质检员只关心灌装量是否**偏多**（右侧检验 $H_1: \mu > 500$ ）：

$$p_{\text{右侧}} = P(Z \geq 2.00) = 1 - \Phi(2.00) = 0.0228. \quad (4.39)$$

$p = 0.0228 < 0.05$ ，同样拒绝 H_0 （证据更强，因为 p 比双侧小一半）。

如果只关心是否**偏少**（左侧检验 $H_1: \mu < 500$ ）：

$$p_{\text{左侧}} = P(Z \leq 2.00) = \Phi(2.00) = 0.9772. \quad (4.40)$$

$p = 0.9772 \gg 0.05$ ，毫无证据拒绝 H_0 。这与样本均值 $503.2 > 500$ 的方向一致。

本章小结

本章系统介绍了统计推断的另一核心内容——假设检验：

1. **基本框架：**原假设/备择假设的设定、两类错误及其概率 α, β 、拒绝域的构造；
2. **正态总体均值检验：** Z 检验（方差已知）、 t 检验（方差未知）、两样本与配对检验；
3. **正态总体方差检验：** χ^2 检验（单总体）、 F 检验（两总体方差比）；
4. **置信区间与检验的对偶性：**置信区间可视为所有不被拒绝的参数值集合；
5. **样本容量选取：**根据效应量、 α 、功效等在抽样前确定所需 n ；
6. **分布拟合检验：**Pearson χ^2 检验判断总体是否服从指定分布；

7. **秩和检验**：不依赖正态假设的非参数方法（Wilcoxon 秩和检验、符号秩检验）；
8. **p 值检验法**：提供证据强度的连续度量，是现代统计实践的标准。

假设检验与参数估计共同构成了**统计推断**的两大基石。在机器学习中，假设检验广泛应用于 A/B 测试、特征选择、模型比较与分布漂移检测等场景。

第五章 方差分析及回归分析

方差分析（ANOVA）和回归分析是统计建模中两类核心方法：

- 方差分析：比较多个总体的均值是否有显著差异（ t 检验的推广）；
- 回归分析：建模自变量与因变量之间的数量关系。

两者在数学上同源——都可以纳入一般线性模型的框架。

5.1 单因素试验的方差分析

5.1.1 问题的提出

前面学过的两样本 t 检验只能比较两个总体的均值。当需要比较三个或更多总体时（如比较 A、B、C 三种教学法的效果），若逐对做 t 检验会累积第一类错误。方差分析（Analysis of Variance, ANOVA）为此提供了一次性检验多个均值是否全相等的框架。

定义 5.1 (单因素方差分析模型). 设因素 A 有 r 个水平，第 i 个水平下有 n_i 个观测值：

$$X_{ij} = \mu_i + \varepsilon_{ij}, \quad i = 1, \dots, r, \quad j = 1, \dots, n_i, \quad (5.1)$$

其中 $\varepsilon_{ij} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2)$ 。

检验假设：

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_r \quad \text{vs.} \quad H_1 : \text{至少有两个 } \mu_i \text{ 不等.} \quad (5.2)$$

ANOVA 的三个前提条件（单因素、双因素均适用）：

1. **独立性**：各观测值相互独立——由随机抽样或随机分配保证；
2. **正态性**：各组数据来自正态总体——用 Q-Q 图或 Shapiro-Wilk 检验诊断；
3. **方差齐性**：各组总体方差相等 $\sigma_1^2 = \dots = \sigma_r^2$ ——用 Levene 检验或 Bartlett 检验诊断。

ANOVA 对正态性偏离有一定鲁棒性，但对方差严重不等较为敏感。

注记 5.1 (模型的另一种参数化). 单因素模型也可等价地写成与双因素统一的形式:

$$X_{ij} = \mu + \alpha_i + \varepsilon_{ij}, \quad \sum_{i=1}^r \alpha_i = 0, \quad (5.3)$$

其中 μ 为总均值 (grand mean), $\alpha_i = \mu_i - \mu$ 为第 i 组偏离总均值的效应量。

这揭示了一种统一的视角: **每个观测值 = 总均值 + 该组效应 + 随机误差**。单因素用 μ_i 更简洁, 双因素因格子均值同时受两个因素影响, 拆成 $\mu + \alpha_i + \beta_j$ 更自然——但两者本质相同。

5.1.2 平方和分解

核心思想: 将总变异分解为**组间变异** (因素引起) 和**组内变异** (随机误差引起), 比较两者的相对大小。

记总均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^r \sum_{j=1}^{n_i} X_{ij}$, 第 i 组均值为 $\bar{X}_{i\cdot} = \frac{1}{n_i} \sum_{j=1}^{n_i} X_{ij}$ 。

分解的核心恒等式 (对每个观测值):

$$X_{ij} - \bar{X} = (\bar{X}_{i\cdot} - \bar{X}) + (X_{ij} - \bar{X}_{i\cdot}). \quad (5.4)$$

即: **总离差 = 组间离差 + 组内离差**。两边平方再对所有 i, j 求和, 交叉项恰好为零:

$$\underbrace{\sum_{i,j} (X_{ij} - \bar{X})^2}_{SS_T} = \underbrace{\sum_i n_i (\bar{X}_{i\cdot} - \bar{X})^2}_{SS_A} + \underbrace{\sum_{i,j} (X_{ij} - \bar{X}_{i\cdot})^2}_{SS_E}. \quad (5.5)$$

符号	名称	含义
SS_T	总平方和	所有数据围绕总均值的总变异
SS_A	组间平方和	各组均值之间的差异 (因素效应)
SS_E	组内平方和 (误差)	组内个体差异 (随机误差)

对应自由度分解: $n - 1 = (r - 1) + (n - r)$ 。

5.1.3 F 检验

均方 (Mean Square):

$$MS_A = \frac{SS_A}{r - 1}, \quad MS_E = \frac{SS_E}{n - r}. \quad (5.6)$$

定理 5.1 (ANOVA F 检验). 在 H_0 为真且正态假设下:

$$F = \frac{MS_A}{MS_E} \sim F(r - 1, n - r). \quad (5.7)$$

若 $F \geq F_\alpha(r - 1, n - r)$, 则拒绝 H_0 。

直观理解：若 H_0 成立，组间差异仅由随机误差造成， MS_A 与 MS_E 应大小接近， $F \approx 1$ ；若因素效应存在， MS_A 会显著偏大， $F \gg 1$ 。

单因素 ANOVA 表

来源	平方和	自由度	均方	F 值
组间 (A)	SS_A	$r - 1$	$MS_A = SS_A / (r - 1)$	$F = MS_A / MS_E$
组内 (E)	SS_E	$n - r$	$MS_E = SS_E / (n - r)$	
总和	SS_T	$n - 1$		

例 5.1 (三种教学法的比较). 比较三种教学法 (A、B、C) 对学生成绩的影响。每种方法随机分配 5 名学生，成绩如下：

教学法	成绩					均值
A	78	82	75	80	85	$\bar{X}_{1.} = 80$
B	88	85	90	86	91	$\bar{X}_{2.} = 88$
C	72	76	70	74	73	$\bar{X}_{3.} = 73$
总均值 $\bar{X} = 80.33$						

计算：

$$SS_A = 5 \times (80 - 80.33)^2 + 5 \times (88 - 80.33)^2 + 5 \times (73 - 80.33)^2 \quad (5.8)$$

$$= 5 \times 0.11 + 5 \times 58.78 + 5 \times 53.78 = 563.33, \quad (5.9)$$

$$SS_E = \text{各组内部离差平方和} = 58 + 26 + 20 = 104, \quad (5.10)$$

$$MS_A = \frac{563.33}{2} = 281.67, \quad MS_E = \frac{104}{12} = 8.67, \quad (5.11)$$

$$F = \frac{281.67}{8.67} = 32.50. \quad (5.12)$$

$F_{0.05}(2, 12) = 3.89$ 。 $F = 32.50 > 3.89$ ，拒绝 H_0 ，三种教学法效果有显著差异。

5.1.4 多重比较

ANOVA 只告诉我们“至少有两个均值不等”，但不告诉我们哪些不等。若 ANOVA 显著，还需做**多重比较** (multiple comparisons) 来找出差异来源。

- **Tukey HSD (Honestly Significant Difference)**: 控制全部配对比较的总体错误率 (family-wise error rate);
- **Bonferroni 校正**: 将显著性水平调整为 α/m (m 为比较次数)，最简单但保守。

5.2 双因素试验的方差分析

实际问题中，响应变量常受多个因素同时影响。双因素 ANOVA 同时考察两个因素的主效应及其交互作用。

5.2.1 无交互作用的双因素 ANOVA

模型：

$$X_{ij} = \mu + \alpha_i + \beta_j + \varepsilon_{ij}, \tag{5.13}$$

其中 α_i 为因素 A 的第 i 水平效应, β_j 为因素 B 的第 j 水平效应, 且满足约束 $\sum_i \alpha_i = 0, \sum_j \beta_j = 0$ (否则模型不可识别)。

平方和分解 (与单因素同理):

对每个观测值, 离差可拆为三部分:

$$X_{ij} - \bar{X} = (\bar{X}_{i\cdot} - \bar{X}) + (\bar{X}_{\cdot j} - \bar{X}) + (X_{ij} - \bar{X}_{i\cdot} - \bar{X}_{\cdot j} + \bar{X}). \tag{5.14}$$

平方求和后交叉项为零:

$$SS_T = SS_A + SS_B + SS_E. \tag{5.15}$$

无交互作用的双因素 ANOVA 表

来源	平方和	自由度	均方	F 值
因素 A	SS_A	$r - 1$	MS_A	$F_A = MS_A/MS_E$
因素 B	SS_B	$s - 1$	MS_B	$F_B = MS_B/MS_E$
误差	SS_E	$(r - 1)(s - 1)$	MS_E	
总和	SS_T	$rs - 1$		

例 5.2 (无交互作用的双因素 ANOVA 完整演示). 某教育研究比较三种教学法 (因素 A: A_1 讲授式、 A_2 讨论式、 A_3 翻转课堂) 在不同学校 (因素 B: B_1, B_2, B_3, B_4 四所学校) 的效果。在每个学校各随机抽取一个班, 共 $3 \times 4 = 12$ 个班, 期末平均成绩如下 (满分 100):

教学法	B_1	B_2	B_3	B_4	行均值 $\bar{X}_{i\cdot}$
A_1 (讲授)	72	75	70	78	73.75
A_2 (讨论)	80	83	78	85	81.50
A_3 (翻转)	88	90	85	92	88.75
列均值 $\bar{X}_{\cdot j}$	80.0	82.67	77.67	85.0	总均值 $\bar{X} = 81.33$

注：每种组合只有一个观测值（无重复），无法估计交互作用，因此假定教学法与学校之间无交互效应。

步骤 1：计算各平方和

$$SS_T = \sum_{i=1}^3 \sum_{j=1}^4 (X_{ij} - 81.33)^2 \quad (5.16)$$

$$= (72 - 81.33)^2 + (75 - 81.33)^2 + \cdots + (92 - 81.33)^2 \quad (5.17)$$

$$= 87.11 + 40.11 + 128.44 + 11.11 \quad (5.18)$$

$$+ 1.78 + 2.78 + 11.11 + 13.44 \quad (5.19)$$

$$+ 44.44 + 75.11 + 13.44 + 113.78 = 542.67, \quad (5.20)$$

$$SS_A = 4 \times [(73.75 - 81.33)^2 + (81.50 - 81.33)^2 + (88.75 - 81.33)^2] \quad (5.21)$$

$$= 4 \times [57.40 + 0.03 + 55.05] = 4 \times 112.48 = 449.92, \quad (5.22)$$

$$SS_B = 3 \times [(80.00 - 81.33)^2 + (82.67 - 81.33)^2 + (77.67 - 81.33)^2 + (85.00 - 81.33)^2] \quad (5.23)$$

$$= 3 \times [1.78 + 1.78 + 13.44 + 13.44] = 3 \times 30.44 = 91.33, \quad (5.24)$$

$$SS_E = SS_T - SS_A - SS_B = 542.67 - 449.92 - 91.33 = 1.42. \quad (5.25)$$

步骤 2：填写 ANOVA 表

来源	SS	df	MS	F	$F_{0.05}$
教学法 (A)	449.92	2	224.96	$F_A = 952.8$	$F_{0.05}(2, 6) = 5.14$
学校 (B)	91.33	3	30.44	$F_B = 128.9$	$F_{0.05}(3, 6) = 4.76$
误差	1.42	6	0.236		
总和	542.67	11			

步骤 3：做出结论

- 教学法： $F_A = 952.8 > 5.14$ ，拒绝 H_0 ，三种教学法效果有极显著差异；
- 学校： $F_B = 128.9 > 4.76$ ，拒绝 H_0 ，不同学校间成绩存在显著差异。

方差分析的解释：

- $SS_A = 449.92$ 占总变异的 82.9%，教学法是成绩差异的主要来源；
- $SS_B = 91.33$ 占 16.8%，学校间差异次之；
- $SS_E = 1.42$ 仅占 0.26%，随机误差极小，模型拟合非常好。

5.2.2 有交互作用的双因素 ANOVA

当两个因素可能相互影响时（如肥料 A 和灌溉量 B 对产量的联合效果），需引入交互效应项 $(\alpha\beta)_{ij}$ ：

模型：

$$X_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk}, \tag{5.26}$$

其中 $k = 1, \dots, c$ （每种处理组合至少有 $c \geq 2$ 次重复）。

有交互作用的双因素 ANOVA 表				
来源	平方和	自由度	均方	F 值
因素 A	SS_A	$r - 1$	MS_A	$F_A = MS_A/MS_E$
因素 B	SS_B	$s - 1$	MS_B	$F_B = MS_B/MS_E$
交互 $A \times B$	SS_{AB}	$(r - 1)(s - 1)$	MS_{AB}	$F_{AB} = MS_{AB}/MS_E$
误差	SS_E	$rs(c - 1)$	MS_E	
总和	SS_T	$rsc - 1$		

分析策略：先检验交互作用。若交互显著，主效应的分析需谨慎——因素 A 的效果可能依赖于因素 B 的水平，应做简单效应分析或分水平讨论。

例 5.3 (有交互作用的双因素 ANOVA 完整演示). 某农业试验研究两种肥料（因素 A: A_1 有机肥、 A_2 化肥）和三种灌溉量（因素 B: B_1 低、 B_2 中、 B_3 高）对作物产量的影响。每种处理组合设置 3 个重复小区，共 $2 \times 3 \times 3 = 18$ 个小区。产量数据（kg/小区）如下：

肥料	灌溉	重复观测值			单元格均值
A_1	B_1	42	45	39	42.0
A_1	B_2	55	58	52	55.0
A_1	B_3	50	53	47	50.0
A_2	B_1	48	51	45	48.0
A_2	B_2	70	73	67	70.0
A_2	B_3	80	84	76	80.0

步骤 1：计算各水平均值

	B_1 （低）	B_2 （中）	B_3 （高）	行均值
A_1 （有机）	42.0	55.0	50.0	49.0
A_2 （化肥）	48.0	70.0	80.0	66.0
列均值	45.0	62.5	65.0	总均值 $\bar{X} = 57.5$

步骤 2：计算各平方和（使用单元格均值 $\bar{X}_{ij}$ 。）

$SS_A = 3 \times 3 \times [(49.0 - 57.5)^2 + (66.0 - 57.5)^2]$ (5.27)

$= 9 \times [72.25 + 72.25] = 9 \times 144.5 = 1300.5,$ (5.28)

$SS_B = 2 \times 3 \times [(45.0 - 57.5)^2 + (62.5 - 57.5)^2 + (65.0 - 57.5)^2]$ (5.29)

$= 6 \times [156.25 + 25.0 + 56.25] = 6 \times 237.5 = 1425.0,$ (5.30)

$SS_{AB} = 3 \times [(42.0 - 49.0 - 45.0 + 57.5)^2 + (55.0 - 49.0 - 62.5 + 57.5)^2]$ (5.31)

$+ (50.0 - 49.0 - 65.0 + 57.5)^2 + (48.0 - 66.0 - 45.0 + 57.5)^2$ (5.32)

$+ (70.0 - 66.0 - 62.5 + 57.5)^2 + (80.0 - 66.0 - 65.0 + 57.5)^2]$ (5.33)

$= 3 \times [30.25 + 1.0 + 42.25 + 30.25 + 1.0 + 42.25]$ (5.34)

$= 3 \times 147.0 = 441.0,$ (5.35)

$SS_E =$ 原始 18 个观测值对各自单元格均值的离差平方和 (5.36)

$= [(42 - 42)^2 + (45 - 42)^2 + (39 - 42)^2] + \cdots + [(80 - 80)^2 + (84 - 80)^2 + (76 - 80)^2]$ (5.37)

$= 18 + 18 + 18 + 18 + 18 + 32 = 122,$ (5.38)

$SS_T = 1300.5 + 1425.0 + 441.0 + 122 = 3288.5.$ (5.39)

验证（直接从原始数据算 SS_T ）： $SS_T = \sum_{k=1}^{18} (X_k - 57.5)^2 = 3288.5$ 。✓

步骤 3：填写 ANOVA 表

来源	SS	df	MS	F	$F_{0.05}$
肥料 (A)	1300.5	1	1300.5	$F_A = 128.0$	$F_{0.05}(1, 12) = 4.75$
灌溉 (B)	1425.0	2	712.5	$F_B = 70.1$	$F_{0.05}(2, 12) = 3.89$
交互 $A \times B$	441.0	2	220.5	$F_{AB} = 21.7$	$F_{0.05}(2, 12) = 3.89$
误差	122.0	12	10.17		
总和	3288.5	17			

步骤 4：得出结论

1. 交互作用： $F_{AB} = 21.7 > 3.89$ ，交互作用极显著。肥料的效果依赖于灌溉水平——不能简单地讨论”哪种肥料更好”。
2. 简单效应分析（分灌溉水平看肥料差异）：
 - 低灌溉 (B_1)：有机 42.0 vs 化肥 48.0，化肥略好；
 - 中灌溉 (B_2)：有机 55.0 vs 化肥 70.0，化肥明显更好；

- 高灌溉 (B_3): 有机 50.0 vs 化肥 80.0, 化肥优势最大。

结论: 化肥在高灌溉条件下增产效果最突出, 有机肥产量随灌溉量变化不大。

3. **交互效应图 (概念描述):** 若将两条折线画在同一坐标系中 (横轴为灌溉量, 纵轴为产量), 化肥的线随灌溉量急剧上升 ($48 \rightarrow 70 \rightarrow 80$), 有机肥的线相对平坦 ($42 \rightarrow 55 \rightarrow 50$, 中灌溉后反而略降)。两条线**不平行**, 这正是交互作用存在的直观证据。

与无交互情形的对比: 若忽略交互项而强行拟合无交互模型, 交互的变异 ($SS_{AB} = 441.0$) 会被错误地归入误差, 导致 MS_E 膨胀、 F 检验不敏感、结论可能完全错误。这就是为什么**有重复时必须检验交互**。

注记 5.2 (本例如何满足 ANOVA 的三个前提条件). 以肥料 $\times$ 灌溉的试验为例, 逐一检查:

1. **独立性:** 试验设计层面保证——18 个小区随机分配 6 种处理组合, 各小区的产量互不影响。独立性主要靠**随机化** (randomization) 来确保, 而非事后检验。
2. **正态性:** ANOVA 要求的是**残差** ($X_{ijk} - \bar{X}_{ij\cdot}$, 即每个观测值减去其所在处理组合的均值) 服从正态分布, 而非原始数据本身。本例共 18 个残差 (6 个处理组合 $\times$ 3 个重复), 可做 Q-Q 图检验。实践中 ANOVA 对中等程度的正态偏离是鲁棒的 (中心极限定理的作用)。
3. **方差齐性:** 要求 6 个处理组合的总体方差相等。从样本方差看:

处理组合	单元格数据	样本方差
A_1B_1	42, 45, 39	$s^2 = 9.0$
A_1B_2	55, 58, 52	$s^2 = 9.0$
A_1B_3	50, 53, 47	$s^2 = 9.0$
A_2B_1	48, 51, 45	$s^2 = 9.0$
A_2B_2	70, 73, 67	$s^2 = 9.0$
A_2B_3	80, 84, 76	$s^2 = 16.0$

前五组方差均为 9.0, 仅 A_2B_3 略高 (16.0)。最大方差比 $16/9 \approx 1.78$, 在每组仅 3 个观测的情况下属于可接受范围。若方差差异悬殊 (如最大/最小 > 4), 则需考虑数据变换 (如 $\log$ 变换) 或改用 Welch 型校正。

实用口诀: 独立性靠设计、正态性看残差、方差齐性比组内。三者中独立性最重要且不可补救, **违反独立性 = 结论无效**。

5.3 一元线性回归

回归分析研究变量之间的数量关系，是机器学习中监督学习的基础。

5.3.1 模型与假设

定义 5.2 (一元线性回归模型).

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, n, \quad (5.40)$$

其中:

- x_i 为自变量 (解释变量), 视为非随机;
- $\varepsilon_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2)$.

5.3.2 最小二乘估计 (OLS)

目标: 找 $\hat{\beta}_0, \hat{\beta}_1$ 使残差平方和最小:

$$Q(\beta_0, \beta_1) = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2. \quad (5.41)$$

令偏导为零, 得正规方程:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}, \quad (5.42)$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}. \quad (5.43)$$

5.3.3 拟合优度: R^2

定义 5.3 (决定系数).

$$R^2 = \frac{SS_R}{SS_T} = 1 - \frac{SS_E}{SS_T} = 1 - \frac{\sum (Y_i - \hat{Y}_i)^2}{\sum (Y_i - \bar{Y})^2}. \quad (5.44)$$

$R^2 \in [0, 1]$ 度量了 x 对 Y 变异性的解释比例。 R^2 越接近 1, 拟合越好。

平方和分解 (与 ANOVA 同源):

$$\underbrace{\sum (Y_i - \bar{Y})^2}_{SS_T} = \underbrace{\sum (\hat{Y}_i - \bar{Y})^2}_{SS_R} + \underbrace{\sum (Y_i - \hat{Y}_i)^2}_{SS_E}. \quad (5.45)$$

5.3.4 回归系数的假设检验

- t 检验：检验 $H_0: \beta_1 = 0$ （即 x 对 Y 无线性影响）。

$$T = \frac{\hat{\beta}_1}{SE(\hat{\beta}_1)} \sim t(n-2), \quad SE(\hat{\beta}_1) = \sqrt{\frac{MS_E}{S_{xx}}}. \quad (5.46)$$

- F 检验：等价于 ANOVA 框架下的整体显著性检验。

$$F = \frac{MS_R}{MS_E} = \frac{SS_R/1}{SS_E/(n-2)} \sim F(1, n-2). \quad (5.47)$$

对于一元回归， $F = T^2$ ，两种检验等价。

5.3.5 置信区间与预测区间

- 均值 $E[Y | x_0]$ 的置信区间：

$$\hat{Y}_0 \pm t_{\alpha/2}(n-2) \cdot s \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}. \quad (5.48)$$

- 新观测值 Y_{new} 的预测区间：

$$\hat{Y}_0 \pm t_{\alpha/2}(n-2) \cdot s \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}. \quad (5.49)$$

其中 $s = \sqrt{MS_E}$ 。

预测区间比置信区间宽（多了根号内的 1），因为新观测值含有额外的随机误差。

例 5.4 (一元线性回归完整演示). 研究学习时间 (x , 小时) 与考试成绩 (Y , 分) 的关系, 数据如下:

学习时间 x_i	1	2	3	4	5	6
考试成绩 Y_i	52	58	65	70	78	85

步骤 1: 计算基本统计量

$$\bar{x} = 3.5, \quad \bar{Y} = 68, \quad (5.50)$$

$$S_{xx} = \sum (x_i - 3.5)^2 = 17.5, \quad (5.51)$$

$$S_{xy} = \sum (x_i - 3.5)(Y_i - 68) = 115. \quad (5.52)$$

步骤 2: 估计回归系数

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{115}{17.5} = 6.571, \quad \hat{\beta}_0 = 68 - 6.571 \times 3.5 = 45.0. \quad (5.53)$$

回归方程: $\hat{Y} = 45.0 + 6.571x$ 。即每多学 1 小时, 成绩预期提高约 6.6 分。

步骤 3: 检验 $\beta_1 = 0$

先计算 $SS_E = \sum(Y_i - \hat{Y}_i)^2 = 18.86$, $MS_E = 18.86/4 = 4.714$ 。

$$SE(\hat{\beta}_1) = \sqrt{\frac{4.714}{17.5}} = 0.519, \quad T = \frac{6.571}{0.519} = 12.66. \quad (5.54)$$

$t_{0.025}(4) = 2.776$ 。 $|T| = 12.66 > 2.776$, 拒绝 H_0 , 学习时间对成绩有显著线性影响。

$R^2 = 1 - 18.86/698 = 0.973$, 学习时间解释了 97.3% 的成绩变异。

5.4 多元线性回归

当影响因素不止一个时, 需要引入多个自变量。

5.4.1 模型与矩阵形式

定义 5.4 (多元线性回归模型)。

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i, \quad \varepsilon_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2). \quad (5.55)$$

矩阵形式:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad (5.56)$$

其中 $\mathbf{Y}$ 为 $n \times 1$ 响应向量, $\mathbf{X}$ 为 $n \times (p+1)$ 设计矩阵 (第一列全为 1), $\boldsymbol{\beta}$ 为 $(p+1) \times 1$ 系数向量, $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$ 。

5.4.2 最小二乘估计

正规方程: $\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{Y}$ 。

当 $\mathbf{X}^\top \mathbf{X}$ 可逆时:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}. \quad (5.57)$$

$\hat{\boldsymbol{\beta}}$ 的协方差矩阵: $\text{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$ 。

注记 5.3 (OLS 与极大似然估计 (MLE) 的关系). OLS 是 MLE 在正态误差假设下的特例。由模型 $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$, 似然函数为:

$$L(\boldsymbol{\beta}, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|^2}{2\sigma^2}\right). \quad (5.58)$$

取对数似然:

$$\ell(\boldsymbol{\beta}, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{\|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|^2}{2\sigma^2}. \quad (5.59)$$

对 β 求最大——前两项不含 β ，第三项分子是残差平方和，负号意味着：

$$\boxed{\arg \max_{\beta} \ell(\beta, \sigma^2) = \arg \min_{\beta} \|\mathbf{Y} - \mathbf{X}\beta\|^2}. \quad (5.60)$$

最大化似然 $\iff$ 最小化残差平方和，因此：

$$\boxed{\hat{\beta}_{\text{OLS}} = \hat{\beta}_{\text{MLE}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}}. \quad (5.61)$$

注意：若误差分布不是正态（如 Laplace），MLE 的解将不再是 OLS——例如 Laplace 误差下 MLE 等价于最小化绝对偏差（LAD / 分位数回归）。OLS 本身是几何/优化方法，无需概率假设即可使用；概率假设赋予其 MLE 的优良渐近性质。

5.4.3 显著性检验

整体显著性检验（ F 检验）：

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0. \quad (5.62)$$

$$F = \frac{SS_R/p}{SS_E/(n-p-1)} \sim F(p, n-p-1). \quad (5.63)$$

单个系数的检验（ t 检验）：

$$H_0 : \beta_j = 0, \quad T_j = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)} \sim t(n-p-1), \quad (5.64)$$

其中 $SE(\hat{\beta}_j) = s\sqrt{(\mathbf{X}^\top \mathbf{X})_{jj}^{-1}}$, $s = \sqrt{MS_E}$ 。

调整 R^2 ：普通 R^2 随变量增加而单调不减（即使加入噪声变量），调整 R^2 引入自由度惩罚：

$$R_{\text{adj}}^2 = 1 - \frac{SS_E/(n-p-1)}{SS_T/(n-1)} = 1 - (1 - R^2) \frac{n-1}{n-p-1}. \quad (5.65)$$

5.4.4 多重共线性

当自变量间高度相关时， $\mathbf{X}^\top \mathbf{X}$ 接近奇异，导致：

- $\hat{\beta}_j$ 的方差极大，估计不稳定；
- 系数符号可能与直觉相反；
- t 检验不显著但 F 检验显著（矛盾现象）。

诊断方法：方差膨胀因子（VIF）， $VIF_j = \frac{1}{1-R_j^2}$ ，其中 R_j^2 为 x_j 对其余 $p-1$ 个自变量回归的决定系数。通常 $VIF > 10$ 表明严重共线性， $VIF > 5$ 需要关注。

5.4.5 回归诊断：假设验证

OLS 回归的 t 检验和 F 检验依赖于三个核心假设。建模后必须逐条诊断——不能跳过这一步直接报告 p 值。

正态性检验：Shapiro-Wilk 检验与 Q-Q 图

回归要求的是残差 $\varepsilon_i = Y_i - \hat{Y}_i$ 服从正态分布（不是 X 或 Y 本身）。

定义 5.5 (Shapiro-Wilk 检验). H_0 : 数据来自正态分布。检验统计量 $W \in [0, 1]$, 越接近 1 越像正态。

- 若 $p > 0.05$: 不拒绝 H_0 , 可以认为残差满足正态性;
- 若 $p \leq 0.05$: 拒绝 H_0 , 残差显著不正态, t 检验和 p 值不可靠。

Shapiro-Wilk 的局限: 样本量很大时 ($n > 5000$), 微小的偏离也会导致 $p < 0.05$ 。此时应以 **Q-Q 图** 为主——只要散点大致沿对角线, 轻微的系统偏离可以接受。

正态性不满足时的补救:

- Box-Cox 变换: $Y^{(\lambda)} = \begin{cases} (Y^\lambda - 1)/\lambda, & \lambda \neq 0 \\ \ln Y, & \lambda = 0 \end{cases}$
- 改用第 4 章的秩和检验等非参数方法
- 大样本下 ($n \geq 30$), 由 CLT, t 检验对正态偏离有一定鲁棒性

方差齐性 (Homoscedasticity)

含义: 不同 X 取值下, Y 的波动幅度应该大致相同。即 $\text{Var}(\varepsilon_i) = \sigma^2$ (常数), 不随 $\hat{Y}_i$ 变化。

诊断方法: 画残差 vs 拟合值散点图:

- 正常: 残差随机散布在零线上下, 无明显的宽窄变化
- 违反正: 残差随拟合值增大而发散 (漏斗形) $\rightarrow$ **异方差 (Heteroscedasticity)**

异方差的后果: $SE(\hat{\beta}_j)$ 的估计不准确 $\rightarrow t$ 检验和置信区间无效, 即使系数估计本身仍然无偏。

补救:

- 对 Y 做对数变换 (最常用): $Y' = \ln Y$
- 使用加权最小二乘 (WLS), 给波动大的点更小的权重
- 使用异方差稳健标准误 (Huber-White / sandwich estimator)

异常值与影响力点

- **Cook's distance**: 度量删除某个观测后回归系数变化的大小。经验阈值: $D_i > 4/n$
- 高 Cook's distance 的点需要检查——可能是录入错误, 也可能是真正有信息量的极端案例

5.4.6 混合效应模型简介

前述回归模型假设所有观测独立同分布。但在实际数据中, 经常出现**重复测量**或**嵌套结构**:

- NIPT 数据: 同一孕妇在不同孕周检测多次 → 同一个人数据天然相似
- 教育数据: 同一学校的学生成绩相关 → 数据嵌套在学校内
- 医学试验: 同一患者多次随访 → 数据嵌套在患者内

如果用普通回归处理这类数据, 相当于把 n 个不完全独立的数据当成 n 个完全独立的数据, 标准误会被严重低估, p 值虚低。

模型形式:

$$Y_{ij} = \underbrace{\alpha + \beta X_{ij}}_{\text{固定效应}} + \underbrace{u_i}_{\text{随机效应}} + \varepsilon_{ij}, \quad (5.66)$$

其中 i 表示第 i 个组 (如第 i 个孕妇), j 表示组内第 j 次测量。

	固定效应	随机效应
含义	对所有组都一样的规律	各组独有的偏移
变量	α, β (待估参数)	$u_i \sim \mathcal{N}(0, \tau^2)$ (方差待估)
例子	BMI 每增加 1, Y 浓度降低 0.008	张三天生 Y 浓度偏高 0.01

两种 R^2 (这正是 NIPT 官方解法的核心洞察):

- **Marginal R^2** : 仅固定效应解释的变异比例——通常很低 (如 3%), 因为个体差异被排除在外
- **Conditional R^2** : 固定效应 + 随机效应共同解释的变异比例——通常很高 (如 83%), 因为”谁是这个孕妇”本身就携带大量信息

二者的巨大差距揭示了一个重要事实: **Y 染色体浓度的变异主要来自个体差异, 而非 BMI 或孕周**。这正是需要按 BMI 分组、制定个性化检测时点的统计依据。

5.4.7 分位数回归 (Quantile Regression)

普通最小二乘 (OLS) 估计的是**条件均值** $\mathbb{E}[Y | X]$ ——回答“在 X 这个水平下, Y 平均是多少”。但在许多实际问题中, 我们关心的不是均值, 而是**分布的不同位置**。

动机: NIPT 问题 2 要求“最早达标时间”——即 Y 染色体浓度达到 4% 时的孕周。用 OLS 估计“平均何时达标”意味着约一半人会早于、一半人会晚于这个时间——这太乐观了。临床需要的是“确保大多数人都已达标”的保守时点。

基本概念

分位数回归估计的是**条件分位数** $Q_\tau(Y | X)$, 其中 $\tau \in (0, 1)$ 是分位水平:

τ	含义	对应的统计量
0.50	条件中位数	一半人高于、一半人低于此值
0.25	条件下四分位数	25% 的人低于此值
0.75	条件上四分位数	75% 的人低于此值

与 OLS 的对比:

	OLS (均值回归)	分位数回归
估计目标	$\mathbb{E}[Y X]$	$Q_\tau(Y X)$
损失函数	$\sum (y_i - \hat{y}_i)^2$	$\sum \rho_\tau(y_i - \hat{y}_i)$
异常值影响	敏感 (平方放大偏差)	稳健 ($\tau = 0.5$ 即为中位数回归)
假设	残差正态、方差齐性	无需分布假设
输出	一条线 (均值)	可画多条线 (不同分位)

损失函数: 检查函数 (Check Function)

分位数回归最小化的是**非对称绝对损失**:

$$\rho_\tau(u) = u \cdot (\tau - \mathbf{1}_{\{u < 0\}}) = \begin{cases} \tau \cdot u, & u \geq 0 \text{ (高估的惩罚)} \\ (\tau - 1) \cdot u, & u < 0 \text{ (低估的惩罚)} \end{cases} \quad (5.67)$$

- $\tau = 0.50$: $\rho_{0.5}(u) = 0.5|u|$, 高估和低估惩罚对称 $\rightarrow$ 退化为中位数回归

- $\tau = 0.30$: 低估的惩罚 ($0.70|u|$) $\gg$ 高估的惩罚 ($0.30|u|$) $\rightarrow$ 回归线被往下拉, 给出保守估计

目标函数:

$$\hat{\beta}_\tau = \arg \min_{\beta} \sum_{i=1}^n \rho_\tau(y_i - \mathbf{x}_i^\top \beta). \quad (5.68)$$

模型形式

与 OLS 形式完全相同, 但系数依赖于 τ :

$$Q_\tau(Y | X) = \beta_0(\tau) + \beta_1(\tau)X_1 + \cdots + \beta_p(\tau)X_p. \quad (5.69)$$

不同 τ 给出不同的 $\hat{\beta}_j(\tau)$ ——例如 BMI 对 Y 浓度的影响可能在低分位 (体重轻的人) 和高分位 (体重大的人) 不同。

NIPT 中的应用

对每组 BMI, 用分位数回归估计 $Q_{0.30}(Y | \text{GA})$, 然后解:

$$\hat{\alpha}_{g,0.30} + \hat{\gamma}_{g,0.30} \cdot \widehat{\text{GA}}_{g,0.30} = 0.04 \implies \widehat{\text{GA}}_{g,0.30} = \frac{0.04 - \hat{\alpha}_{g,0.30}}{\hat{\gamma}_{g,0.30}}. \quad (5.70)$$

取 $\tau = 0.30$ 的含义: 估计的是”至少 30% 的该 BMI 组孕妇在此孕周已达 Y 浓度 4%”——比均值回归更保守、更符合临床对”安全时点”的要求。

5.4.8 模型选择

选择最优子集自变量的常用准则:

- **AIC (赤池信息准则)**: $AIC = n \ln(SS_E/n) + 2p$, 越小越好;
- **BIC (贝叶斯信息准则)**: $BIC = n \ln(SS_E/n) + p \ln n$, 对变量数惩罚更重;
- **逐步回归**: 前向选择、后向剔除、逐步回归——实用但需谨慎解释。

本章小结

本章涵盖了两个紧密关联的统计建模主题:

1. **单因素 ANOVA**: 将总变异分解为组间 + 组内, 通过 F 检验判断多个均值是否全等;

2. **双因素 ANOVA**: 同时考察两个因素及其交互作用, 平方和分解更复杂但思想相同;
3. **一元线性回归**: 最小二乘估计 $\hat{\beta}_0, \hat{\beta}_1$, R^2 评价拟合, t/F 检验显著性;
4. **多元线性回归**: 矩阵形式 $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$, 多重共线性诊断与模型选择。

ANOVA 与回归的统一视角: 两者都是一般线性模型的特例——ANOVA 的自变量是分类变量 (通过虚拟变量编码), 回归的自变量是连续变量。在机器学习中, 线性回归是最简单的监督学习模型, 而 ANOVA 的思想体现在特征重要性和模型比较的 F 检验中。

回归诊断与混合效应: 建立回归模型后, 必须进行诊断——残差正态性 (Shapiro-Wilk 检验、Q-Q 图)、方差齐性 (残差 vs 拟合值图)、多重共线性 (VIF)。当数据存在重复测量或嵌套结构时, 需引入混合效应模型, 用随机效应 (u_i) 区分个体差异与系统性效应, 避免标准误低估。

第六章 Bootstrap 方法

Bootstrap（自助法）由 Bradley Efron 于 1979 年提出，是统计推断中的一项革命性技术。其核心思想极为简洁：**用重抽样模拟抽样分布**。

传统的参数推断依赖正态近似（如 $\bar{X} \pm z_{\alpha/2} \cdot SE$ ），但当统计量形式复杂、分布未知、或样本量不足以依赖大样本理论时，Bootstrap 提供了一种 **完全基于数据本身的计算机密集型替代方案**。

Bootstrap 在机器学习中应用广泛：模型评估（如 Bagging 中的 Bootstrap 采样）、特征选择稳定性评估、集成学习中的随机森林等。

6.1 非参数 Bootstrap 方法

6.1.1 基本思想

设有样本 $\mathbf{x} = (x_1, x_2, \dots, x_n)$ 来自未知总体分布 F 。我们关心某个统计量 $\hat{\theta} = T(\mathbf{x})$ 的抽样分布（标准误、置信区间等）。

经典方法的问题：需要知道 T 的渐近分布，或假设总体服从某种特定分布。

Bootstrap 的解决思路：用经验分布 $\hat{F}_n$ （每个 x_i 赋予概率 $1/n$ ）替代未知的 F ，然后从 $\hat{F}_n$ 中反复重抽样。

定义 6.1 (非参数 Bootstrap 算法). 1. 从原始样本 $\mathbf{x} = (x_1, \dots, x_n)$ 中有放回地抽取 n 个观测，得到一个 Bootstrap 样本 $\mathbf{x}^{*b} = (x_1^*, \dots, x_n^*)$ ；

2. 计算该 Bootstrap 样本的统计量 $\hat{\theta}^{*b} = T(\mathbf{x}^{*b})$ ；

3. 重复步骤 1-2 共 B 次（通常 $B = 1000$ 或更多），得到 Bootstrap 分布 $\{\hat{\theta}^{*1}, \hat{\theta}^{*2}, \dots, \hat{\theta}^{*B}\}$ 。

6.1.2 Bootstrap 标准误

Bootstrap 分布的标准差即为统计量的 Bootstrap 标准误估计：

$$\widehat{SE}_{\text{boot}}(\hat{\theta}) = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}^{*b} - \bar{\theta}^*)^2}, \quad (6.1)$$

其中 $\bar{\theta}^* = \frac{1}{B} \sum_{b=1}^B \hat{\theta}^{*b}$ 。

6.1.3 Bootstrap 置信区间

方法一：正态近似区间

$$\hat{\theta} \pm z_{\alpha/2} \cdot \widehat{SE}_{\text{boot}}. \quad (6.2)$$

简单但不处理偏态。

方法二：百分位数区间 (Percentile Interval) 取 Bootstrap 分布的 $\alpha/2$ 和 $1 - \alpha/2$ 分位数：

$$\left[\hat{\theta}_{(\alpha/2)}^*, \hat{\theta}_{(1-\alpha/2)}^* \right], \quad (6.3)$$

其中 $\hat{\theta}_{(q)}^*$ 为 Bootstrap 分布的 q 分位数。

方法三：BCa 区间 (Bias-Corrected and Accelerated) 对百分位数法做偏度校正和加速校正，处理偏态效果更好，但需要额外计算 jackknife 统计量。

6.1.4 为什么有放回抽样？

有放回地抽取 n 次，一个 Bootstrap 样本中约 63.2% 的原始观测至少出现一次：

$$P(\text{某特定 } x_i \text{ 被抽中}) = 1 - \left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} 1 - e^{-1} \approx 0.632. \quad (6.4)$$

剩余的约 36.8% 的观测未出现，称为袋外样本 (out-of-bag, OOB)，可用于无偏评估模型——这正是随机森林中 OOB 误差估计的原理。

例 6.1 (Bootstrap 估计中位数的标准误—完整演示). 某研究记录了 8 名患者术后恢复时长 (天)：

$$\mathbf{x} = (12, 15, 18, 22, 25, 30, 35, 48). \quad (6.5)$$

我们关心的是中位数 $\hat{\theta} = \text{median}(\mathbf{x})$ ，但中位数的标准误没有像 $\bar{X}$ 那样简单的公式。Bootstrap 恰好擅长处理这类问题。

原始样本中位数： $\hat{\theta} = \frac{22+25}{2} = 23.5$ 天。

Bootstrap 过程 ($B = 5$ 次示意，实际应用取 $B \geq 1000$)：

b	Bootstrap 样本 $\mathbf{x}^{*b}$ (有放回)	$\hat{\theta}^{*b}$
1	15, 25, 12, 35, 25, 18, 30, 22	23.5
2	48, 18, 18, 22, 12, 35, 25, 15	20.0
3	30, 30, 22, 15, 48, 25, 12, 35	27.5
4	25, 12, 35, 18, 48, 30, 22, 22	23.5
5	15, 15, 18, 25, 35, 48, 30, 12	21.5

实际运行 $B = 2000$ 次的结果（用计算机模拟）：

Bootstrap 中位数分布：

- 均值 $\bar{\theta}^* = 23.84$
- Bootstrap 标准误： $\widehat{SE}_{\text{boot}} = 4.31$
- Bootstrap 偏度估计： $\widehat{\text{Bias}} = \bar{\theta}^* - \hat{\theta} = 23.84 - 23.5 = 0.34$

95% 百分位数置信区间：取 Bootstrap 分布的 2.5% 和 97.5% 分位数：

$$[\hat{\theta}_{(0.025)}^*, \hat{\theta}_{(0.975)}^*] = [16.50, 34.25]. \quad (6.6)$$

结论：术后恢复时长中位数的 95% Bootstrap 置信区间为 $[16.5, 34.25]$ 天。注意区间不对称（23.5 不居中），说明中位数分布是偏态的——百分位数法自动捕捉了这一点，这是正态近似法做不到的。

6.2 参数 Bootstrap 方法

6.2.1 与非参数 Bootstrap 的区别

非参数 Bootstrap 直接从原始数据重抽样，不对总体分布形式做任何假设。但当我们知道总体分布的函数形式（只是参数未知）时，可以利用这一额外信息获得更精确的推断——这就是参数 Bootstrap。

	非参数 Bootstrap	参数 Bootstrap
从何处抽样	原始样本（经验分布 $\hat{F}_n$ ）	参数模型 $F_{\hat{\eta}}$
需要假设分布形式	否	是
适用场景	探索性分析、复杂统计量	已知分布族、小样本
信息利用效率	较低	较高（模型正确时）

6.2.2 算法

1. 从原始样本 $\mathbf{x}$ 得到参数 $\boldsymbol{\eta}$ 的估计 $\hat{\boldsymbol{\eta}}$ （如 MLE）；
2. 从拟合分布 $F_{\hat{\boldsymbol{\eta}}}$ 中生成 Bootstrap 样本 $\mathbf{x}^{*b}$ （样本量 n ）；
3. 计算 $\hat{\theta}^{*b}$ ，重复 B 次。

例 6.2（参数 Bootstrap 估计正态总体方差的置信区间）。设 $n = 10$ 个观测来自 $\mathcal{N}(\mu, \sigma^2)$ ：

$$\mathbf{x} = (4.2, 5.1, 3.8, 6.0, 4.5, 5.5, 3.9, 4.8, 5.2, 4.0). \quad (6.7)$$

步骤 1：参数估计

$$\hat{\mu} = \bar{x} = 4.70, \quad (6.8)$$

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2 = 0.542. \quad (6.9)$$

步骤 2：参数 Bootstrap ($B = 2000$)

每次从 $\mathcal{N}(4.70, 0.542)$ 中生成 $n = 10$ 个新观测，计算样本方差 $\hat{\sigma}^{2*}$ 。

步骤 3：结果

Bootstrap 方差分布：

- 均值 $\bar{\sigma}^{2*} = 0.488$ （略低于 $\hat{\sigma}^2 = 0.542$ ，体现方差的负偏）
- 标准误： $\widehat{SE}_{\text{boot}} = 0.225$

95% 百分位数置信区间：

$$\sigma^2 \in [0.183, 1.085]. \quad (6.10)$$

对比理论解：正态总体下 $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(9)$ ，精确的 95% CI 为：

$$\sigma^2 \in \left[\frac{9 \times 0.542}{19.02}, \frac{9 \times 0.542}{2.70} \right] = [0.256, 1.807]. \quad (6.11)$$

参数 Bootstrap 的区间更窄，这是因为 Bootstrap 额外利用了 $\hat{\sigma}^2$ 点估计的信息（而精确 χ^2 区间只用到 S^2 的抽样分布，未假设 σ^2 的可能范围）。一般而言，在小样本下精确理论解更可靠；参数 Bootstrap 在大样本下与之渐近等价。

6.2.3 何时用哪种 Bootstrap?

- **非参数 Bootstrap：**当你不确定总体分布形式，或统计量很复杂（如中位数、分位数、相关系数、AUC）时——这是最通用、最安全的选择。
- **参数 Bootstrap：**当你有充分理由相信数据来自某个已知分布族（如寿命数据常用 Weibull、失效次数用 Poisson），且希望利用这一结构获得更精确的推断时。

Bootstrap 的局限性：

- 当样本量极小（ $n < 8$ ）时，Bootstrap 分布只能取有限个值，效果差；
- 对极值统计量（如最大值）Bootstrap 不一致；
- 对重尾分布，Bootstrap 可能低估尾部变异性；
- 计算量大（但现代硬件下 $B = 2000$ 通常几秒内完成）。

6.2.4 Cluster Bootstrap（聚类自助法）

前述 Bootstrap 方法假设所有观测相互独立。但在实际数据中，经常存在组内相关：

- NIPT 数据：同一孕妇在不同孕周测了多次——这几次检测天然相似（第 9 章混合效应）
- 教育数据：同一学校的学生成绩相关
- 面板数据：同一个体在不同时间点的重复测量

如果无视组结构做普通 Bootstrap——每次以单次检测为单位有放回抽样——同一个孕妇的 3 次检测可能被拆散到不同的 Bootstrap 样本中，组内相关性被破坏，导致标准误被严重低估。

Cluster Bootstrap 的做法：

以“组”（cluster）为单位重抽样，而非以单个观测为单位。

- (1) 将数据按组 ID 分组（如按孕妇 ID）；
- (2) 从所有组中有放回地抽取 K 个组（ K 为原始组数）；
- (3) 被抽中的组的所有观测全部进入 Bootstrap 样本；
- (4) 对 Bootstrap 样本计算统计量，重复 B 次。

与普通 Bootstrap 的对比：

	普通 Bootstrap	Cluster Bootstrap
抽样单位	单个观测	整组（cluster）
保持的内部结构	无	组内相关性
适用数据	独立观测	重复测量 / 嵌套数据
标准误	若忽略组结构则低估	正确反映组间变异

NIPT 问题 2 中的应用：

问题要求“分析检测误差对最佳 NIPT 时点的影响”。由于同一孕妇多次检测，必须用 Cluster Bootstrap（按孕妇 ID 分组重抽样）：

- (1) 保持 BMI 分组和分位数回归模型不变

- (2) 按孕妇 ID 做 Cluster Bootstrap ($B = 1000$)
- (3) 每次重抽样后重新计算每组的最优时点 $\widehat{GA}_{gr}$
- (4) 从 1000 次结果中提取 2.5% 和 97.5% 分位数作为 95% CI

结论：检测误差会使最佳时点推后，BMI 越高推后越明显——这与“高 BMI 组 Y 浓度达标慢、不确定性大”的生物学直觉一致。

本章小结

Bootstrap 是现代统计计算中最强大的工具之一：

1. **核心思想**：用重抽样模拟抽样分布——从经验分布（非参数）或拟合参数模型（参数）中反复抽样；
2. **非参数 Bootstrap**：有放回重抽样，每个样本约 63% 的原始观测被抽中，36.8% 为 OOB 样本；
3. **参数 Bootstrap**：适用于已知分布族的情形，信息利用更充分但依赖模型正确性；
4. **输出**：标准误估计、百分位数置信区间（自动处理偏态）、Bias 估计等；
5. **在 ML 中的角色**：Bagging 的根基、随机森林的 OOB 误差、模型稳定性和变量重要性评估。

关键在于：**Bootstrap 将“分析推导抽样分布”的难题转化为“计算机模拟”的工程问题**，使得我们几乎可以为任何统计量获得标准误和置信区间。

第七章 统计实践：从建模到报告

前面各章分别介绍了假设检验、方差分析、回归分析和 Bootstrap 等统计方法。本章将把这些方法串联起来，形成从数据探索到结果报告的完整实践流程，并介绍学术写作中的 APA 报告规范。

7.1 R^2 与 p 值的区别与联系

R^2 和 p 值是回归输出中最常见的两个数字，但初学者常混淆它们的含义。二者来自完全不同的统计框架，回答完全不同的问题。

7.1.1 框架对比

	R^2 （决定系数）	p 值
所属章节	第 9 章：方差分析与回归分析	第 4 章：假设检验
所属框架	方差分析（ANOVA）	假设检验
回答的问题	模型解释了多少变异？	效应是真实存在的还是巧合？
数学定义	$R^2 = \frac{SS_R}{SS_T} = 1 - \frac{SS_E}{SS_T}$	$p = P(T \geq t_{\text{obs}} \mid H_0)$
关注的是	效应大小（effect size）	效应是否为零（显著性）
取值范围	$[0, 1]$ （调整 R^2 可为负）	$(0, 1)$
受样本量影响	不敏感—— n 增大, R^2 趋于稳定	极敏感—— n 越大, 越容易显著

7.1.2 为什么 R^2 很低但 p 值可以显著？

这是初学者最困惑的地方，答案藏在样本量里。

考虑回归模型 $Y = \beta_0 + \beta_1 X + \varepsilon$ ，检验 $H_0: \beta_1 = 0$ 。


检验统计量 $T = \frac{\hat{\beta}_1}{SE(\hat{\beta}_1)}$ ， $SE(\hat{\beta}_1) = \frac{s}{\sqrt{S_{xx}}}$ 随着 n 增大而减小。而 $s^2 = \frac{SS_E}{n-2}$ 度量的是不能被 X 解释的那部分变异——即使 R^2 很低， SS_E 也不会随着 n 增大而消失，只是我们对 $\hat{\beta}_1$ 的估计越来越精确（ SE 越来越小）。

R^2 与 F 检验的精确关系（已在第 9 章推导）：

$$F = \frac{SS_R/1}{SS_E/(n-2)} = \frac{R^2/1}{(1-R^2)/(n-2)}. \quad (7.1)$$

- 即使 $R^2 = 0.03$ ，只要 n 足够大， $F = \frac{0.03}{(0.97)/(n-2)}$ 仍可超越临界值；
- 例如 $n = 10000$ ： $F = \frac{0.03}{0.97/9998} \approx 309$ ， $p \ll 0.001$ ；
- 结论： p 值显著只说明效应不为零，不说明效应很大。

7.1.3 用“射击靶子”理解二者



7.1.4 四种组合判断表

R^2	p 值	判断	说明
高	显著	理想情况	解释力强，效应确凿
高	不显著	罕见，需检查	可能多重共线性（ F 显著但各 t 不显著，见第 9 章 VIF）
低	显著	最常见于大样本	效应存在但效应量小（如 NIPT 数据）
低	不显著	模型无效	变量可能没有解释力

7.1.5 常见误区纠正

- (1) “ $p < 0.05$ 说明效应很大” → 错。 p 值只拒绝“效应为零”。大样本下微小效应也能 $p < 0.001$ 。
- (2) “ R^2 低说明模型没用” → 错。生物/社会科学中 $R^2 = 0.05 \sim 0.30$ 是常态。关键是 p 值。
- (3) “ $p > 0.05$ 说明 H_0 为真” → 错。只能说“证据不足”（第 4 章第二类错误 β ）。
- (4) “ p 值是 H_0 为真的概率” → 错。 p 值是 $P(\text{数据} \mid H_0)$ ，不是 $P(H_0 \mid \text{数据})$ 。

7.2 因素分析的标准流程

以下结合 NIPT 数据（Y 染色体浓度 ~ 孕周 + BMI）为例，给出因素建模的五步标准流程。每一步都在 R^2 （方差分解，第 9 章）和 p 值（假设检验，第 4 章）之间交替使用。

7.2.1 第 1 步：相关性扫描——看方向和显著性

- 计算 Pearson / Spearman 相关系数矩阵（第 1 章），同时报告 r 和 p 值
- 画散点图矩阵（pairplot），观察非线性关系
- 目的：初步判断哪些变量有关联（ p 值）、关联多强（ r 或 r^2 ）

7.2.2 第 2 步：建立回归模型——量化效应大小

- 从简单模型开始： $Y \sim X_1$ ，逐步加入变量（第 9 章多元回归）
- 对每个系数报告： $\hat{\beta}_j$ 、 $SE(\hat{\beta}_j)$ 、 t 值、 p 值
- 报告整体 R^2 、调整 R^2_{adj} 、 F 统计量及其 p 值

- 目的：量化效应大小 ($\hat{\beta}$)，判断显著性 (p)，评估解释力 (R^2)

7.2.3 第 3 步：模型诊断——验证假设

- 正态性：残差的 Q-Q 图（第 4 章），或 Shapiro-Wilk 检验
- 方差齐性：残差 vs 拟合值散点图（不应有漏斗形）
- 多重共线性：计算 VIF（第 9 章）， $VIF > 10$ 表明严重共线性
- 异常值：Cook's distance 识别高影响力点
- 假设不满足时：Box-Cox 变换、加权最小二乘、或改用第 4 章的秩和检验等非参数方法

7.2.4 第 4 步：模型改进——从简单到复杂

当简单线性模型表现不佳 (R^2 低但 p 值显著，或残差有结构)，考虑：


- (1) 加入交互项： $Y \sim X_1 + X_2 + X_1:X_2$ ，检验交互是否显著
- (2) 加入非线性项： $Y \sim X + X^2$ ，或用 GAM（广义可加模型）
- (3) 分段/分层建模：按关键变量分组，每组独立拟合，比较各组 R^2 和系数
- (4) 引入随机效应（混合效应模型）：当数据有重复测量时（如同一孕妇多次检测），用 $Y_{ij} = \alpha + u_i + \beta X_{ij} + \varepsilon_{ij}$ 区分个体差异（随机效应 u_i ）和系统性效应（固定效应 β ）

7.2.5 第 5 步：报告与解释——讲好故事

不能只报数字，要给出实际含义。结合第 4 章的 p 值检验法和本章的 APA 规范：

- 效应报告示例：
“孕周每增加 1 周，Y 染色体浓度平均增加 0.0035 个单位 ($SE = 0.0004$, $t(9998) = 8.75$, $p < 0.001$)”
- R^2 低的解释示例：
“BMI 和孕周仅解释 Y 浓度变异的 3% ($R^2 = 0.030$)，但效应方向明确且统计显著 ($F(2, 9997) = 154.6$, $p < 0.001$)。剩余变异主要来自个体间差异（条件 $R^2 = 83\%$ ），这正是需要按 BMI 分组制定个性化检测时点的依据。”

7.2.6 完整流程图



7.3 APA 学术报告规范

APA 风格 (American Psychological Association) 是心理学、教育学、社会科学及生物医学领域最广泛使用的学术写作规范。建模竞赛论文虽非正式期刊论文，但遵循 APA 报告统计结果能显著提升论文的专业性和可信度。

7.3.1 核心原则

不能只报 p 值，必须同时报告效应大小。 p 值只回答“效应是否存在”，效应量 ($\hat{\beta}$ 、Cohen's d 、 R^2 等) 回答“效应有多大”。两者缺一不可——这是 APA 规范最核心的要求。

7.3.2 常见统计量的 APA 报告格式

检验类型	APA 格式	示例
t 检验（第 4 章）	$t(df) = x.xx, p = .xxx$	$t(24) = 2.14, p = .043$
F 检验（第 9 章 ANOVA）	$F(df_1, df_2) = x.xx, p = .xxx$	$F(2, 97) = 5.43, p = .006$
χ^2 检验（第 4 章）	$\chi^2(df, N = n) = x.xx, p = .xxx$	$\chi^2(1, N = 200) = 12.5, p < .001$
相关系数（第 1 章）	$r(df) = .xx, p = .xxx$	$r(98) = .34, p < .001$
回归系数（第 9 章）	$b = x.xx, SE = .xxx, t(df) = x.xx, p = .xxx$	$b = -0.008, SE = 0.001, t(98) = -7.0, p < .001$
Bootstrap CI（第 10 章）	95% CI [L, U]	95% CI [16.50, 34.25]

7.3.3 p 值的写法

- 小数前不加 0： $p = .032$ （而非 $p = 0.032$ ），因为 p 值永远不超过 1
- 极小时不写具体值： $p < .001$ （而非 $p = .0003$ ）
- 报告精确值优先于笼统表述： $p = .032$ 好于 $p < .05$

7.3.4 完整报告示例

以下是一个符合 APA 规范的回归分析报告，综合运用了第 1 章（相关系数）、第 4 章（ t 检验与 p 值）、第 9 章（回归与 F 检验）的方法：

结果

首先进行了相关性分析（Pearson 相关系数，第 1 章）。孕周与 Y 染色体浓度呈显著正相关（ $r(9998) = .12, p < .001$ ），BMI 与 Y 染色体浓度呈显著负相关（ $r(9998) = -.08, p < .001$ ）。

随后建立了多元线性回归模型，以 Y 染色体浓度为因变量，孕周和 BMI 为自变量。模型整体显著， $F(2, 9997) = 154.6, p < .001$ ，解释了 Y 浓度变异的 3.0%（ $R^2 = .030$ ，调整 $R^2 = .030$ ）。

BMI 对 Y 浓度具有显著的负效应 ($\hat{\beta} = -0.0084$, $SE = 0.0012$, $t(9997) = -7.00$, $p < .001$), 孕周对 Y 浓度具有显著的正效应 ($\hat{\beta} = 0.0035$, $SE = 0.0004$, $t(9997) = 8.75$, $p < .001$)。

残差的 Q-Q 图表明正态性假设基本满足, VIF 均为 1.02, 表明不存在多重共线性问题。

讨论

虽然 $R^2 = .030$ 看似较低, 但在生物医学数据中属于常见水平。所有系数的 p 值均远小于 .001, 表明效应方向明确且统计可靠。剩余未解释的变异主要来自个体间差异, 这支持了按 BMI 分组制定个性化检测时点的必要性。

7.3.5 建模竞赛论文的 APA 使用要点

- (1) 摘要中必须报告关键数值: 不能只写“模型显著”, 要写“ $F(2, 97) = 5.43$, $p = .006$, $R^2 = .101$ ”
- (2) 每个系数都报告 $\hat{\beta}$ 、 SE 、 t 、 p : 最好用表格呈现
- (3) 效应量和显著性缺一不可: “ $p < .001$ 但不报告 $\hat{\beta}$ ” 是常见扣分点
- (4) 诊断结果要写出: “残差正态 (Shapiro-Wilk $p = .32$), VIF 均 < 2 ” 一句话就够了
- (5) p 值小时写 APA 格式: $p = .032$ (而非 $p = 0.032$)、 $p < .001$ (而非 $p = 0.0003$)

7.4 方法选择速查表

将前面各章的方法按其适用场景整理为速查表, 方便建模时快速定位。

你想做什么	数据类型	参数方法	非参数替代	对应章节
比较两组均值	连续, 正态	两样本 t 检验	Wilcoxon 秩和	第 4 章
比较两组均值	配对数据	配对 t 检验	Wilcoxon 符号秩	第 4 章
比较三组以上	连续, 正态	单因素 ANOVA (F)	Kruskal-Wallis	第 9 章
两个因素的比较	连续, 正态	双因素 ANOVA	—	第 9 章
检验方差齐性	连续	F 检验 / Bartlett	Levene	第 4/9 章
一个 $X \rightarrow Y$	连续	一元线性回归	—	第 9 章
多个 $X \rightarrow Y$	连续	多元线性回归	—	第 9 章
分类 Y	二分类	逻辑回归	—	机器学习部分
分布拟合	频数	Pearson χ^2	—	第 4 章
正态性检验	连续	Shapiro-Wilk	Q-Q 图	第 4 章
标准误/CI (任意统计量)	任意	参数 Bootstrap	非参数 Bootstrap	第 10 章

本章小结

本章作为统计方法部分的收尾，完成了三件事：

- 1. **区分 R^2 与 p 值：** R^2 来自第 9 章的方差分解，度量效应大小； p 值来自第 4 章的假设检验，度量统计显著性。二者互补，必须同时报告。
- 2. **标准化因素分析流程：**相关性扫描 → 回归建模 → 模型诊断 → 模型改进 → 报告解释，五步将第 2、4、9、10 章的方法串联为可操作的工作流。
- 3. **规范化学术报告：**介绍了 APA 风格的核心规则——报告效应量 + 显著性、 p 值的正确写法、各检验的规范格式，并给出了完整的报告示例。

掌握这些内容后，面对建模竞赛的数据分析题（如 CUMCM C 题），你就有了从数据探索到论文写作的完整方法论工具箱。

第八章 信息论基础

8.1 基本概念

定义 8.1 (信息量 / 自信息).

$$I(x) = -\log p(x). \quad (8.1)$$

定义 8.2 (熵). 随机变量 X 的熵度量其不确定性:

$$H(X) = -\sum_x p(x) \log p(x). \quad (8.2)$$

定义 8.3 (KL 散度). 分布 P 与 Q 之间的 KL 散度:

$$D_{\text{KL}}(P\|Q) = \sum_x p(x) \log \frac{p(x)}{q(x)}. \quad (8.3)$$

非负、非对称, $D_{\text{KL}}(P\|Q) = 0 \iff P = Q$.

定义 8.4 (交叉熵).

$$H(P, Q) = -\sum_x p(x) \log q(x) = H(P) + D_{\text{KL}}(P\|Q). \quad (8.4)$$

定义 8.5 (互信息).

$$I(X; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}. \quad (8.5)$$

第二部分

机器学习

第九章 矩阵运算与张量记号

本章为进入机器学习核心内容做数学准备。假设读者已学过线性代数（向量空间、矩阵乘法、行列式、特征值），但未系统学过矩阵微积分。本章聚焦**推导中高频使用的矩阵操作**，并引入张量分析的指标记号（Einstein 求和约定），便于在后续章节中简洁地表达梯度和优化问题。

9.1 迹运算

迹运算是矩阵求导的核心工具——几乎所有标量对矩阵的求导都可以通过迹来统一处理。

定义 9.1 (迹). $n \times n$ 方阵 A 的迹是其主对角线元素之和：

$$\text{tr}(A) = \sum_{i=1}^n a_{ii}. \quad (9.1)$$

命题 9.1 (迹的基本性质). (1) **线性性**: $\text{tr}(\alpha A + \beta B) = \alpha \text{tr}(A) + \beta \text{tr}(B)$;

(2) **转置不变**: $\text{tr}(A^\top) = \text{tr}(A)$;

(3) **循环性 (核心)**: $\text{tr}(AB) = \text{tr}(BA)$, 推广为

$$\text{tr}(ABC) = \text{tr}(BCA) = \text{tr}(CAB); \quad (9.2)$$

(4) **标量即迹**: 若 $x^\top Ax$ 是标量, 则 $x^\top Ax = \text{tr}(x^\top Ax) = \text{tr}(Axx^\top)$ 。

迹技巧的本质: 把标量表达式塞进 $\text{tr}(\cdot)$, 利用循环性质把要求导的变量移到最右侧, 然后利用 $\frac{\partial}{\partial X} \text{tr}(AX) = A^\top$ 一步得出结果。这是推导 OLS、Ridge、MLE 中矩阵梯度的标准方法。

9.2 正定与半正定矩阵

定义 9.2 (正定与半正定). 设 A 为 $n \times n$ 实对称矩阵:

- A **正定** ($A \succ 0$): 对所有 $x \neq 0$, $x^\top Ax > 0$;

- A 半正定 ($A \succeq 0$): 对所有 x , $x^\top A x \geq 0$ 。

命题 9.2 (等价条件). (1) $A \succ 0 \iff$ 所有特征值 $\lambda_i > 0$;

(2) $A \succeq 0 \iff$ 所有特征值 $\lambda_i \geq 0$;

(3) $A \succeq 0 \iff$ 存在 B 使得 $A = B^\top B$ (如 Cholesky 分解 $A = LL^\top$)。

在 ML 中的意义:

- 协方差矩阵 Σ 总是半正定——这是它能做 Cholesky 分解的原因;
- 设计矩阵乘积 $X^\top X$ 是半正定的。当 $p > N$ 时, $X^\top X$ 奇异 (不可逆)——Ridge 回归通过加 λI 使其变为正定, 从而可逆;
- Hessian 矩阵正定 $\implies$ 目标函数是凸函数 $\implies$ 驻点即全局最优。

9.3 矩阵求导

矩阵求导是梯度下降、正规方程推导、MLE 的必要工具。本节以分子布局 (numerator layout) 为约定, 即标量对列向量求导得到行向量。

9.3.1 标量对向量的导数

表达式 $f(x)$	梯度 $\nabla_x f$	出现场景
$a^\top x$	$a^\top$	线性函数求导
$x^\top A x$	$x^\top (A + A^\top)$	二次型的一般形式
$x^\top A x$ (A 对称)	$2x^\top A$	RSS、马氏距离
$\ Ax - b\ ^2$	$2(Ax - b)^\top A$	最小二乘损失
$\ x\ ^2 = x^\top x$	$2x^\top$	L_2 正则化

例 9.1 (OLS 正规方程的推导). 最小二乘的损失函数 $J(\beta) = \|X\beta - y\|^2$:

$$\begin{aligned}
 J(\beta) &= (X\beta - y)^\top (X\beta - y) \\
 \nabla_\beta J &= 2(X\beta - y)^\top X = 0 \\
 \implies X^\top X\beta &= X^\top y \quad (\text{正规方程}).
 \end{aligned} \tag{9.3}$$

9.3.2 标量对矩阵的导数

表达式 $f(X)$	导数 $\frac{\partial f}{\partial X}$	出现场景
$\log \det X$	$X^{-\top}$ (或 X^{-1})	多元正态 MLE 中 Σ 估计
$\text{tr}(AX)$	$A^\top$	迹求导基础公式
$a^\top X b$	$ab^\top$	双线性形式
$\text{tr}(X^\top A X)$	$(A + A^\top)X$	加权最小二乘

9.3.3 向量对向量的导数（雅可比矩阵）

$$\frac{\partial y}{\partial x} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_m}{\partial x_1} & \cdots & \frac{\partial y_m}{\partial x_n} \end{bmatrix}, \quad \frac{\partial Ax}{\partial x} = A. \quad (9.4)$$

9.4 张量分析的指标记号

矩阵语言在处理二阶及以上的求导时会变得非常臃肿。张量分析的指标记号（index notation）提供了一套并行使用的简洁语言，特别适用于表达元素的偏导数关系和 Hessian 结构。

9.4.1 Einstein 求和约定

核心规则：在同一项中，若一个指标出现两次（一上一下，或两下标），则默认对该指标的所有可能取值求和。求和号 $\sum$ 被省略。

矩阵记号	Einstein 记号	含义
$y = Ax$	$y_i = A_{ij}x_j$	$y_i = \sum_j A_{ij}x_j$
$c = a^\top b$	$c = a_i b_i$	$\sum_i a_i b_i$ (内积)
$C = AB$	$C_{ik} = A_{ij}B_{jk}$	$C_{ik} = \sum_j A_{ij}B_{jk}$
$\text{tr}(A)$	A_{ii}	$\sum_i A_{ii}$
$x^\top Ax$	$x_i A_{ij} x_j$	$\sum_{i,j} x_i A_{ij} x_j$

关键约定：

- **哑指标 (dummy index)**：出现两次、被求和的指标（如 j 在 $A_{ij}B_{jk}$ 中），字母可任意更换—— $A_{ij}B_{jk} = A_{ik}B_{kl}$ 并不成立，但 $A_{ij}B_{jk} = A_{im}B_{mk}$ ；
- **自由指标 (free index)**：只出现一次、不被求和的指标（如 i 和 k ）——这些指标在等式两边必须一致出现。

9.4.2 Kronecker δ 符号

$$\delta_{ij} = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases} \quad (9.5)$$

在指标记号中， δ_{ij} 就是单位矩阵 I 的 (i, j) 元素。其核心功能是指标的替换：

$$\delta_{ij}a_j = a_i, \quad \delta_{ij}A_{jk} = A_{ik}. \quad (9.6)$$

例 9.2 (迹的循环性在指标记号下是显然的).

$$\text{tr}(AB) = (AB)_{ii} = A_{ij}B_{ji} = B_{ji}A_{ij} = (BA)_{jj} = \text{tr}(BA). \quad (9.7)$$

不需要任何技巧——指标记号的交换直接揭示了循环性。

9.4.3 偏导数的指标写法

将向量偏导写成指标形式，能大幅简化 Hessian 的分析：

对象	矩阵写法	指标写法
标量对向量的梯度	$\nabla_x f$	$\frac{\partial f}{\partial x_i}$
向量对向量的雅可比	$\frac{\partial y}{\partial x}$	$\frac{\partial y_i}{\partial x_j}$
标量的 Hessian	$\nabla_x^2 f$	$\frac{\partial^2 f}{\partial x_i \partial x_j}$

例 9.3 (二次型的梯度与 Hessian). 设 $f(x) = \frac{1}{2}x^\top Ax$ (A 对称):

$$\text{指标形式: } f = \frac{1}{2}x_i A_{ij} x_j, \quad (9.8)$$

$$\frac{\partial f}{\partial x_k} = \frac{1}{2}(\delta_{ik} A_{ij} x_j + x_i A_{ij} \delta_{jk}) = \frac{1}{2}(A_{kj} x_j + A_{ik} x_i) = A_{ki} x_i \quad (\text{即 } Ax). \quad (9.9)$$

$$\frac{\partial^2 f}{\partial x_k \partial x_\ell} = A_{k\ell} \quad (\text{Hessian 就是 } A). \quad (9.10)$$

9.4.4 矩阵对标量的导数

当损失函数包含参数矩阵时, 需要矩阵对标量求导:

$$\frac{\partial L}{\partial W_{ij}} \quad \text{—— 损失 } L \text{ 对权重矩阵 } W \text{ 每个元素的偏导。} \quad (9.11)$$

这正是反向传播中的 $\nabla_W L$ ——梯度矩阵与 W 同形状。

9.4.5 何时用矩阵记号, 何时用指标记号

场景	推荐记号	原因
OLS 正规方程推导	矩阵	整体运算紧凑, 一步到位
迹技巧 & 矩阵求导	矩阵	查表法最直接
二次型/线性型梯度	矩阵 + 指标	矩阵给结果, 指标验证细节
Hessian 的稀疏结构分析	指标	元素级偏导一目了然
反向传播推导	指标	逐元素的链式法则无法用矩阵简洁表达
$X^\top X$ 不可逆时的分析	矩阵 (谱分解)	SVD 视角揭示本质

实用策略: 用矩阵记号写算法框架, 用指标记号填写推导细节——两者互补而非替代。

9.5 谱分解与奇异值分解 (SVD)

9.5.1 对称矩阵的谱分解

若 A 是 $n \times n$ 实对称矩阵, 则存在正交矩阵 Q ($Q^\top Q = I$) 和对角矩阵 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$, 使得:

$$A = Q\Lambda Q^\top = \sum_{i=1}^n \lambda_i q_i q_i^\top. \quad (9.12)$$

指标形式: $A_{ij} = \sum_k \lambda_k Q_{ik} Q_{jk}$ 。

在 ML 中的意义:

- 若 A 是协方差矩阵, λ_i 是第 i 主成分的方差, q_i 是方向;
- $A^{-1} = Q\Lambda^{-1}Q^\top = \sum \lambda_i^{-1} q_i q_i^\top$ ——特征值越小, 求逆时贡献越大, 这也是 $X^\top X$ 接近奇异时 OLS 方差爆炸的根源。

9.5.2 奇异值分解 (SVD)

对任意 $N \times p$ 矩阵 X , 存在正交矩阵 $U_{N \times N}$ 、 $V_{p \times p}$ 和对角矩阵 $D_{N \times p}$ (对角元 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$), 使得:

$$X = UDV^\top. \quad (9.13)$$

- σ_i : X 的奇异值 (非负);
- U 的列: 左奇异向量 = $XX^\top$ 的特征向量;
- V 的列: 右奇异向量 = $X^\top X$ 的特征向量;
- 关系: $X^\top X = VD^\top DV^\top$, $XX^\top = UDD^\top U^\top$ 。

在 ML 中的关键应用:

- (1) **PCA**: 对去均值后的 X 做 SVD, V 的列就是主成分方向;
- (2) **伪逆 (Moore-Penrose)**: $X^+ = VD^+U^\top$, 其中 D^+ 将非零奇异值取倒数。当 $p > N$ 时 OLS 无唯一解, 伪逆给出最小范数解;
- (3) **Ridge 回归的谱形式**:

$$\hat{\beta}_{\text{ridge}} = (X^\top X + \lambda I)^{-1} X^\top y = V \frac{D}{D^2 + \lambda I} U^\top y = \sum_{j=1}^r \frac{\sigma_j}{\sigma_j^2 + \lambda} (u_j^\top y) v_j. \quad (9.14)$$

λ 将所有方向上的 σ_j^2 上移——小奇异值方向不再爆炸。

9.6 矩阵范数

定义 9.3 (常用矩阵范数). • **Frobenius 范数**: $\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2} = \sqrt{\text{tr}(A^\top A)} = \sqrt{\sum \sigma_i^2}$;

• **谱范数** (L_2 范数): $\|A\|_2 = \sigma_{\max}(A)$, 即最大的奇异值;

• **核范数**: $\|A\|_* = \sum \sigma_i(A)$ (奇异值之和)。

在 ML 中的角色:

- L_2 权重衰减 $\lambda\|w\|^2$ 本质是惩罚向量的 Frobenius 范数平方;
- 谱范数控制 Lipschitz 常数——在 GAN 和对抗训练中用于稳定训练;
- 核范数是秩函数的凸松弛: $\min \text{rank}(A)$ 是 NP-hard, $\min \|A\|_*$ 可凸优化求解——用于矩阵补全 (推荐系统)、低秩表示。

9.7 关键恒等式

9.7.1 Woodbury 矩阵求逆公式

$$(A + UCV)^{-1} = A^{-1} - A^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1}. \quad (9.15)$$

用途: 将一个大矩阵的求逆转化为一个小矩阵的求逆。在留一法交叉验证中, 每次移除一个观测后不需重算整个 $(X^\top X)^{-1}$, 而是用 Woodbury 公式做 $O(p^2)$ 的更新。

9.7.2 矩阵求逆引理 (Woodbury 的特例)

$$(I + AB)^{-1}A = A(I + BA)^{-1}. \quad (9.16)$$

用途: Ridge 回归的等价变形。当 $p \gg N$ 时:

$$\hat{\beta} = (X^\top X + \lambda I_p)^{-1}X^\top y = X^\top (XX^\top + \lambda I_N)^{-1}y. \quad (9.17)$$

左边求逆的是 $p \times p$ 矩阵, 右边是 $N \times N$ ——当 $p \gg N$ 时右边计算量小得多。

9.7.3 期望的二次型

设 $\mathbb{E}[x] = \mu$, $\text{Var}(x) = \Sigma$:

$$\mathbb{E}[x^\top Ax] = \text{tr}(A\Sigma) + \mu^\top A\mu. \quad (9.18)$$

推导:

$$\begin{aligned} \mathbb{E}[x^\top Ax] &= \mathbb{E}[\text{tr}(x^\top Ax)] = \mathbb{E}[\text{tr}(Axx^\top)] = \text{tr}(A\mathbb{E}[xx^\top]) \\ &= \text{tr}(A(\Sigma + \mu\mu^\top)) = \text{tr}(A\Sigma) + \mu^\top A\mu. \end{aligned} \quad (9.19)$$

用途: 推导 RSS 的期望 ($\mathbb{E}[\|y - X\hat{\beta}\|^2]$), 计算预测误差的偏差-方差分解的矩阵形式。

第十章 统计学习导论

统计学习的核心问题是：从数据中学习一个函数，使得它能对未见过的输入做出准确的预测。

10.1 监督学习的数学框架

10.1.1 基本设定

定义 10.1 (监督学习的构成要素). 监督学习由以下要素构成：

- (i) 输入空间 $\mathcal{X} \subseteq \mathbb{R}^p$: p 维特征（自变量）的取值空间；
- (ii) 输出空间 $\mathcal{Y}$:
 - 回归问题: $\mathcal{Y} = \mathbb{R}$ （定量输出）；
 - 分类问题: $\mathcal{Y} = \{1, 2, \dots, K\}$ （定性输出, K 类）；
- (iii) 训练数据 $\mathcal{D} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$, 其中 $(\mathbf{x}_i, y_i) \stackrel{\text{i.i.d.}}{\sim} P(X, Y)$;
- (iv) 预测函数（模型）: $f: \mathcal{X} \rightarrow \mathcal{Y}$;
- (v) 损失函数 $L: \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_{\geq 0}$, 衡量预测 $f(\mathbf{x})$ 与真实 y 之间的代价。

10.1.2 损失函数

定义 10.2 (常见损失函数). • 平方损失（回归）:

$$L(y, f(\mathbf{x})) = (y - f(\mathbf{x}))^2. \quad (10.1)$$

- 绝对损失（回归）:

$$L(y, f(\mathbf{x})) = |y - f(\mathbf{x})|. \quad (10.2)$$

- 0-1 损失（分类）:

$$L(y, f(\mathbf{x})) = \mathbb{I}\{y \neq f(\mathbf{x})\}. \quad (10.3)$$

- 交叉熵损失 / 负对数似然（分类）：

$$L(y, \hat{\mathbf{p}}) = - \sum_{k=1}^K \mathbb{I}\{y = k\} \log \hat{p}_k, \quad (10.4)$$

其中 $\hat{\mathbf{p}} = (\hat{p}_1, \dots, \hat{p}_K)$ 为预测的类别概率向量。

- Hinge 损失（SVM）：

$$L(y, f(\mathbf{x})) = \max(0, 1 - yf(\mathbf{x})), \quad y \in \{-1, +1\}. \quad (10.5)$$

10.1.3 期望风险与经验风险

定义 10.3 (期望风险 (Expected Risk)). 给定损失函数 L , 预测函数 f 的期望风险（泛化误差）为：

$$R(f) = \mathbb{E}_{(X,Y) \sim P} [L(Y, f(X))] = \int_{\mathcal{X} \times \mathcal{Y}} L(y, f(\mathbf{x})) dP(\mathbf{x}, y). \quad (10.6)$$

学习的目标是找到 f^* 使得 $R(f)$ 最小化：

$$f^* = \arg \min_{f \in \mathcal{F}} R(f), \quad (10.7)$$

其中 $\mathcal{F}$ 为假设空间（模型族）。

由于真实分布 $P(X, Y)$ 未知，无法直接计算 $R(f)$ 。在实践中，我们最小化经验风险：

定义 10.4 (经验风险 (Empirical Risk)).

$$\hat{R}(f) = \frac{1}{N} \sum_{i=1}^N L(y_i, f(\mathbf{x}_i)). \quad (10.8)$$

定义 10.5 (经验风险最小化 (ERM)).

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \frac{1}{N} \sum_{i=1}^N L(y_i, f(\mathbf{x}_i)). \quad (10.9)$$

核心挑战： ERM 得到的 $\hat{f}$ 在训练数据上表现好，但我们需要它在未见数据上也表现好。这引出了统计学习理论的核心概念——泛化误差界与偏差-方差权衡。

10.1.4 EPE 与 ERM：理想与现实的桥梁

前两小节的内容可以总结为一个简洁的逻辑链条：

$$\underbrace{\min_f \mathbb{E}[L(Y, f(X))]}_{\text{EPE 最小化：理想目标，不可计算}} \xrightarrow{\text{大数定律：用样本均值替代期望}} \underbrace{\min_f \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i))}_{\text{ERM：实际做法，可计算}}$$

EPE 是真正的目标

无论回归还是分类，EPE 统一了所有监督学习问题的优化目标：

$$\text{EPE}(f) = \mathbb{E}_{(X,Y) \sim P}[L(Y, f(X))].$$

只取决于损失函数 L ，不挑问题类型：

- 平方损失 $\rightarrow$ 回归 $\rightarrow$ 最优解 $f^* = \mathbb{E}[Y | X]$;
- 0-1 损失 $\rightarrow$ 分类 $\rightarrow$ 最优解 $f^* = \arg \max_k \Pr(G = k | X)$;
- 一般损失矩阵 $\rightarrow$ 非对称代价分类 $\rightarrow$ 最优解 $\arg \min_g \sum_k L(G_k, g) \Pr(G_k | X)$ 。

ERM 是唯一能做的

EPE 的期望 $\mathbb{E}[\cdot]$ 是对真实联合分布 $P(X, Y)$ 取的，而 P 未知。我们手中只有从 P 中独立抽取的 N 个样本 $\{(x_i, y_i)\}_{i=1}^N$ 。

大数定律保证：独立同分布样本的均值收敛到期望：

$$\frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i)) \xrightarrow{N \rightarrow \infty} \mathbb{E}[L(Y, f(X))].$$

因此， $\frac{1}{N} \sum L(y_i, f(x_i))$ 是 $\mathbb{E}[L(Y, f(X))]$ 最自然、最直接的**样本替代品**——不需要任何分布假设、不需要参数化，仅靠大数定律就完成了从 EPE 到 ERM 的转换。这正是 ERM 框架如此通用的根本原因。

EPE 与 ERM 的对比

	EPE（期望预测误差）	ERM（经验风险最小化）
公式	$\mathbb{E}_{(X,Y) \sim P}[L(Y, f(X))]$	$\min_f \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i))$
能否计算	需要知道 $P(X, Y)$	只需要训练样本
角色	理想目标（你真正想最小化的）	实际手段（你唯一能做的）
关系	大数定律： $\frac{1}{N} \sum L(y_i, f(x_i)) \rightarrow \mathbb{E}[L(Y, f(X))]$	

核心张力：泛化差距

ERM 最小化得到的是 $\hat{f}$ ，EPE 最小的才是 f^* 。两者一般不相等：

- 训练误差（ERM 的值）可以压到任意低，甚至为零（如 k -NN 取 $k = 1$ ）；

- 测试误差 (EPE 的估计) 才是真正在乎的。

当 ERM 很低而 EPE 很高时 $\rightarrow$ 过拟合。这正是为什么后续章节需要正则化、交叉验证、模型选择——全是为了填平 ERM 和 EPE 之间的这道沟 (泛化差距)。

10.1.5 最优预测器：回归函数

下面用 ESL 的符号体系, 严格推导平方损失和 0-1 损失下的最优预测器。记 $X \in \mathbb{R}^p$ 为实值随机输入向量, $Y \in \mathbb{R}$ 为实值随机输出, 二者的联合分布为 $\Pr(X, Y)$ 。

平方损失下的推导 (回归)

定义 10.6 (期望预测误差 (Expected Prediction Error, EPE)). 在平方损失下, 函数 f 的期望预测误差为:

$$\text{EPE}(f) = \mathbb{E}[(Y - f(X))^2] = \int_{\mathbb{R}^p \times \mathbb{R}} [y - f(\mathbf{x})]^2 \Pr(d\mathbf{x}, dy). \quad (10.10)$$

这里 $\Pr(d\mathbf{x}, dy)$ 是 X 与 Y 的联合概率测度。

下面推导使 $\text{EPE}(f)$ 最小的 f 。

Step 1 — 条件期望展开. 对 X 取条件, 将联合期望分解为:

$$\begin{aligned} \text{EPE}(f) &= \mathbb{E}_X \mathbb{E}_{Y|X} \left([Y - f(X)]^2 \mid X \right) \\ &= \int_{\mathbb{R}^p} \left[\int_{\mathbb{R}} [y - f(\mathbf{x})]^2 \Pr(dy \mid \mathbf{x}) \right] \Pr(d\mathbf{x}). \end{aligned} \quad (10.11)$$

Step 2 — 逐点最小化. 由于 (10.11) 中被积函数非负, 最小化 $\text{EPE}(f)$ 等价于对每个固定的 $\mathbf{x}$, 选择 $f(\mathbf{x})$ 来最小化条件期望:

$$f(\mathbf{x}) = \arg \min_{c \in \mathbb{R}} \mathbb{E}_{Y|X} \left([Y - c]^2 \mid X = \mathbf{x} \right). \quad (10.12)$$

Step 3 — 求解 c^* . 记 $\mu(\mathbf{x}) = \mathbb{E}[Y \mid X = \mathbf{x}]$, 将平方展开:

$$\begin{aligned} \mathbb{E}_{Y|X} [(Y - c)^2 \mid X = \mathbf{x}] &= \mathbb{E}[(Y - \mu(\mathbf{x}) + \mu(\mathbf{x}) - c)^2 \mid X = \mathbf{x}] \\ &= \mathbb{E}[(Y - \mu(\mathbf{x}))^2 \mid X = \mathbf{x}] + \underbrace{2 \mathbb{E}[(Y - \mu(\mathbf{x}))(\mu(\mathbf{x}) - c) \mid X = \mathbf{x}]}_{=0} \\ &\quad + \mathbb{E}[(\mu(\mathbf{x}) - c)^2 \mid X = \mathbf{x}] \\ &= \underbrace{\text{Var}(Y \mid X = \mathbf{x})}_{\text{与 } c \text{ 无关}} + \underbrace{(\mu(\mathbf{x}) - c)^2}_{\geq 0}. \end{aligned} \quad (10.13)$$

交叉项为零的原因如下。在条件期望 $\mathbb{E}[\cdot \mid X = \mathbf{x}]$ 中, $\mu(\mathbf{x}) = \mathbb{E}[Y \mid X = \mathbf{x}]$ 和 c 都是常数 (因为已经条件在 $\mathbf{x}$ 上), 可以提到期望外:

$$\mathbb{E}[(Y - \mu(\mathbf{x}))(\mu(\mathbf{x}) - c) \mid X = \mathbf{x}] = (\mu(\mathbf{x}) - c) \cdot \mathbb{E}[Y - \mu(\mathbf{x}) \mid X = \mathbf{x}].$$

而 $\mathbb{E}[Y - \mu(\mathbf{x}) \mid X = \mathbf{x}] = \mathbb{E}[Y \mid \mathbf{x}] - \mathbb{E}[\mu(\mathbf{x}) \mid \mathbf{x}] = \mu(\mathbf{x}) - \mu(\mathbf{x}) = 0$ 。 $\mathbb{E}[\mu(\mathbf{x}) \mid \mathbf{x}] = \mu(\mathbf{x})$ 是因为已经条件在 $\mathbf{x}$ 上, $\mu(\mathbf{x})$ 是确定的数——这和 $\mathbb{E}[5 \mid X] = 5$ 是同一个道理。

直观理解: 回归函数 $\mu(\mathbf{x})$ 的定义性特征就是把 Y 分解为 $Y = \mu(\mathbf{x}) + \varepsilon$, 其中残差 ε 的条件均值为零。若 $\mathbb{E}[\varepsilon \mid \mathbf{x}] \neq 0$, 则 $\mu(\mathbf{x})$ 就不是真正的条件期望。

Step 4 — 结论. (10.13) 中仅第二项依赖于 c , 当 $c = \mu(\mathbf{x})$ 时取到最小值 0。因此:

定理 10.1 (平方损失下的最优预测器). 在平方损失 $L(y, f(\mathbf{x})) = (y - f(\mathbf{x}))^2$ 下, 使 $\text{EPE}(f)$ 最小的唯一函数是**回归函数 (regression function)**:

$$f^*(\mathbf{x}) = \mathbb{E}[Y \mid X = \mathbf{x}] = \int_{\mathbb{R}} y \cdot \Pr(dy \mid \mathbf{x}). \quad (10.14)$$

EPE 的一般形式: 损失矩阵

前面的 0-1 损失把所有分类错误一视同仁——把猫判为狗和判为老虎代价一样。但在实际问题中, 不同错误的代价往往不同 (例如: 把恶性肿瘤判为良性的代价远大于反过来)。因此需要更一般的框架。

定义 10.7 (损失矩阵与 EPE 的一般形式). 设输出 $G \in \mathcal{G} = \{G_1, \dots, G_K\}$ 有 K 个类别。定义 $K \times K$ 的损失矩阵 $\mathbf{L}$, 其元素:

$$L_{k\ell} = L(G_k, G_\ell) = \text{将真实类 } G_k \text{ 错判为 } G_\ell \text{ 的代价}, \quad L_{kk} = 0, \quad L_{k\ell} \geq 0.$$

分类器 $\hat{G}(X)$ 的期望预测误差为:

$$\text{EPE} = \mathbb{E}[L(G, \hat{G}(X))] = \mathbb{E}_X \sum_{k=1}^K L(G_k, \hat{G}(X)) \Pr(G_k \mid X). \quad (10.15)$$

Step 1 — 条件期望展开. 与平方损失一样, 对 X 取条件:

$$\text{EPE} = \mathbb{E}_X \left[\sum_{k=1}^K L(G_k, \hat{G}(X)) \Pr(G_k \mid X) \right]. \quad (10.16)$$

Step 2 — 逐点最小化. 由于被积函数非负, 只需对每个 $\mathbf{x}$ 独立地选择 $\hat{G}(\mathbf{x}) \in \mathcal{G}$ 最小化括号内的条件风险:

$$\hat{G}(\mathbf{x}) = \arg \min_{g \in \mathcal{G}} \sum_{k=1}^K L(G_k, g) \Pr(G_k \mid X = \mathbf{x}). \quad (10.17)$$

这就是**贝叶斯决策规则**的一般形式: 在每个点上, 选那个使**期望代价**最小的类。

Step 3 — 退化到 0-1 损失. 当 $L(G_k, G_\ell) = \mathbb{I}\{k \neq \ell\}$ (所有错误代价相同) 时:

$$\sum_{k=1}^K \mathbb{I}\{k \neq g\} \Pr(G_k \mid \mathbf{x}) = \sum_{k \neq g} \Pr(G_k \mid \mathbf{x}) = 1 - \Pr(G = g \mid \mathbf{x}).$$

最小化 $1 - \Pr(G = g \mid \mathbf{x})$ 等价于最大化 $\Pr(G = g \mid \mathbf{x})$, 退化为之前得到的贝叶斯分类器 (定理 10.2)。

0-1 损失下的详细推导 (0-1 作为特例验证)

现在考虑 K 类分类问题, 输出 $G \in \mathcal{G} = \{1, 2, \dots, K\}$ 。

0-1 损失是损失矩阵 $L(G_k, G_\ell) = \mathbb{I}\{k \neq \ell\}$ 的特例。下面用 EPE 框架从头推导。

定义 10.8 (0-1 损失下的 EPE).

$$\text{EPE}(f) = \mathbb{E}[\mathbb{I}\{G \neq f(X)\}] = \int_{\mathbb{R}^p \times \mathcal{G}} \mathbb{I}\{g \neq f(\mathbf{x})\} \Pr(d\mathbf{x}, dg). \quad (10.18)$$

Step 1 — 条件期望展开.

$$\begin{aligned} \text{EPE}(f) &= \mathbb{E}_X \mathbb{E}_{G|X}(\mathbb{I}\{G \neq f(X)\} \mid X) \\ &= \int_{\mathbb{R}^p} \left[\sum_{g=1}^K \mathbb{I}\{g \neq f(\mathbf{x})\} \Pr(G = g \mid X = \mathbf{x}) \right] \Pr(d\mathbf{x}). \end{aligned} \quad (10.19)$$

Step 2 — 逐点最小化. 对每个固定的 $\mathbf{x}$, 需选择 $f(\mathbf{x}) \in \mathcal{G}$ 使括号内部最小。注意到:

$$\sum_{g=1}^K \mathbb{I}\{g \neq k\} \Pr(G = g \mid \mathbf{x}) = \sum_{g \neq k} \Pr(G = g \mid \mathbf{x}) = 1 - \Pr(G = k \mid \mathbf{x}).$$

因此最小化该式等价于最大化 $\Pr(G = k \mid \mathbf{x})$ 。

定理 10.2 (贝叶斯分类器). 在 0-1 损失下, 使 $\text{EPE}(f)$ 最小的最优分类器为:

$$f^*(\mathbf{x}) = \arg \max_{k \in \{1, \dots, K\}} \Pr(G = k \mid X = \mathbf{x}). \quad (10.20)$$

该分类器称为贝叶斯分类器 (Bayes classifier), 其错误率:

$$\text{EPE}(f^*) = \int_{\mathbb{R}^p} \left[1 - \max_k \Pr(G = k \mid X = \mathbf{x}) \right] \Pr(d\mathbf{x}) \quad (10.21)$$

称为贝叶斯错误率 (Bayes error rate)——任何分类器都无法超越的下界。

三种损失形式的统一视角

	平方损失 (回归)	0-1 损失 (分类)	一般损失矩阵
EPE	$\mathbb{E}[(Y - f(X))^2]$	$\mathbb{E}[\mathbb{I}\{G \neq f(X)\}]$	$\mathbb{E}[L(G, \hat{G}(X))]$
逐点目标	$\min_c \mathbb{E}[(Y - c)^2 \mid X = \mathbf{x}]$	$\min_k [1 - \Pr(G = k \mid \mathbf{x})]$	$\min_g \sum_k L(G_k, g) \Pr(G_k \mid \mathbf{x})$
最优解	$f^*(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{x}]$	$\arg \max_k \Pr(G = k \mid \mathbf{x})$	$\arg \min_g \sum_k L(G_k, g) \Pr(G_k \mid \mathbf{x})$
不可达下界	$\mathbb{E}[\text{Var}(Y \mid X)]$	$1 - \mathbb{E}[\max_k \Pr(G = k \mid X)]$	$\mathbb{E}[\min_g \sum_k L(G_k, g) \Pr(G_k \mid X)]$

所有情况下, 最优预测器都依赖于真实的条件分布 $P(Y \mid X)$ 。在实际问题中这个条件分布是未知的, 因此学习问题的本质是: 用有限样本 $\mathcal{D}$ 去逼近 $P(Y \mid X)$ 或直接逼近 f^* 。

10.1.6 两种建模策略

统计学习提供了两种基本策略来逼近 $f^*(\mathbf{x}) = \mathbb{E}[Y | X = \mathbf{x}]$:

(1) **参数方法 (Parametric)**: 假设 f 具有某种参数化形式。

- 例: 线性模型 $f(\mathbf{x}) = \boldsymbol{\beta}^\top \mathbf{x} + \beta_0$.
- 将估计无穷维函数的问题简化为估计有限个参数。
- 优点: 高效、可解释; 缺点: 模型假设可能错误 (欠拟合)。

(2) **非参数方法 (Nonparametric)**: 不假设 f 的具体形式, 直接从数据中学习。

- 例: k -近邻、核平滑、决策树、神经网络。

10.1.7 完整示例: 从数据到预测

下面通过两个完整的数值例子, 把上文的概念串成一条线: 数据 $\rightarrow$ 模型假设 $\rightarrow$ 参数估计 $\rightarrow$ 预测 $\rightarrow$ 评估。

例 1: 一元线性回归 (参数方法)

Step 1 — 数据. 设有 $N = 5$ 个观测:

$$\mathcal{D} = \{(1, 2.1), (2, 3.8), (3, 6.2), (4, 7.9), (5, 10.1)\}.$$

Step 2 — 模型假设. 假设 Y 与 X 呈线性关系:

$$f(x) = \beta_0 + \beta_1 x. \quad (10.22)$$

此时假设空间 $\mathcal{F} = \{f(x) = \beta_0 + \beta_1 x \mid \beta_0, \beta_1 \in \mathbb{R}\}$, 仅含两个参数。

Step 3 — 损失函数与优化. 采用平方损失, 经验风险为:

$$\hat{R}(\beta_0, \beta_1) = \frac{1}{5} \sum_{i=1}^5 (y_i - (\beta_0 + \beta_1 x_i))^2.$$

令梯度为零 $\frac{\partial \hat{R}}{\partial \beta_0} = \frac{\partial \hat{R}}{\partial \beta_1} = 0$, 解得:

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{10.0}{10.0} = 1.00, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 6.02 - 1.00 \times 3 = 3.02.$$

用矩阵形式 (正规方程) 得到相同结果。令设计矩阵 $\mathbf{X} = \begin{bmatrix} \mathbf{1} & \mathbf{x} \end{bmatrix}$:

$$\mathbf{X} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 2.1 \\ 3.8 \\ 6.2 \\ 7.9 \\ 10.1 \end{bmatrix}, \quad \hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \begin{bmatrix} 3.02 \\ 1.00 \end{bmatrix}.$$

Step 4 — 预测. 对新输入 $x_0 = 6$, 预测值为:

$$\hat{f}(6) = 3.02 + 1.00 \times 6 = 9.02.$$

Step 5 — 评估. 训练集上的均方误差:

$$\hat{R}(\hat{\beta}) = \frac{1}{5} \sum_{i=1}^5 (y_i - \hat{y}_i)^2 = \frac{0.0064 + 0.0144 + 0.0064 + 0.0144 + 0.0064}{5} \approx 0.0096.$$

训练误差很小, 说明模型对训练数据拟合良好。但真正的泛化能力需要用**独立测试集**来评估——这是第 7 章的核心议题。

例 2: 二分类——线性回归用作分类器 (ESL §2.4 经典示例)

Step 1 — 数据生成. 从两个二元正态分布中各抽取 100 个点, 总计 $N = 200$:

$$\text{Class BLUE: } \mathbf{x} \sim \mathcal{N}\left(\begin{bmatrix} 1 \\ 0 \end{bmatrix}, \mathbf{I}_2\right), \quad Y = 0, \quad (10.23)$$

$$\text{Class ORANGE: } \mathbf{x} \sim \mathcal{N}\left(\begin{bmatrix} 0 \\ 1 \end{bmatrix}, \mathbf{I}_2\right), \quad Y = 1. \quad (10.24)$$

Step 2 — 模型假设: 线性回归用于分类. 虽然是分类问题, 我们先用线性回归来拟合一个连续输出, 然后通过阈值转化为类别:

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2, \quad (10.25)$$

分类规则:

$$\hat{G} = \begin{cases} \text{ORANGE}, & \text{if } \hat{Y} > 0.5, \\ \text{BLUE}, & \text{if } \hat{Y} \leq 0.5. \end{cases} \quad (10.26)$$

Step 3 — 参数估计. 将 BLUE 编码为 $y = 0$, ORANGE 编码为 $y = 1$, 用最小二乘拟合:

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

得到的决策边界 $\hat{Y} = 0.5$ 在输入空间中是一条直线。

Step 4 — 预测与决策边界. 将 $\hat{Y} = 0.5$ 代入 (10.25):

$$\hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2 = 0.5.$$

这是一条将平面划分为两部分的直线——**线性决策边界**。

Step 5 — 评估: 训练误差 vs 测试误差.

(a) **训练误差.** 在训练集 (200 个点) 上计算 0-1 损失:

$$\hat{R}_{\text{train}}(\hat{f}) = \frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} \mathbb{I}\{\hat{G}_i \neq G_i\}. \quad (10.27)$$




图 10.1: 线性回归用于二分类: 决策边界将特征空间划分为两个区域。蓝色点为 Class BLUE, 橙色点为 Class ORANGE。

(b) 生成测试集. 从与训练集相同的分布中独立生成一个大规模测试集 (例如 $N_{\text{test}} = 10,000$ 个点), 以精确估计泛化误差:

$$\mathcal{D}_{\text{test}} = \{(\mathbf{x}_j, y_j)\}_{j=1}^{N_{\text{test}}}, \quad \mathbf{x}_j \sim \begin{cases} \mathcal{N}\left(\begin{bmatrix} 1 \\ 0 \end{bmatrix}, \mathbf{I}_2\right), & y_j = 0 \text{ (BLUE)}, \\ \mathcal{N}\left(\begin{bmatrix} 0 \\ 1 \end{bmatrix}, \mathbf{I}_2\right), & y_j = 1 \text{ (ORANGE)}. \end{cases}$$

注意: 测试集中的点绝不参与模型训练—— $\hat{f}$ 仅由训练集 $\mathcal{D}_{\text{train}}$ 得到。这是评估中最重要的纪律。

(c) 测试误差. 在测试集上计算 0-1 损失, 得到泛化误差的无偏估计:

$$\hat{R}_{\text{test}}(\hat{f}) = \frac{1}{N_{\text{test}}} \sum_{j=1}^{N_{\text{test}}} \mathbb{I}\{\hat{G}_j \neq G_j\}. \quad (10.28)$$

(d) 对比.

	公式	含义
训练误差	$\frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} \mathbb{I}\{\hat{G}_i \neq G_i\}$	模型对见过的数据错多少
测试误差	$\frac{1}{N_{\text{test}}} \sum_{j=1}^{N_{\text{test}}} \mathbb{I}\{\hat{G}_j \neq G_j\}$	模型对未见过的数据错多少

通常训练误差 < 测试误差（因为参数是针对训练数据优化的）。若两者的差距很大，说明模型**过拟合**；若两者都很大，说明模型**欠拟合**。这一诊断框架将在第 7 章（模型评估与选择）中系统展开。

Step 6 — 反思：线性回归做分类的问题。

- 编码方式 (0/1) 是任意的——若改为 $-1/+1$ ，结果不同；
- $\hat{Y}$ 可能超出 $[0, 1]$ ，无法解释为概率；
- 当 $K \geq 3$ 时，类别之间的顺序假设不合理。

这些缺陷正是第 4 章引入 **Logistic 回归** 与 **线性判别分析 (LDA)** 的动机。

例 3: k-近邻 (k-NN) 分类——非参数方法的代表

与例 2 使用完全相同的数据（两类二元高斯，各 100 个训练点），改用 k -近邻分类器。

算法. 对于输入 $\mathbf{x}$ ，k-NN 分类器的决策规则为：

- 在训练集中找出离 $\mathbf{x}$ 最近的 k 个点，记其索引为 $\mathcal{N}_k(\mathbf{x})$ ；
- 对这些点的类别进行**多数投票**：

$$\hat{G}(\mathbf{x}) = \arg \max_{g \in \{\text{BLUE}, \text{ORANGE}\}} \sum_{i \in \mathcal{N}_k(\mathbf{x})} \mathbb{I}\{G_i = g\}. \quad (10.29)$$

距离通常取欧氏距离： $\|\mathbf{x} - \mathbf{x}_i\|$ 。

有效参数个数. k-NN 没有显式的 β 参数，但其复杂度由 k 控制。ESL 定义其**有效自由度**为：

$$\text{df}(k) \approx \frac{N}{k}. \quad (10.30)$$

直观含义：

- $k = 1$: $\text{df} \approx 200$ ——每个训练点就是一个“参数”，纯记忆，决策边界极度蜿蜒；
- $k = 200$: $\text{df} \approx 1$ ——所有人一起投票退化为多数类预测，模型僵硬；
- $k \approx N/p$ 时，k-NN 与 p 个参数的线性模型复杂度大致相当——这是模型选择的粗略基准。

训练误差. 训练误差随 k 单调递增（ k 越小越能完美记住训练集）：

$$k = 1 \Rightarrow \text{训练误差} = 0 \quad (\text{每个点都是自己的最近邻}).$$

因此**不能用训练误差来选择 k** ——它永远偏向 $k = 1$ 。

测试误差与 k 的选择. 在独立测试集（10,000 个点）上评估不同 k 的表现，得到 U 形曲线（参见 ESL Figure 2.4）：

测试误差(k) = $\frac{1}{N_{\text{test}}} \sum_{j=1}^{N_{\text{test}}} \mathbb{I}\{\hat{G}_j^{(k)} \neq G_j\}.$

选择使测试误差最小的 k 。在 Scenario 1（两类各一个高斯，线性最优边界）下，最优 k 约在 30–40 左右。

两个极端：偏差-方差视角.
线性回归与 k -NN 代表了统计学习的两种**极端哲学**：

	线性模型（参数方法）	k -近邻（非参数方法）
核心假设	假设 f 是线性的（全局刚性）	不做假设，纯靠局部记忆
偏差	高（模型错 $\rightarrow$ 预测系统偏）	低（足够灵活，能拟合任意形状）
方差	低（估计量稳定，不易受扰动）	高（局部依赖，对训练样本敏感）
决策边界	光滑、稳定	蜿蜒、不稳定
典型问题	欠拟合（模型太简单）	过拟合（ k 太小则死记硬背）

几乎所有现代 ML 方法都是这两种简单过程的变体：

线性模型谱系	最近邻谱系
Ridge / Lasso（第 3 章）	核平滑（第 6 章）
Logistic 回归 / LDA（第 4 章）	局部回归
SVM（线性核）（第 12 章）	决策树 / 随机森林（第 9, 15 章）
GAM / 样条（第 5, 9 章）	神经网络（第 11 章）

所有现代方法的本质都是在**偏差与方差之间找平衡**——这构成了全书的方法论主线。

三个例子串联总结：

步骤	数据	模型	损失	优化	预测/评估
例 1	$(x_i, y_i) \in \mathbb{R} \times \mathbb{R}$	$f(x) = \beta_0 + \beta_1 x$	平方损失	正规方程	MSE
例 2	$(\mathbf{x}_i, y_i) \in \mathbb{R}^2 \times \{0, 1\}$	$f(\mathbf{x}) = \boldsymbol{\beta}^\top \mathbf{x} + \beta_0$	平方损失	正规方程	0–1 损失
例 3	同例 2	k -NN 多数投票	0–1 损失	调 k	测试误差 U 形曲线

10.1.8 理论回看：从最优预测器到实际估计器

在前面的推导中，定理 10.1 告诉我们：在平方损失下，最优预测器是回归函数 $f^*(\mathbf{x}) = \mathbb{E}[Y | X = \mathbf{x}]$ 。但在实践中我们不知道真实的联合分布 $\Pr(X, Y)$ ，只能用训练数据 $\mathcal{D}$ 去估计它。例 1–3 恰恰展示了两种截然不同的估计策略。

线性回归的估计器（例 1 & 例 2）

线性回归将条件期望限定为**线性函数**：

$$f(\mathbf{x}) \approx \mathbb{E}[Y | X = \mathbf{x}] \implies \hat{f}(\mathbf{x}) = \hat{\beta}_0 + \sum_{j=1}^p \hat{\beta}_j X_j = \mathbf{x}^\top \hat{\boldsymbol{\beta}}. \quad (10.31)$$

其中 $\hat{\boldsymbol{\beta}}$ 通过**经验风险最小化**（平方损失）得到：

$$\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta} \in \mathbb{R}^{p+1}} \frac{1}{N} \sum_{i=1}^N (y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}. \quad (10.32)$$

关键点：线性模型用一个**全局参数化假设**来逼近 f^* ——对所有 $\mathbf{x}$ 用同一组 $\hat{\boldsymbol{\beta}}$ 做预测。这等价于假设真实的 $\mathbb{E}[Y | X = \mathbf{x}]$ 恰好是 $\mathbf{x}$ 的线性函数。如果这个假设成立（Scenario 1），则偏差很小；如果不成立（Scenario 2），则偏差很大。

k-NN 的估计器（例 3）

k-NN 不做全局假设，而是用**局部样本平均**直接估计条件期望：

$$f^*(\mathbf{x}) = \mathbb{E}[Y | X = \mathbf{x}] \approx \hat{f}(\mathbf{x}) = \frac{1}{k} \sum_{i \in \mathcal{N}_k(\mathbf{x})} y_i, \quad (10.33)$$

其中 $\mathcal{N}_k(\mathbf{x})$ 是 $\mathbf{x}$ 的 k 个最近邻的指标集。

关键点：这是条件期望的一个非常直接的非参数估计——用「离 $\mathbf{x}$ 最近的 k 个点的 y 的均值」作为 $\mathbb{E}[Y | X = \mathbf{x}]$ 的估计。不需要假设 f 的形式，但也因此需要足够多的数据来保证局部平均的精度（维数灾难）。

两种估计器的渐近行为：谁逼近了 f^* ？

一个关键问题是：当 $N \rightarrow \infty$ 时， $\hat{f}$ 是否收敛到 $f^*(\mathbf{x}) = \mathbb{E}[Y | X = \mathbf{x}]$ ？

k-NN：在适当条件下（ $N \rightarrow \infty, k \rightarrow \infty, k/N \rightarrow 0$ ），局部平均收敛到条件期望：

$$\hat{f}_{\text{kNN}}(\mathbf{x}) \xrightarrow{N \rightarrow \infty} \mathbb{E}[Y | X = \mathbf{x}] = f^*(\mathbf{x}).$$

k-NN 是渐近无偏的——只要数据够多、 k 增长恰当，它最终能逼近真实的 f^* 。

线性回归：即使 $N \rightarrow \infty$ ， $\hat{f}$ 的极限不一定是 f^* 。线性回归的极限是 f^* 在全体线性函数中的**最佳 L_2 投影**：

$$\hat{f}_{\text{linear}}(\mathbf{x}) \xrightarrow{N \rightarrow \infty} \mathbf{x}^\top \boldsymbol{\beta}^*, \quad \boldsymbol{\beta}^* = \arg \min_{\boldsymbol{\beta} \in \mathbb{R}^{p+1}} \mathbb{E}[(Y - \mathbf{X}^\top \boldsymbol{\beta})^2].$$

只有当真实的 $f^*(\mathbf{x})$ 恰好是线性函数时，投影才等于 f^* 本身；否则 $\mathbf{x}^\top \boldsymbol{\beta}^*$ 只是 f^* 在线性子空间中的**最佳逼近**，而非 f^* 本身。

投影的几何含义. 考虑全体平方可积函数的空间 $\mathcal{L}^2(P_X) = \{g \mid \mathbb{E}[g(X)^2] < \infty\}$ ，其上定义内积 $\langle g, h \rangle = \mathbb{E}[g(X)h(X)]$ 。

线性函数构成一个子空间：

$$\mathcal{L} = \{g(\mathbf{x}) = \mathbf{x}^\top \boldsymbol{\beta} \mid \boldsymbol{\beta} \in \mathbb{R}^{p+1}\} \subset \mathcal{L}^2(P_X).$$

最佳线性近似 $\mathbf{x}^\top \boldsymbol{\beta}^*$ 就是 f^* 向 $\mathcal{L}$ 的**正交投影**：残差 $f^* - \mathbf{x}^\top \boldsymbol{\beta}^*$ 与 $\mathcal{L}$ 中每个函数正交，即 $\mathbb{E}[X_j \cdot (f^*(X) - \mathbf{x}^\top \boldsymbol{\beta}^*)] = 0$ 对所有 j 成立。

换句话说： $\mathbf{x}^\top \boldsymbol{\beta}^*$ 是 $\mathcal{L}$ 中离 f^* “最近”的函数（在 $\|g\|^2 = \mathbb{E}[g(X)^2]$ 的距离意义下）。投影与真值之间的差距 $\|f^* - \mathbf{x}^\top \boldsymbol{\beta}^*\|^2$ 就是线性模型的**平方偏差**。

用欧氏空间的类比：三维空间中，点 f^* 向二维平面 $\mathcal{L}$ 作垂线，垂足 $\mathbf{x}^\top \boldsymbol{\beta}^*$ 就是最佳逼近，垂线长度就是偏差。这和线性代数中 $\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 是 $\mathbf{y}$ 向列空间的投影是同一个道理——只不过这里的“空间”是无穷维的函数空间，内积是 $\mathbb{E}[\cdot]$ 而非 $\mathbf{a}^\top \mathbf{b}$ 。

为什么线性函数不完备？ 线性子空间 $\mathcal{L}$ 的维度仅为 $p+1$ ，而 $\mathcal{L}^2(P_X)$ 是无穷维的。因此 $\mathcal{L}$ 中的有限个基函数 $\{1, X_1, \dots, X_p\}$ 无法张成整个函数空间——它们构成的是一个**不完备的基**。这意味着：除非 f^* 恰好落在 $\mathcal{L}$ 内（即真实关系恰为线性），否则投影永远有非零残差，这正是偏差的来源。

反过来看，这正是全书后续章节的推进逻辑——**逐步扩充基函数集合，让不完备逼近完备**：

方法	扩充方式	子空间维度
线性回归	$\{1, X_1, \dots, X_p\}$	$p+1$ （有限）
多项式回归	加 $X_1^2, X_1 X_2, X_2^2, \dots$	有限，可增大
样条（第 5 章）	加截断幂基 $h_j(X)$	有限，可控
核方法（第 6 章）	每个训练点一个基 $\rightarrow$ RKHS	无穷维（完备!）
神经网络（第 11 章）	万能逼近定理：宽网络可稠密	渐近完备

其中核方法使用的 RKHS（再生核希尔伯特空间）是完备的——其基函数族的闭包就是整个 $\mathcal{L}^2$ ，因此理论上可以逼近任意光滑的 f^* 。偏差-方差权衡中的“偏差”一侧，本质上就是不完备基无法表示 f^* 所带来的**结构误差**。

两种策略对比

	线性回归	k -近邻
对 f^* 的逼近方式	全局线性参数化	局部样本平均
预测函数	$\hat{f}(\mathbf{x}) = \mathbf{x}^\top \hat{\boldsymbol{\beta}}$	$\hat{f}(\mathbf{x}) = \frac{1}{k} \sum_{i \in \mathcal{N}_k(\mathbf{x})} y_i$
假设强度	强（线性）	弱（仅光滑性）
来源	参数方法传统	非参数 / 局部方法传统

两种方法的共同目标都是逼近同一个 $f^*(\mathbf{x}) = \mathbb{E}[Y | X = \mathbf{x}]$ 。差异在于**用什么结构来约束这个逼近**：线性回归用全局线性结构（偏差换方差）， k -NN 用局部常数结构（方差换偏差）。后续章节的所有方法——Ridge、Lasso、样条、核方法、树、神经网络——都可以理解为在这两种极端之间寻找更优的偏差-方差折中。

10.1.9 统计学习 vs 经典统计：两种推理框架

本章建立的数学框架与之前在“统计学基础”部分使用的框架有本质区别。两者并不矛盾，但出发点和核心关切截然不同。

经典统计框架（推断范式）

经典统计的核心目标是**推断 (inference)**——理解数据背后的生成机制：

数据 $\rightarrow$ 假设分布族（正态、二项等） $\rightarrow$ 估计参数 θ $\rightarrow$ 检验假设、构建置信区间。

典型问题：

- “ β_1 显著不为零吗？它的 95% 置信区间是什么？”
- “这批药的效果是否显著优于安慰剂？”
- “哪个自变量对因变量有显著影响？”

好坏的度量： p 值、置信区间、无偏性、有效性、功效。

统计学习框架（预测范式）

统计学习的核心目标是**预测 (prediction)**——对未见过的输入做出准确判断：

数据 $\rightarrow$ 选定损失函数 L $\rightarrow$ 学一个函数 f $\rightarrow$ 在新数据上评估误差。

典型问题：

- “给定这个用户的行为，他明天会不会流失？准确率多少？”

- “这张图片里是什么物体？”
- “这个病人五年内存活的概率是多少？”

好坏的度量：测试误差、交叉验证误差、AUC。

核心对比

	经典统计（推断）	统计学习（预测）
核心问题	数据是怎么生成的？	对新数据能预测多准？
核心对象	参数 θ (β, μ, σ^2)	函数 $f: \mathcal{X} \rightarrow \mathcal{Y}$
必需假设	分布族（正态、二项…）	仅需损失函数（不一定要分布）
模型角色	用于 解释 （哪个变量重要？）	用于 预测 （准确率够不够上线？）
好坏标准	p 值、置信区间、无偏性	测试误差、交叉验证误差

两者并非对立

统计学习中大量使用经典统计的工具，但**目的变了**：

统计工具	在经典统计中的角色	在统计学习中的角色
MLE	参数推断（估计 β 的标准误）	Logistic 回归的参数估计 (§4.4)
正态假设	推导 t 检验、 F 检验	线性回归的噪声模型 (§3.2)
偏差-方差分解	—（经典统计少有此视角）	模型选择的核心工具 (§2.5, §7.3)
Bootstrap	估计标准误	模型评估与 Bagging (§8.2, §8.7)

本质区别：在统计学习中，即使模型参数在统计意义上不显著、无法给出置信区间，只要它能让预测误差降低，它就是有用的——这在经典统计中是不可接受的。一切以预测性能为最终裁判，而非以统计显著性为裁判。

10.2 无监督学习的数学框架

10.2.1 基本设定

定义 10.9 (无监督学习的构成要素). 无监督学习仅有输入而没有输出标签：

- (i) 输入空间 $\mathcal{X} \subseteq \mathbb{R}^p$;
- (ii) 数据 $\mathcal{D} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$, 其中 $\mathbf{x}_i \stackrel{\text{i.i.d.}}{\sim} P(X)$;
- (iii) 目标: 从无标签数据中发现结构——聚类、降维、密度估计、生成建模等。

10.2.2 聚类

定义 10.10 (聚类问题). 给定 N 个数据点 $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ 和聚类数 K , 将数据划分为 K 个互不相交的子集 (簇) $C_1, \dots, C_K$, 使得簇内相似度高、簇间相似度低。

形式化地, K -means 的目标是最小化簇内平方和:

$$W(C) = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2, \quad (10.34)$$

其中 $\boldsymbol{\mu}_k = \frac{1}{|C_k|} \sum_{i \in C_k} \mathbf{x}_i$ 为第 k 簇的质心。

10.2.3 密度估计

定义 10.11 (密度估计). 给定 $\mathbf{x}_1, \dots, \mathbf{x}_N \stackrel{\text{i.i.d.}}{\sim} P$ (密度为 $p(\mathbf{x})$), 密度估计的目标是构造 $\hat{p}(\mathbf{x})$ 来逼近未知的真实密度 $p(\mathbf{x})$ 。

核密度估计 (KDE):

$$\hat{p}(\mathbf{x}) = \frac{1}{Nh^p} \sum_{i=1}^N K\left(\frac{\|\mathbf{x} - \mathbf{x}_i\|}{h}\right), \quad (10.35)$$

其中 $K(\cdot)$ 为核函数, $h > 0$ 为带宽参数。

10.2.4 降维

定义 10.12 (降维问题). 给定 $\mathbf{X} \in \mathbb{R}^{N \times p}$, 降维的目标是找到低维表示 $\mathbf{Z} \in \mathbb{R}^{N \times q}$ ($q < p$), 使得 $\mathbf{Z}$ 尽可能保留原始数据的结构信息。

定义 10.13 (主成分分析 (PCA)). PCA 寻找数据方差最大的方向。形式化地, 第 j 个主成分方向 $\mathbf{v}_j$ 满足:

$$\mathbf{v}_j = \arg \max_{\|\mathbf{v}\|=1, \mathbf{v} \perp \mathbf{v}_1, \dots, \mathbf{v}_{j-1}} \text{Var}(\mathbf{X}\mathbf{v}). \quad (10.36)$$

等价地, $\mathbf{v}_1, \dots, \mathbf{v}_q$ 是样本协方差矩阵 $\hat{\Sigma} = \frac{1}{N} \mathbf{X}^\top \mathbf{X}$ (中心化后) 的前 q 个特征向量。

10.3 监督学习与无监督学习的对比

	监督学习	无监督学习
数据	$\{(\mathbf{x}_i, y_i)\}_{i=1}^N$	$\{\mathbf{x}_i\}_{i=1}^N$
目标	学习映射 $f: \mathcal{X} \rightarrow \mathcal{Y}$	发现 $\mathcal{X}$ 的内在结构
数学核心	条件分布 $P(Y X)$	边缘分布 $P(X)$
优化对象	$\min_f \mathbb{E}[L(Y, f(X))]$	取决于任务（聚类、降维等）
典型任务	回归、分类	聚类、降维、密度估计、关联规则
评估难度	有标签，可计算准确率/MSE	无标签，评估更主观

补充：半监督学习 (Semi-supervised Learning)

- 数据：少量有标签 $\{(\mathbf{x}_i, y_i)\}_{i=1}^{\ell}$ + 大量无标签 $\{\mathbf{x}_j\}_{j=\ell+1}^N$.
- 核心思想：利用 $P(X)$ 的信息来改善对 $P(Y | X)$ 的估计.
- 常见方法：自训练 (self-training)、一致性正则化 (consistency regularization)、生成模型.

10.4 维数灾难与高维空间中的局部方法

维数灾难 (Curse of Dimensionality) 是 Bellman (1961) 提出的概念，在统计学习中特指：随着输入维度 p 增大，基于局部邻域的方法（如 k -NN、核平滑）会遭遇样本稀疏性的指数级恶化。本节用 ESL §2.5 的经典分析来量化这一现象。

10.4.1 单位超立方体中的邻域

考虑 p 维单位超立方体 $[0, 1]^p$ 中均匀分布的数据。对任意点 x_0 ，我们希望捕获其周围占总数据比例 r 的邻域。

问题：要覆盖 r 比例的数据，邻域在每个维度上的边长 $e_p(r)$ 是多少？

$$e_p(r) = r^{1/p}. \quad (10.37)$$

r	$p = 1$	$p = 3$	$p = 10$
1%	0.01	0.22	0.63
10%	0.10	0.46	0.80

在 $p = 10$ 维空间中, 要覆盖仅 1% 的数据就需要在每个维度上扩展 63% 的边长——几乎覆盖了整个范围。这意味着在十维空间中, 不存在真正意义上的”局部”邻域: 要么邻域几乎是全局的, 要么里面几乎没有点。

10.4.2 期望邻域边长

N 个点均匀分布在 $[0, 1]^p$ 中, 为在 x_0 处捕获 k 个最近邻, 所需超立方体邻域的期望边长为:

$$d(p, N) = \left(1 - 2^{-1/N}\right)^{1/p}. \quad (10.38)$$

典型数值 (ESL Exercise 2.3):

$$N = 500, p = 10 \implies d(p, N) \approx 0.52.$$

即需要覆盖每个维度上 52% 的范围来形成邻域——这已是全局尺度, 不再”局部”。

10.4.3 1-NN 的偏差-方差分解 (高维示例)

ESL §2.5 用一个具体例子展示维数灾难如何影响预测性能。

设定.

- $N = 1000$ 个训练点 x_i 均匀分布在 $[-1, 1]^p$ 中;
- 真实函数: $Y = f(X) = e^{-8\|X\|^2}$ ($x_0 = \mathbf{0}$ 处 $f(0) = 1$);
- 在 $x_0 = \mathbf{0}$ 处用 1-NN 预测 $\hat{y}_0$ 。

1-NN 的预测 $\hat{y}_0$ 就是离原点最近的训练点的 y 值。在 $x_0 = \mathbf{0}$ 处, MSE 分解为:

$$\text{MSE}(x_0) = \mathbb{E}_{\mathcal{T}}[(\hat{y}_0 - f(x_0))^2] = \text{Var}_{\mathcal{T}}(\hat{y}_0) + \text{Bias}^2(\hat{y}_0), \quad (10.39)$$

其中 $\mathcal{T}$ 表示对训练集的随机性取期望。

偏差-方差分解 (Bias-Variance Decomposition). 这是频率学派框架下分析模型性能的核心工具 (ESL 第 7 章将系统展开)。设真实函数为 $f(x_0)$, $\hat{f}(x_0)$ 为基于训练集 $\mathcal{T}$ 的估计, ε 为不可约噪声 ($\mathbb{E}[\varepsilon] = 0$, $\text{Var}(\varepsilon) = \sigma^2$), 则:

$$\mathbb{E}_{\mathcal{T}}[(y_0 - \hat{f}(x_0))^2] = \underbrace{(\mathbb{E}_{\mathcal{T}}[\hat{f}(x_0)] - f(x_0))^2}_{\text{偏差}^2} + \underbrace{\mathbb{E}_{\mathcal{T}}[(\hat{f}(x_0) - \mathbb{E}_{\mathcal{T}}[\hat{f}(x_0)])^2]}_{\text{方差}} + \underbrace{\sigma^2}_{\text{不可约噪声}}.$$

- **偏差 (Bias):** 即使有无限多训练集, 模型的平均预测离真实值有多远——衡量模型族本身的表达能力是否足够;
- **方差 (Variance):** 换一组训练集, 预测值波动多大——衡量模型对训练数据的敏感度;
- **不可约噪声:** 数据本身固有的随机性, 与模型无关。

偏差和方差通常不可兼得: 简单模型低方差高偏差 (欠拟合), 复杂模型低偏差高方差 (过拟合)。这里的 $\mathbb{E}_{\mathcal{T}}[\cdot]$ 是对不同训练集的重复抽样取期望——典型的频率学派视角。

本例中的表现. 随着 p 增大:

- **偏差增大:** 最近邻离原点越来越远 (因为高维中数据稀疏), 其 y 值随 $\|x\|$ 增大而衰减 ($f(x) = e^{-8\|x\|^2}$), 导致 $\hat{y}_0$ 系统性低于 $f(0) = 1$;
- **方差增大:** 最近邻位置的高度可变性导致 $\hat{y}_0$ 波动剧烈。

10.4.4 线性模型 vs 1-NN: 高维下的 EPE 对比

ESL 进一步对比了线性回归 (最小二乘) 和 1-NN 在 p 增大时的表现。

线性模型的设定. 假设真实模型为 $Y = X^\top \beta + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma^2)$, 用最小二乘拟合 $\hat{\beta}$ 。对 x_0 的预测:

$$\hat{y}_0 = x_0^\top \hat{\beta} = x_0^\top \beta + \sum_{i=1}^N \ell_i(x_0) \varepsilon_i,$$

其中 $\ell_i(x_0)$ 为 x_0 在帽子矩阵 $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ 中的对应元素。

在模型正确设定下, 对 x_0 取期望后:

$$\mathbb{E}_{x_0} \text{EPE}(x_0) \approx \sigma^2 \frac{p}{N} + \sigma^2. \quad (10.40)$$

第一项 $\sigma^2 p/N$ 来自估计 β 的方差, 随 p 线性增长; 第二项 σ^2 是不可约噪声。

1-NN 的 EPE 行为. 在高维空间中, 1-NN 最近邻的距离随 p 急剧增大, 导致偏差和方差均随 p 爆炸, EPE 远高于线性模型 (在真实模型为线性的条件下)。

核心教训.

方法	EPE 在高维下的行为	根本原因
线性回归	$\approx \sigma^2(p/N) + \sigma^2$, 随 p 线性增长	需要估计 p 个参数, 方差 $\propto p$
1-NN	随 p 指数恶化	邻域在高维中不再“局部”

在高维设置中, 即使真实函数是非线性的, 参数方法 (如线性回归) 往往优于非参数局部方法——因为非参数方法的方差代价在高维中变得不可接受。这一反直觉的结论是理解现代高维统计学习的基石, 也是为什么 Ridge、Lasso、正则化等方法如此重要的原因。

10.4.5 维数灾难的形式化定义与启示

定义 10.14 (维数灾难 (Curse of Dimensionality)). 设 p 为输入维度, ε 为邻域半径的相对大小。为在 p 维空间中保持相同的局部数据密度 (以覆盖固定比例的数据), 所需样本量 N 随 p 指数增长:

$$N \propto \varepsilon^{-p} \quad \text{或等价地} \quad \varepsilon \propto N^{-1/p}. \quad (10.41)$$

启示.

- (1) 基于局部邻域的方法 (k -NN、核平滑、局部回归) 仅在**低维** ($p \leq 4-5$) 中有效;
- (2) 在高维问题中, 必须引入**结构性假设** (线性、稀疏性、光滑性、低秩等) 来规避维数灾难;
- (3) 维数灾难并非诅咒一切方法——它主要打击的是**非参数局部方法**, 而参数方法和正则化方法可以通过假设结构来绕开它。

10.5 统计学习的基本框架：从模型到估计

本节系统梳理统计学习的核心概念链条——从加性误差模型出发, 经过损失函数与期望预测误差, 到达监督学习的参数估计方法 (最小二乘与极大似然), 最终揭示这些方法在函数逼近视角下的统一性。

10.5.1 加性误差模型与条件期望

统计学习最基本的出发点是假设输入 $X \in \mathbb{R}^p$ 与输出 $Y \in \mathbb{R}$ 之间存在如下关系:

$$Y = f(X) + \varepsilon, \quad (10.42)$$

其中:

- $f(X)$ 是 X 对 Y 的系统性影响——一个未知但确定性的函数;
- ε 是随机误差项, 满足

$$\mathbb{E}[\varepsilon] = 0, \quad \varepsilon \perp X; \quad (10.43)$$

- 独立性假设 $\varepsilon \perp X$ 意味着误差的分布不依赖于 X 的取值。

在式 (10.42) 两边对 $X = x$ 取条件期望:

$$\mathbb{E}[Y \mid X = x] = f(x) + \mathbb{E}[\varepsilon \mid X = x] = f(x). \quad (10.44)$$

因此 $f(x)$ 的统计含义就是条件期望（回归函数）：

$$f(x) = \mathbb{E}[Y | X = x]. \quad (10.45)$$

这正是回归分析的核心目标——在任意输入点 x 处，用条件均值作为 Y 的最佳预测。

注记 10.1 (回归函数 $\equiv$ 条件均值：是定义还是推导？). 初学者常有的困惑是：书中似乎”跳过”了损失函数的选择，直接宣称 $f(x) = \mathbb{E}[Y | X = x]$ 是回归函数。这背后的逻辑需要澄清。

两条汇合的推理路径.

路径一（定义先行，ESL 的叙述方式）：

”回归函数”在统计学中有历史定义 $\rightarrow f(x) = \mathbb{E}[Y | X = x] \rightarrow$ 后来发现平方损失恰好以它为目标

路径二（从损失出发，你的推理方式）：

选择损失函数 $L \rightarrow$ 最小化 $\text{EPE}(f) = \mathbb{E}[L(f(X), Y)] \rightarrow$ 解出最优 $f^* \rightarrow$ 若 L 是平方损失， f^* 恰好是条件均值

两条路径最终汇合，但因果关系不同。ESL 选择路径一，是因为”回归”(regression) 一词的历史起源就是条件均值——Galton (1886) 研究父子身高时发现了”向均值回归”(regression toward the mean) 现象，此后统计学便以 regression function 指代 $\mathbb{E}[Y | X]$ 。并非”因为选了平方损失所以最优是条件均值”，而是”回归函数的定义本就是条件均值，平方损失恰好以它为目标”。

不同损失函数导出不同的最优 f^* . 你关于损失函数决定最优预测器的理解完全正确。以下是常见对应：

损失 $L(y, f)$	最优 $f^*(x)$	名称
$(y - f)^2$	$\mathbb{E}[Y X = x]$	条件均值（回归函数）
$ y - f $	$\text{median}(Y X = x)$	条件中位数
$\mathbf{1}_{\{g \neq f\}}$ (0-1 分类损失)	$\arg \max_g P(G = g X = x)$	贝叶斯分类器
$\rho_\tau(y - f)$ (分位数损失)	$Q_\tau(Y X = x)$	条件 τ 分位数
Huber 损失	介于均值和截断均值之间（对异常值稳健）	

”回归”总是指均值吗？

在经典统计学中——是。”回归函数”严格定义为条件期望 $\mathbb{E}[Y | X]$ 。这一术语自 Galton 起已沿用百余年。教科书（包括 ESL）中未加修饰的”回归”默认指对条件均值的建模。

但在现代机器学习中——不完全如此。”回归”常被宽松地用来指任何输出为连续量的预测任务，不一定以均值为目标：

- 用 MAE 训练的网络仍被称为”回归模型”，尽管它估计的是条件中位数而非均值；
- 分位数回归 (quantile regression) 估计条件分位数，名称中仍带”回归”二字；
- 实践中大多默认使用平方损失/MSE，因此多数”回归”确实在估计条件均值——但这更多是惯例而非必然。

区分方式：严格写作时用”均值回归”(mean regression) 或”条件期望估计”；宽松语境下，”回归”≈”预测连续量”，具体目标取决于所用的损失函数。本书此后提及”回归函数”，除非特别说明，均指 $\mathbb{E}[Y | X]$ 。

10.5.2 条件方差：为什么可以不是常数

定义条件方差：

$$\text{Var}(Y | X = x) = \mathbb{E}[(Y - f(x))^2 | X = x] = \mathbb{E}[\varepsilon^2 | X = x] =: \sigma^2(x). \quad (10.46)$$

关键点：模型仅假设了 $\mathbb{E}[\varepsilon | X] = 0$ （一阶矩为零），对二阶矩 $\sigma^2(x)$ 没有任何约束。因此 $\sigma^2(x)$ 完全可以依赖于 x ，不需要是常数——这称为异方差性 (heteroscedasticity)。

例 10.1 (二分类问题的条件方差). 当 $Y \in \{0, 1\}$ 为二分类变量时，设 $p(x) = P(Y = 1 | X = x)$ ，则 $Y | X = x \sim \text{Bernoulli}(p(x))$ ：

$$\text{Var}(Y | X = x) = p(x)[1 - p(x)]. \quad (10.47)$$

方差在 $p = 0.5$ 处最大，在 $p \rightarrow 0$ 或 $p \rightarrow 1$ 时趋于零——明显依赖于 x 。

例 10.2 (泊松计数数据). 若 $Y | X \sim \text{Poisson}(\lambda(x))$ ，则 $\text{Var}(Y | X = x) = \lambda(x) = \mathbb{E}[Y | X = x]$ ——方差等于均值，随 x 变化。

10.5.3 期望预测误差与最优预测器

为了评价一个预测函数的好坏，引入期望预测误差 (Expected Prediction Error, EPE)：

$$\text{EPE}(f) = \mathbb{E}[(Y - f(X))^2]. \quad (10.48)$$

在平方损失下，可以证明**条件期望是最优预测器**：

定理 10.3 (最优预测器). 在加性误差模型 (10.42) 和平方损失下，条件期望 $f(x) = \mathbb{E}[Y | X = x]$ 最小化期望预测误差：

$$\arg \min_g \mathbb{E}[(Y - g(X))^2] = \mathbb{E}[Y | X]. \quad (10.49)$$

推导. 对任意函数 g , 在 $X = x$ 处展开:

$$\begin{aligned}\mathbb{E}[(Y - g(X))^2 | X = x] &= \mathbb{E}[(Y - f(x) + f(x) - g(x))^2 | X = x] \\ &= \underbrace{\mathbb{E}[(Y - f(x))^2 | X = x]}_{\sigma^2(x)} + (f(x) - g(x))^2 \\ &\geq \sigma^2(x),\end{aligned}\tag{10.50}$$

等号成立当且仅当 $g(x) = f(x)$ 。对所有 x 取期望即得结论。 $\square$

平方误差的分解:

$$\mathbb{E}[(Y - \hat{f}(X))^2] = \underbrace{\mathbb{E}[(f(X) - \hat{f}(X))^2]}_{\text{可约误差}} + \underbrace{\mathbb{E}[\sigma^2(X)]}_{\text{不可约噪声}}.\tag{10.51}$$

第一项取决于模型 $\hat{f}$ 的好坏 (可通过改进模型减小), 第二项 $\sigma^2(x) = \text{Var}(Y | X = x)$ 是数据固有的随机性 (≥ 0 , 无法消除)。

当 Y 是定性变量 (类别 G) 时, 平方损失替换为 0-1 损失或其他分类损失, 最优分类器为 $\arg \max_g P(G = g | X = x)$ 。

10.5.4 监督学习的数学表述

定义 10.15 (监督学习). 给定训练集 $\mathcal{T} = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, 其中 (x_i, y_i) 来自某个未知的联合分布 $P(X, Y)$ 的独立抽样。学习算法是一个映射 $\mathcal{A}: \mathcal{T} \mapsto \hat{f}$, 输出一个函数 $\hat{f}: \mathbb{R}^p \rightarrow \mathbb{R}$ (或 $\mathbb{R}^p \rightarrow \mathcal{G}$ 用于分类), 使得 $\hat{f}(x)$ 在未见过的 x 上也能较好地预测 y 。

核心挑战是泛化 (generalization) —— 在训练集上表现好是容易的, 在未知数据上也表现好才是学习的目标。这引出了偏差-方差权衡、正则化、模型选择等核心议题。

10.5.5 函数逼近视角

将 (X, Y) 看作 $\mathbb{R}^{p+1}$ 空间中的点, 学习 f 就是在这个空间中拟合一个曲面。参数化方法将 f 限制在某个函数族 $\{f_\theta: \theta \in \Theta\}$ 中。

线性模型

最简单的参数化是线性模型:

$$f(x) = x^\top \beta = \sum_{j=1}^p x_j \beta_j.\tag{10.52}$$

模型关于参数 β 是线性的, 但 x 本身可以是原始输入变量的任意变换。

线性基展开

更一般地，可以用 K 个基函数 $\{h_k(x)\}_{k=1}^K$ 的线性组合来表示 f ：

$$f_{\theta}(x) = \sum_{k=1}^K h_k(x) \theta_k. \quad (10.53)$$

模型关于参数 $\theta = (\theta_1, \dots, \theta_K)^{\top}$ 仍然是线性的，但基函数 $h_k(x)$ 可以是非线性的。常见选择：

基函数类型	$h_k(x)$ 的形式	示例
多项式	$h_k(x) = x_1^2, x_1x_2, x_2^2, \dots$	二次回归
三角函数	$h_k(x) = \cos(\omega_k^{\top} x), \sin(\omega_k^{\top} x)$	傅里叶基
样条基	$h_k(x)$ 为分段多项式	光滑样条
Sigmoid	$h_k(x) = \frac{1}{1 + \exp(-x^{\top} \beta_k)}$	神经网络隐层
径向基	$h_k(x) = \exp(-\gamma \ x - c_k\ ^2)$	RBF 网络

关键洞察：线性基展开 (10.53) 在数学形式上与线性模型 (10.52) 完全一致——只需将 x 替换为 $h(x) = (h_1(x), \dots, h_K(x))^{\top}$ 。这意味着所有针对线性模型开发的估计理论和算法（最小二乘、正则化等）都可以直接应用于基展开模型——只需先做一次特征变换。

当 $h_k(x) = 1/(1 + \exp(-x^{\top} \beta_k))$ 且 β_k 本身也参与学习时，式 (10.53) 就是单隐层前馈神经网络——这是深度学习的基础构件。

10.5.6 参数估计 I：最小二乘法

对于参数化模型 $f_{\theta}(x)$ ，最自然的估计方法是最小化训练集上的残差平方和（Residual Sum of Squares, RSS）：

$$\text{RSS}(\theta) = \sum_{i=1}^N (y_i - f_{\theta}(x_i))^2, \quad (10.54)$$

其中 $r_i = y_i - f_{\theta}(x_i)$ 称为第 i 个观测的残差（residual）——模型预测值与真实值之间的差距。RSS 将所有残差的平方累加，度量模型在训练集上的总拟合误差。

最小二乘估计量为：

$$\hat{\theta}_{\text{LS}} = \arg \min_{\theta} \text{RSS}(\theta). \quad (10.55)$$

在加性误差模型和线性基展开 $f_{\theta}(x) = h(x)^{\top} \theta$ 下， $\text{RSS}(\theta)$ 是关于 θ 的二次函数，有显式解（假设 $\mathbf{H}^{\top} \mathbf{H}$ 可逆）：

$$\hat{\theta}_{\text{LS}} = (\mathbf{H}^{\top} \mathbf{H})^{-1} \mathbf{H}^{\top} \mathbf{y}, \quad (10.56)$$

其中 $\mathbf{H}$ 是 $N \times K$ 的设计矩阵，第 i 行为 $h(x_i)^\top$ 。

几何解释：最小二乘将 $\mathbf{y}$ 正交投影到 $\mathbf{H}$ 的列空间上， $\hat{\mathbf{y}} = \mathbf{H}\hat{\boldsymbol{\theta}}$ 是该空间中最接近 $\mathbf{y}$ 的点。

10.5.7 参数估计 II：极大似然估计

最小二乘只关心 f_θ 本身。更一般的框架是极大似然估计 (MLE)，它对整个条件分布 $\Pr(Y | X)$ 建模。

条件似然

设条件分布 $\Pr(Y | X)$ 的参数为 θ ，则对数似然为：

$$\ell(\theta) = \sum_{i=1}^N \log \Pr_\theta(y_i | x_i). \quad (10.57)$$

极大似然估计量：

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \ell(\theta). \quad (10.58)$$

正态误差下的 MLE $\Leftrightarrow$ 最小二乘

这是连接两种方法的关键桥梁。假设 $Y | X \sim \mathcal{N}(f_\theta(X), \sigma^2)$ ，即正态分布的位置参数由 f_θ 决定，尺度参数 σ^2 为常数。

对数条件密度：

$$\log \Pr(y_i | x_i, \theta) = -\frac{1}{2} \log(2\pi\sigma^2) - \frac{(y_i - f_\theta(x_i))^2}{2\sigma^2}. \quad (10.59)$$

忽略与 θ 无关的项（仅 σ^2 已知时成立；若 σ^2 也未知则需联合估计），最大化对数似然等价于最小化 $\sum (y_i - f_\theta(x_i))^2$ ：

$$\boxed{\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \ell(\theta) = \arg \min_{\theta} \sum_{i=1}^N (y_i - f_\theta(x_i))^2 = \hat{\theta}_{\text{LS}}.} \quad (10.60)$$

结论：正态误差假设下，MLE 与最小二乘完全等价。

若放宽到 $\text{Var}(Y | X = x) = \sigma^2(x)$ （异方差），最小二乘仍然给出 θ 的一致估计（在温和条件下），但不再是有效的 MLE。此时需用加权最小二乘 (WLS) ——对方差小的点赋予更大权重。

分类问题：多项似然 $\Leftrightarrow$ 交叉熵

当 $Y = G$ 是 K 类定性变量时，用多项分布 (multinomial) 建模条件概率 $p_{g,\theta}(x) = \Pr(G = g | X = x)$ 。

对数似然为：

$$\ell(\theta) = \sum_{i=1}^N \log p_{g_i, \theta}(x_i), \quad (10.61)$$

其中 g_i 是第 i 个样本的真实类别。

最大化 (10.61) 等价于最小化交叉熵损失 (cross-entropy loss)：

$$\text{CE}(\theta) = - \sum_{i=1}^N \sum_{g=1}^K \mathbf{1}_{\{g_i=g\}} \log p_{g, \theta}(x_i). \quad (10.62)$$

结论：交叉熵损失 = 分类问题中 MLE 的等价形式。

10.5.8 参数估计 III：从 EPE 到 ERM

前面讨论了 LS 和 MLE 两种参数估计方法。在将它们与统计学习理论衔接时，有一个关键区别需要澄清。

EPE vs. ERM

平方损失下的期望预测误差 (EPE) 是对真实分布的期望：

$$\text{EPE}(f) = \mathbb{E}_{(X,Y)}[(Y - f(X))^2]. \quad (10.63)$$

但真实的联合分布 $P(X, Y)$ 未知，EPE 无法直接计算。实际中，我们用训练集上的经验平均来近似它，得到经验风险最小化 (Empirical Risk Minimization, ERM)：

$$\widehat{\text{EPE}}(f) = \frac{1}{N} \sum_{i=1}^N (y_i - f(x_i))^2. \quad (10.64)$$

最小二乘就是 ERM 在平方损失下的具体形式：

$$\hat{f}_{\text{LS}} = \arg \min_f \frac{1}{N} \sum_{i=1}^N (y_i - f(x_i))^2. \quad (10.65)$$

由大数定律，当 $N \rightarrow \infty$ 时 $\widehat{\text{EPE}}(f) \xrightarrow{P} \text{EPE}(f)$ ，因此 ERM 的解在样本量足够大时会逼近 EPE 的最优解。

但问题来了：大数定律的收敛需要 f 被固定（或至少来自一个不太复杂的函数族）。如果允许 f 是任意函数，ERM 会直接崩溃——这就是下一节的主题。

LS、ERM、EPE、MLE 四者关系总结：

概念	目标函数	对什么取平均	能否直接计算
EPE	$\mathbb{E}_{(X,Y)}[L(Y, f(X))]$	真实分布 $P(X, Y)$	× 未知
ERM	$\frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i))$	训练样本	✓ 可计算
LS	$\sum_{i=1}^N (y_i - f(x_i))^2$	训练样本（平方损失）	✓ ERM 的特例
MLE	$\sum_{i=1}^N \log P(y_i x_i, \theta)$	训练样本（对数似然）	✓ 等价于 ERM + KL 散度

MLE 与 ERM 的联系：在条件分布建模下，最大化对数似然等价于最小化模型分布与经验分布之间的 KL 散度，因此 MLE 本质上是 ERM 在概率建模框架下的对应物。

10.5.9 无约束最小化的根本困境

到目前为止，我们假设 f_θ 属于某个参数化的函数族（如线性模型 $f_\theta(x) = x^\top \beta$ 或基展开 $f_\theta(x) = \sum_k h_k(x) \theta_k$ ），参数个数 K 远小于样本量 N 。但如果我们不对 f 施加任何限制，直接最小化 $\text{RSS}(f) = \sum_{i=1}^N (y_i - f(x_i))^2$ ，会发生什么？

无穷多完美解

任何经过所有 N 个训练点 (x_i, y_i) 的函数 f 都满足 $\text{RSS}(f) = 0$ ——完美拟合训练数据。但这样的函数有无穷多个：

- 用折线依次连接所有数据点（按 x 排序）；
- 用一个 $N - 1$ 次多项式恰好穿过所有 N 个点（Lagrange 插值）；
- 在训练点之外任取任意值，只要在 x_i 处取值 y_i 即可。

这无穷多个解中，绝大多数在训练集之外的泛化性能极差——它们没有从数据中学到任何“规律”，只是在“背诵”训练点。

核心困境：

无限制的灵活性 + 有限的数据 = $\text{RSS} = 0$ 有无穷多解，全都没有泛化能力

从函数逼近的角度看，问题不在于“找不到函数穿过数据点”，而在于在无穷多穿过数据点的函数中，哪一个在未知点上表现好。

出路：对解空间施加限制

要获得有意义的解，必须缩小候选函数的范围。限制的强弱决定了模型的复杂度：

- **限制太强**（如只允许线性函数）：偏差大，可能漏掉数据的真实结构——欠拟合；
- **限制太弱**（如允许任意光滑函数）：方差大，模型被噪声牵着走——过拟合；
- **合适的限制**：在偏差和方差之间找到平衡。

限制可以通过多种方式实现，下面介绍两类最经典的方法：粗糙惩罚（正则化）和核方法（局部平均）。

10.5.10 受限制的估计量：几类经典方法

粗糙惩罚与平滑样条

核思想：在 RSS 上添加一个惩罚项，惩罚 f 的“粗糙程度”——越粗糙（波动越剧烈）的函数被罚得越重。

带惩罚的残差平方和（Penalized RSS）：

$$\text{PRSS}(f; \lambda) = \underbrace{\sum_{i=1}^N (y_i - f(x_i))^2}_{\text{对数据的拟合度}} + \lambda \cdot \underbrace{J(f)}_{\text{对粗糙度的惩罚}}. \quad (10.66)$$

其中：

- $J(f)$ 是衡量 f 粗糙度的泛函—— $J(f)$ 越大， f 越“不光滑”；
- $\lambda \geq 0$ 是平滑参数，控制拟合度与光滑度之间的权衡：
 - $\lambda = 0$ ：无惩罚，退化为无约束 RSS 最小化（过拟合）；
 - $\lambda \rightarrow \infty$ ：无限惩罚，强制 $J(f) = 0$ ，即 f 必须是线性函数（欠拟合）；
 - λ 取中间值：在数据拟合和函数光滑之间找到平衡。

例 10.3 (三次平滑样条 (Cubic Smoothing Spline)). 在一维输入 $x \in \mathbb{R}$ 的情形下，一个经典选择是惩罚 f 的二阶导数的平方积分：

$$J(f) = \int [f''(x)]^2 dx. \quad (10.67)$$

带惩罚的目标函数为：

$$\text{PRSS}(f; \lambda) = \sum_{i=1}^N (y_i - f(x_i))^2 + \lambda \int [f''(x)]^2 dx. \quad (10.68)$$

这个问题的解是一个自然三次样条 (natural cubic spline) —— 在所有具有绝对连续一阶导数和平方可积二阶导数的函数中, 式 (10.68) 的极小值点是一个节点恰好在所有训练点 x_i 处的三次样条。

直觉:

- $f''(x)$ 度量 f 的曲率——函数“拐弯”的剧烈程度;
- $\int [f'']^2$ 累积了整条曲线的总弯曲量;
- 惩罚此项意味着: 倾向于选择“尽可能直”但仍能拟合数据的曲线。

贝叶斯解释. 粗糙惩罚有一个优雅的贝叶斯对应:

$$\underbrace{\text{PRSS}(f; \lambda)}_{\text{频率学派: 惩罚最小二乘}} \longleftrightarrow \underbrace{-\log P(f \mid \text{数据})}_{\text{贝叶斯: 负对数后验}}$$

具体地, $\lambda J(f)$ 对应负对数先验 $-\log P(f)$:

- 惩罚 $\int [f'']^2$ 对应高斯过程先验: 假定 f 是一个具有特定协方差结构的高斯过程;
- λ 控制先验的强度——等价于贝叶斯框架中“你对 f 光滑的信念有多强”。

这正是正则化与贝叶斯方法的深层联系: **Ridge** 回归的 L_2 惩罚 $\leftrightarrow$ 高斯先验, **Lasso** 的 L_1 惩罚 $\leftrightarrow$ 拉普拉斯先验, 平滑样条的 $\int [f'']^2 \leftrightarrow$ 高斯过程先验。

核方法与局部回归

核思想: 在预测 x_0 处的 $f(x_0)$ 时, 只使用 x_0 附近的训练点, 而且离 x_0 越近的点权重越大。这通过一个核函数 $K_\lambda(x_0, x)$ 来实现。

核函数. $K_\lambda(x_0, x)$ 衡量输入点 x 对目标点 x_0 的“相关性”或“影响力”:

- 当 x 离 x_0 很近时, $K_\lambda(x_0, x)$ 取较大值;
- 当 x 离 x_0 很远时, $K_\lambda(x_0, x)$ 衰减到零;
- λ 是带宽参数, 控制“附近”的范围: λ 越小 $\rightarrow$ 邻域越窄 $\rightarrow$ 模型越灵活 (更局部); λ 越大 $\rightarrow$ 邻域越宽 $\rightarrow$ 模型越光滑 (更全局)。

例 10.4 (高斯核 (Gaussian Kernel)). 最常用的核函数之一:

$$K_\lambda(x_0, x) = \frac{1}{\lambda} \exp\left(-\frac{\|x - x_0\|^2}{2\lambda}\right). \quad (10.69)$$

带宽 λ 控制高斯函数的宽度, 决定了有效邻域的范围。

Nadaraya–Watson 估计量. 最简单的核回归估计量是加权平均:

$$\hat{f}(x_0) = \frac{\sum_{i=1}^N K_\lambda(x_0, x_i) y_i}{\sum_{i=1}^N K_\lambda(x_0, x_i)}. \quad (10.70)$$

这就是 **Nadaraya–Watson 核加权平均**—— $\hat{f}(x_0)$ 是周围训练点 y 值的加权平均, 权重由核函数决定。分母确保所有权重之和为 1, 使估计量成为真正的加权平均。

直觉:

- 预测 x_0 处的值 = 看看周围的数据点标签是什么, 取加权平均;
- 离得近的多参考, 离得远的少参考;
- λ 控制”周围”的范围——这是偏差-方差权衡的旋钮。

局部多项式回归. Nadaraya–Watson 等价于在每个 x_0 处拟合一个局部常数模型。更一般地, 可以在 x_0 的邻域内拟合局部多项式:

$$\min_{\beta_0, \dots, \beta_d} \sum_{i=1}^N K_\lambda(x_0, x_i) (y_i - \beta_0 - \beta_1(x_i - x_0) - \dots - \beta_d(x_i - x_0)^d)^2. \quad (10.71)$$

当 $d = 0$ 时退化为 Nadaraya–Watson (局部常数); $d = 1$ 为局部线性回归 (能更好地处理边界效应); 更高阶的 d 能捕捉更复杂的局部结构。

k -最近邻 (k -NN). 核方法的另一种变体是 k -NN:

$$\hat{f}(x_0) = \frac{1}{k} \sum_{x_i \in \mathcal{N}_k(x_0)} y_i, \quad (10.72)$$

其中 $\mathcal{N}_k(x_0)$ 是 x_0 的 k 个最近邻构成的集合。

k -NN 与核方法的区别:

- 核方法: 固定带宽 λ (固定距离范围), 邻域内的点数随位置变化;
- k -NN: 固定邻域点数 k , 邻域半径随位置和数据密度自适应调整。

在数据密度不均匀的区域, k -NN 的适应性更好 (密集区域邻域小, 稀疏区域邻域大)。

局部方法的共同局限: 维数灾难. 所有基于邻域的方法 (核平滑、局部回归、 k -NN) 在高维空间中都会遭遇维数灾难——为保持相同的局部数据密度, 所需样本量随维度指数增长。这正是为什么在高维问题中, 必须借助结构性假设 (线性、稀疏性、可加性等) 来规避这一问题。

方法	限制方式	复杂度旋钮	数学形式
粗糙惩罚/样条	惩罚 f 的曲率	λ (平滑参数)	$\text{RSS} + \lambda J(f)$
核平滑	局部加权平均	λ (带宽)	$\sum K_\lambda(x_0, x_i) y_i / \sum K_\lambda$
k -NN	固定邻域点数	k (邻居数)	$\frac{1}{k} \sum_{x_i \in \mathcal{N}_k(x_0)} y_i$
局部多项式	局部多项式拟合	λ (带宽) + d (阶数)	加权最小二乘

基函数与字典方法

第三类限制估计量的策略是：将 f 表示为一组基函数的线性组合，从而把无限维的函数空间限制在有限维的线性空间中。

线性基展开（回顾）。如 §5 所述，参数化模型的最一般形式是：

$$f_\theta(x) = \sum_{m=1}^M \theta_m h_m(x), \quad (10.73)$$

其中 $\{h_m(x)\}_{m=1}^M$ 是预先选定的一组基函数（或称为字典）。模型关于参数 θ 是线性的，因此可以用最小二乘直接求解。复杂度由基函数的个数 M 控制： M 太小 $\rightarrow$ 欠拟合（高偏差）， M 太大 $\rightarrow$ 过拟合（高方差）。

多项式样条（Polynomial Splines）。一维输入时，一种经典的基函数选择是截断幂基（truncated power basis）。将输入域用 $M-2$ 个节点（knots） $t_1, \dots, t_{M-2}$ 划分，构造如下基函数：

$$\begin{aligned} h_1(x) &= 1, \\ h_2(x) &= x, \\ h_{m+2}(x) &= (x - t_m)_+, \quad m = 1, \dots, M-2, \end{aligned} \quad (10.74)$$

其中 $(x - t)_+ = \max(0, x - t)$ 是截断幂函数——在节点 t 之前为零，在节点 t 之后线性增长。每个节点处的“弯折”由对应的基函数贡献。

这类基函数产生的 f_θ 是一个分段多项式：在相邻节点之间是低阶多项式，在节点处具有某种连续阶数。例如，上述构造产生的是线性样条（一阶，节点处连续但导数不连续）。若加入二次项 x^2 和截断二次项 $(x - t_m)_+^2$ ，则得到二次样条（一阶导数也连续）；更常用的是三次样条（基函数包含 $1, x, x^2, x^3$ 及 $(x - t_m)_+^3$ ，在节点处直到二阶导数都连续）。

样条与粗糙惩罚的关系。三次平滑样条（§10 粗糙惩罚部分）可以证明等价于将所有 N 个训练点都作为节点的三次样条，加上对系数的特定 L_2 型惩罚——两种视角殊途同归。

径向基函数 (Radial Basis Functions, RBF) . 对于多维输入, 一个自然的选择是径向基函数——它们的值只依赖于输入点到某个中心 μ_m 的距离:

$$f_{\theta}(x) = \sum_{m=1}^M K_{\lambda_m}(\mu_m, x) \theta_m,$$

(10.75)

其中 $K_{\lambda_m}(\mu_m, x)$ 是关于 $\|x - \mu_m\|$ 对称的核函数 (如高斯核 $K_{\lambda}(\mu, x) = \exp(-\|x - \mu\|^2/2\lambda)$).

中心 μ_m 和尺度 λ_m 需要预先选定 (如通过聚类确定中心位置), 然后 θ_m 用最小二乘估计. RBF 网络在低维插值和函数逼近中非常有效, 但在高维中同样受制于维数灾难.

自适应基函数: 单隐层前馈神经网络. 前述所有方法的基函数 $\{h_m\}$ 都是在见到数据之前预先选定的. 神经网络的突破性思想是: 让基函数本身也由数据决定——即基函数含可学习的参数.

单隐层前馈神经网络的形式为:

$$f_{\theta}(x) = \sum_{m=1}^M \beta_m \sigma(\alpha_m^{\top} x + b_m),$$

(10.76)

其中:

- $\sigma(\cdot)$ 是激活函数, 经典选择是 **sigmoid**:

$$\sigma(v) = \frac{1}{1 + e^{-v}};$$

(10.77)

- $\alpha_m \in \mathbb{R}^p$ 和 $b_m \in \mathbb{R}$ 控制第 m 个基函数的形状和位置——它们是从数据中学习的, 而非预先固定;
- β_m 是输出层的权重, 与基展开中的 θ_m 角色相同.

将式 (10.76) 与线性基展开 (10.73) 对比:

	固定基展开	神经网络
基函数	$h_m(x)$ 预先选定	$\sigma(\alpha_m^{\top} x + b_m)$, α_m, b_m 可学习
参数	仅 θ_m (线性)	α_m, b_m, β_m (非线性)
优化	最小二乘有显式解	需迭代优化 (反向传播)
复杂度控制	基函数个数 M	$M +$ 正则化 (权重衰减、早停等)

神经网络的代价是：由于基函数本身含可学习参数，目标函数不再是 θ 的二次函数，无法显式求解，需要迭代数值优化（梯度下降及其变体）。但收益是巨大的——只需适量的 M ，神经网络就能逼近非常复杂的函数，因为每个基函数可以根据数据自适应地调整形状和位置。

限制方法的总览：

方法	限制方式	复杂度旋钮	数学形式
粗糙惩罚/样条	惩罚 f 的曲率	λ （平滑参数）	$\text{RSS} + \lambda J(f)$
核平滑	局部加权平均	λ （带宽）	$\sum K_\lambda(x_0, x_i) y_i / \sum K_\lambda$
k -NN	固定邻域点数	k （邻居数）	$\frac{1}{k} \sum_{x_i \in \mathcal{N}_k(x_0)} y_i$
基展开	限定在 $\{h_m\}$ 张成的空间	M （基函数个数）	$\sum_{m=1}^M \theta_m h_m(x)$
神经网络	自适应基函数	M + 权重衰减	$\sum \beta_m \sigma(\alpha_m^\top x + b_m)$

10.5.11 模型选择与偏差-方差权衡

所有限制估计量方法都有一个复杂度参数（ λ, k, M 等），它控制着模型的灵活度。如何选择这个参数的最优值，是模型选择的核心问题。

偏差-方差分解

在进入 ML 语境下的偏差-方差分解之前，先看一个更基础的概率恒等式——全方差公式（Law of Total Variance）。它不仅本身重要，更是理解”预测误差为什么能拆成偏差和方差”的钥匙。

定理 10.4 (全方差公式 (Law of Total Variance)). 对任意随机变量 X 和 Y ：

$$\text{Var}(X) = \mathbb{E}[\text{Var}(X \mid Y)] + \text{Var}(\mathbb{E}[X \mid Y]).$$

(10.78)

三项的含义（与 ML 的对照将在后面展开）：

项	公式	直觉
总方差	$\text{Var}(X)$	X 本身的全部不确定性
组内方差（期望）	$\mathbb{E}[\text{Var}(X \mid Y)]$	知道了 Y 之后， X 还剩多少波动？
组间方差	$\text{Var}(\mathbb{E}[X \mid Y])$	不同 Y 取值下， X 的均值差异有多大？

直觉：全方差公式说的是—— X 的不确定性来自两个来源：（1）即使你知道 Y ， X 仍然有随机波动（组内方差，不可消除）；（2）不同 Y 下 X 的均值不同（组间方差，这是“规律”部分的差异）。

例 10.5 (一个具体例子). 设 X 是某学生的考试成绩。 Y 是他所属的班级（A 班或 B 班）。

- $\mathbb{E}[\text{Var}(X | Y)]$: 班级确定后，学生在班内的成绩波动——如 A 班内部有人考 70 有人考 90；
- $\text{Var}(\mathbb{E}[X | Y])$: 两个班平均分之间的差异——如 A 班平均 80，B 班平均 72。

全班学生成绩的总方差 = 班内波动的平均 + 班间均值的方差。

全方差公式 → 偏差-方差分解的桥梁.

现在做一步类比替换，全方差公式立刻变成 ML 中的偏差-方差分解：

全方差公式中的量	替换为 ML 中的量	得到
X （被研究的随机变量）	$Y - \hat{f}(x_0)$ （预测误差）	总预测误差的方差
Y （条件变量）	$\mathcal{T}$ （训练集）	以训练集为条件
$\mathbb{E}[X Y]$	$\mathbb{E}_{\mathcal{T}}[Y - \hat{f}(x_0)]$	平均预测误差

代入全方差公式：

$$\text{Var}(Y - \hat{f}(x_0)) = \underbrace{\mathbb{E}_{\mathcal{T}}[\text{Var}(Y - \hat{f}(x_0) | \mathcal{T})]}_{\text{给定训练集后, 预测误差的波动}} + \underbrace{\text{Var}_{\mathcal{T}}(\mathbb{E}[Y - \hat{f}(x_0) | \mathcal{T}])}_{\text{不同训练集下, 平均预测误差的差异}}. \quad (10.79)$$

给定训练集 $\mathcal{T}$ 后， $\hat{f}(x_0)$ 是固定的（模型已经训练好了），而 $Y = f(x_0) + \varepsilon$ ， ε 与 $\mathcal{T}$ 独立。于是第一项展开就是 σ^2 ，第二项展开后分解为 $\text{Bias}^2 + \text{Var}$ 。

下面给出 ML 语境下的标准形式。**推导分两步：先走全方差路径得到 $\text{Var}(Y - \hat{f})$ ，再补上均值平方得到 $\mathbb{E}[(Y - \hat{f})^2]$ 。**

第一步：全方差公式分解 $\text{Var}(Y - \hat{f}(x_0))$ 。

回忆全方差公式 (10.78)，令 $X = Y - \hat{f}(x_0)$ ，条件变量为 $\mathcal{T}$ ：

$$\text{Var}(Y - \hat{f}(x_0)) = \underbrace{\mathbb{E}_{\mathcal{T}}[\text{Var}(Y - \hat{f}(x_0) | \mathcal{T})]}_{\text{①}} + \underbrace{\text{Var}_{\mathcal{T}}(\mathbb{E}[Y - \hat{f}(x_0) | \mathcal{T}])}_{\text{②}}. \quad (10.80)$$

分别化简两项：

化简 ① ——给定 $\mathcal{T}$ 后的条件方差. 给定训练集 $\mathcal{T}$, $\hat{f}(x_0)$ 是一个固定的数 (模型已训练好). 而 $Y = f(x_0) + \varepsilon$, 其中 ε 与 $\mathcal{T}$ 独立, $\text{Var}(\varepsilon) = \sigma^2$:

$$\text{Var}(Y - \hat{f}(x_0) \mid \mathcal{T}) = \text{Var}(f(x_0) + \varepsilon - \hat{f}(x_0) \mid \mathcal{T}) = \text{Var}(\varepsilon \mid \mathcal{T}) = \sigma^2. \quad (10.81)$$

因此 ① = $\mathbb{E}_{\mathcal{T}}[\sigma^2] = \boxed{\sigma^2}$ ——这就是不可约噪声。

化简 ② ——不同训练集下的均值波动. 先求内层期望. $f(x_0)$ 是常数, $\mathbb{E}[\varepsilon] = 0$:

$$\mathbb{E}[Y - \hat{f}(x_0) \mid \mathcal{T}] = f(x_0) + \mathbb{E}[\varepsilon] - \hat{f}(x_0) = f(x_0) - \hat{f}(x_0). \quad (10.82)$$

于是 ② 化为 $\hat{f}(x_0)$ 的方差 ($f(x_0)$ 是常数, 不影响方差):

$$\textcircled{2} = \text{Var}_{\mathcal{T}}(f(x_0) - \hat{f}(x_0)) = \text{Var}_{\mathcal{T}}(\hat{f}(x_0)). \quad (10.83)$$

综上, 全方差公式给出:

$$\boxed{\text{Var}(Y - \hat{f}(x_0)) = \sigma^2 + \text{Var}_{\mathcal{T}}(\hat{f}(x_0))}. \quad (10.84)$$

第二步: 从方差到期望平方误差.

方差和期望平方误差之间差了一个”均值平方”:

$$\mathbb{E}[(Y - \hat{f})^2] = \underbrace{(\mathbb{E}[Y - \hat{f}])^2}_{\text{均值}^2} + \text{Var}(Y - \hat{f}). \quad (10.85)$$

先算均值 (对训练集的期望 + 对 Y 的期望):

$$\mathbb{E}[Y - \hat{f}(x_0)] = \mathbb{E}_{\mathcal{T}}[\mathbb{E}[Y - \hat{f}(x_0) \mid \mathcal{T}]] = \mathbb{E}_{\mathcal{T}}[f(x_0) - \hat{f}(x_0)] = f(x_0) - \mathbb{E}_{\mathcal{T}}[\hat{f}(x_0)]. \quad (10.86)$$

均值平方项恰好是偏差²:

$$(\mathbb{E}[Y - \hat{f}])^2 = (f(x_0) - \mathbb{E}_{\mathcal{T}}[\hat{f}(x_0)])^2 = \text{偏差}^2. \quad (10.87)$$

合并两步:

$$\begin{aligned} \mathbb{E}_{\mathcal{T}}[(Y - \hat{f}(x_0))^2 \mid X = x_0] &= (f(x_0) - \mathbb{E}_{\mathcal{T}}[\hat{f}(x_0)])^2 + \text{Var}(Y - \hat{f}(x_0)) \\ &= (f(x_0) - \mathbb{E}_{\mathcal{T}}[\hat{f}(x_0)])^2 + \sigma^2 + \text{Var}_{\mathcal{T}}(\hat{f}(x_0)) \\ &= \text{偏差}^2 + \sigma^2 + \text{方差}. \end{aligned} \quad (10.88)$$

推导的核心链条:

$$\underbrace{\text{Var}(Y - \hat{f})}_{\text{全方差分解}} = \underbrace{\mathbb{E}[\text{Var}(\cdot \mid \mathcal{T})]}_{=\sigma^2} + \underbrace{\text{Var}(\mathbb{E}[\cdot \mid \mathcal{T}])}_{=\text{Var}(\hat{f})} \xrightarrow{+ (\mathbb{E}[Y - \hat{f}])^2} \underbrace{\mathbb{E}[(Y - \hat{f})^2]}_{\text{EPE}} = \underbrace{(f - \mathbb{E}[\hat{f}])^2}_{\text{偏差}^2} + \underbrace{\text{Var}(\hat{f})}_{\text{方差}} + \underbrace{\sigma^2}_{\text{噪声}}$$

定理 10.5 (偏差-方差分解). 设 $Y = f(X) + \varepsilon$, $\mathbb{E}[\varepsilon] = 0$, $\text{Var}(\varepsilon) = \sigma^2$. 对于在训练集 $\mathcal{T}$ 上拟合的模型 $\hat{f}(x_0)$, 在测试点 x_0 处的期望预测误差为:

$$\mathbb{E}_{\mathcal{T}}[(Y - \hat{f}(x_0))^2 | X = x_0] = \underbrace{(f(x_0) - \mathbb{E}_{\mathcal{T}}[\hat{f}(x_0)])^2}_{\text{偏差}^2} + \underbrace{\mathbb{E}_{\mathcal{T}}[(\hat{f}(x_0) - \mathbb{E}_{\mathcal{T}}[\hat{f}(x_0)])^2]}_{\text{方差}} + \underbrace{\sigma^2}_{\text{不可约噪声}}. \quad (10.89)$$

其中 $\mathbb{E}_{\mathcal{T}}[\cdot]$ 是对不同训练集（从同一分布重复抽样）取期望——典型的频率学派视角。三项的含义:

- **偏差 (Bias²)**: 即使有无穷多训练集, 模型平均预测与真实值差多远。衡量模型族本身的表达能力是否足够;
- **方差 (Variance)**: 换一组训练集, 预测值波动多大。衡量模型对训练数据的敏感度;
- **不可约噪声 (σ^2)**: 数据本身固有的随机性, 与模型无关, 是任何预测器的误差下界。

偏差与方差不可兼得:

- 简单模型 (高偏差, 低方差): 模型族不够灵活, 系统地偏离真实函数, 但对训练数据的扰动不敏感——欠拟合;
- 复杂模型 (低偏差, 高方差): 模型族足够灵活, 可以逼近任意函数, 但不同训练集会给出差异很大的估计——过拟合。

k -NN 的偏差-方差分析

k -最近邻回归为偏差-方差分解提供了一个清晰的实例。在 x_0 处, $\hat{f}_k(x_0) = \frac{1}{k} \sum_{\ell=1}^k y_{(\ell)}$, 其中 $y_{(\ell)}$ 是 x_0 的第 ℓ 近邻的标签。假设 $y_i = f(x_i) + \varepsilon_i$, ε_i 独立且 $\text{Var}(\varepsilon_i) = \sigma^2$:

$$\begin{aligned} \text{EPE}_k(x_0) &= \mathbb{E}[(Y - \hat{f}_k(x_0))^2 | X = x_0] \\ &= \sigma^2 + \underbrace{\left(f(x_0) - \frac{1}{k} \sum_{\ell=1}^k f(x_{(\ell)})\right)^2}_{\text{偏差}^2} + \underbrace{\frac{\sigma^2}{k}}_{\text{方差}}. \end{aligned} \quad (10.90)$$

这个分解非常直观:

- **偏差**: $\hat{f}_k(x_0)$ 的期望是 k 个近邻真实函数值的平均。若 f 在该邻域内不是常数, 这个平均值偏离 $f(x_0)$ —— k 越大, 邻域越大, f 在邻域内变化越大, 偏差越大;
- **方差**: k 个独立噪声的平均, 方差为 σ^2/k —— k 越大, 平均越多, 方差越小。

k 的角色:

- k 小 (如 $k = 1$): 偏差小 (只用最近邻, 其 f 值最接近 $f(x_0)$), 但方差大 ($\sigma^2/1 = \sigma^2$, 没有任何平均) —— 过拟合;
- k 大 (如 $k = N$): 方差小 ($\sigma^2/N \approx 0$), 但偏差大 (所有点的平均 $\approx \mathbb{E}[Y]$, 与 $f(x_0)$ 无关) —— 欠拟合;
- 最优的 k 在两者之间取得平衡。

对照全方差公式解读 k -NN 的分解. 将式 (10.90) 与全方差公式 (10.78) 逐项对照:

$$\text{Var}(Y - \hat{f}_k(x_0)) = \underbrace{\mathbb{E}_{\mathcal{T}}[\text{Var}(Y - \hat{f}_k(x_0) | \mathcal{T})]}_{=\sigma^2} + \underbrace{\text{Var}_{\mathcal{T}}(\mathbb{E}[Y - \hat{f}_k(x_0) | \mathcal{T}])}_{=\text{Bias}^2 + \frac{\sigma^2}{k}}.$$

- 组内方差 $\mathbb{E}[\text{Var}(\cdot | \mathcal{T})] = \sigma^2$: 给定训练集 (即固定了 k 个近邻的位置) 后, 预测误差的唯一随机来源是 $Y = f(x_0) + \varepsilon$ 中的 ε ——其方差为 σ^2 。这就是”不可约噪声”——与 k 无关、与模型无关;
- 组间方差 $\text{Var}(\mathbb{E}[\cdot | \mathcal{T}]) = \text{Bias}^2 + \frac{\sigma^2}{k}$: 不同训练集会选出不同的 k 个近邻, 导致 $\hat{f}_k(x_0)$ 的平均值发生变化。这个变化来自两个来源:
 - 偏差部分: 不同训练集的 k 个近邻位置不同, 其 f 值的平均也不同——离 $f(x_0)$ 的平均距离就是偏差;
 - 方差部分: 不同训练集的 ε_i 不同, 导致 $\frac{1}{k} \sum \varepsilon_i$ 波动——这就是 $\frac{\sigma^2}{k}$ 。

k 控制组间方差的结构:

- k 很小: $\frac{\sigma^2}{k}$ 很大 (噪声平均不够), 组间方差主要由噪声主导 $\rightarrow$ 过拟合;
- k 很大: $\frac{\sigma^2}{k} \rightarrow 0$ (噪声被充分平均), 但偏差部分增大 (邻域太大, 邻近的 f 值不再与 $f(x_0)$ 接近) $\rightarrow$ 欠拟合。

全方差公式在这里的作用是: 把”为什么 k 太大或太小都不好”这个直觉, 精确地分解为两个可量化部分——组内 (不可消除的噪声) 和组间 (偏差 + 方差)。

训练误差 vs. 测试误差

关键观察:

- 训练误差随模型复杂度增加而单调递减——不能单独用训练误差选择模型 (否则永远选最复杂的);
- 测试误差呈 U 形——这是模型选择的核心依据;
- 测试误差的最低点对应最优模型复杂度——在偏差和方差之间取得最佳平衡。




图 10.2: 训练误差与测试误差随模型复杂度的典型变化。训练误差（蓝色）随复杂度增加单调递减——越复杂的模型越能拟合训练数据。测试误差（红色）呈 U 形曲线：模型太简单时高偏差主导（欠拟合），模型太复杂时高方差主导（过拟合），最优复杂度在两者之间。虚线 σ^2 是不可约噪声的下界。

模型选择的实践方法

直接使用测试集来选模型会导致对测试误差的乐观估计（因为你本质上是用测试集来“训练”超参数）。实践中常用以下方法：

- (1) **留出法 (Hold-out)**：将数据划分为训练集和验证集，用验证集选择复杂度参数，最后在测试集上报告性能；
- (2) **K 折交叉验证 (K -fold CV)**：将数据分为 K 份，每次用 $K - 1$ 份训练、1 份验证，轮换 K 次后取平均；
- (3) **信息准则**：AIC、BIC 等在训练误差上加一项对复杂度的惩罚，避免需要单独的验证集（但这些准则通常依赖特定的概率模型假设）。

核心教训：

训练集上的表现 $\neq$ 泛化能力

泛化能力——在未见过的数据上的表现——才是统计学习的终极目标。偏差-方差分解为理解和诊断泛化问题提供了数学框架，而复杂度参数的选择（ λ , k , M 等）正是控制偏差-方差权衡的旋钮。

10.5.12 总结：从模型到估计的统一框架

下图总结了统计学习从建模、估计到模型选择的完整逻辑链条：

$$\underbrace{Y = f(X) + \varepsilon}_{\text{加性误差模型}} \xrightarrow{\mathbb{E}[\cdot|X]} \underbrace{f(x) = \mathbb{E}[Y | X = x]}_{\text{条件期望是最优预测}} \xrightarrow{\text{参数化}} \underbrace{f_{\theta}(x) = \sum_{k=1}^K h_k(x) \theta_k}_{\text{基展开 / 函数逼近}}$$

↓ 如何估计 θ ?

$$\left\{ \begin{array}{l} \text{LS (ERM): } \min_{\theta} \underbrace{\frac{1}{N} \sum_{i=1}^N (y_i - f_{\theta}(x_i))^2}_{\text{经验风险} \approx \text{EPE}} \\ \text{MLE: } \max_{\theta} \underbrace{\sum_{i=1}^N \log \Pr_{\theta}(y_i | x_i)}_{\text{条件对数似然}} \end{array} \right.$$

↓ LS 与 MLE 的关系

正态误差	MLE $\Leftrightarrow$ 最小二乘
多项分布 (分类)	MLE $\Leftrightarrow$ 交叉熵

↓ 无约束 RSS 最小化的困境

RSS = 0 有无穷多解，全都没有泛化能力 $\xrightarrow{\text{必须限制}}$ 对 f 施加约束

↓ 三类限制方法

$$\left\{ \begin{array}{l} \text{粗糙惩罚: } \min_f \text{RSS}(f) + \lambda J(f) \quad (\lambda \text{ 控制光滑度}) \\ \text{核/局部方法: } \hat{f}(x_0) = \frac{\sum K_{\lambda}(x_0, x_i) y_i}{\sum K_{\lambda}(x_0, x_i)} \quad (\lambda \text{ 控制邻域大小}) \\ \text{基展开/字典: } f_{\theta}(x) = \sum_{m=1}^M \theta_m h_m(x) \quad (M \text{ 控制模型容量}) \end{array} \right.$$

↓ 如何选择复杂度参数?

$$\text{EPE} = \underbrace{\text{Bias}^2}_{\text{模型太简单} \uparrow} + \underbrace{\text{Var}}_{\text{模型太复杂} \uparrow} + \underbrace{\sigma^2}_{\text{不可约}} \xrightarrow{\text{权衡}} \text{交叉验证 / 信息准则选择 } \lambda, k, M$$

核心要点:

- (1) **加性误差模型** $Y = f(X) + \varepsilon$ ($\mathbb{E}[\varepsilon] = 0, \varepsilon \perp X$) 是统计学习最基本的建模假设, $f(x) = \mathbb{E}[Y | X = x]$ 是平方损失下的最优预测器;
- (2) **条件方差** $\text{Var}(Y | X = x) = \sigma^2(x)$ 可以依赖于 x , 模型只约束了一阶矩, 对二阶矩没有限制;
- (3) **监督学习的本质**是从训练集 $\mathcal{T} = \{(x_i, y_i)\}$ 中学出一个函数 $\hat{f}$, 使其在未知数据上也能良好泛化;
- (4) **函数逼近**将学习问题视为在 $\mathbb{R}^{p+1}$ 空间中拟合曲面。线性基展开 $f_{\theta}(x) = \sum_k h_k(x) \theta_k$ 是连接线性模型与神经网络等复杂模型的桥梁;

- (5) **LS 是 ERM，不是直接最小化 EPE。** $RSS(\theta) = \sum (y_i - f_\theta(x_i))^2$ 是训练集上的经验平均， $N \rightarrow \infty$ 时收敛到真实的 EPE。MLE 在正态误差下与 LS 等价，在分类问题中与交叉熵等价——**MLE 是比 LS 更统一的参数估计框架**；
- (6) **无约束最小化 RSS 必然失败。**任何穿过所有训练点的函数都满足 $RSS = 0$ ，但这样的函数有无穷多个且全无泛化能力。**必须限制候选函数的范围**——这是所有正则化方法的根本动机；
- (7) **三类经典的限制方法：**
- **粗糙惩罚** ($RSS + \lambda J(f)$)：惩罚函数的曲率， λ 控制光滑度，等价于贝叶斯框架中的先验分布；
 - **核方法与局部回归**：用邻域内的加权平均做预测，带宽/邻居数控制局部范围；
 - **基展开与字典方法**：将 f 限制在一组基函数张成的空间中，神经网络将固定基推广为自适应基（基函数本身也由数据学习）。
- (8) **偏差-方差权衡是模型选择的核心。** $EPE = \text{Bias}^2 + \text{Var} + \sigma^2$ 。简单模型高偏差低方差（欠拟合），复杂模型低偏差高方差（过拟合）。复杂度参数 (λ, k, M) 正是控制这一权衡的旋钮，最优值通过交叉验证等方法选取；
- (9) **泛化能力是终极目标。**训练误差随模型复杂度单调递减，不能用于模型选择。测试误差呈 U 形曲线——统计学习的核心挑战是在偏差和方差之间找到最优平衡点。

第十一章 线性回归模型与最小二乘法

11.1 引言：为什么从线性模型开始

线性回归是统计学习中最基础、最经典的监督学习方法。尽管看起来简单，但它具备几个重要优势：

- **简单性与可解释性：**模型参数直接对应每个特征对输出的线性贡献，易于理解和沟通；
- **低信噪比与小样本场景：**当数据量小或信噪比低时，简单线性模型往往比复杂模型表现更好（偏差-方差权衡）；
- **稀疏数据：**在高维稀疏设定下，带正则化的线性模型（如 Lasso）仍是 SOTA 方法之一；
- **基展开的基石：**通过基函数变换，线性模型可以扩展到非线性关系——样条、核方法、神经网络（最后一层）本质上都是线性模型的推广。

线性回归模型的核心假设是：回归函数 $\mathbb{E}[Y | X]$ 是输入 $X_1, \dots, X_p$ 的线性函数。尽管这个假设几乎从来不是精确成立的，但由于上述原因，它仍然是一个非常实用的出发点。

11.2 线性回归模型

11.2.1 模型形式

定义 11.1 (线性回归模型). 给定输入向量 $X = (X_1, X_2, \dots, X_p)^\top \in \mathbb{R}^p$ ，线性回归模型将输出 $Y \in \mathbb{R}$ 建模为输入的线性组合：

$$f(X) = \beta_0 + \sum_{j=1}^p X_j \beta_j. \quad (11.1)$$

其中 β_0 为截距项 (intercept), β_j ($j = 1, \dots, p$) 为系数 (coefficients) 或权重 (weights)。

11.2.2 输入的来源

线性模型中的 X_j 可以有多种来源，不限于原始测量值：

- (1) **定量输入 (Quantitative inputs)**: 原始连续变量，如温度、年龄、收入；
- (2) **定量输入的变换 (Transformations)**: 如 $\log X$ 、 $\sqrt{X}$ 、 X^2 等，用于捕捉非线性效应；
- (3) **基展开 (Basis expansions)**: 如 $X_2 = X_1^2$ 、 $X_3 = X_1^3$ ，将输入映射到一组基函数上，产生多项式回归；
- (4) **哑变量编码 (Dummy coding)**: 将定性（类别）变量转化为 0/1 指示变量。例如，有 K 个水平的类别变量需要 $K - 1$ 个哑变量（或 K 个哑变量但去掉截距）；
- (5) **交互项 (Interactions)**: 如 $X_3 = X_1 \cdot X_2$ ，用于捕捉变量之间的交互效应。

核心思想: 无论 X_j 是如何构造的，模型关于参数 β_j 始终是线性的。这意味着 $f(X)$ 是 β 的线性函数，尽管它可以是 X 的非线性函数。例如， $f(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_1^2 + \beta_3 X_1 X_2$ 对 X 是非线性的，但对 β 仍是线性的。

11.2.3 矩阵记号

为简洁起见，通常用矩阵记号表示。设训练数据为 $\{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ ，其中 $x_i = (x_{i1}, x_{i2}, \dots, x_{ip})^\top$ 为第 i 个样本的特征向量。

将截距项纳入设计矩阵：

$$\mathbf{X}_{N \times (p+1)} = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{N1} & x_{N2} & \cdots & x_{Np} \end{pmatrix}, \quad \boldsymbol{\beta}_{(p+1) \times 1} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}, \quad \mathbf{y}_{N \times 1} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix}. \quad (11.2)$$

则线性模型写为：

$$\hat{\mathbf{y}} = \mathbf{X}\boldsymbol{\beta}. \quad (11.3)$$

其中 $\hat{y}_i = f(x_i) = \beta_0 + \sum_{j=1}^p x_{ij}\beta_j$ 为第 i 个样本的预测值。

11.3 最小二乘估计

11.3.1 残差平方和

定义 11.2 (残差平方和 (Residual Sum of Squares, RSS)). 给定训练数据, 参数 β 的残差平方和定义为:

$$\text{RSS}(\beta) = \sum_{i=1}^N (y_i - f(x_i))^2 = \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2. \quad (11.4)$$

定义 11.3 (最小二乘估计 (Least Squares Estimator)). 最小二乘法选择使 RSS 最小的参数:

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^{p+1}} \text{RSS}(\beta). \quad (11.5)$$

从 ERM 角度看: 平方损失 $L(y, f(x)) = (y - f(x))^2$ 下的 ERM 正是最小二乘法。因此, LS 是平方损失下的经验风险最小化器。

11.3.2 矩阵形式的解

用矩阵记号, RSS 可写为:

$$\text{RSS}(\beta) = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta) = \|\mathbf{y} - \mathbf{X}\beta\|^2. \quad (11.6)$$

对 β 求导并令其为零, 即可得到最小化 RSS 的 $\hat{\beta}$ 。下面给出两种完整的求导方式——矩阵微积分形式和 Einstein 求和形式——并逐行标注每一步的依据。

方式一: 矩阵微积分求导

Step 1 — 展开 RSS.

$$\begin{aligned} \text{RSS}(\beta) &= (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta) \\ &= \mathbf{y}^\top \mathbf{y} - \mathbf{y}^\top \mathbf{X}\beta - \beta^\top \mathbf{X}^\top \mathbf{y} + \beta^\top \mathbf{X}^\top \mathbf{X}\beta. \end{aligned} \quad (11.7)$$

注: $(\mathbf{X}\beta)^\top \mathbf{y} = \beta^\top \mathbf{X}^\top \mathbf{y}$ 是一个标量, 标量的转置等于自身, 故 $\mathbf{y}^\top \mathbf{X}\beta = \beta^\top \mathbf{X}^\top \mathbf{y}$, 两项合并为 $2\beta^\top \mathbf{X}^\top \mathbf{y}$:

$$\text{RSS}(\beta) = \mathbf{y}^\top \mathbf{y} - 2\beta^\top \mathbf{X}^\top \mathbf{y} + \beta^\top \mathbf{X}^\top \mathbf{X}\beta. \quad (11.8)$$

Step 2 — 逐项对 β 求导.

需要对向量 $\beta \in \mathbb{R}^{p+1}$ 对标量函数 $f(\beta)$ 求梯度:

$$\frac{\partial f}{\partial \beta} = \left(\frac{\partial f}{\partial \beta_0}, \frac{\partial f}{\partial \beta_1}, \dots, \frac{\partial f}{\partial \beta_p} \right)^\top \in \mathbb{R}^{p+1}.$$

结果是一个列向量 (分母布局 / denominator layout)。

第一项: $\mathbf{y}^\top \mathbf{y}$

$\mathbf{y}^\top \mathbf{y} = \sum_{i=1}^N y_i^2$ 是常数, 不含 β :

$$\frac{\partial}{\partial \beta} (\mathbf{y}^\top \mathbf{y}) = \mathbf{0}.$$

依据: 常数的导数为零。

第二项: $-2\beta^\top \mathbf{X}^\top \mathbf{y}$

令 $\mathbf{a} = \mathbf{X}^\top \mathbf{y} \in \mathbb{R}^{p+1}$ (常向量), 则 $-2\beta^\top \mathbf{a} = -2 \sum_{j=0}^p \beta_j a_j$ 。

对每个分量 β_j :

$$\frac{\partial}{\partial \beta_j} (-2 \sum_k \beta_k a_k) = -2a_j.$$

因此:

$$\frac{\partial}{\partial \beta} (-2\beta^\top \mathbf{X}^\top \mathbf{y}) = -2\mathbf{X}^\top \mathbf{y}.$$

依据: $\frac{\partial}{\partial \mathbf{x}} (\mathbf{x}^\top \mathbf{a}) = \frac{\partial}{\partial \mathbf{x}} (\mathbf{a}^\top \mathbf{x}) = \mathbf{a}$ (分母布局)。

第三项: $\beta^\top \mathbf{X}^\top \mathbf{X} \beta$

令 $\mathbf{A} = \mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{(p+1) \times (p+1)}$, 则此项为二次型 $\beta^\top \mathbf{A} \beta$ 。

展开:

$$\beta^\top \mathbf{A} \beta = \sum_{j=0}^p \sum_{k=0}^p \beta_j A_{jk} \beta_k.$$

对分量 β_m 求偏导:

$$\begin{aligned} \frac{\partial}{\partial \beta_m} (\beta^\top \mathbf{A} \beta) &= \frac{\partial}{\partial \beta_m} \sum_j \sum_k \beta_j A_{jk} \beta_k \\ &= \sum_j \sum_k \frac{\partial}{\partial \beta_m} (\beta_j A_{jk} \beta_k) \\ &= \sum_j \sum_k (\delta_{jm} A_{jk} \beta_k + \beta_j A_{jk} \delta_{km}) \\ &= \sum_k A_{mk} \beta_k + \sum_j \beta_j A_{jm} \\ &= (\mathbf{A} \beta)_m + (\mathbf{A}^\top \beta)_m. \end{aligned} \tag{11.9}$$

由于 $\mathbf{A} = \mathbf{X}^\top \mathbf{X}$ 是对称矩阵 ($\mathbf{A}^\top = \mathbf{A}$), 故:

$$\frac{\partial}{\partial \beta} (\beta^\top \mathbf{X}^\top \mathbf{X} \beta) = 2\mathbf{X}^\top \mathbf{X} \beta.$$

依据: $\frac{\partial}{\partial \mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$ (分母布局), 若 $\mathbf{A}$ 对称则为 $2\mathbf{A} \mathbf{x}$ 。

Step 3 — 合并并令其为零。

将三项导数相加：

$$\begin{aligned}\frac{\partial \text{RSS}}{\partial \boldsymbol{\beta}} &= \mathbf{0} - 2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X}\boldsymbol{\beta} \\ &= -2\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) = \mathbf{0}.\end{aligned}\quad (11.10)$$

Step 4 — 正规方程及其解.

令导数为零，得到正规方程 (normal equations)：

$$\mathbf{X}^\top \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}.\quad (11.11)$$

若 $\mathbf{X}^\top \mathbf{X}$ 可逆，则：

$$\boxed{\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}}.\quad (11.12)$$

方式二：Einstein 求和约定 (Einstein Summation)

Einstein 求和约定：当一个指标在同一项中出现两次时，默认对该指标求和，省略 $\sum$ 符号。例如 $a_i b_i \equiv \sum_i a_i b_i$ ， $X_{ij} \beta_j \equiv \sum_j X_{ij} \beta_j$ 。

用 Einstein 记号重写 RSS：

$$\text{RSS}(\boldsymbol{\beta}) = (y_i - X_{ij} \beta_j)(y_i - X_{ik} \beta_k).\quad (11.13)$$

展开（注意指标命名需区分，两个括号用不同的哑指标 j 和 k ）：

$$\begin{aligned}\text{RSS} &= (y_i - X_{ij} \beta_j)(y_i - X_{ik} \beta_k) \\ &= y_i y_i - y_i X_{ik} \beta_k - X_{ij} \beta_j y_i + X_{ij} \beta_j X_{ik} \beta_k \\ &= y_i y_i - 2X_{ij} \beta_j y_i + X_{ij} \beta_j X_{ik} \beta_k.\end{aligned}\quad (11.14)$$

这里约定： i 遍历 $1, \dots, N$ （样本）， j, k 遍历 $0, \dots, p$ （参数，含截距），其中 $X_{i0} \equiv 1$ （截距列）。

对 β_m 求偏导：

$$\begin{aligned}\frac{\partial}{\partial \beta_m}(y_i y_i) &= 0 \quad (\text{常数项}) \\ \frac{\partial}{\partial \beta_m}(-2X_{ij} \beta_j y_i) &= -2X_{ij} \delta_{jm} y_i = -2X_{im} y_i \quad \left(\frac{\partial \beta_j}{\partial \beta_m} = \delta_{jm}\right) \\ \frac{\partial}{\partial \beta_m}(X_{ij} \beta_j X_{ik} \beta_k) &\text{。用乘积法则：}\end{aligned}$$

$$\begin{aligned}\frac{\partial}{\partial \beta_m}(X_{ij} \beta_j X_{ik} \beta_k) &= X_{ij} \delta_{jm} X_{ik} \beta_k + X_{ij} \beta_j X_{ik} \delta_{km} \\ &= X_{im} X_{ik} \beta_k + X_{ij} \beta_j X_{im} \\ &= 2X_{im} X_{ik} \beta_k.\end{aligned}\quad (11.15)$$

（最后一步利用了 j, k 都是哑指标，两项相等。）

合并：

$$\frac{\partial \text{RSS}}{\partial \beta_m} = 0 - 2X_{im}y_i + 2X_{im}X_{ik}\beta_k = 0. \quad (11.16)$$

两边除以 2 并移项：

$$X_{im}X_{ik}\beta_k = X_{im}y_i. \quad (11.17)$$

回到矩阵形式： $X_{im}X_{ik}$ 就是 $(\mathbf{X}^\top \mathbf{X})_{mk}$ ， $X_{im}y_i$ 就是 $(\mathbf{X}^\top \mathbf{y})_m$ 。对每个 m ：

$$(\mathbf{X}^\top \mathbf{X})_{mk} \hat{\beta}_k = (\mathbf{X}^\top \mathbf{y})_m \iff \mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}.$$

这正是正规方程。若 $\mathbf{X}^\top \mathbf{X}$ 可逆，则 $\hat{\beta}_k = (\mathbf{X}^\top \mathbf{X})_{km}^{-1} (\mathbf{X}^\top \mathbf{y})_m$ 。

两种方式的对比

	矩阵微积分	Einstein 求和
表达形式	$\mathbf{X}, \boldsymbol{\beta}, \mathbf{y}$ 整体运算	X_{ij}, β_j, y_i 分量运算
RSS	$(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$	$(y_i - X_{ij}\beta_j)(y_i - X_{ik}\beta_k)$
求导法则	$\frac{\partial}{\partial \mathbf{x}}(\mathbf{x}^\top \mathbf{a}) = \mathbf{a}, \quad \frac{\partial}{\partial \mathbf{x}}(\mathbf{x}^\top \mathbf{A}\mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top)\mathbf{x}$	$\frac{\partial \beta_j}{\partial \beta_m} = \delta_{jm}$ (Kronecker delta), 乘法法则逐分量计算
优势	简洁紧凑, 适合公式推导和编程实现	每个分量显式可见, 适合手算和初学者理解
正规方程	$\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}$	$X_{im}X_{ik}\hat{\beta}_k = X_{im}y_i$
解的矩阵形式	$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$	$\hat{\beta}_k = (\mathbf{X}^\top \mathbf{X})_{km}^{-1} X_{im}y_i$

一句话总结：矩阵微积分是“整体算”，Einstein 是“分量算”——两者指向同一个正规方程。用哪种取决于场景：编程/论文用矩阵形式，手算/验证用 Einstein 形式。

11.3.3 拟合值与 Hat Matrix

定义 11.4 (拟合值). 将 $\hat{\boldsymbol{\beta}}$ 代入模型，得到训练集上的拟合值：

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}. \quad (11.18)$$

定义 11.5 (Hat Matrix (帽子矩阵)). 定义:

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top, \quad (11.19)$$

则 $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ 。矩阵 $\mathbf{H}$ 将观测向量 $\mathbf{y}$ “投射”为拟合值向量 $\hat{\mathbf{y}}$ ，因此也称为投影矩阵 (projection matrix)。

11.3.4 几何解释

最小二乘拟合有清晰的几何意义:

- $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ 是 $\mathbf{y}$ 在 $\mathbf{X}$ 的列空间 (column space) 上的正交投影;
- 残差向量 $\hat{\boldsymbol{\varepsilon}} = \mathbf{y} - \hat{\mathbf{y}} = (\mathbf{I} - \mathbf{H})\mathbf{y}$ 与 $\mathbf{X}$ 的列空间正交:

$$\mathbf{X}^\top (\mathbf{y} - \hat{\mathbf{y}}) = \mathbf{X}^\top (\mathbf{I} - \mathbf{H})\mathbf{y} = \mathbf{0}. \quad (11.20)$$

- $\mathbf{H}$ 是幂等矩阵 (idempotent): $\mathbf{H}^2 = \mathbf{H}$, 且对称: $\mathbf{H}^\top = \mathbf{H}$;
- $\mathbf{H}$ 的迹等于其秩: $\text{tr}(\mathbf{H}) = p + 1$ (参数个数)。

注记 11.1 ($\mathbf{X}^\top \mathbf{X}$ 不可逆时). 当 $\mathbf{X}$ 的列线性相关 (如 $p > N$ 或存在完全共线性) 时, $\mathbf{X}^\top \mathbf{X}$ 奇异, 正规方程有无穷多解。此时需要通过正则化 (如岭回归) 或伪逆来获得唯一解。

11.4 估计量的抽样性质

为了讨论 $\hat{\boldsymbol{\beta}}$ 的统计性质, 需要对数据的生成机制做出假设。

11.4.1 一阶矩与二阶矩的假设

定义 11.6 (一阶与二阶矩假设). 假设观测值 y_i 满足:

$$\mathbb{E}[Y | X = x_i] = \beta_0 + \sum_{j=1}^p x_{ij}\beta_j, \quad (11.21)$$

$$\text{Var}(Y | X = x_i) = \sigma^2, \quad (11.22)$$

$$\text{Cov}(y_i, y_j) = 0 \quad (i \neq j). \quad (11.23)$$

即: 线性模型正确设定, 误差有常数方差 (同方差性), 且不同观测的误差不相关。

用 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ 理解三个假设

上面三条假设直接写在 y_i 上，但更直观的方式是引入误差项 ε ，把数据生成过程显式写出来，然后看每条假设到底在约束谁。

数据生成模型：

$$\underset{N \times 1}{\mathbf{y}} = \underset{N \times (p+1)}{\mathbf{X}} \underset{(p+1) \times 1}{\boldsymbol{\beta}} + \underset{N \times 1}{\boldsymbol{\varepsilon}}. \quad (11.24)$$

即对每个观测 $i = 1, \dots, N$ ：

$$y_i = \underbrace{\beta_0 + \sum_{j=1}^p x_{ij}\beta_j}_{\text{信号 (系统部分)}} + \underbrace{\varepsilon_i}_{\text{噪声 (随机部分)}}.$$

涉及四个量，各自的性质：

量	符号	维度	是随机的吗？
设计矩阵	$\mathbf{X}$	$N \times (p+1)$	$\times$ 固定（固定设计下， x_{ij} 是已知常数）
真实参数	$\boldsymbol{\beta}$	$(p+1) \times 1$	$\times$ 固定（未知但不变的常数，是我们要估计的目标）
误差项	$\boldsymbol{\varepsilon}$	$N \times 1$	$\checkmark$ 随机（不可观测的噪声，所有随机性的 唯一来源 ）
响应变量	$\mathbf{y}$	$N \times 1$	$\checkmark$ 随机（ $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ ，随 $\boldsymbol{\varepsilon}$ 而变）

核心认知：在固定设计下， $\mathbf{X}$ 和 $\boldsymbol{\beta}$ 都不是随机变量——数据中唯一在变的东西是噪声 $\boldsymbol{\varepsilon}$ 。 $\mathbf{y}$ 之所以是随机的，完全因为 $\boldsymbol{\varepsilon}$ 是随机的。因此，对 $\mathbf{y}$ 的三条假设本质上就是对 $\boldsymbol{\varepsilon}$ 的三条约束。

逐条翻译：

假设 1：线性均值假设 $\mathbb{E}[Y \mid X = x_i] = \beta_0 + \sum_{j=1}^p x_{ij}\beta_j$

- 代入 $y_i = x_i^\top \boldsymbol{\beta} + \varepsilon_i$ ：

$$\mathbb{E}[x_i^\top \boldsymbol{\beta} + \varepsilon_i \mid X = x_i] = x_i^\top \boldsymbol{\beta} + \mathbb{E}[\varepsilon_i \mid X = x_i] = x_i^\top \boldsymbol{\beta}.$$

- 因此等价于：

$$\boxed{\mathbb{E}[\varepsilon_i \mid X = x_i] = 0}.$$

- 含义：**噪声 ε_i 的条件期望为零。给定 x_i 后，误差没有系统性偏差——信号 $x_i^\top \boldsymbol{\beta}$ 已经捕获了 y_i 的全部系统变化，剩下的只是均值为零的随机扰动。

- **如果违反：** $\mathbb{E}[\varepsilon_i | X] \neq 0$ 意味着模型遗漏了与 X 相关的系统成分（如漏掉了重要的 X_{p+1} ，或真实关系是非线性的），此时 $\hat{\beta}$ 不再收敛到任何有意义的量。

假设 2：同方差假设 $\text{Var}(Y | X = x_i) = \sigma^2$

- 代入 $y_i = x_i^\top \beta + \varepsilon_i$ ：

$$\text{Var}(y_i | X = x_i) = \text{Var}(x_i^\top \beta + \varepsilon_i | X = x_i) = \text{Var}(\varepsilon_i | X = x_i).$$

（ $x_i^\top \beta$ 是常数，不影响方差。）

- 因此等价于：

$$\boxed{\text{Var}(\varepsilon_i | X = x_i) = \sigma^2, \quad \text{对所有 } i.}$$

- **含义：** 噪声的波动幅度是常数 σ^2 ，不随 x_i 变化。无论 x_i 取什么值， y_i 在回归线周围的散布程度都一样。
- **如果违反（异方差）：** 比如 x_i 大时 y_i 波动也大（金融数据中常见），LS 仍然无偏，但不再是最优的——加权最小二乘（WLS）会更好。异方差下 $\hat{\beta}$ 的标准误公式也会失效。

假设 3：不相关假设 $\text{Cov}(y_i, y_j) = 0 \ (i \neq j)$

- 代入 $y_i = x_i^\top \beta + \varepsilon_i$ ：

$$\text{Cov}(y_i, y_j | \mathbf{X}) = \text{Cov}(x_i^\top \beta + \varepsilon_i, x_j^\top \beta + \varepsilon_j | \mathbf{X}) = \text{Cov}(\varepsilon_i, \varepsilon_j | \mathbf{X}).$$

- 因此等价于：

$$\boxed{\text{Cov}(\varepsilon_i, \varepsilon_j | \mathbf{X}) = 0, \quad i \neq j.}$$

- **含义：** 不同观测的噪声互不相关。知道 ε_1 不能提供任何关于 ε_2 的信息。
- **如果违反（自相关）：** 常见于时间序列数据（今天的误差与昨天的相关）、空间数据（邻近点的误差相关）、重复测量数据（同一个体的多次测量）。此时 LS 仍然无偏，但方差公式 $(\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2$ 不再正确，需要用稳健标准误（sandwich estimator）或广义最小二乘（GLS）。

三条约束的矩阵统一形式：

三条合在一起，可以简洁地写成 ε 的一阶矩和二阶矩条件：

$$\boxed{\mathbb{E}[\varepsilon | \mathbf{X}] = \mathbf{0}, \quad \text{Var}(\varepsilon | \mathbf{X}) = \sigma^2 \mathbf{I}_N.} \quad (11.25)$$

等价地：

$$\mathbb{E}[\mathbf{y} | \mathbf{X}] = \mathbf{X}\beta, \quad \text{Var}(\mathbf{y} | \mathbf{X}) = \sigma^2 \mathbf{I}_N.$$

为什么只假设一阶矩和二阶矩？（不要求正态性）

注意：上述三条约束只涉及期望和方差，没有要求 ε_i 服从正态分布。这意味着：

- $\hat{\beta}$ 的无偏性 ($\mathbb{E}[\hat{\beta}] = \beta$) 和方差公式 ($\text{Var}(\hat{\beta}) = (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2$) 只依赖一阶和二阶矩, 不依赖正态性;
- 高斯-马尔可夫定理同样只要求一阶 + 二阶矩假设, 就能保证 LS 是 BLUE;
- 正态假设是额外加上去的——只有当你需要做精确的 t 检验、 F 检验、置信区间时, 才需要假设 $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ 。

这就是为什么 ESL 将“一阶/二阶矩假设”和“正态假设”分成两节来写——前者保证估计量的质量, 后者保证推断的有效性, 约束强度递增。

定理 11.1 ($\hat{\beta}$ 的均值和方差). 在假设 (11.21)–(11.23) 下:

$$\mathbb{E}[\hat{\beta} | \mathbf{X}] = \beta, \quad (11.26)$$

$$\text{Var}(\hat{\beta} | \mathbf{X}) = (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2. \quad (11.27)$$

简要推导. 由 $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 及 $\mathbb{E}[\mathbf{y} | \mathbf{X}] = \mathbf{X}\beta$:

$$\mathbb{E}[\hat{\beta} | \mathbf{X}] = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbb{E}[\mathbf{y} | \mathbf{X}] = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X} \beta = \beta.$$

由 $\text{Var}(\mathbf{y} | \mathbf{X}) = \sigma^2 \mathbf{I}$:

$$\text{Var}(\hat{\beta} | \mathbf{X}) = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \text{Var}(\mathbf{y} | \mathbf{X}) \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\sigma^2 \mathbf{I}) \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} = (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2.$$

□

11.4.2 三层限制：从模型选择到无偏性的逻辑链

初学者往往会困惑: $\mathbb{E}[\hat{\beta} | \mathbf{X}] = \beta$ 到底是什么意思? $\mathbf{X}$ 不就是手上这份数据吗, 哪来的“期望”? 下面用三层递进来回答这个问题。

第一层：我们对 f 施加了什么限制？

从统计学习的一般框架出发, 我们希望找到 $f(X) \approx \mathbb{E}[Y | X]$ 。但 $\mathbb{E}[Y | X]$ 可以是任意函数, 直接从数据中搜索“所有可能函数”是不可能的。因此, 我们主动施加了**两重限制**:

限制	选择	后果
函数族 $\mathcal{F}$	$f(X) = \beta_0 + \sum_{j=1}^p X_j \beta_j$ (线性)	将搜索空间从“所有函数”压缩到 $\mathbb{R}^{p+1}$ ERM 退化为 $\min_{\beta} \text{RSS}(\beta)$
损失函数 L	$L(y, f(x)) = (y - f(x))^2$ (平方损失)	

两者叠加就唯一确定了估计方法：

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^N (y_i - \mathbf{x}_i^{\top} \beta)^2 = (\mathbf{X}^{\top} \mathbf{X})^{-1} \mathbf{X}^{\top} \mathbf{y}.$$

关键认知： $\hat{\beta}$ 不是一个“发现”——它是在选定线性模型 + 平方损失之后的必然结果。换一种损失（如绝对损失）或换一种函数族（如加样条），得到的就是另一种估计量。

第二层：在这个限制下， $\hat{\beta}$ 是不是“好”的？

选定了估计方法之后，我们需要评估它的质量。评估需要一个标尺：如果数据真的是从线性模型生成的，我们的 $\hat{\beta}$ 能恢复到真实的 β 吗？

这就是 $\mathbb{E}[\hat{\beta} | \mathbf{X}] = \beta$ 的含义：在模型正确设定的前提下，LS 估计量是无偏的。

更进一步，高斯-马尔可夫定理告诉我们：在所有线性无偏估计量中，LS 的方差最小（BLUE）。所以在“线性 + 无偏”这个约束类里，LS 确实是最好的。

但注意前提条件：

- 线性模型必须正确设定： $\mathbb{E}[Y | X] = X\beta$ ；
- 误差必须同方差且不相干： $\text{Var}(\mathbf{y} | \mathbf{X}) = \sigma^2 \mathbf{I}$ 。

如果真实回归函数不是线性的， $\mathbb{E}[\hat{\beta} | \mathbf{X}]$ 根本不等於任何有意义的量—— $\hat{\beta}$ 只是“最优线性近似”的系数，不是“真实参数”的估计。

第三层： $\mathbf{X}$ 固定时，期望到底是对什么取的？

这是最容易混淆的核心问题。手上只有一份数据集 $\{\mathbf{X}, \mathbf{y}\}$ ， $\mathbf{X}$ 是 concrete 的数字矩阵， $\mathbf{y}$ 是 concrete 的数字向量。哪里来的“随机性”？哪里来的“期望”？

答案：随机性来自 $\mathbf{y}$ ，而 $\mathbf{y}$ 的随机性来自误差 ϵ 。

在固定设计（fixed design）设定下， $\mathbf{X}$ 被视为已知常数矩阵（非随机）。数据的生成过程是：

$$\underbrace{\mathbf{y}}_{N \times 1} = \underbrace{\mathbf{X}}_{N \times (p+1), \text{ 固定}} \underbrace{\beta}_{(p+1) \times 1, \text{ 未知常数}} + \underbrace{\epsilon}_{N \times 1, \text{ 随机}}.$$

$\mathbf{X}$ 和 β 都是固定的——变的是 ϵ ，从而变的是 $\mathbf{y}$ 。

用重复抽样来理解 $\mathbb{E}[\hat{\beta} | \mathbf{X}]$ ：

想象我们能让时间倒流，重复以下实验 M 次 ($M \rightarrow \infty$):

第 1 次 保持 $\mathbf{X}$ 完全不变 (同样的 N 个样本点, 同样的特征值);

第 2 次 从 $\mathcal{N}(0, \sigma^2)$ 中重新抽取 N 个独立的误差 $\varepsilon_1^{(m)}, \dots, \varepsilon_N^{(m)}$;

第 3 次 生成新的响应 $\mathbf{y}^{(m)} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}^{(m)}$;

第 4 次 在 $(\mathbf{X}, \mathbf{y}^{(m)})$ 上做 LS, 得到 $\hat{\boldsymbol{\beta}}^{(m)} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}^{(m)}$ 。

那么:

$$\mathbb{E}[\hat{\boldsymbol{\beta}} | \mathbf{X}] = \lim_{M \rightarrow \infty} \frac{1}{M} \sum_{m=1}^M \hat{\boldsymbol{\beta}}^{(m)} = \boldsymbol{\beta}.$$

直观总结:

量	是随机的吗?	说明
$\mathbf{X}$	× 固定	设计矩阵, 已知常数
$\boldsymbol{\beta}$	× 固定	真实参数, 未知但不变
$\boldsymbol{\varepsilon}$	✓ 随机	不可观测的噪声
$\mathbf{y}$	✓ 随机	$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$, 随 $\boldsymbol{\varepsilon}$ 而变
$\hat{\boldsymbol{\beta}}$	✓ 随机	$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$, 是 $\mathbf{y}$ 的函数

一句话: $\mathbb{E}[\hat{\boldsymbol{\beta}} | \mathbf{X}]$ 的期望不是“对不同数据集取平均”, 而是对同一个 $\mathbf{X}$ 下的不同噪声实现取平均。 $\mathbf{X}$ 固定, $\boldsymbol{\varepsilon}$ 在变。

注记 11.2 (固定设计 vs 随机设计). 本书 (ESL) 主要采用固定设计视角, 因为:

- 它让分析更简洁 (不需要对 X 的分布建模);
- 条件推断 (给定观测到的 X 做推断) 在实际中最常用;
- 大多数结果在随机设计下也成立 (只需对 X 取额外期望)。

随机设计视角下, X 也是随机的 (从某个分布 $P(X)$ 中抽取), 此时 $\mathbb{E}[\hat{\boldsymbol{\beta}}] = \mathbb{E}_X [\mathbb{E}[\hat{\boldsymbol{\beta}} | \mathbf{X}]] = \boldsymbol{\beta}$, 无偏性仍然成立, 但方差需要额外考虑 X 的随机性。

11.4.3 深入理解: 固定设计与随机设计

上一节的 remark 提到了两种设计视角, 下面展开讨论。这是理解回归分析中“随机性从哪来”的关键。

固定设计 (Fixed Design)

定义： $\mathbf{X}$ 被视为非随机的已知常数。数据对 (x_i, y_i) 中，只有 y_i 是随机变量（因为 $y_i = f(x_i) + \varepsilon_i$ ， ε_i 是随机的）。

典型场景：控制实验 (controlled experiment)

- 你想研究不同施肥量对作物产量的影响 → 你主动设定 $x_1 = 10, x_2 = 20, x_3 = 30$ (kg/亩)；
- 你想研究温度对化学反应速率的影响 → 你把恒温箱分别设为 $20^\circ, 30^\circ, 40^\circ$ ；
- 药厂做剂量试验 → 医生给患者分配固定剂量：0, 50, 100, 200 mg。

共同特征：实验者控制了 X 的取值。 X 不是从自然界随机观测来的，而是被设计出来的。此时把 X 当常数处理完全合理。

数学上：

- 所有期望和方差都是条件于 $\mathbf{X}$ 的： $\mathbb{E}[\cdot | \mathbf{X}]$, $\text{Var}(\cdot | \mathbf{X})$ ；
- $\mathbf{X}^\top \mathbf{X}$ 是常数矩阵（不是随机矩阵的期望）；
- $\hat{\beta}$ 的随机性完全来自 ε （从而来自 $\mathbf{y}$ ）。

随机设计 (Random Design)

定义： X 和 Y 都是从某个联合分布 $P(X, Y)$ 中随机抽取的。每个数据对 (x_i, y_i) 都是 i.i.d. 的联合观测。

典型场景：观测研究 (observational study) 和机器学习

- 你想预测房价 → 从市场上随机收集 N 套房的面积、地段、房龄和成交价；
- 你想做信用评分 → 从银行数据库中随机抽取客户的收入、负债、历史违约记录；
- 任何“你无法控制 X ，只能被动观测”的场景。

共同特征：你没有控制 X —— X 本身就是随机的。下次再抽一组数据， X 的值也会改变。

数学上：

- $\mathbf{X}$ 本身也是随机矩阵；
- 无条件的期望需要通过迭代期望来求： $\mathbb{E}[\hat{\beta}] = \mathbb{E}_X[\mathbb{E}[\hat{\beta} | \mathbf{X}]]$ ；
- $\mathbf{X}^\top \mathbf{X}$ 是随机的——不同数据集会给出不同的 $(\mathbf{X}^\top \mathbf{X})^{-1}$ ；
- 方差需要额外考虑 $\mathbf{X}$ 的随机性带来的波动。

两者关系：条件推断作为桥梁

实践中，无论数据是怎么来的，统计推断几乎总是条件于观测到的 $\mathbf{X}$ 进行的。原因很简单：你的报告写的是“给定这些数据， β_1 的 95% 置信区间是 $[0.3, 0.8]$ ”，而不是“如果我们从 $P(X)$ 中反复抽样，平均而言置信区间覆盖真值的概率是 95%”。

关键事实：随机设计下的绝大多数结论，只需先对 $\mathbf{X}$ 取条件，就可直接套用固定设计的结论。因为：

$$\begin{cases} \mathbb{E}[\hat{\beta} | \mathbf{X}] = \beta & (\text{固定设计无偏}) \\ \mathbb{E}[\hat{\beta}] = \mathbb{E}_X[\mathbb{E}[\hat{\beta} | \mathbf{X}]] = \mathbb{E}_X[\beta] = \beta & (\text{随机设计无偏}) \end{cases}$$

只要模型在条件意义下正确 ($\mathbb{E}[Y | X] = X\beta$)，无偏性对两种设计都成立。

三种视角的对比

	固定设计 (Fixed)	随机设计 (Random)	条件推断 (Conditional)
X 的性质	已知常数，由实验者设定	随机变量，从 $P(X)$ 中抽取	不管来源，条件于观测值
典型场景	控制实验、A/B 测试	观测研究、ML 预测建模	写统计报告、做置信区间
随机性来源	仅 ε (从而仅 $\mathbf{y}$)	ε 和 $\mathbf{X}$	仅 ε ($\mathbf{X}$ 已观测到)
期望记号	$\mathbb{E}[\cdot \mathbf{X}]$	$\mathbb{E}[\cdot]$	$\mathbb{E}[\cdot \mathbf{X}]$
$X^\top X$	常数矩阵	随机矩阵	常数矩阵 (已观测)
推断性质	精确 (t/F 检验在正态下精确)	渐近 (大样本近似)	精确 (条件于 $\mathbf{X}$)
预测	内插 (interpolation) 较安全	外推 (extrapolation) 有风险	取决于 X 的覆盖范围

ESL 的选择：为什么偏好固定设计视角？

全书 (Elements of Statistical Learning) 几乎都在固定设计 (条件于 $\mathbf{X}$) 框架下讨论，原因有三：

- (1) **数学更简洁。**不需要对 $P(X)$ 建模，不需要 X 的分布假设，避免了“ X 也是随机的所以 $\mathbf{X}^\top \mathbf{X}$ 的逆也有分布”这类复杂问题；
- (2) **更贴近实际推断。**在实际问题中，你拿到的是一份具体的数据集，你要基于这份数据给出结论——这正是条件推断做的事；
- (3) **结论可迁移。**固定设计下的结论（如 $\hat{\beta}_j$ 的标准误公式、 t 检验、 F 检验）在随机设计下也渐近成立，只是需要大样本和适当的正则条件。

一句话总结：固定设计说“ X 不变，我们看噪声怎么影响估计”——这是**分析的工具**；随机设计说“ X 也在变，下次采的数据不一样”——这是**真实的场景**；条件推断说“不管 X 怎么来的，我就基于手上这份 X 做推断”——这是**实践的方法**。三者不矛盾，是同一问题的三个层次。

11.4.4 条件推断：实践中你真正在做的事

前面提到条件推断是“实践的方法”。这一节专门展开：条件推断到底是什么？为什么它如此重要？以及你需要知道什么才能正确理解和报告你的结果。

什么是条件推断？

定义 11.7 (条件推断 (Conditional Inference)). 条件推断是指：所有统计推断（置信区间、 p 值、假设检验）都**条件于观测到的 $\mathbf{X}$** 进行。也就是说，你把 $\mathbf{X}$ 当作已知常数，仅考虑给定这份 $\mathbf{X}$ 下， $\mathbf{y}$ （通过 ϵ ）的随机性带来的不确定性。

用数学记号表达：

类型	记号	含义
无条件推断	$\Pr(\text{CI 覆盖 } \beta_j)$	同时考虑 $\mathbf{X}$ 和 $\mathbf{y}$ 的随机性
条件推断	$\Pr(\text{CI 覆盖 } \beta_j \mid \mathbf{X})$	$\mathbf{X}$ 固定，仅考虑 $\mathbf{y}$ 的随机性

实践中，你用的永远是条件推断。当你写下“ β_1 的 95% 置信区间是 $[0.32, 0.78]$ ”时，你没有说“如果重新采样 $\mathbf{X}$ 和 $\mathbf{y}$ ，95% 的区间会覆盖真值”。你说的是：**给定手上这份数据，基于 $\mathbf{y}$ 的随机性，这个区间以 95% 的概率覆盖 β_1 。**

为什么条件推断是默认选择？

有四个根本原因：

- (1) **你只有一份 $\mathbf{X}$ 。**在实际问题中，你不会重复采样新的 $\mathbf{X}$ 。你拿到的就是这一份设计矩阵。对一份永远不会变的 $\mathbf{X}$ 做“平均而言”的推断没有实操意义——你需要的是**给定这份 $\mathbf{X}$ 的结论**。

- (2) **条件推断更精确。**无条件推断把 $\mathbf{X}$ 的变异性也混进了方差估计里，导致置信区间更宽、检验更保守。条件推断把 $\mathbf{X}$ 的变异性剥离出去，只保留 ε 的不确定性，因此给出的区间更紧、检验更灵敏。
- (3) **条件推断与固定设计的公式完全一致。**在固定设计下推导的 $\text{Var}(\hat{\beta} | \mathbf{X}) = (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2$ 和 $t_j \sim t_{N-p-1}$ 直接就是条件推断的结果。你不需要额外学一套新公式。
- (4) **即使 $\mathbf{X}$ 是随机的，条件推断的性质也是逐点成立的。**对于每份具体的 $\mathbf{X}$ ， $\Pr(t_j \in \text{拒绝域} | \mathbf{X}, H_0) = \alpha$ （精确或在渐近意义下）。无条件性质只需对 $\mathbf{X}$ 取期望即可恢复：

$$\Pr(t_j \in \text{拒绝域} | H_0) = \mathbb{E}_{\mathbf{X}}[\Pr(t_j \in \text{拒绝域} | \mathbf{X}, H_0)] = \alpha.$$

条件推断下，置信区间的正确解读

这是最容易出错的地方。考虑 β_1 的 $100(1 - \alpha)\%$ 置信区间：

$$\hat{\beta}_1 \pm t_{N-p-1}^{(1-\alpha/2)} \cdot \text{se}(\hat{\beta}_1).$$

✓ **正确解读（条件推断）：**“给定我们观测到的 $\mathbf{X}$ ，如果我们能无限次地重新抽取 $\mathbf{y}$ （每次用新的 ε ，保持 $\mathbf{X}$ 不变），那么构造出的区间中有 $100(1 - \alpha)\%$ 会覆盖真实的 β_1 。因此，我们手上这个具体的区间有 $100(1 - \alpha)\%$ 的置信度覆盖 β_1 。”

× **错误解读：**“ β_1 有 95% 的概率落在这个具体区间里。”（ β_1 是固定常数，不是随机变量——要么在里面，要么不在。“概率”描述的是区间的构造方法，不是参数的位置。）

× **也错误：**“如果我们重新采样 $\mathbf{X}$ 和 $\mathbf{y}$ ，95% 的区间会覆盖 β_1 。”（这描述的是无条件性质，混合了 $\mathbf{X}$ 的随机性。）

条件推断 vs 无条件推断：什么时候有区别？

大多数情况下，条件推断和无条件推断给出的数值结果是一样的（比如 t 统计量、 p 值的计算），但它们在哲学层面和某些特殊场景下有本质区别。

- (1) **大多数场景——无区别。**在线性回归中， $\text{Var}(\hat{\beta}_j | \mathbf{X}) = v_j \sigma^2$ 仅通过 $v_j = [(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}$ 依赖于 $\mathbf{X}$ 。条件和无条件标准误公式在数值上是一样的（因为 $\mathbf{X}$ 已观测）。
- (2) **预测区间——条件推断更合理。**对新点 x_0 的预测区间，条件于训练集的 $\mathbf{X}$ 和新的 x_0 给出：

$$\hat{y}_0 \pm t_{N-p-1}^{(1-\alpha/2)} \cdot \hat{\sigma} \sqrt{1 + x_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} x_0}.$$

如果做无条件推断，你需要知道未来 x_0 的分布，而这在实际中几乎不可能准确获得。

- (3) **模型选择后的推断——条件推断是必需的。**如果你先用数据做了变量选择（如 Lasso、逐步回归），再对选出的变量做检验，那么 $\mathbf{X}$ 中哪些列被保留本身是随机的（依赖于 $\mathbf{y}$ ）。此时条件推断必须考虑选择过程带来的不确定性——这是**选择性推断 (selective inference)** 的研究范畴，也是近年来统计学的前沿热点。
- (4) **辅助统计量 (Ancillary Statistics)。**如果一个统计量的分布不依赖于未知参数，它被称为辅助统计量。条件推断原则 (Conditionality Principle) 要求：如果存在辅助统计量，应该条件于它做推断。例如， $\mathbf{X}$ 本身（在随机设计下）就是辅助的——它的分布不含 β 。

你需要记住的三个要点

1. **你总是在做条件推断。**无论你是否意识到，当你基于一份具体数据报告置信区间或 p 值时，你已经在条件于 $\mathbf{X}$ 了。这是实践中的唯一合理做法。
2. **条件推断的公式 = 固定设计的公式。**教材中所有在“固定设计”下推导的标准误、 t 分布、 F 分布结论，都可以直接用作条件推断的工具。你无需区分“这份 $\mathbf{X}$ 是固定的还是随机的”——只要条件于它，结论就一样。
3. **不要混淆条件性质和无条件性质。**一个检验可能在条件意义下是水平的 ($\Pr(\text{拒绝} | \mathbf{X}, H_0) = \alpha$)，也在无条件意义下是水平的 ($\Pr(\text{拒绝} | H_0) = \alpha$)。但**条件性质更强**——它保证了你的推断在每一份具体数据上都是可靠的，而不仅仅是“平均而言”可靠。

一句话总结：条件推断就是把 $\mathbf{X}$ 锁死，只在噪声 ϵ 的维度上讨论不确定性。这是统计实践中唯一合理的做法，也是全书所有公式的默认前提。

总结图：从数据生成到推断的完整逻辑链

下图总结了本节从建模假设、估计量性质、设计视角到条件推断的完整逻辑链条：

$$\boxed{\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}} \xrightarrow{\text{三个量}} \begin{cases} \mathbf{X}: \text{已知常数 (固定设计)} \\ \boldsymbol{\beta}: \text{未知常数 (估计目标)} \\ \boldsymbol{\varepsilon}: \text{随机噪声 (唯一随机源)} \end{cases}$$

↓ 对 $\boldsymbol{\varepsilon}$ 的三条约束 (一阶 + 二阶矩)

$$\begin{cases} \mathbb{E}[\boldsymbol{\varepsilon} | \mathbf{X}] = \mathbf{0} & \implies \mathbb{E}[\mathbf{y} | \mathbf{X}] = \mathbf{X}\boldsymbol{\beta} \quad (\text{线性均值}) \\ \text{Var}(\varepsilon_i) = \sigma^2 & \implies \text{同方差 (常数波动幅度)} \\ \text{Cov}(\varepsilon_i, \varepsilon_j) = 0 & \implies \text{观测间不相关} \end{cases}$$

↓ 约束下的最优估计

$$\boxed{\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}} \xrightarrow{\text{性质}} \begin{cases} \mathbb{E}[\hat{\boldsymbol{\beta}} | \mathbf{X}] = \boldsymbol{\beta} & (\text{无偏性}) \\ \text{Var}(\hat{\boldsymbol{\beta}} | \mathbf{X}) = (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2 & (\text{方差公式}) \\ \text{高斯-马尔可夫: LS 是 BLUE} & (\text{不依赖正态性}) \end{cases}$$

↓ 三种设计视角

固定设计	随机设计	条件推断
$\mathbf{X}$ 不变	$\mathbf{X}$ 也是随机的	不管 $\mathbf{X}$ 怎么来的
控制实验	观测研究 / ML	手上这份数据
分析的工具	真实的场景	实践的方法

↓ 实践中: 永远是条件推断

$$\boxed{\text{给定 } \mathbf{X}, \text{ 仅 } \boldsymbol{\varepsilon} \text{ 是随机的}} \xrightarrow{\text{所有公式}} \begin{cases} \text{Var}(\hat{\beta}_j) = v_j \sigma^2 & (\text{标准误}) \\ t_j = \frac{\hat{\beta}_j}{\hat{\sigma} \sqrt{v_j}} \sim t_{N-p-1} & (t \text{ 检验}) \\ \text{CI: } \hat{\beta}_j \pm t \cdot \hat{\sigma} \sqrt{v_j} & (\text{置信区间}) \end{cases}$$

↓ 加上正态假设: $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$

$$\boxed{\hat{\boldsymbol{\beta}} \sim \mathcal{N}(\boldsymbol{\beta}, (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2)} \xrightarrow{\text{推断}} t \text{ 检验} / F \text{ 检验} / \text{精确置信区间}$$

核心教训:

- 一阶 + 二阶矩假设 $\Rightarrow$ 无偏性 + 方差公式 + 高斯-马尔可夫 (不需正态);
- 正态假设 $\Rightarrow t$ 分布 / F 分布 / 精确推断 (额外条件);
- 条件推断 = 锁死 $\mathbf{X}$, 仅对 ε 的随机性做推断——这是实践中的唯一做法;
- $\mathbb{E}[\hat{\beta} | \mathbf{X}]$ 的期望不是对不同的 $\mathbf{X}$ 取平均, 而是对同一个 $\mathbf{X}$ 下的不同噪声实现取平均。

11.4.5 σ^2 的无偏估计

实践中 σ^2 未知, 需要从数据估计。

定义 11.8 (σ^2 的无偏估计量)。

$$\hat{\sigma}^2 = \frac{1}{N-p-1} \sum_{i=1}^N (y_i - \hat{y}_i)^2 = \frac{\text{RSS}(\hat{\beta})}{N-p-1}. \quad (11.28)$$

分母 $N-p-1$ (而非 N) 保证了无偏性: $\mathbb{E}[\hat{\sigma}^2] = \sigma^2$ 。其中 $p+1$ 是被估计的参数个数 (含截距), 因此自由度为 $N-(p+1)$ 。

注记 11.3 (与第 2 章 S^2 的联系). 单样本情形 ($p=0$, 仅截距) 下, $\hat{\beta}_0 = \bar{y}$, 则:

$$\hat{\sigma}^2 = \frac{1}{N-1} \sum_{i=1}^N (y_i - \bar{y})^2 = S^2.$$

这是第 2 章样本方差 S^2 的自然推广。

11.4.6 单个系数的方差

记 v_j 为 $(\mathbf{X}^\top \mathbf{X})^{-1}$ 的第 $(j+1)$ 个对角元 ($j=0, 1, \dots, p$), 则:

$$\text{Var}(\hat{\beta}_j) = v_j \sigma^2. \quad (11.29)$$

用 $\hat{\sigma}^2$ 替代 σ^2 , 得到 $\hat{\beta}_j$ 的估计标准误:

$$\text{se}(\hat{\beta}_j) = \hat{\sigma} \sqrt{v_j}. \quad (11.30)$$

11.5 正态假设下的推断

如需进行置信区间和假设检验, 则需要更强的分布假设。

11.5.1 正态误差假设

定义 11.9 (带正态误差的线性模型). 假设:

$$Y = \beta_0 + \sum_{j=1}^p X_j \beta_j + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2), \quad (11.31)$$

且不同观测的 ε_i 相互独立。

等价地:

$$\mathbf{y} \mid \mathbf{X} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}). \quad (11.32)$$

11.5.2 $\hat{\boldsymbol{\beta}}$ 的抽样分布

定理 11.2 ($\hat{\boldsymbol{\beta}}$ 的正态性). 在正态误差假设下:

$$\boxed{\hat{\boldsymbol{\beta}} \sim \mathcal{N}(\boldsymbol{\beta}, (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2)}. \quad (11.33)$$

证明. $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 是 $\mathbf{y}$ 的线性变换。 $\mathbf{y}$ 服从多元正态分布，其任意线性变换也服从多元正态分布。均值和方差已在式 (11.26) 和 (11.27) 中给出。□

11.5.3 单个系数的检验： t 检验到底在检验什么？

核心问题：你拟合了一个线性模型，得到了 $\hat{\beta}_j$ 。但 $\hat{\beta}_j$ 永远不精确为零——即使 X_j 和 Y 完全无关，抽样噪声也会让 $\hat{\beta}_j$ 偏离零。 t 检验要回答的是：观测到的 $\hat{\beta}_j$ 离零有多远，这个距离是否大到不能用“随机噪声”来解释？

原假设与备择假设

定义 11.10 (t 检验的假设). 对于单个系数 β_j ($j = 0, 1, \dots, p$):

$$\boxed{H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0}.$$

用大白话说:

- H_0 (原假设 / 零假设): $\beta_j = 0$, 即 X_j 对 Y 没有线性贡献。在模型中, X_j 这个变量是“多余”的——去掉它, 模型预测能力不会系统性地变差;
- H_1 (备择假设): $\beta_j \neq 0$, 即 X_j 对 Y 有线性贡献。 X_j 提供了关于 Y 的信息, 保留它能改善预测。

注记 11.4 (为什么总是检验 $\beta_j = 0$?)。你可能想问: 为什么标准检验的目标是 $\beta_j = 0$, 而不是 $\beta_j = 0.5$ 或其他值?

答案: $\beta_j = 0$ 对应一个自然的基准问题——“这个变量有没有用?” 这是模型选择的第一步: 先筛掉显然没用的变量, 再考虑更精细的问题。

当然, 你也可以检验 $H_0: \beta_j = c$ (c 为任意常数), 只需将 t 统计量改为 $t_j = (\hat{\beta}_j - c)/\text{se}(\hat{\beta}_j)$ 。例如, 检验“ X_j 每增加 1 单位, Y 是否恰好增加 2”: $H_0: \beta_j = 2$ 。但 $\beta_j = 0$ 是最常见、最基础的检验。

检验的逻辑结构

整个 t 检验遵循假设检验的经典四步逻辑:

第 1 步: 假定 H_0 为真。

我们暂时假设 X_j 真的没用 ($\beta_j = 0$)。在这个假设下, $\hat{\beta}_j$ 应该怎样分布?

在 H_0 和正态误差下:

$$\hat{\beta}_j \sim \mathcal{N}(0, v_j \sigma^2).$$

即 $\hat{\beta}_j$ 以 0 为中心、方差为 $v_j \sigma^2$ 的正态分布。这意味着: 即使 β_j 真的是 0, 由于抽样噪声, $\hat{\beta}_j$ 也不会恰好为 0——它会围绕 0 随机波动。

第 2 步: 构造检验统计量, 衡量观测值与 H_0 的偏离程度。

定义 11.11 (t 统计量).

$$t_j = \frac{\hat{\beta}_j}{\text{se}(\hat{\beta}_j)} = \frac{\hat{\beta}_j}{\hat{\sigma} \sqrt{v_j}} \sim t_{N-p-1}. \quad (11.34)$$

t_j 衡量的是: $\hat{\beta}_j$ 离零有多少个标准误。

- $|t_j|$ 很大 $\rightarrow \hat{\beta}_j$ 离零很远 (相对于噪声水平) $\rightarrow$ 不太可能是噪声造成的;
- $|t_j|$ 很小 $\rightarrow \hat{\beta}_j$ 离零很近 $\rightarrow$ 很可能只是随机波动。

第 3 步: 计算 p 值: 在 H_0 为真的前提下, 看到这么极端的结果有多不寻常?

定义 11.12 (p 值).

$$p\text{-value} = \Pr(|T| \geq |t_j^{\text{obs}}| \mid H_0 \text{ 为真}), \quad (11.35)$$

其中 $T \sim t_{N-p-1}$, t_j^{obs} 是从数据中算出的实际 t 值。

p 值大小	含义	通俗解释
$p < 0.001$	极端罕见	“如果 X_j 真的没用, 这种结果几乎不可能出现”
$p \approx 0.01$	很罕见	“只有 1% 的概率是噪声搞出来的”
$p \approx 0.05$	边缘显著	“勉强强强, 可能是真信号也可能是噪声”
$p \approx 0.3$	很常见	“即使 X_j 没用, 这种结果也经常出现——不稀奇”

第 4 步：做出决策。

设定显著性水平 α (通常 $\alpha = 0.05$):

- 若 $p < \alpha$: 拒绝 H_0 。有足够的证据认为 $\beta_j \neq 0$, X_j 对 Y 有显著贡献;
- 若 $p \geq \alpha$: 不拒绝 H_0 。数据没有提供足够证据说明 X_j 有用——但这不等于证明了 X_j 没用!

等价形式：用 t 值与临界值比较

除了看 p 值，也可以直接将 $|t_j|$ 与 t 分布的临界值比较：

$$|t_j| > t_{N-p-1}^{(1-\alpha/2)} \iff p < \alpha.$$

两种方式是等价的——只是表达习惯不同。软件输出通常同时给出 t 值和 p 值。

 t 检验与置信区间的关系

拒绝 $H_0: \beta_j = 0$ (在水平 α 下) 等价于: 0 不在 β_j 的 $100(1 - \alpha)\%$ 置信区间内。
置信区间为:

$$\hat{\beta}_j \pm t_{N-p-1}^{(1-\alpha/2)} \cdot \text{se}(\hat{\beta}_j). \quad (11.36)$$

所以 t 检验和置信区间是同一件事的两种说法:

- t 检验问: “ β_j 可能是 0 吗?” → 用 p 值回答;
- 置信区间问: “ β_j 可能在什么范围?” → 如果区间包含 0, 则不能拒绝 H_0 。

常见误区

- (1) “ $p > 0.05$ 说明 X_j 没用” → × 错误。

正确的说法是: “没有足够证据证明 X_j 有用”。可能是样本量太小 (标准误太大)、噪声太强、或 X_j 与别的变量高度相关导致效应被分散。不显著 $\neq$ 不存在。

- (2) “ $p < 0.05$ 说明效应很大” → × 错误。

p 值小只说明 $\hat{\beta}_j$ 稳定地不为零, 不说明它很大。大样本下, 即使 $\hat{\beta}_j = 0.001$ (几乎可以忽略的实际效应) 也能得到 $p < 0.001$ 。统计显著 $\neq$ 实际重要。判断实际重要性应看 $\hat{\beta}_j$ 的大小及其实际含义。

- (3) “ p 值是 H_0 为真的概率” → × 错误。

p 值是 $\Pr(\text{数据} | H_0)$, 不是 $\Pr(H_0 | \text{数据})$ 。这是频率学派最常被误解的一点: H_0 ($\beta_j = 0$) 不是随机事件——它要么对要么错。 p 值告诉你的是: 假设 H_0 对, 你看到这种数据的概率, 而不是给定数据, H_0 对的概率。

(4) “ $\alpha = 0.05$ 是绝对的阈值” $\rightarrow \times$ 过于僵化。

$p = 0.049$ 和 $p = 0.051$ 几乎没有区别，不应得出截然相反的结论。建议报告实际的 p 值而非仅报告“显著/不显著”。

(5) “ t 分布 vs 正态” 不必纠结。

t 分布比正态分布有更厚的尾部（尤其是在小自由度时），反映了用 $\hat{\sigma}$ 代替 σ 带来的额外不确定性。当自由度 $N - p - 1 \rightarrow \infty$ 时， t 分布收敛于 $\mathcal{N}(0, 1)$ 。实践中， $N - p - 1 \geq 30$ 时 t 分布与标准正态的差异已不大——可以直接用 ± 1.96 （正态 95% 分位数）近似 $\pm t_{30}^{(0.975)} \approx 2.04$ 。

追问： t 检验不显著，可以直接去掉这个变量吗？

这是实践中非常自然的想法，答案是：要小心，不能机械地做。

✓ 什么时候去掉是合理的：

- 变量确实无关。从领域知识判断， X_j 与 Y 之间没有合理的因果或关联机制；
- 样本量足够大。 N 大意味着检验功效 (power) 充足——如果真有微小的效应，应该能检测到。在 N 很大时仍不显著，说明效应确实太小，不值得保留；
- 你不关心预测之外的推断。如果目标是纯预测（而非因果推断或解释），去掉噪声变量可以降低方差，提升泛化性能。

× 什么时候要谨慎——甚至不该去掉：

(1) 样本量太小。

小样本下标准误 $\text{se}(\hat{\beta}_j)$ 很大，即使 $\hat{\beta}_j$ 本身很大也可能不显著。这不是变量没用，是数据不够——你区分不了“效应为零”和“有效应但估计不准”。

例子：医学研究中，某种新药只试了 20 个人， $\hat{\beta} = 2.0$ （效果不小）但 $\text{se} = 1.2$ ， $p = 0.11$ 。如果因此扔掉这个变量，你可能错过了一个真正有效的治疗方法。

(2) 变量是控制变量 (control variable)。

有些变量你不关心它的系数，但必须放在模型里。典型场景：

- 因果推断中， X_j 是混杂因子 (confounder)——去掉它会使得其他变量的系数产生偏倚；
- 实验设计中，实验组别、分层变量等即使不显著也应保留。

核心原则：变量的去留不应仅由 p 值决定。控制变量的存在是为了保护其他系数的估计不受混杂偏倚，而不是因为它们自己显著。

(3) 多重共线性 (multicollinearity)。

如果 X_j 与模型中其他变量高度相关，它的效应会被“分散”到相关变量上，导致每个变量单独都不显著——但它们联合起来可能是显著的。

这正是 F 检验的用武之地：单个 t 检验不显著的一组变量，联合 F 检验可能是显著的。如果你只根据 t 检验逐个删除，可能会误删一组实际上有用的变量。

(4) 变量是理论要求的。

如果你的模型基于某个理论（如经济学模型、物理定律），某些变量必须出现——即使数据中它们不显著，也应该保留并报告。科学推断不只是“让数据说话”。

(5) 逐步删除会扭曲推断。

如果你先做了 t 检验，删掉不显著的变量，再用同样的数据重新拟合，那么剩余变量的 p 值和置信区间就不再有效——它们已经被选择过程污染了。这就是**选择性推断 (selective inference)** 要解决的问题。

正确的做法是：如果要删变量，应该在独立的验证集上评估，或使用专门的选择后推断方法。

实用的经验法则：

场景	建议	理由
纯预测、大样本、 $p \gg 0.05$	可以去掉	减少噪声、降低方差
纯预测、小样本	谨慎，考虑正则化 (Lasso)	正则化自动选择变量，比手动删更好
因果推断 / 控制变量	不能仅看 p 值	保留是为了消除混杂
多重共线性明显	先看 F 检验，考虑合并或正则化	单独 t 检验不可靠
理论驱动的研究	保留并报告	科学推断优先于统计显著

一句话总结： t 检验不显著给了你一个怀疑的理由，但不是删除的充分条件。删不删，要结合样本量、变量的领域角色、共线性状况和你的分析目标来综合判断。

11.5.4 置信区间与显著性检验

对于单个系数 β_j ， $100(1 - \alpha)\%$ 置信区间已在上一节给出 (11.36)。这里补充两点扩展：

任意值的检验：要检验 $H_0: \beta_j = c$ (不一定是 0)，只需将 t 统计量改为：

$$t_j = \frac{\hat{\beta}_j - c}{\text{se}(\hat{\beta}_j)} \sim t_{N-p-1}.$$

置信区间同样适用：若 c 不在 $100(1-\alpha)\%$ 置信区间内，则在水平 α 下拒绝 $H_0: \beta_j = c$ 。

11.5.5 进一步可检验的假设

除单个系数外，还可以检验：

- 一组系数的联合显著性： $H_0: \beta_{j_1} = \beta_{j_2} = \cdots = \beta_{j_k} = 0$ ，使用 F 检验；
- 系数的线性组合： $H_0: \mathbf{a}^\top \boldsymbol{\beta} = c$ ；
- 多个线性约束： $H_0: \mathbf{C}\boldsymbol{\beta} = \mathbf{d}$ ，其中 $\mathbf{C}$ 是约束矩阵。

11.5.6 F 检验与嵌套模型比较

单个系数的显著性用 t 检验。当需要同时检验多个系数是否为零（或更一般地，比较两个嵌套模型），则使用 F 检验。

嵌套模型与 F 统计量

定义 11.13 (嵌套模型 (Nested Models)). 模型 $M_0 (\subset M_1)$ 称为嵌套于 M_1 ，若 M_0 的参数是 M_1 参数的子集。典型的 M_0 是令 M_1 中某几个 $\beta_j = 0$ 。

设有两个模型：

- 大模型 M_1 ：含 $p_1 + 1$ 个参数（含截距），残差平方和 RSS_1 ；
- 小模型 M_0 ：含 $p_0 + 1$ 个参数（ $p_0 < p_1$ ），残差平方和 RSS_0 。

M_0 是 M_1 的限制版本（令 $p_1 - p_0$ 个系数为 0）。由于 M_1 有更多自由度来拟合数据，总有 $\text{RSS}_1 \leq \text{RSS}_0$ 。问题是：RSS 的减少是否足够大，值得增加这些额外参数？

定义 11.14 (F 统计量).

$$F = \frac{(\text{RSS}_0 - \text{RSS}_1)/(p_1 - p_0)}{\text{RSS}_1/(N - p_1 - 1)}. \quad (11.37)$$

定理 11.3 (F 统计量的分布). 在正态误差假设下，若 M_0 为真（即被约束的系数确实为 0），则：

$$F \sim F_{p_1 - p_0, N - p_1 - 1}. \quad (11.38)$$

直觉解释：

- 分子： M_1 相比 M_0 的 RSS 改善量 / 额外参数的个数 = “每个额外参数贡献的 RSS 减少”；
- 分母： M_1 的单位自由度 RSS $= \hat{\sigma}^2$ = 噪声方差的估计；
- 比值 F ：信号（改善量）与噪声（ $\hat{\sigma}^2$ ）的对比。 $F \gg 1$ 意味着改善量远超噪声水平 $\rightarrow$ 拒绝 M_0 。

特例：检验所有非截距系数

最常见的 F 检验是检验“除截距外所有系数均为零”：

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0.$$

此时 M_0 仅含截距 ($p_0 = 0$)， $\text{RSS}_0 = \sum (y_i - \bar{y})^2 = \text{TSS}$ （总平方和）。 F 统计量退化为：

$$F = \frac{(\text{TSS} - \text{RSS})/p}{\text{RSS}/(N - p - 1)}. \quad (11.39)$$

11.5.7 联合置信域

单个系数的置信区间每次只考虑一个 β_j 。如果同时对所有参数做推断，需要**联合置信域 (joint confidence region)**——校正多重比较带来的覆盖概率膨胀。

定义 11.15 (β 的联合置信域). 在正态误差假设下， β 的一个 $100(1 - \alpha)\%$ 联合置信域为：

$$C_\beta = \left\{ \beta \in \mathbb{R}^{p+1} \mid (\hat{\beta} - \beta)^\top \mathbf{X}^\top \mathbf{X} (\hat{\beta} - \beta) \leq \hat{\sigma}^2 \cdot (p+1) \cdot F_{p+1, N-p-1}^{(1-\alpha)} \right\}. \quad (11.40)$$

这是一个以 $\hat{\beta}$ 为中心的**椭球**。

单个区间 vs 联合域：单个 $100(1 - \alpha)\%$ 置信区间意味着该区间有 $1 - \alpha$ 的概率覆盖对应的 β_j （条件于 $\mathbf{X}$ ）。但如果对 $\beta_0, \beta_1, \dots, \beta_p$ 同时使用 $p+1$ 个单独的区间，**所有区间同时覆盖各自真值的概率小于 $1 - \alpha$** （多重比较问题）。联合置信域校正了这一点。

用大样本近似时，椭球可用 χ^2 分位数替代 F 分位数：

$$C_\beta \approx \left\{ \beta \mid (\hat{\beta} - \beta)^\top \mathbf{X}^\top \mathbf{X} (\hat{\beta} - \beta) \leq \hat{\sigma}^2 \cdot \chi_{p+1, (1-\alpha)}^2 \right\}.$$

11.6 高斯-马尔可夫定理

11.6.1 定理陈述与意义

定理 11.4 (高斯-马尔可夫定理 (Gauss–Markov Theorem)). 在假设 (11.21)–(11.23) 下（仅一阶、二阶矩假设，不要求正态性），对任意线性组合 $\theta = \mathbf{a}^\top \beta$ ($\mathbf{a} \in \mathbb{R}^{p+1}$)：

(i) $\hat{\theta} = \mathbf{a}^\top \hat{\boldsymbol{\beta}}$ 是 θ 的线性无偏估计: $\mathbb{E}[\hat{\theta} | \mathbf{X}] = \mathbf{a}^\top \boldsymbol{\beta} = \theta$;

(ii) 对任意其他线性无偏估计 $\tilde{\theta} = \mathbf{c}^\top \mathbf{y}$ (满足 $\mathbb{E}[\tilde{\theta} | \mathbf{X}] = \theta$): $\text{Var}(\hat{\theta} | \mathbf{X}) \leq \text{Var}(\tilde{\theta} | \mathbf{X})$ 。

即: LS 估计量是 $\theta = \mathbf{a}^\top \boldsymbol{\beta}$ 的最佳线性无偏估计 (BLUE)。

定理的意义:

- 在所有线性无偏估计量中, LS 的方差最小——没有人能用线性方法做得更好 (在不引入偏差的前提下);
- 定理不依赖正态性——只要求一阶矩 (线性均值) 和二阶矩 (同方差 + 不相关);
- 但如果误差不是正态的, 可能存在非线性估计量 (如稳健回归中的 M-估计量) 在某些标准下优于 LS。

11.6.2 MSE 分解: 偏差-方差视角

高斯-马尔可夫定理讨论的是无偏估计量类中的最优性。但如果我们放开“无偏”约束呢? 这就引出了 MSE 的分解:

定义 11.16 (均方误差 (Mean Squared Error, MSE)). 对于 θ 的任意估计量 $\tilde{\theta}$:

$$\text{MSE}(\tilde{\theta}) = \mathbb{E}[(\tilde{\theta} - \theta)^2] = \underbrace{\text{Var}(\tilde{\theta})}_{\text{方差}} + \underbrace{(\mathbb{E}[\tilde{\theta}] - \theta)^2}_{\text{偏差}^2}. \quad (11.41)$$

关键洞察:

- LS 估计量 $\hat{\theta}$ 偏差为零, 在所有无偏估计量中方差最小——BLUE;
- 但如果引入一点偏差, 可能大幅降低方差, 从而在 MSE 上优于 LS;
- 这恰恰是岭回归、Lasso 等正则化方法的动机——用有偏换方差, 从而降低 MSE。

高斯-马尔可夫定理告诉我们: 在无偏的线性世界里, LS 已经是最好的了。但现代统计学习恰恰选择了走出这个“无偏”世界——这就是第 3.4 节 (收缩方法) 要讨论的内容。

11.7 预测误差的分解

除了估计 $\boldsymbol{\beta}$ 本身, 我们更关心模型在新数据上的预测表现。

11.7.1 新观测的预测

设新观测点为 x_0 ($p+1$ 维, 含截距列), 其真实响应为:

$$Y_0 = x_0^\top \beta + \varepsilon_0, \quad \varepsilon_0 \sim (0, \sigma^2), \quad \varepsilon_0 \perp \{\varepsilon_1, \dots, \varepsilon_N\}.$$

我们用 $\hat{f}(x_0) = x_0^\top \hat{\beta}$ 来预测 Y_0 。

11.7.2 期望预测误差 (Expected Prediction Error)

定理 11.5 (新点上的预测误差分解).

$$\mathbb{E}[(Y_0 - \hat{f}(x_0))^2] = \sigma^2 + \mathbb{E}[(\hat{f}(x_0) - f(x_0))^2]. \quad (11.42)$$

其中 σ^2 是不可约误差 (即使知道真实 f 也无法消除), 第二项是 $\hat{f}(x_0)$ 作为 $f(x_0)$ 估计量的 MSE。

证明.

$$\begin{aligned} \mathbb{E}[(Y_0 - \hat{f}(x_0))^2] &= \mathbb{E}[(f(x_0) + \varepsilon_0 - \hat{f}(x_0))^2] \\ &= \mathbb{E}[(\varepsilon_0 + (f(x_0) - \hat{f}(x_0)))^2] \\ &= \mathbb{E}[\varepsilon_0^2] + 2\mathbb{E}[\varepsilon_0 \cdot (f(x_0) - \hat{f}(x_0))] + \mathbb{E}[(f(x_0) - \hat{f}(x_0))^2] \\ &= \sigma^2 + 0 + \text{MSE}(\hat{f}(x_0)). \end{aligned} \quad (11.43)$$

交叉项为零因为 ε_0 与训练数据 (从而 $\hat{f}$) 独立。 $\square$

进一步将 $\text{MSE}(\hat{f}(x_0))$ 按偏差-方差分解:

$$\text{MSE}(\hat{f}(x_0)) = \text{Var}(\hat{f}(x_0)) + (\mathbb{E}[\hat{f}(x_0)] - f(x_0))^2.$$

在线性模型正确设定的前提下 ($\mathbb{E}[\hat{f}(x_0)] = f(x_0)$), 偏差为零, 只剩下方差:

$$\mathbb{E}[(Y_0 - \hat{f}(x_0))^2] = \sigma^2 + \underbrace{\text{Var}(x_0^\top \hat{\beta})}_{\text{估计方差}} = \sigma^2 + x_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} x_0 \cdot \sigma^2.$$

11.7.3 训练误差 vs 预测误差

- **训练误差:** $\frac{1}{N} \sum (y_i - \hat{y}_i)^2$ 随模型复杂度增加而单调递减;
- **预测误差 (EPE):** 呈 U 形曲线——模型太简单则欠拟合 (高偏差), 太复杂则过拟合 (高方差)。

这就是第 2 章统计学习导论中讨论的核心张力: 偏差-方差权衡。

11.8 多元回归作为单变量回归的叠加

本节讨论一个深刻而优雅的几何事实：多元线性回归的系数可以逐个通过一系列单变量回归来获得。这不仅是计算上的洞察（Gram-Schmidt 正交化），也揭示了“多元回归 = 逐步剥离已解释信息”的本质。

11.8.1 单变量回归的最小二乘

先回顾最简单的情形——只有一个预测变量（无截距）：

$$\mathbf{y} = \mathbf{x}\beta + \varepsilon.$$

此时 $\mathbf{X}^\top \mathbf{X} = \mathbf{x}^\top \mathbf{x} = \langle \mathbf{x}, \mathbf{x} \rangle$ （内积）， $\mathbf{X}^\top \mathbf{y} = \langle \mathbf{x}, \mathbf{y} \rangle$ 。LS 估计为：

$$\boxed{\hat{\beta} = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\langle \mathbf{x}, \mathbf{x} \rangle}}. \quad (11.44)$$

残差为 $\mathbf{r} = \mathbf{y} - \mathbf{x}\hat{\beta}$ ，满足 $\langle \mathbf{x}, \mathbf{r} \rangle = 0$ （正交）。

11.8.2 有截距时的处理

若模型含截距 $\mathbf{y} = \beta_0 \mathbf{1} + \mathbf{x}\beta_1 + \varepsilon$ ，可以先从 $\mathbf{x}$ 中回归掉 $\mathbf{1}$ （即中心化），再对残差做无截距回归：

第 1 步：将 $\mathbf{x}$ 对 $\mathbf{1}$ 回归，得残差 $\mathbf{z} = \mathbf{x} - \bar{x}\mathbf{1}$ （中心化后的 $\mathbf{x}$ ）；

第 2 步：将 $\mathbf{y}$ 对 $\mathbf{z}$ 做无截距回归：

$$\hat{\beta}_1 = \frac{\langle \mathbf{z}, \mathbf{y} \rangle}{\langle \mathbf{z}, \mathbf{z} \rangle} = \frac{\sum (x_i - \bar{x})y_i}{\sum (x_i - \bar{x})^2}.$$

$\hat{\beta}_0$ 则从 $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ 得到。

11.8.3 推广到多元：正交化 (Gram-Schmidt)

上述思路可以逐列推广到多元回归。设有 p 个预测变量 $\mathbf{x}_1, \dots, \mathbf{x}_p$ ，算法：

第 1 步：初始化 $\mathbf{z}_0 = \mathbf{1}$ （截距列）；

第 2 步：对 $j = 1, \dots, p$ ：

- 将 $\mathbf{x}_j$ 对 $\mathbf{z}_0, \mathbf{z}_1, \dots, \mathbf{z}_{j-1}$ 做多元回归，得残差 $\mathbf{z}_j$ ；
- $\mathbf{z}_j$ 是 $\mathbf{x}_j$ 中与前面所有变量正交的部分——即 $\mathbf{x}_j$ 中不能被 $\mathbf{x}_1, \dots, \mathbf{x}_{j-1}$ 线性表出的“新信息”；

第 3 步：将 $\mathbf{y}$ 对 $\mathbf{z}_p$ 做单变量回归，得 $\hat{\beta}_p$ ；

第 4 步：以此类推，得到所有系数。

关键公式：多元回归中 $\mathbf{x}_j$ 的系数 $\hat{\beta}_j$ 可以通过单变量回归获得：

$$\hat{\beta}_j = \frac{\langle \mathbf{z}_j, \mathbf{y} \rangle}{\langle \mathbf{z}_j, \mathbf{z}_j \rangle}, \quad (11.45)$$

其中 $\mathbf{z}_j$ 是 $\mathbf{x}_j$ 在 $\mathbf{x}_1, \dots, \mathbf{x}_{j-1}$ （及截距）的正交补上的投影残差。

11.8.4 直观理解

- $\hat{\beta}_j$ 测量的是：去掉前面 $j-1$ 个变量已经解释的部分后， $\mathbf{x}_j$ 独有的贡献；
- 如果 $\mathbf{x}_j$ 与前面的变量高度相关，则 $\mathbf{z}_j$ 很小 $\rightarrow \hat{\beta}_j$ 的方差很大（多重共线性问题）；
- 如果预测变量彼此正交（ $\langle \mathbf{x}_j, \mathbf{x}_k \rangle = 0, j \neq k$ ），则每个系数的估计独立于其他变量，添加/删除变量不影响已有系数。

一句话：多元回归中的 $\hat{\beta}_j$ = “ $\mathbf{x}_j$ 独有部分的单变量回归系数”。这就是为什么 $\hat{\beta}_j$ 的符号和大小不能简单解释为 $\mathbf{x}_j$ 的“重要性”——它的估计依赖于模型中还有哪些其他变量。

11.8.5 QR 分解：从 Gram-Schmidt 到数值计算

上一节的 Gram-Schmidt 过程不仅是概念工具，它直接引出了线性回归最重要的数值方法——QR 分解。

从 Gram-Schmidt 到矩阵分解

Gram-Schmidt 过程产生了一组正交向量 $\mathbf{z}_0, \mathbf{z}_1, \dots, \mathbf{z}_p$ 。将它们写成矩阵形式，可以得到 $\mathbf{X}$ 的一个分解。

定义矩阵 $\mathbf{Z} = [\mathbf{z}_0 \ \mathbf{z}_1 \ \cdots \ \mathbf{z}_p]$ （各列正交）。Gram-Schmidt 的构造方式意味着原始设计矩阵 $\mathbf{X}$ 可以表示为 $\mathbf{Z}$ 的列的一个上三角线性组合：

$$\mathbf{X} = \mathbf{Z}\mathbf{\Gamma}, \quad (11.46)$$

其中 $\mathbf{\Gamma}$ 是 $(p+1) \times (p+1)$ 的上三角矩阵，对角线元素全为 1。

为什么是上三角？因为 $\mathbf{z}_j$ 仅依赖 $\mathbf{x}_1, \dots, \mathbf{x}_j$ ， $\mathbf{x}_j$ 表示为 $\mathbf{z}_0, \dots, \mathbf{z}_j$ 的线性组合——系数矩阵自然是上三角的。

标准化得到 QR 分解

将 $\mathbf{Z}$ 的各列标准化为单位长度。令 $\mathbf{D}$ 为对角矩阵, $D_{jj} = \|\mathbf{z}_j\|$ (第 j 列的长度), 定义:

$$\mathbf{Q} = \mathbf{Z}\mathbf{D}^{-1},$$

即 $\mathbf{Q}$ 的每一列 $\mathbf{q}_j = \mathbf{z}_j / \|\mathbf{z}_j\|$ 。则 $\mathbf{Q}$ 是列正交矩阵: $\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}$ 。

定义 11.17 (QR 分解). 将 $\mathbf{X} = \mathbf{Z}\mathbf{\Gamma}$ 改写为:

$$\boxed{\mathbf{X} = \mathbf{Z}\mathbf{D}^{-1}\mathbf{D}\mathbf{\Gamma} = \mathbf{Q}\mathbf{R}}, \quad (11.47)$$

其中:

- $\mathbf{Q}$ 是 $N \times (p+1)$ 列正交矩阵 ($\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}$);
- $\mathbf{R} = \mathbf{D}\mathbf{\Gamma}$ 是 $(p+1) \times (p+1)$ 上三角矩阵, 且对角元 $R_{jj} = \|\mathbf{z}_j\| > 0$ 。

用 QR 分解求解最小二乘

QR 分解让 LS 估计变得极其简洁。代入 $\hat{\beta}$ 的公式:

$$\begin{aligned} \hat{\beta} &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \\ &= ((\mathbf{Q}\mathbf{R})^\top \mathbf{Q}\mathbf{R})^{-1} (\mathbf{Q}\mathbf{R})^\top \mathbf{y} \\ &= (\mathbf{R}^\top \mathbf{Q}^\top \mathbf{Q}\mathbf{R})^{-1} \mathbf{R}^\top \mathbf{Q}^\top \mathbf{y} \\ &= (\mathbf{R}^\top \mathbf{R})^{-1} \mathbf{R}^\top \mathbf{Q}^\top \mathbf{y} \quad (\text{因为 } \mathbf{Q}^\top \mathbf{Q} = \mathbf{I}) \\ &= \mathbf{R}^{-1} \mathbf{Q}^\top \mathbf{y}. \end{aligned} \quad (11.48)$$

即:

$$\boxed{\hat{\beta} = \mathbf{R}^{-1} \mathbf{Q}^\top \mathbf{y}} \iff \boxed{\mathbf{R} \hat{\beta} = \mathbf{Q}^\top \mathbf{y}}.$$

由于 $\mathbf{R}$ 是上三角矩阵, $\mathbf{R} \hat{\beta} = \mathbf{Q}^\top \mathbf{y}$ 可以通过 回代 (back-substitution) 高效求解——从 $\hat{\beta}_p$ 开始向上逐一算出。

拟合值也有了简洁形式:

$$\hat{\mathbf{y}} = \mathbf{X} \hat{\beta} = \mathbf{Q}\mathbf{R} \cdot \mathbf{R}^{-1} \mathbf{Q}^\top \mathbf{y} = \mathbf{Q}\mathbf{Q}^\top \mathbf{y}.$$

单个系数的方差

在 QR 分解下, $\hat{\beta}_j$ 的方差有特别简洁的表达式:

$$\boxed{\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{\|\mathbf{z}_j\|^2}}. \quad (11.49)$$

推导：由 $\text{Var}(\hat{\beta}) = (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2 = (\mathbf{R}^\top \mathbf{R})^{-1} \sigma^2$ ，而 $\mathbf{R}$ 的对角元 $R_{jj} = \|\mathbf{z}_j\|$ 。由于 $\mathbf{R}$ 上三角， $(\mathbf{R}^{-1})_{jj} = 1/R_{jj}$ ，因此：

$$\text{Var}(\hat{\beta}_j) = \sigma^2 \sum_k (\mathbf{R}^{-1})_{jk}^2 \geq \sigma^2 (\mathbf{R}^{-1})_{jj}^2 = \frac{\sigma^2}{\|\mathbf{z}_j\|^2}.$$

当 $\mathbf{X}$ 的列正交时等号成立（ $\mathbf{R}$ 为对角矩阵）。

直观含义： $\|\mathbf{z}_j\|$ 是 $\mathbf{x}_j$ 中“独有信息”的强度。 $\|\mathbf{z}_j\|$ 越小（ $\mathbf{x}_j$ 与其他变量高度相关）， $\hat{\beta}_j$ 的方差越大——这精确量化了多重共线性的危害。

QR vs 正规方程：数值稳定性

实践中，直接计算 $(\mathbf{X}^\top \mathbf{X})^{-1}$ （正规方程法）在数值上不稳定——如果 $\mathbf{X}$ 接近秩亏， $\mathbf{X}^\top \mathbf{X}$ 的条件数是 $\mathbf{X}$ 条件数的平方，求逆会放大舍入误差。QR 分解绕过了 $\mathbf{X}^\top \mathbf{X}$ 的构造，直接处理 $\mathbf{X}$ ，数值稳定性好得多。因此实际统计软件（R 的 `lm`、Python 的 `statsmodels`）都使用 QR 分解，而不是正规方程。

11.9 多输出回归 (Multiple Outputs)

此前我们一直假设 Y 是标量（单输出）。实际中常常需要同时预测多个响应变量。例如：

- 根据天气数据同时预测温度、湿度和风速；
- 根据医学影像同时预测多种疾病的概率；
- 根据学生背景同时预测多门课程的成绩。

11.9.1 模型形式

设有 K 个输出变量 $Y_1, Y_2, \dots, Y_K$ ，每个都使用相同的 p 个预测变量：

定义 11.18 (多输出线性模型). 对第 k 个输出：

$$Y_k = \beta_{0k} + \sum_{j=1}^p X_j \beta_{jk} + \varepsilon_k, \quad k = 1, \dots, K.$$

注意：每个输出有自己的一组系数 $\beta_{0k}, \beta_{1k}, \dots, \beta_{pk}$ ，但所有输出共享同一组输入 $X_1, \dots, X_p$ 。

11.9.2 矩阵形式

将 K 个输出堆叠为矩阵，得到紧凑的矩阵形式：

$$\mathbf{Y}_{N \times K} = \mathbf{X}_{N \times (p+1)} \mathbf{B}_{(p+1) \times K} + \mathbf{E}_{N \times K}. \quad (11.50)$$

其中：

$$\mathbf{Y} = \begin{pmatrix} y_{11} & \cdots & y_{1K} \\ \vdots & \ddots & \vdots \\ y_{N1} & \cdots & y_{NK} \end{pmatrix}, \quad \mathbf{B} = \begin{pmatrix} \beta_{01} & \cdots & \beta_{0K} \\ \beta_{11} & \cdots & \beta_{1K} \\ \vdots & \ddots & \vdots \\ \beta_{p1} & \cdots & \beta_{pK} \end{pmatrix}, \quad \mathbf{E} = \begin{pmatrix} \varepsilon_{11} & \cdots & \varepsilon_{1K} \\ \vdots & \ddots & \vdots \\ \varepsilon_{N1} & \cdots & \varepsilon_{NK} \end{pmatrix}.$$

$\mathbf{X}$ 与单输出情形完全相同 ($N \times (p+1)$ ，含截距列)。 $\mathbf{B}$ 的第 k 列就是第 k 个输出的系数向量。

11.9.3 最小二乘估计

多输出 RSS 定义为所有输出、所有观测的平方误差之和：

$$\text{RSS}(\mathbf{B}) = \sum_{k=1}^K \sum_{i=1}^N (y_{ik} - f_k(\mathbf{x}_i))^2 = \text{tr}((\mathbf{Y} - \mathbf{XB})^\top (\mathbf{Y} - \mathbf{XB})). \quad (11.51)$$

对 $\mathbf{B}$ 求导并令其为零，得到与单输出完全相同的正规方程：

$$\mathbf{X}^\top \mathbf{XB} = \mathbf{X}^\top \mathbf{Y}. \quad (11.52)$$

因此：

$$\hat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}. \quad (11.53)$$

注记 11.5 (核心洞察：为什么可以逐列求解). 注意 $\hat{\mathbf{B}}$ 的公式和单输出的 $\hat{\beta}$ 完全一样，只是把 $\mathbf{y}$ (向量) 换成了 $\mathbf{Y}$ (矩阵)。

这意味着：如果误差在不同输出间不相关，多输出回归等价于对每个输出 Y_k 单独做一次单输出回归。 $\hat{\mathbf{B}}$ 的第 k 列 = $(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}_k$ 。

11.9.4 当误差跨输出相关时

如果不同输出的误差相关 ($\text{Cov}(\varepsilon_{ik}, \varepsilon_{i\ell}) \neq 0$)，逐列 LS 仍然是无偏的，但不再是最优的。此时可以引入多变量加权最小二乘。

定义 11.19 (误差协方差矩阵). 设第 i 个观测的 K 维误差向量 $\boldsymbol{\varepsilon}_i = (\varepsilon_{i1}, \dots, \varepsilon_{iK})^\top$ ，其协方差矩阵为 $\text{Cov}(\boldsymbol{\varepsilon}_i) = \boldsymbol{\Sigma}$ ($K \times K$ ，对所有 i 相同，且不同 i 间独立)。

多变量加权准则：

$$\text{RSS}_{\Sigma}(\mathbf{B}) = \sum_{i=1}^N (\mathbf{y}_i - \mathbf{B}^{\top} \mathbf{x}_i)^{\top} \Sigma^{-1} (\mathbf{y}_i - \mathbf{B}^{\top} \mathbf{x}_i). \quad (11.54)$$

但 Σ 在实践中通常未知。幸运的是：如果所有输出使用相同的输入矩阵 $\mathbf{X}$ ，即使 $\Sigma \neq \mathbf{I}$ ，逐列 LS 仍然是逐列最优的——因为 $\hat{\mathbf{B}}$ 就是最大化多变量似然的解（在正态假设下），且 $\hat{\mathbf{B}}$ 不依赖 Σ 。

一句话总结：如果所有输出用同一组 $\mathbf{X}$ ，多输出回归直接退化为 K 个独立的单输出回归——对每个 Y_k 跑一次 `lm(y_k ~ X)` 即可。这正是 R 中 `lm(Y ~ X)`（ Y 为矩阵时）的行为。

11.10 实例：前列腺癌数据

本节用 ESL 中的前列腺癌数据集来展示线性回归的完整流程。数据来自 Stamey et al. (1989)，研究前列腺特异性抗原 (PSA) 水平与多个临床指标的关系。

11.10.1 变量说明

变量	含义	类型
lcavol	log(癌体积)	连续
lweight	log(前列腺重量)	连续
age	年龄	连续
lbph	log(良性增生量)	连续
svi	精囊侵犯	二值 (0/1)
lcp	log(包膜穿透)	连续
gleason	Gleason 评分	有序类别
pgg45	Gleason 评分 4/5 的百分比	连续
响应变量		
lpsa	log(PSA)	连续

共 $N = 97$ 个观测（划分为训练集 67 + 测试集 30）。

11.10.2 预测变量的相关矩阵

表 ?? 给出了 8 个预测变量两两之间的 Pearson 相关系数。注意到：lcavol 与 lcp 高度相关 ($r \approx 0.68$)，gleason 与 pgg45 也高度相关 ($r \approx 0.75$)，这提示可能存在多重共线性问题。

	lcavol	lweight	age	lbph	svi	lcp	gleason	pgg45
lcavol	1.00	0.30	0.29	0.06	0.59	0.68	0.43	0.43
lweight		1.00	0.35	0.44	0.16	0.16	0.06	0.11
age			1.00	0.35	0.13	0.18	0.27	0.28
lbph				1.00	-0.09	-0.01	0.08	0.08
svi					1.00	0.67	0.32	0.25
lcp						1.00	0.51	0.63
gleason							1.00	0.75
pgg45								1.00

11.10.3 全模型回归结果

将 lpsa 对所有 8 个预测变量做线性回归，结果见表 ??。

项	系数 $\hat{\beta}_j$	标准误	z 值	p 值 (近似)
Intercept	0.429	1.036	0.41	0.68
lcavol	0.576	0.107	5.37	< 0.001
lweight	0.614	0.201	3.06	0.002
age	-0.019	0.011	-1.73	0.084
lbph	0.145	0.058	2.50	0.012
svi	0.737	0.237	3.11	0.002
lcp	-0.106	0.090	-1.18	0.239
gleason	-0.036	0.136	-0.26	0.792
pgg45	0.00446	0.00436	1.02	0.307

解读：

- 显著的变量：lcavol、lweight、svi、lbph ($p < 0.05$)；
- 不显著的变量：age (边缘显著)、lcp、gleason、pgg45；

- 这是典型的多重共线性表现——`lcp` 与 `lcavol` 高度相关，单独的贡献被 `lcavol` “抢走”了；
- `gleason` 和 `pgg45` 高度相关，两者都不显著，但它们联合可能显著。

11.10.4 F 检验：小模型 vs 大模型

考虑比较两个嵌套模型：

- M_1 (全模型)：8 个预测变量 + 截距， $p_1 = 8$ ， $RSS_1 = 29.43$ ；
- M_0 (小模型)：仅 `lcavol`、`lweight`、`svi`、`lbph` 4 个变量 + 截距， $p_0 = 4$ ， $RSS_0 = 32.81$ 。

检验 H_0 ：被去掉的 4 个变量 (`age`, `lcp`, `gleason`, `pgg45`) 的系数全为零。

$$F = \frac{(32.81 - 29.43)/(8 - 4)}{29.43/(67 - 8 - 1)} = \frac{3.38/4}{29.43/58} = \frac{0.845}{0.507} \approx 1.67.$$

$F \sim F_{4,58}$ ， $p\text{-value} \approx 0.17 > 0.05$ 。结论：不能拒绝 H_0 ——这 4 个变量联合来看也不显著，可以从小模型中移除。

这体现了 F 检验的价值：单个变量不显著不代表它们联合也不显著（反之亦然）。 F 检验提供了一种整体评估一组变量贡献的方法。

11.11 完整示例：手算一个线性回归

下面用一个极小的数据集 ($N = 6$, $p = 2$)，从原始数据开始，逐步走完本章讲过的全部流程。所有数值都可以手算验证。

11.11.1 数据与模型

i	y_i	x_{i1}	x_{i2}
1	4	1	3
2	5	2	1
3	7	3	4
4	8	4	2
5	10	5	5
6	12	6	3

模型： $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$ 。

设计矩阵与响应向量：

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 3 \\ 1 & 2 & 1 \\ 1 & 3 & 4 \\ 1 & 4 & 2 \\ 1 & 5 & 5 \\ 1 & 6 & 3 \end{pmatrix}_{6 \times 3}, \quad \mathbf{y} = \begin{pmatrix} 4 \\ 5 \\ 7 \\ 8 \\ 10 \\ 12 \end{pmatrix}_{6 \times 1}.$$

11.11.2 Step 1: 估计 $\hat{\beta}$

计算 $\mathbf{X}^\top \mathbf{X}$ 和 $\mathbf{X}^\top \mathbf{y}$ ：

$$\mathbf{X}^\top \mathbf{X} = \begin{pmatrix} 6 & 21 & 18 \\ 21 & 91 & 71 \\ 18 & 71 & 64 \end{pmatrix}, \quad \mathbf{X}^\top \mathbf{y} = \begin{pmatrix} 46 \\ 189 \\ 153 \end{pmatrix}.$$

求逆（可用软件，此处给出结果）：

$$(\mathbf{X}^\top \mathbf{X})^{-1} \approx \begin{pmatrix} 1.557 & -0.214 & -0.200 \\ -0.214 & 0.071 & -0.019 \\ -0.200 & -0.019 & 0.092 \end{pmatrix}.$$

最小二乘估计：

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} \approx \begin{pmatrix} 1.17 \\ 1.45 \\ 0.28 \end{pmatrix}.$$

拟合模型： $\hat{y} = 1.17 + 1.45x_1 + 0.28x_2$ 。

11.11.3 Step 2: 拟合值与残差

i	y_i	$\hat{y}_i = 1.17 + 1.45x_{i1} + 0.28x_{i2}$	$\hat{\varepsilon}_i = y_i - \hat{y}_i$	$\hat{\varepsilon}_i^2$
1	4	$1.17 + 1.45(1) + 0.28(3) = 3.46$	+0.54	0.29
2	5	$1.17 + 1.45(2) + 0.28(1) = 4.35$	+0.65	0.42
3	7	$1.17 + 1.45(3) + 0.28(4) = 6.64$	+0.36	0.13
4	8	$1.17 + 1.45(4) + 0.28(2) = 7.53$	+0.47	0.22
5	10	$1.17 + 1.45(5) + 0.28(5) = 9.82$	+0.18	0.03
6	12	$1.17 + 1.45(6) + 0.28(3) = 10.71$	+1.29	1.66

$$\text{RSS} = \sum_{i=1}^6 \hat{\varepsilon}_i^2 = 0.29 + 0.42 + 0.13 + 0.22 + 0.03 + 1.66 = 2.75.$$

11.11.4 Step 3: σ^2 的无偏估计

$$\hat{\sigma}^2 = \frac{\text{RSS}}{N - p - 1} = \frac{2.75}{6 - 2 - 1} = \frac{2.75}{3} \approx 0.917.$$

$\hat{\sigma} = \sqrt{0.917} \approx 0.957$ ——这是模型误差的标准差估计。

11.11.5 Step 4: 系数的标准误与 t 检验

$v_j = [(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}$ (对角元):

$$v_0 \approx 1.557, \quad v_1 \approx 0.071, \quad v_2 \approx 0.092.$$

$$\text{se}(\hat{\beta}_j) = \hat{\sigma} \sqrt{v_j}.$$

系数	估计 $\hat{\beta}_j$	$\text{se}(\hat{\beta}_j)$	t_j	p 值	结论 ($\alpha = 0.05$)
β_0 (截距)	1.17	$0.957 \times \sqrt{1.557} \approx 1.19$	0.98	0.399	不显著
β_1 (x_1)	1.45	$0.957 \times \sqrt{0.071} \approx 0.255$	5.69	0.011	显著
β_2 (x_2)	0.28	$0.957 \times \sqrt{0.092} \approx 0.290$	0.97	0.405	不显著

$t_j = \hat{\beta}_j / \text{se}(\hat{\beta}_j)$, 自由度 = $N - p - 1 = 3$ 。

解读:

- β_1 : $p = 0.011 < 0.05$, 拒绝 $H_0: \beta_1 = 0$ 。 x_1 对 y 有显著的线性贡献。每增加 1 单位 x_1 , y 平均增加约 1.45;
- β_2 : $p = 0.405$, 不能拒绝 $H_0: \beta_2 = 0$ 。单独看, 没有足够证据说明 x_2 有用。但这不自动意味着应该删除 x_2 (见下一节讨论)。

11.11.6 Step 5: F 检验——小模型 vs 大模型

现在考虑是否可以把 x_2 从模型中删掉。比较两个嵌套模型:

- 大模型 M_1 : $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2$, $\text{RSS}_1 = 2.75$, $p_1 = 2$;
- 小模型 M_0 : $y = \beta_0 + \beta_1 x_1$ (去掉 x_2), 重新拟合……

先单独拟合 $y \sim x_1$ (仅截距 + x_1):

$$\mathbf{X}_0 = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \\ 1 & 6 \end{pmatrix}, \quad \hat{\beta}_0 = (\mathbf{X}_0^\top \mathbf{X}_0)^{-1} \mathbf{X}_0^\top \mathbf{y} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} \approx \begin{pmatrix} 2.33 \\ 1.54 \end{pmatrix}.$$

拟合值: $\hat{y}_i^{(0)} = 2.33 + 1.54x_{i1}$: 3.87, 5.41, 6.95, 8.49, 10.03, 11.57。

残差平方和:

$$\text{RSS}_0 \approx (4 - 3.87)^2 + \cdots + (12 - 11.57)^2 \approx 3.62.$$

现在计算 F 统计量 (检验 $H_0: \beta_2 = 0$):

$$F = \frac{(\text{RSS}_0 - \text{RSS}_1)/(p_1 - p_0)}{\text{RSS}_1/(N - p_1 - 1)} = \frac{(3.62 - 2.75)/(2 - 1)}{2.75/3} = \frac{0.87}{0.917} \approx 0.95.$$

$F \sim F_{1,3}$, $p\text{-value} \approx 0.40$ 。

注意: 这里 $p_1 - p_0 = 1$ (只检验一个系数), $F = t_2^2$ ($0.95 \approx 0.97^2$), F 检验的 p 值与 β_2 的 t 检验的 p 值一致——因为检验的是同一个假设 $H_0: \beta_2 = 0$ 。

结论: 不能拒绝 $H_0: \beta_2 = 0$ 。但鉴于样本量极小 ($N = 6$), 我们只能说“没有足够证据支持保留 x_2 ”, 不能说“ x_2 一定没用”。

11.11.7 Step 6: R^2 与模型解释力

总平方和: $\text{TSS} = \sum(y_i - \bar{y})^2$, $\bar{y} = 46/6 \approx 7.67$ 。

$$\text{TSS} = (4 - 7.67)^2 + \cdots + (12 - 7.67)^2 \approx 46.33.$$

$$R^2 = 1 - \frac{\text{RSS}}{\text{TSS}} = 1 - \frac{2.75}{46.33} \approx 0.941.$$

模型解释了 y 约 94% 的变异。但注意 $N = 6$ 时 R^2 会被高估——调整 R^2 (adjusted R^2) 对此做了校正:

$$R_{\text{adj}}^2 = 1 - \frac{\text{RSS}/(N - p - 1)}{\text{TSS}/(N - 1)} = 1 - \frac{2.75/3}{46.33/5} \approx 0.901.$$

11.11.8 Step 7: 95% 置信区间

β_1 的 95% 置信区间 ($t_3^{(0.975)} \approx 3.182$, 自由度小所以临界值大):

$$1.45 \pm 3.182 \times 0.255 \approx 1.45 \pm 0.81 = [0.64, 2.26].$$

解读：我们以 95% 的置信度认为， x_1 每增加 1 单位， y 的增加量在 0.64 到 2.26 之间。区间不包含 0，这与 t 检验拒绝 $H_0: \beta_1 = 0$ 一致。

β_2 的 95% 置信区间：

$$0.28 \pm 3.182 \times 0.290 \approx 0.28 \pm 0.92 = [-0.64, 1.20].$$

区间包含 0，与 t 检验不拒绝 $H_0: \beta_2 = 0$ 一致。但区间非常宽（跨度 1.84），反映了 $N = 6$ 时估计的不确定性很大——这就是为什么“不显著”不等于“效应为零”。

11.11.9 Step 8: 预测新观测

假设新样本 $x_1^* = 3.5$, $x_2^* = 3$ ，点预测为：

$$\hat{y}^* = 1.17 + 1.45 \times 3.5 + 0.28 \times 3 = 7.09.$$

预测的标准误需考虑两个不确定性来源：

$$\text{se}(\hat{y}^*) = \hat{\sigma} \sqrt{1 + x^{*\top}(\mathbf{X}^\top \mathbf{X})^{-1}x^*} \approx 0.957 \times \sqrt{1 + 0.19} \approx 1.04.$$

（根号里的“1”来自 σ^2 ——不可约噪声——“0.19”来自系数估计的不确定性。）

95% 预测区间：

$$7.09 \pm 3.182 \times 1.04 \approx 7.09 \pm 3.31 = [3.78, 10.40].$$

11.11.10 总结：从这个例子学到了什么

- (1) **完整流程：**数据 $\rightarrow \hat{\beta} \rightarrow$ 残差 $\rightarrow \hat{\sigma}^2 \rightarrow$ SE $\rightarrow t$ 检验 $\rightarrow F$ 检验 $\rightarrow R^2 \rightarrow$ CI $\rightarrow$ 预测——每一步都环环相扣；
- (2) **小样本的代价：** $N = 6$, $df = 3$ 时 t 的临界值高达 3.182（相比大样本的 1.96），CI 很宽——同样的 $\hat{\beta}_j$ 在大样本中可能显著，在小样本中却未必；
- (3) **t 检验与 F 检验的等价性：**单变量时 $F = t^2$ ，两者给出相同的 p 值；多变量时 F 检验才有独特价值（联合检验一组系数）；
- (4) **“不显著”不等于“可删除”：** β_2 的 $p = 0.40$ ，但 CI 跨度从 -0.64 到 1.20——真值可能是 0，也可能是 1.0（一个不小的效应）——只是 $N = 6$ 让我们区分不了。

11.12 子集选择与系数收缩

前几节回答了“如何拟合线性模型”和“如何检验系数”。本节回答一个更根本的问题：**哪些变量应该留在模型里？**

11.12.1 为什么要超越最小二乘？

LS 估计 $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 有两个 实践中的不足：

- (1) **预测精度 (Prediction Accuracy)**: LS 估计无偏，但方差可能很大——尤其当 p 较大或变量高度相关时。如果愿意牺牲一点无偏性（引入偏差），换取方差的大幅下降，整体预测误差 (MSE) 可能更低：

$$\text{MSE} = \underbrace{\text{Bias}^2}_{\text{有偏} \Rightarrow \uparrow} + \underbrace{\text{Var}}_{\text{收缩} \Rightarrow \downarrow} + \sigma^2.$$

策略：将某些系数向零收缩，甚至直接置零。

- (2) **可解释性 (Interpretation)**: 预测变量太多时，我们希望找出一个较小的子集，展现“最强效应”。牺牲一些细节，换来对大局的清晰理解。

解决方案三条路径：

- **子集选择 (Subset Selection)**: 只保留一部分变量，其余丢弃（本节）；
- **收缩方法 (Shrinkage)**: 保留所有变量，但把系数向零压缩 (§3.4, 岭回归/Lasso)；
- **降维方法 (Dimension Reduction)**: 将原始变量投影到低维空间 (§3.5, PCR/PLS)。

11.12.2 最优子集选择 (Best-Subset Selection)

定义 11.20 (最优子集选择). 对每个 $k \in \{0, 1, 2, \dots, p\}$ ，在所有 $\binom{p}{k}$ 个可能的 k 变量子集中，找到使 RSS 最小的那个：

$$\mathcal{M}_k = \arg \min_{\text{含 } k \text{ 个变量的模型}} \text{RSS}.$$

算法: leaps and bounds 过程 (Furnival & Wilson, 1974) 使得 $p \leq 30 \sim 40$ 时计算可行。它高效地搜索所有子集而不必穷举。

关键性质:

- RSS 随 k 增大必然单调递减——变量越多，拟合越好（至少不更差）；
- 因此 RSS 本身不能用来选 k （总是倾向于选全模型）；
- 需要其他准则来平衡拟合优度与模型复杂度——交叉验证、AIC、BIC 等（详见第 7 章）；
- 通常选择使期望预测误差估计最小的最小模型。

11.12.3 逐步选择 (Stepwise Selection)

当 p 较大时, $\binom{p}{k}$ 的组合爆炸使得最优子集搜索不可行。逐步选择提供了一条计算上可行的“路径”。

前向逐步选择 (Forward-Stepwise)

第 1 步: 从仅含截距的模型开始;

第 2 步: 在所有不在模型中的变量中, 选择加入后 RSS 下降最多的那个, 将其加入;

第 3 步: 重复步骤 2, 直到模型包含 p 个变量 (或达到预设的 $k_{\max}$)。

特点:

- 贪心算法: 每一步只看眼前最优, 不保证全局最优;
- 嵌套序列: $\mathcal{M}_1 \subset \mathcal{M}_2 \subset \cdots \subset \mathcal{M}_p$;
- 计算高效: 利用 QR 分解的更新公式, 每一步只需很少的额外计算;
- 即使 $p \gg N$ 也能用 (而最优子集和向后选择在 $p > N$ 时不可用)。

后向逐步选择 (Backward-Stepwise)

第 1 步: 从全模型 (含所有 p 个变量) 开始;

第 2 步: 在模型当前的变量中, 选择删除后 RSS 增加最少的那个 (即 $|z|$ 值最小的变量), 将其删除;

第 3 步: 重复步骤 2, 直到模型只剩截距 (或达到预设的 $k_{\min}$)。

限制: 仅当 $N > p$ 时可用 (全模型需要 $\mathbf{X}^T \mathbf{X}$ 可逆)。

三种方法的比较

	最优子集	前向逐步	后向逐步
搜索方式	遍历所有 $\binom{p}{k}$	贪心前向添加	贪心后向删除
是否全局最优	✓	×	×
计算可行性	$p \leq 40$	任意 p (包括 $p \gg N$)	$N > p$
嵌套性	不一定	✓ 必然嵌套	✓ 必然嵌套
方差 vs 偏差	低偏差、高方差 (选择空间大)	较低方差、可能稍高偏差 (搜索受限)	介于两者之间

ESL 的模拟研究 (图 3.6, $N = 300$, $p = 31$, 变量间强相关) 表明: 三种方法的 MSE 曲线非常接近, 前向/后向逐步在实际中通常不输给最优子集太多。

关于基于 F 检验的逐步选择

传统软件包常用 F 检验来决定添加/删除变量 (“添加显著的, 删除不显著的”)。这种做法现在已不受推荐, 原因如下。

多重检验问题 (Multiple Testing) 假设有 $p = 20$ 个候选变量, 全都与 Y 无关。用 $\alpha = 0.05$ 逐个做 t 检验, 每个检验有 5% 的概率 “错误显著” (第一类错误)。20 次独立检验中, 至少一次假显著的概率为:

$$1 - (1 - 0.05)^{20} \approx 0.64.$$

64% 的概率会至少 “发现” 一个虚假的显著变量。而逐步回归在每一步都做检验, 整个过程相当于做了几十甚至几百次检验, 却完全不做任何多重性校正——整体的第一类错误率完全不可控。你 “显著” 的变量中可能有相当一部分纯属运气。

选择后偏倚 (Post-Selection Bias) 更隐蔽的问题是选择后偏倚。逐步选择用数据挑出了 “最好的” 变量子集, 然后用同一份数据报告这些变量的系数、标准误和 p 值。但这些数字已经被选择过程污染了:

- 你选出的正是那些 “看起来显著” 的变量 $\rightarrow$ 它们的 $\hat{\beta}_j$ 被系统性高估 (赢家诅咒);
- 标准误被系统性低估, 因为没有考虑 “我们是从一堆候选变量中挑出来的” 这个事实;
- p 值过于乐观——报告 $p = 0.01$ 的真实意义可能更接近 $p = 0.1$ 。

打个比方：你让 100 个人掷硬币，选出掷出 10 次正面的人，然后宣称“这个人的硬币不是公平的”——你没有考虑他是从 100 个人中**选出来的**。数据的同一个随机波动既被用于“选择他”，又被用于“检验他”——选择过程和推断过程用了同一份数据。

替代方案：

- 使用交叉验证或 AIC/BIC 选择模型大小（而非基于 p 值的阈值）；
- 使用 Lasso 或弹性网等收缩方法——连续收缩，无离散选择，自动避免选择后偏倚；
- 若必须在选择后做推断，可以用**数据分割**（只在训练集上选模型，只在验证集上做推断），或使用专门的**选择性推断 (selective inference)** 方法（如 `selectiveInference` R 包）；
- Bootstrap（第 8.2 节）可以部分校正选择带来的不确定性。

现代实践：收缩方法优于逐步选择 正因为上述问题，现代统计实践中：

- 做变量选择时，首选 **Lasso/弹性网 + 交叉验证**（R: `glmnet::cv.glmnet()`, Python: `sklearn.linear_model.LassoCV`），让 L_1 惩罚自动收缩/置零，看交叉验证误差曲线选 λ （推荐用 1-SE rule 取 `lambda.1se`）；
- 逐步选择（基于 AIC 的 `step()`）在探索性分析中仍有使用，但应被视为**模型建议**而非**统计推断**——不能信任其 p 值和标准误；
- 基于 p 值阈值的 add/drop 逐步选择（如 SPSS 的默认行为）应**避免使用**。

其他实践注意事项

- **分组变量：**哑变量编码的多水平分类变量应作为一个整体同时添加或删除，‘R’ 的 ‘`step()`’ 函数默认如此（按自由度整体处理）；
- **混合策略：**‘R’ 的 ‘`step()`’ 在每一步同时考虑前向和后向移动，选择使 AIC 最小的那一步——比纯前向/纯后向更灵活。

11.12.4 前向分段回归 (Forward-Stagewise Regression)

前向分段回归是比前向逐步**更加保守**的方法：

第 1 步： 所有系数初始化为 0，中心化所有预测变量；

第 2 步： 计算当前残差 $\mathbf{r} = \mathbf{y} - \hat{\mathbf{y}}$ ；

第 3 步： 找到与残差**相关性最大**的变量 $\mathbf{x}_j$ ；

第 4 步：将残差对 $\mathbf{x}_j$ 做单变量回归，得增量 $\delta_j = \langle \mathbf{x}_j, \mathbf{r} \rangle / \langle \mathbf{x}_j, \mathbf{x}_j \rangle$ ；

第 5 步：只更新 $\hat{\beta}_j \leftarrow \hat{\beta}_j + \delta_j$ ，其他系数不变；

第 6 步：重复步骤 2-5，直到所有变量与残差的相关性都低于阈值。

与前向逐步的关键区别：

- 前向逐步每次添加变量后，会重新调整所有已选变量的系数（做完整 LS）；
- 前向分段不调整其他变量——只对被选中的那个变量做一次单变量更新；
- 因此前向分段可能需要远超 p 步才能逼近 LS 解（ESL 的例子中超过 1000 步）。

为什么需要这么慢的方法？

- 在高维问题（ $p \gg N$ ）中，LS 甚至不存在唯一解；
- “慢拟合”相当于一种隐式的正则化——每步只走一点点，类似于梯度下降的小步长，避免过拟合；
- 与后续的 Lasso 和 LAR (§3.8) 有深刻联系。

11.12.5 小结：子集选择的统一视角

三种子集选择方法构成了一个约束强度递增的谱系：

方法	搜索空间	约束强度	适用场景
最优子集	所有 $\binom{p}{k}$ 子集	最弱	$p \leq 40$ ，追求最优
前向/后向逐步	序列化嵌套路径	中等	p 较大，计算均衡
前向分段	比逐步更慢、更受限	最强	高维（ $p \gg N$ ），隐式正则化

核心教训：

- 搜索空间越大 $\rightarrow$ 偏差越低、方差越高。限制搜索（前向逐步、前向分段）是一种用偏差换方差的策略——与收缩方法（岭回归/Lasso）殊途同归；
- 模型选择 $\neq$ 推断：选择后的标准误和 p 值不可信——模型选择是预测导向的工具，不是推断工具；
- 下一节 (§3.4) 将引入收缩方法——保留所有变量但压缩系数，用连续的惩罚代替离散的“选/不选”决策。

11.13 收缩方法 (Shrinkage Methods)

子集选择是离散的——变量要么在模型里，要么不在。这种“硬”决策导致高方差：数据稍有扰动，选出的子集可能完全不同。**收缩方法**用连续的方式替代离散选择：保留所有变量，但把系数向零压缩。

11.13.1 前列腺癌实例回顾

在进入方法细节之前，先看表 11.13.1 中所有方法的对比结果。表中展示了 LS、最优子集、岭回归、Lasso、主成分回归 (PCR) 和偏最小二乘 (PLS) 的估计系数和测试误差。

项	LS	最优子集	岭回归	Lasso	PCR	PLS
Intercept	2.465	2.477	2.452	2.468	2.497	2.452
lcavol	0.680	0.740	0.420	0.533	0.543	0.419
lweight	0.263	0.316	0.238	0.169	0.289	0.344
age	-0.141		-0.046		-0.152	-0.026
lbph	0.210		0.162	0.002	0.214	0.220
svi	0.305		0.227	0.094	0.315	0.243
lcp	-0.288		0.000		-0.051	0.079
gleason	-0.021		0.040		0.232	0.011
pgg45	0.267		0.133	-0.056	0.084	
测试误差	0.521	0.492	0.492	0.479	0.449	0.528
标准误	0.179	0.143	0.165	0.164	0.105	0.152

复杂度参数的选择：每种方法都有一个复杂度参数（子集大小 k 、惩罚 λ 、主成分个数等），通过**十折交叉验证 (10-fold CV)** 选择：将训练集随机分成 10 份，每次用 9 份训练、1 份验证，轮换 10 次取平均预测误差。选择一个**标准误规则 (one-standard-error rule)**：取在最小 CV 误差一个标准误以内的最简约模型。

关键观察：

- LS 的测试误差为 0.521；所有收缩方法都降低了测试误差；
- 最优子集只选了 lcavol 和 lweight 两个变量；
- 注意 LS 中 lcavol 系数最大 (0.680)，岭回归将其收缩到 0.420，Lasso 进一步收缩到 0.533——但都保留了它。

11.13.2 岭回归 (Ridge Regression)

定义与两种等价形式

岭回归在线性回归的 RSS 上增加一个系数的平方和惩罚：

定义 11.21 (岭回归——惩罚形式 (Lagrangian)).

$$\hat{\beta}^{\text{ridge}} = \arg \min_{\beta} \left\{ \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}. \quad (11.55)$$

其中 $\lambda \geq 0$ 是复杂度参数： λ 越大，收缩越强。

定义 11.22 (岭回归——约束形式). 等价地：

$$\hat{\beta}^{\text{ridge}} = \arg \min_{\beta} \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 \quad \text{s.t.} \quad \sum_{j=1}^p \beta_j^2 \leq t. \quad (11.56)$$

λ 与 t 一一对应： $\lambda = 0 \Leftrightarrow t = \infty$ (LS), $\lambda \rightarrow \infty \Leftrightarrow t \rightarrow 0$ (仅截距)。

注意：

- 截距 β_0 不参与惩罚。惩罚截距会使得模型依赖于 Y 的原点选择——给所有 y_i 加常数 c ，预测不应只平移 c ；
- 输入需标准化。惩罚 $\sum \beta_j^2$ 不是尺度不变的—— β_j 的大小依赖于 x_j 的单位。标准做法是将每个 x_j 中心化并缩放到单位方差后，用 $\bar{y}$ 估计 β_0 ，对中心化后的 $\mathbf{X}$ 做无截距岭回归。

矩阵形式与闭式解

中心化后，设 $\mathbf{X}$ 为 $N \times p$ (不含截距列， p 个变量均中心化)，岭回归准则为：

$$\text{RSS}(\lambda) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) + \lambda \boldsymbol{\beta}^\top \boldsymbol{\beta}. \quad (11.57)$$

求导并令其为零：

$$\boxed{\hat{\beta}^{\text{ridge}} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}}. \quad (11.58)$$

与 LS 的唯一区别：对角线上加了 λ 。这使得：

- 即使 $\mathbf{X}^\top \mathbf{X}$ 奇异 ($p > N$ 或完全共线性)， $(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})$ 总是可逆；
- 当 $\lambda = 0$ 时退化为 LS；
- $\hat{\beta}^{\text{ridge}}$ 仍然是 $\mathbf{y}$ 的线性函数。

贝叶斯解释

岭回归有自然的贝叶斯解读。假设：

$$y_i | \mathbf{x}_i, \boldsymbol{\beta}, \sigma^2 \sim \mathcal{N}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2), \quad \beta_j \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \tau^2).$$

则 $\boldsymbol{\beta}$ 的（负对数）后验密度正比于：

$$\frac{1}{\sigma^2} \sum_{i=1}^N (y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 + \frac{1}{\tau^2} \sum_{j=1}^p \beta_j^2.$$

这恰好是岭回归准则 (11.55)，其中 $\lambda = \sigma^2/\tau^2$ 。因此：**岭估计 = 高斯先验 $\mathcal{N}(0, \tau^2)$ 下的后验众数（也是后验均值）**。 τ^2 越大（先验越扩散） $\rightarrow \lambda$ 越小 $\rightarrow$ 越接近 LS。

11.13.3 岭回归的 SVD 视角

对中心化后的 $\mathbf{X}$ 做奇异值分解 (SVD)，可以最深刻地理解岭回归在做什么。

定义 11.23 (SVD of $\mathbf{X}$).

$$\underset{N \times p}{\mathbf{X}} = \underset{N \times p}{\mathbf{U}} \underset{p \times p}{\mathbf{D}} \underset{p \times p}{\mathbf{V}}^\top, \quad (11.59)$$

其中：

- $\mathbf{U}$ ($N \times p$): 列正交 ($\mathbf{U}^\top \mathbf{U} = \mathbf{I}$)，列空间 = $\mathbf{X}$ 的列空间；
- $\mathbf{V}$ ($p \times p$): 正交 ($\mathbf{V}^\top \mathbf{V} = \mathbf{V} \mathbf{V}^\top = \mathbf{I}$)；
- $\mathbf{D}$ ($p \times p$): 对角阵， $d_1 \geq d_2 \geq \dots \geq d_p \geq 0$ 为**奇异值**。

LS 的 SVD 表示

利用 SVD，LS 的拟合值可写为：

$$\mathbf{X} \hat{\boldsymbol{\beta}}^{\text{ls}} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \mathbf{U} \mathbf{U}^\top \mathbf{y} = \sum_{j=1}^p \mathbf{u}_j (\mathbf{u}_j^\top \mathbf{y}). \quad (11.60)$$

$\mathbf{u}_j^\top \mathbf{y}$ 是 $\mathbf{y}$ 在正交基 $\mathbf{u}_j$ 上的坐标；LS 不做任何收缩——直接将 $\mathbf{y}$ 投影到 $\mathbf{U}$ 的列空间。

岭回归的 SVD 表示

代入岭回归解：

$$\begin{aligned} \mathbf{X} \hat{\boldsymbol{\beta}}^{\text{ridge}} &= \mathbf{X}(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y} \\ &= \mathbf{U} \mathbf{D} (\mathbf{D}^2 + \lambda \mathbf{I})^{-1} \mathbf{D} \mathbf{U}^\top \mathbf{y} \\ &= \sum_{j=1}^p \mathbf{u}_j \underbrace{\frac{d_j^2}{d_j^2 + \lambda}}_{\text{收缩因子}} (\mathbf{u}_j^\top \mathbf{y}). \end{aligned} \quad (11.61)$$

核心洞察：

- 岭回归和 LS 使用同一个正交基 $\mathbf{U}$;
- 区别在于每个方向上乘以了收缩因子 $\frac{d_j^2}{d_j^2 + \lambda} \leq 1$;
- d_j^2 大 (高方差方向) $\rightarrow$ 收缩因子接近 1 $\rightarrow$ 几乎不收缩;
- d_j^2 小 (低方差方向) $\rightarrow$ 收缩因子接近 0 $\rightarrow$ 大量收缩。

追问：为什么 d_j^2 大就是“高方差方向”？

这需要从 SVD 与 PCA 的联系来理解。 $\mathbf{X}$ 是中心化后的设计矩阵，其（缩放）协方差矩阵为 $\frac{1}{N}\mathbf{X}^\top\mathbf{X}$ 。对 $\mathbf{X}^\top\mathbf{X}$ 做特征分解：

$$\mathbf{X}^\top\mathbf{X} = \mathbf{V}\mathbf{D}^2\mathbf{V}^\top.$$

$\mathbf{V}$ 的列 $\mathbf{v}_j$ 是特征向量（主成分方向），对角阵 $\mathbf{D}^2$ 的对角元 d_j^2 是特征值。

现在看投影 $\mathbf{z}_j = \mathbf{X}\mathbf{v}_j$ （第 j 个主成分得分）。由 SVD $\mathbf{X} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$ 得：

$$\mathbf{z}_j = \mathbf{X}\mathbf{v}_j = \mathbf{U}\mathbf{D}\mathbf{V}^\top\mathbf{v}_j = \mathbf{U}\mathbf{D}\mathbf{e}_j = \mathbf{u}_jd_j.$$

这个投影的样本方差为：

$$\text{Var}(\mathbf{z}_j) = \frac{1}{N}\mathbf{z}_j^\top\mathbf{z}_j = \frac{1}{N}(\mathbf{u}_jd_j)^\top(\mathbf{u}_jd_j) = \frac{d_j^2}{N}.$$

追问：为什么 $\text{Var}(\mathbf{z}_j) = \frac{1}{N}\mathbf{z}_j^\top\mathbf{z}_j$ ？向量方差的定义是什么？

$\mathbf{z}_j = (z_{1j}, z_{2j}, \dots, z_{Nj})^\top$ 是一个 N 维向量，每个分量 z_{ij} 是第 i 个观测在第 j 个主成分上的得分。

N 个标量 $\{z_{1j}, \dots, z_{Nj}\}$ 的样本方差定义为：

$$\text{Var}(\mathbf{z}_j) = \frac{1}{N} \sum_{i=1}^N (z_{ij} - \bar{z}_j)^2.$$

关键： $\mathbf{X}$ 已经中心化（每列均值为 0），而 $\mathbf{z}_j = \mathbf{X}\mathbf{v}_j$ 是中心化列的一个线性组合，因此 $\bar{z}_j = 0$ 。于是：

$$\text{Var}(\mathbf{z}_j) = \frac{1}{N} \sum_{i=1}^N z_{ij}^2 = \frac{1}{N} \mathbf{z}_j^\top \mathbf{z}_j.$$

（严格来说，无偏样本方差用 $N-1$ 。这里用 $1/N$ 是 ESL 的约定——将 $\frac{1}{N}\mathbf{X}^\top\mathbf{X}$ 视作协方差矩阵的估计， d_j^2/N 视作该方向的方差估计。用 N 还是 $N-1$ 只差一个常数因子，不影响 PCA 方向的排序。）

所以： d_j^2 直接正比于第 j 个主成分方向的投影方差。 $d_1^2 \geq d_2^2 \geq \dots \geq d_p^2$ 意味着第一主成分捕获了最多的数据变异，最后一主成分变异最小。

回到岭回归：收缩因子 $\frac{d_j^2}{d_j^2 + \lambda}$ 的意思是——数据在某个方向上散布得越开（ d_j^2 越大），我们越信任该方向的 LS 估计，收缩越少；散布得越窄（ d_j^2 越小），该方向的估计越不可靠（方差大），收缩越多。这就是岭回归保护我们不被低方差方向上不可靠的梯度估计所伤害的机制。

11.13.4 主成分与方差方向

SVD 中的 $\mathbf{V}$ 和 $\mathbf{D}$ 与 $\mathbf{X}$ 的主成分分析 (PCA) 密切相关。样本协方差矩阵的特征分解为:

$$\mathbf{X}^\top \mathbf{X} = \mathbf{V} \mathbf{D}^2 \mathbf{V}^\top. \quad (11.62)$$

$\mathbf{v}_j$ ($\mathbf{V}$ 的第 j 列) 是第 j 个主成分方向。投影 $\mathbf{z}_j = \mathbf{X} \mathbf{v}_j = \mathbf{u}_j d_j$ 是第 j 个主成分, 其方差为 $\text{Var}(\mathbf{z}_j) = d_j^2/N$ 。

- **第一主成分:** 投影方差最大 (d_1^2/N) 的方向;
- **最后一主成分:** 投影方差最小的方向。

岭回归的隐含假设: 响应 Y 倾向于在输入的高方差方向上变化最多。这在实践中常常成立 (预测变量之所以被选中, 正是因为它们与响应有关), 但不是必然。

11.13.5 有效自由度

岭回归虽然估计了 p 个系数, 但由于 λ 的约束, **有效自由度** 小于 p :

$$\text{df}(\lambda) = \text{tr}(\mathbf{H}_\lambda) = \text{tr}(\mathbf{X}(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top) = \sum_{j=1}^p \frac{d_j^2}{d_j^2 + \lambda}. \quad (11.63)$$

- $\lambda = 0$: $\text{df} = p$ (无正则化, 每个变量贡献 1 个自由度);
- $\lambda \rightarrow \infty$: $\text{df} \rightarrow 0$ (所有系数被压缩到零, 只剩截距);
- $\text{df}(\lambda)$ 是 λ 的单调递减函数。

在交叉验证中, 通常将误差曲线画成 $\text{df}(\lambda)$ 的函数 (而非 λ 本身), 因为这在不同方法间具有可比性。

11.13.6 Lasso

定义

Lasso (Least Absolute Shrinkage and Selection Operator) 将岭回归的 L_2 惩罚替换为 L_1 惩罚:

定义 11.24 (Lasso——约束形式).

$$\hat{\boldsymbol{\beta}}^{\text{lasso}} = \arg \min_{\boldsymbol{\beta}} \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 \quad \text{s.t.} \quad \sum_{j=1}^p |\beta_j| \leq t. \quad (11.64)$$

定义 11.25 (Lasso——Lagrangian 形式).

$$\hat{\boldsymbol{\beta}}^{\text{lasso}} = \arg \min_{\boldsymbol{\beta}} \left\{ \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}. \quad (11.65)$$

Lasso 与岭回归的本质区别

	岭回归 (L_2)	Lasso (L_1)
惩罚	$\sum \beta_j^2$	$\sum \beta_j $
解的闭式	✓ $\hat{\beta} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}$	× 需迭代算法
对 $\mathbf{y}$ 的线性性	✓ 线性	× 非线性
稀疏性	× 系数都非零	✓ 可将系数精确压缩到 0
变量选择	×	✓ 自带变量选择功能
几何形状	球形约束域	菱形约束域（有尖角）

Lasso 为何能得到零系数？关键在于 L_1 约束域的尖角。RSS 的等高线（椭圆）与菱形约束域的接触点最容易落在坐标轴上（即某些 $\beta_j = 0$ ）。而球形约束域（ L_2 ）与椭圆的切点几乎总在内部，所有系数非零。

一句话：岭回归把大系数压小，Lasso 把小系数压到零。因此 Lasso 同时做了**收缩 + 变量选择**，而岭回归只做收缩。

11.13.7 正交输入情形下的统一视角

当输入矩阵 $\mathbf{X}$ 的列彼此正交时（ $\mathbf{X}^\top \mathbf{X} = \mathbf{I}$ ），三种方法都有显式解。设 $\hat{\beta}_j^{\text{ls}}$ 为 LS 估计，则：

方法	公式	操作
最优子集 (size M)	$\hat{\beta}_j \cdot I(\hat{\beta}_j \geq \hat{\beta}_{(M)})$	硬阈值：保留最大的 M 个，其余置零
岭回归	$\hat{\beta}_j / (1 + \lambda)$	比例收缩：所有系数等比缩放
Lasso	$\text{sign}(\hat{\beta}_j)(\hat{\beta}_j - \lambda)_+$	软阈值：向零平移 λ ，过零则截断

其中 $x_+ = \max(x, 0)$ 表示”正部”。这揭示了三个方法的本质：

- **岭回归：**均匀收缩，无一为零——”大家都少一点”；
- **Lasso：**软阈值——”不够强的直接清零，够强的减去一个常数”；
- **最优子集：**硬阈值——”只留前 M 名，其余全砍”。

在非正交情形下，没有如此简洁的显式解，但**几何直觉**仍然成立。




图 11.1: 三种收缩方法的可视化比较。灰色 45° 线为 OLS 基准（无收缩）；红色虚线分别为最优子集（硬阈值）、岭回归（比例收缩）和 Lasso（软阈值）。横轴为 OLS 估计 $\hat{\beta}_j^{\text{ls}}$ ，纵轴为各方法的估计值。

11.13.8 几何直观： $p = 2$ 时的图形比较

图 3.11 是理解 Lasso 与岭回归差异的最经典图示。考虑 $p = 2$ （两个预测变量）：

- **RSS 等高线**：以 LS 估计 $\hat{\beta}^{\text{ls}}$ 为中心的椭圆；
- **岭回归约束域**：圆盘 $\beta_1^2 + \beta_2^2 \leq t$ （光滑边界）；
- **Lasso 约束域**：菱形 $|\beta_1| + |\beta_2| \leq t$ （有四个尖角）。

两种方法都在寻找 RSS 等高线首次触及约束域边界的那一点。

关键差异：

- 圆盘没有角落 $\rightarrow$ 切点几乎总在弧上 $\rightarrow \beta_1 \neq 0$ 且 $\beta_2 \neq 0$ ；
- 菱形有尖角 $\rightarrow$ 如果切点落在角上（如 β_1 轴上），则 $\beta_2 = 0$ 。

当 $p > 2$ 时，约束域变为菱形体 (rhomboid)，有大量的角、棱和面——因此 Lasso 有很多机会将某些系数精确置零。

图中三种元素的含义（逐层解读）

为彻底理解这张图，把图中的元素拆成三层来看：

1. 红色同心椭圆——RSS 等高线

$$\text{RSS}(\beta) = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta)$$

- 椭圆中心 $\hat{\beta}^{\text{ls}}$ 是无约束最小二乘解——RSS 的全局最小值点。
- 每一条椭圆线代表 RSS 取某一固定值；越靠近中心 RSS 越小，越远离 RSS 越大。
- 如果没有约束，最优解就是椭圆中心本身。

2. 蓝色区域——约束范围（可行域）

	Lasso（左图）	Ridge（右图）
约束形式	$ \beta_1 + \beta_2 \leq t$	$\beta_1^2 + \beta_2^2 \leq t^2$
几何形状	菱形（ L_1 球）	圆形（ L_2 球）
边界特征	有四个尖角（在坐标轴上）	处处光滑，没有尖角

参数必须在蓝色区域内部（或边界上）取值——这是正则化施加的硬约束。

3. 最优解：椭圆首次碰到蓝色区域的那个点

约束优化问题等价于从椭圆中心出发，逐步扩大 RSS 椭圆的半径。椭圆扩大的过程中，第一次触碰到蓝色区域边界的那个点，就是约束下的最优解 $\hat{\beta}^{\text{constrained}}$ 。

为什么 Lasso 产生零系数而 Ridge 不能？

关键全在尖角上：

- **Lasso (菱形)**：菱形在坐标轴上有四个尖角，例如 $(\beta_1, 0)$ 或 $(0, \beta_2)$ 。当 RSS 椭圆向外扩展时，**极易先碰到尖角**——此时交点恰好落在坐标轴上，意味着其中一个参数被精确压到 0。
- **Ridge (圆形)**：圆形处处光滑。RSS 椭圆与圆的切点几乎总在弧的内部——两坐标均非零。系数被压缩，但**从不精确为零**。

一句话总结：

Lasso 的 L_1 约束域有尖角，

RSS 椭圆碰到尖角时就自动做了变量选择——不重要的系数精确置零。

当 $p \gg 2$ 时， L_1 约束域变为高维菱形体，拥有大量的角、棱和面，Lasso 有更多机会将不重要的系数精确置零——这就是它的高维问题中表现优异的原因。

11.13.9 一般 L_q 惩罚与贝叶斯统一视角

三种方法可以纳入一个统一的 L_q 惩罚框架：

$$\tilde{\beta} = \arg \min_{\beta} \left\{ \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \sum_{j=1}^p |\beta_j|^q \right\}, \quad q \geq 0. \quad (11.66)$$

不同 q 值对应不同方法：

q	方法	先验分布	约束域形状
0	最优子集	尖峰-平板 (spike-and-slab)	计数惩罚 (非凸)
1	Lasso	拉普拉斯 (双指数)	菱形 (凸)
2	岭回归	高斯	球 (凸)

贝叶斯解读：将 $\sum |\beta_j|^q$ 视为 β_j 的负对数先验密度，则：

- $q = 2$ ：高斯先验 $\beta_j \sim \mathcal{N}(0, \tau^2)$ ， $\lambda = \sigma^2/\tau^2$ ；
- $q = 1$ ：拉普拉斯先验 $p(\beta_j) = \frac{1}{2\tau} \exp(-|\beta_j|/\tau)$ ， $\tau = 1/\lambda$ ；
- $q < 1$ ：先验在坐标轴方向上集中更多质量——更容易产生零系数。

推导：从最大后验 (MAP) 到正则化

考虑线性模型 $y_i = \beta_0 + \sum_j x_{ij}\beta_j + \varepsilon_i$, $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ 。似然函数为：

$$p(\mathbf{y} | \boldsymbol{\beta}) \propto \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij}\beta_j\right)^2\right).$$

为 β_j 引入独立先验 $p(\beta_j) \propto \exp(-|\beta_j|^q/\tau)$ 。由贝叶斯定理，后验：

$$p(\boldsymbol{\beta} | \mathbf{y}) \propto p(\mathbf{y} | \boldsymbol{\beta}) \cdot \prod_{j=1}^p p(\beta_j).$$

取负对数，最大化后验 (MAP) 等价于最小化：

$$-\log p(\boldsymbol{\beta} | \mathbf{y}) = \underbrace{\frac{1}{2\sigma^2} \sum_{i=1}^N \left(y_i - \beta_0 - \sum_j x_{ij}\beta_j\right)^2}_{\text{RSS} / 2\sigma^2} + \underbrace{\frac{1}{\tau} \sum_{j=1}^p |\beta_j|^q}_{\text{负对数先验}} + \text{const.}$$

乘以 $2\sigma^2$ ，令 $\lambda = 2\sigma^2/\tau$ ，即得：

$$\hat{\boldsymbol{\beta}}^{\text{MAP}} = \arg \min_{\boldsymbol{\beta}} \left\{ \text{RSS} + \lambda \sum_{j=1}^p |\beta_j|^q \right\}$$

这就是正则化框架：惩罚系数 λ 本质上编码了先验强度 (τ 小 $\Rightarrow \lambda$ 大 $\Rightarrow$ 先验强 $\Rightarrow$ 强收缩)。

为什么 $q = 2$ 对应高斯， $q = 1$ 对应拉普拉斯？

核心对应关系： L_q 惩罚 $\leftrightarrow$ 指数幂分布族

$$p(\beta) \propto \exp(-|\beta|^q/\tau)$$

具体展开：

q	先验密度形式	分布名称	在 0 处的形状
2	$p(\beta) \propto \exp\left(-\frac{\beta^2}{2\tau^2}\right)$	$\mathcal{N}(0, \tau^2)$ (高斯)	光滑抛物线，可微
1	$p(\beta) \propto \exp\left(-\frac{ \beta }{\tau}\right)$	Laplace(0, τ) (拉普拉斯/双指数)	尖峰，在 0 处不可微
0	$p(\beta)$ 为 0 处点质量 + 平坦尾部的混合	尖峰-平板 (spike-and-slab)	极端集中

几何直觉：为什么拉普拉斯先验导致稀疏？

- **高斯先验** ($q = 2$)：在 $\beta_j = 0$ 附近光滑、平缓——先验并不特别偏爱零值，后验众数几乎不会精确落在 0 上。
- **拉普拉斯先验** ($q = 1$)：在 $\beta_j = 0$ 处有一个**尖峰**——先验强烈倾向于零。只要数据没有压倒性证据，MAP 估计就会精确落在 0。

换个角度：拉普拉斯分布的尾部比高斯更重——如果 β_j 真的非零，它允许系数取到较大值而不被过度惩罚。这正是 Lasso 的优势：**对小系数”赶尽杀绝”（压到 0），对大系数”网开一面”（只减去常数 λ ）。**

注意：以上都是后验众数（mode）。岭回归同时也是后验均值（因为高斯后验对称），但 Lasso 和最优子集的后验均值不等于后验众数。

为什么 $q = 1$ 是”神奇”的值？

- $q = 1$ 是使得约束域**凸**的最小 q ($q < 1$ 时为非凸，优化困难)；
- $q = 1$ 是使得约束域在坐标轴上有**尖角**的最大 q ($q > 1$ 时在零点可微，无尖角 $\rightarrow$ 无稀疏性)。

因此 $q = 1$ 是唯一同时满足**凸性**（易于优化）+ **稀疏性**（可产生零系数）的值。

11.13.10 弹性网 (Elastic Net)

$q \in (1, 2)$ 的 L_q 惩罚是岭回归和 Lasso 的折中，但在零点处可微（无尖角），因此不能产生稀疏解。Zou & Hastie (2005) 提出了弹性网惩罚：

$$\lambda \sum_{j=1}^p \left(\alpha \beta_j^2 + (1 - \alpha) |\beta_j| \right). \quad (11.67)$$

弹性网 = 岭回归 (L_2) + Lasso (L_1) 的**凸组合**，通过 $\alpha \in [0, 1]$ 调节两者权重：

- $\alpha = 0$ ：退化为 Lasso；
- $\alpha = 1$ ：退化为岭回归；
- 中间值：同时具备两者的优点。

弹性网的优势：

- **变量选择**： L_1 部分保留尖角 $\rightarrow$ 可产生稀疏解，像 Lasso；
- **处理相关变量**： L_2 部分使高度相关的变量系数被一起收缩，像岭回归；
- **计算优势**：比一般的 L_q ($1 < q < 2$) 更容易优化；
- **高维适用**：当 $p \gg N$ 时，Lasso 最多选 N 个变量，弹性网可以选更多。

11.13.11 最小角回归 (LAR)——Lasso 的高效算法

Lasso 没有闭式解，如何高效计算整个解路径（随 λ 变化的所有 $\hat{\beta}^{\text{lasso}}$ ）？答案是最小角回归 (Least Angle Regression, LAR) (Efron et al., 2004)。

与前向逐步的对比

- **前向逐步**：每次选出与残差最相关的变量，然后完全拟合该变量（调整到 LS 值），再找下一个变量。偏好过于激进——一旦加入就“吃饱”；
- **LAR**：每次选出与残差最相关的变量，但只让它的系数沿 LS 方向移动，直到另一个变量与残差的相关性追上来。然后两者一起移动，保持相关性相等。这是一种“民主”的前向逐步——每个变量只得到它“应得”的那份。

算法直觉

第 1 步：所有系数初始化为 0，残差 $\mathbf{r} = \mathbf{y} - \bar{y}$ ；

第 2 步：找到与 $\mathbf{r}$ 最相关的变量 $\mathbf{x}_{j_1}$ ；

第 3 步：将 $\hat{\beta}_{j_1}$ 从 0 向 LS 方向移动。随 $\hat{\beta}_{j_1}$ 增大， $\mathbf{x}_{j_1}$ 与残差的相关性逐渐下降；

第 4 步：当某个其他变量 $\mathbf{x}_{j_2}$ 与残差的相关性追上来（等于 $\mathbf{x}_{j_1}$ 的），将其加入活跃集；

第 5 步：现在同时移动 $\hat{\beta}_{j_1}$ 和 $\hat{\beta}_{j_2}$ ，保持两者与残差的相关性相等且逐步减小；

第 6 步：重复，直到所有变量都进入模型（或残差为 0）。

与 Lasso 的深刻联系：LAR 稍加修改（当一个系数穿过零时从活跃集中移除该变量），就精确等价于 Lasso 的解路径。因此 LAR 提供了一种计算整个 Lasso 路径的高效方法——计算量与单次 LS 拟合相当。

11.13.12 小结：收缩方法谱系

	子集选择	岭回归	Lasso
操作方式	/		+
解的线性性	×	✓	×
稀疏性	✓	×	✓
变量选择	✓	×	✓
方差			
偏差			
高维适用	p	✓	✓
贝叶斯解释	(<i>spike</i>)		

核心教训：

- 子集选择的离散性导致高方差——数据微小扰动可能选出完全不同的子集；
- 岭回归通过 L_2 惩罚连续收缩，方差低但无稀疏性；
- Lasso 通过 L_1 惩罚同时实现收缩和变量选择——是现代高维统计的基准方法；
- 正交情形下三者有统一显式解：硬阈值 / 比例收缩 / 软阈值；
- LAR 为 Lasso 提供了高效的计算路径——增量式地、“民主”地添加变量；
- 弹性网结合 $L_1 + L_2$ ，在有相关变量和高维场景下优于纯 Lasso。

11.14 使用导出输入方向的方法 (Derived Input Directions)

前两节（子集选择和收缩方法）通过控制系数来正则化。另一种思路是：先把原始变量降维，在低维空间做回归。这是一种“先压缩、再回归”的策略。

11.14.1 主成分回归 (PCR)

定义 11.26 (主成分回归). PCR 的执行步骤：

第 1 步：对 $\mathbf{X}$ （中心化后）做 PCA，取前 M 个主成分 $\mathbf{z}_1, \dots, \mathbf{z}_M$ ；

第 2 步：将 $\mathbf{y}$ 对 $\mathbf{z}_1, \dots, \mathbf{z}_M$ 做普通最小二乘。

关键特征：

- 主成分 $\mathbf{z}_m = \mathbf{X}\mathbf{v}_m$ 的选择只依赖 $\mathbf{X}$ ，不依赖 $\mathbf{y}$ ；
- PCR 丢弃了低方差方向——这些方向上信噪比通常最差；
- 但与 PLS 不同，PCR 不考虑 $\mathbf{y}$ ——高方差方向不一定预测力强。

11.14.2 偏最小二乘 (PLS)

PLS 的思想是：在构造降维方向时同时考虑 $\mathbf{x}$ 的方差和与 $\mathbf{y}$ 的相关性。

定义 11.27 (PLS 算法 (Algorithm 3.3)). 第 1 步： 标准化所有 $\mathbf{x}_j$ (均值 0, 方差 1), 设 $\hat{\mathbf{y}}^{(0)} = \bar{y}\mathbf{1}$;

第 2 步： 对 $m = 1, 2, \dots, p$:

- (a) $\mathbf{z}_m = \sum_{j=1}^p \hat{\phi}_{mj} \mathbf{x}_j^{(m-1)}$, 其中 $\hat{\phi}_{mj} = \langle \mathbf{x}_j^{(m-1)}, \mathbf{y} \rangle$;
- (b) $\hat{\theta}_m = \langle \mathbf{z}_m, \mathbf{y} \rangle / \langle \mathbf{z}_m, \mathbf{z}_m \rangle$;
- (c) $\hat{\mathbf{y}}^{(m)} = \hat{\mathbf{y}}^{(m-1)} + \hat{\theta}_m \mathbf{z}_m$;
- (d) 将每个 $\mathbf{x}_j^{(m-1)}$ 关于 $\mathbf{z}_m$ 正交化: $\mathbf{x}_j^{(m)} = \mathbf{x}_j^{(m-1)} - [\langle \mathbf{z}_m, \mathbf{x}_j^{(m-1)} \rangle / \langle \mathbf{z}_m, \mathbf{z}_m \rangle] \mathbf{z}_m$.

第 3 步： 输出拟合序列 $\{\hat{\mathbf{y}}^{(m)}\}_{m=1}^p$.

PLS 与 PCR 的核心区别：

- **PCR**: 选择方向只最大化 $\text{Var}(\mathbf{X}\boldsymbol{\alpha})$ (不管 $\mathbf{y}$);
- **PLS**: 选择方向最大化 $\text{Corr}^2(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha}) \cdot \text{Var}(\mathbf{X}\boldsymbol{\alpha})$ (同时考虑方差和相关性)。

实证研究表明: PLS 中方差项倾向于占主导地位, 因此 PLS 的表现与岭回归和 PCR 非常相似。Frank & Friedman (1993) 结论: 就最小化预测误差而言, 岭回归通常优于变量子集选择、PCR 和 PLS, 但优势仅略微。

有趣的事实: 如果 $\mathbf{X}$ 的列正交, PLS 在 $m = 1$ 步后就得到 LS 解——后续步骤没有效果 (因为 $\hat{\phi}_{mj} = 0, m > 1$)。PLS 系数序列 $m = 1, 2, \dots, p$ 恰好是计算 LS 解的共轭梯度序列。

11.14.3 PCR 与 PLS 的优化问题

第 m 个 PCR 方向 $\mathbf{v}_m$ 求解:

$$\max_{\boldsymbol{\alpha}} \text{Var}(\mathbf{X}\boldsymbol{\alpha}) \quad \text{s.t.} \quad \|\boldsymbol{\alpha}\| = 1, \quad \boldsymbol{\alpha}^\top \mathbf{S}\mathbf{v}_\ell = 0, \quad \ell = 1, \dots, m-1. \quad (11.68)$$

第 m 个 PLS 方向 $\hat{\phi}_m$ 求解:

$$\max_{\boldsymbol{\alpha}} \text{Corr}^2(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha}) \cdot \text{Var}(\mathbf{X}\boldsymbol{\alpha}) \quad \text{s.t.} \quad \|\boldsymbol{\alpha}\| = 1, \quad \boldsymbol{\alpha}^\top \mathbf{S}\hat{\phi}_\ell = 0, \quad \ell = 1, \dots, m-1. \quad (11.69)$$

11.14.4 深入理解 PLS：正交投影、实例与动机

从正交投影看 PLS

PLS 的每一步本质上在做两件事：**投影** + **剔除**。理解它的关键是把它和 Gram-Schmidt 正交化做类比。

回顾 Gram-Schmidt（纯 $\mathbf{X}$ 视角）：

给定向量 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_p$ ，Gram-Schmidt 依次构造正交基：

$$\mathbf{z}_1 = \mathbf{x}_1, \quad \mathbf{z}_2 = \mathbf{x}_2 - \frac{\langle \mathbf{z}_1, \mathbf{x}_2 \rangle}{\langle \mathbf{z}_1, \mathbf{z}_1 \rangle} \mathbf{z}_1, \quad \mathbf{z}_3 = \mathbf{x}_3 - \frac{\langle \mathbf{z}_1, \mathbf{x}_3 \rangle}{\langle \mathbf{z}_1, \mathbf{z}_1 \rangle} \mathbf{z}_1 - \frac{\langle \mathbf{z}_2, \mathbf{x}_3 \rangle}{\langle \mathbf{z}_2, \mathbf{z}_2 \rangle} \mathbf{z}_2, \quad \dots$$

每一步把新向量投影到前面所有 $\mathbf{z}$ 的正交补上——提取“前面还没用过的信息”。

PLS 的投影逻辑（ $\mathbf{X} + \mathbf{y}$ 联合视角）：

PLS 把同样的正交化思想用在 $\mathbf{X}$ 上，但顺序由 $\mathbf{y}$ 来定：

第 m 步的核心操作：

- (1) **选方向权重**：计算每个 $\mathbf{x}_j^{(m-1)}$ （经前面 $m-1$ 步正交化后的残差变量）与 $\mathbf{y}$ 的内积： $\hat{\phi}_{mj} = \langle \mathbf{x}_j^{(m-1)}, \mathbf{y} \rangle$ 。这是 $\mathbf{x}_j^{(m-1)}$ 与 $\mathbf{y}$ 的协方差（在零均值下）。
- (2) **构造方向**： $\mathbf{z}_m = \sum_j \hat{\phi}_{mj} \mathbf{x}_j^{(m-1)}$ ，相当于把当前所有“剩余变量”按它们与 $\mathbf{y}$ 的协方差加权组合成新方向。
- (3) **$\mathbf{y}$ 对 $\mathbf{z}_m$ 投影**： $\hat{\theta}_m = \langle \mathbf{z}_m, \mathbf{y} \rangle / \langle \mathbf{z}_m, \mathbf{z}_m \rangle$ ，这就是 $\mathbf{y}$ 在 $\mathbf{z}_m$ 上的最小二乘回归系数（无截距）。更新拟合： $\hat{\mathbf{y}}^{(m)} = \hat{\mathbf{y}}^{(m-1)} + \hat{\theta}_m \mathbf{z}_m$ 。
- (4) **剔除已用信息**：将每个 $\mathbf{x}_j^{(m-1)}$ 对 $\mathbf{z}_m$ 做正交投影，去掉 $\mathbf{z}_m$ 分量：

$$\mathbf{x}_j^{(m)} = \mathbf{x}_j^{(m-1)} - \frac{\langle \mathbf{z}_m, \mathbf{x}_j^{(m-1)} \rangle}{\langle \mathbf{z}_m, \mathbf{z}_m \rangle} \mathbf{z}_m.$$

这一步保证 $\mathbf{z}_{m+1}$ （下一轮构造的方向）与 $\mathbf{z}_m$ 正交。

一句话理解：PLS = Gram-Schmidt 正交化，但每次选哪个变量先做，由“谁和 $\mathbf{y}$ 协方差大”来决定，而非由“谁方差大”来决定。

投影矩阵视角：

由于 $\mathbf{z}_m$ 是 $\mathbf{x}_j^{(m-1)}$ 的线性组合，而 $\mathbf{x}_j^{(m-1)}$ 本身是原始 $\mathbf{X}$ 的线性组合（经过 $m-1$ 次正交化），所以 $\mathbf{z}_m$ 最终是 $\mathbf{X}$ 的线性组合：

$$\mathbf{z}_m = \mathbf{X} \mathbf{w}_m,$$

其中 $\mathbf{w}_m$ 可由 PLS 权重反向推导。所有 $\mathbf{z}_1, \dots, \mathbf{z}_M$ 张成的子空间是 $\mathbf{X}$ 列空间的子空间。最终的拟合 $\hat{\mathbf{y}}^{(M)}$ 是 $\mathbf{y}$ 在这个子空间上的投影。

完整数值例子

下面用一个极简数据集 ($N = 4, p = 2$) 手动走一遍 PLS。

i	y_i	x_{i1}	x_{i2}
1	3	1	2
2	5	2	2
3	7	3	5
4	9	4	3

第 0 步：标准化。

中心化：

$$\bar{y} = 6, \quad \bar{x}_1 = 2.5, \quad \bar{x}_2 = 3.0.$$

$$\mathbf{y}^{(0)} = \begin{pmatrix} -3 \\ -1 \\ 1 \\ 3 \end{pmatrix}, \quad \mathbf{x}_1^{(0)} = \begin{pmatrix} -1.5 \\ -0.5 \\ 0.5 \\ 1.5 \end{pmatrix}, \quad \mathbf{x}_2^{(0)} = \begin{pmatrix} -1 \\ -1 \\ 2 \\ 0 \end{pmatrix}.$$

缩放到单位范数 ($\|\mathbf{x}_j\| = 1$):

$$\|\mathbf{x}_1^{(0)}\| = \sqrt{1.5^2 + 0.5^2 + 0.5^2 + 1.5^2} = \sqrt{5} \approx 2.236, \quad \|\mathbf{x}_2^{(0)}\| = \sqrt{1^2 + 1^2 + 2^2 + 0^2} = \sqrt{6} \approx 2.449.$$

$$\mathbf{x}_1^{(0)} \leftarrow \frac{1}{\sqrt{5}} \begin{pmatrix} -1.5 \\ -0.5 \\ 0.5 \\ 1.5 \end{pmatrix}, \quad \mathbf{x}_2^{(0)} \leftarrow \frac{1}{\sqrt{6}} \begin{pmatrix} -1 \\ -1 \\ 2 \\ 0 \end{pmatrix}.$$

$$\hat{\mathbf{y}}^{(0)} = \bar{y} \mathbf{1} = (6, 6, 6, 6)^\top.$$

第 1 步 ($m = 1$):

(a) 计算权重：

$$\hat{\phi}_{11} = \langle \mathbf{x}_1^{(0)}, \mathbf{y}^{(0)} \rangle = \frac{(-1.5)(-3) + (-0.5)(-1) + 0.5 \cdot 1 + 1.5 \cdot 3}{\sqrt{5}} = \frac{4.5 + 0.5 + 0.5 + 4.5}{\sqrt{5}} = \frac{10}{\sqrt{5}} \approx 4.472.$$

$$\hat{\phi}_{12} = \langle \mathbf{x}_2^{(0)}, \mathbf{y}^{(0)} \rangle = \frac{(-1)(-3) + (-1)(-1) + 2 \cdot 1 + 0 \cdot 3}{\sqrt{6}} = \frac{3 + 1 + 2 + 0}{\sqrt{6}} = \frac{6}{\sqrt{6}} \approx 2.45.$$

(b) 构造 $\mathbf{z}_1$ ：

$$\mathbf{z}_1 = \hat{\phi}_{11} \mathbf{x}_1^{(0)} + \hat{\phi}_{12} \mathbf{x}_2^{(0)} = \frac{10}{\sqrt{5}} \mathbf{x}_1^{(0)} + \frac{6}{\sqrt{6}} \mathbf{x}_2^{(0)}.$$

直接写出 $\mathbf{z}_1$ 的坐标（代入标准化前的中心化值更方便）——等价于用原始中心化变量： $\mathbf{z}_1 \propto 10 \cdot \tilde{\mathbf{x}}_1 + 6 \cdot \tilde{\mathbf{x}}_2$ ，其中 $\tilde{\mathbf{x}}_j$ 为中心化后的原始值。

$$\mathbf{z}_1 \propto 10 \begin{pmatrix} -1.5 \\ -0.5 \\ 0.5 \\ 1.5 \end{pmatrix} + 6 \begin{pmatrix} -1 \\ -1 \\ 2 \\ 0 \end{pmatrix} = \begin{pmatrix} -21 \\ -11 \\ 17 \\ 15 \end{pmatrix}.$$

归一化： $\|\mathbf{z}_1\| = \sqrt{21^2 + 11^2 + 17^2 + 15^2} = \sqrt{1076}$ 。实际 PLS 中不必须单位化，关键是计算 $\hat{\theta}_1$ ：

(c) 计算回归系数：

$$\hat{\theta}_1 = \frac{\langle \mathbf{z}_1, \mathbf{y}^{(0)} \rangle}{\langle \mathbf{z}_1, \mathbf{z}_1 \rangle} = \frac{(-21)(-3) + (-11)(-1) + 17 \cdot 1 + 15 \cdot 3}{1076} = \frac{63 + 11 + 17 + 45}{1076} = \frac{136}{1076} \approx 0.1264.$$

(d) 更新拟合 ($\mathbf{y}$ 的投影)：

$$\hat{\mathbf{y}}^{(1)} = \hat{\mathbf{y}}^{(0)} + \hat{\theta}_1 \mathbf{z}_1 = \begin{pmatrix} 6 \\ 6 \\ 6 \\ 6 \end{pmatrix} + 0.1264 \begin{pmatrix} -21 \\ -11 \\ 17 \\ 15 \end{pmatrix} \approx \begin{pmatrix} 3.35 \\ 4.61 \\ 8.15 \\ 7.90 \end{pmatrix}.$$

残差 $\mathbf{y}^{(1)} = \mathbf{y} - \hat{\mathbf{y}}^{(1)} \approx (-0.35, 0.39, -1.15, 1.10)^\top$ 。

(e) 正交化 $\mathbf{x}_j$ (剔除 $\mathbf{z}_1$ 分量)：

$$\mathbf{x}_1^{(1)} = \mathbf{x}_1^{(0)} - \frac{\langle \mathbf{z}_1, \mathbf{x}_1^{(0)} \rangle}{\langle \mathbf{z}_1, \mathbf{z}_1 \rangle} \mathbf{z}_1, \quad \mathbf{x}_2^{(1)} = \mathbf{x}_2^{(0)} - \frac{\langle \mathbf{z}_1, \mathbf{x}_2^{(0)} \rangle}{\langle \mathbf{z}_1, \mathbf{z}_1 \rangle} \mathbf{z}_1.$$

第 2 步 ($m = 2$)：

用 $\mathbf{x}_1^{(1)}, \mathbf{x}_2^{(1)}$ 和残差 $\mathbf{y}^{(1)}$ ($\mathbf{y}$ 中尚未被 $\mathbf{z}_1$ 解释的部分) 重复上述过程。构造 $\mathbf{z}_2$ (与 $\mathbf{z}_1$ 正交)，将 $\mathbf{y}^{(1)}$ 投影到 $\mathbf{z}_2$ 上，更新拟合。此时 $\hat{\mathbf{y}}^{(2)}$ 接近 $\mathbf{y}$ 在 $\mathbf{X}$ 列空间上的完整投影。

观察：

- $\mathbf{z}_1$ 里， x_1 的权重 (10) 大于 x_2 (6) ——因为 x_1 与 y 的协方差更大；
- 经过第 1 步正交化， $\mathbf{x}_j^{(1)} \perp \mathbf{z}_1$ ——第 2 步只会用到“ $\mathbf{z}_1$ 没吸收的信息”；
- 这和 Gram-Schmidt 一模一样，只是顺序由协方差驱动。

为什么同时考虑方差和相关性？

PLS 的优化准则可以化简：

$$\text{Corr}^2(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha}) \cdot \text{Var}(\mathbf{X}\boldsymbol{\alpha}) = \frac{\text{Cov}^2(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha})}{\text{Var}(\mathbf{y})\text{Var}(\mathbf{X}\boldsymbol{\alpha})} \cdot \text{Var}(\mathbf{X}\boldsymbol{\alpha}) = \frac{\text{Cov}^2(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha})}{\text{Var}(\mathbf{y})}.$$

由于 $\text{Var}(\mathbf{y})$ 是常数，这等价于最大化 $|\text{Cov}(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha})|$ 。也就是说，PLS 的准则在数学上退化为简单的协方差最大化。那为什么 ESL 要写成“相关性 × 方差”这种貌似复杂的形式？

答案：两个极端失败案例能说明一切。

	只最大化相关性 (CCA 方向)	只最大化方差 (PCA 方向)
准则	$\max \text{Corr}^2(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha})$	$\max \text{Var}(\mathbf{X}\boldsymbol{\alpha})$
会怎样	可能选到一个与 $\mathbf{y}$ 高度相关、但 $\mathbf{X}\boldsymbol{\alpha}$ 波动极小的方向 → $\hat{\theta}$ 估计极不稳定（方差巨大）	可能选到一个 $\mathbf{X}\boldsymbol{\alpha}$ 方差大、但与 $\mathbf{y}$ 完全不相干的方向 → 白做，预测力为零
极端例子	$\mathbf{x}_1$ 与 $\mathbf{y}$ 相关 0.9，但 $\text{Var}(\mathbf{x}_1) = 0.001$ ； $\hat{\theta}$ 的方差 $\propto 1/\ \mathbf{z}\ ^2 \rightarrow \infty$	$\mathbf{x}_2$ 方差极大但 $\text{Corr}(\mathbf{x}_2, \mathbf{y}) \approx 0$ ；这个方向对预测毫无用处
PLS 的做法	同时要求两者： $\text{Corr}^2 \cdot \text{Var} = \text{Cov}^2 / \text{Var}(\mathbf{y})$ —— 既不接受方差太小的方向（不稳定），也不接受相关性太弱的方向（无预测力）	

更深入的理解——为什么恰好是协方差？

协方差 $\text{Cov}(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha}) = \rho \cdot \sigma_y \cdot \sigma_{\mathbf{X}\boldsymbol{\alpha}}$ 本身就是“相关性 × 标准差”：

$$\text{Cov} = \underbrace{\text{Corr}}_{\text{关系强度}} \times \underbrace{\sigma_y}_{\text{固定常数}} \times \underbrace{\sigma_{\mathbf{X}\boldsymbol{\alpha}}}_{\text{信号强度}}.$$

所以 PLS 选的方向是在相关性和信号强度之间取得平衡：

- 信号太弱 ($\sigma_{\mathbf{X}\boldsymbol{\alpha}}$ 小) → 即使相关性高也不可靠；
- 相关性太弱 ($\rho \approx 0$) → 即使信号强也与 $\mathbf{y}$ 无关。

这就是为什么 PLS 的准则写成 $\text{Corr}^2 \cdot \text{Var}$ ——它清楚地表达了这两个成分的权衡，尽管数学上退化为协方差最大化。

与 PCR 的对比更加清楚：

- PCR: $\max \text{Var}(\mathbf{X}\boldsymbol{\alpha}) \rightarrow$ 只关心 $\mathbf{X}$ 自己的变异结构，完全忽略 $\mathbf{y}$ 。如果 $\mathbf{y}$ 主要依赖低方差成分（如光谱学中痕量成分），PCR 会直接扔掉它。
- PLS: $\max \text{Cov}(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha}) \rightarrow$ 取 $\mathbf{X}$ 的变异和 $\mathbf{y}$ 的交集。不浪费自由度在“方差大但与 $\mathbf{y}$ 无关”的方向上。

一句话总结：PLS 的准则看似是两个量的乘积，实际就是协方差最大化——它要的是“ $\mathbf{X}$ 中与 $\mathbf{y}$ 有关系的那部分变异”，PCR 要的是“ $\mathbf{X}$ 中变异最大的那部分”，而不管变异是否与 $\mathbf{y}$ 有关。

追问：按协方差大小选方向，会不会让与 $\mathbf{y}$ 几乎无关的变量永远被忽略？

这恰恰是 PLS 设计中最精妙的地方——正交化步骤让变量有“第二次机会”。

关键不在于单个变量在第 1 步权重有多大，而在于第 m 步用的是什么变量。第 m 步使用的 $\mathbf{x}_j^{(m-1)}$ 不是原始 $\mathbf{x}_j$ ，而是经过前 $m-1$ 轮正交化后的残差：

$$\mathbf{x}_j^{(m-1)} = \mathbf{x}_j - \sum_{\ell=1}^{m-1} \frac{\langle \mathbf{z}_\ell, \mathbf{x}_j \rangle}{\langle \mathbf{z}_\ell, \mathbf{z}_\ell \rangle} \mathbf{z}_\ell.$$

这意味着：

三种典型情况：

情况 1: $\mathbf{x}_j$ 与 $\mathbf{y}$ 边缘协方差很大 $\rightarrow$ 第 1 步权重高，直接被大量纳入 $\mathbf{z}_1$ 。好的——这正是我们想要的。

情况 2: $\mathbf{x}_j$ 与 $\mathbf{y}$ 边缘协方差很小，但与某个已被纳入的 $\mathbf{x}_k$ 高度相关 $\rightarrow$ 第 1 步权重小，但正交化后 $\mathbf{x}_j^{(1)}$ 很小（因为大部分已被 $\mathbf{z}_1$ 剥离）。后续步骤中它与残差 $\mathbf{y}^{(m)}$ 的协方差仍然很小 $\rightarrow$ 最终被忽略。这是对的：它的信息已经被 $\mathbf{x}_k$ 代表了。

情况 3: $\mathbf{x}_j$ 与 $\mathbf{y}$ 边缘协方差很小，但与已纳入变量不相关 $\rightarrow$ 第 1 步权重小。但正交化几乎不影响它 ($\mathbf{x}_j^{(1)} \approx \mathbf{x}_j$)。第 1 步后， $\mathbf{y}^{(1)} = \mathbf{y} - \hat{\theta}_1 \mathbf{z}_1$ 中与 $\mathbf{x}_j$ 有关的分量 仍然在残差里——因此第 2 步时 $\langle \mathbf{x}_j^{(1)}, \mathbf{y}^{(1)} \rangle$ 和 $\langle \mathbf{x}_j, \mathbf{y} \rangle$ 几乎一样大。如果其他变量的协方差在第 1 步已被大量消耗， $\mathbf{x}_j$ 在第 2 步就会脱颖而出。这就是“第二次机会”。

用一个具体例子说明：

假设 $p=3$ ，真实模型为 $y = 2x_1 + 1.5x_3 + \varepsilon$ ，且 x_1 与 x_2 高度相关 ($r \approx 0.9$)， x_3 与 x_1, x_2 均独立。

第 1 步的边际协方差大小排序可能是：

$$|\text{Cov}(\mathbf{x}_1, \mathbf{y})| > |\text{Cov}(\mathbf{x}_2, \mathbf{y})| > |\text{Cov}(\mathbf{x}_3, \mathbf{y})|.$$

$\mathbf{x}_2$ 的协方差较大，不是因为 $\mathbf{x}_2$ 本身对 y 有因果效应，而是因为它与 $\mathbf{x}_1$ 高度相关—— $\mathbf{x}_2$ “搭了 $\mathbf{x}_1$ 的便车”。 $\mathbf{x}_3$ 虽然真实系数是 1.5，但因为方差可能较小，边际协方差排在最后。

第 1 步后：

- $\mathbf{z}_1$ 主要捕获了 $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 的共同变异；
- $\mathbf{x}_1^{(1)}$ 和 $\mathbf{x}_2^{(1)}$ 都变得很小（大部分已被剥离）；
- $\mathbf{x}_3^{(1)} \approx \mathbf{x}_3$ （几乎未被触及，因为它与 $\mathbf{z}_1$ 正交）。

第 2 步：

- $\mathbf{y}^{(1)}$ 中 $\mathbf{x}_3$ 的贡献纹丝未动；
- 此时 $\langle \mathbf{x}_3^{(1)}, \mathbf{y}^{(1)} \rangle \approx \langle \mathbf{x}_3, \mathbf{y} \rangle$ ；
- 而 $\mathbf{x}_1^{(1)}, \mathbf{x}_2^{(1)}$ 与 $\mathbf{y}^{(1)}$ 的协方差已大幅下降；
- 因此 $\mathbf{x}_3$ 在第 2 步以最高权重进入 $\mathbf{z}_2$ 。

核心结论： PLS 不会因为一个变量第 1 步协方差不够大就永远丢弃它。正交化步骤在每一轮“消耗”已纳入变量的信息，给尚未被代表的变量腾出空间。这与逐步回归的“竞争”逻辑完全不同——逐步回归是淘汰制，PLS 是排队制。只要变量与 y 有任何独特的线性关系（不以其他变量为中介），它总会在某一轮被选中。

一句话： PLS 不会丢失与 $\mathbf{y}$ 有关的变量——它只是让协方差大的先走，协方差小的耐心排队。正交化保证每一轮过后，前排选手已经被消化，后排选手的“相对重要性”自动上升。

11.15 选择与收缩方法的比较 (Discussion)

考虑两个相关输入 X_1, X_2 （相关系数 ρ ），真实系数 $\beta_1 = 4, \beta_2 = 2$ 。图 3.18 展示了不同方法的系数路径（随着调节参数变化）：

- **岭回归：** 将所有系数一起向原点收缩，最终收敛到 LS 解；
- **PCR 和 PLS：** 行为与岭回归相似，但是离散的且更极端；
- **最优子集：** 先“冲过头”再折回 LS 解（overshoot）；
- **Lasso：** 介于岭回归和最优子集之间。

关于收缩行为的核心发现：

- 岭回归对所有方向做收缩，但低方差方向收缩更多；
- PCR 保留 M 个高方差方向，丢弃其余方向；
- PLS 也倾向于收缩低方差方向，但可能膨胀某些高方差方向——导致 PLS 比岭回归略不稳定、预测误差略高。

总结：PLS、PCR 和岭回归的行为往往相似。岭回归可能更受青睐，因为它连续收缩而非离散步骤。Lasso 介于岭回归和最优子集之间，兼具两者的特性。

11.16 多输出收缩与选择

当有 K 个输出时，可以独立处理每个输出（使用不同的 λ_k ），也可以共享同一个 λ 。但更精细的策略可以利用输出之间的相关性。

两个前提性问题

前文方法（子集选择、岭回归、Lasso）在多输出场景下有什么局限？

前文所有方法都是单输出的——每次只建模一个 y 。当有 K 个输出时，最直接的做法是对每个输出独立跑一遍。但这有四个问题：

- (1) 忽略输出间的共享结构。如果 y_1 和 y_2 高度相关且背后是同一个 $f(X)$ （如 $y_1 = f(X) + \varepsilon_1$, $y_2 = f(X) + \varepsilon_2$ ），独立建模等于把本该合并在一起估计 $f(X)$ 的 $2N$ 个观测，拆成两份各 N 个去分别估计——浪费了一半数据。
- (2) 调参成本高。独立做意味着 K 个 λ （岭回归/Lasso）或 K 个子集大小（子集选择）需要分别调。如果共享同一个 λ ，则隐含假设所有输出需要相同强度的正则化——这在实践中几乎从不成立。
- (3) 变量选择不一致。用 Lasso 对每个输出独立选变量，可能 y_1 选了 $\{x_1, x_3\}$ ， y_2 选了 $\{x_2, x_4\}$ 。即使两个输出高度相关，选出的变量集合也可能完全不同——这对科学解释是灾难性的。
- (4) 不能利用输出间的相关性来降噪。多输出场景的核心优势是借力（borrow strength）：如果一个输出在某些观测上噪声大，其他与之相关的输出可以提供额外信息来稳定估计。单输出方法完全放弃了这种可能性。

一句话：单输出方法把 K 个输出当成 K 个互不相关的独立问题，而多输出方法把它们当成一个整体的 K 维问题来建模。

CCA / 降秩回归 / C+W 的前提条件是什么？

这三种方法都建立在线性框架之上，核心前提如下：

前提	具体要求	违反时的后果
多输出	$K \geq 2$ ，否则退化为单输出问题	无意义
线性关联	$\mathbf{X}$ 和 $\mathbf{Y}$ 之间主要是线性关系	CCA 只捕捉线性相关，非线性关联（U 形、交互）会被遗漏
中心化	$\mathbf{X}$ 、 $\mathbf{Y}$ 需列中心化（均值为 0）。标准化（单位方差）非必须但强烈建议	不中心化会导致截距污染交叉协方差；不标准化会导致尺度大的变量主导方向
样本量	至少 $N > p + K$ 才能稳定估计协方差矩阵。建议 $N \gg pK$ （高维小样本下 CCA 极不稳定）	N 不够时典型相关系数被严重高估（回忆前面例子中 $c_1 > 1$ ）
误差结构 (RRR/C+W)	假设 $\text{Cov}(\epsilon_i) = \Sigma$ 对所有 i 相同（同方差），不同 i 间独立	异方差或自相关时最优性不保证，但只要 $\mathbf{X}$ 和 Σ 无关，解仍然不依赖 Σ
无多重共线性极端值	Σ_{XX} 和 Σ_{YY} 需可逆（用于白化）	完全共线时需先做 PCA 或正则化预处理

实践中最重要的两个检查：

- **N 够不够？** 如果 $N < p$ 或 $N < K$ ， Σ_{XX} 或 Σ_{YY} 不可逆——白化步骤无法进行。此时可以先用 PCA 降维，或在 Σ_{XX} 上加 ridge ($\Sigma_{XX} + \gamma \mathbf{I}$) 做正则化 CCA。
- **是线性关系吗？** 画散点图矩阵检查 $\mathbf{X}$ 和 $\mathbf{Y}$ 的边际关系。如果明显非线性，CCA 找到的方向可能没有意义。可以先用基展开（样条、多项式）将 $\mathbf{X}$ 变换后再做 CCA。

11.16.1 典型相关分析 (CCA)

CCA 找到 $\mathbf{x}_j$ 的线性组合 $\mathbf{X}\mathbf{v}_m$ 和响应的线性组合 $\mathbf{Y}\mathbf{u}_m$ ，使得两者的相关性依次最大化：

$$\text{Corr}^2(\mathbf{Y}\mathbf{u}_m, \mathbf{X}\mathbf{v}_m) \rightarrow \max.$$

最多可找到 $M = \min(K, p)$ 对方向。

核心直觉：前面的典型响应变元被 $\mathbf{x}$ 预测得最好；后面的典型变元预测力弱，可以考虑丢弃。

完整例子：手动走一遍 CCA。

下面用一个 $N = 4$ 、 $p = 2$ 、 $K = 2$ 的小数据集，逐步展示 CCA 的计算流程。

第 0 步：原始数据。

i	x_{i1}	x_{i2}	y_{i1}	y_{i2}
1	0	0	1	1
2	0	1	1	4
3	1	0	3	3
4	1	1	3	6

实质关系（从数据生成看）：

$$y_1 = 1 + 2x_1, \quad y_2 = 1 + 3x_1 + 2x_2.$$

这意味着 y_1 只和 x_1 有关， y_2 同时依赖 x_1 和 x_2 。CCA 能否自动发现这个结构？

第 1 步：中心化 + 标准化。

中心化（每列减均值）：

$$\bar{x}_1 = 0.5, \bar{x}_2 = 0.5, \bar{y}_1 = 2, \bar{y}_2 = 3.5.$$

$$\mathbf{X}_c = \begin{pmatrix} -0.5 & -0.5 \\ -0.5 & 0.5 \\ 0.5 & -0.5 \\ 0.5 & 0.5 \end{pmatrix}, \quad \mathbf{Y}_c = \begin{pmatrix} -1.0 & -2.5 \\ -1.0 & 0.5 \\ 1.0 & -0.5 \\ 1.0 & 2.5 \end{pmatrix}.$$

缩放到单位方差（每列除以标准差）。 $\mathbf{X}_c$ 的每列方差 = 0.25，标准差 = 0.5； $\mathbf{Y}_c$ 的 y_1 方差 = 1（标准差 = 1）， y_2 方差 = 3.25（标准差 ≈ 1.803 ）：

$$\mathbf{X} = \begin{pmatrix} -1 & -1 \\ -1 & 1 \\ 1 & -1 \\ 1 & 1 \end{pmatrix}, \quad \mathbf{Y} = \begin{pmatrix} -1 & -1.387 \\ -1 & 0.277 \\ 1 & -0.277 \\ 1 & 1.387 \end{pmatrix}.$$

验证： $\mathbf{X}^\top \mathbf{X} / 4 = \mathbf{I}_2$ ， $\mathbf{Y}^\top \mathbf{Y} / 4 = \mathbf{I}_2$ 。✓

第 2 步：计算交叉协方差矩阵。

$$\Sigma_{XY} = \frac{\mathbf{X}^\top \mathbf{Y}}{N} = \frac{1}{4} \begin{pmatrix} (-1)(-1) + (-1)(-1) + (1)(1) + (1)(1) & (-1)(-1.387) + (-1)(0.277) + (1)(-0.277) \\ (-1)(-1) + (1)(-1) + (-1)(1) + (1)(1) & (-1)(-1.387) + (1)(0.277) + (-1)(-0.277) \end{pmatrix}$$

观察：第一行 (1.000, 0.832) 说明 $\mathbf{x}_1$ 与两个 y 都有很强协方差；第二行 (0, 0.555) 说明 $\mathbf{x}_2$ 与 y_1 正交、与 y_2 有中等协方差——与真实生成关系一致。

第 3 步：计算核心矩阵并做 SVD。

由于 $\mathbf{X}$ 和 $\mathbf{Y}$ 都已标准化 ($\Sigma_{XX} = \Sigma_{YY} = \mathbf{I}$)，CCA 的核心矩阵简化为交叉协方差本身：

$$\mathbf{K} = \Sigma_{XX}^{-1/2} \Sigma_{XY} \Sigma_{YY}^{-1/2} = \Sigma_{XY} = \begin{pmatrix} 1.000 & 0.832 \\ 0 & 0.555 \end{pmatrix}.$$

对 $\mathbf{K}$ 做 SVD: $\mathbf{K} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$ 。

先计算 $\mathbf{K}^\top \mathbf{K}$ ：

$$\mathbf{K}^\top \mathbf{K} = \begin{pmatrix} 1.000 & 0.832 \\ 0.832 & 1.000 \end{pmatrix}.$$

特征值： $\det(\mathbf{K}^\top \mathbf{K} - \lambda \mathbf{I}) = (1 - \lambda)^2 - 0.832^2 = 0$ ，得 $\lambda_1 = 1.832$, $\lambda_2 = 0.168$ 。

典型相关系数（奇异值）：

$$c_1 = \sqrt{\lambda_1} \approx 1.353, \quad c_2 = \sqrt{\lambda_2} \approx 0.410.$$

但相关系数不能超过 1——说明我们的计算中 $c_1 > 1$ 是因为 $N = 4$ 的小样本偏高。在总体中 $0 \leq c_m \leq 1$ 。这里我们把 c_1 理解为接近 1（完美相关）， $c_2 \approx 0.41$ 。

c_1 很大 $\rightarrow$ 存在一个 $\mathbf{X}$ 的线性组合与某个 $\mathbf{Y}$ 的线性组合高度相关。 c_2 较小 $\rightarrow$ 第二个方向的相关性弱得多。

第 4 步：提取典型方向。

对 $\mathbf{K}^\top \mathbf{K}$ 的特征向量（即 $\mathbf{V}$ 的列， $\mathbf{X}$ 端方向）：

$\lambda_1 = 1.832$ 的特征向量： $(1 - \lambda_1)v_1 + 0.832v_2 = 0$ ，即 $-0.832v_1 + 0.832v_2 = 0$, $v_1 = v_2$ ：

$$\mathbf{v}_1 \propto (1, 1)^\top \xrightarrow{\text{归一化}} \mathbf{v}_1 \approx (0.707, 0.707)^\top.$$

$\lambda_2 = 0.168$ 的特征向量： $v_1 = -v_2$ ：

$$\mathbf{v}_2 \propto (1, -1)^\top \xrightarrow{\text{归一化}} \mathbf{v}_2 \approx (0.707, -0.707)^\top.$$

$\mathbf{Y}$ 端方向 $\mathbf{u}_m$ 由 $\mathbf{u}_m \propto \mathbf{K}\mathbf{v}_m$ （归一化后）：

$$\mathbf{u}_1 \propto \mathbf{K}\mathbf{v}_1 = \begin{pmatrix} 1.000 & 0.832 \\ 0 & 0.555 \end{pmatrix} \begin{pmatrix} 0.707 \\ 0.707 \end{pmatrix} \approx \begin{pmatrix} 1.295 \\ 0.392 \end{pmatrix} \xrightarrow{\text{归一化}} \mathbf{u}_1 \approx (0.957, 0.290)^\top.$$

$$\mathbf{u}_2 \propto \mathbf{K}\mathbf{v}_2 \approx \begin{pmatrix} 0.119 \\ -0.392 \end{pmatrix} \xrightarrow{\text{归一化}} \mathbf{u}_2 \approx (0.290, -0.957)^\top.$$

第 5 步：解读。

方向	典型相关系数	$\mathbf{X}$ 端组合	$\mathbf{Y}$ 端组合
第 1	$c_1 \approx 1.0$	$0.71 x_1 + 0.71 x_2$	$0.96 y_1 + 0.29 y_2$
第 2	$c_2 \approx 0.41$	$0.71 x_1 - 0.71 x_2$	$0.29 y_1 - 0.96 y_2$

发现了什么？

- **第一典型方向：** $\mathbf{X}$ 端几乎等权重地组合 x_1 和 x_2 ， $\mathbf{Y}$ 端主要由 y_1 主导（权重 0.96）。这说明 y_1 和 $x_1 + x_2$ 高度相关。但回忆真实模型： y_1 只和 x_1 有关！这里 x_2 也获得了权重，是因为在 $N = 4$ 的小样本中， $x_1 + x_2$ 碰巧与 y_1 的相关性比单独的 x_1 更高（过拟合的雏形）。
- **第二典型方向：** y_2 权重最大（ -0.96 ），对应 $x_1 - x_2$ 。这和真实模型一致—— y_2 同时依赖 x_1 和 x_2 ，两者方向相反说明它们对 y_2 的贡献在 CCA 视角下有某种互补关系。
- CCA 成功发现了两个正交的关联维度，但第一维度将 x_2 也纳入，反映出小样本下估计的不稳定性。在大样本（ $N \rightarrow \infty$ ）极限下，CCA 会正确恢复： $y_1 \leftrightarrow x_1$ （ $c_1 \rightarrow 1$ ）和 $y_2 \leftrightarrow x_1, x_2$ 的某种组合。

CCA 算法总结（五步）：

第 1 步： 标准化 $\mathbf{X}$ 和 $\mathbf{Y}$ （每列均值 0，方差 1）；

第 2 步： 计算交叉协方差 $\Sigma_{XY} = \mathbf{X}^\top \mathbf{Y} / N$ ；

第 3 步： 构造核心矩阵 $\mathbf{K} = \Sigma_{XX}^{-1/2} \Sigma_{XY} \Sigma_{YY}^{-1/2}$ （若已标准化则 $\mathbf{K} = \Sigma_{XY}$ ）；

第 4 步： 对 $\mathbf{K}$ 做 SVD： $\mathbf{K} = \mathbf{U} \mathbf{D} \mathbf{V}^\top$ ，奇异值 d_m 就是典型相关系数 c_m ；

第 5 步： 提取方向： $\mathbf{X}$ 端 $\mathbf{v}_m$ （ $\mathbf{V}$ 的列）， $\mathbf{Y}$ 端 $\mathbf{u}_m$ （ $\mathbf{U}$ 的列）。

为什么 SVD 能给出 $\mathbf{X}$ 端和 $\mathbf{Y}$ 端的组合？

这是 CCA 最核心的数学洞察。下面从优化问题出发，完整推导出 SVD 的来龙去脉。

第一步：CCA 的优化问题

CCA 要找到 $\mathbf{v} \in \mathbb{R}^p$ （ $\mathbf{X}$ 端权重）和 $\mathbf{u} \in \mathbb{R}^K$ （ $\mathbf{Y}$ 端权重），最大化：

$$\text{Corr}(\mathbf{Y}\mathbf{u}, \mathbf{X}\mathbf{v}) = \frac{\text{Cov}(\mathbf{Y}\mathbf{u}, \mathbf{X}\mathbf{v})}{\sqrt{\text{Var}(\mathbf{Y}\mathbf{u}) \cdot \text{Var}(\mathbf{X}\mathbf{v})}}.$$

代入协方差矩阵：

$$\begin{aligned}\text{Cov}(\mathbf{Y}\mathbf{u}, \mathbf{X}\mathbf{v}) &= \frac{1}{N}(\mathbf{Y}\mathbf{u})^\top(\mathbf{X}\mathbf{v}) = \mathbf{u}^\top \frac{\mathbf{Y}^\top \mathbf{X}}{N} \mathbf{v} = \mathbf{u}^\top \Sigma_{YX} \mathbf{v}. \\ \text{Var}(\mathbf{X}\mathbf{v}) &= \mathbf{v}^\top \Sigma_{XX} \mathbf{v}, \quad \text{Var}(\mathbf{Y}\mathbf{u}) = \mathbf{u}^\top \Sigma_{YY} \mathbf{u}.\end{aligned}$$

所以 CCA 求解：

$$\max_{\mathbf{u}, \mathbf{v}} \frac{\mathbf{u}^\top \Sigma_{YX} \mathbf{v}}{\sqrt{\mathbf{u}^\top \Sigma_{YY} \mathbf{u} \cdot \mathbf{v}^\top \Sigma_{XX} \mathbf{v}}}.$$

第二步：白化——消去分母

分子和分母都依赖 $\mathbf{u}$ 和 $\mathbf{v}$ ，不好直接优化。关键在于先做变量替换，把分母消掉。
令：

$$\tilde{\mathbf{v}} = \Sigma_{XX}^{1/2} \mathbf{v}, \quad \tilde{\mathbf{u}} = \Sigma_{YY}^{1/2} \mathbf{u}.$$

这里 $\Sigma^{1/2}$ 是协方差矩阵的对称平方根 ($\Sigma^{1/2} \Sigma^{1/2} = \Sigma$)。

则有 $\mathbf{v} = \Sigma_{XX}^{-1/2} \tilde{\mathbf{v}}$, $\mathbf{u} = \Sigma_{YY}^{-1/2} \tilde{\mathbf{u}}$ 。代入：

- 分子： $\mathbf{u}^\top \Sigma_{YX} \mathbf{v} = \tilde{\mathbf{u}}^\top \Sigma_{YY}^{-1/2} \Sigma_{YX} \Sigma_{XX}^{-1/2} \tilde{\mathbf{v}} = \tilde{\mathbf{u}}^\top \mathbf{K} \tilde{\mathbf{v}}$,

其中 $\mathbf{K} = \Sigma_{YY}^{-1/2} \Sigma_{YX} \Sigma_{XX}^{-1/2}$ 。

- 分母： $\mathbf{v}^\top \Sigma_{XX} \mathbf{v} = \tilde{\mathbf{v}}^\top \Sigma_{XX}^{-1/2} \Sigma_{XX} \Sigma_{XX}^{-1/2} \tilde{\mathbf{v}} = \|\tilde{\mathbf{v}}\|^2$ 。

同理 $\mathbf{u}^\top \Sigma_{YY} \mathbf{u} = \|\tilde{\mathbf{u}}\|^2$ 。

因此，CCA 的优化问题变为：

$$\max_{\tilde{\mathbf{u}}, \tilde{\mathbf{v}}} \frac{\tilde{\mathbf{u}}^\top \mathbf{K} \tilde{\mathbf{v}}}{\|\tilde{\mathbf{u}}\| \cdot \|\tilde{\mathbf{v}}\|}.$$

分母被消掉了——这就是白化的几何意义：把 $\mathbf{X}$ 和 $\mathbf{Y}$ 内部的协方差结构“拉平”，让不同方向和变量不再有尺度差异，剩下的 $\mathbf{K}$ 就是纯净的跨集合关联矩阵。

注意：笔记中前面例子用的是 $\mathbf{K} = \Sigma_{XX}^{-1/2} \Sigma_{XY} \Sigma_{YY}^{-1/2}$ ，与这里 $\Sigma_{YY}^{-1/2} \Sigma_{YX} \Sigma_{XX}^{-1/2}$ 的区别只是转置——两者做 SVD 后的奇异值相同， $\mathbf{U}$ 和 $\mathbf{V}$ 交换。哪个顺手用哪个。

第三步：Rayleigh 商与 SVD

现在问题变成：

$$\max_{\tilde{\mathbf{u}}, \tilde{\mathbf{v}}} \tilde{\mathbf{u}}^\top \mathbf{K} \tilde{\mathbf{v}}, \quad \|\tilde{\mathbf{u}}\| = 1, \|\tilde{\mathbf{v}}\| = 1.$$

这是一个双线性型在有约束下的最大化。SVD 恰好是它的最优解。

定理 11.6 (SVD 与双线性型的极值). 对任意矩阵 $\mathbf{K}$ ，其 SVD 为 $\mathbf{K} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$ ，其中 $\mathbf{D}$ 的对角元 $d_1 \geq d_2 \geq \dots \geq 0$ 。则：

$$\max_{\|\tilde{\mathbf{u}}\|=1, \|\tilde{\mathbf{v}}\|=1} \tilde{\mathbf{u}}^\top \mathbf{K} \tilde{\mathbf{v}} = d_1,$$

最优解为 $\tilde{\mathbf{u}} = \mathbf{u}_1$ ($\mathbf{U}$ 的第 1 列)， $\tilde{\mathbf{v}} = \mathbf{v}_1$ ($\mathbf{V}$ 的第 1 列)。

直观验证. 取 $\tilde{\mathbf{u}} = \mathbf{u}_1$, $\tilde{\mathbf{v}} = \mathbf{v}_1$:

$$\tilde{\mathbf{u}}^\top \mathbf{K} \tilde{\mathbf{v}} = \mathbf{u}_1^\top (\mathbf{U} \mathbf{D} \mathbf{V}^\top) \mathbf{v}_1 = (\mathbf{U}^\top \mathbf{u}_1)^\top \mathbf{D} (\mathbf{V}^\top \mathbf{v}_1) = \mathbf{e}_1^\top \mathbf{D} \mathbf{e}_1 = d_1.$$

这就是最大的可能值, 因为任何单位向量 $\tilde{\mathbf{u}}$ 都是 $\mathbf{U}$ 列的线性组合 $\tilde{\mathbf{u}} = \mathbf{U} \mathbf{a}$ ($\|\mathbf{a}\| = 1$), $\tilde{\mathbf{v}} = \mathbf{V} \mathbf{b}$ ($\|\mathbf{b}\| = 1$), 则:

$$\tilde{\mathbf{u}}^\top \mathbf{K} \tilde{\mathbf{v}} = \mathbf{a}^\top \mathbf{D} \mathbf{b} \leq \sum_i d_i |a_i b_i| \leq d_1 \sum_i |a_i b_i| \leq d_1 \|\mathbf{a}\| \|\mathbf{b}\| = d_1.$$

□

第四步: 回到原始坐标

SVD 给出的是白化空间中的方向。回到原始变量:

$$\mathbf{v}_1^{\text{orig}} = \Sigma_{XX}^{-1/2} \mathbf{v}_1, \quad \mathbf{u}_1^{\text{orig}} = \Sigma_{YY}^{-1/2} \mathbf{u}_1.$$

这就是 $\mathbf{X}$ 端和 $\mathbf{Y}$ 端的典型方向。对于第二个方向, 在约束与第一个方向正交的条件下重复。

用一句话记住

$$\mathbf{K} = \Sigma_{YY}^{-1/2} \Sigma_{YX} \Sigma_{XX}^{-1/2} \xrightarrow{\text{SVD}} \mathbf{U} \mathbf{D} \mathbf{V}^\top$$

SVD 输出	CCA 中的含义	来源
$\mathbf{D}$ 的对角元 d_m	典型相关系数 c_m	奇异值 = 最大可达的交叉协方差
$\mathbf{V}$ 的第 m 列 $\mathbf{v}_m$	$\mathbf{X}$ 端典型方向 (白化空间)	右奇异向量
$\mathbf{U}$ 的第 m 列 $\mathbf{u}_m$	$\mathbf{Y}$ 端典型方向 (白化空间)	左奇异向量
$\Sigma_{XX}^{-1/2} \mathbf{v}_m$	$\mathbf{X}$ 端典型方向 (原始坐标)	从白化空间拉回
$\Sigma_{YY}^{-1/2} \mathbf{u}_m$	$\mathbf{Y}$ 端典型方向 (原始坐标)	从白化空间拉回

几何直觉: SVD 把 $\mathbf{K}$ 分解为“旋转 $\rightarrow$ 缩放 $\rightarrow$ 再旋转”。

- $\mathbf{V}^\top$: 把 $\mathbf{X}$ 空间旋转到最优方向 ($\mathbf{v}_m$ 彼此正交);
- $\mathbf{D}$: 在每个方向上缩放, 缩放因子就是典型相关系数 c_m ;
- $\mathbf{U}$: 把缩放后的结果旋转到 $\mathbf{Y}$ 空间 ($\mathbf{u}_m$ 彼此正交)。

所以 $\mathbf{X}$ 端的组合是 $\mathbf{V}$ 的列 (经过白化逆变换), $\mathbf{Y}$ 端的组合是 $\mathbf{U}$ 的列 (经过白化逆变换) ——两者分别从 SVD 的左右两侧“对偶”地产生, 通过奇异值 c_m 连接。

11.16.2 降秩回归 (Reduced-Rank Regression)

定义 11.28 (降秩回归). 在约束 $\text{rank}(\mathbf{B}) \leq m$ 下最小化多变量回归的加权 RSS:

$$\hat{\mathbf{B}}(m) = \arg \min_{\text{rank}(\mathbf{B})=m} \sum_{i=1}^N (\mathbf{y}_i - \mathbf{B}^\top \mathbf{x}_i)^\top \boldsymbol{\Sigma}^{-1} (\mathbf{y}_i - \mathbf{B}^\top \mathbf{x}_i). \quad (11.70)$$

其解由 CCA 给出:

$$\hat{\mathbf{B}}(m) = \hat{\mathbf{B}} \mathbf{U}_m \mathbf{U}_m^{-},$$

其中 $\mathbf{U}_m$ 是前 m 个左典型向量, $\mathbf{U}_m^{-}$ 是其广义逆。

解读: 降秩回归先在“合并后的响应矩阵” $\mathbf{Y}\mathbf{U}_m$ 上做普通回归, 再将系数映射回原始响应空间。拟合值为:

$$\hat{\mathbf{Y}}(m) = \mathbf{H}\mathbf{Y}\mathbf{P}_m,$$

其中 $\mathbf{H}$ 是普通 LS 投影矩阵, $\mathbf{P}_m$ 是秩- m CCA 响应投影矩阵。

$\boldsymbol{\Sigma}^{-1}$ 是什么?

$\boldsymbol{\Sigma}$ 是多输出误差的协方差矩阵, 维度 $K \times K$ 。

在多输出线性模型 $\mathbf{Y} = \mathbf{X}\mathbf{B} + \mathbf{E}$ 中, 每个观测 i 的 K 个误差构成一个向量:

$$\boldsymbol{\varepsilon}_i = (\varepsilon_{i1}, \dots, \varepsilon_{iK})^\top \in \mathbb{R}^K,$$

其协方差矩阵为 $\text{Cov}(\boldsymbol{\varepsilon}_i) = \boldsymbol{\Sigma}$ (假设对所有 i 相同, 且不同 i 间独立)。

$\boldsymbol{\Sigma}$ 的对角元 Σ_{kk} 是第 k 个输出的误差方差; 非对角元 $\Sigma_{k\ell}$ 是第 k 和第 ℓ 个输出误差之间的协方差。

为什么目标函数里要乘 $\boldsymbol{\Sigma}^{-1}$? 这和 GLS (广义最小二乘) 的逻辑一致。如果不同输出的误差尺度不同 (如温度误差 $\approx 1^\circ\text{C}$, 湿度误差 $\approx 5\%$), 直接加和 RSS 会让尺度大的输出主导优化。 $\boldsymbol{\Sigma}^{-1}$ 将其「标准化」——每个输出的残差按其精度加权, 同时消除输出间相关性对拟合方向的扭曲。

实践中 $\boldsymbol{\Sigma}$ 未知, 通常用 $\mathbf{Y}^\top \mathbf{Y} / N$ 估计。好消息是: 在正态假设下, 降秩回归的解不依赖 $\boldsymbol{\Sigma}$ 的具体值 (见 ESL 习题 3.22), 所以实际操作中可以直接用 CCA 求解, 无需显式估计 $\boldsymbol{\Sigma}$ 。

「降秩」是让输入变量变少吗?

不是。降秩回归不减少输入变量, 它约束的是系数矩阵 $\mathbf{B}$ 的秩。

$\mathbf{B}$ 是 $(p+1) \times K$ 的矩阵——每一列是某个输出对应的 $p+1$ 个系数。如果不加约束, $\mathbf{B}$ 的秩最多为 $\min(p+1, K)$, 意味着 K 个输出的系数向量可以是「各自独立的」。

$\text{rank}(\mathbf{B}) \leq m$ 强制 $\mathbf{B}$ 的列最多张成一个 m 维子空间。等价地说: 所有 K 个输出共享 m 个「潜在因子」, 每个输出的回归系数是这 m 个因子的线性组合:

$$\mathbf{B} = \underset{(p+1) \times m}{\mathbf{A}} \underset{m \times K}{\mathbf{C}}.$$

m 个因子 $\times K$ 个输出 = 参数从 $(p+1)K$ 降到 $m(p+1+K)$ 。

	普通多输出回归	降秩回归 (rank = m)
B 的样子	K 列彼此独立	K 列共享 m 个因子
参数个数	$(p+1)K$	$m(p+1+K)$ (实际更少)
对输出的假设	各输出独立建模	输出间有共享结构
极端 $m=1$	—	所有输出共用一个回归方向 (缩放不同)

输入变量一个没少—— p 个 x_j 全部参与。变的是它们到 K 个输出的映射方式：不是 K 条独立的路，而是 m 条共享的路再分配到 K 个出口。

打个比方：普通回归是给每个学生（输出）单独请家教（系数），降秩回归是开 m 门大课（因子），每个学生去听然后按自己的权重组合。老师（输入变量）数量不变，但授课方式被约束了。

11.16.3 Curds & Whey 收缩

Breiman & Friedman (1997) 提出对典型变元做连续收缩（而非离散截断），形式为：

$$\hat{\mathbf{B}}^{\text{c+w}} = \hat{\mathbf{B}} \mathbf{U} \mathbf{\Lambda} \mathbf{U}^{-1},$$

其中 $\mathbf{\Lambda}$ 为对角收缩矩阵，对角元：

$$\lambda_m = \frac{c_m^2}{c_m^2 + \frac{p}{N}(1 - c_m^2)},$$

c_m 是第 m 个典型相关系数。当 p/N 很小时，收缩因子接近 1。

他们还建议同时在 $\mathbf{Y}$ 空间和 $\mathbf{X}$ 空间做收缩，得到混合收缩模型 $\hat{\mathbf{Y}} = \mathbf{A}_\lambda \mathbf{Y} \mathbf{S}^{\text{c+w}}$ 。

这三样东西各自什么时候用？

三个方法共享同一个数学核心——对 $\mathbf{X}$ 和 $\mathbf{Y}$ 的交叉协方差矩阵做 SVD 找典型方向——但目的不同，场景不同。

	CCA	降秩回归 (RRR)	Curds & Whey
本质	探索性工具：发现 $\mathbf{X}$ 与 $\mathbf{Y}$ 之间的关联结构	建模工具：强制系数矩阵低秩来约束模型	预测工具：连续收缩典型方向来改善预测
对典型方向的处理	保留/丢弃（看相关性大小）	取前 m 个，后面截断	全部保留，但按 λ_m 软收缩
输出	典型变量对 $(\mathbf{Y}\mathbf{u}_m, \mathbf{X}\mathbf{v}_m)$ ，典型相关系数 c_m	低秩系数矩阵 $\hat{\mathbf{B}}(m)$ ，拟合值	收缩后的系数矩阵和预测值
调参	选 m （保留几对典型变量）	选秩 m	λ_m 由 c_m 和 p/N 自动确定
典型场景	心理学/社会科学：人格特质与学业成绩的关系；基因组学：基因表达与药物响应的关联	经济学：多国 GDP、通胀、失业率联合建模；信号处理：多通道信号的联合滤波	任何多输出预测问题：同时预测温度/湿度/风速；化学计量学：从光谱同时预测多种成分浓度

用一个具体行业例子串起来。

假设你是气象局的数据科学家， $p = 10$ 个大气指标预测 $K = 3$ 个目标（温度、湿度、风速）。

- **CCA 阶段（探索）**：你发现第一对典型变量的 $c_1 = 0.92$ ——存在一个大气指标的线性组合，与一个温度/湿度/风速的特定加权组合高度相关。这个组合告诉你什么物理过程在主导——可能是“海洋气团输送效应”。第二对 $c_2 = 0.45$ ，第三对 $c_3 = 0.12$ 。探索完成：你知道大概有 1–2 个有意义的关联方向。
- **降秩回归（建模）**：基于 CCA 结果，你决定用秩 $m = 2$ 的降秩回归。这相当于说：三个目标之间的变化主要由两个潜在因子驱动，第三个“因子”基本是噪声。秩约束强制模型只从数据中学习这两个因子， $\hat{\mathbf{B}}$ 有 $10 \times 3 = 30$ 个参数但只有 $10 \times 2 + 2 \times 3 = 26$ 个自由度（实际更低）。相比对每个目标独立跑回归（30 个参数），降秩回归参数更少、方差更低。
- **C+W 收缩（预测）**：你不想硬截断（ $c_3 = 0.12$ 可能还有点信息），也不想要秩约束的离散决策。C+W 对三个方向分别收缩：

$$\lambda_1 \approx \frac{0.92^2}{0.92^2 + \frac{10}{N} \cdot 0.15} \approx 0.98, \quad \lambda_2 \approx 0.82, \quad \lambda_3 \approx 0.12(\text{几乎被压到零}).$$

第一个方向几乎原样保留，第三个基本丢弃，第二个部分收缩——用连续权重替代了硬截断。预测时你甚至可以在 $\mathbf{X}$ 端也做岭回归收缩（混合模型），进一步降低方差。

选择指南：

你的目标	用哪个
我只是想理解 $\mathbf{X}$ 和 $\mathbf{Y}$ 之间的关联结构	CCA
我要做预测，且输出之间肯定有共享结构	降秩回归
我要做预测，但不确定截断几个方向最好	Curds & Whey（或交叉验证选 m 的 RRR）
N 很小、 K 很大，我需要大幅降维	降秩回归（用力截断）
p/N 很大（高维），输出高度相关	C+W（自动根据 p/N 调整收缩力度）

一句话：CCA 是显微镜（看结构），降秩回归是剪刀（硬截断），C+W 是调光器（软收缩）。同一个数学底座，三种使用姿势。

11.17 Lasso 深入与路径算法

11.17.1 增量前向分段回归 (Incremental Forward Stagewise, FS)

第 3.3.3 节的前向分段回归每次走一整步 ($\delta_j = \langle \mathbf{x}_j, \mathbf{r} \rangle$)。增量版本只走一小步 $\epsilon > 0$ ：

第 1 步：残差 $\mathbf{r} = \mathbf{y}$ ，所有 $\beta_j = 0$ ($\mathbf{x}_j$ 标准化)；

第 2 步：找到与 $\mathbf{r}$ 最相关的 $\mathbf{x}_j$ ；

第 3 步： $\beta_j \leftarrow \beta_j + \delta_j$ ，其中 $\delta_j = \epsilon \cdot \text{sign}(\langle \mathbf{x}_j, \mathbf{r} \rangle)$ ；

第 4 步： $\mathbf{r} \leftarrow \mathbf{r} - \delta_j \mathbf{x}_j$ ；

第 5 步：重复，直到所有变量与残差不相关。

关键极限： $\epsilon \rightarrow 0$ 的极限过程称为 FS_0 （无穷小前向分段回归）。图 3.19 展示了前列腺癌数据上 $\epsilon = 0.01$ 和 $\epsilon \rightarrow 0$ 的系数路径。在此例中 FS_0 路径是单调的，因此与 Lasso/LAR 完全相同。

FS_0 与 LAR 的关系：Efron 最初以为 LAR 算法就是 FS_0 的实现，但发现 LAR 在活跃变量间的最小二乘拟合可能导致某个系数的方向与其相关性符号相反——这在 FS 中不可能发生。修正方案是 LAR 的修改版 (Algorithm 3.2b)：在活跃集中求解带符号约束的最小二乘问题。

定义 11.29 (FS_0 与 Lasso 的区别).

- Lasso 每次在 RSS 下降每单位 L_1 范数增加上做最优推进;
- FS_0 在 RSS 下降每单位 L_1 弧长上做最优推进。

因此 FS_0 的系数路径被“抑制频繁改变方向”，可以被视为 Lasso 的单调版本。在 $p \gg N$ 场景下， FS_0 的路径更平滑、方差更低。

11.17.2 分段线性路径算法

LAR 利用了 Lasso 解路径的分段线性特性。Rosset & Zhu (2007) 给出了解路径分段线性的充分条件：

$$\hat{\beta}(\lambda) = \arg \min_{\beta} [R(\beta) + \lambda J(\beta)]$$

1. R 是 β 的二次或分段二次函数；
2. J 是 β 的分段线性函数。

满足此条件的例子包括：平方/绝对误差损失 + L_1/L_∞ 惩罚、Hinge Loss (SVM) + 二次惩罚（在对偶空间中分段线性）。

11.17.3 Dantzig 选择器

Candes & Tao (2007) 提出了 Dantzig 选择器 (DS)：

$$\min_{\beta} \|\beta\|_1 \quad \text{s.t.} \quad \|\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\beta)\|_\infty \leq s. \quad (11.71)$$

等价于：

$$\min_{\beta} \|\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\beta)\|_\infty \quad \text{s.t.} \quad \|\beta\|_1 \leq t.$$

与 Lasso 的区别：Lasso 最小化 RSS（梯度分量的平方和）；DS 最小化梯度的最大绝对值。两者在 t 大时都收敛到 LS 解（ $N < p$ 时取最小 L_1 范数解）。

但 DS 的运行性质不太令人满意：DS 试图让残差与所有预测变量的最大内积最小化，但它选入模型的变量不一定与当前残差相关性最大——可能出现模型中某变量的相关性反而低于某些被排除变量的情况。这可能导致预测精度较差和极不稳定的系数路径。

11.17.4 分组 Lasso (Grouped Lasso)

当预测变量有自然分组时（如同一条生物通路中的基因、一个分类变量的哑变量组），可能希望整组同时被选入或剔除。

定义 11.30 (分组 Lasso). 设 p 个预测变量分为 L 组 (第 ℓ 组有 p_ℓ 个), $\mathbf{X}_\ell$ 和 β_ℓ 对应第 ℓ 组。最小化:

$$\min_{\beta} \left\{ \left\| \mathbf{y} - \beta_0 \mathbf{1} - \sum_{\ell=1}^L \mathbf{X}_\ell \beta_\ell \right\|^2 + \lambda \sum_{\ell=1}^L \sqrt{p_\ell} \|\beta_\ell\|_2 \right\}. \quad (11.72)$$

关键: 惩罚项使用欧几里得范数 $\|\beta_\ell\|_2$ (不是平方)。因为 $\|\beta_\ell\|_2 = 0$ 当且仅当该组所有系数为零——这鼓励**组级稀疏性**。 $\sqrt{p_\ell}$ 项用于调整不同组的大小。

推广包括更一般的 L_2 范数 $\|\eta\|_K = (\eta^\top \mathbf{K} \eta)^{1/2}$ 和允许重叠分组。

完整例子：房价预测中的分组 Lasso

设你要预测房价 y , 候选预测变量来自三个来源:

组	变量	含义
组 1: 地段	$x_1 =$ 距市中心距离, $x_2 =$ 周边学校评分, $x_3 =$ 犯罪率	
组 2: 户型	$x_4 =$ 面积, $x_5 =$ 卧室数, $x_6 =$ 建造年份	
组 3: 经济	$x_7 =$ 当地失业率, $x_8 =$ 家庭收入中位数	

$L = 3$ 组, $p_1 = 3, p_2 = 3, p_3 = 2$, 共 $p = 8$ 。每组有内在关联——「地段」的三个指标来自同一个社区的描述, 「户型」的三个来自同一套房的特征, 「经济」的两个来自同一个宏观经济背景。

为什么不用普通 Lasso? 普通 Lasso 可能选出 (x_1, x_5, x_8) 这样横跨三组的组合, 报告会很难解释: 「房价由距市中心距离、卧室数和家庭收入决定, 但地段中的学校评分和犯罪率反而没影响」——这在领域逻辑上说不通 (同一地段的数据不应该被割裂)。分组 Lasso 强制每组要么全进、要么全出。

过程 (概念层面):

第 1 步: 数据准备: 中心化所有 x_j , 标准化到单位范数 ($\|\mathbf{x}_j\| = 1$)。截距 $\beta_0 = \bar{y}$ 。

第 2 步: 选 λ : 用 10 折交叉验证。从小到大试 λ 的网格, 记录 CV 误差。

第 3 步: 路径追踪: 从 $\lambda_{\max}$ (所有组系数全为零) 开始, 逐步减小 λ 。

不同 λ 下各组的表现:

λ	组 1 (地段)	组 2 (户型)	组 3 (经济)	CV 误差
大 λ	全为零	全为零	全为零	高 (欠拟合)
中等 λ	被激活 (三个系数都非零)	全为零	全为零	中等
较小 λ	非零	被激活	全为零	最低
极小 λ	非零	非零	被激活	略回升 (过拟合)

用 1-SE rule: 选 CV 误差在一个标准误以内的最简模型 $\rightarrow$ 保留组 1 + 组 2, 剔除组 3。

第 4 步: 最终模型:

$$\hat{y} = \hat{\beta}_0 + \underbrace{(\hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3)}_{\text{地段: 全部保留}} + \underbrace{(\hat{\beta}_4 x_4 + \hat{\beta}_5 x_5 + \hat{\beta}_6 x_6)}_{\text{户型: 全部保留}} + \underbrace{(0 \cdot x_7 + 0 \cdot x_8)}_{\text{经济: 整组剔除}}.$$

读出的结论: 「地段和户型对房价有联合影响, 经济指标在控制了地段和户型后没有额外解释力。」这句话比分变量 Lasso 的三变量散装结论干净得多, 也更容易被领域专家接受。

为什么 L2 范数 (不是平方) 使整组可以恰好为零?

单变量 Lasso 用 $|\beta_j|$ 而非 β_j^2 来实现稀疏——绝对值在零点不可微, 导数不连续。分组 Lasso 同理: $\|\beta_\ell\|_2$ (欧几里得范数) 在 $\beta_\ell = \mathbf{0}$ 处不可微 (梯度不存在), 而 $\|\beta_\ell\|_2^2$ 在零点光滑可微。当一个组对当前残差的贡献不够大时, 不可微性使最优点精确落在 $\beta_\ell = \mathbf{0}$ ——全组一并清零。换成平方范数就退化为组级岭回归, 系数只收缩、不归零。

11.17.5 Lasso 的进一步性质

大量文献研究了 Lasso 在 $N, p \rightarrow \infty$ 时恢复正确模型的能力 (Knight & Fu, 2000; Greenshtein & Ritov, 2004; Donoho, 2006b; Meinshausen & Bühlmann, 2006; Zhao & Yu, 2006; Wainwright, 2006 等)。

模型选择一致性条件: 很多结果假设设计矩阵满足:

$$\max_{j \in S^c} \|\mathbf{x}_j^\top \mathbf{X}_S (\mathbf{X}_S^\top \mathbf{X}_S)^{-1}\|_1 \leq 1 - \epsilon, \quad \epsilon \in (0, 1].$$

即“好”变量 S 不应该与“噪声”变量 S^c 高度相关。

系数一致性问题: Lasso 将非零系数向零收缩, 因此估计量不是一致的 (即使 $N \rightarrow \infty$, $\hat{\beta}_j$ 也不收敛到 β_j)。缓解方案:

- **Relaxed Lasso (Meinshausen, 2007):** 先用 Lasso 选变量, 再对被选变量用更小的 λ 做第二次 Lasso; 因为被选变量不再与噪声变量“竞争”, 交叉验证会选到更小的 λ ;

- **SCAD 惩罚 (Fan & Li, 2005)**: 用非凸惩罚代替 $\lambda|\beta|$, 对大系数减少惩罚力度:

$$\frac{dJ_a(\beta, \lambda)}{d\beta} = \lambda \cdot \text{sign}(\beta) \left[I(|\beta| \leq \lambda) + \frac{(a\lambda - |\beta|)_+}{(a-1)\lambda} I(|\beta| > \lambda) \right], \quad a \geq 2. \quad (11.73)$$

当 $a \rightarrow \infty$ 时退化为不收缩——但非凸性使计算困难;

- **Adaptive Lasso (Zou, 2006)**: 使用加权惩罚 $\sum w_j |\beta_j|$, 其中 $w_j = 1/|\hat{\beta}_j|^\nu$ ($\hat{\beta}_j$ 为 OLS 估计, $\nu > 0$)。这是 $|\beta_j|^q$ ($q = 1 - \nu$) 惩罚的实用近似——保留了凸性而获得一致估计。

11.17.6 路径坐标优化 (Pathwise Coordinate Descent)

这是计算 Lasso 解的另一种重要算法 (与 LAR 互补):

第 1 步: 固定 λ , 对每个参数逐一优化 (其他参数固定在当前值);

第 2 步: β_j 的更新有显式解:

$$\tilde{\beta}_j(\lambda) \leftarrow S\left(\sum_{i=1}^N x_{ij}(y_i - \tilde{y}_i^{(j)}), \lambda\right), \quad (11.74)$$

其中 $\tilde{y}_i^{(j)} = \sum_{k \neq j} x_{ik} \tilde{\beta}_k(\lambda)$ 是排除变量 j 的当前拟合值, $S(t, \lambda) = \text{sign}(t)(|t| - \lambda)_+$ 是软阈值算子。

第 3 步: 循环所有变量直到收敛; 从 $\lambda_{\max}$ (所有系数为零的最大 λ) 开始, 逐步减小 λ , 用前一个解作为“热启动”。

优势:

- 在大问题上可以比 LAR 更快;
- 关键加速技巧: $\sum x_{ij}(y_i - \tilde{y}_i^{(j)})$ 可以快速更新, 且经常是保持 $\tilde{\beta}_j = 0$ 不变 (无需更新);
- 输出的是 λ 网格上的解 (而非整个解路径);
- 可应用于弹性网、分组 Lasso、融合 Lasso 等。

11.18 计算考量

最小二乘拟合的两种主要数值方法:

	Cholesky 分解	QR 分解
操作	对 $\mathbf{X}^\top \mathbf{X}$ 做 Cholesky	对 $\mathbf{X}$ 做 QR
运算量	$p^3 + Np^2/2$	Np^2
速度	$N \gg p$ 时可能更快	N 和 p 相当时更快
稳定性	较差（条件数平方放大）	更稳定

实践建议：大多数现代统计软件（R 的 `lm`、Python 的 `statsmodels`）使用 QR 分解，因为数值稳定性更重要。LAR 算法计算 Lasso 路径的运算量与单次 LS 拟合同阶。

11.19 小结

I. 模型、估计与几何

$$\underbrace{\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}}_{\text{线性模型}} \quad \begin{array}{l} \mathbf{X} : N \times (p+1), \text{ 固定设计} \\ \boldsymbol{\beta} : (p+1) \times 1, \text{ 未知常数} \\ \boldsymbol{\varepsilon} : \mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{X}] = \mathbf{0}, \text{ Var}(\boldsymbol{\varepsilon} \mid \mathbf{X}) = \sigma^2 \mathbf{I} \end{array}$$

↓ 平方损失下 ERM

$$\boxed{\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}} \xrightarrow{\text{几何}} \boxed{\hat{\mathbf{y}} = \mathbf{H} \mathbf{y}} \quad \begin{array}{l} \mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \\ \mathbf{H}^2 = \mathbf{H}, \text{ tr}(\mathbf{H}) = p+1 \end{array}$$

Gram-Schmidt: $\hat{\beta}_j = \frac{\langle \mathbf{z}_j, \mathbf{y} \rangle}{\langle \mathbf{z}_j, \mathbf{z}_j \rangle}$, $\mathbf{z}_j = \mathbf{x}_j$ 对 $\{\mathbf{z}_0, \dots, \mathbf{z}_{j-1}\}$ 的正交补

$$\downarrow \xrightarrow{\text{数值}} \mathbf{X} = \mathbf{Q}\mathbf{R}, \mathbf{R}\hat{\boldsymbol{\beta}} = \mathbf{Q}^\top \mathbf{y}, \text{ Var}(\hat{\beta}_j) = \frac{\sigma^2}{\|\mathbf{z}_j\|^2}$$

II. 推断层次（固定设计，条件于 $\mathbf{X}$ ）

	一阶 + 二阶矩	正态假设
条件	$\mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{X}] = \mathbf{0}$ $\text{Var}(\boldsymbol{\varepsilon} \mid \mathbf{X}) = \sigma^2 \mathbf{I}$	$\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$
$\hat{\boldsymbol{\beta}}$	$\mathbb{E}[\hat{\boldsymbol{\beta}}] = \boldsymbol{\beta}$ $\text{Var}(\hat{\boldsymbol{\beta}}) = (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2$	$\hat{\boldsymbol{\beta}} \sim \mathcal{N}(\boldsymbol{\beta}, (\mathbf{X}^\top \mathbf{X})^{-1} \sigma^2)$
单系数	Gauss-Markov: BLUE	$t_j = \frac{\hat{\beta}_j}{\hat{\sigma} \sqrt{v_j}} \sim t_{N-p-1}$ CI: $\hat{\beta}_j \pm t^{(1-\alpha/2)} \text{se}(\hat{\beta}_j)$
多系数	—	$F = \frac{(\text{RSS}_0 - \text{RSS}_1)/(p_1 - p_0)}{\text{RSS}_1/(N - p_1 - 1)} \sim F_{p_1 - p_0, N - p_1 - 1}$
联合	—	联合置信椭球（ F 分布）
$\downarrow \hat{\sigma}^2 = \frac{\text{RSS}}{N - p - 1} \xrightarrow{\text{预测}} \mathbb{E}[(Y_0 - \hat{f})^2] = \underbrace{\sigma^2}_{\text{不可约}} + \underbrace{\text{Var}(\hat{f}) + \text{Bias}^2(\hat{f})}_{\text{MSE}}$		

III. 正则化：偏差-方差与收缩方法

$$\underbrace{\text{MSE} = \text{Bias}^2 + \text{Var}}_{\text{偏差-方差权衡}} \xrightarrow{\text{用偏差换方差}} \begin{cases} \text{子集选择 (离散, 硬阈值)} \\ \text{Lasso } L_1 (\text{连续, 软阈值, 稀疏}) \\ \text{弹性网 } L_1 + L_2 \\ \text{岭回归 } L_2 (\text{连续, 比例收缩}) \end{cases}$$

↓ 正交设计下的解对比

	子集	Lasso	岭回归
正交解	硬阈值	$\text{sign}(\hat{\beta}_j)(\hat{\beta}_j - \lambda)_+$	$\hat{\beta}_j/(1 + \lambda)$
稀疏	✓	✓	×
凸优化	×	✓	✓
先验	spike-slab	拉普拉斯	高斯

↓ SVD 视角下的岭回归

$$\hat{\mathbf{y}}^{\text{ridge}} = \sum \mathbf{u}_j \frac{d_j^2}{d_j^2 + \lambda} (\mathbf{u}_j^\top \mathbf{y}) \quad \text{低方差方向收缩更多}$$

↓ Lasso 的计算路径

$$\text{LAR} \xrightarrow{\text{活跃变量等速推进}} \text{保持与残差等相关} \xrightarrow{\text{稍加修改}} \boxed{\text{Lasso 路径}}$$

$$\text{FS}_0 \xrightarrow{\epsilon \rightarrow 0} \text{增量前向分段} \xrightarrow{p \gg N \text{ 更平滑}} \text{Lasso 单调版}$$

$$\tilde{\beta}_j \leftarrow S\left(\sum x_{ij}(y_i - \tilde{y}_i^{(j)}), \lambda\right) \xrightarrow{\text{热启动} + \text{循环}} \boxed{\text{坐标下降: 大问题比 LAR 快}}$$

↓ 扩展：分组稀疏与去偏

$$\lambda \sum_{\ell} \sqrt{p_{\ell}} \|\beta_{\ell}\|_2 \xrightarrow{\text{零点不可微}} \text{分组 Lasso: 整组归零}$$

$$\text{SCAD} / \text{Adaptive} \xrightarrow{\text{非凸惩罚}} \text{减偏倚, 一致估计}$$

IV. 降维与多输出

$$\underbrace{\text{PCR}}_{\max \text{Var}(\mathbf{X}\boldsymbol{\alpha})} \longrightarrow \underbrace{\text{PLS}}_{\max \text{Cov}^2} \longrightarrow \underbrace{\text{CCA/SVD}}_{\max \text{Corr}(\mathbf{Y}\mathbf{u}, \mathbf{X}\mathbf{v})}$$

	PCR	PLS
准则	$\max \text{Var}(\mathbf{X}\boldsymbol{\alpha})$	$\max \text{Cov}^2(\mathbf{y}, \mathbf{X}\boldsymbol{\alpha})$
用 $\mathbf{y}$	$\times$	$\checkmark (\hat{\phi}_{mj} \propto \langle \mathbf{x}_j^{(m-1)}, \mathbf{y} \rangle)$
正交化	—	每步后剔除 $\mathbf{z}_m$ 分量

↓ 多输出：从 SVD 到收缩

$$\mathbf{K} = \mathbf{U}\mathbf{D}\mathbf{V}^\top \rightarrow \text{降秩回归 (RRR): } \text{rank}(\mathbf{B}) \leq m, \text{ 硬截断}$$

↓ Curds&Whey: 用软收缩替代硬截断

$$\lambda_m = \frac{c_m^2}{c_m^2 + \frac{p}{N}(1 - c_m^2)}$$

	CCA	RRR	C+W
角色	看结构	硬截断建模	软收缩预测
输出	典型对 + c_m	低秩 $\hat{\mathbf{B}}(m)$	收缩预测值

$$\underbrace{\max \text{Corr}(\mathbf{Y}\mathbf{u}, \mathbf{X}\mathbf{v})}_{\text{CCA 优化}} \xrightarrow{\text{白化}} \underbrace{\max_{\|\tilde{\mathbf{u}}\|=\|\tilde{\mathbf{v}}\|=1} \tilde{\mathbf{u}}^\top \mathbf{K} \tilde{\mathbf{v}}}_{\|\tilde{\mathbf{u}}\|=\|\tilde{\mathbf{v}}\|=1} \xrightarrow{\text{SVD}} \boxed{\mathbf{K} = \mathbf{U}\mathbf{D}\mathbf{V}^\top}$$

$\mathbf{V} \rightarrow \mathbf{X}$ 端方向, $\mathbf{U} \rightarrow \mathbf{Y}$ 端方向, $\mathbf{D} \rightarrow c_m$ (典型相关系数)

核心要点:

1. 模型形式: $f(X) = \beta_0 + \sum_{j=1}^p X_j \beta_j$, 关于参数线性, X_j 可来自任意变换;
2. LS 估计: $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$, 几何上是 $\mathbf{y}$ 在 $\mathbf{X}$ 列空间的正交投影 (Hat matrix);
3. 推断层次: 一阶 + 二阶矩 $\Rightarrow$ 无偏 + BLUE (Gauss-Markov); 正态假设 $\Rightarrow t/F$ 检验 + 精确置信区间/椭圆;
4. 偏差-方差: $\text{MSE} = \text{Bias}^2 + \text{Var}$ ——正则化用偏差换方差, 在 MSE 上优于 LS;
5. 正则化谱系: 子集选择 (离散) $\rightarrow$ Lasso(L_1 , 稀疏 + 凸) $\rightarrow$ 弹性网 $\rightarrow$ 岭回归 (L_2 , 仅收缩);

6. 降维三兄弟: PCR(方差) $\rightarrow$ PLS(协方差 = 相关性 $\times$ 信号) $\rightarrow$ CCA/SVD(双向关联);
7. 多输出: CCA(探索结构) $\rightarrow$ 降秩回归 (硬截断建模) $\rightarrow$ C+W(软收缩预测)。

第十二章 分类的线性方法

本章聚焦于**决策边界为线性**的分类方法。虽然限制在线性边界，但通过基展开可以推广到二次或更一般的非线性边界。

12.1 引言

分类问题中，预测函数 $G(x)$ 取值于离散集合 $\mathcal{G}$ ，因此可将输入空间划分为对应各类的区域。若这些区域的边界是线性的，就称为**分类的线性方法**。

基本设定

设输入空间 $\mathcal{X} \subseteq \mathbb{R}^p$ ，类别标签集 $\mathcal{G} = \{1, 2, \dots, K\}$ 。 (X, Y) 服从联合分布 P_{XY} ，其中 $X \in \mathcal{X}$ ， $Y \in \mathcal{G}$ 。

判别函数与分类规则

一族判别函数 $\{\delta_k\}_{k \in \mathcal{G}}$ ， $\delta_k : \mathcal{X} \rightarrow \mathbb{R}$ 。分类器 $\hat{G} : \mathcal{X} \rightarrow \mathcal{G}$ 定义为取最大判别值：

$$\hat{G}(x) = \arg \max_{k \in \mathcal{G}} \delta_k(x). \quad (12.1)$$

用一阶逻辑精确表述（假设最大值唯一，否则约定取最小的 k ）：

$$\forall x \in \mathcal{X}, \quad \hat{G}(x) = k \iff \left(\forall j \in \mathcal{G} \setminus \{k\}, \delta_k(x) > \delta_j(x) \right).$$

决策边界

类别 k 与 ℓ ($k \neq \ell$) 之间的决策边界 $\mathcal{B}_{k\ell}$ 定义为使 δ_k 与 δ_ℓ 并列最大（且不小于其他任何类）的全体 x ：

$$\mathcal{B}_{k\ell} = \left\{ x \in \mathcal{X} \mid \delta_k(x) = \delta_\ell(x) \wedge \forall j \in \mathcal{G} \setminus \{k, \ell\}, \delta_k(x) \geq \delta_j(x) \right\}. \quad (12.2)$$

线性判别函数的充要条件

称 δ_k 是线性的，当且仅当：

$$\forall k \in \mathcal{G}, \exists \beta_k \in \mathbb{R}^p, \exists \beta_{k0} \in \mathbb{R}, \forall x \in \mathcal{X} : \quad \delta_k(x) = \beta_k^\top x + \beta_{k0}.$$

此时对任意 $k \neq \ell$, 由式 (12.2):

$$\mathcal{B}_{k\ell} = \left\{ x \in \mathcal{X} \mid (\beta_k - \beta_\ell)^\top x + (\beta_{k0} - \beta_{\ell0}) = 0 \right\},$$

即 $\mathbb{R}^p$ 中的一个超平面 (线性决策边界)。

若存在严格单调递增函数 $g: \mathbb{R} \rightarrow \mathbb{R}$ 使得 $g \circ \delta_k$ 是线性的, 则决策边界仍是线性的, 因为:

$$\forall k \neq \ell, \forall x \in \mathcal{X}: g(\delta_k(x)) = g(\delta_\ell(x)) \iff \delta_k(x) = \delta_\ell(x).$$

关键: 只要求 δ_k 的某个单调变换是线性的, δ_k 本身不必是线性的。

损失函数

损失函数是一个映射 $L: \mathcal{G} \times \mathcal{G} \rightarrow \mathbb{R}_{\geq 0}$, 其中 $L(g, \hat{g})$ 表示真类别为 g 、预测为 $\hat{g}$ 时的代价。最常用的 0-1 损失:

$$L(g, \hat{g}) = \mathbf{1}\{g \neq \hat{g}\} = \begin{cases} 0, & g = \hat{g}, \\ 1, & g \neq \hat{g}. \end{cases}$$

更一般地可用损失矩阵 $\mathbf{L} = (L_{k\ell})_{K \times K}$, 其中 $L_{k\ell} = L(k, \ell)$ 。

期望预测误差 (EPE)

分类器 $\hat{G}$ 的期望预测误差为损失在联合分布下的期望:

$$\text{EPE}(\hat{G}) = \mathbb{E}_{(X,Y) \sim P_{XY}} [L(Y, \hat{G}(X))]. \quad (12.3)$$

展开为积分形式 (记 f_X 为 X 的边缘密度, $P(Y = k \mid X = x)$ 为后验概率):

$$\text{EPE}(\hat{G}) = \int_{\mathcal{X}} \left[\sum_{k=1}^K L(k, \hat{G}(x)) \cdot P(Y = k \mid X = x) \right] f_X(x) dx. \quad (12.4)$$

逐点最小化: 要最小化 EPE, 等价于对每个 $x \in \mathcal{X}$ 独立地最小化括号内的条件期望——

$$\forall x \in \mathcal{X}, \quad \hat{G}_{\text{opt}}(x) = \arg \min_{g \in \mathcal{G}} \sum_{k=1}^K L(k, g) \cdot P(Y = k \mid X = x).$$

Bayes 分类器: EPE 的最优解

在 0-1 损失下, 逐点最小化简化为:

$$\hat{G}_{\text{Bayes}}(x) = \arg \min_{g \in \mathcal{G}} (1 - P(Y = g \mid X = x)) = \arg \max_{g \in \mathcal{G}} P(Y = g \mid X = x).$$

即: 选择后验概率最大的类别。

框架统一

将上述诸概念串成一条链：

$$\begin{array}{l}
 \text{判别函数族 } \{\delta_k\}_{k \in \mathcal{G}} \\
 \downarrow \quad \hat{G}(x) = \arg \max_k \delta_k(x) \\
 \text{EPE} = \mathbb{E}_{(X,Y)}[L(Y, \hat{G}(X))] \\
 \downarrow \quad \text{逐点最小化} \\
 \hat{G}_{\text{Bayes}}(x) = \arg \max_k P(Y = k \mid X = x)
 \end{array}$$

若取 $\delta_k(x) = P(Y = k \mid X = x)$ （或其单调变换如 $\log P(Y = k \mid X = x)$ ），则判别函数分类器 $\hat{G}$ 等价于 Bayes 分类器。实际算法（LDA、Logistic 回归等）通过不同方式估计这些后验概率或其单调变换，从而逼近 Bayes 最优解。

12.1.1 判别函数方法

一类通用方法是：对每个类别 k 建模一个判别函数 $\delta_k(x)$ ，然后分类到最大值：

$$\hat{G}(x) = \arg \max_{k \in \mathcal{G}} \delta_k(x). \quad (12.5)$$

如果 $\delta_k(x)$ （或其某个单调变换）是 x 的线性函数，则决策边界是线性的。

12.1.2 Logit 变换与 Logistic 模型

对于二分类，一个流行的后验概率模型是：

$$\Pr(G = 1 \mid X = x) = \frac{\exp(\beta_0 + \beta^\top x)}{1 + \exp(\beta_0 + \beta^\top x)}, \quad \Pr(G = 2 \mid X = x) = \frac{1}{1 + \exp(\beta_0 + \beta^\top x)}. \quad (12.6)$$

取 logit 变换 $\log[p/(1-p)]$ 后得到线性形式：

$$\log \frac{\Pr(G = 1 \mid X = x)}{\Pr(G = 2 \mid X = x)} = \beta_0 + \beta^\top x. \quad (12.7)$$

决策边界是 $\{x \mid \beta_0 + \beta^\top x = 0\}$ ，即一个超平面。

下面将 Logistic 回归套入前面建立的判别函数 / EPE 框架，逐一说明各符号的具体含义。

Logistic 回归中的 δ_k 是什么？

在 Logistic 回归中，自然地取后验概率作为判别函数：

$$\delta_1(x) = \Pr(G = 1 \mid X = x), \quad \delta_2(x) = \Pr(G = 2 \mid X = x) = 1 - \delta_1(x).$$

分类规则 $\hat{G}(x) = \arg \max_k \delta_k(x)$ 即选择后验概率较大的类别，等价于 Bayes 分类器（在 0-1 损失下最优）。

δ_k 本身并非线性，但单调变换后是线性的

这里的 $\delta_1(x)$ 是 sigmoid 函数，显然不是 x 的线性函数。但取 logit 变换

$$g(p) = \log \frac{p}{1 - p}$$

(g 在 $(0, 1)$ 上严格单调递增)，则有：

$$g(\delta_1(x)) = \log \frac{\Pr(G = 1 \mid X = x)}{\Pr(G = 2 \mid X = x)} = \beta_0 + \beta^\top x,$$

即 $g \circ \delta_1$ 是 x 的线性函数。

由于 g 严格单调递增，对任意 x ：

$$\delta_1(x) > \delta_2(x) \iff g(\delta_1(x)) > g(\delta_2(x)) \iff \beta_0 + \beta^\top x > 0.$$

因此决策边界 $\{x \mid \delta_1(x) = \delta_2(x)\}$ 等价于 $\{x \mid \beta_0 + \beta^\top x = 0\}$ ，是一个线性超平面。这正好印证了引言中的结论：只要存在某个单调变换使 δ_k 变为线性，决策边界就是线性的， δ_k 本身不必是线性的。

δ_k 的一般取法

除后验概率外，不同方法中 δ_k 还有多种自然取法，本质都是对「 x 属于第 k 类的证据强度」的某种度量：

$\delta_k(x)$ 的取法	来源方法	单调变换后线性？
$P(G = k \mid X = x)$	Bayes 最优	不一定
$\log P(G = k \mid X = x)$	等价 Bayes (log 单调)	不一定
$x^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k$	LDA	δ_k 本身就是线性的
$\beta_{k0} + \beta_k^\top x$ (直接建模)	指示矩阵回归	δ_k 本身就是线性的
$\beta_{k0} + \beta_k^\top x$ (log-odds 形式)	多类 Logistic 回归	其 logit 变换是线性的
$f_k(x) \pi_k$ (似然 $\times$ 先验)	Bayes 定理展开	取决于 f_k 假设

关键：只要各类使用同一个度量尺度（同一单调变换）， $\arg \max_k \delta_k(x)$ 的结果不变。

「后验概率」的理解

「后验」即后于数据、后于经验——看到证据 x 之后更新了的信念。由 Bayes 定理展开：

$$\underbrace{P(G = k | X = x)}_{\text{后验}} = \frac{\overbrace{f_k(x)}^{\text{似然}} \cdot \overbrace{\pi_k}^{\text{先验}}}{\underbrace{\sum_{j=1}^K f_j(x) \pi_j}_{\text{归一化常数}}},$$

其中:

- **先验** $\pi_k = P(G = k)$: 在看到任何特征之前, 样本属于第 k 类的初始信念;
- **似然** $f_k(x) = P(X = x | G = k)$: 已知属于第 k 类的前提下, 观察到 x 的可能性 (类条件密度);
- **后验** $P(G = k | X = x)$: 给定已观察到的 x , 属于第 k 类的更新后概率。

整条逻辑链为: 先验 $\xrightarrow{\text{数据 } x}$ 后验。这正是统计推断的核心思想, 也是 LDA (§4.3) 通过假设 f_k 为 Gaussian 来估计后验概率的理论基础。

训练的本质: 用数据估计 δ_k

前面把后验概率当作 δ_k , 自然会引出一个困惑: 训练时只有 $\{(x_i, y_i)\}_{i=1}^N$, 既不知道真实的 δ_k , 也不知道真实的 $P(G = k | X = x)$ ——为什么还能用它?

关键在于区分**理论目标**和**实践操作**:

理论: Bayes 分类器 $\arg \max_k P(G = k | X = x)$ 是 EPE 最小的最优解 (不可达上界)

实践: 用数据拟合参数化模型来**估计**后验, 而非直接使用真实后验

训练流程可以拆成三步:

- (1) **选定模型族:** 假设 δ_k 具有某种参数化形式 $\delta_k(x; \theta)$, 例如 Logistic 回归假设 $\log \frac{P(G=k)}{P(G=K)} = \beta_{k0} + \beta_k^\top x$;
- (2) **用数据估计参数:** 通过训练数据 $\{(x_i, y_i)\}$ 估计参数 $\hat{\theta}$ (MLE、最小二乘等), 得到 $\hat{\delta}_k(x) = \delta_k(x; \hat{\theta})$;
- (3) **预测:** 对新输入 x , 计算 $\hat{G}(x) = \arg \max_k \hat{\delta}_k(x)$ 。

不同方法估计后验的方式不同:

方法	如何估计后验
Logistic 回归	假设 log-odds 线性, 用 MLE 估计 β , 代入公式算 $\hat{P}(G = k X = x)$
LDA	假设 f_k 为 Gaussian 且等协方差, 用样本均值/协方差估计 $\hat{\mu}_k, \hat{\Sigma}$, 代入 Bayes 公式
KNN	用邻居类别比例直接估计 $\hat{P}(G = k X = x) = \frac{\#\{i \in \mathcal{N}(x): y_i = k\}}{ \mathcal{N}(x) }$

一句话: 真实后验是靶子, $\hat{\delta}_k$ 是射出的箭, 训练就是用 (X, Y) 校准瞄准的过程。

12.1.3 实操流程：从线性函数到分类决策


看完公式 (12.6) 和 (12.7)，自然会产生三个疑问：

- (1) 目标还是最小化 $\mathbb{E}[L(f(X), Y)]$ 吗？
- (2) 「单调变换」到底加在哪一步？
- (3) $\Pr(G = 1 \mid X = x)$ 在整个流程中起什么作用？

下面把完整流水线串起来。

预测阶段（前向传播）：三段式流水线

给定一个已训练好的系数 β_0, β ，对新输入 x 做分类经过三步：



关键洞察：Step 1 中的 $\eta(x)$ 就是那个「线性函数」；Step 2 中的 sigmoid（即 logit^{-1} ）就是那个「单调变换」。正向走是 $\eta \xrightarrow{\text{sigmoid}} p$ ，反向看就是 $\log \frac{p}{1-p} = \eta$ ，即 logit 变换。

由于 sigmoid 是单调的， $\eta(x) > 0 \iff p(x) > 0.5$ ，所以决策边界可以等价地写为 $\{x \mid \eta(x) = 0\}$ ，即 $\{x \mid \beta_0 + \beta^\top x = 0\}$ 。根本不需要显式计算 $p(x)$ 就能做分类。

训练阶段：用什么损失函数？

你的第一个直觉是对的——总体框架仍是最小化期望损失 $\mathbb{E}[L(f(X), Y)]$ 。但损失函数不是平方误差！

对于分类，我们有两层损失：

- 最终评估用 0-1 损失： $L(G, \hat{G}) = \mathbb{I}\{G \neq \hat{G}\}$ 。这是真正关心的指标，但它不可导，不能直接优化。
- 训练用负对数似然（交叉熵）：对二分类 Logistic 回归，第 i 个样本的损失为

$$\ell_i(\beta) = -\left[\mathbb{I}\{y_i = 1\} \log p(x_i) + \mathbb{I}\{y_i = 2\} \log(1 - p(x_i))\right], \quad (12.8)$$

其中 $p(x_i) = 1/(1 + e^{-(\beta_0 + \beta^\top x_i)})$ 。最小化 $\sum_i \ell_i(\beta)$ 等价于最大化似然。

注记 12.1. 为什么不用平方误差？如果强行对 0/1 标签做线性最小二乘（即 §4.2 的指示矩阵回归），拟合值 $\hat{f}(x)$ 可能 < 0 或 > 1 ，且会出现 masking。Logistic 回归通过 sigmoid 变换把输出压缩到 $[0, 1]$ ，解决了这个问题。

$\Pr(G = 1 | X = x)$ 的作用

后验概率 $p(x) = \Pr(G = 1 | X = x)$ 在整个流程中扮演三个角色：

- (1) **建模目标：**我们不是直接建模 $G(x)$ ，而是建模 $\Pr(G | X = x)$ ——一个 $[0, 1]$ 内的实数。这比直接输出离散标签信息更丰富。
- (2) **sigmoid 的输出：** $p(x)$ 是线性得分 $\eta(x)$ 经过 sigmoid 后的结果，是连接线性函数与分类决策的桥梁。
- (3) **置信度量：** $p(x)$ 不仅告诉我们分到哪一类，还告诉我们有多确信。例如 $p(x) = 0.51$ 和 $p(x) = 0.99$ 都预测类别 1，但后者置信度更高。

一句话总结

Logistic 回归 = 线性函数 $\xrightarrow{\text{sigmoid}}$ 概率 $\xrightarrow{>0.5}$ 分类 用交叉熵（而非 MSE）拟合

本章将讨论两种产生线性 log-odds 的方法：

- 线性判别分析 (LDA)；
- 线性 Logistic 回归。

二者本质区别在于线性函数拟合到训练数据的方式不同。

此外还介绍直接建模分离超平面的方法：感知机 (Rosenblatt, 1958) 和最优分离超平面 (Vapnik, 1996, 不可分情况见第 12 章)。

12.1.4 基展开：从线性到非线性

通过变量集的基展开，可以将线性边界推广为非线性边界。例如添加平方项和交互项：

$$X_1, X_2 \longrightarrow X_1, X_2, X_1^2, X_2^2, X_1 X_2,$$

增广为 $p(p+1)/2$ 个额外变量。增广空间中的线性函数映射到原始空间即为二次函数，从而实现二次决策边界（见图 4.1）。

任何基变换 $h: \mathbb{R}^p \rightarrow \mathbb{R}^q$ ($q > p$) 都可以类似使用，后续章节将进一步探讨。

12.1.5 本章对 f 的核心限制

本章名为「分类的线性方法」，对判别函数 f （或 δ_k ）的根本限制是：

决策边界必须是线性的（即 $\mathbb{R}^p$ 中的超平面）

但这并不意味着 $\delta_k(x)$ 或 $\Pr(G = k | X = x)$ 本身必须是 x 的线性函数。原书原文明确指出：

“Actually, all we require is that some monotone transformation of δ_k or $\Pr(G = k | X = x)$ be linear for the decision boundaries to be linear.”

也就是说：只要存在某个单调变换 g ，使得 $g(\delta_k(x))$ 是 x 的线性函数，那么决策边界 $\{x | \delta_k(x) = \delta_\ell(x)\}$ 就是线性的。

各方法以不同方式落实这一限制：

- (1) **指示矩阵回归 (§4.2)**：直接限制 $\hat{f}_k(x) = \beta_{k0} + \beta_k^\top x$ 为线性。这是最「刚性」的——不仅边界线性，拟合值本身也是线性的，导致 masking 问题。
- (2) **LDA (§4.3)**：通过分布假设间接实现。假设每类 $f_k(x)$ 为多元 Gaussian 且协方差矩阵相同 ($\Sigma_k = \Sigma$)，则 log-ratio 中的二次项抵消，自然导出线性判别函数 $\delta_k(x) = x^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k$ 。
- (3) **Logistic 回归 (§4.4)**：直接假设 log-odds 为线性： $\log \frac{\Pr(G=k)}{\Pr(G=K)} = \beta_{k0} + \beta_k^\top x$ 。这里限制的是后验概率的 logit 变换，而非判别函数本身。
- (4) **分离超平面方法**：显式地寻找一个超平面来分离类别。

为什么限制为线性？不是因为我们相信真实边界是线性的，而是出于**偏差-方差权衡**：线性边界的偏差可以接受，但其估计方差远低于复杂模型。数据往往只能支持简单边界，线性模型提供了稳定且可解释的解。此外，通过基展开 $h(X)$ 可以将线性限制推广为非线性边界（如二次判别边界），在对 β 保持线性的同时获得灵活性。

注记 12.2. QDA (§4.3) 放松了等协方差假设，边界变为二次的——这已超出「线性方法」的范畴，但仍属于参数化 Gaussian 框架内的自然推广。

12.2 指示矩阵的线性回归

12.2.1 模型设定

将 K 个类别用指示变量编码： $Y_k = 1$ 若 $G = k$ ，否则 0。 N 个训练样本构成 $N \times K$ 的指示响应矩阵 $\mathbf{Y}$ ，每行恰好有一个 1。

对 $\mathbf{Y}$ 的每一列同时拟合线性回归：

$$\hat{\mathbf{Y}} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}, \quad (12.9)$$

得到 $(p+1) \times K$ 的系数矩阵 $\hat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$ 。

对新观测 x 的分类规则：

$$\hat{G}(x) = \arg \max_{k \in \mathcal{G}} \hat{f}_k(x), \quad \text{其中 } \hat{f}(x) = (1, x^\top) \hat{\mathbf{B}}. \quad (12.10)$$

12.2.2 理论依据

一种形式化的理由是：将回归视为条件期望的估计。由于 $\mathbb{E}(Y_k | X = x) = \Pr(G = k | X = x)$ ，每个 Y_k 的条件期望是合理的估计目标。

关键在于：刚性线性回归对条件期望的近似有多好？

注记 12.3. 可以验证：只要模型有截距项， $\sum_k \hat{f}_k(x) = 1$ 对任意 x 成立。但 $\hat{f}_k(x)$ 可能为负或大于 1——这是线性回归刚性本质的后果，尤其是对训练数据凸包之外的预测。

通过基展开 $h(X)$ 上的线性回归，当 $N \rightarrow \infty$ 时自适应地增加基函数数量，可以一致地估计概率（第 5 章讨论）。

12.2.3 最近目标分类视角

令 t_k 为 $K \times K$ 单位矩阵的第 k 列（第 k 类的目标向量）。最小二乘准则可写为：

$$\min_{\mathbf{B}} \sum_{i=1}^N \|y_i - [(1, x_i^\top) \mathbf{B}]^\top\|^2. \quad (12.11)$$

分类时选择与拟合向量最近的目标：

$$\hat{G}(x) = \arg \min_k \|\hat{f}(x) - t_k\|^2. \quad (12.12)$$

这与最大化 $\hat{f}_k(x)$ 完全等价，因为平方范数是分量可分离的。

12.2.4 完整数值示例（ $N = 5, K = 3, p = 1$ ）

下面用一个具体的数据集走通全流程。

Step 1: 构造数据

5 个样本，1 个特征 X ，3 个类别：

i	X	类别 G
1	1	1
2	2	1
3	3	2
4	4	2
5	5	3

Step 2: 构建设计矩阵 $\mathbf{X}$ 和指示矩阵 $\mathbf{Y}$

$$\mathbf{X}_{5 \times 2} = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}, \quad \mathbf{Y}_{5 \times 3} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}.$$

$\mathbf{X}$ 第一列全是 1 (截距), 第二列是特征 X 。 $\mathbf{Y}$ 每行有且仅有一个 1。

Step 3: 计算 $\mathbf{X}^\top \mathbf{X}$ 和 $\mathbf{X}^\top \mathbf{Y}$

$$\mathbf{X}^\top \mathbf{X} = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}, \quad \mathbf{X}^\top \mathbf{Y} = \begin{pmatrix} 2 & 2 & 1 \\ 3 & 7 & 5 \end{pmatrix}.$$

Step 4: 求逆并计算系数矩阵 $\hat{\mathbf{B}}$

$$\det(\mathbf{X}^\top \mathbf{X}) = 5 \times 55 - 15^2 = 50, \quad (\mathbf{X}^\top \mathbf{X})^{-1} = \frac{1}{50} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} = \begin{pmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{pmatrix}.$$

$$\hat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} = \begin{pmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{pmatrix} \begin{pmatrix} 2 & 2 & 1 \\ 3 & 7 & 5 \end{pmatrix} = \begin{pmatrix} 1.3 & 0.1 & -0.4 \\ -0.3 & 0.1 & 0.2 \end{pmatrix}.$$

因此三个类的拟合函数为:

$$\hat{f}_1(x) = 1.3 - 0.3x, \quad \hat{f}_2(x) = 0.1 + 0.1x, \quad \hat{f}_3(x) = -0.4 + 0.2x.$$

验证: $\hat{f}_1(x) + \hat{f}_2(x) + \hat{f}_3(x) = (1.3 + 0.1 - 0.4) + (-0.3 + 0.1 + 0.2)x = 1$ 。

Step 5: 用 $\hat{\mathbf{B}}$ 对新点分类

新点 x	$\hat{f}_1(x)$	$\hat{f}_2(x)$	$\hat{f}_3(x)$	预测类别
2.5	$1.3 - 0.75 = 0.55$	$0.1 + 0.25 = 0.35$	$-0.4 + 0.50 = 0.10$	1
3.5	$1.3 - 1.05 = 0.25$	$0.1 + 0.35 = 0.45$	$-0.4 + 0.70 = 0.30$	2
5.5	$1.3 - 1.65 = -0.35$	$0.1 + 0.55 = 0.65$	$-0.4 + 1.10 = 0.70$	3


Step 6: 确定决策边界

令 $\hat{f}_k(x) = \hat{f}_\ell(x)$:

$$\text{类 1-2: } 1.3 - 0.3x = 0.1 + 0.1x \implies x = 3,$$

$$\text{类 2-3: } 0.1 + 0.1x = -0.4 + 0.2x \implies x = 5,$$

$$\text{类 1-3: } 1.3 - 0.3x = -0.4 + 0.2x \implies x = 3.4.$$



最终分类规则: $x < 3 \rightarrow$ 类别 1, $3 < x < 5 \rightarrow$ 类别 2, $x > 5 \rightarrow$ 类别 3。在本例中三类有序排列且分离良好, 没有发生 masking。

注记 12.4. 注意 $\hat{f}_2(5.5) = 0.65$ 和 $\hat{f}_3(5.5) = 0.70$ 都很正常 (在 $[0, 1]$ 内), 但 $\hat{f}_1(5.5) = -0.35$ 是负数——这就是线性回归刚性本质的体现: 在外推区域, 拟合值可能超出 $[0, 1]$ 。Logistic 回归通过 sigmoid 变换解决了这个问题。

12.2.5 Masking 问题

当 $K \geq 3$ 时, 线性回归存在严重的掩蔽 (masking) 问题: 某些类别可能被其他类别完全掩盖。

例 12.1 (三类完美分离的 masking). 图 4.2 展示了一个极端情况: 三类数据被线性决策边界完美分离, 但线性回归完全错过了中间类。将数据投影到连接三个类质心的直线上, 中间类的回归线是水平的, 其拟合值永远不会最大。

注记 12.5. 一个宽松的通用规则是: 如果 $K \geq 3$ 个类别排成一线, 可能需要高达 $K - 1$ 次的多项式才能区分它们。在 p 维输入空间中, 最坏情况下需要总次数 $K - 1$ 的通用多项式和交互项, 共 $O(p^{K-1})$ 个项。


12.2.6 Masking 数值演示 ($N = 5, K = 3, p = 1$)

下面构造一个会发生 masking 的数据集, 与上一节的正常示例对比。

数据构造: 让中间类「被夹击」

关键思路: 让类别 1 和类别 3 分别位于两端, 类别 2 孤零零在中间。

i	X	类别 G
1	0	1
2	1	1
3	4	2
4	7	3
5	8	3



Step 1-2: 构造 $\mathbf{X}$ 和 $\mathbf{Y}$

$$\mathbf{X}_{5 \times 2} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 4 \\ 1 & 7 \\ 1 & 8 \end{pmatrix}, \quad \mathbf{Y}_{5 \times 3} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{pmatrix}.$$

Step 3: 计算 $\mathbf{X}^\top \mathbf{X}$ 和 $\mathbf{X}^\top \mathbf{Y}$

$$\mathbf{X}^\top \mathbf{X} = \begin{pmatrix} 5 & 20 \\ 20 & 130 \end{pmatrix}, \quad \mathbf{X}^\top \mathbf{Y} = \begin{pmatrix} 2 & 1 & 2 \\ 1 & 4 & 15 \end{pmatrix}.$$

Step 4: 系数矩阵 $\hat{\mathbf{B}}$

$$\det = 5 \times 130 - 20^2 = 250, \quad (\mathbf{X}^\top \mathbf{X})^{-1} = \frac{1}{250} \begin{pmatrix} 130 & -20 \\ -20 & 5 \end{pmatrix} = \begin{pmatrix} 0.52 & -0.08 \\ -0.08 & 0.02 \end{pmatrix}.$$

$$\hat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} = \begin{pmatrix} 0.52 & -0.08 \\ -0.08 & 0.02 \end{pmatrix} \begin{pmatrix} 2 & 1 & 2 \\ 1 & 4 & 15 \end{pmatrix} = \begin{pmatrix} 0.96 & 0.20 & -0.16 \\ -0.14 & 0.00 & 0.14 \end{pmatrix}.$$

因此:

$$\boxed{\hat{f}_1(x) = 0.96 - 0.14x}, \quad \boxed{\hat{f}_2(x) = 0.20}, \quad \boxed{\hat{f}_3(x) = -0.16 + 0.14x}.$$

关键发现: $\hat{f}_2(x)$ 是常数 0.20, 斜率为零! 这意味着一根水平线——这正是 masking 的数学表现。

验证: $\sum_k \hat{f}_k(x) = (0.96 + 0.20 - 0.16) + (-0.14 + 0 + 0.14)x = 1$ 。

Step 5: 检验各类拟合值——谁在主导？

x	$\hat{f}_1(x)$	$\hat{f}_2(x)$	$\hat{f}_3(x)$	最大值
0	0.96	0.20	-0.16	类 1 (0.96)
2	0.68	0.20	0.12	类 1 (0.68)
4	0.40	0.20	0.40	类 1/3 平局 (0.40)
6	0.12	0.20	0.68	类 3 (0.68)
8	-0.16	0.20	0.96	类 3 (0.96)

在任意 x 处, $\hat{f}_2(x) = 0.20$ 永远不会是最大值!

Step 6: 从数学上看为什么会这样

求两两决策边界:

$$\text{类 1-2: } 0.96 - 0.14x = 0.20 \implies x \approx 5.43,$$


$$\text{类 2-3: } 0.20 = -0.16 + 0.14x \implies x \approx 2.57,$$

$$\text{类 1-3: } 0.96 - 0.14x = -0.16 + 0.14x \implies x = 4.$$

注意: 类 2「理论上应该统治」的区间是 (2.57, 5.43)——在这个区间内, $\hat{f}_2$ 同时大于 $\hat{f}_1$ 和 $\hat{f}_3$ 的 等等, 真的是这样吗?

$$x \in (2.57, 5.43) \implies \begin{cases} \hat{f}_1(x) < 0.20 & (\text{只在 } x > 5.43 \text{ 时}) \\ \hat{f}_3(x) < 0.20 & (\text{只在 } x < 2.57 \text{ 时}) \end{cases}$$

在 (2.57, 5.43) 内, $\hat{f}_1(x) > 0.20$ 且 $\hat{f}_3(x) > 0.20$, 两者都不给 $\hat{f}_2$ 机会!



橙色阴影是类 2 本应统治的区间, 但被 $\hat{f}_1$ 和 $\hat{f}_3$ 的斜线从上方盖过。即使 $x = 4$ (类 2 唯一的训练点), $\hat{f}_1 = \hat{f}_3 = 0.40$ 也远超 $\hat{f}_2 = 0.20$ 。

与正常示例的对比

	正常示例 (前节)	Masking 示例 (本节)	原因
数据排列	1,1,2,2,3 (各类均匀)	1,1,2,3,3 (中间稀疏)	类 2 样本太少、太孤立
$\hat{f}_2$ 斜率	+0.10 (正斜率)	0 (水平线)	线性回归无法为上翘分配系数
类 2 是否出现	是, $3 < x < 5$	否, 永不最大	水平线被两条斜线全程压制

本质原因

线性回归对每个类的指示变量独立拟合一条直线。当中间类样本稀疏且被两端类「夹击」时，最小二乘倾向于给中间类分配**近零斜率**——因为任何非零斜率都会增大对两端类标签的残差，而最小二乘被两端类的多数样本主导。中间类于是变成水平线，被全程压制。

这也解释了为什么 **LDA 能解决 masking**：LDA 不是对每类独立拟合，而是通过共同的协方差矩阵 Σ 把所有类的几何关系耦合在一起。

为什么只有 1 个点时 $\hat{f}_2$ 恰好是常数？——最小二乘的视角

回到 $\hat{f}_2(x) = 0.20$ （斜率为零）这个结果。你的直觉很对： $\hat{f}_2$ 和 $\hat{f}_1, \hat{f}_3$ 是独立拟合的，给 $\hat{f}_2$ 加斜率不会直接影响另外两条线。那为什么最小二乘偏偏选择了斜率为零？

原因：简单线性回归的斜率公式。

$\hat{f}_2$ 只拟合类 2 的指示变量列： $\mathbf{y}_2 = (0, 0, 1, 0, 0)^\top$ 。这是 $N = 5$ 个点上的简单线性回归（带截距）。斜率的 OLS 公式为：

$$\hat{\beta}_{12} = \frac{\text{Cov}(x, y_2)}{\text{Var}(x)} = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_{2i} - \bar{y}_2)}{\sum_{i=1}^N (x_i - \bar{x})^2}.$$

代入数值： $\bar{x} = \frac{0+1+4+7+8}{5} = 4$ ， $\bar{y}_2 = \frac{1}{5} = 0.2$ 。

$$\begin{aligned} \text{Cov}(x, y_2) &= (0-4)(0-0.2) + (1-4)(0-0.2) + \underbrace{(4-4)(1-0.2)}_{=0} + (7-4)(0-0.2) + (8-4)(0-0.2) \\ &= (-4)(-0.2) + (-3)(-0.2) + 0 + (3)(-0.2) + (4)(-0.2) \\ &= 0.8 + 0.6 + 0 - 0.6 - 0.8 = 0. \end{aligned}$$

$$\hat{\beta}_{12} = \frac{0}{\text{Var}(x)} = 0.$$

协方差恰好为零！这不是巧合——因为类 2 唯一的训练点 $x = 4$ 恰好等于所有样本的均值 $\bar{x} = 4$ 。在最小二乘的几何中，回归直线必然经过 $(\bar{x}, \bar{y}_2) = (4, 0.2)$ 。此时类 2 的正样本就在「重心」上，**没有任何杠杆来撬动斜率**——无论向左还是向右倾斜，都会增大其余 4 个零标签点的残差，而不会改善 $x = 4$ 处的拟合（它已经被截距覆盖了）。

如果类 2 的点不在均值呢？

假设把类 2 的点从 $x = 4$ 移到 $x = 5$ （即数据变为 0, 1, 5, 7, 8），则：

$$\begin{aligned} \bar{x} = 4.2, \quad \text{Cov}(x, y_2) &= (-4.2)(-0.2) + (-3.2)(-0.2) + (0.8)(0.8) + (2.8)(-0.2) + (3.8)(-0.2) \\ &= 0.84 + 0.64 + 0.64 - 0.56 - 0.76 = 0.80, \end{aligned}$$

$$\hat{\beta}_{12} = \frac{0.80}{50.8} \approx 0.016, \quad \hat{f}_2(x) \approx 0.134 + 0.016x.$$

斜率不再是零，但非常接近零（几乎水平）。Masking 依然发生，只是不如斜率为零时那么「干净」。

结论：

$\hat{f}_2$ 为常数是**最小二乘 + 正样本位于重心**的共同结果，不是独立拟合的必然。

独立拟合意味着各 $\hat{f}_k$ 互不干扰，但每条 $\hat{f}_k$ 自身的斜率完全由最小二乘决定。当 $K \geq 3$ 且中间类样本稀疏时，最小二乘自然倾向于给中间类分配近零斜率，从而产生 masking。这正是 ESL 指出「指示矩阵回归本质上是刚性线性回归」的含义——刚性不在于各条线之间的耦合，而在于**每条线自身的线性约束 + 最小二乘准则**共同导致的脆弱性。

注记 12.6. 即使在 $x = 4$ （类 2 唯一训练点所在位置）， $\hat{f}_2(4) = 0.20$ 也小于 $\hat{f}_1(4) = \hat{f}_3(4) = 0.40$ ——连自己的训练样本都分不对。这是 masking 最直观的体现。

12.3 线性判别分析 (LDA)

12.3.1 Bayes 分类框架

分类的决策论 (§2.4) 指出，最优分类需要知道后验概率 $\Pr(G | X)$ 。设 $f_k(x)$ 为类别 k 下 X 的条件密度， π_k 为类别 k 的先验概率。由 Bayes 定理：

$$\Pr(G = k | X = x) = \frac{f_k(x)\pi_k}{\sum_{\ell=1}^K f_{\ell}(x)\pi_{\ell}}. \quad (12.13)$$

为什么最优分类需要 $\Pr(G | X)$ ？——从损失函数到后验概率

前面 §4.1–§4.2 讨论了各种分类方法，但始终没有显式写出 $\Pr(G | X)$ 和损失函数 $L(G, \hat{G})$ 之间的关系。这里补全。

给定 x ，预测类别 k 的期望损失：

设损失函数为 $L(g, \hat{g})$ ，其中 g 为真实类别， $\hat{g}$ 为预测类别。对于一个新的输入点 x ，若我们预测其类别为 k ，则该决策的**条件期望损失**为：

$$R(k | x) = \mathbb{E}_{G|X} [L(G, k) | X = x] = \sum_{\ell=1}^K L(\ell, k) \cdot \Pr(G = \ell | X = x). \quad (12.14)$$

即：遍历所有可能的真实类别 ℓ ，用后验概率加权对应的损失。

$\mathbb{E}[L(G, \hat{G})]$ 与 $R(k | x)$ 的关系：

上述 $R(k | x)$ 是**给定 x 之后**，选择类别 k 的条件风险。而我们在 §4.1 讨论的 $\mathbb{E}[L(G, \hat{G})]$ 是**无条件期望损失**。二者通过全期望公式（tower property）连接：

$$\mathbb{E}[L(G, \hat{G}(X))] = \mathbb{E}_X [\mathbb{E}_{G|X} [L(G, \hat{G}(X)) | X]] = \mathbb{E}_X [R(\hat{G}(X) | X)]. \quad (12.15)$$

展开为积分形式：

$$\mathbb{E}[L(G, \hat{G})] = \int_{\mathcal{X}} R(\hat{G}(x) | x) dP_X(x).$$

含义：整体期望损失 = 在每个 x 处查询分类器 $\hat{G}(x)$ 所选类别的条件风险 $R(\hat{G}(x) | x)$ ，再对 x 的分布取平均。

由此，Bayes 最优分类器的构造逻辑是**逐点最小化**——对每个 x 独立地选择使 $R(k | x)$ 最小的 k ：

$$\hat{G}^*(x) = \arg \min_{k \in \mathcal{G}} R(k | x), \quad (12.16)$$

其对应的 **Bayes 风险**（不可再降低的最小期望损失）为：

$$R^* = \mathbb{E}_X \left[\min_k R(k | X) \right]. \quad (12.17)$$

对任意分类器 $\hat{G}$ ，恒有 $\mathbb{E}[L(G, \hat{G})] \geq R^*$ 。

代入 0-1 损失：

对于分类问题最自然的损失——0-1 损失 $L(\ell, k) = \mathbb{I}\{\ell \neq k\}$ ：

$$\begin{aligned} R(k | x) &= \sum_{\ell=1}^K \mathbb{I}\{\ell \neq k\} \cdot \Pr(G = \ell | X = x) \\ &= \sum_{\ell \neq k} \Pr(G = \ell | X = x) \\ &= 1 - \Pr(G = k | X = x). \end{aligned} \quad (12.18)$$

预测为类别 k 的期望 0-1 损失 = $1 - \Pr(G = k | X = x)$

Bayes 最优分类器：

要最小化期望 0-1 损失，只需最大化后验概率。因此最优分类规则为：

$$\hat{G}^*(x) = \arg \max_{k \in \mathcal{G}} \Pr(G = k | X = x). \quad (12.19)$$

这就是「最优分类需要知道后验概率」的完整数学链条：

最小化 $\mathbb{E}[L(G, \hat{G})] \iff$ 逐点最小化 $R(k | x) \iff$ 最大化 $\Pr(G = k | X = x)$

推广到一般损失函数：

若损失不是 0-1（例如非对称损失：把「类 1 错判为类 2」的代价远大于反向），则 (12.14) 依然适用——只需将 $L(\ell, k)$ 替换为实际损失矩阵。此时最优分类不再是简单地取最大后验，而是取最小期望代价。

回到本章的方法：

本章所有方法本质上都是在**用不同方式估计** $\Pr(G = k | X = x)$ （或其单调变换）：

- LDA/QDA：假设 $f_k(x)$ 为 Gaussian $\rightarrow$ Bayes 定理 $\rightarrow$ 后验；
- Logistic 回归：直接参数化 log-odds $\rightarrow$ sigmoid $\rightarrow$ 后验；
- 指示矩阵回归：用 $\hat{f}_k(x)$ 近似 $\Pr(G = k | X = x)$ （但可能越界）。

LDA/QDA 如何逼近 Bayes 上界

Bayes 分类器 $\arg \max_k P(G = k \mid X = x)$ 给出了 EPE 的理论下界——但真实后验未知。LDA/QDA 的策略不是直接估计后验，而是通过 Bayes 定理把它拆成可估计的零件：

$$P(G = k \mid X = x) = \frac{f_k(x) \pi_k}{\sum_j f_j(x) \pi_j},$$

然后对类条件密度 $f_k(x)$ 做分布假设，用训练数据估计其参数。

二者的差异仅在于协方差假设：

	LDA	QDA
假设	$f_k \sim N(\mu_k, \Sigma)$, Σ 所有类共用	$f_k \sim N(\mu_k, \Sigma_k)$, Σ_k 各类不同
决策边界	线性超平面	二次曲面

逼近上界的逻辑：如果 Gaussian 假设恰好成立，代入估计参数后 $\hat{\delta}_k$ 在大样本下收敛到真实 Bayes 上界 ($\hat{\mu}_k \rightarrow \mu_k$ 等)。若假设不成立，则是有偏近似——偏差来自分布假设的错误，方差来自参数估计的不确定性。

LDA/QDA 的训练：估计什么参数？

LDA/QDA 的训练不涉及迭代优化或梯度下降——直接从 (X, Y) 计算样本统计量，然后组装成 δ_k ：

参数	含义	估计公式
$\hat{\mu}_k \in \mathbb{R}^p$	第 k 类均值	$\frac{1}{N_k} \sum_{i:y_i=k} x_i$ （类内样本均值）
$\hat{\Sigma} \in \mathbb{R}^{p \times p}$	LDA 公共协方差	$\frac{1}{N - K} \sum_{k=1}^K \sum_{i:y_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^\top$ （池化）
$\hat{\Sigma}_k \in \mathbb{R}^{p \times p}$	QDA 各类协方差	$\frac{1}{N_k - 1} \sum_{i:y_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^\top$ （各自估计）
$\hat{\pi}_k \in [0, 1]$	先验概率	N_k / N （类频率），或由领域知识给定

最后将估计参数代入 LDA 的线性判别函数：

$$\delta_k(x) = x^\top \hat{\Sigma}^{-1} \hat{\mu}_k - \frac{1}{2} \hat{\mu}_k^\top \hat{\Sigma}^{-1} \hat{\mu}_k + \log \hat{\pi}_k,$$

或 QDA 的二次判别函数：

$$\delta_k(x) = -\frac{1}{2} \log |\hat{\Sigma}_k| - \frac{1}{2} (x - \hat{\mu}_k)^\top \hat{\Sigma}_k^{-1} (x - \hat{\mu}_k) + \log \hat{\pi}_k.$$

训练完成后，对新输入 x 只需计算这些 $\delta_k(x)$ 并取 $\arg \max$ 即可分类。

这与 Logistic 回归的本质区别在于：LDA 是**生成式**（建模 $P(X \mid G)$ ，再通过 Bayes 定理得后验），Logistic 回归是**判别式**（直接建模 $P(G \mid X)$ ，跳过了对 X 分布的假设）。

完整数值示例：从密度到后验到决策

下面用一个二分类一维 Gaussian 例子走完整个 Bayes 分类流水线。

设定：

- 类别 1: $X | G = 1 \sim \mathcal{N}(\mu_1 = 2, \sigma^2 = 1)$, 先验 $\pi_1 = 0.4$;
- 类别 2: $X | G = 2 \sim \mathcal{N}(\mu_2 = 5, \sigma^2 = 1)$, 先验 $\pi_2 = 0.6$ 。

两类的方差相同（这是 LDA 的前提），但先验不同。

Step 1: 对新点 $x = 3$, 计算类条件密度 $f_k(x)$ 。

$$f_k(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu_k)^2}{2\sigma^2}\right), \quad \frac{1}{\sqrt{2\pi}} \approx 0.3989.$$

$$f_1(3) = 0.3989 \cdot \exp\left(-\frac{(3-2)^2}{2}\right) = 0.3989 \cdot e^{-0.5} \approx 0.3989 \cdot 0.6065 = 0.2420,$$

$$f_2(3) = 0.3989 \cdot \exp\left(-\frac{(3-5)^2}{2}\right) = 0.3989 \cdot e^{-2} \approx 0.3989 \cdot 0.1353 = 0.0540.$$

Step 2: Bayes 定理 $\rightarrow$ 后验概率 $\Pr(G = k | X = 3)$ 。

$$\begin{aligned} \Pr(G = 1 | X = 3) &= \frac{f_1(3) \pi_1}{f_1(3) \pi_1 + f_2(3) \pi_2} \\ &= \frac{0.2420 \times 0.4}{0.2420 \times 0.4 + 0.0540 \times 0.6} = \frac{0.0968}{0.0968 + 0.0324} = \frac{0.0968}{0.1292} \approx \mathbf{0.749}, \end{aligned}$$

$$\Pr(G = 2 | X = 3) = 1 - 0.749 = \mathbf{0.251}.$$

Step 3: 计算条件风险 $R(k | x)$ (0-1 损失)。

$$R(1 | 3) = 1 - \Pr(G = 1 | X = 3) = 1 - 0.749 = \mathbf{0.251},$$

$$R(2 | 3) = 1 - \Pr(G = 2 | X = 3) = 1 - 0.251 = \mathbf{0.749}.$$

Step 4: 最优决策。

$$\hat{G}^*(3) = \arg \min_k R(k | 3) = \arg \max_k \Pr(G = k | X = 3) = \mathbf{1}.$$

在 $x = 3$ 处, 预测为类别 1 的期望 0-1 损失 (0.251) 远小于预测为类别 2 (0.749), 因此判为类别 1。

Step 5 (附加): 求决策边界。

决策边界是 $\Pr(G = 1 | X = x) = \Pr(G = 2 | X = x)$ 的位置, 即 $f_1(x) \pi_1 = f_2(x) \pi_2$:

$$0.4 \cdot \exp\left(-\frac{(x-2)^2}{2}\right) = 0.6 \cdot \exp\left(-\frac{(x-5)^2}{2}\right).$$

取对数:

$$\ln 0.4 - \frac{(x-2)^2}{2} = \ln 0.6 - \frac{(x-5)^2}{2}.$$

$$-0.9163 - \frac{x^2 - 4x + 4}{2} = -0.5108 - \frac{x^2 - 10x + 25}{2}.$$

两边乘以 2:


$$-1.8326 - (x^2 - 4x + 4) = -1.0216 - (x^2 - 10x + 25).$$

展开并消去 $-x^2$:

$$-1.8326 - x^2 + 4x - 4 = -1.0216 - x^2 + 10x - 25 \implies -6x = -20.189 \implies x \approx 3.365.$$

更简洁地用判别函数: 由于方差相等, 边界也可由 (12.21) 的特例得出:

$$x = \frac{\mu_1 + \mu_2}{2} - \frac{\sigma^2}{\mu_2 - \mu_1} \ln \frac{\pi_2}{\pi_1} = \frac{7}{2} - \frac{1}{3} \ln \frac{0.6}{0.4} = 3.5 - \frac{\ln 1.5}{3} \approx 3.5 - 0.135 = 3.365.$$



总结流水线:

$$\begin{aligned} & \text{类条件密度 } f_k(x) \\ & \downarrow \text{Bayes 定理} \\ & \text{后验概率 } \Pr(G = k \mid X = x) \\ & \downarrow \text{0-1 损失} \\ & \text{条件风险 } R(k \mid x) = 1 - \Pr(G = k \mid X = x) \\ & \downarrow \arg \min_k \\ & \text{最优分类 } \hat{G}^*(x) \end{aligned}$$

在本例中, 当 $x < 3.365$ 时判为类 1, 否则判为类 2。注意由于 $\pi_2 > \pi_1$, 边界从 $\frac{\mu_1 + \mu_2}{2} = 3.5$ 向左偏移到了 3.365——先验的差异会移动决策边界。

基于类条件密度的常见方法有:

- 线性/二次判别分析: 使用 Gaussian 密度;
- 混合 Gaussian: 允许非线性边界 (§6.8);
- 非参数密度估计: 最大灵活性 (§6.6.2);
- Naive Bayes: 假设各输入在类内条件独立 (§6.6.3)。

12.3.2 Gaussian 假设下的 LDA

假设每类密度为多元 Gaussian:

$$f_k(x) = \frac{1}{(2\pi)^{p/2} |\Sigma_k|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu_k)^\top \Sigma_k^{-1} (x - \mu_k)\right). \quad (12.20)$$

LDA 的特例: 假设各类协方差相同 $\Sigma_k = \Sigma$ (对所有 k)。比较两类 k 和 ℓ 时, 考虑 log-ratio:

$$\log \frac{\Pr(G = k | X = x)}{\Pr(G = \ell | X = x)} = \log \frac{\pi_k}{\pi_\ell} - \frac{1}{2}(\mu_k + \mu_\ell)^\top \Sigma^{-1} (\mu_k - \mu_\ell) + x^\top \Sigma^{-1} (\mu_k - \mu_\ell). \quad (12.21)$$

注记 12.7. 等协方差矩阵使得归一化因子和指数中的二次项相互抵消, log-ratio 成为 x 的线性函数。因此决策边界是超平面。

12.3.3 线性判别函数

从 (12.21) 可提取出等价的判别函数:

$$\delta_k(x) = x^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k. \quad (12.22)$$

分类规则为 $\hat{G}(x) = \arg \max_k \delta_k(x)$ 。

注记 12.8. 决策边界不是类质心连线的垂直平分线, 除非 $\Sigma = \sigma^2 \mathbf{I}$ 且各类先验相等。

12.3.4 参数估计

实践中参数由训练数据估计:

- $\hat{\pi}_k = N_k/N$, 其中 N_k 为第 k 类的样本数;
- $\hat{\mu}_k = \sum_{g_i=k} x_i / N_k$;
- $\hat{\Sigma} = \sum_{k=1}^K \sum_{g_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^\top / (N - K)$ (pooled 协方差)。

12.3.5 二分类 LDA 与最小二乘的对应

对于二分类, LDA 分类为类别 2 的条件是:

$$x^\top \hat{\Sigma}^{-1} (\hat{\mu}_2 - \hat{\mu}_1) > \frac{1}{2} (\hat{\mu}_1 + \hat{\mu}_2)^\top \hat{\Sigma}^{-1} (\hat{\mu}_2 - \hat{\mu}_1) - \log(N_2/N_1). \quad (12.23)$$

若将两类分别编码为 +1 和 -1, 最小二乘得到的系数向量与 LDA 方向成比例 (习题 4.2)。但除非 $N_1 = N_2$, 截距不同, 从而决策规则不同。

注记 12.9. LDA 方向通过最小二乘的推导不依赖于 Gaussian 假设, 因此适用范围超出 Gaussian 数据。但截距/切点的推导确实需要 Gaussian 假设。实践中, 可以选择经验上最小化训练误差的切点, 效果通常很好。

当 $K > 2$ 时, LDA 与指示矩阵的线性回归不再等价, 且 LDA 能避免 masking 问题。回归与 LDA 的对应可通过最优得分 (§12.5) 建立。

12.4 二次判别分析 (QDA)

若不假设各类协方差相等 (Σ_k 不同), 则 (12.21) 中的抵消不再发生, x 的二次项保留。得到二次判别函数:

$$\delta_k(x) = -\frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (x - \mu_k)^\top \Sigma_k^{-1} (x - \mu_k) + \log \pi_k. \quad (12.24)$$

每对类别之间的决策边界由二次方程 $\{x \mid \delta_k(x) = \delta_\ell(x)\}$ 描述。

12.4.1 参数数量

- LDA: $(K - 1) \times (p + 1)$ 个参数 (因为只需知道 $\delta_k(x) - \delta_K(x)$ 的差分);
- QDA: $(K - 1) \times \{p(p + 3)/2 + 1\}$ 个参数。

当 p 较大时, QDA 的参数数量急剧增加。

12.4.2 LDA 与 QDA 的性能讨论

LDA 和 QDA 在很多分类任务中表现优异。例如 STATLOG 项目 (Michie et al., 1994) 中:

- LDA 在 22 个数据集中的 7 个上进入前三;
- QDA 在 4 个数据集上进入前三;
- 二者之一在 10 个数据集上进入前三。

注记 12.10. LDA/QDA 表现好的原因不太可能是数据近似 Gaussian 且协方差近似相等。更可能的原因是: 数据只能支持简单的线性或二次决策边界, 而 Gaussian 模型提供的估计是稳定的。这是偏差-方差权衡——线性边界的偏差可以接受, 因为其方差远低于更复杂的替代方法。

12.5 正则化判别分析 (RDA)

Friedman (1989) 提出了 LDA 与 QDA 之间的折中方案: 将 QDA 的各类协方差向公共协方差收缩, 类似于岭回归的思想。

12.5.1 模型形式

正则化协方差矩阵:

$$\hat{\Sigma}_k(\alpha) = \alpha \hat{\Sigma}_k + (1 - \alpha) \hat{\Sigma}, \quad (12.25)$$

其中 $\hat{\Sigma}$ 是 LDA 的池化协方差矩阵。 $\alpha \in [0, 1]$ 控制从 LDA ($\alpha = 0$) 到 QDA ($\alpha = 1$) 的连续过渡, 通常通过交叉验证选择。

进一步可将 $\hat{\Sigma}$ 自身向标量协方差收缩:

$$\hat{\Sigma}(\gamma) = \gamma \hat{\Sigma} + (1 - \gamma) \hat{\sigma}^2 \mathbf{I}, \quad (12.26)$$

$\gamma \in [0, 1]$ 。将 $\hat{\Sigma}(\gamma)$ 替代 (12.25) 中的 $\hat{\Sigma}$, 得到由 (α, γ) 参数化的更一般的协方差族 $\hat{\Sigma}_k(\alpha, \gamma)$ 。

12.6 LDA 的计算

LDA 和 QDA 的计算可通过对角化协方差矩阵来简化。

12.6.1 对角化方法

对每个 $\hat{\Sigma}_k$ 做特征分解 $\hat{\Sigma}_k = U_k D_k U_k^\top$, 其中 U_k 为 $p \times p$ 正交矩阵, D_k 为对角正特征值矩阵。则判别函数 $\delta_k(x)$ 的两个成分简化为:

- 马氏距离: $(x - \hat{\mu}_k)^\top \hat{\Sigma}_k^{-1} (x - \hat{\mu}_k) = [U_k^\top (x - \hat{\mu}_k)]^\top D_k^{-1} [U_k^\top (x - \hat{\mu}_k)]$;
- 对数行列式: $\log |\hat{\Sigma}_k| = \sum_\ell \log d_{k\ell}$ 。

12.6.2 LDA 的球形化实现

为什么要球形化?

LDA 的判别函数 (12.22) 中, 核心项是马氏距离:

$$(x - \mu_k)^\top \Sigma^{-1} (x - \mu_k).$$

若直接使用欧氏距离 $\|x - \mu_k\|^2$, 则隐含假设协方差 $\Sigma = \sigma^2 \mathbf{I}$ (各向同性球状分布)。但实际数据常呈椭球状——不同方向上的方差不同, 且特征之间可能相关 (Σ 非对角)。

马氏距离通过 Σ^{-1} 对空间做了「扭曲」, 正确度量了在数据分布下的距离。但每分类一个新点都要算一次 $(\cdot)^\top \Sigma^{-1} (\cdot)$, 不够经济。球形化的思路是: 一次性把整个空间变换好, 此后距离计算退化为欧氏距离。

球形化变换

对公共协方差估计做特征分解：

$$\hat{\Sigma} = UDU^{\top}, \quad (12.27)$$

其中 U 为 $p \times p$ 正交矩阵（列是 $\hat{\Sigma}$ 的特征向量）， $D = \text{diag}(d_1, \dots, d_p)$ 为特征值对角矩阵（ $d_j > 0$ ）。

定义球形化变换：

$$X^* = D^{-\frac{1}{2}}U^{\top}X, \quad (12.28)$$

其中 $D^{-\frac{1}{2}} = \text{diag}(d_1^{-1/2}, \dots, d_p^{-1/2})$ 。

变换后的协方差

验证：变换后 X^* 的公共协方差成为单位矩阵：

$$\begin{aligned} \text{Cov}(X^*) &= D^{-\frac{1}{2}}U^{\top} \hat{\Sigma} U D^{-\frac{1}{2}} \\ &= D^{-\frac{1}{2}}U^{\top} (UDU^{\top}) U D^{-\frac{1}{2}} \\ &= D^{-\frac{1}{2}} D D^{-\frac{1}{2}} \\ &= \mathbf{I}. \end{aligned}$$

Sphering 的几何含义

$D^{-\frac{1}{2}}U^{\top}$ 这个操作分两步理解：

- (1) $U^{\top}X$ （旋转）：将坐标轴旋转到 $\hat{\Sigma}$ 的特征向量方向，消除特征间的相关性（使协方差矩阵对角化）；
- (2) $D^{-\frac{1}{2}}(\cdot)$ （缩放）：沿每个新坐标轴除以对应的标准差 $\sqrt{d_j}$ ，使各方向方差均变为 1。

几何上，原始空间中「1 单位马氏距离」的椭球 $\{x \mid x^{\top} \hat{\Sigma}^{-1} x = 1\}$ ，经变换后成为单位球面 $\{x^* \mid \|x^*\|^2 = 1\}$ 。

球形化后的分类规则

设 $\mu_k^* = D^{-\frac{1}{2}}U^{\top} \hat{\mu}_k$ 为球形化空间中的类质心。则在球形化空间中，马氏距离退化为欧氏距离：

$$(x - \hat{\mu}_k)^{\top} \hat{\Sigma}^{-1} (x - \hat{\mu}_k) = \|x^* - \mu_k^*\|^2.$$

因此 LDA 分类规则等价于：

$$\hat{G}(x) = \arg \max_k \delta_k(x) = \arg \max_k \left(x^{*\top} \mu_k^* - \frac{1}{2} \|\mu_k^*\|^2 + \log \hat{\pi}_k \right).$$

在球形化空间中， $-\frac{1}{2} \|\mu_k^*\|^2 + \log \hat{\pi}_k$ 是仅依赖类别的常数修正项。

简化情形：若各类先验相等（ $\pi_k \equiv 1/K$ ），修正项退化为仅依赖 $\|\mu_k^*\|^2$ ，分类简化为——在球形化空间中，到哪个质心最近就分到哪类。

两步实现总结

- (1) **球形化**: 对原始数据施加 (12.28), 一次性变换为「各向同性」空间;
- (2) **分类到最近质心**: 在球形化空间中计算到各类质心的欧氏距离, 取最近者 (必要时加 $\log \pi_k$ 修正)。

注记 12.11. 实际使用 `sklearn` 等库时无需手动实现这些步骤——库内部自动完成特征分解和球形化。但理解球形化有助于: 诊断 $\hat{\Sigma}$ 奇异 (特征值为零时 $D^{-\frac{1}{2}}$ 无定义 $\rightarrow$ 无法球形化 $\rightarrow$ 高维小样本下 LDA 失效), 以及理解后续降秩 LDA 的原理。

12.7 降秩线性判别分析

12.7.1 动机: 质心在低维仿射子空间中

K 个类质心 (p 维空间中的点) 必然落在至多 $K-1$ 维的仿射子空间中。若 $p \gg K$, 维度大幅降低。在定位最近质心时, 可忽略与该子空间正交方向上的距离——因为这些距离对各质心贡献相同, 不影响比较结果。

当 $K=3$ 时, 可将数据投影到二维平面上查看 (如图 4.4), 且不丢失 LDA 分类所需的任何信息。

12.7.2 Fisher 的判别准则

Fisher 不从 Gaussian 假设出发, 而是直接提出优化问题。




FIGURE 4.9. Although the line joining the centroids defines the direction of greatest centroid spread, the projected data overlap because of the covariance (left panel). The discriminant direction minimizes this overlap for Gaussian data (right panel).

图 12.1: 左图: 质心连线方向投影——虽然该方向质心分离最大, 但由于协方差结构, 投影后两类严重重叠。右图: Fisher 判别方向——同时考虑类内协方差, 投影后方差最小化、类间分离最大化 (Gaussian 数据下)。来源: ESL Figure 4.9。

如图 12.1 所示，仅沿质心连线方向投影是不够的——该方向虽然最大化质心间距，却忽略了数据本身的散布（协方差）。Fisher 的关键洞察是：**好的投影方向应同时最大化类间分离和最小化类内散布**。形式化地：

寻找线性组合 $Z = a^\top X$ ，使类间方差相对于类内方差最大化

这等价于最大化 Rayleigh 商：

$$\max_a \frac{a^\top B a}{a^\top W a}, \quad (12.29)$$

或等价地：

$$\max_a a^\top B a \quad \text{s.t.} \quad a^\top W a = 1,$$

其中 B 为类间散布矩阵， W 为类内散布矩阵。

各符号的精确含义

- $a \in \mathbb{R}^p \setminus \{0\}$ ：投影方向向量。投影操作 $z = a^\top x$ 将 p 维向量 x 压缩为标量 z （沿 a 方向的坐标）。任何非零 p 维向量都是候选方向，优化目标是从 $\mathbb{R}^p$ 中选出最好的那个。
- B （类间散布，**Between-class scatter**）：度量各类质心相对于总质心的散布程度，

$$B = \sum_{k=1}^K N_k (\mu_k - \mu)(\mu_k - \mu)^\top,$$

其中 μ_k 为第 k 类均值（质心）， μ 为全体总均值。对二分类退化为 $B \propto (\mu_1 - \mu_2)(\mu_1 - \mu_2)^\top$ （秩-1 矩阵，方向沿质心连线）。

- W （类内散布，**Within-class scatter**）：池化（pooled）的公共类内离差和，

$$W = \sum_{k=1}^K \sum_{i: y_i=k} (x_i - \mu_k)(x_i - \mu_k)^\top = \sum_{k=1}^K (N_k - 1) \hat{\Sigma}_k,$$

其中 $\hat{\Sigma}_k$ 为各类各自的协方差估计。注意 W 不分类别——它假设各类协方差相同（ $\Sigma_1 = \dots = \Sigma_K = \Sigma$ ），用一个公共 W 估计。这就是 LDA 的核心假设：等协方差。若各类协方差不同，则需用 QDA。

为什么是比值形式？

若只最大化 $a^\top B a$ （组间方差），问题病态——将 a 放大 10 倍， $a^\top B a$ 放大 100 倍，无上界。因此必须归一化。分母 $a^\top W a$ 是投影后的类内方差，比值 $a^\top B a / a^\top W a$ 就是**信噪比**（组间分离是「信号」，类内散布是「噪声」）。方向缩放时分子分母同比例变化，比值不变——优化良定。

比值形式和约束形式等价：

$$\max_a \frac{a^\top B a}{a^\top W a} \iff \max_a a^\top B a \quad \text{s.t.} \quad a^\top W a = 1.$$

后者将类内方差固定为 1，在此约束下最大化组间方差。

这是一个广义特征值问题，解 a_1 是 $W^{-1}B$ 的最大特征值对应的特征向量。后续方向 $a_2, a_3, \dots$ 在 W -正交约束下依次最大化 Rayleigh 商，对应 $W^{-1}B$ 的次大特征值对应的特征向量。

这些 a_ℓ 称为判别坐标 (discriminant coordinates) 或典型变量 (canonical variates)。

12.7.3 LDA 子空间的计算步骤

- (1) 计算 $K \times p$ 的类质心矩阵 M 和公共类内协方差矩阵 W ；
- (2) 计算 $M^* = MW^{-\frac{1}{2}}$ （利用 W 的特征分解）；
- (3) 计算 M^* 的协方差矩阵 B^* （类间协方差），做特征分解 $B^* = V^* D_B V^{*\top}$ ；
- (4) V^* 的列按特征值从大到小排列，定义了最优子空间的坐标。

结合以上步骤，第 ℓ 个判别变量为：

$$Z_\ell = v_\ell^\top X, \quad v_\ell = W^{-\frac{1}{2}} v_\ell^*.$$

12.7.4 用于分类与降维

降秩子空间不仅可用于数据可视化，还可直接用于分类——只需将距离计算限制在所选子空间内即可。可以证明这等价于附加约束（Gaussian 质心位于 $\mathbb{R}^p$ 的 L 维子空间中）的高斯分类规则。

12.7.5 Fisher 方法与 Gaussian LDA 的等价性

Fisher 的判别坐标 a_ℓ 与 Gaussian LDA 导出的 v_ℓ 完全相同（习题 4.1）。这意味着：

Fisher 判别 $\iff$ Gaussian LDA 的最优子空间

但 Fisher 的推导不依赖 Gaussian 假设，因此其适用范围更广。这里「更广」需精确理解：Fisher 和 Gaussian LDA 给出同一套判别方向，但二者提供的保证层次不同。

	Gaussian LDA	Fisher 判别
给出什么	方向 a_ℓ + 截距/切点（完整分类器）	仅给出方向 a_ℓ
依赖假设	$f_k \sim N(\mu_k, \Sigma)$	无分布假设（仅需均值、协方差存在）
方向最优性	Gaussian 下全体线性分类器中 EPE 最优	对任意分布，在方差比意义下是最优线性判别
切点最优性	Gaussian 下切点最优	不提供切点，需另行确定

关键区别：Fisher 只回答「往哪个方向投影使类间分离相对类内散布最大」——这仅涉及一阶矩和二阶矩，不依赖分布形状（偏态、厚尾、多峰均无妨）。而 Gaussian LDA 额外用 Gaussian 假设确定决策边界的具体位置（切点）。

因此：

- 若数据确实为 Gaussian 且等协方差：LDA 的完整分类器（方向 + 切点）是最优的；
- 若数据非 Gaussian：Fisher 方向仍然有效，但 Gaussian 导出的切点可能次优。此时可保留 Fisher 方向，通过训练集上扫描切点最小化分类误差来另行确定决策边界。

一句话：Fisher 保证方向对（任意分布成立）；Gaussian LDA 额外承诺截距也对（仅 Gaussian 下成立）。

12.7.6 总结

- Gaussian 分类（等协方差）→ 线性决策边界。通过球形化后分类到最近质心（加 $\log \pi_k$ 修正）。
- 只需相对距离 → 数据可限制在球形化空间中质心张成的子空间内。
- 该子空间可进一步分解为 centroid separation 意义上的递进最优子空间，等价于 Fisher 分解。

12.8 几何视角： W^{-1} -内积空间中的 LDA 与 Fisher

前面各节的推导可以统一到一个更深刻的几何框架下：一切操作本质上都是在由 W^{-1} （或 Σ^{-1} ）定义的内积空间中进行的。

12.8.1 W^{-1} -内积空间

以类内散布矩阵 W （对称正定）的逆作为度量矩阵，定义新内积：

$$\langle x, y \rangle_W = x^\top W^{-1} y.$$

(12.30)

W^{-1} 对称正定, 满足内积的三条公理 (对称、双线性、正定性), 因此 $(\mathbb{R}^p, \langle \cdot, \cdot \rangle_W)$ 是合法的内积空间。

导出:

$$\|x\|_W = \sqrt{\langle x, x \rangle_W} = \sqrt{x^\top W^{-1}x}, \quad d_W(x, y) = \|x - y\|_W = \sqrt{(x - y)^\top W^{-1}(x - y)}.$$

d_W 正是马氏距离 (Mahalanobis distance)。

12.8.2 标准内积 vs W^{-1} -内积

同一向量空间 $\mathbb{R}^p$ 上可定义不同内积, 度量不同的「形状」:

	标准欧氏内积 $x^\top y$	W^{-1} -内积 $x^\top W^{-1}y$
单位球形状	球面	椭球面 (贴合数据散布)
正交的含义	直角	马氏意义下的「不相关」
距离	欧氏距离	马氏距离

关键思想: Fisher/LDA 使用 W^{-1} -内积而非标准欧氏内积, 是因为它尊重数据本身的协方差结构——在数据散布大的方向上「距离单位」被压缩, 散布小的方向上被拉伸。这比强加外部标准欧氏几何更合理。

12.8.3 在此框架下重新理解 LDA

LDA 判别函数 (12.22) 用 W -内积改写:

$$\delta_k(x) = \langle x, \mu_k \rangle_W - \frac{1}{2} \|\mu_k\|_W^2 + \log \pi_k.$$

展开 $\|x - \mu_k\|_W^2 = \|x\|_W^2 - 2\langle x, \mu_k \rangle_W + \|\mu_k\|_W^2$, 消去与 k 无关的 $\frac{1}{2}\|x\|_W^2$, 得:

$$\hat{G}(x) = \arg \max_k \delta_k(x) = \arg \min_k \left(\frac{1}{2} \|x - \mu_k\|_W^2 - \log \pi_k \right).$$

LDA = 在 W^{-1} -内积空间中, 用马氏距离分类到最近质心, 以 $\log \pi_k$ 修正。

12.8.4 在此框架下重新理解 Fisher

Fisher 的 Rayleigh 商可写为:

$$R(a) = \frac{a^\top B a}{a^\top W a} = \frac{\text{标准内积下的组间方差}}{\|a\|_W^2}.$$

分子用标准内积度量组间分离, 分母用 W -范数归一化方向长度。做变量替换 $b = W^{1/2}a$, 问题退化为标准特征值问题。

Fisher = 在 W^{-1} -内积几何中寻找使信噪比最大的投影方向, 即 $W^{-1}B$ 的最大特征向量。

12.8.5 球形化的几何意义

球形化变换 $X^* = D^{-1/2}U^\top X$ (其中 $W = UDU^\top$) 等价于将 W^{-1} -内积空间等距映射到标准欧氏空间:

$$\langle x, y \rangle_W = x^\top W^{-1}y = (D^{-1/2}U^\top x)^\top (D^{-1/2}U^\top y) = \langle x^*, y^* \rangle_{\text{std}}.$$

即: 球形化是一次性地将弯曲的 W^{-1} -几何「拉直」为欧氏几何。此后所有操作退化为标准欧氏空间中的最近质心分类。

12.8.6 统一视角总结

概念	标准欧氏空间	W^{-1} -内积空间
内积	$x^\top y$	$x^\top W^{-1}y$
范数	$\ x\ $	$\ x\ _W$ (马氏范数)
距离	欧氏距离	马氏距离
单位球	球面	数据分布形状的椭球面
LDA 分类	—	马氏最近质心 + $\log \pi_k$
Fisher 方向	—	$W^{-1}B$ 的最大特征向量
球形化	—	将 W^{-1} -几何等距拉直为欧氏几何

一句话: LDA 和 Fisher 本质上都是在马氏距离定义的弯曲几何中做线性代数——Fisher 找该几何的「主轴」, LDA 用马氏距离做最近质心分类, 球形化是一次性将该几何拉直。

12.9 Logistic 回归

12.9.1 回到判别函数与 EPE 框架

在 §4.1 引言中建立了分类问题的严格框架: 判别函数 $\delta_k(x) \rightarrow \arg \max \rightarrow \hat{G}(x) \rightarrow$ EPE 最小化 $\rightarrow$ Bayes 分类器 $\arg \max_k P(G = k | X = x)$ 。Logistic 回归是该框架的直接实例化:

框架概念	Logistic 回归中的对应
$\delta_k(x)$	$p_k(x; \theta) = \Pr(G = k X = x; \theta)$, 即参数化后验概率
分类规则	$\hat{G}(x) = \arg \max_k p_k(x; \theta)$ (等价于 Bayes 分类器)
线性条件	不要求 δ_k 线性, 只要求 $\log \frac{p_k}{p_K}$ 是 x 的线性函数 (单调变换后线性)
损失函数	训练用交叉熵 (负对数似然); 最终评估用 0-1 损失
训练方式	最大似然估计 (MLE), 等价于最小化 EPE 的经验近似

与 LDA (§4.3) 的生成式路线不同, Logistic 回归走判别式路线: 直接参数化 $P(G | X)$ 的 log-odds, 跳过对 X 分布的建模。核心假设只有一条——log-odds 是 x 的线性函数。

12.9.2 模型设定

出发点: 我们有什么, 不知道什么

训练时手头只有数据 $\{(x_i, y_i)\}_{i=1}^N$ ($x_i \in \mathbb{R}^p$, $y_i \in \{1, \dots, K\}$), 并不知道真实的 $P(G = k | X = x)$ 。但引言中已证明 Bayes 分类器 $\arg \max_k P(G = k | X = x)$ 是 EPE 的最优解——因此目标不是使用真实后验, 而是用一个参数化模型去逼近它。这与回归中不知道真实 $f(x)$ 却用 $\hat{f}(x) = \hat{\beta}^\top x$ 去逼近的逻辑完全一致。

核心假设: log-odds 是线性的

Logistic 回归不假设 $P(G | X)$ 本身是线性的, 而是假设其 log-odds (logit 变换) 是 x 的线性函数。对 K 类问题:

$$\log \frac{\Pr(G = k | X = x)}{\Pr(G = K | X = x)} = \beta_{k0} + \beta_k^\top x, \quad k = 1, \dots, K-1. \quad (12.31)$$

注意:

- 这是假设, 不是从数据推导出的事实——是我们选择相信这个结构, 然后用数据去验证和拟合;
- 因为只对 $P(G | X)$ 做假设、不对 X 的分布做任何假设, Logistic 回归是判别式方法; 而 LDA 假设了 $X | G$ 的 Gaussian 分布, 是生成式方法。

从 log-odds 到后验概率

以最后一类 K 为参考类 (选择任意, 估计是等变的)。由 (12.31) 解出后验概率:

$$\Pr(G = k | X = x) = \frac{\exp(\beta_{k0} + \beta_k^\top x)}{1 + \sum_{\ell=1}^{K-1} \exp(\beta_{\ell 0} + \beta_\ell^\top x)}, \quad k = 1, \dots, K-1, \quad (12.32)$$

且 $\Pr(G = K | X = x) = 1 / (1 + \sum_{\ell=1}^{K-1} \exp(\beta_{\ell 0} + \beta_\ell^\top x))$ 。记全部参数为 $\theta = \{\beta_{10}, \beta_1, \dots, \beta_{(K-1)0}, \beta_{K-1}\}$, 概率简记为 $p_k(x; \theta) = \Pr(G = k | X = x; \theta)$ 。

当 $K = 2$ 时退化为一对 log-odds, 即 §4.1 中讨论的二分类形式。

训练的本质: 找参数 β

模型结构 (log-odds 线性) 已经定了, 剩下的工作是用数据 $\{(x_i, y_i)\}$ 来估计参数 β :

$$\text{训练} = \arg \min_{\beta} \left(\text{负对数似然} \ell(\beta) \right) = \arg \max_{\beta} \left(\text{观测数据的似然} \right).$$

训练结束后得到 $\hat{\beta}$ ，代入 (12.32) 即可算出任何新 x 的后验概率估计 $\hat{P}(G = k | X = x)$ ，从而分类。具体求解算法 (IRLS) 在下一节详述。

一句话：Logistic 回归 = 假设 log-odds 线性 + 用 MLE 拟合 β ，与线性回归「假设 f 线性 + 用最小二乘拟合 β 」逻辑完全相同。

12.9.3 拟合：最大似然与 IRLS

Logistic 回归通常通过最大化条件似然 $\Pr(G | X)$ 来拟合。由于 $\Pr(G | X)$ 完全指定了条件分布，适用多项分布。 N 个观测的对数似然为：

$$\ell(\theta) = \sum_{i=1}^N \log p_{g_i}(x_i; \theta). \quad (12.33)$$

二分类情形

用 0/1 编码： $y_i = 1$ 当 $g_i = 1$ ， $y_i = 0$ 当 $g_i = 2$ 。记 $p(x; \beta) = p_1(x; \beta)$ ，对数似然写为：

$$\ell(\beta) = \sum_{i=1}^N \left\{ y_i \log p(x_i; \beta) + (1 - y_i) \log(1 - p(x_i; \beta)) \right\} = \sum_{i=1}^N \left\{ y_i \beta^\top x_i - \log(1 + e^{\beta^\top x_i}) \right\}. \quad (12.34)$$

这里 $\beta = (\beta_{10}, \beta_1)$ ， x_i 包含常数项 1。

令导数为零得得分方程：

$$\frac{\partial \ell(\beta)}{\partial \beta} = \sum_{i=1}^N x_i (y_i - p(x_i; \beta)) = 0, \quad (12.35)$$

这是 $p + 1$ 个关于 β 的非线性方程。注意第一分量 ($x_{i1} = 1$) 给出 $\sum_i y_i = \sum_i p(x_i; \beta)$ ——观测类别 1 的数量等于期望类别 1 的数量。

Newton-Raphson 算法

需要 Hessian 矩阵：

$$\frac{\partial^2 \ell(\beta)}{\partial \beta \partial \beta^\top} = - \sum_{i=1}^N x_i x_i^\top p(x_i; \beta) (1 - p(x_i; \beta)). \quad (12.36)$$

Newton 更新为 $\beta^{\text{new}} = \beta^{\text{old}} - (\partial^2 \ell / \partial \beta \partial \beta^\top)^{-1} (\partial \ell / \partial \beta)$ 。

矩阵形式与 IRLS

记 $\mathbf{y}$ 为 y_i 向量， $\mathbf{X}$ 为 $N \times (p + 1)$ 矩阵， $\mathbf{p}$ 为拟合概率向量， $\mathbf{W}$ 为 $N \times N$ 对角权重矩阵（第 i 个对角元为 $p(x_i; \beta^{\text{old}})(1 - p(x_i; \beta^{\text{old}}))$ ）。则：

$$\frac{\partial \ell}{\partial \beta} = \mathbf{X}^\top (\mathbf{y} - \mathbf{p}), \quad \frac{\partial^2 \ell}{\partial \beta \partial \beta^\top} = -\mathbf{X}^\top \mathbf{W} \mathbf{X}.$$

Newton 步可改写为加权最小二乘形式：

$$\beta^{\text{new}} = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{z}, \quad \mathbf{z} = \mathbf{X} \beta^{\text{old}} + \mathbf{W}^{-1}(\mathbf{y} - \mathbf{p}), \quad (12.37)$$

其中 $\mathbf{z}$ 称为调整响应 (adjusted response)。

每次迭代求解加权最小二乘问题 $\beta^{\text{new}} \leftarrow \arg \min_{\beta} (\mathbf{z} - \mathbf{X}\beta)^\top \mathbf{W}(\mathbf{z} - \mathbf{X}\beta)$ 。该算法称为迭代重加权最小二乘 (IRLS)。

注记 12.12. 对数似然是凹函数，算法通常收敛。若罕见情况下似然下降，步长减半可保证收敛。对于多分类 ($K \geq 3$)，Newton 算法也可写为 IRLS 形式，但每观测有一个 $K - 1$ 维响应向量和对角块权重矩阵。实际中可用坐标下降方法（如 R 包 `glmnet`）高效拟合。

12.9.4 示例：南非心脏病数据

表 4.2 展示了对南非心脏病数据的 Logistic 回归拟合结果。该数据来自 CORIS 基线调查，响应变量为心肌梗死 (MI) 的有无（总体患病率 5.1%），包含 160 个病例和 302 个对照。

输出包括每个系数的 Z 得分（系数除以其标准误）。Z 得分不显著（绝对值 < 2 ）的变量可考虑从模型中剔除，对应于 Wald 检验（零假设为该系数为零而其他系数不变）。显著性水平 5% 对应 $|Z| \approx 2$ 。

该例揭示了几个意外：**sbp**（收缩压）不显著，而 **obesity**（肥胖）的系数甚至为负——这并不意味着肥胖对心脏病有保护作用，而是可能被其他变量（如年龄、ldl）所解释（多重共线性效应）。典型分析中需要拟合多个模型来寻找简约且包含交互项的子集。

注记 12.13. Logistic 回归与 LDA 的关键区别：

- LDA 是生成式：假设 $X | G$ 的分布 $\rightarrow$ Bayes 定理 $\rightarrow$ 后验，log-odds 自然为线性（若等协方差）；
- Logistic 回归是判别式：直接假设 log-odds 为线性，不对 X 的分布做任何假设。

这使得 Logistic 回归比 LDA 更一般、更鲁棒（不依赖 Gaussian 假设），但在数据确实近似 Gaussian 且等协方差时效率略低于 LDA。

12.9.5 二次近似与推断

与加权最小二乘的联系

在 IRLS 的收敛点 $\hat{\beta}$ 处，调整响应与拟合值满足精确的加权最小二乘关系：

$$\hat{\beta} = \arg \min_{\beta} (\mathbf{z} - \mathbf{X}\beta)^\top \mathbf{W}(\mathbf{z} - \mathbf{X}\beta), \quad (12.38)$$

其中权重 $w_i = \hat{p}_i(1 - \hat{p}_i)$ 依赖于 $\hat{\beta}$ 本身。这一联系不仅提供了计算上的便利，还有更多统计推断上的价值。

Pearson 卡方与离差

加权残差平方和正是熟悉的 Pearson 卡方统计量：

$$\sum_{i=1}^N \frac{(y_i - \hat{p}_i)^2}{\hat{p}_i(1 - \hat{p}_i)}, \quad (12.39)$$

它是离差 (deviance) 的二次近似。离差定义为模型拟合的对数似然的两倍差值（类比线性回归中的残差平方和）。

渐近理论

若模型设定正确，最大似然估计具有优良的大样本性质：

- **一致性：** $\hat{\beta} \xrightarrow{P} \beta$ （样本量增大时收敛到真值）；
- **渐近正态性：** $\hat{\beta} \sim N(\beta, (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1})$ 。该结果可直接从加权最小二乘的类比导出。

模型选择的快捷方法

Logistic 回归中每个子模型都需迭代拟合，计算开销较大。常用的不需要重新完整迭代的方法：

- **Rao 得分检验 (score test)：** 检验是否可以添加某个变量（基于当前模型的得分函数，无需拟合更大模型）；
- **Wald 检验：** 检验是否可以剔除某个变量（利用当前模型的 $\hat{\beta}$ 和标准误）。

两者均等价于在加权最小二乘中添加/剔除一项（使用相同权重），计算高效。

GLM 框架

R 中广义线性模型 (GLM) 软件将上述联系充分工具化：Logistic 回归作为二项分布族模型处理，GLM 对象可视为线性模型对象，所有线性模型的诊断工具（残差图、杠杆值等）均可自动应用。

几何解释：W-加权内积空间

上述所有操作可以在统一的几何框架下理解。

定义 W-内积： 对 $\mathbf{u}, \mathbf{v} \in \mathbb{R}^N$ ，定义

$$\langle \mathbf{u}, \mathbf{v} \rangle_W = \mathbf{u}^\top \mathbf{W} \mathbf{v} = \sum_{i=1}^N w_i u_i v_i,$$

对应范数 $\|\mathbf{u}\|_W = \sqrt{\langle \mathbf{u}, \mathbf{u} \rangle_W}$ 。这是 $\mathbb{R}^N$ 上的**加权欧氏内积**——每观测按其权重 w_i 被赋予不同重要性。

注意与 LDA 中 W^{-1} -内积的区别：

	LDA/Fisher	IRLS/Logistic
空间	$\mathbb{R}^p$ (特征空间)	$\mathbb{R}^N$ (观测空间)
度量矩阵	Σ^{-1} (固定)	$W = \text{diag}(p_i(1 - p_i))$ (逐轮变化)
含义	马氏距离几何	加权残差几何

IRLS 的几何意义：每次 Newton 迭代等价于求 $\mathbf{z}$ 在 $\mathbf{X}$ 列空间中的 W -正交投影：

$$\mathbf{X}\hat{\beta} = P_W^{\mathbf{X}}\mathbf{z}, \quad \mathbf{X}^\top W(\mathbf{z} - \mathbf{X}\hat{\beta}) = 0.$$

即残差与 $\mathbf{X}$ 的每一列在 W -内积意义下正交。对比普通最小二乘，仅将正交性从「等权重」推广为「 w_i 加权」。

Pearson 卡方的几何意义：残差向量在 W^{-1} -范数下的平方长度，

$$\text{Pearson } \chi^2 = \sum_{i=1}^N \frac{(y_i - \hat{p}_i)^2}{\hat{p}_i(1 - \hat{p}_i)} = (\mathbf{y} - \hat{\mathbf{p}})^\top W^{-1}(\mathbf{y} - \hat{\mathbf{p}}) = \|\mathbf{y} - \hat{\mathbf{p}}\|_{W^{-1}}^2.$$

同一个 W ：正向用于拟合（ W -范数加权 LS），逆向用于检验（ W^{-1} -范数标准化残差）。

这里关键厘清两条线的方向：

- **IRLS 的 W ：** $W = \text{diag}(p_i(1 - p_i)) = \text{diag}(\text{Var}(\hat{Y}_i))$ 。权重就是方差本身——方差大的点（ $\hat{p}_i \approx 0.5$ ，模型不确定）被赋予更高权重，IRLS 重点关注。
- **Pearson 的 W^{-1} ：** $W^{-1} = \text{diag}(1/\text{Var}(\hat{Y}_i))$ 。方差大的点除以大方差 → 容忍更大残差；方差小的点除以小方差 → 微小残差也被放大惩罚。拟合阶段多关注模糊点，检验阶段多挑剔确信点。

W^{-1} -范数与 Pearson 型统计量在其他 GLM 中的推广：上述「残差除以方差」的结构是 GLM 的通用模式。对 $Y_i \sim$ 指数族分布， $\text{Var}(Y_i) = \phi V(\mu_i)$ （ V 为方差函数）。IRLS 的权重 W_{ii} 来自 Hessian，等于 $V(\mu_i)$ （对典型链接）；Pearson 统计量除以 $V(\mu_i)$ ，即使用 W^{-1} 。不同分布下的对应：

分布	$V(\mu)$ (方差函数)	IRLS 权重 W_{ii}	Pearson 分母 = W_{ii}^{-1}
Bernoulli	$\mu(1 - \mu)$	$\mu_i(1 - \mu_i)$	$\mu_i(1 - \mu_i)$ (除以它)
Poisson	μ	μ_i	μ_i
Gaussian	1	1	1 (即普通 RSS)
Gamma	μ^2	μ_i^2	μ_i^2

注意：IRLS 的 W_{ii} 和 Pearson 的分母数值相同（都是 $V(\mu_i)$ ），但作用方向相反——IRLS 乘它（ W -范数），Pearson 除它（ W^{-1} -范数）。

统一形式：

$$\text{Pearson } \chi^2 = \sum_i \frac{(y_i - \hat{\mu}_i)^2}{\text{Var}(\hat{Y}_i)} = \|\mathbf{y} - \hat{\boldsymbol{\mu}}\|_{W^{-1}}^2, \quad W = \text{diag}(\text{Var}(\hat{Y}_i)).$$

核心不变： $W_{ii} = \text{Var}(\hat{Y}_i)$ ——方差大的点 IRLS 重点关注（乘），Pearson 宽容对待（除）。

权重 w_i 的来源： $w_i = p_i(1 - p_i)$ 并非人为设定，而是 Logistic 回归 Hessian 的必然结果。对数似然的 Hessian 为 $\partial^2 \ell / \partial \beta \partial \beta^\top = -\mathbf{X}^\top \mathbf{W} \mathbf{X}$ ，Newton 步重排后自然导出加权 LS 形式。 $p(1 - p)$ 是 Bernoulli 分布的方差——当 $\hat{p}_i \approx 0.5$ （模型不确定）， w_i 最大；当 $\hat{p}_i \approx 0$ 或 1（模型确信）， $w_i \rightarrow 0$ 。IRLS 因此自适应地关注分类边界附近最模糊的样本。

W-加权内积的起源与推广：加权欧氏内积并非 Logistic 回归的专属发明，其思想可追溯至 Gauss (1821) 和 Aitken (1934) 的广义最小二乘 (GLS)——当误差具有异方差性时，按方差的倒数加权修正。Logistic 回归的 IRLS 借用了这一既有数学结构。该方法在统计中广泛应用：

应用场景	w_i 的来源	含义
异方差线性回归	$w_i = 1/\sigma_i^2$	噪声小的观测更可信
加权最小二乘 (WLS)	用户指定	对特定数据点赋予优先拟合
GLM (IRLS)	$w_i = 1/\text{Var}(Y_i) \cdot (\partial \mu_i / \partial \eta_i)^2$	Fisher 信息权重
鲁棒回归	$w_i = \psi(r_i)/r_i$	自动降权离群点
核平滑/局部回归	$w_i = K_h(x - x_i)$	靠近目标点的观测权重大
逆概率加权 (IPW)	$w_i = 1/\text{Pr}(\text{observed})$	因果推断中校正选择偏差

这些方法的共同结构： $\hat{\beta} = \arg \min_{\beta} \|\mathbf{y}_{\text{adj}} - \mathbf{X}\beta\|_W^2$ ，其中 W 可为已知常数、依赖参数的变量、或依赖目标位置的函数。 W -加权内积本质上是「给不同观测赋不同重要性」的数学表达。

12.9.6 L_1 正则化 Logistic 回归

Lasso (§3.4.2) 的 L_1 惩罚可应用于 Logistic 回归，实现变量选择与系数收缩。最大化带惩罚的对数似然：

$$\max_{\beta_0, \beta} \left\{ \sum_{i=1}^N [y_i(\beta_0 + \beta^\top x_i) - \log(1 + e^{\beta_0 + \beta^\top x_i})] - \lambda \sum_{j=1}^p |\beta_j| \right\}. \quad (12.40)$$

求解方法：利用与 Newton 算法相同的二次近似，可通过反复应用加权 Lasso 算法求解。非零系数的得分方程形式为：

$$\mathbf{x}_j^\top (\mathbf{y} - \mathbf{p}) = \lambda \cdot \text{sign}(\beta_j), \quad (12.41)$$

这推广了 §3.4.4 中线性回归 Lasso 的类似方程——活跃变量在「与残差的广义相关性」上被绑定。

系数路径：由于目标函数的非线性，系数路径是分段光滑而非分段线性的。但使用二次近似仍可追踪。R 包 `glmnet` (Friedman et al., 2010) 可高效拟合大规模 (N 大或 p 大) Logistic 回归问题，并支持稀疏矩阵 $\mathbf{X}$ 。详见 §18.4 对 L_1 正则化多项模型的讨论。

12.9.7 Logistic 回归还是 LDA?

形式上的等价

在 Gaussian 且等协方差假设下, LDA 的对数后验比也是 x 的线性函数 (见 (12.21)):

$$\log \frac{\Pr(G = k | X = x)}{\Pr(G = K | X = x)} = \alpha_{k0} + \alpha_k^\top x.$$

Logistic 回归直接假设 log-odds 为线性:

$$\log \frac{\Pr(G = k | X = x)}{\Pr(G = K | X = x)} = \beta_{k0} + \beta_k^\top x.$$

形式上完全一样——但线性系数的估计方式不同。

似然分解视角

将 X 和 G 的联合密度分解为:

$$\Pr(X, G = k) = \underbrace{\Pr(X)}_{\text{边缘密度}} \cdot \underbrace{\Pr(G = k | X)}_{\text{logit-线性}}. \quad (12.42)$$

- **Logistic 回归:** $\Pr(X)$ 完全放任自流——用经验分布 (每观测赋质量 $1/N$) 非参数估计; 只对 $\Pr(G | X)$ 的参数做条件似然最大化。
- **LDA:** 对 $\Pr(X)$ 施加 Gaussian 混合结构:

$$\Pr(X) = \sum_{k=1}^K \pi_k \phi(X; \mu_k, \Sigma),$$

并通过最大化全似然 (包括 $\Pr(X)$ 部分) 来估计参数。

效率与鲁棒性的权衡

LDA 的额外假设 ($\Pr(X)$ 为 Gaussian 混合) 既是优势也是代价:

- **优势——更高效率:** 若真实 $f_k(x)$ 确实是 Gaussian, LDA 利用了更多信息, 参数估计方差更低。Efron (1975) 指出忽略边缘部分最多损失约 30% 的渐近效率——即 Logistic 回归需要多约 30% 数据才能达到相同的误分类率。
- **代价——缺乏鲁棒性:** 远离决策边界的观测点仍然对协方差估计有贡献 $\rightarrow$ LDA 对离群点敏感。此外, 即使没有标签的观测在混合模型中也提供参数信息 (虽然标签昂贵、无标签数据便宜时可利用)。
- **完全分离问题:** 若两类可被超平面完美分离, Logistic 回归的 MLE 无定义 (系数趋于无穷, 习题 4.5); 而 LDA 由于 Gaussian 假设的正则化效应, 系数仍有限。

12.9.8 LDA 和 Logistic 回归总结

	LDA	Logistic 回归
建模方式	生成式： $X G$ 的分布 + Bayes 定理	判别式：直接建模 $P(G X)$
对 X 的假设	$f_k \sim N(\mu_k, \Sigma)$	无任何假设
参数估计	最大化全似然（含 $\Pr(X)$ 部分）	最大化条件似然
效率（Gaussian 成立时）	更高（30% 渐近优势）	略低
鲁棒性	对离群点敏感	更鲁棒
完美分离时	系数有限	MLE 无定义（ $\rightarrow \infty$ ）
参数个数	$(K - 1) \times (p + 1)$	$(K - 1) \times (p + 1)$ （相同）

12.10 分离超平面

LDA 和 Logistic 回归都通过不同方式估计线性决策边界。分离超平面分类器走另一条路：**显式地构造一个尽可能好地分离各类数据的线性边界**。它们是第 12 章支持向量机的基础。

12.10.1 超平面的线性代数

超平面（仿射集）定义为 $\{x \mid f(x) = \beta_0 + \beta^\top x = 0\}$ 。其基本性质：

- (1) 对 L 上任意两点 x_1, x_2 , $\beta^\top (x_1 - x_2) = 0$, 故 $\beta^* = \beta / \|\beta\|$ 是 L 的单位法向量;
- (2) 对 L 上任一点 x_0 , $\beta^\top x_0 = -\beta_0$;
- (3) 任意点 x 到 L 的带符号距离为:

$$\beta^{*\top}(x - x_0) = \frac{1}{\|\beta\|}(\beta^\top x + \beta_0) = \frac{1}{\|f'(x)\|}f(x).$$

(12.43)

即 $f(x)$ 与 x 到超平面的带符号距离成正比。

12.10.2 Rosenblatt 感知机学习算法

感知机（Rosenblatt, 1958）试图通过最小化误分类点到决策边界的距离来寻找分离超平面，奠定了 1980–90 年代神经网络的基础。

动机：一条不断修正的线

感知机的核心思想极其朴素：找一条直线把两堆点分开，分错了就往正确方向挪一挪。用几何直觉来理解：在 $\mathbb{R}^2$ 中有一面墙（超平面），红点在左、蓝点在右。目标是调整墙的角度和位置，使所有点都在正确的一侧。算法流程为：

- (1) 随机初始化一面墙（任意 β, β_0 ）；
- (2) 逐个检查每个点——若发现一个红点跑到了蓝侧（分错），把墙往红点方向推一下；
- (3) 若发现蓝点在红侧，反方向推一下；
- (4) 反复修正，直到没有点被分错。

这与线性回归、LDA、Logistic 回归的哲学截然不同：

方法	动机
线性回归	最小化残差平方和（关心所有点，包括分对的）
LDA	Bayes 最优分类（Gaussian 假设下）
Logistic 回归	最大化似然（概率框架，关注边界附近）
感知机	只关心分错的点——错了就推一把，对了就不动

感知机不问「离边界多远」「概率是多少」——只回答一个二值问题：分对还是分错？这种简单粗暴的风格正是神经网络最早的雏形。

目标函数

设 $y_i \in \{-1, +1\}$ 。若 $y_i = +1$ 被误分类，则 $\beta^\top x_i + \beta_0 < 0$ （反之亦然）。令 $\mathcal{M}$ 为误分类点集，目标为：

$$D(\beta, \beta_0) = - \sum_{i \in \mathcal{M}} y_i (\beta^\top x_i + \beta_0). \quad (12.44)$$

该值非负，与误分类点到决策边界的距离成正比。

随机梯度下降更新

感知机使用**随机梯度下降**——逐个访问误分类点，每次更新（学习率 ρ 可取 1）：

$$\begin{pmatrix} \beta \\ \beta_0 \end{pmatrix} \leftarrow \begin{pmatrix} \beta \\ \beta_0 \end{pmatrix} + \rho \begin{pmatrix} y_i x_i \\ y_i \end{pmatrix}. \quad (12.45)$$

收敛性与问题

若类别线性可分，算法在有限步内收敛到某个分离超平面（习题 4.6）。但存在若干问题（Ripley, 1996）：

- **解不唯一**：分离超平面有无穷多个，哪个被找到取决于初值；
- **收敛可能极慢**：间隔（margin）越小，收敛越慢；
- **数据不可分时发散**：算法不收敛且产生周期振荡，可能难以检测。

图 4.14 展示了两类的玩具数据：最小二乘线（等价于 LDA）误分一个点，而两条蓝色感知机线（不同随机初值）均完美分离。

12.10.3 最优分离超平面

感知机有多解的问题可通过对分离超平面施加额外约束来解决。最优分离超平面 (Vapnik, 1996) 分离两类且最大化到最近点的距离——不仅给出唯一解, 通过最大化训练数据上的间隔 (margin) 还能改善泛化性能。

优化问题的建立

设 $y_i \in \{-1, +1\}$ 。最大化间隔的优化问题:

$$\max_{\beta, \beta_0, \|\beta\|=1} M \quad \text{s.t.} \quad y_i(\beta^\top x_i + \beta_0) \geq M, \quad i = 1, \dots, N.$$

消去 $\|\beta\| = 1$ 约束 (用 $\frac{1}{\|\beta\|}y_i(\beta^\top x_i + \beta_0) \geq M$ 替换), 并注意到对任意满足不等式的 (β, β_0) , 正缩放倍数仍满足, 可设 $\|\beta\| = 1/M$, 得到等价凸优化问题:

$$\min_{\beta, \beta_0} \frac{1}{2} \|\beta\|^2 \quad \text{s.t.} \quad y_i(\beta^\top x_i + \beta_0) \geq 1, \quad i = 1, \dots, N. \quad (12.46)$$

几何解释

约束定义了一个围绕决策边界的空「平板」(slab), 厚度为 $1/\|\beta\|$ 。最小化 $\|\beta\|^2$ 即最大化该厚度——在线性可分约束下尽可能扩大 margin。

Lagrange 对偶推导

引入 Lagrange 乘子 $\alpha_i \geq 0$, Lagrange 原始函数为:

$$L_P = \frac{1}{2} \|\beta\|^2 - \sum_{i=1}^N \alpha_i [y_i(\beta^\top x_i + \beta_0) - 1]. \quad (12.47)$$

令导数为零:

$$\beta = \sum_{i=1}^N \alpha_i y_i x_i, \quad 0 = \sum_{i=1}^N \alpha_i y_i. \quad (12.48)$$

代入 L_P 消去 β 和 β_0 , 得 Wolfe 对偶:

$$L_D = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{k=1}^N \alpha_i \alpha_k y_i y_k x_i^\top x_k \quad \text{s.t.} \quad \alpha_i \geq 0, \quad \sum_{i=1}^N \alpha_i y_i = 0. \quad (12.49)$$

这是在正象限中的更简单的凸优化问题, 可用标准软件求解。

KKT 条件与支持向量

Karush-Kuhn-Tucker 条件要求:

$$\alpha_i [y_i(\beta^\top x_i + \beta_0) - 1] = 0, \quad \forall i. \quad (12.50)$$

由此得到关键性质:

- 若 $\alpha_i > 0$, 则 $y_i(\beta^\top x_i + \beta_0) = 1$ ——该点恰好落在 margin 边界上, 称为**支持向量 (support point)**;
- 若 $y_i(\beta^\top x_i + \beta_0) > 1$, 则该点在 margin 外部, $\alpha_i = 0$ 。

由 (12.48), 解向量 β 是支持向量的线性组合:

$$\beta = \sum_{i:\alpha_i>0} \alpha_i y_i x_i.$$

即只有支持向量对决定超平面有贡献——移动非支持向量不改变解。 β_0 可由任一支持向量的 (12.50) 解出。

分类函数

最优分离超平面产生的分类函数为:

$$\hat{f}(x) = x^\top \hat{\beta} + \hat{\beta}_0, \quad \hat{G}(x) = \text{sign } \hat{f}(x). \quad (12.51)$$

训练数据全部落在 margin 之外 (由构造保证), 但测试数据则不一定。

与 LDA 和 Logistic 回归的对比

图 4.16 展示了同一玩具数据上三种方法的决策边界:

- **最优分离超平面** (蓝色线): 三个支持向量 (落在 margin 边界上的点) 完全决定了它。直觉上, 它更关注「关键点」, 对模型误设更鲁棒。
- **Logistic 回归** (红色线): 与最优分离超平面非常接近 (参见 §12.3.3 的详细讨论)。当分离超平面存在时, Logistic 回归总能找到它 (似然可驱动至 0, 习题 4.5)。其系数由加权 LS 确定, 靠近决策边界的点权重较大。
- **LDA**: 依赖**所有**数据, 包括远离决策边界的点。若各类确为 Gaussian, LDA 最优; 而分离超平面因聚焦于边界附近 (噪声更大的) 数据, 会付出一定代价。

支持向量的识别需使用全部数据——这不是无成本的稀疏性。

不可分情况的推广


当数据线性不可分时, (12.46) 无可行解。此时可:

- 通过基展开将数据映射到高维空间 (但可能导致过拟合下的伪分离);
- 允许重叠并最小化重叠程度——即第 12 章的**支持向量机 (SVM)**, 引入松弛变量实现软间隔。

注记 12.14. 本章参考文献包括 Duda et al. (2000)、Ripley (1996)、Vapnik (1996) 等。习题 4.1 证明 Fisher 特征值问题与标准特征值问题的等价性; 习题 4.2 证明二分类下 LDA 方向与最小二乘系数成比例 ($\hat{\beta} \propto \hat{\Sigma}^{-1}(\hat{\mu}_2 - \hat{\mu}_1)$)。

12.11 本章小结

下图总结了本章各类线性分类方法的逻辑关系与统一框架：



第十三章 基展开与正则化

13.1 引言

到目前为止，我们使用的模型——线性回归、LDA、Logistic 回归、分离超平面——全部依赖**线性模型**。但真实的 $f(X) = \mathbb{E}[Y | X]$ 几乎不可能恰好是 X 的线性函数。线性模型只是一种便利的、有时是必须的近似：便利是因为易于解释且是 $f(X)$ 的一阶 Taylor 近似；必须是因为当 N 小或 p 大时，线性模型可能是我们唯一能拟合而不至于过拟合的模型。

本章讨论突破线性局限的核心方法。

13.1.1 两种突破线性的思路：参数化 vs 非参数化

面对「 $f(X)$ 不是线性的」这个问题，存在两条建模路线：

参数化路线（变换—验证）：用领域知识或探索性分析猜测一个具体的变换形式—— $h(X) = \log X, \sqrt{X}, X^2, \dots$ ——然后在新变量上做线性拟合。例如，若猜测血压与剂量的对数成正比，则拟合 $BP = \beta_0 + \beta_1 \log(\text{dose})$ 。这种做法的优势在于解释性强、参数量少（低方差），但风险是：一旦猜错了 h 的形式，模型就是错的（高偏差）。

非参数化路线（基展开—让数据说话）：不对 f 的形状做具体假设，而是用一组足够丰富的基函数 $\{h_m(X)\}$ 的线性组合去自适应逼近。样条、核方法、小波、神经网络均属此类。优势在于灵活——几乎任何光滑函数都能被逼近；代价是使用了更多参数（高方差风险），需要复杂度控制（本章核心主题）。

实践中二者并非互斥。在低维问题中，现代做法（如广义可加模型 GAM）倾向于对每个变量单独使用非参数光滑（如样条），同时保持可加结构 $\sum_j f_j(X_j)$ ——相当于「结构参数化、形状非参数化」的折中方案。本章重点介绍非参数化路线中的基展开与正则化方法。

13.1.2 核心思想：变换输入空间

用 X 的变换 $h_m(X) : \mathbb{R}^p \rightarrow \mathbb{R}$ ($m = 1, \dots, M$) 替代或增广原始输入，然后在这些派生特征的新空间中继续使用线性模型：

$$f(X) = \sum_{m=1}^M \beta_m h_m(X). \quad (13.1)$$

关键在于：一旦基函数 h_m 确定，模型对新变量仍是线性的，所有之前的拟合方法（最小二乘、MLE 等）照常使用。

13.1.3 常见基函数示例

- 恒等变换： $h_m(X) = X_m$ ($m = 1, \dots, p$)，还原为原始线性模型。
- 多项式： $h_m(X) = X_j^2$ 或 $X_j X_k$ ，实现高阶 Taylor 展开。注意：变量数随阶数指数增长—— p 个变量的 d 次多项式需要 $O(p^d)$ 个项。
- 非线性变换： $h_m(X) = \log(X_j), \sqrt{X_j}, \dots$ ，也可使用涉及多个输入的变换如 $\|X\|$ 。
- 指示函数（分箱）： $h_m(X) = I(L_m \leq X_k < U_m)$ ，将 X_k 划分为区间，得到分段常数模型。

13.1.4 复杂度的控制

基展开产生一个字典 $\mathcal{D}$ ，通常包含大量基函数——远超我们负担得起的数量。控制模型复杂度的方法分为三类：

- 限制法：限定每个分量函数使用的基函数数量 M_j ；
- 选择法：自适应扫描字典，仅包含对拟合有显著贡献的基函数（CART、MARS、boosting 走这条路）；
- 正则化法：使用整个字典但限制系数（Ridge、Lasso 属于此类）。

Q：基展开到底是一种什么方法？是给出很多基函数的通用方法吗？

基展开不是一种具体的“生成基”的方法，而是一种建模框架/范式：把原始输入 X 通过基函数 $h_m(X)$ 变换到派生特征空间，然后在这个新空间里用线性模型 $\sum \beta_m h_m(X)$ 去拟合。之所以叫“展开”（expansion），是因为把原本只有 p 维的输入空间“撑开”成一个更大的 M 维空间——在这个高维空间里，原本非线性的关系变得（近似）线性了。

类比线性代数：一组基向量通过线性组合可以张成向量空间；这里一组基函数通过线性组合可以逼近很宽泛的一类函数。基展开本身只是一个容器——它统一了

后面几乎所有非参数方法的视角：样条是手工设计基函数 + 限制数量，平滑样条是每个点放一个基 + 正则化，CART/MARS 是自适应选择基，boosting 是自适应学习基。

Q：为什么说字典 $\mathcal{D}$ 通常包含大量基函数——远超负担得起的数量？

这是刻意为之的：字典必须足够大才能灵活逼近任意的 $f(X)$ ，否则能表示的函数类太窄。例如多项式基中 p 个变量 d 次就有 $O(p^d)$ 个项，样条网格上有 K^p 个项，核基可以在每个训练点放一个。但数据量 N 是有限的—— $M \gg N$ 时全用上必然过拟合，这就是“远超负担得起”的含义（“负担”指在有限数据下稳定拟合的能力）。所以整章的逻辑链是：要灵活 $\rightarrow$ 字典必须大 $\rightarrow$ 但数据有限 $\rightarrow$ 需要复杂度控制（限制/选择/正则化）。字典大不是失误，而是这个框架要解决的核心张力。

13.2 分段多项式与样条

本节假设 X 为一维（至 §5.7 放宽）。分段多项式通过将 X 的定义域划分为连续区间、在每个区间内用单独的多项式表示 f 来构造。

13.2.1 分段常数与分段线性

分段常数：三个基函数

$$h_1(X) = I(X < \xi_1), \quad h_2(X) = I(\xi_1 \leq X < \xi_2), \quad h_3(X) = I(\xi_2 \leq X),$$

最小二乘估计 $\hat{\beta}_m = \bar{Y}_m$ （第 m 区间的 Y 均值）。

分段线性：需要额外三个基函数 $h_{m+3} = h_m(X)X$ ($m = 1, 2, 3$)，共 6 个参数。但通常我们希望函数在节点 ξ_1, ξ_2 处连续——连续性约束 $f(\xi_1^-) = f(\xi_1^+)$ 和 $f(\xi_2^-) = f(\xi_2^+)$ 各消耗一个自由度，剩下 4 个自由参数。

13.2.2 截断幂基

更直接的方式是使用内建了连续性约束的基函数：

$$h_1(X) = 1, \quad h_2(X) = X, \quad h_3(X) = (X - \xi_1)_+, \quad h_4(X) = (X - \xi_2)_+,$$

其中 $(X - \xi)_+ = \max(0, X - \xi)$ 为截断幂函数。

截断幂函数的直观： $(X - \xi)_+$ 在 ξ 之前恒为 0（「关着」），在 ξ 之后是一条斜率为 1 的直线（「打开」）。在 ξ 处值为 0，故连续但导数不连续（有个「折角」）。用截断幂函数构造分段线性模型的逻辑为：

$$f(X) = \beta_0 + \beta_1 X + \beta_2 (X - \xi_1)_+ + \beta_3 (X - \xi_2)_+.$$




FIGURE 5.1. The top left panel shows a piecewise constant function fit to some artificial data. The broken vertical lines indicate the positions of the two knots ξ_1 and ξ_2 . The blue curve represents the true function, from which the data were generated with Gaussian noise. The remaining two panels show piecewise linear functions fit to the same data—the top right unrestricted, and the lower left restricted to be continuous at the knots. The lower right panel shows a piecewise-linear basis function, $h_3(X) = (X - \xi_1)_+$, continuous at ξ_1 . The black points indicate the sample evaluations $h_3(x_i)$, $i = 1, \dots, N$.

图 13.1: 分段多项式拟合人造数据。左上: 分段常数 (三个区间各自的均值); 右上: 无约束分段线性; 左下: 节点处连续的分段线性; 右下: 截断幂基函数 $h_3(X) = (X - \xi_1)_+$ (在 ξ_1 之前为 0, 之后线性增长)。来源: ESL Figure 5.1。

- $X < \xi_1$: 只有 $\beta_0 + \beta_1 X$ (一条直线);
- $\xi_1 \leq X < \xi_2$: $(X - \xi_1)_+$ 打开 $\rightarrow$ 斜率从 β_1 变为 $\beta_1 + \beta_2$ (拐弯了);
- $X \geq \xi_2$: $(X - \xi_2)_+$ 也打开 $\rightarrow$ 斜率再变一次。

每个截断幂函数在对应节点处添加一个「拐弯」, 不影响节点左侧, 只改变右侧行为。这比显式施加连续性约束更加自然。

更高次幂的推广: $(X - \xi)_+^2$ 在节点处有一阶连续导数 (光滑拐弯), $(X - \xi)_+^3$ 在节点处有二阶连续导数 (人眼无法察觉拐弯)。

注记 13.1. 有人可能会问: 为什么 $(X - \xi_1)_+$ 在第二、第三区间都开着, 而不设计成只在 $[\xi_1, \xi_2)$ 上非零? 答案是为了**保证连续性**——如果在 ξ_2 处强行把它关掉 (变为 0), 函数值会突然跳变, 破坏连续性。截断幂基的「全局影响」是换取系数可解释性的代价 (β_j 直接对应「第 j 个节点处的斜率变化量」)。若需要只在局部非零的基函数, 可用 **B-样条 (B-splines)**——每个 B-样条基函数只在有限几个区间上非零 (局部支撑), 数值更稳定, 但系数不再有截断幂基那样的直观解释。

13.2.3 三次样条 (Cubic Spline)

分段三次多项式, 在节点处具有连续的一阶和二阶导数 ($M = 4$ 阶样条)。可视作:

阶数	连续性	名称
$M = 1$	无连续要求	分段常数
$M = 2$	连续, 导数不连续	线性样条 (连续分段线性)
$M = 4$	二阶导数连续	三次样条

对于节点 ξ_1, ξ_2 , 三次样条的一个基础表示 (截断幂基):

$$\begin{aligned} h_1(X) &= 1, & h_2(X) &= X, & h_3(X) &= X^2, \\ h_4(X) &= X^3, & h_5(X) &= (X - \xi_1)_+^3, & h_6(X) &= (X - \xi_2)_+^3. \end{aligned} \quad (13.2)$$

共 6 个基函数对应 6 维线性函数空间。参数计数验证: 3 个区域 $\times$ 每区域 4 参数 $-$ 2 个节点 $\times$ 每节点 3 个约束 $= 6$ 。

13.2.4 一般阶样条

M (阶数) 的含义: $M = \text{次数} + 1$, 即每个区间内多项式的参数个数。

M	次数	名称	连续性
1	0 次 (常数)	分段常数	无
2	1 次 (线性)	线性样条	f 连续
3	2 次 (二次)	二次样条	f, f' 连续
4	3 次 (三次)	三次样条	f, f', f'' 连续




FIGURE 5.2. A series of piecewise-cubic polynomials, with increasing orders of continuity.

图 13.2: 分段三次多项式, 节点处连续性递增。左上: 不连续; 右上: 连续但导数不连续; 左下: 一阶导数连续; 右下: 一阶和二阶导数均连续 (三次样条)。再额外施加一阶连续性将退化为全局三次多项式。来源: ESL Figure 5.2。

M 阶样条是 M 阶分段多项式，且在节点处有直到 $M - 2$ 阶的连续导数。带 K 个节点 ξ_j 的截断幂基一般形式为：

$$\begin{aligned} h_j(X) &= X^{j-1}, \quad j = 1, \dots, M, \\ h_{M+\ell}(X) &= (X - \xi_\ell)_+^{M-1}, \quad \ell = 1, \dots, K. \end{aligned} \quad (13.3)$$

即 M 个全局多项式基函数 + K 个节点处的截断幂基函数，共 $M + K$ 个。

自由度的计算：

$$\boxed{\text{df} = M + K.}$$

推导：($K + 1$) 个区间 $\times$ 每区间 M 个系数 $- K$ 个节点 $\times$ 每节点 $M - 1$ 个连续性约束
 $= M(K + 1) - K(M - 1) = M + K$ 。

具体示例：

样条类型	M	节点数 K	df
分段常数	1	2	3
线性样条	2	2	4
三次样条	4	2	6
自然三次样条	4	K	K ($4 + K$ 减去边界 4 个约束)

在 R 中，`bs(x, df=7)` 的内部逻辑：三次样条 $M = 4$ ，故内节点数 $= 7 - 4 = 3$ （加 3 个边界节点共 6 个节点），放于适当的分位数处。

实践中最常用的阶数： $M = 1, 2, 4$ 。三次样条是最低阶的「人眼看不见节点处不连续」的样条——极少有理由使用更高阶。

注记 13.2. 截断幂基在概念上简单，但数值上不稳健——大数的幂会导致严重舍入误差。实际计算中普遍使用 **B-样条基**（见本章附录），它具有更好的数值稳定性且计算高效。

13.2.5 节点选择

R 中的实现

ESL 全书使用统计编程语言 R 做代码示例。`bs(x, df=7)` 是 R 的 `splines` 包中的函数：输入向量 x ，输出 $N \times 7$ 的 B-样条基矩阵。Python 中类似功能由 `scipy.interpolate.BSpline` 或 `patsy.dmatrix` 提供。

内部逻辑：三次样条 $M = 4$ ，故 $\text{df}=7 \rightarrow$ 内节点数 $= 7 - 4 = 3$ ，自动放置在 x 的 25%, 50%, 75% 分位数处（加上边界节点构成完整节点集）。

实践中节点位置怎么选？

标准做法——不看节点位置，只选 df。实践中几乎不手动指定节点位置，而是通过交叉验证选择 df（自由度 复杂度），让函数自动放置节点：

df	模型含义
1	常数（仅截距）
2	直线（截距 + 斜率）
4	很光滑的非线性
7	中等弯曲
12	相当灵活

df 越大 → 节点越多 → 模型越灵活 → 偏差 ↓、方差 ↑。通过 K 折交叉验证选择使测试误差最小的 df。

默认分位数放置的启发式原理：R 将节点放在 x 的均匀分位数处（而不是等间距）。直觉是——数据密集的地方需要更多灵活性来捕捉信号，数据稀疏的地方不宜浪费自由度拟合噪声。这并非数学最优（本节末尾讨论），但在绝大多数实际问题中足够好用。

特定场景的调整：

- 有领域知识时：在已知的物理拐点（如材料相变温度、药物半衰期）处手动放置节点；
- 自然样条：边界外线性约束 → 边界节点靠近数据极值，内部节点均匀分位数；
- 周期性数据：改用周期样条基（Fourier 基或周期 B-样条）。

分位数放置是最优的吗？

不是。最优节点选择是组合优化问题——从 N 个数据点中选 K 个节点有 $\binom{N}{K}$ 种可能，NP-hard。

分位数放置只是一个统计上稳健的启发式，原理是「在数据多的地方多放节点」。真正试图优化节点位置的方法：

- **MARS (§9.4)：**贪心添加 + 剪枝，自适应搜索节点位置；
- **穷举/贪心搜索：**计算量过大， $K > 3$ 时不可行。

实践结论：没人手动调节点位置。标准做法是用 $bs(x, df=k)$ ， k 由 CV 决定，分位数自动放置节点。这套组合虽非数学最优，但在偏差-方差权衡下统计上稳健。真正花精力搜索最优节点的方法反而不如大量节点 + 惩罚（光滑样条，§5.4）实用。

13.2.6 自然三次样条

标准三次样条在边界区域方差爆增（图 5.3）。自然三次样条添加额外约束：函数在边界节点之外是线性的。这释放了 4 个自由度（两个边界区域各两个约束），可重新分配到内部区域增加节点。

带 K 个节点的自然三次样条由 K 个基函数表示。从截断幂基出发施加边界约束，可得基函数（习题 5.4）：

$$N_1(X) = 1, \quad N_2(X) = X, \quad N_{k+2}(X) = d_k(X) - d_{K-1}(X), \quad (13.4)$$

其中

$$d_k(X) = \frac{(X - \xi_k)_+^3 - (X - \xi_K)_+^3}{\xi_K - \xi_k}.$$

每个基函数在 $X \geq \xi_K$ 处二阶和三阶导数均为零。

权衡：边界附近偏差略有增加（假设函数在边界处近似线性通常是合理的），但方差大幅降低。

为什么边界外是线性的？

这里的「边界」指最外层节点 ξ_1 和 ξ_K ，而非数据的最值点。自然样条的线性约束作用于两个区域： $X < \xi_1$ （最左节点以左）和 $X > \xi_K$ （最右节点以右）。

左侧边界外（ $X < \xi_1$ ）。此时对所有 $j = 1, \dots, K$ ， $(X - \xi_j)_+ = 0$ （截断幂函数尚未「打开」），故 $d_k(X) = 0$ 。于是 $N_{k+2}(X) = 0 - 0 = 0$ ，只剩下 $N_1(X) = 1$ 和 $N_2(X) = X$ ：

$$f(X) = \beta_1 \cdot 1 + \beta_2 \cdot X = \beta_1 + \beta_2 X,$$

是严格的线性函数。

右侧边界外（ $X > \xi_K$ ）。此时所有截断都开着， $(X - \xi_j)_+ = X - \xi_j$ 。代入 $d_k(X)$ ：

$$\begin{aligned} d_k(X) &= \frac{(X - \xi_k)^3 - (X - \xi_K)^3}{\xi_K - \xi_k} = \frac{1}{\xi_K - \xi_k} \left[(X^3 - 3X^2\xi_k + 3X\xi_k^2 - \xi_k^3) \right. \\ &\quad \left. - (X^3 - 3X^2\xi_K + 3X\xi_K^2 - \xi_K^3) \right] \\ &= \frac{1}{\xi_K - \xi_k} \left[3X^2(\xi_K - \xi_k) - 3X(\xi_K^2 - \xi_k^2) + (\xi_K^3 - \xi_k^3) \right] \\ &= 3X^2 - 3X(\xi_K + \xi_k) + (\xi_K^2 + \xi_K\xi_k + \xi_k^2). \end{aligned}$$

可见 $d_k(X)$ 在 $X > \xi_K$ 时是 X 的二次函数，且 X^2 的系数始终为 3，与 k 无关。

现在考虑 $N_{k+2}(X) = d_k(X) - d_{K-1}(X)$ 。因为 d_k 和 d_{K-1} 的 X^2 系数都是 3，相减时恰好消掉：

$$\begin{aligned} N_{k+2}(X) &= [3X^2 - 3X(\xi_K + \xi_k) + \dots] - [3X^2 - 3X(\xi_K + \xi_{K-1}) + \dots] \\ &= 3X(\xi_{K-1} - \xi_k) + \text{常数}, \end{aligned}$$

剩下的是 X 的一次函数（线性）。加上 $N_1 = 1$ （常数）和 $N_2 = X$ （线性），所有基函数在 $X > \xi_K$ 时都是线性的，因此 $f(X) = \sum \beta_m N_m(X)$ 也是线性的，且二阶、三阶导数均为零。

一句话总结：线性外推不是拟合后施加的额外约束，而是基函数本身内建性质—— $d_k - d_{K-1}$ 的设计故意消掉了 X^3 和 X^2 项。

基函数构造示例（ $K = 5$ ）

以 $\xi = [0, 1, 2, 3, 4]$ （ $K = 5$ ）为例，逐步构造 $N_1, \dots, N_5$ 。

Step 1——前两个基函数始终不变：

$$N_1(X) = 1, \quad N_2(X) = X.$$

Step 2——计算 $d_k(X)$ ， $k = 1, 2, 3, 4$ （分母用 $\xi_K = \xi_5 = 4$ ）：

$$\begin{aligned} d_1(X) &= \frac{(X-0)_+^3 - (X-4)_+^3}{4-0} = \frac{(X)_+^3 - (X-4)_+^3}{4}, \\ d_2(X) &= \frac{(X-1)_+^3 - (X-4)_+^3}{4-1} = \frac{(X-1)_+^3 - (X-4)_+^3}{3}, \\ d_3(X) &= \frac{(X-2)_+^3 - (X-4)_+^3}{4-2} = \frac{(X-2)_+^3 - (X-4)_+^3}{2}, \\ d_4(X) &= \frac{(X-3)_+^3 - (X-4)_+^3}{4-3} = (X-3)_+^3 - (X-4)_+^3. \end{aligned}$$

Step 3——以 $d_{K-1} = d_4$ 为基准，构造 N_3, N_4, N_5 ：

$$N_3(X) = d_1(X) - d_4(X), \quad N_4(X) = d_2(X) - d_4(X), \quad N_5(X) = d_3(X) - d_4(X).$$

直观理解： d_4 充当「基准函数」，每个 N_{k+2} 是「第 k 个节点的贡献减去基准贡献」。这个减法有两个目的：(i) 保证边界外的线性性（消去高阶项）；(ii) 使得基函数之间在节点密度和位置变化时保持数值稳定性。在实践中， d_{K-1} 的选择并非唯一——任何 d_j 都可以充当基准，但 ESL 选择 d_{K-1} 是约定俗成。

验证：取 $X = 5, 6, 7$ （均在 $\xi_5 = 4$ 右侧），计算 N_3 的一阶差分——若为常数则 N_3 是线性的：

$$\begin{aligned} N_3(5) &= d_1(5) - d_4(5), \quad N_3(6) = d_1(6) - d_4(6), \quad N_3(7) = d_1(7) - d_4(7), \\ \implies N_3(6) - N_3(5) &= N_3(7) - N_3(6). \quad (\text{一阶差分为常数} \rightarrow \text{线性无误}) \end{aligned}$$

13.2.7 样条方法概览

在进入具体实例之前，对目前以及后续出现的样条方法做一个系统总结：

类型	节点	复杂度控制	特点
回归样条 (§5.2)	手动选 K 个内节点	$df = M + K$	最基础
自然样条 (§5.2.1)	同上 + 边界线性约束	$df = K$	降边界方差, 最常用
B-样条 (附录)	同回归样条	同回归样条	局部支撑, 数值稳定
周期样条	同上 + 循环边界	同上	周期性数据
光滑样条 (§5.4)	每个 x_i 都是节点	λ 惩罚 $\int (f'')^2$	免选节点, λ 由 CV 定
惩罚样条 (P-splines)	均匀密节点 + 差分惩罚	λ 惩罚系数差	更高效, 现代 GAM 主流
薄板样条 (§5.7)	多维推广	λ 惩罚曲率	多维光滑样条
张量积样条	多维交互	基数 = 各维基数的乘积	建模联合非线性
MARS (§9.4)	自适应选择	贪心 + 剪枝	自动找交互和节点

本章重点介绍回归样条 (§5.2)、自然样条 (§5.2.1) 和光滑样条 (§5.4), 后续各章将逐步展开其余方法。读者可随时回查此表以保持方向感。

13.2.8 示例：南非心脏病数据（续）

问题设定

将 §4.4.2 的南非心脏病回顾性调查重新考察。数据概要：

- **响应 Y ：**二分类——是否患有心肌梗死 (MI/chd), $Y = 1$ (患病/病例), $Y = 0$ (未患病/对照);
- **特征 X ：**7 个风险因子——sbp (收缩压)、tobacco (累计烟龄, kg)、ldl (坏胆固醇)、famhist (家族史: 有/无)、obesity (肥胖指数)、alcohol (饮酒量)、age (年龄);
- **样本量：** $N = 462$ (160 病例 + 302 对照)。

第一步：线性 Logistic 回归 → 确定谁不显著

先用线性 Logistic 回归 (§4.4.2, 表 4.2) 拟合并做 Wald 检验。Z 得分 = $\hat{\beta}_j / \text{SE}(\hat{\beta}_j)$ (系数除以其标准误), $|Z| > 2 \approx p < 0.05$ 表示显著。结果：

变量	$\hat{\beta}$	SE	Z
sbp	0.006	0.006	1.02 不显著
tobacco	0.080	0.026	3.03 显著
ldl	0.185	0.057	3.22 显著
famhist	0.939	0.225	4.18 显著
obesity	-0.035	0.029	-1.19 不显著
age	0.043	0.010	4.18 显著

在线性模型中, **sbp** 和 **obesity** 被判为「没有用」——会被剔除。但直觉上血压和肥胖应该与心脏病相关——可能线性假设太强了。

第二步：改用自然样条 → 允许非线性效应

对每个连续变量 X_j , 用 4 个自然样条基函数（对应 3 个内节点放在 X_j 的均匀分位数处）替代原始 X_j :

$$\text{logit}[\text{Pr}(\text{chd} \mid X)] = \theta_0 + h_1(X_1)^\top \theta_1 + \cdots + h_p(X_p)^\top \theta_p, \quad (13.5)$$

其中每个 $h_j(X_j)$ 是 X_j 处 4 个自然样条基函数的取值向量, θ_j 是 4 维系数向量。二值因子 **famhist** 仍用哑变量编码（1 个参数）。

关键区别：线性模型中 **sbp** 的效应是 $\beta_{\text{sbp}} \times \text{sbp}$ （一条直线，一个系数）；样条模型中 **sbp** 的效应是 $f_{\text{sbp}}(\text{sbp}) = h(\text{sbp})^\top \theta_{\text{sbp}}$ （一条曲线，4 个系数共同决定形状）。图 5.4 中每个面板画的正是 $\hat{f}_j(X_j)$ ——第 j 个变量对 log-odds 的（非线性的）估计贡献函数。

$f_j(X_j)$ 的计算方式：将所有 p 组基函数（加常数项）合并为大向量 $h(X)$, 总参数 $\text{df} = 1 + \sum_j \text{df}_j$ 。评在 N 个样本上得 $N \times \text{df}$ 基矩阵 **H**, 用 §4.4.1 的 IRLS 算法拟合 Logistic 回归得 $\hat{\theta}$, 然后 f_j 在任意 X_j 处的值由 $h_j(X_j)^\top \hat{\theta}_j$ 计算。

第三步：模型选择与最终结果

执行向后逐步删除，保留项的组结构（一次删除整组基函数而非单个系数），用 AIC 统计量（§7.5）决定。最终模型见 Figure 5.4 和 Table 5.1。

Figure 5.4 读法：六个面板，每个对应一个变量。

- **实线** = $\hat{f}_j(X_j)$ ——该变量对 log-odds 的非线性估计效应。弯曲 = 非线性，平直 = 线性够用；
- **虚线带** = ± 2 标准误的逐点置信带——带越宽，估计越不确定（数据稀疏处自然宽）；
- **底部 rug plot** = 每个刻度是一个样本在该变量上的取值——刻度密 → 数据多 → 曲线可信；
- **famhist 面板：**二值变量，显示为两个点 + 误差棒（有/无家族史 增加约 0.5 个 log-odds 单位的风险）。

Table 5.1 读法（以 sbp 行为例）：

Terms	Df	Deviance	AIC	LRT	P-value
none（全模型）	—	458.09	502.09	—	—
sbp（删除后）	4	467.16	503.16	9.076	0.059




FIGURE 5.4. Fitted natural-spline functions for each of the terms in the final model selected by the stepwise procedure. Included are pointwise standard-error bands. The rug plot at the base of each figure indicates the location of each of the sample values for that variable (jittered to break ties).

图 13.3: 最终模型中各变量的拟合自然样条函数。实线: $\hat{f}_j(X_j)$; 虚线带: ± 2 标准误差的逐点置信带; 底部 rug plot: 每个刻度对应一个样本在该变量上的取值 (抖动防重叠)。famhist 为二值变量, 显示为两个点 + 误差棒。来源: ESL Figure 5.4。

TABLE 5.1. Final logistic regression model, after stepwise deletion of natural splines terms. The column labeled “LRT” is the likelihood-ratio test statistic when that term is deleted from the model, and is the change in deviance from the full model (labeled “none”).

Terms	Df	Deviance	AIC	LRT	P-value
none		458.09	502.09		
sbp	4	467.16	503.16	9.076	0.059
tobacco	4	470.48	506.48	12.387	0.015
ldl	4	472.39	508.39	14.307	0.006
famhist	1	479.44	521.44	21.356	0.000
obesity	4	466.24	502.24	8.147	0.086
age	4	481.86	517.86	23.768	0.000

图 13.4: 逐步删除自然样条项后的最终 Logistic 回归模型。Terms: 变量名 (none= 全模型); Df: 该变量占用自由度; Deviance: 离差; AIC: 赤池信息准则; LRT: 似然比检验统计量 (该变量删除后 deviance 的增加量); P-value: LRT 的 p 值。来源: ESL Table 5.1。

- **Df:** 该变量占用的自由度 (连续变量 = 4 个样条基函数; famhist = 1 个哑变量);
- **Deviance:** 删除该变量后模型的离差 ($= -2 \times$ 对数似然, 类比 RSS);
- **AIC:** Deviance + $2 \times df$ 的惩罚 (越小越好);
- **LRT (似然比检验)** = Deviance_{删除后} - Deviance_{全模型}: 衡量删除该变量造成的拟合损失。越大 变量越重要;
- **P-value:** LRT 的 p 值, < 0.05 显著 (不能删)。sbp 的 $p=0.059$, 接近显著但刚好过线——作者选择保留。

按重要性排名(LRT 从大到小): age(23.8) > famhist(21.4) > ldl(14.3) > tobacco(12.4) > sbp(9.1) > obesity(8.1)。

关键发现与解释

sbp (收缩压) 和 obesity (肥胖) 在线性模型中不显著 (Z 得分 ≈ 1), 但在样条模型中被保留下来——因为它们的贡献本质上是非线性的 (图 5.4 显示 U 形效应: 低值和高值均增加风险)。这正是基展开超越线性的实际价值: 「直线工具太钝, 切不出曲线」——换样条这把更灵活的工具, 真实的非线性效应才得以显现。

低值区域出现风险上升看似反常 (血压低/体重轻反而风险高?), 但这是回顾性数据的体现: 患者心梗发作后已受益于健康饮食和生活方式改变 (血压降低了、体重减轻了), 导致低 sbp/obesity 区域的表面风险升高——因果方向被数据收集方式反转。

数学推导: $\hat{f}_{\text{sbp}}(x)$ 如何计算

以 sbp 为例, 用严格的符号语言揭示图 5.4 的完整计算链。

Step 1——构造基函数: 对 sbp 选取 $K = 5$ 个节点 (2 个边界 = min 和 max, 3 个内节点放在样本分位数处), 4 个自然三次样条基函数为 ((13.4)):

$$h_1(x) = 1, \quad h_2(x) = x, \quad h_3(x) = d_1(x) - d_{K-1}(x), \quad h_4(x) = d_2(x) - d_{K-1}(x),$$

其中 $d_k(x) = \frac{(x-\xi_k)_+^3 - (x-\xi_K)_+^3}{\xi_K - \xi_k}$ (每 d_k 保证在 $x \geq \xi_K$ 处三阶导数为零)。

Step 2——构造 sbp 的设计矩阵: 对 $i = 1, \dots, N$, 第 i 个样本的 sbp 值为 $x_{i,\text{sbp}}$, 其对应的 1×4 基向量为:

$$h_{\text{sbp}}(x_{i,\text{sbp}}) = [h_1(x_{i,\text{sbp}}), h_2(x_{i,\text{sbp}}), h_3(x_{i,\text{sbp}}), h_4(x_{i,\text{sbp}})].$$

所有 7 个变量的基函数 + 常数项合并为 $\mathbf{H}_{N \times \text{df}}$, 其中 sbp 对应的 4 列为第 $k_{\text{sbp}} + 1$ 到 $k_{\text{sbp}} + 4$ 列。

Step 3——拟合 Logistic 回归: 用 IRLS (§4.4.1) 最大化对数似然, 得参数估计 $\hat{\theta} \in \mathbb{R}^{\text{df}}$. sbp 对应的 4 个系数为子向量 $\hat{\theta}_{\text{sbp}} = (\hat{\theta}_{\text{sbp},1}, \dots, \hat{\theta}_{\text{sbp},4})^\top$ 。

Step 4——在任意值 x 处计算 $\hat{f}_{\text{sbp}}(x)$:

$$\hat{f}_{\text{sbp}}(x) = \sum_{m=1}^4 \hat{\theta}_{\text{sbp},m} h_m(x) = h_{\text{sbp}}(x)^\top \hat{\theta}_{\text{sbp}}.$$

在 sbp 的值域上取均匀网格 $\{x_1, \dots, x_{100}\}$, 逐点计算即得图 5.4 中的实线。

Step 5——置信带的计算: $\hat{\theta}$ 的渐近协方差矩阵为 $\widehat{\text{Cov}}(\hat{\theta}) = (\mathbf{H}^\top \mathbf{W} \mathbf{H})^{-1}$ (从 IRLS 最后一轮获得)。取 sbp 对应的 4×4 子块 $\widehat{\text{Cov}}(\hat{\theta}_{\text{sbp}})$, 则在 x 处 $\hat{f}_{\text{sbp}}(x)$ 的标准误为:

$$\text{SE}[\hat{f}_{\text{sbp}}(x)] = \sqrt{h_{\text{sbp}}(x)^\top \widehat{\text{Cov}}(\hat{\theta}_{\text{sbp}}) h_{\text{sbp}}(x)}.$$

图中虚线带即为 $\hat{f}_{\text{sbp}}(x) \pm 2 \cdot \text{SE}[\hat{f}_{\text{sbp}}(x)]$ 。

标准误 (Standard Error) 的定义

给定参数估计量 $\hat{\psi}$ (例如一个回归系数 $\hat{\beta}_j$, 或某点处的拟合值 $\hat{f}(x_0)$), 其**标准误**是估计量抽样分布的标准差的估计:

$$\text{SE}(\hat{\psi}) = \sqrt{\widehat{\text{Var}}(\hat{\psi})} = \text{「如果我们反复从同一总体中抽取新样本并重拟合, } \hat{\psi} \text{ 会如何波动」的估计标准}$$

以线性回归为例: $\text{Cov}(\hat{\beta}) = \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}$, 故 $\text{SE}(\hat{\beta}_j) = \hat{\sigma} \sqrt{[(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}}$ 。Logistic 回归中相应量为 $(\mathbf{H}^\top \mathbf{W} \mathbf{H})^{-1}$ (Fisher 信息矩阵的逆)。标准误不是数据的标准差, 而是**估计精度**的度量——SE 越小, 估计越精确, Z 得分 ($\hat{\beta}_j/\text{SE}$) 越大, 越可能统计显著。

训练与画图的时序

一个容易混淆的点： $\hat{f}(\text{sbp})$ 看起来是「对 sbp 单独拟合的曲线」，但实际上 $\hat{\theta}$ 在画图之前就已经训练完毕。完整时序如下：

- (1) 构造完整设计矩阵 $\mathbf{H}$ ($N \times \text{df}$, 包含所有 7 个变量的样条基函数列 + 常数项)；
- (2) 一次性拟合 Logistic 回归 $\min \ell(\theta) \xrightarrow{\text{IRLS}} \hat{\theta}$ ——此时模型已训练完成；
- (3) 用 $\hat{\theta}$ 做各种事后操作：
 - 画 $\hat{f}(\text{sbp})$ ：在 sbp 值域网格上计算 $h_{\text{sbp}}(x)^\top \hat{\theta}_{\text{sbp}}$ ；
 - 预测新患者：输入 7 个变量值 $\rightarrow \text{logit} = \hat{\theta}_0 + \sum_j \hat{f}_j(x_j) \rightarrow \text{分类}$ ；
 - 模型选择：删变量 $\rightarrow$ 看 AIC 变化（可在原 $\hat{\theta}$ 上近似计算，无需重拟合）；
 - 推断：对每组系数做 LRT、计算 p 值。

$\hat{f}(\text{sbp})$ 不是单独训练的——它是完整大模型的一个「切片」，与 $\hat{f}(\text{obesity}), \hat{f}(\text{age})$ 等同时通过同一个最大似然过程得到。画图只是在已训练好的模型上，把 sbp 维度拎出来观察其形状。训练（找 $\hat{\theta}$ ）只做一次，之后的画图、预测、检验都是对同一个 $\hat{\theta}$ 的不同使用方式。

13.2.9 示例：音素识别

另一个应用方向：用样条增加约束而非灵活性——即函数型建模。与前一例构成样条的两个极端用法：

	南非心脏病	音素识别
特征数 p	7（很少）	256（很多）
每系数有效数据	充足	≈ 4 个观测/系数
原始模型的问题	太刚性——直线切不出曲线	太灵活——256 个系数严重过拟合
样条的作用	增加灵活性：每变量 $1 \rightarrow 4$ 个参数	减少灵活性：256 $\rightarrow$ 12 个参数
$\mathbf{H}$ 维度变化	$N \times 7 \rightarrow N \times 28$ （变大）	$N \times 256 \rightarrow N \times 12$ （变小）
方向	展开 (expand)	压缩 (compress)

数学操作完全相同——自然三次样条 $\beta = \mathbf{H}\theta$ ——但统计目的恰好相反。合在一起完整展示了样条作为「复杂度双向调节器」的威力。

数据：两个音素「aa」和「ao」的 log-periodogram，在 256 个均匀频率点上测量（图 5.5 上）。目标是用这些数据分类口语音素。

原始 Logistic 回归: 将 256 个 log-periodogram 值作为输入直接拟合（相当于离散化 $\int X(f)\beta(f)df \approx \sum_j x_j\beta_j$ ）。系数曲线（图 5.5 下的灰色锯齿线）极其粗糙——输入信号有强正自相关，导致系数负自相关，且有效样本量仅每系数约 4 个观测。

正则化方案: 用自然三次样条强制系数作为频率的光滑函数： $\beta(f) = \sum_{m=1}^M h_m(f)\theta_m$ ，即 $\beta = \mathbf{H}\theta$ ，其中 $\mathbf{H}$ 是 $p \times M$ 自然样条基矩阵（ $M = 12$ ，节点在 $1, \dots, 256$ 上均匀放置）。

由于 $\mathbf{x}^\top \beta = \mathbf{x}^\top \mathbf{H}\theta$ ，只需将输入特征替换为滤波后版本 $\mathbf{x}^* = \mathbf{H}^\top \mathbf{x}$ ，然后对 $\mathbf{x}^*$ 拟合线性 Logistic 回归。红色光滑曲线 $\hat{\beta}(f) = h(f)^\top \hat{\theta}$ （图 5.5 下）清晰揭示：低频区域提供最大判别力。

	训练误差	测试误差
原始（无约束）	0.080	0.255
光滑样条正则化	0.185	0.158

光滑化不仅使对比模式更易解释，还产生了更准确的分类器——偏差-方差权衡的又一个例证：接受少量偏差增加换取了大幅方差降低。

13.3 滤波与特征提取

音素识别示例体现了一个更一般的模式：构造 $p \times M$ 基矩阵 $\mathbf{H}$ ，然后将特征变换为 $\mathbf{x}^* = \mathbf{H}^\top \mathbf{x}$ ，最后将滤波后的特征作为学习过程的输入。这种高维特征的预处理在信号和图像处理中尤为常见。

- 可通过基 $\mathbf{H}$ 的选择来施加先验知识——如要求系数光滑或稀疏；
- 滤波后的特征 $\mathbf{x}^*$ 维度 $M \ll p$ ，实现降维的同时保留对预测有用的结构。

更一般地，派生特征 $\mathbf{x}^* = g(\mathbf{x})$ 可作为任何学习过程（线性或非线性）的输入。例如信号/图像识别中常用小波变换 $\mathbf{x}^* = \mathbf{H}^\top \mathbf{x}$ （§5.9）提取特征后送入神经网络（第 11 章）：小波擅长捕获离散跳跃和边缘，神经网络擅长构造这些特征的非线性组合。

13.4 光滑样条

前面讨论的回归样条需要手动选择节点位置和数量。光滑样条通过采取最大节点集 + 正则化控制复杂度的策略，彻底规避了节点选择问题。

13.4.1 惩罚残差平方和

在具有二阶连续导数的所有函数 $f(x)$ 中，寻找最小化以下目标的 f ：

$$\text{RSS}(f, \lambda) = \sum_{i=1}^N \{y_i - f(x_i)\}^2 + \lambda \int \{f''(t)\}^2 dt, \quad (13.6)$$

其中 $\lambda \geq 0$ 是固定的光滑参数。

两项的含义：

- 第一项：与数据的拟合紧密度（残差平方和）；
- 第二项：对曲率的惩罚—— f'' 越大（曲线越弯），惩罚越重；
- λ ：在拟合度与光滑度之间建立权衡。

两种极端：

$\lambda = 0 \implies f$ 可以是任何插值数据的函数（极度粗糙），

$\lambda = \infty \implies$ 最小二乘直线（无曲率可容忍）。

希望 $\lambda \in (0, \infty)$ 索引一类有意义的折中函数。

13.4.2 有限维解

准则 (13.6) 定义在无穷维函数空间（Sobolev 空间）上。但可以证明（习题 5.7）：其唯一最小化解是节点位于所有唯一 x_i 值处的自然三次样条。表面上参数数量惊人（多达 N 个节点），但正则化项 $\lambda \int (f'')^2$ 自动控制了有效复杂度。

为什么恰好是自然三次样条？两个互补的直觉：

物理直觉——弹性梁：将 f 想象成一根弹性木条， $\int (f'')^2$ 即弯曲能（弯得越厉害弹性势能越大）。 N 个数据点好比套在木条上的环，木条倾向于笔直（减小弯曲能），但环拉着它靠近数据（减小残差）。在环之间的自由段，弯曲能的 Euler-Lagrange 方程 $f'''' = 0$ 表明最优形状是分段三次多项式。环处 f, f', f'' 连续（外力平衡），端点外无力作用 $\implies f'' = 0$ （直线）——即自然边界。

变分直觉——任何非样条函数都可改善：若 f 不是节点在 x_i 的自然三次样条，可构造 g 为插值 $f(x_i)$ 的自然三次样条。由分部积分可得 $\int f'' g'' = \int (g'')^2$ ，于是

$$\int (f'')^2 = \int (g'')^2 + \int (f'' - g'')^2 \geq \int (g'')^2,$$

即 g 与 f 拟合完全一致但曲率惩罚更小。因此最优解必须在自然三次样条族中。

推论：无穷维优化 $\implies$ 有限维广义岭回归。这个定理是光滑样条能够实际计算的数学基础——没有它，光滑样条只是一个不可计算的抽象概念。

设 $\{N_j(x)\}_{j=1}^N$ 为此族自然样条的 N 维基函数，则 $f(x) = \sum_{j=1}^N N_j(x) \theta_j$ 。准则化为：

$$\text{RSS}(\theta, \lambda) = (\mathbf{y} - \mathbf{N}\theta)^\top (\mathbf{y} - \mathbf{N}\theta) + \lambda \theta^\top \mathbf{\Omega} \theta, \quad (13.7)$$

其中 $\mathbf{N}_{ij} = N_j(x_i)$ ， $\mathbf{\Omega}_{jk} = \int N_j''(t) N_k''(t) dt$ 。解为：

$$\hat{\theta} = (\mathbf{N}^\top \mathbf{N} + \lambda \mathbf{\Omega})^{-1} \mathbf{N}^\top \mathbf{y}, \quad (13.8)$$

广义岭回归的形式。拟合的光滑样条为：

$$\hat{f}(x) = \sum_{j=1}^N N_j(x) \hat{\theta}_j.$$

图 5.6 展示了青少年骨密度（BMD）数据上男性和女性各一条光滑样条（ $\lambda \approx 0.00022$ ，对应约 12 个自由度），清晰揭示女性的生长陡增比男性早约两年。

13.4.3 完整示例：光滑样条的符号化流程

下面不涉及具体数值，用标准符号语言展示光滑样条从数据到预测的完整六步流水线。

给定

训练数据 $\{(x_i, y_i)\}_{i=1}^N$ ， $x_i \in \mathbb{R}$ （一维输入）， $y_i \in \mathbb{R}$ （连续响应）。真实 $f(x) = \mathbb{E}[Y | X = x]$ 未知，不假设任何参数形式。目标：估计一个光滑的 $\hat{f}(x)$ 。

Step 1——选择光滑参数 λ （或等价地 df_λ ）

λ 控制拟合度与光滑度的权衡，通常通过交叉验证确定。等价地可指定有效自由度 $\text{df}_\lambda \in [2, N]$ ——实践中最常用的参数化方式（如 ‘smooth.spline(x, y, df=12)’）。

Step 2——构造自然三次样条基矩阵

将全体 $\{x_i\}$ 的 M 个唯一值排序： $x_{(1)} < x_{(2)} < \dots < x_{(M)}$ 。以这些点为节点构造 M 个自然三次样条基函数 $\{N_j(x)\}_{j=1}^M$ （ $N_1(x) = 1, N_2(x) = x$ ，其余由 (13.4) 定义）。在 N 个训练点上求值，构造 $N \times M$ 基矩阵：

$$\mathbf{N}_{ij} = N_j(x_i), \quad i = 1, \dots, N, j = 1, \dots, M.$$

Step 3——构造惩罚矩阵

计算基函数二阶导数的内积：

$$\mathbf{\Omega}_{jk} = \int N_j''(t) N_k''(t) dt, \quad j, k = 1, \dots, M,$$

得 $M \times M$ 惩罚矩阵 $\mathbf{\Omega}$ （对称半正定）。注意： $\mathbf{\Omega}$ 仅依赖于 $\{x_i\}$ 的位置，与 y 无关。

Step 4——求解广义岭回归

模型为 $f(x) = \sum_{j=1}^M N_j(x) \theta_j$ 。将 $\{N_j\}$ 代入 (13.6)，目标函数化为：

$$\min_{\boldsymbol{\theta} \in \mathbb{R}^M} \{(\mathbf{y} - \mathbf{N}\boldsymbol{\theta})^\top (\mathbf{y} - \mathbf{N}\boldsymbol{\theta}) + \lambda \boldsymbol{\theta}^\top \boldsymbol{\Omega} \boldsymbol{\theta}\}.$$

解析解：

$$\hat{\boldsymbol{\theta}} = (\mathbf{N}^\top \mathbf{N} + \lambda \boldsymbol{\Omega})^{-1} \mathbf{N}^\top \mathbf{y}.$$

此时 $\hat{\boldsymbol{\theta}}$ 已确定，模型训练完毕。拟合值向量 $\hat{\mathbf{f}} = \mathbf{N}\hat{\boldsymbol{\theta}} = \mathbf{S}_\lambda \mathbf{y}$ ，其中 $\mathbf{S}_\lambda = \mathbf{N}(\mathbf{N}^\top \mathbf{N} + \lambda \boldsymbol{\Omega})^{-1} \mathbf{N}^\top$ 为光滑矩阵。

Step 5——在新点 x_0 处预测

计算 x_0 处的基函数值 $\mathbf{n}_0 = [N_1(x_0), \dots, N_M(x_0)]^\top \in \mathbb{R}^M$ 。预测为：

$$\hat{f}(x_0) = \sum_{j=1}^M \hat{\theta}_j N_j(x_0) = \mathbf{n}_0^\top \hat{\boldsymbol{\theta}}.$$

Step 6——复杂度与 λ 的选择

光滑矩阵的迹给出有效自由度：

$$\text{df}_\lambda = \text{trace}(\mathbf{S}_\lambda) = \sum_{k=1}^M \frac{1}{1 + \lambda d_k} \in [2, M],$$

其中 d_k 为惩罚矩阵 $\boldsymbol{\Omega}$ 相对于 $\mathbf{N}^\top \mathbf{N}$ 的广义特征值 ($d_1 = d_2 = 0$ ，线性函数永不惩罚)。实践中：

- 用 K 折 CV 对 df_λ (或 λ) 的候选网格做搜索，选 CV 误差最小的；
- 或直接用 R 的 `smooth.spline(x, y, df=12)` / Python 的 `UnivariateSpline(x, y, s=...)`，库内部完成所有矩阵操作。

与回归样条的操作对比

	回归样条 (§5.2)	光滑样条 (§5.4)
节点数	手动选 K (少)	每个 x_i 一个 (多)
防止过拟合	基函数本身就少	$\lambda \int (f'')^2$ 惩罚
目标函数	$\min \ \mathbf{y} - \mathbf{B}\boldsymbol{\beta}\ ^2$	$\min \ \mathbf{y} - \mathbf{N}\boldsymbol{\theta}\ ^2 + \lambda \boldsymbol{\theta}^\top \boldsymbol{\Omega} \boldsymbol{\theta}$
复杂度旋钮	K (节点数)	λ 或 df_λ (连续值)
解的形式	$\hat{\boldsymbol{\beta}} = (\mathbf{B}^\top \mathbf{B})^{-1} \mathbf{B}^\top \mathbf{y}$	$\hat{\boldsymbol{\theta}} = (\mathbf{N}^\top \mathbf{N} + \lambda \boldsymbol{\Omega})^{-1} \mathbf{N}^\top \mathbf{y}$

一句话：光滑样条将节点的离散选择替换为 λ (光滑度) 的连续调节——你拧旋钮，它自动决定曲线弯多少。

13.4.4 自由度与光滑矩阵

光滑矩阵 $\mathbf{S}_\lambda$

光滑样条是线性光滑器——拟合值 $\hat{\mathbf{f}}$ 是 $\mathbf{y}$ 的线性函数。记 $\hat{f}_i = \hat{f}(x_i)$, 则:

$$\hat{\mathbf{f}} = \mathbf{N}(\mathbf{N}^\top \mathbf{N} + \lambda \mathbf{\Omega})^{-1} \mathbf{N}^\top \mathbf{y} = \mathbf{S}_\lambda \mathbf{y}, \quad (13.9)$$

其中 $\mathbf{S}_\lambda$ ($N \times N$) 称为光滑矩阵。 $\hat{\mathbf{f}}$ 的构造过程不依赖于 $\mathbf{y}$ 本身—— $\mathbf{S}_\lambda$ 仅由 x_i 和 λ 决定。

投影光滑器 vs 收缩光滑器

对比回归样条的帽子矩阵 $\mathbf{H}_\xi$ 与光滑样条的 $\mathbf{S}_\lambda$:

性质	$\mathbf{H}_\xi$ (回归样条)	$\mathbf{S}_\lambda$ (光滑样条)
对称半正定		
幂等性	$\mathbf{H}_\xi \mathbf{H}_\xi = \mathbf{H}_\xi$	$\mathbf{S}_\lambda \mathbf{S}_\lambda \preceq \mathbf{S}_\lambda$ (收缩性)
秩	M (基函数个数)	N
类型	投影光滑器	收缩光滑器

$\mathbf{H}_\xi$ 将 $\mathbf{y}$ 投影到 M 维子空间 (M 个特征值为 1, 其余为 0), 而 $\mathbf{S}_\lambda$ 对所有方向做不同程度的收缩 (所有特征值 $\in [0, 1]$)。

光滑样条的自由度

有效自由度定义为光滑矩阵的迹:

$$\boxed{\text{df}_\lambda = \text{trace}(\mathbf{S}_\lambda)}. \quad (13.10)$$

这一极有用的定义提供了参数化光滑样条的一致方式——不说「 $\lambda = 0.00022$ 」, 而说「 $\text{df} = 12$ 」。图 5.6 中正是通过数值求解 $\text{trace}(\mathbf{S}_\lambda) = 12$ 来反推 $\lambda \approx 0.00022$ 。

df_λ 的两个极端:

$$\lambda \rightarrow 0 \implies \text{df}_\lambda \rightarrow N \quad (\text{插值}), \quad \lambda \rightarrow \infty \implies \text{df}_\lambda \rightarrow 2 \quad (\text{线性回归}).$$

特征分解

$\mathbf{S}_\lambda$ 可写为 Reinsch 形式 $\mathbf{S}_\lambda = (\mathbf{I} + \lambda \mathbf{K})^{-1}$ ($\mathbf{K}$ 为惩罚矩阵, 不依赖 λ , 习题 5.9)。 $\hat{\mathbf{f}} = \mathbf{S}_\lambda \mathbf{y}$ 等价于求解 $\min_f (\mathbf{y} - \mathbf{f})^\top (\mathbf{y} - \mathbf{f}) + \lambda \mathbf{f}^\top \mathbf{K} \mathbf{f}$ 。

$\mathbf{S}_\lambda$ 的特征分解:

$$\mathbf{S}_\lambda = \sum_{k=1}^N \rho_k(\lambda) \mathbf{u}_k \mathbf{u}_k^\top, \quad \rho_k(\lambda) = \frac{1}{1 + \lambda d_k},$$

其中 d_k 是 $\mathbf{K}$ 的特征值 ($d_1 = d_2 = 0$, 对应线性函数空间, 永不收缩)。

关键性质 (图 5.7):

- 特征向量 $\mathbf{u}_k$ **不依赖** λ ——整个光滑样条族共享同一组特征基 (Demmler-Reinsch 基);
- $\mathbf{S}_\lambda \mathbf{y} = \sum_k \mathbf{u}_k \rho_k(\lambda) \langle \mathbf{u}_k, \mathbf{y} \rangle$, 即沿各特征方向对 $\mathbf{y}$ 的分量进行**差异收缩**;
- 特征向量按 $\rho_k(\lambda)$ 递减排序, 复杂度递增 (类似递增阶数的多项式); 复杂度越高的方向被收缩得越厉害;
- 前两个特征值恒为 1 (对应 $\{u: u \text{ 是 } x \text{ 的线性函数}\}$, 永不惩罚);
- $\text{df}_\lambda = \text{trace}(\mathbf{S}_\lambda) = \sum_{k=1}^N \rho_k(\lambda)$ 。对投影光滑器, 所有特征值为 1, 每个对应投影子空间的一个维度。

等价核——光滑样条的局部性

图 5.8 展示了光滑矩阵 $\mathbf{S}_\lambda$ 的带状结构 (行按 x 排序)——表明光滑样条本质上是一个**局部拟合方法**, 类似于第 6 章的局部加权回归。 $\mathbf{S}_\lambda$ 的每一行即为**等价核**—— $\hat{f}(x_i)$ 实质上是 y_i 附近点的加权平均, 权重在 x_i 处最大并向两侧衰减。

$$\lambda \rightarrow 0 \implies \text{df} \rightarrow N, \mathbf{S}_\lambda \rightarrow \mathbf{I}, \quad \lambda \rightarrow \infty \implies \text{df} \rightarrow 2, \mathbf{S}_\lambda \rightarrow \mathbf{H}_{\text{线性}}.$$

13.5 光滑参数的自动选择

13.5.1 用有效自由度参数化

光滑样条的 $\text{df}_\lambda = \text{trace}(\mathbf{S}_\lambda)$ 关于 λ 单调递减 (λ 越大 $\rightarrow$ df 越小 $\rightarrow$ 越光滑), 可以反解——**固定 df 来确定 λ** 。实践中通过简单数值方法实现 (如 R 的 `smooth.spline(x, y, df=6)`)。

这种方法鼓励更传统的模型选择模式: 尝试几个不同的 df 值, 基于近似 F 检验、残差图等主观准则选择。 **df 的统一度量使不同的光滑方法可以公平比较**——在广义加性模型 (第 9 章) 中尤其有用, 多个光滑方法可同时用于一个模型。

13.5.2 偏差-方差权衡

图 5.9 用模拟数据 $Y = \frac{\sin(12(X+0.2))}{X+0.2} + \varepsilon$ ($X \sim U[0, 1], \varepsilon \sim N(0, 1), N = 100$) 展示了 df 的三个取值:




FIGURE 5.8. The smoother matrix for a smoothing spline is nearly banded, indicating an equivalent kernel with local support. The left panel represents the elements of S as an image. The right panel shows the equivalent kernel or weighting function in detail for the indicated rows.

图 13.5: 光滑样条的光滑矩阵 S_λ 。左: 矩阵元素图 (行按 x 排序), 带状结构表明局部支撑。右: 选定行的等价核 (加权函数), 每行在对应 x_i 处取峰值并向两侧衰减。来源: ESL Figure 5.8。




FIGURE 5.9. The top left panel shows the $EPE(\lambda)$ and $CV(\lambda)$ curves for a realization from a nonlinear additive error model (5.22). The remaining panels show the data, the true functions (in purple), and the fitted curves (in green) with yellow shaded $\pm 2 \times$ standard error bands, for three different values of df_λ .

图 13.6: 左上: $EPE(\lambda)$ 和 $CV(\lambda)$ 曲线。其余三面板: 真实函数 (紫色)、拟合曲线 (绿色) 及 ± 2 标准误差带 (黄色), 分别对应 $df = 5, 9, 15$ 。 $df = 5$ 欠拟合, $df = 15$ 略显过拟合, $df = 9$ 接近最优。来源: ESL Figure 5.9。

df_λ	表现	诊断
5	欠拟合: 削峰填谷, 高曲率区偏差大	标准误差带极窄——有偏但确信
9	接近最优, 轻微偏差	方差尚未明显增加
15	略显波动, 接近真实函数	标准误差带增宽——追随个别点

定量表达: $\hat{\mathbf{f}} = \mathbf{S}_\lambda \mathbf{y}$ 的方差-偏差分解为

$$\text{Cov}(\hat{\mathbf{f}}) = \mathbf{S}_\lambda \mathbf{S}_\lambda^\top, \quad \text{Bias}(\hat{\mathbf{f}}) = \mathbf{f} - \mathbf{S}_\lambda \mathbf{f},$$

其中 $\mathbf{f}$ 是未知真实值向量。**EPE** (期望预测误差) 综合了偏差和方差:

$$\text{EPE}(\hat{f}_\lambda) = \mathbb{E}(Y - \hat{f}_\lambda(X))^2 = \sigma^2 + \underbrace{\mathbb{E}[\text{Bias}^2(\hat{f}_\lambda(X))] + \mathbb{E}[\text{Var}(\hat{f}_\lambda(X))]}_{\text{MSE}(\hat{f}_\lambda)}.$$

13.5.3 交叉验证 (CV)

λ 的实际选择通过最小化 CV 得分:

$$\text{CV}(\hat{f}_\lambda) = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{f}_\lambda^{(-i)}(x_i))^2,$$

其中 $\hat{f}_\lambda^{(-i)}$ 是删除第 i 个观测后拟合的模型。对光滑样条这一线性光滑器, 有**免重拟合公式** (习题 5.13):

$$\text{CV}(\hat{f}_\lambda) = \frac{1}{N} \sum_{i=1}^N \left(\frac{y_i - \hat{f}_\lambda(x_i)}{1 - S_\lambda(i, i)} \right)^2,$$

即只需完整拟合一次, 使用对角线元素 $S_\lambda(i, i)$ 校正。CV 曲线是 EPE 曲线的近似无偏估计量 (图 5.9 左上)。**对回归样条**还需额外选择节点位置和数量——这是个组合爆炸问题, 除非使用 MARS (§9.4) 等贪心策略。

13.6 非参数 Logistic 回归

将光滑样条从回归推广到分类是直接了当的。对单个连续输入 X 的 Logistic 回归:

$$\log \frac{\Pr(Y = 1 | X = x)}{\Pr(Y = 0 | X = x)} = f(x), \quad \Pr(Y = 1 | X = x) = \frac{e^{f(x)}}{1 + e^{f(x)}}.$$

在光滑样条框架下拟合 f 得到条件概率 $\Pr(Y = 1 | x)$ 的光滑估计。

惩罚对数似然准则:

$$\ell(f; \lambda) = \sum_{i=1}^N [y_i f(x_i) - \log(1 + e^{f(x_i)})] - \frac{\lambda}{2} \int \{f''(t)\}^2 dt, \quad (13.11)$$

第一项是二项分布的对数似然（第 4 章），第二项是曲率惩罚。与回归情况一样，最优 f 是节点在唯一 x_i 处的有限维自然样条： $f(x) = \sum_{j=1}^N N_j(x) \theta_j$ 。

Newton-Raphson 迭代：梯度和 Hessian 为

$$\frac{\partial \ell}{\partial \boldsymbol{\theta}} = \mathbf{N}^\top (\mathbf{y} - \mathbf{p}) - \lambda \boldsymbol{\Omega} \boldsymbol{\theta}, \quad \frac{\partial^2 \ell}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}^\top} = -\mathbf{N}^\top \mathbf{W} \mathbf{N} - \lambda \boldsymbol{\Omega},$$

其中 $\mathbf{W} = \text{diag}(p_i(1 - p_i))$ 。Newton 更新为：

$$\boldsymbol{\theta}^{\text{new}} = (\mathbf{N}^\top \mathbf{W} \mathbf{N} + \lambda \boldsymbol{\Omega})^{-1} \mathbf{N}^\top \mathbf{W} \mathbf{z}, \quad (13.12)$$

或以拟合值表示：

$$\mathbf{f}^{\text{new}} = \underbrace{\mathbf{N}(\mathbf{N}^\top \mathbf{W} \mathbf{N} + \lambda \boldsymbol{\Omega})^{-1} \mathbf{N}^\top \mathbf{W}}_{\mathbf{S}_{\lambda, w}} \mathbf{z} = \mathbf{S}_{\lambda, w} \mathbf{z}.$$

这恰好是加权光滑样条对工作响应 $\mathbf{z}$ 的拟合——与 §4.4.1 的 IRLS 完全一致，只是将线性回归换成了光滑样条。

推广： $\mathbf{S}_{\lambda, w}$ 可替换为任何非参数（加权）回归算子，得到一般的非参数 Logistic 回归族。该思想自然推广到高维——这正是广义加性模型（GAM，第 9 章）的基石。

13.7 多维样条

至此所有样条均为一维。本节讨论多维推广。

13.7.1 张量积基

设有一维基函数族 $\{h_{1j}(X_1)\}_{j=1}^{M_1}$ 和 $\{h_{2k}(X_2)\}_{k=1}^{M_2}$ ，则 $M_1 \times M_2$ 维张量积基定义为：

$$g_{jk}(X) = h_{1j}(X_1) h_{2k}(X_2), \quad j = 1, \dots, M_1, \quad k = 1, \dots, M_2, \quad (13.13)$$

二维函数表示为：

$$g(X) = \sum_{j=1}^{M_1} \sum_{k=1}^{M_2} \theta_{jk} g_{jk}(X).$$

系数由最小二乘拟合。

可推广到 d 维，但基的维度指数增长——维数灾难的又一个表现。MARS (§9.4) 使用贪心前向算法仅包含最小二乘认为必要的张量积项。

加性 vs 张量积：图 5.11 比较了二维分类问题上两者的决策边界。加性模型（各自样条相加）捕捉主效应，张量积可拟合更灵活的交互，但可能引入虚假结构。




FIGURE 5.10. A tensor product basis of B-splines, showing some selected pairs. Each two-dimensional function is the tensor product of the corresponding one dimensional marginals.

图 13.7: B-样条的张量积基。选取了部分代表性函数对，每个二维函数是对应一维边缘基函数的张量积。来源：ESL Figure 5.10。




FIGURE 5.11. The simulation example of Figure 2.1. The upper panel shows the decision boundary of an additive logistic regression model, using natural splines in each of the two coordinates (total $df = 1 + (4 - 1) + (4 - 1) = 7$). The lower panel shows the results of using a tensor product of natural spline bases in each coordinate (total $df = 4 \times 4 = 16$). The broken purple boundary is the Bayes decision boundary for this problem.

图 13.8: 图 2.1 模拟例子的二维分类。上图: 可加 Logistic 回归模型, 每维用自然样条 (总 $df = 1 + (4 - 1) + (4 - 1) = 7$)。下图: 每维自然样条基的张量积 (总 $df = 4 \times 4 = 16$)。紫色虚线为 Bayes 决策边界。来源: ESL Figure 5.11。

13.7.2 薄板样条 (Thin-Plate Splines)

一维光滑样条的正则化思想可推广到 $\mathbb{R}^d$:

$$\min_f \sum_{i=1}^N \{y_i - f(x_i)\}^2 + \lambda J[f], \quad (13.14)$$

其中 $J[f]$ 是 d 维粗糙度惩罚。对 $d = 2$:

$$J[f] = \iint_{\mathbb{R}^2} \left[\left(\frac{\partial^2 f}{\partial x_1^2} \right)^2 + 2 \left(\frac{\partial^2 f}{\partial x_1 \partial x_2} \right)^2 + \left(\frac{\partial^2 f}{\partial x_2^2} \right)^2 \right] dx_1 dx_2.$$

解的形式 (与一维自然三次样条共享性质):

$$f(x) = \beta_0 + \beta^\top x + \sum_{j=1}^N \alpha_j h_j(x), \quad h_j(x) = \|x - x_j\|^2 \log \|x - x_j\|,$$

其中 h_j 为径向基函数 (§5.9 详述)。系数由带线性约束的惩罚最小二乘确定 (习题 5.14)。

$$\lambda \rightarrow 0 \Rightarrow \text{插值表面}, \quad \lambda \rightarrow \infty \Rightarrow \text{最小二乘平面}.$$

计算复杂度: 薄板样条为 $O(N^3)$ (一般无稀疏结构可资利用), 实践中用放置在一组格点上的节点约简: 用 K 个节点将计算量降至 $O(NK^2 + K^3)$ 。图 5.12 展示了心脏病数据上年龄 $\times$ 肥胖的薄板样条拟合 ($df = 15$)。

13.7.3 加性样条与 ANOVA 分解

多维样条的一类重要限制是**加性模型**:

$$f(X) = \alpha + f_1(X_1) + f_2(X_2) + \cdots + f_d(X_d),$$

每 f_j 是一维样条。惩罚自然施加于各分量:

$$J[f] = \sum_{j=1}^d \int f_j''(t_j)^2 dt_j.$$

这自然推广到 ANOVA 分解:

$$f(X) = \alpha + \sum_j f_j(X_j) + \sum_{j < k} f_{jk}(X_j, X_k) + \cdots,$$

每项为相应维数的样条。需做的选择包括: 最大交互阶数、包含哪些项、每项使用回归样条还是光滑样条。MARS (§9.4) 和 MART (第 10 章) 提供了自动化方案。

13.7.4 小结：从一维到多维的选择路线

面对 d 维输入，样条建模有三条路线，对应递增的复杂度与表达力：

策略	模型形式	基函数数	能建模的效应
加性模型	$\alpha + \sum_{j=1}^d f_j(X_j)$	$O(dM)$	仅主效应
ANOVA 分解	$\alpha + \sum_j f_j + \sum_{j < k} f_{jk} + \cdots$	递增	主效应 + 指定交互
全张量积	$\sum_{j,k,\dots} \theta_{jk\dots} h_{1j} h_{2k} \cdots$	$O(M^d)$	所有效应（维数灾难）

实践中何时考虑交互效应？一个务实的四步流程：

1. **领域知识优先**：若物理/生物学机制暗示交互存在（如「药效取决于年龄」），直接加入；
2. **加性拟合后检查残差**：拟合纯加性模型，画残差 vs (X_j, X_k) 的二维散点图或热力图——若出现系统模式（而非随机噪声），提示遗漏了交互；
3. **定量诊断**：使用 Friedman's H -statistic 测两个变量间的交互强度——该统计量衡量预测函数偏离纯加性的程度，值越大交互越强（ $H_{jk}^2 \in [0, 1]$ ，0 表示纯加性）；
4. **交叉验证做最终裁决**：加入候选交互项后，用 CV 检验预测误差是否显著下降——下降则保留，否则剔除（除非解释性有强需求）。

EDA 的局限性：对于两连续变量的交互，肉眼从散点图中几乎无法察觉——因为交互本质是「 X_1 对 Y 的效应如何随 X_2 变化」，这需要条件化思维，通常超出纯 EDA 的能力。MARS 和 boosting 等自适应方法（后续章节）能自动检测并纳入交互，是实践中更可靠的方案。

一般原则：大多数问题中，主效应解释了绝大部分可预测变异——交互是锦上添花，常带来过拟合风险而非实质提升。从加性出发，有证据再加交互。

13.8 正则化与再生核 Hilbert 空间 (RKHS)

本节将样条纳入正则化方法的更广阔框架。

13.8.1 一般形式

一类正则化问题可统一写为：

$$\min_{f \in \mathcal{H}} \left[\sum_{i=1}^N L(y_i, f(x_i)) + \lambda J(f) \right], \quad (13.15)$$

其中 L 为损失函数， $J(f)$ 为惩罚泛函， $\mathcal{H}$ 为 $J(f)$ 有定义的函数空间。

若惩罚在 Fourier 域中取形式 $J(f) = \int |\tilde{f}(s)|^2 / \tilde{G}(s) ds$ ($\tilde{G}$ 在高频处衰减), 则解具有有限维表示:

$$f(X) = \sum_{k=1}^K \alpha_k \phi_k(X) + \sum_{i=1}^N \theta_i G(X - x_i),$$

其中 ϕ_k 张成惩罚的零空间 (不惩罚的方向), G 是 $\tilde{G}$ 的 Fourier 逆变换。光滑样条和薄板样条均属此框架。

13.8.2 RKHS 与核方法

正定核

一个二元函数 $K(\cdot, \cdot) : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ 称为**正定核**, 当且仅当: 对任意 n 个点 $\{x_1, \dots, x_n\} \subset \mathcal{X}$ 和任意实数 $\{c_1, \dots, c_n\}$,

$$\sum_{i=1}^n \sum_{j=1}^n c_i c_j K(x_i, x_j) \geq 0. \quad (13.16)$$

等价地, $n \times n$ 的 Gram 矩阵 $\mathbf{K}_{ij} = K(x_i, x_j)$ 对任意 n 和任意点集都是**半正定的**。

这个条件的几何含义是: K 可以作为某个函数空间的内积。直观上, $K(x, y)$ 度量了 x 和 y 的「相似度」; 半正定性保证了这个相似度定义在几何上是自洽的——你无法通过加权组合相似度得到负值。

常见正定核示例:

- **线性核**: $K(x, y) = x^\top y$, 对应有限维内积空间, 生成的函数类为线性函数;
- **多项式核**: $K(x, y) = (x^\top y + 1)^d$, 对应 $\binom{p+d}{d}$ 维特征空间, 生成的函数类为 d 次多项式;
- **高斯核 (RBF)**: $K(x, y) = e^{-\nu \|x-y\|^2}$, 对应无限维特征空间, 生成的函数类为任意光滑函数 (ν 越大 $\rightarrow$ 越局部 $\rightarrow$ 有效维数越高)。

再生核 Hilbert 空间 (RKHS)

给定正定核 K , 其对应的函数空间 $\mathcal{H}_K$ 按如下方式构造:

Step 1——构造稠密子集。把核固定在每个训练点 x_i 上, 得到单变量函数 $K(\cdot, x_i)$ 。这些函数的有限线性组合:

$$f(x) = \sum_{i=1}^n \alpha_i K(x, x_i)$$

构成了 $\mathcal{H}_K$ 的一个稠密子集——即任何属于 $\mathcal{H}_K$ 的函数都可以用这种形式的函数序列去逼近。

Step 2——定义内积。在该稠密子集上定义内积：

$$\left\langle \sum_i \alpha_i K(\cdot, x_i), \sum_j \beta_j K(\cdot, y_j) \right\rangle_{\mathcal{H}_K} = \sum_i \sum_j \alpha_i \beta_j K(x_i, y_j).$$

注意两个核函数的内积恰好是核本身的价值——这是 RKHS 构造的精妙之处。

Step 3——完备化。取该内积空间在 Cauchy 列意义下的完备化, 得到真正的 Hilbert 空间 $\mathcal{H}_K$ ——其范数由内积自然诱导: $\|f\|_{\mathcal{H}_K}^2 = \langle f, f \rangle_{\mathcal{H}_K}$ 。

再生性 (Reproducing Property)——RKHS 得名的关键性质:

$$f(x) = \langle f, K(\cdot, x) \rangle_{\mathcal{H}_K}, \quad \forall x \in \mathcal{X}, \forall f \in \mathcal{H}_K. \quad (13.17)$$

函数 f 在任意点 x 处的求值操作等价于 f 与「以 x 为中心的核」做内积。换言之, 求值泛函在 RKHS 中是连续的——这是普通 Hilbert 空间 (如 L^2) 不具备的性质, 也是 RKHS 能支撑「无穷维优化 $\Rightarrow$ 有限维问题」这一魔法的基础。

范数的含义。回头再看特征展开视角——设核有特征分解 $K(x, y) = \sum_{m=1}^{\infty} \gamma_m \phi_m(x) \phi_m(y)$ (Mercer 定理), 则任意 $f \in \mathcal{H}_K$ 可展开为 $f = \sum_m c_m \phi_m$, 且

$$\|f\|_{\mathcal{H}_K}^2 = \sum_{m=1}^{\infty} \frac{c_m^2}{\gamma_m}.$$

这意味着: 若 γ_m 随 m 增大而快速衰减 (如高斯核), 则函数在高频方向的分量 c_m 被赋予极大的范数惩罚——RKHS 范数天然偏好「低频」(光滑) 函数。这正是 $\lambda \|f\|_{\mathcal{H}_K}^2$ 作为正则化项的内在机理。

表示定理 (Representer Theorem): 问题

$$\min_{f \in \mathcal{H}_K} \sum_{i=1}^N L(y_i, f(x_i)) + \lambda \|f\|_{\mathcal{H}_K}^2$$

的有限维解为:

$$f(x) = \sum_{i=1}^N \alpha_i K(x, x_i).$$

且 $J(f) = \alpha^\top \mathbf{K} \alpha$ ($\mathbf{K}_{ij} = K(x_i, x_j)$)。无穷维优化 $\Rightarrow N$ 维问题 $\min_{\alpha} L(\mathbf{y}, \mathbf{K} \alpha) + \lambda \alpha^\top \mathbf{K} \alpha$ 。

表示定理如何导出 α 的解

以最重要的特例——平方损失 $L(y_i, f(x_i)) = (y_i - f(x_i))^2$ ——演示从无穷维泛函到有限维解析解的完整推导。

Step 1——代入表示定理。将 $f(x) = \sum_{j=1}^N \alpha_j K(x, x_j)$ 代入目标函数的两项。

Step 2——化简损失项。在训练点 x_i 处:

$$f(x_i) = \sum_{j=1}^N \alpha_j K(x_i, x_j) = (\mathbf{K} \alpha)_i,$$

其中 $\mathbf{K}$ 是 $N \times N$ 的 Gram 矩阵。因此：

$$\sum_{i=1}^N (y_i - f(x_i))^2 = \|\mathbf{y} - \mathbf{K}\boldsymbol{\alpha}\|_2^2 = (\mathbf{y} - \mathbf{K}\boldsymbol{\alpha})^\top (\mathbf{y} - \mathbf{K}\boldsymbol{\alpha}).$$

Step 3——化简惩罚项。由 RKHS 内积的定义：

$$\langle K(\cdot, x_i), K(\cdot, x_j) \rangle_{\mathcal{H}_K} = K(x_i, x_j),$$

可得：

$$\|f\|_{\mathcal{H}_K}^2 = \left\langle \sum_i \alpha_i K(\cdot, x_i), \sum_j \alpha_j K(\cdot, x_j) \right\rangle_{\mathcal{H}_K} = \sum_i \sum_j \alpha_i \alpha_j K(x_i, x_j) = \boldsymbol{\alpha}^\top \mathbf{K} \boldsymbol{\alpha}.$$

Step 4——化为有限维二次型。无穷维泛函转化为对 $\boldsymbol{\alpha} \in \mathbb{R}^N$ 的普通无约束二次优化：

$$\min_{\boldsymbol{\alpha} \in \mathbb{R}^N} \{(\mathbf{y} - \mathbf{K}\boldsymbol{\alpha})^\top (\mathbf{y} - \mathbf{K}\boldsymbol{\alpha}) + \lambda \boldsymbol{\alpha}^\top \mathbf{K} \boldsymbol{\alpha}\}. \quad (13.18)$$

Step 5——求导得解析解。对 $\boldsymbol{\alpha}$ 求梯度（利用 $\mathbf{K}$ 对称）：

$$\frac{\partial}{\partial \boldsymbol{\alpha}} = -2\mathbf{K}(\mathbf{y} - \mathbf{K}\boldsymbol{\alpha}) + 2\lambda \mathbf{K}\boldsymbol{\alpha} = 0 \implies \mathbf{K}\mathbf{K}\boldsymbol{\alpha} + \lambda \mathbf{K}\boldsymbol{\alpha} = \mathbf{K}\mathbf{y}.$$

对严格正定核（如高斯核、多项式核）， $\mathbf{K}$ 可逆，两边左乘 $\mathbf{K}^{-1}$ 即得：

$$\boxed{\hat{\boldsymbol{\alpha}} = (\mathbf{K} + \lambda \mathbf{I})^{-1} \mathbf{y}.} \quad (13.19)$$

Step 6——预测新点。对于任意新输入 x_{new} ，预测直接在核空间中完成：

$$\hat{f}(x_{\text{new}}) = \sum_{i=1}^N \hat{\alpha}_i K(x_{\text{new}}, x_i) = \mathbf{k}_{\text{new}}^\top \hat{\boldsymbol{\alpha}},$$

其中 $\mathbf{k}_{\text{new}} = [K(x_{\text{new}}, x_1), \dots, K(x_{\text{new}}, x_N)]^\top$ 只需 N 次核函数求值。

与线性岭回归的平行结构。核岭回归与线性岭回归在代数上完全对应——唯一的区别是把 $p \times p$ 的 $\mathbf{X}^\top \mathbf{X}$ 换成了 $N \times N$ 的 $\mathbf{K}$ ：

	线性岭回归	核岭回归
参数空间	$\boldsymbol{\beta} \in \mathbb{R}^p$	$\boldsymbol{\alpha} \in \mathbb{R}^N$
目标	$\ \mathbf{y} - \mathbf{X}\boldsymbol{\beta}\ ^2 + \lambda \ \boldsymbol{\beta}\ ^2$	$\ \mathbf{y} - \mathbf{K}\boldsymbol{\alpha}\ ^2 + \lambda \boldsymbol{\alpha}^\top \mathbf{K} \boldsymbol{\alpha}$
解析解	$(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}$	$(\mathbf{K} + \lambda \mathbf{I})^{-1} \mathbf{y}$
预测	$x_{\text{new}}^\top \hat{\boldsymbol{\beta}}$	$\mathbf{k}_{\text{new}}^\top \hat{\boldsymbol{\alpha}}$
计算量	$O(p^3 + p^2 N)$	$O(N^3)$

核形式的关键优势：计算复杂度与特征维度 p 完全无关——即使核隐式映射到无限维空间，实际求解始终是 $N \times N$ 的线性系统。代价是 $O(N^3)$ 对大规模数据不友好，后续章节（如 SVM 的 SMO 算法、高斯过程的稀疏近似）将讨论应对策略。

一般损失函数的推广。若 L 不是平方损失（如分类问题的 hinge loss 或交叉熵），则优化问题

$$\min_{\alpha} L(\mathbf{y}, \mathbf{K}\alpha) + \lambda \alpha^{\top} \mathbf{K} \alpha$$

通常无闭式解，但可用梯度下降或 Newton 法迭代求解。支持向量机（第 12 章）和核 Logistic 回归（第 4 章）恰是这一框架在不同损失函数下的特例。

更一般的分解 $\mathcal{H} = \mathcal{H}_0 \oplus \mathcal{H}_1$ ： $\mathcal{H}_0$ （多项式零空间，不惩罚）+ $\mathcal{H}_1$ （惩罚空间）。解为 $f(x) = \sum_j \beta_j h_j(x) + \sum_i \alpha_i K(x, x_i)$ 。

13.8.3 实例

平方误差损失： $\hat{\alpha} = (\mathbf{K} + \lambda \mathbf{I})^{-1} \mathbf{y}$, $\hat{\mathbf{f}} = \mathbf{K}(\mathbf{K} + \lambda \mathbf{I})^{-1} \mathbf{y} = (\mathbf{I} + \lambda \mathbf{K}^{-1})^{-1} \mathbf{y}$ （对比光滑样条的 $(\mathbf{I} + \lambda \mathbf{K})^{-1} \mathbf{y}$ ）。在空间统计中称为 Kriging 估计。

多项式核： $K(x, y) = (\langle x, y \rangle + 1)^d$ 。 $M = \binom{p+d}{d}$ 个基函数（可能 $\gg N$ ），但核表示只需 $O(N^3)$ ——这是**核技巧**的本质：隐式使用高维特征空间而不显式构造它。

高斯径向基核： $K(x, y) = e^{-\nu \|x - y\|^2}$ 。每个基函数 $k_m(x) = K(x, x_m)$ 是以训练点 x_m 为中心的 Gaussian。核尺度 ν 控制局部性： ν 越大 $\rightarrow$ 越局部 $\rightarrow$ 有效维数越高（图 5.14–5.15）。

薄板样条核： $K(x, y) = \|x - y\|^2 \log(\|x - y\|)$ （径向基函数形式的薄板样条）。

支持向量机（第 12 章）：二分类下使用 hinge loss：

$$\min_{\alpha_0, \alpha} \sum_{i=1}^N [1 - y_i f(x_i)]_+ + \frac{\lambda}{2} \alpha^{\top} \mathbf{K} \alpha,$$

非零 $\hat{\alpha}_i$ 对应的 x_i 即为**支持向量**。

13.8.4 实践指南：何时使用核方法

核方法并非万能工具。以下从数据规模、特征维度、任务需求三个维度给出实用判断标准。

核方法的理想适用场景

以下三个条件**同时成立**时，核方法通常是最优选择：

条件	原因
N 适中 ($10^2 \sim 10^4$)	$O(N^3)$ 的计算量是主要瓶颈。 $N > 10^4$ 时需用 Nyström 近似或随机 Fourier 特征，但实践中常被 XGBoost 取代
p 中等 ($5 \sim 100$)	p 太大时高斯核的距离在高维中坍塌（维数灾难）； p 很小时 (< 5) 样条或 GAM 更简单且可解释
非线性复杂且未知	确定存在非线性，但无法用简单参数形式（二次、对数等）捕捉——如生物标记物预测、信用评分、图像像素级分类

典型成功案例： $N = 500$ ， $p = 30$ ，分类问题中决策边界高度非线性——SVM with RBF 核是标准基线。

何时不应使用核方法

- **大样本** ($N > 10^5$): $O(N^3)$ 直接不可行。即使采用近似方法, XGBoost / LightGBM / 神经网络通常更快、精度相当或更好。
- **高维稀疏数据** ($p > 10^3$ ，多数特征为零): 高维中欧氏距离失去区分力，高斯核退化为近似常数矩阵。此时带 L_1 惩罚的线性模型或稀疏加性模型更实用。
- **需要强解释性**: $\hat{f}(x) = \sum \alpha_i K(x, x_i)$ 本质是「与训练点的加权相似度」，医生、风控人员等非技术受众通常无法理解。若解释性必需，优先考虑 GAM 或决策树。
- **特征有明确的物理含义和尺度**: 如果已知 $y \approx \log(x_1) + x_2^2$ 这类显式关系，直接做参数化建模比核方法更高效（更少参数、更低方差）。

EDA 中值得注意的信号

做探索性分析时，以下模式提示核方法可能优于线性或简单参数模型：

1. **线性回归残差图有系统结构**: 残差 vs 拟合值图呈现 U 形、波浪形或局部团簇，而非均匀随机散布——说明线性模型遗漏了非线性信号；
2. **变量间存在复杂互补性**: X_1 大且 X_2 中等时 Y 才高——这类交互难以用有限阶多项式捕捉，但 RBF 核能自然建模；
3. **样本量和维度落入「甜区」**: N 在数百至数千、 p 在数十量级——刚好是参数模型可能欠拟合、深度学习数据不足的交界地带。

快速决策表

数据画像	推荐方法
$N < 10^3, p < 20$, 需不确定性量化	高斯过程 (GP) / 核岭回归
$N < 10^4, p < 100$, 分类任务	SVM (RBF 核)
$N < 10^4, p < 100$, 回归任务	核岭回归 / Nyström 近似 GP
$N > 10^4$, 任意 p	XGBoost / LightGBM / 神经网络
$p > 500, N$ 任意	带 L_1 的线性模型 + 特征工程
$p < 10$, 需可解释性	GAM (样条) / 加性核模型

一般原则：核方法是中等规模非线性问题的首选工具之一，但在大规模数据和强解释性需求面前有明确边界。实践中常作为基线模型——先跑一个 SVM/GP，若性能不够再考虑更复杂的集成方法或深度学习。

13.9 小波光滑

小波提供了一种与样条互补的基函数字典：样条通过光滑性实现压缩，小波通过稀疏性实现压缩。

13.9.1 核心思想：时间-频率定位

样条擅长表示光滑函数（用少量基函数）；小波擅长表示「大部分平坦 + 少数突起」的信号（用少量 bumpy 基函数）。小波基能同时定位**时间**（突起在哪里）和**频率**（突起有多尖锐）——传统 Fourier 基只能定位频率。

13.9.2 多分辨率分析

小波基通过单个**尺度函数** $\phi(x)$ （父小波）和**母小波** $\psi(x)$ 的平移和缩放生成。以 Haar 小波为例：

$$\phi(x) = I(0 \leq x < 1), \quad \psi(x) = \phi(2x) - \phi(2x - 1) \text{ (在 } [0, \frac{1}{2}) \text{ 为 } +1, [\frac{1}{2}, 1) \text{ 为 } -1).$$

空间分解： $V_{j+1} = V_j \oplus W_j$ （ V_j = 分辨率 2^{-j} 的逼近空间， W_j = 细节空间）。迭代得多分辨率分解：

$$V_J = V_0 \oplus W_0 \oplus W_1 \oplus \cdots \oplus W_{J-1}.$$

V_0 是最粗逼近（Haar 下为常数）， $W_0, W_1, \dots$ 是递增分辨率的细节层。

Haar 基简单但不光滑，实践中更常用 **symmlet-p** 族：

- 支撑： $2p - 1$ 个连续区间（Haar 为 1）；

- 消失矩: p 个 ($\int \psi(x)x^j dx = 0, j = 0, \dots, p-1$), 使 V_0 可精确复现 p 阶多项式——类比光滑样条惩罚的零空间。




FIGURE 5.16. Some selected wavelets at different translations and dilations for the Haar and symmlet families. The functions have been scaled to suit the display.

图 13.9: Haar 和 symmlet 族在不同平移和尺度下的小波函数。函数已缩放以适配显示。
来源: ESL Figure 5.16。

13.9.3 小波变换的数学定义

设母小波 $\psi(x)$ 满足容许条件 $\int \psi(x)dx = 0$ 。通过平移和缩放生成一族基函数:

$$\psi_{j,k}(x) = 2^{j/2} \psi(2^j x - k), \quad j, k \in \mathbb{Z}, \quad (13.20)$$

其中 j 为尺度参数 (控制频率: j 越大 $\rightarrow$ 基函数越窄 $\rightarrow$ 频率越高), k 为平移参数 (控制时间位置)。因子 $2^{j/2}$ 保证所有基函数具有相同的 L^2 范数。

连续小波变换。函数 $f(x)$ 在尺度 j 和位置 k 处的小波系数为:

$$d_{jk} = \int_{-\infty}^{\infty} f(x) \psi_{j,k}(x) dx = \langle f, \psi_{j,k} \rangle.$$

离散小波变换 (DWT)。给定 $N = 2^J$ 个等间距观测 $y_i = f(x_i)$ ($i = 1, \dots, N$)，存在正交小波基矩阵 $\mathbf{W}$ ($N \times N$) 使得系数向量 $\mathbf{y}^*$ 和原始信号彼此由线性变换关联：

$$\mathbf{y}^* = \mathbf{W}^\top \mathbf{y} \quad (\text{正变换}), \quad \mathbf{y} = \mathbf{W} \mathbf{y}^* \quad (\text{逆变换}). \quad (13.21)$$

$\mathbf{y}^*$ 的前半部分对应粗尺度（低频），后半部分对应细尺度（高频）。正交性 $\mathbf{W}^\top \mathbf{W} = \mathbf{I}$ 保证变换可逆且保范数（Parseval 恒等式： $\|\mathbf{y}^*\| = \|\mathbf{y}\|$ ）。

多分辨率结构。小波系数 $\mathbf{y}^*$ 可按分辨率层级组织：

$$\mathbf{y}^* = (\underbrace{v_0}_{\text{最粗}}, \underbrace{w_0, w_1, \dots, w_{J-1}}_{\text{递增分辨率}}),$$

对应空间分解 $V_J = V_0 \oplus W_0 \oplus W_1 \oplus \dots \oplus W_{J-1}$ 。 v_0 是最粗尺度的逼近， w_j 包含尺度 2^{-j} 的细节信息。

13.9.4 自适应小波阈值 (Wavelet Shrinkage)

对一维离散信号 $\mathbf{y}$ ($N = 2^J$ 均匀样本)，设 $\mathbf{W}$ 为 $N \times N$ 正交小波基矩阵，小波变换 $\mathbf{y}^* = \mathbf{W}^\top \mathbf{y}$ 给出每个基上的系数。

SURE 收缩 (Donoho & Johnstone, 1994) 求解 Lasso 型问题：

$$\min_{\boldsymbol{\theta}} \|\mathbf{y} - \mathbf{W}\boldsymbol{\theta}\|^2 + 2\lambda \|\boldsymbol{\theta}\|_1.$$

由于 $\mathbf{W}$ 正交，解有显式软阈值规则：

$$\hat{\theta}_j = \text{sign}(y_j^*) (|y_j^*| - \lambda)_+. \quad (13.22)$$

即将系数向零平移 λ ，不足 λ 的置为零。常用阈值 $\lambda = \hat{\sigma} \sqrt{2 \log N}$ ——理由： N 个白噪声变量的最大绝对值约为 $\sigma \sqrt{2 \log N}$ ，低于此的系数大概率是噪声。

逆小波变换 $\hat{\mathbf{f}} = \mathbf{W}\hat{\boldsymbol{\theta}}$ 得光滑后信号。

13.9.5 小波 vs 光滑样条 (图 5.19)

	光滑样条	小波收缩
适应对象	整体光滑的信号	平坦 + 局部尖峰的信号
压缩方式	曲率惩罚 $\rightarrow$ 光滑	ℓ_1 阈值 $\rightarrow$ 稀疏
计算	$O(N)$	$O(N)$ (金字塔算法, 比 FFT 更快)

图 5.17 的 NMR 信号演示了完整流程：原始信号 $\rightarrow$ 小波变换（系数按尺度排列） $\rightarrow$ 软阈值去噪 $\rightarrow$ 逆变换重建。

图 5.19 对比了两类信号的拟合：NMR 尖峰信号中小波优于样条（精确定位尖峰，样条为迁就尖峰在整个域引入多余波动）；光滑信号中样条优于小波（小波为获得自适应性付出了额外方差的代价）。两者的选择取决于信号的光滑 vs 稀疏性质。




FIGURE 5.17. The top panel shows an NMR signal, with the wavelet-shrunk version superimposed in green. The lower left panel represents the wavelet transform of the original signal, down to V_4 , using the symmlet-8 basis. Each coefficient is represented by the height (positive or negative) of the vertical bar. The lower right panel represents the wavelet coefficients after being shrunk using the `wavelshrink` function in S-PLUS, which implements the SureShrink method of wavelet adaptation of Donoho and Johnstone.

图 13.10: 上图: NMR 信号 (黑) 与小波收缩后信号 (绿) 叠绘。左下: 使用 symmlet-8 基的原始信号小波变换系数 (V_0 至 V_4), 竖条高度 = 系数值 (正/负)。右下: 经 S-PLUS 的 SureShrink 方法收缩后的小波系数——大部分噪声尺度的系数被阈值化为零, 仅保留显著突起。来源: ESL Figure 5.17。





FIGURE 5.19. Wavelet smoothing compared with smoothing splines on two examples. Each panel compares the SURE-shrunk wavelet fit to the cross-validated smoothing spline fit.

图 13.11: 小波光滑与光滑样条的对比 (两例)。每面板对比 SURE-shrunk 小波拟合 (实线) 与交叉验证光滑样条拟合 (虚线)。左: NMR 尖峰信号——小波精确定位尖峰, 样条为捕捉尖峰产生额外波动。右: 光滑信号——样条以更少有效参数获得相近拟合, 小波因自适应性付出方差代价。来源: ESL Figure 5.19。

注记 13.3. 二维小波是现代图像压缩（如 JPEG2000）的核心技术。本章参考文献见 de Boor (1978)、Wahba (1990)、Daubechies (1992)、Donoho & Johnstone (1994) 等。

13.10 本章小结

下图总结了本章从线性模型到核方法的完整方法论脉络：



本章核心要点：

- (1) **基展开**是将非线性建模统一纳入线性框架的核心范式： $f(X) = \sum_m \beta_m h_m(X)$ 。基函数一经选定，所有线性方法（最小二乘、MLE、IRLS）照常使用。
- (2) **样条**是最经典的基展开实例。一维样条从分段多项式出发，通过截断幂基 $h_{M+\ell}(X) = (X - \xi_\ell)_+^{M-1}$ 实现节点的平滑过渡。三次样条（ $M = 4$ ）是实践标准——人眼无法察觉节点处的三阶不连续性。
- (3) **自然三次样条**通过边界线性约束 $f''(\xi_1) = f''(\xi_K) = 0$ 释放 4 个自由度，将基函数数从 $K + 4$ 压缩为 K ，显著降低边界方差——是本章最重要的实用改进。
- (4) **光滑样条**将节点选择从离散决策转化为连续调节：每个 x_i 放一个节点 $+\lambda \int (f'')^2$ 惩罚。解为节点在所有唯一 x_i 处的自然三次样条，有效自由度 $\text{df}_\lambda = \text{trace}(\mathbf{S}_\lambda) \in [2, N]$ 。CV/GCV 自动选择 λ ，免去人工调参。
- (5) **RKHS 与核方法**将样条纳入更广阔的正则化框架。正定核 $K(x, y)$ 定义一个再生核 Hilbert 空间 $\mathcal{H}_K$ ，其范数天然偏好低频函数。**表示定理**将无穷维优化 $\min_{f \in \mathcal{H}_K} \sum L(y_i, f(x_i)) + \lambda \|f\|_{\mathcal{H}_K}^2$ 化为 N 维问题 $\min_{\boldsymbol{\alpha}} L(\mathbf{y}, \mathbf{K}\boldsymbol{\alpha}) + \lambda \boldsymbol{\alpha}^\top \mathbf{K}\boldsymbol{\alpha}$ 。高斯核 $K(x, y) = e^{-\nu \|x-y\|^2}$ 隐式映射到无限维空间，是实践中最重要的核函数。
- (6) **小波**通过 ℓ_1 阈值化（软阈值）实现稀疏压缩，与样条的 ℓ_2 光滑惩罚形成互补。小波适合平坦 + 局部尖峰的信号（如 NMR、图像边缘），计算复杂度 $O(N)$ （金字塔算法，比 FFT 更快）。两者选择的根本判据：信号是整体光滑（用样条）还是局部稀疏（用小波）。
- (7) **多维推广**面临维数灾难： d 维张量积样条需 $O(M^d)$ 个基函数。加性模型 $f(X) = \alpha + \sum_j f_j(X_j)$ 降至 $O(dM)$ ，但损失交互效应。ANOVA 分解提供中间地带：按需添加指定交互项。实践中从加性出发，以残差诊断和交叉验证为指导逐步增加交互。
- (8) **复杂度控制的统一视角**：所有方法——限制基函数数（样条）、连续惩罚参数（光滑样条、核岭回归）、 ℓ_1 稀疏化（Lasso、小波阈值）——本质上都是在偏差-方差曲线上寻找最优工作点。本章建立了理解后续章节（MARS、boosting、GAM、SVM、神经网络）所需的核心概念框架。

第十四章 核光滑方法

本章介绍一类基于记忆（memory-based）的回归与分类技术：在每个查询点 x_0 处，仅使用 x_0 附近的观测来拟合一个局部简单模型，并使得整体估计 $\hat{f}(X)$ 在 $\mathbb{R}^p$ 上光滑。这种局部化通过核函数（kernel） $K_\lambda(x_0, x)$ 实现——给 x_i 分配一个随其到 x_0 距离递减的权重，参数 λ 控制邻域宽度。

注意区分：本章的「核」主要用于局部化（localization），与第 5.8、12、14.5.4、18.5 节中计算高维内积的「核方法」（kernel methods）不同，尽管在 §6.7 末尾会建立一些联系。

这类方法几乎不需要训练——所有工作都在评估时完成，唯一需要从训练数据确定的参数是 λ 。

14.1 一维核光滑器

14.1.1 从 k -最近邻平均到核加权平均

在第 2 章中， k -最近邻平均

$$\hat{f}(x_0) = \text{Ave}(y_i \mid x_i \in N_k(x_0)) \quad (14.1)$$

被用作回归函数 $\mathbb{E}[Y \mid X = x_0]$ 的估计，其中 $N_k(x_0)$ 是距离 x_0 最近的 k 个点的集合。其思想是将条件期望的定义「松弛」——在目标点的邻域内做平均。

然而 k -NN 平均存在一个明显缺陷： $\hat{f}(x_0)$ 对 x_0 是不连续的。当 x_0 从左向右移动时， k -最近邻集合保持不变，直至某个右侧点比邻域中最远的左侧点更近——此时邻域成员发生替换，导致平均值跳跃。图 6.1 左面板展示了这种「颠簸」的绿色曲线。

Nadaraya–Watson 核加权平均通过给邻域内各点分配平滑递减的权重来解决此问题：

$$\hat{f}(x_0) = \frac{\sum_{i=1}^N K_\lambda(x_0, x_i) y_i}{\sum_{i=1}^N K_\lambda(x_0, x_i)} \quad (14.2)$$

其中 $K_\lambda(x_0, x_i)$ 是核函数。使用 Epanechnikov 二次核时，拟合函数变为连续的且相当光滑（图 6.1 右面板）。




FIGURE 6.1. In each panel 100 pairs x_i, y_i are generated at random from the blue curve with Gaussian errors: $Y = \sin(4X) + \varepsilon$, $X \sim U[0, 1]$, $\varepsilon \sim N(0, 1/3)$. In the left panel the green curve is the result of a 30-nearest-neighbor running-mean smoother. The red point is the fitted constant $\hat{f}(x_0)$, and the red circles indicate those observations contributing to the fit at x_0 . The solid yellow region indicates the weights assigned to observations. In the right panel, the green curve is the kernel-weighted average, using an Epanechnikov kernel with (half) window width $\lambda = 0.2$.

图 14.1: 每面板中 100 对 (x_i, y_i) 由蓝色曲线加高斯误差随机生成: $Y = \sin(4X) + \varepsilon$, $X \sim U[0, 1]$, $\varepsilon \sim N(0, 1/3)$ 。左面板: 绿色曲线是 30-最近邻滑动平均光滑器的结果。红点是拟合的常数 $\hat{f}(x_0)$, 红色圆圈标示了参与 x_0 处拟合的观测。黄色实心区域表示分配给各观测的权重。右面板: 绿色曲线是核加权平均, 使用 Epanechnikov 核, 半窗宽 $\lambda = 0.2$ 。

14.1.2 核函数的形式

一般地，核函数可写为

$$K_\lambda(x_0, x) = D\left(\frac{|x - x_0|}{h_\lambda(x_0)}\right) \quad (14.3)$$

其中 $D(\cdot)$ 是核函数的具体形状， $h_\lambda(x_0)$ 是宽度函数（width function）。

- **固定宽度（metric window）**: $h_\lambda(x_0) = \lambda$ 为常数，邻域宽度不随 x_0 变化。
- **最近邻宽度**: $h_k(x_0) = |x_0 - x_{[k]}|$ ，其中 $x_{[k]}$ 是距离 x_0 第 k 近的点，邻域大小 k 取代 λ 作为参数。

14.1.3 三种常用核

在介绍具体核之前，先明确**紧支撑（compact support）**的数学含义：函数 f 的支撑集定义为 $\text{supp}(f) = \overline{\{x \mid f(x) \neq 0\}}$ （即非零值集合的闭包）。若 $\text{supp}(f)$ 是紧集（在 $\mathbb{R}^d$ 中等价于有界闭集），则称 f 具有**紧支撑**。直观地说，紧支撑函数仅在有限范围内非零，范围之外恒为零——这对于结合最近邻窗宽使用的核是必要的。

- **Epanechnikov 核**（紧支撑，边界处不可导）：

$$D(t) = \begin{cases} \frac{3}{4}(1 - t^2), & |t| \leq 1 \\ 0, & \text{否则} \end{cases} \quad (14.4)$$

- **Tri-cube 核**（紧支撑，边界处有二阶连续导数，顶部更平坦）：

$$D(t) = \begin{cases} (1 - |t|^3)^3, & |t| \leq 1 \\ 0, & \text{否则} \end{cases} \quad (14.5)$$

- **Gaussian 核**（非紧支撑，无穷可微）：

$$D(t) = \phi(t) = \frac{1}{\sqrt{2\pi}} e^{-t^2/2} \quad (14.6)$$

标准差充当窗口宽度的角色。

14.1.4 实践中的注意事项

1. **光滑参数 λ 的选择**: λ 大 $\rightarrow$ 方差低（平均更多观测）但偏差高（假设窗内函数为常数）。
2. **固定宽度 vs 最近邻宽度的行为差异**:

- 固定宽度：偏差保持恒定，但方差与局部密度成反比；
 - 最近邻宽度：方差保持恒定，绝对偏差与局部密度成反比。
3. **结 (ties) 的处理**：当 x_i 存在重复值时，可以先对相同 x 值处的 y_i 做平均，并对合并后的观测赋予额外的权重 w_i 。
 4. **观测权重 w_i** ：将 w_i 乘以核权重后计算加权平均；在最近邻邻域中，使用权重总量 k （而非点数 k ）来定义邻域。
 5. **边界问题**：固定宽度窗在边界处包含的点更少，而最近邻窗在边界处会变宽。

14.2 局部线性回归

14.2.1 边界偏差问题

尽管核加权平均已经比原始滑动平均光滑得多，但在**定义域边界附近**仍存在严重的偏差问题（图 6.3 左面板）。原因在于：边界处核是非对称的——邻域内大多数观测的均值高于目标点，因此即使加权后均值仍向上偏。

实际上，如果 X 值不是等间距的，在定义域内部也可能存在类似偏差（通常程度较轻）。通过在局部拟合**直线**而非常数，可以精确到一阶地消除这种偏差。

14.2.2 局部加权最小二乘

在每个目标点 x_0 处求解一个独立的加权最小二乘问题：

$$\min_{\alpha(x_0), \beta(x_0)} \sum_{i=1}^N K_{\lambda}(x_0, x_i) [y_i - \alpha(x_0) - \beta(x_0)x_i]^2 \quad (14.7)$$

估计值为 $\hat{f}(x_0) = \hat{\alpha}(x_0) + \hat{\beta}(x_0)x_0$ 。注意：虽然拟合了整个线性模型，但只在单点 x_0 处使用。

14.2.3 矩阵形式与等价核

定义 $\mathbf{b}(x)^T = (1, x)$ 。设 $\mathbf{B}$ 为 $N \times 2$ 回归矩阵（第 i 行为 $\mathbf{b}(x_i)^T$ ）， $\mathbf{W}(x_0)$ 为 $N \times N$ 对角矩阵，第 i 个对角元为 $K_{\lambda}(x_0, x_i)$ 。则

$$\hat{f}(x_0) = \mathbf{b}(x_0)^T (\mathbf{B}^T \mathbf{W}(x_0) \mathbf{B})^{-1} \mathbf{B}^T \mathbf{W}(x_0) \mathbf{y} = \sum_{i=1}^N l_i(x_0) y_i \quad (14.8)$$

权重 $l_i(x_0)$ 结合了核权重 $K_{\lambda}(x_0, \cdot)$ 和最小二乘操作，称为**等价核 (equivalent kernel)**。 $\hat{f}(x_0)$ 对 y_i 是线性的（ $l_i(x_0)$ 不依赖于 y_i ）。




FIGURE 6.3. The locally weighted average has bias problems at or near the boundaries of the domain. The true function is approximately linear here, but most of the observations in the neighborhood have a higher mean than the target point, so despite weighting, their mean will be biased upwards. By fitting a locally weighted linear regression (right panel), this bias is removed to first order.

图 14.2: 局部加权平均在定义域边界处或附近存在偏差问题。此处的真实函数近似线性, 但邻域内大多数观测的均值高于目标点, 因此即使加权后, 其均值仍向上偏。通过在局部拟合加权线性回归 (右面板), 这一偏差被精确到一阶地消除。

14.2.4 自动核木工 (Automatic Kernel Carpentry)

历史上, Nadaraya–Watson 等局部平均核方法的偏差通过直接修改核函数来修正——这些修正基于渐近 MSE 理论, 不仅实现繁琐, 而且在有限样本下仅是近似的。局部线性回归能自动修改核以精确到一阶地校正偏差, 这一现象被称为「自动核木工」。

考虑 $\mathbb{E}[\hat{f}(x_0)]$ 的展开 (利用局部回归的线性和 f 在 x_0 处的 Taylor 展开):

$$\begin{aligned}\mathbb{E}[\hat{f}(x_0)] &= \sum_{i=1}^N l_i(x_0) f(x_i) \\ &= f(x_0) \underbrace{\sum_{i=1}^N l_i(x_0)}_{=1} + f'(x_0) \underbrace{\sum_{i=1}^N (x_i - x_0) l_i(x_0)}_{=0} + \frac{f''(x_0)}{2} \sum_{i=1}^N (x_i - x_0)^2 l_i(x_0) + R\end{aligned}\tag{14.9}$$

其中余项 R 涉及 f 的三阶及以上导数, 在适当光滑性假设下通常很小。对于局部线性回归, 可证 $\sum l_i(x_0) = 1$ 且 $\sum (x_i - x_0) l_i(x_0) = 0$ (习题 6.2), 因此偏差 $\mathbb{E}[\hat{f}(x_0)] - f(x_0)$ 仅依赖于 f 展开中的二阶及更高阶项——一阶偏差被完全消除。

Q: 自动核木工 (Automatic Kernel Carpentry) 到底在说什么?

可以从「等价核」的角度来理解。Nadaraya–Watson 核加权平均本质上等价于用一

个给定的核 $D(\cdot)$ 做局部常数拟合。这个固定形状的核在边界处不对称，导致一阶偏差。历史上人们试图通过手工设计「高阶核」(higher-order kernels) 来修正——让核函数满足特定的矩条件（如 $\int tK(t)dt = 0$ ），从而消除低阶偏差。但这需要针对不同情况手工调整核的形状和参数，实现繁琐，且只在渐近意义下精确。

局部线性回归的巧妙之处在于：它不直接修改 K_λ ，而是通过最小二乘的代数结构自动生成了正确的等价核 $l_i(x_0)$ 。从式 (14.9) 可以看到，只要等价权重满足 $\sum l_i = 1$ 和 $\sum (x_i - x_0)l_i = 0$ ，一阶偏差就自动消失——而局部线性回归的最小二乘解恰好保证这两个条件成立，无需任何手工调整。换句话说，与其自己费劲「雕琢」核函数的形状来消偏差，不如让最小二乘帮你自动「打磨」出正确的权重——这就是「自动核木工」(automatic kernel carpentry) 这个比喻的含义。

Q：在实践中是怎么利用这个方法的？

实践者几乎不需要关心核木工的细节——它对你完全透明。你只需要在使用局部回归软件时选择**局部线性** ($d = 1$) 而非**局部常数** ($d = 0$)，偏差校正就自动生效。具体来说：

- 在 R 的 `loess()` 或 `locfit` 中，设置 `degree=1`（通常这就是默认值）；
- 在 Python 的 `statsmodels.nonparametric.KernelReg` 中，选择 `reg_type='ll'` (local linear)。

你实际要做的决策只有两个：(1) 选什么核（tri-cube 是常用默认，紧支撑且边界光滑）；(2) 选多大窗宽 λ （通过交叉验证确定）。选好之后直接拟合，边界处的偏差自动被一阶校正——不需要你手工设计高阶核，也不需要区分边界和内部做不同处理。这就是自动核木工给实践者带来的便利：用局部线性替代局部常数几乎只有收益（以微小的方差增加换取大幅的边界偏差降低），所以局部线性已经成为了局部多项式回归的事实标准。

14.3 局部多项式回归

14.3.1 d 阶局部多项式拟合

将局部拟合从线性推广到任意 d 次多项式：

$$\min_{\alpha(x_0), \beta_j(x_0)} \sum_{i=1}^N K_\lambda(x_0, x_i) \left[y_i - \alpha(x_0) - \sum_{j=1}^d \beta_j(x_0) x_i^j \right]^2 \quad (14.10)$$

估计值为 $\hat{f}(x_0) = \hat{\alpha}(x_0) + \sum_{j=1}^d \hat{\beta}_j(x_0) x_0^j$ 。类似式 (14.9) 的展开表明，偏差仅包含 $d+1$ 阶及以上的分量（习题 6.2）。

14.3.2 削峰填谷效应

局部线性拟合在真实函数有曲率的区域存在偏差——这一现象称为「削峰填谷 (trimming the hills and filling the valleys)」：线性拟合倾向于低估峰值、高估谷底。局部二次回归通常能够校正这种曲率偏差（图 6.5）。




FIGURE 6.5. Local linear fits exhibit bias in regions of curvature of the true function. Local quadratic fits tend to eliminate this bias.

图 14.3: 局部线性拟合在真实函数曲率区域表现出偏差。局部二次拟合倾向于消除此偏差。左面板中红色曲线（局部线性）在曲率处偏离绿色真实曲线，右面板中局部二次拟合更好地追踪了曲率。

14.3.3 偏差-方差权衡

偏差降低的代价是方差增大。假设模型 $y_i = f(x_i) + \varepsilon_i$, $\varepsilon_i \sim \text{i.i.d.}(0, \sigma^2)$, 则

$$\text{Var}(\hat{f}(x_0)) = \sigma^2 \|\mathbf{l}(x_0)\|^2 \quad (14.11)$$

其中 $\mathbf{l}(x_0)$ 是等价核权重向量。可证 $\|\mathbf{l}(x_0)\|^2$ 随 d 增加而增大（习题 6.3），因此存在偏差-方差权衡。

图 6.6 展示了局部常数、线性、二次回归的方差函数曲线。

14.3.4 奇数阶 vs 偶数阶：实践建议

- 局部线性拟合 ($d = 1$) 能以适度的方差代价在边界处大幅降低偏差；局部二次拟合 ($d = 2$) 在边界处对偏差改善不大，但方差增加很多。
- 局部二次拟合最有助于减少定义域内部的曲率偏差。

- 渐近分析表明，奇数阶局部多项式优于偶数阶——这主要是因为渐近 MSE 由边界效应主导。

通常由应用场景决定拟合阶数：若关注外推，则边界更重要，局部线性拟合更可靠。不推荐在不同区域使用不同阶数的策略。

14.4 核宽度的选择

14.4.1 λ 在不同核中的含义

- Epanechnikov 或 tri-cube 核（固定宽度）： λ 是支撑区域的半径。
- Gaussian 核： λ 是标准差。
- k -最近邻： λ 是近邻数 k ，通常表示为总训练样本的比例（span） k/N 。

14.4.2 偏差-方差权衡与窗宽

改变平均窗宽时存在自然的偏差-方差权衡，以局部平均为例最为直观：

- **窄窗：** $\hat{f}(x_0)$ 仅对 x_0 附近少数 y_i 做平均，方差较大（接近单个 y_i 的方差）；偏差较小——因为每个 $\mathbb{E}(y_i) = f(x_i)$ 都接近 $f(x_0)$ 。
- **宽窗：** $\hat{f}(x_0)$ 的方差因平均效应而较小；偏差较大——使用了远离 x_0 的 x_i ，无法保证 $f(x_i)$ 接近 $f(x_0)$ 。

对局部回归估计（如局部线性）类似：窗宽趋于零时，估计趋近于插值训练数据的分段线性函数；窗宽趋于无穷时，拟合趋近于全局线性最小二乘拟合。

14.4.3 线性估计量与光滑矩阵

局部回归光滑器是线性估计量： $\hat{\mathbf{f}} = \mathbf{S}_\lambda \mathbf{y}$ 。光滑矩阵 $\mathbf{S}_\lambda$ 由等价核构建，其第 ij 个元素为 $\{\mathbf{S}_\lambda\}_{ij} = l_i(x_j)$ 。

为什么称 $\mathbf{S}_\lambda$ 为「光滑」算子？核 K_λ 去哪了？

核 K_λ 并没有消失——它被「吸收」进了 $\mathbf{S}_\lambda$ 。从局部线性回归的矩阵形式

$$\hat{f}(x_0) = \mathbf{b}(x_0)^T (\mathbf{B}^T \mathbf{W}(x_0) \mathbf{B})^{-1} \mathbf{B}^T \mathbf{W}(x_0) \mathbf{y}$$

可以看到，核权重通过 $\mathbf{W}(x_0)$ （对角元为 $K_\lambda(x_0, x_i)$ ）进入计算，再经过最小二乘的代数运算，最终凝练为等价核权重 $l_i(x_0)$ 。 $\mathbf{S}_\lambda$ 的第 j 列正是对所有 x_j 的等价核在这些训练点上的取值排列。

称 $\mathbf{S}_\lambda$ 为「光滑矩阵」(smoother matrix) 是因为: (1) 从效果上看, $\hat{\mathbf{f}} = \mathbf{S}_\lambda \mathbf{y}$ 确实在光滑原始响应 y_i ——把带噪声的点云变成一条平滑曲线; (2) 这一写法是统一的框架——不仅核光滑器, 光滑样条、回归样条等所有线性光滑方法都可以写成 $\hat{\mathbf{f}} = \mathbf{S}_\lambda \mathbf{y}$ 的形式, 便于用统一语言讨论自由度、交叉验证等概念。核的作用在构造 $\mathbf{S}_\lambda$ 的阶段已经完成, 后续分析直接使用 $\mathbf{S}_\lambda$ 即可。

交叉验证 (CV) 在局部回归中的具体做法

因为 $\hat{\mathbf{f}} = \mathbf{S}_\lambda \mathbf{y}$ 是线性估计量, 交叉验证有非常简洁的计算公式, 无需反复重新拟合。

留一交叉验证 (LOOCV)。记 $\hat{f}^{(-i)}(x_i)$ 为去掉第 i 个观测后模型在 x_i 处的预测。LOOCV 准则为

$$\text{CV}(\lambda) = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{f}^{(-i)}(x_i))^2$$

由于 $\hat{f}^{(-i)}(x_i)$ 可写为 $\hat{f}^{(-i)}(x_i) = \sum_{j \neq i} \frac{S_{ij}}{1 - S_{ii}} y_j$ (习题 6.7), 经过代数推导得到捷径公式:

$$\text{CV}(\lambda) = \frac{1}{N} \sum_{i=1}^N \left[\frac{y_i - \hat{f}(x_i)}{1 - S_{ii}} \right]^2 \quad (14.12)$$

这意味着只需拟合一次全模型得到 $\hat{\mathbf{f}}$ 和 S_{ii} ($\mathbf{S}_\lambda$ 的对角元), 即可计算 LOOCV——极大地节省了计算量。

广义交叉验证 (GCV)。GCV 将 S_{ii} 替换为其平均值 $\frac{1}{N} \sum_i S_{ii} = \frac{\text{tr}(\mathbf{S}_\lambda)}{N} = \frac{\text{df}_\lambda}{N}$:

$$\text{GCV}(\lambda) = \frac{1}{N} \sum_{i=1}^N \left[\frac{y_i - \hat{f}(x_i)}{1 - \text{tr}(\mathbf{S}_\lambda)/N} \right]^2 = \frac{\text{RSS}/N}{(1 - \text{df}_\lambda/N)^2} \quad (14.13)$$

GCV 的优势在于: (1) 不需要逐个计算 S_{ii} , 只需 $\text{tr}(\mathbf{S}_\lambda)$; (2) 具有某些不变性 (如在正交变换下不变); (3) 在许多情况下与 LOOCV 表现接近。

k -折交叉验证。将数据随机分为 k 个大小相近的折, 每次留一折作为验证集, 其余 $k-1$ 折训练。计算量比 LOOCV 小 (只需 k 次拟合), 但无法使用上述捷径公式。实践中 $k=5$ 或 $k=10$ 较为常用。

选择 λ 时, 在 λ 的候选网格上计算 CV/GCV 得分, 选择使得分最小的 λ 。这一过程对局部平均和局部回归均适用。

14.4.4 有效自由度

有效自由度定义为 $\text{df}_\lambda = \text{tr}(\mathbf{S}_\lambda)$, 可用于校准光滑量。

14.5 $\mathbb{R}^p$ 中的局部回归

核光滑和局部回归可以非常自然地推广到二维及以上。Nadaraya-Watson 核光滑器使用 p 维核提供的权重在局部拟合常数; 局部线性回归则通过加权最小二乘在 X 空间中局部拟合超平面, 实现简单且边界性能优于局部常数拟合。




FIGURE 6.7. *Equivalent kernels for a local linear regression smoother (tri-cube kernel; orange) and a smoothing spline (blue), with matching degrees of freedom. The vertical spikes indicates the target points.*

图 14.4: 局部线性回归光滑器 (tri-cube 核, 橙色) 与光滑样条 (蓝色) 的等价核, 两者具有匹配的自由度。竖直尖刺标示目标点。局部回归光滑器的 span 为 40%, 对应 $df = \text{tr}(\mathbf{S}_\lambda) = 5.86$; 光滑样条被校准到相同 df, 两者的等价核定性上高度相似。

14.5.1 多项式向量与径向核

设 $\mathbf{b}(X)$ 为 X 中最大次数为 d 的多项式项向量。例如:

- $d = 1, p = 2$: $\mathbf{b}(X) = (1, X_1, X_2)$;
- $d = 2, p = 2$: $\mathbf{b}(X) = (1, X_1, X_2, X_1^2, X_2^2, X_1X_2)$;
- $d = 0$: $\mathbf{b}(X) = 1$ (退化为局部常数)。

在每个 $x_0 \in \mathbb{R}^p$ 处求解

$$\min_{\beta(x_0)} \sum_{i=1}^N K_\lambda(x_0, x_i) (y_i - \mathbf{b}(x_i)^T \beta(x_0))^2 \quad (14.14)$$

得到拟合 $\hat{f}(x_0) = \mathbf{b}(x_0)^T \hat{\beta}(x_0)$ 。

核通常采用径向函数, 如径向 Epanechnikov 或 tri-cube 核:

$$K_\lambda(x_0, x) = D \left(\frac{\|x - x_0\|}{\lambda} \right) \quad (14.15)$$

其中 $\|\cdot\|$ 为欧氏距离。由于欧氏距离依赖于各坐标的单位, 最合理的做法是先在平滑前将每个预测变量标准化 (如标准化到单位标准差)。

14.5.2 高维中的边界问题与维数灾难

边界效应在一维平滑中是一个问题, 但在二维或更高维中更为严重——边界上点的比例更大。事实上, 维数灾难的一个表现就是: 随着维数增长, 靠近边界的点的比例趋

近于 1。直接修改核以适应二维边界非常繁琐（尤其对于不规则边界），而局部多项式回归能在任意维度下无缝地完成所需阶数的边界校正。

然而，局部回归在维数远高于 2 或 3 时变得不太有用。第 2 章已详细讨论过维数问题：随着维数增加，不可能同时保持局部性（低偏差）和邻域内有足够的样本量（低方差），除非总样本量随 p 指数增长。此外， $\hat{f}(X)$ 的可视化在高维也变得困难——而这往往是平滑的主要目标之一。从数据分析的角度看，条件图（conditional plots）远比散点云和线框图更有用（图 6.9 的 trellis 展示）。

14.6 $\mathbb{R}^p$ 中的结构化局部回归模型

当维数与样本量之比不利时，局部回归的帮助有限——除非我们愿意对模型施加一些结构性假设。

14.6.1 结构化核

一种思路是修改核函数。默认的球形核（式 14.15）对各坐标赋予等权重，因此自然的默认策略是将每个变量标准化到单位标准差。更一般的方法是用一个半正定矩阵 $\mathbf{A}$ 对不同坐标加权：

$$K_{\lambda, \mathbf{A}}(x_0, x) = D \left(\frac{(x - x_0)^T \mathbf{A} (x - x_0)}{\lambda} \right) \quad (14.16)$$

通过对 $\mathbf{A}$ 施加适当的限制，可以降权或忽略某些坐标或方向。例如，若 $\mathbf{A}$ 为对角阵，则可以增大或减小单个预测变量 X_j 的影响。当预测变量多且高度相关时（如来自数字化模拟信号或图像），可利用预测变量的协方差函数来定制度量 $\mathbf{A}$ ，使对高频对比的关注减少。也有方法尝试学习多维核的参数（如第 11 章中的投影寻踪回归）。

14.6.2 结构化回归函数

我们试图在 $\mathbb{R}^p$ 中拟合 $f(X_1, X_2, \dots, X_p)$ ，其中可能存在各种交互。自然的思路是考虑方差分析（ANOVA）分解：

$$f(X_1, \dots, X_p) = \alpha + \sum_j g_j(X_j) + \sum_{k < \ell} g_{k\ell}(X_k, X_\ell) + \dots \quad (14.17)$$

然后通过去掉某些高阶项来引入结构。

可加模型仅保留主效应项： $f(X) = \alpha + \sum_{j=1}^p g_j(X_j)$ 。二阶模型最多包含二阶交互项，以此类推。第 9 章描述了用于拟合此类低阶交互模型的**迭代 backfitting 算法**。以可加模型为例：若假设除第 k 项外所有项已知，则可通过 $Y - \sum_{j \neq k} g_j(X_j)$ 对 X_k 的局部回归来估计 g_k ；轮流对每个函数重复此操作直至收敛。关键细节是：在任何阶段都只需一维局部回归。

14.6.3 变系数模型

结构化模型的一个重要特例是**变系数模型** (varying coefficient models)。将 p 个预测变量划分为集合 $(X_1, \dots, X_q)$ ($q < p$) 和 Z , 假设条件线性模型:

$$f(X) = \alpha(Z) + \beta_1(Z)X_1 + \dots + \beta_q(Z)X_q \quad (14.18)$$

对给定的 Z , 这是线性模型, 但每个系数可随 Z 变化。自然地通过局部加权最小二乘拟合:

$$\min_{\alpha(z_0), \beta(z_0)} \sum_{i=1}^N K_\lambda(z_0, z_i) (y_i - \alpha(z_0) - x_{1i}\beta_1(z_0) - \dots - x_{qi}\beta_q(z_0))^2 \quad (14.19)$$

图 6.10–6.11 以人体主动脉数据为例: 将主动脉直径建模为年龄的线性函数, 但允许系数随性别和沿主动脉的深度变化。

14.7 局部似然与其他模型

局部回归和变系数模型的概念非常广泛: 只要拟合方法支持观测权重, 任何参数模型都可以「局部化」。

14.7.1 局部似然

设每个观测 y_i 关联一个参数 $\theta_i = \theta(x_i) = x_i^T \beta$, 基于对数似然 $l(\beta) = \sum_i l(y_i, x_i^T \beta)$ 对 β 做推断。通过使用 x_0 处的局部似然, 可以对 $\theta(x_0) = x_0^T \beta(x_0)$ 做更灵活的推断:

$$l(\beta(x_0)) = \sum_{i=1}^N K_\lambda(x_0, x_i) l(y_i, x_i^T \beta(x_0)) \quad (14.20)$$

许多似然模型——特别是广义线性模型家族 (包括 logistic 和对数线性模型) ——以线性方式引入协变量。局部似然允许从全局线性模型松弛到局部线性模型。

进一步, 定义 θ 的变量和用于定义局部似然的变量可以不同:

$$l(\theta(z_0)) = \sum_{i=1}^N K_\lambda(z_0, z_i) l(y_i, \eta(x_i, \theta(z_0))) \quad (14.21)$$

例如 $\eta(x, \theta) = x^T \theta$ 是 x 中的线性模型——这将通过最大化局部似然来拟合变系数模型 $\theta(z)$ 。

14.7.2 局部自回归时间序列

k 阶自回归模型 $y_t = \beta_0 + \beta_1 y_{t-1} + \dots + \beta_k y_{t-k} + \varepsilon_t$ 。记滞后集 $z_t = (y_{t-1}, \dots, y_{t-k})$, 模型形如标准线性模型 $y_t = z_t^T \beta + \varepsilon_t$ 。使用核 $K(z_0, z_t)$ 做局部最小二乘拟合, 使模型可随序列的短期历史变化——这有别于按时间加窗的传统动态线性模型。

14.7.3 局部多类 Logistic 回归

以第 4 章的多类线性 logistic 回归模型为例。数据包含特征 x_i 和类别响应 $g_i \in \{1, \dots, J\}$, 线性模型为

$$\Pr(G = j \mid X = x) = \frac{e^{\beta_{j0} + \beta_j^T x}}{1 + \sum_{k=1}^{J-1} e^{\beta_{k0} + \beta_k^T x}} \quad (14.22)$$

其局部对数似然可写为 ($\beta_{j0} = 0, \beta_j = 0$, 且局部回归在 x_0 处做了中心化):

$$\sum_{i=1}^N K_\lambda(x_0, x_i) \left\{ \beta_{g_i 0}(x_0) + \beta_{g_i}(x_0)^T (x_i - x_0) - \log \left[1 + \sum_{k=1}^{J-1} \exp(\beta_{k0}(x_0) + \beta_k(x_0)^T (x_i - x_0)) \right] \right\} \quad (14.23)$$

中心化后, x_0 处的拟合后验概率简化为

$$\widehat{\Pr}(G = j \mid X = x_0) = \frac{e^{\hat{\beta}_{j0}(x_0)}}{1 + \sum_{k=1}^{J-1} e^{\hat{\beta}_{k0}(x_0)}} \quad (14.24)$$

图 6.12 展示了用局部线性 logistic 模型对心脏病数据的两个风险因子分别拟合的结果——这是一种检测非线性的有用筛查工具。由于 CHD 是二值指标, 也可以直接对二值响应做平滑来估计条件概率 (相当于局部常数 logistic 回归, 习题 6.5); 但为了享受局部线性平滑的偏差校正, 在无约束的 logit 尺度上操作更为自然。此外, 局部 logistic 回归同样可以计算参数估计及其标准误, 从而得到逐点标准误带。

14.8 核密度估计与分类

核密度估计是一种无监督学习过程, 历史早于核回归。它也自然地引出一类简单的非参数分类方法。

14.8.1 核密度估计

假设有来自概率密度 $f_X(x)$ 的随机样本 $x_1, \dots, x_N$, 欲在点 x_0 处估计 f_X 。类似之前的论证, 自然的局部估计为

$$\hat{f}_X(x_0) = \frac{\#\{x_i \in N(x_0)\}}{N\lambda} \quad (14.25)$$

其中 $N(x_0)$ 是 x_0 周围宽度为 λ 的小邻域。此估计是颠簸的, 更光滑的 **Parzen** 估计被优先采用:

$$\hat{f}_X(x_0) = \frac{1}{N\lambda} \sum_{i=1}^N K_\lambda(x_0, x_i) \quad (14.26)$$

即每个点 x_0 处的密度估计是各核在该点的平均贡献。

若取 K_λ 为 Gaussian 核 ϕ_λ (均值为零、标准差为 λ)，则 Parzen 估计可写为卷积形式：

$$\hat{f}_X(x) = \frac{1}{N} \sum_{i=1}^N \phi_\lambda(x - x_i) = (\hat{F} \star \phi_\lambda)(x) \quad (14.27)$$

其中 $\hat{F}$ 是经验分布 (在每个观测 x_i 处放置质量 $1/N$)。这意味着核密度估计本质上是对颠簸的经验分布 $\hat{F}$ 用 ϕ_λ 做了光滑——等价于给每个 x_i 加上独立 Gaussian 噪声。

在 $\mathbb{R}^p$ 中，Gaussian 密度估计的自然推广是使用 Gaussian 乘积核：

$$\hat{f}_X(x_0) = \frac{1}{N(2\lambda^2\pi)^{p/2}} \sum_{i=1}^N e^{-\frac{1}{2}(\|x_i - x_0\|/\lambda)^2} \quad (14.28)$$

14.8.2 核密度分类

利用 Bayes 定理，可以直接用各类别的非参数密度估计来做分类。对 J 类问题，分别在每个类中拟合密度估计 $\hat{f}_j(X)$ ，并估计类先验 $\hat{\pi}_j$ (通常取样本比例)，则

$$\widehat{\Pr}(G = j \mid X = x_0) = \frac{\hat{\pi}_j \hat{f}_j(x_0)}{\sum_{k=1}^J \hat{\pi}_k \hat{f}_k(x_0)} \quad (14.29)$$

图 6.14 用此方法估计了心脏病的 CHD 概率，与局部 logistic 回归 (图 6.12) 相比，主要差异出现在高 SBP 区域——那里数据稀疏，Gaussian 核密度估计 (使用固定宽度核) 质量差、方差大。而局部 logistic 回归使用的 tri-cube 核配合 k -NN 窗宽在稀疏区域自动展宽了核，并利用局部线性假设 (在 logit 尺度上) 平滑了估计。

一个重要的洞察 (图 6.15)：如果最终目标是分类，则没有必要把各类密度本身估计得很好——事实上这样做可能具有误导性。图 6.15 展示了两类密度都是多峰的，但后验比值相当光滑。学习各类密度时，为了捕捉这些多峰结构可能采用较粗糙的高方差拟合，而这些特征对估计后验概率而言是**无关的**。实际上，若目标仅为分类，只需在**决策边界附近**把后验估计好即可 (对于二分类，即集合 $\{x \mid \Pr(G = 1 \mid X = x) = \frac{1}{2}\}$)。

14.8.3 朴素 Bayes 分类器

朴素 Bayes 分类器尽管名字朴素，却历久不衰。当特征空间维数 p 很高、密度估计不可行时尤其适用。其核心假设是：**给定类别 $G = j$ ，各特征 X_k 相互独立**：

$$f_j(X) = \prod_{k=1}^p f_{jk}(X_k) \quad (14.30)$$

虽然这个假设一般不成立，但它极大地简化了估计：

- 每个类条件边缘密度 f_{jk} 可以分别用**一维核密度估计**来拟合——这实际上是对原始朴素 Bayes (使用单变量 Gaussian 表示边缘密度) 的推广。

- 若某分量 X_j 是离散的，可使用直方图估计——这提供了一种在特征向量中无缝混合不同变量类型的方法。

尽管假设如此「天真」，朴素 Bayes 分类器的表现往往优于远更复杂的方法。原因与图 6.15 相关：虽然各类密度估计可能有偏，但偏差未必损害后验概率——尤其在决策区域附近。问题可能能够承受可观的偏差，以换取「朴素」假设带来的方差节省。

从式 (14.30) 可以推导 logit 变换（以第 J 类为基准）：

$$\begin{aligned} \log \frac{\Pr(G = \ell | X)}{\Pr(G = J | X)} &= \log \frac{\pi_\ell \prod_{k=1}^p f_{\ell k}(X_k)}{\pi_J \prod_{k=1}^p f_{Jk}(X_k)} \\ &= \log \frac{\pi_\ell}{\pi_J} + \sum_{k=1}^p \log \frac{f_{\ell k}(X_k)}{f_{Jk}(X_k)} = \alpha_\ell + \sum_{k=1}^p g_{\ell k}(X_k) \end{aligned} \quad (14.31)$$

这恰好具有广义可加模型（GAM）的形式（第 9 章详述），尽管拟合方式截然不同。朴素 Bayes 与 GAM 的关系，类似于线性判别分析与 logistic 回归的关系。

14.9 径向基函数与核

第 5 章将函数表示为基展开 $f(x) = \sum_j \beta_j h_j(x)$ 。基展开的灵活性取决于选择合适的基函数族并控制复杂度。有些基函数族是局部定义的（如 B-样条在 $\mathbb{R}$ 中局部）；张量积将其推广到 $\mathbb{R}^p$ 中的局部基。但并非所有基函数都是局部的——例如样条的截断幂基，或神经网络中的 sigmoid 基函数 $\sigma(\alpha_0 + \alpha^T x)$ 。

核方法通过在目标点 x_0 附近拟合简单模型来获得灵活性，局部化通过加权核 K_λ 实现。径向基函数（RBF）将这两种思想融合——将核函数 $K_\lambda(\xi, x)$ 本身作为基函数：

$$f(x) = \sum_{j=1}^M K_{\lambda_j}(\xi_j, x) \beta_j = \sum_{j=1}^M D\left(\frac{\|x - \xi_j\|}{\lambda_j}\right) \beta_j \quad (14.32)$$

每个基元素由位置（原型）参数 ξ_j 和尺度参数 λ_j 索引。常用 D 为标准 Gaussian 密度。

参数学习方法（以 Gaussian 核最小二乘回归为例）：

1. 联合优化所有参数（RBF 网络）：

$$\min_{\{\lambda_j, \xi_j, \beta_j\}_1^M} \sum_{i=1}^N \left[y_i - \beta_0 - \sum_{j=1}^M \beta_j \exp\left(-\frac{(x_i - \xi_j)^T(x_i - \xi_j)}{\lambda_j^2}\right) \right]^2 \quad (14.33)$$

该准则非凸、有多个局部极小值，优化算法类似神经网络训练。 ξ_j 和 λ_j 扮演类似神经网络中权重的角色。

2. 分离估计 $\{\lambda_j, \xi_j\}$ 与 β_j ：先确定核参数，再用最小二乘求 β_j 。核参数通常以无监督方式仅基于 X 分布确定——常用方法是对训练 x_i 拟合 Gaussian 混合密度模型来获得中心 ξ_j 和尺度 λ_j ；更简单的方法是用聚类定位原型 ξ_j ，取 $\lambda_j = \lambda$ 为超参数。这种方法显然忽略了条件分布 $\Pr(Y | X)$ 的信息，但实现简单得多。

空洞问题与重归一化 RBF。若所有 $\lambda_j = \lambda$ 取常数值，可能导致空洞—— $\mathbb{R}^p$ 中某些区域没有任何核具有显著支撑（图 6.16 上）。重归一化径向基函数可以避免此问题：

$$h_j(x) = \frac{D(\|x - \xi_j\|/\lambda)}{\sum_{k=1}^M D(\|x - \xi_k\|/\lambda)} \quad (14.34)$$

Nadaraya–Watson 作为 RBF 展开。 $\mathbb{R}^p$ 中的 NW 核回归估计量可以视为重归一化 RBF 展开：

$$\hat{f}(x_0) = \sum_{i=1}^N y_i \frac{K_\lambda(x_0, x_i)}{\sum_{i=1}^N K_\lambda(x_0, x_i)} = \sum_{i=1}^N y_i h_i(x_0) \quad (14.35)$$

每个观测点 x_i 处放置一个基函数 h_i ，系数为 y_i ：即 $\xi_i = x_i$, $\hat{\beta}_i = y_i$, $i = 1, \dots, N$ 。

注意式 (14.35) 与第 5 章由核 K 诱导的正则化问题的解（式 5.50）之间的相似性。径向基函数构成了现代「核方法」与局部拟合技术之间的桥梁。

14.10 混合模型用于密度估计与分类

混合模型是密度估计的有用工具，可视为一种核方法。Gaussian 混合模型的形式为

$$f(x) = \sum_{m=1}^M \alpha_m \phi(x; \mu_m, \Sigma_m) \quad (14.36)$$

其中 $\sum \alpha_m = 1$ 。参数通常通过 EM 算法（第 8 章）做最大似然估计。

一些特例：

- 若协方差阵约束为标量阵 $\Sigma_m = \sigma_m I$ ，则式 (14.36) 具有径向基展开的形式。
- 若进一步 $\sigma_m = \sigma > 0$ 固定，且 $M \uparrow N$ ，则最大似然估计趋近于核密度估计 (14.26)，其中 $\hat{\alpha}_m = 1/N$, $\hat{\mu}_m = x_m$ 。

利用 Bayes 定理，各类别分别拟合混合密度可得到灵活的 $\Pr(G | X)$ 模型（第 12 章详述）。图 6.17 以心脏病风险研究中的年龄变量为例：在不使用 CHD 标签的情况下，用双分量 Gaussian 混合模型拟合年龄数据，结果自动发现的两个分量与 CHD / 非 CHD 两组有较好的对应（分类误差率 32%，与线性 logistic 回归相当）。

14.11 计算考量

核方法与局部回归是**基于记忆**的方法：模型就是整个训练数据集，拟合在评估或预测时进行。对许多实时应用来说，这可能使此类方法不可行。

- 在单个 x_0 处拟合的计算代价为 $O(N)$ ，除非是过度简化的情况（如方形核）。
- 相比之下， M 个基函数的展开每次评估仅需 $O(M)$ ，且通常 $M \sim O(\log N)$ 。基函数方法的初始代价至少为 $O(NM^2 + M^3)$ 。

- 核方法的光滑参数 λ 通常离线确定（如交叉验证），代价 $O(N^2)$ 。

主流局部回归实现（如 S-PLUS/R 的 `loess` 和 `locfit`）使用三角剖分方案来减少计算量：在 M 个精心选择的位置精确计算拟合（ $O(NM)$ ），然后用混合技术在其他位置插值（每次评估 $O(M)$ ）。

第十五章 模型评估与选择

15.1 引言

学习方法的泛化性能 (generalization performance) 涉及其在独立测试数据上的预测能力。在实践中, 评估这一性能极为重要——它指导学习方法或模型的选择, 并给出最终所选模型质量的度量。

本章描述并展示性能评估的关键方法, 以及如何利用它们进行模型选择。我们从偏差、方差和模型复杂度之间的交互关系开始讨论。

15.2 偏差、方差与模型复杂度

15.2.1 定量响应情形

对定量 (区间尺度) 响应 Y , 给定输入向量 X 和由训练集 $\mathcal{T}$ 估计的预测模型 $\hat{f}(X)$ 。损失函数 $L(Y, \hat{f}(X))$ 衡量预测误差, 常见选择为:

- 平方误差: $L(Y, \hat{f}(X)) = (Y - \hat{f}(X))^2$
- 绝对误差: $L(Y, \hat{f}(X)) = |Y - \hat{f}(X)|$

测试误差 (test error), 也称泛化误差, 是在独立测试样本上的预测误差:

$$\text{Err}_{\mathcal{T}} = \mathbb{E}_{X^0, Y^0} [L(Y^0, \hat{f}(X^0)) \mid \mathcal{T}] \quad (15.1)$$

其中 (X^0, Y^0) 是从联合分布 (总体) 中随机抽取的。训练集 $\mathcal{T}$ 固定, 测试误差指该特定训练集的误差。

$\text{Err}_{\mathcal{T}}$ 中的 (X^0, Y^0) 是从测试集中抽的吗?

不是。 (X^0, Y^0) 并非从某个实际的「测试集」中抽取, 而是从数据的联合分布 (总体) F 中随机抽取的。 $\mathbb{E}_{X^0, Y^0}$ 是对总体的积分, 而非对有限测试样本的平均。

区别在于: 理论上 $\text{Err}_{\mathcal{T}}$ 对所有可能的未来数据点取期望, 衡量模型在整个分布上的表现; 实践中我们只有一个有限的测试集, 用其上的平均损失 $\frac{1}{M} \sum_{j=1}^M L(y_j^0, \hat{f}(x_j^0))$ 来




FIGURE 7.1. Behavior of test sample and training sample error as the model complexity is varied. The light blue curves show the training error $\overline{\text{err}}$, while the light red curves show the conditional test error $\text{Err}_{\mathcal{T}}$ for 100 training sets of size 50 each, as the model complexity is increased. The solid curves show the expected test error Err and the expected training error $\mathbb{E}[\overline{\text{err}}]$.

图 15.1: 测试误差和训练误差随模型复杂度变化的行为。浅蓝色曲线为训练误差 $\overline{\text{err}}$, 浅红色曲线为 100 个大小为 50 的训练集各自的条件测试误差 $\text{Err}_{\mathcal{T}}$, 随模型复杂度增加而变化。实线为期望测试误差 Err 和期望训练误差 $\mathbb{E}[\overline{\text{err}}]$ 。

估计 $\text{Err}_{\mathcal{T}}$ 。这就是 $\text{Err}_{\mathcal{T}}$ 被称为「额外样本误差 (extra-sample error)」的原因——测试输入向量不需要与训练输入向量重合。

与此相关的量是**期望预测误差 (expected prediction error)**:

$$\text{Err} = \mathbb{E}[L(Y^0, \hat{f}(X^0))] = \mathbb{E}[\text{Err}_{\mathcal{T}}] \quad (15.2)$$

该期望对一切随机因素取平均，包括产生 $\hat{f}$ 的训练集的随机性。

图 7.1 展示了 100 个大小为 50 的模拟训练集的预测误差曲线（浅红色），以及其平均（实红色，估计 Err ）。Lasso（第 3.4.2 节）用于产生拟合序列。

如何区分不同训练集训练出的模型？

$\hat{f}$ 依赖于训练集 $\mathcal{T}$ ，不同的 $\mathcal{T}$ 会拟合出不同的 $\hat{f}$ 。 $\text{Err}_{\mathcal{T}}$ 的下标 $\mathcal{T}$ 明确表示在**该特定训练集**上训练出的模型的测试误差。在图 7.1 中，100 条浅红色曲线各对应一个不同的 $\mathcal{T}$ ，框架本身不需要额外的区分机制—— $\mathcal{T}$ 的随机性已经刻画了这种差异。简言之： $\text{Err}_{\mathcal{T}}$ 把 $\mathcal{T}$ 视为条件（固定）， Err 把 $\mathcal{T}$ 视为随机变量（对其积分）。

期望预测误差和测试误差的区别

两个概念的区别在于**对什么取平均**：两者都对 (X^0, Y^0) 在总体上积分，但 $\text{Err}_{\mathcal{T}}$ 固定训练集 $\mathcal{T}$ （是随机变量，取决于抽到哪份数据），而 $\text{Err} = \mathbb{E}_{\mathcal{T}}[\text{Err}_{\mathcal{T}}]$ 进一步对训练集取平均（是固定数，属于学习方法本身的属性）。

类比： $\text{Err}_{\mathcal{T}}$ 像某个人的身高（取决于挑中谁）， Err 像人群平均身高（固定参数）。ESL 更关注 Err ，因为它具有更好的统计可操作性——大多数方法（ C_p 、AIC、交叉验证等）实际估计的都是 Err 而非 $\text{Err}_{\mathcal{T}}$ 。

训练误差 (training error) 是训练样本上的平均损失：

$$\overline{\text{err}} = \frac{1}{N} \sum_{i=1}^N L(y_i, \hat{f}(x_i)) \quad (15.3)$$

$\overline{\text{err}}$ 、 $\text{Err}_{\mathcal{T}}$ 、 Err 三者的关系

三个量构成一条从「可算」到「不可算」的链条：

$$\overline{\text{err}} \leq \text{Err}_{\mathcal{T}} \approx \text{Err} \quad (15.4)$$

- Err 是最终目标——它回答「这个**学习方法**从总体中反复抽样训练，平均表现如何」，是方法本身的属性，不依赖于某一份运气好坏的训练集。
- $\text{Err}_{\mathcal{T}}$ 是「用手里这份 $\mathcal{T}$ 训练出的那个模型」在全体未来数据上的期望误差。它仍是对总体积分，但训练集固定，故 $\text{Err} = \mathbb{E}_{\mathcal{T}}[\text{Err}_{\mathcal{T}}]$ 。实践中我们只有一份 $\mathcal{T}$ ，只能接触到 $\text{Err}_{\mathcal{T}}$ ，但**算不出来**（需要对总体积分）。

- $\overline{\text{err}}$ 是唯一能直接算的量，但它是 $\text{Err}_{\mathcal{T}}$ 的系统性偏低估计——同一批数据既拟合又评估，模型会「记忆」训练数据。

本章所有方法（ C_p 、AIC、交叉验证、Bootstrap）本质上都是在 $\overline{\text{err}}$ 上加一个乐观性修正项 $\hat{\omega}$ ，使其逼近 Err （或 $\text{Err}_{\mathcal{T}}$ ）：

$$\widehat{\text{Err}} = \overline{\text{err}} + \hat{\omega} \quad (15.5)$$

随着模型越来越复杂，它更好地利用训练数据并适应更复杂的底层结构，因此偏差减小但方差增大。存在某个中间模型复杂度使期望测试误差达到最小。

注记 15.1. 训练误差不是测试误差的良好估计（如图 7.1 所示）。训练误差随模型复杂度单调递减，若模型足够复杂甚至可以降至零。然而，训练误差为零的模型是对训练数据过拟合的，通常泛化能力很差。

15.2.2 定性响应情形

对于取 $\mathcal{G}$ 中 K 个值之一的定性（分类）响应 G ，通常对概率 $p_k(X) = \Pr(G = k | X)$ 建模，然后 $\hat{G}(X) = \arg \max_k \hat{p}_k(X)$ 。常见损失函数为：

- 0-1 损失： $L(G, \hat{G}(X)) = I(G \neq \hat{G}(X))$
- 偏差（deviance）：

$$L(G, \hat{p}(X)) = -2 \sum_{k=1}^K I(G = k) \log \hat{p}_k(X) = -2 \log \hat{p}_G(X) \quad (15.6)$$

量 $-2 \times$ 对数似然也称为偏差。

测试误差 $\text{Err}_{\mathcal{T}}$ 是分类器在总体上的误分类误差， Err 是期望误分类误差。训练误差为样本类似量，例如：

$$\overline{\text{err}} = -\frac{2}{N} \sum_{i=1}^N \log \hat{p}_{g_i}(x_i) \quad (15.7)$$

即模型的样本对数似然。

注记 15.2. 「 -2 」使得高斯分布下的对数似然损失与平方误差损失一致。为叙述方便，本章后续以定量响应（平方误差损失）为主，其他情形的适当变换是显然的。

15.2.3 模型选择 vs 模型评估

本章的方法通常涉及调节参数 α ，预测记为 $\hat{f}_{\alpha}(x)$ 。调节参数改变模型复杂度，我们希望找到使误差最小的 α 。

需要区分两个目标：

- **模型选择 (Model selection)**: 估计不同模型的性能以选择最佳模型。
- **模型评估 (Model assessment)**: 选定最终模型后, 估计其在新数据上的预测误差 (泛化误差)。

在数据充足的情况下, 最佳做法是随机将数据分为三部分:

- **训练集 (training set)**: 用于拟合模型;
- **验证集 (validation set)**: 用于估计预测误差以进行模型选择;
- **测试集 (test set)**: 用于评估最终所选模型的泛化误差。

注记 15.3. 理想情况下, 测试集应被「锁在保险柜里」, 仅在数据分析的最后阶段取出。若反复使用测试集——选择测试集误差最小的模型——则最终所选模型的测试集误差将低估真实测试误差, 有时低得相当严重。

本章的方法通过**解析近似** (AIC、BIC、MDL、SRM) 或**高效的样本重复利用** (交叉验证和自助法) 来近似验证步骤。

15.3 偏差-方差分解

与第 2 章一样, 假设 $Y = f(X) + \varepsilon$, 其中 $\mathbb{E}(\varepsilon) = 0$, $\text{Var}(\varepsilon) = \sigma_\varepsilon^2$ 。对回归拟合 $\hat{f}(X)$ 在输入点 $X = x_0$ 处的期望预测误差 (使用平方误差损失), 有如下分解:

$$\begin{aligned} \text{Err}(x_0) &= \mathbb{E}[(Y - \hat{f}(x_0))^2 \mid X = x_0] \\ &= \sigma_\varepsilon^2 + [\mathbb{E}\hat{f}(x_0) - f(x_0)]^2 + \mathbb{E}[\hat{f}(x_0) - \mathbb{E}\hat{f}(x_0)]^2 \\ &= \sigma_\varepsilon^2 + \text{Bias}^2(\hat{f}(x_0)) + \text{Var}(\hat{f}(x_0)) \\ &= \text{不可约误差} + \text{偏差}^2 + \text{方差}. \end{aligned} \quad (15.8)$$

第一项是目标值围绕其真实均值 $f(x_0)$ 的方差, 无论 $\hat{f}$ 多好都无法避免 (除非 $\sigma_\varepsilon^2 = 0$)。第二项是**平方偏差**——估计的均值与真实均值之差; 第三项是**方差**——估计围绕其均值的期望平方偏差。

注记 15.4. 通常模型越复杂, 平方偏差越低但方差越高。

15.3.1 k -最近邻回归的偏差-方差分解

对 k -最近邻回归拟合, 假设训练输入 x_i 固定, 随机性仅来自 y_i :

$$\text{Err}(x_0) = \mathbb{E}[(Y - \hat{f}_k(x_0))^2 \mid X = x_0] = \sigma_\varepsilon^2 + \left[f(x_0) - \frac{1}{k} \sum_{\ell=1}^k f(x_{(\ell)}) \right]^2 + \frac{\sigma_\varepsilon^2}{k} \quad (15.9)$$

邻居数 k 与模型复杂度成反比。 k 小 $\rightarrow$ 能更好地适应 $f(x_0)$; k 增大 $\rightarrow$ 偏差通常增大而方差减小。

15.3.2 线性回归的偏差-方差分解

对线性模型 $\hat{f}_p(x_0) = x_0^T \hat{\beta}$ 使用最小二乘拟合：

$$\text{Err}(x_0) = \sigma_\varepsilon^2 + [f(x_0) - \mathbb{E}\hat{f}_p(x_0)]^2 + \|h(x_0)\|^2 \sigma_\varepsilon^2 \quad (15.10)$$

其中 $h(x_0) = X(X^T X)^{-1}x_0$ ，是产生拟合的 N 维线性权重向量。该方差虽随 x_0 变化，但其平均值（以样本值 x_i 为 x_0 ）为 $(p/N)\sigma_\varepsilon^2$ ，从而得到样本内误差：

$$\frac{1}{N} \sum_{i=1}^N \text{Err}(x_i) = \sigma_\varepsilon^2 + \frac{1}{N} \sum_{i=1}^N [f(x_i) - \mathbb{E}\hat{f}_p(x_i)]^2 + \frac{p}{N} \sigma_\varepsilon^2 \quad (15.11)$$

复杂度直接与参数个数 p 相关。

15.3.3 岭回归的偏差分解

对岭回归拟合 $\hat{f}_\alpha(x_0)$ ，检验误差形式与 (15.10) 相同，但方差项中的线性权重不同： $h(x_0) = X(X^T X + \alpha I)^{-1}x_0$ 。偏差项也不同。

对线性模型族（如岭回归），偏差可进一步精细分解。设 β_* 为 f 的最佳线性逼近参数：

$$\beta_* = \arg \min_{\beta} \mathbb{E}[f(X) - X^T \beta]^2 \quad (15.12)$$

期望关于输入变量 X 的分布。则平均平方偏差可写为：

$$\begin{aligned} \mathbb{E}_{x_0} [f(x_0) - \mathbb{E}\hat{f}_\alpha(x_0)]^2 &= \mathbb{E}_{x_0} [f(x_0) - x_0^T \beta_*]^2 + \mathbb{E}_{x_0} [x_0^T \beta_* - \mathbb{E}(x_0^T \hat{\beta}_\alpha)]^2 \\ &= \text{Ave}[\text{模型偏差}] + \text{Ave}[\text{估计偏差}] \end{aligned} \quad (15.13)$$

- **模型偏差 (Model Bias)**：最佳线性逼近与真实函数之间的误差——只能通过将线性模型族扩大为更丰富的模型集合（如引入交互项和变量变换）来减小。
- **估计偏差 (Estimation Bias)**：平均估计与最佳线性逼近之间的误差。OLS 的估计偏差为零；受限拟合（如岭回归）的估计偏差为正，我们用它换取方差的降低。

若用更少的预测变量或对系数向零收缩来拟合模型，则得到「收缩拟合」。该拟合离模型空间中的最佳拟合更远（增加了估计偏差），但方差更小。若方差减少超过（平方）偏差的增加，则这种收缩是值得的。

15.3.4 示例：偏差-方差权衡

共有 80 个观测和 20 个预测变量，均匀分布在超立方体 $[0, 1]^{20}$ 中：

- **左侧面板**： Y 当 $X_1 \leq 1/2$ 时为 0，否则为 1，使用 k -最近邻。




FIGURE 7.2. Schematic of the behavior of bias and variance. The model space is the set of all possible predictions from the model, with the “closest fit” labeled with a black dot. The model bias from the truth is shown, along with the variance, indicated by the large yellow circle centered at the black dot labeled “closest fit in population.” A shrunk or regularized fit is also shown, having additional estimation bias, but smaller prediction error due to its decreased variance.

图 15.2: 偏差与方差行为的示意图。模型空间是模型所有可能预测的集合,「最近拟合」以黑点标出。真值与最近拟合之间的距离为模型偏差。方差由以「总体中的最近拟合」为中心的大黄色圆表示。收缩/正则化拟合具有额外的估计偏差,但由于方差减小,预测误差反而更小。




FIGURE 7.3. Expected prediction error (orange), squared bias (green) and variance (blue) for a simulated example. The top row is regression with squared error loss; the bottom row is classification with 0–1 loss. The models are k -nearest neighbors (left) and best subset regression of size p (right). The variance and bias curves are the same in regression and classification, but the prediction error curve is different.

图 15.3: 模拟示例的期望预测误差（橙色）、平方偏差（绿色）和方差（蓝色）。上行：平方误差损失的回归；下行：0-1 损失的分类。左列： k -最近邻；右列：大小为 p 的最佳子集线性回归。偏差和方差曲线在回归与分类中相同，但预测误差曲线不同。

- **右侧面板：** Y 当 $\sum_{j=1}^{10} X_j > 5$ 时为 1，否则为 0，使用大小为 p 的最佳子集线性回归。

上行是平方误差损失的回归；下行是 0-1 损失的分​​类。图中展示了预测误差（红色）、平方偏差（绿色）和方差（蓝色），均在大型测试样本上计算。

回归情形：偏差和方差相加产生预测误差曲线，最小值出现在 $k \approx 5$ (k -NN) 和 $p \geq 10$ (线性模型)。

分类情形（下行）：出现了一些有趣现象：

- 偏差和方差曲线与上行相同，但预测误差现在指误分类率。
- 预测误差不再是平方偏差与方差之和。
- 对 k -NN 分类器，当邻居数从 1 增加到 20 时，预测误差下降或保持不变，尽管平方偏差在上升。
- 对线性模型分类器，最小值和回归一样在 $p \geq 10$ 处，但相比 $p = 1$ 的改进更为显著。
- 偏差和方差似乎在决定预测误差时存在交互作用。

15.4 训练误差的乐观性

关于误差率估计的讨论可能令人困惑，因为需要明确哪些量是固定的、哪些是随机的。

15.4.1 泛化误差、期望误差与样本内误差

给定训练集 $\mathcal{T} = \{(x_1, y_1), \dots, (x_N, y_N)\}$ ，模型 $\hat{f}$ 的泛化误差为：

$$\text{Err}_{\mathcal{T}} = \mathbb{E}_{X^0, Y^0} [L(Y^0, \hat{f}(X^0)) \mid \mathcal{T}] \quad (15.14)$$

训练集 $\mathcal{T}$ 固定， (X^0, Y^0) 是从数据的联合分布 F 中抽取的新测试点。

对训练集 $\mathcal{T}$ 取平均得到期望误差：

$$\text{Err} = \mathbb{E}_{\mathcal{T}} \mathbb{E}_{X^0, Y^0} [L(Y^0, \hat{f}(X^0)) \mid \mathcal{T}] \quad (15.15)$$

大多数方法实际估计的是期望误差而非 $\text{Err}_{\mathcal{T}}$ （见第 7.12 节）。

训练误差为：

$$\overline{\text{err}} = \frac{1}{N} \sum_{i=1}^N L(y_i, \hat{f}(x_i)) \quad (15.16)$$

由于同一批数据既用于拟合方法又用于评估误差，训练误差 $\overline{\text{err}}$ 通常是泛化误差 $\text{Err}_{\mathcal{T}}$ 的过度乐观的估计。

为了更清晰地理解乐观性的本质，引入**样本内误差**（in-sample error）：

$$\text{Err}_{\text{in}} = \frac{1}{N} \sum_{i=1}^N \mathbb{E}_{Y_i^0} [L(Y_i^0, \hat{f}(x_i)) \mid \mathcal{T}] \quad (15.17)$$

其中 Y_i^0 表示在每个训练点 x_i 处观察 N 个新的响应值。

Err_{in} 与 Err_T 的关系

两者评估的是不同位置的数据：

- Err_T：(X^0, Y^0) 从总体 F 中任意抽取， X^0 是全新的——称为「额外样本误差」。
- Err_{in}： X 固定在训练集的 x_i 上，仅 Y_i^0 重新生成——称为「样本内误差」。

引入 Err_{in} 的原因在于数学上的便利： X 不动，只有 Y 重抽样，这使得乐观性公式 $\omega = \frac{2}{N} \sum \text{Cov}(\hat{y}_i, y_i)$ 得以推导。 C_p 、AIC 等解析准则估计的正是 Err_{in}（或其对训练集的期望）。

Err_{in} 与最终目标 Err 的关系

Err_{in} 与 Err 之间没有简单的等号或近似关系——它们服务于不同目的：

- **模型比较**：Err_{in} 足以胜任。在训练 x_i 上表现好的模型，在新 X 上也通常表现好，排序一致。
- **绝对评估**：Err_{in} 的绝对值没有实际意义——未来数据的 X 几乎不可能恰好等于某个训练 x_i 。需用交叉验证或 Bootstrap 直接估计 Err。

简言之： C_p 、AIC 估计 Err_{in} → 用于选模型（比大小）；交叉验证、Bootstrap 估计 Err → 用于评估最终模型（要绝对值）。

15.4.2 乐观性及其性质

定义**乐观性**（optimism）为样本内误差与训练误差之差：

$$\text{op} \equiv \text{Err}_{\text{in}} - \overline{\text{err}} \quad (15.18)$$

这通常是正的，因为 $\overline{\text{err}}$ 作为预测误差的估计通常偏低。

平均乐观性是乐观性对训练集的期望：

$$\omega \equiv \mathbb{E}_y(\text{op}) \quad (15.19)$$

这里预测变量固定，期望针对训练集的响应值。




图 15.4: $\overline{\text{err}}$ 、 Err_{in} 、 $\text{Err}_{\mathcal{T}}$ 、 Err 四者关系与各自用途。上行为样本内视角， C_p 、AIC 修正乐观性后用于模型比较；下行为泛化视角，交叉验证与 Bootstrap 直接估计 Err 用于最终评估。

对于平方误差、0-1 损失及其他损失函数，可以一般地证明：

$$\omega = \frac{2}{N} \sum_{i=1}^N \text{Cov}(\hat{y}_i, y_i) \quad (15.20)$$

其中 Cov 表示协方差。

注记 15.5. $\overline{\text{err}}$ 低估真实误差的程度取决于 y_i 对其自身预测的影响有多强。我们对数据拟合越用力， $\text{Cov}(\hat{y}_i, y_i)$ 就越大，乐观性也随之增加。对于回归的平方误差损失， $\hat{y}_i$ 是拟合值；对 0-1 分类， $\hat{y}_i \in \{0, 1\}$ 是分类结果；对熵损失， $\hat{y}_i \in [0, 1]$ 是类别 1 的拟合概率。

综上，有重要关系：

$$\mathbb{E}_y(\text{Err}_{\text{in}}) = \mathbb{E}_y(\overline{\text{err}}) + \frac{2}{N} \sum_{i=1}^N \text{Cov}(\hat{y}_i, y_i) \quad (15.21)$$

15.4.3 线性拟合的特殊情形

若 $\hat{y}_i$ 由具有 d 个输入或基函数的线性拟合得到，且假设可加误差模型 $Y = f(X) + \varepsilon$ ，则：

$$\sum_{i=1}^N \text{Cov}(\hat{y}_i, y_i) = d \sigma_{\varepsilon}^2 \quad (15.22)$$

从而：

$$\mathbb{E}_y(\text{Err}_{\text{in}}) = \mathbb{E}_y(\overline{\text{err}}) + 2 \cdot \frac{d}{N} \sigma_{\varepsilon}^2 \quad (15.23)$$

这是第 7.6 节定义的有效参数个数概念的基础。乐观性随使用的输入/基函数个数 d 线性增长，但随训练样本量增大而减小。

注记 15.6. 一个自然的估计预测误差的思路是：先估计乐观性，然后将它加到训练误差上。下一节描述的 C_p 、AIC、BIC 等方法即是按此思路运作的——对参数为线性的特殊估计类。

注记 15.7. 交叉验证和自助法（本章后续介绍）则是直接估计额外样本误差（extra-sample error） $\text{Err}_{\mathcal{T}}$ 。这些通用工具可用于任意损失函数以及非线性、自适应的拟合技术。

样本内误差虽然在实践中不直接关注（因为未来特征值不太可能与训练集特征值重合），但对于模型间的比较，样本内误差是方便的，且通常能有效地进行模型选择——因为重要的是误差的相对（而非绝对）大小。

15.5 样本内预测误差的估计

样本内估计的一般形式为：

$$\widehat{\text{Err}}_{\text{in}} = \overline{\text{err}} + \hat{\omega} \quad (15.24)$$

其中 $\hat{\omega}$ 是平均乐观性的估计。

15.5.1 C_p 统计量

利用 (15.23)（ d 个参数在平方误差损失下拟合），得到 C_p 统计量的一种形式：

$$C_p = \overline{\text{err}} + 2 \cdot \frac{d}{N} \hat{\sigma}_\varepsilon^2 \quad (15.25)$$

其中 $\hat{\sigma}_\varepsilon^2$ 是噪声方差的估计，由低偏差模型的均方误差获得。该准则按使用的基函数数量成比例地调整训练误差。

15.5.2 AIC 准则

Akaike 信息准则（AIC）是使用对数似然损失函数时更一般适用的 Err_{in} 估计。它依赖于当 $N \rightarrow \infty$ 时渐近成立的类似关系：

$$-2 \cdot \mathbb{E}[\log \Pr_{\hat{\theta}}(Y)] \approx -\frac{2}{N} \cdot \mathbb{E}[\log \text{lik}] + 2 \cdot \frac{d}{N} \quad (15.26)$$

其中 $\Pr_{\theta}(Y)$ 是 Y 的密度族（包含「真实」密度）， $\hat{\theta}$ 是 θ 的极大似然估计， $\log \text{lik} = \sum_{i=1}^N \log \Pr_{\hat{\theta}}(y_i)$ 是最大化对数似然。

AIC 定义为：

$$\text{AIC} = -\frac{2}{N} \cdot \log \text{lik} + 2 \cdot \frac{d}{N} \quad (15.27)$$

选择使 AIC 最小的模型。注意到 $-\frac{2}{N} \cdot \log \text{lik}$ 是训练误差（对数似然损失），而 $2d/N$ 是乐观性的估计。

注记 15.8. C_p 和 AIC 虽然形式相似，但动机不同： C_p 来自精确的无偏估计（线性模型 + 平方误差），而 AIC 来自渐近论证（一般似然框架）。

15.5.3 AIC 的实践使用

对 logistic 回归，使用二项对数似然：

$$\text{AIC} = -\frac{2}{N} \cdot \text{loglik} + 2 \cdot \frac{d}{N} \quad (15.28)$$

对高斯模型（方差 $\sigma_\varepsilon^2 = \hat{\sigma}_\varepsilon^2$ 已知），AIC 与 C_p 等价，因此常统称为 AIC。

给定由调节参数 α 索引的模型族 $f_\alpha(x)$ ，记 $\overline{\text{err}}(\alpha)$ 和 $d(\alpha)$ 为每个模型的训练误差和参数个数，则：

$$\text{AIC}(\alpha) = \overline{\text{err}}(\alpha) + 2 \cdot \frac{d(\alpha)}{N} \hat{\sigma}_\varepsilon^2 \quad (15.29)$$

$\text{AIC}(\alpha)$ 给出测试误差曲线的估计，选择使 AIC 最小的 $\hat{\alpha}$ 。

注记 15.9. 若基函数是自适应选择的（如从 p 个输入中选最佳 $d < p$ 个），则乐观性将超过 $2d\sigma_\varepsilon^2/N$ ——选择最佳 d 输入模型时，实际拟合的有效参数个数大于 d 。

图 7.4 展示了 AIC 在音素识别示例中的应用：logistic 回归系数 $\beta(f) = \sum_{m=1}^M h_m(f)\theta_m$ 展开为 M 个样条基函数，AIC 选择的基函数个数近似最小化了 $\text{Err}(M)$ （对对数似然和 0-1 损失均表现良好）。

15.6 有效参数个数

「参数个数」的概念可以推广，尤其适用于使用正则化的模型。

15.6.1 线性拟合方法的有效自由度

将输出 $y_1, \dots, y_N$ 和预测 $\hat{y}_1, \dots, \hat{y}_N$ 分别堆叠为向量 $\mathbf{y}$ 和 $\hat{\mathbf{y}}$ 。线性拟合方法满足：

$$\hat{\mathbf{y}} = \mathbf{S}\mathbf{y} \quad (15.30)$$

其中 $\mathbf{S}$ 是 $N \times N$ 矩阵，仅依赖于输入 $\mathbf{x}_i$ 而不依赖于 y_i 。此类方法包括：原始特征或导出基上的线性回归、岭回归、三次光滑样条等。

有效参数个数定义为：

$$\text{df}(\mathbf{S}) = \text{tr}(\mathbf{S}) \quad (15.31)$$

即 $\mathbf{S}$ 对角元之和（也称有效自由度）。若 $\mathbf{S}$ 是向 M 个特征张成的基集的正交投影矩阵，则 $\text{tr}(\mathbf{S}) = M$ 。

可以证明， $\text{tr}(\mathbf{S})$ 恰好是 C_p 统计量中替代 d 的正确量。在可加误差模型下：

$$\sum_{i=1}^N \text{Cov}(\hat{y}_i, y_i) = \text{tr}(\mathbf{S}) \sigma_\varepsilon^2 \quad (15.32)$$

这引出了更一般的定义：

$$\text{df}(\hat{\mathbf{y}}) = \frac{\sum_{i=1}^N \text{Cov}(\hat{y}_i, y_i)}{\sigma_\varepsilon^2} \quad (15.33)$$

15.6.2 神经网络的有效参数个数

对带权重衰减惩罚（正则化） $\alpha \sum_m w_m^2$ 的神经网络，有效参数个数为：

$$\text{df}(\alpha) = \sum_{m=1}^M \frac{\theta_m}{\theta_m + \alpha} \quad (15.34)$$

其中 θ_m 是 Hessian 矩阵 $\partial^2 R(\mathbf{w})/\partial \mathbf{w} \partial \mathbf{w}^T$ 在解处的特征值。该式可在误差函数的二次逼近下由 (15.31) 导出。

15.7 贝叶斯方法与 BIC

15.7.1 BIC 的定义

贝叶斯信息准则（BIC）适用于通过最大化对数似然进行拟合的情形，其一般形式为：

$$\text{BIC} = -2 \cdot \log \text{lik} + (\log N) \cdot d \quad (15.35)$$

BIC（乘 1/2 后）也称 Schwarz 准则。

在高斯模型（方差 σ_ε^2 已知）下：

$$\text{BIC} = \frac{N}{\sigma_\varepsilon^2} \left[\overline{\text{err}} + (\log N) \cdot \frac{d}{N} \sigma_\varepsilon^2 \right] \quad (15.36)$$

因此 BIC 与 AIC (C_p) 成比例，只是因子 2 被替换为 $\log N$ 。由于 $N > e^2 \approx 7.4$ 时 $\log N > 2$ ，BIC 对复杂模型的惩罚更重，倾向于选择更简单的模型。

注记 15.10. 误分类误差度量不出现于 BIC 框架中，因为它不对应于任何概率模型下数据的对数似然。

15.7.2 BIC 的贝叶斯推导

设候选模型为 $\mathcal{M}_m$ ($m = 1, \dots, M$)，对应参数 θ_m ，先验为 $\Pr(\theta_m | \mathcal{M}_m)$ 。模型的后验概率为：

$$\Pr(\mathcal{M}_m | \mathbf{Z}) \propto \Pr(\mathcal{M}_m) \cdot \Pr(\mathbf{Z} | \mathcal{M}_m) \quad (15.37)$$

其中 $\mathbf{Z}$ 表示训练数据。比较两个模型的后验几率（posterior odds）：

$$\frac{\Pr(\mathcal{M}_m | \mathbf{Z})}{\Pr(\mathcal{M}_\ell | \mathbf{Z})} = \frac{\Pr(\mathcal{M}_m)}{\Pr(\mathcal{M}_\ell)} \cdot \frac{\Pr(\mathbf{Z} | \mathcal{M}_m)}{\Pr(\mathbf{Z} | \mathcal{M}_\ell)} \quad (15.38)$$

右端第二个因子称为贝叶斯因子（Bayes factor）。

假设模型先验均匀，对积分 $\Pr(\mathbf{Z} | \mathcal{M}_m)$ 使用 Laplace 近似：

$$\log \Pr(\mathbf{Z} | \mathcal{M}_m) = \log \Pr(\mathbf{Z} | \hat{\theta}_m, \mathcal{M}_m) - \frac{d_m}{2} \cdot \log N + O(1) \quad (15.39)$$

其中 $\hat{\theta}_m$ 是极大似然估计, d_m 是模型 $\mathcal{M}_m$ 的自由参数个数。因此选择最小 BIC 等价于选择最大 (近似) 后验概率的模型。

此外, 可估计每个模型的后验概率:

$$\Pr(\mathcal{M}_m | \mathbf{Z}) \approx \frac{e^{-\frac{1}{2}\text{BIC}_m}}{\sum_{\ell=1}^M e^{-\frac{1}{2}\text{BIC}_\ell}} \quad (15.40)$$

15.7.3 AIC 与 BIC 的比较

- **BIC 是渐近一致的:** 若真实模型在候选族中, 当 $N \rightarrow \infty$ 时 BIC 选出正确模型的概率趋近于 1。AIC 不具有此性质——随 $N \rightarrow \infty$ 倾向于选择过于复杂的模型。
- **有限样本下:** BIC 因其对复杂度的重惩罚, 常选择过于简单的模型。
- 模型选择中 AIC 与 BIC 没有绝对的优劣, 取决于具体场景。

如何直观理解 C_p 、AIC、df、BIC?

这四个量都围绕同一个核心公式: $\widehat{\text{Err}} = \overline{\text{err}} + \text{复杂度惩罚}$ 。区别在于惩罚项用什么、怎么来:

- C_p (Mallows' C_p): 最直白—— $\overline{\text{err}} + 2 \cdot \frac{d}{N} \hat{\sigma}_\varepsilon^2$ 。思想是「用了 d 个参数, 每个参数贡献 $2\sigma_\varepsilon^2/N$ 的乐观性」。仅在平方误差 + 线性模型下精确成立。
- **AIC (Akaike 信息准则):** C_p 的泛化版——把 $\overline{\text{err}}$ 换成对数似然损失, 惩罚项仍是 $2d/N$ 。来自渐近理论 ($N \rightarrow \infty$), 适用于任何用极大似然拟合的模型。记法: **AIC = 「2 × 参数个数」的惩罚**。
- **df (有效自由度):** 回答「 d 到底该用多少」的问题。对线性模型 d 就是参数个数; 对正则化模型 (岭回归、样条), 系数被收缩了, 实际「有效」参数少于名义 d 。公式 $\text{df} = \text{tr}(\mathbf{S})$ 给出精确答案: $\hat{\mathbf{y}} = \mathbf{S}\mathbf{y}$, $\mathbf{S}$ 的对角元之和就是有效参数个数。记法: **df 就是 $\mathbf{S}$ 的迹**。
- **BIC (贝叶斯信息准则):** AIC 的「更严厉」版本——惩罚项从 2 换成 $\log N$ 。由于 $\log N > 2$ ($N \geq 8$), BIC 对复杂模型惩罚更重。来自贝叶斯推导 (选择最大后验概率模型), 具有渐近一致性。记法: **BIC = 「 $\log N \times$ 参数个数」的惩罚**。

一句话区分:

准则	惩罚因子	适用场景
C_p	2	线性模型 + 平方误差
AIC	2	一般似然模型, $N \rightarrow \infty$ 渐近
df	—	回答「有效参数个数是多少」
BIC	$\log N$	贝叶斯框架, $N \rightarrow \infty$ 一致性

15.8 最小描述长度

最小描述长度（MDL）方法给出的选择准则在形式上与 BIC 相同，但其动机来自最优编码视角。

15.8.1 编码与熵

将数据 $\mathbf{z}$ 视为需要编码传输的消息，模型视为编码方式，选择最精简的模型（最短编码）。

对具有概率 $\Pr(z_i)$ 的消息，Shannon 定理指出应使用码长 $l_i = -\log_2 \Pr(z_i)$ ，且平均消息长度满足：

$$\mathbb{E}(\text{length}) \geq -\sum_i \Pr(z_i) \log_2 \Pr(z_i) \quad (15.41)$$

右端称为分布的熵。结论：传输概率密度为 $\Pr(z)$ 的随机变量约需 $-\log_2 \Pr(z)$ 比特。

15.8.2 MDL 用于模型选择

对于模型 $\mathcal{M}$ （参数 θ ）和数据 $\mathbf{Z} = (\mathbf{X}, \mathbf{y})$ ，假设接收方已知输入 $\mathbf{X}$ ，需传输输出 $\mathbf{y}$ 。总消息长度为：

$$\text{length} = -\log \Pr(\mathbf{y} \mid \theta, \mathcal{M}, \mathbf{X}) - \log \Pr(\theta \mid \mathcal{M}) \quad (15.42)$$

第一项传输模型与真实目标的偏差，第二项传输模型参数。二者之和的最小化即最小描述长度原则。

MDL 的模型选择观点是选择后验概率最高的模型——这与 BIC 一致。然而许多贝叶斯学者更倾向于从后验分布中抽样做推断，而非仅选一个模型。

15.9 Vapnik–Chervonenkis 维

使用样本内误差估计的一个困难在于需要指定拟合中使用的参数个数（复杂度） d 。第 7.6 节的有效参数个数对某些非线性模型有用，但并不完全通用。VC 理论提供了复杂度的一般度量，并给出相应的乐观性界。

15.9.1 打散与 VC 维定义

设 $\{f(x, \alpha)\}$ 为一类函数。暂时假设 f 是指示函数（取值 0 或 1）。例如：

- $f(x, \alpha) = I(\alpha_0 + \alpha_1 x > 0)$ ——线性指示函数
- $f(x, \alpha) = I(\sin(\alpha \cdot x) > 0)$ ——正弦指示函数（图 7.5）

VC 维定义为该类函数能打散 (shatter) 的点的最大个数 (在某种配置下)。

一组点被函数类「打散」是指：无论怎样为每个点分配二值标签，该类中总存在一个成员能完全分离它们。

图 7.6 表明平面中线性指示函数的 VC 维为 3 (3 个点可被打散, 4 个点不可)。一般地, p 维线性指示函数的 VC 维为 $p + 1$ ——等于自由参数个数。而 $\sin(\alpha x)$ 族的 VC 维为无穷 (通过选择适当频率 α 可打散任意多个点)。

对实值函数类 $\{g(x, \alpha)\}$, 其 VC 维定义为指示函数类 $\{I(g(x, \alpha) - \beta > 0)\}$ 的 VC 维, 其中 β 取 g 的值域。

15.9.2 VC 界与结构风险最小化

利用 VC 维可构造预测误差的估计。对二分类:

$$\text{Err}_{\mathcal{T}} \leq \overline{\text{err}} + \frac{\epsilon}{2} \left(1 + \sqrt{1 + \frac{4 \cdot \overline{\text{err}}}{\epsilon}} \right) \quad (15.43)$$

对回归:

$$\text{Err}_{\mathcal{T}} \leq \frac{\overline{\text{err}}}{(1 - c\sqrt{\epsilon})_+} \quad (15.44)$$

其中 $\epsilon = a_1 \frac{h[\log(a_2 N/h) + 1] - \log(\eta/4)}{N}$, h 为 VC 维。这些界对所有 $f(x, \alpha)$ 同时成立, 从而允许在函数类中搜索。

结构风险最小化 (SRM): 拟合一个 VC 维递增的嵌套模型序列 $h_1 < h_2 < \dots$, 选择使上界最小的模型。

注记 15.11. VC 界通常非常宽松, 但这不妨碍其作为模型选择准则——重要的是相对而非绝对大小。主要缺点是 VC 维计算困难, 通常只能获得粗略上界。支持向量机 (第 12.2 节) 是 SRM 的成功应用案例。

15.9.3 示例: AIC、BIC、SRM 的比较

AIC 在所有四个场景中表现良好 (即使 0-1 损失缺乏理论支持), BIC 表现接近, SRM 表现参差不齐。

15.10 交叉验证

交叉验证可能是估计预测误差最简单且最广泛使用的方法。该方法直接估计期望额外样本误差 $\text{Err} = \mathbb{E}[L(Y, \hat{f}(X))]$ ——即将方法 $\hat{f}(X)$ 应用于来自 X 和 Y 联合分布的独立测试样本时的平均泛化误差。第 7.12 节将说明, 交叉验证通常只能较好地估计期望预测误差, 而非条件误差 $\text{Err}_{\mathcal{T}}$ 。




FIGURE 7.7. Boxplots show the distribution of the relative error $100 \times [\text{Err}_{\mathcal{T}}(\hat{\alpha}) - \min_{\alpha} \text{Err}_{\mathcal{T}}(\alpha)] / [\max_{\alpha} \text{Err}_{\mathcal{T}}(\alpha) - \min_{\alpha} \text{Err}_{\mathcal{T}}(\alpha)]$ over the four scenarios of Figure 7.3. This is the error in using the chosen model relative to the best model. There are 100 training sets each of size 80 represented in each boxplot, with the errors computed on test sets of size 10,000.

图 15.5: 箱线图展示图 7.3 四个场景下相对误差 $100 \times [\text{Err}_{\mathcal{T}}(\hat{\alpha}) - \min_{\alpha} \text{Err}_{\mathcal{T}}(\alpha)] / [\max_{\alpha} \text{Err}_{\mathcal{T}}(\alpha) - \min_{\alpha} \text{Err}_{\mathcal{T}}(\alpha)]$ 的分布——即使用所选模型相对于最佳模型的误差。每个箱线图代表 100 个大小为 80 的训练集，误差在大小为 10,000 的测试集上计算。

15.10.1 K 折交叉验证

将数据随机分为 K 个大小大致相等的折。对第 k 折，用其余 $K - 1$ 折数据拟合模型，计算在第 k 折上的预测误差。 K 折 CV 估计为：

$$\text{CV}(\alpha) = \frac{1}{K} \sum_{k=1}^K \frac{1}{|F_k|} \sum_{i \in F_k} L(y_i, \hat{f}_\alpha^{-k}(x_i)) \quad (15.45)$$

其中 $\hat{f}_\alpha^{-k}$ 是剔除第 k 折后拟合的模型， F_k 为第 k 折的索引集。

典型选择： $K = 5$ 或 $K = 10$ 。 $K = N$ 的特例称为**留一交叉验证 (LOOCV)**。

更精确地，设 $\kappa: \{1, \dots, N\} \rightarrow \{1, \dots, K\}$ 为指示观测 i 分配到哪一折的索引函数， $\hat{f}^{-k}(x)$ 为剔除第 k 折后拟合的函数。则 CV 预测误差估计为：

$$\text{CV}(\hat{f}) = \frac{1}{N} \sum_{i=1}^N L(y_i, \hat{f}^{-\kappa(i)}(x_i)) \quad (15.46)$$

对含调节参数 α 的模型族：

$$\text{CV}(\hat{f}, \alpha) = \frac{1}{N} \sum_{i=1}^N L(y_i, \hat{f}^{-\kappa(i)}(x_i, \alpha)) \quad (15.47)$$

选择使 $\text{CV}(\hat{f}, \alpha)$ 最小的 $\hat{\alpha}$ ，再用全部数据拟合最终模型 $f(x, \hat{\alpha})$ 。

这里容易混淆：LOOCV ($K = N$) 并非一种不同的做法——它仍是 K 折 CV，只是每折恰好包含 1 个观测。以 $N = 100$ 为例，5 折 CV 每次用 80 个训练、20 个验证，共做 5 次；LOOCV 每次用 99 个训练、1 个验证，共做 100 次。LOOCV 的每个训练集几乎等于全量数据（只差一个点），因此偏差极低；但 100 个训练集高度相似，导致方差大。

最终模型用什么训练？ CV 全程只用原始训练集——从未见过独立的测试集。CV 的作用仅仅是选 $\hat{\alpha}$ 。选定后，用**全部 N 个观测**重新训练一次，得到最终模型 $\hat{f}(\cdot, \hat{\alpha})$ 。测试集（如果保留了一份）只在最后评估这个最终模型时使用一次。

一个具体流程示例。 假设有 $N = 150$ 条数据，要做岭回归，调节参数 α 候选为 $\{0.01, 0.1, 1, 10, 100\}$ 。

1. 随机打乱数据，分成 5 折（每折 30 条）。
2. 对每个候选 α ：
 - 第 1 折做验证，第 2-5 折（120 条）训练 $\rightarrow$ 算验证误差 $e_1(\alpha)$
 - 第 2 折做验证，其余训练 $\rightarrow e_2(\alpha)$
 - ... 共 5 次，取平均 $\text{CV}(\alpha) = \frac{1}{5} \sum_{k=1}^5 e_k(\alpha)$
3. 选 $\hat{\alpha} = \arg \min_{\alpha} \text{CV}(\alpha)$ ，假设结果为 $\hat{\alpha} = 1$ 。

4. 用全部 150 条数据，以 $\alpha = 1$ 做岭回归 $\rightarrow$ 得到最终模型 $\hat{\beta}_{\alpha=1}^{\text{ridge}}$ 。

5. (可选) 在保留的独立测试集上评估该模型的泛化误差。

整个过程没有用到测试集来选 α ——这正是 CV 的核心价值：在训练数据内部模拟「训-验」分离。

15.10.2 K 的选择：偏差-方差权衡

CV 实际估计的是什么呢？ $K = 5$ 或 10 时，每折的训练集与原训练集差别较大，估计的应是 Err （期望误差）。 $K = N$ （LOOCV）时，训练集几乎与原集相同，可能更接近 $\text{Err}_{\mathcal{T}}$ 。但第 7.12 节将说明，CV 通常只能有效估计 Err 。

- $K = N$ （LOOCV）：近似无偏（对 Err ），但方差高—— N 个训练集高度相似。
- $K = 5$ 或 10 ：方差低，但若学习曲线在给定训练集大小处有显著斜率，则会有偏差。




FIGURE 7.8. Hypothetical learning curve for a classifier on a given task: a plot of $1 - \text{Err}$ versus the size of the training set N . With a dataset of 200 observations, 5-fold cross-validation would use training sets of size 160, which would behave much like the full set. However, with a dataset of 50 observations fivefold cross-validation would use training sets of size 40, and this would result in a considerable overestimate of prediction error.

图 15.6: 某个分类任务假设的学习曲线： $1 - \text{Err}$ 随训练集大小 N 的变化。若数据集有 200 个观测，5 折 CV 使用大小为 160 的训练集，其表现与全量集几乎相同。但若仅有 50 个观测，5 折 CV 使用大小为 40 的训练集，将导致显著高估预测误差。

总体建议：5 折或 10 折 CV 作为折中方案。

15.10.3 广义交叉验证（GCV）

GCV 为线性拟合方法在平方误差损失下的 LOOCV 提供方便的近似。对线性拟合 $\hat{\mathbf{y}} = \mathbf{S}\mathbf{y}$ ：

$$\text{GCV}(\hat{f}) = \frac{1}{N} \sum_{i=1}^N \left[\frac{y_i - \hat{f}(x_i)}{1 - \text{tr}(\mathbf{S})/N} \right]^2 \quad (15.48)$$

其中 $\text{tr}(\mathbf{S})$ 是有效参数个数。当 $\text{tr}(\mathbf{S})$ 比单个 S_{ii} 更易计算时, GCV 有计算优势。在光滑问题中, GCV 还可缓解 CV 的欠光滑倾向。

GCV 与 AIC 的联系: 利用近似 $1/(1-x)^2 \approx 1+2x$ 可见其相似性。

15.10.4 交叉验证的正确与错误做法

常见错误: 先在全量数据上做变量筛选 (如选与标签最相关的 100 个预测变量), 再对筛选后的数据做 CV。这相当于筛选出的变量「已经见过」被留出的样本——CV 误差会严重偏低。

仿真示例: $N = 50$, $p = 5000$ 个与标签独立的预测变量, 真实误差率 50%。先用全量数据选 100 个最相关变量, 再对 1-NN 做 CV $\rightarrow$ 平均 CV 误差仅 3% (严重错误)。




图 15.7: 交叉验证的错误做法与正确做法对比。上图: 先在全量数据上做变量筛选再划分折——筛选时已「偷看」了所有样本的标签, 导致 CV 误差严重偏低。下图: 先划分折, 在每折的训练部分独立筛选变量和训练——CV 误差无偏。

这里「变量筛选」指的是从众多预测变量中挑选出一个子集——选列, 而非选值。




FIGURE 7.10. Cross-validation the wrong and right way: histograms shows the correlation of class labels, in 10 randomly chosen samples, with the 100 predictors chosen using the incorrect (upper red) and correct (lower green) versions of cross-validation.

图 15.8: 交叉验证的错误与正确方式: 直方图展示了在 10 个随机选择的样本中, 使用错误 (上, 红色) 和正确 (下, 绿色) CV 方式所选 100 个预测变量与类别标签的相关性。错误方式下相关性被人为夸大。

例如从 5000 个基因中挑出与标签 Y 最相关的前 100 个，扔掉其余 4900 个：

$$X_1, X_2, \dots, X_{5000} \xrightarrow{\text{按相关性排序截断}} X_{(1)}, X_{(2)}, \dots, X_{(100)}$$

筛选方法：对每个变量 j 单独计算 $|r_j| = |\text{Cor}(X_j, Y)|$ ，排序取最大的若干个。每折独立做——用该折的 40 个训练样本算相关性、独立排序、独立截断，各折选出的变量通常不同，不取平均。

完整流程演示 ($N = 50$, $p = 5000$, 5 折 CV, 1-NN 分类器)：

1. 随机将 50 人分成 5 折，每折 10 人。
2. **第 1 折做验证**：用折 2-5 的 40 人，对 5000 个基因逐一算 $|r_j|$ ，取前 100 个。用这 100 个基因和 40 人训练 1-NN，在折 1 的 10 人上算误差 e_1 。
3. **第 2 折做验证**：用折 1,3,4,5 的 40 人，重新算 $|r_j|$ 、重新选前 100（可能与折 1 不同！），训练并算 e_2 。
4. 第 3-5 折同理，分别得 e_3, e_4, e_5 。
5. $CV = \frac{1}{5}(e_1 + \dots + e_5)$ 。CV 的作用至此完成——它给出了用 100 个基因时 1-NN 的期望误差估计。
6. **训练最终模型**：回到全量 50 人，重新算 $|r_j|$ （这次用全部 50 人），取前 100 个基因。用这 100 个基因和全部 50 人训练最终 1-NN 分类器。这 100 个基因可能与任一折选出的都不同——这是正常的，因为现在是用全量数据筛选。
7. **最终评估**：在独立的测试集（从未参与上述任何步骤）上评估最终模型的泛化误差。

错误做法的区别仅在于第 1 步之前：先用全部 50 人算 $|r_j|$ 、一次性选出 100 个基因，此后各折不再重新筛选——这 100 个基因在筛选时已「见过」全部 50 人的标签，导致 CV 误差虚低。

这里有一个容易困惑的点：既然 CV 时每折独立筛选、最终训练又回到全量数据重新筛选，那 CV 到底做了什么决策？CV 的目的不是训练最终模型，而是**评估和选择方案**。比如你同时考虑三种方案——用 50 个基因、100 个基因、200 个基因——CV 分别给出它们的泛化误差估计，你据此选择最合适的方案（如 100 个基因）。决策完成后 CV 使命结束。最后一步用全量数据重新筛选 100 个基因并训练，是**充分利用所有数据产出最佳模型**——此时不再需要验证，用全量数据筛选不违反任何原则。两个阶段的分工：CV 负责选超参数，最终训练负责出模型。

正确做法：CV 必须应用于**整个建模流程**——样本必须在任何筛选步骤之前被留出。对 K 折 CV 的第 k 折：

1. 用除第 k 折外的样本筛选「好」变量

2. 用除第 k 折外的样本构建分类器
3. 在第 k 折上评估

唯一的例外是**无监督**的初始筛选（如按方差选变量）可在留出样本前进行——因为它不涉及标签，不会给变量不公平的优势。

15.10.5 交叉验证真的有效吗？——高维示例

考虑 $N = 20$ （两类各半）， $p = 500$ 个与标签独立的标准高斯预测变量，真实误差率 50%。使用单变量树桩（stump）分类器。简单论证认为 CV 会失败：因为全量数据上总能找到一个分裂得很好的预测变量，它在任何 $4/5$ 和 $1/5$ 子集上也应分裂得好。

图 7.11 的仿真表明这个论证是**错误**的——关键在于**分割点必须在 CV 的每折中重新估计**。对 50 个模拟数据集的 5 折 CV，平均误差率约为 50%，正是真实的期望预测误差。不过 CV 估计的变异性很大，报告 CV 估计的标准误差很重要。

15.11 自助法（Bootstrap）

自助法是一种评估统计准确性的通用工具。与交叉验证类似，Bootstrap 试图估计条件误差 Err_T ，但通常只能较好地估计期望预测误差 Err 。

15.11.1 基本思想

设训练集为 $\mathbf{Z} = (z_1, z_2, \dots, z_N)$ ，其中 $z_i = (x_i, y_i)$ 。基本做法是从 $\mathbf{Z}$ 中有放回地随机抽取 N 个样本，形成一个 Bootstrap 样本 $\mathbf{Z}^{*b}$ 。重复 B 次（如 $B = 100$ ），对每个 $\mathbf{Z}^{*b}$ 拟合模型 $\hat{f}^{*b}(x)$ 。

一个具体例子。设 $N = 5$ 的数据为 $\mathbf{Z} = \{z_1, z_2, z_3, z_4, z_5\}$ ，欲估计 $\bar{z}$ 的标准误差。

1. 从 $\mathbf{Z}$ 中有放回地抽 5 个样本，得 $\mathbf{Z}^{*1}$ 。例如抽到 $\{z_3, z_1, z_1, z_5, z_2\}$ （ z_1 出现两次， z_4 未出现）。计算 $\bar{z}^{*1}$ 。
2. 重复 $B = 1000$ 次： $\mathbf{Z}^{*1}, \mathbf{Z}^{*2}, \dots, \mathbf{Z}^{*1000}$ ，每次计算 $\bar{z}^{*b}$ 。
3. $\{\bar{z}^{*1}, \dots, \bar{z}^{*1000}\}$ 的样本标准差即为 $\bar{z}$ 标准误差的 Bootstrap 估计。

对于预测误差估计， $S(\mathbf{Z})$ 就是模型在原始训练集上的某种误差度量。Bootstrap 的核心优势是**无需假设数据分布**——仅通过重抽样模拟「从总体中反复抽样」的过程。直观理解：总体 F 不可知，样本 $\mathbf{Z}$ 是你对于 F 的全部认知，Bootstrap 把 $\mathbf{Z}$ 当作「迷你总体」，从中反复抽样来模拟从真总体反复抽样会发生什么——数据长什么样，Bootstrap 就照猫画虎，不需要假设正态或任何参数分布。




FIGURE 7.12. Schematic of the bootstrap process. We wish to assess the statistical accuracy of a quantity $S(\mathbf{Z})$ computed from our dataset. B training sets $\mathbf{Z}^{*b}$, $b = 1, \dots, B$ each of size N are drawn with replacement from the original dataset. The quantity of interest $S(\mathbf{Z})$ is computed from each bootstrap training set, and the values $S(\mathbf{Z}^{*1}), \dots, S(\mathbf{Z}^{*B})$ are used to assess the statistical accuracy of $S(\mathbf{Z})$.

图 15.9: Bootstrap 过程示意图。目标是从数据集计算出的量 $S(\mathbf{Z})$ 的统计准确性。 B 个训练集 $\mathbf{Z}^{*b}$ ($b = 1, \dots, B$) 各含 N 个观测，均从原始数据集中有放回抽取。在每个 Bootstrap 训练集上计算 $S(\mathbf{Z}^{*b})$ ，用 $S(\mathbf{Z}^{*1}), \dots, S(\mathbf{Z}^{*B})$ 来评估 $S(\mathbf{Z})$ 的统计准确性。

何时使用 Bootstrap? 当公式推导困难或不可行时。典型场景：估计中位数或自定义复杂统计量的标准误差、小样本下正态假设不成立、对非线性自适应模型估计预测误差（解析准则如 C_p 、AIC 失效）、以及任何需要评估统计量稳定性的场合。原则是「能用公式算就用公式，推不出就用 Bootstrap」，代价是计算量——需重复拟合 B 次模型（通常 $B = 200$ 或更多）。

每次 Bootstrap 样本平均含有约 $0.632N$ 个不同的原始观测（其余为重复），这一点在后面.632 估计的推导中起关键作用。

15.11.2 Bootstrap 估计预测误差

一种自然的做法是用 Bootstrap 样本拟合模型后，在原始训练集上评估：

$$\widehat{\text{Err}}_{\text{boot}} = \frac{1}{B} \frac{1}{N} \sum_{b=1}^B \sum_{i=1}^N L(y_i, \hat{f}^{*b}(x_i)) \quad (15.49)$$

但此估计通常很差——Bootstrap 样本与原始训练集有重叠，过拟合会导致估计过于乐观。例如对 1-NN 分类器，当预测变量与标签独立时（真实误差 50%）， $\widehat{\text{Err}}_{\text{boot}}$ 的期望仅为约 $0.5 \times 0.368 = 0.184$ 。这是因为一个观测不在某次 Bootstrap 样本中的概率约为：

$$\Pr\{\text{观测 } i \in \text{Bootstrap 样本 } b\} = 1 - \left(1 - \frac{1}{N}\right)^N \approx 1 - e^{-1} = 0.632 \quad (15.50)$$

留一 Bootstrap (leave-one-out bootstrap)：对每个观测 i ，仅使用不含 i 的 Bootstrap 样本来预测 i ：

$$\widehat{\text{Err}}^{(1)} = \frac{1}{N} \sum_{i=1}^N \frac{1}{|C^{-i}|} \sum_{b \in C^{-i}} L(y_i, \hat{f}^{*b}(x_i)) \quad (15.51)$$

其中 C^{-i} 是不含观测 i 的 Bootstrap 样本的索引集。留一 Bootstrap 解决了过拟合问题，但产生训练集大小偏差——每次 Bootstrap 样本平均仅含 $0.632N$ 个不同观测，其偏差大致类似于 2 折 CV。若学习曲线在 $N/2$ 处有显著斜率，留一 Bootstrap 会高估真实误差。

.632 估计：为缓解此偏差，将留一 Bootstrap 估计向训练误差方向拉回：

$$\widehat{\text{Err}}^{(.632)} = .368 \cdot \overline{\text{err}} + .632 \cdot \widehat{\text{Err}}^{(1)} \quad (15.52)$$

常数.632 来自 (15.50)。但.632 估计对过拟合严重的情况（如 1-NN 与独立标签）会低估误差——此时 $\widehat{\text{Err}}^{(1)} = 0.5$ ， $\overline{\text{err}} = 0$ ， $\widehat{\text{Err}}^{(.632)} = 0.316$ ，而真实误差为 0.5。

.632+ 估计：通过考虑过拟合程度来改进。定义无信息误差率 γ 为预测变量与标签独立时的误差率，其估计为：

$$\hat{\gamma} = \frac{1}{N^2} \sum_{i=1}^N \sum_{i'=1}^N L(y_i, \hat{f}(x_{i'})) \quad (15.53)$$

相对过拟合率:

$$\hat{R} = \frac{\widehat{\text{Err}}^{(1)} - \overline{\text{err}}}{\hat{\gamma} - \overline{\text{err}}} \quad (15.54)$$

$\hat{R}$ 从 0 (无过拟合) 到 1 (过拟合最严重)。 $.632+$ 估计为:

$$\widehat{\text{Err}}^{(.632+)} = (1 - \hat{w}) \cdot \overline{\text{err}} + \hat{w} \cdot \widehat{\text{Err}}^{(1)}, \quad \hat{w} = \frac{.632}{1 - .368\hat{R}} \quad (15.55)$$

权重 $\hat{w}$ 从 .632 (无过拟合) 到 1 (严重过拟合), 使 $.632+$ 在 $.632$ 估计和留一 Bootstrap 之间自适应插值。

15.11.3 示例: CV 与 Bootstrap 比较




FIGURE 7.13. Boxplots show the distribution of the relative error $100 \cdot [\text{Err}_{\hat{\alpha}} - \min_{\alpha} \text{Err}(\alpha)] / [\max_{\alpha} \text{Err}(\alpha) - \min_{\alpha} \text{Err}(\alpha)]$ over the four scenarios of Figure 7.3. This is the error in using the chosen model relative to the best model. There are 100 training sets represented in each boxplot.

图 15.10: 箱线图展示四个场景 (图 7.3) 下相对误差 $100 \cdot [\text{Err}_{\hat{\alpha}} - \min_{\alpha} \text{Err}(\alpha)] / [\max_{\alpha} \text{Err}(\alpha) - \min_{\alpha} \text{Err}(\alpha)]$ 的分布——即所选模型相对于最佳模型的误差百分比。每个箱线图代表 100 个训练集。上部为 10 折 CV, 下部为 $.632+$ Bootstrap。

箱线图读法：每个箱子代表一种场景（如「reg/KNN」即回归 + KNN）下 100 个训练集的相对误差分布。箱子中间的粗线为中位数，箱体上下沿为第 25 和 75 百分位（即中间 50% 数据的范围），延伸出的须线（whisker）达到约 $\pm 1.5 \times$ 四分位距内的最远点，须线外的空心点为离群值。纵轴「% Increase Over Best」表示：若最佳模型误差为 0.20，所选模型误差为 0.22，则相对误差为 $100 \times (0.22 - 0.20) / (\max - \min)$ 。数字越小说明选出的模型越接近最优。

从图中可见，CV 和 Bootstrap 在所有四个场景中整体良好，与 AIC（图 7.7）相比略优或持平。对模型选择目的，任一度量的偏差不影响相对排序。

然而作为**绝对误差估计**，AIC 平均高估 30%–51%，而 CV 仅高估 0%–4%，Bootstrap 与之相当。因此若需要准确的测试误差估计值，CV 或 Bootstrap 的额外计算代价是值得的。

注意对树等自适应方法，CV 和 Bootstrap 可低估真实误差约 10%（因为最优树的搜索受验证集影响强烈），此时只有独立测试集能提供无偏估计。

15.12 条件误差还是期望误差？

CV 到底估计的是 $\text{Err}_{\mathcal{T}}$ （条件误差）还是 Err （期望误差）？图 7.14 和图 7.15 给出了答案。

图 7.14 的仿真表明：10 折 CV 对 Err 的估计优于对 $\text{Err}_{\mathcal{T}}$ 的估计——10 折 CV 的黑曲线与 Err （红色）几乎重合，而与各 $\text{Err}_{\mathcal{T}}$ 的偏差更大。N 折（LOO）CV 的表现类似。


图 7.15 更揭示了惊人事实：CV 误差与条件误差 $\text{Err}_{\mathcal{T}}$ 之间的相关性往往是**负的**——CV 低的训练集反而可能泛化差。

结论：仅凭一份训练集自身的数据，通常难以估计该特定训练集的条件测试误差。CV 和相关方法能合理估计的是**期望误差** Err 。这一现象对 Bootstrap 误差估计同样成立。

简言之：CV 告诉我们「这个方法平均有多好」，而非「这一份数据训练的模型有多好」。从实践角度看这通常已足够——我们更关心方法的整体表现，而非某一次抽样的运气。

15.13 本章小结

15.13.1 核心框架



关键结论： CV / Bootstrap 实际估计的是 Err （期望误差），而非 $\text{Err}_{\mathcal{T}}$ 。仅凭一份训练集无法估计该份训练集的条件误差。

图 15.13: 第 7 章核心框架：四种误差量、两大目标、各类方法的对应关系。 C_p /AIC/BIC 估计样本内误差 Err_{in} ，常用于模型选择（只需相对比较）；CV/Bootstrap 直接估计期望误差 Err ，既可用于模型选择（计算代价更高但更通用），也可用于模型评估（需绝对值）。

15.13.2 方法选用指南




图 15.14: 模型评估与选择方法的选用决策树。选模型：线性 + 平方误差用 C_p ，否则 AIC/BIC (CV 也可但更慢)；评估：首选 CV，小样本或需精校用 .632+ Bootstrap。核心： C_p /AIC/BIC 估计 Err_{in} 用于比大小；CV/Bootstrap 直接估计 Err 可得绝对值，但所有方法估计的都是期望误差 Err 而非条件误差 $\text{Err}_{\mathcal{T}}$ 。

记忆要点： $C_p = \overline{\text{err}} + 2 \cdot \frac{d}{N} \hat{\sigma}_\epsilon^2$ (线性 + 平方误差) $\text{AIC} = -2\log\text{lik}/N + 2d/N$ (一般似然，渐近) $\text{BIC} = -2\log\text{lik} + d\log N$ (重罚，渐近一致)。CV 直接估计 Err，最通用，误差估计最准 (高估 0–4% vs AIC 高估 30–50%)。**关键局限：**所有方法估计的都是期望误差 Err，无法仅凭一份训练集估计该特定训练集的条件误差 $\text{Err}_{\mathcal{T}}$ 。

15.13.3 关键结论

1. **偏差-方差权衡**是模型选择的根基：复杂模型偏差低但方差高，最优复杂度在两者之间。
2. $\overline{\text{err}}$ 是唯一可算的，但它系统性偏低——所有方法本质上都是 $\widehat{\text{Err}} = \overline{\text{err}} + \hat{\omega}$ 。
3. **解析准则** (C_p , AIC, BIC) 估计 Err_{in} ，适合模型选择，计算快但只适用于参数可数的模型。AIC 渐近选复杂模型，BIC 渐近一致。
4. **重抽样方法** (CV, Bootstrap) 直接估计 Err，适用任何模型和损失函数，但计算量大。CV 的正确做法是包裹整个建模流程。
5. **关键局限：**所有方法估计的都是 Err (期望误差)，而非 $\text{Err}_{\mathcal{T}}$ (你手头这份训练集的条件误差)。独立的测试集是获得无偏 $\text{Err}_{\mathcal{T}}$ 估计的唯一途径。




FIGURE 7.14. Conditional prediction-error $\text{Err}_{\mathcal{T}}$, 10-fold cross-validation, and leave-one-out cross-validation curves for a 100 simulations from the top-right panel in Figure 7.3. The thick red curve is the expected prediction error $\text{Err}_{\mathcal{T}}$, while the thick black curves are the expected CV curves $\mathbb{E}_{\mathcal{T}}\text{CV}_{10}$ and $\mathbb{E}_{\mathcal{T}}\text{CV}_N$. The lower-right panel shows the mean absolute deviation of the CV curves from the conditional error, $\mathbb{E}_{\mathcal{T}}|\text{CV}_K - \text{Err}_{\mathcal{T}}|$ for $K = 10$ (blue) and $K = N$ (green), as well as from the expected error $\mathbb{E}_{\mathcal{T}}|\text{CV}_{10} - \text{Err}_{\mathcal{T}}|$ (orange).

图 15.11: 在图 7.3 右上场景的 100 次模拟中, 条件预测误差 $\text{Err}_{\mathcal{T}}$ 、10 折 CV 和留一 CV 曲线。粗红线为期望预测误差 $\text{Err}_{\mathcal{T}}$, 粗黑线为期望 CV 曲线 $\mathbb{E}_{\mathcal{T}}\text{CV}_{10}$ 和 $\mathbb{E}_{\mathcal{T}}\text{CV}_N$ 。右下面板展示 CV 曲线与条件误差的平均绝对偏差 $\mathbb{E}_{\mathcal{T}}|\text{CV}_K - \text{Err}_{\mathcal{T}}|$ ($K = 10$ 蓝色, $K = N$ 绿色), 以及与期望误差的偏差 $\mathbb{E}_{\mathcal{T}}|\text{CV}_{10} - \text{Err}_{\mathcal{T}}|$ (橙色)。




FIGURE 7.15. Plots of the CV estimates of error versus the true conditional error for each of the 100 training sets, for the simulation setup in the top right panel Figure 7.3. Both 10-fold and leave-one-out CV are depicted in different colors. The first three panels correspond to different subset sizes p , and vertical and horizontal lines are drawn at $\text{Err}(p)$. Although there appears to be little correlation in these plots, we see in the lower right panel that for the most part the correlation is negative.

图 15.12: CV 误差估计值与真实条件误差的散点图 (100 个训练集, 图 7.3 右上场景)。10 折 CV (蓝色) 和留一 CV (绿色) 分别展示。前三面板对应不同子集大小 p , 水平和垂直线标于 $\text{Err}(p)$ 处。图中散点几乎无相关性; 右下面板显示大部分情形下相关性为负。

第十六章 模型推断与平均

16.1 引言

此前章节中，模型拟合（学习）通过最小化平方和（回归）或交叉熵（分类）来实现。这些最小化本质上都是最大似然估计的特例。

本章将系统介绍最大似然方法和贝叶斯推断方法，并讨论 Bootstrap 在这两种框架下的角色。最后介绍模型平均与改进的相关技术，包括委员会方法、Bagging、Stacking 和 Bumping。

16.2 Bootstrap 与最大似然方法

16.2.1 一个光滑示例

Bootstrap 提供了一种直接的计算方式，通过从训练数据中抽样来评估不确定性。这里以一个一维光滑问题为例，展示其与最大似然的联系。

数据与模型：训练数据 $\mathbf{Z} = \{z_1, \dots, z_N\}$, $z_i = (x_i, y_i)$, x_i 为一维输入， y_i 为响应。考虑 $N = 50$ 的数据点（图 8.1 左面板）。用三次样条拟合，在 X 的四分位处放置三个结点，构成 7 维 B-样条基函数空间（图 8.1 右面板）：

$$\mu(x) = \sum_{j=1}^7 \beta_j h_j(x) \quad (16.1)$$

令 $\mathbf{H}$ 为 $N \times 7$ 矩阵， $h_{ij} = h_j(x_i)$ 。最小二乘估计为：

$$\hat{\boldsymbol{\beta}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y} \quad (16.2)$$

$\hat{\boldsymbol{\beta}}$ 的估计协方差矩阵为：

$$\widehat{\text{Var}}(\hat{\boldsymbol{\beta}}) = (\mathbf{H}^T \mathbf{H})^{-1} \hat{\sigma}^2 \quad (16.3)$$

其中 $\hat{\sigma}^2 = \sum_{i=1}^N (y_i - \hat{\mu}(x_i))^2 / N$ 。预测 $\hat{\mu}(x) = \mathbf{h}(x)^T \hat{\boldsymbol{\beta}}$ 的标准误差为：

$$\widehat{\text{se}}[\hat{\mu}(x)] = [\mathbf{h}(x)^T (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{h}(x)]^{1/2} \hat{\sigma} \quad (16.4)$$

右上展示了 $\hat{\mu}(x) \pm 1.96 \cdot \widehat{\text{se}}$ 的逐点 95% 置信带。




FIGURE 8.1. (Left panel): Data for smoothing example. (Right panel:) Set of seven B-spline basis functions. The broken vertical lines indicate the placement of the three knots.

图 16.1: (左) 光滑示例的数据。(右) 七个 B-样条基函数。竖直虚线指示三个结点的位置。

Bootstrap 做法: 从训练数据中有放回地抽取 B 个大小为 $N = 50$ 的数据集, 抽样单位为 (x_i, y_i) 对。对每个 Bootstrap 数据集拟合三次样条 $\hat{\mu}^*(x)$ 。图 8.2 左下展示了 10 次 Bootstrap 光滑, 右下为由 $B = 200$ 次 Bootstrap 的分位数构造的 95% 置信带——与最小二乘置信带相似, 在端点处略宽。

16.2.2 非参数 Bootstrap 与参数 Bootstrap

上述直接从数据中有放回重抽样的做法称为**非参数 Bootstrap** (nonparametric bootstrap), 它是「无模型」的——只用原始数据本身生成新数据集, 不依赖特定的参数模型。

若假设模型误差为高斯:

$$Y = \mu(X) + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2), \quad \mu(x) = \sum_{j=1}^7 \beta_j h_j(x) \quad (16.5)$$

则可使用**参数 Bootstrap** (parametric bootstrap): 向拟合值添加高斯噪声模拟新响应

$$y_i^* = \hat{\mu}(x_i) + \varepsilon_i^*, \quad \varepsilon_i^* \sim N(0, \hat{\sigma}^2), \quad i = 1, \dots, N \quad (16.6)$$

重复 B 次, 重新拟合 B-样条光滑。参数 Bootstrap 给出的置信带与最小二乘置信带**精确一致**——因为高斯误差的可加性。




FIGURE 8.2. (Top left:) B-spline smooth of data. (Top right:) B-spline smooth plus and minus $1.96 \times$ standard error bands. (Bottom left:) Ten bootstrap replicates of the B-spline smooth. (Bottom right:) B-spline smooth with 95% standard error bands computed from the bootstrap distribution.

图 16.2: (左上) 数据的 B-样条光滑。(右上) B-样条光滑 $\pm 1.96 \times$ 标准误差带。(左下) B-样条光滑的 10 次 Bootstrap 重复。(右下) 由 Bootstrap 分布构造的 95% 标准误差带。

16.2.3 最大似然推断

基本定义

设观测的密度函数（或概率质量函数）为 $z_i \sim g_\theta(z)$ ，其中 θ 为未知参数。似然函数定义为：

$$L(\theta; \mathbf{Z}) = \prod_{i=1}^N g_\theta(z_i) \quad (16.7)$$

对数似然（log-likelihood）为：

$$\ell(\theta; \mathbf{Z}) = \sum_{i=1}^N \log g_\theta(z_i) = \sum_{i=1}^N \ell(\theta; z_i) \quad (16.8)$$

最大似然估计（MLE） $\hat{\theta}$ 使 $\ell(\theta; \mathbf{Z})$ 最大化。

得分函数（score function）：

$$\dot{\ell}(\theta; \mathbf{Z}) = \sum_{i=1}^N \dot{\ell}(\theta; z_i), \quad \dot{\ell}(\theta; z_i) = \frac{\partial \ell(\theta; z_i)}{\partial \theta} \quad (16.9)$$

信息矩阵（information matrix）：

$$\mathbf{I}(\theta) = - \sum_{i=1}^N \frac{\partial^2 \ell(\theta; z_i)}{\partial \theta \partial \theta^T} \quad (16.10)$$

在 $\hat{\theta}$ 处取值时称为观测信息（observed information）。Fisher 信息（期望信息）为 $\mathbf{i}(\theta) = \mathbb{E}_\theta[\mathbf{I}(\theta)]$ 。

MLE 属于频率学派框架：参数 θ 是固定但未知的常数，数据是随机的；推断依赖「重复抽样下估计量的行为」。与之对照，贝叶斯学派将 θ 视为随机变量，用先验 $\Pr(\theta)$ 表达初始不确定性，数据固定后通过贝叶斯公式更新为后验 $\Pr(\theta | \mathbf{Z})$ 。频率学派给出置信区间（「若重复实验，95% 的区间会覆盖 θ 」），贝叶斯给出可信区间（「 θ 有 95% 概率在此区间」）。

实践中真的知道分布族吗？常不知道确切形式，但有合理理由假设：计数数据 $\rightarrow$ Poisson，二元结果 $\rightarrow$ Bernoulli，大样本独立和 $\rightarrow$ 近似正态（CLT）。有时为了数学可行性而假设（如回归中的高斯误差）。当不愿假设分布时，非参数 Bootstrap 是替代方案——直接从数据重抽样，不指定 g_θ 。这也是 §8.2 将 Bootstrap 和 MLE 放在同一章的原因。

MLE 框架的完整定义体系

除已给出的基本定义外，MLE 框架还包括以下核心概念：

- 一致性（Consistency）： $\hat{\theta} \xrightarrow{P} \theta_0$ ($N \rightarrow \infty$)，样本越大估计越准。

- **渐近有效性 (Asymptotic efficiency)**: $N \rightarrow \infty$ 时 MLE 达到 Cramér-Rao 下界 (见下文详述), 在所有渐近无偏估计中方差最小。
- **不变性 (Invariance)**: 若 $\hat{\theta}$ 是 θ 的 MLE, 则 $g(\hat{\theta})$ 是 $g(\theta)$ 的 MLE。
- **Delta 方法**: 用于求 $g(\hat{\theta})$ 的渐近分布: $\sqrt{N}(g(\hat{\theta}) - g(\theta_0)) \xrightarrow{d} N(0, g'(\theta_0)^2 / \mathbf{i}(\theta_0))$ 。
- **似然比检验 (LRT)**: $2[\ell(\hat{\theta}) - \ell(\theta_0)] \xrightarrow{d} \chi_p^2$, 即式 (16.19)。
- **Wald 检验**: 直接用 $\hat{\theta}$ 的渐近正态性检验 $H_0: \theta = \theta_0$ 。
- **得分检验 (Rao)**: 仅需在原假设下拟合模型, 计算量最小。
- **剖面似然 (Profile likelihood)**: 处理多余参数——对不感兴趣的参数取最大化后留轮廓。
- **指数族**: GLM 的基础, 似然标准形式为 $\exp\{[y\theta - b(\theta)]/a(\phi) + c(y, \phi)\}$ 。

LRT、Wald、得分检验合称 MLE 框架的「三大检验」。




图 16.3: MLE 框架的完整定义体系。自上而下: 数据 + 模型 $\rightarrow$ 似然 $\rightarrow$ 对数似然 $\rightarrow$ 得分 $\rightarrow$ MLE; 左下: 大样本性质 (一致性、有效性、渐近正态、不变性); 右下: 三大检验 (LRT、Wald、得分); 底部: 扩展工具 (Delta 方法、剖面似然、指数族)。

Cramér-Rao 下界

Cramér-Rao 下界 (CRLB) 给出了所有无偏估计量方差的下限, 是 Fisher 信息最核心的应用。设 $T(\mathbf{Z})$ 是 θ 的任意无偏估计量 ($\mathbb{E}_\theta[T] = \theta$), 在正则条件下:

$$\text{Var}_\theta(T) \geq \frac{1}{\mathbf{i}(\theta)} \quad (16.11)$$

其中 $\mathbf{i}(\theta) = \mathbb{E}_\theta[(\frac{\partial}{\partial \theta} \log g_\theta(Z))^2]$ 是 Fisher 信息 (单参数情形)。

多参数推广: 对 $\theta \in \mathbb{R}^p$, 无偏估计量 $\mathbf{T}$ 的协方差矩阵满足 $\text{Cov}_\theta(\mathbf{T}) \succeq \mathbf{i}(\theta)^{-1}$ (矩阵差为半正定), 各分量方差 $\text{Var}_\theta(T_j) \geq [\mathbf{i}(\theta)^{-1}]_{jj}$ 。

三种理解角度:

1. **参数估计精度的理论上限**— $\mathbf{i}(\theta)$ 越大, CRLB 越低, 参数能被估计得越精确。MLE 渐近达到此下界 (渐近有效性), 这就是为什么 MLE 在理论上是最优的。
2. **得分函数的方差 (基础定义)**— $\mathbf{i}(\theta) = \text{Var}_\theta[\dot{\ell}(\theta; Z)]$ 。得分函数衡量「数据对参数的敏感度」: 数据轻微变化, 得分剧烈波动 $\rightarrow$ 方差大 $\rightarrow$ 信息多 $\rightarrow$ 下界低。若不管数据怎么变得得分几乎不动 $\rightarrow$ 信息少 $\rightarrow$ 参数难以估计。
3. **区分邻近参数的能力 (KL 散度视角)**—两个邻近参数 θ 和 $\theta + d\theta$ 对应分布的 KL 散度展开为 $\text{KL}(g_\theta \parallel g_{\theta+d\theta}) \approx \frac{1}{2}\mathbf{i}(\theta)(d\theta)^2$ 。Fisher 信息大 $\rightarrow$ 邻近参数对应分布差异大 $\rightarrow$ 容易区分 $\rightarrow$ 可精确估计。Fisher 信息小 $\rightarrow$ 参数变化几乎不影响分布 $\rightarrow$ 不可识别。

与观测信息的区别: 观测信息 $\mathbf{I}(\hat{\theta})$ 和 Fisher 信息 $\mathbf{i}(\hat{\theta})$ 在大样本下等价, 均可用于构造标准误差。实践中 $\mathbf{I}(\hat{\theta})$ 更常用——它只需在 MLE 处计算二阶导数, 无需对 g_θ 积分。

正则条件与推导

CRLB 的成立需要以下正则条件 (regularity conditions):

1. **支撑集与 θ 无关:** $\{z : g_\theta(z) > 0\}$ 不依赖于 θ 。这排除了均匀分布 $U(0, \theta)$ 等边界随参数移动的情形。
2. **可微性:** $g_\theta(z)$ 对 θ 可微, 且积分和求导可交换次序:

$$\frac{\partial}{\partial \theta} \int g_\theta(z) dz = \int \frac{\partial}{\partial \theta} g_\theta(z) dz = 0 \quad (16.12)$$

3. **得分函数零均值:** 由条件 2 立即得到 $\mathbb{E}_\theta[\dot{\ell}(\theta; Z)] = 0$ 。
4. **Fisher 信息有限且正定:** $0 < \mathbf{i}(\theta) < \infty$ 。

推导 (单参数情形): 设 $T = T(\mathbf{Z})$ 为 θ 的任意无偏估计量, $\mathbb{E}_\theta[T] = \theta$ 。

由无偏性 $\int T(\mathbf{z}) g_\theta(\mathbf{z}) d\mathbf{z} = \theta$, 两边对 θ 求导:

$$\int T(\mathbf{z}) \frac{\partial g_\theta(\mathbf{z})}{\partial \theta} d\mathbf{z} = 1 \quad (16.13)$$

利用 $\frac{\partial g_\theta}{\partial \theta} = g_\theta \cdot \frac{\partial \log g_\theta}{\partial \theta} = g_\theta \cdot \dot{\ell}(\theta)$, 代入得:

$$\int T(\mathbf{z}) \dot{\ell}(\theta; \mathbf{z}) g_\theta(\mathbf{z}) d\mathbf{z} = \mathbb{E}_\theta[T \cdot \dot{\ell}] = 1 \quad (16.14)$$

又 $\mathbb{E}_\theta[\dot{\ell}] = 0$, 故 $\text{Cov}_\theta(T, \dot{\ell}) = \mathbb{E}_\theta[T \cdot \dot{\ell}] - \mathbb{E}_\theta[T] \cdot \mathbb{E}_\theta[\dot{\ell}] = 1$ 。

由 Cauchy-Schwarz 不等式:

$$1 = \text{Cov}_\theta(T, \dot{\ell})^2 \leq \text{Var}_\theta(T) \cdot \text{Var}_\theta(\dot{\ell}) = \text{Var}_\theta(T) \cdot \mathbf{i}(\theta) \quad (16.15)$$

移项即得:

$$\boxed{\text{Var}_\theta(T) \geq \frac{1}{\mathbf{i}(\theta)}} \quad (16.16)$$

取等条件: 当且仅当 T 和 $\dot{\ell}$ 线性相关, 即 $\dot{\ell}(\theta) = a(\theta)(T - \theta)$ 时等号成立。这意味着分布族必须是指数族且 T 是充分统计量——这正是 MLE 渐近达到下界的深层原因。

直观小结: CRLB 的推导核心只有三步: 无偏性 $\rightarrow$ 协方差为 1 $\rightarrow$ Cauchy-Schwarz 放缩。Fisher 信息出现在分母是因为它恰好是得分函数的方差。

三个完整示例

例 1: Bernoulli 试验 (p 未知)。 N 次独立抛硬币, 观测 $y_i \in \{0, 1\}, Y_i \sim \text{Bernoulli}(p)$ 。

- **模型:** $g_p(y) = p^y(1-p)^{1-y}$
- **对数似然:** $\ell(p) = \sum y_i \log p + \sum (1-y_i) \log(1-p) = N\bar{y} \log p + N(1-\bar{y}) \log(1-p)$
- **得分 (找 MLE):** $\dot{\ell}(p) = \frac{N\bar{y}}{p} - \frac{N(1-\bar{y})}{1-p} = 0 \Rightarrow \hat{p} = \bar{y}$ (样本均值)
- **信息 (算 SE):** $\mathbf{I}(\hat{p}) = -\ddot{\ell}(\hat{p}) = \frac{N}{\hat{p}(1-\hat{p})}$, 故 $\widehat{\text{se}}(\hat{p}) = \sqrt{\hat{p}(1-\hat{p})/N}$
- **CI (表达不确定性):** $\hat{p} \pm 1.96 \sqrt{\frac{\hat{p}(1-\hat{p})}{N}}$

数值演示: $N = 100$ 次抛硬币, 58 次正面。

- **MLE:** $\hat{p} = 58/100 = 0.58$
- **SE:** $\widehat{\text{se}} = \sqrt{0.58 \times 0.42/100} = 0.049$
- **95% CI:** $0.58 \pm 1.96 \times 0.049 = [0.484, 0.676]$

结论：硬币正面概率的 MLE 为 0.58，标准误差 0.049（基于 100 次观测的信息量）。95% 置信区间 $[0.484, 0.676]$ 包含 0.5——因此 58 次正面并不构成硬币不公平的充分证据（在 95% 置信水平下不能拒绝 $p = 0.5$ ）。这里得分求出了点估计，信息量化了精度（ $SE=0.049$ 意味着要检测出 0.08 的偏差，大约需要 $1.96 \times 0.049 < 0.08 \rightarrow N$ 不足），CI 把精度翻译为可读的区间。

例 2：高斯分布（ μ 未知， σ^2 已知）。 $Y_i \stackrel{\text{iid}}{\sim} N(\mu, \sigma_0^2)$ ， σ_0^2 已知。

- 对数似然： $\ell(\mu) = -\frac{N}{2} \log(2\pi\sigma_0^2) - \frac{1}{2\sigma_0^2} \sum (y_i - \mu)^2$
- 得分（找 MLE）： $\dot{\ell}(\mu) = \frac{1}{\sigma_0^2} \sum (y_i - \mu) = 0 \Rightarrow \hat{\mu} = \bar{y}$
- Fisher 信息（算 SE）： $\mathbf{i}(\mu) = -\mathbb{E}[\ddot{\ell}(\mu)] = N/\sigma_0^2$ ， $\widehat{\text{se}}(\hat{\mu}) = \sigma_0/\sqrt{N}$
- CI（表达不确定性）： $\bar{y} \pm 1.96 \sigma_0/\sqrt{N}$

数值演示：测量某零件长度 25 次，已知仪器精度 $\sigma_0 = 0.2$ mm， $\bar{y} = 10.3$ mm。

- MLE： $\hat{\mu} = 10.3$
- SE： $\widehat{\text{se}} = 0.2/\sqrt{25} = 0.04$
- 95% CI： $10.3 \pm 1.96 \times 0.04 = [10.22, 10.38]$

结论：零件平均长度为 10.3 mm，标准误差 0.04 mm（25 次测量 + 已知精度提供了足够信息）。95% CI $[10.22, 10.38]$ 很窄，说明估计相当精确。如果规格要求为 10.0 mm，则 CI 不包含 10.0——有明显偏差。这里 σ_0 已知使得信息可以直接写为 N/σ_0^2 ，不需要从数据估计。

例 3：高斯分布（ μ 和 σ^2 均未知）。 $Y_i \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$ ， $\theta = (\mu, \sigma^2)$ 。

- 对数似然： $\ell(\mu, \sigma^2) = -\frac{N}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum (y_i - \mu)^2$ （略去常数项）
- 得分方程组（联合求解）： $\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum (y_i - \mu) = 0$ ， $\frac{\partial \ell}{\partial \sigma^2} = -\frac{N}{2\sigma^2} + \frac{1}{2\sigma^4} \sum (y_i - \mu)^2 = 0$
- MLE： $\hat{\mu} = \bar{y}$ ， $\hat{\sigma}^2 = \frac{1}{N} \sum (y_i - \bar{y})^2$ （分母为 N ，非 $N-1$ ——MLE 不校正自由度）
- 观测信息矩阵：块对角（ μ 和 σ^2 在 MLE 处信息正交）， $\mathbf{I}_{11} = N/\hat{\sigma}^2$ ， $\mathbf{I}_{22} = N/(2\hat{\sigma}^4)$
- SE： $\widehat{\text{se}}(\hat{\mu}) = \hat{\sigma}/\sqrt{N}$ ， $\widehat{\text{se}}(\hat{\sigma}^2) = \hat{\sigma}^2\sqrt{2/N}$
- CI for μ ：由于 σ^2 未知，实际用 t 分布： $\bar{y} \pm t_{N-1, 0.975} \cdot s/\sqrt{N}$ （ s 为样本标准差 $s^2 = \sum (y_i - \bar{y})^2/(N-1)$ ）；大样本下近似于 $\bar{y} \pm 1.96 \cdot \hat{\sigma}/\sqrt{N}$

数值演示：测量 16 次， $\bar{y} = 10.3$ ， $s = 0.5$ ， $\hat{\sigma} = 0.484$ 。

- MLE： $\hat{\mu} = 10.3$ ， $\hat{\sigma}^2 = 0.234$

- **SE:** $\widehat{\text{se}}(\hat{\mu}) = 0.484/\sqrt{16} = 0.121$, $\widehat{\text{se}}(\hat{\sigma}^2) = 0.234 \times \sqrt{2/16} = 0.083$
- **95% CI for μ :** $10.3 \pm 2.131 \times 0.125 = [10.03, 10.57]$ (用 $t_{15,0.975} = 2.131$ 和 $s/\sqrt{16} = 0.125$); 大样本近似: $10.3 \pm 1.96 \times 0.121 = [10.06, 10.54]$
- **95% CI for σ^2 :** 基于卡方近似 $[\hat{\sigma}^2 \cdot \chi_{15,0.025}^2/15, \hat{\sigma}^2 \cdot \chi_{15,0.975}^2/15] = [0.128, 0.519]$

结论: 当 σ^2 未知时, μ 的 SE 变大了 (0.121 vs 例 2 的 0.04) ——多估计一个参数消耗了信息。信息矩阵的块对角性意味着 μ 和 σ^2 的 MLE 渐近不相关, 可以分别推断。 $\hat{\sigma}^2$ 的 MLE 有有限样本偏差 ($\mathbb{E}[\hat{\sigma}^2] = \frac{15}{16}\sigma^2$), 但 $N = 16$ 时偏差已很小, 且渐近性质优良——这是 MLE 的典型特征。

渐近正态性

经典结果: 当 $N \rightarrow \infty$ 时, MLE 的抽样分布趋于正态:

$$\hat{\theta} \rightarrow N(\theta_0, \mathbf{i}(\theta_0)^{-1}) \quad (16.17)$$

其中 θ_0 为真实参数值。实践中用以下近似:

$$\hat{\theta} \sim N(\hat{\theta}, \mathbf{i}(\hat{\theta})^{-1}) \text{ 或 } N(\hat{\theta}, \mathbf{I}(\hat{\theta})^{-1}) \quad (16.18)$$

标准误差的估计为 $\sqrt{\mathbf{i}(\hat{\theta})_{jj}^{-1}}$ 或 $\sqrt{\mathbf{I}(\hat{\theta})_{jj}^{-1}}$ 。置信区间形如 $\hat{\theta}_j \pm z^{(1-\alpha)} \cdot \widehat{\text{se}}$ 。也可直接利用似然函数构造更精确的置信区域——利用卡方近似:

$$2[\ell(\hat{\theta}) - \ell(\theta_0)] \sim \chi_p^2 \quad (16.19)$$

光滑示例的最大似然解

在光滑示例中, $\theta = (\beta, \sigma^2)$, 对数似然为:

$$\ell(\theta) = -\frac{N}{2} \log \sigma^2 2\pi - \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \mathbf{h}(x_i)^T \beta)^2 \quad (16.20)$$

MLE 解与最小二乘一致, β 的信息矩阵块为 $\mathbf{I}(\beta) = \mathbf{H}^T \mathbf{H} / \sigma^2$, 方差估计 $\widehat{\text{Var}}(\hat{\beta}) = (\mathbf{H}^T \mathbf{H})^{-1} \hat{\sigma}^2$ 与 (8.3) 一致。

16.2.4 Bootstrap 与最大似然的比较

Bootstrap 本质上是非参数或参数最大似然的计算机实现。其优势在于: 当解析公式不可得时, Bootstrap 仍能计算标准误差和其他量。

例如, 若结点数量和位置 λ 通过交叉验证自适应选择, 则标准误差和置信带应反映 λ 的变异性——解析上无法处理, 但 Bootstrap 可以在每轮重抽样中自适应选择 λ , 从而捕捉这种额外的不确定性。在多数使用更多自适应的实际问题中, 这一效应非常重要。

16.3 贝叶斯方法

16.3.1 基本框架

贝叶斯推断包含三个要素：

1. 抽样模型 $\Pr(\mathbf{Z} | \theta)$ ：给定参数下数据的分布
2. 先验分布 $\Pr(\theta)$ ：见到数据前对 θ 的了解
3. 后验分布：见到数据后对 θ 的更新认知

$$\Pr(\theta | \mathbf{Z}) = \frac{\Pr(\mathbf{Z} | \theta) \cdot \Pr(\theta)}{\int \Pr(\mathbf{Z} | \theta) \cdot \Pr(\theta) d\theta} \quad (16.21)$$


不确定性更新视角：公式中三个角色分工明确——**先验是起点**（数据前的信念），**似是更新器**（数据如何修改信念），**后验是终点**（更新后的信念）。后验通常比先验更集中（数据提供了信息），但除非数据无穷，否则不确定性不会归零。

与频率学派的分歧在“谁随机”：频率学派认为参数 θ 固定未知、**数据随机**（依赖重复抽样视角）；贝叶斯认为数据已实现、固定不变，**参数随机**（有分布）。同样“给定数据做推断”，两派眼中的随机性归属完全相反。

预测分布给出未来观测 z^{new} 的预测：

$$\Pr(z^{\text{new}} | \mathbf{Z}) = \int \Pr(z^{\text{new}} | \theta) \cdot \Pr(\theta | \mathbf{Z}) d\theta \quad (16.22)$$

这比最大似然插值式预测 $\Pr(z^{\text{new}} | \hat{\theta})$ 更合理——后者未考虑 θ 估计的不确定性。



先验知识错了会怎样？需区分“错在哪”：

- **先验的支撑不含真值**（如真实 $\theta = 5$ ，先验只在 $[0, 1]$ 上有质量）：后验永远无法接近真值——真实 θ 处 $\Pr(\mathbf{Z} | \theta) \Pr(\theta) = 0$ ，数据再多也救不回来，先验“不可反驳”地错。
- **先验形状偏了但支撑包含真值**（如真实 $\theta = 5$ ，先验集中在 3 附近）：数据足够多时，似然项越来越尖锐地压在真值附近，逐渐“淹没”先验（Bernstein–von Mises 定理），后验收敛到真值；但小样本下错误先验会显著带偏结论。

因此实践中倾向选**无信息/扩散先验**作为保守默认，并做**敏感性分析**（换几个先验看结论是否稳健）。频率学派“无先验”看似回避了此问题，代价是数据前无法融入知识、不确定性无法表达为概率——它只是把模型假设藏了起来，并非没有假设。

我们控制什么？目的是什么？ 贝叶斯中真正可控的是**先验**（最自由的建模选择）与**模型/似然**（分布族假设）；数据 $\mathbf{Z}$ 已实现、真实 θ 未知，均不可控。一旦选定先验与似然，后验就被贝叶斯公式**唯一确定**——贝叶斯里没有“最大化”（与 MLE 的优化不同），只有“乘起来、归一化”。目的分三层：**推断**（由后验回答 θ 的合理取值与不确定性）、**预测**（用后验做 $\Pr(z^{\text{new}} | \mathbf{Z})$ ）、**决策**（在期望损失意义下做最优决策、模型平均/选择，见 §8.8）。一句话：贝叶斯是概率论的“推理引擎”——输入先验、似然与数据，引擎内部按贝叶斯公式唯一运转，输出后验、预测与决策。

16.3.2 光滑示例的贝叶斯分析

在光滑示例中，假设模型 (8.5) 且 σ^2 已知。对 β 取高斯先验：

$$\beta \sim N(\mathbf{0}, \tau) \quad (16.23)$$

τ 控制先验的强度， τ 控制相关性结构。

后验分布也为高斯，均值和协方差为：

$$\begin{aligned} \mathbb{E}(\beta | \mathbf{Z}) &= \left(\mathbf{H}^T \mathbf{H} + \frac{\sigma^2}{\tau} \mathbf{I} \right)^{-1} \mathbf{H}^T \mathbf{y} \\ \text{Cov}(\beta | \mathbf{Z}) &= \left(\mathbf{H}^T \mathbf{H} + \frac{\sigma^2}{\tau} \mathbf{I} \right)^{-1} \sigma^2 \end{aligned} \quad (16.24)$$

$\mu(x)$ 的后验均值和协方差为：

$$\begin{aligned} \mathbb{E}(\mu(x) | \mathbf{Z}) &= \mathbf{h}(x)^T \left(\mathbf{H}^T \mathbf{H} + \frac{\sigma^2}{\tau} \mathbf{I} \right)^{-1} \mathbf{H}^T \mathbf{y} \\ \text{Cov}[\mu(x), \mu(x') | \mathbf{Z}] &= \mathbf{h}(x)^T \left(\mathbf{H}^T \mathbf{H} + \frac{\sigma^2}{\tau} \mathbf{I} \right)^{-1} \mathbf{h}(x') \sigma^2 \end{aligned} \quad (16.25)$$

取 $\tau = \mathbf{I}$ (B-样条基已保证光滑性)。图 8.3 展示了先验分布中 $\mu(x)$ 的 10 次抽样；图 8.4 展示了后验分布的 10 次抽样，取 $\tau = 1$ 和 $\tau = 1000$ 。

关键观察：当 $\tau \rightarrow \infty$ (无信息先验) 时，后验分布 (8.27) 与 Bootstrap 分布 (8.7) 完全一致。 $\tau = 1000$ 的右面板几乎等同于图 8.2 左下的 Bootstrap 分布。而 $\tau = 1$ 时后验曲线更光滑——更强的先验平滑约束。

Bootstrap 与贝叶斯的对应：在高斯模型中使用无信息先验时，最大似然和参数 Bootstrap 与贝叶斯分析趋于一致——因为常数先验下，后验正比于似然。这一对应关系也推广到非参数情形：非参数 Bootstrap 近似于无信息贝叶斯分析。

16.3.3 Bootstrap 与贝叶斯推断的正式关系

考虑一个极简例子：单个观测 $z \sim N(\theta, 1)$ 。取先验 $\theta \sim N(0, \tau)$ ，后验为：

$$\theta | z \sim N\left(\frac{z}{1 + 1/\tau}, \frac{1}{1 + 1/\tau}\right) \quad (16.26)$$

当 $\tau \rightarrow \infty$ (无信息先验) 时， $\theta | z \sim N(z, 1)$ ——这与参数 Bootstrap 分布一致 (重抽样 $z^* \sim N(\hat{\theta} = z, 1)$ 然后估计 $\hat{\theta}^* = z^*$)。

这种对应的三个条件：

1. 选择无信息先验
2. 对数似然对数据的依赖仅通过 $\hat{\theta}$: $\ell(\theta; \mathbf{Z}) = \ell(\theta; \hat{\theta})$

3. ℓ 在 θ 和 $\hat{\theta}$ 间的对称性: $\ell(\theta; \hat{\theta}) = \ell(\hat{\theta}; \theta) + \text{const}$


条件 2 和 3 严格仅在高斯分布下成立, 但多项分布下近似成立。

多项分布下的对应: 设样本空间有 L 个类别, w_j 为真实概率, $\hat{w}_j$ 为观测比例。取对称 Dirichlet 先验 $\mathbf{w} \sim \text{Di}_L(a\mathbf{1})$, 令 $a \rightarrow 0$ 得无信息先验, 后验为 $\mathbf{w} \sim \text{Di}_L(N\hat{\mathbf{w}})$ 。Bootstrap 抽样等价于 $\mathbf{w}^* \sim \frac{1}{N}\text{Mult}(N, \hat{\mathbf{w}})$ ——与后验有相同支撑集、相同均值、几乎相同的协方差。因此 Bootstrap 分布紧密近似后验分布。

一句话: Bootstrap 是「穷人的贝叶斯后验」——通过扰动数据来近似扰动参数的贝叶斯效果, 无需显式指定先验, 也无需从后验抽样。

四种方法的统一视角

参数 Bootstrap、非参数 Bootstrap、MLE、贝叶斯四者围绕同一个核心关系:



核心链条: MLE → 需要 SE/CI → 参数 Bootstrap (假设分布) → 不愿假设分布 → 非参数 Bootstrap (直接重抽样) → 无信息先验 → 贝叶斯后验。四种方法在渐近意义下等价——都是利用数据中的信息来刻画参数的不确定性, 区别仅在于对「数据生成机制」的假设强度。

简言之: MLE 给出点估计; 需要精度时, 若知道分布族用参数 Bootstrap, 不知道用非参数 Bootstrap; 若愿意引入先验知识, 用贝叶斯。扰动数据 (Bootstrap) 和扰动参数 (贝叶斯) 在渐近意义下殊途同归。

16.3.4 Bootstrap 用法总览

Bootstrap 的三方面应用与参数/非参数分类是两个独立维度——前者回答「抽完干什么」, 后者回答「怎么抽」:

应用方面	做什么	典型例子
统计推断	估计任意统计量 $S(\mathbf{Z})$ 的 SE / CI	中位数的标准误差、AUC 差的置信区间
预测误差估计	通过重抽样估计泛化误差（第 7 章）	$\widehat{\text{Err}}^{(1)}$ 、.632、.632+
模型改进	生成多个模型后组合以降低方差	Bagging、Bumping、随机森林

参数 Bootstrap（假设 g_θ ，从 $g_{\hat{\theta}}$ 抽） $\left\{ \begin{array}{ll} \text{统计推断} & \text{如光滑示例的标准误差带} \\ \text{预测误差估计} & \text{如 BIC 框架下的误差评估} \\ \text{模型改进} & \text{Bagging 通常在参数模型下} \end{array} \right.$

非参数 Bootstrap（不假设分布，从数据直接抽） $\left\{ \begin{array}{ll} \text{统计推断} & \text{分布未知时最通用} \\ \text{预测误差估计} & \text{CV 的竞争方法} \\ \text{模型改进} & \text{随机森林的本质} \end{array} \right.$

原则：知道分布族用参数 Bootstrap（更精确），不知道用非参数 Bootstrap（更通用）。第 7 章用 Bootstrap 估计误差，第 8 章用 Bootstrap 做推断和改进——同一工具，不同目的。

16.4 EM 算法

EM 算法是简化困难最大似然问题的流行工具。基本思想：引入**隐变量**（latent variables）使似然最大化变简单，然后迭代地估计隐变量、更新参数。

16.4.1 两分量高斯混合模型

图 8.5 显示了一个双峰数据集的直方图，单一高斯无法拟合。模型设为两个高斯分布的混合：

$$Y_1 \sim N(\mu_1, \sigma_1^2), \quad Y_2 \sim N(\mu_2, \sigma_2^2)$$
$$Y = (1 - \Delta) \cdot Y_1 + \Delta \cdot Y_2, \quad \Delta \in \{0, 1\}, \Pr(\Delta = 1) = \pi$$

(16.27)

混合密度为：

$$g_Y(y) = (1 - \pi)\phi_{\theta_1}(y) + \pi\phi_{\theta_2}(y)$$

(16.28)

参数 $\theta = (\pi, \mu_1, \sigma_1^2, \mu_2, \sigma_2^2)$ 。对数似然为 $\ell(\theta; \mathbf{Z}) = \sum_{i=1}^N \log[(1 - \pi)\phi_{\theta_1}(y_i) + \pi\phi_{\theta_2}(y_i)]$ ——直接最大化困难，因为对数内有求和。

引入隐变量 Δ_i ：若知道每个 y_i 来自哪个分量，对数似然分裂为：

$$\ell_0(\theta; \mathbf{Z}, \Delta) = \sum_{i=1}^N \left[(1 - \Delta_i) \log \phi_{\theta_1}(y_i) + \Delta_i \log \phi_{\theta_2}(y_i) \right] + \sum_{i=1}^N \left[(1 - \Delta_i) \log(1 - \pi) + \Delta_i \log \pi \right] \quad (16.29)$$

此时 MLE 就是简单的分组均值和方差。但 Δ_i 未知——所以取其期望（在当前参数估计下）：

$$\hat{\gamma}_i = \mathbb{E}[\Delta_i | \theta, \mathbf{Z}] = \Pr(\Delta_i = 1 | \theta, \mathbf{Z}) = \frac{\hat{\pi} \phi_{\hat{\theta}_2}(y_i)}{(1 - \hat{\pi}) \phi_{\hat{\theta}_1}(y_i) + \hat{\pi} \phi_{\hat{\theta}_2}(y_i)} \quad (16.30)$$

$\hat{\gamma}_i$ 称为观测 i 对分量 2 的责任（responsibility）。

EM 算法（两分量高斯混合）：

1. **初始化：** $\hat{\mu}_1, \hat{\mu}_2$ 取两个随机数据点； $\hat{\sigma}_1^2 = \hat{\sigma}_2^2$ 取总体方差； $\hat{\pi} = 0.5$ 。
2. **E 步（Expectation）：** 用当前参数计算责任 $\hat{\gamma}_i$ （式 8.42）。
3. **M 步（Maximization）：** 用 $\hat{\gamma}_i$ 作为权重计算加权均值和方差，更新 $\hat{\pi} = \frac{1}{N} \sum \hat{\gamma}_i$ 。
4. 迭代至收敛。

表 8.2 展示了实际数据（20 个点）的 EM 迭代过程，约 20 次后收敛： $\hat{\mu}_1 = 4.62$ ， $\hat{\mu}_2 = 1.06$ ， $\hat{\pi} = 0.546$ 。

16.4.2 EM 算法的一般形式

一般 EM（Algorithm 8.2）：观测数据 $\mathbf{Z}$ ，隐变量 $\mathbf{Z}^m$ ，完全数据 $\mathbf{T} = (\mathbf{Z}, \mathbf{Z}^m)$ ，完全数据对数似然 $\ell_0(\theta; \mathbf{T})$ 。

1. **E 步：** 计算 $Q(\theta', \hat{\theta}^{(j)}) = \mathbb{E}[\ell_0(\theta'; \mathbf{T}) | \mathbf{Z}, \hat{\theta}^{(j)}]$
2. **M 步：** $\hat{\theta}^{(j+1)} = \arg \max_{\theta'} Q(\theta', \hat{\theta}^{(j)})$

为什么 EM 有效？设 $\ell(\theta; \mathbf{Z})$ 为观测对数似然。令 $\theta^* = \hat{\theta}^{(j)}$ 。由于：

$$\ell(\theta'; \mathbf{Z}) = Q(\theta', \theta^*) - R(\theta', \theta^*) \quad (16.31)$$

其中 R 是条件对数似然的期望。由 Jensen 不等式， $R(\theta', \theta^*) \leq R(\theta^*, \theta^*)$ ，故 θ' 使 Q 增加必使 ℓ 增加。EM 永不降低似然。

E-M 作为联合最大化： EM 也可看作交替最大化函数 $F(\theta', \tilde{P}) = \mathbb{E}_{\tilde{P}}[\ell_0(\theta'; \mathbf{T})] - \mathbb{E}_{\tilde{P}}[\log \tilde{P}(\mathbf{Z}^m)]$ 。E 步在固定 θ' 下对 $\tilde{P}$ 最大化；M 步在固定 $\tilde{P}$ 下对 θ' 最大化。图 8.7 展示了此交替过程。

注记 16.1. M 步不需要完全最大化——只需增加 Q 即可（广义 EM，GEM）。EM 也可看作 minorization 过程（见练习 8.7）。

16.5 MCMC：从后验抽样

定义贝叶斯模型后，需要从后验分布抽样以做推断。除简单模型外，这通常很困难。本节讨论马尔可夫链蒙特卡洛（MCMC）方法。

16.5.1 背景与动机：为什么需要从后验分布抽样？

「定义贝叶斯模型后，需要从后验分布抽样以做推断」这句话的完整含义，需要拆开来谈：

1. 贝叶斯建模先给出后验分布。由贝叶斯公式

$$\Pr(\theta | \mathbf{Z}) = \frac{\Pr(\mathbf{Z} | \theta) \Pr(\theta)}{\int \Pr(\mathbf{Z} | \theta) \Pr(\theta) d\theta}$$

后验综合了先验知识 $\Pr(\theta)$ 与数据信息 $\Pr(\mathbf{Z} | \theta)$ 。

2. 所有推断都归结为对后验求期望。后验均值 $\mathbb{E}[\theta | \mathbf{Z}]$ 、后验方差、预测分布 $\Pr(z^{\text{new}} | \mathbf{Z})$ 等，都可以写成某个函数 $g(\theta)$ 在后验分布下的积分 $\int g(\theta) \Pr(\theta | \mathbf{Z}) d\theta$ 。
3. 但这个积分常常算不出来。复杂模型（高维、非共轭、多模态）下，后验没有解析形式，分母（归一化常数）也无法计算。
4. 抽样替代积分（蒙特卡洛）。若能「从后验分布抽出大量样本」 $\theta^{(1)}, \dots, \theta^{(M)}$ ，则由大数定律

$$\mathbb{E}[g(\theta) | \mathbf{Z}] \approx \frac{1}{M} \sum_{t=1}^M g(\theta^{(t)})$$

完全绕开了解析积分。这就是「需要从后验分布抽样以做推断」。

5. 最后的问题：后验很难直接抽样。后验分布不标准、归一化常数未知，逆变换法等直接抽样手段不可行。MCMC 的解决办法是：构造一条马尔可夫链，使它的平稳分布恰好是目标后验，让链跑足够久，链上的状态就近似是来自后验的样本。

注记 16.2. 整个动机链条：贝叶斯模型 → 需要后验期望 → 解析积分不可行 → 蒙特卡洛（抽样求期望）→ 无法直接抽样 → 构造以目标分布为平稳分布的马尔可夫链。EM 求点估计，MCMC 求分布，二者是同一类「隐变量迭代」思想的两面。

问：这里的「推断」是什么意思？

答：「推断」（inference）就是从数据对未知量做结论，并量化这种结论的不确定性。贝叶斯框架下，数据 $\mathbf{Z}$ 与先验只给出一张「关于 θ 的分布图」——后验 $\Pr(\theta | \mathbf{Z})$ 。它本身不是答案，而是所有知识的载体；「做推断」就是从这张图里读出我们关心的具体问题的答案：

- θ 大概是多少? $\rightarrow$ 后验均值 $\mathbb{E}[\theta | \mathbf{Z}]$ (类比频率学派的点估计)
- 有多大把握? $\rightarrow$ 后验可信区间 (θ 落在区间内的概率为 95%, 类比置信区间)
- 新观测会怎样? $\rightarrow$ 预测分布 $\Pr(z^{\text{new}} | \mathbf{Z})$
- 哪个模型更合理? $\rightarrow$ 模型后验概率 $\Pr(M_m | \mathbf{Z})$

换言之: 后验是「答案库」, 推断是「查询」。MCMC 抽样的意义在于——答案库里的量都是对后验的积分, 算不出来; 抽出大量样本后, 用样本平均近似这些积分, 就能完成查询。

16.5.2 先验如何作用: 后验是「先验 $\times$ 似然」的目标分布

「后验推不出来」的准确含义: 后验的公式永远存在——它是贝叶斯公式的定义; 推不出来的不是公式, 而是数值。能否解析读出后验, 取决于共轭性:

- 共轭情形 (先验与似然是「好搭档」, 如高斯先验 $\times$ 高斯似然): 分母积分能解析算出, 后验有闭合形式 (见 §8.3 光滑示例) ——**不需要 MCMC**。
- 非共轭情形: 分母 $\int \Pr(\mathbf{Z} | \theta) \Pr(\theta) d\theta$ 算不出来, 后验的归一化常数、均值、方差、分位数全都没有解析数值。此时后验「存在但读不出来」, 才需要 MCMC 数值读出。

一个没有解析数值的简单例子: 单个观测 $Y \sim N(\theta, 1)$ (高斯似然), 但先验取 Laplace (双指数) 分布 $\theta \sim \text{Laplace}(0, b)$, 密度正比于 $e^{-|\theta|/b}$ 。共轭性被破坏, 未归一化后验为

$$\Pr(\theta | y) \propto \underbrace{\exp\left(-\frac{(y-\theta)^2}{2}\right)}_{\text{似然}} \cdot \underbrace{\exp\left(-\frac{|\theta|}{b}\right)}_{\text{先验}}$$

归一化常数 $\int \exp\left(-\frac{(y-\theta)^2}{2} - \frac{|\theta|}{b}\right) d\theta$ 没有闭合形式——即使似然是最「友善」的高斯, 一旦先验换成 Laplace, 后验便失去解析解, 只能用抽样读出。

先验如何作用 (核心): 后验正比于

$$\pi(\theta) \propto \Pr(\mathbf{Z} | \theta) \Pr(\theta) \quad (16.32)$$

MCMC 的目标分布就是这个乘积 (未归一化)。于是先验作为乘法权重直接塑造了被抽样的分布: 先验密度高的区域乘积大、被访问得多; 先验密度为 0 的区域乘积恒为 0、抽样永远不会到达 (即使似然很大)。先验从未消失, 它内建在目标分布里。

MCMC 随机游走的形式化 (Metropolis-Hastings 视角): 设 $\pi(\theta)$ 如 (16.32)。每一步 t :

1. 从提议分布 $q(\theta' | \theta^{(t)})$ 提议候选 θ'
2. 以接受概率接受：

$$\alpha(\theta^{(t)} \rightarrow \theta') = \min \left\{ 1, \frac{\pi(\theta') q(\theta^{(t)} | \theta')}{\pi(\theta^{(t)}) q(\theta' | \theta^{(t)})} \right\}$$

3. 若接受则 $\theta^{(t+1)} = \theta'$ ，否则 $\theta^{(t+1)} = \theta^{(t)}$

两个关键观察：

1. 只需要未归一化的后验。接受概率中只出现密度比值 $\pi(\theta')/\pi(\theta)$ ，归一化常数 $Z = \int \Pr(\theta) \Pr(\mathbf{Z} | \theta) d\theta$ 在比值中被消掉——这正是 MCMC 能工作的原因：只需知道 $\pi \propto \text{先验} \times \text{似然}$ ，而无需算出那个算不出的积分。
2. 访问频率正比于 $\pi(\theta)$ 。链达到平稳后，在 θ 处停留的时间比例收敛到 $\pi(\theta)$ ，即按正比于 $\Pr(\theta) \Pr(\mathbf{Z} | \theta)$ 的密度访问 θ 。先验的乘法权重就这样进入每一步抽样：多访问先验支持的区域，永不去先验否决的区域。

注记 16.3. Gibbs 采样是 Metropolis–Hastings 的一个特例：其转移核即条件分布抽样，接受概率恒为 1。两种方法都只依赖「先验 $\times$ 似然」这个未归一化目标，区别仅在如何游走。

16.5.3 马尔可夫性质：如何体现？

马尔可夫性质指：给定「现在」，过去与未来条件独立，即

$$\Pr(U^{(t+1)} | U^{(t)}, U^{(t-1)}, \dots, U^{(0)}) = \Pr(U^{(t+1)} | U^{(t)})$$

一步转移只依赖当前状态，与更早的历史无关。

在 Gibbs 采样 (Algorithm 8.3) 中，这一性质直接体现：生成 $U_k^{(t)}$ 时只用

$$U_1^{(t)}, \dots, U_{k-1}^{(t)}, \quad U_{k+1}^{(t-1)}, \dots, U_K^{(t-1)}$$

即只依赖「现在」的状态向量 $U^{(t-1)}$ （以及本轮已更新的分量），不依赖 $U^{(t-2)}, U^{(t-3)}, \dots$ 。整条样本序列 $\{U^{(0)}, U^{(1)}, U^{(2)}, \dots\}$ 构成一条一阶马尔可夫链，其行为完全由转移核 $\Pr(U' | U)$ 描述。

注记 16.4. 强调：马尔可夫链的相邻样本不独立（它们强烈相关），不能直接当作独立同分布样本。但链收敛后，从长远看访问各状态的比例收敛到目标分布——我们只需对长期的样本求平均。相关性只影响估计的效率（需要更多样本），不影响正确性。

16.5.4 为什么联合分布最终稳定？

分两层理解：

(1) 目标联合分布是平稳分布 (stationary / invariant distribution)。若从分布 π 出发做一次转移后分布仍为 π ，即满足细致平衡 (detailed balance)

$$\pi(U) \Pr(U' | U) = \pi(U') \Pr(U | U')$$

则 π 是平稳分布。Gibbs 采样满足这一条件，直观理由是：若当前状态 U 已服从目标联合分布 π ，那么只把其中一个分量 U_k 按其条件分布 $\Pr(U_k | U_{-k})$ 重新抽样，新向量 $(U_1, \dots, U'_k, \dots, U_K)$ 仍然服从 π ——因为「从条件分布重新抽样」保持联合分布不变。逐分量依次操作，每一步都保持 π 不变，故 π 是平稳分布。

(2) 从任意初始分布收敛到平稳分布。在正则条件（不可约、非周期、正递归）下，马尔可夫链理论保证：无论从哪个初始状态 $U^{(0)}$ 出发，当 $t \rightarrow \infty$ 时 $U^{(t)}$ 的分布都收敛到唯一的平稳分布。直观上，每次转移都在状态分布空间上施加一次「混合」操作，反复施加会把任何初始分布「拉」向不动点——即平稳分布。因此需要一段 **burn-in**（烧入）期，丢弃开头未收敛的样本，只用收敛后的部分（式 (16.33) 中从 m 开始平均）。

16.5.5 一个具体的 Gibbs 采样例子

用一个离散二维例子直观展示整个过程。设目标联合分布 $\pi(x, y)$ ($x, y \in \{0, 1\}$) 为：

$$\pi(0, 0) = 0.1, \quad \pi(0, 1) = 0.2, \quad \pi(1, 0) = 0.3, \quad \pi(1, 1) = 0.4$$

边际为 $\pi(x=0) = 0.3$, $\pi(x=1) = 0.7$; $\pi(y=0) = 0.4$, $\pi(y=1) = 0.6$ 。由这些可算出所有条件分布，例如：

$$\pi(y | x) : \quad \pi(0 | 0) = \frac{1}{3}, \quad \pi(1 | 0) = \frac{2}{3}; \quad \pi(0 | 1) = \frac{3}{7}, \quad \pi(1 | 1) = \frac{4}{7}$$

$$\pi(x | y) : \quad \pi(0 | 0) = \frac{1}{4}, \quad \pi(1 | 0) = \frac{3}{4}; \quad \pi(0 | 1) = \frac{1}{3}, \quad \pi(1 | 1) = \frac{2}{3}$$

假设从任意起点 $(x, y) = (0, 0)$ 出发（它可能远离高概率区域，对应未收敛的 burn-in 期），开始交替抽样：

- 固定 $x = 0$ ，按 $\pi(y | x = 0)$ 抽 y ：以概率 $2/3$ 抽到 $y = 1$ ，状态变为 $(0, 1)$ 。
- 固定 $y = 1$ ，按 $\pi(x | y = 1)$ 抽 x ：以概率 $2/3$ 抽到 $x = 1$ ，状态变为 $(1, 1)$ 。
- 固定 $x = 1$ ，按 $\pi(y | x = 1)$ 抽 y ：以概率 $4/7$ 抽到 $y = 1$ ，状态仍为 $(1, 1)$ 。
- 继续迭代……

每一步都只依赖当前状态（马尔可夫性质），且每次条件抽样都让链在保持联合分布的意义下移动。长时间运行后，各状态被访问的频率收敛到目标联合分布：

$$\hat{\pi}(0,0) \rightarrow 0.1, \quad \hat{\pi}(0,1) \rightarrow 0.2, \quad \hat{\pi}(1,0) \rightarrow 0.3, \quad \hat{\pi}(1,1) \rightarrow 0.4$$

于是 $\mathbb{E}[g(X,Y)] \approx \frac{1}{M} \sum_t g(x^{(t)}, y^{(t)})$ 。教材中的高斯混合例子（Algorithm 8.4）原理与此完全相同，只是把离散状态换成连续参数：从 $\Pr(\Delta_i | \theta, \mathbf{Z})$ 和 $\Pr(\mu_1, \mu_2 | \Delta, \mathbf{Z})$ 交替抽样，最终收敛到参数的后验分布。

16.5.6 Gibbs 采样

设有随机变量 $U_1, U_2, \dots, U_K$ ，从联合分布直接抽样困难，但从每个条件分布 $\Pr(U_j | U_1, \dots, U_{j-1}, U_{j+1}, \dots, U_K)$ 抽样容易。Gibbs 采样（Algorithm 8.3）交替从每个条件分布模拟，过程稳定后即从目标联合分布抽样。

1. 初始化 $U_k^{(0)}$, $k = 1, \dots, K$
2. 对 $t = 1, 2, \dots$ ：依次从 $\Pr(U_k | U_1^{(t)}, \dots, U_{k-1}^{(t)}, U_{k+1}^{(t-1)}, \dots, U_K^{(t-1)})$ 抽样 $U_k^{(t)}$
3. 直到联合分布稳定

注记 16.5. Gibbs 采样与 EM 算法紧密相关：主要区别在于 Gibbs 从条件分布抽样，而 EM 在条件分布上取最大值。两者都是处理隐变量问题的迭代算法，只是目的不同——EM 求点估计（MAP），Gibbs 求分布。

收敛性与边际密度估计

Gibbs 采样之所以有效，是因为它产生一条马尔可夫链，其平稳分布（stationary distribution）恰为 $U_1, \dots, U_K$ 的真实联合分布——这正是「马尔可夫链蒙特卡洛」名称的由来。虽然不同 t 的样本 $(U_1^{(t)}, \dots, U_K^{(t)})$ 明显不独立，但在正则条件下该过程最终稳定，得到的随机变量确实是联合分布的一个样本。因为每一步都保持各个 U_k 的边际分布不变，所以真实联合分布是此过程的平稳分布。

达到平稳后，任何变量子集的边际密度都可以把密度估计方法应用于样本值来近似。若条件密度 $\Pr(U_k | U_\ell, \ell \neq k)$ 的显式形式已知，则 U_k 边际密度的更好估计为（练习 8.3）：

$$\widehat{\Pr}_{U_k}(u) = \frac{1}{M - m + 1} \sum_{t=m}^M \Pr(u | U_\ell^{(t)}, \ell \neq k) \quad (16.33)$$

其中对序列的最后 $M - m + 1$ 个成员求平均，以允许在达到平稳前有一段初始「烧入（burn-in）」期。

注记 16.6. 我们不需要知道条件密度的显式形式，只需能够从条件分布抽样。这就是 Gibbs 采样的实用门槛：对贝叶斯推断而言，只要给定其他参数和数据 $\mathbf{Z}$ 时每个参数的条件后验易于抽样，即可应用。

高斯混合模型的 Gibbs 采样

在指数族模型中，从后验的 Gibbs 采样与 EM 算法有密切联系。关键是把 EM 中的隐数据 $\mathbf{Z}^m$ 视为 Gibbs 采样器的另一个参数。对高斯混合问题，取参数为 (θ, Δ) ；为简洁固定 σ_1^2, σ_2^2 和 π 于其最大似然值，仅 μ_1, μ_2 未知。Gibbs 采样器 (Algorithm 8.4) 为：

1. 取初始值 $\theta^{(0)} = (\mu_1^{(0)}, \mu_2^{(0)})$

2. 对 $t = 1, 2, \dots$:

(a) 对 $i = 1, \dots, N$ 生成 $\Delta_i^{(t)} \in \{0, 1\}$ ，其中 $\Pr(\Delta_i^{(t)} = 1) = \hat{\gamma}_i(\theta^{(t)})$ (由式 (16.30) 的责任)

(b) 令

$$\hat{\mu}_1 = \frac{\sum_i (1 - \Delta_i^{(t)}) y_i}{\sum_i (1 - \Delta_i^{(t)})}, \quad \hat{\mu}_2 = \frac{\sum_i \Delta_i^{(t)} y_i}{\sum_i \Delta_i^{(t)}}$$

并生成 $\mu_1^{(t)} \sim N(\hat{\mu}_1, \hat{\sigma}_1^2)$ 、 $\mu_2^{(t)} \sim N(\hat{\mu}_2, \hat{\sigma}_2^2)$

3. 直到联合分布 $(\Delta^{(t)}, \mu_1^{(t)}, \mu_2^{(t)})$ 稳定

步骤 2(a) 和 2(b) 与 EM 的 E 步、M 步相同，区别仅在于**抽样而非最大化**：2(a) 不是计算最大似然责任 $\gamma_i = \mathbb{E}(\Delta_i | \theta, \mathbf{Z})$ ，而是从 $\Pr(\Delta_i | \theta, \mathbf{Z})$ 模拟隐数据 Δ_i ；2(b) 不是计算后验 $\Pr(\mu_1, \mu_2 | \Delta, \mathbf{Z})$ 的最大化者，而是从条件分布 $\Pr(\mu_1, \mu_2 | \Delta, \mathbf{Z})$ 模拟。

图 8.8 展示了 200 次 Gibbs 迭代：均值参数 μ_1 (下)、 μ_2 (上) 稳定后围绕最大似然估计 $\hat{\mu}_1, \hat{\mu}_2$ 均匀分布。更现实的做法是对 σ_1^2, σ_2^2 和 π 也放置先验，并加入单独的抽样步骤。注意均值参数的先验不能是**非正常先验** (improper prior)，否则会导致退化后验——所有权重落到一个分量上。

注记 16.7. Gibbs 采样会围绕 MLE 波动 (后验均值的中心是 $\hat{\mu}$)，而不是停在 MLE 上——因为后验是分布而非点。这是贝叶斯「推断分布而非点估计」思想的直接体现。

其他 MCMC 方法

Gibbs 采样只是从后验抽样的一类方法。它利用「给定其余参数时的条件抽样」，当问题结构使这种抽样容易时很有用。其他方法不要求这种结构，例如 **Metropolis–Hastings 算法**。这些计算贝叶斯方法已应用于高斯过程模型和神经网络等复杂学习算法。

16.5.7 MCMC 的实践：有限步收敛与诊断

平稳分布是 $t \rightarrow \infty$ 的极限性质，而所有 MCMC 使用都只有有限步。关键在于理解：我们并不需要「到达」平稳，只需要任意精确的近似，且这个近似由两部分误差控制：

$$\hat{\mathbb{E}}[g(\theta) | \mathbf{Z}] = \frac{1}{M} \sum_{t=1}^M g(\theta^{(t)}) \approx \mathbb{E}[g(\theta) | \mathbf{Z}]$$

误差的两个来源：

- **burn-in 误差**：链从初始状态出发，需要一段时间「忘记起点」，分布才接近平稳。实践中丢弃开头 m 个样本（烧入期，见式 (16.33)）。
- **蒙特卡洛误差**：即使已收敛， M 个样本的估计仍有方差，随 $1/\sqrt{M_{\text{eff}}}$ 衰减，其中 M_{eff} 是有效样本量（effective sample size, ESS）。因为链内样本相关， $M_{\text{eff}} \leq M$ ，相关性越强越小。

MCMC 与模拟退火的区别：模拟退火解决优化（把温度压到 $T \rightarrow 0$ ，使分布 $\pi(\theta)^{1/T}$ 收敛到众数，输出一个点）；MCMC 解决采样（还原整个分布，输出一串样本）。因此 MCMC 没有「模拟退火式的有限步保证」。但确有退火式改进技巧：**并行回火**（parallel tempering）同时跑几条不同温度的链，高温链分布平坦、易全局探索，低温链聚焦真实后验的模式，定期交换状态——用于帮助多模态、高相关的链更快混合，本质是增大谱隙、加速收敛，而非保证到达平稳。

数学视角：收敛其实是指数的。在正则条件下，有限步分布以几何速率逼近平稳：

$$\|\pi^{(t)} - \pi\|_{\text{TV}} \leq C \lambda_2^t$$

其中 λ_2 是转移核的第二大特征值，谱隙 $1 - \lambda_2$ 控制混合时间（mixing time）。收敛本身是指数的；问题是谱隙可能很小（高相关、多模态的链混合慢），此时需要的步数才多。

实践中的收敛诊断（有限步「是否够好」靠诊断而非保证）：

1. **轨迹图（trace plot）**：看链是否稳定振荡、无漂移趋势。
2. **Gelman–Rubin 诊断 $\hat{R}$** ：跑多条不同起点的链， $\hat{R}$ 接近 1（通常 < 1.1 ）表示各链分布一致、起点影响已消失。
3. **自相关时间与有效样本量 ESS**：判断需要多少样本才足够（ESS 越大越好）。

对一般目标分布，「是否已收敛」在理论上不可判定（无免费午餐），故实践中靠诊断 + 多条链交叉验证 + 领域常识来确认。

注记 16.8. 所有改善技巧（好的提议分布、参数化、并行回火）本质上都是在增大谱隙、加速混合，从而减小有限步近似的误差。

16.6 Bagging

此前我们用 Bootstrap 评估参数估计或预测的精度。本节展示如何用 Bootstrap 改进估计或预测本身。§8.4 中发现 Bootstrap 均值近似于后验平均，**Bagging** (bootstrap aggregation, Bootstrap 聚合) 进一步利用这一联系。

考虑回归问题：对训练数据 $\mathbf{Z} = \{(x_1, y_1), \dots, (x_N, y_N)\}$ 拟合模型，得到输入 x 处的预测 $\hat{f}(x)$ 。Bagging 在一组 Bootstrap 样本上平均这个预测，从而降低其方差。对每个 Bootstrap 样本 $\mathbf{Z}^{*b}$ ($b = 1, \dots, B$) 拟合模型，得预测 $\hat{f}^{*b}(x)$ ，Bagging 估计定义为：

$$\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x) \quad (16.34)$$

记 $\hat{P}$ 为对每个数据点 (x_i, y_i) 赋予等概率 $1/N$ 的经验分布。「真正的」Bagging 估计定义为 $\mathbb{E}_{\hat{P}} \hat{f}^*(x)$ ，其中 $\mathbf{Z}^* = \{(x_1^*, y_1^*), \dots, (x_N^*, y_N^*)\}$ 且每个 $(x_i^*, y_i^*) \sim \hat{P}$ 。式 (16.34) 是真实 Bagging 估计的蒙特卡洛估计， $B \rightarrow \infty$ 时逼近之。

注记 16.9. Bagging 只对数据的非线性或自适应函数有效果。例如 B-样条光滑对数据是线性的，故使用参数 Bootstrap 时 $\hat{f}_{\text{bag}}(x) \rightarrow \hat{f}(x)$ (练习 8.4) ——Bagging 只是复现原始光滑，没有改进。更典型的例子是回归树：每个 Bootstrap 树通常使用不同特征、可能有不同终结点数，Bagged 估计是这 B 棵树预测的平均。

16.6.1 分类情形：投票 vs 平均概率

若树产生 K 类分类器 $\hat{G}(x)$ ，可考虑底层指示向量函数 $\hat{f}(x)$ (一个 1、其余 $K-1$ 个 0)，使得 $\hat{G}(x) = \arg \max_k \hat{f}_k(x)$ 。此时 Bagged 估计 $\hat{f}_{\text{bag}}(x)$ 是 K 维向量 $[p_1(x), \dots, p_K(x)]$ ，其中 $p_k(x)$ 是预测第 k 类的树的**比例**。Bagged 分类器选择「得票」最多的类：

$$\hat{G}_{\text{bag}}(x) = \arg \max_k \hat{f}_{\text{bag},k}(x) \quad (16.35)$$

注记 16.10. 投票比例 $p_k(x)$ 未必是好的类概率估计。反例：若 x 处类 1 的真实概率为 0.75，且每个 Bagged 分类器都准确预测类 1，则 $p_1(x) = 1$ ，这是错误的。许多分类器 (如树的终结点类比例) 已有估计类概率的底层函数 $\hat{f}(x)$ ——更好的策略是**平均这些概率**而非投票指示向量。这既改进了类概率估计，又往往降低 Bagged 分类器的方差 (尤其小 B 时，见图 8.10)。

16.6.2 例：树与模拟数据

生成 $N = 30$ 的样本，两类、 $p = 5$ 个特征 (标准高斯、两两相关 0.95)。响应按 $\Pr(Y = 1 \mid x_1 \leq 0.5) = 0.2$ 、 $\Pr(Y = 1 \mid x_1 > 0.5) = 0.8$ 生成，贝叶斯误差为 0.2。对训练样本及 200 个 Bootstrap 样本拟合分类树 (不剪枝)。图 8.9 显示原始树和 11 棵 Bootstrap 树——它们完全不同 (不同的分裂特征和切点)。图 8.10 显示测试误差：由于预测变量相关，树的方差很高，Bagging 成功平滑了方差并降低测试误差。

16.6.3 Bagging 为什么有效

平方误差损失下, Bagging 能戏剧性地降低不稳定过程(如树)的方差。设训练观测独立同分布地来自分布 P , 考虑理想聚合估计 $f_{\text{ag}}(x) = \mathbb{E}_P \hat{f}^*(x)$ (x 固定, Bootstrap 数据集从真实总体 P 而非数据抽样)。它是不可用于实践的分析工具。可以写:

$$\begin{aligned} \mathbb{E}_P[Y - \hat{f}^*(x)]^2 &= \mathbb{E}_P[Y - f_{\text{ag}}(x) + f_{\text{ag}}(x) - \hat{f}^*(x)]^2 \\ &= \mathbb{E}_P[Y - f_{\text{ag}}(x)]^2 + \mathbb{E}_P[\hat{f}^*(x) - f_{\text{ag}}(x)]^2 \\ &\geq \mathbb{E}_P[Y - f_{\text{ag}}(x)]^2 \end{aligned} \quad (16.36)$$

右边多出的误差来自 $\hat{f}^*(x)$ 围绕其均值 $f_{\text{ag}}(x)$ 的方差。因此真实总体聚合从不增加均方误差。这提示 Bagging (从训练数据抽样) 通常会降低均方误差。

三层概念对照: 上述推导容易混淆, 这里明确区分三个对象:

名称	定义	从哪抽样	能否实现
理想聚合 $f_{\text{ag}}(x)$	$\mathbb{E}_P \hat{f}^*(x)$	真实总体 P	否 (P 未知)
真 Bagging	$\mathbb{E}_{\hat{P}} \hat{f}^*(x)$	经验分布 $\hat{P}$	仍是期望
实际 Bagging	$\frac{1}{B} \sum_b \hat{f}^{*b}(x)$	训练数据重抽样	是

实际 Bagging 是「真 Bagging」的蒙特卡洛估计 ($B \rightarrow \infty$ 时逼近之); 「真 Bagging」是「理想聚合」用经验分布 $\hat{P}$ 替换 P 的插件版本。平时所说的 Bagging 即第三行——从训练集抽样。

推导 (16.36) 的要点: 交叉项之所以消失, 是因为 $\mathbb{E}_P[\hat{f}^*(x)] = f_{\text{ag}}(x)$ (f_{ag} 正是 $\hat{f}^*$ 的期望), 故

$$\mathbb{E}_P[(Y - f_{\text{ag}}(x))(f_{\text{ag}}(x) - \hat{f}^*(x))] = 0$$

于是分解为「偏差 + 方差」, 而方差项 ≥ 0 , 去掉它只会更小——这正是「平均消除方差、不影响偏差」的数学来源。

两个常见误区:

- 「正常不就应该从训练集抽样吗?」对——实际 Bagging 就是从训练集 (经验分布 $\hat{P}$) 抽样。理想聚合从真实总体 P 抽样, 只是为推导而构造的思想实验, 不是实践算法。
- 「理想聚合不可用是因为抽到了测试集数据?」错——不可用的原因是真实总体 P 未知、无法从它抽样, 与测试集无关。实际做法是插件原则: 用经验分布 $\hat{P}$ (训练数据) 代替未知的 P 。

「真实总体聚合从不增加均方误差」的理解: 不等式 (16.36) 的比较对象是任意单个 Bootstrap 模型 $\hat{f}^*$:

$$\underbrace{\mathbb{E}_P[Y - \hat{f}^*(x)]^2}_{\text{随机抽一个 Bootstrap 模型的期望误差}} \geq \underbrace{\mathbb{E}_P[Y - f_{\text{ag}}(x)]^2}_{\text{聚合模型 } f_{\text{ag}} \text{ 的误差}}$$

左侧是「从 P 抽一个 Bootstrap 数据集、训练一个模型 $\hat{f}^*$ 」的期望误差；右侧是所有这些模型平均值 f_{ag} 的误差。结论：聚合模型的 MSE 不超过随机单个 Bootstrap 模型的期望 MSE。

机理：方差项正是单个模型的方差。 分解式中第二项 $\mathbb{E}_P[\hat{f}^*(x) - f_{\text{ag}}(x)]^2$ 就是单个模型围绕其均值（聚合值）波动的方差，它 ≥ 0 ，故「单个模型误差 = 聚合误差 + 单模型方差」。平均把这种抖动（方差）消掉，而 f_{ag} 本身是均值、没有围绕均值的波动——所以 MSE 不增。直觉：某 x 处 10 棵 Bootstrap 树的预测在 0.1, 0.3, ..., 0.9 间大幅抖动、真值为 0.5，随机挑一棵可能误差很大，平均后约 0.5、几乎无偏差。

两点边界（教材用词是「提示」而非严格保证）：

- **比较对象不是原始模型 $\hat{f}$ ：**不等式比较的是 f_{ag} 与随机单模型 $\hat{f}^*$ ；而实际 Bagging 想改进的是用全部数据训练的原模型 $\hat{f}$ （比单个重抽样模型更稳定）。故「提示」Bagging 通常会降低 MSE，是理想情形下的推断。
- **仅在平方损失下成立：**0-1 损失下偏差与方差不可加，见下节。

0-1 损失下不成立

上述论证在 0-1 损失分类下不成立，因为偏差和方差不可加。此时 Bagging 一个好分类器可以更好，但 Bagging 一个差分类器可能更差。简单反例（随机化规则）：设对所有 x 有 $Y = 1$ ，分类器 $\hat{G}(x)$ 以概率 0.4 预测 1、以概率 0.6 预测 0。则 $\hat{G}$ 的误分类率为 0.6，而 Bagged 分类器的误分类率为 1.0。

分类情形可用「独立弱学习者的共识」理解 (Dietterich, 2000a)。设二分类中贝叶斯最优决策为 $G(x) = 1$ ，每个弱学习者 G_b^* 有错误率 $e_b = e < 0.5$ ， $S_1(x) = \sum_{b=1}^B I(G_b^*(x) = 1)$ 为类 1 的共识票。弱学习者独立时 $S_1(x) \sim \text{Bin}(B, 1 - e)$ ，故 $\Pr(S_1 > B/2) \rightarrow 1$ (B 增大)。这被普及为「**众智 (Wisdom of Crowds)**」——多样化且独立的人群的集体知识通常超过任何个人，且可通过投票利用。

注记 16.11. 关键前提是「独立」——而 Bagged 树并不独立。第 15 章的**随机森林**正是通过降低抽样树之间的相关性来改进 Bagging。

Bagging 不生效的情形

Bagging 一个模型会**丢失模型的简单结构**——Bagged 树不再是树，解释性丧失。更稳定的过程（如最近邻）受 Bagging 影响很小；而最受益于 Bagging 的不稳定模型恰恰因强调可解释性而不稳定，这种可解释性在 Bagging 中丢失了。

图 8.12 展示 Bagging 无帮助的例子：100 个数据点、两个特征两类，被线性边界 $x_1 + x_2 = 1$ 分开，选择单个轴对齐分裂分类器。将 0-1 决策规则在 $B = 50$ 个 Bootstrap 样本上 Bagging 得到的边界（蓝线）未能捕捉真实边界。Bagging 估计的是单分裂规则的平均类概率，无法在单个复现中实现——如同「一个女人不可能有 2.4 个孩子」。Bagging

一定程度上扩大了基础分类器的模型空间，但在此类需要更大模型类扩展的例子中无济于事。「Boosting」正是扩展模型类的方法，见第 10 章。

16.7 模型平均与 Stacking

在 §8.4 中我们将估计量的 Bootstrap 值视为对应参数的后验值（一种非参数贝叶斯分析）。如此看来，Bagged 估计 (16.34) 是近似的后验贝叶斯均值，而训练样本估计 $\hat{f}(x)$ 对应后验的众数。由于后验均值（而非众数）最小化平方误差损失，Bagging 常能降低均方误差就不足为奇了。

更一般地讨论贝叶斯模型平均（Bayesian model averaging）。对训练集 $\mathbf{Z}$ 有一组候选模型 M_m ($m = 1, \dots, M$)，它们可以是同类型不同参数值（如线性回归的子集），或不同模型（如神经网络和回归树）。

设 ζ 是感兴趣的某个量（如固定特征值 x 处的预测 $f(x)$ ）。 ζ 的后验分布为：

$$\Pr(\zeta | \mathbf{Z}) = \sum_{m=1}^M \Pr(\zeta | M_m, \mathbf{Z}) \Pr(M_m | \mathbf{Z}) \quad (16.37)$$

后验均值为：

$$\mathbb{E}(\zeta | \mathbf{Z}) = \sum_{m=1}^M \mathbb{E}(\zeta | M_m, \mathbf{Z}) \Pr(M_m | \mathbf{Z}) \quad (16.38)$$

即各模型预测以模型后验概率为权重的加权平均。

此框架引出一系列模型平均策略：

- **委员会方法（committee methods）**：对每个模型的预测取简单无加权平均，本质上是给每个模型相等的概率。
- **BIC 加权**：§7.7 表明 BIC 准则可用于估计后验模型概率，适用于同一参数模型、不同参数值的情形。BIC 依据拟合好坏和参数数量给各模型权重。
- **完整贝叶斯**：若每个模型 M_m 有参数 θ_m ，

$$\Pr(M_m | \mathbf{Z}) \propto \Pr(M_m) \Pr(\mathbf{Z} | M_m) \propto \Pr(M_m) \int \Pr(\mathbf{Z} | \theta_m, M_m) \Pr(\theta_m | M_m) d\theta_m \quad (16.39)$$

原则上可指定先验 $\Pr(\theta_m | M_m)$ 并数值计算后验概率作为权重，但没有实际证据表明这比简单得多的 BIC 近似更值得。

BIC 的定义式与渐进：最常用的权重来自 **BIC 准则** (§7.7)。BIC 定义为

$$\text{BIC}_m = -2\ell(\hat{\theta}_m) + d_m \log N \quad (16.40)$$

其中 $\hat{\theta}_m$ 是模型 m 的最大似然估计， $\ell(\hat{\theta}_m)$ 是最大对数似然， d_m 是模型 m 的参数个数， N 是样本量。第一项 -2ℓ 衡量拟合好坏（越小越好），第二项 $d_m \log N$ 是复杂度惩罚（参数越多惩罚越大）——BIC 在「拟合」与「复杂度」之间取平衡。

BIC 的渐近合理性 (Laplace 近似)：在正则条件下，BIC 是「对数边际似然 $\log \Pr(\mathbf{Z} | M_m)$ 」的近似：

$$\log \Pr(\mathbf{Z} | M_m) = \ell(\hat{\theta}_m) - \frac{d_m}{2} \log N + O_P(1)$$

即 $\text{BIC}_m = -2 \log \Pr(\mathbf{Z} | M_m) + \text{const}$ 。于是模型后验概率可近似为（先验均匀时）

$$\Pr(M_m | \mathbf{Z}) \propto e^{-\text{BIC}_m/2}$$

这就是 BIC 作为 BMA 权重的基础：与 §7.7 模型选择一致——BIC 最小的模型后验概率最大。

注记 16.12. BMA 的深层动机不只是「让预测更有效」，而是把「选哪个模型」的不确定性也纳入预测——不把模型选择当作确定的一步，而是对候选模型平均。这与本章「量化不确定性」的主线一脉相承。

16.7.1 频率学派视角

给定预测 $\hat{f}_1(x), \dots, \hat{f}_M(x)$ ，在平方误差损失下求权重 $w = (w_1, \dots, w_M)$ 使得：

$$\hat{w} = \arg \min_w \mathbb{E}_P \left[Y - \sum_{m=1}^M w_m \hat{f}_m(x) \right]^2 \quad (16.41)$$

解是 Y 对 $\hat{F}(x)^T \equiv [\hat{f}_1(x), \dots, \hat{f}_M(x)]$ 的总体线性回归：

$$\hat{w} = \mathbb{E}_P[\hat{F}(x)\hat{F}(x)^T]^{-1} \mathbb{E}_P[\hat{F}(x)Y] \quad (16.42)$$

且完整回归的误差不超过任何单个模型：

$$\mathbb{E}_P \left[Y - \sum_{m=1}^M \hat{w}_m \hat{f}_m(x) \right]^2 \leq \mathbb{E}_P[Y - \hat{f}_m(x)]^2, \quad \forall m \quad (16.43)$$

即在总体层面，组合模型从不使事情变差。

但总体回归 (16.42) 不可得，自然地用训练集上的线性回归替代——但有简单反例说明这不奏效。若 $\hat{f}_m(x)$ 表示在 M 个总输入中大小为 m 的最佳输入子集的预测，则线性回归会把所有权重放在最大的模型上（ $\hat{w}_M = 1$ ，其余为 0）。问题在于没有通过考虑各模型的复杂度（本例中输入数量 m ）把它们放在同等的地位。

为什么训练集回归会偏爱复杂模型？ 直接原因有两点：

1. **嵌套结构**：大模型（ m 大的子集）通常嵌套小模型，在训练集上拟合更好，其预测与 y 的相关性更强；
2. **共线性**：各模型预测高度共线，最小二乘回归把权重几乎全部推给「训练集上最能解释 y 」的那个模型。

但训练集拟合好 $\neq$ 泛化好——复杂模型过拟合训练集，测试集上未必最优。因此直接在训练集上回归得到的权重反映的是训练拟合能力而非泛化能力，这正是 Stacking 需要改用「样本外」预测的原因。

16.7.2 Stacking

堆叠泛化 (stacked generalization)，或 **stacking** 是解决上述问题的方法。设 $\hat{f}_m^{-i}(x)$ 为使用模型 m 、去掉第 i 个训练观测后对 x 的预测。Stacking 的权重估计来自 y_i 对 $\hat{f}_m^{-i}(x_i)$ ($m = 1, \dots, M$) 的最小二乘回归：

$$\hat{w}^{\text{st}} = \arg \min_w \sum_{i=1}^N \left[y_i - \sum_{m=1}^M w_m \hat{f}_m^{-i}(x_i) \right]^2 \quad (16.44)$$

最终预测为 $\sum_m \hat{w}_m^{\text{st}} \hat{f}_m(x)$ 。通过使用交叉验证预测 $\hat{f}_m^{-i}(x)$ ，Stacking 避免了对复杂度更高的模型给予不公平的高权重。

为什么必须用「样本外」预测（而非训练集预测）赋权？若直接用训练集预测 $\hat{f}_m(x_i)$ 做回归，就掉进上文的陷阱——复杂模型在训练集上表现好而被过度偏爱。 $\hat{f}_m^{-i}(x_i)$ 是模型 m 在「没见过」的点 x_i 上的预测（留一交叉验证预测），公平反映其真实预测能力，不受过拟合偏袒。

Bootstrap 版本是否可行？——可行，是同一思想。除了留一，也可以用 Bootstrap 样本训练模型、在袋外样本 (out-of-bag, OOB) 上预测，再对 y 做最小二乘回归赋权 (**Bootstrap stacking**)。留一、K 折交叉验证、Bootstrap OOB 都是「用样本外预测公平赋权」这一思想的不同实现。教材选留一，是因为它简单，且与 §7.10 的留一交叉验证模型选择联系最直接（把权重限制为 one-hot 即退化为 LOOCV 选模型）。


注记 16.13. 将权重限制为非负且和为 1 可得到更好结果——若把权重解释为 (16.38) 的后验模型概率，这似乎合理，且导致可解的二次规划问题。

Stacking 与留一交叉验证的模型选择 (§7.10) 联系紧密：若把 (16.44) 的最小化限制在「一个单位权重、其余为零」的权重向量上，就得到留一交叉验证误差最小的模型选择 $\hat{m}$ 。Stacking 不是选择单个模型，而是以估计的最优权重组合它们——通常预测更好，但可解释性不如只选 M 个模型之一。

Stacking 的思想比上述更一般：组合模型时可用任何学习方法而不只是线性回归，权重也可依赖输入位置 x 。这样，学习方法被「堆叠」在彼此之上以改进预测性能。

16.7.3 小结：模型组合方法的谱系


§8.8 讨论了几种「组合多个模型」的策略。它们共享同一目标——用多个模型提升预测——但在「权重从哪来」「是否使用样本外信息」上各不相同，形成一条谱系：




三者的关系与取舍：

- **贝叶斯模型平均**：权重 = 模型后验概率（委员会 / BIC / 完整贝叶斯），把「选模型」的不确定性平均掉；权重的统计意义最清晰，但需指定先验或做近似。
- **频率学派最优权重**：理论上最优权重来自总体回归 (16.42)，但 P 未知；直接训练集回归偏爱复杂模型，不可用。
- **Stacking**：用样本外预测（留一 / K 折 / OOB）回归赋权，避开「偏爱复杂模型」问题，是频率学派想法的可用实现，也最灵活（可用任意学习器组合、权重可依赖 x ）。

频率学派赋权思路的演进：



Stacking 的机制：



注记 16.14. 若把 Stacking 的权重限制为 one-hot, 就退化为留一交叉验证模型选择; 若限制为等权, 就退化为委员会方法。因此 Stacking 是「委员会 (等权)」与「选最优模型 (one-hot)」之间的连续统一体——用数据学出最优权重。

16.8 随机搜索: Bumping

本章最后一个方法不涉及平均或组合模型, 而是寻找更好的单个模型的技术。Bumping 使用 Bootstrap 抽样在模型空间中随机移动。

与 Bagging 类似, 抽取 Bootstrap 样本并各拟合一个模型, 但不平均预测, 而是选择在训练数据上拟合最好的 Bootstrap 模型。具体地, 抽取 Bootstrap 样本 $\mathbf{Z}^{*1}, \dots, \mathbf{Z}^{*B}$ 并各拟合模型, 得到输入点 x 处的预测 $\hat{f}^{*b}(x)$ ($b = 1, \dots, B$), 然后选择在原始训练集上平均预测误差最小的模型。平方误差下, 选择来自 Bootstrap 样本 $\hat{b}$ 的模型:

$$\hat{b} = \arg \min_b \sum_{i=1}^N [y_i - \hat{f}^{*b}(x_i)]^2 \quad (16.45)$$

对应预测为 $\hat{f}^{*\hat{b}}(x)$ 。按惯例把原始训练样本也包含在 Bootstrap 样本集合中, 使方法在原始模型训练误差最低时自由选择之。

注记 16.15. 通过扰动数据, Bumping 试图把拟合过程移到模型空间的良好区域。若少数数据点导致过程找到差解, 任何省略这些点的 Bootstrap 样本都应产生更好的解。

例: XOR 问题 (图 8.13)。 两类、两个输入特征, 特征表现出纯交互作用。在 $x_1 = 0$ 处分裂、再在每个分块内于 $x_2 = 0$ 处分裂 (或反之), 树分类器即可完美判别。然而贪心短视的 CART 算法 (§9.2) 尝试在任一特征上找最佳分裂再分裂所得分块。由于数


据平衡, x_1 或 x_2 上的所有初始分裂看起来都没用, 过程在顶层本质上产生随机分裂。Bumping 通过 Bootstrap 抽样打破类别平衡, 在合理数量的 Bootstrap 样本 (此处 20) 下, 碰巧至少产生一棵初始分裂接近 $x_1 = 0$ 或 $x_2 = 0$ 的树。仅用 20 个 Bootstrap 样本, Bumping 就找到了接近最优的分裂 (图 8.13 右面板)。若加入若干与类别标签无关的噪声特征, 贪心树生长算法的这一缺陷会加剧——它无法区分 x_1, x_2 与其他特征, 会严重迷失。

注记 16.16. 由于 Bumping 在训练数据上比较不同模型, 必须确保模型复杂度大致相同 (树的情形即每个 Bootstrap 样本生长相同终结点数量的树)。Bumping 也有助于难以优化拟合准则的问题 (如缺乏光滑性) ——技巧是在 Bootstrap 样本上优化一个更方便的不同准则, 再选择在训练样本上对目标准则产生最佳结果的模型。


16.9 本章小结

16.9.1 核心框架：两条主线

第 8 章围绕「从数据量化不确定性」与「用数据改进预测」两条主线展开：频率学派与贝叶斯学派提供两种推断视角，Bootstrap 是连接二者的计算工具，EM 与 MCMC 处理隐变量问题，而 Bagging、模型平均与 Bumping 属于模型利用层面的改进。



16.9.2 方法选用指南



16.9.3 关键结论

1. 两种学派的根本分歧是「谁随机」：频率学派参数固定、数据随机（重复抽样视角），输出点估计 + 置信区间；贝叶斯学派数据固定、参数随机，输出整个后验分布 + 可信区间。贝叶斯的核心动机是量化不确定性。
2. **Bootstrap 是「穷人的贝叶斯后验」**：无信息先验下，后验 $\approx$ 似然 $\approx$ Bootstrap 分布。Bootstrap 既是评估工具（标准误、置信区间），也是改进工具（Bagging）——同一工具，两种用途。
3. **EM 与 MCMC 是同一隐变量结构的两面**：EM 用「期望 + 最大化」求 MLE 点估计（频率）；Gibbs 把「最大化」换成「抽样」，从后验分布抽样（贝叶斯）。区别是「点」与「分布」。
4. **MCMC 的实践本质**：平稳分布是极限，有限步只能给任意精度的近似；误差来自 burn-in 与蒙特卡洛（ESS）；靠 trace、 $\hat{R}$ 、自相关诊断；谱隙 $1 - \lambda_2$ 决定混合速度。
5. **Bagging 降方差、不扩模型类**：平方损失下理想聚合不增 MSE（消掉单模型方差）；但 Bagging 平均救不了表达能力不足的基础模型——这正是第 10 章 Boosting 的动机。

6. **模型组合的三条路线：** BMA（权重 = 模型后验概率，BIC 近似）、频率最优权重（总体回归，因 P 未知不可用）、Stacking（样本外预测公平赋权）。Stacking 是「等权委员会」与「选最优模型」之间的连续统一体。
7. **Bumping 帮助贪心算法跳出局部最优：** 通过 Bootstrap 扰动在模型空间随机移动，选择训练误差最小的模型（XOR 例），本质是随机化的模型搜索。

第十七章 加性模型、树及相关方法

第 9 章开始讨论监督学习的若干具体方法。这些方法都对未知回归函数假设某种（不同的）结构化形式，从而缓解维数灾难；代价是可能误设模型，因此每处都需要权衡。本章介绍五种相关技术：广义加性模型（GAM）、树（trees）、多元自适应回归样条（MARS）、患者规则归纳法（PRIM）与专家分层混合（HME）。本节先介绍其中的广义加性模型。

17.1 广义加性模型

传统线性模型虽然简洁，但现实效应往往非线性。此前章节用预定义基函数实现非线性；本节介绍更自动、灵活的统计方法——广义加性模型（Generalized Additive Models, GAM），用于识别和刻画非线性回归效应。

17.1.1 模型定义

回归设置下，广义加性模型形式为

$$\mathbb{E}(Y \mid X_1, X_2, \dots, X_p) = \alpha + f_1(X_1) + f_2(X_2) + \dots + f_p(X_p) \quad (17.1)$$

其中 f_j 是未指定的光滑（非参数）函数。与第 5 章「每个函数用基函数展开」不同，这里用散点图平滑器（如三次平滑样条或核平滑器）拟合每个函数，并提供同时估计全部 p 个函数的算法（§9.1.1）。

二分类情形（logistic）：回忆 §4.4 的二元数据 logistic 回归，把响应均值 $\mu(X) = \Pr(Y = 1 \mid X)$ 通过 logit 链接与预测变量线性相连。加性 logistic 回归把每个线性项换成更一般的函数形式：

$$\log \frac{\mu(X)}{1 - \mu(X)} = \alpha + f_1(X_1) + \dots + f_p(X_p) \quad (17.2)$$

非参数形式使模型更灵活，但保留可加性，因此解释方式与线性模型类似。加性 logistic 回归是 GAM 的一个例子。

一般地，响应 Y 的条件均值 $\mu(X)$ 通过链接函数 g 与预测变量的加性函数相连：

$$g[\mu(X)] = \alpha + f_1(X_1) + \dots + f_p(X_p) \quad (17.3)$$

常见链接函数：

- $g(\mu) = \mu$: 恒等链接, 用于高斯响应数据的线性/加性模型
- $g(\mu) = \text{logit}(\mu)$ 或 $g(\mu) = \text{probit}(\mu) = \Phi^{-1}(\mu)$: 二项概率
- $g(\mu) = \log(\mu)$: Poisson 计数数据的对数线性/对数加性模型

这三类都来自指数族抽样模型 (还包括 gamma、负二项分布), 构成著名的**广义线性模型 (GLM)**, 并同样推广为**广义加性模型**。

GAM 的灵活性:

- 可混合线性与非线性项——当某些输入是定性变量 (因子) 时需要参数形式
- 非线性项不限于主效应: 可以是两个以上变量的非线性分量, 或对因子 X_k 每个水平给出独立曲线
- 例: $g(\mu) = X^T\beta + \alpha_k + f(Z)$ (半参数模型, X 线性建模、 Z 非参数、 α_k 是定性输入 V 第 k 水平效应); $g(\mu) = f(X) + g_k(Z)$ (产生交互项 $g(V, Z) = g_k(Z)$); $g(\mu) = f(X) + g(Z, W)$ (g 是双特征非参数函数)

加性模型可在广泛场景替代线性模型, 例如时间序列的加性分解

$$Y_t = S_t + T_t + \varepsilon_t \quad (17.4)$$

其中 S_t 是季节分量、 T_t 是趋势、 ε 是误差项。

17.1.2 拟合加性模型: Backfitting

加性模型形式为

$$Y = \alpha + \sum_{j=1}^p f_j(X_j) + \varepsilon \quad (17.5)$$

其中误差项 ε 均值为零。给定观测 (x_i, y_i) , 可用类似 (5.9) 的惩罚平方和准则:

$$\text{PRSS}(\alpha, f_1, \dots, f_p) = \sum_{i=1}^N \left(y_i - \alpha - \sum_{j=1}^p f_j(x_{ij}) \right)^2 + \sum_{j=1}^p \lambda_j \int f_j''(t_j)^2 dt_j \quad (17.6)$$

其中 $\lambda_j \geq 0$ 是调节参数。可以证明 (9.7) 的极小化者是加性三次样条模型: 每个 f_j 是关于 X_j 的三次样条, 结点在 x_{ij} ($i = 1, \dots, N$) 的每个唯一值处。

为什么用惩罚项 (而不是显式基展开)? 这里与第 5 章形成两条路线的对比:

- **显式基展开 (第 5 章):** 预先选定基函数 (如 B 样条/自然样条) 并手动选择节点的位置与数量, 再最小二乘求系数——节点选择是复杂度控制的关键, 也是麻烦所在。

- **惩罚样条 (本节的 PRSS): 不需要选节点**——每个唯一观测值都作为节点, 靠曲率惩罚 $\lambda_j \int f_j''(t_j)^2 dt_j$ 控制光滑度。节点不再是复杂度控制: $\lambda_j \rightarrow \infty$ 时解退化为全局线性 ($df_j \rightarrow 2$), $\lambda_j \rightarrow 0$ 时解趋向插值 (过拟合)。

所以惩罚项的作用是**正则化**: 非参数 f_j 有无限自由度, 必须有惩罚约束; 同时它把「选节点」换成连续参数 λ_j (或等价地 df_j) 来控制复杂度。「解是自然三次样条、结点在所有观测处、边界线性」是优化问题的自动产物, 而非预先指定的基性质。

可识别性: 常数 α 不可识别——可以给每个 f_j 加/减任意常数, 再相应调整 α 。标准约定是 $\sum_i f_j(x_{ij}) = 0$ (各函数在数据上均值为零), 此时 $\hat{\alpha} = \text{ave}(y_i)$ 。若输入矩阵满列秩, 则 (9.7) 严格凸、极小值唯一; 若奇异, 则各分量的**线性部分**无法唯一确定 (非线性部分仍可, Buja et al., 1989)。

Backfitting 算法 (Algorithm 9.1):

1. 初始化: $\hat{\alpha} = \frac{1}{N} \sum_{i=1}^N y_i$, $\hat{f}_j \equiv 0$ ($\forall j$)
2. 循环 $j = 1, 2, \dots, p, 1, 2, \dots, p, \dots$:

$$\hat{f}_j \leftarrow S_j \left[\left\{ y_i - \hat{\alpha} - \sum_{k \neq j} \hat{f}_k(x_{ik}) \right\}_{i=1}^N \right], \quad \hat{f}_j \leftarrow \hat{f}_j - \frac{1}{N} \sum_{i=1}^N \hat{f}_j(x_{ij})$$

3. 直到 $\hat{f}_j$ 的变化小于预设阈值

其中 S_j 是对目标 $\{y_i - \hat{\alpha} - \sum_{k \neq j} \hat{f}_k(x_{ik})\}$ 关于 x_{ij} 的**三次平滑样条算子**。对每个预测变量依次操作, 计算 $y_i - \hat{\alpha} - \sum_{k \neq j} \hat{f}_k(x_{ik})$ 时使用其他函数的最新估计 $\hat{f}_k$ 。结果类似于线性模型的多重回归。

第二步 (重中心化) 在做什么? $\hat{f}_j \leftarrow \hat{f}_j - \frac{1}{N} \sum_i \hat{f}_j(x_{ij})$ 是把刚更新的 $\hat{f}_j$ 减去它在数据上的均值, 强制满足可识别性约束 $\sum_i f_j(x_{ij}) = 0$ 。原因: α 已锁死为 $\text{ave}(y_i)$, 若某次迭代后 $\hat{f}_j$ 均值不为零, 常数会在各函数间「漂移」、破坏「常数归 α 、函数归 f_j 」的分配。这一步**不是更新变化量** (更新在 $S_j[\dots]$ 那一行已完成), 而是把更新结果拉回均值零的约束流形——类似坐标下降中的投影。理论上它可省略 (对均值零响应的样条拟合均值也为零, 练习 9.1), 但实践中机器舍入会造成偏移 (slippage), 故建议保留。

平滑算子 S_j 做了什么? S_j 是「把散点 (x_j, r) 光滑成自然三次样条曲线」的**线性光滑算子**:

1. **输入**: 目标值向量 $r = \{r_i\}_{i=1}^N$ (在 Backfitting 中即部分残差), 对应输入点 $x_{1j}, \dots, x_{Nj}$
2. **操作**: 求最小化 $\sum_i (r_i - f(x_{ij}))^2 + \lambda_j \int f''(t)^2 dt$ 的函数 f ——在所有唯一 x_{ij} 处放节点, 第一项贴近数据、第二项惩罚弯曲, 解是自然三次样条 (分段三次多项式、拼接处连续到二阶导数、边界段线性)
3. **输出**: 光滑曲线 $\hat{f}_j$ 在数据点处的拟合值

作为线性算子，输出是输入的线性函数： $\hat{\mathbf{f}}_j = \mathbf{S}_j \mathbf{r}$ ，其中 $\mathbf{S}_j$ 是 $N \times N$ 算子矩阵（对称、半正定、行和为 1，类似「软投影」但非幂等）。Backfitting 正是用 S_j 把「 y 去掉其他所有变量贡献后」的部分残差，磨平成 x_j 的光滑效应——这就是「交替一元光滑」的原子操作。

算法的模块化：指定合适的平滑算子 S_j 即可容纳其他拟合方法：

- 一元回归平滑器：局部多项式回归、核方法
- 线性回归算子：多项式拟合、分段常数、参数样条、级数和 Fourier 拟合
- 更复杂算子：二阶及以上交互的表面平滑器、季节效应的周期平滑器

自由度：若只在训练点考察平滑算子 S_j ，可表示为 $N \times N$ 算子矩阵 $\mathbf{S}_j$ （见 §5.4.1）。第 j 项的自由度近似为

$$\text{df}_j = \text{trace}[\mathbf{S}_j] - 1 \quad (17.7)$$

对一大类线性平滑器，backfitting 等价于求解某个线性方程组的 **Gauss–Seidel 算法**（练习 9.2）。

对 logistic 回归等广义加性模型，合适的准则是**惩罚对数似然**；最大化时 backfitting 与似然最大化器结合使用。GLM 中常用的 Newton–Raphson 最大化对数似然可重写为 **IRLS（迭代加权最小二乘）** 算法：反复对工作响应变量关于协变量做加权线性回归，每次回归得到新的参数估计，再得到新的工作响应与权重，迭代进行。在 GAM 中，加权线性回归被替换为**加权 backfitting**。

GLM 与 GAM 是什么、关系如何？

- **GLM（广义线性模型）：**三个组成部分——**随机分量：**响应 Y 服从**指数族**分布（正态、二项、Poisson、gamma、负二项等）；**系统分量：**线性预测子 $\eta = \alpha + \beta_1 X_1 + \cdots + \beta_p X_p$ ；**链接函数：** $g(\mu) = \eta$ ，其中 $\mu = \mathbb{E}(Y | X)$ 。经典 GLM 中每个预测变量的贡献是**线性的**： $g(\mu) = \alpha + \sum_j \beta_j X_j$ 。例：线性回归（正态 + 恒等链接）、logistic 回归（二项 + logit 链接）、Poisson 回归（Poisson + log 链接）。
- **GAM（广义加性模型）：**把 GLM 的线性预测子换成**加性非参数形式** $g(\mu) = \alpha + \sum_j f_j(X_j)$ （式 (17.3)），每个 f_j 是未指定的光滑函数（§9.1.1 用平滑样条估计）。
- **关系：**GAM 是 GLM 的**非参数推广**——保留 GLM 的「随机分布（指数族）+ 链接函数 g 」框架不变，只把「线性项 $\beta_j X_j$ 」换成「光滑函数 $f_j(X_j)$ 」。当所有 f_j 都是线性函数时，GAM 退化为 GLM。这也解释了「广义」一词：链接与分布族共享，变的只是线性预测子被加性化。


拟合的对应关系：GLM 用 IRLS（每次迭代做**加权线性回归**）；GAM 只需把其中的加权线性回归替换为**加权 backfitting**（每次迭代做**加权平滑**）——这正是「加权线性回

归被替换为加权 backfitting」的含义：两者共享分布/链接框架，区别仅在「线性回归器」换成「平滑器」。

Newton-Raphson：求根思想与严格表述。它用于求方程 $f(x) = 0$ 的根（在优化中即解 $\nabla \ell(\theta) = 0$ ）。思想：在 x_k 处作一阶泰勒展开（切线近似），令其为零解出下一个近似：

$$f(x) \approx f(x_k) + f'(x_k)(x - x_k) = 0 \implies x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

即沿当前点切线的方向走到零点附近：



图：Newton 法一步：在 x_0 处作切线，切线与 x 轴的交点 x_1 比 x_0 更接近根 r 。

定理（Newton 法局部二阶收敛）：设 $f \in C^2$ 于含根 r 的开区间 I ，且 $f(r) = 0$ 、 $f'(r) \neq 0$ 。则存在邻域 $U \subset I$ 含 r ，使得对任意初值 $x_0 \in U$ ：

1. 迭代 $x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$ 明确定义且收敛到 r ；
2. 收敛为二阶：存在 $C > 0$ 使 $|x_{k+1} - r| \leq C|x_k - r|^2$ （有效位数每步翻倍）。

若 $f'(r) = 0$ （重根），收敛阶降为线性。该定理是**局部**的——初值必须落在收敛域内，否则可能发散。

推广到优化与多维：求最大化 $\ell(\theta)$ 即解 $\nabla \ell(\theta) = 0$ 。多维更新为

$$\theta_{k+1} = \theta_k - \mathbf{H}(\theta_k)^{-1} \nabla \ell(\theta_k)$$

其中 $\nabla \ell$ 为梯度（得分函数）， $\mathbf{H}$ 为 Hessian。对 GLM，指数族结构使该步等价于**加权最小二乘**（IRLS）；对 GAM，再把加权线性回归换成**加权 backfitting**（Local Scoring）。

注记 17.1. Newton 法二阶收敛（快），但需一阶/二阶导数、只局部收敛、Hessian 可能奇异；优点是初值好时极快，是 GLM/IRLS 等统计优化的骨架。

IRLS 算法步骤（拟合 GLM）：拟合 GLM 即最大化对数似然，等价于 Newton-Raphson；IRLS 把它重写为反复的加权最小二乘。给定当前参数 β ：

1. 计算线性预测子 $\hat{\eta}_i = x_i^T \beta$
2. 计算拟合均值 $\hat{\mu}_i = g^{-1}(\hat{\eta}_i)$ (g 为链接函数)
3. 构造工作响应 $z_i = \hat{\eta}_i + \frac{y_i - \hat{\mu}_i}{g'(\hat{\mu}_i)}$
4. 构造权重 $w_i = \frac{1}{V(\hat{\mu}_i) g'(\hat{\mu}_i)^2}$ ($V(\mu)$ 为指数族的方差函数)
5. 用权重 w_i 对工作响应 z_i 关于 x_i 做加权最小二乘, 得新 β

迭代 1–5 至收敛。对 logistic 回归: $g(\mu) = \text{logit}(\mu)$ 、 $V(\mu) = \mu(1-\mu)$, 于是 $w_i = \hat{\mu}_i(1-\hat{\mu}_i)$ 、 $z_i = \hat{\eta}_i + \frac{y_i - \hat{\mu}_i}{\hat{\mu}_i(1-\hat{\mu}_i)}$ ——正是 Algorithm 9.2 中的工作目标与权重。

例子 1: GLM (logistic 回归) 流程。 设 $X_1, X_2 \in \mathbb{R}$, $Y \in \{0, 1\}$, 模型 $\Pr(Y = 1 | X) = \sigma(\beta_0 + \beta_1 X_1 + \beta_2 X_2)$ (σ 为 sigmoid)。IRLS 流程: 初始化 $\beta = (0, 0, 0) \rightarrow$ 迭代「计算 $\hat{\eta}_i$ 、 $\hat{p}_i = \sigma(\hat{\eta}_i) \rightarrow$ 构造 z_i 、 $w_i = \hat{p}_i(1-\hat{p}_i) \rightarrow$ 加权最小二乘更新 β 」 $\rightarrow$ 收敛得 $\hat{\beta}$, 据此预测任意 x 处的 $\Pr(Y = 1)$ 。输出的是三个常数系数。

例子 2: GAM (加性 logistic) 流程。 同样的二分类, 但模型 $\Pr(Y = 1 | X) = \sigma(\alpha + f_1(X_1) + f_2(X_2))$ 。用 Algorithm 9.2 (Local Scoring): 外层仍是 Newton–Raphson / IRLS 的迭代, 但其中「加权线性回归」一步换成「加权 backfitting」——固定其他函数、对部分残差做加权平滑样条更新 f_j , 直到收敛。输出的是两条光滑曲线 f_1, f_2 (而非常数系数)。

对比与联系:

	GLM	GAM
预测子	$\eta = \alpha + \sum_j \beta_j X_j$ (线性)	$\eta = \alpha + \sum_j f_j(X_j)$ (加性非参数)
参数	有限维 β	无限维 (惩罚约束)
拟合	IRLS (加权最小二乘)	Local Scoring (IRLS + 加权 backfitting)
可解释	系数 β_j = 常数效应	曲线 f_j = 随 X_j 变化的效应
关系	GAM 的特例 (f_j 取线性)	保留 GLM 的分布 + 链接

联系: GAM 与 GLM 共享「指数族分布 + 链接函数 g 」框架; 区别只在预测子的函数形式 (线性 vs 加性光滑)。拟合层面, GAM 的 Local Scoring 就是在 IRLS 中把「加权线性回归」替换为「加权 backfitting」——结构完全对应、层层嵌套。

17.1.3 例: 加性 logistic 回归 (spam 数据)

医学研究中最常用的模型是二元数据的 logistic 模型: 结果 Y 编码为 0/1 (1 表示事件发生, 如死亡或疾病复发), 目标是建模 $\Pr(Y = 1 | X)$ (给定预后因子时事件的概率)。加性 logistic 模型为

$$\log \frac{\Pr(Y = 1 | X)}{\Pr(Y = 0 | X)} = \alpha + f_1(X_1) + \cdots + f_p(X_p) \quad (17.8)$$

Local Scoring 算法 (Algorithm 9.2) ——backfitting 嵌套在 Newton-Raphson 过程内:

1. 初始值: $\hat{\alpha} = \log[\bar{y}/(1 - \bar{y})]$ ($\bar{y} = \text{ave}(y_i)$ 为样本中 1 的比例), $\hat{f}_j \equiv 0$
2. 令 $\hat{\eta}_i = \hat{\alpha} + \sum_j \hat{f}_j(x_{ij})$, $\hat{p}_i = 1/[1 + \exp(-\hat{\eta}_i)]$, 迭代:
 - (a) 构造工作目标 $z_i = \hat{\eta}_i + \frac{y_i - \hat{p}_i}{\hat{p}_i(1 - \hat{p}_i)}$
 - (b) 构造权重 $w_i = \hat{p}_i(1 - \hat{p}_i)$
 - (c) 用权重 w_i 对目标 z_i 拟合加性模型 (加权 backfitting), 得新估计 $\hat{\alpha}, \hat{f}_j$
3. 直到函数变化低于预设阈值

spam 例子: 4601 封电子邮件 (检测垃圾邮件 spam), 57 个预测变量: 48 个定量词频 (business、address、internet、free、george 等)、6 个字符频 (ch;, ch(, ch[, ch!, ch\$, ch#)、以及 3 个大写字母统计 (CAPAVE 平均连续大写长度、CAPMAX 最长连续大写、CAPTOT 连续大写长度总和)。编码 spam = 1、email = 0。随机选 1536 为测试集、3065 为训练集。GAM 对每个预测变量用名义 4 自由度的三次平滑样条——即对每个 X_j 选择 λ_j 使 $\text{trace}[\mathbf{S}_j(\lambda_j)] - 1 = 4$ 。多数预测变量长尾分布, 拟合前做 $\log(x + 0.1)$ 变换。

测试误差 5.3% (线性 logistic 回归为 7.6%, 表 9.1 混淆矩阵)。表 9.2 将显著预测变量的贡献分解为**线性部分** + **非线性部分** (线性部分用加权最小二乘线性拟合, 非线性部分为残差)。图 9.1 显示许多非线性效应在 0 处有**强间断**: 例如 george 频率从 0 增加时 spam 概率显著下降, 之后几乎不变——提示可用「零计数」的指示变量代替频率, 再加线性项, 测试误差降至 6.6%。

非对称损失: 把真实 email 误判为 spam 更严重 (好邮件被过滤掉)。可通过改变损失 (§2.4) 调节两类错误率: 设 L_{01} 为把真 0 判 1 的损失、 L_{10} 为把真 1 判 0 的损失, 贝叶斯规则在概率大于 $L_{01}/(L_{01} + L_{10})$ 时判 1。取 $L_{01} = 10, L_{10} = 1$ 时两类错误率变为 0.8% 与 8.7%; 若再对类 0 观测加权 L_{01} 、类 1 观测加权 L_{10} , 错误率为 1.2% 与 8.0%。

17.1.4 小结

优点: 加性模型是线性模型的灵活扩展, 在更灵活的同时保留大部分可解释性。线性模型中熟悉的建模与推断工具同样可用于加性模型 (如表 9.2)。Backfitting 简单、模块化, 可对每个输入变量选择适当的拟合方法, 因此在统计界被广泛使用。

局限: 大数据挖掘应用中, backfitting 拟合所有预测变量不可行或不可取。**BRUTO** 过程 (Hastie and Tibshirani, 1990) 把 backfitting 与输入选择结合, 但并非为大规模问题设计。近年有使用 lasso 型惩罚估计稀疏加性模型的工作 (如 **COSMO** 的 Lin and Zhang, 2006、**SpAM** 的 Ravikumar et al., 2008)。对大规模问题, **前向分段 (forward stagewise)** 方法如 **boosting** (第 10 章) 更有效, 且可包含交互项。

注记 17.2. GAM 的「可加性」是它与完整非参数回归的关键区别：每个变量贡献独立相加，代价是不能自动捕捉变量间交互；好处是维数灾难被缓解、且每个 f_j 可单独可视化和解释（图 9.1）。这正好呼应本章开篇「结构化假设换取可解释性」的权衡。

17.2 基于树的方法

17.2.1 背景

基于树的方法把特征空间划分为一组矩形区域，并在每个区域内拟合简单模型（如常数）。它概念简单而强大。本节介绍 CART（分类与回归树），并与主要竞争对手 C4.5 对比。

特征空间的形式化定义：设有 p 个预测变量，每个观测的输入为 $x = (x_1, x_2, \dots, x_p)$ 。特征空间（feature space）是所有输入向量可能取值的集合：

$$\mathcal{X} = \mathcal{X}_1 \times \mathcal{X}_2 \times \dots \times \mathcal{X}_p \quad (17.9)$$

其中 $\mathcal{X}_j$ 是第 j 个变量的取值空间：连续变量 $\mathcal{X}_j \subseteq \mathbb{R}$ （ p 个变量全连续时 $\mathcal{X} \subseteq \mathbb{R}^p$ ）；分类变量 $\mathcal{X}_j$ 为有限集合。训练数据是其中的 N 个带响应点： $\mathbf{Z} = \{(x_i, y_i)\}_{i=1}^N$ ， $x_i \in \mathcal{X}$ ， $y_i \in \mathcal{Y}$ ；监督学习的目标是估计映射 $f: \mathcal{X} \rightarrow \mathcal{Y}$ 。

树的矩形划分：树方法把特征空间划分成互不相交的矩形区域（轴对齐盒）：

$$\mathcal{X} = \bigcup_{m=1}^M R_m, \quad R_m \cap R_{m'} = \emptyset \ (m \neq m') \quad (17.10)$$

每块 R_m 由一系列轴对齐条件（每个形如 $x_j \leq s$ 或 $x_j > s$ ）的交定义：

$$R_m = \{x \in \mathcal{X} : x_{j_1} \leq s_1, x_{j_2} > s_2, \dots\} \quad (17.11)$$

即坐标方向上的「切刀」反复切分特征空间。模型在每块内拟合常数 c_m ：

$$f(x) = \sum_{m=1}^M c_m I(x \in R_m) \quad (17.12)$$

几个相关形式化量（回归树）：记 $N_m = \#\{x_i \in R_m\}$ 为落入区域 R_m 的观测数，区域内拟合常数取均值

$$\hat{c}_m = \text{ave}(y_i \mid x_i \in R_m)$$

维数 p 即特征空间的维数； p 大时空间体积随维度指数增长（维数灾难），树通过「分块常数」这种强结构化假设来缓解。

考虑连续响应 Y 和输入 X_1, X_2 （都在单位区间）。图 9.2 左上展示用平行于坐标轴的直线划分特征空间，每个划分元素用不同常数建模 Y 。问题：虽然每条划分线有简单描述（如 $X_1 = c$ ），但有些区域难以描述。




FIGURE 9.2. Partitions and CART. Top right panel shows a partition of a two-dimensional feature space by recursive binary splitting, as used in CART, applied to some fake data. Top left panel shows a general partition that cannot be obtained from recursive binary splitting. Bottom left panel shows the tree corresponding to the partition in the top right panel, and a perspective plot of the prediction surface appears in the bottom right panel.

图 17.1: 划分与 CART (图 9.2)。右上: 对二维特征空间用递归二元划分 (CART 采用) 得到的分割; 左上: 无法由递归二元划分得到的一般分割; 左下: 与右上分割对应的树; 右下: 预测面的透视图。

递归二元划分: 为简化, 限制为递归二元划分 (图 9.2 右上)。先把空间分成两个区域, 用每个区域的 Y 均值建模响应; 选择变量和切点使拟合最优。然后其中一个或两个区域再分成两个区域, 如此继续直到某个停止规则。例如图 9.2: 先在 $X_1 = t_1$ 处分裂, $X_1 \leq t_1$ 的区域在 $X_2 = t_2$ 处分裂、 $X_1 > t_1$ 的区域在 $X_1 = t_3$ 处分裂, 最后 $X_1 > t_3$ 在 $X_2 = t_4$ 处分裂, 得到五个区域 $R_1, \dots, R_5$ 。对应的回归模型用区域 R_m 中的常数 c_m 预

测 Y :

$$\hat{f}(X) = \sum_{m=1}^5 c_m I\{(X_1, X_2) \in R_m\} \quad (17.13)$$

同一模型可用二元树表示 (图 9.2 左下): 数据集在树顶, 满足每个节点条件的观测走左支、否则走右支; 终结点 (叶) 对应区域 $R_1, \dots, R_5$ 。右下是预测面的透视图。

关键优势: 可解释性。特征空间划分由单棵树完整描述; 两个以上输入时划分难画, 但树表示同样工作。这在医学中很流行, 因为它模仿医生思考方式——树根据病人特征把总体分层为高/低结果。

17.2.2 回归树

如何生长回归树? 数据为 N 个观测 (x_i, y_i) , $x_i = (x_{i1}, \dots, x_{ip})$ 。算法需自动决定分裂变量、切点、以及树形 (topology)。先假设已有 M 个区域 $R_1, \dots, R_M$, 用每个区域的常数 c_m 建模:

$$f(x) = \sum_{m=1}^M c_m I(x \in R_m) \quad (17.14)$$

以最小化平方和 $\sum_i (y_i - f(x_i))^2$ 为准则, 最优 $\hat{c}_m$ 是区域 R_m 中 y_i 的平均:

$$\hat{c}_m = \text{ave}(y_i \mid x_i \in R_m) \quad (17.15)$$

贪心算法: 求最小化平方和的全局最优二元划分通常计算上不可行, 因此用贪心算法。从全部数据出发, 考虑分裂变量 j 和切点 s , 定义两个半平面:

$$R_1(j, s) = \{X \mid X_j \leq s\}, \quad R_2(j, s) = \{X \mid X_j > s\} \quad (17.16)$$

求使下式最小的 (j, s) :

$$\min_{j, s} \left[\min_{c_1} \sum_{x_i \in R_1(j, s)} (y_i - c_1)^2 + \min_{c_2} \sum_{x_i \in R_2(j, s)} (y_i - c_2)^2 \right] \quad (17.17)$$

对任意 (j, s) , 内层最小化由 $\hat{c}_1 = \text{ave}(y_i \mid x_i \in R_1(j, s))$ 、 $\hat{c}_2 = \text{ave}(y_i \mid x_i \in R_2(j, s))$ 解出。对每个分裂变量, 切点 s 的确定可很快完成, 扫描全部输入即可求最佳 (j, s) 。找到最佳分裂后, 把数据分成两个区域, 在每个区域重复分裂过程。

树该长多大? 大树可能过拟合, 小树可能漏掉重要结构。树大小是控制复杂度的调节参数, 应自适应选择。一种做法是只在分裂使平方和下降超过阈值时才分裂——但这也太短视 (看似无用的分裂可能带来其下很好的分裂)。**首选策略: 先长一棵大树 T_0** , 只在达到最小节点大小 (如 5) 时停止; 然后用**代价复杂度剪枝 (cost-complexity pruning)**。

定义子树 $T \subset T_0$ 为对 T_0 剪枝得到的任意树 (折叠任意内部节点)。设 $|T|$ 为 T 的终结点数, 定义

$$N_m = \#\{x_i \in R_m\}, \quad \hat{c}_m = \frac{1}{N_m} \sum_{x_i \in R_m} y_i, \quad Q_m(T) = \frac{1}{N_m} \sum_{x_i \in R_m} (y_i - \hat{c}_m)^2 \quad (17.18)$$

代价复杂度准则：

$$C_\alpha(T) = \sum_{m=1}^{|T|} N_m Q_m(T) + \alpha |T| \quad (17.19)$$

对每个 α ，求使 $C_\alpha(T)$ 最小的子树 $T_\alpha \subseteq T_0$ 。调节参数 $\alpha \geq 0$ 控制树大小与拟合的权衡： α 大 $\rightarrow$ 树小， α 小 $\rightarrow$ 树大， $\alpha = 0$ 时解为全树 T_0 。

对每个 α 存在唯一的最小化 $C_\alpha(T)$ 的最小子树 T_α 。用最弱链接剪枝 (**weakest link pruning**) 求 T_α ：依次折叠使 $\sum_m N_m Q_m(T)$ 每节点增加最小的内部节点，直到单节点（根）树。这给出有限子树序列，必含 T_α 。 α 用五折或十折交叉验证估计：选使交叉验证平方和最小的 $\hat{\alpha}$ ，最终树为 $T_{\hat{\alpha}}$ 。

17.2.3 分类树

若目标是取值 $1, \dots, K$ 的分类结果，树算法的变化只在节点分裂和剪枝准则。回归用平方误差节点不纯度 $Q_m(T)$ （式 (17.18)），不适合分类。在节点 m （区域 R_m ， N_m 个观测）中，设

$$\hat{p}_{mk} = \frac{1}{N_m} \sum_{x_i \in R_m} I(y_i = k)$$

为节点 m 中类 k 的比例。把节点 m 中的观测分类到多数类 $k(m) = \arg \max_k \hat{p}_{mk}$ 。节点不纯度 $Q_m(T)$ 的度量包括：

误分类误差： $1 - \hat{p}_{mk(m)}$

$$\text{Gini 指数：} \sum_{k \neq k'} \hat{p}_{mk} \hat{p}_{mk'} = \sum_{k=1}^K \hat{p}_{mk} (1 - \hat{p}_{mk}) \quad (17.20)$$

$$\text{交叉熵（偏差）：} - \sum_{k=1}^K \hat{p}_{mk} \log \hat{p}_{mk}$$

两类情形（ p 为第二类比例）下三者分别为 $1 - \max(p, 1 - p)$ 、 $2p(1 - p)$ 、 $-p \log p - (1 - p) \log(1 - p)$ （图 9.3）。三者相似，但交叉熵和 Gini 指数可微，更适合数值优化。分裂节点时需用两个子节点的观测数 N_{mL}, N_{mR} 加权不纯度。

此外，交叉熵和 Gini 对节点概率变化比误分类率更敏感。例：两类各 400 观测 (400, 400)，一个分裂产生 (300, 100) 和 (100, 300)，另一个产生 (200, 400) 和 (200, 0)——两者误分类率都是 0.25，但后者产生纯节点、更可取；Gini 和交叉熵对后者更低。因此生长树时用 Gini 或交叉熵；剪枝时三种都可用，但通常用误分类率。

Gini 的两种解释： 不把观测分到多数类，而以概率 $\hat{p}_{mk}$ 分到类 k ，则该规则在节点内的期望训练误差率正是 Gini 指数 $\sum_{k \neq k'} \hat{p}_{mk} \hat{p}_{mk'}$ ；把每个观测编码为类 k 则 1、否则 0，节点内 0-1 响应的方差为 $\hat{p}_{mk}(1 - \hat{p}_{mk})$ ，对所有类求和即 Gini 指数。

17.2.4 其他问题

分类预测变量：有 q 个无序取值的预测变量分裂时，有 $2^q - 1$ 种把 q 个值分成两组的可能划分， q 大时计算不可行。但 0-1 结果时计算可简化：按结果类 1 中的比例排序预测变量类别，然后当作有序预测变量分裂——可证明这在交叉熵或 Gini 意义上给出所有 $2^q - 1$ 种分裂中的最优分裂（定量结果 + 平方损失也成立，按结果均值递增排序；Fisher, 1958）。多类别结果无此简化。**注意：**划分算法倾向偏爱水平数 q 多的分类预测变量（选择越多越容易对当前数据找到好的）， q 大时会导致严重过拟合，应避免。

损失矩阵：分类中某些类误分类的后果更严重（如把有心脏病的人预测为没有）。定义 $K \times K$ 损失矩阵 L ， $L_{kk'}$ 是把类 k 观测分成类 k' 的损失，通常 $L_{kk} = 0$ 。可把 Gini 指数修改为 $\sum_{k \neq k'} L_{kk'} \hat{p}_{mk} \hat{p}_{mk'}$ （随机规则的期望损失）——多类有效，但二类时因系数为 $L_{kk'} + L_{k'k}$ 而无效果。二类更好的方法是对类 k 的观测加权 $L_{kk'}$ （仅当作为 k 的函数 $L_{kk'}$ 不依赖 k' 时可用于多类）。观测加权可配合偏差使用，效果是改变类的先验概率。终节点中经验贝叶斯规则分类到 $k(m) = \arg \min_k \sum_{\ell} L_{\ell k} \hat{p}_{m\ell}$ 。

缺失预测值：丢弃含缺失值的观测可能严重削减训练集；填充（如均值）也可行。树模型有更好的两种方法：**分类预测变量：**为「缺失」建一个新类别；**更一般：替代变量（surrogate variables）。**分裂时只用该预测变量不缺失的观测；选定最佳（主）预测变量和切点后，形成替代预测变量和切点列表——第一替代是最能模仿主分裂的预测变量，第二替代次之，依次类推。训练或预测中，若主分裂变量缺失，就依次使用替代分裂。替代分裂利用预测变量间的相关性缓解缺失的影响。缺失数据的一般问题见 §9.6。

为什么二元分裂？多元分裂（一次分多组）会过快碎片化数据，使下一层数据不足。多元分裂可用一系列二元分裂实现，因此后者更可取。

其他树构建方法：讨论聚焦 CART。另一流行方法是 ID3 及其后续 C4.5、C5.0（Quinlan, 1993）。早期版本限于分类预测变量、自顶向下且不剪枝；C5.0 与 CART 已很相似。C5.0 独有的最重要特性是推导**规则集**：树长好后，定义终节点的分裂规则有时可简化（去掉一个或多个条件不改变落入节点的观测子集），得到简化的规则集——不再是树结构，但更简单、对用户更有吸引力。

线性组合分裂：可允许沿 $\sum_j a_j X_j \leq s$ 形式的线性组合分裂，权重 a_j 和切点 s 优化以最小化相关准则（如 Gini）。可提高预测力但损害可解释性；切点搜索的离散性使权重无法用光滑优化。更好的方式是在 **HME（专家分层混合）** 模型中引入 (§9.5)。

树的不稳定性：主要问题是高方差。数据的微小变化常导致完全不同的分裂序列，使解释不稳。主因是过程的层次性：顶层分裂的错误会传播到其下所有分裂。可用更稳定的分裂准则缓解，但固有不确定性无法消除——这是从数据估计简单树结构的代价。

Bagging (§8.7) 平均许多树来降低此方差。

缺乏光滑性：预测面不光滑（图 9.2 右下）。0/1 损失分类下影响不大（类概率估计的偏差影响有限），但回归设置中会降低性能（通常期望底层函数光滑）。**MARS (§9.4)** 可看作缓解此缺点的 CART 修正。

难以捕捉加性结构：树难以建模加性结构。例： $Y = c_1 I(X_1 < t_1) + c_2 I(X_2 < t_2) + \varepsilon$ 。

二元树第一层在 X_1 上近 t_1 分裂；下一层需在 X_2 的 t_2 处分裂两个节点才能捕捉加性结构——数据充足时可能发生，但模型没有被特别鼓励去找这种结构。若有十个加性效应，需很多凑巧的分裂才能重建结构。MARS 放弃树结构以捕捉加性结构。

17.2.5 spam 例子（续）

对 spam 数据应用分类树方法：用偏差度量生长树、误分类率剪枝。图 9.4 显示 10 折交叉验证误差率随剪枝树大小的变化（ ± 2 标准误）；注意交叉验证误差由 α 值序列索引（不同折生长的树，同一 α 可能意味着不同大小）。误差在约 17 个终结点处变平（用「1 标准误」规则），得到剪枝树（图 9.5）。树选出的 13 个不同特征中有 11 个与加性模型的 16 个显著特征重叠（表 9.2）。总体误差率（表 9.3，9.3%）比加性模型（表 9.1，5.3%）约高 50%。

看图 9.5 最右分支：若 ch\$ 字符比例超过 5.5% 则有 spam 警告；但若 hp 短语频繁出现，则更像公司业务、判为 email（22 个满足条件的测试用例全部正确分类）；若第二个条件不满足且 CAPAVE（重复大写字母平均长度） > 2.9 ，判为 spam（227 个测试用例中仅 7 个误分类）。

医学中常用**灵敏度**（sensitivity）与**特异度**（specificity）刻画规则：灵敏度 = 真实有病时预测有病的概率；特异度 = 真实无病时预测无病的概率。把 spam/email 视为有病/无病，由表 9.3 得：

$$\text{灵敏度} = 100 \times \frac{33.4}{33.4 + 5.3} = 86.3\%, \quad \text{特异度} = 100 \times \frac{57.3}{57.3 + 4.0} = 93.4\%$$

ROC 曲线：通过改变损失 L_{01}, L_{10} 的相对大小可提高灵敏度/降低特异度（或反之）。本例要避免把好 email 标为 spam，故希望特异度很高——设 $L_{01} > 1, L_{10} = 1$ 实现。**ROC 曲线**是评估灵敏度与特异度权衡的常用总结：随分类规则参数变化，绘制灵敏度对特异度的曲线。对 17 节点树在 L_{01} 从 0.1 到 10 变化下应用贝叶斯规则，得到图 9.6 的 ROC 曲线；**曲线下面积（AUC）**约 0.95。GAM 模型（§9.1.2）的 ROC 曲线对任何损失都更好，AUC 0.98。用损失 $L_{01} = 5, L_{10} = 1$ 生长同大小树（观测加权），在高特异度处灵敏度更高——对这个应用明显优于原树。

c 统计量：AUC 有时称为 c 统计量。可证 AUC 等价于 **Mann–Whitney U 统计量**（或 Wilcoxon 秩和检验）关于两组预测分数中位数差异（Hanley and McNeil, 1982）。评估给标准模型增加一个预测变量的贡献时，c 统计量可能不是有信息量的度量：新预测变量在模型偏差变化上可能非常显著，但 c 统计量只增一点（如去掉显著的 george 项，c 统计量下降不到 0.01）。应检查新预测变量如何在单个样本基础上改变分类（Cook, 2007）。

17.3 PRIM: Bump Hunting (引入)

基于树的方法（回归）把特征空间划分为盒状区域，使每个盒内响应均值尽可能不同。§9.3 将介绍另一种互补方法 **PRIM**（患者规则归纳法，**Patient Rule Induction Method**），用于寻找特征空间中响应均值特别高的区域——「bump hunting（隆起搜寻）」。其细节将在后续阅读中补充。